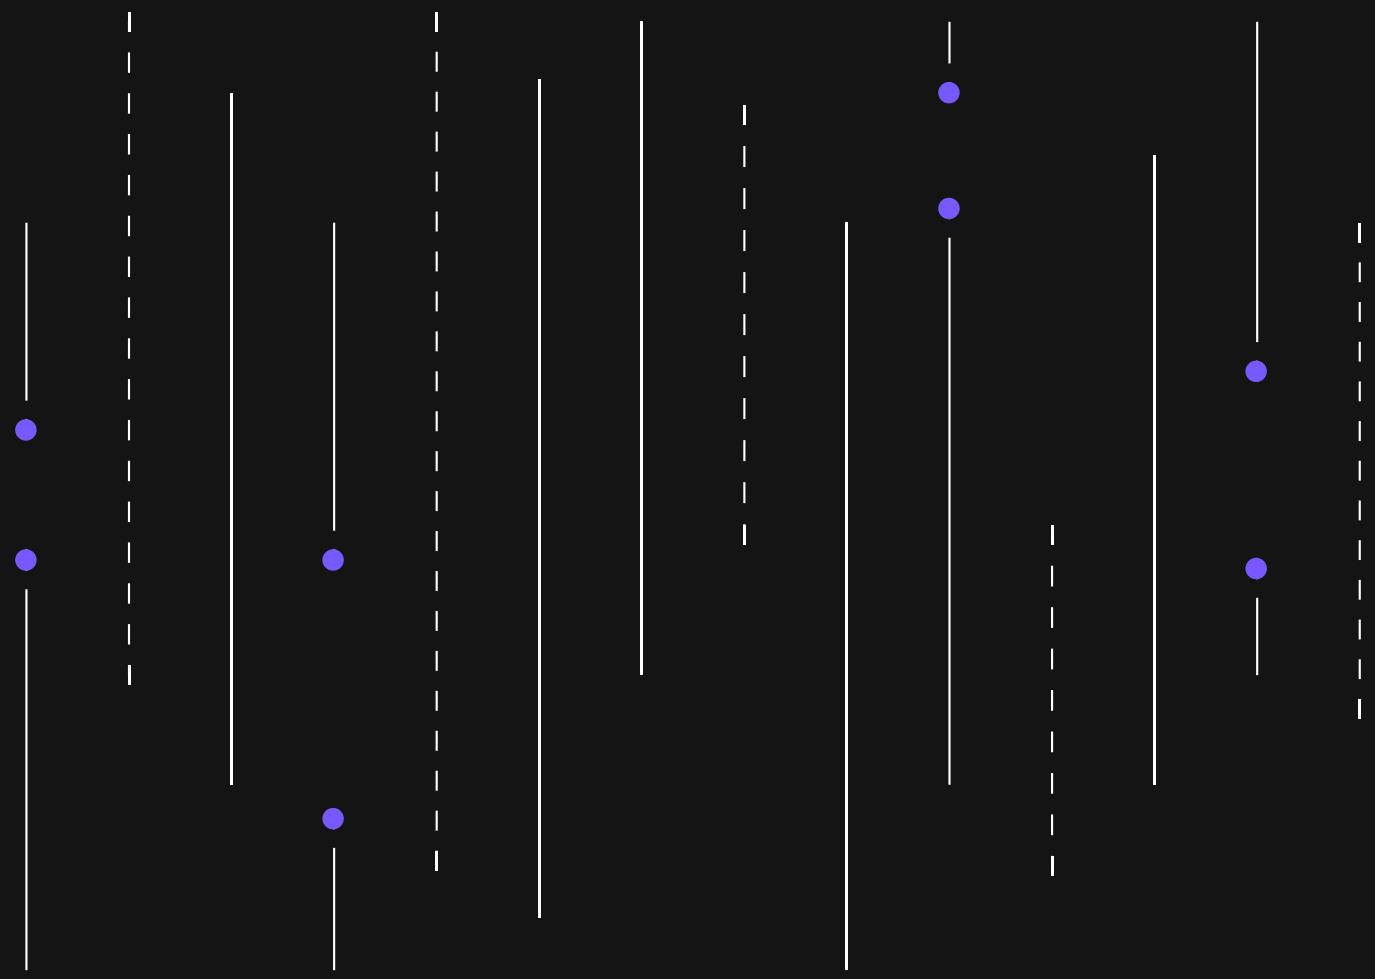
Машинное обучение | Лонгрид

Прикладная математика для машинного обучения | 06

Выпуклый анализ



Занятие 6. Выпуклый анализ

1. ВВЕДЕНИЕ

Контекст

В этой лекции мы изучим выпуклые множества и выпуклые функции, а также узнаем несколько способов, позволяющих проверить, что функция (или множество) действительно является выпуклой.

Применение

Обучение многих алгоритмов в ML сводится к задаче оптимизации, например к минимизации средней ошибки (MSE) на обучающей выборке. Особые свойства выпуклых функций делают их очень удобными для оптимизации, что обуславливает их использование в методах машинного обучения.

Краткий план

- Выпуклые множества
- Выпуклые функции
- Дифференциальные критерии выпуклости
- Применение в ML

2. ВЫПУКЛЫЕ МНОЖЕСТВА

Перед тем как переходить к функциям, дадим определение выпуклому множеству. Геометрически множество является **выпуклым**, если для любых двух точек отрезок, их соединяющий, целиком лежит внутри этого множества.

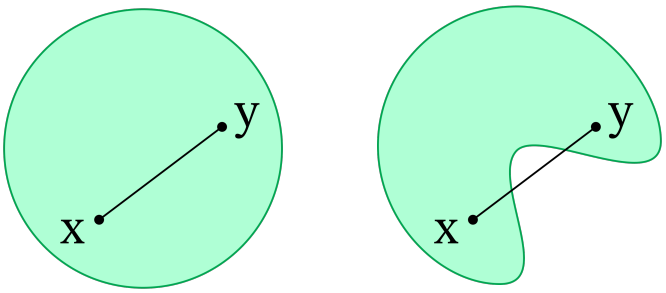


Рисунок 1. Иллюстрация к условию выпуклого множества. Слева: выпуклое множество. Справа: невыпуклое множество

Более формально это определение звучит так.

ОПРЕДЕЛЕНИЕ 1

Множество $Q \subseteq \mathbb{R}^n$ называется **выпуклым**, если для любых $x, y \in Q$ и любого $\alpha \in (0, 1)$

$$\alpha \times x + (1 - \alpha) \times y \in Q.$$

ЗАМЕЧАНИЕ

В определении выпуклого множества $\mathbb{R}^n$ можно заменить на произвольное линейное вещественное пространство.

ПРИМЕР 1

Рассмотрим примеры выпуклых множеств.

1. **Всё множество $\mathbb{R}^n$.**
2. **Пустое множество $\varnothing$.**
3. **Гиперплоскость**, т. е. множество вида $\{x \in \mathbb{R}^n \,:\, \langle a,\, x\rangle = b\}$.
4. **Полупространство**, т. е. множество вида $\{x \in \mathbb{R}^n \,:\, \langle a,\, x\rangle \leqslant b\}$.
5. **Полиэдр**, т. е. множество вида $\{x \in \mathbb{R}^n \,:\, Ax \preccurlyeq b, Cx = d\}$, где $A \in \mathbb{R}^{m\times n}$, $b \in \mathbb{R}^m$ и $C \in \mathbb{R}^{p\times n}$, $d \in \mathbb{R}^p$ (здесь символ $\preccurlyeq$ нужно понимать как поэлементное неравенство $\leqslant$).
6. В пространстве симметричных матриц $\mathbb{S}^n$ — множество **положительно полуопределённых матриц** $\mathbb{S}^n_+$. Напомним, что симметрическая матрица $A \in \mathbb{R}^{n\times n}$ называется **положительно полуопределённой** (или **неотрицательно определённой**), если $\forall\, x \in \mathbb{R}^n$, $x \neq \theta$, $\langle Ax,\, x\rangle \geqslant 0$.

ЗАМЕЧАНИЕ

Напомним, что положительная полуопределённость матрицы $A \in \mathbb{S}^n$ обозначается как

$$A \succeq 0.$$

Внимание! Не перепутай знак положительной полуопределённости $\succeq$ со знаком поэлементного меньше равно $\preccurlyeq$.

Ещё одним примером выпуклого множества является **шар**. Разбор этого примера можно найти в видеолекции «Выпуклость шара».

ИНСАЙТ

Рассмотрим особый случай полиэдра:

$$\Delta_n = \left\{ x \in \mathbb{R}^n \,:\, x \succcurlyeq 0,\, \sum_{i=1}^n x_i = 1 \right\}.$$

Это множество называется **симплексом** и довольно часто возникает в различных разделах математики, например в методах оптимизации и теории вероятностей.

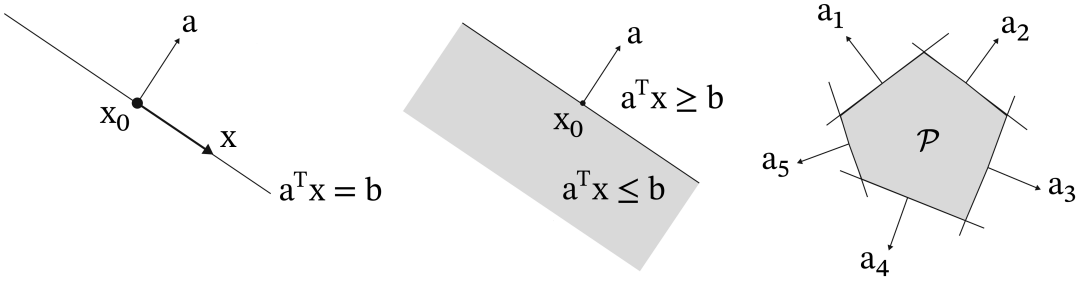


Рисунок 2. Иллюстрация к примерам. Слева направо: гиперплоскость, полупространство, полиэдр

ОПРЕДЕЛЕНИЕ 2

Функция $A : \mathbb{R}^n \to \mathbb{R}^m$ вида $A(x) = Lx + a$, где $L \in \mathbb{R}^{m\times n}$, $a \in \mathbb{R}^m$, называется **аффинным преобразованием**.

ПРАВИЛО 1

Следующие операции сохраняют выпуклость множеств.

1. **Пересечение.** Пусть I — произвольное (не обязательно конечное и не обязательно счётное) индексное множество и для каждого индекса $i \in I$ задано множество Q_i в пространстве $\mathbb{R}^n$. Если каждое из множеств Q_i для $i \in I$ является выпуклым, тогда и их пересечение

$$\bigcap_{i \in I} Q_i = \{x \,:\, x \in Q_i \,\forall\, i \in I\}$$

также является выпуклым множеством.

2. **Образ при аффинном преобразовании.** Пусть $A : \mathbb{R}^n \to \mathbb{R}^m$ — аффинное преобразование. Если множество Q является выпуклым, тогда и его образ при аффинном преобразовании A, т. е. множество

$$A(Q) = \{A(x) : x \in Q\}$$

является выпуклым.

3. **Прообраз при аффинном преобразовании.** Пусть $A : \mathbb{R}^n \to \mathbb{R}^m$ — аффинное преобразование. Если множество Q является выпуклым, тогда и его обратный образ при аффинном преобразовании A, т. е. множество

$$A^{-1}(Q) = \{x \in \mathbb{R}^n : A(x) \in Q\}$$

является выпуклым.

4. **Прямое произведение.** Пусть $Q_1 \in \mathbb{R}^{m_1}, \ldots, Q_n \in \mathbb{R}^{m_n}$. Если каждое из множеств $Q_1, \ldots, Q_n$ является выпуклым, тогда и их прямое (декартово) произведение

$$Q_1 \times \cdots \times Q_n = \{(x_1, \ldots, x_n) \,:\, x_1 \in Q_1, \ldots, x_n \in Q_n\}$$

является выпуклым.

5. **Линейная комбинация.** Пусть $Q_1, \ldots, Q_k$ — множества в пространстве $\mathbb{R}^n$. Пусть также $\alpha_1, \ldots, \alpha_k$ — скаляры (произвольного знака). Если каждое из множеств $Q_1, \ldots, Q_k$ является выпуклым, тогда и их линейная комбинация

$$\alpha_1 \times Q_1 + \cdots + \alpha_k \times Q_k = \left\{ \sum_{i=1}^{k} \alpha_i x_i \,:\, x_i \in Q_i \,\forall\, i, 1 \leqslant i \leqslant k \right\}$$

является выпуклой.

6. **Проекция.** Пусть Q — выпуклое множество в пространстве $\mathbb{R}^{m_1} \times \cdots \times \mathbb{R}^{m_n}$. Пусть также $1 \leqslant i \leqslant n$. Тогда проекция множества Q на i-ю ось, т. е. множество

$$\{x_i \in \mathbb{R}^{m_1} \ : \ (x_1, \ldots, x_{i-1}, x_i, x_{i+1}, \ldots, x_n) \in Q\}$$

является выпуклым.

ЗАМЕЧАНИЕ

В теореме пространство $\mathbb{R}^n$ можно заменить на произвольное линейное вещественное пространство.

Примеры того, как эти свойства помогают доказывать выпуклость множеств, можно найти в видеолекциях «Пересечение выпуклых множеств» и «Декартово произведение выпуклых множеств».

3. ВЫПУКЛЫЕ ФУНКЦИИ

ОПРЕДЕЛЕНИЕ 3

Функция $f : \mathbb{R}^\times \to \mathbb{R}$ называется **выпуклой** на *выпуклом множестве* $Q \subseteq \mathbb{R}^n$, если для любых $x, y \in Q$ и любого $\alpha \in (0, 1)$

$$f(\alpha x + (1 - \alpha)y) \leqslant \alpha f(x) + (1 - \alpha) f(y).$$

Функция $f : \mathbb{R}^\times \to \mathbb{R}$ называется **вогнутой** на *выпуклом множестве* $Q \subseteq \mathbb{R}^n$, если для любых $x, y \in Q$ и любого $\alpha \in (0, 1)$

$$f(\alpha x + (1 - \alpha)y) \geqslant \alpha f(x) + (1 - \alpha) f(y).$$

ЗАМЕЧАНИЕ

Выпуклость множества в определении выпуклой функции нужна, чтобы была возможность вычислить значение функции в любой точке на отрезке между двумя произвольными точками множества.

СЛЕДСТВИЕ

В случае функции одной переменной это определение означает, что график функции между двух произвольных точек лежит ниже хорды, соединяющей эти точки (см. рисунок ниже).

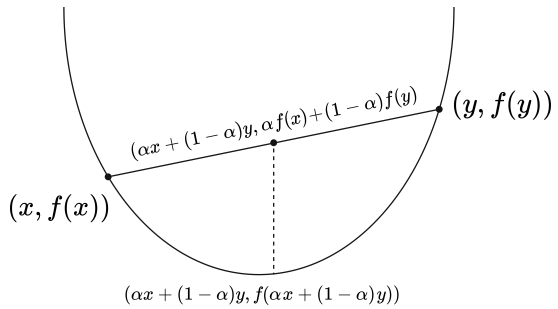


Рисунок 3. Иллюстрация к определению выпуклой функции. Хорда лежит целиком над графиком функции

ПРИМЕР 2

Функция $f(x) = x$, $x \in \mathbb{R}$, является **выпуклой** на всём множестве $\mathbb{R}$. Докажем это, используя определение. Пусть $\alpha \in [0, 1]$, $x,\ y \in \mathbb{R}$. Тогда

$$f(\alpha x + (1-\alpha)y) = \alpha x + (1-\alpha)y = \alpha f(x) + (1-\alpha)f(y).$$

Таким образом, $f(\alpha x + (1-\alpha)y) \leqslant \alpha f(x) + (1-\alpha)f(y)$, что и требовалось доказать.

ПРИМЕР 3

Функция $f(x) = x^2$, $x \in \mathbb{R}$, является **выпуклой** на всём множестве $\mathbb{R}$. Докажем это, используя определение. Пусть $\alpha \in [0, 1]$, $x,\ y \in \mathbb{R}$. Тогда

$$\begin{aligned} f(\alpha x + (1-\alpha)y) &= (\alpha x + (1-\alpha)y)^2 = \alpha^2 x^2 + 2\alpha(1-\alpha)xy + (1-\alpha)^2 y^2 = \\ &= \alpha^2 x^2 + 2\alpha(1-\alpha)xy + (1-\alpha)^2 y^2 + \alpha x^2 - \alpha x^2 + (1-\alpha)y^2 + (1-\alpha)y^2 = \\ &= \alpha(\alpha-1)x^2 - 2\alpha(\alpha-1)xy + \alpha(\alpha-1)y^2 + \alpha x^2 + \alpha y^2 = \\ &= \alpha(\alpha-1)(x-y)^2 + \alpha f(x) + (1-\alpha)f(y). \end{aligned}$$

Так как первое слагаемое всегда не больше нуля, то $f(\alpha x + (1-\alpha)y) \leqslant \alpha f(x) + (1-\alpha)f(y)$, что и требовалось доказать.

ОПРЕДЕЛЕНИЕ 4

Пусть Q — непустое множество в $\mathbb{R}^n$. **Надграфиком** функции $f : Q \to \mathbb{R}$ называется множество

$$Epi(f) = \{(x,\, t) \in Q \times \mathbb{R} \ :\ f(x) \leqslant t\}.$$

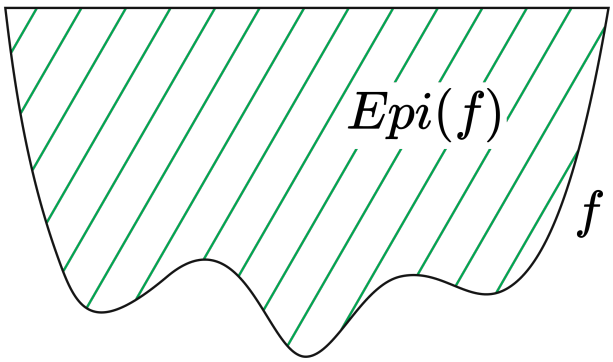


Рисунок 4. Иллюстрация к определению надграфика функции

Связь между выпуклостью множества и выпуклостью функции иллюстрирует следующая теорема.

ТЕОРЕМА 1

Пусть Q — непустое выпуклое множество в $\mathbb{R}^n$. Функция $f : Q \to \mathbb{R}$ является выпуклой тогда и только тогда, когда её надграфик $Epi(f)$ является выпуклым множеством в пространстве $\mathbb{R}^n \times \mathbb{R}$.

С помощью этой теоремы бывает удобно доказывать отдельные свойства выпуклых функций, а также выпуклость множеств, представляя их в виде надграфика выпуклой функции.

ПРАВИЛО 2

Чтобы доказать выпуклость функции, бывает полезно представить функцию в виде набора сохраняющих выпуклость операций над одной или несколькими выпуклыми функциями. Ниже приведён список таких операций.

1. Функция $g(x) = \sum_{i=1}^{k} c_i f_i(x)$ — выпуклая, если $c_1, \ldots, c_k$ — неотрицательные числа, а $f_1, \ldots, f_k$ — выпуклые функции.
2. Функция $g(x) = f(A(x))$ — выпуклая, если $f(x)$ — выпуклая функция, $A(x)$ — аффинное преобразование.
3. Функция $g(x) = \max_{i \in I} f_i(x)$ — выпуклая (I — произвольное множество индексов), если $f_i(x)$ — выпуклая функция при любом $i \in I$.
4. $g(x) = \phi(f_1(x), \ldots, f_k(x))$ — выпуклая, если $f_i(x)$ — выпуклая функция при $i = \overline{1,k}$, ϕ — выпуклая и **монотонно неубывающая**, т. е. $\phi(y) \leqslant \phi(y')$ для всех $y \preccurlyeq y$.
5. $g(x) = \min_{y \in \mathbb{R}^k} f(x, y)$ — выпуклая, если $f(x, y)$ — выпуклая функция (двух переменных).

Отметим, что все утверждения выше справедливы и для вогнутых функций (нужно лишь поменять $\leqslant$ на $\geqslant$, $\preccurlyeq$ на $\succcurlyeq$ и минимум на максимум).

ПРИМЕР 4

Рассмотрим пример, показывающий, что доказательство выпуклости функции часто удобнее осуществлять с помощью операций, сохраняющих выпуклость.

Пусть $a, b \in \mathbb{R}^k$, $c = (c_1, \ldots, c_k) \in \mathbb{R}^k$, $c_i \geqslant 0$, при $i = \overline{1,k}$.

Функция $f(x) = \sum_{i=1}^{k} c_i e^{(\langle a, x \rangle + b_i)}$ является выпуклой как взвешенная сумма экспонент с аффинной подстановкой аргумента.

Ещё пример доказательства выпуклости функции с помощью декомпозиции на более простые функции можно найти в видеолекции «Максимум выпуклой функции».

В различных разделах математики бывает полезным следующее неравенство.

ТЕОРЕМА 2

Пусть $Q \subseteq \mathbb{R}^n$, $n \geqslant 1$, непустое выпуклое множество $f : Q \to \mathbb{R}$ — выпуклая функция. Пусть также $x_1, \ldots, x_k$ — точки во множестве Q и $\alpha_1, \ldots, \alpha_k$ — неотрицательные коэффициенты, суммирующиеся в единицу: $\alpha_i \geqslant 0$ и $\sum_{i=1}^{k} \alpha_i = 1$. Тогда справедливо следующее неравенство:

$$\sum_{i=1}^{k} \alpha_i f(x_i) \geqslant f\left(\sum_{i=1}^{k} \alpha_i x_i\right).$$

Это неравенство называется **неравенством Йенсена**

ЗАМЕЧАНИЕ

Для вогнутой функции f неравенство Йенсена принимает вид

$$\sum_{i=1}^{k} \alpha_i f(x_i) \leqslant f\left(\sum_{i=1}^{k} \alpha_i x_i\right).$$

Доказательство неравенства Йенсена можно найти в видеолекции «Неравенство Йенсена».

4. ДИФФЕРЕНЦИАЛЬНЫЕ КРИТЕРИИ ВЫПУКЛОСТИ

Для дифференцируемых функций существуют специальные критерии выпуклости, которые в ряде ситуаций удобнее, чем проверка выпуклости по определению или через операции, сохраняющие выпуклость.

ТЕОРЕМА 3

Пусть $f(x)$ определена на всём множестве $\mathbb{R}^n$ и всюду дифференцируема. Тогда $f(x)$ выпукла на множестве $\mathbb{R}^n$ тогда и только тогда, когда для любых $x, y \in \mathbb{R}^n$

$$f(y) \geqslant f(x) + \langle \nabla f(x), y - x \rangle.$$

СЛЕДСТВИЕ

В случае функции одной переменной это означает, что график выпуклой функции лежит целиком выше касательной, проведённой к функции в произвольной точке (см. рисунок).

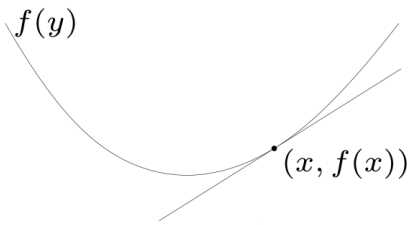


Рисунок 5. Иллюстрация к условию выпуклости первого порядка. График функции лежит всюду выше касательной, проведенной к графику в любой точке x

ПРИМЕР 5

Рассмотрим функцию $f(x) = \langle c,\, x \rangle$, $c,\, x \in \mathbb{R}^n$. Докажем выпуклость функции $f(x)$, используя дифференциальный критерий выпуклости. Вспомним, что градиент функции f в точке x равняется

$$\nabla f(x) = c.$$

Пусть $y \in \mathbb{R}^n$.

$$f(y) = \langle c,\, y \rangle = \langle c,\, y \rangle + \langle c,\, x \rangle - \langle c,\, x \rangle = \langle c,\, x \rangle + \langle c,\, y - x \rangle = \langle c,\, x \rangle + \langle \nabla f(x),\, y - x \rangle,$$

что и требовалось доказать!

ТЕОРЕМА 4

Пусть $f(x)$ определена на всём множестве $\mathbb{R}^n$, а также всюду дважды дифференцируема. В таком случае $f(x)$ выпукла тогда и только тогда, когда $H(f) \succeq 0$ в любой точке $x \in \mathbb{R}^n$.

ПРИМЕР 6

Рассмотрим функцию $f(x) = \langle c,\, x \rangle$, $c,\, x \in \mathbb{R}^n$. Докажем выпуклость функции $f(x)$, используя дифференциальный критерий выпуклости через матрицу Гессе. Вспомним, что матрица Гессе функции f в точке x равняется

$$\nabla f(x) = \mathcal{O}_{n \times n}.$$

Докажем положительную полуопределённость функции $\mathbb{O}_{n\times n}$. Пусть $h \in \mathbb{R}^n$, $h \neq \theta$.

$$\langle \mathbb{O}_{n\times n} h,\, h\rangle = \langle \theta,\, h\rangle = 0,$$

что и требовалось доказать!

Больше примеров доказательства выпуклости функции с помощью дифференциального критерия можно найти в видеолекции «Критерий выпуклости функций».

ОПРЕДЕЛЕНИЕ 5

Точка $x^* \in \mathbb{R}^n$ называется **точкой стационарности** дифференцируемой функции $f : \mathbb{R}^n \to \mathbb{R}$, если $\nabla f(x^*) = \theta$.

ПРИМЕР 7

Рассмотрим функцию $f(x_1,\, x_2) = x_1^2 - x_2^2$. Найдём градиент функции f в точке $x = \theta$.

$$\frac{\partial f}{\partial x_1} = 2x_1,$$
$$\frac{\partial f}{\partial x_2} = -2x_2.$$

$\nabla f(\theta) = (0, 0) = \theta$. Таким образом, точка θ является точкой стационарности функции f.

Покажем, что точка θ не является локальным экстремумом функции f. Рассмотрим произвольное $\varepsilon > 0$, $x_{\varepsilon+} = (\varepsilon,\, 0)$, $x_{\varepsilon-} = (0,\, \varepsilon)$. Для любого наперёд загаданного $\delta > 0$ найдётся такое $\varepsilon = \frac{\delta}{2}$, что точки $x_{\varepsilon+} = (\varepsilon,\, 0)$, $x_{\varepsilon-}$ будут лежать в δ-окрестности точки θ. При этом

$$f(\theta) = 0,$$
$$f(x_{\varepsilon+}) = \varepsilon^2 > 0,$$
$$f(x_{\varepsilon-}) = -\varepsilon^2 < 0.$$

Таким образом, ни в какой окрестности точки θ значение функции $f(\theta)$ не является ни максимальным, ни минимальным. Следовательно, точка θ хоть и стационарная, но не является локальным экстремумом функции f.

ОПРЕДЕЛЕНИЕ 6

Точка $x^* \in \mathbb{R}^n$ называется **седловой точкой** дифференцируемой функции $f : \mathbb{R}^n \to \mathbb{R}$, если x^* является стационарной точкой функции f, но не является локальным экстремумом функции f.

Из-за существования седловых точек бывает неудобно использовать градиент для поиска экстремумов функции. В следующем разделе мы узнаем, что выпуклые функции лишены такой проблемы.

5. ПРИМЕНЕНИЕ В ML

В машинном обучении нам часто приходится искать минимум функции, поскольку модели, как правило, настраиваются из соображений минимизации средней ошибки на обучающей выборке.

Предположим, что у выпуклой дифференцируемой функции f есть **точка стационарности** x^*. Тогда, согласно критерию выпуклости,

$$f(x) \geqslant f(x^*) + \langle \nabla_x f(x^*), x - x^* \rangle = f(x^*).$$

Отсюда следует, если градиент выпуклой функции $f(x)$ равен нулю в точке x^*, то x^* — **глобальный минимум** функции $f(x)$ (то есть наименьшее значение функции на множестве $\mathbb{R}^n$).

Это свойство выпуклых функций делает их очень удобными для оптимизации, что обуславливает их использование в машинном обучении.

На прошлой неделе мы рассматривали функцию потерь для линейной модели (линейную регрессию), где переменными выступают веса модели w:

$$L(w) = \sum_{i=1}^{N} (y_i - \langle x_i,\, w \rangle)^2 + \lambda \sum_{j=1}^{M} w_j^2.$$

Мы остановились на том, что приравнивание частных производных к нулю $\frac{\partial L}{\partial w_k} = 0$ порождает огромную систему уравнений. И мы задались вопросом: *откуда нам знать, что решив её, мы найдем именно минимум, а не максимум или седловую точку?*

На основе материалов текущей недели можно легко показать, что эта функция выпуклая. Мы проделаем это доказательство на лекции.

Это значит, что та пугающая система уравнений из прошлой лекции описывает точку не глобального минимума, а никаких локальных минимумов или седловых точек у этой функции нет.

На следующей неделе мы соберём воедино все знания: с помощью векторных производных мы решим эту систему уравнений ровно в одну строчку, получив искомые веса w^* без единого цикла for!

6. КРАТКО

- **Выпуклые множества** — множества, для которых отрезок, соединяющий любые две точки множества, целиком принадлежит этому множеству.
- **Операции, сохраняющие выпуклость множества**, позволяют быстро доказать выпуклость множества.
- **Выпуклые функции** — это функции, надграфик которых является выпуклым множеством.
- **Операции, сохраняющие выпуклость функции**, позволяют быстро доказать выпуклость функции.
- С помощью **дифференциальных критериев выпуклости** мы можем проверить выпуклость дифференцируемых функций.
- У **выпуклых функций** стационарная точка является **глобальным минимумом**, благодаря чему их часто используют в ML.

7. ПОЛЕЗНЫЕ ССЫЛКИ

- Pryce J. D. Convex Analysis. Proceedings of the Edinburgh Mathematical Society, 2009.

  Это классический труд, который считается фундаментальным руководством по выпуклому анализу. Книга охватывает широкий спектр тем, включая выпуклые функции, множества и их свойства, а также приложения в оптимизации.
- Потапов М. М., Буряков М. Л., Методы оптимизации. Конспект лекций. М.: МГУ, 2023.

  Конспект лекций по курсу методов оптимизации, который читается на факультете ВМК МГУ. Один из разделов курса посвящён выпуклому анализу, там освещаются основные интересующие нас темы.