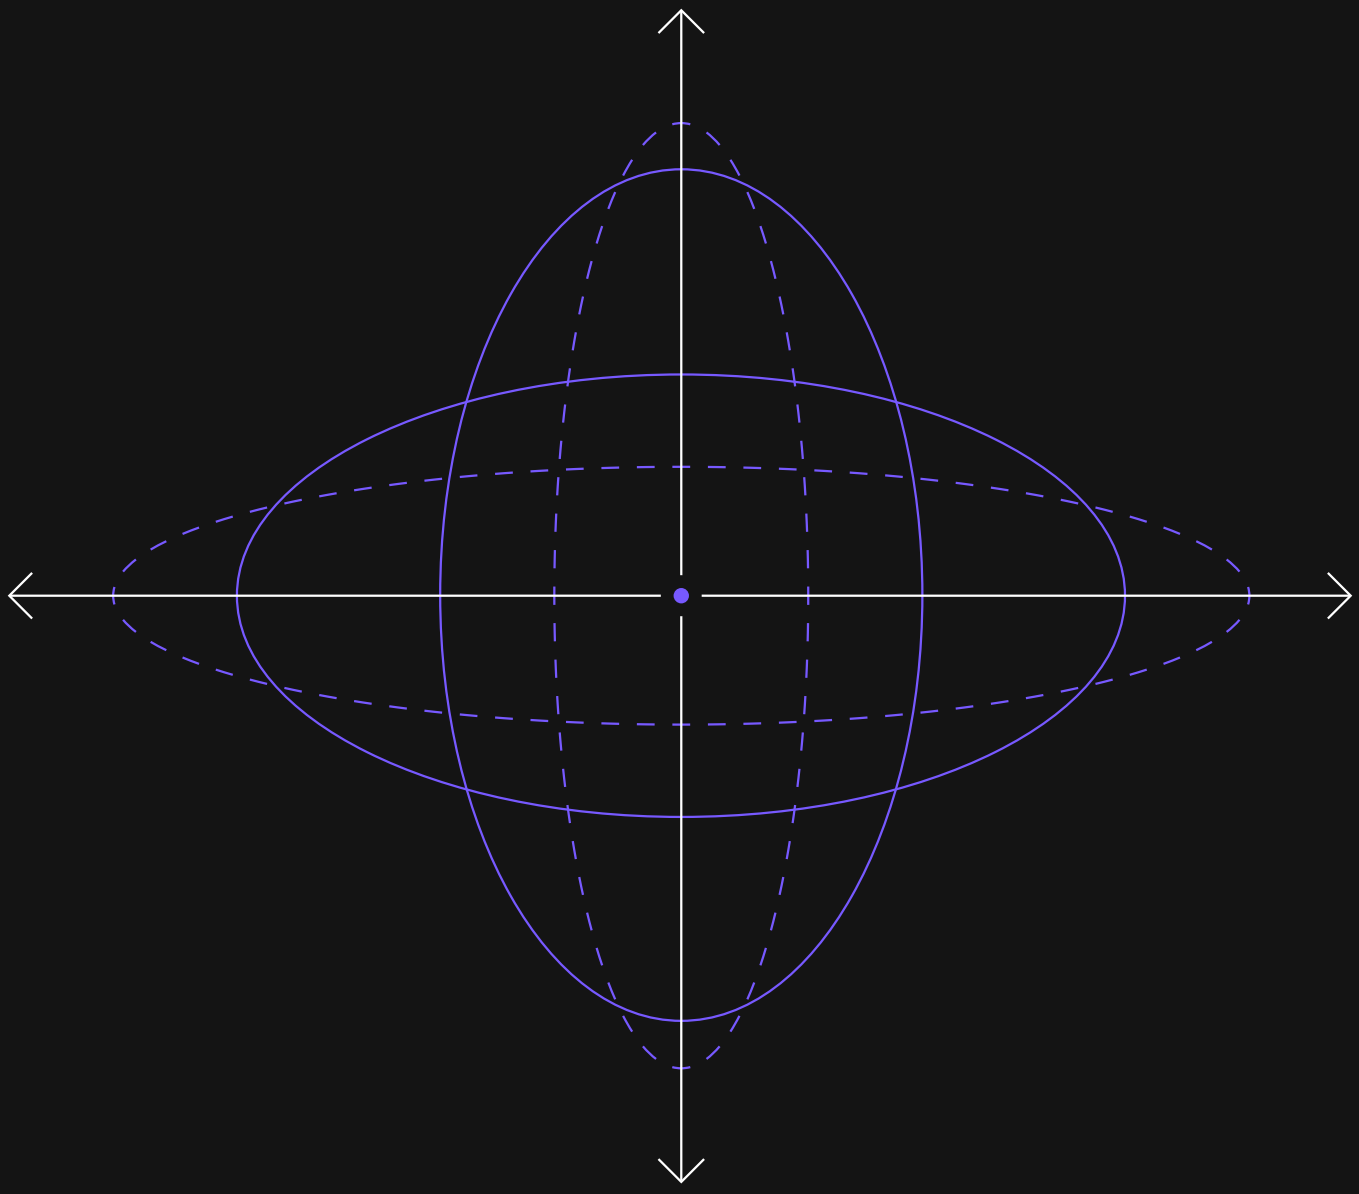
Дифференциал



Занятие 7. Дифференциал

Контекст

В этом материале мы изучим новый способ вычисления градиента и матрицы Гессе функции векторного аргумента. А также на примерах убедимся, что в ряде ситуаций этот способ намного удобнее, чем через частные производные.

Применение

Для обучения многих алгоритмов в ML (в том числе нейронных сетей) используются методы, основанные на вычислении первой или второй производных функции. Поэтому важно понимать, как эффективно считать производные (не только скалярные, но также «векторные» и «матричные»), для лучшего понимания работы этих алгоритмов.

Краткий план

- Вычисление векторной производной по определению
- Дифференциал
- Вычисления с помощью дифференциала
- Свойства дифференциала
- Вычисление второй производной

1. ВЫЧИСЛЕНИЕ ВЕКТОРНОЙ ПРОИЗВОДНОЙ ПО ОПРЕДЕЛЕНИЮ

В прошлых материалах мы разобрались, что такое частная производная, градиент и матрица Гессе, а также научились считать градиент и матрицу Гессе через подсчёт частных производных.

На этом занятии мы узнаем ещё один способ вычисления векторной производной, который во многом удобнее, чем вычисление частных производных.

Напомним, что приращение функции $f(x) : \mathbb{R}^n \to \mathbb{R}$ в точке $x = (x_1, x_2, \ldots, x_n) \in \mathbb{R}^n$ обозначается как $\Delta f = f(x_1 + \Delta x_1, x_2 + \Delta x_2, \ldots, x_n + \Delta x_n) - f(x_1, x_2, \ldots, x_n) = f(x + \Delta x) - f(x)$.

Если f — дифференцируемая функция, то (как мы знаем из прошлых материалов) её приращение можно представить в виде:

$$\Delta f = a_1 \Delta x_1 + a_2 \Delta x_2 + \cdots + a_n \Delta x_n + o\left(\|\Delta x\|\right),$$

где a_1, a_2, ..., a_n — некоторые числа, которые равны значению соответствующей частной производной функции f в точке x.

Если обозначить $a = (a_1, \ldots, a_n) \in \mathbb{R}^n$, $h = \Delta x \in \mathbb{R}^n$, то приращение функции можно переписать в виде:

$$f(x + h) - f(x) = \langle a, h \rangle + o\left(||h||\right). \tag{1}$$

Здесь вектор a состоит из частных производных $\frac{\partial f}{\partial x_i}$, то есть является по определению градиентом. Следовательно:

$$f(x+h) - f(x) = \langle \nabla_x f, h \rangle + o\left(||h||\right).$$

Таким образом, для вычисления производной достаточно представить приращение функции в виде 1, и вектор a будет искомым градиентом.

Аналогичный трюк можно проделать с матрицей Гессе. Для этого представим **приращение градиента** в виде:

$$\nabla f(x+h) - \nabla f(x) = \nabla^2 f(x)h + \alpha(h),$$

где $\alpha : \mathbb{R}^n \to \mathbb{R}^n$ (вектор-функция) и $\frac{\|\alpha(h)\|}{\|h\|} \to 0$, $||h|| \to 0$, $\nabla^2 f(x)$ — матрица Гессе размера $n \times n$.

ИНСАЙТ

Если мы сможем представить приращение функции в виде **скалярного произведения** и остатка, то сможем найти её градиент. Аналогичным образом можно будет искать и матрицу Гессе.

Рассмотрим это на примере.

ПРИМЕР 1

$f(x) = \langle c, x \rangle, c \in \mathbb{R}^n$ — константный вектор, $x \in \mathbb{R}^n$.

Найти новым способом градиент и матрицу Гессе функции f.

Посчитаем градиент:

$$f(x+h) - f(x) = \langle c, x+h \rangle - \langle c, x \rangle = \langle c, x+h-x \rangle = \langle c, h \rangle + 0.$$

Получили, что $o(||h||) = 0$, а $\langle \nabla f(x), h \rangle = \langle c, h \rangle$. Поэтому градиент функции f равен:

$$\nabla f(x) = c.$$

Посчитаем матрицу Гессе:

$$\nabla f(x+h) - \nabla f(x) = c - c = O_{n \times n} h + \theta.$$

Получили, что $\alpha(h) = \theta$.

Таким образом, матрица Гессе функции f имеет вид:

$$\nabla^2 f = O_{n \times n}$$

В некоторых случаях считать градиент и матрицу Гессе по векторному определению получается гораздо проще, чем делать это через частные производные. Оказывается, что можно пойти ещё дальше

и обобщить такой способ подсчёта через введение определения дифференциала, о котором речь пойдёт в следующей главе.

2. ДИФФЕРЕНЦИАЛ

В этой главе мы введём понятие дифференциала в самом общем случае и рассмотрим, как с его помощью вычислять производные для функций вида $f : \mathbb{R}^n \to \mathbb{R}$ и $f : \mathbb{R}^{n\times m} \to \mathbb{R}$.

Попробуем сформулировать это понятие дифференцируемости в более общем виде. Для этого введём определение линейного оператора.

ОПРЕДЕЛЕНИЕ 1

Пусть U и V — евклидовы пространства. **Линейным оператором** называется отображение $L : U \to V$, обладающее следующими свойствами.

1. $L(\alpha x) = \alpha L(x), \forall\, \alpha \in \mathbb{R}, \forall\, x \in U.$
2. $L(x + y) = L(x) + L(y), \forall\, x, y \in U.$

Основная идея **дифференцируемости** в том, чтобы аппроксимировать (приблизить) функцию в окрестности точки **линейной функцией**. В случае произвольных линейных векторных пространств мы будем приближать функцию в окрестности точки **линейным оператором**.

ОПРЕДЕЛЕНИЕ 2

Пусть $f : U \to V$, где U и V — конечномерные евклидовы пространства с нормой, порождённой скалярным произведением. Тогда функция f является **дифференцируемой в точке** $x \in U$ **с производной** L_x, если для малых приращений $h \in U$ справедливо следующее представление:

$$f(x + h) - f(x) = L_x(h) + o(||h||),$$

где $L_x : U \to V$ — линейный оператор, который может быть разным в зависимости от точки x.

ОПРЕДЕЛЕНИЕ 3

$L_x(h)$ называется **дифференциалом** функции f в точке x с приращением h. Также в литературе может встречаться эквивалентное название: **касательное отображение.**

Обозначения. Все нижеприведённые обозначения эквивалентны и могут встречаться в различной литературе:

$$L_x(h) \equiv Df(x)[h] \equiv df(x)[h] \equiv L(x)[h] \equiv L[h]$$

Часто могут встречаться записи, где приращение h или x пропускают:

$$df(x) \equiv Df(x) \equiv df$$

Также h обозначают как dx:

$$h \equiv dx$$

Мы же будем пользоваться записями $Df(x)[h]$, $df(x)$, dx и h.

В случае $f : \mathbb{R} \to \mathbb{R}$ получаем привычную нам запись производной одномерной функции f :

$f'(x) = \dfrac{df(x)}{dx}$, так как
$f(x+h) - f(x) = f'(x)h + o(h) = f'(x)dx + o(h) = df(x) + o(h)$

В случае $f : \mathbb{R}^n \to \mathbb{R}$ получаем возможность вычислить градиент через представление, разобранное на предыдущем материале и в начале этого:

$$df(x) = \langle \nabla_x f(x), dx \rangle$$

Остальные случаи более подробно разберём далее.

3. ВЫЧИСЛЕНИЯ С ПОМОЩЬЮ ДИФФЕРЕНЦИАЛА

ИНСАЙТ

Важным свойством дифференциала является то, что не нужно задумываться, какой он размерности.

Дифференциал по определению лежит в том же пространстве, где лежат значения функции: если $f(x) : X \to V$, то $Df(x)[h] \in V$. В частности, это означает следующее:

- если значения функции — это числа $(\mathbb{R})$, то и дифференциал будет числом (и неважно, что будет аргументом функции: число, вектор, матрица или тензор);
- если результатом применения функции будет вектор $(\mathbb{R}^n)$, то и дифференциал будет вектором. И так далее.

Именно поэтому считать дифференциалы зачастую бывает проще, чем напрямую пытаться вычислить градиент. Шпаргалку по формам дифференциала в различных пространствах ты найдёшь в таблице ниже.

Выход, $f(x)$ / **Вход,** x	$\mathbb{R}$ **(скаляр)**	$\mathbb{R}^n$ **(вектор)**
$\mathbb{R}$ **(скаляр)**	$f'(x)dx$ $f'(x)$ — производная (скаляр), dx — скаляр	—
$\mathbb{R}^n$ **(вектор)**	$\langle \nabla f(x), dx \rangle$ $\nabla f(x)$ — градиент (вектор), dx — вектор	$J_f(x)dx$ $J_f(x)$ — матрица Якоби[1], dx — вектор
$\mathbb{R}^{n\times m}$ **(матрица)**	$\langle \nabla f(X), dX \rangle$ $\nabla f(X)$ — градиент (матрица), dX — матрица[2]	—

Таблица 1. Формы дифференциала $df(x)$ для различных функций. Случаи " — " оставим за рамками этого курса

Алгоритм вычисления производной/градиента через дифференциал

1. Вычислить дифференциал $Df(x)[h]$ функции f.
2. По табличке понять, какой вид должен принимать дифференциал функции f.
3. Привести дифференциал $Df(x)[h]$ к этому виду.
4. Посчитать нужную производную, исходя из этого вида.

4. СВОЙСТВА ДИФФЕРЕНЦИАЛА

При вычислении одномерной производной пользуются общими правилами их преобразований (например, $(f+g)' = f' + g'$. По аналогии с ними есть и общие правила преобразований дифференциалов. Они позволяют выражать сложные функции через последовательность простых преобразований, для которых известно, как считать дифференциал.

ТЕОРЕМА 1

На самом деле аналогичные правила также применимы, если a, b — матрицы, а $f(x)$ — матричная функция.

Правила преобразования дифференциала

- $d(a) = \theta$
- $d(\alpha f(x)) = \alpha df(x)$
- $d(af(x)b) = a(df(x))b$
- $d(f(x) + g(x)) = df(x) + dg(x)$
- $d(f(x)^T) = (df(x))^T$
- $d(f(x)g(x)) = (df(x))g(x) + f(x)dg(x)$
- $d\langle f(x), g(x)\rangle = \langle df(x), g(x)\rangle + \langle f(x), dg(x)\rangle$
- $d\left(\dfrac{f(x)}{\phi(x)}\right) = \dfrac{\phi(x)df(x) - (d\phi(x))f(x)}{\phi(x)^2}$,

где a, b — фиксированные векторы, α — фиксированный скаляр, $f(x), g(x)$ — *произвольные дифференцируемые векторные функции из* $\mathbb{R}^n$ *в* $\mathbb{R}^n$, $\phi(x) : \mathbb{R}^n \to \mathbb{R}$ — произвольная дифференцируемая скалярная функция. Во всех случаях предполагаем согласованность по размерностям.

[1] Пройдём в дальнейших материалах.

[2] Напоминаем, что скалярное произведение в пространстве матриц можно определить, например, как $\langle A, B\rangle = tr(B^T A)$.

ИНСАЙТ

Заметим, что правила даны в общем виде для векторных функций. Это означает, что функции $f(x), g(x)$ могут быть как и одномерными (в случае $n = 1$, $\mathbb{R}^1$), так и векторными. И это ещё одно очень важное свойство дифференциала — не нужно думать, какого вида у нас функции, **достаточно только знать правила преобразования.**

УПРАЖНЕНИЕ

Можешь предположить, что $f(x), g(x)$ — это одномерные функции ($\mathbb{R}$ в $\mathbb{R}$), и проверить, что правила действительно сводятся к аналогичным из прошлых материалов.

ТЕОРЕМА 2

Формула полного дифференциала

Пусть функция $f(x_1, x_2, \ldots, x_n)$ дифференцируема в точке $M(x_1, x_2, \ldots, x_n) \in \mathbb{R}^n$. Тогда её **полный дифференциал** выражается формулой:

$$df = \frac{\partial f}{\partial x_1}dx_1 + \frac{\partial f}{\partial x_2}dx_2 + \cdots + \frac{\partial f}{\partial x_n}dx_n.$$

Или:

$$df = \sum_{i=1}^{n} \frac{\partial f}{\partial x_i}dx_i.$$

- df — полный дифференциал функции f;
- $\frac{\partial f}{\partial x_i}$ — частная производная функции f по переменной x_i;
- dx_i — дифференциал соответствующей переменной x_i.

ИНСАЙТ

Из данного представления полного дифференциала в случае одномерных аргументов ($x_i \in \mathbb{R}$) можно вывести разложение и в более общем случае. Например, если

$$z = f(x, y), x, y \in \mathbb{R}^n, z \in \mathbb{R},$$

то $dz = df(x, y) = \langle \nabla_x f(x, y), dx \rangle + \langle \nabla_y f(x, y), dy \rangle$.

ПРИМЕР 2

Найти дифференциал функции $f(x) = x, \quad f(x) : \mathbb{R}^n \to \mathbb{R}^n$

$$f(x + h) - f(x) = x + h - x = h + \theta = Df(x)[h] + o(||h||) \Rightarrow$$
$$Df(x)[h] = Dx[h] = h = dx$$

Это означает, что если мы где-либо в вычислениях получаем выражение вида $Dx[h]$, то можем его сразу заменять на h или dx.

Аналогичная замена верна для любого вида функции, не обязательно только для функций вида $f(x) : \mathbb{R}^n \to \mathbb{R}^n$.

ПРИМЕР 3

Найти градиент функции $f(x) = \langle c, x \rangle, c \in \mathbb{R}^n$ — константный вектор, $x \in \mathbb{R}^n$ с помощью дифференциала.

Рассмотрим решение через две формы записи: $df(x)$ и $Df(x)[h]$.

Если записывать через $df(x)$:

$$df(x) = d(\langle c, x\rangle) = \langle d(c), x\rangle + \langle c, dx\rangle = \\ = \langle \theta, x\rangle + \langle c, dx\rangle \Rightarrow \nabla f(x) = c.$$

Через $Df(x)[h]$:

$$Df(x)[h] = D(\langle c, x\rangle)[h] = \langle D(c)[h], x\rangle + \langle c, Dx[h]\rangle = \\ = \langle \theta, x\rangle + \langle c, h\rangle = \langle c, h\rangle \Rightarrow \nabla f(x) = c.$$

Как и в одномерном случае, дифференциал композиции функций вычисляют по определённому правилу.

ТЕОРЕМА 3

Дифференциал сложной функции (композиции функций).

Пусть $g(y)$ и $f(x)$ — две дифференцируемые функции, $y = f(x)$, и мы знаем выражения для их дифференциалов: $dg(y)$ и $df(x)$. Чтобы посчитать дифференциал композиции функций $\phi(x) = g(f(x))$ нужно:

- взять выражение посчитанного дифференциала $dg(y)$. Отметим, что формально его можно записать как и $Dg(y)[dy]$, то есть в записи дифференциала содержится dy.
- подставить в него **формально**:
  - вместо y — значение $f(x)$;
  - вместо dy — значение $df(x)$.

ПРИМЕР 4

Найти градиент функции $\phi(x) = \sqrt{\langle c, x\rangle}, c \in \mathbb{R}^n$— константный вектор, $x \in \mathbb{R}^n$ с помощью дифференциала.

Разобьём данную функцию на композицию двух:

$$f(x) = \langle c, x\rangle, \quad \mathbb{R}^n \to \mathbb{R} \\ g(y) = \sqrt{y}, \quad \mathbb{R} \to \mathbb{R}$$

Вычислим дифференциал функции $g(y)$. Это одномерная скалярная функция, поэтому вычисляется по привычному нам правилу:

$$dg(y) = \frac{1}{\sqrt{y}} dy.$$

Значение для $df(x)$ мы уже посчитали выше:

$$df(x) = \langle c, dx\rangle.$$

Склеиваем всё вместе:

$$dg(y) = \frac{1}{y}dy = \frac{1}{\sqrt{\langle c, x\rangle}}\langle c, dx\rangle = \left\langle \frac{c}{\sqrt{\langle c, x\rangle}}, dx \right\rangle \Rightarrow \nabla\phi(x) = \frac{c}{\sqrt{\langle c, x\rangle}}.$$

В нотации $D\phi(x)[h]$ это выглядело бы так:

$$D\phi(x)[h] = \left\langle \frac{c}{\sqrt{\langle c, x\rangle}}, h \right\rangle.$$

5. ВЫЧИСЛЕНИЕ ВТОРОЙ ПРОИЗВОДНОЙ

Как и прежде, введём понятие производной высшего порядка в общем виде.

ОПРЕДЕЛЕНИЕ 4

Пусть $f : X \to V$, где $X \subseteq U$ — некоторая функция, действующая из подмножества одного конечномерного линейного пространства в другое. Пусть она дифференцируема и её дифференциал равен $Df(x)[h]$.

Рассмотрим новую функцию $g(x) = Df(x)[h_1]$ — зафиксировав приращение h равным некоторому h_1. При этом функция $g(x)$ становится функцией одного аргумента x и действует из X в V: $g(x) : X \to V$.

Если для функции g в точке x существует производная, то она называется **второй производной функции** f, обозначается как:

$$D^2f(x)[h_1, h_2] = Dg(x)[h_2],$$

и вычисляется подсчётом дифференциала функции $g(x)$. Причём во второй производной h_1 снова можно будет менять. По аналогии мы можем определить дифференциалы более высоких порядков.

ТЕОРЕМА 4

Форма второй производной для функций $f(x) : \mathbb{R}^n \to \mathbb{R}$

Для таких функций дифференциал представим в виде:

$$D^2f(x)[h_1, h_2] = \langle \nabla^2 f(x)h_1, h_2\rangle;$$
$$d^2f(x) = \langle \nabla^2 f(x)dx_1, dx_2\rangle.$$

ИНСАЙТ

На самом деле можно доказать, что ввиду дифференцируемости функции можно приводить дифференциал и к виду:

$$D^2f(x)[h_1, h_2] = \langle \nabla^2 f(x) h_2, h_1 \rangle,$$

то есть без разницы, в каком порядке мы берём приращения.

Исходя из этого вида теперь можно считать матрицу Гессе с помощью дифференциалов.

ТЕОРЕМА 5

Алгоритм вычисления второй производной

- Вычислить значения дифференциала $Df(x)[h]$ для функции $f(x)$.
- Найти в этом выражении h. Зафиксировать его и формально переобозначить: $h_1 = h$.
- Вычислить дифференциал для функции $Df(x)[h_1]$, считая h_1 константой.
- Новое приращение, которое считаем на предыдущем шаге, обозначаем через h_2, чтобы не запутаться с h_1.

ПРИМЕР 5

Посчитать матрицу Гессе функции $f(x) = \langle c, x \rangle, c \in \mathbb{R}^n$— константный вектор, $x \in \mathbb{R}^n$ с помощью дифференциала.

Решим сначала этот пример с помощью записи $Df(x)[h]$, чтобы не потерять нигде приращений.

$Df(x)[h]$ мы уже посчитали выше:

$$Df(x)[h] = \langle c, h \rangle.$$

Теперь нужно посчитать дифференциал для функции $Df(x)[h_1]$ при фиксированном h_1:

$$\begin{aligned} D(Df(x)[h_1])[h_2] = D(\langle c, h_1 \rangle)[h_2] = \langle D(c)[h_2], h_1 \rangle + \langle c, D(h_1)[h_2] \rangle \\ = \langle \theta, h_1 \rangle + \langle c, \theta \rangle = 0 + 0 = \langle \theta, h_2 \rangle = \langle O_{n \times n} h_1, h_2 \rangle \Rightarrow \\ \Rightarrow \nabla^2 f(x) = O_{n \times n} \end{aligned}$$

В терминах $df(x)$ это вычислялось бы аналогично (с заменой $dx_1 = h_1$ и $dx_2 = h_2$):

$$\begin{aligned} df(x) = \langle c, dx \rangle \\ d(df(x)) = d(\langle c, dx_1 \rangle) = \langle dc, dx_1 \rangle + \langle c, d(dx_1) \rangle = \langle \theta, dx_1 \rangle + \langle c, \theta \rangle = \\ = 0 = \langle O_{n \times n} dx_1, dx_2 \rangle \Rightarrow \nabla^2 f(x) = O_{n \times n} \end{aligned}$$

6. КРАТКО

- **Дифференциал функции** $f(x)$ — линейный оператор $Df(x)[h]$, аппроксимирующий приращение: $f(x+h) - f(x) = Df(x)[h] + o(\|h\|)$.
- **Градиент и матрица Гессе извлекаются из дифференциала:** для $f : \mathbb{R}^n \to \mathbb{R}$ верно $df(x) = \langle \nabla f, dx \rangle$, а вторая производная выражается как $d^2 f(x) = \langle \nabla^2 f(x) dx_1, dx_2 \rangle$.
- Вычисление производных через дифференциал **упрощает работу с векторными/матричными функциями:** дифференциал сохраняет структуру вывода (скаляр, вектор, матрицу).
- **Правила преобразования дифференциалов** (линейность, произведение, композиция) аналогичны классическим и универсальны для любых размерностей.

7. ПОЛЕЗНЫЕ ССЫЛКИ

- Учебник по математическому анализу для первого курса. Стр. 179, стр. 497.

  Более подробное и формальное объяснение теории по дифференциалам.
- Зорич В. А. Математический анализ, часть 2.

  Университетский учебник по математическому анализу. Содержит много подробностей с доказательствами.
- Хендбук по матричному дифференцированию.

  Онлайн-материал с краткой выжимкой теории по матричному дифференцированию.