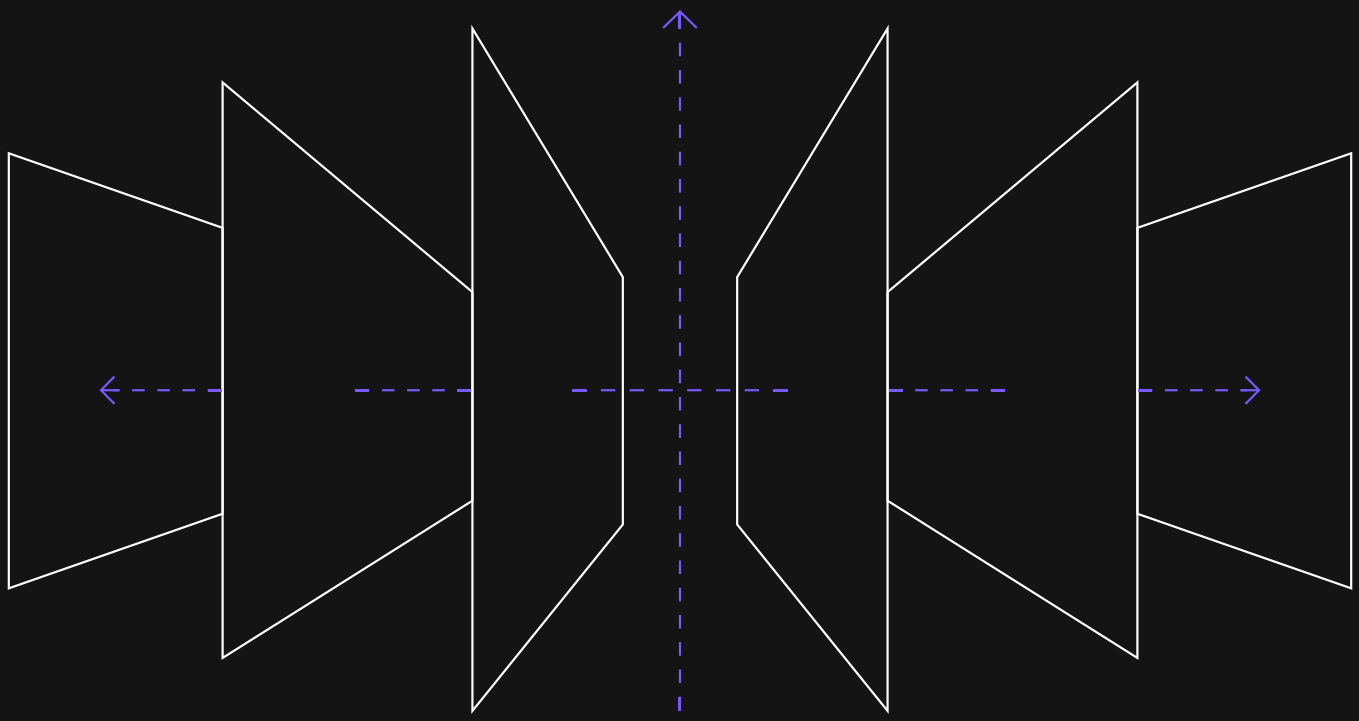
Машинное обучение

Лонгрид

Прикладная математика для машинного обучения

08

Методы выпуклой оптимизации



Занятие 8. Простейшие методы оптимизации

Контекст

В этой лекции рассматривается постановка задачи оптимизации, методы её решения и классы функций, обладающие полезными свойствами при решении задач оптимизации.

Применение

Оптимизационная задача — основа любых алгоритмов машинного обучения. Без её решения невозможно построить ни линейную регрессию, ни модели на основе деревьев, ни нейронные сети. Для этого используются различные методы градиентного спуска, ключевым моментом в которых является умение считать градиенты оптимизируемых функций.

Краткий план

- Оптимизационная задача
- Классы функций
- Градиент и градиентный спуск
- Метод наискорейшего спуска
- Условия Вульфа и Армихо
- Метод инерции и метод Нестерова
- Сходимость
- Число обусловленности — враг градиентного спуска
- Кратко
- Полезные ссылки

1. ОПТИМИЗАЦИОННАЯ ЗАДАЧА

ОПРЕДЕЛЕНИЕ 1

Задача непрерывной оптимизации

$$f(x) \to \min_x, x \in \mathbb{R}^n,$$

где $f(x)$ — непрерывная функция.

ЗАМЕЧАНИЕ

Решение непрерывной задачи оптимизации будем обозначать как $f^* = \min_x(f(x))$ и $x^* : f(x^*) = f^*$. То есть для решения бывает важным найти как минимальное значение функции, так и значение аргумента, на котором этот минимум достигается.

ИНСАЙТ

Задача оптимизации чаще всего рассматривается как задача поиска минимума, так как $f(x) \to \max_x$ эквивалентно $-f(x) \to \min_x$. Также существуют задачи дискретной оптимизации — в этом материале они разбираться не будут.

ПРИМЕР 1

Почти любая задача обучения модели сводится к минимизации функции потерь, и не так важно, регрессия это или классификация, линейна ли модель или речь идёт о нейронной сети с большим числом параметров. При этом важно определить именно *точку*, в которой достигается минимум: именно эта точка задаёт параметры обученной модели. Значение функции потерь в этой точке может служить метрикой качества модели на обучающей выборке, но само по себе имеет меньшее значение, чем точка минимума.

В простейшем случае решить задачу оптимизации можно без использования итерационных методов, найдя точное решение (его также называют «аналитическим» или «решением в замкнутой форме»). Рассмотрим такой случай на примере линейной регрессии.

Пусть дана выборка $\{(x_i, y_i)\}_{i=1}^m$, где $x_i \in \mathbb{R}^n$, $y_i \in \mathbb{R}$. Будем искать модель $\hat{y}_i = x_i^\top w$, где $w \in \mathbb{R}^n$ — вектор параметров. В качестве функции потерь возьмём среднеквадратичную ошибку. Собрав объекты в матрицу $X \in \mathbb{R}^{m \times n}$, а ответы — в вектор $y \in \mathbb{R}^m$, задачу можно переписать в матричном виде:

$$L(w) = \frac{1}{m} \sum_{i=1}^{m} \left(x_i^\top w - y_i \right)^2 = \frac{1}{m} \|Xw - y\|_2^2 \to \min_w .$$

Раскроем скобки и найдём градиент:

$$L(w) = \frac{1}{m} \left(w^\top X^\top X w - 2 y^\top X w + y^\top y \right), \qquad \nabla_w L(w) = \frac{2}{m} X^\top (Xw - y).$$

В точке минимума градиент равен нулю, откуда получаем систему $X^\top X w = X^\top y$. Если $X^\top X$ обратима (на практике это почти всегда выполняется), решение находится напрямую:

$$\boxed{w^* = (X^\top X)^{-1} X^\top y}, \qquad \boxed{L^* = \frac{1}{m} \|Xw^* - y\|_2^2}.$$

Покажем, что найденная точка действительно является минимумом, а не произвольной точкой с нулевым градиентом (например, седловой). Матрица $X^\top X$ неотрицательно определена, поскольку

$$z^\top X^\top X z = \|Xz\|_2^2 \geqslant 0,$$

значит, $L(w)$ — выпуклая функция. Для выпуклой функции нулевой градиент является не только необходимым, но и достаточным условием того, что найденная точка — минимум, причём глобальный. Таким образом, выпуклость позволяет сделать вывод о глобальном минимуме на основании локального условия — равенства градиента нулю.

Таким образом, линейная регрессия с квадратичной функцией потерь — пример задачи, которую можно полностью решить аналитически, без использования градиентного спуска (на практике вместо явного обращения матрицы обычно решают соответствующую систему линейных уравнений: это быстрее и численно устойчивее). Однако для более сложных моделей — логистической регрессии, случайного леса, нейронных сетей — аналитического решения не существует, и параметры ищут итерационными методами оптимизации, которым посвящён дальнейший материал.

2. КЛАССЫ ФУНКЦИЙ

Методы оптимизации эффективнее на определённых классах функций, поэтому опишем некоторые из них. Понятие выпуклой функции было введено ранее; сейчас оно потребуется.

Для выпуклых функций существует теорема, которая делает процесс поиска их минимума эффективным.

ТЕОРЕМА 1

Если $f(x), x \in \mathbb{R}^n$ — выпуклая функция, она дифференцируема в точке x' и

$$\nabla f(x') = \theta,$$

то x' — точка минимума $f(x)$.

ОПРЕДЕЛЕНИЕ 2

Функция $f(x)$ называется **сильно выпуклой с параметром** $\mu > 0$,
если $\exists\, \mu > 0 : \forall\, x, y \in \mathbb{R}^n, \forall\, \lambda \in [0,1]$, справедливо:

$$f(\lambda x + (1-\lambda)y) \leqslant \lambda f(x) + (1-\lambda) f(y) - \mu\lambda(1-\lambda)\|x-y\|^2.$$

(См. видео №5.)

ПРИМЕР 2

$f(x) = x_1^2 + x_2^2$ — сильно выпуклая функция с параметром $\mu = 1$.

Сильная выпуклость подразумевает возможность «подпереть» заданную выпуклую функцию параболой. Условие определения выше эквивалентно:

- в случае дифференцируемости функции $f(x)$

$$f(x) - f(y) \geqslant \langle \nabla f(y), x-y \rangle + \mu\|x-y\|^2, \forall\, x, y \in \mathbb{R}^n;$$

- в случае непрерывно дифференцируемой функции $f(x)$

$$\langle \nabla f(x) - \nabla f(y), x-y \rangle \geqslant 2\mu\|x-y\|^2, \forall\, x, y \in \mathbb{R}^n;$$

- в случае дважды непрерывно дифференцируемой функции $f(x)$

$$\langle \nabla^2 f(x) h, h \rangle \geqslant 2\mu\|h\|^2, \forall\, x, h \in \mathbb{R}^n.$$

ОПРЕДЕЛЕНИЕ 3

Функция $f(x)$ обладает **липшицевым градиентом с константой** $L > 0$,
если $\forall\, x, y \in \mathbb{R}^n$, справедливо:

$$\|\nabla f(x) - \nabla f(y)\| \leqslant L\|x-y\|.$$

ПРИМЕР 3

Функция $f(x) = x_1 + x_2$ обладает липшицевым градиентом с произвольной константой L, так как $\nabla f(x) = (1,1)$ во всех точках
и $\forall\, x, y \in \mathbb{R}^2\ \|\nabla f(x) - \nabla f(y)\| = 0$.

Функция $g(x) = x_1^2 + x_2^2$ обладает липшицевым градиентом с константой $L \geqslant 2$, так как $\nabla g(x) = (2x_1, 2x_2)$ во всех точках и $\forall\, x, y \in \mathbb{R}^2\ \|\nabla g(x) - \nabla g(y)\| = 2\|(x_1 - y_1, x_2 - y_2)\| = 2\|x-y\|$.

Введём некоторые классы функций.

ОПРЕДЕЛЕНИЕ 4

Функция $f(x) \in \mathscr{F}_L^1$, если $f(x)$ выпуклая и обладает липшицевым градиентом с константой L.

ОПРЕДЕЛЕНИЕ 5

Функция $f(x) \in \mathscr{S}_{\mu,D}^1$, если $f(x)$ дважды дифференцируемая сильно выпуклая функция с параметром μ, для которой $\exists\, D : \langle \nabla^2 f(x)h, h\rangle \leqslant D\|h\|^2, \forall\, x, h \in \mathbb{R}^n$.

(См. видео №4.)

Следующие утверждения позволяют получить оценки констант μ, L и D.

ТЕОРЕМА 2

Дважды непрерывно дифференцируемая функция $f(x) \in \mathscr{F}_L^1$ тогда и только тогда, когда $\forall\, x \in \mathbb{R}^n$:

$$\lambda_{min}(\nabla^2 f(x)) \geqslant 0,$$
$$\lambda_{max}(\nabla^2 f(x)) \leqslant L,$$

где λ_{min} и λ_{max} — наименьшее и наибольшее собственные значения матрицы Гессе.

ТЕОРЕМА 3

Дважды непрерывно дифференцируемая функция $f(x) \in \mathscr{S}_{\mu,D}^1$ тогда и только тогда, когда $\forall\, x \in \mathbb{R}^n$:

$$\lambda_{min}(\nabla^2 f(x)) \geqslant 2\mu,$$
$$\lambda_{max}(\nabla^2 f(x)) \leqslant D,$$

где λ_{min} и λ_{max} — наименьшее и наибольшее собственные значения матрицы Гессе.

ЗАМЕЧАНИЕ

Отношение наибольшего и наименьшего собственных значений $\lambda_{max}/\lambda_{min}$ матрицы Гессе определяет **число обусловленности** матрицы Гессе. От него зависит эффективность решения задачи оптимизации градиентными методами; этому вопросу посвящён отдельный раздел ниже.

ПРИМЕР 4

Пример для квадратичной функции:

$$f(x) = \frac{1}{2}\langle Ax,\, x\rangle + \langle b,\, x\rangle + c,\; A = A^T > 0.$$

Матрица Гессе везде равна $\nabla^2 f(x) = A$.

Таким образом, $f(x) \in \mathscr{F}_L^1$, где $L = \lambda_{max}(A)$. И если $\lambda_{min}(A) = 2\mu > 0$ и $D = = \lambda_{max}(A)$, то $f(x) \in \mathscr{S}_{\mu,D}^1$.

3. ГРАДИЕНТ И ГРАДИЕНТНЫЙ СПУСК

Градиентный спуск — это один из итерационных численных методов, который используется для решения непрерывной оптимизационной задачи $f(x) \to \min\limits_x, x \in \mathbb{R}^n$. Его идея опирается на ключевое свойство градиента, которое напомним в первую очередь. Ранее было введено понятие градиента (вектора из частных производных, ∇f) и понятие матрицы Гессе (матрицы из вторых частных производных, $\nabla^2 f$). Для понимания сути градиентных методов потребуется также определение производной по направлению: единичный вектор $\hat{e} \in \mathbb{R}^n$ и производная по направлению $\nabla_{\hat{e}} f(x^0)$.

ИНСАЙТ

Производная функции $f(x), x \in \mathbb{R}^n$ в точке x^0 по направлению, определяемому градиентом этой функции в указанной точке, имеет максимальное значение по сравнению с производной в этой точке по любому другому направлению. Иными словами, градиент определяет направление наибольшего роста функции. Это видно из формулы

$$\nabla_{\hat{e}} f(x^0) = \langle \hat{e}, \nabla f(x^0) \rangle = \|\hat{e}\| \|\nabla f(x^0)\| cos(\hat{e}, \nabla f(x^0)) = \|\nabla f(x^0)\| cos(\hat{e}, \nabla f(x^0)),$$

которая достигает своего максимума при $\hat{e} = \frac{\nabla f(x^0)}{\|\nabla f(x^0)\|}$, её значение равно $\|\nabla f(x^0)\|$.

ЗАМЕЧАНИЕ

Также из этой формулы следует, что **антиградиент** $-\nabla f(x^0)$ определяет направление наибольшего убывания функции и его значение равно $-\|\nabla f(x^0)\|$.

ПРИМЕР 5

Рассмотрим простую функцию $f(x) = x_1 + x_2$ в точке $x^0 = (2, 2)$. Градиент функции $\nabla f(x) = (1, 1)$. Рассмотрим представление функции в окрестности из-за дифференцируемости функции:

$$f(x) - f(x^0) = \langle \nabla f(x^0), x - x^0 \rangle + o(\|x - x^0\|),$$

или по направлению:

$$f(x^0 + h\hat{e}) - f(x^0) = h\langle \nabla f(x^0), \hat{e} \rangle + o(\|h\|).$$

Так как у нас линейная функция, то $o(\|h\|) = 0$. Это следует из того, что вся функция целиком описывается скалярным произведением и нет никаких дополнительных слагаемых у неё. Далее можно рассмотреть направления при $h = 1$.

$$f(x^0 + h\hat{e}) - f(x^0) = f(x^0 + \hat{e}) - f(x^0) = \langle \nabla f(x^0), \hat{e} \rangle = \hat{e}_1 + \hat{e}_2.$$

Если $\hat{e} = \frac{\nabla f(x^0)}{\|\nabla f(x^0)\|} = (\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}})$, то $f(x^0 + \hat{e}) - f(x^0) = \sqrt{2}$. Это максимально возможное приращение по направлению из-за косинуса в формуле

$$\langle e, \nabla f(x^0) \rangle = \|e\| \|\nabla f(x^0)\| cos(e, \nabla f(x^0)) = \|\nabla f(x^0)\| cos(e, \nabla f(x^0)).$$

По той же причине при $\hat{e} = -\frac{\nabla f(x^0)}{\|\nabla f(x^0\|} = (-\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}})$ приращение $f(x^0 + \hat{e}) - f(x^0) = -\sqrt{2}$. Это минимально возможное приращение по направлению.

Более подробно про градиентный спуск — в видео №3.

Раз антиградиент указывает направление наибольшего убывания функции, естественно двигаться к минимуму, делая шаги именно в этом направлении. На этом и основан градиентный спуск.

ОПРЕДЕЛЕНИЕ 6

Метод градиентного спуска строит последовательность приближений $x^0, x^1, \ldots, x^m, \ldots$ к точке минимума дифференцируемой функции $f(x), x \in \mathbb{R}^n$ по следующей формуле:

$$x^{k+1} = x^k - \alpha_k \nabla f(x^k),$$

где $\alpha_k > 0$ — число.

В качестве x^0 можно взять случайную точку или 0.

Тот же выбор направления можно обосновать и через локальную аппроксимацию функции. Если функция $f(x)$ дифференцируема, то верно следующее разложение в окрестности x^k, которое выводится из разложения Тейлора:

$$f(x) = f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + o(\|x - x^k\|).$$

Минимум функции $\langle \nabla f(x^k), x - x^k \rangle$ на шаре $U = \{x : \|x - x^k\| \leqslant r\}$ достигается в точке

$$x^{k+1} = x^k - r\frac{\nabla f(x^k)}{\|\nabla f(x^k)\|}.$$

Таким образом, минимум линейной части разложения функции $f(x)$ в окрестности точки x^k достигается, если направление шага совпадает с направлением антиградиента $-\nabla f(x^k)$.

Основные вопросы, которые задаются при применении градиентного спуска

- Какую величину шага выбрать?
- Сойдётся ли метод?
- Какой будет скорость сходимости?
- Когда завершать работу алгоритма?

В качестве критериев останова могут использоваться следующие условия.

- Достигнута необходимая точность, однако необходимо знать f^*:

$$|f(x^k) - f^*| < \delta.$$

- Достигнута необходимая точность по норме градиента:

$$\|\nabla f(x^k)\|^2 < \delta.$$

- Шаг градиентного метода меньше заданного значения:

$$\|x^k - x^{k-1}\| < \delta.$$

- Изменение функции за шаг градиентного метода меньше заданного значения:

$$|f(x^k) - f(x^{k-1})| < \delta.$$

Градиентный метод с дискретным шагом

Для метода градиентного спуска возможно выбрать коэффициенты α_k постоянными. При этом в некоторых случаях возможно добиться выполнения неравенства:

$$f(x^k - \alpha_k \nabla f(x^k)) - f(x^k) \leqslant -\epsilon \alpha_k \|\nabla f(x^k)\|^2, \epsilon \in (0, 1).$$

Это неравенство часто используется для обоснования сходимости многих методов минимизации, обычно $\epsilon = \frac{1}{2}$.

ТЕОРЕМА 4

Пусть $f(x) \in \mathscr{F}_L^1$, тогда можно выбрать $\alpha_k = \alpha \in (0, \frac{1-\epsilon}{L}]$ для достижения неравенства:

$$f(x^k - \alpha_k \nabla f(x^k)) - f(x^k) \leqslant -\epsilon \alpha_k \|\nabla f(x^k)\|^2, \epsilon \in (0, 1).$$

ТЕОРЕМА 5

Пусть $f(x) \in \mathscr{S}_{\mu,D}^1$. Для неё можно выбрать $\alpha_k = \alpha \in (0, \frac{2(1-\epsilon)}{D}]$, чтобы достигнуть неравенства:

$$f(x^k - \alpha_k \nabla f(x^k)) - f(x^k) \leqslant -\epsilon \alpha_k \|\nabla f(x^k)\|^2, \epsilon \in (0, 1)$$

Эти два утверждения показывают, какой константный шаг можно выбирать для определённых классов функций, чтобы гарантировать сходимость метода. Однако для их определения необходимо знать константы D и L, вычисление которых может стать сложной задачей.

Градиентный метод с дроблением шага

ОПРЕДЕЛЕНИЕ 7

Градиентным методом с дроблением шага называется метод градиентного спуска, для которого определяются константы β, $\lambda \in (0, 1)$. Величина шага $\alpha_k > 0$ определяется следующим образом: $\alpha_0 = \beta$. Далее проверяется неравенство для произвольного ϵ:

$$f(x^k - \alpha_k \nabla f(x^k)) - f(x^k) \leqslant -\epsilon \alpha_k \|\nabla f(x^k)\|^2, \epsilon \in (0, 1).$$

Если оно выполнено, то α_k найдено, иначе $\alpha_k = \lambda \alpha_k$ и процесс повторяется, пока неравенство не будет выполнено.

Введём обозначения.

$$\overline{\alpha} = min\left(\beta, \frac{\lambda(1-\epsilon)}{L}\right) \mid f(x) \in \mathscr{F}_L^1,$$

$$\widetilde{\alpha} = min\left(\beta, \frac{\lambda 2(1-\epsilon)}{D}\right) \mid f(x) \in \mathscr{S}_{\mu,D}^1.$$

Если $f(x) \in \mathscr{F}_L^1$, то $\alpha_k \geqslant \overline{\alpha}$, если $f(x) \in \mathscr{S}_{\mu,D}^1$, то $\alpha_k \geqslant \widetilde{\alpha}$. Достаточно посмотреть на утверждения из градиентного метода с дискретным шагом и способ определения α_k, где каждый раз идёт умножение на λ коэффициента градиентного спуска. Отдельно стоит отметить, что определение α_k на каждом шагу будет требовать больше вычислительных ресурсов, так как понадобится проверять неравенство и искать подходящее α_k.

Более детально про метод градиентного спуска с дроблением шага — в видео №7.

4. МЕТОД НАИСКОРЕЙШЕГО СПУСКА

Решается задача непрерывной оптимизации $f(x) \to \min\limits_{x}, x \in \mathbb{R}^n$. Ранее был рассмотрен градиентный метод решения этой задачи:

$$x^{k+1} = x^k - \alpha_k \nabla f(x^k).$$

Далее рассмотрим ещё один способ, которым можно выбирать параметр α_k.

ОПРЕДЕЛЕНИЕ 8

Методом наискорейшего спуска называется метод градиентного спуска, для которого величина шага $\alpha_k > 0$ определяется из условия

$$\alpha_k : f(x^k - \alpha_k \nabla f(x^k)) \to \min\limits_{\alpha_k}.$$

Для этого метода на каждом шаге придётся решать задачу одномерной оптимизации.

ПРИМЕР 6

Рассмотрим пример для квадратичной функции.

$$f(x) = x_1^2 + x_2^2,$$

$$x^0 = (1, 1),$$

$$\nabla f(x) = (2x_1, 2x_2),$$

$$\nabla f(x^0) = (2, 2),$$

$$f(x^0 - \alpha \nabla f(x^0)) = f(1 - 2\alpha, 1 - 2\alpha) = 2(1 - 2\alpha)^2 \to min_\alpha,$$

$$\frac{df((x^0 - \alpha \nabla f(x^0))}{d\alpha} = -8(1 - 2\alpha) = 0,$$

$$\alpha = \frac{1}{2},$$

$$x^1 = x^0 - \frac{1}{2}\nabla f(x^0) = (0, 0).$$

Это глобальный минимум.

Более детально про метод наискорейшего спуска — в видео №8.

5. УСЛОВИЯ ВУЛЬФА И АРМИХО

В градиентных методах выбор длины шага является одной из основных задач. Чтобы гарантировать достижение стационарной точки, могут использоваться **условия Вульфа**. Они формулируются для произвольного направления шага p_k, а не только для антиградиента, так как шаг минимизации функции в методах оптимизации может осуществляться и в других направлениях (например, в методе Ньютона, который будет рассмотрен на следующем занятии).

ОПРЕДЕЛЕНИЕ 9

Длина шага α_k удовлетворяет **условиям Вульфа** в точке x_k при направлении шага p_k для функции $f(x)$:

1) если $f(x_k + \alpha_k p_k) \leqslant f(x_k) + c_1 \alpha_k \langle \nabla f(x_k), p_k \rangle$;
2) $\langle p_k, \nabla f(x_k + \alpha_k p_k) \rangle \geqslant c_2 \langle p_k, \nabla f(x_k) \rangle$,

где $0 < c_1 < c_2 < 1$.

ЗАМЕЧАНИЕ

Обычно c_1 выбирают достаточно малым, например $c_1 = 10^{-4}$, а c_2 — достаточно большим, например $c_2 = 0.9$.

Первое неравенство также называют **условием Армихо**. Оно отвечает за достаточное убывание целевой функции при каждом шаге. Второе неравенство называют **условием кривизны**. Оно отвечает за достаточный прогресс шага в пространстве определения функции.

ЗАМЕЧАНИЕ

Условия Вульфа также можно записать через производную вспомогательной функции одной переменной. Пусть $\phi_k(\alpha) = f(x_k + \alpha p_k)$. Тогда $\phi_k'(\alpha) = \nabla f(x_k + \alpha p_k)^T p_k = = \langle \nabla f(x_k + \alpha p_k), p_k \rangle$.

Тогда условия Вульфа можно переписать в виде

1) $\phi_k(\alpha) \leqslant \phi_k(0) + \alpha c_1 \phi_k'(0)$;
2) $\phi_k'(\alpha) \geqslant c_2 \phi_k'(0)$.

ПРИМЕР 7

Для градиентного спуска $p_k = -\nabla f(x^k)$.

$$f(x) = x^2,$$

$$x^0 = 4,$$

$$\nabla f(x) = 2x,$$

$$\nabla f(x^0) = 8,$$

$$x^1 = x^0 - \alpha_0 \nabla f(x^0) = 4 - 8\alpha_0.$$

Для первого условия

$$f(4 - 8\alpha_0) \leqslant f(4) - c_1 \alpha_0 \|8\|^2,$$

$$16 - 64\alpha_0 + 64\alpha_0^2 \leqslant 16 - c_1 64 \alpha_0,$$

$$64\alpha_0^2 - (64 - 64c_1)\alpha_0 \leqslant 0,$$

$$\alpha_0 \leqslant 1 - c_1.$$

Пусть $c_1 = 1/4$, тогда $\alpha_0 \leqslant \frac{3}{4}$.

Для второго условия

$$8 \times 2(4 - 8\alpha_0) \leqslant c_2 \times 64,$$

$$4 - 8\alpha_0 \leqslant 4c_2,$$

$$\alpha_0 \geqslant \frac{1 - c_2}{2}.$$

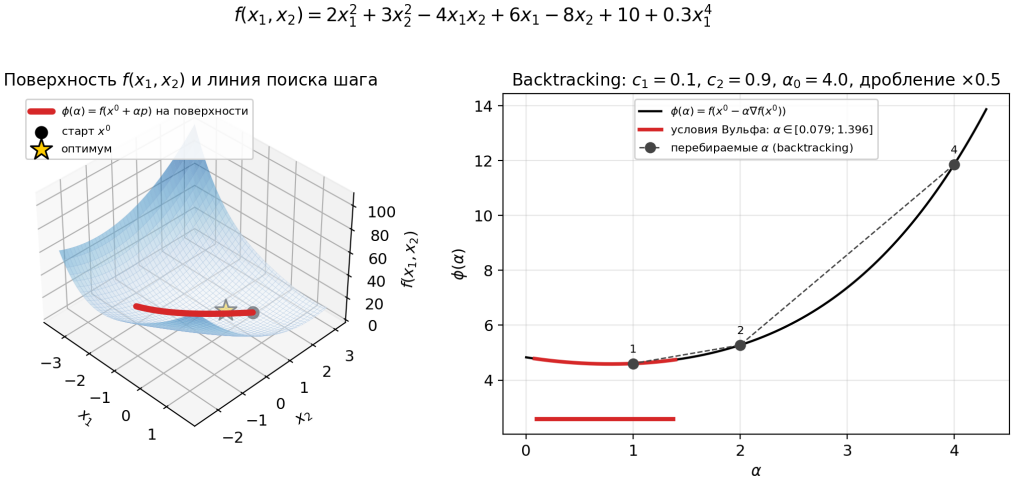
Пусть $c_2 = 3/4$, тогда $\alpha_0 \geqslant \frac{1}{8}$.

Итого под условия Вульфа попадает следующий диапазон длины шага: $\frac{1}{8} \leqslant \alpha_0 \leqslant \frac{3}{4}$.

Условия Вульфа задают диапазон подходящих значений α_k на каждом шаге. В отличие от метода наискорейшего спуска, где на каждом шаге ищется одно конкретное (оптимальное) значение α_k, здесь достаточно найти любое значение из допустимого диапазона, что обычно значительно дешевле вычислительно. Например, с помощью backtracking: начиная с достаточно большого α и уменьшая его в несколько раз, пока оба условия не будут выполнены (тот же приём, что и в градиентном методе с дроблением шага).

ПРИМЕР 8

Поиск шага для функции $f(x_1, x_2) = 2x_1^2 + 3x_2^2 - 4x_1x_2 + 6x_1 - 8x_2 + 10 + 0.3x_1^4$ — квадратичной части, рассмотренной на семинаре, с добавлением слагаемого $0.3x_1^4$, из-за которого поверхность перестаёт быть параболоидом (минимум не выражается в замкнутой форме и найден численно). Слева — поверхность $f(x_1, x_2)$ и путь $\phi(\alpha) = f(x^0 - \alpha\nabla f(x^0))$, расположенный на этой поверхности вдоль направления антиградиента. Справа — тот же $\phi(\alpha)$ в двумерном представлении: backtracking начинается с $\alpha_0 = 4$ и последовательно делится пополам (точки $4 \to 2 \to 1$) до попадания в допустимый диапазон (выделен красным), в котором выполняются условия Вульфа.



При выборе шага из допустимого диапазона итерационный метод будет сходиться к стационарной точке для функций с липшицевым градиентом с константой L. Сходимость обеспечивается первым условием (условием Армихо) и тем же неравенством, которое мы использовали для доказательства сходимости градиентного метода с дроблением шага:

$$f(x^k - \alpha_k \nabla f(x^k)) - f(x^k) \leqslant -\epsilon\alpha_k \|\nabla f(x^k)\|^2, \epsilon \in (0, 1).$$

ЗАМЕЧАНИЕ

Перепишем первое условие Вульфа при $p_k = -\nabla f(x_k)$:

$$f(x^k - \alpha_k \nabla f(x^k)) \leqslant f(x^k) - c_1\alpha_k \|\nabla f(x^k)\|^2,$$

что эквивалентно записи

$$f(x^k - \alpha_k \nabla f(x^k)) - f(x^k) \leqslant -c_1\alpha_k \|\nabla f(x^k)\|^2, \; c_1 \in (0, 1).$$

Здесь c_1 играет роль ϵ в исходном неравенстве.

6. МЕТОД ИНЕРЦИИ И МЕТОД НЕСТЕРОВА

Существует модификация градиентного спуска, которая ускоряет сходимость за счёт учёта истории предыдущих шагов (*инерция*). Подробный вывод выходит за рамки этого занятия, однако полезно знать формулу и название метода, так как он постоянно встречается на практике.

ОПРЕДЕЛЕНИЕ 10

Метод инерции модифицирует шаг ГД, добавляя слагаемое, пропорциональное предыдущему шагу:

$$x^{k+1} = x^k - \alpha_k \nabla f(x^k) + \beta_k (x^k - x^{k-1}).$$

Идея в том, чтобы сохранять «инерцию» движения и не сразу останавливаться / менять направление: это помогает проскакивать небольшие локальные препятствия рельефа функции.

ОПРЕДЕЛЕНИЕ 11

Метод Нестерова — развитие метода инерции, где градиент считается не в текущей точке x^k, а в точке, куда алгоритм пришёл бы, если бы продолжил двигаться по направлению предыдущего шага:

$$x^{k+1} = x^k - \alpha_k \nabla f(x^k + \beta_k (x^k - x^{k-1})) + \beta_k (x^k - x^{k-1}).$$

Метод Нестерова является оптимальным методом первого порядка для решения выпуклых оптимизационных задач. Ниже, в разделе о числе обусловленности, на конкретном примере показано, какой выигрыш в скорости сходимости может дать инерция.

7. СХОДИМОСТЬ

ТЕОРЕМА 6

Пусть $f(x)$ дифференцируема, ограничена снизу и обладает липшицевым градиентом с константой L. Тогда при произвольной начальной точке x^0 градиентный метод сходится к стационарной точке:

$$\lim_{k \to +\infty} \|\nabla f(x^k)\| = 0.$$

ЗАМЕЧАНИЕ

В случае невыпуклой функции стационарная точка может не являться точкой минимума.

ПРИМЕР 9

Для $f(x) = x_1^2 - x_2^2$ стационарная точка $(0, 0)$ из $\nabla f(x) = (2x_1, -2x_2) = 0$ не является ни точкой максимума, ни точкой минимума. Но так как эта функция не ограничена ни снизу, ни сверху, то градиентный метод может разойтись и не найти эту стационарную точку.

Далее будет показано, что градиентный метод с оптимальным шагом или дроблением шага сходится к стационарной точке. Однако сам факт сходимости не определяет, сколько итераций для этого потребуется, а разница между методами может быть значительной (это будет продемонстрировано

далее при сравнении методов на одном графике). Поскольку каждая итерация требует вычислительных затрат, вопрос о том, насколько быстро сходится метод, имеет непосредственное практическое значение. Это характеризуется **скоростью сходимости**.

ОПРЕДЕЛЕНИЕ 12

Скорость сходимости последовательности $\{x^k\}$ к x^* (или значений $f(x^k)$ к f^*) называется:

- **линейной**, если последовательность сходится со скоростью геометрической прогрессии:

$$\exists\, C, 0 < q < 1 : |f(x^k) - f(x^*)| \leqslant Cq^k \ \forall\ k \geqslant m, m \geqslant 0$$ — некоторое число;

- **сублинейной**, если последовательность сходится, но не обладает линейной скоростью:

$$\exists\, C : |f(x^k) - f(x^*)| \leqslant C\frac{1}{k} \ \forall\ k \geqslant m, m \geqslant 0$$ — некоторое число;

- **сверхлинейной** порядка p (при $p = 2$ сходимость называется **квадратичной**):

$$\exists\, C, 0 < q < 1 : |f(x^k) - f(x^*)| \leqslant Cq^{p^k} \ \forall\ k \geqslant m, m \geqslant 0$$ — некоторое число.

ИНСАЙТ

Название «линейная» сходимость может показаться противоречивым, поскольку прогрессия Cq^k является показательной, а не линейной функцией от k. Это связано со способом графического представления: если отложить $\log(f(x^k) - f^*)$ по вертикальной оси, а k — по горизонтальной, то $\log(Cq^k) = \log C + k \log q$ — уравнение *прямой линии*. Таким образом, на графике с логарифмической осью y линейная сходимость выглядит как прямая линия. Это будет продемонстрировано далее на графике сравнения методов. Сублинейная сходимость на таком графике приближается к прямой линии лишь асимптотически, а сверхлинейная — убывает быстрее любой прямой линии.

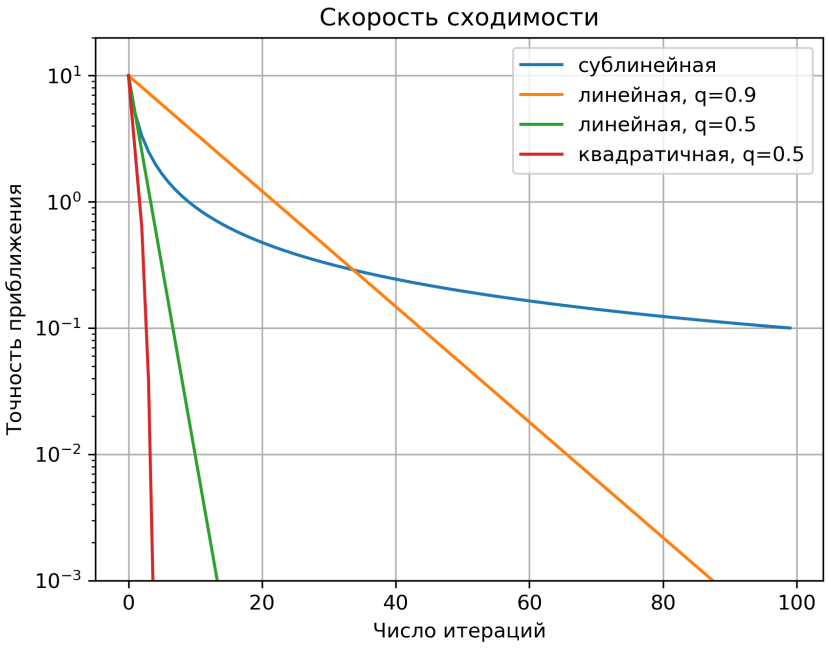


Рисунок 1. Сравнение скоростей сходимости

Напомним классы функций $\mathscr{F}_L^1$ (выпуклая, липшицев градиент с константой L) и $\mathscr{S}_{\mu,D}^1$ (сильно выпуклая с параметром μ, вторая производная ограничена сверху константой D), которые мы ввели в разделе «Классы функций».

ТЕОРЕМА 7

Пусть $f(x) \in \mathscr{F}_L^1$. Тогда при произвольной начальной точке x^0 градиентный метод (с оптимальным шагом или дроблением шага) сходится к точке минимума с *сублинейной скоростью:*

$$f(x^k) - f(x^*) \leqslant \frac{1}{2\alpha' k}\|x^0 - x^*\|^2,$$

где α' — минимальный используемый коэффициент в градиентном методе (для дискретного шага — сама константа α, для дробления шага — оценка $\overline{\alpha}$ из соответствующего раздела).

ТЕОРЕМА 8

Пусть $f(x) \in \mathscr{S}_{\mu,D}^1$. Тогда при произвольной начальной точке x^0 градиентный метод сходится к точке минимума со скоростью геометрической прогрессии **(линейная сходимость)**:

$$f(x^k) - f(x^*) \leqslant q^k(f(x^0) - f(x^*)),$$

где $q \in (0,1)$ — константа, зависящая от μ, D и выбранного шага.

Про то, когда метод градиентного спуска может не сойтись, смотри видео №6.

ЗАМЕЧАНИЕ

Можно показать, что чем ближе отношение μ/D к $1/2$ (то есть чем лучше обусловлена задача, смотри следующий раздел), тем меньше q и тем быстрее сходимость. И наоборот, при $\mu/D \ll 1/2$ (плохо обусловленная задача) константа q приближается к 1 и сходимость становится очень медленной, почти как сублинейная.

Для метода наискорейшего спуска можно показать похожий результат: он сходится со скоростью геометрической прогрессии со знаменателем $q = \frac{D-2\mu}{D+2\mu}$, здесь тоже видно, что при $D \gg \mu$ (плохая обусловленность) знаменатель q стремится к 1.

Сведём известные оценки скорости сходимости для разобранных методов в одну таблицу.

Функция	Метод	Скорость сходимости
$f(x)$ обладает липшицевым градиентом	Градиентный спуск	Сублинейная
$f(x) \in \mathscr{F}_L^1$	Градиентный спуск	Сублинейная
$f(x) \in \mathscr{S}_{\mu,D}^1$	Градиентный спуск	Линейная

8. ЧИСЛО ОБУСЛОВЛЕННОСТИ — ВРАГ ГРАДИЕНТНОГО СПУСКА

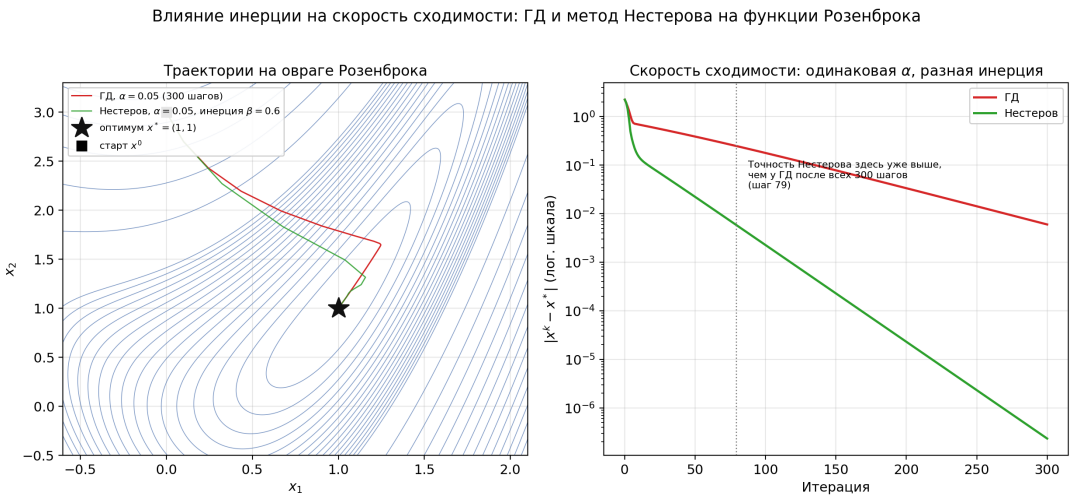
Число обусловленности матрицы Гессе было определено выше как отношение $\lambda_{max}/\lambda_{min}$ её собственных значений (раздел «Классы функций»). Рассмотрим, почему именно оно определяет, насколько эффективно будет сходиться градиентный спуск.

ИНСАЙТ

При большом числе обусловленности линии уровня функции образуют сильно вытянутый «овраг» — узкий и длинный, а не круглую чашу. Антиградиент в таком овраге направлен почти перпендикулярно стенкам оврага, а не вдоль его дна, то есть почти перпендикулярно направлению на минимум. Вследствие этого шаг ГД на каждой итерации «перелетает» через дно оврага на противоположную стенку и траектория начинает **зигзагообразно колебаться**: вместо движения прямо к минимуму метод совершает множество мелких колебательных шагов поперёк оврага, медленно продвигаясь вдоль его дна.

ПРИМЕР 10

Градиентный спуск (красный) и метод Нестерова (зелёный) с одинаковым шагом $\alpha = 0.05$ на функции Розенброка $f(x_1, x_2) = (1 - x_1)^2 + (x_2 - x_1^2)^2$ — классическом примере функции, сложной для градиентных методов. Слева — траектории: обе имеют качественно одинаковую форму (плавный вход в овраг, без перелётов и колебаний), однако метод Нестерова с умеренной инерцией ($\beta = 0.6$) продвигается вдоль дна оврага заметно быстрее. Справа — скорость сходимости: обе кривые близки к прямым линиям на логарифмической шкале (линейная сходимость), но с разным наклоном. Метод Нестерова достигает на 79-м шаге точности, для которой ГД требуется 300 шагов, а к 300-му шагу превосходит его по точности на четыре порядка.



ЗАМЕЧАНИЕ

Именно поэтому на практике перед запуском градиентных методов признаки почти всегда *масштабируют* (например, приводят к нулевому среднему и единичной дисперсии). Если один признак измеряется в единицах порядка 10^0, а другой — в единицах порядка 10^2–10^3, соответствующие вторые производные функции потерь по этим переменным будут отличаться на порядки и число обусловленности может достигать десятков тысяч. При таком числе обусловленности градиентный спуск с постоянным шагом становится практически неработоспособным: шаг либо приходится делать крайне малым, что приводит к чрезвычайно медленной сходимости вдоль пологого направления, либо оказывается слишком большим для крутого направления, что приводит к расходимости метода.

Этим объясняется важность рассмотренных выше способов выбора шага (дробление шага, условия Вульфа): они позволяют алгоритму подстраивать длину шага под локальную кривизну функции в текущей точке, а не полагаться на одну и ту же константу во всех направлениях сразу. Но полностью проблему плохой обусловленности эти методы не решают. Для этого требуются методы, использующие информацию о матрице Гессе (метод Ньютона и квазиньютоновские методы), которые будут рассмотрены на следующем занятии.

9. КРАТКО

- Оптимизационная задача часто рассматривается как задача поиска минимума.
- Стационарная точка для выпуклой функции является глобальным минимумом.
- Для градиентного спуска важно выбирать длину шага α: константный шаг, дробление шага, метод наискорейшего спуска и условия Вульфа — Армихо — четыре разных способа её подобрать, с разной ценой и разными гарантиями.
- В случае липшицевости градиента градиентный спуск (в том числе с дроблением шага или условиями Вульфа) сходится к стационарной точке, причём для выпуклых функций — с сублинейной скоростью, а для сильно выпуклых — с линейной.
- Важные свойства функций для эффективного решения оптимизационной задачи: выпуклость, липшицевость градиента, сильная выпуклость.
- Метод инерции и метод Нестерова ускоряют сходимость за счёт учёта направления предыдущего шага. Ещё на практике часто используются СГД и Adam, подробное описание — в дополнительном материале.

- Число обусловленности матрицы Гессе — главный враг градиентного спуска: чем оно больше, тем заметнее траектория метода колеблется поперёк оврага и тем медленнее сходится метод.

10. ПОЛЕЗНЫЕ ССЫЛКИ

- Сухарев А. Г., Тимохов А. В., Федоров В. В. Курс методов оптимизации — университетский учебник по методам оптимизации. В 5-й главе можно найти подробно про оценки сходимости. А начало учебника раскроет причину сходимости для неравенства в градиентном спуске с дроблением шага.

- Градиентные методы для продолжающих — доступное и понятное изложение основных методов оптимизации.

- Пшеничный Б. Н., Данилин Ю. М. Численные методы в экстремальных задачах — в разделе про градиентный метод можно узнать подробнее о причинах сходимости градиентного метода.

- Ещё немного о скорости сходимости — раскрывает тему скорости сходимости и показывает, как можно её определять.

- Ещё более мощный лонгрид про условия Армихо и Вульфа — позволяет наглядно оценить процесс поиска подходящего шага для условий Вульфа.