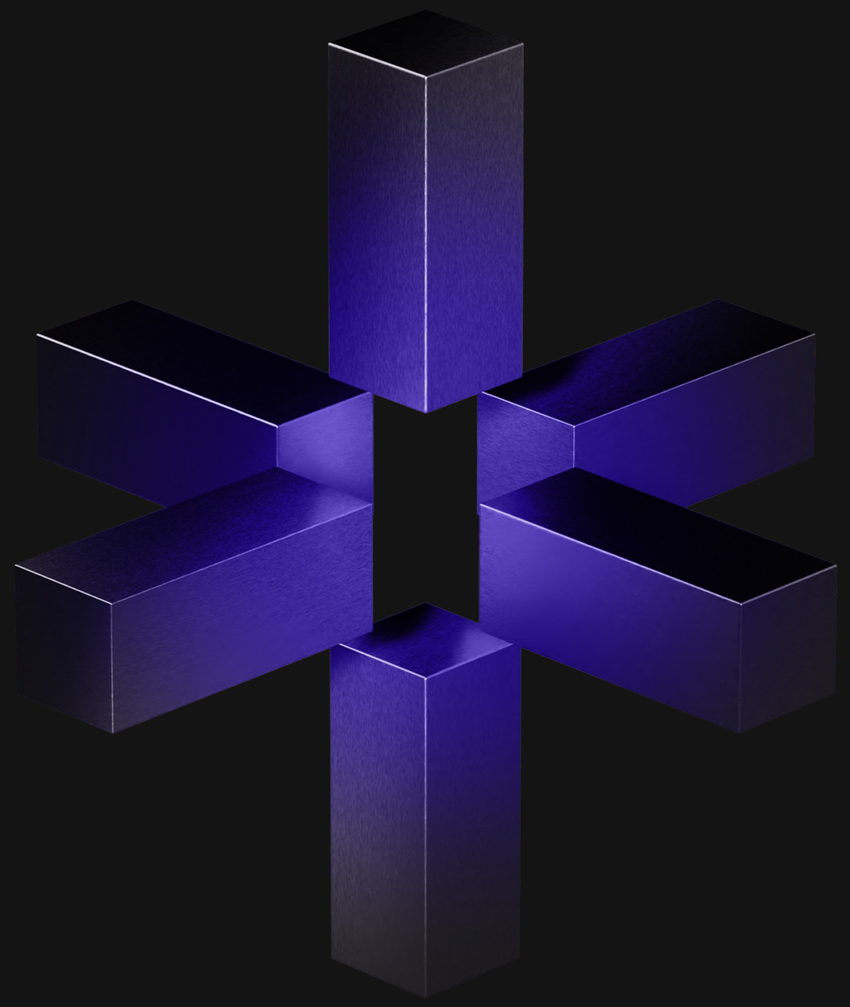
ЦЕНТРАЛЬНЫЙ УНИВЕРСИТЕТ

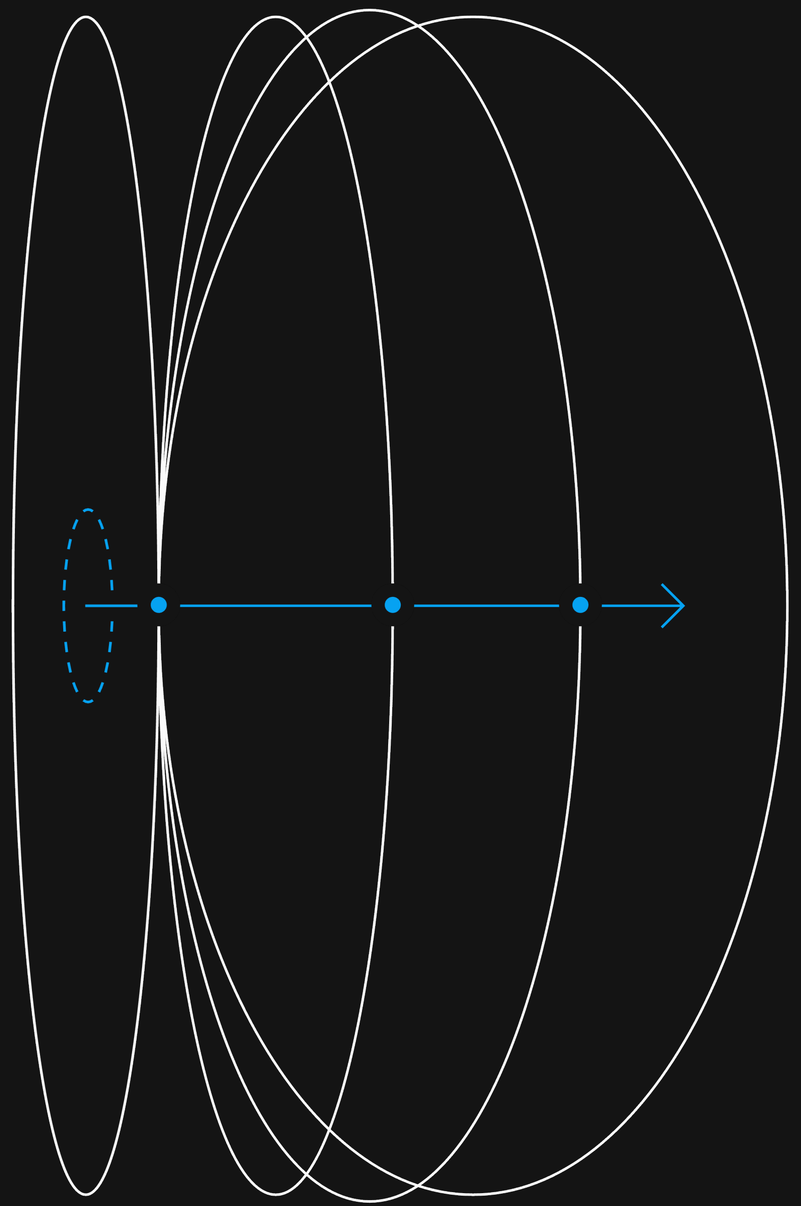
Функционалы потерь и метрики в задачах классификации



ML
Машинное обучение

02

Роман Васильев

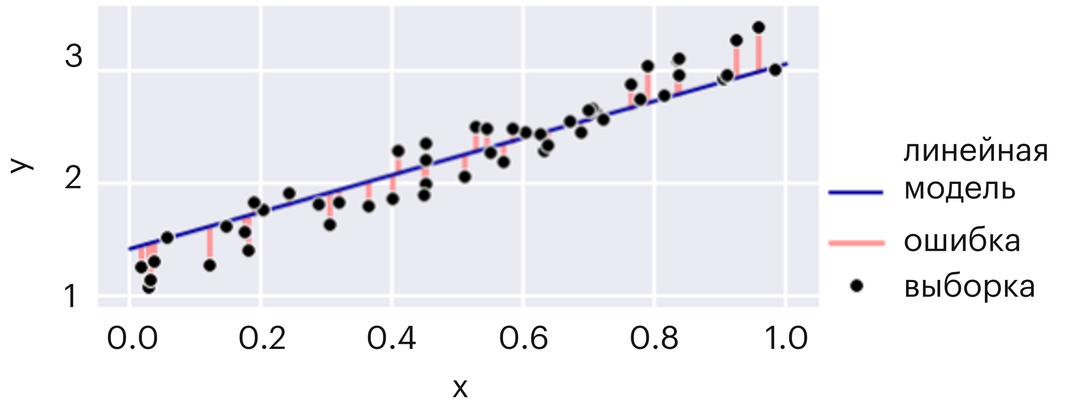


План

- Задача классификации
- Метрики качества классификации
- Бинарные метрики качества классификации
- Метрики многоклассовой и многометочной классификации

Вспомним теорию

Регрессия — это задача предсказания непрерывной числовой величины на основе входных признаков.



Вспомним теорию

Функция потерь — математическая функция, которая измеряет, насколько сильно модель ошибается в предсказаниях на этапе обучения.

Метрика машинного обучения — математическая функция, которая позволяет оценить качество предсказаний модели после обучения.

В задачах регрессии функция потерь и метрика машинного обучения могут совпадать.

$$\mathrm{MAE} = \frac{1}{m}\sum_{i=1}^{m} | a_i - y_i |$$

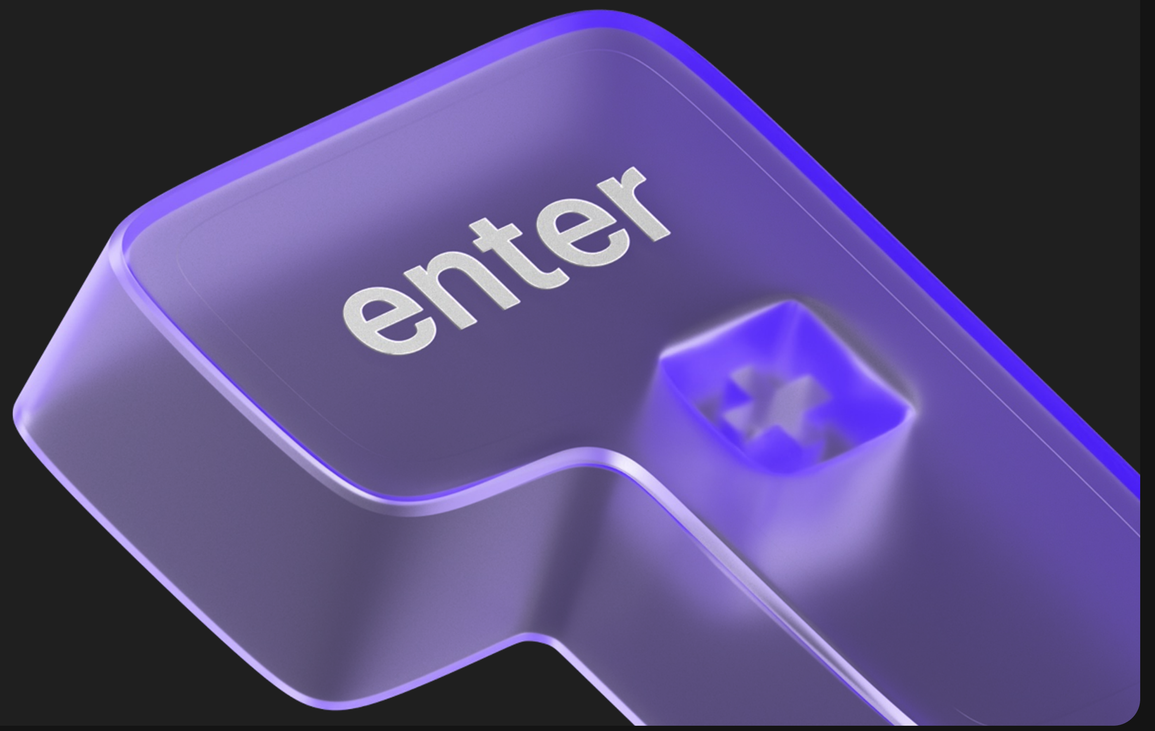
Вспомним теорию

Существует множество метрик регрессии, и у каждой — свои логика, преимущества, недостатки и область применения.

Название	Формула	Когда использовать
MAE Mean Absolute Error	$\mathrm{MAE} = \frac{1}{m}\sum_{i=1}^{m} \lvert a_i - y_i \rvert$	Когда важна равномерная оценка всех ошибок и устойчивость к выбросам
MSE Mean Squared Error	$\mathrm{MSE} = \frac{1}{m}\sum_{i=1}^{m} \lvert a_i - y_i \rvert^2$	Когда нужно сильнее штрафовать крупные ошибки
RMSE Root Mean Squared Error	$\mathrm{RMSE} = \sqrt{\frac{1}{m}\sum_{i=1}^{m} \lvert a_i - y_i \rvert^2}$	Когда важно сохранить масштаб целевой переменной
R2 Коэффициент детерминации	$R^2 = 1 - \frac{\sum_{i=1}^{m} \lvert a_i - y_i \rvert^2}{\sum_{i=1}^{m} \lvert \overline{y} - y_i \rvert^2}$	Когда нужно понять, насколько хорошо модель объясняет поведение целевой переменной

Задача классификации

Постановка и виды

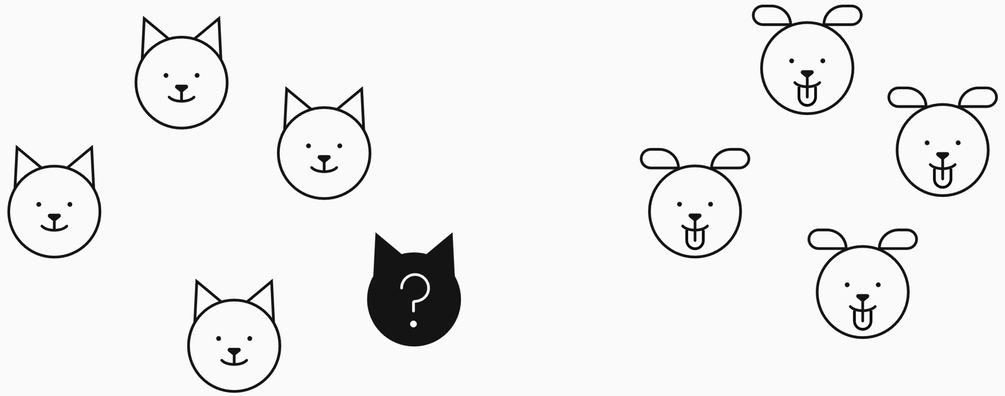


Постановка задачи классификации

В чём идея?

Классификация — это задача предсказания категории или класса из конечного множества допустимых меток. ML-модель учится находить границы между классами и определять, к какому из них относится новый объект.

ПРИМЕР



В задаче 2 класса: «кошка» и «собака».

Задача: для каждого нового объекта определить, кошкой или собакой он является.

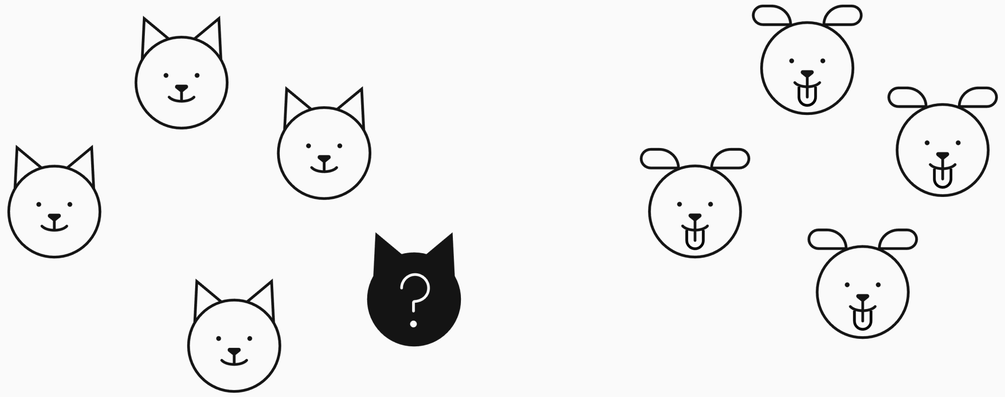
Постановка задачи классификации

Ключевое отличие между регрессией и классификацией заключается в **целевой переменной**.

Задача регрессии — предсказать непрерывное численное значение.

Задача классификации — **предсказать категорию/класс из ограниченного множества.**

ПРИМЕР



В задаче 2 класса: «кошка» и «собака».

Задача: для каждого нового объекта определить, кошкой или собакой он является.

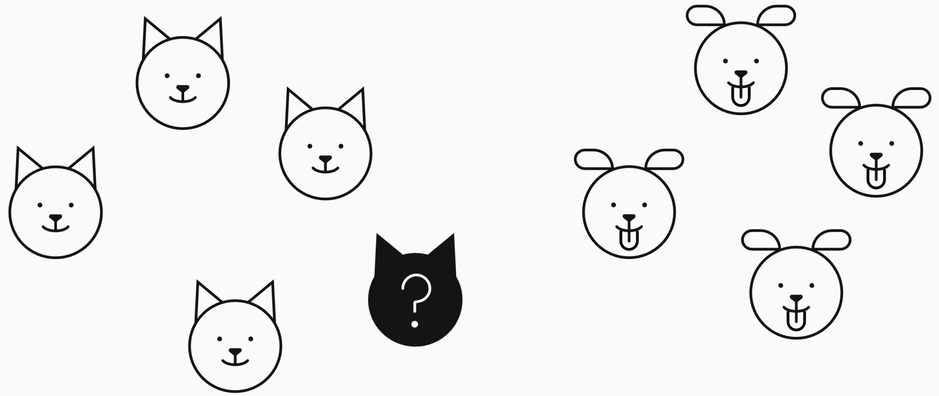
Виды задач классификации

Существуют 3 основных вида задачи классификации		
Бинарная	Многоклассовая	Многометочная

Ключевые отличия этих методов	
Количество классов во множестве вариантов.	Необходимость предсказать более одного класса за раз (или отсутствие такой необходимости).

Бинарная классификация

Бинарная классификация (англ. binary classification) — это базовый случай задачи классификации, в котором множество классов состоит из 2 элементов (например, «да» или «нет», «болен» или «здоров», «кошка» или «собака»).



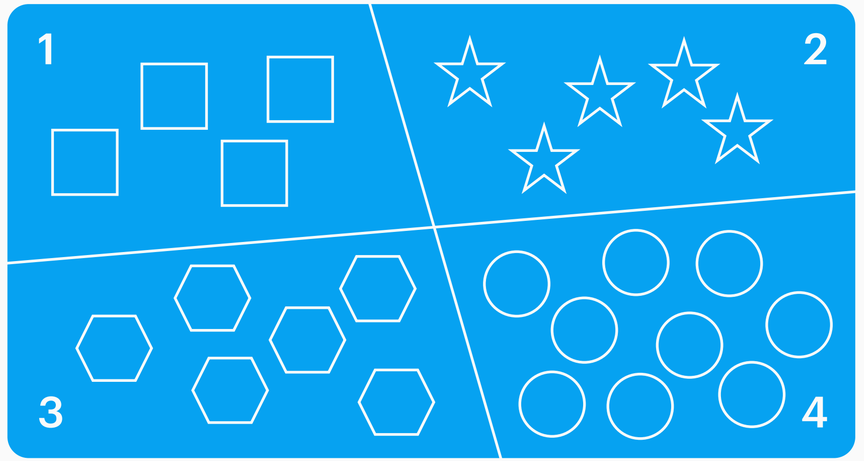
Это задача бинарной классификации.

Возможные классы: «кошка»/«собака».

Бинарная | **Многоклассовая** | Многометочная

Многоклассовая классификация

Многоклассовая классификация (англ. multiclass classification) — задача классификации, в которой модель учится предсказывать один из нескольких (больше двух) взаимоисключающих классов.



Это задача многоклассовой классификации.

Возможные классы: «квадрат»/«звезда»/«круг»/«шестиугольник».

Источник

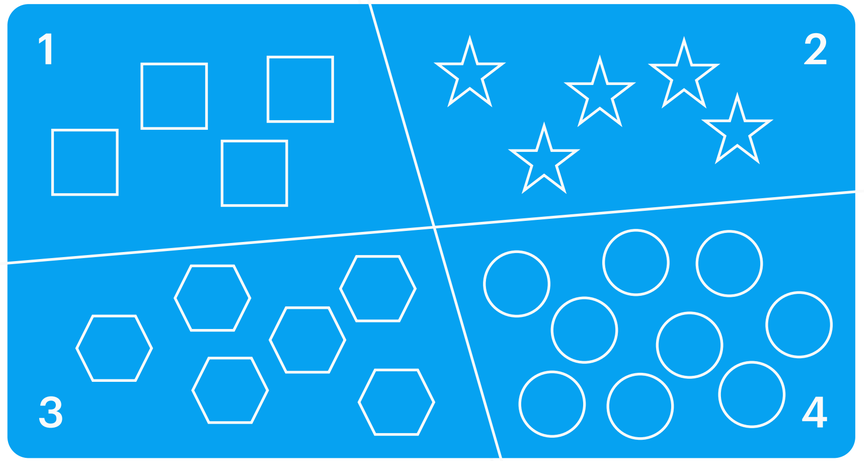
Многоклассовая классификация

Основные подходы к решению задачи многоклассовой классификации включают		
One-vs-All (или One-vs-Rest)	One-vs-One	Softmax-классификация

Ключевые отличия этих подходов	
Способ сведения многоклассовой задачи к бинарной классификации.	Количество обучаемых классификаторов и связь предсказаний.

Подход One-vs-All

1. Для *K* классов обучается *K* бинарных моделей.
2. Каждая модель учится отличать свой класс от всех остальных.
3. На предсказании выбирается класс, получивший наиболее уверенное предсказание.

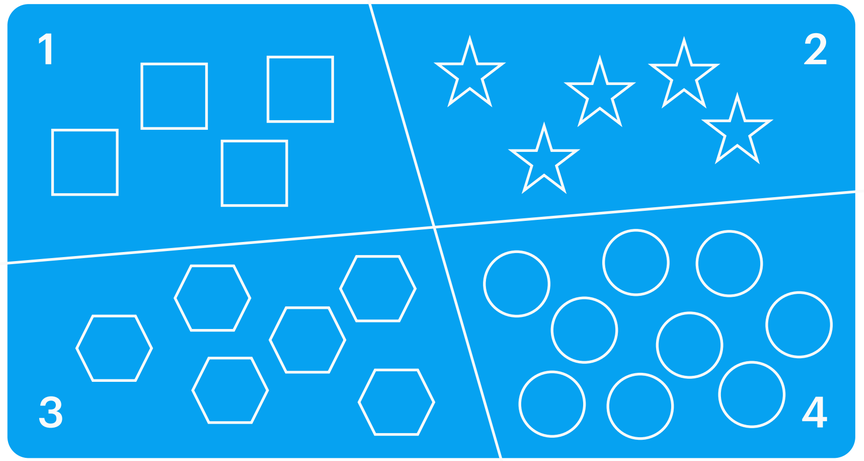


На данном примере мы бы построили 4 бинарных классификатора.

Источник

Подход One-vs-One

1. Для *K* классов обучается *C (k, 2)* модель, каждая — для пары классов.
2. Каждая модель определяет, какой из двух классов «побеждает».
3. «Побеждает» класс, предсказанный чаще всего.

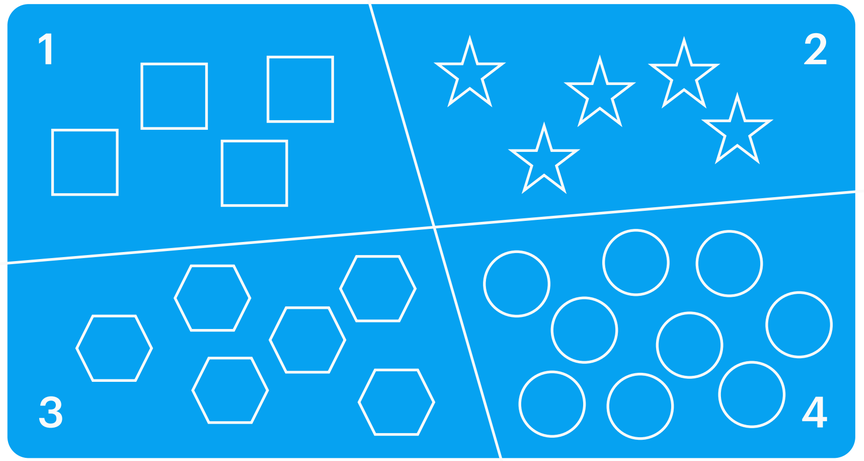


В данном случае мы бы построили 6 бинарных классификаторов.

Источник

Подход Softmax-классификации

1. Используется одна модель, которая обучается предсказывать сразу все классы.
2. Выход модели — вектор вероятностей принадлежности объекта ко всем классам (через Softmax-функцию).
3. Класс с наибольшей вероятностью и будет итоговым предсказанием.



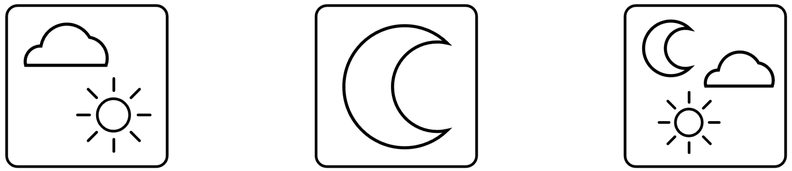
Пример такого подхода к задаче многоклассовой классификации: модель логистической регрессии с определёнными гиперпараметрами.

Источник

Многометочная классификация

Многометочная классификация (англ. multilabel classification) — задача классификации, в которой каждому объекту могут соответствовать несколько классов одновременно, и они не взаимоисключающие (например, теги товара в рекомендательной системе).

Samples



Labels (t)

[1 0 1] [0 1 0] [1 1 1]

В задаче мы работаем с многометочной классификацией.

Возможные классы: «облако»/«солнце»/«месяц». При этом каждому объекту могут подходить несколько классов.

Источник

Сравнение задач классификации

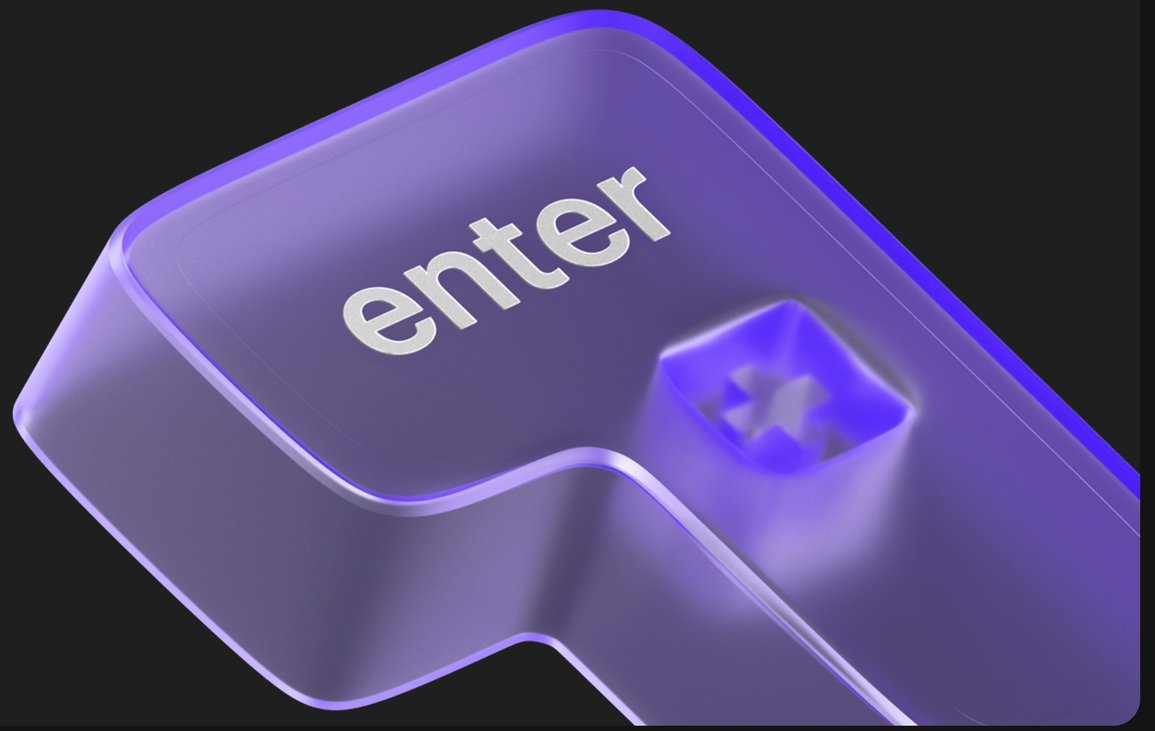
Классификация: есть множество классов, нужно определить, какой/какие из них соответствуют объекту.

Ключевое отличие от регрессии: работаем с конечным множеством вариантов, а не с непрерывными значениями.

Бинарная классификация	Многоклассовая классификация	Многометочная классификация
Всего 2 класса.	Всего *N* классов, но они взаимоисключающие.	Всего N классов, но каждому объекту могут соответствовать несколько классов.
Учимся отличать их друг от друга.	Можем использовать либо One-vs-All, либо One-vs-One, либо Softmax-подход для решения.	Можем рассмотреть как набор независимых бинарных задач — с наличием/отсутствием метки.

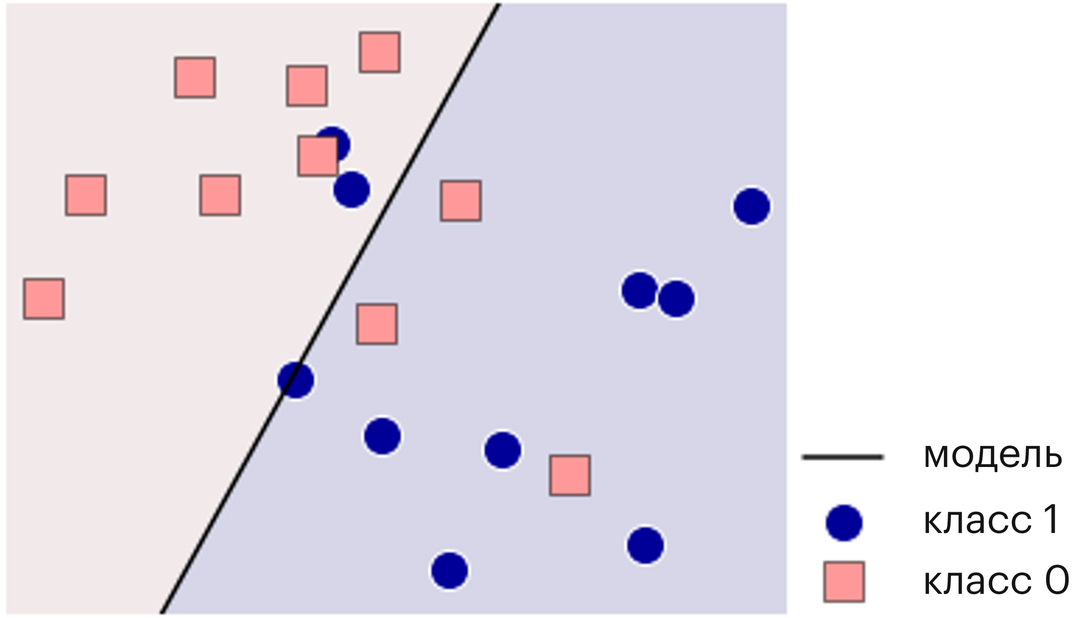
Метрики качества классификации

Бинарные, многоклассовые
и многометочные



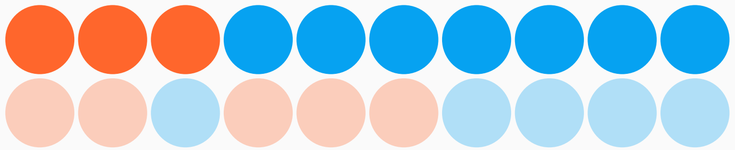
Начнём с задачи бинарной классификации

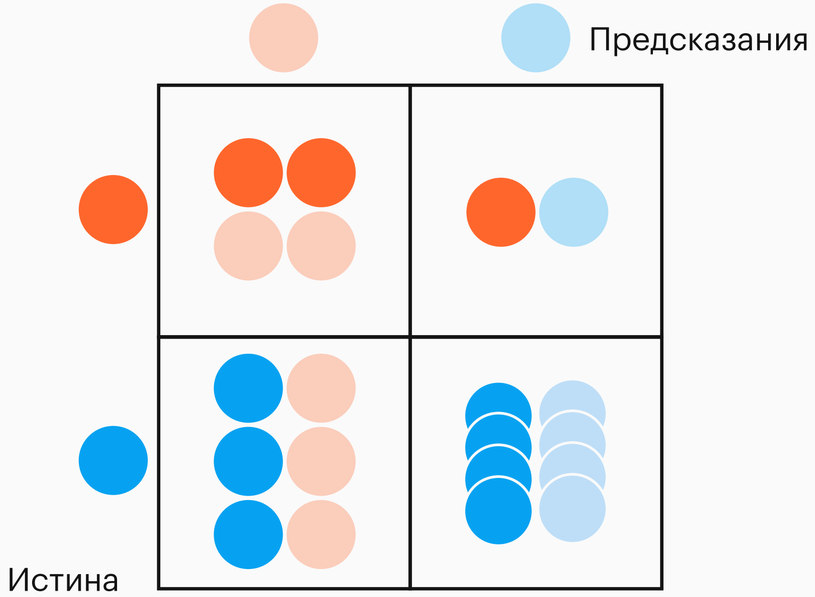
Сперва модель будет предсказывать только итоговую метку класса.
Как оценить такое решение?



«Confusion Matrix»

Для задачи бинарной классификации



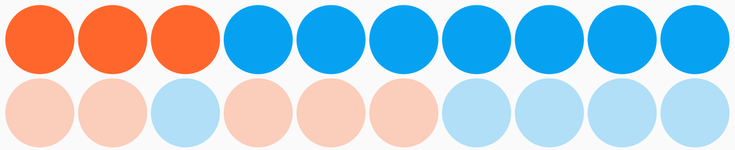


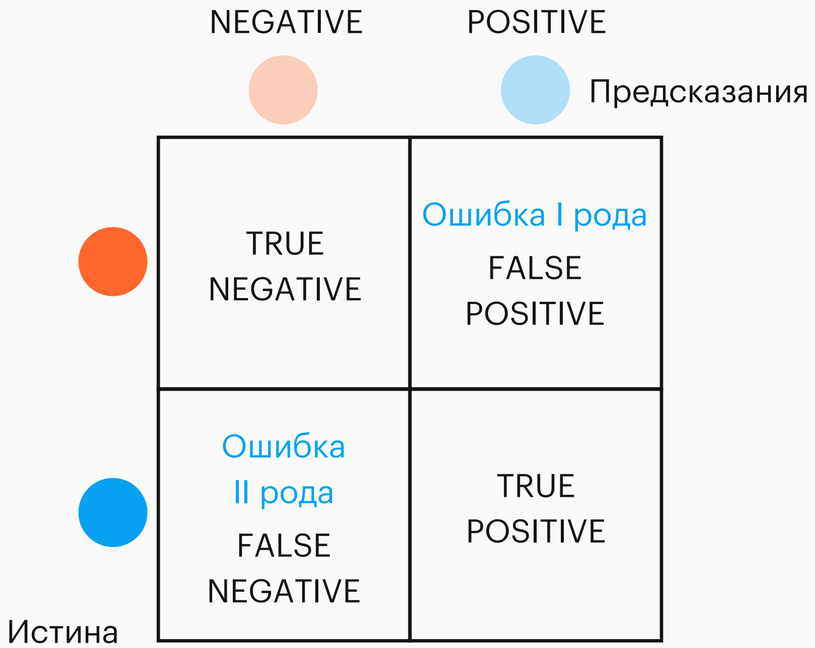
	Предсказание = 0	Предсказание = 1
Истина = 0	13599	2600
Истина = 1	898	903

В sklearn используется именно такая ориентация матрицы.

«Confusion Matrix»

Для задачи бинарной классификации






```
tn, fp, fn, tp = confusion_matrix(y, a).ravel()
# вычисление tn, ...
```

«Confusion Matrix»

Для задачи бинарной классификации

Ошибка I рода: **не учил**, но **сдал**
(= знает по мнению экзаменатора)



Ошибка I рода

$$\mathrm{FP}/\,m$$

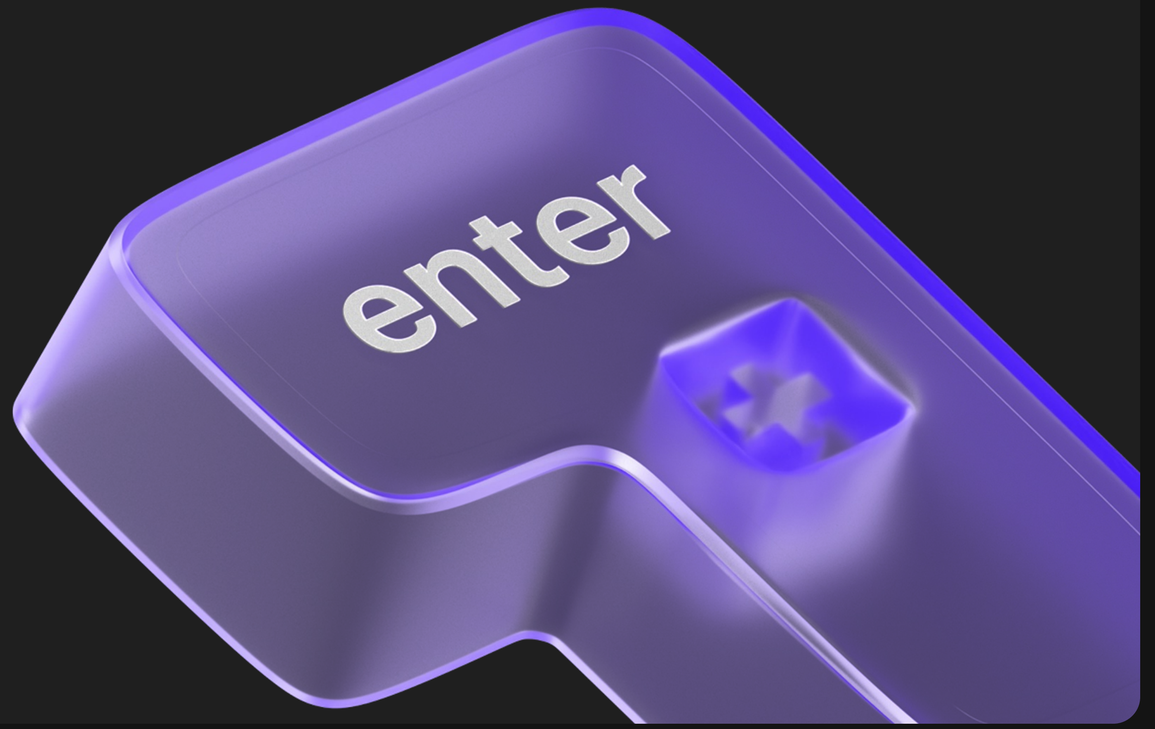
Ошибка II рода: **учил**, но **не сдал**
(= не знает по мнению экзаменатора)



Ошибка II рода

$$\mathrm{FN}/\,m$$

Бинарные метрики качества классификации



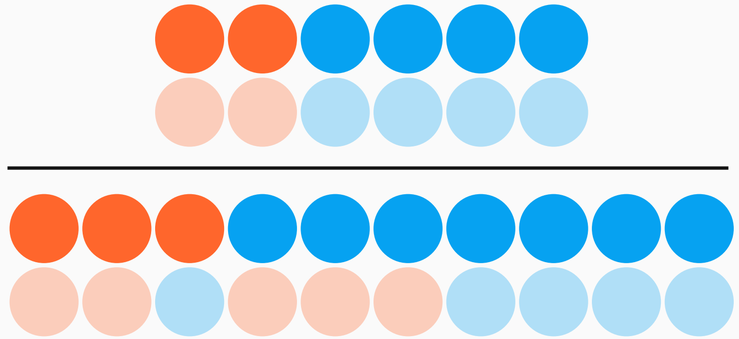
Accuracy

Accuracy Score

Accuracy — метрика классификации, которая показывает долю правильных предсказаний от их общего числа.

С практической точки зрения Accuracy — вероятность того, что модель даст корректный ответ на случайно выбранном объекте.

	$a = 0$	$a = 1$
$y = 0$	13599	2600
$y = 1$	898	903



$$\text{Accuracy} = \frac{\text{TN} + \text{TP}}{\text{TN} + \text{FN} + \text{TP} + \text{FP}}$$

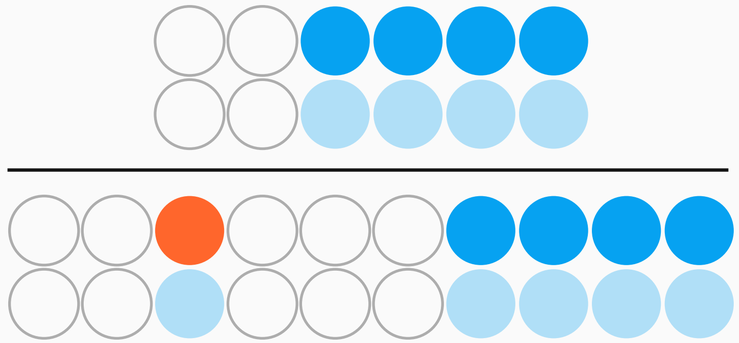
Precision

Precision Score

Precision, или Positive Predictive Value, — метрика, показывающая долю объектов, предсказанных моделью как положительные, которые действительно являются истинно положительными по разметке.

С практической точки зрения Precision отвечает на вопрос: если модель говорит, что объект принадлежит к положительному классу, насколько велика вероятность, что она права?

	$a = 0$	$a = 1$
$y = 0$	13599	2600
$y = 1$	898	903



$$\text{PPV} = P = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

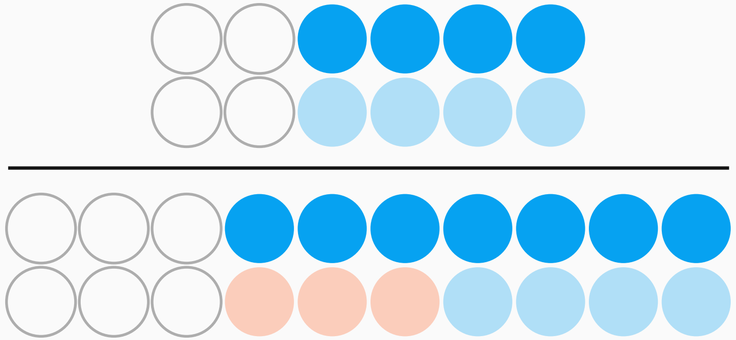
Recall

Recall Score

Recall (True Positive Rate) — это метрика, отражающая долю найденных положительных объектов.

С практической точки зрения Recall отвечает на вопрос: какой процент истинно положительных объектов найдёт модель?

	$a = 0$	$a = 1$
$y = 0$	13599	2600
$y = 1$	898	903



$$\mathrm{TPR} = R = \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FN}}$$

F-Beta Score

F-мера

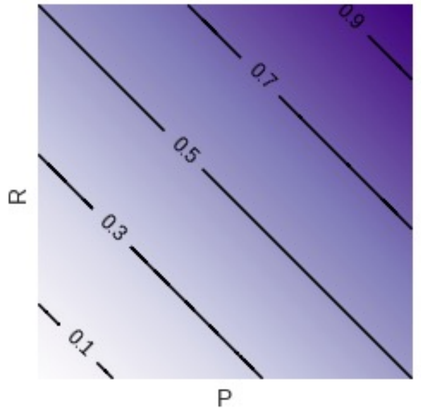
F-Beta Score (F-мера) — это метрика качества классификации, которая объединяет Precision и Recall, позволяя регулировать их относительную важность для задачи с помощью параметра $\boldsymbol{\beta}$.

→ $\boldsymbol{\beta} > \mathbf{1}$ смещает акцент формулы в сторону важности Recall (приоритет на уменьшение количества FN-предсказаний).

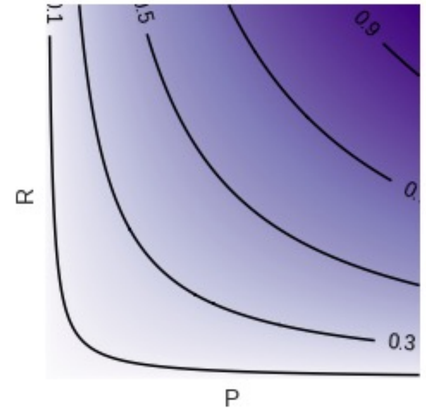
→ $\boldsymbol{\beta} < \mathbf{1}$ смещает акцент формулы в сторону важности Precision (приоритет на уменьшение количества FP-предсказаний).

$$F_\beta = (1 + \beta^2) \times \frac{Precision \times Recall}{(\beta^2 \times Precision) + Recall}$$

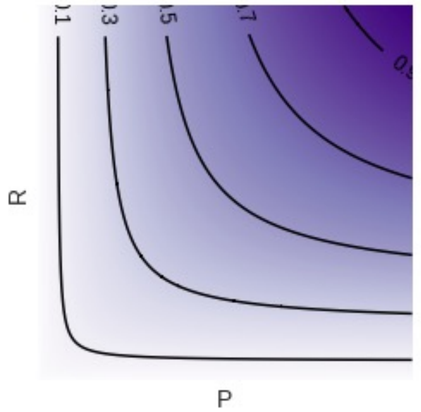
Почему используется F-мера



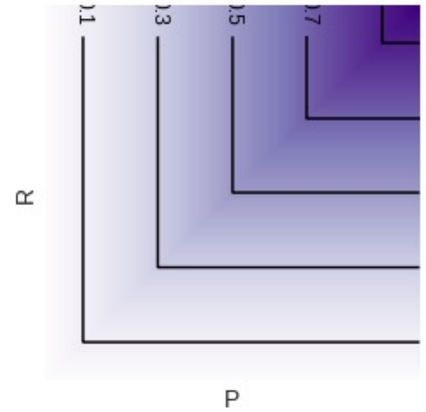
$(P+R)/2$



$\sqrt{P \cdot R}$

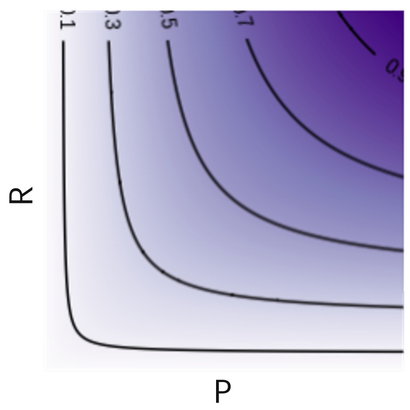


$2/(1/P+1/R)$

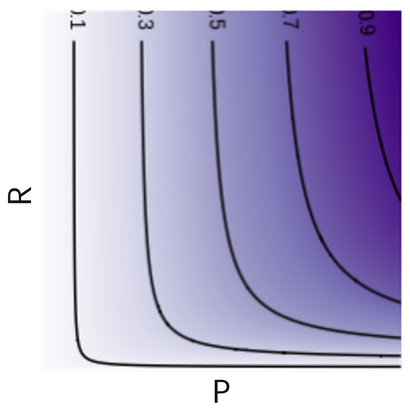


$\min(P,R)$

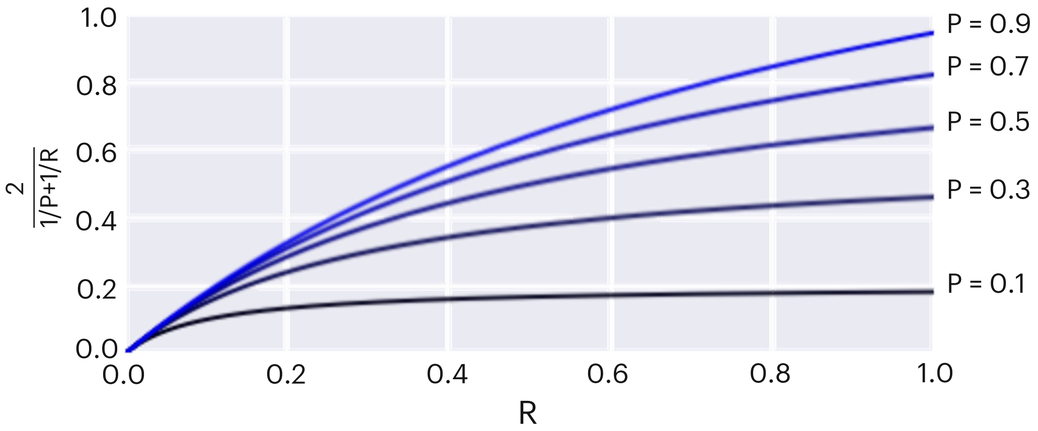
Почему используется F-мера



2 / (1 / P + 1 / R)



1 / (0.9 / P + 0.1 / R)



Можно бесконечно улучшать один из показателей (R), но если второй не увеличивается (P), то качество модели ограничено.

F1-Score

F1-мера

При $\boldsymbol{\beta = 1}$ возникает классический **F1-Score (F1-мера)** — метрика качества классификации, представляющая собой гармоническое среднее между Precision и Recall.

Гармоническое среднее применяется здесь неслучайно: оно штрафует дисбаланс между Precision и Recall. Это делает F1 чувствительной к случаям, когда модель показывает хорошие результаты по одной метрике, но проваливается по другой. Данный аспект важен в большинстве задач с несбалансированными классами.

$$F_1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} = \frac{2 \times TP}{2 \times TP + FP + FN}$$

TPR и FPR

False Positive Rate (FPR) дополняет **True Positive Rate (TPR или Recall)**, измеряя долю отрицательных примеров, ошибочно классифицированных как положительные.

С практической точки зрения FPR отвечает на вопрос: какова доля истинно отрицательных объектов, которые модель ошибочно предсказала как положительные?

	$a = 0$	$a = 1$
$y = 0$	13599	2600
$y = 1$	898	903

$$\mathrm{FPR} = \frac{\mathrm{FP}}{\mathrm{TN} + \mathrm{FP}}$$

Чёткая бинарная классификация

ВЫВОДЫ

Модель уже выдала итоговый класс.

Все правильные ответы и ошибки описываются числами TP, TN, FP и FN.

Что хотим понять	Метрика
Какую долю объектов классифицировали верно	**Accuracy**
Насколько можно доверять прогнозу класса 1	**Precision**
Какую долю объектов класса 1 нашли	**Recall/TPR**
Какую долю объектов класса 0 ошибочно тревожим	**FPR**
Как одним числом учесть precision и recall	**F1 или F-beta**

Усложним условия

Нужно решить задачу нечёткой бинарной классификации.

Модель выдаёт оценку/вероятность принадлежности объекта к классу 1.

$$y \in \{0, 1\} \qquad a \in [0, 1]$$

Кроме меток {0, 1} возможны промежуточные значения, которые можно интерпретировать как вероятности.

Рабочий пример

Для каждой операции модель выдаёт score a_i — чем он выше, тем вероятнее класс 1.

Порог $t = 0.55$ переводит score в итоговый ответ модели.

При пороге $t = 0.55$

$$\hat{y}_i = \begin{cases} 1, & a_i \geq 0.55, \\ 0, & a_i < 0.55. \end{cases}$$

Операция	Score (a_i)	($a_i \geq 0.55$)	Ответ ($\hat{y}_i$)	Факт (y_i)
0	0.95	Да	1	1
1	0.90	Да	1	0
2	0.80	Да	1	1
3	0.70	Да	1	0
4	0.60	Да	1	1
5	0.50	Нет	0	0
6	0.40	Нет	0	1
7	0.30	Нет	0	0
8	0.20	Нет	0	0
9	0.10	Нет	0	0

ЦУ

Как порог меняет precision и recall

Порог t переводит score модели в итоговый класс.

$$\hat{y}_i = \mathbb{1}(a_i \geq t)$$

Меняя порог, мы меняем количество ошибок FP и FN.

Порог ниже

- Больше предсказаний класса 1
- $FN \downarrow$, recall $\uparrow$
- $FP \uparrow$, precision обычно снижается

Порог выше

- Меньше предсказаний класса 1
- $FP \downarrow$, precision обычно растёт
- $FN \uparrow$, recall $\downarrow$

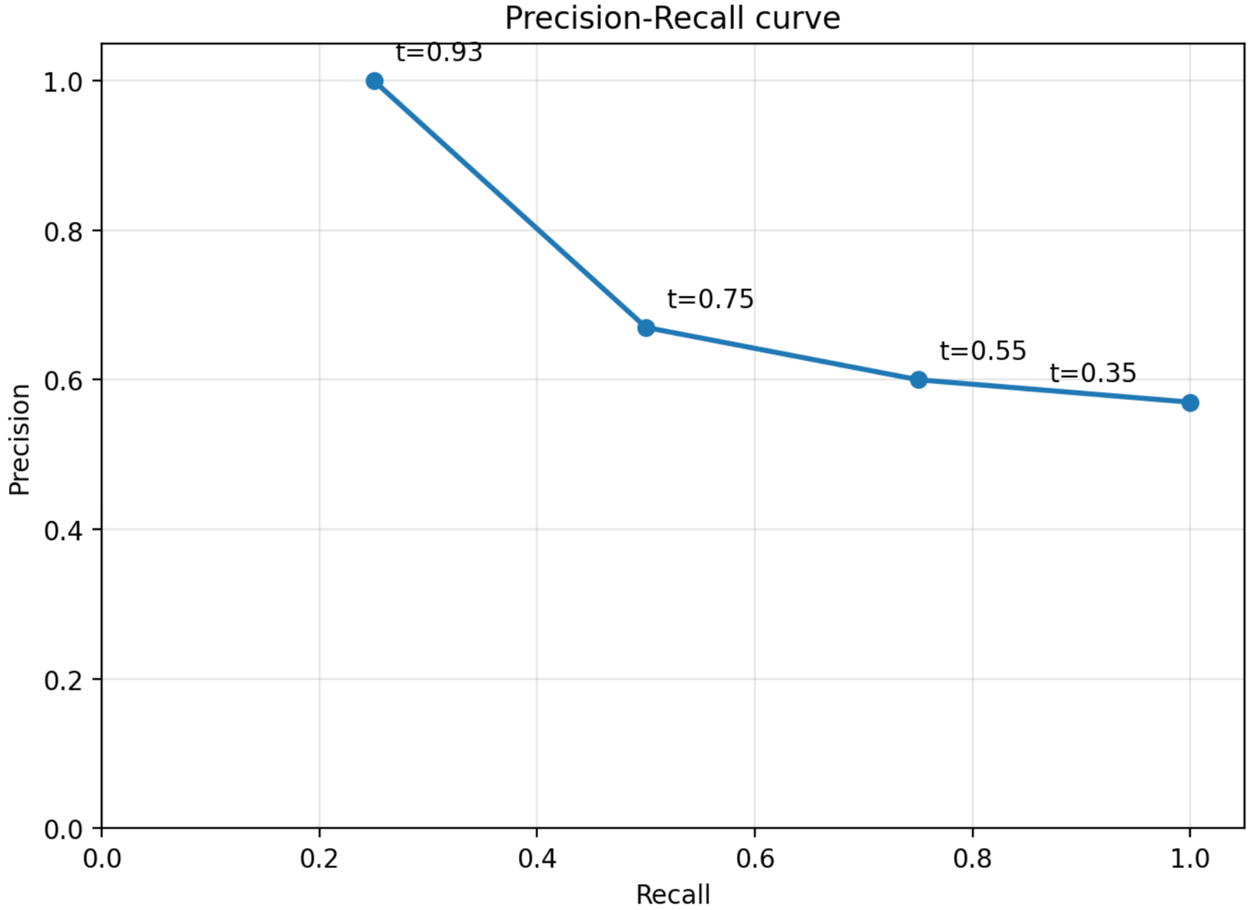
Порог (t)	Precision	Recall
0.93	1.00	0.25
0.75	0.67	0.50
0.55	0.60	0.75
0.35	0.57	1.00

Precision-Recall Curve

Качество при разных порогах

Для каждого значения порога t. получаем свою пару: **precision** и **recall**.

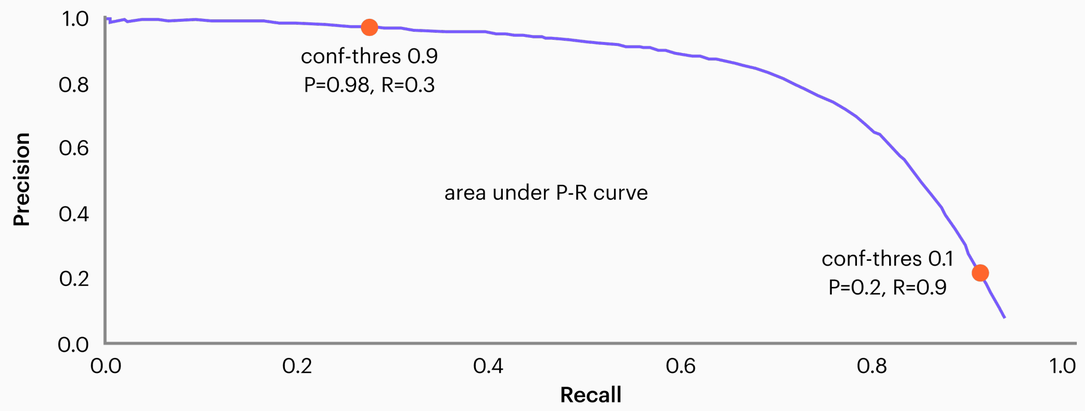
- Каждая точка на кривой соответствует отдельному порогу.
- Чем ближе к правому верхнему углу, тем лучше.
- При снижении порога обычно растёт recall, но снижается precision.



Precision-Recall Curve & area under P-R Curve

Иногда качество модели по всем порогам сводят к одной метрике: площади под Precision-Recall-кривой (area under P-R curve).

Чем больше площадь, тем лучше модель в среднем по порогам.



Бейзлайн для PR-кривой равен доле положительного класса в выборке. Чем выше кривая над baseline и ближе к правому верхнему углу, тем лучше модель.



Precision-Recall Curve

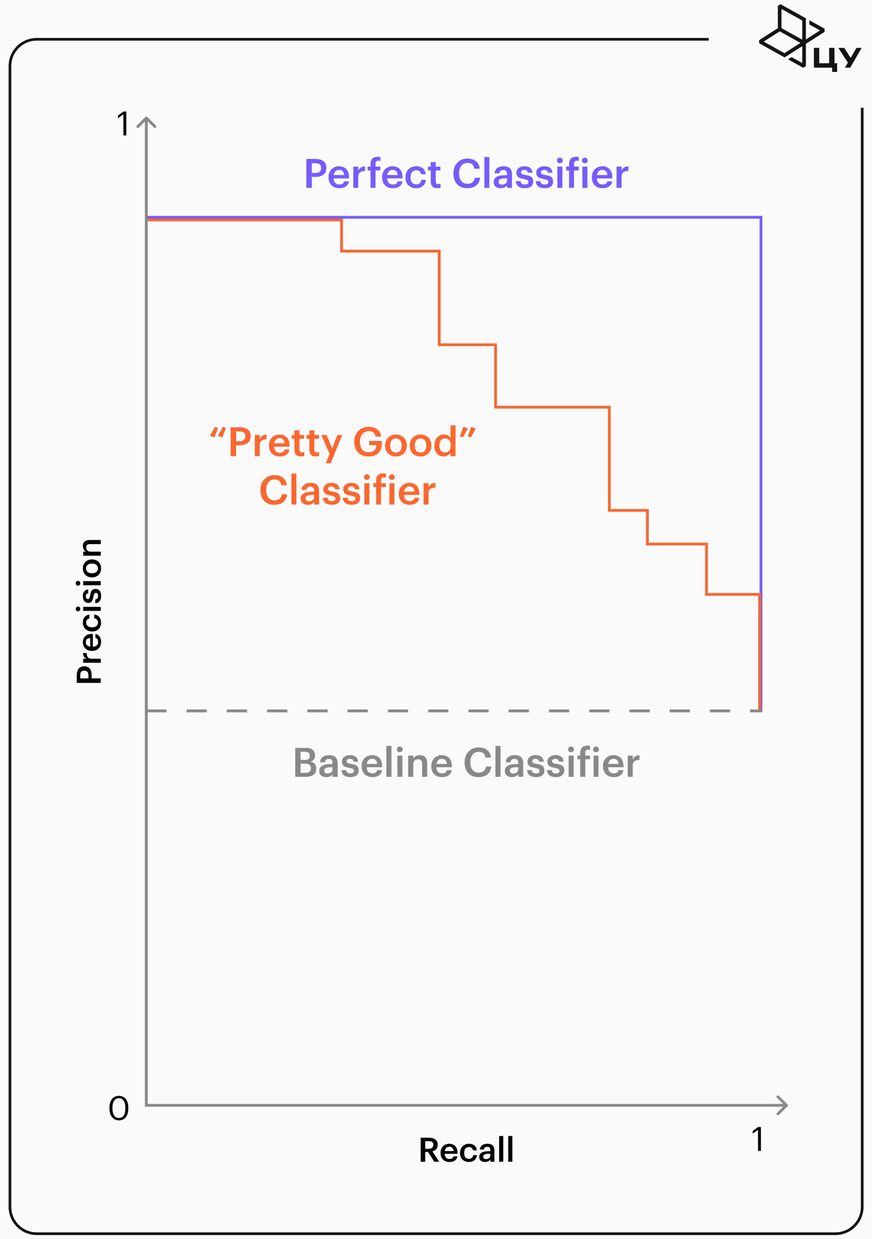
Преимущества и недостатки

Преимущества

- Наглядно показывает компромисс между precision и recall.
- Хорошо отражает качество модели, когда важно находить редкий положительный класс и не допускать слишком много ложных срабатываний.
- Помогает выбрать рабочий порог под нужный баланс между FP и FN.

Недостатки

- Сильно зависит от доли положительного класса в выборке.
- Поэтому значения кривой и PR-AUC нельзя напрямую сравнивать между выборками с разным балансом классов.
- Почти ничего не говорит о качестве на отрицательном классе.



Источник

ROC Curve (ROC-кривая) и AUC-ROC

ROC-кривая (англ. Receiver Operating Characteristic curve) показывает качество бинарного классификатора при разных порогах.

Для каждого порога рассчитываются **TPR** и **FPR**, из которых строится точка ROC-кривой.

$$TPR = \frac{TP}{TP + FN}, \qquad FPR = \frac{FP}{FP + TN}$$

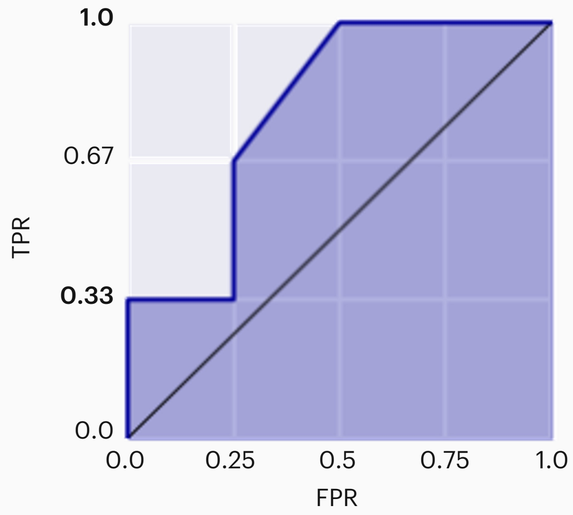
- **TPR:** доля найденных объектов класса 1, то же самое, что recall.
- **FPR:** доля объектов класса 0, ошибочно отнесённых к классу 1.

ROC Curve и AUC-ROC

Функционал зависит не от конкретных значений, а от их порядка

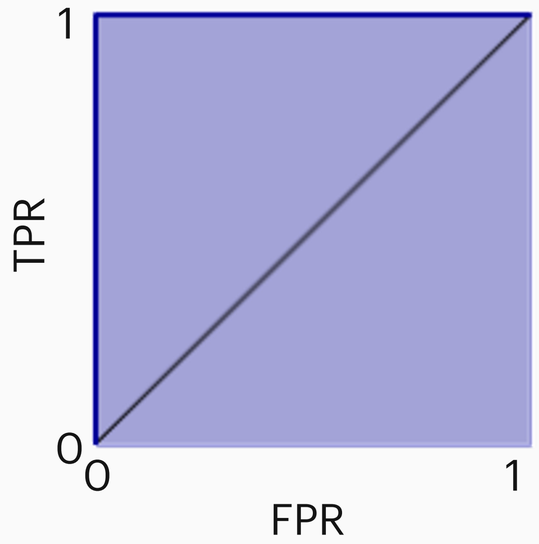
	оценка	класс
0	0.5	0
1	0.1	0
2	0.2	0
3	0.6	1
4	0.2	1
5	0.3	1
6	0.0	0

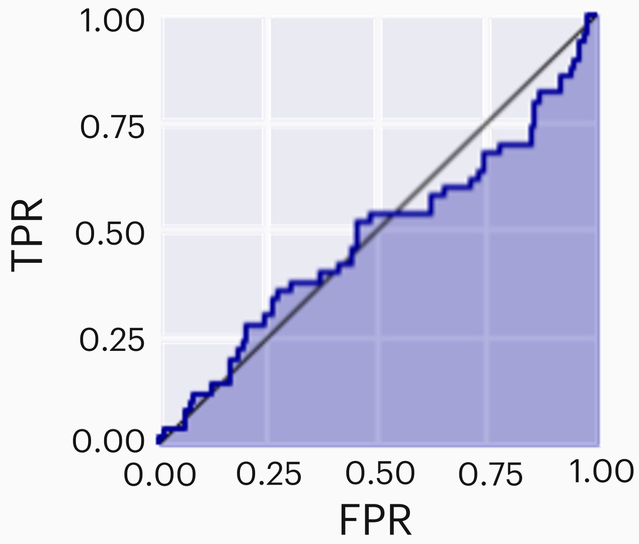
	оценка	класс	ответ
3	0.6	1	1
0	0.5	0	1
5	0.3	1	1
2	0.2	0	0
4	0.2	1	0
1	0.1	0	0
0	0.0	0	0

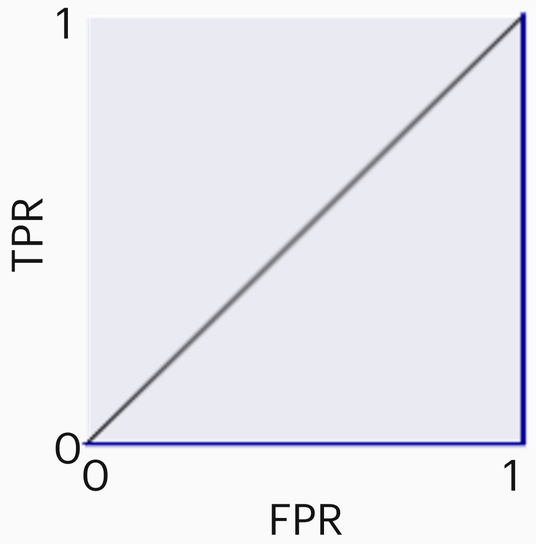



```
df['ответ'] = (df['оценка'] > 0.25).astype(int)
df.sort_values('оценка', ascending False
```

ROC Curve и AUC-ROC







Наилучший (AUC = 1), случайный (AUC ~ 0.5) и наихудший (AUC = 0) алгоритм

AUC = area under the curve

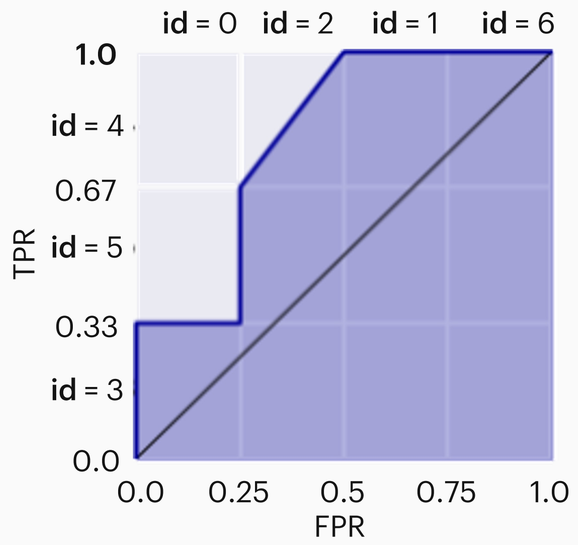
```
from sklearn.metrics import roc_curve
fpr, tpr, thresholds = roc_curve(y_test, a)
plt.plot(fpr, tpr, lw=3, c='#000099')
```

Смысл AUC

AUC — число правильно отсортированных пар (на графике кривой).

Это сложно объяснить заказчику!

$$\mathrm{AUC} = \frac{\sum_{i=1}^{m}\sum_{j=1}^{m} I[y_i < y_j]\, I[a_i < a_j]}{\sum_{i=1}^{m}\sum_{j=1}^{m} I[y_i < y_j]}$$



	оценка	класс	ответ
3	0.6	1	1
0	0.5	0	1
5	0.3	1	1
2	0.2	0	0
4	0.2	1	0
1	0.1	0	0
0	0.0	0	0

Чем хороша эта запись?

Что неправильно или требует пояснения в формуле?

Смысл AUC

Чем удобна запись?

Можно обобщить, например, на регрессию.

Что неправильно или требует пояснения в формуле?

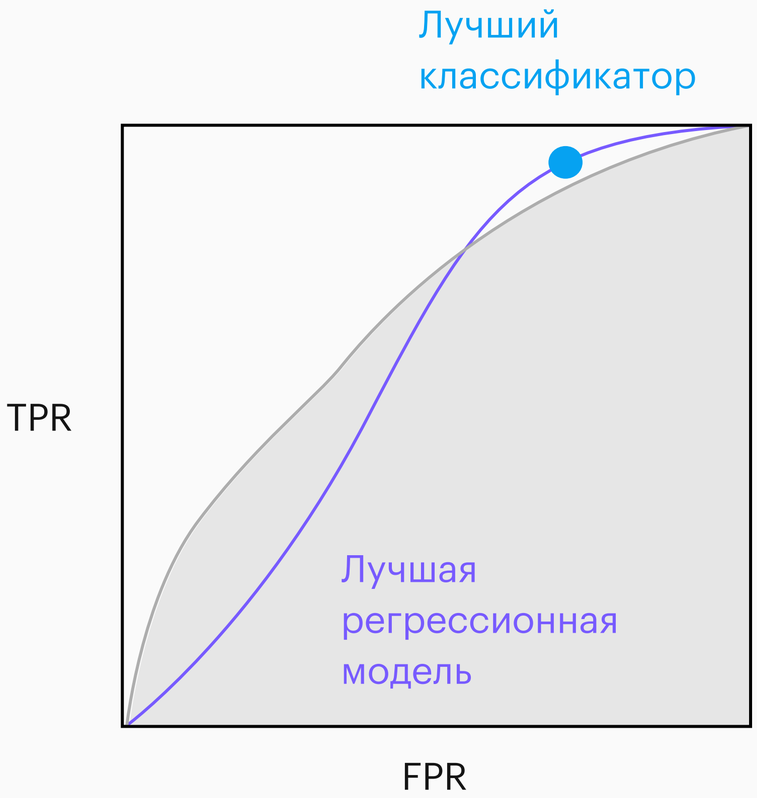
$$\text{AUC} = \frac{\sum_{i=1}^{m}\sum_{j=1}^{m} I[y_i < y_j] I[a_i < a_j]}{\sum_{i=1}^{m}\sum_{j=1}^{m} I[y_i < y_j]}$$

$$I[a_i < a_j] = \begin{cases} 1, & a_i < a_j \\ 1/2, & a_i = a_j \\ 0, & a_i > a_j \end{cases}$$

AUC ROC

Преимущества и недостатки

+	Полезен в задачах, где важен порядок
+	Учитывает разную мощность классов (не зависит от пропорций)
+	Опирается на порядок, а не на значения
+	Можно использовать для оценки признаков
–	«Завышает» качество
–	Оценивает не конкретный классификатор, а регрессию
–	Сложно объяснить заказчику



Log Loss

Во время обучения модель не работает с метриками: она минимизирует определённую функцию потерь (Loss-функцию), которая направляет обновление весов. Для задач классификации одной из наиболее часто используемых функций потерь является **Log Loss**, также известная как **Logistic Loss** или **Cross-Entropy Loss**.

Если нужно предсказать не метку класса, а вероятность его принадлежности к положительному классу, стоит использовать эту функцию потерь.

$$\text{logloss} = -\frac{1}{m}\sum_{i=1}^{m}(y_i \log a_i + (1 - y_i)\log(1 - a_i))$$

Log Loss

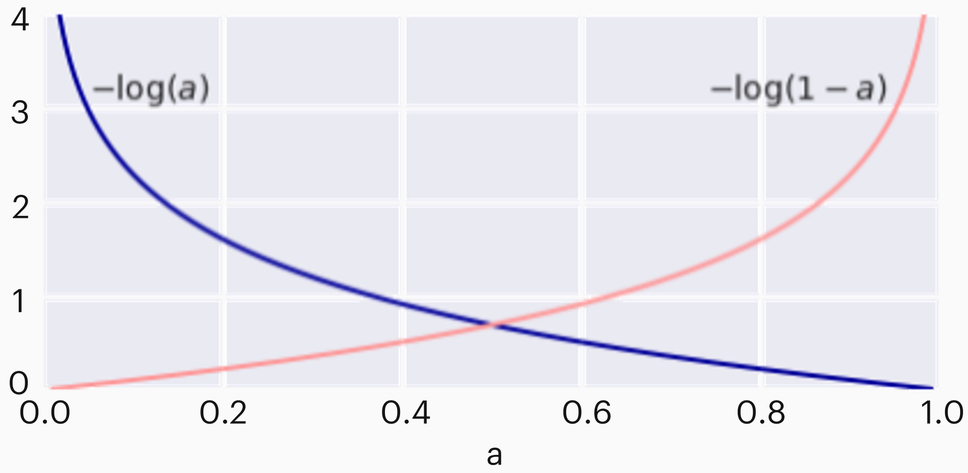
Log Loss применяется в бинарной классификации (классы 0 и 1), где модель возвращает вероятность отнесения объекта к классу 1.

$$\text{logloss} = -\frac{1}{m}\sum_{i=1}^{m}(y_i \log a_i + (1 - y_i)\log(1 - a_i))$$

Раздельная форма записи формулы понятнее:

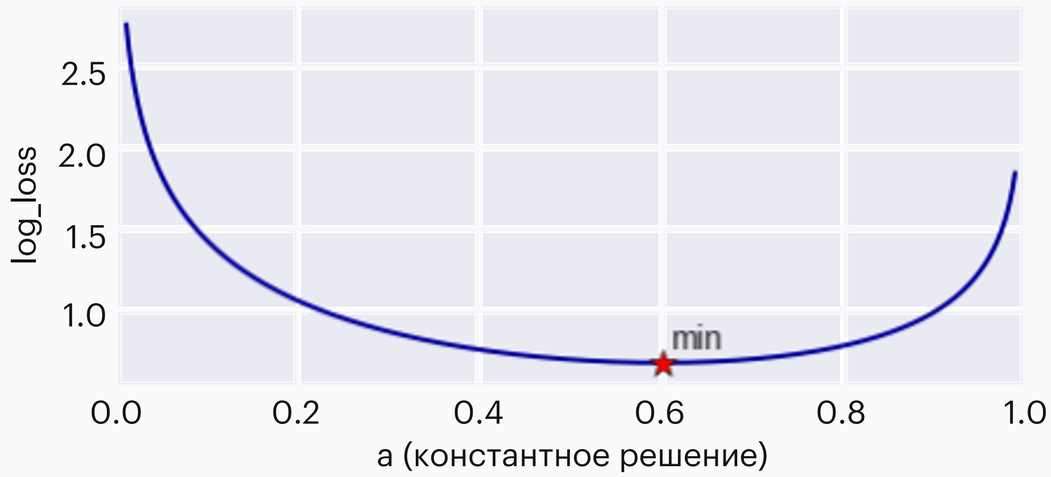
$$-\begin{cases} \log a_i, & y_i = 1 \\ \log(1 - a_i), & y_i = 0 \end{cases}$$

Нельзя ошибаться: чем увереннее и точнее модель в предсказании — тем лучше.



Log Loss

Оптимальная константа для конечной выборки



$$-\frac{1}{m}\sum_{i=1}^{m}(y_i \log a + (1-y_i)\log(1-a)) \to \min_a$$

$$-\frac{m_1}{m}\log a - \frac{m_0}{m}\log(1-a) \to \min_a$$

$$a = \frac{m_1}{m}$$

Log Loss

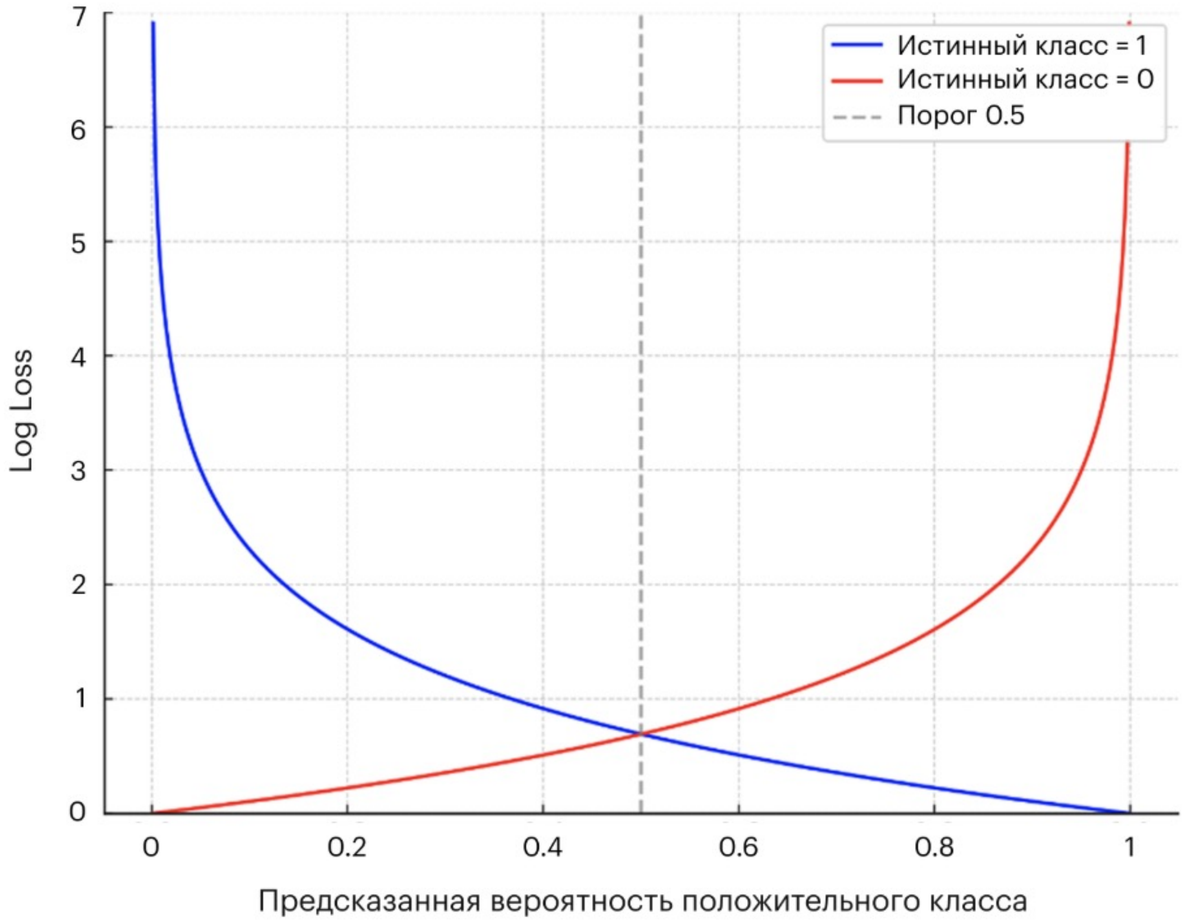
Преимущества и недостатки

Преимущества

- Учитывает не только правильность ответа, но и уверенность модели
- Не требует выбора порога классификации
- Гладкая и дифференцируемая функция, удобная для обучения моделей

Недостатки

- Слабо интерпретируется в абсолютных значениях.
- Сильно штрафует уверенные ошибки и чувствителен к шуму в разметке.
- Требует вероятностных прогнозов, а не произвольных скоров.
- Не показывает качество модели при конкретном рабочем пороге.



Нечёткая бинарная классификация

ВЫВОДЫ

Модель выдаёт score a_i.

Порог t переводит его в итоговый класс.

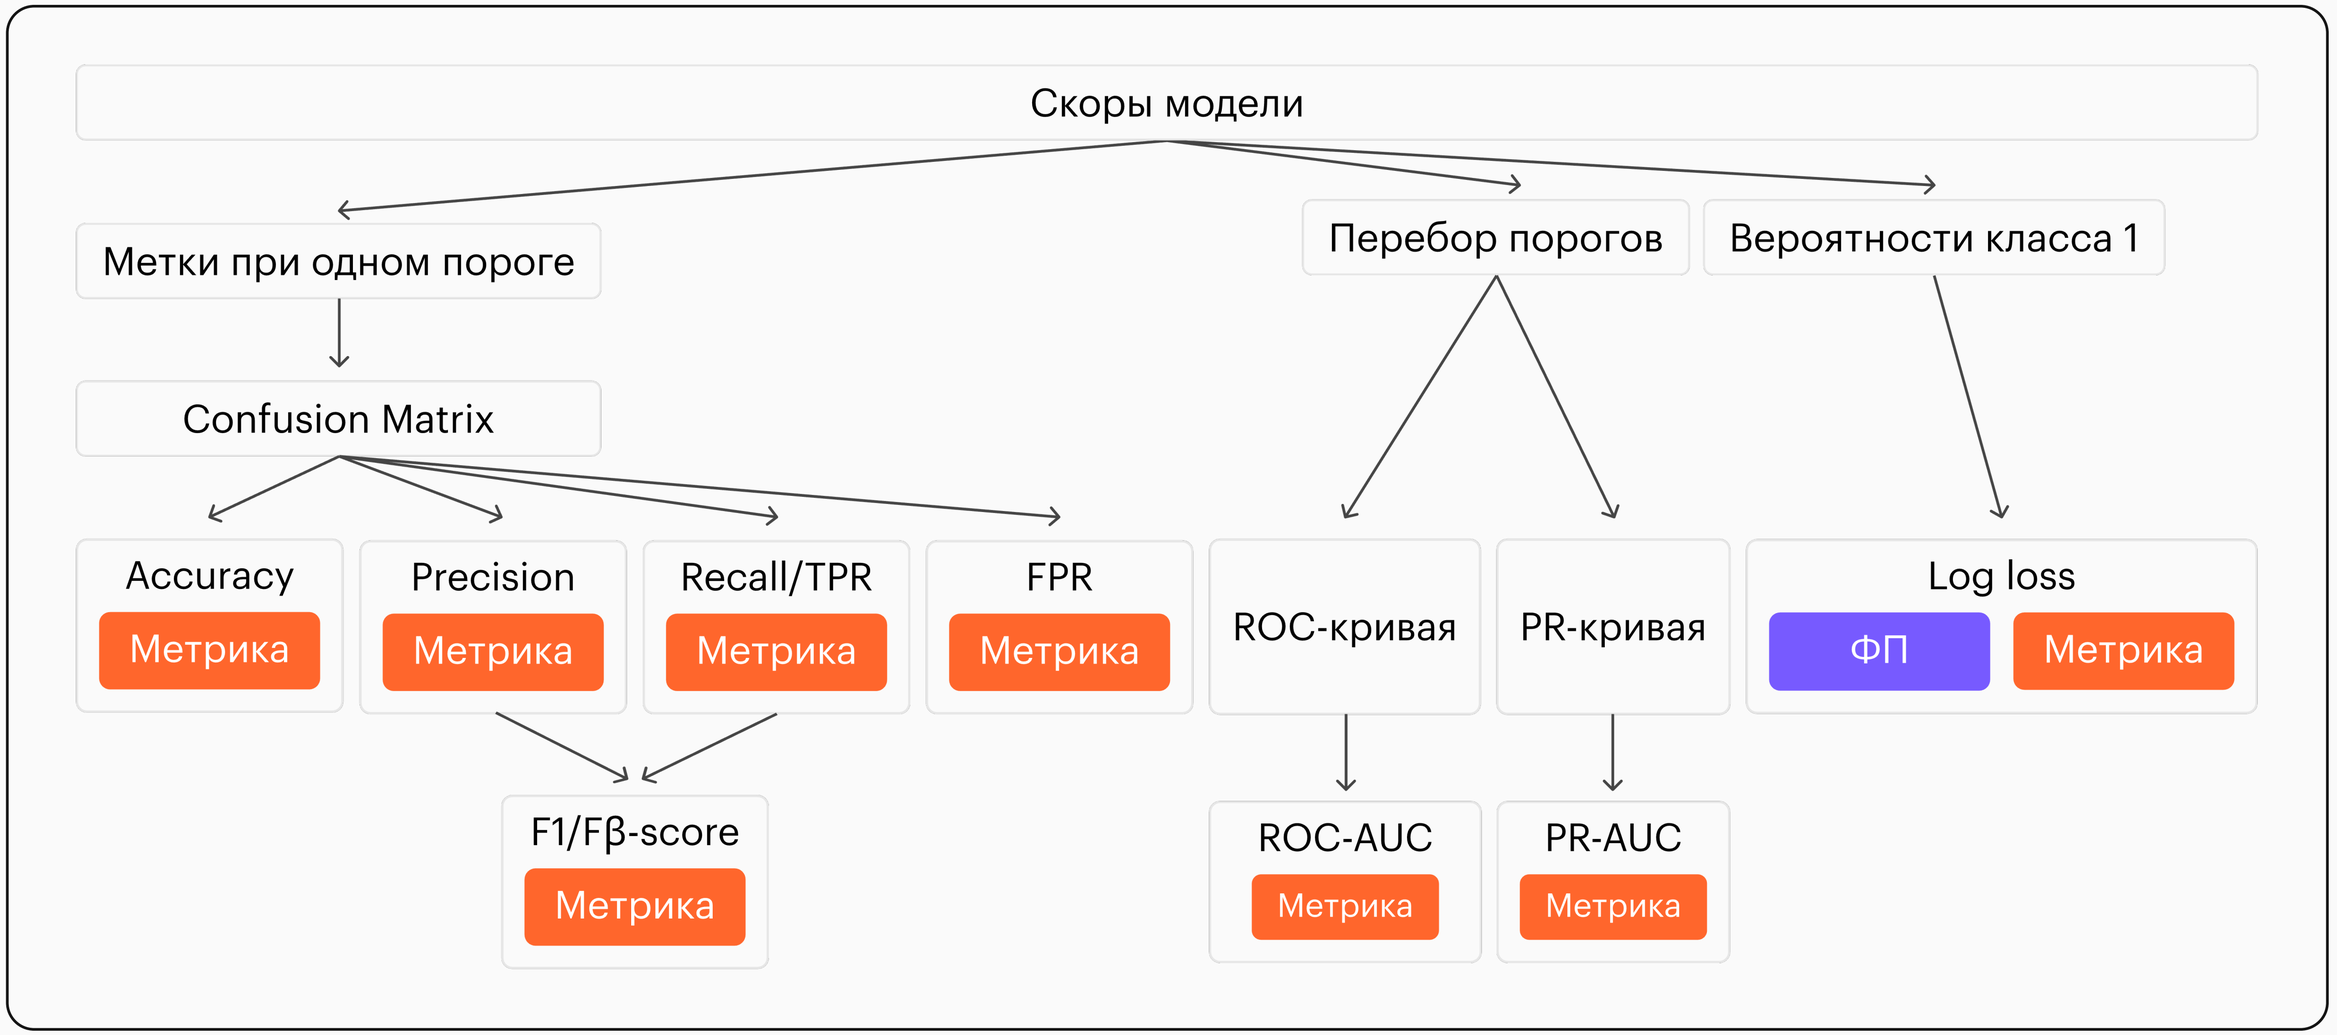
$$\hat{y}_i = \mathbb{1}(a_i \geq t)$$

Для ROC/PR важен **порядок** значений score.

При использовании Log Loss прогноз модели интерпретируется как **вероятность** класса 1.

Что хотим понять	Метрика или инструмент
Качество итоговых решений при выбранном пороге	**Precision, recall, F1, FPR**
Как меняется качество при изменении порога	**PR-кривая, ROC-кривая**
Насколько хорошо модель ранжирует классы	**ROC-AUC**
Как модель находит редкий положительный класс	**PR-AUC**
Насколько качественны предсказанные вероятности	**Log loss**

Карта ФП и метрик бинарной классификации



*Метрики также могут использоваться как целевые функционалы при подборе порога, гиперпараметров и в специальных алгоритмах прямой оптимизации

Пример подбора ФП и метрики классификации

Кейс 1. Поиск читеров в онлайн-игре

По поведению игрока определяем, использует ли он запрещённые программы.

- Читеры встречаются редко.
- Ошибочный бан честного игрока очень дорог.
- Среди заблокированных игроков почти не должно быть невиновных.

Кейс 2. Поиск дефектов на производстве

По фотографии определяем, есть ли на детали дефект.

- Пропущенный дефект может привести к поломке продукта.
- Ложное срабатывание означает только дополнительную проверку.
- Особенно важно находить почти все дефектные детали.

Кейс 3. Прогноз отмены бронирования

Предсказываем вероятность того, что гость отменит бронь в отеле.

- Прогноз используется для планирования загрузки номеров.
- Важна не только метка «отменит / не отменит», но и сама вероятность.
- Слишком завышенные и заниженные вероятности одинаково вредны.

Пример подбора ФП и метрики классификации

Кейс 1. Поиск читеров в онлайн-игре

По поведению игрока определяем, использует ли он запрещённые программы.

- Читеры встречаются редко.
- Ошибочный бан честного игрока очень дорог.
- Среди заблокированных игроков почти не должно быть невиновных.

- **ФП:** log loss.
- **Для сравнения моделей**: PR-AUC, так как читеры редкие.
- **После выбора порога:** precision, recall и FPR.
- **Правило выбора порога:** обеспечить требуемую precision, затем максимизировать recall.

Кейс 2. Поиск дефектов на производстве

По фотографии определяем, есть ли на детали дефект.

- Пропущенный дефект может привести к поломке продукта.
- Ложное срабатывание означает только дополнительную проверку.
- Особенно важно находить почти все дефектные детали.

- **ФП:** log loss.
- **Для сравнения моделей:** PR-AUC, так как дефекты редкие.
- **После выбора порога:** recall и precision.
- **Правило выбора порога:** обеспечить требуемый recall, затем максимизировать precision.

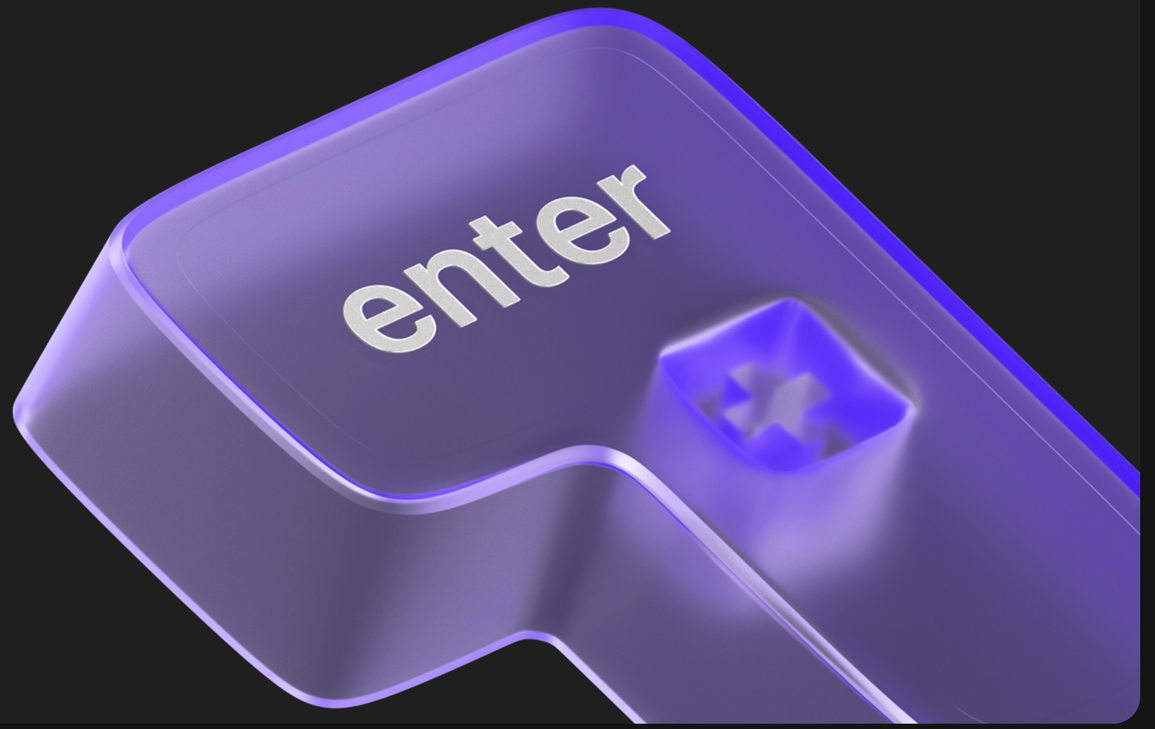
Кейс 3. Прогноз отмены бронирования

Предсказываем вероятность того, что гость отменит бронь в отеле.

- Прогноз используется для планирования загрузки номеров.
- Важна не только метка «отменит / не отменит», но и сама вероятность.
- Слишком завышенные и заниженные вероятности одинаково вредны.

- **ФП:** log loss.
- **Основная метрика:** log loss.
- **Дополнительно:** ROC-AUC для проверки качества ранжирования.
- **Порог:** не обязателен, если в процессе используется сама вероятность.

Метрики многоклассовой и многометочной классификации



Как получить одну метрику для нескольких классов

Самое простое — посмотреть sklearn.metrics.classification_report!

	precision	recall	f1-score	support
Автомобили	0.79	0.84	0.81	389
Мотоциклы	0.80	0.75	0.77	396
Бейсбол	0.66	0.83	0.73	398
Хоккей	0.84	0.82	0.83	397
Медицина	0.92	0.87	0.89	399
Космос	0.74	0.71	0.72	393
Компьютерная графика	0.86	0.81	0.83	396
Электроника	0.84	0.76	0.80	394
accuracy			0.80	3162
macro avg	0.80	0.80	0.80	3162
weighted avg	0.80	0.80	0.80	3162

Варианты усреднения

Для получения сводной оценки модели по всем классам результат расчёта бинарной метрики для каждого класса необходимо агрегировать в единое итоговое значение.

Для этого существует несколько видов усреднения

Макроусреднение	Микроусреднение	Взвешенное усреднение

Пример

Пример: 10 объектов, 3 класса.

По одной матрице ошибок смотрим три способа усреднения:

Истинный класс	Прогноз A	Прогноз B	Прогноз C	Объектов
A	4	2	0	6
B	1	2	0	3
C	0	0	1	1

Макроусреднение

Макроусреднение (англ. macro-averaging) предлагает:

1) рассчитать выбранную бинарную метрику (например, Precision, Recall или F1) отдельно для каждого класса;
2) усреднить их результат.

$$Precision_{macro} = \frac{1}{K}\sum_{i=1}^{K} Precision_i$$

где K — количество классов.

Пример: 10 объектов, 3 класса

$Precision_A = 4/5 = 0{,}80$

$Precision_B = 2/4 = 0{,}50$

$Precision_C = 1/1 = 1{,}00$

$Precision_{macro} = (0{,}80 + 0{,}50 + 1{,}00)/3 = 0{,}77$

Все классы имеют одинаковый вес.

Микроусреднение

Микроусреднение (англ. micro-averaging) предлагает:

1) построить One-vs-All Confusion Matrix для каждого класса;
2) вычислить суммарные TP, FP и FN по всем классам;
3) на их основе рассчитать финальное значение выбранной метрики.

Стоит обратить внимание на то, что в этом случае нет расчёта метрик по каждому классу отдельно — всё агрегируется сразу.

$$Precision_{micro} = \frac{\sum_{i=1}^{K} TP_i}{\sum_{i=1}^{K} (TP_i + FP_i)}$$

Пример многоклассового Precision с микроусреднением.

Пример: 10 объектов, 3 класса

Суммарный TP = 4 + 2 + 1 = 7
Суммарный FP = 1 + 2 + 0 = 3

$Precision_{micro} = 7/(7 + 3) = 0{,}70$

Все решения объединяются до расчета метрики.

Взвешенное усреднение

Взвешенное усреднение (англ. weighted-averaging) предлагает:

1) рассчитать выбранную бинарную метрику (например, Precision, Recall и F1) отдельно для каждого класса;
2) усреднить их с учётом доли каждого класса (вес пропорционален количеству примеров класса).

В итоге классы с большим числом объектов повлияют на итоговый результат сильнее.

$$Precision_{weighted} = \frac{\sum_{i=1}^{K} Precision_i \times n_i}{\sum_{i=1}^{K} n_i}$$

где n_i — количество объектов класса i

Пример: 10 объектов, 3 класса

В классах A, B и C: 6, 3 и 1 объект соответственно.

$$Precision_{weighted} = (6 * 0{,}80 + 3 * 0{,}50 + 1 * 1{,}00)/10 = 0{,}73$$

Вес класса равен его доле в выборке.

Сводная таблица по усреднениям

Вид усреднения	Как считается	Что особенно важно	Когда использовать
Macro	Среднее по классам	Класс	Когда важно, чтобы предсказания на всех классах (в том числе редких) были равнозначными, без сильного перекоса в один из классов
Micro	Сумма по наблюдениям	Предсказание	Когда важен общий результат по всем объектам, частые классы влияют сильнее
Weighted	Среднее по классам с весами	Класс с учётом веса	Когда распределение классов соответствует реальному потоку и его нужно сохранить в итоговой оценке

Hamming Score

Hamming Score — это ML-метрика для многометочных задач, которая показывает верно предсказанную долю всех меток (и положительных, и отрицательных).

$$Hamming\ score = \frac{1}{n_{samples} \times n_{labels}} \sum_{i=1}^{n_{samples}} \sum_{j=1}^{n_{labels}} 1(y_{i,j} = \hat{y}_{i,j})$$

где $y_{i,j}$ — истинное значение метки j для объекта i;

$\hat{y}_{i,j}$ — предсказанная моделью метка;

$1(.)$ — индикатор (1 — если условие выполняется, в других случаях — 0).

Многоклассовая задача: Log Loss

Cross-Entropy

Естественное обобщение логистической ошибки:

$$a_{ij} \in [0,1]$$

$$\text{logloss} = -\frac{1}{m}\sum_{i=1}^{m}\sum_{j=1}^{l} y_{ij} \log a_{ij}$$

Стоит обратить внимание — лучше для непересекающихся классов:

$\{a_{ij}\}_{j=1}^{l}$ ~ распределение, $\sum_j a_{ij} = 1$

В задаче с пересекающимися классами (Multilabel):

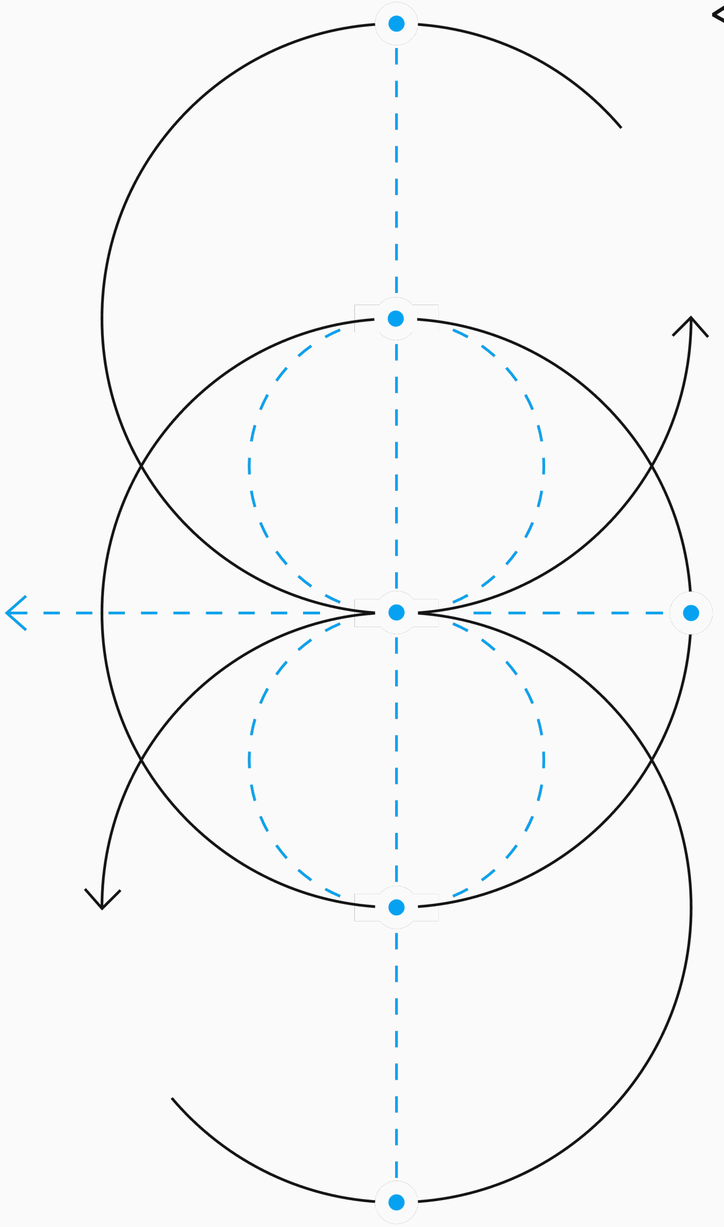
$$\text{logloss}_{\text{multi-label}} = -\frac{1}{l}\frac{1}{m}\sum_{j=1}^{l}\sum_{i=1}^{m}(y_{ij} \log a_{ij} + (1 - y_{ij}) \log(1 - a_{ij}))$$

$a_{ij} \in [0,1]$ — макроусреднение Log Loss по классам.

Разница между Multiclass- и Multilabel-задачами

→ **Multiclass:** качество оценивается по классам с помощью Macro-, Micro- или Weighted-усреднения.

→ **Multilabel:** каждая метка рассматривается как отдельная бинарная задача, результаты агрегируются по меткам или по объектам

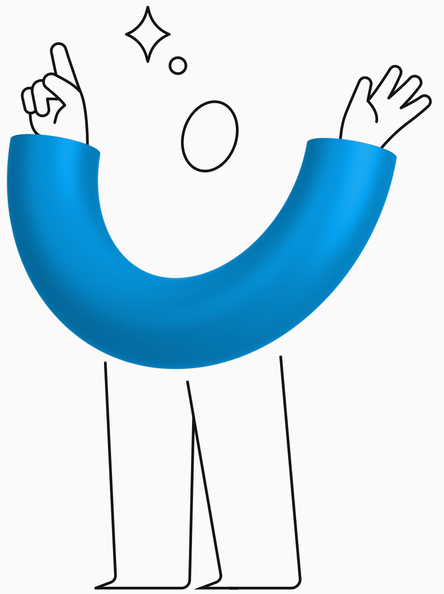


Итоги лекции

01 | 02 | 03 | 04

→ **Классификация:** есть множество классов, нужно определить, какой/какие из них соответствуют объекту.

→ Задачи классификации делятся на **бинарные, многоклассовые** и **многометочные.**



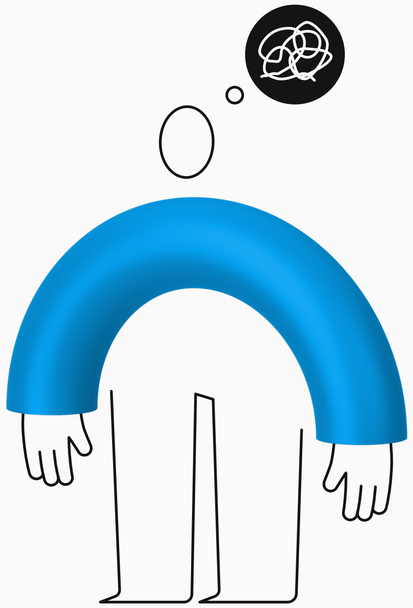
Итоги лекции

01 | 02 | 03 | 04

→ Многоклассовую классификацию можно решать через подходы:

- **One-vs-All**
- **One-vs-One**
- **Softmax**

→ Confusion Matrix — основа метрик классификации при фиксированном пороге.



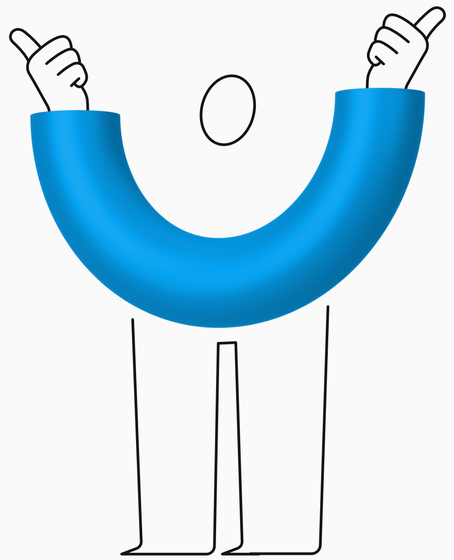
Итоги лекции

01 | 02 | **03** | 04

→ Метрики качества классификации с разной логикой:

- **Accuracy, Precision, Recall**
- **F-Beta Score, F1-Score**
- **ROC-AUC**, PR-AUC

→ **Log Loss / Cross-Entropy** — функции потерь для задачи классификации.

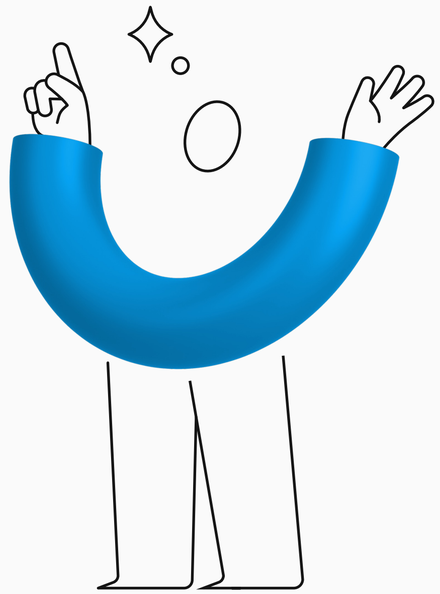


Итоги лекции

01 02 03 04

→ **Micro-, Macro-, Weighted**-усреднения используются для оценки качества многоклассовых моделей классификации.

→ **Hamming Score** — метрика для многометочной классификации.





ЦЕНТРАЛЬНЫЙ УНИВЕРСИТЕТ



Вопросы