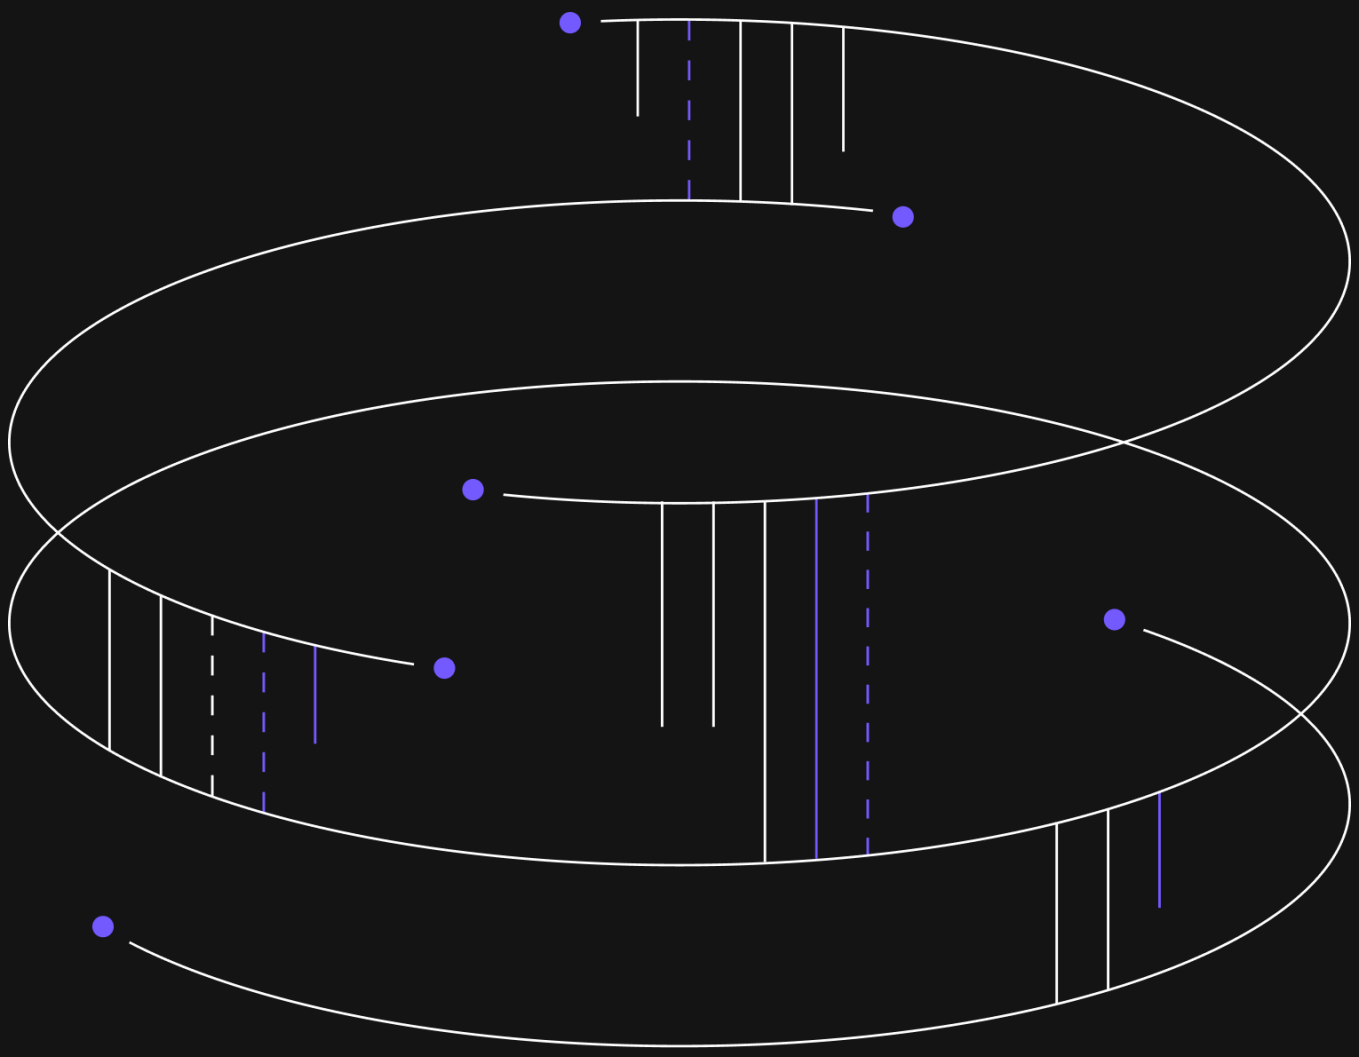
Аналитика

Лонгрид

Python для анализа данных

07

Когортный анализ



Уровень сложности: средний

Время чтения: ~35 минут

Цель материала: изучить методы проведения когортного анализа, подготовку данных (витрин) в Pandas, транкование дат и расчёт метрик абсолютного и относительного клиентского удержания (Retention).

КОНТЕКСТ

Когортный анализ представляет собой расчёт продуктовых и финансовых показателей для каждой когорты пользователей по отдельности.

Когорта — это сегмент пользователей, схожих друг с другом датой своего «продуктового рождения». Под продуктовым рождением чаще всего подразумевается дата регистрации или дата первого контакта пользователя с продуктом (например, совершение первой покупки или оформление подписки).

Примеры когорт:

- множество пользователей, зарегистрировавшихся в сентябре 2023 года, — месячная когорта сентября 2023 года;
- пользователи, впервые посмотревшие фильм в онлайн-кинотеатре в 2022 году, — годовая когорта 2022 года.

Зачем нужен когортный анализ? Он позволяет отслеживать изменения в поведении пользователей во времени, выявлять «уязвимые» с точки зрения клиентского опыта когорты и сравнивать эффективность маркетинговых кампаний, запущенных в разные периоды (например, не привлекли ли мы ботов вместо реальных клиентов).

1. ОПРЕДЕЛЕНИЕ КОГОРТЫ И ПЕРВИЧНАЯ ГРУППИРОВКА

Для начала необходимо исследовать данные и определить самую раннюю дату активности для каждого клиента. Это и будет дата, определяющая его когорту.

Для этого используется метод группировки по идентификатору клиента (id_client) с применением агрегации (agg) для поиска минимума по колонке с датами:

```
df_cls_minreg = df_cls.groupby('id_client').agg(min_date_reg=('date_reg',
'min')).reset_index()
```

Также на этом этапе часто рассчитывают общее количество целевых действий (например, количество подписок) для каждого клиента, используя агрегацию с функцией count.

2. ТРАНКОВАНИЕ (УСЕЧЕНИЕ) ДАТ

Винтаж — это гранулярность (размерность) периода, для которого будет произведён расчёт Retention. Чаще всего винтажом выступает месяц.

Поскольку в исходных данных дата обычно содержит точные дни, часы и минуты, её нужно привести к формату месяца (обрезать/транковать до первого числа месяца). В Pandas для этого используется перевод даты в периодический формат и обратно в timestamp:

```
df_cls_minreg['month_min_reg'] =
df_cls_minreg['min_date_reg'].dt.to_period('M').dt.to_timestamp()
```

3. ФОРМИРОВАНИЕ КЛИЕНТСКОЙ ВИТРИНЫ

Для дальнейших расчётов сырые данные нужно привести в удобный вид. Слияние таблицы с самыми ранними датами регистрации и таблицы с общим количеством действий клиента образует так называемую витрину — готовую, очищенную таблицу, хранящую агрегированную информацию об основных статистических единицах (клиентах).

```
df_vitr = df_cnt_by_client.merge(df_minreg_by_client, how='inner',
on='id_client')
```

4. РАСЧЁТ КЛИЕНТСКОГО УДЕРЖАНИЯ (RETENTION)

ОПРЕДЕЛЕНИЕ

Retention (удержание) — это показатель, отражающий динамику обновления клиентской базы. В подписочных сервисах он показывает, какая часть клиентов продлевает подписку из месяца в месяц.

Абсолютный Retention выражается в абсолютных числах (количество людей). Рассчитывается с помощью группировки по когортам и применения лямбда-функций для подсчёта пользователей, совершивших N и более действий:

```
df_coh = df_vitr.groupby('month_min_reg').agg(
    cnt_all=('cnt_reg', lambda x: (x >= 1).sum()),
    cnt_1=('cnt_reg', lambda x: (x >= 2).sum()),
    cnt_2=('cnt_reg', lambda x: (x >= 3).sum())
).reset_index()
```

Относительный Retention показывает удержание в долях (или процентах) от изначального размера когорты. Для его расчёта абсолютный показатель целевого месяца делится на общее число людей в когорте:

```
df_coh['ret_1'] = df_coh['cnt_1'] / df_coh['cnt_all']
df_coh['ret_2'] = df_coh['cnt_2'] / df_coh['cnt_all']
```

5. РАБОТА С НЕПОЛНЫМИ ДАННЫМИ (АНОМАЛИИ)

При анализе когорт можно столкнуться с аномалиями. Например, последний месяц в датасете может показывать крайне низкие значения. Обычно это связано не с реальным оттоком, а с тем, что данные охватывают лишь начало месяца (период ещё не закрыт). Поэтому неполные (последние) когорты рекомендуется исключать из анализа, чтобы они не искажали общую статистику.

```
df_coh = df_coh[df_coh['month_min_reg'] != '2023-07-01']
```

РЕЗЮМЕ

- Используйте группировку с поиском минимума для определения старта когорты.
- В Pandas активно применяйте транкование дат для формирования нужного винтажа (например, месяца).
- Операция слияния (merge) позволяет собирать клиентские витрины из сырых данных.
- Рассчитывайте абсолютный и относительный Retention для анализа удержания, но всегда исключайте неполные когорты (последний период), чтобы избежать искажения статистики.