Содержание

1.0 Часть 1. Равновероятностная модель 6
- 1.1 Введение в теорию множеств 6
- 1.2 Модель равновероятных исходов 15
- 1.3 Комбинаторика 24
- 1.4 Геометрическая вероятность 30

2.0 Часть 2. Множества, алгебры и меры 31
- 2.1 Кольца и полукольца 31
- 2.2 Алгебры и σ-алгебры 37
- 2.3 Меры на кольцах и полукольцах 46
- 2.4 Внешняя мера 49
- 2.5 Меры на σ-алгебрах 51
- 2.6 Измеримые функции и пространства 59
- 2.7 Свойства измеримых функций 62
- 2.8 Сходимости измеримых функций 66
- 2.9 Интеграл Лебега и его свойства 71
- 2.10 Аксиоматика Колмогорова 85

3.0 Часть 3. Характеристики случайных величин 91
- 3.1 Случайные величины и функции распределения 91
- 3.2 Квантили распределений 97
- 3.3 Условная вероятность 100
- 3.4 Совместные распределения 107
- 3.5 Свёртки распределений 110
- 3.6 Математическое ожидание 113
- 3.7 Дисперсия, стандартное отклонение и ковариация 118
- 3.8 Начальные и центральные моменты распределений 124
- 3.9 Асимметрия и эксцесс 126
- 3.10 Характеристические функции 129
- 3.11 Производящая функция моментов 137
- 3.12 Неравенство Йенсена 140
- 3.13 Гауссовские вектора 142
- 3.14 Сходимости 151
- 3.15 Наследование сходимости 158
- 3.16 Неравенства Маркова и Чебышева 163

3.17 Закон Больших Чисел 164
3.18 Центральная предельная теорема 166
3.19 УМО 168
3.20 Условные распределения 177
3.21 Условные моменты 181
4.0 Часть 4. Основы статистического анализа 182
4.1 Генеральная совокупность и выборка 182
4.2 Шкалы измерения 187
4.3 Меры центральной тенденции и квантили 190
4.4 Вариационная статистика 200
4.5 Визуализация в статистике 210
5.0 Часть 5. Точечные оценки 216
5.1 Введение в точечные оценки 216
5.2 Свойство состоятельности 219
5.3 Асимптотическая нормальность 221
5.4 Свойство несмещённости 224
5.5 Информация Фишера 227
5.6 Неравенство Рао-Крамера 231
5.7 Свойство эффективности 232
5.8 Достаточные статистики 237
5.9 Полные статистики 241
5.10 Свойство оптимальности 243
6.0 Часть 6. Методы построения точечных оценок 247
6.1 Метод моментов 247
6.2 Метод максимального правдоподобия 249
6.3 Оценки максимального правдоподобия для различных распределений 255
7.0 Часть 7. Доверительные интервалы 261
7.1 Интервальная оценка и доверительный интервал 262
7.2 Доверительный интервал для математического ожидания 269
7.3 Доверительный интервал для пропорции 275
7.4 Доверительный интервал для дисперсии 280
7.5 Доверительный интервал для дисперсии 285
8.0 Часть 8. Численные методы 289
8.1 Метод Монте-Карло 290
8.2 Бутстреп 294
8.3 Разница между методом Монте-Карло и бутстрепом 307
9.0 Часть 9. Введение в гипотезы 309

9.1 Введение в гипотезы 309
9.2 Конструирование критериев 318
9.3 Z-критерий 328
9.4 p-значение 335
9.5 Необходимое количество наблюдений 346
10.0 Часть 10. Параметрические критерии 355
10.1 Критерии для дискретных распределений 355
10.2 t-критерии Стьюдента и Уэлча 361
10.3 Одновыборочный хи-квадрат тест для дисперсии 367
10.4 Двухвыборочный F-тест для дисперсии 370
10.5 Итоги по параметрическим критериям 371
11.0 Часть 11. Непараметрические критерии 372
11.1 Критерий Манна-Уитни-Уилкоксона 372
11.2 Критерии согласия 381
11.3 Хи-квадрат критерий Пирсона 389
11.4 Критерии проверки нормальности 398
12.0 Часть 12. Множественные тесты 400
12.1 Family-wise error 402
12.2 Поправка Бонферони 403
12.3 Поправка Холма 404
12.4 ANOVA F-тест 405
13.0 Часть 13. Выборочная корреляция 409
13.1 Введение в выборочную корреляцию 409
13.2 Выборочная линейная корреляция Пирсона 412
13.3 Ранговая корреляция Спирмена 419
13.4 Тау-корреляция Кендалла 421
13.5 Бинарная корреляция Мэтьюса 425
13.6 Корреляция и каузация 429
14.0 Часть 14. Линейная регрессия 435
14.1 Введение в линейную регрессионную модель 436
14.2 Качество и значимость модели линейной регрессии 445
14.3 Значимость регрессии в целом 449
14.4 Значимость коэффициентов в линейной регрессии 450
14.5 Теорема Гаусса — Маркова 456
14.6 Информационные критерии 474
14.7 Нормальность остатков линейной регрессии 477
14.8 MSE и MAE 479

14.9 Гребневая регрессия 482
14.10 Лассо 487
14.11 Квантильная регрессия 491
14.12 Переход к логистической регрессии 494
14.13 Частный коэффициент корреляции 497
15.0 Приложение А. Распределения 502
15.1 Нормальное распределение 502
15.2 Логнормальное распределение 505
15.3 Распределение Бернулли 507
15.4 Биномиальное распределение 508
15.5 Геометрическое распределение 511
15.6 Пуассоновское распределение 518
15.7 Экспоненциальное распределение 520
15.8 Непрерывное равномерное распределение 522
15.9 Гипергеометрическое распределение 523
15.10 Распределение хи-квадрат 533
15.11 Распределение Стьюдента 540
15.12 Распределение Фишера (F-распределение) 548
15.13 Распределение Лапласа 555
15.14 Распределение Коши 565
15.15 Треугольное распределение 571
15.16 Гамма распределение 579
15.17 Бета распределение 588
15.18 Категориальное распределение 601
15.19 Распределение Вейбулла 604
15.20 Экспоненциальное семейство распределений 613
16.0 Приложение Б. A/B тесты 618
16.1 Введение в продуктовые эксперименты 618
16.2 Сплит-система A/B теста 632
16.3 Ratio-метрики в A/B тестах 651
16.4 Базовые методы ускорения A/B тестов 664
16.5 Методы CUPED и CUPAC 672
16.6 Другие методы снижения дисперсии 686
17.0 Приложение В. Теория информации 699
17.1 От сообщений к количеству информации 699
17.2 Энтропия, кросс-энтропия и KL-дивергенция 702
17.3 KL-дивергенция и максимум правдоподобия 707
17.4 Локальная геометрия и информация Фишера 708
17.5 Смысл информации Фишера: что именно она измеряет 710

17.6 Натуральный градиент 712
17.7 ELBO и нижняя оценка правдоподобия 715
17.8 Заключение 717

Часть 1. Равновероятностная модель

1. ВВЕДЕНИЕ В ТЕОРИЮ МНОЖЕСТВ

Булева алгебра

Логика как наука о правильном мышлении зародилась ещё в Древней Греции. Одной из отправных точек в развитии логики стала задача формализации математического рассуждения.

ОПРЕДЕЛЕНИЕ 1.1.1
Булева алгебра

Булева алгебра — это раздел математики, который изучает операции над логическими значениями.

Рассмотрим некоторые из них.

Парадокс лжеца

Пример 1.1.1. Лжец говорит: «Это утверждение ложно». Истинно это утверждение или ложно? Если истинно, тогда всё, что в нём сказано, тоже истинно. Но в нём сказано, что оно ложно. Получается противоречие.

Если же утверждение ложно, тогда неверно то, что в нём сказано, что оно ложно. Снова противоречие. Выходит, это утверждение нельзя назвать ни истинным, ни ложным.

Парадокс брадобрея, или парадокс Рассела

Пример 1.1.2. В некотором городе живёт брадобрей, который бреет тех, кто не бреется сам, и только их. Возникает вопрос: кто бреет самого брадобрея?

Если брадобрей бреется сам, то он среди тех, кто бреется сам. Но утверждается, что брадобрей никогда не бреет тех, кто бреется сам. Следовательно, брадобрей не может брить самого себя.

Пусть брадобрей не бреется сам. Но в утверждении сказано, что он бреет всех, кто не бреется сам. То есть он всё-таки должен бриться сам.

Итак, любое из двух предположений (он бреется сам или он не бреется сам) приводит к противоречию. Значит, такой брадобрей просто не может существовать.

Парадокс Берри

Пример 1.1.3. Пусть n — наименьшее натуральное число, которое нельзя задать менее чем одиннадцатью словами. Но «наименьшее натуральное число, которое нельзя задать менее чем одиннадцатью словами» — это 10 слов. Значит, такое число n не может существовать.

Вывод из этих примеров такой: без должной формализации логических высказываний рассуждения могут превращаться в парадоксы.

Высказывание

ОПРЕДЕЛЕНИЕ 1.1.2
Высказывание

Высказывание — это предложение, про которое можно однозначно сказать, истинно ли оно или ложно. Предложение считается высказыванием:

1) если все используемые в нём термины имеют чёткое и однозначное значение;
2) оно не утверждает прямым или косвенным образом что-то про себя само (иначе может возникнуть парадокс).

Вместо слова «высказывание» часто используют слово «утверждение». Ложность высказывания обозначают «0», а истинность — «1». Сами высказывания чаще всего обозначают латинскими буквами, например A или B.

Пример 1.1.4. Какие из предложений ниже — высказывания?

1. Эверест — это самая высокая гора на Земле.
2. $2 + 2 = 5$.
3. Хлеб — всему голова.
4. В любой четырёхугольник можно вписать окружность.
5. Если данное утверждение верно, то русалки существуют.
6. Простых чисел бесконечно много.

Решение. Предложения 1, 2, 4, 6 — высказывания: 1 и 6 — истинные, а 2 и 4 — ложные. Предложения 3 и 5 не высказывания. В третьем нельзя однозначно трактовать все слова: нарушается первое условие из определения 1.1.2. А пятое предложение указывает на само себя, нарушая второе условие из определения 1.1.2. ■

Булевы операции

Несколько простых утверждений можно объединить в несколько более сложных с помощью специальных логических связок.

ОПРЕДЕЛЕНИЕ 1.1.3
Булевы операции

Булевы операции — это логические операции над одним или несколькими высказываниями, результатом которых становится новое высказывание.

Рассмотрим основные логические операции на примере высказываний A и B.

ОПРЕДЕЛЕНИЕ 1.1.4
Отрицание, или логическое «НЕ», или $\neg$

Отрицание высказывания A — это высказывание, обозначаемое $\neg A$ или $\overline{A}$. Оно истинно тогда, когда высказывание A ложно, и наоборот.

Например, если A — это утверждение «Идёт дождь», то $\overline{A}$ — «Не идёт дождь».

В программировании операция $\neg$ обычно обозначается NOT.

ОПРЕДЕЛЕНИЕ 1.1.5
Конъюнкция, или логическое «И», или $\wedge$

Конъюнкция высказываний A и B — это высказывание, обозначаемое $A \wedge B$, которое истинно только тогда, когда истинны и A, и B.

Например, если A — это утверждение «Сегодня идёт дождь», а B — «Илья взял зонт», конъюнкция $A \wedge B$ («Сегодня идёт дождь, и Илья взял зонт») будет истинна только в том случае,

если оба условия выполняются: и дождь действительно идёт, и у Ильи есть зонт. В противном случае высказывание ложно.

В программировании операция $\wedge$ обозначается AND или &.

ОПРЕДЕЛЕНИЕ 1.1.6

Дизъюнкция, или логическое «ИЛИ», или $\vee$

Дизъюнкция высказываний A и B — это высказывание, обозначаемое $A \vee B$, которое истинно, если хотя бы одно из высказываний, A или B, истинно. Если и A и B ложны, то $A \vee B$ ложно.

Например, если A — это утверждение «Илья взял зонт», а B — «Илья надел дождевик», конъюнкция $A \wedge B$ («Илья взял зонт или надел дождевик») будет истинна, если Илья выполнил хотя бы одно из этих действий, и ложным — если он и не взял зонт, и не надел дождевик.

В программировании операция $\vee$ обозначается OR или |.

Оценивать истинность или ложность высказываний, содержащих логические связки, удобно с помощью **таблицы истинности**. Для высказываний $A \vee B$ и $A \wedge B$ она представлена в таблице 1.

Сначала в таблице перебираем все возможные значения A и B, затем записываем, какое значение будет у соответствующих сложных высказываний. Например, для высказываний $A \vee B$ и $A \wedge B$ в первых двух столбцах таблицы указаны все возможные значения A и B, а в третьем и четвёртом — соответствующие значения этих сложных высказываний.

A	B	$A \vee B$	$A \wedge B$
0	0	0	0
0	1	1	0
1	0	1	0
1	1	1	1

Таблица 1. Таблица истинности для высказываний $A \vee B$ и $A \wedge B$

В логических формулах у операции $\neg$ более высокий приоритет, чем у остальных. Например, $\neg A \wedge B$ означает $(\neg A) \wedge B$, а не $\neg(A \wedge B)$. Так, если A — «идёт дождь», а B — «дует ветер», то выражение $\neg A \wedge B$ означает «дождя нет, но ветер есть», а не «неверно, что одновременно идёт дождь и дует ветер».

ОПРЕДЕЛЕНИЕ 1.1.7

Закон исключённого третьего

Закон исключённого третьего — это одна из аксиом математической логики: любое корректное высказывание либо истинно, либо ложно, и третьего не дано.

$$A \vee \overline{A} = 1.$$

ОПРЕДЕЛЕНИЕ 1.1.8

Закон двойного отрицания

Закон двойного отрицания — прямое следствие закона исключённого третьего: если получилось установить, что высказыва-

ние A точно не ложно, то оно истинно.

$$\neg\neg A = A.$$

Например, утверждение «Это не правда, что Илья не забыл ключи» эквивалентно утверждению «Илья забыл ключи».

Законы де Моргана

Законы де Моргана устанавливают правила отрицания составных высказываний.

По **законам де Моргана** отрицание конъюнкции есть дизъюнкция:

ОПРЕДЕЛЕНИЕ 1.1.9

Законы де Моргана

$$\neg(A \wedge B) = \neg A \vee \neg B,$$

а отрицание дизъюнкции есть конъюнкция:

$$\neg(A \vee B) = \neg A \wedge \neg B.$$

Например, отрицание утверждения «Сегодня солнышко светит и птички поют» — это «Сегодня солнышко не светит ИЛИ птички не поют». Это связано с тем, что исходное утверждение верно только в том случае, если оба условия выполняются одновременно — и солнце светит, и птички поют.

Если же использовать И вместо ИЛИ, «Сегодня солнышко не светит и птички не поют», то получится более сильное утверждение: оно истинно только тогда, когда одновременно не выполняются оба условия. Но это не соответствует отрицанию исходного утверждения. Использовать в отрицании союз И вместо ИЛИ в этом примере — это логическая ошибка (то есть получение неверного вывода из верных высказываний).

Закон непротиворечивости

По **закону непротиворечивости** логическое высказывание не может быть одновременно истинным и ложным

ОПРЕДЕЛЕНИЕ 1.1.10

Закон непротиворечивости

$$A \wedge \overline{A} = 0.$$

Например, невозможно одновременно утверждать, что «этот медведь белый» и «этот медведь не белый». Эти высказывания взаимоисключают друг друга, поэтому одно из них ложное.

Больше булевых операций

Простые булевы операции — это только верхушка айсберга. Когда нужно учитывать сразу несколько условий, используют более сложные булевы операции. Рассмотрим некоторые: импликацию, эквивалентность и исключающее «ИЛИ». Среди них самой неинтуитивной можно назвать импликацию.

ОПРЕДЕЛЕНИЕ 1.1.11

Импликация, или $\to$

Импликация высказываний A и B — это высказывание, обозначаемое $A \to B$, которое ложно только тогда, когда A истинно, а B ложно. Во всех остальных случаях высказывание $A \to B$ истинно.

Например, если A — это утверждение «Сегодня дождь», а B — утверждение «Илья взял зонт», то импликация $A \to B$ будет ложной только в том случае, если дождь идёт, а зонт Илья не взял.

Иногда импликацию читают как «если A, то B», но стоит учитывать, что это не совсем «если... то» в бытовом смысле.

Никакой причинно-следственной связи между утверждениями при этом не требуется. Например, следующие предложения считаются истинными:

- если Эверест — это самая высокая гора на Земле, то $2 + 2 = 4$;
- если в любой четырёхугольник можно вписать окружность, то Луна сделана из зелёного сыра;
- если $2 + 2 = 5$, то Амазонка — самая длинная река на Земле.

Импликацию можно рассматривать как обещание: определённое действие выполняется при выполнении другого условия. Например, пусть кто-то утверждает: «Если ты закроешь сессию без троек, то получишь стипендию». Если при этом ты закроешь сессию без троек, то получишь стипендию, иначе получится, что обещание нарушено. Но это утверждение не запрещает тебе получить стипендию, даже если сессия не закрыта без троек: на этот случай просто не было дано никаких гарантий. Если первая часть импликации ложна, то любой исход событий разрешён.

Можно определить импликацию через другие логические операции: высказывание $A \to B$ означает в точности то же самое, что и $\neg A \vee B$ — можешь проверить это в таблице истинности. Это полезно помнить при решении задач, когда требуется упростить логическое выражение.

Такое определение кажется примерно соответствующим тому, что означает «если... то» в повседневной жизни. Например, Илья говорит соседу: «Если ты не уберёшь свою машину с газона, то я вызову эвакуатор». Он мог бы сформулировать по-другому: «Или ты уберёшь машину с газона, или я вызову эвакуатор». С точки зрения математической логики эти два высказывания абсолютно эквивалентны: второе из них — это выражение импликации через отрицание и дизъюнкцию.

ОПРЕДЕЛЕНИЕ 1.1.12

Эквивалентность, или $\leftrightarrow$

Эквивалентность высказываний A и B — это высказывание, обозначаемое $A \leftrightarrow B$, которое истинно тогда, когда высказывания A и B либо истинны, либо ложны одновременно.

Например, если A — это утверждение «Число 10 чётное», а B — утверждение «Число 5 простое», то эквивалентность $A \leftrightarrow B$ будет истинной, так как оба утверждения истинны.

Важно различать булеву импликацию $\to$ и булеву эквивалентность $\leftrightarrow$ с «более привычным» логическим следствием $\Rightarrow$ и равносильностью $\Leftrightarrow$.

ОПРЕДЕЛЕНИЕ 1.1.13

Исключающее «ИЛИ», или XOR, или $\oplus$

Исключающее «ИЛИ» высказываний A и B — это высказывание, обозначаемое $A \oplus B$, которое истинно, когда ровно одно из высказываний истинно.

Высказывание $A \oplus B$ можно читать как «либо A, либо B». К примеру, если A — это утверждение «Амазонка — самая длинная река на Земле», а B — это утверждение «Эверест — самая высокая гора на Земле», то $A \oplus B$ будет ложным, потому что оба исходных утверждения истинны, а должно быть только одно.

Приведём таблицу истинности 2 для вышеперечисленных булевых операций.

A	B	$A \to B$	$A \leftrightarrow B$	$A \oplus B$
0	0	1	1	0
0	1	1	0	1
1	0	0	0	1
1	1	1	1	0

Таблица 2. Таблица истинности для сложных булевых операций

Закон контрапозиции

ОПРЕДЕЛЕНИЕ 1.1.14

Закон контрапозиции

По **закону контрапозиции** утверждение «Если A, то B» эквивалентно утверждению «Если неверно B, то неверно A»:

$$A \to B = \neg B \to \neg A.$$

Одна из самых распространённых ошибок — считать, что $A \to B$ означает $\neg A \to \neg B$. На самом деле $A \to B$ никак не ограничивает случай, когда A ложно.

Например, фраза «Если ты сдашь экзамен, то ты поступишь в магистратуру» ($A \to B$) не означает «Если ты не сдашь экзамен, то ты не поступишь в магистратуру» ($\neg A \to \neg B$). Она означает только «Если ты не поступишь в магистратуру, то только при условии, что ты не сдашь экзамен» ($\neg B \to \neg A$), и это совсем не одно и то же.

На законе контрапозиции основаны многие математические доказательства: чтобы установить истинность B, предположим его ложность и придём к противоречию с истинностью A.

Поупражняемся

Пример 1.1.5. Собрались три блогера — Гоша, Кеша и Рома. Один из них всегда говорит правду, другой всегда лжёт, а третий — хитрец, он иногда говорит правду, иногда лжёт. На вопрос «Кто Кеша?» блогеры ответили так: Гоша утверждал, что Кеша лжец. Кеша заявил, что он сам хитрец. Рома сказал, что Кеша абсолют-

но честный блогер. Кто же из блогеров честный, кто лжец, а кто хитрец?

Решение. Посмотри внимательно на то, что сказали блогеры. Кеша не может быть честным, потому что тогда должно быть верно, что он хитрец. Но блогер не может быть одновременно честным и хитрецом. Рома тоже не может быть честным, так как Кеша точно не честный. Следовательно, **честный — Гоша**. Тогда **лжец — Кеша**, а **хитрец — Рома**.

Пример 1.1.6. Прогноз погоды на завтра: «Если не будет ветра, то будет пасмурная погода без дождя. Если будет дождь, то будет пасмурно и без ветра. Если будет пасмурная погода, то будет дождь и не будет ветра». Так какая же погода будет завтра?

Решение. Выделим высказывания:

- A — ветра не будет;
- B — будет пасмурно;
- C — будет дождь.

Запишем условия из прогноза погоды на языке логики.

- «Если не будет ветра, то будет пасмурная погода без дождя» — $A \to (B \wedge \neg C)$.
- «Если будет дождь, то будет пасмурно и без ветра» — $C \to (B \wedge A)$.
- «Если будет пасмурная погода, то будет дождь и не будет ветра» — $B \to (C \wedge A)$.

Тогда итоговая формула примет следующий вид:

$$(A \to (B \wedge \neg C)) \wedge (C \to (B \wedge A)) \wedge (B \to (C \wedge A)) = 1.$$

Определим, при каких значениях A, B и C выражение выше будет верно. Получаем: $A = 0$, $B = 0$, $C = 0$. Значит, завтра будет ветер, не будет пасмурно, не будет дождя.

Пример 1.1.7. Народная примета племени Ых-Ух гласит: «Если бегемоты ныряют глубоко, то будет дождь». Если примета верна, то какое из следующих утверждений истинно?

1. Если будет дождь, то бегемоты должны нырять глубоко.
2. Если в местности нет бегемотов, то там не бывает дождя.
3. Если бегемоты сидят на берегу, то дождя не ожидается.
4. Если бегемоты ныряют не глубоко, то дождя не будет.
5. Если дождя не ожидается, а бегемоты ныряют, то они ныряют не глубоко.

Решение. Выделим высказывания:

- A — бегемоты ныряют глубоко, тогда $\neg A$ — бегемоты ныряют не глубоко;
- B — будет дождь, тогда $\neg B$ — дождя не будет.

Тогда исходное утверждение задачи — это импликация $A \to B$.

1. «Если будет дождь, то бегемоты должны нырять глубоко». Это утверждение можно записать как $B \to A$, то есть посыл-

ка и следствие поменялись местами. Но разумеется, тогда это утверждение не следует из приметы. Например, примета допускает исход событий «бегемоты ныряют неглубоко, и будет дождь», а новое утверждение такого развития событий не допускает.

2. «Если в местности нет бегемотов, то там не бывает дождя». Это утверждение вообще никак не связано с приметой. Примета накладывает ограничения лишь на случай, когда бегемоты ныряют глубоко, и допускает любой исход событий, если бегемотов вообще не было.
3. «Если бегемоты сидят на берегу, то дождя не ожидается». Как и в предыдущем случае, это утверждение логически не связано с приметой. Примета накладывает ограничения лишь на случай, когда бегемоты ныряют глубоко. Если же они сидят на берегу, примета допускает любое развитие событий.
4. «Если бегемоты ныряют не глубоко, то дождя не будет». И снова это утверждение не следует из приметы. Примета допускает любое развитие событий, если бегемоты ныряют не глубоко. Заметим, что данное утверждение — это утверждение $\neg A \to \neg B$. Считать его эквивалентным утверждению $A \to B$ — распространённая ошибка, о которой мы говорили.
5. «Если дождя не ожидается, а бегемоты ныряют, то они ныряют не глубоко». Это утверждение можно записать как $\neg\, B \;\to\; \neg\, A$. По закону контрапозиции именно это утверждение эквивалентно исходной примете. ■

Пример 1.1.8. Построй таблицу истинности для

$$(A \wedge C) \vee (A \wedge \neg C) \vee (\neg(\neg A \to \neg B))\,.$$

Решение. Разделим на более короткие утверждения:

- $D = A \wedge C$;
- $E = A \wedge \neg C$;
- $F = \neg A \to \neg B$;
- $G = \neg(\neg A \to \neg B)$.

A	B	C	D	E	F	G	$D \vee E \vee G$
0	0	0	0	0	1	0	0
0	0	1	0	0	1	0	0
0	1	0	0	0	0	1	1
0	1	1	0	0	0	1	1
1	0	0	0	1	1	0	1
1	0	1	1	0	1	0	1
1	1	0	0	1	1	0	1
1	1	1	1	0	1	0	1

Пример 1.1.9. Для какого слова **ложно** высказывание «Первая буква слова гласная $\to$ (Вторая буква слова гласная $\vee$ Последняя буква слова гласная)»?

А) Жара Б) Орда В) Огород Г) Парад

Решение. Выделим высказывания:

- A — 1-я буква гласная;
- B — 2-я буква гласная;
- C — последняя буква гласная.

Тогда исходное выражение имеет вид $A \to (B \vee C)$. При $A = 0$ утверждение всегда верно, значит, слова «жара» и «парад» не подходят. При $A = 1$ должно быть выполнено $B \vee C = 0$, чтобы итоговое выражение стало ложным. Соответственно, вторая и последняя буквы должны быть согласными. В результате получим слово «огород».

Пример 1.1.10. Докажи:

а) $(A \wedge (\overline{A} \vee B)) \to B = 1$;
б) $(A \wedge B) \to (A \vee B) = 1$.

Решение.

а)

A	B	$\neg A \vee B$	$A \wedge (\neg A \vee B)$	$A \wedge (\neg A \vee B) \to B$
0	0	1	0	1
0	1	1	0	1
1	0	0	0	1
1	1	1	1	1

б)

A	B	$A \wedge B$	$A \vee B$	$(A \wedge B) \to (A \vee B)$
0	0	0	0	1
0	1	0	1	1
1	0	0	1	1
1	1	1	1	1

Пример 1.1.11. Известно, что истинны утверждения $A \vee (B \wedge \neg C)$ и $\neg A \wedge (B \vee C)$. Какие из высказываний A, B и C истинны?

Решение.

Разделим на более короткие утверждения:

- $D = A \vee (B \wedge \neg C)$;

- $E = \neg A \wedge (B \vee C)$.

A	B	C	D	E	$D \wedge E$
0	0	0	0	0	0
0	0	1	0	1	0
0	1	0	1	1	1
0	1	1	0	1	0
1	0	0	1	0	0
1	0	1	1	0	0
1	1	0	1	0	0
1	1	1	1	0	0

По таблице истинности видно, что утверждение истинно на наборе $A = 0, B = 1, C = 0$.

Пример 1.1.12. Докажи, что $1 \oplus A \oplus B = (A \to B) \wedge (B \to A)$.

Решение. Разделим на более короткие утверждения:

- $C = (A \to B) \wedge (B \to A)$;
- $D = 1 \oplus A \oplus B$.

Докажем с помощью таблицы истинности:

A	B	$A \to B$	$B \to A$	C	D
0	0	1	1	1	1
0	1	1	0	0	0
1	0	0	1	0	0
1	1	1	1	1	1

2. МОДЕЛЬ РАВНОВЕРОЯТНЫХ ИСХОДОВ

Некоторые считают, что случайным может быть любое число, которое заранее неизвестно. Но на самом деле это не так. Вероятность события тоже иногда понимают упрощённо — как ответ на вопрос: «Как часто происходит это событие». Однако такая формулировка тоже неточна.

Люди по-разному ведут себя в ситуации неопределённости. Например, Анатолий никогда не принимает решения, пока не получит надёжную информацию. Он избегает неопределённости. А Борис оценивает возможные исходы и начинает действовать ещё до того, как ситуация прояснилась:

1) составляет список возможных сценариев;
2) оценивает последствия каждого сценария;
3) предполагает, какие сценарии самые частые;
4) заранее готовится к наиболее вероятным сценариям с серьёзными последствиями.

По сути, Борис использует концепцию вероятностного пространства.

Случайность и вероятностное пространство

ОПРЕДЕЛЕНИЕ 1.2.1
Вероятностное пространство

Вероятностное пространство — это модель, которая отвечает на вопросы «Какие сценарии возможны?» и «Как часто они реализуются?».

Банк прогнозирует риски и рассматривает несколько возможных сценариев.

1. Действующие клиенты положат больше денег на вклады.
2. Некоторые категории клиентов заберут деньги со вкладов, а другие — нет.
3. Все клиенты заберут деньги со вкладов.

Аналитики оценивают вероятности сценариев. Чтобы описать такую ситуацию, можно использовать вероятностное пространство.

Главная задача модели — перевести словесные оценки частоты в числа. Сравни два описания:

- клиент из сегмента A, *скорее всего*, закажет доставку еды в ближайшие сутки, а клиент из сегмента B — *вряд ли*;
- вероятность заказа в ближайшие сутки в сегменте A — 60%, для B — 42%.

Перейдём к случайности в вероятностной модели.

ОПРЕДЕЛЕНИЕ 1.2.2
Случайное событие

Случайное событие — это ситуация, для которой заранее неизвестно, случится ли она.

Для каждого сценария можно определить, произошло событие или нет. А единственная причина, почему неизвестно, случится ли ситуация, — мы не знаем, какой сценарий реализуется.

Приведём примеры случайных событий:

- сумма заказов клиента A за конкретный день превысит 1000 рублей;
- клиент B за конкретный месяц сделает меньше 3 заказов;
- число новых клиентов за конкретный год превысит 100.

ОПРЕДЕЛЕНИЕ 1.2.3
Случайная величина

Случайная величина — это числовая характеристика, значение которой заранее неизвестно.

Для каждого сценария можно определить конкретное значение. Единственная причина, почему значение величины неизвестно заранее, — мы не знаем, какой сценарий реализуется.

Приведём примеры случайных величин:

- сумма заказов клиента A за конкретный день;
- количество заказов клиента A за конкретный месяц;
- число новых клиентов за конкретный год.

Чтобы формализовать понятия события и случайные величины, сценарии должны быть:

- взаимоисключающими,
- всеохватывающими,
- достаточно детальными.

Тогда остальное определяется по сценарию: произойдут ли события и чему будут равны числовые показатели.

Рассмотрим ещё один сценарий. Из мешка вынимают шарик с числом. Обозначим это число через X. Пока что X:

- числовой показатель, значение которого заранее неизвестно;
- **не**случайная величина.

Добавим информацию. Всего в мешке 10 шариков: на одном написано число 1, на двух — 2, на трёх — 3, на остальных — 4. Каждый шарик вытаскивают с одинаковой вероятностью $1/10$.

Тогда X:

- числовой показатель, значение которого заранее неизвестно;
- случайная величина в заданном вероятностном пространстве.

Нечто заранее неизвестное становится объектом теории вероятностей только после того, как для него задали вероятностное пространство.

Случайность «до» vs «после»

Начинающие специалисты часто путают разные понятия, у которых похожие названия и которые профессионалы часто вообще называют одинаково.

Пример 1.2.1. Катя подбросила кубик. Выпало 5. Случайно ли это значение на кубике?

Решение. И да и нет: значение кубика может отсылать к любому из понятий.

А. Реализация случайной величины — число 5. Известно и не случайно.

Б. Случайная величина — числовая характеристика кубика, разная для каждого сценария — подбрасывания.

Иногда первое понятие называют случайной величиной после реализации, а второе — до реализации. Чаще всего каждое из них называют просто — случайная величина. Это может сильно запутывать. ■

Конечное вероятностное пространство

Теперь формализуем понятия.

ОПРЕДЕЛЕНИЕ 1.2.4
Пространство элементарных исходов Ω

Пространство элементарных исходов Ω — это произвольное конечное непустое множество. Оно описывает всевозможные взаимоисключающие сценарии будущего.

ОПРЕДЕЛЕНИЕ 1.2.5
Элементарный исход ω

Элементарный исход ω — элемент множества Ω. Он выделяет конкретный сценарий будущего и исключает все остальные.

ОПРЕДЕЛЕНИЕ 1.2.6
Множество всех допустимых событий $\mathcal{F}$

Множество всех допустимых событий $\mathcal{F}$ — это множество всех подмножеств Ω. Оно описывает события, над которыми разрешено выполнять определённые операции: пересекать, объединять, переходить к дополнению.

ОПРЕДЕЛЕНИЕ 1.2.7
Событие A

Событие A — элемент множества $\mathcal{F}$. Одновременно событие A — подмножество Ω, которое состоит из элементарных исходов. Оно объединяет сценарии, в которых выполняется некоторое условие или возникает определённая ситуация.

Мы используем пустое событие $\varnothing$, когда условие события не выполняется ни в одном из сценариев. Например, «на кубике выпало 7» $= \varnothing$.

Пример 1.2.2. На столе лежат таблички со словами: as, is, so, go. Одну из них берут наугад. Из скольких элементарных исходов состоят следующие события?

А. Совпадает с is.
Б. Содержит «s».
В. Содержит «k».
Г. Состоит из двух букв.

Решение.

А. Элементарный исход $\omega = is$. Исключает все другие исходы. Событие $A = \{is\}$. Состоит из одного элементарного исхода.
Б. Событие $B = \{as, is, so\}$. Содержит три исхода.
В. Событие $C = \varnothing$. Никогда не наступает.
Г. Событие $D = \Omega$. Наступает всегда. Такое событие называют достоверным. ■

ОПРЕДЕЛЕНИЕ 1.2.8
Наступление события A для элементарного исхода ω

Наступление события A для элементарного исхода ω — бинарное значение: истина или ложь. Оно служит названием «события после», когда сценарий уже известен: случилось ли событие.

Сначала дадим общее определение понятия вероятности для любого конечного пространства исходов.

ОПРЕДЕЛЕНИЕ 1.2.9
Вероятность

Вероятность — числовая функция на событиях : $\mathcal{F} \to [0, 1]$ с условиями:

а) $\mathbb{P}(A) \geqslant 0$ для любого $A \in \mathcal{F}$;
б) $\mathbb{P}(\Omega) = 1$;
в) $\mathbb{P}(A_1 \cup A_2 \cup \ldots \cup A_m) = \mathbb{P}(A_1) + \ldots + \mathbb{P}(A_m)$, если никакие два события A_i, A_j не пересекаются.

Под это определение подходит много функций. Мы пока не будем им пользоваться, а ограничимся случаем, когда у всех элементарных исходов одинаковые вероятности.

Вероятностное пространство равновероятных исходов

Вероятность — числовая функция на событиях : $\mathcal{F} \to [0,1]$:

$$\mathbb{P}(A) = \frac{|A|}{|\Omega|} = \frac{\text{количество исходов в } A}{\text{общее число исходов}}.$$

ОПРЕДЕЛЕНИЕ 1.2.10

Вероятность $\mathbb{P}$

Это значит, что вероятность:

- считает все сценарии равновероятными;
- показывает, как часто каждое событие происходит при многократном повторении эксперимента равновероятным выбором сценария.

Свойства вероятности в модели равновероятных исходов:

а) $\mathbb{P}(A) \geqslant 0$ для любого $A \in \mathcal{F}$;
б) $\mathbb{P}(\Omega) = 1$;
в) $\mathbb{P}(A_1 \cup A_2 \cup \ldots \cup A_m) = \mathbb{P}(A_1) + \ldots + \mathbb{P}(A_m)$, если никакие два события не пересекаются.

Вероятность события A — число $\mathbb{P}(A)$. Она служит названием «вероятности после», но, в отличие от случайной величины или события, в неё подставляют не элементарный исход, а событие.

ОПРЕДЕЛЕНИЕ 1.2.11

Вероятность события A

Важно не путать событие и его вероятность. Опишем разницу на примере. На столе лежат таблички со словами: as, is, so, go. Одну из них берут наугад.

Тогда:

а) слово содержит букву s — событие A;
б) вероятность события $(A) = 3/4 = 0,75 = 75\%$;
в) в этом случае одно событие состоит из 3 элементарных исходов.

Операции на событиях

Можно пересекать события, объединять их и брать к ним дополнение. Эти операции позволяют рассчитывать вероятности сложных событий, опираясь на вероятность простых событий.

Иногда полезно представлять события в виде диаграмм Эйлера (рисунок 1).

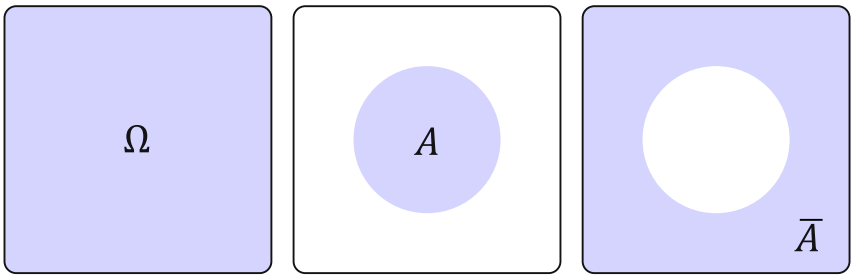

Рисунок 1. Диаграммы Эйлера

В этом случае:

а) случайное событие Ω покрывает всё множество элементарных исходов;
б) событие A сопоставляется с кругом с относительной площадью — вероятностью;
в) дополнение к событию A закрашивает всю площадь Ω, кроме события A.

Дополнение

Дополнение $\overline{A}$ к событию A — событие, которое содержит все элементарные исходы, не входящие в A. Обозначается чертой сверху: $\overline{A} = \Omega \backslash A$ — дополнение к множеству.

ОПРЕДЕЛЕНИЕ 1.2.12
Дополнение $\overline{A}$ к событию A

Эта операция объединяет «все сценарии, кроме этих»:

$$\mathbb{P}(\overline{A}) = 1 - \mathbb{P}(A).$$

Пример 1.2.3. На столе лежат таблички со словами: as, is, so, go. Одну из них берут наугад.

А. Найди дополнение $\overline{A}$ к событию $A =$ слово содержит «а».
Б. Найди вероятности A и $\overline{A}$.

Решение.

А. $A = \{as\}$. В дополнение войдут «все исходы, кроме», поэтому:

$$\overline{A} = \{\cancel{as}, is, so, go\} = \{is, so, go\}.$$

Б.

$$\mathbb{P}(A) = 1/4, \qquad \mathbb{P}(\overline{A}) = 3/4.$$

Пересечение и объединение событий

Объединение событий $A \cup B$ — это событие, которое содержит все элементарные исходы только из A и B.

ОПРЕДЕЛЕНИЕ 1.2.13
Объединение событий $A \cup B$

Эта операция объединяет сценарии, в которых *хотя бы одно* из событий произошло. Соответствует союзу «или»:

$$A \cup B = B \cup A.$$

Пересечение событий $A \cap B$ — это событие, которое содержит все элементарные исходы, попавшие сразу в оба события.

ОПРЕДЕЛЕНИЕ 1.2.14
Пересечение событий $A \cap B$

Эта операция объединяет сценарии, в которых *одновременно оба* события произошли. Соответствует союзу «и»:

$$A \cap B = B \cap A.$$

Есть три разных обозначения для пересечения:

$$A \cap B \quad = \quad A, B \quad = \quad AB.$$

Пример 1.2.4. Есть приложение, в котором клиенты проводят время, совершают покупки и получают за это бонусные баллы.

Датафрейм задаёт генеральную совокупность всех клиентов.

- *ID* — сокращённый идентификатор клиента.
- *Age* — возраст клиента в годах.
- *Time* — количество проведённых в приложении часов за сутки.
- *Points* — накопленные за сегодня бонусные баллы.

Клиента выбирают равновероятно:

ID	Age	Time	Points
ω_1	18–21	1	0
ω_2	22–25	1	100
ω_3	25+	0	200
ω_4	22–25	2	100
ω_5	18–21	2	0
ω_6	18–21	2	0

Рассмотри три события.

А. $C =$ возраст 18–21 $= \{\omega_1, \omega_5, \omega_6\}$.
Б. $G =$ 1 час в приложении $= \{\omega_1, \omega_2\}$.
В. $H =$ больше 100 бонусов $= \{\omega_3\}$.

Какие клиентские сегменты получатся вследствие операций $C \cap G$ и $C \cup G$? Рассчитай соответствующие вероятности.
Найди:

а) $C \cap G$;
б) $C \cup G$;
в) $\mathbb{P}(C \cap G)$;
г) $\mathbb{P}(C \cup G)$;
д) $\mathbb{P}(C \cap H)$;
е) $\mathbb{P}(C \cup H)$.

Решение. $C \cap G$ — возраст 18–21 лет **и** 1 час в приложении — это пересечение.

$C \cup G$ — возраст 18–21 лет **или** 1 час в приложении — это объединение.

А. $C \cap G = \{\omega_1, \omega_5, \omega_6\} \cap \{\omega_1, \omega_2\} = \{\omega_1\}$.
Б. $C \cup G = \{\omega_1, \omega_5, \omega_6\} \cup \{\omega_1, \omega_2\} = \{\omega_1, \omega_2, \omega_5, \omega_6\}$.
В. $\mathbb{P}(C \cap G) = \mathbb{P}(\{\omega_1\}) = 1/6$ — вероятность пересечения.
Г. $\mathbb{P}(C \cup G) = \mathbb{P}(\{\omega_1, \omega_2, \omega_5, \omega_6\}) = 4/6$ — вероятность объединения.
Д. $\mathbb{P}(C \cap H) = \mathbb{P}(\{\omega_1, \omega_5, \omega_6\} \cap \{\omega_3\}) = \mathbb{P}(\varnothing) = 0$.

E. $\mathbb{P}(C \cup H) = \mathbb{P}(\{\omega_1, \omega_5, \omega_6\} \cup \{\omega_3\}) = \mathbb{P}(\{\omega_1, \omega_3, \omega_5, \omega_6\}) = \\ = 4/6.$ ■

Связь между пересечением и объединением

Объединение и пересечение событий связаны соотношением (рисунок 2):

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

Пример 1.2.4. Продолжение. Продолжение предыдущего примера.

$$A = \{\omega_1, \omega_2, \omega_3\}, \qquad B = \{\omega_3, \omega_4\},$$

генеральная совокупность: $\{\omega_1, \omega_2, \omega_3, \omega_4, \omega_5, \omega_6\}$.

$$\underset{\frac{4}{6}}{\mathbb{P}(A \cup B)} = \underset{\frac{3}{6}}{\mathbb{P}(A)} + \underset{\frac{2}{6}}{\mathbb{P}(B)} - \underset{\frac{1}{6}}{\mathbb{P}(A \cap B)}$$

$$\{\omega_1, \omega_2, \omega_3, \omega_4\} \quad \{\omega_1, \omega_2, \omega_3\} \quad \{\omega_3, \omega_4\} \quad \{\omega_3\}$$

A	ω_1	18–21	1	0
	ω_2	22–25	1	100
$A \cap B$	ω_3	25+	0	200
B	ω_4	22–25	2	100
	ω_5	18–21	2	0
	ω_6	18–21	2	0

Рисунок 2. Объединение и пересечение событий

ОПРЕДЕЛЕНИЕ 1.2.15

Взаимоисключающие события

Взаимоисключающие события — это события, пересечение которых пусто. Они не могут произойти одновременно.

Специальный знак **дизъюнктивного объединения** $\sqcup$ вместо привычного $\cup$ используют только для взаимоисключающих событий:

$$\mathbb{P}(A \sqcup B) = \mathbb{P}(A) + \mathbb{P}(B).$$

Композиция операций над событиями

Для нескольких операций объединения и пересечения обязательно расставлять скобки, так как порядок важен и не очевиден.

- $A \cap B \cup C$ — некорректная запись.
- $(A \cap B) \cup C$ — корректная запись.

- $A \cap (B \cup C)$ — корректная запись.

События $(A \cap B) \cup C$ и $A \cap (B \cup C)$ могут не совпадать.

Пример 1.2.5. Даны события:

- $A = \{\omega_3, \omega_4\}$;
- $B = \{\omega_1, \omega_2, \omega_3\}$;
- $C = \{\omega_1, \omega_5, \omega_6\}$.

Сравни $\mathbb{P}((A \cap B) \cup C)$ и $\mathbb{P}(A \cap (B \cup C))$.

Решение. Найдём пересечения и объединения событий в разном порядке.

$(A \cap B) \cup C = \{c3\} \cup C = \{c1, c3, c5, c6\} \Rightarrow$ вероятность $4/6$.

$A \cap (B \cup C) = A \cap \{c1, c2, c3, c5, c6\} = \{c3\} \Rightarrow$ вероятность $1/6$.

Получили разные события с разными вероятностями. ■

Формулы для композиции операций над событиями

События и их вероятности можно преобразовывать с помощью формул:

- $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$;
- $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$;
- $\overline{A \cap B \cap C} = \overline{A} \cup \overline{B} \cup \overline{C}$;
- $\overline{A \cup B \cup C} = \overline{A} \cap \overline{B} \cap \overline{C}$.

Пример 1.2.6. Равновероятно выбирается число от 1 до $12\,000$. Найди вероятность того, что оно **не** делится на 4, 5 или 6.

Решение. Запишем вероятность того, что число не делится на 4, 5 или 6:

$$\mathbb{P}(B_4 \cup B_5 \cup B_6),$$

где событие B_m — число не делится на m.

Применим закон де Моргана:

$$\mathbb{P}(B_4 \cup B_5 \cup B_6) = 1 - \mathbb{P}(\overline{B_4 \cup B_5 \cup B_6}) = 1 - \mathbb{P}(\overline{B_4} \cap \overline{B_5} \cap \overline{B_6}).$$

Пусть A_m — число делится на m. Тогда $\overline{B}_m = A_m$.

Число делится на 4, 5 и $6 \Leftrightarrow$ оно делится на 60.

$$1 - \mathbb{P}(\overline{B_4} \cap \overline{B_5} \cap \overline{B_6}) = 1 - \mathbb{P}(A_4 \cap A_5 \cap A_6) = 1 - \mathbb{P}(A_{60}).$$

Осталось подставить количество всех чисел и тех, которые делятся на 60:

$$1 - \mathbb{P}(A_{60}) = 1 - \frac{12\,000/60}{12\,000} = \frac{59}{60} \approx 0,973333.$$

■

3. КОМБИНАТОРИКА

Методы комбинаторики широко применяются в теории вероятностей, поскольку многие вероятностные задачи сводятся к подсчёту числа возможных исходов. В частности, зная число всех возможных комбинаций и число комбинаций, благоприятствующих событию A, можно определить вероятность этого события.

ОПРЕДЕЛЕНИЕ 1.3.1
Комбинаторика

Комбинаторика — это раздел математики, изучающий методы решения комбинаторных задач, то есть задач на расчёт потенциального количества комбинаций.

Прежде чем рассматривать основные методы комбинаторики — перестановку, размещение и сочетание, рассмотрим два фундаментальных правила, лежащих в основе формул для подсчёта числа возможных комбинаций: правило суммы и правило произведения.

Правило суммы

Рассмотрим первое из двух основных правил комбинаторики — правило суммы.

Если каждый элемент A_i можно выбрать n_i способами, то есть:

- элемент A_1 можно выбрать n_1 способами;
- элемент A_2 — другими n_2 способами;
- ...
- элемент A_k — n_k способами, отличными от первых $(k-1)$,

то один из элементов A_i можно выбрать

$$n_1 + n_2 + \ldots + n_k = \sum_{i=1}^{k} n_i \text{ способами.}$$

То есть если выбор осуществляется между несколькими взаимно исключающими вариантами, то общее число способов выбора равно сумме числа способов для каждого варианта.

Пример 1.3.1. В группе 100 студентов:

- 25 отличников,
- 35 хорошистов,
- 30 троечников,
- 10 двоечников.

Сколько есть способов выбрать одного студента, который учится на 4 или 5?

Решение. Отличника можно выбрать 25 способами, а хорошиста — 35 способами. Поскольку эти группы студентов не пересекаются, по правилу суммы: $25 + 35 = 60$ способов. ■

Правило произведения

Правило произведения применяют, когда нужно последовательно выполнить несколько действий. Пусть элемент A_1 можно выбрать n_1 способами. После каждого такого выбора элемент A_2 можно выбрать n_2 способами. Аналогично после каждого $k-1$ выбора элемент A_k можно выбрать n_k способами. Тогда число способов последовательно выбрать все элементы $A_1, A_2, \ldots, A_k$:

$$n_1 \times n_2 \times \ldots \times n_k.$$

Пример 1.3.2. В группе 100 студентов. Среди них нужно выбрать старосту, его заместителя и профорга. Сколько есть способов это сделать?

Решение. Старостой можно выбрать любого из 100 студентов, его заместителем — любого из оставшихся 99, а профоргом — любого из оставшихся 98 учащихся, то есть $n_1 = 100$, $n_2 = 99$, $n_2 = 98$.

По правилу произведения, общее число способов выбрать старосту, его заместителя и профорга:

$$n_1 \times n_2 \times n_3 = 100 \times 99 \times 98 = 970\,200.$$

Комбинации без повторений

Способы выбора элементов из заданного множества принято разделять на два класса: без повторений и с повторениями. Начнём с рассмотрения комбинаций без повторений.

ОПРЕДЕЛЕНИЕ 1.3.2

Перестановка без повторений

Перестановка из n элементов — это упорядоченный набор из всех n элементов. Число таких перестановок равно

$$P_n = n!$$

Например, есть яблоко, банан и апельсин. На рисунке 6 показаны все возможные способы расположить эти фрукты в ряд: $P_3 = 3!$

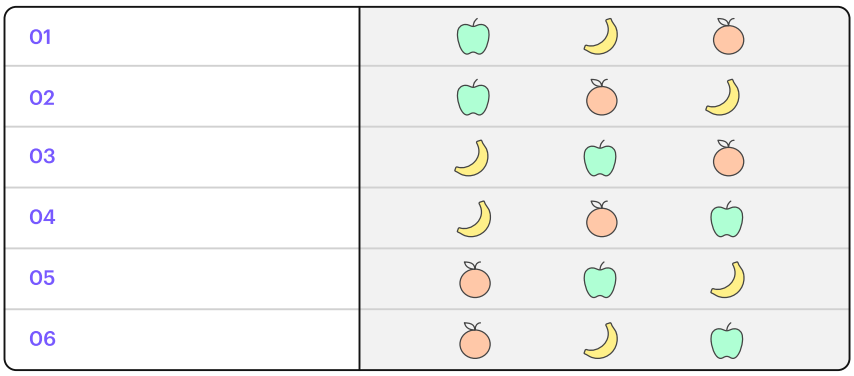

Рисунок 3. Перестановки без повторений

Пример 1.3.3. В линейку на первое сентября выстраиваются семь

школьников. Сколькими способами они могут выстроиться в ряд?

Решение.

$$P_7 = 7! = 5040.$$

■

ОПРЕДЕЛЕНИЕ 1.3.3

Размещение без повторений

Если комбинации из n элементов по m (*комбинации по m выбранных из n элементов*) отличаются либо составом элементов, либо порядком их расположения (либо и тем и другим), то такие комбинации называют **размещениями** из n элементов по m. Число размещений из n элементов по m равно

$$A_n^m = n \times (n-1) \times (n-2) \times \ldots \times (n-m+1) = \frac{n!}{(n-m)!}.$$

Размещение из n элементов по m — это упорядоченный набор из m различных элементов, выбранных из общего числа n элементов. Число таких размещений:

$$A_n^m = n \times (n-1) \times (n-2) \times \ldots \times (n-m+1) = \frac{n!}{(n-m)!}.$$

Снова возьмём яблоко, банан и апельсин. На рисунке 4 показаны все возможные способы выбрать из этого набора два фрукта с учётом порядка их расположения:

$$A_3^2 = \frac{3!}{(3-2)!} = 6.$$

Рисунок 4. Размещения без повторений

Рассмотрим ещё один пример.

Пусть дано множество из n различных элементов. Из этого множества образуются подмножества из m элементов: $0 < m \leqslant n$. Так, для множества из пяти элементов a, b, c, d, e получаются следующие комбинации:

- по 2 элемента — ab, ba, dc, cd, de и так далее;
- по 3 элемента — abc, bca, ace, edc и так далее.

В случае если $m = n$, то получаем перестановку как частный случай размещения.

Пример 1.3.4. Доступная палитра включает 8 цветов. Сколько различных флагов-**триколоров** можно составить, используя три различных цвета из этой палитры, если порядок полос имеет значение?

Решение.

$$A_8^3 = 8 \times 7 \times 6 = \frac{8!}{(8-3)!} = \frac{8!}{5!} = 336.$$

ОПРЕДЕЛЕНИЕ 1.3.4

Сочетание без повторений

Сочетание из n элементов по m — это неупорядоченный набор из m элементов, выбранных из общего числа n элементов. Число таких сочетаний:

$$C_n^m = \frac{n!}{m!(n-m)!}.$$

В качестве примера дополним сливой ранее рассмотренный набор, состоящий из яблока, банана и апельсина. На рисунке 5 показано, какие пары можно из них составить. При этом не важно, в каком порядке выбраны плоды.

$$C_4^2 = \frac{4!}{2!(4-2)!} = 6.$$

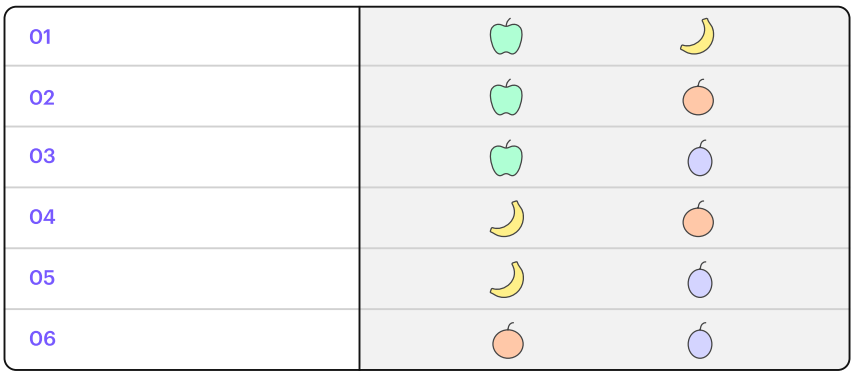

Рисунок 5. Сочетания без повторений

ОПРЕДЕЛЕНИЕ 1.3.5

Биномиальный коэффициент

Биномиальный коэффициент (C_n^m) — это коэффициент разложения бинома Ньютона при члене $a^{n-m} \times b^m$:

$$(a+b)^n = \sum_{m=0}^{n} C_m^n \times a^{n-m} \times b^m.$$

Биномиальный коэффициент обладает свойством симметричности:

$$C_n^k = C_n^{n-k}.$$

Это означает, что выбор k элементов из n равносилен выбору $n-k$ элементов, которые останутся невыбранными, поэтому

соответствующие биномиальные коэффициенты совпадают.

Пример 1.3.5. Доступная палитра включает 8 цветов. Сколько различных цветов можно получить, смешивая по 2 цвета из палитры?

Решение. Последовательность цветов в данном случае не важна: смешение красного и жёлтого даст такой же оранжевый, как и смешение жёлтого и красного в обратном порядке.

Таким образом, рассчитаем потенциальные комбинации с помощью формулы сочетания, а не размещения.

Для двух цветов:

$$C_8^2 = \frac{8!}{2!(8-2)!} = 28.$$

Рассчитаем также количество комбинаций для трёх цветов:

$$C_8^3 = \frac{8!}{3!(8-3)!} = 56.$$

Комбинации с повторениями

Мы рассмотрели комбинации из множеств, в которых элементы не повторяются. Теперь рассмотрим возможность дублирования среди n элементов.

ОПРЕДЕЛЕНИЕ 1.3.6
Перестановка с повторениями

Перестановка с повторениями из n элементов — это упорядоченный набор из n элементов, в котором некоторые или все элементы могут быть одинаковыми. Число таких перестановок:

$$P(n_1, \ldots, n_k) = \frac{n!}{n_1! n_2! \cdots n_k!},$$

где n_i — количество элементов i-того типа.

Пример 1.3.6. Есть 4 карточки с буквами: две с буквой M и две с буквой A. Сколько различных слов можно составить, переставляя все четыре карточки?

Решение.

$$n_1 = 2, \quad n_2 = 2, \quad n = 4,$$
$$P = \frac{n!}{n_1! \times n_2!} = \frac{4!}{2! \times 2!} = 6.$$

ОПРЕДЕЛЕНИЕ 1.3.7
Размещение с повторениями

Размещение с повторениями из n элементов по m — это упорядоченный набор длиной m из общего числа n элементов, в котором некоторые или все элементы могут быть одинаковыми.

Число таких размещений:

$$\widetilde{A}_n^m = n^m.$$

Пример 1.3.7. Сколько можно составить различных трёхзначных чисел из цифр $1, 2, 3, 4$ при условии, что цифры в числе могут повторяться?

Решение.

$$n = 4, \quad m = 3,$$
$$P = \widetilde{A}_4^3 = 4^3 = 64.$$

Пример 1.3.8. Какова вероятность, что при случайном перемешивании цифр $1, 2, 3, 4$ получится число 1234?

Решение. Пусть A — событие, состоящее в том, что после случайного перемешивания цифр $1, 2, 3, 4$ получается число 1234.

Как было сказано, чаще всего на практике применяется именно классическое определение вероятности. Воспользуемся им: обозначим рассматриваемое событие как A, тогда

$$\mathbb{P}(A) = \frac{1}{P} = \frac{1}{64}.$$

Пример 1.3.9. Среди 10 кинофильмов нужно распределить 5 разных призов. Один и тот же фильм может получить несколько призов. Сколько существует способов распределения призов?

Решение. Каждый из вариантов распределения призов представляет собой комбинацию 5 фильмов из 10, отличающуюся от других комбинаций или составом фильмов, или их порядком по номинациям (или и тем и другим), причём одни и те же фильмы могут повторяться несколько раз, то есть представляет размещение с повторениями из 10 элементов по 5.

Тогда

$$\widetilde{A}_{10}^5 = 10^5 = 100\,000.$$

ОПРЕДЕЛЕНИЕ 1.3.8

Сочетание с повторениями

Сочетание с повторениями из n элементов по m — это неупорядоченный набор длиной m из общего числа n элементов, в котором несколько или все элементы могут быть одинаковыми. Число таких сочетаний:

$$\widetilde{C}_n^m = C_{n+m-1}^m.$$

Пример 1.3.10. В конкурсе по 5 номинациям участвуют 10 кинофильмов. Сколько существует вариантов распределить призы, если по каждой номинации установлены одинаковые призы? Один и тот же фильм может стать победителем нескольких номинаций.

Решение. В этом случае порядок следования фильмов в комбинации из пяти призёров значения не имеет и число вариантов распределения призов представляет собой число сочетаний с повто-

рениями из 10 элементов по 5.

Тогда

$$\widetilde{C}_{10}^{5} = C_{10+5-1}^{5} = \frac{14 \times 13 \times 12 \times 11 \times 10}{1 \times 2 \times 3 \times 4 \times 5} = 2002.$$

Обрати внимание, насколько количество размещений **превышает** количество сочетаний.

Пример 1.3.11. В кондитерской продаются конфеты трёх видов: шоколадные, карамельные и мармеладные. Сколько различных наборов из 6 конфет можно собрать? Какова вероятность, что в одном из таких наборов окажется по 2 конфеты каждого вида?

Решение. Сначала найдём общее число возможных исходов. Так как конфеты одного вида неразличимы, а каждый вид может встречаться в наборе любое число раз, то число всех возможных наборов определяем по формуле сочетаний с повторениями:

$$n = 3, \quad m = 6,$$

$$P = \widetilde{C}_{n}^{m} = C_{n+m-1}^{m} = C_{6+3-1}^{6} = C_{8}^{6} = \frac{8!}{2! \times 6!} = 28.$$

Таким образом, всего возможных исходов 28. Благоприятный исход — это набор, содержащий ровно 2 шоколадные, 2 карамельные и 2 мармеладные конфеты. Так как конфеты одного вида неразличимы, такой набор единственный, то есть искомая вероятность:

$$\mathbb{P} = \frac{1}{P} = \frac{1}{28}.$$

4. ГЕОМЕТРИЧЕСКАЯ ВЕРОЯТНОСТЬ

Мы определили вероятность в классическом дискретном случае. Однако это определение не подходит, когда потенциальных элементарных исходов **бесконечно** много. В таких случаях используют геометрическую интерпретацию вероятности.

ОПРЕДЕЛЕНИЕ 1.4.1

Интерпретация геометрической вероятности

Интерпретация геометрической вероятности — представление благоприятных и неблагоприятных исходов в виде **площадей** определённых фигур.

Пусть в плоскую фигуру G включена плоская фигура меньшего размера g.

Тогда, если точка **равновероятно** может попасть в любую часть G, вероятность попасть в фигуру g равна отношению площадей g

и G:

$$\mathbb{P}(A) = \frac{g}{G}.$$

Пример 1.4.1. В случайную точку квадрата со стороной один метр падает дождевая капля. Какова вероятность, что она попадёт в круг, вписанный в этот квадрат?

Решение. Рассчитаем площадь этого круга: $\pi \times 0,5^2 = \frac{\pi}{4}$. Тогда вероятность рассчитывается как отношение двух площадей: $\mathbb{P}(A) = \frac{\pi}{4}$. ■

Геометрическая вероятность также применима к задачам со временем. Рассмотрим пример.

Вы с другом договорились встретиться между 15.00 и 16.00 в условленном месте и ждать друг друга в течение 5 минут.

Какова вероятность того, что вы встретитесь?

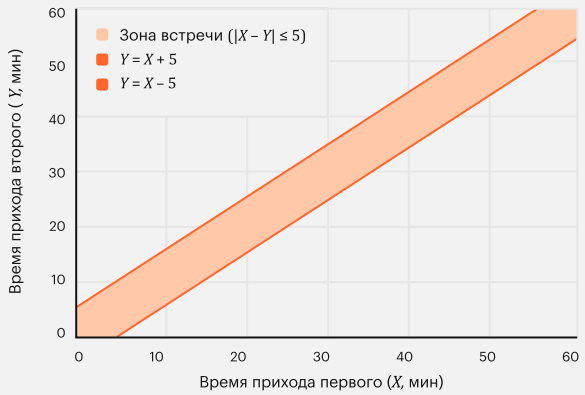

$$S = \{(x, y) \in [0, 60] \times [0, 60] \mid |x - y| \leq 5\}$$

$$A_{\text{total}} = 60 \times 60 = 3600\,\text{мин}^2$$

$$A_{\text{fail}} = 2 \times \left(\frac{1}{2} \times 55 \times 55\right) = 3025\,\text{мин}^2$$

$$A_{\text{success}} = A_{\text{total}} - A_{\text{fail}} = 575\,\text{мин}^2$$

$$P = \frac{A_{\text{success}}}{A_{\text{total}}} = \frac{575}{3600} \approx 0.1597$$

Рисунок 6. Задача на геометрическую вероятность и время

В этом случае время рассчитывается по тому же принципу, что и площадь или объём.

Часть 2. Множества, алгебры и меры

1. КОЛЬЦА И ПОЛУКОЛЬЦА

8 августа 1900 года на Международном конгрессе математиков в Париже немецкий учёный Давид Гильберт представил доклад «Математические проблемы». В нём он сформулировал 23 задачи, которые определили основные направления развития математики на ближайшее столетие.

Для теории вероятностей особое значение имела шестая задача. В упрощённой формулировке она звучит так: требуется строго аксиоматизировать те теории, которые используются в физике, особенно теорию вероятностей и механику.

К началу XX века в этих областях уже накопилось множество результатов, но они не были оформлены в виде строгих аксиоматических теорий.

Полностью шестая проблема до сих пор не решена. Но Андрей Николаевич Колмогоров аксиоматизировал теорию вероятностей и изложил её в 1933 году в монографии «Основные понятия теории вероятностей». Дата выхода монографии считается днём рождения теории вероятностей как строгой математической дисциплины. Сегодня более 90% научных публикаций, имеющих отношение к теории вероятностей, так или иначе опираются на аксиоматику Колмогорова.

Аксиоматика Колмогорова

Любая математическая теория строится по стандартной схеме: выделяются основные понятия и формулируются аксиомы — то есть правила «жизни» этих понятий.

Рассмотрим для примера аксиоматику линейного пространства. Пусть $\mathbb{F}$ — поле. Например, поле вещественных чисел $\mathbb{R}$ или комплексных чисел $\mathbb{C}$.

ОПРЕДЕЛЕНИЕ 2.1.1

Векторным пространством над полем $\mathbb{F}$ называется упорядоченная четвёрка $(V, \mathbb{F}, +, \cdot)$, в которой на множестве V определены операции:

- сложения $(+)$: $V \times V \to V$, обозначается $u + v$;
- умножения на скаляр $(\cdot)$: $\mathbb{F} \times V \to V$, обозначается $a \cdot v$ или av.

При этом для всех $u, v, w \in V$ и $a, b \in \mathbb{F}$ выполняются следующие аксиомы.

- Ассоциативность сложения: $(u + v) + w = u + (v + w)$.
- Коммутативность сложения: $u + v = v + u$.
- Существует нулевой вектор $0 \in V$, такой, что $u + 0 = u$.
- Для каждого $u \in V$ существует $-u \in V$, такое, что $u + (-u) = 0$.
- Дистрибутивность по векторной сумме: $a(u + v) = au + av$.
- Дистрибутивность по скалярам: $(a + b)u = au + bu$.
- Ассоциативность умножения: $a(bu) = (ab)u$.
- $1 \cdot u = u$, где 1 — единица в $\mathbb{F}$.

В этом примере основные понятия аксиоматики — это множество векторов, множество скаляров, операция сложения векторов и операция умножения вектора на скаляр, а сами аксиомы задают свойства этих операций и определяют, как они взаимодействуют между собой.

Теперь сформулируем аксиоматику Колмогорова.

ОПРЕДЕЛЕНИЕ 2.1.2

Аксиоматика Колмогорова

Вероятностное пространство — это тройка:

$$(\Omega, \mathcal{F}, \mathrm{P}),$$

где Ω — множество элементарных исходов (пространство исходов);

$\mathcal{F}$ — σ-алгебра подмножеств Ω, элементы которой называются событиями;

$\mathrm{P}\colon \mathcal{F} \to [0,1]$ — вероятностная мера, то есть σ-аддитивная функция на $\mathcal{F}$, удовлетворяющая $\mathrm{P}(\Omega) = 1$.

Это определение обычно приводится в начале всех курсов по теории вероятностей. У многих студентов оно вызывает недоумение: зачем всё так сложно? Что такое σ-алгебра и σ-аддитивность, если в простых примерах и так всё понятно?

Пример 2.1.1. Бросаем игральный кубик. Какова вероятность того, что выпадет число, не делящееся ни на 2, ни на 3?

Решение. Множество исходов: $\Omega = \{1,2,3,4,5,6\}$. Интересующее нас событие: $A = \{1,5\}$. 1 и 5. Таких исходов два из шести, значит:

$$\mathbb{P}(A) = \frac{2}{6} = \frac{1}{3}.$$

Кажется, всё понятно и без аксиоматики. Но чтобы двигаться дальше — к случайным процессам, законам больших чисел и центральной предельной теореме, интуитивного понимания недостаточно. Важно опираться на строгую математическую базу. Ей и посвящена эта глава. Мы не будем заниматься теорией вероятностей, но, чтобы обосновать введение новых объектов, будем иногда ссылаться на неё.

Полукольца

Полукольца и кольца нужны, чтобы понять, на каких множествах сначала удобно задавать меру и как затем последовательно расширять её на более сложные семейства множеств. Они служат промежуточными структурами между отдельными множествами и σ-алгеброй, на которой формулируется аксиоматика Колмогорова.

Прежде чем перейти к мысли о том, что такое полукольца, введём ряд обозначений:

- Ω — некоторое непустое множество. Это пространство элементарных исходов из курса теории вероятностей;
- 2^{Ω} — система всех подмножеств множества Ω;
- $\sqcup$ — операция объединения множеств, применяемая только к попарно дизъюнктным (то есть попарно непересекающимся) множествам.

ОПРЕДЕЛЕНИЕ 2.1.3

Полукольцо, или $\mathcal{S}$ (от *англ.* semiring)

Полукольцо — это такая непустая система $\mathcal{S} \subset 2^\Omega$ подмножеств, для которой выполняется следующее:

- $A \cap B \in \mathcal{S}$ для любых $A, B \in \mathcal{S}$, то есть полукольцо замкнуто относительно операции пересечения;
- для любых $A, B \in \mathcal{S}$ найдутся такие $n \in \mathbb{N}$ и $A_1, \ldots, A_n \in \mathcal{S}$, что:

$$A \setminus B = \bigsqcup_{k=1}^{n} A_k.$$

Ценность полукольца как системы множеств состоит в маленьком числе требований: замкнутость относительно пересечения и возможность представить разность двух элементов системы в виде конечного дизъюнктного объединения элементов системы. В результате эти системы могут быть достаточно «бедными», а значит, на них будет проще задавать меру.

Примеры полуколец: всё 2^Ω, система полуинтервалов $[a, b) \subset [0, 1)$ и система всевозможных промежутков на отрезке. В полукольце обязательно лежит пустое множество.

УТВЕРЖДЕНИЕ 2.1.1

Доказательство. Раз полукольцо непустое, возьмём его элемент A и применим к нему второй пункт определения 2.1.3 для $B = A$. Получим $\varnothing = A \setminus A = \bigsqcup_{k=1}^{n} A_k$, откуда получаем, что все A_k являются пустыми элементами полукольца. □

С полукольцами не очень удобно работать в том смысле, что у них довольно мало свойств. Например, нет гарантии, что, даже объединяя два элемента полукольца, получим элемент полукольца. Это приводит к более сложным системам множеств.

Кольца

Полукольцо замкнуто только относительно операции пересечения. Рассмотрим системы множеств, которые замкнуты относительно большего числа операций.

ОПРЕДЕЛЕНИЕ 2.1.4

Симметрическая разность, или $\triangle$

Симметрическая разность $A \triangle B$ двух множеств A и B — это множество, состоящее из элементов, которые принадлежат ровно одному из этих множеств:

$$A \triangle B = (A \cup B) \setminus (A \cap B).$$

Интуитивно, если симметрическая разность двух множеств мала, значит, множества похожи друг на друга. Это понимание поможет нам позже определить измеримые множества.

ОПРЕДЕЛЕНИЕ 2.1.5

Кольцо, или $\mathcal{R}$ (от *англ.* ring)

Кольцо — это система $\mathcal{R} \subset 2^\Omega$, замкнутая относительно пересечения и симметрической разности:

$$A \cap B \in \mathcal{R} \text{ и } A \triangle B \in \mathcal{R} \text{ для любых } A, B \in \mathcal{R}.$$

Своим названием кольца обязаны так называемым булевым кольцам с операциями $\cap$ в качестве умножения и $\triangle$ в качестве сложения. В начале есть похожий пример про векторные пространства.

Примерами колец могут быть: всё 2^Ω или система конечных объединений промежутков на отрезке.

Обрати внимание, что полукольцо полуинтервалов не будет кольцом (кроме тривиального случая). Таким образом, кольца обладают более сложной структурой, чем полукольца.

Кольцо замкнуто относительно объединения и вычитания.

УТВЕРЖДЕНИЕ 2.1.2

Доказательство. Следует из того, что $A \cup B = (A \triangle B) \triangle (A \cap B)$ и $A \setminus B = (A \cup B) \triangle B$. □

Таким образом, с элементами кольца можно совершать разные теоретико-множественные операции, не выходя при этом за рамки кольца.

Кольцо является полукольцом.

УТВЕРЖДЕНИЕ 2.1.3

Доказательство. Следует из предыдущего. □

Таким образом, кольца расширяют функционал полуколец, и потому их удобнее использовать, но при этом кольца — более «богатая» система множеств, потому что на ней сложнее задавать меру. С полуколец удобно стартовать, а кольца удобно использовать в качестве промежуточного итога при задании меры.

Если система множеств замкнута относительно пересечения и объединения, она может ещё не быть кольцом. Но если она замкнута ещё относительно вычитания, то это кольцо.

Построение минимального кольца

Из любой системы множеств можно построить кольцо. В частности, если исходная система — полукольцо, то сделать это особенно просто. В дальнейшем это позволит нам исследовать нужные свойства на полукольце, а затем переносить их на построенное по нему кольцо.

Над любой системой $\mathcal{X}$ множеств найдётся **наименьшее** (по включению) кольцо. Это наименьшее кольцо порождает **система** $\mathcal{X}$.

ТЕОРЕМА 2.1.1

Доказательство. Можно считать, что $\mathcal{X}$ является системой подмножеств множества $\Omega := \bigcup_{X \in \mathcal{X}} X$. Таким образом, есть по крайней мере одно кольцо над $\mathcal{X}$: всё 2^Ω.

Рассмотрим множество Δ всех колец над $\mathcal{X}$, которое по доказанному непусто. Рассмотрим пересечение $\bigcap_{\mathcal{D} \in \Delta} \mathcal{D}$ всех этих колец. Оно тоже является кольцом: если $A, B \in \bigcap_{\mathcal{D} \in \Delta} \mathcal{D}$, то $A, B \in \mathcal{D}$ для всех $\mathcal{D} \in \Delta$, откуда $A * B \in \mathcal{D}$ для всех $\mathcal{D} \in \Delta$ (где звёздочкой обозначено $\cap$ или $\triangle$), откуда $A * B \in \bigcap_{\mathcal{D} \in \Delta} \mathcal{D}$. □

Следующая лемма утверждает, что для полуколец возможно сделать минимальное кольцо, построив его «руками» из «кирпичиков» полукольца.

ЛЕММА 2.1.1

Наименьшее кольцо над полукольцом $\mathcal{S}$:

$$R(\mathcal{S}) := \left\{ \bigsqcup_{k=1}^{n} A_k : n \in \mathbb{N},\ A_1, \ldots, A_n \in \mathcal{S} \right\}.$$

Для доказательства потребуется следующий вспомогательный факт.

УТВЕРЖДЕНИЕ 2.1.4

Пусть $A, B_1, \ldots, B_n$ — элементы полукольца $\mathcal{S}$. Тогда существует такое $m \in \mathbb{N}$ и такие элементы $A_1, \ldots, A_m \in \mathcal{S}$, что:

$$A \setminus B_1 \setminus \ldots \setminus B_n = \bigsqcup_{k=1}^{m} A_k.$$

Доказательство. Зафиксируем произвольное полукольцо $\mathcal{S}$. Доказательство индукцией по n. База $n = 1$ является определением полукольца. Докажем переход от n к $n + 1$. Применив предположение индукции, получаем множества $A_1, \ldots, A_m$. Далее по определению каждое из множеств $A_1 \setminus B_{n+1}, \ldots, A_m \setminus B_{n+1}$ разбивается на дизъюнктное объединение элементов полукольца. □

Доказательство леммы 2.1.1. Обозначим через $\mathcal{R}$ минимальное кольцо над полукольцом $\mathcal{S}$. Включение $\mathcal{R} \supset R(\mathcal{S})$ очевидно, поскольку любое кольцо над $\mathcal{S}$ включает в себя элементы $R(\mathcal{S})$, так как кольцо замкнуто относительно операции объединения.

Докажем включение $\mathcal{R} \subset R(\mathcal{S})$. То есть нужно доказать, что $R(\mathcal{S})$ является кольцом в силу определения наименьшего кольца.

Неформально нужно доказать, что при пересечении и симметрической разности «склейки кирпичиков» получается более мелкая «склейка кирпичиков». Формально же нужно доказать, что $R(\mathcal{S})$ замкнуто относительно пересечения и симметрической разности. Рассмотрим:

$$A = \bigsqcup_{k=1}^{n} A_k \quad \text{и} \quad B = \bigsqcup_{s=1}^{m} B_s,$$

где A_k, B_s — элементы полукольца. Замкнутость относительно пересечения очевидна, так как

$$A \cap B = \bigsqcup_{k,s} (A_k \cap B_s)$$

и поскольку полукольцо замкнуто относительно пересечения (то есть все $A_k \cap B_s$ лежат в полукольце). Для замкнутости относительно симметрической разности нужно провернуть следующее. По утверждению 2.1.4 найдутся такие элементы $A_{k,i}$ и $B_{s,j}$ полукольца (где индексы i, j пробегают множества значений,

зависящие от $k,\ s$ соответственно), что:

$$A_k \setminus B_1 \setminus \ldots \setminus B_m = \bigsqcup_i A_{k,i} \quad \text{для всех} \quad k = 1, \ldots, n$$

и

$$B_s \setminus A_1 \setminus \ldots \setminus A_n = \bigsqcup_j B_{s,j} \quad \text{для всех} \quad s = 1, \ldots, m.$$

Теперь

$$A \triangle B = \left(\bigsqcup_{k,i} A_{k,i} \right) \sqcup \left(\bigsqcup_{s,j} B_{s,j} \right). \qquad \square$$

В будущем понадобится следующее умение раскладывать произвольные элементы полукольца на «кирпичики» из некоего общего набора.

УТВЕРЖДЕНИЕ 2.1.5

«Об общих кирпичах»

Пусть $A_1, \ldots, A_n$ — произвольные элементы полукольца $\mathcal{S}$. Тогда существуют такие попарно дизъюнктные элементы $B_1, \ldots, B_m \in \mathcal{S}$, что для любого $i \in \{1, \ldots, n\}$ найдётся такое $\Gamma_i \subset \{1, \ldots, m\}$, что:

$$A_i = \bigsqcup_{\gamma \in \Gamma_i} B_\gamma.$$

Доказательство. Докажем это утверждение индукцией по n. База $n = 1$ очевидна: берём $m = 1$ и $B_1 = A_1$. Для перехода $n \to n + 1$ применим предположение индукции для множеств $A_1, \ldots, A_n$; нам дадут некоторые множества $B_1, \ldots, B_m$. По утверждению 2.1.4 существует разбиение:

$$A_{n+1} \setminus B_1 \setminus \ldots \setminus B_m = \bigsqcup_j D_j.$$

Каждое из множеств $B_s \setminus A_{n+1}$ разобьём по определению полукольца; получим некоторые множества $B_{s,i}$. В итоге множества $B_{s,i}$, D_j и $A_{n+1} \cap B_s$ и есть искомые B_γ. $\square$

2. АЛГЕБРЫ И σ-АЛГЕБРЫ

Полуалгебра и алгебра

Полукольцо и кольцо задают семейство множеств с определёнными операциями, но их свойств недостаточно, чтобы построить вероятностную модель. Для этого есть полуалгебры и алгебры множеств.

ОПРЕДЕЛЕНИЕ 2.2.1

Единица, или Ω

Единица — это множество, содержащее любой другой элемент полукольца в качестве подмножества. Часто единицу обозначают как Ω.

Полуалгебра — это полукольцо, в котором лежит единица.

ОПРЕДЕЛЕНИЕ 2.2.2
Полуалгебра

Примеры полуалгебр: всё 2^{Ω}, система промежутков на отрезке. Система промежутков конечной длины на прямой будет полукольцом, но не полуалгеброй.

Алгебра — это кольцо, в котором лежит единица.

ОПРЕДЕЛЕНИЕ 2.2.3
Алгебра

Например, система конечных подмножеств множества натуральных чисел — кольцо, но не алгебра. Чтобы получить из неё алгебру, нужно добавить к ней все дополнения конечных множеств.

Любая алгебра является и полуалгеброй. Это непосредственно следует из определений выше.

Над любой системой множеств можно построить наименьшую алгебру, содержащую эту систему, так же как строили наименьшее кольцо.

Но наименьшее кольцо и наименьшая алгебра могут и не совпадать. Например, если система множеств — кольцо, но не алгебра. Более того, если $\mathcal{S}$ — полуалгебра, то наименьшее кольцо $R(\mathcal{S})$ будет и наименьшей алгеброй.

σ- и δ-алгебры

Мы хотим от вероятностной меры, чтобы она была σ-аддитивна, так как это свойство необходимо для построения вероятностного пространства. Это значит, что будем брать счётные наборы множеств и рассматривать их объединения. Как это сделать, если алгебра множеств не замкнута относительно счётных теоретико-множественных операций? Эта проблема приводит к следующим понятиям.

δ-кольцо — это кольцо, замкнутое относительно счётного пересечения.

ОПРЕДЕЛЕНИЕ 2.2.4
δ-кольцо

δ-алгебра — это δ-кольцо, которое ещё и алгебра.

ОПРЕДЕЛЕНИЕ 2.2.5
δ-алгебра

σ-кольцо — это кольцо, замкнутое относительно счётного объединения.

ОПРЕДЕЛЕНИЕ 2.2.6
σ-кольцо

σ-алгебра — это σ-кольцо, которое ещё и алгебра.

ОПРЕДЕЛЕНИЕ 2.2.7
σ-алгебра

Пример 2.2.1. Дано кольцо всевозможных конечных подмножеств множества натуральных чисел. Является ли это кольцо δ-кольцом и σ-кольцом?

Решение. Это кольцо замкнуто относительно счётных пересечений, так как при пересечении конечных множеств получаем конечные множества. Поэтому это кольцо ещё и δ-кольцо.

Но оно не является σ-кольцом, так как $\bigcup_{n\in\mathbb{N}}\{n\} = \mathbb{N}$ — не элемент кольца. ■

Теперь выясним, существует ли строгая импликация между σ- и δ-кольцами, а также алгебрами.

ТЕОРЕМА 2.2.1

Любое σ-кольцо является и δ-кольцом. Любая δ-алгебра является и σ-алгеброй.

Доказательство. Докажем первую часть. Рассмотрим σ-кольцо $\mathcal{R}$. Тогда для любых его элементов $A_1, A_2, \ldots$ выполнено следующее:

$$\bigcap_{n=1}^{\infty} A_n = A_1 \setminus \bigcup_{n=2}^{\infty} (A_1 \setminus A_n) \in \mathcal{R}.$$

Докажем вторую часть. Рассмотрим δ-алгебру $\mathcal{A}$. Тогда для любых её элементов $A_1, A_2, \ldots$ выполнено следующее:

$$\bigcup_{n=1}^{\infty} A_n = \Omega \setminus \bigcap_{n=1}^{\infty} (\Omega \setminus A_n) \in \mathcal{A}.$$

□

Таким образом, самая сильная система — это σ-алгебра: в неё включены свойства и алгебры, и σ-кольца, и δ-кольца. То есть именно σ-алгебра — это та самая система, которая замкнута относительно счётных операций.

Борелевские множества

Рассмотрим самый важный для теории вероятностей пример σ-алгебр для систем подмножеств прямой или пространства.

Аналогично порождённым кольцам и алгебрам можно ввести понятие порождённых δ-колец, δ-алгебр, σ-колец и σ-алгебр.

При этом наименьшая δ-алгебра — это и наименьшая σ-алгебра.

ОПРЕДЕЛЕНИЕ 2.2.8

Синглетон на $\mathbb{R}$

Синглетон на $\mathbb{R}$ — это множество единичной мощности.

Например, пусть система множества состоит из синглетонов на $\mathbb{R}$. Тогда над ней:

- наименьшим кольцом будет система, состоящая из всевозможных *конечных* подмножеств прямой;
- наименьшим δ-кольцом будет она же;
- наименьшим σ-кольцом будет система, состоящая из всевозможных *счётных* подмножеств прямой;
- наименьшей алгеброй будет система, состоящая из всевозможных конечных подмножеств прямой и из их дополнений (до прямой);
- наименьшей σ-алгеброй и наименьшей δ-алгеброй будет система, состоящая из всевозможных счётных подмножеств прямой и их дополнений.

ОПРЕДЕЛЕНИЕ 2.2.9

Борелевская σ-алгебра, борелевские множества

Борелевской σ-алгеброй $\mathcal{B}(\mathbb{R})$ на прямой называется σ-алгебра, порождённая системой открытых множеств. Множества, лежащие в ней, называются **борелевскими**.

Примеры боролевсих множеств — открытые и замкнутые множества (так как они дополнения открытых). В частности, интервалы и отрезки — тоже борелевские. Полуинтервалы — это борелевские множества, так как:

$$[a,b) = \bigcap_{\varepsilon \to 0} (a-\varepsilon, b).$$

Неборелевское множество построить сложно, но можно.

Порождённое кольцо строится так: на первом шаге рассматриваем множества, полученные однократным применением разных теоретико-множественных операций, а на втором шаге применяем теоретико-множественные операции к первому шагу и так далее. Через счётное число шагов получается порождённое кольцо.

На первый взгляд кажется, что борелевскую σ-алгебру можно порождать так же, разрешив дополнительно счётные объединения. Но это не так. Через счётное число операций мы *не получим борелевскую σ-алгебру*! Она получится через *несчётное* число операций. Так что фраза «рассмотрим операции, порождающие конкретное борелевское множество» некорректна: борелевские множества строятся сложной индукцией до несчётного количества операций.

Тем не менее есть простой способ, как работать с борелевской σ-алгеброй: нужно пользоваться тем, что это минимальная σ-алгебра над открытыми множествами. Следующие утверждения демонстрируют простоту использования этого метода.

ТЕОРЕМА 2.2.2

Борелевская σ-алгебра порождается системой замкнутых множеств.

Доказательство. Рассмотрим σ-алгебру, порождённую системой замкнутых множеств. С одной стороны, она содержит и открытые множества, а потому включает в себя борелевскую σ-алгебру. С другой стороны, замкнутые множества являются борелевскими, поэтому эта σ-алгебра включена в борелевскую. Таким образом, она совпадает с борелевской σ-алгеброй. □

ТЕОРЕМА 2.2.3

Борелевскую σ-алгебру можно порождать системой интервалов.

Доказательство. Рассмотрим σ-алгебру, порождённую системой интервалов. Поскольку интервалы открыты, понятно, что эта σ-алгебра лежит в борелевской. Так что достаточно показать, что она содержит открытые множества: отсюда будет следовать, что она содержит и все борелевские множества. □

Следующее утверждение закончит доказательство того, что борелевская σ-алгебра порождается системой интервалов.

ТЕОРЕМА 2.2.4

Любое открытое множество на прямой представимо в виде не более чем счётного дизъюнктного объединения интервалов (возможно, бесконечных).

Доказательство. Рассмотрим произвольное (непустое) открытое множество $U \subset \mathbb{R}$. Введём на его элементах отношение эквивалентности: $x \sim y$ для $x, y \in U$, если $[x, y] \subset U$ или $[y, x] \subset U$.

Это и правда отношение эквивалентности: рефлексивность и симметричность очевидны, а транзитивность нужно проверить небольшим перебором. Она следует из того, что если весь отрезок от x до y лежит в множестве и отрезок от y до z лежит в множестве, то и отрезок от x до z лежит в множестве как подмножество объединения двух других отрезков.

Так, открытое множество разбивается на классы эквивалентности. Если $x \sim y$, то и все точки между ними лежат в том же классе, так что классами эквивалентности являются промежутки (возможно, бесконечные).

На самом деле эти промежутки обязательно являются открытыми — иначе U не было бы открытым.

Таким образом, мы уже показали, что U представимо в виде дизъюнктного объединения интервалов. Осталось отметить, что это объединение не более чем счётное: в каждом интервале можно так выбрать рациональную точку, чтобы все выбранные рациональные точки не повторились (так как все классы эквивалентности не пересекаются). □

Субаддитивность и супераддитивность меры

Мы знаем, что

$$(x + y)^2 \geqslant x^2 + y^2$$

для неотрицательных чисел $x,\ y$. Если бы вместо знака неравенства стояло равно, то мы бы сказали, что «функция возведения в квадрат обладает свойством аддитивности». В нашем случае говорят, что функция возведения в квадрат *супераддитивна*. Аналогично для

$$\sqrt{x + y} \leqslant \sqrt{x} + \sqrt{y}$$

говорят, что функция корня *субаддитивна* (знак неравенства в другую сторону). Аналогичные определения можно дать и для меры.

ОПРЕДЕЛЕНИЕ 2.2.10

Отображение $m\colon \mathcal{S} \to [0, +\infty)$ называется **субаддитивным**, если

$$m(A) \leqslant \sum_{k=1}^{n} m(A_k), \text{ как только } A,\ A_1,\ \ldots,\ A_n \in \mathcal{S} \text{ и } A \subset \bigcup_{k=1}^{n} A_k.$$

ОПРЕДЕЛЕНИЕ 2.2.11

Отображение $m\colon \mathcal{S} \to [0, +\infty)$ называется **супераддитивным**, если

$$m(A) \geqslant \sum_{k=1}^{n} m(A_k), \text{ как только } A,\, A_1,\, \ldots,\, A_n \in \mathcal{S} \text{ и } A \supset \bigsqcup_{k=1}^{n} A_k.$$

УТВЕРЖДЕНИЕ 2.2.1

Мера на полукольце является субаддитивной и супераддитивной.

Доказательство. Обозначим через m меру на полукольце $\mathcal{S}$. Рассмотрим произвольные элементы $A,\, A_1,\, \ldots,\, A_n \in \mathcal{S}$. Применим к ним утверждение «об общих кирпичах». Получим некоторые множества $B_1,\, \ldots,\, B_r$ и такие множества $\Gamma,\, \Gamma_1,\, \ldots,\, \Gamma_n \subset \{1,\, \ldots,\, r\}$, что

$$A = \bigsqcup_{k \in \Gamma} B_k, \quad A_i = \bigsqcup_{k \in \Gamma_i} B_k.$$

Теперь супераддитивность следует из того, что

$$m(A) = \sum_{\gamma \in \Gamma} m(B_\gamma) \geqslant \sum_{i=1}^{n} \sum_{\gamma \in \Gamma_i} m(B_\gamma) = \sum_{i=1}^{n} m(A_i),$$

а субаддитивность следует из того, что

$$m(A) = \sum_{\gamma \in \Gamma} m(B_\gamma) \leqslant \sum_{i=1}^{n} \sum_{\gamma \in \Gamma_i} m(B_\gamma) = \sum_{i=1}^{n} m(A_i).$$

Обрати внимание, что условия на A_i различны для суб- и супераддитивности. □

Счётные субаддитивность и супераддитивность

Аналогично σ-аддитивности можно определить понятия **счётной субаддитивности** и **счётной супераддитивности**.

УТВЕРЖДЕНИЕ 2.2.2

Мера на полукольце является счётно супераддитивной.

Доказательство. Это легко следует из обычной супераддитивности и из того факта, что если $a_n \leqslant c$, то и $\lim a_n \leqslant c$. □

В отличие от счётной супераддитивности, со счётной субаддитивностью ситуация поинтереснее.

ТЕОРЕМА 2.2.5

Для меры на полукольце понятия счётной аддитивности и счётной субаддитивности равносильны.

Доказательство. Из счётной субаддитивности следует σ-аддитивность в силу того, что счётная супераддитивность меры уже доказана. Покажем, что из σ-аддитивности следует счётная субаддитивность. Каждое A_n заменим на его пересечение с A, это только уменьшит (точнее, не увеличит) сумму ряда $\sum m(A_n)$. Теперь по одному из утверждений первого лонгрида для каждого

n существует разбиение

$$A_n \setminus A_1 \setminus \ldots \setminus A_{n-1} = \bigsqcup_i B_{n,\,i}$$

на элементы полукольца, причём множества $B_{n,\,i}$ попарно дизъюнктны при различных n. Теперь

$$A = \bigcup_{n=1}^{\infty} A_n = \bigsqcup_{n,\,i} B_{n,\,i},$$

откуда

$$m(A) = \sum_{n=1}^{\infty} \sum_i m(B_{n,\,i}) \leqslant \sum_{n=1}^{\infty} m(A_n).$$

□

Как обещано, докажем σ-аддитивность меры Лебега — Стилтьеса (теорема из прошлого лонгрида).

Доказательство. По только что доказанному достаточно доказать счётную субаддитивность. Итак, пусть мера Лебега — Стилтьеса m построена по функции F на полукольце ограниченных полуинтервалов. Рассмотрим

$$[a,\,b) \subset \bigcup_{n=1}^{\infty} [a_n,\,b_n),$$

где все $a,\,b,\,a_n,\,b_n$ конечны. По непрерывности слева функции F можно отступить от a_n влево в точку $a'_n < a_n$ так, чтобы значение функции изменилось не больше чем на $\frac{\varepsilon}{2^n}$. Аналогично можно отступить от b влево в $b' < b$ так, чтобы значения функции F в этих точках отличались не больше чем на ε. Теперь

$$[a,\,b'] \subset \bigcup_{n=1}^{\infty} (a'_n,\,b_n),$$

и по лемме Гейне — Бореля можно выбрать конечное подпокрытие:

$$[a,\,b') \subset [a,\,b'] \subset \bigcup_{n=1}^{N} (a'_n,\,b_n) \subset \bigcup_{n=1}^{N} [a'_n,\,b_n).$$

Теперь

$$m[a,\,b) \leqslant m[a,\,b') + \varepsilon \leqslant \sum_{n=1}^{\infty} m[a_n,\,b_n) + 2\varepsilon.$$

Произвольный выбор погрешности ε завершает доказательство. □

Непрерывность снизу

У числовых функций есть ещё одно важное свойство: непрерывность, то есть переход к пределу. Для функций множества вводятся аналогичные понятия.

ОПРЕДЕЛЕНИЕ 2.2.12

Для возрастающей последовательности множеств $A_1 \subset A_2 \subset \ldots$ **пределом** называется

$$\lim_{n\to\infty} A_n := \bigcup_{n=1}^{\infty} A_n.$$

В дальнейшем мы будем использовать именно знак объединения, чтобы помнить, с каким именно объектом мы работаем.

ОПРЕДЕЛЕНИЕ 2.2.13

Мера m называется **непрерывной снизу**, если

$$m\left(\bigcup_{n=1}^{\infty} A_n\right) = \lim_{n\to\infty} m(A_n), \quad \text{где} \quad A_1 \subset A_2 \subset \ldots$$

и мера определена для всех множеств.

Не любая аддитивная функция является непрерывной. А что можно сказать про меры?

ТЕОРЕМА 2.2.6

Для меры на кольце понятия σ-аддитивности и непрерывности снизу равносильны. Для меры на полукольце из σ-аддитивности следует непрерывность, а обратное не всегда верно.

Доказательство. Докажем, что из σ-аддитивности на полукольце следует непрерывность снизу. Рассмотрим σ-аддитивную меру m на полукольце $\mathcal{S}$. Пусть множества $A_1 \subset A_2 \subset \ldots$ суть элементы полукольца, возрастающие к элементу $A \in \mathcal{S}$. По определению полукольца, для каждого n (полагая $A_0 = \varnothing$) существуют конечные разбиения

$$A_n \setminus A_{n-1} = \bigsqcup_i B_{n,\,i}$$

на элементы из полукольца. Теперь

$$m(A) = \sum_{n=1}^{\infty} \sum_i m(B_{n,\,i}) = \lim_{n\to\infty} m(A_n).$$

Осталось показать, что из непрерывности снизу на кольце следует σ-аддитивность. Рассмотрим непрерывную меру ν на кольце $\mathcal{R}$ и множество $A = \bigsqcup_{n=1}^{\infty} A_n \in \mathcal{R}$, где все A_n — тоже элементы кольца. Рассмотрим множества $B_n := \bigsqcup_{k=1}^{n} A_k$. Они возрастают к A, и поэтому

$$\nu(A) = \lim_{n\to\infty} \nu(B_n) = \lim_{n\to\infty} \sum_{k=1}^{n} \nu(A_k) = \sum_{k=1}^{\infty} \nu(A_k).$$

□

Пример 2.2.2. Контрпример, показывающий, что из непрерывности не следует σ-аддитивность, мы уже встречали: на полуалгебре $\{\langle a,\, b\rangle \cap \mathbb{Q} : a,\, b \in [0,\, 1]\}$ задаём меру $m(\langle a,\, b\rangle \cap \mathbb{Q}) := b - a$. Непрерывность этой меры понятна, а отсутствие σ-аддитивности мы уже знаем.

Непрерывность сверху

Аналогично непрерывности снизу можно рассмотреть и непрерывность сверху. Формулировки здесь не меняются.

ОПРЕДЕЛЕНИЕ 2.2.14

Для убывающей последовательности множеств $A_1 \supset A_2 \supset \dots$ **пределом** называется

$$\lim_{n\to\infty} A_n := \bigcap_{n=1}^{\infty} A_n.$$

В дальнейшем мы будем использовать именно знак пересечения, чтобы помнить, с каким именно объектом мы работаем.

ОПРЕДЕЛЕНИЕ 2.2.15

Мера m называется **непрерывной сверху**, если

$$m\left(\bigcap_{n=1}^{\infty} A_n\right) = \lim_{n\to\infty} m(A_n), \quad \text{где} \quad A_1 \supset A_2 \supset \dots$$

и мера определена для всех множеств.

ТЕОРЕМА 2.2.7

Для меры на кольце понятия σ-аддитивности и непрерывности сверху равносильны. Для меры на полукольце из σ-аддитивности следует непрерывность, а обратное не всегда верно.

Доказательство. Контрпример, показывающий, что из непрерывности не следует σ-аддитивность, такой же.

Докажем, что из σ-аддитивности на полукольце следует непрерывность сверху. Рассмотрим σ-аддитивную меру m на полукольце $\mathcal{S}$. Пусть множества $A_1 \supset A_2 \supset \dots$ суть элементы полукольца, убывающие к элементу A. По определению полукольца, для каждого n существуют конечные разбиения

$$A_n \setminus A_{n+1} = \bigsqcup_i B_{n,\,i}$$

на элементы из полукольца. Теперь

$$\begin{aligned} m(A_1) - m(A) &= \sum_{n=1}^{\infty} \sum_i m(B_{n,\,i}) = \\ &= \lim_{N\to\infty} \sum_{n=1}^{N} \sum_i m(B_{n,\,i}) = \\ &= m(A_1) - \lim_{N\to\infty} m(A_N). \end{aligned}$$

Осталось показать, что из непрерывности сверху на кольце следует σ-аддитивность. Рассмотрим непрерывную меру ν на кольце $\mathcal{R}$ и множество $A = \bigsqcup_{n=1}^{\infty} A_n \in \mathcal{R}$, где все A_n — тоже элементы кольца. Рассмотрим множества $B_n := A \setminus \bigsqcup_{k=1}^{n-1} A_k$. Они убывают к пустому множеству, и поэтому

$$0 = \lim_{n\to\infty} \nu(B_n) = \nu(A) - \lim_{n\to\infty} \sum_{k=1}^{n} \nu(A_k) = \nu(A) - \sum_{k=1}^{\infty} \nu(A_k).$$

□

3. МЕРЫ НА КОЛЬЦАХ И ПОЛУКОЛЬЦАХ

Мера на полукольце

Итак, мы теперь знаем два объекта в колмогоровской тройке $(\Omega, \mathcal{F}, \mathrm{P})$. Осталось разобраться с тем, что такое P. Начнём издалека.

ОПРЕДЕЛЕНИЕ 2.3.1

На полукольце $\mathcal{S}$ **мерой** (англ. measure) $m\colon \mathcal{S} \to [0, +\infty)$ называется **аддитивное отображение**, то есть такое, что

$$m\left(\bigsqcup_{k=1}^{n} A_k\right) = \sum_{k=1}^{n} m(A_k), \quad \text{как только} \quad A_1, \ldots, A_n, \bigsqcup_{k=1}^{n} A_k \in \mathcal{S}.$$

Понятно, что если в полукольце есть пустое множество и какое-то ещё, то мера пустого множества обязательно равна нулю.

Пример 2.3.1. Самый простой пример меры: вероятность на конечном пространстве элементарных исходов.

Пример 2.3.2. Слово «мера» часто используется в физике: мера объёма, мера веса и так далее. Это полностью согласовано с нашим определением. Объём аддитивен, масса аддитивна...

ОПРЕДЕЛЕНИЕ 2.3.2

Мера m на полукольце называется **монотонной**, если $m(A) \leqslant m(B)$ для любых элементов $A \subset B$ полукольца. (Обрати внимание, что даже для строгого включения нельзя написать строгое неравенство.)

УТВЕРЖДЕНИЕ 2.3.1

Мера на полукольце монотонна.

Пример 2.3.3. Главным примером меры для нас будет мера на полукольце промежутков, равная длине промежутка. Несложно проверить, что длина и правда аддитивна. Построенная нами мера является заготовкой для **классической меры Лебега**.

Пример 2.3.4. Ещё один интересный пример меры таков. Рассмотрим полукольцо полуинтервалов $[a, b) \subset \mathbb{R}$. Рассмотрим непрерывную, слева ограниченную, нестрого возрастающую функцию $F\colon \mathbb{R} \to \mathbb{R}$. На нашем полукольце определим меру по правилу:

$$\mu_F[a, b) := F(b) - F(a).$$

Нетрудно проверить, что эта функция будет мерой. Построенная нами мера является заготовкой для **меры Лебега — Стилтьеса**. Она интересна тем, что, как мы потом увидим, по сути любая мера на прямой является мерой Лебега — Стилтьеса.

σ-аддитивные меры

Аддитивные меры — это хорошо, но этого мало. Например, если мы работаем с распределением Пуассона

$$\mathrm{P}\{X = n\} = \frac{\lambda^n}{n!} e^{-\lambda}, \qquad n \in \{0, 1, 2, \ldots\}$$

из теории вероятностей, нам нужно уметь складывать вероятности счётного количества событий. Аддитивность не гарантирует нам, что ряд сойдётся к вероятности всего события. Для гарантий нам нужно усиление свойства аддитивности.

ОПРЕДЕЛЕНИЕ 2.3.3

Мера на полукольце $\mathcal{S}$ называется **σ-аддитивной** (иногда говорят *счётно-аддитивной*), если дополнительно к свойству аддитивности требуется аналогичное свойство для счётных объединений, то есть

$$m\left(\bigsqcup_{k=1}^{\infty} A_k\right) = \sum_{k=1}^{\infty} m(A_k), \text{ как только } A_1, \ldots, A_n, \ldots, \bigsqcup_{k=1}^{\infty} A_k \in \mathcal{S}.$$

Нетрудно понять, что из σ-аддитивности следует конечная аддитивность, поскольку можно брать A_n пустыми, начиная с некоторого номера.

Пример 2.3.5. На самом деле проще построить σ-аддитивную меру, чем не σ-аддитивную. Понятно, что если полукольцо конечно (в частности, если Ω конечно), то из аддитивности автоматически следует и σ-аддитивность. Вот хитрый пример, когда σ-аддитивность всё-таки нарушается.

Возьмём полукольцо $\mathcal{S} := \{\langle a, b\rangle \cap \mathbb{Q} : a, b \in [0,1]\}$, то есть полукольцо промежутков на рациональных числах. Определим на нём меру μ равной длине промежутка. Тогда мера любой точки равна 0,

$$\mu([0,1] \cap \mathbb{Q}) = 1 \neq 0 = \sum_{r \in [0,1] \cap \mathbb{Q}} \mu\{r\}.$$

Следующая теорема показывает, что σ-аддитивные меры и правда часто встречаются.

ТЕОРЕМА 2.3.1

Меры Лебега и Лебега — Стилтьеса σ-аддитивные на полукольце полуинтервалов.

Мы научимся доказывать теорему, когда изучим чуть больше свойств про меру.

Продолжение меры на кольцо

Построили меру на полукольце — что дальше? Хочется, например, для полуинтервалов научиться понимать, что общая длина двух интервалов равна сумме их длин. Хочется сказать, что меру можно продолжить на минимальное кольцо всевозможных объединений интервалов. Оказывается, это действительно можно сделать, причём единственным способом.

ТЕОРЕМА 2.3.2

Продолжение меры на кольцо

Пусть $m\colon \mathcal{S} \to [0, +\infty)$ является мерой на полукольце и $R(\mathcal{S})$ — порождённое
кольцо. Тогда существует единственное продолжение меры m до меры
$\nu\colon R(\mathcal{S}) \to [0, +\infty)$, то есть существует единственная мера

$\nu\colon R(\mathcal{S}) \to [0, +\infty)$, совпадающая с m на $\mathcal{S}$. Более того, если мера m была σ-аддитивна, то продолжение ν тоже будет σ-аддитивной мерой (в таком случае говорят, что *σ-аддитивность наследуется* при продолжении меры).

Доказательство. Любой элемент $A \in R(\mathcal{S})$ представим в виде $A = \bigsqcup_{k=1}^{n} A_k$, где $A_k \in \mathcal{S}$. Тогда, поскольку $\nu|_{\mathcal{S}} = m$ и ν аддитивна, единственный способ определить ν — это

$$\nu(A) := \sum_{k=1}^{n} m(A_k).$$

Неужели лемма доказана? Нет, нам сначала нужно доказать корректность построения (а потом ещё аддитивность полученного отображения). Допустим, оказалось, что имеется другое представление $A = \bigsqcup_{i=s}^{r} B_s$ в виде объединения элементов из полукольца. Тогда равенство

$$\sum_{k=1}^{n} m(A_k) = \sum_{s=1}^{r} m(B_s)$$

следует из утверждения «об общих кирпичах», что и доказывает корректность определения.

Докажем, что ν аддитивна (таким образом, она будет являться мерой). Рассмотрим элементы $R_1, \ldots, R_n \in R(\mathcal{S})$ и обозначим $R := \bigsqcup_{k=1}^{n} R_k \in R(\mathcal{S})$. Для каждого из множеств R_k есть представление в виде конечного дизъюнктного объединения элементов $A_{k,j}$ из полукольца соответственно. Тогда

$$\nu(R) = \sum_{k} \sum_{j} m(A_{k,j}) = \sum_{k} \nu(R_k).$$

Таким образом, мы показали, что мера с полукольца продолжается единственным образом на наименьшее кольцо.

Осталось показать наследование σ-аддитивности. Для этого достаточно в предыдущем рассуждении сказать, что k теперь пробегает счётное число значений, а j — всё ещё конечное. Рассмотрев разбиение множества R на конечное дизъюнктное объединение элементов A_i из полукольца, имеем

$$\nu(R) = \sum_{i} m(A_i) = \sum_{i,k,j} m(A_i \cap A_{k,j}) = \\ = \sum_{k,j} m(A_{k,j}) = \sum_{k} \nu(R_k),$$

где второе равенство следует из σ-аддитивности меры m, а третье — из того, что ряд по k сходится абсолютно. □

Таким образом, мы и вправду можем продолжить меру с полукольца интервалов на кольцо конечных объединений интервалов. Но нам хочется ещё большего! Хочется продолжить меру хотя бы на минимальную σ-алгебру (которой, кстати, будет борелевская). Оказывается, что и это можно сделать, но нужна чуть более про-

двинутая техника.

4. ВНЕШНЯЯ МЕРА

Построение внешней меры

Зафиксируем σ-аддитивную меру m на полуалгебре $\mathcal{S}$ подмножеств множества Ω. Мы уже умеем продолжать её на порождённую алгебру, но теперь мы хотим продолжить её на нечто большее.

ОПРЕДЕЛЕНИЕ 2.4.1

Внешняя мера Лебега $\mu^*\colon 2^\Omega \to [0;+\infty)$ определяется как

$$\mu^*(A) := \inf_{\substack{A_1,\, A_2,\, \ldots \in \mathcal{S} \\ \bigcup_{n=1}^{\infty} A_n \supset A}} \sum_{n=1}^{\infty} m(A_n).$$

Пример 2.4.1. Бывший муж — не муж, а внешняя мера — не мера! В самом деле, пусть $\mathcal{S} = \{\varnothing; \{1;\, 2\}\}$ и $m\{1;\, 2\} = 1$. Тогда $\mu^*\{1\} = \mu^*\{2\} = \mu^*\{1;\, 2\} = 1$, что нарушает свойство аддитивности.

ЛЕММА 2.4.1

Сужение внешней меры на порождённую алгебру совпадает с продолжением меры на эту алгебру.

Доказательство. Итак, рассмотрим $A \in R(\mathcal{S})$. Нужно доказать, что $\mu^*(A) = \nu(A)$. Поскольку $A = \\ = \bigsqcup_{n=1}^{N} A_n$, где $A_n \in \mathcal{S}$, то отсюда следует, что $\mu^*(A) \leqslant \nu(A)$. Неравенство в другую сторону следует из счётной субаддитивности меры ν. □

Таким образом, мы снова построили продолжение меры на порождённую алгебру.

Свойства внешней меры

Ну построили мы внешнюю меру, и что с ней делать? Давайте узнаем, что же это за зверь.

ЛЕММА 2.4.2

Внешняя мера счётно субаддитивна.

Доказательство. Мы это знали для сужения внешней меры на порождённую алгебру. Теперь мы это докажем для произвольных множеств. Рассмотрим произвольные $A \subset \bigcup_{n=1}^{\infty} A_n$. По определению внешней меры для каждого A_n существует счётное покрытие $\bigcup_{k=1}^{\infty} A_{n,k}$ элементами полуалгебры с точностью до $\frac{\varepsilon}{2^n}$, то есть такое покрытие, что

$$\sum_{k=1}^{\infty} m(A_{n,k}) < \mu^*(A_n) + \frac{\varepsilon}{2^n}.$$

Тогда $\bigcup_{n,k} A_{n,k}$ является счётным покрытием множества A, и мы

получаем:

$$\mu^*(A) \leqslant \sum_{n,k} m(A_{n,k}) < \sum_n \mu^*(A_n) + \varepsilon.$$

Произвольность выбранного ε заканчивает доказательство. □

Как мы знаем, для меры на полукольце σ-аддитивность и счётная субаддитивность равносильны. Следует ли отсюда, что внешняя мера σ-аддитивна? Конечно, нет, ведь внешняя мера — не мера. Зато есть такое следствие.

СЛЕДСТВИЕ 2.4.1

Для любых множеств $A,\ B \subset \Omega$ выполнено $|\mu^*(A) - \mu^*(B)| \leqslant \mu^*(A \triangle B)$.

Доказательство. Следует из того, что $A \subset B \cup (A \triangle B)$, и наоборот. □

Как мы обсуждали ещё при определении колец, маленькая симметрическая разность показывает, что сами множества похожи друг на друга. Только что доказанное следствие показывает, что то же самое верно и для внешних мер: если внешняя мера симметрической разности мала, то и внешние меры самих множеств близки.

Измеримые множества

Теперь мы выделим класс «хороших» множеств, для которых внешняя мера всё-таки является мерой. Как мы выяснили, в качестве такого класса, например, подходит порождённая алгебра $R(\mathcal{S})$. Но зачем ограничивать себя только этим классом?

ОПРЕДЕЛЕНИЕ 2.4.2

Итак, множество $A \subset \Omega$ называется **измеримым по Лебегу**, если «оно хорошо приближается множествами из порождённой алгебры», то есть для любого $\varepsilon > 0$ найдётся такое $A_\varepsilon \in R(\mathcal{S})$, что $\mu^*(A \triangle A_\varepsilon) < \varepsilon$. Несложно заметить, что любое множество из порождённой алгебры измеримо (приближая само себя).

Из предыдущего следствия получается, что внешние меры множеств A и A_ε близки.

Прежде чем работать с измеримостью, докажем несколько важных утверждений.

УТВЕРЖДЕНИЕ 2.4.1

Класс измеримых множеств образует алгебру.

Доказательство. Единица измерима как элемент порождённой алгебры. Рассмотрим произвольные измеримые множества $A,\ B$ и произвольное $\varepsilon > 0$. Обозначим через $*$, либо $\cap$, либо $\triangle$. Неудивительный факт заключается в том, что множество $A * B$ приближается множеством $A_\varepsilon * B_\varepsilon$, поскольку

$$(A * B) \triangle (A_\varepsilon * B_\varepsilon) \subset (A \triangle A_\varepsilon) \cup (B \triangle B_\varepsilon),$$

где внешняя мера большего множества (по субаддитивности) не превосходит 2ε.

Исходя из этого, оба множества $A \cap B$ и $A \triangle B$ измеримы. □

Таким образом, измеримые множества образуют надалгебру над порождённой алгеброй $R(\mathcal{S})$. Неплохо, да? Дальше будет ещё интереснее.

УТВЕРЖДЕНИЕ 2.4.2

Внешняя мера аддитивна на классе измеримых множеств (и, таким образом, является там мерой).

Доказательство. Поскольку класс измеримых множеств образует алгебру, достаточно показать, что если $A = B \sqcup C$ и все три множества измеримы, то $\mu^*(A) = \mu^*(B) + \mu^*(C)$. Неравенство $\mu^*(A) \leqslant \mu^*(B) + \mu^*(C)$ следует из субаддитивности внешней меры, поэтому нужно доказать только неравенство в другую сторону.

Зафиксируем произвольное $\varepsilon > 0$ и рассмотрим приближающие множества B_ε, C_ε из порождённой алгебры. Заметим, что допустимо взять $A_{2\varepsilon} := B_\varepsilon \cup C_\varepsilon$, поскольку $A \triangle A_{2\varepsilon} \subset (B \triangle B_\varepsilon) \cup (C \triangle C_\varepsilon)$. Таким образом (по следствию 2.4.1), нужно оценить внешнюю меру множества $A_{2\varepsilon}$. Это нетрудно сделать, поскольку все три множества $A_{2\varepsilon}$, B_ε, C_ε лежат в порождённой алгебре, на которой внешняя мера является мерой. В самом деле,

$$B_\varepsilon \cap C_\varepsilon \subset (B \triangle B_\varepsilon) \cup (C \triangle C_\varepsilon)$$

в силу дизъюнктности множеств B и C, а тогда $\mu^*(B_\varepsilon \cap C_\varepsilon) < 2\varepsilon$ и

$$\mu^*(A_{2\varepsilon}) = \mu^*(B_\varepsilon) + \mu^*(C_\varepsilon) - \mu^*(B_\varepsilon \cap C_\varepsilon) \geqslant \\ \geqslant \mu^*(B) + \mu^*(C) - 4\varepsilon.$$

Отсюда

$$\mu^*(A) \geqslant \mu^*(A_{2\varepsilon}) - 2\varepsilon \geqslant \mu^*(B) + \mu^*(C) - 6\varepsilon.$$

□

Таким образом, внешняя мера является мерой на алгебре измеримых множеств. Это подводит нас к следующему определению.

ОПРЕДЕЛЕНИЕ 2.4.3

Мерой Лебега μ называется сужение внешней меры на алгебру измеримых множеств. Следствие 2.4.1 утверждает, что мера измеримых множеств не сильно отличается от меры их приближений из полуалгебры.

Итак, мы научились продолжать σ-аддитивную меру с полуалгебры на алгебру измеримых множеств. На следующей неделе мы ещё немного изучим свойства этой меры и свойства продолжения меры.

5. МЕРЫ НА σ-АЛГЕБРАХ

Продолжение меры: теорема Каратеодори

Итак, на прошлой неделе мы научились продолжать σ-аддитивную меру m с полуалгебры аж до меры Лебега μ на

алгебре измеримых множеств, которая, возможно, даже больше порождённой алгебры. Какими же ещё интересными свойствами она обладает?

Класс измеримых множеств образует σ-алгебру, и мера Лебега на ней σ-аддитивна.

ТЕОРЕМА 2.5.1

Доказательство. Счётная аддитивность меры Лебега получается совсем просто: мера Лебега счётно субаддитивна на классе измеримых множеств, поскольку совпадает на нём с внешней мерой Лебега, которая всегда счётно субаддитивна (лемма 2 из предыдущего лонгрида). Класс измеримых множеств образует алгебру, а как мы знаем, счётная субаддитивность и σ-аддитивность меры на полукольце равносильны.

Покажем, что алгебра измеримых множеств замкнута относительно счётного объединения. Рассмотрим измеримые множества $A_1,\ A_2,\ \ldots$ и положим $A := \bigcup_{n=1}^{\infty} A_n$. Для каждого n рассмотрим измеримые множества $B_n := A_n \setminus \bigcup_{k=1}^{n-1} A_k$. Теперь $A = \bigsqcup_{n=1}^{\infty} B_n$, и в силу монотонности внешней меры для произвольного N:

$$\sum_{n=1}^{N} \mu(B_n) = \mu\left(\bigsqcup_{n=1}^{N} B_n\right) \leqslant \mu^*(A) < +\infty.$$

Отсюда можно заключить, что $\sum_{n=1}^{\infty} \mu(B_n) < +\infty$. Теперь идея в том, чтобы отбросить маленький, но бесконечный хвост: для произвольного $\varepsilon > 0$ рассмотрим такое N, что $\sum_{n=N+1}^{\infty} \mu(B_n) < \frac{\varepsilon}{2}$, и в качестве A_ε возьмём множество, $\frac{\varepsilon}{2}$-приближающее измеримое объединение $\bigsqcup_{n=1}^{N} B_n$. Оно подходит, поскольку

$$A \triangle A_\varepsilon \subset \left(A_\varepsilon \triangle \bigsqcup_{n=1}^{N} B_n\right) \cup \bigsqcup_{n=N+1}^{\infty} B_n,$$

и по субаддитивности внешней меры

$$\mu^*\left(A \triangle A_\varepsilon\right) \leqslant \mu^*\left(A_\varepsilon \triangle \bigsqcup_{n=1}^{N} B_n\right) + \mu^*\left(\bigsqcup_{n=N+1}^{\infty} B_n\right) < \\ < \frac{\varepsilon}{2} + \frac{\varepsilon}{2} = \varepsilon.$$

□

В частности, мы доказали, что любую σ-аддитивную меру можно продолжить с полуалгебры на порождённую σ-алгебру $\sigma(\mathcal{S})$. Как мы помним, любую меру можно продолжить с полуалгебры на порождённую алгебру единственным способом. А что происходит с единственностью продолжения, если мы добавляем σ-аддитивность?

Пусть на полуалгебре $\mathcal{S}$ задана σ-аддитивная мера m. Тогда сужение меры Лебега на $\sigma(\mathcal{S})$ является единственным σ-аддитивным продолжением меры m до меры на $\sigma(\mathcal{S})$.

ТЕОРЕМА 2.5.2

Теорема Каратеодори о продолжении меры

Доказательство. Мы уже доказали, что мера Лебега является σ-аддитивной мерой на σ-алгебре измеримых множеств, включающей в себя $\sigma(\mathcal{S})$. Поэтому осталось доказать только единственность продолжения. Рассмотрим некоторое другое σ-аддитивное продолжение η меры m, не совпадающее с мерой Лебега на $\sigma(\mathcal{S})$.

Рассмотрим такое $A \in \sigma(\mathcal{S})$, что $\eta(A) \neq \mu(A)$. В силу его измеримости по Лебегу, для любого $\varepsilon > 0$ найдётся такое $A_\varepsilon \in R(\mathcal{S})$, что

$$|\mu(A) - \mu(A_\varepsilon)| < \mu(A \triangle A_\varepsilon) < \varepsilon.$$

Поскольку мера m продолжается на $R(\mathcal{S})$ единственным способом, то $\eta(A_\varepsilon) =$
$= \mu(A_\varepsilon)$. Из субаддитивности меры η получаем:

$$|\eta(A) - \eta(A_\varepsilon)| < \eta(A \triangle A_\varepsilon).$$

В итоге по неравенству треугольника

$$|\mu(A) - \eta(A)| \leqslant \varepsilon + \eta(A \triangle A_\varepsilon).$$

По определению внешней меры существует такое счётное покрытие

$$\bigcup_{n=1}^{\infty} B_n \supset A \triangle A_\varepsilon$$

элементами полуалгебры, что

$$\sum_{n=1}^{\infty} m(B_n) < \mu^*(A \triangle A_\varepsilon) + \varepsilon = \mu(A \triangle A_\varepsilon) + \varepsilon < 2\varepsilon.$$

Тогда по субаддитивности меры η и в силу совпадения мер на полуалгебре

$$\eta(A \triangle A_\varepsilon) \leqslant \sum_{n=1}^{\infty} \eta(B_n) = \sum_{n=1}^{\infty} m(B_n) < 2\varepsilon,$$

и окончательно

$$|\mu(A) - \eta(A)| < 3\varepsilon,$$

что завершает доказательство. □

Мера Лебега — Стилтьеса и борелевская мера

Вспомним один важный пример меры, который мы когда-то приводили.

ОПРЕДЕЛЕНИЕ 2.5.1

Рассмотрим полуалгебру $\mathcal{S}$ прямой, состоящую из всех полуинтервалов вида $[a,\, b)$. Границы $a,\, b$ могут быть бесконечными, но левую $-\infty$ мы не включаем, конечно. Для непрерывной слева, нестрого возрастающей, ограниченной функции $F\colon \mathbb{R} \to \mathbb{R}$ зададим конечную меру $m\colon \mathcal{S} \to [0, +\infty)$ по правилу:

$$m[a,\, b) := F(b) - F(a).$$

Как мы знаем, m является σ-аддитивной мерой. Мера Лебега, построенная по этой мере m, называется **мерой Лебега — Стилтьеса**.
То есть по функции можно строить меру! Оказывается, в некотором смысле верно и обратное.

Теорема Каратеодори гарантирует, что если на прямой задана σ-аддитивная мера на полуинтервалах, то она единственным образом продолжается на борелевскую σ-алгебру. Это подводит к следующему определению.

ОПРЕДЕЛЕНИЕ 2.5.2

Борелевской мерой, или **мерой Бореля**, называется σ-аддитивная мера на борелевской σ-алгебре.

Стоит отметить, что поскольку наш курс ориентирован на теорию вероятностей, в которой мера всей прямой — единица, то в нём рассматриваются только конечные меры. Вообще же в обычной жизни меры могут принимать и бесконечные значения. В таком случае говорят, что мера *σ-конечна*, если единицу σ-алгебры можно разбить на счётное объединение множеств конечной меры. Определение борелевских мер тем самым не меняется, но меры могут быть и σ-конечными.

Исторически сначала человечество пыталось построить именно борелевские меры. Подход к этому был не очень удобный, как мы увидим, ещё и потому, что сами борелевские меры не обладают всеми теми свойствами, которые даёт подход Лебега.

Следующая теорема показывает, что разные подходы приводят почти к одному и тому же.

ТЕОРЕМА 2.5.3

Любая борелевская мера на прямой является сужением некоторой меры Лебега — Стилтьеса на борелевскую σ-алгебру.

Доказательство. Для борелевской меры μ рассмотрим функцию $F\colon \mathbb{R} \to \mathbb{R}$, определённую по правилу:

$$F(x) := \mu(-\infty,\, x).$$

Тогда она нестрого возрастает, непрерывна слева и ограничена, а потому по ней можно построить меру Лебега — Стилтьеса. Её сужение на борелевскую σ-алгебру совпадает с μ по теореме Каратеодори в силу единственности продолжения. □

Структура измеримых множеств

Как мы понимаем, σ-алгебра измеримых множеств может оказаться больше порождённой σ-алгебры. Но насколько больше? Ответ неоднозначен. С одной стороны, класс измеримых множеств может оказаться даже больше по мощности. С другой стороны, как говорит теорема о структуре измеримых множеств, измеримые множества крайне похожи на множества из порождённой σ-алгебры.

ТЕОРЕМА 2.5.4
О структуре измеримых множеств

Множество A является измеримым тогда и только тогда, когда найдётся такое *измеримое ядро* $A' \in \sigma(\mathcal{S})$ и такая *измеримая оболочка* $A'' \in \sigma(\mathcal{S})$, что

$$A' \subset A \subset A'' \quad \text{и} \quad \mu(A'' \setminus A') = 0.$$

Прежде чем переходить к доказательству, заметим одно важное свойство меры Лебега.

ОПРЕДЕЛЕНИЕ 2.5.3

Мера называется **полной**, если любое подмножество множества нулевой меры измеримо (и имеет нулевую меру).

Как мы увидим дальше, мера Бореля, построенная по длинам интервалов, не полна. А вот мера Лебега полна.

Следовательно, по теореме о структуре измеримых множеств любое измеримое множество представимо в виде дизъюнктного объединения множества из $\sigma(\mathcal{S})$ и множества нулевой меры.

Для доказательства теоремы нам потребуется следующая лемма.

ЛЕММА 2.5.1

Для любого множества $A \subset \Omega$ найдётся такое *измеримое ядро* $A' \in \sigma(\mathcal{S})$ и такая *измеримая оболочка* $A'' \in \sigma(\mathcal{S})$, что

$$A' \subset A \subset A'', \qquad \mu(A'') = \mu^*(A) \quad \text{и} \quad \mu(\Omega \setminus A') = \mu^*(\Omega \setminus A).$$

Доказательство. По определению внешней меры (и по её счётной субаддитивности) для всякого $\varepsilon > 0$ найдётся такое покрытие $A^\varepsilon \in \sigma(\mathcal{S})$ множества A, что $\mu^*(A) \geqslant \mu(A^\varepsilon) - \varepsilon$. Таким образом, найдётся такое множество $A'' := \bigcap_{\varepsilon \to 0} A^\varepsilon \in \sigma(\mathcal{S})$, что $A'' \supset A$ и $\mu^*(A) = \mu(A'')$. Аналогично строится множество $\Omega \setminus A'$ для множества $\Omega \setminus A$. □

Доказательство теоремы о структуре измеримых множеств

Доказательство. Пусть множество A измеримо. Тогда из предыдущей леммы получаем измеримые ядро и оболочку и, заменяя внешние меры на меры, получаем требуемое. Обратно: пусть $\mu(A'' \setminus A') = 0$. Тогда $A = A' \sqcup B$, где $B \subset A'' \setminus A'$ — некое измеримое множество нулевой меры. □

Множество Кантора

Сегодня мы в основном будем работать с самой обычной мерой на прямой, построенной по длинам полуинтервалов.

ОПРЕДЕЛЕНИЕ 2.5.4

Мера Лебега на прямой, построенная по длинам полуинтервалов, называется **классической**. Классической мерой Бореля называется сужение классической меры Лебега на борелевскую σ-

алгебру.
Напомним одно важное свойство, которым обладают меры Лебега (не только классическая).

ОПРЕДЕЛЕНИЕ 2.5.5

Мера называется **полной**, если любое подмножество множества нулевой меры измеримо (и имеет нулевую меру).

Это очень удобное свойство, без которого могут возникать разные неприятные ситуации (которые мы разберём позже). Скоро мы увидим, что классическая мера Бореля не полна. Для этого нам потребуется знаменитое множество Кантора.

ОПРЕДЕЛЕНИЕ 2.5.6

Обозначим $C_0 := [0,\ 1]$. Выделим в нём центральную треть $\left(\frac{1}{3},\ \frac{2}{3}\right)$ и удалим — получим множество C_1. На следующем шаге выделим в каждом из двух отрезков в C_1 центральный интервал и удалим их оба — получится множество C_2. И так далее: множество C_{n+1} получается из множества C_n выкидыванием 2^n интервалов, являющихся центральными третями отрезков, из которых состоит множество C_n. Предельное множество

$$C := \bigcap_{n=0}^{\infty} C_n$$

называется **множеством Кантора**.

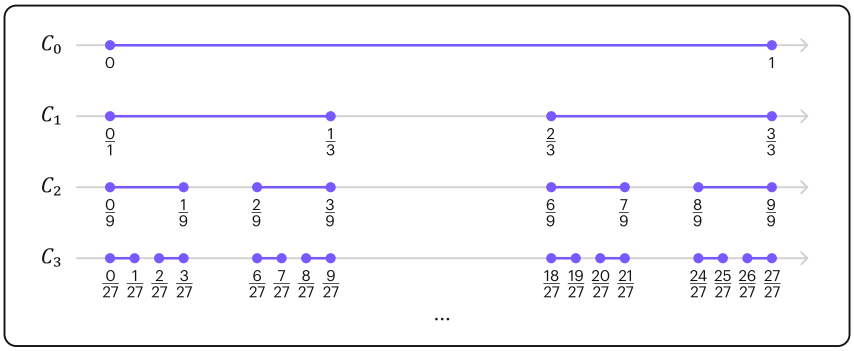

Рисунок 7. К определению множества Кантора

ТЕОРЕМА 2.5.5

Множество Кантора нигде не плотно, континуально, компактно и является борелевским множеством нулевой меры.

Доказательство. Нигде не плотность множества C означает, что в любой (непустой) открытой окрестности U найдётся (непустое) открытое множество V, в котором нет ни одной точки нашего множества C, то есть $V \subset U \setminus C$. Действительно, числа вида $\frac{k}{3^n}$ всюду плотны — в любом интервале найдутся представители этого вида. Каждое из них является либо концом, либо внутренней точкой одного из выкинутых интервалов, в котором нет точек нашего множества C. Пересечение этого интервала с U и есть искомое открытое множество V.

Континуальность множества Кантора следует из того, что каждая его точка однозначно сопоставляется последовательности из $\{0,\ 1\}^{\mathbb{N}}$, которых, как известно, континуум.

Как строится это сопоставление? Итерационно по n — номеру члена последовательности. Пусть $x \in C_{n-1}$ и $x \in C_n$, то есть x

принадлежит какому-то отрезку C_{n-1}, и при выкидывании интервала из центра этого отрезка x остался либо в левой его трети, либо в правой. В первом случае поставим 0 на n-м месте нашей последовательности, во втором — 1.

Компактность следует из того, что множество Кантора ограничено и замкнуто как счётное пересечение замкнутых множеств из $[0,\,1]$.

Борелевость следует из замкнутости.

Заметим, что $\lambda(C_n) = \frac{2}{3}\lambda(C_{n-1})$, а значит,

$$\lambda(C) = \lim_{n\to\infty} \lambda(C_n) = \lim_{n\to\infty} \left(\frac{2}{3}\right)^n = 0$$

в силу непрерывности меры. □

Пример 2.5.1. Покажем, что классическая мера Бореля не полна. Рассмотрим множество Кантора. У него $2^{\mathbb{R}}$ различных подмножеств, что строго больше континуума. Известный факт (который мы оставляем без доказательства, так как для него нужна сложная техника трансфинитной индукции) заключается в том, что борелевская σ-алгебра континуальна. Следовательно, канторово множество имеет неборелевское подмножество (и даже много). Поскольку само оно имеет нулевую меру, это нарушает полноту классической меры Бореля.

Позже мы научимся строить неборелевское множество нулевой меры своими собственными руками, что даст нам ещё одно доказательство неполноты меры Бореля.

Пример 2.5.2. В силу полноты меры Лебега все подмножества канторова множества измеримы. Таким образом, в предыдущем примере мы доказали существование большого количества измеримых неборелевских множеств. Это лишний раз подтверждает, что подход Лебега даёт больше, чем подход Бореля.

Множество Витали

Итак, на прямой существуют измеримые неборелевские множества. А существуют ли просто неизмеримые множества? До этого мы не задавались этим вопросом, полагая, что работаем только с измеримыми множествами. На самом деле, ответ зависит от меры, но даже на классической мере ответ неоднозначен.

Пример 2.5.3. Зафиксируем точку $x \in [0,\,1]$ и зададим **меру Дирака** как

$$\delta_x(A) := I\{x \in A\}.$$

По этой мере все множества измеримы.

Для классической меры Лебега ситуация меняется.

ТЕОРЕМА 2.5.6
Множество Витали

У любого подмножества отрезка $[0,\,1]$, имеющего классическую положительную меру Лебега, существует неизмеримое по Лебегу

подмножество.

Доказательство. Здесь удобнее считать, что мера задана на чуть большем отрезке (чтобы можно было залезать за края).

Введём на отрезке $[0,\,1]$ отношение эквивалентности: $x \sim y$, если $x - y \in \mathbb{Q}$. Таким образом, весь отрезок разбивается на классы эквивалентности. *Выберем* в каждом классе по представителю. Обозначим через V множество всех выбранных представителей.

Для каждого рационального $r \in [-1,\,1] \cap \mathbb{Q}$ рассмотрим сдвиги $V_r := V + r = \\ = \{v + r : v \in V\}$. Заметим, что при различных $r \neq r'$ множества V_r и $V_{r'}$ не пересекаются: иначе бы это означало, что некоторые два разных представителя отличаются на $r - r' \in \mathbb{Q}$.

Покажем, что ни одно из множеств V_r не имеет подмножества положительной меры. В самом деле, пусть нашлось $B_{r_0} \subset V_{r_0}$ положительной меры. Поскольку классическая мера Лебега не меняется, если множество подвергают сдвигу, то для каждого r найдутся $B_r \subset V_r$ той же меры. Тогда

$$\bigsqcup_r B_r \subset \bigsqcup_r V_r \subset [-1,\,2]$$

и

$$+\infty = \sum_r \lambda(B_r) \leqslant \sum_r \lambda(V_r) \leqslant 3,$$

то есть мы пришли к противоречию, а значит, такого B_{r_0} не существует.

Осталось завершить доказательство теоремы. Рассмотрим произвольное подмножество $A \subset [0,\,1]$ положительной меры. Рассмотрим множества $A \cap V_r$. По только что доказанному ни одно из них не является множеством положительной меры. Но они не могут все быть множествами нулевой меры, поскольку

$$A \subset \bigsqcup_r A \cap V_r.$$

Следовательно, как минимум одно из этих множеств неизмеримо. □

Аксиома выбора

В построении множества Витали выделено курсивом слово «*выберем*». Это непроста. На самом деле, утверждение, что в любой системе непустых множеств можно выбрать из каждого множества по представителю, не выводится из других аксиом. Это утверждение само является аксиомой, называемой **аксиомой выбора**. Его возвели в ранг аксиомы потому, что, несмотря на его интуитивную естественность, из него следуют довольно контринтуитивные результаты. Вот один из таких результатов.

Апельсин можно разрезать на пять частей, переставить их местами и получить два точно таких же апельсина.

ТЕОРЕМА 2.5.7

Парадокс Банаха — Тарского

На первый взгляд кажется, что это нарушает закон сохранения массы или аддитивность объёма для твёрдых тел. Но тут стоит держать в голове, что и объём, и масса являются *мерами*, а в парадоксе Банаха — Тарского, конечно, вырезаются пять *неизмеримых* множеств.

Парадокс Банаха — Тарского так не понравился математикам, что некоторые перестали принимать аксиому выбора и работают без неё. Можно пойти ещё дальше и сформулировать аксиому, заменяющую аксиому выбора. Одной из таких аксиом является **аксиома детерминированности**. Мы не будем приводить здесь её формулировку, потому что она довольно громоздкая и мы всё равно не будем с ней работать. Но полезно знать, что аксиома выбора и аксиома детерминированности взаимно исключают друг друга: если выполняется одна, то не выполняется другая, и наоборот.

Так вот, если не принимать аксиому выбора, а принять вместо неё аксиому детерминированности, то *все множества на отрезке будут измеримы по Лебегу*.

В дальнейшем мы всегда будем полагать, что верна аксиома выбора, и что на прямой существуют неизмеримые множества. Это самый распространённый подход.

6. ИЗМЕРИМЫЕ ФУНКЦИИ И ПРОСТРАНСТВА

Измеримые функции

Пару (X, σ_X), состоящую из единицы X и σ-алгебры σ_X на ней, называют **измеримым пространством**. Это определение объясняется тем, что обычно на σ_X ещё задана некоторая мера, относительно которой все элементы σ-алгебры являются измеримыми.

ОПРЕДЕЛЕНИЕ 2.6.1

Итак, мы построили меру и задали измеримое пространство. Мы теперь можем работать на нём с любыми функциями? Конечно, нет. Представь, что мы хотим найти меру ядра некоторого отображения на нашем измеримом пространстве. Чтобы это можно было сделать, необходимо, чтобы ядро было измеримым, а это выполняется не для всех функций. Это накладывает некоторые ограничения на функции, которые приводят к следующему определению.

Рассмотрим два измеримых пространства (X, σ_X) и (Y, σ_Y). Отображение $f\colon X \to Y$ называется $\boldsymbol{\sigma_X|\sigma_Y}$**-измеримым**, или просто **измеримым** (при условии, что понятно, о каких σ-алгебрах речь), если $f^{-1}(B) \in \sigma_X$ для любого $B \in \sigma_Y$. Иногда такие отображения обозначают $f\colon (X, \sigma_X) \to (Y, \sigma_Y)$, чтобы явно подчеркнуть, относительно каких σ-алгебр полагается

ОПРЕДЕЛЕНИЕ 2.6.2

измеримость.

В случае если $(Y, \sigma_Y) = (\mathbb{R}, \mathcal{B}(\mathbb{R}))$, мы будем использовать термин **«измеримая функция»**.
Несложно проверить, что композиция двух измеримых отображений (с согласованными областями определений и значений) тоже измерима.

Пример 2.6.1. Рассмотрим некоторое измеримое множество $A \in \sigma_X$. Самым простым примером измеримой функции является **индикатор**: это функция $\mathcal{I}_A \colon X \to \mathbb{R}$, определяемая как

$$\mathcal{I}_A(x) = \begin{cases} 1, & \text{если } x \in A; \\ 0, & \text{если иначе.} \end{cases}$$

Пример 2.6.2. Через $\mathcal{M}$ обозначим σ-алгебру измеримых по Лебегу множеств. **Борелевскими** называются функции $(\mathbb{R}, \mathcal{B}(\mathbb{R})) \to (\mathbb{R}, \mathcal{B}(\mathbb{R}))$. **Измеримыми по Лебегу** (или просто **измеримыми**) называются функции $(\mathbb{R}, \mathcal{M}) \to (\mathbb{R}, \mathcal{B}(\mathbb{R}))$. Из свойств измеримости мы знаем, что любая борелевская функция измерима. Как мы увидим дальше, обратное не всегда верно. Сами по себе борелевские функции всем нравятся потому, что если навесить борелевскую функцию на измеримую функцию, то получится снова измеримая функция. В частности, композиция борелевских функций сама является борелевской функцией.

Ещё один важный пример: случайные величины, являющиеся измеримыми функциями относительно некоторой σ-алгебры событий.

Кажется, что измеримость очень сложно проверять. На самом деле это не так, если воспользоваться следующим трюком.

ТЕОРЕМА 2.6.1
Критерий измеримости

Пусть $\sigma_Y = \sigma(\mathcal{G})$, то есть $\mathcal{G} \subset \sigma_Y$ — некоторый порождающий класс. Тогда отображение $f \colon (X, \sigma_X) \to (Y, \sigma_Y)$ измеримо тогда и только тогда, когда оно $\sigma_X|\mathcal{G}$-измеримо.

Доказательство. Необходимость тривиальна, так что докажем достаточность. На этом доказательстве мы продемонстрируем очень мощный принцип подходящих множеств. Рассмотрим систему $\mathcal{A} := \{A \in \sigma_Y : f^{-1}(A) \in \sigma_X\}$. Заметим, во-первых, что она является σ-алгеброй, а во-вторых, что $\mathcal{A} \supset \mathcal{G}$. Но тогда $\mathcal{A} \supset \sigma_Y$, откуда следует $\mathcal{A} = \sigma_Y$. □

Продемонстрируем действие этого критерия на следующем важном примере.

ЛЕММА 2.6.1

Любая непрерывная функция $\mathbb{R} \to \mathbb{R}$ является борелевской.

Доказательство. Следует по критерию измеримости из того, что открытые множества порождают борелевскую σ-алгебру и что прообраз любого открытого множества под действием непрерывной функции открыт. □

Арифметические операции над измеримыми функциями

Далее мы зафиксируем некое измеримое пространство (X, σ_X) и будем рассматривать измеримые функции $(X, \sigma_X) \to (\mathbb{R}, \mathcal{B}(\mathbb{R}))$. Для удобства будем обозначать

$$f^{-1}(B) = \{x \in X : f(x) \in B\} =: \{f \in B\}.$$

Это мы, конечно, переняли от случайных величин.

ЗАМЕЧАНИЕ

Иногда приходится иметь дело с функциями, которые могут принимать ещё бесконечные значения. В таком случае дополнительно требуется, чтобы прообраз бесконечности был измерим. Принципиально это ничего не меняет, поэтому мы не будем заострять на этом внимание. Формально всюду, где функция действует на прямую, мы предполагаем, что она действует в расширенную прямую вместе с бесконечными значениями.

Итак, мы построили измеримые функции, осталось научиться с ними работать. Было бы фиаско, если бы сумма (такая естественная операция) измеримых функций оказалась неизмеримой. К счастью, такого не бывает.

УТВЕРЖДЕНИЕ 2.6.1

Сумма, разность, произведение и частное измеримых функций — измеримы.

Доказательство. По критерию измеримости достаточно проверить, что прообразы всех левосторонних лучей измеримы.

Для начала заметим, что борелевская функция от измеримой — измерима. В частности, сдвиг и домножение на константу оставляют функцию измеримой. Рассмотрим две измеримые f, g. Для произвольного $c \in \mathbb{R}$

$$\{f + g < c\} = \bigcup_{r \in \mathbb{Q}} \{f < r\} \cap \{r < c - g\} \in \sigma_X,$$

поэтому сумма $f + g$ измерима. Разность измерима, так как $-g$ измерима. Наконец, $fg = \frac{(f+g)^2 - f^2 - g^2}{2}$ измерима. Функция $\frac{1}{g}$ измерима (здесь впервые может возникнуть бесконечное значение при делении на ноль, и нужно сказать, что прообраз нуля измерим), а поэтому и частное измеримо. □

Предельный переход для измеримых функций

Ещё одна операция, которую мы хотим уметь выполнять с функциями, — это переход к пределу.

УТВЕРЖДЕНИЕ 2.6.2

Измеримость наследуется при взятии супремума/инфимума по счётному набору функций, а также при переходе к верхнему, нижнему и просто пределу.

Доказательство. Рассмотрим измеримые функции f_1, f_2, …

Тогда для произвольного $c \in \mathbb{R}$

$$\left\{\sup_n f_n \leqslant c\right\} = \bigcap_{n=1}^{\infty} \{f_n \leqslant c\} \in \sigma_X,$$

откуда следует измеримость супремума. Измеримость инфимума доказывается аналогично. Измеримость верхнего предела следует из того, что

$$\overline{\lim_{n\to\infty}} f_n = \inf_{n\geqslant 1} \sup_{m\geqslant n} f_m.$$

С нижним пределом аналогично. Наконец, просто предел, когда существует, совпадает с верхним и с нижним. □

В этом доказательстве стоит обратить внимание, что, например, при взятии супремума могла возникнуть бесконечность, даже если сами функции принимали только конечное значение. Формально это ничему не противоречит, супремум остаётся измеримой функцией. Но если хочется совсем избавиться от работы с бесконечностями, можно сузиться на множество, на котором функции ограничены сверху некоторой общей константой, и работать на этом множестве. На нём супремум получится функцией, принимающей только конечные значения.

7. СВОЙСТВА ИЗМЕРИМЫХ ФУНКЦИЙ

Порождённая σ-алгебра

Неформально, если события приходят из богатой σ-алгебры, значит, мы получаем через них большое количество информации. Если события приходят из бедной σ-алгебры, это означает, что они приносят мало информации.

Пример 2.7.1. Пусть $\mathcal{F} = \{\varnothing, \Omega\}$. Тогда, если мы знаем, что произошло событие $A \in \mathcal{F}$, это не даёт нам вообще никакой информации. Мы и так знали, что уж какой-то исход из Ω должен произойти.

Аналогично можно рассуждать о том, какую информацию мы получаем, узнавая значения некоторой измеримой функции. Это подводит нас к следующему определению.

ОПРЕДЕЛЕНИЕ 2.7.1

Для измеримой функции $f\colon (X, \sigma_X) \to (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ через $\sigma(f) \subset \sigma_X$ обозначается ***σ*-алгебра прообразов** борелевских множеств под действием функции f.

Пример 2.7.2. Нетрудно убедиться, что для константы выполнено $\sigma(c) = \{\varnothing, X\}$. То есть, узнавая значение константы, мы не получим никакой информации. В этом нет ничего удивительного: мы и так знали значение константы.

Пример 2.7.3. Рассмотрим две измеримые функции:

$$\sin, \cos\colon ([0, \pi], \mathcal{B}[0, \pi]) \to (\mathbb{R}, \mathcal{B}(\mathbb{R})).$$

Тогда $\sigma(\cos) = \mathcal{B}[0,\, \pi]$, так как $\cos$ оказывается инъекцией. Иными словами, зная значение косинуса, мы однозначно восстанавливаем значение аргумента. А вот $\sigma(\sin)$ состоит из борелевских множеств, симметричных относительно $\frac{\pi}{2}$. Это наглядно показывает, что, зная значение синуса, мы можем восстановить значение аргумента только с точностью до знака.

ОПРЕДЕЛЕНИЕ 2.7.2

Измеримая функция называется **простой**, если она принимает конечное число значений. Введя обозначение индикатора $\mathcal{I}_A = \mathcal{I}(A)\colon X \to \mathbb{R}$ для $A \in \sigma_X$, определённого как

$$\mathcal{I}_A(x) = \mathcal{I}(A)(x) := \begin{cases} 1, & \text{если } x \in A, \\ 0, & \text{если иначе,} \end{cases}$$

можно любую простую функцию φ представить в виде линейной комбинации

$$\varphi = \sum_{y \in \operatorname{Im}\varphi} y\mathcal{I}\{\varphi = y\}.$$

Здесь и далее мы упростили запись $(\{x : \varphi(x) = y\}) = (\{\varphi = y\}) = \{\varphi = y\}$. Через $\operatorname{Im}\varphi$ обозначают множество значений функции φ, которое в нашем случае конечно.

Следующая теорема говорит, что, оказывается, любую измеримую функцию можно приблизить простыми функциями, не дающими никакой информации помимо той, которую уже даёт исходная функция.

ОПРЕДЕЛЕНИЕ 2.7.3

Формально мы будем говорить, что g является $\boldsymbol{f}$**-измеримой**, если $\sigma(g) \subset \sigma(f)$.

ТЕОРЕМА 2.7.1

Для любой измеримой функции f существует последовательность простых $\sigma(f)$-измеримых функций, сходящаяся к f поточечно.

Доказательство. Рассмотрев отдельно функции $f^+ := \max(f,\, 0)$ и $f^- := -\min(0,\, f)$, достаточно доказать утверждение для неотрицательной f. Тогда построим

$$\varphi_n := \sum_{k=1}^{n2^n} \frac{k}{2^n} \mathcal{I}\left\{\frac{k}{2^n} \leqslant f < \frac{k+1}{2^n}\right\}.$$

Легко проверяется, что $\varphi_n(x) \xrightarrow[n\to\infty]{} f(x)$ при каждом $x \in X$.

Свойство

$$\sigma(\varphi_n) \subset \sigma(f)$$

следует из построения. □

Напоследок приведём ещё одну теорему, утверждающую, что одна функция измерима относительно другой, если может быть получена из той некоторым борелевским преобразованием.

ТЕОРЕМА 2.7.2

Пусть имеется измеримая функция $f\colon X \to \mathbb{R}$ и борелевская функция $h\colon \mathbb{R} \to \mathbb{R}$. Тогда функция $g = h \circ f$ является f-измеримой.

Доказательство. Это следует из того, что $g^{-1}(B) = f^{-1}(h^{-1}(B)) \in \sigma(f)$ для любого борелевского B. □

ЗАМЕЧАНИЕ

Стоит отметить, что в обратную сторону теорема тоже верна. То есть если функция g является f-измеримой, то она может быть получена из функции f некоторым борелевским преобразованием. Но этот факт доказывается уже гораздо сложнее, и самое элегантное его доказательство требует использования условного математического ожидания, которое выходит за рамки данного курса.

Контрпримеры

ОПРЕДЕЛЕНИЕ 2.7.4

Лестница Кантора $c(x)$ отображает $[0,\,1]$ в $[0,\,1]$. Для её задания вспомним, как мы итерационно строили множество Кантора: на n-м шаге мы выкидывали из отрезков, составляющих множество C_{n-1}, все «серединные» интервалы (центр интервала совпадал с центром отрезка, длина интервала составляла треть длины отрезка) и получали C_n. Предел таких C_n (то есть их пересечение) и называли множеством Кантора.

Составим множество D как объединение границ всех выкидываемых интервалов вместе с точками 0 и 1. На данном множестве зададим функцию $\tilde{c}(x)$ итерационно: $\tilde{c}(0) = 0$, $\tilde{c}(1) = 1$; при выкидывании очередного интервала зададим $\tilde{c}(x)$ в его границах как среднее арифметическое значений $\tilde{c}(x)$ в концах отрезка, из которого выкидывается интервал

$$\tilde{c}(1/3) = \tilde{c}(2/3) = \frac{\tilde{c}(0) + \tilde{c}(1)}{2} = 1/2,$$

$$\tilde{c}(1/9) = \tilde{c}(2/9) = \frac{\tilde{c}(0) + \tilde{c}(1/3)}{2} = 1/4\ldots.$$

Заметим, что $\tilde{c}(x)$ не убывает на D и принимает все значения вида $\frac{k}{2^n}, \quad n \in \mathbb{N}, 0 \leqslant k \leqslant 2^n$, что доказывается простой индукцией.

Наконец, определим функцию $c(x)$ на $[0,\,1]$ как $c(x) := \sup\limits_{y \leqslant x,\ y \in D} \tilde{c}(y)$.

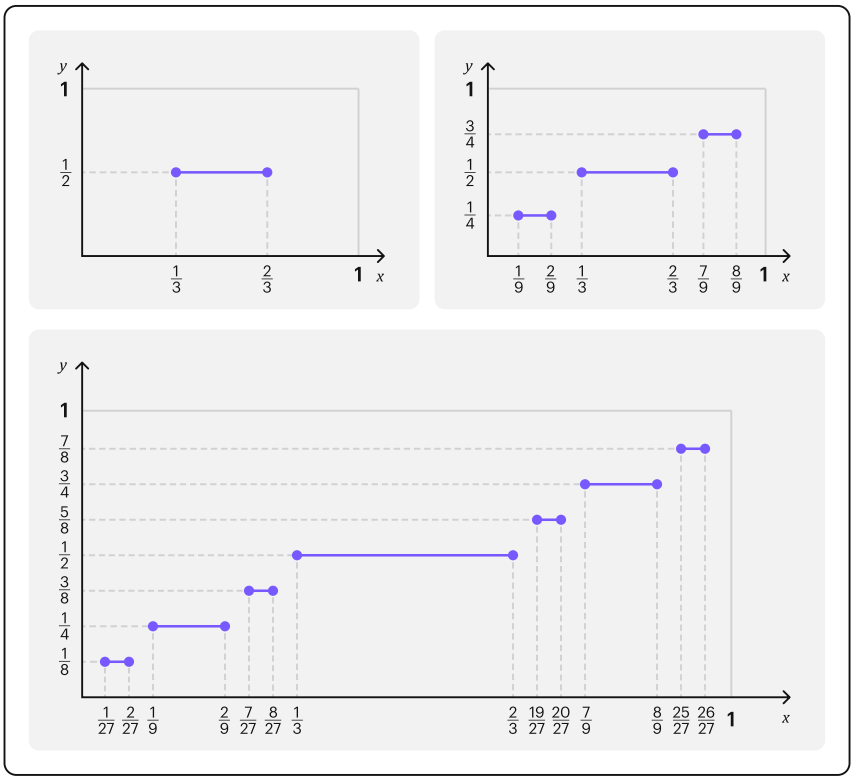

Рисунок 8. Первые три итерации построения лестницы Кантора

ТЕОРЕМА 2.7.3

Лестница Кантора непрерывна и нестрого возрастает. В частности, она является борелевской функцией.

Доказательство.

Монотонность лестницы Кантора сразу следует из её определения.

Заметим, что $\tilde{c}(x)$ не убывает на D, а значит, на D верно $\tilde{c}(x) = c(x)$. Допустим, она не непрерывна, тогда она имеет неустранимые разрывы первого рода. В этих разрывах обязательно найдётся точка вида $\frac{k}{2^n}$. Остаётся заметить, что лестница Кантора принимает все значения такого вида, что приводит к противоречию. □

ТЕОРЕМА 2.7.4

Используя лестницу Кантора, докажем следующий факт.

1. Классическая мера Бореля, в отличие от меры Лебега, не полна.
2. Существует измеримая функция, не являющаяся борелевской.
3. Измеримая функция от борелевской не всегда измерима.

Доказательство. Рассмотрим функцию $h := \frac{c+\mathrm{id}}{2} : [0,\, 1] \to [0,\, 1]$. По доказанному выше, она непрерывна, строго монотонна, а потому биективна, и тогда её обратная h^{-1} тоже непрерывна. То есть h является *гомеоморфизмом* отрезка $[0,\, 1]$ на себя. Заметим, что $\lambda(h(C)) = \frac{1}{2}$. В самом деле, мера образа всех выкинутых интервалов равна половине их длины, а потому мера дополнения образа канторова множества равна $\frac{1}{2}$ (помним, что мера всех интервалов дала единицу). То есть существует неизмеримое по Лебегу подмножество $V \subset h(C)$ и, как следствие, неборе-

левское. Тогда его прообраз $h^{-1}(V) \subset C$ тоже неборелевское множество, но измеримое, в силу полноты меры Лебега. Этим мы доказали (i).

В качестве измеримой неборелевской функции достаточно взять индикатор
$\mathcal{I}\big(h^{-1}(V)\big)$. Это доказывает (ii).

Наконец, для доказательства утверждения (iii) нужно рассмотреть композицию $\mathcal{I}\big(h^{-1}(V)\big) \circ h^{-1}$. Она не является измеримой, поскольку прообраз единицы

$$\Big\{\mathcal{I}\big(h^{-1}(V)\big) \circ h^{-1} = 1\Big\} = \big\{h^{-1} \in h^{-1}(V)\big\} = V$$

неизмерим. □

8. СХОДИМОСТИ ИЗМЕРИМЫХ ФУНКЦИЙ

Сходимости почти всюду и по мере

Отныне и впредь будем работать с σ-аддитивными мерами на σ-алгебрах.

Теперь мы считаем, что у нас задано измеримое пространство с мерой, а именно зафиксирована тройка $(X,\, \sigma_X,\, \mu)$, где σ-алгебра σ_X состоит из множеств, измеримых относительно меры μ. Мы работаем только с измеримыми функциями, чтобы не возникало парадоксов с неизмеримостью.

Пример 2.8.1. Рассмотрим функции $f_n\colon [0,\, 1] \to [0,\, 1]$, заданные как $f_n(x) = x^n$. С точки зрения матанализа они поточечно сходятся к индикатор-функции точки 1. Но если проигнорировать это значение, хочется сказать, что они почти сходятся к тождественно нулевой функции. Иными словами, сходятся к нулю почти всюду (то есть за исключением пренебрежимо малого множества аргументов). Оказывается, слова «почти всюду» являются математическим термином.

ОПРЕДЕЛЕНИЕ 2.8.1

Последовательность измеримых функций $f_n\colon X \to \mathbb{R}$ **сходится почти всюду** к измеримой функции f, если $\mu\{f_n \not\to f\} = 0$. Обозначение: $f_n \xrightarrow[n\to\infty]{\text{п. в.}} f$.

В теории вероятностей такую сходимость называют «почти наверное» вместо «почти всюду».

ОПРЕДЕЛЕНИЕ 2.8.2

Вообще, свойство выполнено почти всюду, если множество, где свойство не выполняется, имеет нулевую меру.

Пример 2.8.2. Как мы увидим позже, иногда даже сходимость почти всюду оказывается слишком сильной. Например, в законе больших чисел из теории вероятностей утверждается, что средние значения результатов эксперимента отклоняются от математического ожидания на некоторую абсолютную ошибку с вероятностью, стремящейся к нулю. Закон не говорит ничего непосред-

ственно про сходимость почти всюду на элементарных исходах. Просто вероятности плохих событий стремятся к нулю.

ОПРЕДЕЛЕНИЕ 2.8.3

Последовательность функций f_n **сходится по мере** к функции f, если для любого $\varepsilon > 0$ *«меры плохих множеств сходятся к нулю»*, то есть

$$\mu\{|f_n - f| > \varepsilon\} \xrightarrow[n\to\infty]{} 0.$$

Обозначение: $f_n \xrightarrow[n\to\infty]{\mu} f$.

Как мы знаем из курса матанализа, поточечный предел функций единственен. Можно ли то же самое сказать для наших видов сходимости? И да и нет.
Пределы почти всюду и по мере единственны с точностью до равенства почти всюду.

ТЕОРЕМА 2.8.1

О единственности пределов

Доказательство. Для сходимости почти всюду теорема очевидна. Для сходимости по мере она следует из неравенства треугольника: для двух пределов f, g

$$\{|f - g| > 2\varepsilon\} \subset \{|f_n - f| > \varepsilon\} \cup \{|f_n - g| > \varepsilon\},$$

где мера правого множества сколь угодно мала, а мера левого множества постоянна. □

Связь между сходимостями

Кажется, что устанавливать сходимость почти всюду проще, чем сходимость по мере. На самом деле наоборот: обычно оценить вероятность плохих множеств проще, чем доказывать, что сходимость выполняется всюду, кроме множества нулевой меры. Поэтому следующий критерий довольно полезен.

ТЕОРЕМА 2.8.2

Критерий сходимости почти всюду

Сходимость $f_n \xrightarrow[n\to\infty]{\text{п. в.}} f$ равносильна сходимости $\sup\limits_{n\geqslant N} |f_n - f| \xrightarrow[N\to\infty]{\mu} 0$, что эквивалентно

$$\mu\left(\bigcup_{n\geqslant N}\{|f_n - f| > \varepsilon\}\right) \xrightarrow[N\to\infty]{} 0$$

для любого $\varepsilon > 0$.

Доказательство. Доказательство очень простое. Рассмотрим множество, где нет сходимости:

$$\{f_n \not\to f\} = \{\exists\,\varepsilon\ \forall\, N\ \exists\, n \geqslant N : |f_n - f| \geqslant \varepsilon\} = \\ = \bigcup_{\varepsilon\to 0}\bigcap_{N=1}^{\infty}\bigcup_{n\geqslant N}\{|f_n - f| \geqslant \varepsilon\}.$$

Сходимость почти всюду равносильна тому, что мера данного множества нулевая. В силу непрерывности снизу меры это равно-

сильно тому, что для любого $\varepsilon > 0$ мера множества

$$\bigcap_{N=1}^{\infty} \bigcup_{n \geqslant N} \{|f_n - f| \geqslant \varepsilon\}$$

нулевая. В силу непрерывности сверху — последнее равносильно сходимости в критерии. □

Из критерия сразу вытекает такое следствие.

Из сходимости почти всюду следует сходимость по мере.

ТЕОРЕМА 2.8.3

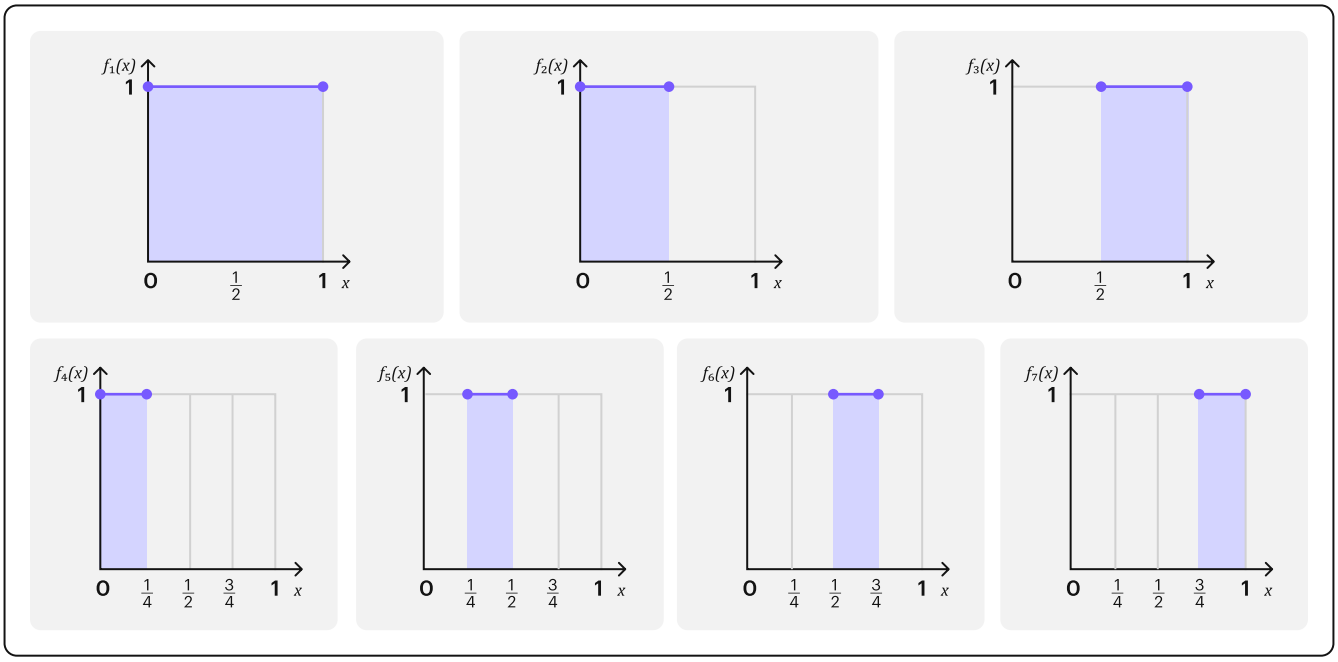

Рисунок 9. Функции $f_1, \ldots, f_7$ из контрпримера Рисса

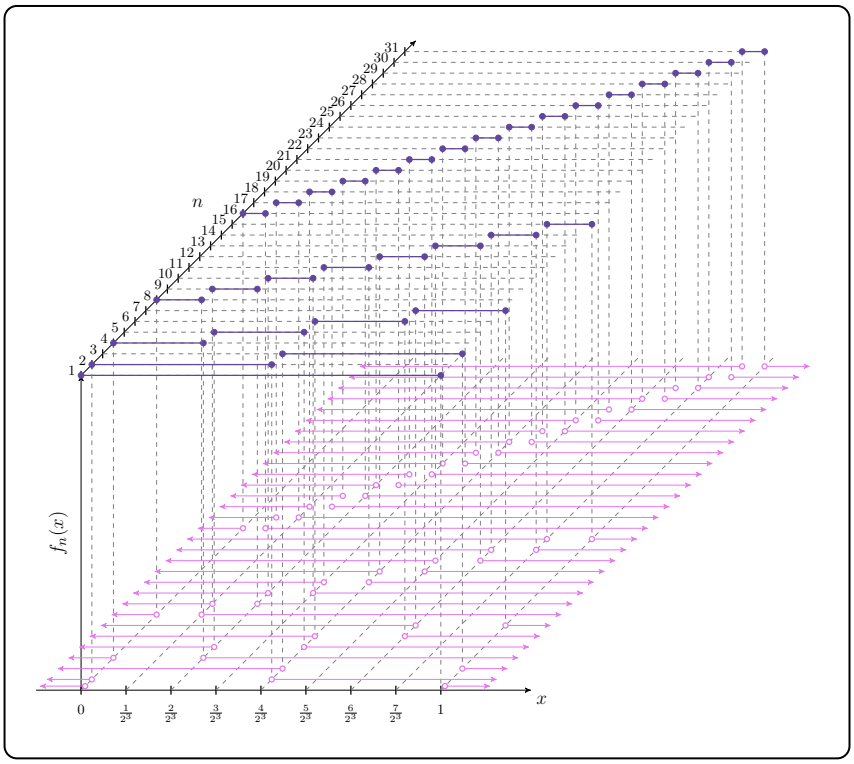

Рисунок 10. Функции $f_1, \ldots, f_{31}$ из контрпримера Рисса

Контрпример Рисса

Пример 2.8.3. Следующий пример показывает, что из сходимости по мере не всегда следует сходимость почти всюду. В английской литературе его называют **typewriter sequence**.

На отрезке $[0,\ 1]$ с классической мерой Лебега рассмотрим последовательность подотрезков

$$\left[0,\ 1\right],\ \left[0,\ \frac{1}{2}\right],\ \left[\frac{1}{2},\ 1\right],\ \left[0,\ \frac{1}{4}\right],\ \left[\frac{1}{4},\ \frac{2}{4}\right],\ \left[\frac{2}{4},\ \frac{3}{4}\right],\ \left[\frac{3}{4},\ 1\right],\ \left[0,\ \frac{1}{8}\right],\ \left[\frac{1}{8},\ \frac{2}{8}\right],\ \ldots$$

В качестве функции f_n возьмём индикатор n-го подотрезка (см. рисунки 9, 10 для примера графиков первых нескольких функций). Тогда $f_n \xrightarrow[n\to\infty]{\mu} 0$, так как длины подотрезков стремятся к нулю. Но при этом в каждой точке $x \in [0,\ 1]$ среди значений $f_n(x)$ бесконечно часто появляются как нули, так и единицы, что означает отсутствие сходимости в любой точке отрезка. Таким образом, f_n сходятся к нулю по классической мере Лебега, но не почти всюду.

Оказывается, ещё не всё пропало и следующая теорема немного исправляет ситуацию.

ТЕОРЕМА 2.8.4

Теорема Рисса

Из последовательности, сходящейся по мере, можно выделить подпоследовательность, сходящуюся почти всюду (к той же функции).

Доказательство. Доказательство существенно использует критерий сходимости почти всюду. Идея в том, что в подпоследова-

тельность нужно взять функции, для которых плохие множества не просто маленькие (как в сходимости по мере), а ну о-о-очень маленькие.

Итак, пусть f_n сходятся к f по мере. Для любого k найдём такой номер n_k, что

$$\mu\left\{|f_{n_k} - f| > \frac{1}{k}\right\} < \frac{1}{2^k}.$$

Остаётся применить критерий сходимости почти всюду к последовательности f_{n_k}.

Действительно, для любого $\varepsilon > 0$ при достаточно больших $N > \frac{1}{\varepsilon}$ имеем

$$\mu\left(\bigcup_{k\geqslant N}\{|f_{n_k} - f| > \varepsilon\}\right) \leqslant \mu\left(\bigcup_{k\geqslant N}\left\{|f_{n_k} - f| > \frac{1}{k}\right\}\right) \leqslant$$
$$\leqslant \sum_{k=N}^{\infty}\frac{1}{2^k} = \frac{1}{2^{N-1}} \xrightarrow[N\to\infty]{} 0,$$

что заканчивает доказательство. □

Почти равномерная сходимость

В теории меры выделяют ещё один довольно удобный тип сходимости.

ОПРЕДЕЛЕНИЕ 2.8.4

Последовательность функций f_n **сходится почти равномерно** к функции f, если для любого $\gamma > 0$ найдётся такое «плохое, но маленькое» измеримое множество E_γ меры $\mu(E_\gamma) < \gamma$, что вне E_γ функции сходятся равномерно, то есть

$$\sup_{x\in X\setminus E_\gamma}|f_n(x) - f(x)| \xrightarrow[n\to\infty]{} 0.$$

Из определения понятно, что это ослабленная версия равномерной сходимости. В качестве несложного упражнения можно доказать, что из почти равномерной сходимости следуют обе сходимости: и почти всюду, и почти наверное.

Из сходимости почти всюду следует и почти равномерная сходимость.

ТЕОРЕМА 2.8.5

Теорема Егорова

Доказательство. Зафиксируем произвольное $\gamma > 0$. Из критерия сходимости почти всюду возьмём такую последовательность N_m, что

$$\mu\left\{\sup_{n\geqslant N_m}|f_n - f| > \frac{1}{m}\right\} < \frac{\gamma}{2^m}.$$

Обозначим множества под мерой через E_m и положим $E_\gamma := \bigcup_{m=1}^{\infty} E_m$. По счётной субаддитивности меры $\mu(E_\gamma) < \gamma$. На дополнении $X \setminus E_\gamma$ для любого $\varepsilon > 0$ начиная с некоторого m для всех $n > N_m$ выполнено $|f_n(x) - f(x)| < \varepsilon$ равномерно по всем x. □

Таким образом, в нашем случае сходимости почти всюду и почти равномерная равносильны. В силу того, что сходимость почти всюду выглядит гораздо более естественной, обычно работают именно с ней. Как мы увидим позже, в работе с интегралом Лебега зачастую бывает удобно воспользоваться теоремой Егорова и перейти к почти равномерной сходимости.

9. ИНТЕГРАЛ ЛЕБЕГА И ЕГО СВОЙСТВА

Арифметические операции

Из математического анализа известно, что сумма равномерно сходящихся последовательностей функций сходится равномерно к сумме пределов. Кроме того, известно, что навешивание непрерывной функции сохраняет поточечную сходимость, но может не сохранять равномерную. В связи с этим возникает естественный вопрос, какие действия можно совершать над последовательностями измеримых функций, чтобы наследовались сходимости по мере или почти всюду.

Напомним, что у нас зафиксировано некоторое измеримое пространство (мера всего пространства конечна), и мы рассматриваем только измеримые функции.

Для того, чтобы понять происходящее, докажем сперва лёгкое упражнение.

Сходимости почти всюду и по мере наследуются при домножении на некоторую действительную константу.

УТВЕРЖДЕНИЕ 2.9.1

Доказательство. Для сходимости почти всюду это понятно: множество аргументов, на котором была сходимость, не уменьшится и останется той же меры. Для сходимости по мере это следует из того, что для любого $\varepsilon > 0$ и любой $c \neq 0$ имеем

$$\mu\{|cf_n - cf| > \varepsilon\} = \mu\{|f_n - f| > \varepsilon/|c|\} \xrightarrow[n\to\infty]{} 0.$$

Случай $c = 0$ тривиален. □

Теперь перейдём к чему-то более интересному.

Сходимости почти всюду и по мере наследуются при сложении.

ТЕОРЕМА 2.9.1

Доказательство. Для сходимости почти всюду это следует из того, что для последовательностей предел суммы равен сумме пределов. Для сходимости по мере рассмотрим $f_n \xrightarrow[n\to\infty]{\mu} f$ и $g_n \xrightarrow[n\to\infty]{\mu} g$.

Тогда для любого $\varepsilon > 0$ в силу неравенства треугольника имеем

$$\{|f_n + g_n - f - g| > \varepsilon\} \subset \{|f_n - f| > \varepsilon/2\} \cup \{|g_n - g| > \varepsilon/2\},$$

откуда следует наследование сходимости. □

В итоге, мы получили, что сходимость наследуется при взятии различных линейных комбинаций.

Непрерывные функции

Следующий естественный вопрос: наследуется ли сходимость при композиции с непрерывной функцией? Оказывается, да, причём в следующем смысле.

ТЕОРЕМА 2.9.2
О наследовании сходимости

Пусть функции f_n сходятся к f почти всюду или по мере. Пусть борелевская функция $g\colon \mathbb{R} \to \mathbb{R}$ непрерывна «$\mu \circ f^{-1}$-п.в.», т.е. непрерывна на таком борелевском множестве $B \subset \mathbb{R}$, что $\mu\{f \notin B\} = 0$. Тогда для функций $g \circ f_n$ наследуется сходимость к $g \circ f$.

В английской литературе эта теорема называется continuous mapping theorem; то есть даже в названии содержится слово «непрерывность». Стоит обратить внимание, что по факту функция может не быть непрерывной. Например, если предельная функция f является константой, то есть $f = c$, то функция g должна должна быть непрерывна только в точке c.

Стоит так же отметить, что эта теорема покрывает утверждение 2.9.1 про наследование сходимости при домножении на константу, поскольку умножение на константу является непрерывной функцией.

Доказательство наследования сходимости почти всюду Доказательство. Множество

$$\{g \circ f_n \to g \circ f\} \supset \{f_n \to f\} \cap \{f \in B\}$$

измеримо, а тогда множество

$$\{g \circ f_n \not\to g \circ f\} \subset \{f_n \not\to f\} \cup \{f \notin B\}$$

имеет меру ноль. □

ЛЕММА 2.9.1
Критерий сходимости по мере

Сходимость функций $f_n \xrightarrow[n\to\infty]{\mu} f$ равносильна тому, что у любой последовательности номеров n_m можно выделить такую подпоследовательность номеров n_{m_k}, что $f_{n_{m_k}} \xrightarrow[k\to\infty]{\text{п.в.}} f$.

Доказательство. Необходимость следует из теоремы Рисса. Достаточность докажем от противного. Отсутствие сходимости по мере означает, что для некоторых $\varepsilon, \varepsilon' > 0$ нашлась последовательность номеров n_m, для которых

$$\mu\{|f_{n_m} - f| > \varepsilon\} > \varepsilon'.$$

При этом по условию можно выделить подпоследовательность $f_{n_{m_k}}$, сходящуюся к f почти всюду. Раз мера конечна, то эта же подпоследовательность сходится к f по мере, что приводит к противоречию. □

Доказательство наследования сходимости по мере Доказательство. По критерию сходимости по мере, достаточно для про-

извольной последовательности номеров n_m так выделить подпоследовательность, чтобы $g \circ f_{n_{m_k}}$ сходились к $g \circ f$ почти всюду. Поскольку f_{n_m} сходятся к f по мере, то теорема Рисса даст нужную подпоследовательность, и теорема о наследовании сходимости почти всюду завершит доказательство. □

ЗАМЕЧАНИЕ

Наследование сходимости эффективно применяется в математической статистике, когда речь заходит про построение оценок некоей величины. Например, проведены эксперименты с результатами $X_1, \ldots, X_n$. Известно, что у них у всех одинаковое среднее a, но нужно оценить параметр a^2. Здравый смысл подсказывает, что раз по Закону Больших Чисел усреднение $\overline{X} := \frac{X_1+\ldots+X_n}{n}$ хорошо оценивает (читай: сходится по вероятности к) среднее a, то

$$\left(\overline{X}\right)^2$$

должно хорошо оценивать a^2. Теорема о наследовании сходимости гарантирует, что это действительно так.

Теперь отсюда можно получить и наследование предела при оставшихся арифметических операциях.

ТЕОРЕМА 2.9.3

Пусть f_n сходятся почти всюду или по мере к f, а g_n сходятся в том же смысле к g. Тогда $f_n g_n$ сходятся в том же смысле к fg.

Доказательство. Теперь это легко получается из предыдущих результатов. Под сходимостью ниже понимается сходимость в том же смысле, что в условии. Имеем

$$f_n + g_n \xrightarrow[n\to\infty]{} f + g.$$

Тогда по теореме о наследовании сходимости,

$$f_n^2 \xrightarrow[n\to\infty]{} f^2,$$
$$g_n^2 \xrightarrow[n\to\infty]{} g^2,$$
$$(f_n + g_n)^2 \xrightarrow[n\to\infty]{} (f + g)^2.$$

Вычитая из последней строки две первые и деля пополам, получаем требуемое. □

ТЕОРЕМА 2.9.4

Пусть f_n сходятся почти всюду или по мере к f, а g_n сходятся в том же смысле к g, и $g \neq 0$ почти всюду. Тогда f_n/g_n сходятся в том же смысле к f/g.

ЗАМЕЧАНИЕ

Заметим, что функции f_n/g_n и f/g определены не всюду. Как же мы можем тогда говорить об их сходимости? В этом случае мы всегда доопределяем функцию на множестве меры ноль, если на нем возникают какие-то проблемы. Доопределять можно чем угодно, поскольку это не повлияет на сходимость, но обычно доопределяют нулем.

Доказательство. Поскольку $g \neq 0$ почти всюду и функция $h(x) = 1/x$ непрерывна на борелевском $B = (-\infty; 0) \cup (0; +\infty)$, то $1/g_n$ сходятся почти всюду или по мере к $1/g$ и к ним можно применить предыдущую теорему. □

Таким образом, мы показали, что сходимости наследуются при всех арифметических операциях.

Интеграл Лебега от простых функций

Кажется, зачем нужен какой-то интеграл Лебега, когда есть интеграл Римана? На самом деле, интеграл Лебега нужен затем, чтобы уметь интегрировать функции, определённые на абстрактном множестве Ω, а не только на прямой или пространстве. Но даже на прямой интеграл Римана не помогает, если хочется интегрировать измеримые функции вообще. Например, функция $\mathcal{I}(\mathbb{Q} \cap [0,\, 1])$ измерима и почти всюду равна нулю, но проинтегрировать по Риману её нельзя. Как мы увидим позже, по Лебегу она интегрируется довольно легко.

Итак, мы снова фиксируем произвольное измеримое пространство $(X,\, \sigma_X,\, \mu)$ с σ-аддитивной мерой μ и рассматриваем измеримые функции $(X,\, \sigma_X) \to (\mathbb{R},\, \mathcal{B}(\mathbb{R}))$. Им разрешено принимать бесконечные значения, но лишь на множестве нулевой меры; мы не заостряем на этом внимание.

Сперва определим интеграл Лебега от простых функций (потому что так проще). Напомним, что измеримая функция называется простой, если она принимает конечное число значений.

ОПРЕДЕЛЕНИЕ 2.9.1

Интеграл Лебега от простой функции φ определяется как

$$\int \varphi(x)\, d\mu(x) \equiv \int \varphi\, d\mu \equiv \int \varphi := \sum_{y \in \operatorname{Im}\varphi} y\, \mu\{\varphi = y\},$$

где считается, что $0 \cdot \infty = \infty \cdot 0 = 0$. Определение должно навевать приятные ассоциации с математическим ожиданием. Чаще всего мы будем пользоваться последним обозначением, поскольку обычно понятно, по какой мере берётся интеграл.

ЗАМЕЧАНИЕ

Как правило, интеграл Лебега определяют иначе: для представления

$$\varphi = \sum_{n=1}^{N} c_n \mathcal{I}(A_n)$$

пишут

$$\int \varphi = \sum_{n=1}^{N} c_n\, \mu(A_n).$$

Если все A_n дизъюнктны, это равенство следует по определению в силу аддитивности меры. Для произвольного представления мы получим это как следствие линейности интеграла.

ОПРЕДЕЛЕНИЕ 2.9.2

Интеграл Лебега от простой функции φ по множеству $E \in \sigma_X$

определяется как

$$\int_E \varphi := \int \varphi \mathcal{I}_E.$$

Например, для $\varphi = 1$ имеем

$$\int_E 1 = \int \mathcal{I}_E = \mu(E).$$

Проверим несколько довольно очевидных свойств интеграла Лебега.
Здесь мы рассматриваем только простые функции.

УТВЕРЖДЕНИЕ 2.9.2

1. Интеграл Лебега линеен по функции.
2. Интеграл Лебега аддитивен по множеству.
3. Интеграл Лебега монотонен по (интегрируемой) функции.
4. Любая функция φ интегрируема только вместе со своим модулем, и
$$\left|\int \varphi\right| \leqslant \int |\varphi|.$$
5. Для любых интегрируемых φ, ψ
$$\int |\varphi + \psi| \leqslant \int |\varphi| + \int |\psi|.$$

Доказательство. Для доказательства линейности сперва докажем, что можно выносить константу: для $\alpha = 0$ это очевидно, а при $\alpha \neq 0$

$$\int \alpha\varphi = \sum_{y \in \operatorname{Im}\varphi} \alpha y\, \mu\{\alpha\varphi = \alpha y\} = \alpha \int \varphi.$$

Аддитивность по функции

$$\int (\varphi + \psi) = \sum_{y,\, z} (y + z)\, \mu\{\varphi = y,\ \psi = z\} = \int \varphi + \int \psi$$

теперь следует из независимости интеграла от представления простой функции в виде индикаторов попарно дизъюнктных множеств.

Аддитивность по множеству следует из аддитивности по функциям.

Монотонность следует из того, что интеграл от неотрицательной функции неотрицателен.

Функция интегрируема вместе с модулем, поскольку $\{\varphi \neq 0\} = \{|\varphi| \neq 0\}$. Неравенство в (iv) следует из монотонности, и $-|\varphi| \leqslant \varphi \leqslant |\varphi|$.

Последнее следует по монотонности и аддитивности из $|f + g| \leqslant |f| + |g|$. □

Напоследок обсудим ещё одно крайне важное свойство интегра-

ла Лебега.

ТЕОРЕМА 2.9.5

Интеграл Лебега от любой простой функции φ **абсолютно непрерывен**: это означает, что для любого $\varepsilon > 0$ найдётся такое $\delta > 0$, что для любого множества E меры меньше δ выполнено

$$\int_E |\varphi| < \varepsilon.$$

Доказательство. Обозначим через M максимальное значение, которое достигает функция $|\varphi|$ (исключая множество нулевой меры с бесконечными значениями). Теперь достаточно взять $\delta < \frac{\varepsilon}{M}$ и убедиться, что

$$\int_E |\varphi| < M\mu(E) < M\delta < \varepsilon.$$

□

Последовательности простых функций

Мы хотим определить интеграл Лебега от произвольной измеримой функции как предел интегралов простых функций, сходящихся к данной измеримой. К сожалению, бесплатно это сделать не получится: функции $\mathcal{I}[0,\ \frac{1}{n}]$, $n\mathcal{I}[0,\ \frac{1}{n}]$ и $n^2\mathcal{I}[0,\ \frac{1}{n}]$ все сходятся к нулю почти всюду, но при этом у первой последовательности интегралы сходятся к нулю, у второй — интегралы равны 1, а у третьей — интегралы уходят на бесконечность.

Значит, одной лишь сходимостью почти всюду ограничиваться нельзя, нужно накладывать дополнительные условия.

ОПРЕДЕЛЕНИЕ 2.9.3

Функция расстояния $\rho(\varphi,\ \psi)$ определяется для простых интегрируемых функций как

$$\rho(\varphi,\ \psi) := \int |\varphi - \psi|.$$

Нетрудно убедиться в том, что функция расстояния симметрична и удовлетворяет неравенству треугольника. Кроме того, $\rho(\varphi,\ \psi) = 0$ равносильно равенству функций почти всюду.

ОПРЕДЕЛЕНИЕ 2.9.4

Простые функции φ_n **сходятся в среднем** к простой функции φ, если

$$\rho(\varphi_n,\ \varphi) \xrightarrow[n\to\infty]{} 0.$$

Простые функции φ_n **фундаментальны в среднем**, если

$$\rho(\varphi_n,\ \varphi_m) \xrightarrow[n,\ m\to\infty]{} 0.$$

Чем так хороши фундаментальные в среднем функции? К примеру, они ломают контрпример выше: функции $\mathcal{I}[0,\ \frac{1}{n}]$ фундаментальны в среднем, в то время как ни $n\mathcal{I}[0,\ \frac{1}{n}]$, ни $n^2\mathcal{I}[0,\ \frac{1}{n}]$ не фундаментальные в среднем. Посмотрим, чем же ещё они хороши.

ЛЕММА 2.9.2

Для фундаментальных в среднем простых функций φ_n существует предел

$$\lim_{n\to\infty}\int\varphi_n<\infty.$$

Доказательство. Числовая последовательность $\int\varphi_n$ фундаментальна, поскольку

$$\left|\int\varphi_n-\int\varphi_k\right|\leqslant\rho(\varphi_n,\,\varphi_k)\xrightarrow[n,\,k\to\infty]{}0.$$

Теперь лемма следует из критерия Коши сходимости числовых последовательностей. □

ЛЕММА 2.9.3

Фундаментальные в среднем простые функции φ_n **равностепенно абсолютно непрерывны**: это означает, что для любого $\varepsilon>0$ найдётся такое $\delta>0$, что для любого множества E меры меньше δ и любого n выполнено

$$\int_E|\varphi_n|<\varepsilon.$$

Доказательство. В силу фундаментальности в среднем, начиная с некоторого N для всех $n,\ k\geqslant N$ выполнено

$$\int|\varphi_n-\varphi_k|<\frac{\varepsilon}{2}.$$

Обозначим через M максимальное значение, достигаемое функциями $|\varphi_1|,\,\ldots,\,|\varphi_N|$. Возьмём $\delta<\frac{\varepsilon}{2M}$ и рассмотрим произвольное E меры меньше δ. Теперь для любого $n\leqslant N$ имеем

$$\int_E|\varphi_n|<M\mu(E)<\varepsilon,$$

а для остальных $n>N$ по неравенству треугольника

$$\int_E|\varphi_n|\leqslant\int_E|\varphi_n-\varphi_N|+\int_E|\varphi_N|\leqslant\frac{\varepsilon}{2}+M\mu(E)<\varepsilon.$$

□

Общее определение интеграла Лебега

Наконец, мы можем дать определение интеграла Лебега для произвольной измеримой функции f.

ОПРЕДЕЛЕНИЕ 2.9.5

Измеримая функция f называется **интегрируемой по Лебегу**, если существует фундаментальная в среднем последовательность простых функций, сходящаяся к f почти всюду. В таком случае **интегралом Лебега от функции f** называют предел

$$\int f:=\lim_{n\to\infty}\int\varphi_n<\infty,$$

существующий в силу леммы 2.9.2.

Нужно доказать корректность определения.
Определение интеграла Лебега не зависит от выбора последовательности простых функций.

УТВЕРЖДЕНИЕ 2.9.3

Доказательство. Пусть для измеримой функции f нашлись две фундаментальные в среднем последовательности $\{\varphi_n\}$ и $\{\psi_n\}$ простых функций, сходящиеся почти всюду к f. В силу равностепенной абсолютной непрерывности интегралов Лебега, для любого $\varepsilon > 0$ найдётся такое $\delta > 0$, что для любого измеримого E из $\mu(E) < \delta$ следует

$$\int_E |\varphi_n| + \int_E |\psi|_n < \varepsilon.$$

В силу теоремы Егорова найдётся такое «плохое» множество E_δ, что $\mu(E_\delta) < \delta$ и вне E_δ функции φ_n и ψ_n сходятся равномерно к f. Значит, начиная с некоторого номера N, для всех $n \geqslant N$ выполнено

$$\sup_{x \in X \setminus E_\delta} |\varphi_n(x) - \psi_n(x)| < \varepsilon.$$

Теперь для всех $n \geqslant N$ выполнено

$$\left|\int \varphi_n - \int \psi_n\right| \leqslant \int_{X \setminus E_\delta} |\varphi_n - \psi_n| + \int_{E_\delta} |\varphi_n| + \\ + \int_{E_\delta} |\psi_n| < \varepsilon\big(\mu(X) + 1\big),$$

откуда и следует

$$\lim_{n\to\infty} \int \varphi_n = \lim_{n\to\infty} \int \psi_n.$$

□

Основные свойства интеграла Лебега

Мы остановились на том, что определили интеграл Лебега, но так и не выяснили его основные свойства. Восполним этот пробел.
Абсолютная величина интегрируемой функции, произведение интегрируемой функции и константы и сумма двух интегрируемых функций представляют собой интегрируемые функции. Функции f^+ и f^- интегрируемы вместе с f.

УТВЕРЖДЕНИЕ 2.9.4

Доказательство. Рассмотрим интегрируемую функцию f и фундаментальные в среднем, простые φ_n, сходящиеся к f почти всюду. Для первых трёх случаев нужно рассмотреть $|\varphi_n|$, $c\varphi_n$ и $\varphi_n + \psi_n$ соответственно (где ψ_n — это простые функции из определения интегрируемости функции g). Последнее следует из того, что $f^+ = \frac{|f|+f}{2}$ и $f^- = \frac{|f|-f}{2}$. □

1. Интеграл Лебега линеен по функции.
2. Интеграл Лебега аддитивен по множеству.
3. Интеграл Лебега монотонен по функции.

УТВЕРЖДЕНИЕ 2.9.5

4. Для любой интегрируемой f

$$\left|\int f\right| \leqslant \int |f|.$$

5. Для любых интегрируемых f, g

$$\int |f+g| \leqslant \int |f| + \int |g|.$$

Доказательство. Линейность по интегрируемым функциям следует из свойств предела, аддитивность по множеству — из линейности. Монотонность следует из того, что если интегрируемость неотрицательной функции определялась простыми φ_n, то можно взять и $|\varphi_n|$. Остальные два свойства доказываются аналогично свойствам с простыми функциями. □

ТЕОРЕМА 2.9.6

Интеграл Лебега от интегрируемой функции f **абсолютно непрерывен**: то есть для любого $\varepsilon > 0$ найдётся такое $\delta > 0$, что для любого множества E меры меньше δ выполнено

$$\int_E |f| < \varepsilon.$$

Доказательство. Возьмём последовательность фундаментальных в среднем, неотрицательных простых функций φ_n, сходящихся почти всюду к $|f|$. Зафиксируем $\varepsilon > 0$ и возьмём $\delta > 0$ из их равностепенной абсолютной непрерывности. Рассмотрим произвольное E меры меньше δ. Заметим, что $\varphi_n \mathcal{I}_E$ фундаментальны в среднем и сходятся почти всюду к $|f|\mathcal{I}_E$. Тогда

$$\int_E |f| = \lim_{n\to\infty} \int_E \varphi_n \leqslant \varepsilon.$$

□

Интегральное свойство

Одно из самых необычных свойств интеграла Лебега говорит, что значения интеграла Лебега по разным множествам от некоторой функции характеризуют эту функцию практически однозначно. Грубо говоря, интеграл Лебега является «паспортом» интегрируемой функции. Формально выполняется теорема.

У двух интегрируемых функций интегралы по всем измеримым множествам совпадают тогда и только тогда, когда эти две функции равны почти всюду.

ТЕОРЕМА 2.9.7

Интегральное свойство

В одну сторону свойство очевидно. В другую — оно потребует некоторой техники.

Для любой неотрицательной интегрируемой f, любого измеримо-

ТЕОРЕМА 2.9.8

Неравенство Чебышёва

го E и любой константы $c > 0$

$$\mu\big(\{f \geqslant c\} \cap E\big) \leqslant \frac{1}{c}\int_E f.$$

Доказательство. Следует из того, что

$$\int_E f \geqslant \int_{\{f \geqslant c\}\cap E} f \geqslant c\mu\big(\{f \geqslant c\} \cap E\big).$$

□

ЛЕММА 2.9.4

Для неотрицательной интегрируемой f условие $\int f = 0$ равносильно тому, что $f = 0$ почти всюду.

Доказательство. Достаточность следует из того, что можно взять $\varphi_n = 0$; необходимость — из неравенства Чебышёва ввиду того, что

$$\mu\{f > 0\} = \lim_{\varepsilon \to +0} \mu\{f \geqslant \varepsilon\} \leqslant \lim_{\varepsilon \to +0} \frac{1}{\varepsilon}\int f = 0.$$

□

Доказательство интегрального свойства Доказательство. Достаточно доказать, что если $\int_E f = 0$ для любого измеримого E, то $f = 0$ почти всюду. Это следует из леммы 2.9.4 ввиду того, что $f\mathcal{I}\{f \geqslant 0\} = f\mathcal{I}\{f \leqslant 0\} = 0$ почти всюду. □

Связь интегралов Римана и Лебега

Итак, мы умеем интегрировать по Лебегу на произвольном измеримом пространстве. Но что, если речь идёт про обычное пространство? Как мы знаем на примере индикатора рациональных точек, даже тут из интегрируемости по Лебегу не следует интегрируемость по Риману. Оказывается, обратное выполняется (с некоторыми оговорками).

ТЕОРЕМА 2.9.9

Пусть функция f интегрируема по Риману в собственном смысле на отрезке $[a, b]$. Тогда она интегрируема по классической мере Лебега, причём интегралы Римана и Лебега от функции f совпадают.

Доказательство. Будем обозначать интеграл Лебега как и раньше, а интеграл Римана — как $R(\cdot)$.

Для каждого n разобьём отрезок $[a, b]$ на 2^n отрезков $I_1, \ldots, I_{2^n}$ длины $\frac{1}{2^n}$. Обозначим для всех $k \in \{1, \ldots, 2^n\}$

$$m_k := \inf_{x \in I_k} f(x), \qquad M_k := \sup_{x \in I_k} f(x).$$

Рассмотрим ступенчатые функции

$$\varphi_n := \sum_{k=1}^{2^n} m_k \mathcal{I}_{I_k}, \qquad \psi_n := \sum_{k=1}^{2^n} M_k \mathcal{I}_{I_k}.$$

$\varphi_n \leqslant f \leqslant \psi_n$, и функции φ_n нестрого возрастают, а ψ_n нестрого

убывают. Обозначим

$$\varphi := \lim_{n\to\infty} \varphi_n, \qquad \psi := \lim_{n\to\infty} \psi_n.$$

$\varphi \leqslant f \leqslant \psi$, и функции $\varphi,\ \psi$ измеримы по Лебегу как поточечные пределы простых функций. Кроме того, в силу ступенчатости функций $\varphi_n,\ \psi_n$ и по определению интеграла Римана мы знаем, что

$$\lim_{n\to\infty} \int \varphi_n = \lim_{n\to\infty} R(\varphi_n) = R(f) = \lim_{n\to\infty} R(\psi_n) = \lim_{n\to\infty} \int \psi_n.$$

Заметим, что функции φ_n фундаментальны в среднем: при $n > m$

$$\int |\varphi_n - \varphi_m| = \int \varphi_n - \int \varphi_m \xrightarrow[n,\, m\to\infty]{} 0,$$

где последнее следует из фундаментальности числовой последовательности $\int \varphi_n$. Поэтому функция φ интегрируема по Лебегу. Аналогично с функцией ψ. Отсюда мы получаем

$$\int \varphi_n \leqslant \int \varphi \leqslant \int \psi \leqslant \int \psi_n.$$

Переходя к пределу, замыкаем цепочку неравенств и получаем, что

$$\int \varphi = R(f) = \int \psi.$$

Исходя из этого, $\int (\psi - \varphi) = 0$, откуда следует, что $\varphi = \psi$ почти всюду. Тогда в силу полноты классической меры Лебега $\varphi = f = \psi$ почти всюду, функция f интегрируема и её интеграл Лебега совпадает с интегралами от функций $\varphi,\ \psi$, которые, в свою очередь, равны $R(f)$. □

Критерий Коши сходимости в среднем

Аналогично случаю с простыми функциями естественно ввести следующее определение.

ОПРЕДЕЛЕНИЕ 2.9.6

Расстояние между двумя интегрируемыми функциями $f,\ g$ определяется как

$$\rho(f,\, g) := \int |f - g|\,.$$

Аналогично случаю с простыми функциями расстояние симметрично и удовлетворяет неравенству треугольника. Кроме того, $\rho(\varphi,\, \psi) = 0$ равносильно равенству функций почти всюду.

ОПРЕДЕЛЕНИЕ 2.9.7

Функции f_n **сходятся в среднем** к функции f, если

$$\rho(f_n,\, f) \xrightarrow[n\to\infty]{} 0\,.$$

Функции f_n **фундаментальны в среднем**, если

$$\rho(f_n,\, f_m) \xrightarrow[n,\, m\to\infty]{} 0\,.$$

Обрати внимание, что в силу неравенства треугольника из сходимости в среднем следует и

$$\lim_{n\to\infty} \int f_n = \int f.$$

Из математического анализа известен критерий Коши, устанавливающий связь между сходимостью числовых последовательностей и их фундаментальностью. Его аналог легко доказывается для сходимостей поточечной, равномерной, почти всюду и почти равномерной. Он даже переносится на сходимость по мере, но уже сложнее. Оказывается, для сходимости в среднем он тоже выполняется. Мы докажем немного другое утверждение, похожее по сути.

ТЕОРЕМА 2.9.10

Пусть интегрируемые функции f_n фундаментальны в среднем и сходятся к функции f почти всюду. Тогда функция f интегрируема и функции f_n сходятся к ней в среднем.

Доказательство для простых $f_n = \varphi_n$ **Доказательство.** В этом случае интегрируемость функции f следует по определению. Зафиксируем произвольное $\varepsilon > 0$. Возьмём общее $\delta > 0$ из равностепенной абсолютной непрерывности для φ_n и из абсолютной непрерывности для f. По теореме Егорова существует такое «плохое» множество E_δ, что $\mu(E_\delta) < \delta$ и вне E_δ сходимость φ_n к f равномерная. То есть, начиная с некоторого N, для всех $n \geqslant N$ имеем

$$\sup_{x\in X\setminus E_\delta} |f(x) - \varphi_n(x)| < \varepsilon.$$

Тогда для этих же $n \geqslant N$ имеем

$$\int |f-\varphi_n| \leqslant \int_{E_\delta} |f-\varphi_n| + \int_{X\setminus E_\delta} |f-\varphi_n| < 2\varepsilon + \mu(X)\varepsilon.$$

□

Таким образом, мы только что доказали, что простые функции из определения интегрируемости сходятся не просто почти всюду, но и в среднем.

СЛЕДСТВИЕ 2.9.1

Пространство простых функций всюду плотно в среднем в пространстве интегрируемых функций. Иными словами, для любой интегрируемой функции f и любого $\varepsilon > 0$ найдётся такая простая функция φ, что $\rho(f,\, \varphi) < \varepsilon$.

Доказательство теоремы 2.9.10 Доказательство. В силу следствия выше для каждого n можно найти такую простую φ_n, что

$$\rho(f_n,\, \varphi_n) < \frac{1}{n}.$$

Таким образом, φ_n фундаментальны в среднем. Кроме того, они

сходятся по мере к функции f, поскольку

$$\mu\{|\varphi_n - f| > \varepsilon\} \leqslant \mu\left\{|\varphi_n - f_n| > \frac{\varepsilon}{2}\right\} + \mu\left\{|f_n - f| > \frac{\varepsilon}{2}\right\} \leqslant$$
$$\leqslant \frac{1}{2n\varepsilon} + \mu\left\{|f_n - f| > \frac{\varepsilon}{2}\right\}$$

и поскольку f_n сходятся к f по мере. Тогда, переходя по теореме Рисса к подпоследовательности, получаем, что φ_n сходятся к f почти всюду. Следовательно, f интегрируема, φ_n сходятся к f в среднем и

$$\rho(f_n,\, f) \leqslant \rho(f_n,\, \varphi_n) + \rho(\varphi_n,\, f) \xrightarrow[n\to\infty]{} 0.$$

□

Теорема Лебега

Для начала разберёмся, в чём проблема.

Пример 2.9.1. Рассмотрим функции $n\mathcal{I}[0,\, \frac{1}{n}]$. Они почти всюду сходятся к нулю. Хочется, чтобы интегралы от них тоже сошлись к нулю. К сожалению, это не выполняется: интегралы от функций равны единице и к нулю не сходятся.

ТЕОРЕМА 2.9.11

Теорема Лебега о мажорируемой сходимости

Пусть интегрируемые функции f_n сходятся к измеримой функции f почти всюду. Пусть почти всюду $|f_n| \leqslant F$ для некоторой интегрируемой функции F. Тогда f интегрируема и f_n сходятся к f в среднем.

Пример 2.9.2. Сначала посмотрим, как работает теорема. В примере 2.9.1 у функций нет ограниченной мажоранты, поэтому теорема неприменима и заключение нарушается. Но, например, если рассмотреть функции $\mathcal{I}[0,\, \frac{1}{n}]$, у них есть интегрируемая мажоранта (константа 1) и их интегралы сходятся к интегралу нуля, то есть к нулю — как и предсказывает теорема Лебега.

Доказательство теоремы Лебега Доказательство. Покажем, что f_n фундаментальны в среднем. Зафиксируем произвольное $\varepsilon > 0$. По теореме Егорова для произвольного $\delta > 0$ возьмём такое «плохое» множество E_δ меры меньше δ, что вне его сходимость f_n к f равномерная. Тогда, начиная с некоторого N, для всех $n \geqslant N$

$$\sup_{x \in X \setminus E_\delta} |f_n - f| < \varepsilon.$$

Тогда для всех $n,\, m > N$

$$\int |f_n - f_m| = \int_{E_\delta} |f_n - f_m| + \int_{X \setminus E_\delta} |f_n - f_m| \leqslant$$
$$\leqslant 2\int_{E_\delta} F + 2\varepsilon\mu(X).$$

В силу абсолютной непрерывности функции F, первое слагаемое можно сделать сколь угодно малым за счёт уменьшения δ. Таким

образом, функции f_n фундаментальны в среднем. Тогда по теореме 2.9.10 функция f интегрируема и f_n сходятся к ней в среднем. □

Отсюда получается одно замечательное следствие.

СЛЕДСТВИЕ 2.9.2

Если f измерима, F интегрируема и $|f| \leqslant F$ почти всюду, то f интегрируема.

Доказательство. Построим простые функции, сходящиеся к f и не превосходящие $|f|$ по абсолютной величине. Они интегрируемы, следовательно к ним можно применить теорему Лебега. □

СЛЕДСТВИЕ 2.9.3

Измеримая функция интегрируема только вместе со своей абсолютной величиной.

Доказательство. Новое здесь только то, что если $|f|$ интегрируем, то и f тоже. Это следует из предыдущего следствия для $F = |f|$. □

Теорема Леви

Принято считать, что если ровно одна из функций f^+, f^- неинтегрируема, то $\int f := \pm\infty$ в зависимости от того, какая именно из функций неинтегрируема. Это не меняет определения интегрируемой функции!

ТЕОРЕМА 2.9.12

Теорема Леви о монотонной сходимости

Пусть интегрируемые функции f_n нестрого возрастают по n (почти всюду) к функции f. Тогда $\lim_n \int f_n = \int f$, и если предел конечен (то есть f интегрируема), то будет сходимость и в среднем.

Доказательство. Вычитая отовсюду f_1, можно считать, что функции неотрицательные.

Если функция f интегрируема, то теорема следует из теоремы Лебега.

Остаётся показать, что при $\lim_n \int f_n < +\infty$ функция f интегрируема. Заметим, что в этом случае функции f_n фундаментальны в среднем, поскольку для $n > m$

$$\int |f_n - f_m| = \left| \int f_n - f_m \right|,$$

и числовая последовательность $\int f_n$ фундаментальна. Тогда по теореме 2.9.10 f_n сходятся к f в среднем. □

У теоремы Леви есть одно известное следствие.

СЛЕДСТВИЕ 2.9.4

Пусть неотрицательные функции f_n интегрируемы и

$$\lim_{n\to\infty} \int \sum_{k=1}^{n} f_k < +\infty.$$

Тогда

$$\lim_{n\to\infty} \int \sum_{k=1}^{n} f_k = \int \sum_{k=1}^{\infty} f_k.$$

В частности, интеграл Лебега σ-аддитивен по множеству.

Доказательство. Нужно просто применить теорему Леви к частичным суммам. Для доказательства σ-аддитивности нужно разбить функцию на положительную и отрицательную части и применить следствие для произведений функции и индикаторов. □

Лемма Фату

Иногда нет монотонной сходимости функций, а переходить к пределу хочется. Совсем к пределу перейти так просто не получится, но есть следующий «утешительный приз».

ЛЕММА 2.9.5

Лемма Фату

Для неотрицательных интегрируемых функций f_n выполнено

$$\int \varliminf_{n\to\infty} f_n \leqslant \varliminf_{n\to\infty} \int f_n.$$

Доказательство. Поскольку неотрицательные $\inf\limits_{m\geqslant n} f_m$ нестрого возрастают по n к нижнему пределу $\varliminf\limits_{n\to\infty} f_n$, то по теореме Леви

$$\int \varliminf_{n\to\infty} f_n = \lim_{n\to\infty} \int \inf_{m\geqslant n} f_m \leqslant \varliminf_{n\to\infty} \int f_n.$$

□

10. АКСИОМАТИКА КОЛМОГОРОВА

Аксиоматика Колмогорова представляет собой подход к построению вероятностного пространства для оценки вероятности тех или иных событий с помощью различных вероятностных моделей. Рассмотрение борелевской σ-алгебры и меры Лебега позволяет работать со случайными величинами (не только дискретными) и их характеристиками в аксиоматике Колмогорова.

Здесь мы введём понятие вероятностного пространства, рассмотрим способы построения вероятностных моделей, а также изучим основные свойства вероятностной меры.

Кроме этого, рассмотрим , как введённая мера Лебега позволяет обобщить понятие площади и меры Жордана для корректного решения практических задач.

Вероятностное пространство

Пусть проводится случайный эксперимент. Этот эксперимент заканчивается исходом $\omega \in \Omega$.

ОПРЕДЕЛЕНИЕ 2.10.1

Пространство элементарных исходов

Множество Ω исходов, одним из которых может заканчиваться случайный эксперимент, называется **пространством элементарных исходов**. Если $\Omega = \{\omega_1, \ldots, \omega_n\}$ или $\Omega = \{\omega_1, \ldots, \omega_n, \ldots\}$, то оно называется дискретным пространством элементарных исходов.

Пример 2.10.1.

- Монету подбросили 2 раза. Тогда множество элементарных исходов состоит из 4 исходов $\{$(Г, Г), (Г, Р), (Р, Г), (Р, Р)$\}$. Также заметим, что в случае симметричности монетки все исходы равновероятны, и мы получаем пример классического вероятностного пространства.
- Пусть бросается монетка. Если она выпала гербом, то её бросают ещё раз, иначе бросают кубик. Тогда множество элементарных исходов состоит из 8 исходов $\{$(Г, Г), (Г, Р), (Р, 1), (Р, 2), (Р, 3), (Р, 4), (Р, 5), (Р, 6)$\}$. Пространство элементарных исходов остаётся конечным, но исходы уже не будут равновероятными.
- Пусть монетка бросается до тех пор, пока не выпадет решка. Тогда множество элементарных исходов $\mathbb{N}$. Оно не является конечным, но является дискретным пространством элементарных исходов.
- Пусть 2 человека договорились встретиться на промежутке $(0:00, 1:00)$. Тогда пространство элементарных исходов (время прихода первого человека и второго человека) перестаёт быть дискретным и может быть представлено в виде квадрата $[0,1]^2$, где соответственно первая координата — время (в часах) прихода первого человека в часах, а вторая координата — время (в часах) прихода второго человека.

В отличие от дискретного вероятностного пространства мы не всегда можем определить вероятность того или иного подмножества $A \subseteq \Omega$. Соответственно, важным моментом, который отвечает за «информацию» в результате эксперимента, становится алгебра или σ-алгебра событий.

Напомним, что объединением $A \cup B$ множеств A и B называется множество, содержащее те и только те элементы, которые входят хотя бы в одно из множеств A или B. $A \cup B = \{\omega\colon \omega \in A$ или $\omega \in B\}$.

Пересечением $A \cap B$ множеств A и B называется множество, содержащее те и только те элементы, которые входят в оба множества A и B. $A \cap B = AB = \{\omega\colon \omega \in A$ и $\omega \in B\}$.

Разностью $A \setminus B$ множеств A и B называется множество, содержащее те и только те элементы, которые входят в множество A и не входят в множество B. $A \setminus B = \{\omega\colon \omega \in A$ и $\omega \notin B\}$.

Дополнением $\overline{A}$ называется множество, содержащее те и только те элементы, которые не входят в множество A. Заметим, что $\overline{A} = \Omega \setminus A = \{\omega\colon \omega \notin A\}$.

ОПРЕДЕЛЕНИЕ 2.10.2

Алгебра событий

Алгебра событий — система подмножеств Ω, удовлетворяющая следующим свойствам.

1. $\Omega \in \mathcal{A}$.
2. Если $A \in \mathcal{A}, B \in \mathcal{A}$, то $A \cap B \in \mathcal{A}, A \cup B \in \mathcal{A}, A \setminus B \in \mathcal{A}$ (замкнутость относительно конечного объединения, пересечения и разности).
   Алгебра событий называется **σ-алгеброй**, если свойство 2 заменяется на 2′.

2′. Если $A_1, \ldots \in \mathcal{A}, B \in \mathcal{A}$, то $\bigcap_{i=1}^{\infty} A_i \in \mathcal{A}, \bigcup_{i=1}^{\infty} A_i \in \mathcal{A}, A_i \setminus B \in \mathcal{A}$ (замкнутость относительно конечного разности и счётного объединения и пересечения).

Физический смысл: $\mathcal{A}$ — «информация об эксперименте», то есть те множества, относительно которых мы можем сказать, что они произошли в результате эксперимента. Соответственно, по результатам большого количества проведённых экспериментов мы можем проверить, верна ли наша модель, сравнив частоту появления события $A \in \mathcal{A}$ и её модельную вероятность.

ЗАМЕЧАНИЕ

Из свойств теоретико-множественных операций легко видеть, что для выполнения свойств **2** и **2′** достаточно выполнения замкнутости только относительно операций пересечения и разности или объединения и разности (закон де Моргана).

Пример 2.10.2. Пусть монета бросается 2 раза. В первом эксперименте ты видишь результаты обоих бросаний. Тогда $\Omega_1 = \{$(Г, Г), (Г, Р), (Р, Г), (Р, Р)$\}$, а $\mathcal{F}_1 = 2^{\Omega_1} = \Big\{\varnothing, \Omega, \{$(Г, Г)$\}, \{$(Г, Р)$\}, \{$(Р, Г)$\}, \{$(Р, Р)$\}, \{$(Г, Г), (Г, Р)$\}, \{$(Г, Г), (Р, Р)$\}, \{$(Г, Г), (Р, Г)$\}, \{$(Г, Р), (Р, Р)$\}, \{$(Р, Г), (Г, Р)$\}, \{$(Р, Г), (Р, Р)$\}, \{$(Г, Г), (Г, Р)$\}, \{$(Г, Г), (Р, Г), (Г, Р)$\}, \{$(Р, Р), (Р, Г), (Г, Р)$\}, \{$(Г, Г), (Р, Г), (Р, Р)$\}\Big\}$ состоит из 16 событий.

Во втором эксперименте ты видишь результат только первого бросания, а второе бросание закрыли ногой. Тогда $\Omega_2 = \Omega_1$ и

$\mathcal{F}_2 = \left\{\varnothing, \Omega, \{(\text{Г}, \text{Г}), (\text{Г}, \text{Р})\}, \{(\text{Р}, \text{Г}), (\text{Р}, \text{Р})\}\right\}$ состоит из 4 событий, так как исходы (Р, Г), (Р, Р) нельзя разделить, исходя из информации во втором эксперименте.

Если же в результате эксперимента ты закроешь результаты обоих бросаний ногой, то ты не будешь обладать никакой информацией, а соответственно, $\Omega_3 = \Omega_1$ и $\mathcal{F}_3 = \left\{\varnothing, \Omega\right\}$ состоит из 2 событий, которые лежат в любой алгебре или σ-алгебре.

Напомним определения операций над множествами с учётом кванторов («существует», «любой», «ровно один»).

ЗАМЕЧАНИЕ

Пусть имеются множества $(A_1, A_2, \ldots)$. Опишем следующие события.

- Множество C состоит из элементов, которые находятся во всех множествах (квантор $\forall$). Тогда $C = \bigcap_{i=1}^{n} A_i$.
- Множество C состоит из элементов, которые находятся хотя бы в одном множестве (квантор $\exists$). Тогда $C = \bigcup_{i=1}^{n} A_i$.
- Множество C состоит из элементов, которые находятся ровно в одном множестве (квантор $\exists!$). Тогда $C = \bigcup_{i=1}^{n} (A_i \bigcap_{j \neq i} \bar{A}_j)$.

Заметим, что в случае общего пространства элементарных исходов уже нельзя определять вероятность попадания в какое-то множество как сумму вероятностей исходов, в него входящих. Чтобы обеспечить свойство непрерывности меры (а именно: если у нас есть информация о том, произошло ли каждое из счётного количества множеств, то мы знаем, произошло ли их объединение/пересечение, а соответственно, можем определить вероятность этого события), введём понятие вероятностной меры (вероятности) на σ-алгебре событий.

ОПРЕДЕЛЕНИЕ 2.10.3

Вероятностная мера

Вероятность (вероятностная мера) — отображение $\mathsf{P}\colon \mathcal{F} \to [0, 1]$ со следующими свойствами:

1. $\mathsf{P}(\Omega) = 1$;
2. если $A_i \cap A_j = \varnothing \; \forall i \neq j$, то $\mathsf{P}(\bigsqcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} \mathsf{P}(A_i)$.

Для вероятности в общем случае выполнены следующие свойства:

- $\mathsf{P}(A \cup B) = \mathsf{P}(A) + \mathsf{P}(B) - \mathsf{P}(A \cap B)$. Покажем это. Пусть $A \cap B = C, A \setminus AB = D, B \setminus AB = E$. Тогда $\mathsf{P}(A \cup B) = \mathsf{P}(C) + \mathsf{P}(D) + \mathsf{P}(E)$, а $\mathsf{P}(A) = \mathsf{P}(C) + \mathsf{P}(D), \mathsf{P}(B) = \mathsf{P}(C) + \mathsf{P}(E)$, что и завершает доказательство;
- $\mathsf{P}(\overline{A}) = 1 - \mathsf{P}(A)$;
- $\mathsf{P}(\bigcup_{i=1}^{n} A_i) = \sum_{k=1}^{n} (-1)^{k+1} \sum_{1 \leqslant i_1 < \cdots < i_k \leqslant n} \mathsf{P}(A_{i_1} \ldots A_{i_k})$ — формула включения-исключения.

ОПРЕДЕЛЕНИЕ 2.10.4

Вероятностное пространство

Вероятностное пространство — тройка $(\Omega, \mathcal{F}, \mathsf{P})$, где Ω — пространство элементарных исходов, $\mathcal{F}$ — σ-алгебра событий, P — вероятностная мера.

ЗАМЕЧАНИЕ

Вероятность в случае полного дискретного пространства $(\Omega, 2^{\Omega}, \mathsf{P})$ — отображение $\mathsf{p}\colon \Omega \to [0, 1]$ со следующими свойствами:

1. $\sum_{i=1}^{n} \mathsf{p}(\omega_i) = 1$;

2. $\mathrm{P}(A) = \sum_{\omega_i \in A} \mathrm{p}(\omega_i)$.

Если все исходы равнозначны, то мы имеем дело с классическим вероятностным пространством, а именно:

1. $p(\omega_i) = \frac{1}{n}$;
2. $\mathrm{P}(A) = \frac{|A|)}{|\Omega|)}$.

Борелевская σ-алгебра

Для построения σ-алгебры на произвольном пространстве элементарных исходов Ω необходимо задать набор множеств $\mathcal{E}$, которые порождают данную σ-алгебру, а далее — обогатить её другими множествами, чтобы образовать σ-алгебру.

ЛЕММА 2.10.1

Построение минимальной σ-алгебры

Пусть $\mathcal{E}$ — класс подмножеств Ω. Тогда существует и единственная σ-алгебра $\mathcal{F} = \sigma(\mathcal{E})$, удовлетворяющая следующим двум свойствам:

1. $\mathcal{F} \supseteq \mathcal{E}$;
2. для любой σ-алгебры $\mathcal{G} \supseteq \mathcal{E}$ выполнено, что $\mathcal{G} \supseteq \mathcal{F}$.

Тогда $\mathcal{F} = \sigma(\mathcal{E})$ называется **минимальной σ-алгеброй**, порождённой системой множеств $\mathcal{E}$.

Пример 2.10.3.

- Рассмотрим пустое семейство множеств $\mathcal{E} = \varnothing$. Тогда минимальная σ-алгебра, порождённая $\mathcal{E}$, будет тривиальной, то есть $\sigma(\mathcal{E}) = \mathcal{F}_{triv} = \{\Omega, \varnothing\}$. С точки зрения информации мы ничего не узнаём из этого эксперимента.
- Пусть семейство множеств $\mathcal{E}$ состоит из одного множества, отличного от всего пространства элементарных исходов и пустого множества, то есть $\mathcal{E} = \{A\}$. Тогда минимальная σ-алгебра, порождённая $\mathcal{E}$, будет следующей: $\sigma(\mathcal{E}) = \{\Omega, \varnothing, A, \overline{A}\}$. С точки зрения информации мы из эксперимента узнаём, произошло событие A или нет.

Таким образом, можно задать «хорошую» борелевскую σ-алгебру на множестве действительных чисел.

ОПРЕДЕЛЕНИЕ 2.10.5

Борелевская σ-алгебра

Борелевская σ-алгебра на множестве $\mathbb{R}$ может быть порождена всевозможными отрезками, то есть $\mathcal{B}(\mathbb{R}) = \sigma([a,b] \colon a,b \in \mathbb{R})$.

Следующий пример показывает, что все интервалы, полуинтервалы, лучи лежат в этой σ-алгебре, а соответственно, это весьма естественная σ-алгебра на множестве действительных чисел.

Пример 2.10.4.

- Пусть $B_n = [a + 1/n, b - 1/n]$. Тогда $\bigcup_{n=1}^{\infty} B_n = (a,b)$.
- Пусть $B_n = (a, b + 1/n]$. Тогда $\bigcap_{n=1}^{\infty} B_n = (a,b]$.
- Пусть $B_n = (a, b - 1/n]$. Тогда $\bigcup_{n=1}^{\infty} B_n = (a,b)$.
- Заметим, что $(a,b] = (-\infty, b] \setminus (-\infty, a]$.
- Пусть $B_n = (a - n, a]$. Тогда $\bigcup_{n=1}^{\infty} B_n = (-\infty, a]$.

ЗАМЕЧАНИЕ

1. Заметим, что таким образом можно ввести борелевскую σ-алгебру на любом метрическом пространстве $(\mathcal{X}, \rho)$ следующим образом: $\mathcal{B}(\mathcal{X}) = \sigma(B_\varepsilon(a) \colon a \in \mathcal{X}, \varepsilon > > 0)$, где $B_\varepsilon(a) = \{x \in \mathcal{X} \colon \rho(x, a) < \varepsilon\}$.
2. Кроме этого, заметим, что все часто используемые множества (открытые, замкнутые) также лежат в борелевской σ-алгебре.

Введение в меру Лебега

Для построения корректного вероятностного пространства на отрезке $[0, 1]$ рассмотрим меру Лебега μ_L, которая естественным образом определяется на отрезках/интервалах/полуинтервалах, то есть $\mu_L([a, b]) = \mu_L((a, b]) = \mu_L([a, b)) = \mu_L((a, b))) = b - a$ при $b \geqslant a$. Также конечное объединение этих множеств образует алгебру событий, а меру Лебега — как сумму длин этих отрезков/интервалов/полуинтервалов. Таким образом, мы задали аддитивную меру на отрезке $[0, 1]$. Для следующего шага нам понадобятся эквивалентные свойства вероятностной меры.

ТЕОРЕМА 2.10.1

Эквивалентные определения вероятностной меры

Пусть Ω — пространство элементарных исходов, $\mathcal{F}$ — σ-алгебра на Ω, а P — конечная аддитивная мера, а именно: для любых $A_1, \ldots, A_k \colon A_i \cap A_j = \varnothing \; \forall i \neq j$ верно, что $\mathsf{P}(\bigsqcup_{i=1}^k A_i) = \sum_{i=1}^k \mathsf{P}(A_i)$. Тогда следующие условия эквивалентны:

- P — **σ-аддитивная мера**, то есть для любых $A_1, \ldots \colon A_i \cap A_j = \varnothing \; \forall i \neq j$ верно, что

$$\mathsf{P}(\bigsqcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} \mathsf{P}(A_i);$$

- P **непрерывна снизу**, то есть для любых $A_1, \ldots \colon A_i \subseteq A_{i+1}$ верно, что

$$\mathsf{P}(\bigcup_{i=1}^{\infty} A_i) = \lim_{i \to \infty} \mathsf{P}(A_i);$$

- P **непрерывна сверху**, то есть для любых $A_1, \ldots \colon A_i \supseteq A_{i+1}$ верно, что

$$\mathsf{P}(\bigcap_{i=1}^{\infty} A_i) = \lim_{i \to \infty} \mathsf{P}(A_i);$$

- P **непрерывна в нуле**, то есть для любых $A_1, \ldots \colon A_i \supseteq A_{i+1}, \bigcap_{i=1}^{\infty} A_i = \varnothing$ верно, что

$$\lim_{i \to \infty} \mathsf{P}(A_i) = 0.$$

Для построения вероятностной меры требуется теорема Каратеодори.

ТЕОРЕМА 2.10.2

Теорема Каратеодори

Пусть $\mathcal{E}$ — алгебра подмножеств на Ω. Пусть задана мера P — аддитивная непрерывная в нуле мера на $\mathcal{E}$. Тогда существует и единственное продолжение меры P на $\sigma(\mathcal{E})$, то есть $\exists!\mathrm{P}^*\colon\ \sigma(\mathcal{E}) \to [0,1]\colon\ \mathrm{P}^*(A) = \mathrm{P}(A)\ \forall A \in \mathcal{E}$, где P^* — σ-аддитивная мера.

Используя эту теорему, можно продолжить меру Лебега на $\mathcal{B}([0,1])$.

Пример 2.10.5. Пусть $x \in \mathbb{R}$. Тогда $\mu_L(\{x\}) = \mu_L([x,x]) = x - x = 0$.

Рассмотрим множество рациональных точек на отрезке $[0,1]$, то есть $X = \mathbb{Q} \cap [0,1]$. Тогда $\mu_L(X) = \sum_{x\in\mathbb{Q}} \mu_L(\{x\}) = 0$, где суммирование возможно, так как множество X — счётно.

Часть 3. Характеристики случайных величин

1. СЛУЧАЙНЫЕ ВЕЛИЧИНЫ И ФУНКЦИИ РАСПРЕДЕЛЕНИЯ

Во всём блоке теории вероятностей мы считаем, что у нас зафиксировано вероятностное пространство $(\Omega, \mathcal{F}, \mathrm{P})$, где Ω является **пространством элементарных исходов**, $\mathcal{F}$ является σ-алгеброй **событий** с единицей Ω, а $\mathrm{P}\colon\ \mathcal{F} \to [0,1]$ является σ-аддитивной мерой с условием $\mathrm{P}(\Omega) = 1$. Благодаря нормировке на 1 мера P называется **вероятностной**. Элементарные исходы принято обозначать буквой ω; то есть, $\omega \in \Omega$.

Неформально, **случайная величина** — это числовая интерпретация элементарных исходов. Иными словами, это функция на множестве элементарных исходов, то есть случайная характеристика, которая может быть померена в результате эксперимента.

Формально, если пространство Ω **дискретно**, то есть конечно или счётно, и $\mathcal{F} = 2^\Omega$, то **случайной величиной** называется отображение $\Omega \to \mathbb{R}$.

Пример 3.1.1. Допустим, мы хотим построить вероятностное пространство бросков нечестной монетки. Если мы подбросили её n раз, то исход можно записать кортежем из n нулей и единиц. Таким образом, в этой модели, пространство элементарных исходов можно задать как $\Omega = \{0,1\}^n$. Если считать, что единица имеет вероятность p, а нолик, соответственно, $1-p$, то получаем, что

$$\mathrm{P}(\omega) = p^{\sum_{i=1}^n \omega_i}(1-p)^{n-\sum_{i=1}^n \omega_i} = \\ = p^{\text{число успехов}}(1-p)^{\text{число неудач}}.$$

Такая пара (Ω, P) называется **схемой испытаний Бернулли**.

Если мы теперь заинтересуемся вопросом, на первом месте выпал нолик или единица, удобно ввести отображение $\xi_1 \colon \Omega \to \mathbb{R}$, задаваемое как $\xi_1(\omega) = \omega_1$. Это отображение и будет случайной величиной: по исходу (кортеж выпадений монетки) она выдаёт число (успех или неуспех первого броска). Аналогично можно ввести случайные величины $\xi_i \colon \omega \mapsto \omega_i$, отвечающие за i-й бросок. Если нас интересует общее количество успехов, то не нужно теперь вводить новую случайную величину, достаточно рассмотреть сумму

$$\sum_{i=1}^{n} \xi_i \colon \omega \mapsto \sum_{i=1}^{n} \xi_i(\omega) = \sum_{i=1}^{n} \omega_i.$$

Формально, **случайной величиной** называется $\mathcal{F}|\mathcal{B}(\mathbb{R})$-измеримое отображение $\Omega \to \mathbb{R}$, где через $\mathcal{B}(\mathbb{R})$ обозначена **борелевская σ-алгебра прямой**. Иными словами, $\xi \colon \Omega \to \mathbb{R}$ является случайной величиной, если

$$\{\xi \in B\} \equiv \{\omega : \xi(\omega) \in B\} \equiv \xi^{-1}(B) \in \mathcal{F}$$

для любого борелевского множества $B \in \mathcal{B}(\mathbb{R})$.

Пример 3.1.2. Если $\Omega = \mathbb{R}$ и $\mathcal{F} = \mathcal{B}(\mathbb{R})$, то тождественное отображение $x \mapsto x$ будет случайной величиной.

В теории вероятностей и статистике нас обычно не интересуют случайные величины как функции на Ω. Нас интересует, с какой вероятностью случайные величины принимают разные значения (или, в более сложном случае, попадают в какие-то интервалы). Пусть случайная величина ξ **дискретна**, то есть принимает не более счётное множество значений. Тогда функция

$$\mathrm{P}_\xi \colon x \mapsto \mathrm{P}\{\xi = x\}$$

называется **функцией вероятности** (англ. PMF, probability mass function) случайной величины ξ, и задаёт её **распределение**.

Пример 3.1.3. Случайная величина ξ имеет **распределение Бернулли** с параметром $p \in [0,1]$, пишут $\xi \sim \mathrm{Bern}(p)$, если

$$\mathrm{P}\{\xi = 1\} = p \qquad \text{и} \qquad \mathrm{P}\{\xi = 0\} = 1 - p.$$

В примере 3.1.2 все величины ξ_i имеют распределение Бернулли. То есть, иными словами, распределение Бернулли имеет случайная величина, которая равна 1 при успехе, и 0 при неуспехе.

Пример 3.1.4. Случайная величина ξ имеет **биномиальное распределение** с параметрами $n \in \mathbb{N}$ и $p \in [0,1]$, пишут $\xi \sim$

$\mathrm{Bin}(n,p)$, если

$$\mathrm{P}\{\xi = k\} = \binom{n}{k} p^k (1-p)^{n-k}, \qquad \text{где} \qquad k = 0,1,2,\ldots,n.$$

В примере 3.1.2 сумма $\sum_{i=1}^{n} \xi_i$ имеет биномиальное распределение. То есть, биномиальное распределение это распределение числа успехов в схеме испытаний Бернулли, где всего n независимых экспериментов с вероятностями успеха p.

Пример 3.1.5. Случайная величина ξ имеет **геометрическое распределение** с параметром $p \in (0,1]$, пишут $\xi \sim \mathrm{Geom}(p)$, если

$$\mathrm{P}\{\xi = n\} = p(1-p)^n, \qquad n = 0,1,2,\ldots$$

Чтобы построить это распределение, одной схемы испытаний Бернулли уже не хватит. Смысл здесь в том, что при вероятности успеха p количество неуспехов до первого успеха имеет геометрическое распределение. Иногда в геометрическом распределении считают общее число попыток, а не число неудач; тогда n начинается с 1, и все вероятности сдвигаются влево.

Пример 3.1.6. Случайная величина ξ имеет **распределение Пуассона** с параметром $\lambda > 0$, пишут $\xi \sim \mathrm{Pois}(\lambda)$, если

$$\mathrm{P}\{\xi = n\} = \frac{\lambda^n}{n!} e^{-\lambda}, \qquad n = 0,1,2,\ldots$$

Это распределение возникает, например, если мы считаем количество звонков в колл-центр в течение одного часа. По-другому оно возникает, если мы попытаемся приближённо вычислять биномиальное распределение (о чём ниже).

При больших n, m расчёт $\binom{n}{k} p^k (1-p)^{n-k}$ оказывается достаточно трудоёмким. Следовательно, требуется использовать различные приближения. Оказывается, при маленьком p и большом n эти вероятности можно рассчитать приближённо.

ТЕОРЕМА 3.1.1

Пусть $\xi_n \sim \mathrm{Bin}(n, p_n)$, и $np_n \xrightarrow[n\to\infty]{} \lambda$ для $0 < \lambda < \infty$. Тогда величины ξ_n *сходятся по распределению к распределению Пуассона с параметром* λ, то есть

$$\mathrm{P}\{\xi_n = k\} \xrightarrow[n\to\infty]{} \frac{\lambda^k}{k!} e^{-\lambda} \qquad \text{для всех} \quad k = 0,1,2,\ldots$$

Доказательство. При любом фиксированном k имеем

$$\mathrm{P}\{\xi_n = k\} = \binom{n}{k} p_n^k (1-p_n)^{n-k} =$$

$$= \frac{(np_n)^k}{k!} \left(1 - \frac{1}{n}\right) \ldots \left(1 - \frac{k-1}{n}\right) \frac{(1-p_n)^n}{(1-p_n)^k} \xrightarrow[n\to\infty]{} \frac{\lambda^k}{k!} \cdot 1 \cdot \ldots$$

$$\ldots \cdot 1 \cdot \frac{e^{-\lambda}}{1^k}.$$

Здесь в последнем переходе мы пользуемся тем, что

$$(1-p_n)^n \xrightarrow[n\to\infty]{} e^{-\lambda}.$$

Это следует из непрерывности экспоненты в силу того, что

$$n\ln(1-p_n) = -np_n + o(np_n) \xrightarrow[n\to\infty]{} -\lambda.$$

□

В общем случае, **распределение $\mathbf{P}_{\boldsymbol{\xi}}$** случайной величины ξ является вероятностной σ-аддитивной мерой на борелевской σ-алгебре прямой, и задаётся как

$$\mathrm{P}_\xi(B) := \mathrm{P}\{\xi \in B\} \quad \text{для любого борелевского } B \in \mathcal{B}(\mathbb{R}).$$

Пример 3.1.7. Стоит отметить, что совпадение распределений отнюдь не означает совпадение самих случайных величин. Например, в схеме испытаний Бернулли 3.1.2 все величины ξ_i имеют одно и то же Бернуллиевское распределение, но, очевидно, не совпадают как функции на Ω.

Как мы могли видеть, обсуждая меру Лебега—Стилтьеса, для задания меры на прямой достаточно знать её значения на полуинтервалах. Этот же принцип существенно облегчает задание распределения случайной величины.

Следуя ему, назовём **функцией распределения** (англ. *CDF, cumulative distribution function*) случайной величины ξ функцию $F_\xi\colon \mathbb{R} \to [0,1]$, задаваемую как

$$F_\xi(x) := \mathrm{P}\{\xi \leqslant x\}.$$

Очевидно, что для дискретной случайной величины выполнено

$$F_\xi(x) = \sum_{y \leqslant x} \mathrm{P}\{\xi = y\}.$$

Использование CDF в качестве способа «хранить» распределение в компьютере ускоряет выполнение запросов на поиск вероятности в произвольном промежутке: требуется не больше одного вычитания. Если же хранить только PMF, то количество операций для поиска вероятности пропорционально количеству значений, которые попали в запрашиваемый промежуток. При сотнях тысяч значений хранение CDF ускоряет поиск вероятности в сотни тысяч раз. Если тебе из программирования знаком термин «префиксная сумма», то CDF — это префиксная сумма PMF. Префиксные суммы используют для ускоренного расчёта сумм на промежутках, и ровно этого же достигаетCDF.

Перечислим три основных свойства функции распределения:

1. она нестрого возрастает,
2. она непрерывна справа,
3. $F_\xi(-\infty) = 0$ и $F_\xi(+\infty) = 1$.

Как мы знаем, первые два свойства вместе с ограниченностью гарантируют, что F_ξ задаёт какое-то распределение на $\mathbb{R}$. Третье свойство гарантирует нам нормировку, что полученное распределение является вероятностным. По свойству мер Лебега—Стилтьеса, этого же и достаточно для задания вероятностной меры. То есть, **функцией распределения** $F\colon \mathbb{R} \to [0,1]$ называется нестрого возрастающая непрерывная справа функция, удовлетворяющая условию $F(-\infty) = 0$ и $F(+\infty) = 1$. По свойствам мер Лебега—Стилтьеса, такие функции являются в точности функциями распределения случайных величин.

Пример 3.1.8. ля константы, CDF выглядит как функция скачка: до константы 0, а после константы 1.

Пример 3.1.9. ля $\xi \sim \mathrm{Bern}(p)$, CDF выглядит как два скачка:

$$F_\xi(x) = \begin{cases} 0, & x < 0, \\ 1-p, & 0 \leqslant x < 1, \\ 1, & x \geqslant 1. \end{cases}$$

Аналогично, для дискретных распределений CDF выглядит как функция скачков, где в точке x_i происходит скачок на значение $\mathrm{P}\{\xi = x_i\}$.

Пусть мы хотим придумать вероятностное пространство, при котором все точки отрезка $[0,1]$ равновероятны. Вероятность каждой точки должна быть одним и тем же числом.

Она не может равняться 0.01, поскольку вероятность 200 таких точек превысит 100%. По аналогичным соображениям, вероятность точки не может быть равна никакому положительному числу. Поэтому вероятность каждой точки обязана равняться нулю.

Вероятность множества, в котором счётное количество точек будет равна сумме вероятностей этих точек, то есть нулю. Сумму можно писать для счётного числа слагаемых, но на отрезке несчётное число точек. Значит сумма вероятностей всех точек отрезка вообще математически не определена.

При этом вероятность целого отрезка должна равняться 1. Она не будет равна сумме нулевых вероятностей всех точек. Вероятность несчётного множества нельзя определить через сумму вероятностей входящих в неё точек. Её нужно определять как-то иначе.

Можно определить вероятность события через длину события. Например $\mathrm{P}\{0 \leqslant X \leqslant 0.5\} = len([0,0.5]) = 0.5$, тогда

все отрезки одинаковой длины имеют одинаковую вероятность, общая вероятность составляет 100%, а вероятность каждой точки равна её длине, то есть нулю.

Такой подход позволяет определить вероятностное пространство, которое обобщит равновероятное пространство на случай бесконечного числа исходов. Мы не будем на нём останавливаться и сразу перейдём к общему случаю абсолютно непрерывного распределения.

Случайная величина ξ называется **абсолютно непрерывной**, если существует такая неотрицательная функция $p_\xi \colon \mathbb{R} \to \mathbb{R}_+$, что

$$F_\xi(x) = \int_{-\infty}^{x} p_\xi(x)\,dx$$

для всех $x \in \mathbb{R}$ (где интеграл понимается в смысле Лебега). Функция p_ξ называется **плотностью**.

Перечислим несколько свойств плотности.

1. Оказывается, плотность и правда характеризует распределение: а именно, для любого борелевского множества B выполнено
$$\mathrm{P}_\xi(B) = \int_B p_\xi(x)\,dx.$$
2. В частности,
$$\int_{\mathbb{R}} p_\xi(x)\,dx = 1.$$
3. Кроме того, для абсолютно непрерывной случайной величины выполнено
$$\mathrm{P}\{\xi = c\} = 0$$
для любой константы c.
4. Функция распределения F_ξ является непрерывной (но не всякая непрерывная функция задаёт абсолютно непрерывное распределение).
5. Наконец, F_ξ почти всюду дифференцируема, и $F'_\xi = p_\xi$.

Пример 3.1.10. Случайная величина ξ имеет **равномерное распределение**, пишут $\xi \sim \mathrm{U}[a,b]$, если

$$p_\xi(x) = \frac{1}{b-a}\mathcal{I}\{a < x < b\}.$$

Пример 3.1.11. Случайная величина ξ имеет **нормальное распределение**, пишут $\xi \sim N(a,\sigma^2)$, если

$$p_\xi(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-a)^2}{2}}.$$

Распределение $N(0,1)$ называют **стандартным нормальным**.

Пример 3.1.12. Случайная величина ξ имеет **экспоненциальное**

распределение, пишут $\xi \sim \mathrm{Exp}(\lambda)$, если

$$p_\xi(x) = \lambda e^{-\lambda x} \mathcal{I}\{x > 0\}.$$

В таком случае,

$$F_\xi(x) = \begin{cases} 1 - e^{-\lambda x}, & x > 0, \\ 0, & x \leqslant 0. \end{cases}$$

Пример 3.1.13. Пусть $\xi \sim N(0,1)$. Найдём распределение величины ξ^2. Для этого находим

$$F_{\xi^2}(x) = \mathrm{P}\{\xi^2 \leqslant x\} = \mathrm{P}\{-\sqrt{x} \leqslant \xi \leqslant \sqrt{x}\} = 2\int_0^{\sqrt{x}} p_\xi(t)\,dt.$$

Беря производную, получаем

$$p_{\xi^2}(x) = p_\xi(\sqrt{x})/\sqrt{x} = \frac{1}{\sqrt{2\pi x}} e^{-x/2}, \qquad x > 0.$$

Это называется распределение хи-квадрат с одной степенью свободы, $\chi^2(1)$, или ещё это совпадает с $\Gamma(\frac{1}{2}, \frac{1}{2})$.

Пример 3.1.14. Естественный вопрос: а как строить случайные величины с нужным распределением? На самом деле, очень просто: нужно взять вероятностное пространство $(\Omega, \mathcal{F}, \mathrm{P}) = (\mathbb{R}, \mathcal{B}(\mathbb{R}), \mathrm{P})$ с нужным распределением P, и взять случайную величину $\xi : \omega \to \omega$.

Есть более общий способ для расчёта распределений в некоторых частных случаях.

ТЕОРЕМА 3.1.2

Пусть ξ абсолютно непрерывная случайная величина, а функция $\varphi\colon \mathbb{R} \to \mathbb{R}$ строго монотонна на множестве значений $\mathrm{Im}\,\xi$. Тогда случайная величина $\varphi(\xi)$ тоже абсолютно непрерывна, причём

$$p_{\varphi(\xi)}(x) = \frac{p_\xi(\varphi^{-1}(x))}{|\varphi'(\varphi^{-1}(x))|}.$$

Доказательство. Мы не будем доказывать, что полученная случайная величина является абсолютно непрерывной. Кроме того, для удобства мы рассмотрим только строго возрастающую функцию. Тогда

$$F_{\varphi(\xi)}(x) = \mathrm{P}\{\xi \leqslant \varphi^{-1}(x)\} = \int_{-\infty}^{\varphi^{-1}(x)} p_\xi(t)\,dt.$$

Беря производную, получаем требуемое. □

2. КВАНТИЛИ РАСПРЕДЕЛЕНИЙ

Функция распределения эффективно решает задачу поиска вероятности: например, пусть ξ задаёт балл на экзамене случайно вытя-

нутого студента. Тогда $F_\xi(7.3)$ показывает долю студентов, которые набрали на экзамене 7.3 или меньше баллов. Часто возникает обратная задача — по известной вероятности найти пороговое значение: например, показать порог, который отделяет топ-10% самых высоких результатов от 90% остальных. Для решения обратной задачи служит **обратная функция распределения** (англ. PPF, percent-point function), которую в русской литературе называют **p-квантилью**, где $p \in [0, 1]$ обозначает интересующую нас долю (например, если мы хотим отделить топ-10% студентов, нужно взять $p = 0.9$).

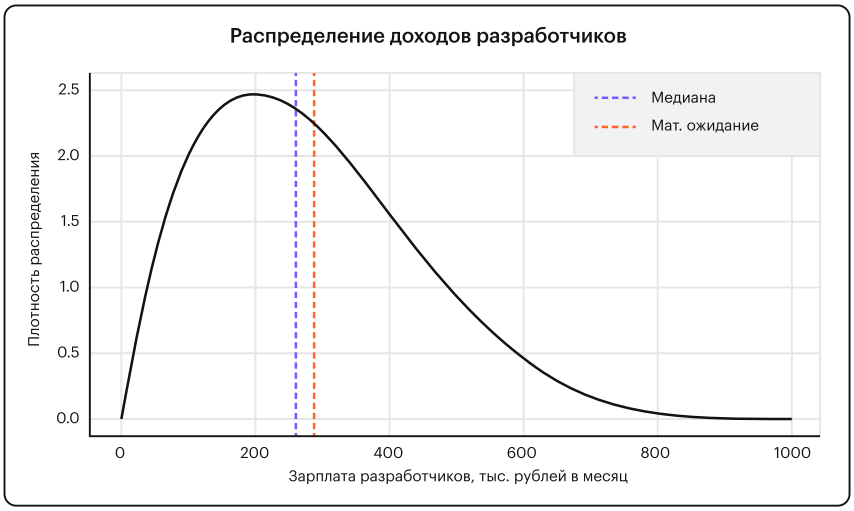

Рисунок 11. Медиана непрерывного распределения

Если функция распределения F непрерывна и строго монотонна, то тогда это биекция, и можно задать её p-квантиль как

$$x_p := F^{-1}(p).$$

То есть это буквально такое число, что левее него мы попадём с вероятностью p.

Пример 3.2.1. Для распределения $\xi \sim \mathrm{Exp}(\alpha)$, имеем

$$p = F_\xi(x_p) = 1 - e^{-\alpha x_p},$$

откуда

$$x_p = \frac{-\ln(1-p)}{\alpha}.$$

Стоить обратить внимание, что $x_1 = +\infty$.

Для разрывных и нестрого монотонных функций распределения квантиль задаётся похожим образом: нужно взять самое маленькое значение, левее которого мы попадём с вероятностью хотя бы p. Формально,

$$x_p := \inf\{x \in \mathbb{R} : F(x) \geqslant p\}.$$

Если заменить знак неравенства на строгий, значения кван-

тили изменятся на участках, где функция распределения горизонтальна.

Отдельного внимания заслуживает **медиана** распределения, которая просто является 0.5-квантилью (см. рис. 11). Обрати внимание, что, когда мы будем рассматривать выборочные характеристики, выборочная медиана и выборочная 0.5-квантиль уже могут не совпадать!

Пример 3.2.2. Пусть ξ задаёт время, за которое участник заплыва финишировал, в минутах. Тогда $x_{0.1} = 5$, означает, что примерно 10% (столько или больше) самых быстрых пловцов финишировали за 5 минут или быстрее.

Пример 3.2.3. Пусть ξ задаёт балл студента на экзамене. Тогда $x_{0.1} = 5$, означает, что примерно 10% (столько или больше) студентов получили 5 и меньше баллов на экзамене.

Пример 3.2.4. Пусть ξ задаёт средний платёж клиента, в тысячах рублей. Тогда $x_{0.1} = 5$, означает, что примерно 10% (столько или больше) клиентов платят 5 и меньше тысяч рублей.

Иногда вводят функцию $Q\colon [0,1] \to \mathbb{R}$, которую называют **функцией квантили**, и определяют как $Q(p) = x_p$. То есть, в каком-то смысле, Q и есть обратная к F.

ТЕОРЕМА 3.2.1

Функция Q почти наверное является левой обратной к F_ξ, то есть, п.н. выполнено

$$Q(F_\xi(\xi)) = \xi.$$

Доказательство. Заметим, что $Q(p) \leqslant x$ равносильно тому, что $p \leqslant F_\xi(x)$. Таким образом, $Q(F_\xi(x)) \leqslant x$ равносильно тому, что $F_\xi(x) \leqslant F_\xi(x)$, то есть выполнено всегда. В итоге, нам нужно доказать, что

$$Q(F_\xi(\xi)) < \xi$$

выполнено с нулевой вероятностью. Понятно, что $Q(F_\xi(x)) < x$ равносильно тому, что x попало на горизонтальный участок функции распределения F_ξ. Но случайная величина ξ попадает на горизонтальные участки функции распределения F_ξ с нулевой вероятностью. Следовательно, на их объединение она тоже попадает с нулевой вероятностью. □

ТЕОРЕМА 3.2.2

В случае абсолютно непрерывных распределений квантиль можно выражать как решение некоторых уравнений.
Пусть функция распределения абсолютно непрерывна и строго монотонна (кроме, возможно, участков 0 и 1). Пусть f её плотность. Тогда

$$\frac{dQ}{dp} = \frac{1}{f(Q)}.$$

Доказательство. Поскольку

$$F(Q(p)) = p$$

дифференцируя по p, получаем

$$f(Q)Q'(p) = 1,$$

что и требовалось. □

3. УСЛОВНАЯ ВЕРОЯТНОСТЬ

По смыслу функция вероятности показывает, насколько «часто» происходит то или иное событие. Пусть мы хотим узнать, насколько «ожидаемо» событие A при условии, что произошло некоторое другое событие B. В таком случае мы исходим из того, что событие B уже произошло, а потому его вероятность считают равной 1.

Вернёмся к задаче с шарами в урне. Ты уже можешь посчитать вероятность, например, достать белый шар. А как посчитать вероятность достать чёрный шар, если известно, что до этого вынули белый?

Пример 3.3.1. Дана урна с 10 шарами, из них 4 белых и 6 чёрных.

- Какова вероятность вытащить чёрный шар?
- Какова вероятность вытащить чёрный шар, если до этого вынули белый?

В урну возвращать шары нельзя.

- Вероятность равна $\frac{6}{10} = \frac{3}{5}$.
- После того как вынули белый шар, всего осталось 9 шаров. Поэтому вероятность стала $\frac{6}{9} = \frac{2}{3}$.

Во втором пункте мы посчитали так называемую **условную вероятность**, которая для события A при условии события B определяется как

$$\mathrm{P}(A \mid B) := \frac{\mathrm{P}(A \cap B)}{\mathrm{P}(B)}.$$

Смысл определения можно пояснить следующим образом. Допустим, у нас имелось некоторое вероятностное пространство $(\Omega, \mathcal{F}, \mathrm{P})$, в котором мы жили, а потом произошло некоторое событие B. Логично, что теперь наше старое пространство не годится: наши сведения устарели, вероятность уже не та. В частности, теперь вероятность события B стала равна 1. В итоге, нам нужно пересчитать вероятности и перенормировать с учётом того, что произошло событие B.

Стоит отметить, что если $\mathrm{P}(B) = 0$, то дробь превращается в $\frac{0}{0}$. С физической точки зрения, мы говорили, что «B произошло», и вряд ли мы такое могли сказать про события нулевой вероятности. С математической точки зрения, удобно полагать, что неопределённость $\frac{0}{0}$ раскрывается любым способом, то есть заранее верны равенства его любому другому числу.

Пример 3.3.2. Мы бросили n-гранный «честный» кубик один раз. Пусть известно, что выпала чётная грань. Какова вероятность, что выпала 2?

- Пусть n чётное, тогда чётных граней всего $\frac{n}{2}$. P равна $\frac{1}{\frac{n}{2}} = \frac{2}{n}$.
- Пусть n нечётное, тогда чётных граней $\frac{n-1}{2}$. P равна $\frac{1}{\frac{n-1}{2}} = \frac{2}{n-1}$.

Важно понимать, что условная вероятность — это вероятность со множеством B, выступающим в роли Ω. То есть для неё выполнены все свойства выше (и ниже).

Теперь рассмотрим такую задачу.

Пример 3.3.3. Дима придумал следующую систему принятия решений, что ему поесть на обед. У него есть носки трёх цветов — красного, зелёного и синего. Он случайно достаёт носок из коробки.

- Если он достал красный носок, он съест борщ.
- Если он достал зелёный носок, он съест щи.
- Если он достал синий носок, он съест десерт с голубой матчей.

Если Диме достанется суп, с вероятностью $0,6$ он захочет съесть что-то ещё. В случае с десертом вероятность быть сытым после обеда равна $0,1$. Если же Диме достанется борщ, то он точно будет сытым.

С какой вероятностью Дима будет сыт после обеда?

Заметим, что в этой задаче события $\{$Дима достал красный носок$\}$, $\{$Дима достал зелёный носок$\}$ и $\{$Дима достал синий носок$\}$ не пересекаются — подобные события называют **несовместными**. При этом они покрывают все возможные исходы — в таком случае говорят, что эти события образуют **разбиение** множества исходов.

Разбиением называется такая система событий B_n, что $\Omega = \bigsqcup_{n=1}^{\infty} B_n$. Иногда вместо теоретико-множественного разбиения берут вероятностное. Неформально это означает, что все события могут различаться на множества нулевой вероятности. Формально должно выполняться равенство $\mathrm{P}(B_n \cap B_m) = 0$ для всех $n \neq m$ и $\mathrm{P}\left(\bigcup_{n=1}^{\infty} B_n\right) = 1$. В дальнейшем, говоря про разбиение, мы будем подразумевать только теоретико-множественное разбиение.

ТЕОРЕМА 3.3.1

Для разбиения $\Omega = \bigsqcup_{n=1}^{\infty} B_n$ и для любого события A выполнено:

$$\mathrm{P}(A) = \sum_{n=1}^{\infty} \mathrm{P}(A \mid B_n)\mathrm{P}(B_n).$$

Доказательство. Используя формулу условной вероятности, в силу σ-аддитивности вероятности получаем:

$$\mathrm{P}(A) = \sum_{n=1}^{\infty} \mathrm{P}(A \cap B_n) = \sum_{n=1}^{\infty} \mathrm{P}(A \mid B_n)\mathrm{P}(B_n).$$

□

Пример 3.3.4. Продолжим пример 3.3.3. Обозначим за событие $A = \{$Дима будет сыт после обеда$\}$, а за $B_1 = \{$Дима достал красный носок$\}$, $B_2 = \{$Дима достал зелёный носок$\}$ и $B_3 = \{$Дима достал синий носок$\}$. Тогда, используя формулу полной вероятности, получаем:

$$\mathrm{P}(A) = \sum_{n=1}^{3} \mathrm{P}(A \mid B_n)\mathrm{P}(B_n) = \frac{1}{3} \cdot 1 + \frac{1}{3} \cdot 0{,}4 = \frac{1}{3} \cdot 0{,}1 = 0{,}5,$$

то есть вероятность остаться сытым после такой системы принятия решений равна $0,5$.

Пример 3.3.5. Маша проснулась утром и забыла, какой сейчас день недели и нужно ли идти на пары. Маша любит теорию вероятностей и не любит календари, поэтому решила так: если вероятность пары больше $\frac{1}{2}$, она пойдёт в университет. Она знает, что во вторник, среду, четверг и пятницу ей нужно на пары с вероятностью $\frac{3}{4}$ (скорее всего, там будут важные занятия), в субботу ей нужно на пары с вероятностью $\frac{1}{2}$ (там когда-то маячила физкультура), а в воскресенье и понедельник на пары не нужно. Считая, что все дни равновероятны, ответь, пойдёт ли Маша в университет?

По формуле полной вероятности:

$$\begin{aligned}\mathrm{P}(\text{пары}) = \\ = 0 \cdot \frac{1}{7} + \frac{3}{4} \cdot \frac{1}{7} + \frac{3}{4} \cdot \frac{1}{7} + \frac{3}{4} \cdot \frac{1}{7} + \frac{3}{4} \cdot \frac{1}{7} + \frac{1}{2} \cdot \frac{1}{7} + 0 \cdot \frac{1}{7} = \\ = \frac{1}{2}.\end{aligned}$$

Таким образом, Маша останется дома :)

Следующая формула нужна, чтобы уточнять вероятности по новым полученным данным.

ТЕОРЕМА 3.3.2

Для разбиения $\Omega = \bigsqcup_{n=1}^{\infty} B_n$ и для любого события A вероятность события B_n при условии A равна вероятности пересечения

этих событий, делённой на вероятность A:

$$\mathrm{P}(B_n \mid A) = \frac{\mathrm{P}(A \mid B_n)\mathrm{P}(B_n)}{\sum_i \mathrm{P}(A \mid B_i)\mathrm{P}(B_i)}.$$

Доказательство. По определению условной вероятности и по формуле полной вероятности:

$$\mathrm{P}(B_n \mid A) = \frac{\mathrm{P}(A \cap B_n)}{\mathrm{P}(A)} = \frac{\mathrm{P}(A \mid B_n)\mathrm{P}(B_n)}{\sum_i \mathrm{P}(A \mid B_i)\mathrm{P}(B_i)}.$$

□

Смысл формулы Байеса в следующем. Пусть для некоторого разбиения $\Omega = \bigsqcup_n B_n$ известны их вероятности $\mathrm{P}(B_n)$; они в таком контексте называются **априорными** (от лат. a priori — «от предшествующего») вероятностями. Затем произошло событие A — новые вероятности событий B_n с учётом события A называются **апостериорными** (от лат. a posteriori — «из последующего»). Так можно продолжать и дальше, принимая апостериорную вероятность за априорную, уточняя значения вероятностей при поступлении новых данных. На этом принципе основан **байесовский подход** — статистический метод, использующийся, в частности, в машинном обучении.

Пример 3.3.6. Оказалось, что вероятность Машу подвела и всё-таки была пара. Тем не менее Маша любит вероятность больше, чем календари, поэтому ответ на вопрос, какой сегодня день недели, она по-прежнему доверяет случаю, хотя использует знание о том, что пара была.

По формуле Байеса находим:

$$\mathrm{P}(\text{четверг} \mid \text{пары}) = \frac{\frac{3}{4} \cdot \frac{1}{7}}{\frac{1}{2}} = \frac{3}{14}.$$

То есть вероятность, что сегодня четверг, возросла в полтора раза. Аналогично произойдёт со средой, четвергом и пятницей. Вероятности воскресенья и понедельника занулятся, а вероятность субботы не поменяется.

Для произвольных событий $A_1, \ldots, A_n$ выполнено:

ТЕОРЕМА 3.3.3

$$\mathrm{P}(A_1 \ldots A_n) = \mathrm{P}(A_1)\mathrm{P}(A_2 \mid A_1)\mathrm{P}(A_3 \mid A_1A_2)\ldots \\ \ldots \mathrm{P}(A_n \mid A_1 \ldots A_{n-1}).$$

Доказательство. По определению условной вероятности имеем:

$$\begin{aligned}\mathrm{P}(A_1)\mathrm{P}(A_2 \mid A_1)\mathrm{P}(A_3 \mid A_1A_2)\dots\mathrm{P}(A_n \mid A_1\dots A_{n-1}) = \\ = \mathrm{P}(A_1)\frac{\mathrm{P}(A_1A_2)}{\mathrm{P}(A_1)}\frac{\mathrm{P}(A_1A_2A_3)}{\mathrm{P}(A_1A_2)}\dots\frac{\mathrm{P}(A_1\dots A_n)}{\mathrm{P}(A_1\dots A_{n-1})} = \\ = \mathrm{P}(A_1\dots A_n).\end{aligned}$$

□

Пример 3.3.7. Дима с одногруппниками тянут билеты на экзамене, среди которых один сложный. Каким по счёту в очереди надо встать Диме, чтобы с меньшей вероятностью вытянуть сложный билет?

Пусть Дима стоит k-м по счёту, а всего билетов $n \geqslant k$. Тогда он вытянет сложный билет, только если его сначала не вытянет первый в очереди, потом не вытянет второй и так далее, что в итоге даёт:

$$\begin{aligned}\mathrm{P}(\text{сложный билет}) = \frac{n-1}{n}\cdot\frac{n-2}{n-1}\cdot\dots \\ \dots\cdot\frac{n-k+1}{n-k+2}\cdot\frac{1}{n-k+1} = \frac{1}{n}.\end{aligned}$$

То есть всё равно, где он стоит — вероятность одна и та же.

Напоследок, обсудим такое важное понятие, как независимость событий.

Рассмотрим такой пример. Какова вероятность, что при броске честной монеты выпадет решка, если за окном идёт снег? Очевидно, что эти два события не влияют друг на друга. С точки зрения вероятности это значит, что вероятность одного события не зависит от наступления или ненаступления второго — то есть

$$\mathrm{P}(A \mid B) = \mathrm{P}(A) = \frac{\mathrm{P}(A \cap B)}{\mathrm{P}(B)} \Rightarrow \mathrm{P}(A \cap B) = \mathrm{P}(A)\cdot\mathrm{P}(B).$$

События A и B называются **независимыми**, если

$$\mathrm{P}(AB) = \mathrm{P}(A)\cdot\mathrm{P}(B).$$

Геометрически вероятность независимых событий можно представить как площадь фигуры, основаниями которой служат вероятности событий (рисунок 12). Важно не путать независимость с несовместностью (рисунок 13).

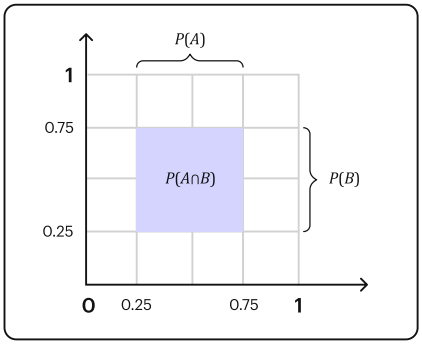

Рисунок 12. Совместная вероятность двух независимых событий

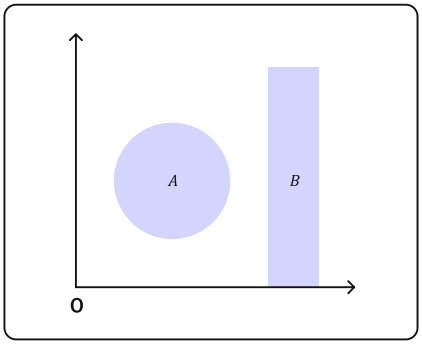

Рисунок 13. Два несовместных события

В случайных экспериментах предполагается независимость испытаний. Например, бросок честной монетки или кубика не зависит от предыдущих бросков и не влияет на последующие.

Пример 3.3.8. Перед Димой всего один человек в очереди тянуть билет. Лежат 10 билетов, и один из них сложный. Являются ли независимыми события {студент перед Димой вытянул сложный билет} и {Дима вытянул сложный билет}?

Интуитивно кажется, что события должны быть зависимы: если студент перед Димой вытянул сложный билет, он уже может не бояться (только посочувствовать). Давай проверим это.

Обозначим через A событие, что студент перед Димой вытянул хороший билет; через B — событие, что Дима вытянул хороший билет. Тогда, как мы обсуждали в примере выше:

$$\mathrm{P}(A) = \mathrm{P}(B) = \frac{9}{10}.$$

При этом

$$\mathrm{P}(AB) = \mathrm{P}(A)\mathrm{P}(B \mid A) = \frac{9}{10} \cdot \frac{8}{9} = \frac{8}{10} < \frac{81}{100} = \mathrm{P}(A)\mathrm{P}(B).$$

Значит, интуиция оказалась верной — события зависимы.

Пусть есть некоторый набор событий. Как определить, независимы ли они? Есть два способа:

- составить всевозможные пары из событий и проверить их независимость — то есть проверить *попарную независимость*;
- ввести аналог независимости для наборов с произвольным конечным числом событий — то есть проверить *независимость в совокупности*.

События $A_1, A_2, \ldots$ называются **независимыми в совокупности**, если для любого $n \in \mathbb{N}$ и любых попарно различных $i_1, \ldots, i_n$

выполнено:

$$\mathrm{P}(A_{i_1} \dots A_{i_n}) = \mathrm{P}(A_{i_1}) \dots \mathrm{P}(A_{i_n}).$$

Понятно, что из независимости в совокупности следует попарная. Как показывает следующий пример, обратное не всегда верно.

Пример 3.3.9. Вершины тетраэдра (треугольной пирамиды) покрашены в три цвета: красный, синий и зелёный. Четвёртая вершина трёхцветная. Тетраэдр подбрасывают и смотрят, какой вершиной он упал наверх; все вершины равновероятны. Рассмотрим события R, G, B: тетраэдр упал красной, зелёной или синей вершиной соответственно. Являются ли эти события независимыми попарно и в совокупности?

Так как события равновероятны,

$$\mathrm{P}(R) = \mathrm{P}(G) = \mathrm{P}(B) = \frac{1}{2}$$

и

$$\mathrm{P}(RG) = \mathrm{P}(RB) = \mathrm{P}(GB) = \mathrm{P}(RGB) = \frac{1}{4},$$

так что события независимы попарно, но не в совокупности.

Пример 3.3.10. Пусть $\mathrm{P}(ABC) = \mathrm{P}(A)\mathrm{P}(B)\mathrm{P}(C)$. Являются ли события независимыми
в совокупности?

Оказывается, не всегда. Например, в классической модели определим:

$$\Omega = \{1, \dots, 8\}, \quad A = \{1, 2, 3, 4\},$$
$$B = \{1, 2, 5, 6\}, \quad C = \{1, 6, 7, 8\}.$$

Тогда вероятности всех трёх событий равны $\frac{1}{2}$, но
$\mathrm{P}(ABC) = \mathrm{P}(AC) = \frac{1}{8}$.

Поэтому для проверки независимости в совокупности необходимо проверять независимость всех комбинаций событий.

Оказывается, мы уже встречались с независимостью в совокупности: когда обсуждали схему испытаний Бернулли.

Следующая теорема показывает, что модель действительно описывает независимые броски.

ТЕОРЕМА 3.3.4

Пусть $\Omega = \{0,1\}^n$ задаёт схему испытаний Бернулли с вероятностью успеха p. Тогда для любых $a_1, \dots, a_n \in \{0, 1\}$ события $\{\omega_1 = a_1\}, \dots, \{\omega_n = a_n\}$ независимы в совокупности.

Доказательство. Рассмотрим некоторый поднабор этих событий: зафиксируем произвольные номера $1 \leqslant i_1 < \dots < i_m \leqslant n$. Заметим, что событие $\{\omega_{i_1} = a_{i_1}, \dots, \omega_{i_m} = a_{i_m}\}$ состоит из 2^{n-m} элементарных исходов, в которых m координат определены, а оставшиеся $(n - m)$ координат исхода ω могут варьироваться. Обозначим через k количество единиц в наборе

$a_{i_1}, \ldots, a_{i_m}$. Посчитаем вероятность события по определению:

$$\begin{aligned}
&\mathrm{P}\{\omega_{i_1} = a_{i_1}, \ldots, \omega_{i_m} = a_{i_m}\} = \\
&= \sum_{a_{j_1}, \ldots, a_{j_{n-m}}} \mathrm{P}\{\omega_{i_1} = a_{i_1}, \ldots, \omega_{i_m} = a_{i_m}, \omega_{j_1} = a_{j_1}, \ldots, \omega_{j_{n-m}} = a_{j_{n-m}}\} = \\
&= \sum_{a_{j_1}, \ldots, a_{j_{n-m}}} p^{k+\sum_{i=1}^{n-m} \omega_{j_i}} (1-p)^{m-k+(n-m)-\sum_{i=1}^{n-m} \omega_{j_i}} = \\
&= p^k (1-p)^{m-k} \sum_{j=0}^{n-m} C_{n-m}^j p^j (1-p)^{n-m-j} = p^k (1-p)^{m-k},
\end{aligned}$$

то есть вероятность не зависит от остальных бросков монеты. В частности,

$$\mathrm{P}\{\omega_\ell = a_\ell\} = p^{a_\ell}(1-p)^{1-a_\ell}.$$

Тогда

$$\mathrm{P}\{\omega_{i_1} = a_{i_1}\} \cdot \ldots \cdot \mathrm{P}\{\omega_{i_m} = a_{i_m}\} = p^k (1-p)^{m-k},$$

что заканчивает доказательство. □

4. СОВМЕСТНЫЕ РАСПРЕДЕЛЕНИЯ

Если у нас имеются несколько случайных величин, то хочется исследовать их не по отдельности, а вместе. Иными словами, если имеются случайные величины $\xi_1, \ldots, \xi_n$, то можно составить из них **случайный вектор** $\boldsymbol{\xi} = (\xi_1, \ldots, \xi_n) \colon \Omega \to \mathbb{R}^n$.

Можно сказать иначе: отображение $\boldsymbol{\xi} \colon \Omega \to \mathbb{R}^n$ называется случайным вектором, если оно $\mathcal{F}|\mathcal{B}(\mathbb{R}^n)$ измеримо.

Как и в случае со случайными величинами, **распределением** случайного вектора $\boldsymbol{\xi}$ называется вероятностная мера $\mathrm{P}_{\boldsymbol{\xi}}$, заданная на борелевской σ-алгебре $\mathcal{B}(\mathbb{R}^n)$ как

$$\mathrm{P}_{\boldsymbol{\xi}}(B) := \mathrm{P}\{\boldsymbol{\xi} \in B\}.$$

Пример 3.4.1. Пусть $\Omega = \{1,2,3,4,5,6\}$ задаёт броски честного игрального кубика. Зададим ξ_1 как остаток при делении броска на 2, а ξ_2 как остаток при делении броска на 3. Тогда можно задать совместное распределение вектора (ξ_1, ξ_2) таблицей вероятностей

$\xi_1 \backslash \xi_2$	0	1	2
0	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$
1	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$

Иными словами, получилось равномерное распределение на множестве $\{0,1\} \times \{0,1,2\}$.

Аналогично одномерному случаю, для случайного вектора $\boldsymbol{\xi}\colon \Omega \to \mathbb{R}^n$ можно ввести понятие **многомерной функции распределения** как

$$F\colon \mathbb{R}^n \to [0,1], \qquad F(x_1,\dots,x_n) := \mathrm{P}\{\xi_1 \leqslant x_1,\dots,\xi_n \leqslant x_n\}.$$

Обратно, по многомерной функции распределения можно единственным образом задать вероятностную меру на борелевской σ-алгебре $\mathcal{B}(\mathbb{R}^n)$.

ТЕОРЕМА 3.4.1

Чтобы функция $F\colon \mathbb{R}^n \to [0,1]$ являлась чьей-то функцией распределения, необходимо и достаточно, чтобы она обладала следующими свойствами:

1. $\lim\limits_{\exists i: x_i \to -\infty} F(\boldsymbol{x}) = 0$ и $\lim\limits_{\forall i: x_i \to +\infty} F(\boldsymbol{x}) = 1$,
2. F непрерывна сверху,
3. вероятностная мера, построенная по F, неотрицательна на прямоугольниках.

Пример 3.4.2. Поясним последнее свойство на примере для $n = 2$. Вероятность прямоугольника $(a,b] \times (c,d]$ находится по формуле включений-исключений

$$\mathrm{P}\big((a,b] \times (c,d]\big) = F(b,d) - F(b,c) - F(a,d) + F(a,c).$$

Пример 3.4.3. Если заменить последнее свойство просто на монотонность, то функция F может и не быть функцией распределения, даже если она удовлетворяет двум другим свойствам. Например, пусть

$$F(x,y) = \mathcal{I}\{xy \geqslant 1\}.$$

Тогда, очевидно, выполнены свойства про пределы, и F непрерывна сверху. Но при этом

$$\begin{aligned}\mathrm{P}\big((1/2,2] \times (1/2,2]\big) = \\ = F(2,2) - F(2,1/2) - F(1/2,2) + F(1/2,1/2) = \\ = 1 - 1 - 1 + 0 = -1.\end{aligned}$$

В дискретном случае, случайные величины $\xi_1,\dots,\xi_n$ называются **независимыми** (попарно или в совокупности), если для любых $x_1,\dots,x_n \in \mathbb{R}$ события $\{\xi_1 = x_1\},\dots\{\xi_n = x_n\}$ независимы в том же смысле.

Пример 3.4.4. В схеме испытаний Бернулли, случайные величины $\xi_i\colon \omega \mapsto \omega_i$ независимы в совокупности, что элементарно следует из теоремы 3.3.4.

В общем случае, случайные величины $\xi_1,\dots,\xi_n$ **независимы** (попарно или в совокупности), если для любых $B_1,\dots,B_n \in \mathcal{B}(\mathbb{R})$ события $\{\xi_1 \in B_1\},\dots\{\xi_n \in B_n\}$ независимы в том же смысле. В силу произвольности выбора борелевских множеств,

можно дать и эквивалентное определение: случайные величины $\xi_1, \dots, \xi_n$ независимы в совокупности, если для любых $B_1, \dots, B_n \in \mathcal{B}(\mathbb{R})$ выполнено

$$\mathrm{P}\{\xi_1 \in B_1, \dots \xi_n \in B_n\} = \mathrm{P}\{\xi_1 \in B_1\} \cdot \ldots \cdot \mathrm{P}\{\xi_n \in B_n\}.$$

ТЕОРЕМА 3.4.2

Случайные величины $\xi_1, \dots, \xi_n$ независимы в совокупности тогда и только тогда, когда для любых $x_1, \dots, x_n \in \mathbb{R}$ выполнено

$$F_{\xi_1, \dots, \xi_n}(x_1, \dots, x_n) = F_{\xi_1}(x_1) \cdot \ldots \cdot F_{\xi_n}(x_n).$$

Говорят, что функция **факторизуется** (распадается на произведение множителей, факторов).

Доказательство. В одну сторону теорема тривиальна, так что нужно её доказать только в сложную сторону. Рассмотрим вероятностную меру, заданную как

$$\mathrm{P}(B_1 \times \ldots \times B_n) := \mathrm{P}\{\xi_1 \in B_1\} \cdot \ldots \cdot \mathrm{P}\{\xi_n \in B_n\}.$$

Она задаёт распределение независимых случайных величин. Кроме того, она удовлетворяет равенству

$$\mathrm{P}\big((-\infty, x_1] \times \ldots \times (-\infty, x_n]\big) = F_{\xi_1}(x_1) \cdot \ldots \cdot F_{\xi_n}(x_n).$$

По теореме Фубини, данное выражение задаёт единственную вероятностную меру на $\mathcal{B}(\mathbb{R}^n)$. Следовательно, вектору случайных величин соответствует именно распределение P, что и означает их независимость. □

Случайный вектор $\boldsymbol{\xi}$ имеет **абсолютно непрерывное распределение**, если существует функция **плотности** $p_{\boldsymbol{\xi}} \colon \mathbb{R}^n \to \mathbb{R}_+$, удовлетворяющая

$$F_{\boldsymbol{\xi}}(x_1, \dots, x_n) = \int_{-\infty}^{x_1} dx_1 \dots \int_{-\infty}^{x_n} dx_n \, p_{\boldsymbol{\xi}}(x_1, \dots, x_n).$$

В таком случае,

$$\frac{\partial^n F}{\partial x_1 \dots \partial x_n} = p.$$

УТВЕРЖДЕНИЕ 3.4.1

сли абсолютно непрерывные величины независимы, то их вектор абсолютно непрерывно распределён, и его плотность факторизуется.

Доказательство. Это совсем просто следует из того, что можно почленно взять частные производные от факторизованной функции распределения. □

Особого внимания заслуживает обратный переход от совместного распределения к одной случайной величине. Пусть имелась плотность $p_{\boldsymbol{\xi}}$ абсолютно непрерывного вектора $\boldsymbol{\xi}$. Тогда **маргинальным распределением** случайной величины ξ_1 называется

её распределение, когда по остальным величинам случайность убирается; **маргинальная плотность** считается по формуле

$$p_{\xi_1}(x_1) := \int \cdots \int_{\mathbb{R}^{n-1}} p_{\boldsymbol{\xi}}(x_1, \ldots, x_n)\, dx_2 \ldots dx_n.$$

Пример 3.4.5. Если случайный вектор составлен из независимых абсолютно непрерывных случайных величин, то их маргинальные распределения и есть их первоначальные распределения.

Пример 3.4.6. Пусть $p(x,y) = x + y$ на квадрате $[0,1]^2$, а вне него случайный вектор (X,Y) не принимает никаких значений. Заметим, что это и правда плотность, так как

$$\int_0^1 dx \int_0^1 dy\,(x+y) = \int_0^1 dx \left(x + \frac{1}{2}\right) = \frac{1}{2} + \frac{1}{2} = 1.$$

Теперь находим маргинальную плотность

$$p_X(x) = \int_0^1 p(x,y)\, dy = \int_0^1 (x+y)\, dy = x + \frac{1}{2}.$$

Собственно, это выражение мы получили в предыдущем выражении под интегралом по иксу. Аналогично,

$$p_Y(y) = y + \frac{1}{2}.$$

Стоит заметить, что величины X, Y оказались зависимыми, так как их плотность не факторизуется.

Аналогично, если вектор составлен из дискретных случайных величин, можно найти **маргинальную функцию вероятности** по формуле

$$\mathrm{P}_{\xi_1}(x_1) := \sum_{x_2,\ldots,x_n} \mathrm{P}_{\boldsymbol{\xi}}(x_1, \ldots, x_n).$$

5. СВЁРТКИ РАСПРЕДЕЛЕНИЙ

Начнём с примера.

Пример 3.5.1. Пусть $\xi \sim \mathrm{Pois}(\alpha)$ и $\eta \sim \mathrm{Pois}(\lambda)$ независимы. Найдём распределение их суммы $\xi + \eta$:

$$\begin{aligned}\mathrm{P}\{\xi + \eta = n\} &= \sum_{k=0}^{n} \mathrm{P}\{\xi = k, \eta = n-k\} = \\ &= \sum_{k=0}^{n} \frac{\alpha^k \lambda^{n-k}}{k!(n-k)!} e^{-\lambda-\alpha} = \frac{1}{n!} e^{-\lambda-\alpha} \sum_{k=0}^{n} \binom{n}{k} \alpha^k \lambda^{n-k} = \\ &= \frac{(\alpha\lambda)^n}{n!} e^{-\lambda-\alpha}.\end{aligned}$$

Таким образом, $\xi + \eta \sim \mathrm{Pois}(\alpha + \lambda)$. Говорят, что распределение Пуассона **аддитивно по параметру**.

То, что мы с вами получили, называется **формулой свёртки**.

В общем виде для дискретных распределений она выглядит так:

ТЕОРЕМА 3.5.1

Пусть дискретные величины ξ, η независимы. Тогда

$$\mathrm{P}\{\xi + \eta = n\} = \sum_k \mathrm{P}\{\xi = n - k\}\mathrm{P}\{\eta = k\},$$
$$\mathrm{P}\{\xi - \eta = n\} = \sum_k \mathrm{P}\{\xi = n + k\}\mathrm{P}\{\eta = k\},$$
$$\mathrm{P}\{\xi\eta = n\} = \sum_k \mathrm{P}\{\xi = n/k\}\mathrm{P}\{\eta = k\},$$
$$\mathrm{P}\{\xi/\eta = n\} = \sum_k \mathrm{P}\{\xi = nk\}\mathrm{P}\{\eta = k\}.$$

Доказательство полностью повторяет пример выше. Стоит отметить, что аргументы в распределениях подобраны так, чтобы в сумме/разности/произведении/частном получалось ровно n. Это главный принцип.

В общем виде, формула свёртки выглядит несколько иначе.

ТЕОРЕМА 3.5.2

Пусть случайные величины ξ, η независимы. Тогда

$$F_{\xi+\eta}(x) = \int F_\xi(x - y)\, dF_\eta(y).$$

Доказательство. По теореме Фубини,

$$F_{\xi+\eta}(x) = \mathrm{P}\{\xi + \eta \leqslant x\} = \int_{y\in\mathbb{R}} dF_\eta(y) \int_{z\leqslant x-y} dF_\xi(z) = \\ = \int F_\xi(x - y)\, dF_\eta(y).$$

□

Вообще говоря, для двух вероятностных мер μ, ν на борелевской σ-алгебре, их **свёрткой** $\mu * \nu$ называется образ продакт-меры $\mu \otimes \nu$ при сложении; то есть,

$$\mu * \nu(B) := \mu \otimes \nu(f^{-1}(B)),$$

где $f\colon (x, y) \mapsto x + y$, и $B \in \mathcal{B}(\mathbb{R})$. Иными словами,

$$\mu * \nu(B) = \iint \mathcal{I}_B(x + y)\, d\mu(x) d\nu(y) = \\ = \int \mu(B - y)\, d\nu(y) = \int \nu(B - y)\, d\mu(y),$$

где последние два равенства следуют по теореме Фубини.

Таким образом, для независимых случайных величин ξ, η выпол-

нено

$$\mathrm{P}_{\xi+\eta} = \mathrm{P}_\xi * \mathrm{P}_\eta,$$

что и обосновывает название *формулы свёртки*.

ТЕОРЕМА 3.5.3

Для абсолютно непрерывных независимых случайных величин ξ, η выполнено

$$\begin{aligned} p_{\xi+\eta}(x) &= \int_{\mathbb{R}} p_\xi(x-y)p_\eta(y)\,dy, \\ p_{\xi-\eta}(x) &= \int_{\mathbb{R}} p_\xi(x+y)p_\eta(y)\,dy, \\ p_{\xi\eta}(x) &= \int_{\mathbb{R}} \frac{1}{|y|}p_\xi(x/y)p_\eta(y)\,dy, \\ p_{\xi/\eta}(x) &= \int_{\mathbb{R}} |y|p_\xi(xy)p_\eta(y)\,dy. \end{aligned}$$

Доказательство. Первое равенство следует из теоремы 3.5.2 дифференцированием по x. Второе равенство следует из первого благодаря

$$p_\eta(y) = p_{-\eta}(-y).$$

Третье и четвёртое равенство доказываются аналогично, но нужно вытащить якобиан замены переменных:

$$\begin{aligned} F_{\xi\eta}(z) &= \int_{y=-\infty}^{0} p_\eta(y)\,dy \int_{v=z/y}^{+\infty} p_\xi(v)\,dv + \\ &+ \int_{y=0}^{+\infty} p_\eta(y)\,du \int_{v=-\infty}^{z/y} p_\xi(v)\,dv = \left|\begin{matrix} x = yv \\ dv = dx/y \end{matrix}\right| = \\ &= \int_{y=-\infty}^{0} p_\eta(y)\,dy \int_{x=-\infty}^{z} p_\xi(x/y)\frac{1}{|y|}\,dx + \\ &+ \int_{y=0}^{+\infty} p_\eta(y)\,dy \int_{x=-\infty}^{z} p_\xi(x/y)\frac{1}{|y|}\,dx = \\ &= \int_{x=-\infty}^{z} dx \int_{y=-\infty}^{+\infty} p_\eta(y)p_\xi(x/y)\frac{1}{|y|}\,dy. \end{aligned}$$

Остаётся заметить, что под внешним интегралом как раз стоит плотность, по определению. □

Пример 3.5.2. Пусть $\xi, \eta \sim \mathrm{Exp}(\alpha)$ независимы. Найдём распределение суммы. По формуле свёртки, при $x > 0$ имеем

$$\begin{aligned} p_{\xi+\eta}(x) = \int p_\xi(x-y)p_\eta(y)\,dy &= \int_{y=0}^{x} \alpha^2 e^{-\alpha y}e^{-\alpha(x-y)}\,dy = \\ &= \alpha^2 e^{-\alpha x}\int_{y=0}^{x} dy = \alpha^2 x e^{-\alpha x}, \end{aligned}$$

то есть $\xi + \eta \sim \Gamma(2, \alpha)$.

Пример 3.5.3. Пусть $\xi \sim N(a, \sigma^2)$ и $\eta \sim N(b, \tau^2)$ независимы. Найдём распределение суммы $\xi + \eta$. Для начала заметим, что a и b являются просто сдвигом, поэтому их можно прибавить в конце, а пока считать их равными нулю. Тогда по формуле свёртки,

$$p_{\xi+\eta}(x) = \int p_\xi(y) p_\eta(x-y)\, dy = \int \frac{1}{2\pi\sigma\tau} e^{-\frac{y^2}{2\sigma^2} - \frac{(x-y)^2}{2\tau^2}}\, dy.$$

Заметим, что если в экспоненте довести выражение до полного квадрата вида $-\dfrac{(y-cx)^2}{2\lambda^2} dx^2$, то весь интеграл, с точностью до констант, будет равен e^{dx^2}. Но это в точности плотность нормальной случайной величины! Следовательно, $\xi + \eta$ имеет нормальное распределение. Кроме того, в силу линейности матожидания,

$$\mathrm{E}(\xi + \eta) = \mathrm{E}\xi + \mathrm{E}\eta = a + b,$$

и в силу аддитивности дисперсии для независимых случайных величин,

$$\mathrm{Var}(\xi + \eta) = \mathrm{Var}\,\xi + \mathrm{Var}\,\eta = \sigma^2 + \tau^2,$$

откуда

$$\xi + \eta \sim N(a + b, \sigma^2 + \tau^2).$$

В последнем примере мы нагло воспользовались свойствами математического ожидания и дисперсии, которые мы пока не изучали. Сейчас мы к ним и переходим.

6. МАТЕМАТИЧЕСКОЕ ОЖИДАНИЕ

Вспомним нашу модель: вероятность является идеализированным понятием частоты, а случайная величина является интерпретацией результатов эксперимента. Если мы проведём эксперимент много раз, логично предположить, что среднее значение интерпретации будет равно среднему взвешенному по всем интерпретациям с весами, равными частоте одного исхода.

Поясним определение на дискретном вероятностном пространстве. Вот мы поставили N экспериментов с исходами $\xi_1, \ldots, \xi_k$, и эти исходы произошли, соответственно, $n_1, \ldots, n_k$ раз. Тогда частота i-го эксперимента равна n_i/N, а среднее взвешенное равно

$$\xi_1 \frac{n_1}{N} + \ldots + \xi_k \frac{n_k}{N}.$$

Переходя от частот к вероятностям, для дискретной случайной величины находим среднее взвешенное

$$\mathrm{E}\xi := \sum_{\omega \in \Omega} \xi(\omega)\mathrm{P}(\omega) \in \mathbb{R} \cup \{+\infty, -\infty\},$$

которое и называется **математическим ожиданием** (обозначение происходит от английского expected value или expectation; в

русской литературе иногда обозначается как $M\xi$). Чтобы математическое ожидание было конечным, ряд должен сходиться абсолютно. В противном случае рассматривают отдельно положительные и отрицательные слагаемые, и если сходится ровно один из рядов, то полагают $\mathrm{E}\xi = \pm\infty$, где знак берётся как у расходящегося ряда.

Пример 3.6.1. Пусть $\Omega = \{0, 1\}$ с вероятностями $\mathrm{P}\{1\} = p$ и $\mathrm{P}\{0\} = 1 - p$. Эксперимент интерпретируется тривиально $\xi(\omega) = \omega$. Иными словами, подбрасывается монетка, и смотрится на результат. Математическое ожидание, таким образом, должно показать, среднее количество единичек, которые будут выпадать при достаточно большом количестве подбрасываний. Формально, так и получается:

$$\mathrm{E}\xi = 0 \cdot (1 - p) + 1 \cdot p = p.$$

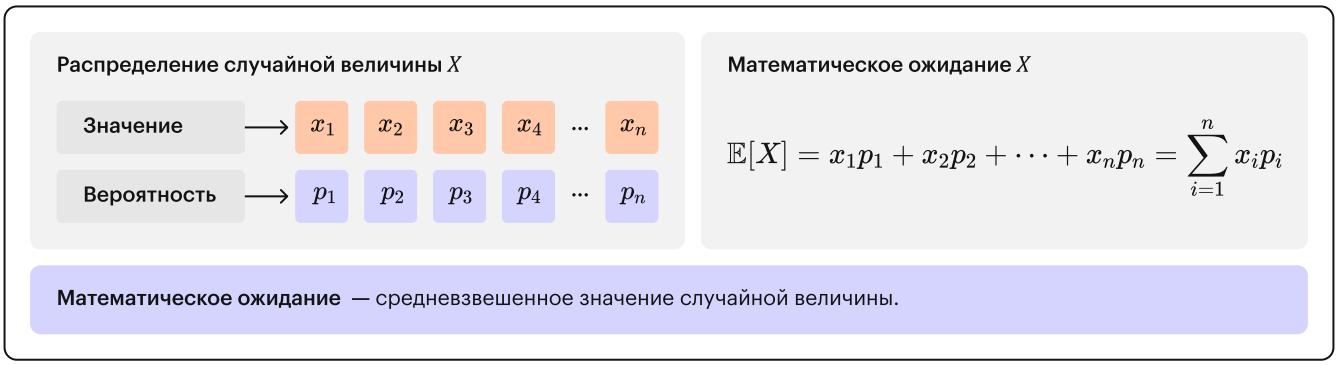

Рисунок 14. Связь среднего взвешенного и математического ожидания

В общем случае, **математическим ожиданием** случайной величины $\xi\colon \Omega \to \mathbb{R}$ называется интеграл Лебега

$$\mathrm{E}\xi := \int \xi(\omega)\, d\mathrm{P}(\omega) \in \mathbb{R} \cup \{+\infty, -\infty\}$$

Знак плюс или минус бесконечности выбирается в случае, если у ξ интегрируема только отрицательная или положительная часть, соответственно; если же обе не интегрируемы, то говорят, что математическое ожидание не определено.

Обычно случайные величины задаются не как функции на Ω, а своими распределениями. Как говорит следующая теорема, математическое ожидание — это именно функционал от распределения.

ТЕОРЕМА 3.6.1

Пусть $\xi\colon \Omega \to \mathbb{R}$ случайная величина, а борелевская функция $f\colon \mathbb{R} \to \mathbb{R}$ такова, что существует математическое ожидание случайной величины $f(\xi)$. Тогда

$$\mathrm{E}f(\xi) = \int f(x)\, d\mathrm{P}_\xi(x).$$

Доказательство. Следует напрямую из теоремы о замене переменных в интеграле Лебега. □

Для дискретной случайной величины ξ,

$$\mathrm{E}f(\xi) = \sum_x f(x)\mathrm{P}\{\xi = x\}.$$

Для абсолютно непрерывной случайной величины ξ,

$$\mathrm{E}f(\xi) = \int f(x)p_\xi(x)\,dx.$$

Доказательство. Для дискретной меры интеграл это буквально сумма. Для абсолютно непрерывной меры равенство следует из определения плотности. □

Как мы увидим в примерах ниже, общий принцип расчёта математических ожиданий: сводить сложные ряды и интегралы к известным плотностям и распределениям.

Пример 3.6.2. Пусть $\xi \sim N(a, \sigma^2)$. Тогда находим

$$\begin{aligned}\mathrm{E}\xi = \int x p_\xi(x)\,dx &= \int x \frac{1}{\sqrt{2\pi\sigma^2}} e^{-(x-a)^2/2}\,dx = \\ &= \int (y+a)\frac{1}{\sqrt{2\pi\sigma^2}} e^{-y^2/2}\,dy = \\ &= \underbrace{\int y \frac{1}{\sqrt{2\pi\sigma^2}} e^{-y^2/2}\,dy}_{=0} + a \cdot \underbrace{\int \frac{1}{\sqrt{2\pi\sigma^2}} e^{-y^2/2}\,dy}_{=1} = a.\end{aligned}$$

Пример 3.6.3. Пусть $\xi \sim \mathrm{Bern}(p)$. Тогда

$$\mathrm{E}\xi = 0 \cdot (1-p) + 1 \cdot = p.$$

Этот пример отличается от примера 3.6.1 тем, что здесь может быть довольно сложное вероятностное пространство, на котором мы задали случайную величину, и она чудесным образом имеет такое простое бернуллиевское распределение.

Пример 3.6.4. Пусть $\xi \sim \mathrm{Pois}(\lambda)$. Тогда

$$\mathrm{E}\xi = \sum_{n=0}^{+\infty} n \frac{\lambda^n}{n!} e^{-\lambda} = \lambda \underbrace{\sum_{n=1}^{+\infty} \frac{\lambda^{n-1}}{(n-1)!} e^{-\lambda}}_{=1} = \lambda.$$

Пример 3.6.5. Пусть $\xi \sim \mathrm{Geom}(p)$. Тогда

$$\mathrm{E}\xi = \sum_{n=0}^{+\infty} np(1-p)^n = \\ = (1-p)\underbrace{\sum_{n=1}^{+\infty} p(1-p)^{n-1}}_{=1} + (1-p)\underbrace{\sum_{n=1}^{+\infty}(n-1)p(1-p)^{n-1}}_{=\mathrm{E}\xi}.$$

Отсюда $p\mathrm{E}\xi = 1-p$, и окончательно

$$\mathrm{E}\xi = \frac{1-p}{p}.$$

Здесь легко себя проверить: вспомним, что в этой модели p отвечает за вероятность успеха в схеме испытаний Бернулли, а ξ равна количеству неудач до первого успеха. Тогда при $p > \frac{1}{2}$ получаем $\mathrm{E}\xi < 1$, то есть при большой вероятности успеха среднее количество неудач мало; и наоборот, при $p < \frac{1}{2}$ получаем $\mathrm{E}\xi > 1$, то есть среднее количество неудач велико.

Пример 3.6.6. Пусть $\xi \sim \mathrm{Exp}(\lambda)$. Тогда

$$\mathrm{E}\xi = \int_0^\infty x\lambda e^{-\lambda x}\,dx = -\int_0^\infty x\,de^{-\lambda x} = \\ = 0 + \int_0^\infty e^{-\lambda x}\,dx = \frac{1}{-\lambda}(0-1) = \frac{1}{\lambda}.$$

Для других расчётов могут понадобится следующие формулы.

УТВЕРЖДЕНИЕ 3.6.1

атематическое ожидание линейно. То есть, если оно конечно для ξ и η, то конечно и

$$\mathrm{E}(a\xi + b\eta) = a\mathrm{E}\xi + b\mathrm{E}\eta$$

для любых $a, b \in \mathbb{R}$.

Доказательство. Вообще, это свойство интеграла Лебега. На дискретном вероятностном пространстве это легко доказывается через сходимости рядов:

$$\mathrm{E}(a\xi + b\eta) = \sum_{\omega\in\Omega}(a\xi(\omega) + b\eta(\omega))\mathrm{P}(\omega) = \\ = a\sum_{\omega\in\Omega}\xi(\omega)\mathrm{P}(\omega) + b\sum_{\omega\in\Omega}\eta(\omega)\mathrm{P}(\omega) = a\mathrm{E}\xi + b\mathrm{E}\eta$$

□

Обратите внимание, что в предыдущем утверждении не требовалась независимость случайных величин!

Пример 3.6.7. Пусть $\xi \sim \mathrm{Bin}(n,p)$. Тогда можно считать, что $\xi \stackrel{d}{=} \sum_{i=1}^n \xi_i$, где $\xi_i \sim \mathrm{Bern}(p)$ независимы в совокупности (хотя для

вывода матожидания эта независимость и не нужна). Отсюда

$$\mathrm{E}\xi = \sum_{i=1}^{n} \mathrm{E}\xi_i = np.$$

атематическое ожидание монотонно. То есть, если $\xi \leqslant \eta$ п.н., то $\mathrm{E}\xi \leqslant \mathrm{E}\eta$.

УТВЕРЖДЕНИЕ 3.6.2

Доказательство. Тоже свойство интеграла Лебега. На дискретном пространстве снова легко следует из

$$\mathrm{E}\xi = \sum_{\omega\in\Omega} \xi(\omega)\mathrm{P}(\omega) \leqslant \sum_{\omega\in\Omega} \eta(\omega)\mathrm{P}(\omega) = \mathrm{E}\eta.$$

□

ля любой случайной величины выполнено

$$|\mathrm{E}\xi| \leqslant \mathrm{E}\,|\xi|\,.$$

УТВЕРЖДЕНИЕ 3.6.3

Доказательство. Следует из предыдущего утверждения и цепочки неравенств $-|\xi| \leqslant \xi \leqslant |\xi|$. □

Пусть случайные величины $\xi_1, \ldots, \xi_n$ независимы в совокупности. Тогда

$$\mathrm{E}\xi_1 \ldots \xi_n = \mathrm{E}\xi_1 \ldots \mathrm{E}\xi_n.$$

ТЕОРЕМА 3.6.2

Доказательство. Теорему достаточно доказать для двух случайных величин. Пусть величины ξ, η независимы; нужно доказать, что $\mathrm{E}\xi\eta = \mathrm{E}\xi\mathrm{E}\eta$.

Если эти величины индикаторы $\xi = \mathcal{I}_A$ и $\eta = \mathcal{I}_B$, то

$$\mathrm{E}\xi\eta = \mathrm{E}\mathcal{I}_{A\cap B} = \mathrm{P}(A \cap B) = \mathrm{P}(A)\mathrm{P}(B) = \mathrm{E}\xi\mathrm{E}\eta.$$

Далее по линейности получаем, что для простых величин $\xi = \sum \xi_i$ и $\eta = \sum \eta_j$, где все ξ_i попарно независимы с η_i, и представляют собой взвешенные индикаторы, выполнено

$$\mathrm{E}\xi\eta = \sum_{i,j} \mathrm{E}\xi_i\eta_j = \sum_{i,j} \mathrm{E}\xi_i\mathrm{E}\eta_j = \mathrm{E}\xi\mathrm{E}\eta.$$

Наконец, пусть ξ, η произвольные случайные величины. Опять же, по линейности достаточно разложить их на положительную и отрицательную части $\xi = \xi^+ - \xi^-$ и $\eta = \eta^+ - \eta^-$, так что будем считать, что обе величины неотрицательные. Тогда возьмём последовательность простых величин $\xi_n \geqslant 0$, которые возрастают снизу к ξ, и аналогично с η_n. Тогда величины $\xi_n\eta_n \geqslant 0$ монотонно возрастают к случайной величине $\xi\eta$. Отсюда, по тео-

реме Леве о монотонной сходимости,

$$\mathrm{E}\xi\eta = \lim_{n\to\infty} \mathrm{E}\xi_n\eta_n = \lim_{n\to\infty} \mathrm{E}\xi_n \mathrm{E}\eta_n = \mathrm{E}\xi\mathrm{E}\eta.$$

□

7. ДИСПЕРСИЯ, СТАНДАРТНОЕ ОТКЛОНЕНИЕ И КОВАРИАЦИЯ

Важной мерой случайной величины является ***дисперсия***, или мера разброса её значений. Дисперсия определяется как

$$\operatorname{Var}\xi := \mathrm{E}(\xi - \mathrm{E}\xi)^2 \in \mathbb{R}_{\geqslant 0}.$$

(от английского variance). В русской литературе часто обозначается $\mathbb{D}\xi$.

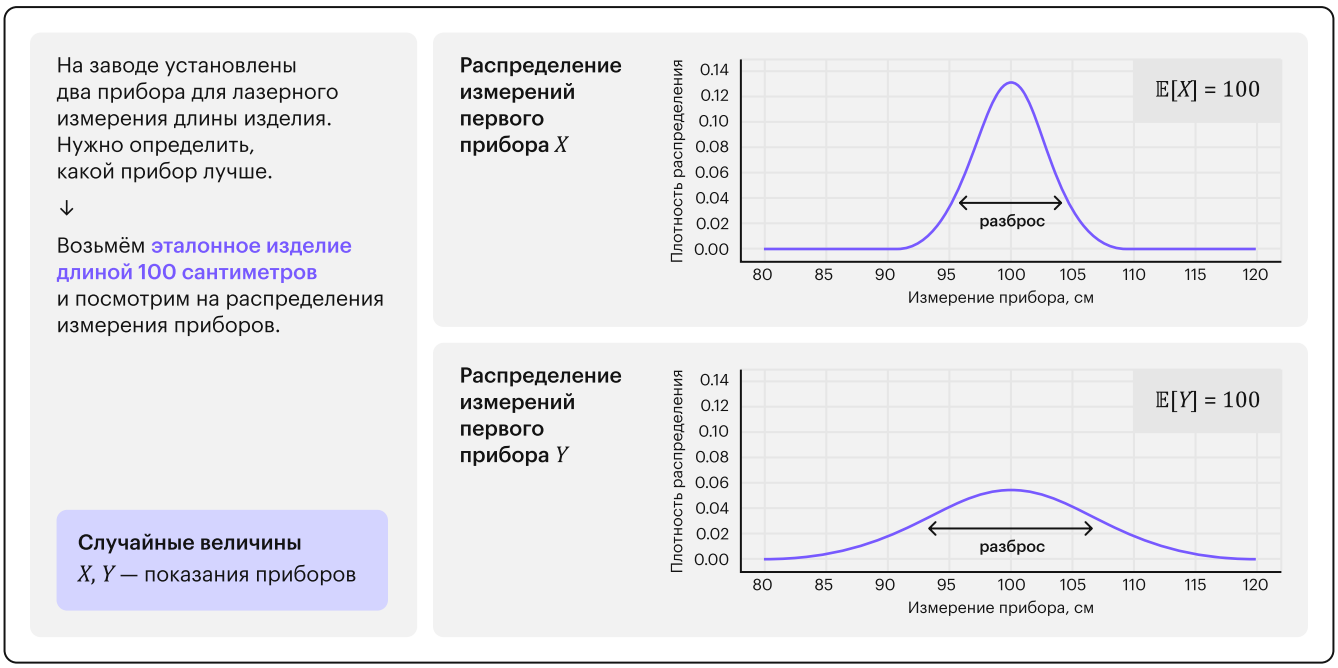

Рисунок 15. Физический смысл дисперсии

УТВЕРЖДЕНИЕ 3.7.1

Пусть у случайной величины ξ определена дисперсия. Тогда

(i) $\operatorname{Var}\xi = \mathrm{E}\xi^2 - (\mathrm{E}\xi)^2$;
(ii) $\operatorname{Var}(c\xi) = c^2 \operatorname{Var}\xi$ для $c \in \mathbb{R}$;
(iii) $\operatorname{Var}\xi = 0$ равносильно тому, что ξ — константа с вероятностью 1.

Доказательство. Первое следует по линейности матожидания, ибо

$$\begin{aligned}\operatorname{Var}\xi = \mathrm{E}(\xi - \mathrm{E}\xi)^2 = \mathrm{E}(\xi^2 - 2\xi\mathrm{E}\xi + (\mathrm{E}\xi)^2) = \\ = \mathrm{E}\xi^2 - 2(\mathrm{E}\xi)^2 + (\mathrm{E}\xi)^2 = \mathrm{E}\xi^2 - (\mathrm{E}\xi)^2.\end{aligned}$$

Второе тоже следует по линейности матожидания, так как

$$\operatorname{Var}(c\xi) = \mathrm{E}(c(\xi - \mathrm{E}\xi))^2 = c^2 \operatorname{Var}\xi.$$

Третье свойство доказывается следующим образом. Понятно, что

$$\operatorname{Var} c = \mathrm{E}(c - c)^2 = \mathrm{E}0 = 0.$$

Обратно, пусть $\operatorname{Var}\xi = 0$. Тогда $\mathrm{E}(\xi - \mathrm{E}\xi)^2 = 0$, откуда следует, что $\xi - \mathrm{E}\xi = 0$ с вероятностью 1. □

Пример 3.7.1. Пусть $\xi \sim \mathrm{Bern}(p)$. Тогда $\mathrm{E}\xi^2 = \mathrm{E}\xi = p$, и

$$\operatorname{Var}\xi = \mathrm{E}\xi^2 - (\mathrm{E}\xi)^2 = p - p^2 = p(1-p).$$

Пример 3.7.2. Пусть $\xi \sim N(a, \sigma^2)$. Тогда $\operatorname{Var}\xi = \sigma^2 \operatorname{Var}\eta$, где $\eta \sim N(0,1)$. Остаётся найти

$$\operatorname{Var}\eta = \mathrm{E}\eta^2 = \int_{\mathbb{R}} x^2 \frac{1}{\sqrt{2\pi}} e^{-x^2/2}\,dx = \\ = \int_0^\infty y \frac{2}{\sqrt{2\pi}} e^{-y/2}\,d\sqrt{y} = \int_0^\infty \underbrace{\sqrt{y}\frac{1}{\sqrt{2\pi}} e^{-y/2}}_{\text{плотность } \Gamma(\frac{3}{2}, \frac{1}{2})}\,dy = 1.$$

Отсюда $\operatorname{Var}\xi = \sigma^2$.

Пример 3.7.3. Пусть $\xi \sim \mathrm{Pois}(\lambda)$. Тогда

$$\mathrm{E}\xi^2 = \sum_{n=0}^\infty n^2 \frac{\lambda^n}{n!} e^{-\lambda} = \sum_{n=1}^\infty (n-1+1)\frac{\lambda^n}{(n-1)!} e^{-\lambda} = \\ = \lambda \mathrm{E}\eta + \lambda = \lambda^2 + \lambda.$$

Отсюда

$$\operatorname{Var}\xi = \mathrm{E}\xi^2 - (\mathrm{E}\xi)^2 = \lambda.$$

Хочется получить какой-то численный аналог независимости. Так появляется понятие ***ковариации*** двух случайных величин ξ, η:

$$\operatorname{cov}(\xi, \eta) := \mathrm{E}\big((\xi - \mathrm{E}\xi)(\eta - \mathrm{E}\eta)\big) \in \mathbb{R}$$

(от английского covariance). Нестрого говоря, если величины имеют прямую зависимость, ковариация будет положительной, а если обратную, то отрицательной.

ля случайных величин, у которых определена ковариация,

$$\operatorname{cov}(\xi, \eta) = \mathrm{E}\xi\eta - \mathrm{E}\xi\mathrm{E}\eta.$$

УТВЕРЖДЕНИЕ 3.7.2

формула для расчёта

Доказательство. Из линейности матожидания, как и в формуле

дисперсии,

$$\operatorname{cov}(\xi,\eta) = \mathrm{E}(\xi\eta - \xi\mathrm{E}\eta - \eta\mathrm{E}\xi + \mathrm{E}\xi\mathrm{E}\eta) = \\ = \mathrm{E}\xi\eta - 2\mathrm{E}\xi\mathrm{E}\eta + \mathrm{E}\xi\mathrm{E}\eta = \mathrm{E}\xi\eta - \mathrm{E}\xi\mathrm{E}\eta.$$

□

Независимые случайные величины имеют нулевую ковариацию.

УТВЕРЖДЕНИЕ 3.7.3

Доказательство. По мультипликативности матожидания для независимых случайных величин,

$$\operatorname{cov}(\xi,\eta) = \mathrm{E}\xi\eta - \mathrm{E}\xi\mathrm{E}\eta = \mathrm{E}\xi\mathrm{E}\eta - \mathrm{E}\xi\mathrm{E}\eta = 0.$$

□

Пример 3.7.4. Обратное может быть неверно. Пусть $\Omega = \{0, \frac{\pi}{2}, \pi, \frac{3\pi}{4}\}$ с вероятностями исходов $\frac{1}{4}$. Тогда случайные величины $\sin, \cos$ зависимы, поскольку связаны тождеством

$$\sin^2 + \cos^2 = 1.$$

Однако,

$$\operatorname{cov}(\sin,\cos) = \mathrm{E}\sin\cos - \mathrm{E}\sin\mathrm{E}\cos = \\ = \frac{0+0+0+0}{4} - \frac{0+1+0-1}{4} \cdot \frac{1+0-1+0}{4} = 0.$$

Ковариация является симметричной и билинейной.

УТВЕРЖДЕНИЕ 3.7.4

Доказательство. Симметричность очевидна из определения, а билинейность следует из линейности матожидания. □

сегда $\operatorname{cov}(\xi,\xi) = \operatorname{Var}\xi$.

УТВЕРЖДЕНИЕ 3.7.5

Доказательство. По определению,

$$\operatorname{cov}(\xi,\xi) = \mathrm{E}(\xi - \mathrm{E}\xi)^2 = \operatorname{Var}\xi.$$

□

Таким образом, ковариация является аналогом скалярного произведения векторов, а дисперсия — квадрата длины. Аналогия очень удачна: для сонаправленных векторов скалярное произведение положительно, для перпендикулярных равно нулю.

Возможно, в школе на уроках физики вы считали погрешности измерений. Если вы делали это правильно, то при сложении двух измерений погрешность суммы вы считали не как сумму погрешностей, а путём сложения квадратов погрешностей, и затем извлекали обратно корень. Все эти действия обосновывает следующая лемма, если иметь в виду, что дисперсия по сути и задаёт квадрат погрешности.

ЛЕММА 3.7.1

Для величин с попарно нулевой ковариацией дисперсия аддитивна:

$$\operatorname{Var}(\xi_1 + \ldots + \xi_n) = \operatorname{Var}\xi_1 + \ldots + \operatorname{Var}\xi_n.$$

В частности, дисперсия аддитивна для попарно независимых величин.

Доказательство. Это следует из билинейности ковариации:

$$\operatorname{Var}\sum_{i=1}^{n}\xi_i = \operatorname{cov}\left(\sum_{i=1}^{n}\xi_i, \sum_{j=1}^{n}\xi_j\right) =$$
$$= \sum_{i=1}^{n}\operatorname{cov}(\xi_i,\xi_i) + \sum_{i\neq j}\operatorname{cov}(\xi_i,\xi_j) = \sum_{i=1}^{n}\operatorname{Var}\xi_i.$$

□

Пример 3.7.5. Для зависимых величин дисперсия может быть неаддитивна. Например, для случайной величины, не являющейся константой почти наверное,

$$\operatorname{Var}(\xi + \xi) = \operatorname{Var}(2\xi) = 4\operatorname{Var}\xi \neq 2\operatorname{Var}\xi.$$

Пример 3.7.6. Пусть $\xi \sim \operatorname{Bin}(n,p)$. Как мы знаем, можно представить

$$\xi \stackrel{d}{=} \sum_{i=1}^{n}\xi_i,$$

где все $\xi_i \sim \operatorname{Bern}(p)$ независимы. Тогда по лемме 3.7.1,

$$\operatorname{Var}\xi = \sum \operatorname{Var}\xi_i = np(1-p).$$

Допустим, мы получили, что $\operatorname{cov}(\xi,\eta) = 0{,}001$. Понятно, что величины зависимы, но можно ли сказать, что мера зависимости у них очень мала? Другая ситуация: $\operatorname{cov}(\xi,\eta) = 10000$. Можно ли сказать, что величины сильно зависимы? В обоих случаях ответ отрицательный: очевидно, надо посмотреть, насколько большие значения принимают сами случайные величины. Это подводит к такому определению.

Корреляцией (или *коэффициентом корреляции*) двух случайных величин называется

$$\rho(\xi,\eta) := \frac{\operatorname{cov}(\xi,\eta)}{\sqrt{\operatorname{Var}\xi}\sqrt{\operatorname{Var}\eta}}.$$

Величины, имеющие нулевую ковариацию, называют *некоррелированными*.

ТЕОРЕМА 3.7.1

Для величин ξ,η с конечной дисперсией определена и ковариа-

ция, и выполнено

$$|\operatorname{cov}(\xi,\eta)| \leqslant \sqrt{\operatorname{Var}\xi}\sqrt{\operatorname{Var}\eta}.$$

Более того, равенство означает, что величины линейно зависимы с вероятностью 1.

Доказательство. Ковариация определена, поскольку $2\mathrm{E}|\xi\eta| \leqslant \mathrm{E}\xi^2 + \mathrm{E}\eta^2$. Последнюю часть тоже легко получить из похожих соображений, но мы получим её как следствие из более общего утверждения. □

СЛЕДСТВИЕ 3.7.1

Коэффициент корреляции всегда лежит на отрезке $[-1,1]$, причём равенство его ± 1 равносильно тому, что величины линейно зависимы с вероятностью 1.

Таким образом, если ковариация — аналог скалярного произведения, то корреляция — аналог косинуса.

Из случайных величин $\xi_1,\xi_2,\ldots,\xi_n$ можно составить и случайный вектор $\boldsymbol{\xi}\colon \Omega \to \mathbb{R}^n$. В таком случае прямым обобщением ковариации и дисперсии является **матрица ковариаций** $\Sigma \in \mathbb{R}^{n\times n}$ с элементами $\Sigma_{ij} = \operatorname{cov}(\xi_i,\xi_j)$.

ЛЕММА 3.7.2

Матрица ковариаций симметрична и неотрицательно полуопределена. При этом, нарушение свойства положительной определённости равносильно тому, что с вероятностью 1 компоненты вектора $\boldsymbol{\xi}$ линейно зависимы.

Доказательство. Симметричность следует из симметричности ковариации. Рассмотрим произвольный вектор $\boldsymbol{x} \in \mathbb{R}^n$. Тогда по билинейности ковариации

$$\boldsymbol{x}^T\Sigma\boldsymbol{x} = \sum_{i,j} x_i x_j \operatorname{cov}(\xi_i,\xi_j) = \operatorname{cov}\left(\sum_i x_i\xi_i, \sum_j x_j\xi_j\right) = \\ = \operatorname{Var}\boldsymbol{x}^T\boldsymbol{\xi} \geqslant 0.$$

Таким образом, Σ неотрицательно определена. Линейная зависимость равносильна тому, что для некоторого ненулевого вектора $\boldsymbol{x}$ выполнено $\boldsymbol{x}^T\boldsymbol{\xi} = c$. Последнее (с вероятностью 1) равносильно $\operatorname{Var}(\boldsymbol{x}^T\boldsymbol{\xi}) = 0$, что и означает нарушение положительной определённости. □

Размерности		
01 Случайная величина X — количество грузчиков в заказе	⟶	штуки
02 Математическое ожидание $\mathbb{E}[X]$	⟶	штуки
03 Квадрат отклонения $(X - \mathbb{E}[X])^2$	⟶	штуки²
04 Дисперсия $\mathbb{V}[X]$	⟶	штуки²
05 Стандартное отклонение $\sigma = \sqrt{\mathbb{V}[X]}$	⟶	штуки

Стандартное отклонение

Квадратный корень из дисперсии

$$\sigma = \sqrt{\mathbb{E}\left[(X - \mathbb{E}[X])^2\right]}$$

Рисунок 16. Стандартное отклонение на примере размерностей

Отдельного внимания заслуживает **стандартное отклонение**, которое определяется как

$$\sigma := \sqrt{\operatorname{Var} \xi}.$$

Грубо говоря, оно показывает, насколько далеко в среднем отклоняется величина от своего среднего (см. рис. 17).

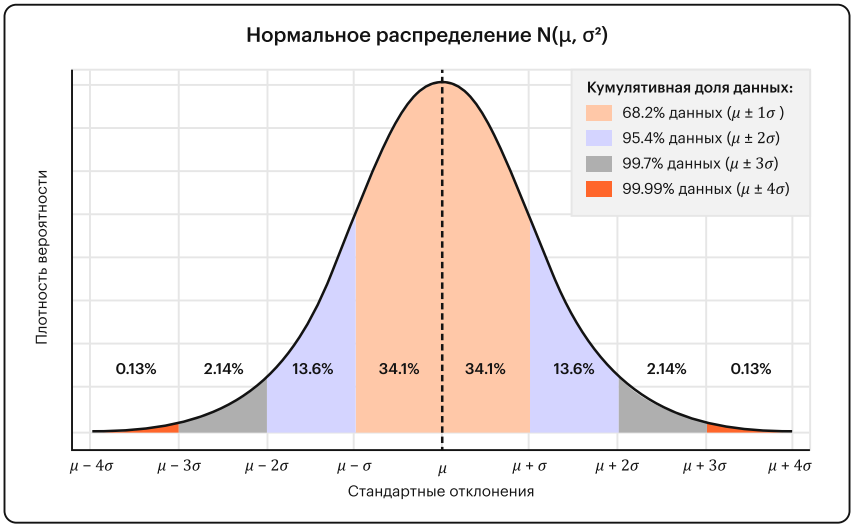

Рисунок 17. Правило трёх сигм

Пример 3.7.7. Рассмотрим величину $\xi \sim N(a, \sigma^2)$. Её стандартное отклонение равно σ. Для нормального распределения известен закон трёх сигм (см. рис. 17):

- с вероятностью $\approx 68\%$ случайная величина ξ попадёт в «ворота» $a \pm \sigma$,
- с вероятностью $\approx 95{,}5\%$ случайная величина ξ попадёт в «ворота» $a \pm 2\sigma$,
- с вероятностью $\approx 99{,}7\%$ случайная величина ξ попадёт в «ворота» $a \pm 3\sigma$.

8. НАЧАЛЬНЫЕ И ЦЕНТРАЛЬНЫЕ МОМЕНТЫ РАСПРЕДЕЛЕНИЙ

Теория предыдущей части обобщается на случай подсчёта математических ожиданий разных степеней случайной величины. Как мы увидим позже, в некоторых случаях распределение случайной величины буквально характеризуется её моментами, так что теоретически они очень важны для работы с распределениями. На практике же обычно не залезают дальше третьего и четвёртого моментов.

Для натурального числа k, **k-м начальным моментом** (иногда слово *начальный* опускают) случайной величины ξ называется

$$\mathrm{E}\xi^k.$$

Пример 3.8.1. Первый момент случайной величины — это просто её математическое ожидание.

Пример 3.8.2. Если у случайной величины определена дисперсия, то её второй момент равен

$$\mathrm{E}\xi^2 = \mathrm{Var}\,\xi + (\mathrm{E}\xi)^2.$$

Если дисперсия не определена или бесконечна, то второй момент равен $+\infty$.

Пример 3.8.3. Для распределения Бернулли все его начальные моменты совпадают с его математическим ожиданием.

Пример 3.8.4. Для $\xi \sim \mathrm{Exp}(1)$, буквально по определению гамма-функции находим k-й начальный момент как

$$\mathrm{E}\xi^k = \int_0^\infty x^k e^{-x}\,dx =: \Gamma(k+1) = k!.$$

В принципе, данную формулу можно доказать и по индукции:

$$\mathrm{E}\xi^k = \int_0^\infty x^k e^{-x}\,dx = -\int_0^\infty x^k\,de^{-x} = \\ = k\int_0^\infty x^{k-1}e^{-x}\,dx = k\cdot(k-1)! = k!.$$

Теперь можно и для $\eta \sim \mathrm{Exp}(\lambda)$ из соображений $\eta \sim \xi/\lambda$ найти

$$\mathrm{E}\eta^k = \frac{k!}{\lambda^k}.$$

Проверяя себя, убеждаемся, что

$$\mathrm{E}\eta = \frac{1}{\lambda}$$

и

$$\mathrm{E}\eta^2 = \operatorname{Var}\eta + (\mathrm{E}\eta)^2 = \frac{1}{\lambda^2} + \frac{1}{\lambda^2} = \frac{2}{\lambda^2}.$$

Как и в случае с дисперсией, иногда нас интересуют не сами моменты, а моменты для центрированной случайной величины. В таком случае, **k-м центральным моментом** случайной величины ξ называется

$$\mathrm{E}(\xi - \mathrm{E}\xi)^k.$$

Пример 3.8.5. Дисперсия случайной величины является её вторым центральным моментом.

Пример 3.8.6. Первый центральный момент всегда равен нулю.

Понятно, что если случайная величина имеет симметричное относительно своего среднего распределение, то считать нечётные центральные моменты бессмысленно. Аналогично происходит, если распределение случайной величины симметрично относительно нуля, а мы хотим посчитать её нечётные начальные моменты. В таком случае нужно считать абсолютное отклонение величины: **k-й абсолютный начальный момент** случайной величины ξ определяется как

$$\mathrm{E}|\xi|^k,$$

а **k-й абсолютный центральный момент** случайной величины ξ определяется как

$$\mathrm{E}|\xi - \mathrm{E}\xi|^k.$$

Очевидно, что для чётных k не имеет значения, считать абсолютный центральный момент или обычный центральный.

Пример 3.8.7. Для $\xi \sim N(a, \sigma^2)$ её абсолютные центральные моменты считаются как

$$\mathrm{E}|\xi - \mathrm{E}\xi|^k = \sigma^k c_k,$$

где

$$c_k = \frac{2^{k/2}\Gamma\left(\frac{k+1}{2}\right)}{\sqrt{\pi}} = \begin{cases} (k-1)!!\sqrt{\frac{2}{\pi}}, & \text{если } k \text{ нечётно}, \\ (k-1)!!, & \text{если } k \text{ чётно}. \end{cases}$$

Чтобы понять это, сперва заметим, что

$$\eta := \frac{(\xi - \mathrm{E}\xi)^2}{\sigma^2} = \frac{(\xi - a)^2}{\sigma^2} \sim \chi^2(1) = \Gamma\left(\frac{1}{2}, \frac{1}{2}\right).$$

Таким образом, нас интересует $\mathrm{E}\eta^{k/2}$. Зная плотность

$$p_\eta(x) = \frac{1}{\sqrt{2\pi x}} e^{-x/2} \mathcal{I}\{x > 0\},$$

находим

$$\mathrm{E}\eta^\alpha = \int_0^\infty \frac{x^\alpha}{\sqrt{2\pi x}} e^{-x/2}\,dx = \\ = \frac{\Gamma(\alpha+1/2)2^{\alpha+1/2}}{\sqrt{2\pi}} \underbrace{\int_0^\infty \frac{x^{\alpha-1/2}}{\Gamma(\alpha+1/2)2^{\alpha+1/2}} e^{-x/2}\,dx}_{=1 \text{ как интеграл плотности } \Gamma(\alpha+\frac{1}{2},\frac{1}{2})} = \\ = \frac{\Gamma(\alpha+1/2)2^\alpha}{\sqrt{\pi}}.$$

В некоторых отдельных случаях удобен **k-й факториальный момент**, который определяется как

$$\mathrm{E}(\xi)_k := \mathrm{E}\big(\xi(\xi-1)\dots(\xi-k+1)\big).$$

Понятно, что первый факториальный момент — это первый начальный момент, то есть просто математическое ожидание.

Пример 3.8.8. Для $\xi \sim \mathrm{Pois}(\lambda)$,

$$\mathrm{E}(\xi)_k = \lambda^k.$$

В самом деле,

$$\mathrm{E}(\xi)_k = \sum_{n=k}^\infty \frac{n!}{(n-k)!}\cdot\frac{\lambda^n}{n!}e^{-\lambda} = \lambda^k \underbrace{\sum_{m=0}^\infty \frac{\lambda^m}{m!}e^{-\lambda}}_{=1} = \lambda^k.$$

9. АСИММЕТРИЯ И ЭКСЦЕСС

Обсуждая моменты, мы поняли, что в зависимости от симметричности или асимметричности распределения, некоторые моменты нужно корректировать (заменять на центральные или абсолютные) в зависимости от наших целей. Чтобы понять, насколько симметричное распределение, вводят так называемый **коэффициент асимметрии** (англ. skewness)

$$\gamma := \frac{\mu_3}{\sigma^3},$$

где в числителе стоит третий центральный момент

$$\mu_3 = \mathrm{E}\,(\xi - \mathrm{E}\xi)^3,$$

а в знаменателе находится куб стандартного отклонения

$$\sigma = \sqrt{\mathrm{Var}\,\xi}.$$

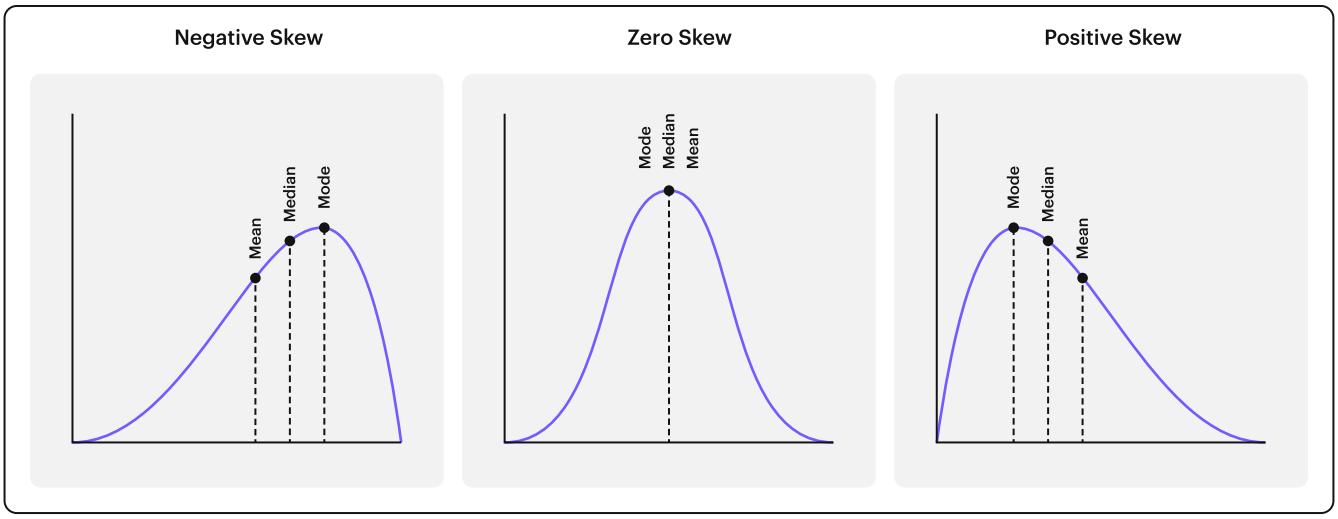

Рисунок 18. Параметр skewness позволяет характеризовать симметрию распределений: насколько самые большие значения находятся дальше от среднего, чем самые маленькие

За сложной формулой скрывается простой принцип:

- $\gamma > 0$ означает перекос вправо, то есть правые хвосты распределения длиннее,
- $\gamma < 0$ означает перекос вправо, то есть левые хвосты распределения длиннее, а
- $\gamma = 0$ означает, что распределение в каком-то смысле симметрично.

Например, для нормального распределения, $\gamma = 0$.

Пример 3.9.1. Если $\gamma = 0$, это ещё не означает, что распределение симметрично. Пусть, например, случайная величина имеет распределение на числах $-3, 2, -1$ с вероятностями

$$\mathrm{P}\{\xi = -3\} = 0.1, \qquad \mathrm{P}\{\xi = 2\} = 0.4, \qquad \mathrm{P}\{\xi = -1\} = 0.5.$$

Тогда

$$\mathrm{E}\xi = -0.3 + 0.8 - 0.5 = 0,$$

и потому

$$\mu_3 = \mathrm{E}\xi^3 = -2.7 + 3.2 - 0.5 = 0.$$

Пример 3.9.2. Для $\xi \sim \mathrm{Pois}(\lambda)$,

$$\gamma = \frac{1}{\sqrt{\lambda}}.$$

В самом деле, как мы знаем из примера 3.8.8,

$$\mathrm{E}\xi^3 - 3\mathrm{E}\xi^2 + 2\mathrm{E}\xi = \mathrm{E}(\xi)_3 = \lambda^3.$$

Как известно для распределения Пуассона, $\mathrm{E}\xi = \mathrm{Var}\,\xi = \lambda$, откуда $\mathrm{E}\xi^2 = \lambda^2 + \lambda$, и

$$\mathrm{E}\xi^3 = \lambda^3 + 3\lambda^2 + \lambda.$$

Наконец,

$$\mu_3 = \mathrm{E}(\xi - \lambda)^3 = \\ = (\lambda^3 + 3\lambda^2 + \lambda) - 3(\lambda^3 + \lambda^2) + 3\lambda^3 - \lambda^3 = \lambda.$$

Зная $\sigma = \sqrt{\lambda}$, находим

$$\gamma = \frac{\mu_3}{\sigma^3} = \frac{\lambda}{\lambda^{3/2}} = \frac{1}{\sqrt{\lambda}}.$$

Другой широко распространённый параметр — это **коэффициент эксцесса** (англ. excess kurtosis), который определяется как

$$\kappa := \frac{\mu_4}{\sigma^4} - 3,$$

где в числителе стоит четвёртый центральный момент

$$\mu_4 = \mathrm{E}(\xi - \mathrm{E}\xi)^4.$$

Сразу отметим, что -3 стоит только для красоты, чтобы у нормального распределения коэффициент эксцесса равнялся нулю. Само отношение $\frac{\mu_4}{\sigma^4}$ в русской литературе никак не называется, а в английской называется просто kurtosis.

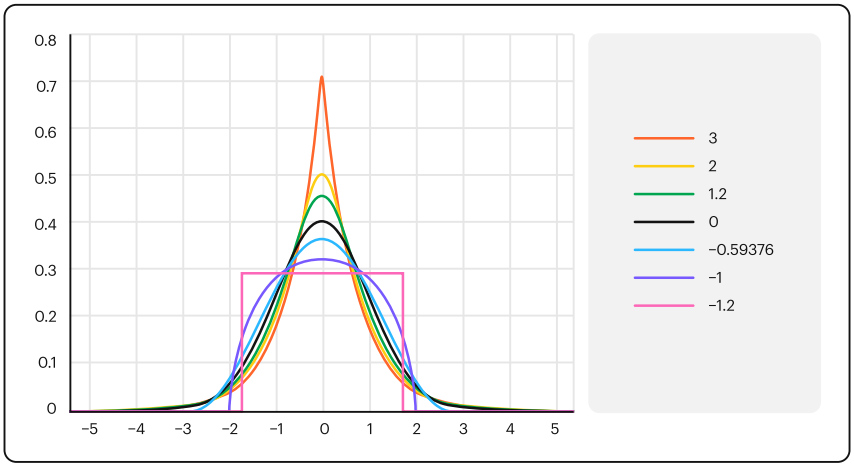

Рисунок 19. Параметр kurtosis позволяет характеризовать остроту пика распределения: чем выше значение коэффициента, тем более острый пик у распределения. В порядке уменьшения высоты пика идут распределения: Лаплас, гиперболический секанс, логистическое, нормальное, поднятый косинус, полукруговой закон Вигнера, равномерное

Здесь тоже по знаку коэффициента можно сделать выводы про распределение:

- $\kappa > 0$ означает, что у распределения острый пик (в сравнении с нормальным). Такое распределение называют лептокуртическим, и оно имеет тяжёлые хвосты.
- $\kappa < 0$ означает, что у распределения пологий пик (в сравнении с нормальным). Такое распределение называют платикур-

тическим, и оно имеет лёгкие хвосты.

Следующее утверждение говорит, что для величин с одинаковым разбросом при их сложении острота их пика накапливается.

УТВЕРЖДЕНИЕ 3.9.1

Пусть независимые случайные величины $\xi_1, \ldots, \xi_n$ имеют одинаковую дисперсию. Тогда

$$\kappa(\xi_1 + \ldots + \xi_n) = \frac{1}{n^2}\sum_{i=1}^{n}\kappa(\xi_i).$$

Доказательство. Поскольку смещение не влияет на центральные моменты, можно считать, что у всех величин нулевое матожидание и дисперсия σ^2. Обозначим $\eta := \sum_{i=1}^{n}\xi_i$. Тогда $\operatorname{Var}\eta = n\sigma^2$, откуда

$$\kappa(\eta) = \frac{\mathrm{E}\eta^4}{n^2\sigma^4} - 3.$$

Теперь

$$\mathrm{E}\eta^4 = \sum_{i=1}^{n}\mathrm{E}\xi_i^4 + \sum_{i\neq j}\mathrm{E}\xi_i^2\mathrm{E}\xi_j^2 = \sum_{i=1}^{n}\mathrm{E}\xi_i^4 + 3n(n-1)\sigma^4,$$

где при раскрытии скобок слагаемые вида $\mathrm{E}\xi_i^3\mathrm{E}\xi_j$, $\mathrm{E}\xi_i^2\mathrm{E}\xi_j\mathrm{E}\xi_k$ и $\mathrm{E}\xi_i\mathrm{E}\xi_j\mathrm{E}\xi_k\mathrm{E}\xi_m$ занулились ввиду того, что у всех величин нулевое матожидание. Теперь находим

$$\kappa(\eta) = \frac{\mathrm{E}\eta^4}{n^2\sigma^4} - 3 = \frac{1}{n^2}\sum_{i=1}^{n}\frac{\mathrm{E}\xi_i^4}{\sigma^4} - \frac{3}{n} =$$
$$= \frac{1}{n^2}\sum_{i=1}^{n}(\kappa(\xi_i)+3) - \frac{3}{n} = \frac{1}{n^2}\sum_{i=1}^{n}\kappa(\xi_i).$$

□

10. ХАРАКТЕРИСТИЧЕСКИЕ ФУНКЦИИ

Напомним, что i — это мнимая единица. То есть $i^2 = -1$. Стандартная запись для комплексного числа $a + bi$, где $a, b \in \mathbb{R}$, это $re^{i\varphi}$, где $r = \sqrt{a^2+b^2}$, а φ подбирается таким образом, чтобы выполнялось $\frac{a}{r} = \cos\varphi$, $\frac{b}{r} = \sin\varphi$. Это обусловлено формулой

$$e^{i\varphi} = \cos\varphi + i\sin\varphi.$$

Таким образом, если мы интегрируем комплексные числа, то можно интегрировать отдельно действительную и мнимую часть, а потом складывать их.

Мы уже знаем много разных характеристик про случайные вели-

чины: распределение, функция распределения, плотность, функция вероятности, мат. ожидание, дисперсия, высшие моменты...Понятно, что все эти данные можно восстановить по распределению, но само распределение задаётся довольно сложно (особенно если случайная величина не дискретная и не абсолютно непрерывная). Оказывается, есть способ заархивировать всю информацию о случайной величине в функцию! Этот способ архивации называется характеристической функцией.

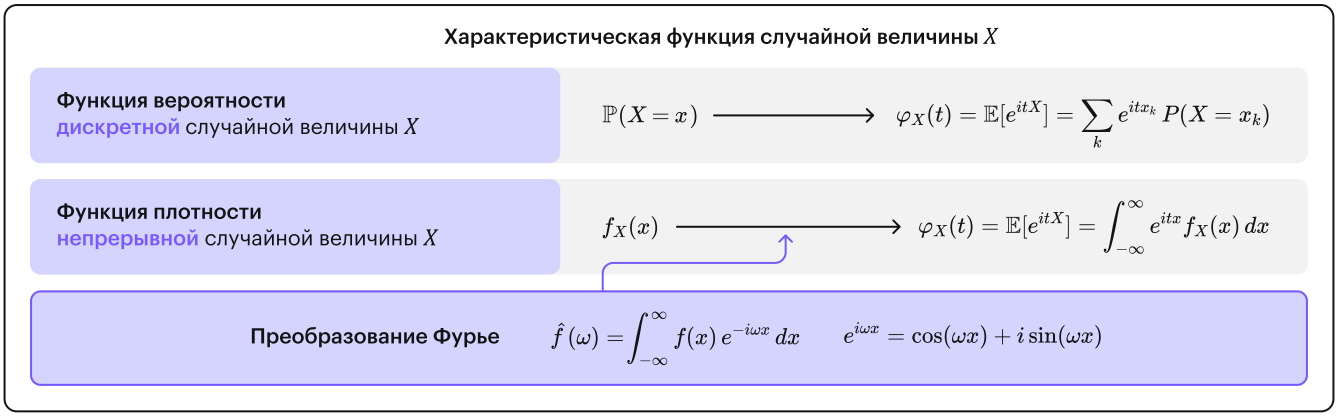

Рисунок 20. Вычисление характеристических функций

ОПРЕДЕЛЕНИЕ 3.10.1

Характеристическая функция $\varphi_\xi : \mathbb{R} \to \mathbb{C}$ случайной величины ξ определяется как

$$\varphi_\xi(t) := \mathrm{E}e^{it\xi} = \mathrm{E}\cos t\xi + i\mathrm{E}\sin t\xi.$$

Если ξ дискретна, то формула превращается в

$$\varphi_\xi(t) = \sum_x e^{itx}\mathrm{P}\{\xi = x\}.$$

Если ξ абсолютно непрерывна, то формула превращается в

$$\varphi_\xi(t) = \int_x e^{itx} p_\xi(x)\, dx.$$

См. также рис. 20

Заметим, что $\left|e^{it\xi}\right| = 1$, а значит, данная характеристическая функция всегда существует. По сути, она является преобразованием Фурье от функции распределения, а соответственно, полностью определяет свойства распределения.

Пример 3.10.1. Пусть $\xi \sim \mathrm{Bern}(p)$. Тогда

$$\varphi_\xi(t) = \mathrm{E}e^{it\xi} = pe^{it} + (1 - p).$$

Пример 3.10.2. Пусть $\xi \sim \mathrm{Exp}(\lambda)$. Тогда

$$\varphi_\xi(t) = \int_0^\infty \lambda e^{x(it-\lambda)}\,dx = \frac{\lambda}{\lambda - it}.$$

Чтобы проверить, что мы не ошиблись в подсчёте, удобно пользоваться такими свойствами характеристической функции.

- $|\varphi_\xi(t)| \leqslant 1$, так как $|\mathrm{E}e^{it\xi}| \leqslant \mathrm{E}|e^{it\xi}| = 1$.
- Если $\xi = c$-п. н., то $\varphi_\xi(t) = e^{itc}$.
- $\varphi_\xi(0) = 1$.
- $\varphi_{a\xi+b}(t) = e^{itb}\varphi_\xi(at)$, так как $\mathrm{E}e^{it(a\xi+b)} = e^{itb}\mathrm{E}e^{i(at)\xi}$.
- φ_ξ равномерно непрерывна.
- φ_ξ действительно-значна тогда и только тогда, когда распределение случайной величины ξ симметрично относительно нуля.
- Если ξ, η независимы, то $\varphi_{\eta+\xi}(t) = \varphi_\xi(t)\varphi_\eta(t)$, так как $\mathrm{E}e^{it(\xi+\eta)} = $
  $= \mathrm{E}e^{it\xi}e^{it\eta} = \mathrm{E}e^{it\xi}\mathrm{E}e^{it\eta}$.
- Заметим, что из свойств дифференцирования по параметру получаем следующее: если существует $\mathrm{E}|\xi^n|$, то

  $$\mathrm{E}\xi^n = \frac{\varphi_\xi^{(n)}(0)}{i^n},$$

  так как

  $$\varphi_\xi^{'}(t) = \mathrm{E}i\xi e^{it\xi}, \varphi_\xi^{(n)}(t) = \mathrm{E}(i\xi)^n e^{it\xi}, \varphi_\xi^{'}(0) = \mathrm{E}i\xi, \varphi_\xi^{(n)}(t) = \mathrm{E}i^n\xi^n,$$

  а значит, с помощью характеристической функции можно находить моменты распределения случайной величины.

Пример 3.10.3. Легко видеть, что функция e^t не является характеристической, так как неограничена.

Аналогично, функция $\sin t$ не является характеристической, так как в нуле не равна 1.

А вот $\cos t$ является характеристической функцией. Сейчас мы это можем только угадать: нужно взять ξ, равную ± 1 равновероятно. Тогда

$$\varphi_\xi(t) = \frac{e^{it} + e^{-it}}{2} = \cos t.$$

У случайной величины ξ с хар. функцией $\cos t$ легко можно найти мат. ожидание, и не подбирая распределение. Надо всего лишь воспользоваться тем, что

$$\mathrm{E}\xi = -i\varphi_\xi'(0) = i\sin 0 = 0.$$

Рассмотрим ещё примеры нахождения характеристических функций.

Пример 3.10.4. Пусть $\xi \sim \mathrm{Bin}(n, p)$. Как мы знаем, можно считать, что

$$\xi = \sum_{k=1}^{n} \xi_k,$$

где $\xi_k \sim \mathrm{Bern}(p)$. Тогда

$$\varphi_\xi(t) = \prod_{k=1}^{n} \varphi_{\xi_k}(t) = (pe^{it} + 1 - p)^n.$$

Пример 3.10.5. Пусть $\xi \sim \mathrm{Pois}(\lambda)$. Тогда

$$\varphi_\xi(t) = \sum_{m=1}^{\infty} e^{itm} \frac{\lambda^m}{m!} e^{-\lambda} = \exp\{\lambda(e^{it} - 1)\}.$$

Пример 3.10.6. Пусть $\xi \sim \mathrm{Geom}(p)$. Тогда

$$\varphi_\xi(t) = \sum_{m=1}^{\infty} e^{itm} p(1-p)^{m-1} = pe^{it} \sum_{m=0}^{\infty} e^{itm}(1-p)^m = \\ = \frac{pe^{it}}{1 - (1-p)e^{it}}.$$

На этих примерах видно, что есть биекция между дискретными распределениями и характеристическими функциями: просто глядя на ряд из вероятностей и комплексных экспонент, легко понять, какое значение с какой вероятностью принимает случайная величина. Прежде чем обсуждать дальше это удивительное свойство, посмотрим ещё на примеры характеристических функций для абсолютно непрерывных случайных величин.

Пример 3.10.7. Пусть $\xi \sim \mathrm{U}[0, 1]$. Тогда

$$\varphi_\xi(t) = \int_0^1 e^{itx} dx = \frac{e^{it} - 1}{it},$$

где по непрерывности в нуле функция, естественно, равна 1.

Пример 3.10.8. Пусть $\xi \sim \mathrm{U}[a, b]$. Тогда, масштабируя величину из предыдущего примера на $(b - a)$ и смещая на a,

$$\varphi_\xi(t) = \frac{e^{itb} - e^{ita}}{it(b-a)},$$

где по непрерывности в нуле функция равна 1.

Пример 3.10.9. Пусть $\xi \sim N(0,1)$. Тогда

$$\varphi_\xi(t) = \int_{-\infty}^{\infty} e^{itx} \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx|_{y=x-it} = e^{-\frac{t^2}{2}} \int_{-\infty-it}^{\infty-it} \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} dy = \\ = e^{-\frac{t^2}{2}} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} dy = e^{-\frac{t^2}{2}}.$$

Удивительно, что характеристическая функция нормального закона с точностью до нормировки равна его же плотности.

Пример 3.10.10. Пусть $\xi \sim N(a, \sigma^2)$. Тогда, центрируя и нормируя,

$$\varphi_\xi(t) = e^{ita - \frac{\sigma^2 t^2}{2}}.$$

Одно важное свойство характеристических функций мы уже заметили: по ним можно восстанавливать дискретное распределение, а значит, есть биекция между дискретными распределениями и их характеристическими функциями. Оказывается, это свойство верно вообще для всех распределений.

Две случайные величины имеют одинаковое распределение тогда и только тогда, когда их характеристические функции совпадают.

ТЕОРЕМА 3.10.1
Теорема единственности

Пример 3.10.11. Пусть

$$\varphi_\xi(t) = e^{it - t^2}.$$

Тогда $\xi \sim N(1,2)$.

Через теорему единственности гораздо удобнее искать свёртки распределений, чем собственно по формуле свёртки.

Пример 3.10.12. Пусть $\xi \sim N(a, \sigma^2)$ и $\eta \sim N(b, \tau^2)$. Тогда

$$\varphi_{\xi+\eta}(t) = \varphi_\xi(t)\varphi_\eta(t) = e^{it(a+b)} e^{-\frac{t^2}{2}(\sigma^2+\tau^2)},$$

что по теореме единственности означает, что $\xi + \eta \sim N(a + b, \sigma^2 + \tau^2)$.

Важно понимать, что, по теореме единственности, хар. функция содержит *всю информацию* о распределении случайной величины. Например, зная хар. функцию, есть (как минимум) три способа посчитать мат. ожидание (или высшие моменты):

1) найти производную хар. функции в нуле,
2) разложить хар. функцию в ряд Тейлора,
3) восстановить распределение случайной величины, и найти мат. ожидание по определению.

Продемонстрируем это на примере.

Пример 3.10.13. Пусть

$$\varphi_\xi(t) = \frac{\lambda^n}{(\lambda - it)^n},$$

где n натуральное, а $\lambda > 0$. Найдём $\mathrm{E}\xi$ тремя разными способами.

1) Находим

$$\varphi'_\xi(t) = \frac{in\lambda^n}{(\lambda - it)^{n+1}},$$

откуда

$$\mathrm{E}\xi = -i\varphi'_\xi(0) = \frac{n}{\lambda}.$$

2) Воспользуемся известным разложением в ряд Тейлора

$$\frac{1}{(1-x)^n} = \sum_{k=0}^{\infty} \binom{n+k-1}{k} x^k.$$

Раскладывая хар. функцию в ряд Тейлора, находим

$$\varphi_\xi(t) = \sum_{k=0}^{\infty} \binom{n+k-1}{k} \left(\frac{it}{\lambda}\right)^k,$$

откуда находим

$$\mathrm{E}\xi^k = \binom{n+k-1}{k} \frac{1}{\lambda^k};$$

в частности,

$$\mathrm{E}\xi = \binom{n}{1} \frac{1}{\lambda} = \frac{n}{\lambda}.$$

3) Наконец, можно заметить, что для $\xi_k \sim \mathrm{Exp}(\lambda)$ имеем

$$\varphi_{\xi_k}(t) = \frac{\lambda}{\lambda - it},$$

откуда $\xi \stackrel{d}{=} \sum_{k=1}^n \xi_k$. Тогда

$$\mathrm{E}\xi = n\mathrm{E}\xi_1 = \frac{n}{\lambda}.$$

Пример 3.10.14. Рассмотрим ещё один пример подсчёта мат. ожидания. Пусть

$$\varphi_\xi(t) = \left(\frac{\sin t}{t}\right)^2.$$

1) Находим производную в нуле:

$$\varphi'_\xi(0) = \lim_{t\to 0} \frac{\left(\frac{\sin t}{t}\right)^2 - 1}{t} = \lim_{t\to 0} \frac{(t + o(t^2))^2 - t^2}{t^3} = \lim_{t\to 0} \frac{o(t^3)}{t^3} = 0,$$

откуда

$$\mathrm{E}\xi = -i\varphi'_\xi(0) = 0.$$

2) Раскладываем в ряд Тейлора:

$$\cos x = \sum_{n=0}^{\infty} \frac{x^{2n}}{(2n!)}(-1)^n,$$

откуда

$$(\sin t)^2 = \frac{1-\cos(2t)}{2} = \frac{1}{2} + \sum_{n=0}^{\infty} \frac{2^{2n-1}t^{2n}}{(2n!)}(-1)^{n+1} = \\ = \sum_{n=1}^{\infty} \frac{2^{2n-1}t^{2n}}{(2n!)}(-1)^{n+1}.$$

Тогда

$$\varphi_\xi(t) = \frac{(\sin t)^2}{t^2} = \sum_{n=1}^{\infty} \frac{2^{2n-1}t^{2n-2}}{(2n!)}(-1)^{n+1}.$$

Коэффициент при $t = 1$ равен нулю, поэтому $\mathrm{E}\xi = 0$.

3) Заметим, что

$$\varphi_\eta(t) = \frac{\sin t}{t} = \frac{e^{it} - e^{-it}}{2it}$$

соответствует распределению $\eta \sim \mathrm{U}[-1,1]$. Выбирая независимую копию $\eta' \sim \mathrm{U}[-1,1]$, получаем $\xi \stackrel{d}{=} \eta + \eta'$, откуда

$$\mathrm{E}\xi = 2\mathrm{E}\eta = 0.$$

Чтобы в полной мере пользоваться третьим способом, полезна теорема ниже. Теорема единственности является её следствием.

ТЕОРЕМА 3.10.2

Формула обращения

1) Для любых двух точек $a < b$, выполнено

$$\frac{\mathrm{P}_\xi(a,b] + \mathrm{P}_\xi[a,b)}{2} = \frac{1}{2\pi} \lim_{T\to\infty} \int_{-T}^{T} \frac{e^{-ita} - e^{-itb}}{it} \varphi_\xi(t)\, dt.$$

Если a, b являются точками непрерывности функции F_ξ, то выражение равно $F_\xi(b) - F_\xi(a)$.

2) Пусть дополнительно Пусть

$$\int_{\mathbb{R}} \left|\varphi_\xi(t)\right| dt < +\infty.$$

Тогда ξ абсолютно непрерывна, и её плотность равна

$$p_\xi(x) = \frac{1}{2\pi} \int_{\mathbb{R}} \varphi_\xi(t) e^{-itx}\, dt.$$

ЗАМЕЧАНИЕ

В математическом анализе последний интеграл называется преобразованием Фурье, а определение характеристической функции для абсолютно непрерывной случайной величины называется обратным преобразованием Фурье. Как видно из формулы обращения, эти два преобразования отличаются только знаком минус в комплексной экспоненте. То есть формула говорит, что почти одним и тем же преобразованием можно перегонять плотность в характеристическую функцию, и обратно.

Пример 3.10.15. Пусть $\varphi_\xi(t) = (1 - |t|)\mathcal{I}\{|t| < 1\}$. Тогда интеграл от характеристической функции конечен, и случайная величина абсолютно непрерывна. Так как φ_ξ чётная функция, интеграл по синусу зануляется, и можно найти плотность как

$$p_\xi(x) = \frac{1}{\pi}\int_0^1 \cos(tx)(1-t)\,dt = \frac{1-\cos x}{\pi x^2}.$$

Можно попробовать найти мат. ожидание:

$$\mathrm{E}\xi = \int \frac{1-\cos x}{\pi x}\,dx = ?!?$$

Тут возникают проблемы, потому что данный интеграл не существует, функция по Лебегу не интегрируема. Это можно было заметить и без всяких интегралов: мы же знаем, что

$$\mathrm{E}\xi = -i\varphi'_\xi(0),$$

а в нашем примере производной в нуле нет.

Напоследок отметим, что мы здесь не проверяем, является ли данная функция характеристической функцией какого-нибудь распределения. Мы принимаем это на веру. Иногда это проверить легко (проверить непрерывность, ограниченность, и значение в нуле), но в более сложных ситуациях нужна продвинутая техника, которую мы не рассматриваем.

Раз характеристические функции являют собой такой удобный инструмент, нельзя ли перенести его и на случай случайных векторов? Оказывается, можно, и это тоже существенно упрощает работу со случайными векторами.

ОПРЕДЕЛЕНИЕ 3.10.2
Характеристическая функция случайного вектора

Характеристическая функция $\boldsymbol{\varphi_\xi}$**:** $\mathbb{R}^{\boldsymbol{d}} \to \mathbb{C}$ случайного вектора $\boldsymbol{\xi} = (\xi_1, \ldots, \xi_d)$ определяется как

$$\varphi_{\boldsymbol{\xi}}(\boldsymbol{t}) = \mathrm{E}e^{i\langle \boldsymbol{t}, \boldsymbol{\xi}\rangle} = \mathrm{E}e^{\sum_{j=1}^d it_j\xi_j}.$$

Для характеристических функций случайного вектора работают те же основные свойства, что и для случайных величин: про масштабируемость, сдвиг, сумму независимых случайных величин, и теоремы единственности и непрерывности. Но есть также одно важное свойство, связывающее характеристические функции случайных величин и случайных векторов.

ТЕОРЕМА 3.10.3

Случайные величины $\xi_1, \ldots, \xi_d$ независимы тогда и только тогда,

когда для любых $t_1, \ldots, t_d \in \mathbb{R}$ происходит факторизация

$$\varphi_{(\xi_1,\ldots,\xi_d)}(t_1, \ldots, t_d) = \varphi_{\xi_1}(t_1) \ldots \varphi_{\xi_d}(t_d).$$

Доказательство. Необходимость очевидна: для независимых случайных величин имеем

$$\varphi_{(\xi_1,\ldots,\xi_d)}(t_1, \ldots, t_d) = \mathrm{E} e^{\sum_{j=1}^d it_j\xi_j} = \prod_{j=1}^d \mathrm{E} e^{it_j\xi_j} = \varphi_{\xi_1}(t_1) \ldots \varphi_{\xi_d}(t_d).$$

Достаточность следует по теореме единственности: единственное распределение, соответствующее вектору $(\xi_1, \ldots, \xi_d)$, это распределение независимых случайных величин, маргинальные распределения которых совпадают с распределениями случайных величин ξ_j. □

Таким образом, мы можем восстанавливать распределение случайной величины по характеристической функции и проверять независимость случайных величин.

Пример 3.10.16. Пусть $\xi = (\xi_1, \ldots, \xi_d)$ — случайный вектор, имеющий следующую характеристическую функцию:

$$\varphi_\xi(t) = e^{\sum_{j=1}^d (it_j a_j - \sigma_j^2 t_j^2/2)}.$$

Тогда это случайный вектор, все компоненты которого независимы и имеют нормальные распределение $N(a_j, \sigma_j^2)$.

11. ПРОИЗВОДЯЩАЯ ФУНКЦИЯ МОМЕНТОВ

В этом разделе мы введём важнейший инструмент для исследования поведения случайных величин — производящую функцию моментов, а также рассмотрим её свойства.

ОПРЕДЕЛЕНИЕ 3.11.1

Производящей функцией моментов (п. ф. м.) случайной величины X называется функция $M_X : U \to \mathbb{R}$, заданная при всех $t \in U$ равенством

$$M_X(t) := \mathbb{E}\left(e^{tX}\right), \tag{1}$$

где $U \subseteq \mathbb{R}$ состоит из тех и только тех t, что математическое ожидание $\mathbb{E}e^{tX}$ определено и конечно.

ЗАМЕЧАНИЕ

Иногда производящую функцию моментов называют **MGF** (от англ. moment generating function).

ЗАМЕЧАНИЕ

Если случайная величина X дискретна и принимает значения $x_1, x_2, \ldots$, то её производящая функция моментов имеет вид

$$M_X(t) = \mathbb{E}e^{tX} = \sum_k e^{tx_k} \cdot \mathbf{P}(X = x_k).$$

Пример 3.11.1. Найди производящую функцию моментов M_X,

если $X \sim \mathrm{Bern}(p)$.

Решение. По определению п. ф. м. получаем равенства

$$M_X(t) = \mathbb{E}e^{tX} = pe^{t\cdot 1} + (1-p)e^{t\cdot 0} = pe^t + (1-p).$$

Отметим основные свойства производящей функции моментов:

- $M_X(0) = 1$;
- для всяких чисел a и b и всякого t из области определения M_{aX+b} справедливо соотношение

$$M_{aX+b}(t) = e^{bt}M_X(at).$$

Пример 3.11.2. Найди производящую функцию моментов M_X, если $X \sim \mathrm{Pois}(\lambda)$.

Решение. Имеем равенства

$$M_X(t) = \mathbb{E}e^{tX} = \sum_{k=0}^{\infty} e^{tk}\frac{e^{-\lambda}\lambda^k}{k!}$$
$$= e^{-\lambda}\sum_{k=0}^{\infty}\frac{(\lambda e^t)^k}{k!} = e^{-\lambda}e^{\lambda e^t} = e^{\lambda(e^t-1)}.$$

ЗАМЕЧАНИЕ

Производящие функции моментов из примеров 3.11.1, 3.11.2 существуют при всяком $t \in \mathbb{R}$.

Справедлива следующая теорема, связывающая производящую функцию моментов суммы независимых случайных величин с производящими функциями моментов слагаемых, входящих в эту сумму.

ТЕОРЕМА 3.11.1

Пусть случайные величины $X_1, \ldots, X_n$ независимы. Пусть также для всякого t из некоторой окрестности нуля $(-a, a)$, $a > 0$ определены производящие функции моментов $M_{X_1}(t), \ldots, M_{X_n}(t)$. Тогда для всякого $t \in (-a, a)$ существует $M_{X_1+\ldots+X_n}(t)$ и имеет место равенство

$$M_{X_1+\ldots+X_n}(t) = M_{X_1}(t)\cdot\ldots\cdot M_{X_n}(t).$$

Доказательство. В силу независимости случайных величин $X_1, \ldots, X_n$ имеют место равенства

$$M_{X_1+\ldots+X_n}(t) = \mathbb{E}e^{tX_1+\ldots+tX_n} = \mathbb{E}e^{tX_1}\cdot\ldots\cdot$$
$$\mathbb{E}e^{tX_n} = M_{X_1}(t)\cdot\ldots\cdot M_{X_n}(t).$$

□

Пример 3.11.3. Найди производящую функцию моментов M_X, если $X \sim \mathrm{Bin}(n, p)$.

Решение. Для случайной величины X справедливо представление

$$X = \sum_{j=1}^{n} X_j,$$

где $X_j \sim \mathrm{Bern}(p)$, $j = 1, \ldots, n$ — независимы. Пользуясь теоремой 2 и результатом примера 2, получаем равенство

$$M_X(t) = \prod_{j=1}^{n} M_{X_j}(t) = \prod_{j=1}^{n} (pe^t + 1 - p) = (pe^t + 1 - p)^n,$$

причём $M_X(t)$ определена для всякого числа t. ■

Справедлива следующая теорема, связывающая функции моментов случайных величин и их распределения.

ТЕОРЕМА 3.11.2

Пусть производящие функции моментов M_X и M_Y определены в некоторой окрестности нуля $(-a, a)$ и для всякого $t \in (-a, a)$ справедливо равенство

$$M_X(t) = M_Y(t).$$

Тогда для всякого числа z имеет место равенство

$$\mathbf{P}(X = z) = \mathbf{P}(Y = z).$$

Теорема 3.11.2 позволяет привести более простое доказательство аддитивности распределения Пуассона.

Пример 3.11.4. Введём обозначение $X = X_1 + \ldots + X_n$. В примере 3.11.2 мы нашли, что производящая функция моментов случайной величины, имеющей пуассоновское распределение с параметром λ, равна $\exp(\lambda(e^t - 1))$. Таким образом, $M_{X_j}(t) = \exp(\lambda_j(e^t - 1))$. Пользуясь тем, что случайные величины $\{X_j\}_{j=1}^n$ независимы, получаем равенство

$$M_X(t) = \prod_{j=1}^{n} e^{\lambda_j(e^t - 1)} = \exp\left(\sum_{j=1}^{n} \lambda_j (e^t - 1)\right) = \\ = \exp\left((e^t - 1)\sum_{j=1}^{n} \lambda_j\right).$$

Таким образом, производящая функция моментов моментов $M_X(t)$ во всех точках t совпадает с производящей функцией моментов величины, имеющей распределение $\mathrm{Poiss}(\lambda_1 + \ldots + \lambda_n)$. В силу теоремы 3, $X \sim \mathrm{Poiss}(\lambda_1 + \ldots + \lambda_n)$.

Название производящей функции моментов оправдывает следующая теорема.

ТЕОРЕМА 3.11.3

Если производящая функция моментов $M_X(t)$ определена для

всех t из некоторой окрестности нуля ($t \in (-a, a)$, $a > 0$):

- то функция моментов M_X является бесконечно дифференцируемой в точке ноль;
- существуют все моменты случайной величины X;
- производная k-го порядка функции моментов в нуле равна k-му моменту случайной величины:

$$M_X^{(k)}(0) = \mathbb{E}(X^k), \qquad k = 1, 2, \ldots.$$

СЛЕДСТВИЕ 3.11.1

В силу того, что производящие функции моментов для $X \sim Bern(p)$ и $X \sim Poiss(\lambda)$ определены для всех вещественных чисел, из теоремы 3.11.3 следует, что и пуассоновская, и бернуллиевская случайные величины имеют моменты всякого порядка.

ЗАМЕЧАНИЕ

Напоследок отметим, что производящие функции моментов и характеристические функции очень похожи: у одной в экспоненте стоит мнимая единица, а у другой нет. И идея у них одна и та же: заархивировать информацию о распределении.

12. НЕРАВЕНСТВО ЙЕНСЕНА

В теории вероятностей довольно часто возникает задача оценить сверху или снизу матожидание не самой случайной величины, а какой-то функции от неё. Например, мы знаем, что

$$|\mathrm{E}\xi| \leqslant \mathrm{E}\,|\xi|\,.$$

Причём обычно возникают функции вроде $|x|$, x^2, $\sqrt{x}$, e^x, e^{-x}, x^3 на положительной полуоси, и многие другие. Перечисленные функции обладают одним замечательным свойством: они вогнутые или выпуклые.

Напомним, что **выпуклость вниз** функции $V : \mathbb{R} \to \mathbb{R}$ означает, что для любого $t_0 \in \mathbb{R}$ найдётся такое $\alpha \in \mathbb{R}$, что $V(t) \geqslant V(t_0) + \alpha(t - t_0)$ для всех $t \in \mathbb{R}$. Соответственно, для **выпуклости вверх** знак неравенства переворачивается.

ТЕОРЕМА 3.12.1

Пусть ξ случайная величина с конечным математическим ожиданием. Пусть функция $V : \mathbb{R} \to \mathbb{R}$ такова, что $\mathrm{E}V(\xi)$ тоже конечно. Тогда, если V выпукла вниз, то

$$V(\mathrm{E}\xi) \leqslant \mathrm{E}V(\xi);$$

а если V выпукла вверх, то

$$V(\mathrm{E}\xi) \geqslant \mathrm{E}V(\xi);$$

Доказательство. Поскольку выпуклость вверх от выпуклости вниз отличаются только сменой знака, достаточно доказать неравенство только для выпуклости вниз.

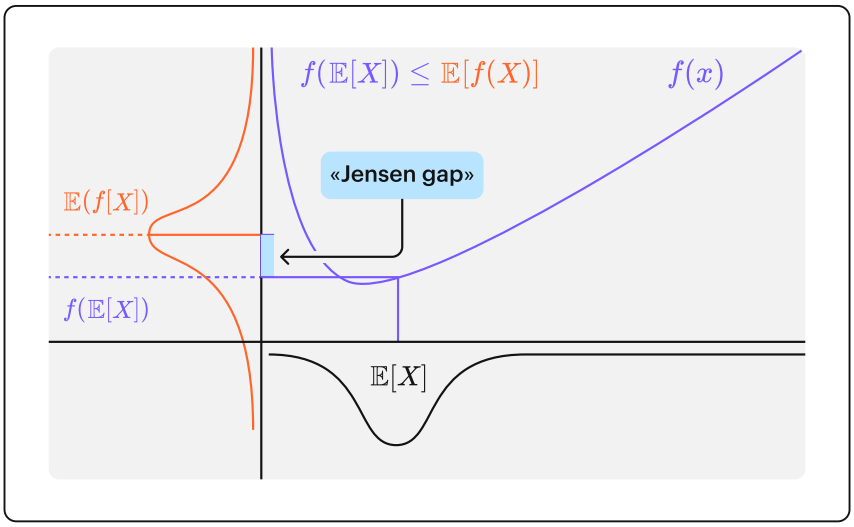

Рисунок 21. Геометрический смысл неравенства Йенсена

В определении выпуклости, возьмём точку $t_0 := \mathrm{E}\xi$. Теперь для некоторого $\alpha \in \mathbb{R}$,

$$V(\xi) \geqslant V(\mathrm{E}\xi) + \alpha(\xi - \mathrm{E}\xi).$$

Навешивая слева и справа матожидание, получаем

$$\mathrm{E}V(\xi) \geqslant \mathrm{E}V(\mathrm{E}\xi) + \alpha\mathrm{E}(\xi - \mathrm{E}\xi) = V(\mathrm{E}\xi),$$

что и требовалось. □

Смысл неравенства довольно простой: когда мы считаем матожидание функции, то мы усредняем по её «объёму», который находится где-то высоко. А когда мы берём функцию от среднего, мы так и остаёмся на границе, которая где-то низко, если функция выпукла; см. рис. 21 для геометрической интуиции.

Пример 3.12.1. Пусть $\xi \sim \mathrm{Pois}(\lambda)$. Тогда

$$\lambda + \lambda^2 = \mathrm{E}\xi^2 \geqslant (\mathrm{E}\xi)^2 = \lambda^2.$$

Пример 3.12.2. Пусть $\xi \sim N(a, \sigma^2)$. Тогда

$$\mathrm{E}e^{\xi} \geqslant e^{\mathrm{E}\xi} = e^{a}.$$

Кроме того,

$$\mathrm{E}e^{-\xi} \geqslant e^{-\mathrm{E}\xi} = e^{-a}.$$

Пример 3.12.3. Пусть $\xi \sim \mathrm{Exp}(\lambda)$. Тогда

$$\mathrm{E}\sqrt{\xi} \leqslant \sqrt{\mathrm{E}\xi} = \frac{1}{\sqrt{\lambda}}.$$

13. ГАУССОВСКИЕ ВЕКТОРА

Как мы помним, случайная величина ξ имеет нормальное распределение $N(a, \sigma^2)$, если её плотность имеет вид

$$p_\xi(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-a)^2}{2\sigma^2}}.$$

Физики говорят: «Всё в жизни нормально». Действительно, в жизни нормальное распределение встречается довольно часто, не в последнюю очередь благодаря центральной предельной теореме.

Напомним ЦПТ. *Пусть случайные величины $\xi_1, \xi_2, \ldots$ независимы, одинаково распределены и имеют конечные математическое ожидание и дисперсию. Тогда, обозначая $S_n := \xi_1 + \ldots + \xi_n$, получаем*

$$\frac{S_n - \mathrm{E}S_n}{\sqrt{\mathrm{Var}\, S_n}} \xrightarrow[n\to\infty]{d} N(0,1).$$

Смысл ЦПТ в том, что если много раз проводить один и тот же эксперимент и усреднять, то полученные усреднения «лягут на колокол» нормального закона.

Пример 3.13.1. Представим теперь, что мы измеряем n абсолютно непрерывных случайных величин $X_1, \ldots, X_n$; например, при $n = 3$ это могут быть скорости молекулы воздуха. Они образуют случайный вектор $\boldsymbol{X} = (X_1, \ldots, X_n)$. Допустим, все его координаты X_i независимы (в совокупности) и распределение вектора $\boldsymbol{X}$ изотропно, то есть не зависит от выбора направления. Обозначим также через p_i плотности самих случайных величин X_i. Независимость случайных величин означает, что плотность вектора $\boldsymbol{X}$

$$p(\boldsymbol{x}) = p_1(x_1) \ldots p_n(x_n).$$

Логарифмируя, получаем

$$\ln p(\boldsymbol{x}) = \ln p_1(x_1) + \ldots + \ln p_n(x_n).$$

Независимость от направления означает, что функции $p(\boldsymbol{x})$ и $\ln p(\boldsymbol{x})$ принимают постоянные значения на сферах

$$x_1^2 + \ldots + x_n^2 = const.$$

Другими словами, нормали поверхностей уровня функции $\ln p(\boldsymbol{x})$ коллинеарны нормалям сферы; то есть для некоторого $\lambda \in \mathbb{R}$

$$\nabla \ln p(\boldsymbol{x}) = -\lambda \nabla |\boldsymbol{x}|^2,$$

что для всех $i = 1, \ldots, n$ даёт

$$\frac{p_i'(x_i)}{p_i(x_i)} = -2\lambda x_i.$$

Интегрируя, получаем

$$\ln p_i(x_i) = -\lambda x_i^2 + C_i,$$

откуда

$$p_i(x_i) = \mu_i e^{-\lambda x_i^2}.$$

Чтобы найти константы, надо задать нормировку. Предположим дополнительно, что величины имеют одинаковую дисперсию σ^2. Тогда нормировка задаёт условия на плотность и на дисперсию:

$$\int p_i(x_i)\,dx_i = 1, \quad \int x_i^2 p_i(x_i)\,dx_i = \sigma^2.$$

Отсюда получаем, что $\lambda > 0$. Первое условие нормировки даёт

$$\mu_i \frac{\sqrt{\pi}}{\sqrt{\lambda}} = 1.$$

Второе условие даёт

$$\mu_i \frac{\sqrt{\pi}}{\sqrt{\lambda}} \frac{1}{2\lambda} = \sigma^2.$$

Наконец, отсюда находим

$$\lambda = \frac{1}{2\sigma^2}, \quad \mu_i = \frac{1}{\sqrt{2\pi\sigma^2}}.$$

Окончательно получаем

$$p_i(x_i) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{x_i^2}{2\sigma^2}}.$$

Батюшки, да это же плотность нормального закона! То есть мы получили нормальный закон **просто из предположений о независимости координат друг от друга и от поворота**!

Если пойти чуть дальше, получаем

$$p(\boldsymbol{x}) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} e^{-\frac{|\boldsymbol{x}|^2}{2\sigma^2}}.$$

Логично эту плотность назвать плотностью гауссовского вектора, но не совсем....

Давайте теперь разовьём математический аппарат (физический уже развили). Мы поняли, как получается гауссовский вектор в природе. Далее считается, что, например, если сжать наше распределение по одной из осей, то вектор останется гауссовским. Если произвести «поворот», он всё ещё останется гауссовским в силу первоначально заявленной изотропии распределения. Вообще говоря, разрешается любое аффинное отображение над гауссовским вектором — то есть композиция линейного отображения и сдвига. Это подводит нас к первому определению.

«Гауссовский вектор через аффинные отображения». Случайный вектор $\boldsymbol{\xi}\colon \Omega \to \mathbb{R}^d$ называется **гауссовским**, если он получен

аффинным отображением из вектора $\boldsymbol{\eta}\colon \Omega \to \mathbb{R}^s$, составленного из s независимых (в совокупности) случайных величин, имеющих стандартное нормальное распределение $N(0,1)$. Иными слова, должны сосуществовать такие неслучайные $A \in \mathbb{R}^{d\times s}$ и $\boldsymbol{b} \in \mathbb{R}^d$, что

$$\boldsymbol{\xi} = A\boldsymbol{\eta} + \boldsymbol{b}.$$

ЗАМЕЧАНИЕ

Таким образом, можно сделать определение гауссовского вектора чуть более «физическим» и сказать, что вектор гауссовский, если он получен аффинным преобразованием из вектора, составленного из независимых нормальных величин.

ЗАМЕЧАНИЕ

Если вы не помните, что такое аффинное отображение — не беда. Поймите последнее равенство: вектор называется гауссовским, если он получен из вектора независимых стандартных нормальных случайных величин (это мы про $\boldsymbol{\eta}$) умножением на матрицу из констант A со сдвигом на $\boldsymbol{b}$.

ЗАМЕЧАНИЕ

Если ξ имеет распределение константы c, будем считать, что $\xi \sim N(c,0)$.

Отдельный вид линейного отображения — скалярное произведение. А именно: если взять матрицу $B\in R^{1\times d}$, то случайная величина

$$B\boldsymbol{\xi} = \sum_{k=1}^{d} b_{1k}\xi_k = BA\boldsymbol{\eta} + B\boldsymbol{b}$$

по определению обязана являться гауссовским вектором, то есть нормальной величиной. Оказывается, это является и определяющим свойством гауссовского вектора.

«Гауссовский вектор через линейную комбинацию». Случайный вектор называется **гауссовским**, если любая линейная комбинация его компонент является нормальной случайной величиной.

Мы сформулировали уже два определения гауссовского вектора. Всего их будет три, нам надо доказать, что все они равносильны. Схема доказательства будет «круговая»: мы покажем, что из первого следует второе, из второго — третье, из третьего — первое. Начнем.

Доказательство. [Доказательство из «аффинных отображений» в «линейные комбинации»] По сути, это мы уже доказали, когда придумывали новое определение. Рассмотрим случайный вектор $\boldsymbol{\xi}\colon \Omega \to \mathbb{R}^d$, гауссовский в том смысле, что $\boldsymbol{\xi} = A\boldsymbol{\eta}$ для некоторой матрицы A и вектора $\boldsymbol{\eta}$, составленного из независимых нормальных случайных величин. Нужно доказать, что для любого $\boldsymbol{\lambda} \in \mathbb{R}^d$ линейная комбинация

$$\lambda_1\xi_1 + \ldots + \lambda_d\xi_d$$

является нормальной случайной величиной. Для этого рассмот-

рим матрицу

$$\Lambda := \begin{pmatrix} \lambda_1 & \lambda_2 & \dots & \lambda_d \end{pmatrix}$$

и аффинное отображение

$$\Lambda\boldsymbol{\xi} = \lambda_1\xi_1 + \ldots + \lambda_d\xi_d.$$

Тогда

$$\Lambda\boldsymbol{\xi} = (\Lambda A)\boldsymbol{\eta}$$

тоже является гауссовским (одномерным) вектором. Значит, эта линейная комбинация имеет нормальное распределение. □

Как ещё можно задавать распределения? Через характеристические функции!

Пример 3.13.2. Вспомним, как найти характеристическую функцию φ для $\xi \sim N(0,1)$. В силу чётности плотности нормального закона имеем

$$\varphi(t) = \int_{\mathbb{R}} \cos(tx)\,\frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}\,dx.$$

Отсюда (по теореме Лебега о мажорируемой сходимости)

$$\begin{aligned}\varphi'(t) &= -\int_{\mathbb{R}} x\sin(tx)\,\frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}\,dx = \int_{\mathbb{R}} \sin(tx)\,\frac{1}{\sqrt{2\pi}}\,de^{-\frac{x^2}{2}} = \\ &= \sin(tx)\,\frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}\Big|_{x=-\infty}^{+\infty} - \int_{\mathbb{R}} \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}\,d\sin(tx) = \\ &= 0 - \int_{\mathbb{R}} t\cos(tx)\,\frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}\,dx = t\varphi(t).\end{aligned}$$

Поэтому

$$\frac{\varphi'(t)}{\varphi(t)} = -t,$$

откуда

$$\varphi(t) = Ce^{-\frac{t^2}{2}}.$$

Константу $C = 1$ находим из условия нормировки $\varphi(0) = 1$.

Получили удивительный результат, что для стандартного нормального закона его плотность и характеристическая функция различаются только домножением на константу.

Тогда для произвольного нормального закона $\eta \sim N(a, \sigma^2)$ по свойствам характеристических функций имеем

$$\varphi_\eta(t) = \varphi_{\sigma\xi+a}(t) = e^{ita}e^{-\frac{\sigma^2 t^2}{2}}.$$

Пример 3.13.3. Для вектора, составленного из независимых нормальных законов $N(a_i, \sigma_i^2)$, получаем, что его характеристическая функция

$$\varphi(\boldsymbol{t}) = e^{i\boldsymbol{a}\cdot\boldsymbol{t}}e^{-\frac{1}{2}\sum_{i=1}^d t_i^2\sigma_i^2}.$$

Определив матрицу $\Sigma := \operatorname{diag}(\sigma_i^2)$, последнее можем переписать в виде

$$\varphi(\boldsymbol{t}) = e^{i\boldsymbol{a}\cdot\boldsymbol{t}} e^{-\frac{1}{2}\boldsymbol{t}^\intercal \Sigma \boldsymbol{t}}.$$

Теперь мы готовы к третьему определению гауссовских векторов.

«Гауссовский вектор через характеристические функции». Случайный вектор $\boldsymbol{\xi}\colon \Omega \to \mathbb{R}^d$ называется **гауссовским с распределением $\boldsymbol{N(a, \Sigma)}$** для неслучайных вектора $\boldsymbol{a} \in \mathbb{R}^d$ и симметричной неотрицательно определённой матрицы $\Sigma \in \mathbb{R}^{d\times d}$, если

$$\varphi_{\boldsymbol{\xi}}(\boldsymbol{t}) = e^{i\boldsymbol{a}\cdot\boldsymbol{t}} e^{-\frac{1}{2}\boldsymbol{t}^\intercal \Sigma \boldsymbol{t}}.$$

Плюс этого определения в том, что мы сразу смогли задать параметры $\boldsymbol{a}$ и Σ, которые, как мы скоро увидим, являются вектором средних и матрицей ковариации гауссовского вектора.

Доказательство из «линейных комбинаций» в «характеристические функции» Доказательство. Итак, рассмотрим случайный вектор $\boldsymbol{\xi}\colon \Omega \to \mathbb{R}^d$, гауссовский в том смысле, что для любого $\boldsymbol{\lambda} \in \mathbb{R}^d$ случайная величина

$$\boldsymbol{\lambda}\cdot\boldsymbol{\xi} = \lambda_1\xi_1 + \ldots + \lambda_d\xi_d$$

имеет нормальное распределение. Тогда

$$\varphi_{\boldsymbol{\xi}}(\boldsymbol{\lambda}) = \varphi_{\boldsymbol{\lambda}\cdot\boldsymbol{\xi}}(1) = \mathrm{E}e^{i\boldsymbol{\lambda}\cdot\boldsymbol{\xi}} = e^{i\mathrm{E}\boldsymbol{\lambda}\cdot\boldsymbol{\xi}} e^{-\frac{1}{2}\operatorname{Var}\boldsymbol{\lambda}\cdot\boldsymbol{\xi}} = e^{i\boldsymbol{\lambda}\cdot\mathrm{E}\boldsymbol{\xi}} e^{-\frac{1}{2}\boldsymbol{\lambda}^\intercal\Sigma\boldsymbol{\lambda}},$$

где через Σ обозначена матрица ковариаций вектора $\boldsymbol{\xi}$. □

Доказательство из «характеристических функций» в «аффинные отображения» Доказательство. Итак, рассмотрим случайный вектор $\boldsymbol{\xi}\colon \Omega \to \mathbb{R}^d$, гауссовский в том смысле, что

$$\varphi_{\boldsymbol{\xi}}(\boldsymbol{t}) = e^{i\boldsymbol{a}\cdot\boldsymbol{t}} e^{-\frac{1}{2}\boldsymbol{t}^\intercal \Sigma \boldsymbol{t}}.$$

Так как матрица Σ по определению симметрична и неотрицательно определена, то для некоторой ортогональной матрицы

$S \in \mathbb{R}^{d\times d}$ выполнено

$$S^\intercal \Sigma S = \operatorname{diag}(\lambda_1, \ldots, \lambda_k, \underbrace{0, \ldots, 0}_{d-k \text{ штук}}),$$

где все $\lambda_1, \ldots, \lambda_k$ строго положительны. Обозначим

$$B := \operatorname{diag}\left(\frac{1}{\sqrt{\lambda_1}}, \ldots, \frac{1}{\sqrt{\lambda_k}}, \underbrace{1, \ldots, 1}_{d-k \text{ штук}}\right).$$

Теперь начинается игра с характеристическими функциями:

$$\varphi_{(SB)^\intercal \boldsymbol{\xi}}(\boldsymbol{t}) = \mathrm{E} e^{i\boldsymbol{t}\cdot(SB)^\intercal \boldsymbol{\xi}} = \varphi_{\boldsymbol{\xi}}(SB\boldsymbol{t}) = e^{i\boldsymbol{a}\cdot SB\boldsymbol{t}} e^{-\frac{1}{2}\boldsymbol{t}^\intercal B^\intercal S^\intercal \Sigma S B \boldsymbol{t}}.$$

Поскольку

$$B^\intercal S^\intercal \Sigma S B = \operatorname{diag}(\underbrace{1, \ldots, 1}_{k \text{ штук}}, \underbrace{0, \ldots, 0}_{d-k \text{ штук}}),$$

то

$$\varphi_{(SB)^\intercal \boldsymbol{\xi}}(\boldsymbol{t}) = e^{i\boldsymbol{t}\cdot(SB)^\intercal \boldsymbol{a}} e^{-\frac{1}{2}\sum_{j=1}^k t_j^2} = e^{i\boldsymbol{t}\cdot(SB)^\intercal \boldsymbol{a}} \prod_{j=1}^k \varphi_{\eta_j}(t_j),$$

где все $\eta_j \sim N(0,1)$ независимы. Следовательно, по теореме единственности, чтобы представить $\boldsymbol{\xi}$ в виде

$$\boldsymbol{\xi} = A\boldsymbol{\eta} + \boldsymbol{a},$$

нужно в качестве A взять матрицу $d \times k$, полученную из матрицы $((SB)^\intercal)^{-1}$ удалением лишних $(d-k)$ правых столбцов. □

Довольно естественный вопрос: зачем мы так мучаемся с разными определениями, когда можно просто задать плотность гауссовского вектора, как и в одномерном случае? Ответ на этот вопрос довольно простой: не у всех гауссовских векторов есть плотность.

Пример 3.13.4. Рассмотрим случайную величину $\xi \sim N(0,1)$. Случайный вектор

$$\begin{pmatrix} \xi \\ \xi \end{pmatrix}$$

является гауссовким по определениям через аффинные отображения и через линейные комбинации. При этом он не имеет плотности. В самом деле, его функция распределения равна

$$F(x,y) = \mathrm{P}\{\xi \leqslant x \wedge \xi \leqslant y\} = F_\xi(\min(x,y)),$$

откуда плотность, если бы она существовала, выражалась бы как

$$p(x,y) = \frac{\partial^2 F}{\partial x \partial y}(x,y) = 0$$

при $x \neq y$. Такие распределения называются **сингулярными**.

К обсуждению плотности мы вернёмся чуть позже. Ещё один интересный вопрос: почему мы не объявили гауссовским вектор, который просто составлен из нормальных величин? Ответ: такой вектор может и не быть гауссовским.

Пример 3.13.5. Рассмотрим случайную величину $\xi \sim N(0,1)$ и независимую с ней случайную величину η, принимающую равновероятно значения ± 1. Заметим, что случайная величина $\xi\eta$ тоже имеет нормальное распределение:

$$F_{\xi\eta}(x) = \mathrm{P}\{\xi\eta \leqslant x\} = \frac{\mathrm{P}\{\xi \leqslant x\} + \mathrm{P}\{-\xi \leqslant x\}}{2} = F_\xi(x),$$

где в последнем переходе мы воспользовались тем, что $-\xi$ тоже имеет нормальное распределение $N(0,1)$. При этом вектор

$$\begin{pmatrix} \xi \\ \xi\eta \end{pmatrix}$$

не является гауссовским, так как случайная величина

$$\xi + \xi\eta$$

с вероятностью $\frac{1}{2}$ равна 0 и, таким образом, не может иметь нормальное распределение.

Оказывается, гауссовский вектор обладает ещё одним очень важным свойством: из некоррелируемости его компонент следует их независимость. Как мы знаем, для произвольных случайных величин это неверно!

ТЕОРЕМА 3.13.1

Пусть $\boldsymbol{\xi} \sim N(\boldsymbol{a}, \Sigma)$ и подматрица матрицы Σ, образованная строками и столбцами с одними и теми же номерами, диагональная. Тогда компоненты, соответствующие строкам и столбцам этой подматрицы, независимы в совокупности.

Доказательство. По определению через аффинные отображения можно считать, что $\boldsymbol{\xi}$ и есть вектор, составленный из данных компонентов, и что матрица Σ диагональная. Кроме того, можно считать, что все компоненты гауссовского вектора $\boldsymbol{\xi}$ отцентрированы и отнормированы, то есть $\boldsymbol{a} = \mathbf{0}$ и $\Sigma = I_d$. Тогда

$$\varphi_{\boldsymbol{\xi}}(\boldsymbol{t}) = e^{-\frac{1}{2}\sum_{k=1}^d t_k^2} = \prod_{k=1}^d \varphi_{\xi_k}(t_k).$$

Равенство первого и третьего члена для всех $\boldsymbol{t} \in \mathbb{R}^d$ равносильно независимости компонентов вектора $\boldsymbol{\xi}$. □

Пример 3.13.6. Стоит отметить, что в примере 3.13.5 выполнено

$$\mathrm{cov}(\xi, \xi\eta) = \mathrm{E}(\xi^2\eta) - \mathrm{E}\xi\mathrm{E}\xi\eta = 0 - 0 = 0,$$

то есть величины имеют нулевую ковариацию, но при этом, очевидно, не являются независимыми. А всё потому, что, опять же,

не образуют гауссовский вектор.

Интересно посмотреть на преобразование гауссовского вектора.

ТЕОРЕМА 3.13.2

Рассмотрим d-мерный гауссовский вектор $\boldsymbol{\xi} \sim N(\boldsymbol{a}, \Sigma)$. Тогда для произвольных $A \in \mathbb{R}^{s\times d}$ и $\boldsymbol{b} \in \mathbb{R}^s$ случайный вектор

$$A\boldsymbol{\xi} + \boldsymbol{b}$$

тоже является гауссовским с распределением

$$N(A\boldsymbol{a} + \boldsymbol{b}, A\Sigma A^\intercal).$$

Доказательство. Нужно аккуратно расписать характеристическую функцию:

$$\begin{aligned}\varphi_{A\boldsymbol{\xi}+\boldsymbol{b}}(\boldsymbol{t}) = \mathrm{E}e^{i\boldsymbol{t}\cdot(A\boldsymbol{\xi}+\boldsymbol{b})} = e^{i\boldsymbol{t}\cdot\boldsymbol{b}}\mathrm{E}e^{i\boldsymbol{t}^\intercal A\boldsymbol{\xi}} = e^{i\boldsymbol{t}\cdot\boldsymbol{b}}\mathrm{E}e^{i(A^\intercal\boldsymbol{t})^\intercal\boldsymbol{\xi}} = \\ = e^{i\boldsymbol{t}\cdot\boldsymbol{b}}\varphi_{\boldsymbol{\xi}}(A^\intercal\boldsymbol{t}) = e^{i\boldsymbol{t}\cdot\boldsymbol{b}}e^{iA^\intercal\boldsymbol{t}\cdot\boldsymbol{a}}e^{-\frac{1}{2}(A^\intercal\boldsymbol{t})^\intercal\Sigma A^\intercal\boldsymbol{t}} = \\ = e^{i\boldsymbol{t}\cdot(A\boldsymbol{a}+\boldsymbol{b})}e^{-\frac{1}{2}\boldsymbol{t}^\intercal A\Sigma A^\intercal\boldsymbol{t}}.\end{aligned}$$

□

ТЕОРЕМА 3.13.3

Пусть $\boldsymbol{\xi} \sim N(\boldsymbol{0}, \Sigma)$ для невырожденной матрицы $\Sigma \in \mathbb{R}^{d\times d}$. Тогда

$$\Sigma^{-\frac{1}{2}}\boldsymbol{\xi} \sim N(\boldsymbol{0}, I_d).$$

Доказательство. По предыдущей теореме:

$$\Sigma^{-\frac{1}{2}}\boldsymbol{\xi} \sim N(\boldsymbol{0}, \Sigma^{-\frac{1}{2}}\Sigma\Sigma^{-\frac{1}{2}}) = N(0, I_d).$$

□

ТЕОРЕМА 3.13.4

Пусть $\boldsymbol{\xi} \sim N(\boldsymbol{a}, \Sigma)$ для невырожденной матрицы $\Sigma \in \mathbb{R}^{d\times d}$. Тогда этот гауссовский вектор является абсолютно непрерывным и имеет плотность

$$p_{\boldsymbol{\xi}}(\boldsymbol{x}) = \frac{1}{\sqrt{|\det\Sigma|}(2\pi)^{d/2}}e^{-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{a})^\intercal\Sigma^{-1}(\boldsymbol{x}-\boldsymbol{a})}.$$

Доказательство. В ситуации с диагональной матрицей ковариаций плотность факторизуется, и получается ответ, который мы выводили из физических предположений. В общем случае можно считать, что сдвига нет, то есть $\boldsymbol{a} = \boldsymbol{0}$, и нужно рассмотреть гауссовский вектор $\boldsymbol{\eta} \sim N(\boldsymbol{0}, I_d)$. По предыдущей теореме:

$$\boldsymbol{\xi} = \Sigma^{\frac{1}{2}}\boldsymbol{\eta}.$$

Заметим, что матрица $\Sigma^{\frac{1}{2}}$ задаёт диффеоморфное преобразование пространства $\mathbb{R}^d$, а потому вектор ξ тоже является абсолютно непрерывным, и его плотность получается из плотности вектора η

вычислением через якобиан преобразования

$$\boldsymbol{x} = \Sigma^{\frac{1}{2}} \boldsymbol{y}.$$

А именно:

$$p_{\boldsymbol{\xi}}(\boldsymbol{x}) = p_{\boldsymbol{\eta}}(\Sigma^{-\frac{1}{2}}\boldsymbol{x}) \left|\frac{\partial \boldsymbol{x}}{\partial \boldsymbol{y}}\right|^{-1} =$$
$$= \frac{1}{\sqrt{|\det \Sigma|}(2\pi)^{d/2}} e^{-\frac{1}{2}(\Sigma^{-\frac{1}{2}}\boldsymbol{x})^{\intercal}(\Sigma^{-\frac{1}{2}}\boldsymbol{x})} =$$
$$= \frac{1}{\sqrt{|\det \Sigma|}(2\pi)^{d/2}} e^{-\frac{1}{2}\boldsymbol{x}^{\intercal}\Sigma^{-1}\boldsymbol{x}}.$$

□

Напоследок обсудим ещё одно важное свойство гауссовских векторов, активно применяющееся в статистике при обсуждении линейных моделей.

ТЕОРЕМА 3.13.5

Рассмотрим гауссовский вектор $\boldsymbol{\xi} \sim N(\boldsymbol{a}, \sigma^2 I_d)$. Пусть

$$\mathbb{R}^d = L_1 \oplus \ldots \oplus L_r.$$

Обозначим через

$$\boldsymbol{\eta}_j := \operatorname*{proj}_{L_j} \boldsymbol{\xi}$$

проекцию на подпространство L_j для $j = 1, \ldots, r$. Тогда все проекции $\boldsymbol{\eta}_j$ независимы в совокупности, а также

$$\frac{1}{\sigma^2} |\boldsymbol{\eta}_j - \mathrm{E}\boldsymbol{\eta}_j|^2 \sim \chi^2(\dim L_j).$$

Доказательство. Идея доказательства в том, что если перейти в базис подпространств L_j, то в разложении вектора $\boldsymbol{\xi}$ по этим подпространствам его компоненты тоже окажутся независимы. Отсюда квадраты длин автоматически будут иметь распределение хи-квадрат.

Обозначим $\dim L_j =: d_j$. Возьмём в $\mathbb{R}^d$ такой ортонормированный базис $\boldsymbol{f}_1, \ldots, \boldsymbol{f}_d$, что первые d_1 векторов являются базисом подпространства L_1, следующие d_2 векторов являются базисом подпространства L_2 и так далее. Для $k = 1, \ldots, d$ положим

$$\zeta_k := \boldsymbol{f}_k \cdot \boldsymbol{\xi}.$$

Таким образом, если обозначить через F ортогональную матрицу, строками которой являются $\boldsymbol{f}_k^{\intercal}$, то

$$\boldsymbol{\zeta} = F\boldsymbol{\xi}$$

тоже является гауссовским вектором $N(F\boldsymbol{a}, \sigma^2 F F^{\intercal}) =$

$N(F\boldsymbol{a}, \sigma^2 I_d)$ с независимыми компонентами. Тогда векторы

$$\begin{gathered}\boldsymbol{\eta}_1 = \zeta_1 \boldsymbol{f}_1 + \ldots + \zeta_{d_1} \boldsymbol{f}_{d_1}, \\ \boldsymbol{\eta}_2 = \zeta_{d_1+1} \boldsymbol{f}_{d_1+1} + \ldots + \zeta_{d_1+d_2} \boldsymbol{f}_{d_1+d_2}, \\ \vdots \\ \boldsymbol{\eta}_j = \zeta_{d_1+\ldots+d_{j-1}+1} \boldsymbol{f}_{d_1+\ldots+d_{j-1}+1} + \ldots + \zeta_{d_1+\ldots+d_j} \boldsymbol{f}_{d_1+\ldots+d_j}, \\ \vdots \\ \boldsymbol{\eta}_r = \zeta_{d_1+\ldots+d_{r-1}+1} \boldsymbol{f}_{d_1+\ldots+d_{r-1}+1} + \ldots + \zeta_{d_1+\ldots+d_r} \boldsymbol{f}_{d_1+\ldots+d_r}\end{gathered}$$

независимы в совокупности. Осталось найти распределения их длин. Для этого заметим, что

$$\frac{\zeta_k - \mathrm{E}\zeta_k}{\sigma} \sim N(0,1),$$

и тогда

$$\begin{aligned}\frac{1}{\sigma^2} |\boldsymbol{\eta}_j - \mathrm{E}\boldsymbol{\eta}_j|^2 &= \left| \sum_{k=d_1+\ldots+d_{j-1}+1}^{d_1+\ldots+d_j} \frac{\zeta_k - \mathrm{E}\zeta_k}{\sigma} \boldsymbol{f}_k \right|^2 = \\ &= \sum_{k=d_1+\ldots+d_{j-1}+1}^{d_1+\ldots+d_j} \left(\frac{\zeta_k - \mathrm{E}\zeta_k}{\sigma} \right)^2 \sim \chi^2(d_j).\end{aligned}$$

□

14. СХОДИМОСТИ

В курсе теории меры рассматривались различные виды сходимостей последовательности случайных величин. Они практически без изменений переносятся на случайные величины и случайные векторы. Так,

- сходимость почти всюду становится сходимостью почти наверное,
- сходимость по мере становится сходимостью по вероятности.

Случайные векторы $\boldsymbol{\xi_n}$ сходятся **почти наверное** к случайному вектору $\boldsymbol{\xi}$, если

$$\mathrm{P}\{\boldsymbol{\xi_n} \to \boldsymbol{\xi}\} = 1.$$

Такую сходимость обозначают как $\boldsymbol{\xi_n} \xrightarrow[n\to\infty]{\text{п.н.}} \boldsymbol{\xi}$.

ЗАМЕЧАНИЕ

Если понятие сходимости п.н. для случайных величин дается тяжело, то вспомним, где раньше появлялась подобная сходимость.

Мы пишем $n \to \infty$ — значит, речь идет о сходимости последовательности. Последовательности каких элементов? У нас случайные величины, это измеримые функции от случайного аргумента ω.

Встречалась ли раньше сходимость последовательности функций? Да, в математическом анализе: $f_n(x) \xrightarrow[n\to\infty]{} f(x),\ x \in X$.

Самый просто вид сходимости последовательности функций —

поточечная сходимость, т.е. для любого $x_0 \in X$ числовая последовательность $f_n(x_0)$ сходится к числу $f(x_0)$.

В определении сходимости п.н рассматриваются точки $\omega:\ \{\xi_n(\omega) \to \xi(\omega)\}$ и объявляется, что вероятность такого события равна 1.

Напомним, что под сходимостью неслучайных векторов $\boldsymbol{\xi_n}(\omega) \to \boldsymbol{\xi}(\omega)$ подразумевается сходимость расстояния между векторами к нулю. Расстояние, в свою очередь, считается евклидовым. То есть для $\boldsymbol{x} \in \mathbb{R}^d$ введём норму

$$\|\boldsymbol{x}\| := \sqrt{x_1^2 + \ldots + x_d^2}.$$

Тогда под сходимостью **случайных векторов** подразумевается сходимость нормы разности к нулю. На самом деле можно брать и любую другую норму, так как они все эквивалентны на $\mathbb{R}^d$.

Иногда бывает полезен другой, более слабый вид сходимости. Случайные векторы $\boldsymbol{\xi_n}$ сходятся **по вероятности** к случайному вектору $\boldsymbol{\xi}$, если для любого $\varepsilon > 0$

$$\mathrm{P}\left\{\|\boldsymbol{\xi_n} - \boldsymbol{\xi}\| < \varepsilon\right\} \xrightarrow[n\to\infty]{} 1$$

или, что то же самое,

$$\mathrm{P}\left\{\|\boldsymbol{\xi_n} - \boldsymbol{\xi}\| \geqslant \varepsilon\right\} \xrightarrow[n\to\infty]{} 0.$$

Такую сходимость обозначают как $\boldsymbol{\xi_n} \xrightarrow[n\to\infty]{\mathrm{P}} \boldsymbol{\xi}$. **Смысл её предельно прост: вероятности плохих событий стремятся к нулю**, где плохими событиями называются те, на которых случайные величины далеки.

Пример 3.14.1. Пусть $\xi_n \sim \mathrm{Bern}(p_n)$, где $p_n \to 0$. Тогда $\xi_n \xrightarrow[n\to\infty]{\mathrm{P}} 0$, так как вероятности плохих множеств в точности равны p_n.

В сходимости по вероятности мы следим только за тем, чтобы плохие события имели маленькую вероятность. Причём то, насколько эти события плохие, нас особо не интересует. Если же мы зададимся вопросом, насколько плохо себя ведут величины на этих плохих событиях, мы придём к следующему определению.

Сперва, введём p-норму вектора в $\mathbb{R}^d$ как

$$\|\boldsymbol{x}\|_p := \left(|x_1|^p + \ldots + |x_d|^p\right)^{\frac{1}{p}}.$$

Например, $\|\boldsymbol{x}\|_2$ это просто евклидово расстояние, а $\|\boldsymbol{x}\|_1$ это Манхэттеновское расстояние.

Случайные векторы $\boldsymbol{\xi_n}$ сходятся **в $\boldsymbol{L_p}$** к случайному вектору $\boldsymbol{\xi}$, если у всех векторов их p-нормы имеют конечные матожидания, и

$$\mathrm{E}\,\|\boldsymbol{\xi}_n - \boldsymbol{\xi}\|_p^p \xrightarrow[n\to\infty]{} 0.$$

Пишут $\boldsymbol{\xi}_n \xrightarrow[n\to\infty]{L_p} \boldsymbol{\xi}$. Иногда эту сходимость называют **сходимостью в $\boldsymbol{p}$-среднем**, поскольку теперь считают не просто вероят-

ность плохих множеств, а усредняют, насколько плохо себя на этих множествах ведут случайные величины.

Пример 3.14.2. Пусть $\xi_n \sim \mathrm{Bern}(p_n)$ и $p_n \to 0$. Тогда $\xi_n \xrightarrow[n\to\infty]{L_p} 0$, поскольку

$$\mathrm{E}\,|\xi_n - 0|^p = p_n \xrightarrow[n\to\infty]{} 0.$$

Обычно в ТВ и статистике мы работаем не с самими случайными величинами, как с функциями, а с их распределениями. Этому и посвящён последний вид сходимости. Случайные векторы $\boldsymbol{\xi_n}$ сходятся **по распределению** к случайному вектору $\boldsymbol{\xi}$, если

$$F_{\boldsymbol{\xi_n}}(\boldsymbol{x}) \xrightarrow[n\to\infty]{} F_{\boldsymbol{\xi}}(\boldsymbol{x})$$

для всех точек $\boldsymbol{x} \in \mathbb{R}^d$ непрерывности функции распределения $F_{\boldsymbol{\xi}}$.

Такую сходимость обозначают как $\boldsymbol{\xi_n} \xrightarrow[n\to\infty]{d} \boldsymbol{\xi}$.

Смысл последнего определения в том, что распределения случайных векторов сходятся к распределению предела.

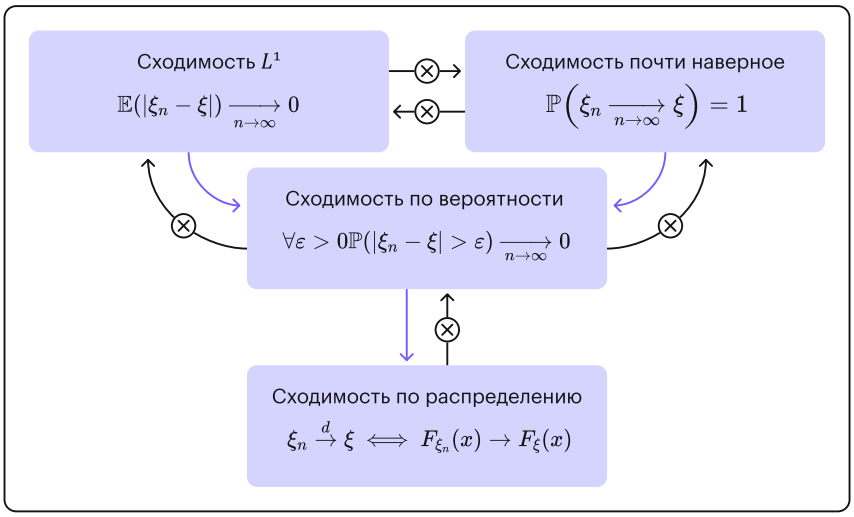

Рисунок 22. Взаимосвязи между сходимостями

	Сходимость L_1	Сходимость почти вероятна	Сходимость по вероятности	Пример
Кол-во вариантов = **2** Кол-во сходимостей = **3** $N = k^n = 2^3 = 8$	✓	✓	✓	$X_n = \frac{1}{n}$
	✓	✓	✗	$\nexists$
	✓	✗	✗	$\nexists$
	✓	✗	✓	Пример Рисса бегающих отрезков
	✗	✓	✗	$\nexists$
	✗	✓	✓	$X_n = n\mathbf{1}_{[0,\,1/n)}(U)$
	✗	✗	✓	Пример Рисса бегающих отрезков с растущей амплитудой
	✗	✗	✗	$X_n = (-1)^n$

Рисунок 23. Примеры различных комбинаций видов сходимостей

Иногда на практике удобно воспользоваться другим определением, которое даёт следующая теорема.

ТЕОРЕМА 3.14.1

Сходимость по распределению $\boldsymbol{\xi_n} \xrightarrow[n\to\infty]{d} \boldsymbol{\xi}$ равносильна тому, что для любой ограниченной непрерывной функции $f\colon \mathbb{R}^d \to \mathbb{R}$ выполнено

$$\mathrm{E} f(\boldsymbol{\xi_n}) \xrightarrow[n\to\infty]{} \mathrm{E} f(\boldsymbol{\xi}).$$

Необходимость в этой теореме доказывается довольно сложно. Достаточность же следует из следующей теоремы.

ТЕОРЕМА 3.14.2

Сходимость по распределению $\boldsymbol{\xi}_n \xrightarrow[n\to\infty]{d} \boldsymbol{\xi}$ равносильна поточечной сходимости $\varphi_{\boldsymbol{\xi}_n}(\boldsymbol{t}) \xrightarrow[n\to\infty]{} \varphi_{\boldsymbol{\xi}}(\boldsymbol{t})$ во всех $\boldsymbol{t} \in \mathbb{R}^d$.

Доказательство достаточности в теореме Александрова Доказательство. в качестве непрерывной и ограниченной функции надо сначала взять $f(\boldsymbol{x}) = \sin(\boldsymbol{t}\cdot\boldsymbol{x})$, потом $f(\boldsymbol{x}) = \cos(\boldsymbol{t}\cdot\boldsymbol{x})$. Получить сходимости

$$\begin{gathered}\mathrm{E}\sin(\boldsymbol{t}\cdot\boldsymbol{\xi_n}) \xrightarrow[n\to\infty]{} \mathrm{E}\sin(\boldsymbol{t}\cdot\boldsymbol{\xi}),\\ \mathrm{E}\cos(\boldsymbol{t}\cdot\boldsymbol{\xi_n}) \xrightarrow[n\to\infty]{} \mathrm{E}\cos(\boldsymbol{t}\cdot\boldsymbol{\xi}),\\ \forall \boldsymbol{t} \in \mathbb{R}^d\,,\end{gathered}$$

что сразу даёт сходимость характеристических функций, а значит, в силу теоремы непрерывности, сходимость случайных величин по распределению. А вот необходимость доказывается намного сложнее и это мы пропустим. □

Из сходимости почти наверное следует сходимость по вероятности. Из сходимости в L_p следует сходимость по вероятности. Из

ТЕОРЕМА 3.14.3

сходимости по вероятности следует сходимость по распределению. Других следствий нет.
См. на рисунках 22, 23 пояснение к теореме.

Доказательство. Связь сходимости почти наверное и по вероятности следует из взаимосвязи между сходимостями почти всюду и по мере. Из L_p следует сходимость по вероятности по неравенству Маркова:

$$\mathrm{P}\{|\xi_n - \xi| > \varepsilon\} \leqslant \frac{\mathbb{E}\,|\xi_n - \xi|_p^p}{\varepsilon^p} \xrightarrow[n\to\infty]{} 0.$$

Докажем, что из сходимости по вероятности следует сходимость по распределению. Для простоты, рассмотрим случай случайных величин. Пусть $\xi_n \xrightarrow[n\to\infty]{\mathrm{P}} \xi$. Рассмотрим точку непрерывности a функции распределения F_ξ. Заметим, что для любых случайных величин X, Y выполнено

$$\{X \leqslant c\} \subset \{Y \leqslant c + \varepsilon\} \cup \{|X - Y| > \varepsilon\},$$

откуда

$$\mathrm{P}\{X \leqslant c\} \leqslant \mathrm{P}\{Y \leqslant c + \varepsilon\} + \mathrm{P}\{|X - Y| > \varepsilon\}.$$

Поэтому,

$$\mathrm{P}\{\xi_n \leqslant a\} \leqslant \mathrm{P}\{\xi \leqslant a + \varepsilon\} + \mathrm{P}\{|\xi_n - \xi| > \varepsilon\},$$
$$\mathrm{P}\{\xi \leqslant a - \varepsilon\} \leqslant \mathrm{P}\{\xi_n \leqslant a\} + \mathrm{P}\{|\xi_n - \xi| > \varepsilon\}.$$

Отсюда

$$\mathrm{P}\{\xi \leqslant a - \varepsilon\} - \mathrm{P}\{|\xi_n - \xi| > \varepsilon\} \leqslant \mathrm{P}\{\xi_n \leqslant a\} \leqslant \\ \leqslant \mathrm{P}\{\xi \leqslant a + \varepsilon\} + \mathrm{P}\{|\xi_n - \xi| > \varepsilon\}.$$

Переходя к пределу по $n \to \infty$, получаем

$$F_\xi(a - \varepsilon) \leqslant \varliminf_{n\to\infty} F_{\xi_n}(a) \leqslant F_\xi(a + \varepsilon).$$

В силу того, что a является точкой непрерывности функции F_ξ, переходя к пределу по $\varepsilon \to 0$, получаем, что

$$\lim_{\varepsilon\to 0} F_\xi(a + \varepsilon) = \lim_{\varepsilon\to 0} F_\xi(a - \varepsilon) = F_\xi(a),$$

откуда

$$\lim_{n\to\infty} F_{\xi_n}(a) = F_\xi(a),$$

что и требовалось. □

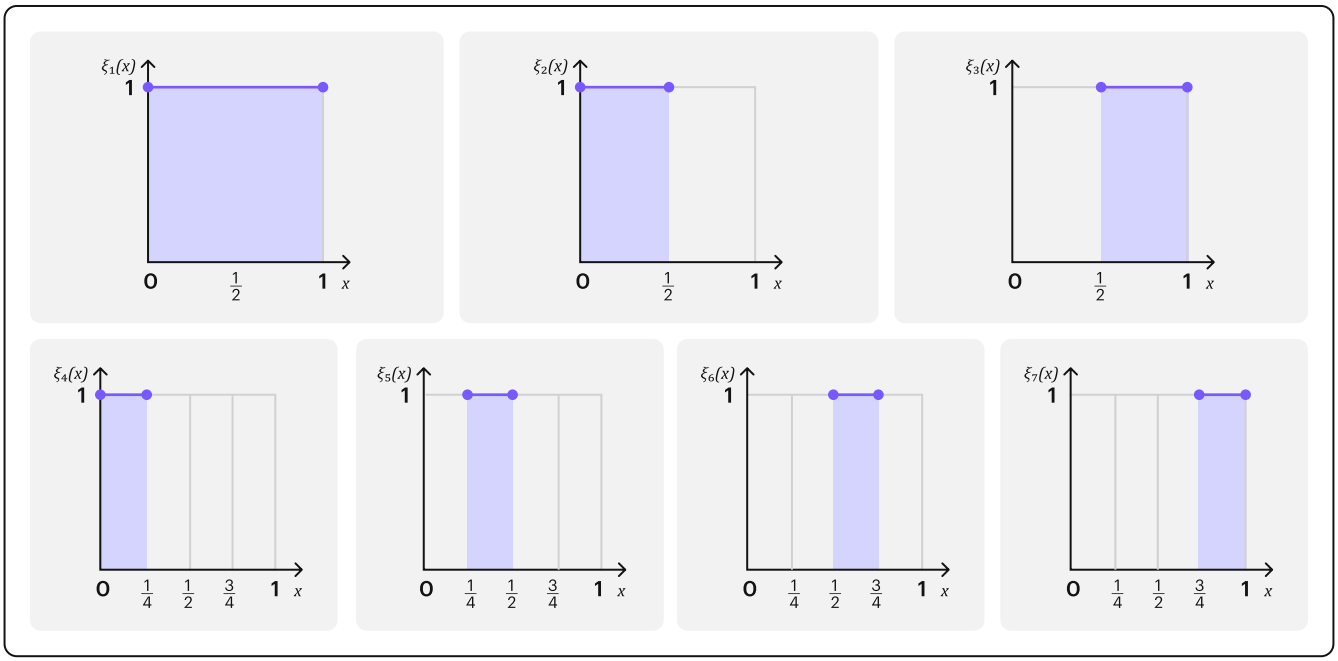

Рисунок 24. Случайные величины $\xi_1, \ldots, \xi_7$ из контрпримера Рисса

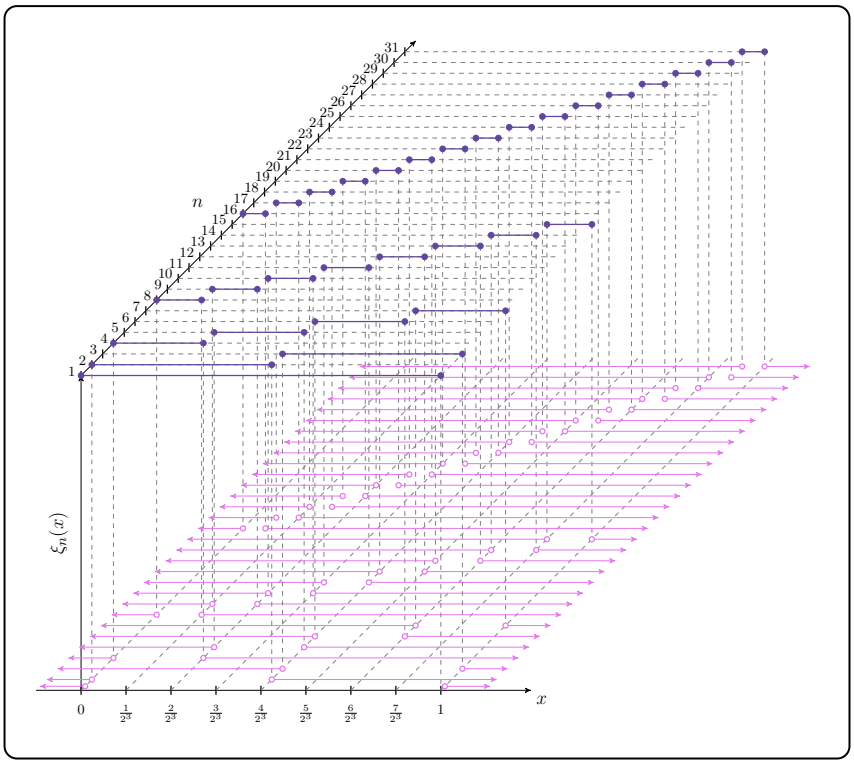

Рисунок 25. Функции $f_1, \ldots, f_{31}$ из контрпримера Рисса

Контрпример Рисса про бегающие отрезки (в английской литературе его называют typewriter sequence) показывает, почему из сходимости по вероятности не всегда следует сходимость почти наверное.

Контрпример Рисса

Пример 3.14.3. ледующий пример показывает, что из сходимости по вероятности не всегда следует сходимость почти наверное. В

английской литературе его называют typewriter sequence. Иногда встречается название «бегающие отрезки».

На вероятностном пространстве $[0,\,1]$ с равномерной вероятностью рассмотрим последовательность подотрезков

$$\left[0,\,1\right], \left[0,\,\frac{1}{2}\right], \left[\frac{1}{2},\,1\right], \left[0,\,\frac{1}{4}\right], \left[\frac{1}{4},\,\frac{2}{4}\right],$$
$$\left[\frac{2}{4},\,\frac{3}{4}\right], \left[\frac{3}{4},\,1\right], \left[0,\,\frac{1}{8}\right], \left[\frac{1}{8},\,\frac{2}{8}\right], \ldots$$

В качестве случайной величины ξ_n возьмём индикатор n-го подотрезка (смотри графики первых нескольких функций на рисунках 24, 25).

Тогда $\xi_n \xrightarrow[n\to\infty]{\mathrm{P}} 0$, так как длины подотрезков стремятся к нулю. Но при этом в каждой точке $\omega \in [0,\,1]$ среди значений $\xi_n(\omega)$ бесконечно часто появляются как нули, так и единицы, что означает отсутствие сходимости в любой точке отрезка. Таким образом, ξ_n сходятся к нулю по вероятности, но не почти наверное.

Теперь напомним, почему из сходимости по распределению не следует сходимость по вероятности.

Пример 3.14.4. Рассмотрим случайные величины $\xi_n \sim \mathrm{Bern}(\frac{1}{2})$, тождественно равные друг другу. Положим $\xi := 1 - \xi_n$. Тогда $\xi \sim \mathrm{Bern}(\frac{1}{2})$. Значит, есть сходимость по распределению ξ_n к ξ. Но $\|\xi_n - \xi\| = 1$, поэтому сходимости по вероятности нет.

ТЕОРЕМА 3.14.4

Если $\boldsymbol{\xi}_n \xrightarrow[n\to\infty]{d} \boldsymbol{C} \in \mathbb{R}^d$, то $\boldsymbol{\xi}_n \xrightarrow[n\to\infty]{\mathrm{P}} \boldsymbol{C}$.

Смысл теоремы 3.14.4 в том, что в принципе бывают разные случайные величины с одинаковым распределением, но если это распределение константное, то все эти случайные величины оказываются равными между собой (с точностью до п.н.).

Доказательство. [Доказательство теоремы 3.14.4] По теореме 3.15.1 из векторной сходимости по распределению следует покомпонентная. Доказав покомпонентно сходимость по вероятности, мы получим и векторную сходимость по вероятности. Таким образом, достаточно доказать теорему в одномерном случае.

Итак, зафиксируем произвольное $\varepsilon > 0$. Заметим, что функция F_C имеет разрыв с 0 до 1 только в точке C, так что точки $C \pm \varepsilon$ являются её точками непрерывности. Поэтому

$$\mathrm{P}\{|\xi_n - C| \leqslant \varepsilon\} = F_{\xi_n}(C+\varepsilon) - F_{\xi_n}(C-\varepsilon-0) \geqslant$$
$$\geqslant F_{\xi_n}(C+\varepsilon) - F_{\xi_n}(C-\varepsilon) \xrightarrow[n\to\infty]{} F_C(C+\varepsilon) - F_C(C-\varepsilon) =$$
$$= 1 - 0 = 1,$$

что и означает сходимость по вероятности. □

15. НАСЛЕДОВАНИЕ СХОДИМОСТИ

Здесь мы научимся работать со сходимостями не только по определению, но и через их аналитические свойства. Для начала, рассмотрим связи между сходимостью векторов и их компонент.

ТЕОРЕМА 3.15.1

Для сходимостей почти наверное и по вероятности сходимости векторов и их компонентов равносильны. Из векторной сходимости по распределению следует покомпонентная, но обратное в общем случае неверно.

Доказательство. Для сходимости почти наверное для каждой $\omega \in \Omega$ утверждение является свойством сходимостей неслучайных векторов.

Для сходимости по вероятности нужно показать равносильность

$$\|\boldsymbol{\xi_n} - \boldsymbol{\xi}\| \xrightarrow[n\to\infty]{\mathrm{P}} 0 \iff \forall i = 1, \ldots, d \ : \ \left|\xi_n^i - \xi^i\right| \xrightarrow[n\to\infty]{\mathrm{P}} 0.$$

Она следует из того, что для любого $x \in \mathbb{R}^d$

$$\max_{i=1,\ldots,d} \left|x^i\right| \leqslant \|\boldsymbol{x}\| \leqslant \sqrt{d} \max_{i=1,\ldots,d} \left|x^i\right|.$$

Покажем, что из векторной сходимости по распределению следует покомпонентная. Для каждого $i \in \{1, \ldots, d\}$ рассмотрим проектор $\pi^i \colon \mathbb{R}^d \to \mathbb{R}$, действующий по правилу $\pi^i(\boldsymbol{x}) = x^i$. Тогда для любой ограниченной непрерывной функции $f \colon \mathbb{R} \to$ $\to \mathbb{R}$ функция $f \circ \pi^i \colon \mathbb{R}^d \to \mathbb{R}$ тоже ограниченная и непрерывная. Поэтому, если $\boldsymbol{\xi_n} \xrightarrow[n\to\infty]{d} \boldsymbol{\xi}$, то

$$\mathrm{E} f(\xi_n^i) = \mathrm{E} f(\pi^i(\boldsymbol{\xi_n})) \xrightarrow[n\to\infty]{} \mathrm{E} f(\pi^i(\boldsymbol{\xi})) = \mathrm{E} f(\xi^i).$$

Приведём пример, который показывает, что из покомпонентной сходимости по распределению не следует векторная. Рассмотрим произвольную случайную величину ξ. Пусть ξ_n, η_n — независимые случайные величины, распределение которых совпадает с распределением случайной величины ξ. Тогда

$$\xi_n \xrightarrow[n\to\infty]{d} \xi, \quad \eta_n \xrightarrow[n\to\infty]{d} \xi,$$

но

$$\begin{pmatrix} \xi_n \\ \eta_n \end{pmatrix} \xrightarrow[n\to\infty]{\not{d}} \begin{pmatrix} \xi \\ \xi \end{pmatrix},$$

так как случайные величины $\xi_n - \eta_n$ имеют одно и то же невырожденное распределение и не сходятся по распределению к $\xi - \xi = 0$. Это противоречит следующей теореме. □

ТЕОРЕМА 3.15.2

Пусть:

- случайные векторы $\boldsymbol{\xi}_n\colon\ \Omega \to \mathbb{R}^d$ сходятся к случайному вектору $\boldsymbol{\xi}\colon\ \Omega \to \mathbb{R}^d$ почти наверное, по вероятности или по распределению;
- борелевская функция $\boldsymbol{f}\colon\ \mathbb{R}^d \to \mathbb{R}^s$ непрерывна P_ξ-п.н., то есть $\boldsymbol{f}$ непрерывна на некотором борелевском множестве $B \in \mathcal{B}(\mathbb{R}^d)$, для которого $\mathrm{P}\{\boldsymbol{\xi} \in B\} = 1$.

Тогда случайные векторы $\boldsymbol{f}(\boldsymbol{\xi_n})\colon\ \Omega \to \mathbb{R}^s$ сходятся к случайному вектору $\boldsymbol{f}(\boldsymbol{\xi})\colon\ \Omega \to \mathbb{R}^s$ в том же смысле.

Доказательство.

1. Для сходимости почти наверное заключение теоремы следует из того, что

$$\{\boldsymbol{f}(\boldsymbol{\xi_n}) \to \boldsymbol{f}(\boldsymbol{\xi})\} \supset \{\boldsymbol{\xi_n} \to \boldsymbol{\xi}\} \cap \{\boldsymbol{\xi} \in B\},$$

   где вероятности множеств справа (а потому и слева) равны единице.
2. Для сходимости по вероятности предположим противное. Тогда для некоторых ε, γ существует подпоследовательность n_k, для которой

$$\mathrm{P}\{\|\boldsymbol{\xi}_{n_k} - \boldsymbol{\xi}\| > \varepsilon\} > \gamma.$$

   Здесь воспользуемся теоремой Рисса: она позволяет из последовательности, сходящейся по вероятности, выделить подпоследовательность, сходящуюся почти наверное. То есть можем выделить подпоследовательность n_{k_m}, для которой $\boldsymbol{\xi}_{n_{k_m}}$ сходятся п.н. к ξ. Тогда $\boldsymbol{f}(\boldsymbol{\xi}_{n_{k_m}})$ сходятся п.н. к $\boldsymbol{f}(\boldsymbol{\xi})$. Значит, они сходятся и по вероятности, что противоречит выбору последовательности n_k.
3. Для сходимости по распределению доказательство технически сложное. Мы разберём только случай, когда функция $\boldsymbol{f}$ непрерывна всюду на $\mathbb{R}^d$. В этом случае для любой ограниченной непрерывной функции $g\colon\ \mathbb{R}^s \to \mathbb{R}$ функция $g \circ \boldsymbol{f}\colon\ \mathbb{R}^d \to \to \mathbb{R}$ тоже ограничена и непрерывна, потому

$$\mathrm{E}g(\boldsymbol{f}(\boldsymbol{\xi}_n)) \xrightarrow[n\to\infty]{} \mathrm{E}g(\boldsymbol{f}(\boldsymbol{\xi})).$$

□

Теорема о наследовании сходимости позволяет проворачивать следующие трюки. Пусть имеются случайные величины $\xi_n \xrightarrow[n\to\infty]{\mathrm{P}} \xi$ и $\eta_n \xrightarrow[n\to\infty]{\mathrm{P}} \eta$. Интуитивно хочется их сложить и получить, что

$$\xi_n + \eta_n \xrightarrow[n\to\infty]{\mathrm{P}} \xi + \eta.$$

Оказывается, это действительно можно сделать! Нужно сначала

сказать, что

$$\begin{pmatrix} \xi_n \\ \eta_n \end{pmatrix} \xrightarrow[n\to\infty]{\mathrm{P}} \begin{pmatrix} \xi \\ \eta \end{pmatrix}.$$

Затем применяем теорему о наследовании сходимости для $f(x,y) = x + y$, чтобы получить сходимость суммы случайных величин к сумме пределов.

К сожалению, первый шаг ломается, если вместо сходимости по вероятности имеется сходимость по распределению $\xi_n \xrightarrow[n\to\infty]{d} \xi$ и $\eta_n \xrightarrow[n\to\infty]{d} \eta$. Тогда $\xi_n + \eta_n$ может не сойтись по распределению к $\xi + \eta$. В таком случае не выйдет объединить величины в случайный вектор и не потерять сходимость.

А значит, не получится применить теорему о наследовании сходимости, чтобы получить сходимость суммы случайных величин к сумме пределов. Эту проблему в некоторых случаях решит лемма Слуцкого.

ЛЕММА 3.15.1

Пусть случайные векторы $\boldsymbol{\xi}_n \colon \Omega \to \mathbb{R}^d$ сходятся по распределению к $\boldsymbol{\xi}$, а случайные векторы $\boldsymbol{\eta}_n \colon \Omega \to \mathbb{R}^s$ сходятся по распределению к константе $\boldsymbol{C} \in \mathbb{R}^s$. Тогда случайные векторы

$$\begin{pmatrix} \boldsymbol{\xi}_n \\ \boldsymbol{\eta}_n \end{pmatrix} : \Omega \to \mathbb{R}^{d+s}$$

сходятся по распределению к случайному вектору

$$\begin{pmatrix} \boldsymbol{\xi} \\ \boldsymbol{C} \end{pmatrix} : \Omega \to \mathbb{R}^{d+s}.$$

Иногда леммой Слуцкого называют не это общее утверждение, а следующее из него и из теоремы о наследовании сходимости частное, применяемое на практике.

СЛЕДСТВИЕ 3.15.1

Пусть $\xi_n \xrightarrow[n\to\infty]{d} \xi$ и $\eta_n \xrightarrow[n\to\infty]{d} C$. Тогда

$$\xi_n + \eta_n \xrightarrow[n\to\infty]{d} \xi + C, \quad \xi_n \eta_n \xrightarrow[n\to\infty]{d} \xi \cdot C.$$

Смысл леммы Слуцкого в том, что сходимость к константе несёт в себе гораздо больше информации про случайные величины, чем просто сходимость к некоторой величине. Формально это очень похоже на теорему 3.14.4.

Лемма Слуцкого Доказательство. Для случайных векторов

$(\boldsymbol{\xi}_n, \boldsymbol{\eta}_n)$ характеристические функции равны

$$\varphi_n(\boldsymbol{x}, \boldsymbol{y}) = \mathrm{E} e^{i\boldsymbol{x}\cdot\boldsymbol{\xi}_n} e^{i\boldsymbol{y}\cdot\boldsymbol{\eta}_n},$$

где $\boldsymbol{x} \in \mathbb{R}^d$ и $\boldsymbol{y} \in \mathbb{R}^s$. Для предельного вектора $(\boldsymbol{\xi}, \boldsymbol{C})$ имеем

$$\varphi(\boldsymbol{x}, \boldsymbol{y}) = \mathrm{E} e^{i\boldsymbol{x}\cdot\boldsymbol{\xi}} e^{i\boldsymbol{y}\cdot\boldsymbol{C}}.$$

Оценим

$$\begin{aligned}
&|\varphi_n(\boldsymbol{x}, \boldsymbol{y}) - \varphi(\boldsymbol{x}, \boldsymbol{y})| \leqslant \\
&\quad \leqslant \left|\mathrm{E} e^{i\boldsymbol{x}\cdot\boldsymbol{\xi}_n} e^{i\boldsymbol{y}\cdot\boldsymbol{\eta}_n} - \mathrm{E} e^{i\boldsymbol{x}\cdot\boldsymbol{\xi}_n} e^{i\boldsymbol{y}\cdot\boldsymbol{C}}\right| + \left|\mathrm{E} e^{i\boldsymbol{x}\cdot\boldsymbol{\xi}_n} e^{i\boldsymbol{y}\cdot C} - \mathrm{E} e^{i\boldsymbol{x}\cdot\boldsymbol{\xi}} e^{i\boldsymbol{y}\cdot\boldsymbol{C}}\right| = \\
&\quad = \left|\mathrm{E} e^{i\boldsymbol{x}\cdot\boldsymbol{\xi}_n} (e^{i\boldsymbol{y}\cdot\boldsymbol{\eta}_n} - e^{i\boldsymbol{y}\cdot\boldsymbol{C}})\right| + |\varphi_{\boldsymbol{\xi}_n}(\boldsymbol{x}) - \varphi_{\boldsymbol{\xi}}(\boldsymbol{x})| \leqslant \\
&\quad \leqslant \mathrm{E}\left|(e^{i\boldsymbol{y}\cdot\boldsymbol{\eta}_n} - e^{i\boldsymbol{y}\cdot\boldsymbol{C}})\right| + |\varphi_{\boldsymbol{\xi}_n}(\boldsymbol{x}) - \varphi_{\boldsymbol{\xi}}(\boldsymbol{x})| \xrightarrow[n\to\infty]{} 0,
\end{aligned}$$

где в последней сумме первое слагаемое стремится к 0 по теореме Лебега о мажорируемой сходимости (поскольку $\boldsymbol{\eta}_n$ сходятся к $\boldsymbol{C}$ по вероятности), а второе слагаемое стремится к 0 по теореме непрерывности. □

Иногда в статистике приходится применять сложные манипуляции для получения оценок. Для этого нам пригодится дельта-метод.

ТЕОРЕМА 3.15.3

Пусть:

- случайные величины ξ_n сходятся по распределению к ξ;
- борелевская функция $h\colon \mathbb{R} \to \mathbb{R}$ дифференцируема в точке $a \in \mathbb{R}$;
- $b_n \to 0$.

Тогда

$$\frac{h(a + b_n\xi_n) - h(a)}{b_n} \xrightarrow[n\to\infty]{d} \xi h'(a).$$

Доказательство. Идея доказательства строится на том, что выражение в теореме напоминает случайную производную, поэтому нужно рассмотреть функцию, которая моделирует производную. Формально введём функцию $H\colon \mathbb{R} \to \mathbb{R}$ как

$$H(x) = \begin{cases} \frac{h(a+x)-h(a)}{x}, & \text{если } x \neq 0, \\ h'(a), & \text{иначе.} \end{cases}$$

Применим лемму Слуцкого:

$$b_n\xi_n \xrightarrow[n\to\infty]{d} 0.$$

Заметим, что функция H как раз непрерывна в нуле; иными словами, она P_0-п.н. непрерывна, а потому можно применить теоре-

му о наследовании сходимости и получить

$$H(b_n\xi_n) \xrightarrow[n\to\infty]{d} H(0) = h'(a).$$

Заметим, что

$$\frac{h(a+b_n\xi_n)-h(a)}{b_n} = H(b_n\xi_n)\xi_n.$$

Второй раз применяя лемму Слуцкого, получаем

$$\frac{h(a+b_n\xi_n)-h(a)}{b_n} = H(b_n\xi_n)\xi_n \xrightarrow[n\to\infty]{d} h'(a)\xi.$$

□

ЗАМЕЧАНИЕ

В доказательстве дельта-метода видно, что в теореме о наследовании сходимости важна непрерывность функции не всюду, а лишь почти всюду относительно предельного распределения. Так, функция H была непрерывна лишь в одной точке, но этого оказалось достаточно для доказательства.

В английской литературе дельта-методом называют не доказанную нами теорему, а наиболее часто применяемое следствие из неё.

ТЕОРЕМА 3.15.4

Пусть:

- для некоторой последовательности случайных величин X_n и некоторых констант a, σ^2 выполнено

$$\sqrt{n}(X_n - a) \xrightarrow[n\to\infty]{d} N(0,\sigma^2);$$

- борелевская функция $h\colon \mathbb{R}\to\mathbb{R}$ дифференцируема в точке a.

Тогда

$$\sqrt{n}\,(h(X_n)-h(a)) \xrightarrow[n\to\infty]{d} N(0,\sigma^2\cdot(h'(a))^2).$$

Доказательство. Применим дельта-метод к

$$\xi_n := \sqrt{n}(X_n - a), \qquad b_n := \frac{1}{\sqrt{n}},$$

и получим в точности

$$\begin{aligned}\sqrt{n}\,(h(X_n)-h(a)) = \\ = \frac{h(a+b_n\xi_n)-h(a)}{b_n} \xrightarrow[n\to\infty]{d} N(0,\sigma^2)h'(a) = \\ = N(0,\sigma^2\cdot(h'(a))^2).\end{aligned}$$

□

Приведём напоследок многомерный дельта-метод, которым удобно пользоваться для многомерной ЦПТ. Доказательство аналогично одномерному случаю, поэтому мы его опускаем.

ТЕОРЕМА 3.15.5

Пусть:

- случайные векторы $\boldsymbol{\xi}_n\colon \Omega \to \mathbb{R}^d$ сходятся по распределению к $\boldsymbol{\xi}$;
- борелевская функция $h\colon \mathbb{R}^d \to \mathbb{R}$ дифференцируема в точке $\boldsymbol{a} \in \mathbb{R}^d$;
- $b_n \to 0$.

Тогда

$$\frac{h(\boldsymbol{a} + b_n\boldsymbol{\xi}_n) - h(\boldsymbol{a})}{b_n} \xrightarrow[n\to\infty]{d} \boldsymbol{\xi} \cdot \nabla h(\boldsymbol{a}),$$

где точкой обозначено скалярное произведение.

16. НЕРАВЕНСТВА МАРКОВА И ЧЕБЫШЕВА

Чтобы научиться получать сходимость по вероятности, нужно научиться оценивать вероятности больших отклонений случайных величин. В теории вероятностей есть много неравенств, посвящённых большим уклонениям. Мы обсудим два самых основных.

ТЕОРЕМА 3.16.1

Пусть случайная величина ξ неотрицательна, и пусть $a > 0$. Тогда

$$\mathrm{P}\{\xi \geqslant a\} \leqslant \frac{\mathrm{E}\xi}{a}.$$

Доказательство. Запишем цепочку неравенств:

$$\mathrm{E}\xi = \mathrm{E}\xi\mathcal{I}\{\xi \geqslant a\} + \mathrm{E}\xi\mathcal{I}\{\xi < a\} \leqslant \mathrm{E}\xi\mathcal{I}\{\xi \geqslant a\} \leqslant \\ \leqslant a\mathrm{E}\mathcal{I}\{\xi \geqslant a\} = a\mathrm{P}\{\xi \geqslant a\},$$

где

- первое равенство по линейности матожидания,
- первое неравенство в силу неотрицательности случайной величины ξ,
- второе неравенство по монотонности матожидания,
- последнее равенство по определению матожидания индикатора.

Теперь теорема следует в силу положительности константы a. □

Смысл неравенства Маркова в том, что большие значения случайная величина принимает с маленькой вероятностью, обратно пропорциональной интересующей нас границе.

Пример 3.16.1. Пусть $\xi \sim \mathrm{Exp}(1)$. Тогда по неравенству Маркова,

$$\mathrm{P}\{\xi > 10\} \leqslant \frac{\mathrm{E}\xi}{10} = 0.1.$$

С другой стороны, эта вероятность в точности равна $e^{-10} \sim 0.001$. То есть неравенство работает, но очень грубо.

Пример 3.16.2. Пусть $\xi \sim \mathrm{Pois}(\lambda)$. Тогда

$$\mathrm{P}\{\xi > 10\lambda\} \leqslant \frac{\mathrm{E}\xi}{10\lambda} = \frac{1}{10}.$$

То есть с ошибкой всего 10% можно считать, что пуассоновская случайная величина принимает значения на отрезке $[0, 10\lambda]$. Аналогично, с ошибкой всего 1% можно считать, что пуассоновская случайная величина принимает значения на отрезке $[0, 100\lambda]$.

Как мы увидим дальше, довольно часто нужно уметь оценивать отклонение величины от её среднего. В этом нам поможет следующая теорема.

ТЕОРЕМА 3.16.2

Пусть случайная величина ξ имеет конечное матожидание, и пусть $a > 0$. Тогда

$$\mathrm{P}\{|\xi - \mathrm{E}\xi| \geqslant a\} \leqslant \frac{\mathrm{Var}\,\xi}{a^2}.$$

Доказательство. Надо заметить, что $\{|\xi - \mathbb{E}\xi| \geqslant a\} = \{|\xi - \mathbb{E}\xi|^2 \geqslant a^2\}$, и применить неравенство Маркова. □

Пример 3.16.3. Для случайной величины $\xi \sim N(0, \sigma^2)$ можно легко оценить

$$\mathrm{P}\{|\xi| > \sigma\} \leqslant 1, \quad \mathrm{P}\{|\xi| > 2\sigma\} \leqslant \frac{1}{4}, \quad \mathrm{P}\{|\xi| > 3\sigma\} \leqslant \frac{1}{9}.$$

Это гораздо грубее, чем правило трёх сигм, зато не нужно помнить эти вероятности.

17. ЗАКОН БОЛЬШИХ ЧИСЕЛ

Мы определили математическое ожидание, идеализируя понятие среднего значения эксперимента. Теперь нас интересует, насколько это идеализированное понятие близко к оригиналу?

ТЕОРЕМА 3.17.1

ЗБЧ в форме Чебышёва

Пусть дана последовательность попарно некоррелированных случайных величин $\xi_1, \xi_2, \ldots$, у которых математические ожидания совпадают, а дисперсии равностепенно ограничены некоторой константой. Тогда $\dfrac{\sum_{i=1}^{n} \xi_i}{n}$ сходится по вероятности к $\mathbb{E}\xi_1$.

Смысл теоремы в том, что если вы проведёте много независимых экспериментов с одинаковым математическим ожиданием, то ваше выборочное среднее должно быть близко к истинному среднему.

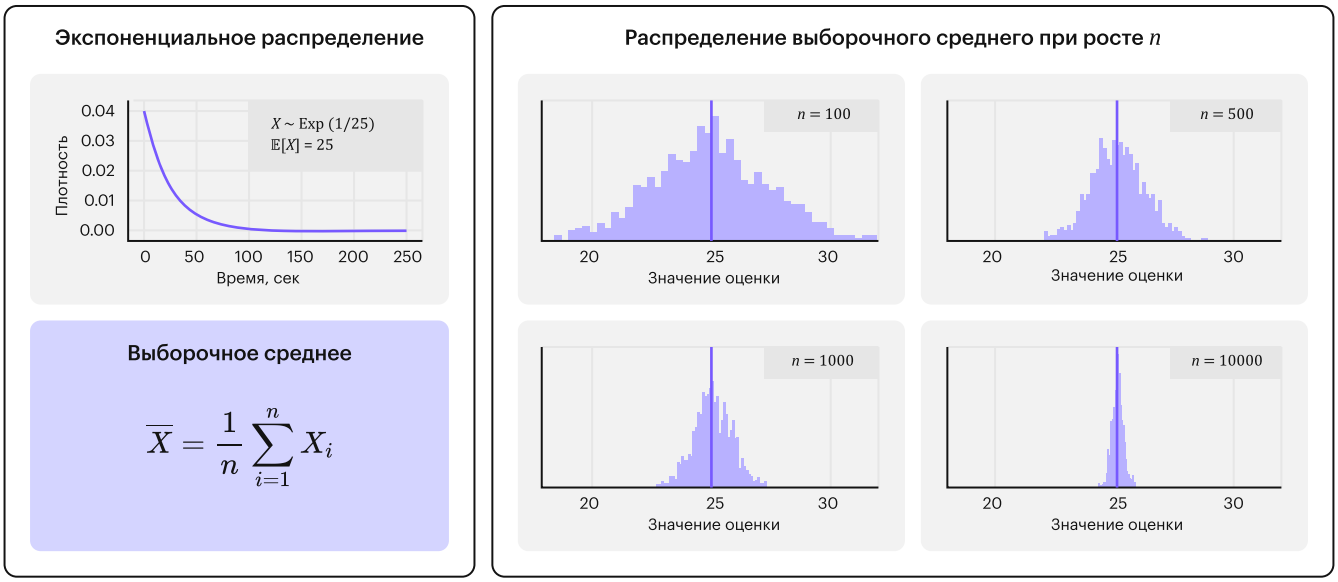

Рисунок 26. Пример ЗБЧ для экспоненциального распределения

Доказательство ЗБЧ. Обозначим через $c > 0$ константу, мажорирующую все дисперсии. Обозначим $S_n := \sum_{i=1}^{n} \xi_n$. Тогда по неравенству Чебышёва,

$$\mathrm{P}\left\{\left|\frac{S_n}{n} - \mathbb{E}\xi_1\right| > \varepsilon\right\} \leqslant \frac{\mathrm{Var}\,\frac{S_n}{n}}{\varepsilon^2} = \frac{\mathrm{Var}\,S_n}{n^2\varepsilon^2} \leqslant \frac{c}{n\varepsilon^2} \xrightarrow[n\to\infty]{} 0.$$

□

Отметим, что можно оценить скорость сходимости в ЗБЧ в смысле следующей теоремы. Её доказательство по сути ничем не отличается от доказательства выше.

ТЕОРЕМА 3.17.2

Пусть дана последовательность попарно некоррелированных случайных величин $\xi_1, \xi_2, \ldots$, у которых математические ожидания совпадают, а дисперсии равностепенно ограничены некоторой константой. Тогда для любого $\delta > 0$ последовательность $\dfrac{\sum_{i=1}^{n}\xi_i - \mathrm{E}\sum_{i=1}^{n}\xi_i}{n^{0.5+\delta}}$ сходится по вероятности к 0.

Как мы знаем из примера Рисса о бегающих отрезках, сходимость по вероятности может быть довольно плохой. В жизни мы хотим скорее получать сходимость почти наверное вместо сходимости по вероятности. Такие виды теорем называются *усиленными законами больших чисел*.

ТЕОРЕМА 3.17.3

УЗБЧ в форме Чебышёва

В условиях теоремы 3.17.2 имеет место сходимость почти наверное.

Иногда проблема наших экспериментов заключается в том, что они имеют среднее, но при этом могут иметь неограниченный разброс (бесконечную дисперсию). В таком случае, УЗБЧ в форме Чебышёва не работает. Зато работают другие виды УЗБЧ.

ТЕОРЕМА 3.17.4

УЗБЧ в форме Этемади

Пусть дана последовательность попарно независимых одинаково распределённых случайных величин $\xi_1, \xi_2, \ldots$, которые имеют конечное матожидание. Тогда $\dfrac{\sum_{i=1}^{n} \xi_i}{n}$ сходится почти наверное к $\mathbb{E}\xi_1$.

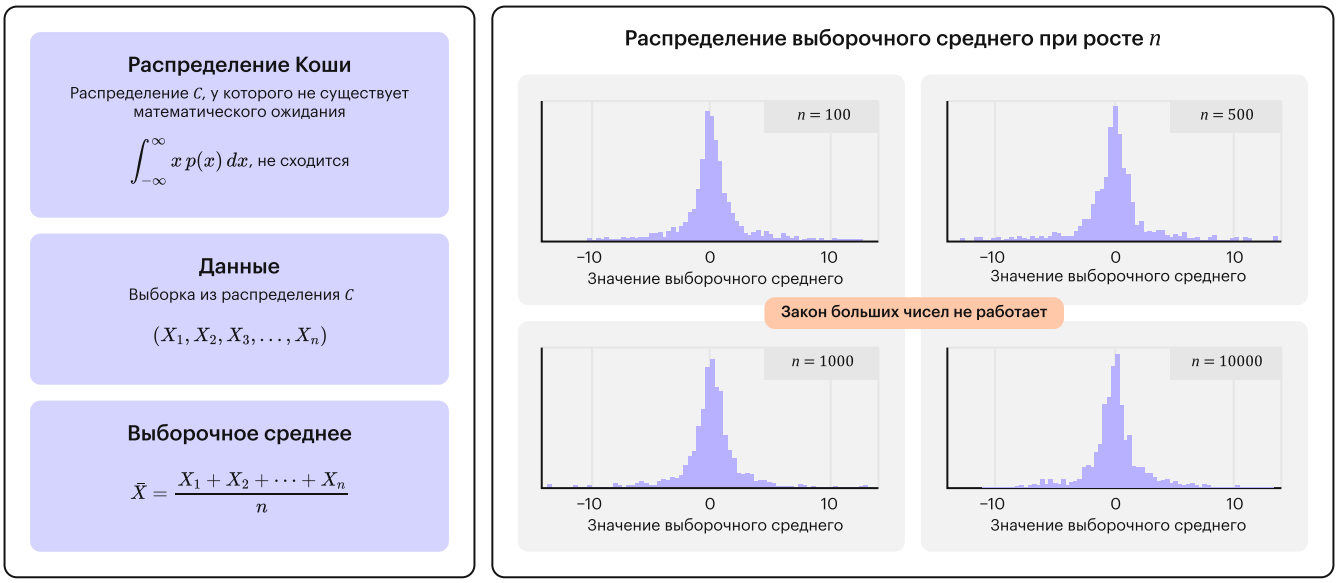

Рисунок 27. Пример отсутствия ЗБЧ для распределения Коши

Стоит отметить, что если величины не имеют матожидания, то и ЗБЧ для них не выполняется, как видно на рис. 27.

18. ЦЕНТРАЛЬНАЯ ПРЕДЕЛЬНАЯ ТЕОРЕМА

В ЗБЧ в форме Чебышёва можно делить отклонение $S_n - \mathrm{E}S_n$ не на n, а на $n^{0.5+\delta}$ для сколь угодно малого $\delta > 0$. Иными словами, это показывает, что сходимость к мат. ожиданию достаточно быстрая. Логичный вопрос: а что будет, если всё-таки поделить на $\sqrt{n}$, то есть положить $\delta = 0$? Оказывается, в таком случае ЗБЧ вообще перестаёт работать! Сходимость к мат. ожиданию пропадает, и вместо этого наши выборочные средние «размазывает» по нормальному распределению. В этом и заключается Центральная Предельная Теорема.

ТЕОРЕМА 3.18.1

Центральная предельная теорема

Пусть случайные величины $\xi_1, \xi_2, \ldots$ независимы, одинаково распределены, и имеют конечные математическое ожидание $\mathrm{E}\xi_k := a \in \mathbb{R}$ и дисперсию $\mathrm{Var}\,\xi_k := \sigma^2 \in (0, +\infty)$. Положим $S_n := \sum_{k=1}^{n} \xi_k$. Тогда

$$\frac{S_n - \mathrm{E}S_n}{\sqrt{\mathrm{Var}\,S_n}} = \frac{S_n - na}{\sigma\sqrt{n}} \xrightarrow[n\to\infty]{d} N(0,1).$$

ЗАМЕЧАНИЕ

В статистике обычно записывают ЦПТ в виде

$$\sqrt{n}\left(\frac{S_n}{n} - a\right) \xrightarrow[n\to\infty]{d} N(0, \sigma^2).$$

Этот вид отличается от предыдущего просто домножением всего выражения на σ.

С точки зрения статистики это надо трактовать следующим образом: выборочное среднее оценивает мат. ожидание с ошибкой (среднеквадратичным отклонением) $\frac{\sigma}{\sqrt{n}}$.

ЗАМЕЧАНИЕ

Физический смысл ЦПТ в следующем. Допустим, мы провели $N \gg 1$ серий по $n \gg 1$ экспериментов. Посчитали выборочные средние

$$\frac{S_n^{(1)}}{n}, \frac{S_n^{(2)}}{n}, \ldots, \frac{S_n^{(N)}}{n}.$$

Произвели центрирование и нормировку, то есть, рассмотрели

$$\sqrt{n}\left(\frac{S_n^{(1)}}{n} - a\right), \sqrt{n}\left(\frac{S_n^{(2)}}{n} - a\right), \ldots, \sqrt{n}\left(\frac{S_n^{(N)}}{n} - a\right).$$

Тогда все эти наблюдения лягут на кривую плотности нормального закона $N(0, \sigma^2)$.

Доказательство ЦПТ. Мы снова будем пользоваться теоремой непрерывности. Положим

$$\eta_k := \frac{\xi_k - a}{\sigma}.$$

Тогда

$$T_n := \frac{S_n - \mathrm{E}S_n}{\sqrt{\mathrm{Var}\, S_n}} = \frac{S_n - na}{\sigma\sqrt{n}} = \frac{\sum_{k=1}^n \eta_k}{\sqrt{n}}.$$

Поскольку $\mathrm{E}\eta_k = 0$ и $\mathrm{Var}\,\eta_k = 1$, то, раскладывая характеристическую функцию по формуле Тейлора с остаточным членом в форме Пеано до второго порядка,

$$\varphi_{\eta_k}(t/\sqrt{n}) = 1 + it/\sqrt{n} \cdot 0 - \frac{t^2}{2n} + o(1/n),$$

откуда

$$\varphi_{T_n}(t) = \prod_{k=1}^n \varphi_{\eta_k}(t/\sqrt{n}) = \left(1 - \frac{t^2}{2n} + o(1/n)\right)^n \xrightarrow[n\to\infty]{} e^{-t^2/2},$$

что является характеристической функцией стандартного нормального закона $N(0,1)$. □

Пример 3.18.1. Пусть $\xi_n \sim \mathrm{Exp}(\lambda)$ независимы. Так как $\mathrm{E}\xi_n = \frac{1}{\lambda}$ и $\mathrm{Var}\,\xi_n = \frac{1}{\lambda^2}$ конечны, то

$$\frac{S_n - \frac{n}{\lambda}}{\sqrt{n}/\lambda} \xrightarrow[n\to\infty]{d} N(0,1).$$

Пример 3.18.2. Удобно вместе применять ЦПТ, ЗБЧ, лемму Слуцкого и теорему о наследовании сходимости. Например, из ЦПТ мы знаем, что

$$\sqrt{n}\left(\frac{S_n}{n} - a\right) \xrightarrow[n\to\infty]{d} N(0,\sigma^2).$$

А что в таком случае можно сказать про поведение $\left(\frac{S_n}{n}\right)^2$? Оказывается, тут всё довольно просто: распишем

$$\sqrt{n}\left(\left(\frac{S_n}{n}\right)^2 - a^2\right) = \sqrt{n}\left(\frac{S_n}{n} - a\right)\cdot\left(\frac{S_n}{n} + a\right).$$

Левый множитель по ЦПТ сходится (по распределению) к $N(0,\sigma^2)$, а правый по ЗБЧ сходится (по вероятности, а значит, и по распределению) к $2a$. Применяя лемму Слуцкого, получаем, что

$$\sqrt{n}\left(\left(\frac{S_n}{n}\right)^2 - a^2\right) \xrightarrow[n\to\infty]{d} 2a\cdot N(0,\sigma^2) = N(0,4a^2\sigma^2).$$

С точки зрения статистики это надо трактовать следующим образом: квадрат выборочное среднее оценивает квадрат мат. ожидания с ошибкой (среднеквадратичным отклонением) $\frac{2|a|\sigma}{\sqrt{n}}$. То есть здесь ситуация немного отличается от ЦПТ: чем меньше математическое ожидание, тем точнее мы оцениваем его квадрат.

19. УМО

Представь следующую ситуацию. Планировали произвести случайный эксперимент, поведение которого описывалось случайной величиной ξ. А потом вдруг поступила дополнительная информация. Как изменить случайную величину, чтобы она описывала эксперимент с учётом дополнительной информации? В такой постановке вопроса вообще непонятно, что имеется в виду. Давай уточним, что под информацией мы понимаем σ-алгебру.

Вспомним, что для случайной величины ξ её порождённая σ-алгебра $\mathcal{F}_\xi := \{\xi^{-1}(B) : B \in \mathcal{B}(\mathbb{R})\}$ описывает информацию об эксперименте: чем сложнее эксперимент, тем больше неопределённости и тем больше σ-алгебра. Таким образом, при поступлении дополнительной информации мера неопределённости должна уменьшиться, то есть случайная величина должна стать измеримой относительно σ-алгебры, описывающей поступившую информацию. Но какой именно она должна стать?

Интуитивно можно представить происходящее следующим образом. Исходная σ-алгебра была сложной и состояла из множества мелких неделимых событий (в случае конечной σ-алгебры это действительно так; в случае бесконечной σ-алгебры это не так, но давай так представлять). Поступила информация, и σ-алгебра стала попроще: некоторые мелкие события слились в одно крупное. Как теперь на этих более крупных событиях пересчитать слу-

чайную величину? Логично на каждом крупном событии усреднить случайную величину по тем мелким событиям, которые слились в это крупное. Это и получится новая случайная величина, описывающая эксперимент с учётом полученных данных.

Рассмотрим случайную величину ξ с конечным математическим ожиданием на вероятностном пространстве $(\Omega, \mathcal{F}, \mathrm{P})$. Рассмотрим некоторую под-σ-алгебру $\mathcal{G} \subset \mathcal{F}$. **Условным математическим ожиданием (УМО)** случайной величины ξ относительно σ-алгебры $\mathcal{G}$ называют $\mathcal{G}$-измеримую случайную величину $\mathrm{E}(\xi \mid \mathcal{G})$, для которой выполнено **интегральное свойство**:

$$\mathrm{E}(\xi \mathcal{I}_A) = \mathrm{E}(\mathrm{E}(\xi \mid \mathcal{G})\mathcal{I}_A) \quad \text{для всех} \quad A \in \mathcal{G}.$$

Единственность УМО Доказательство. Достаточно доказать, что если $\mathrm{E}(\xi \mathcal{I}_A) = 0$ для $\mathcal{G}$-измеримой ξ и для всех $A \in \mathcal{G}$, то $\xi = 0$ почти всюду. В самом деле, допустим, событие $\{\xi > 0\}$ имеет положительную вероятность. Тогда для некоторого $\varepsilon > 0$ тоже $\mathrm{P}\{\xi \geqslant \varepsilon\} > 0$. Отсюда

$$\mathrm{E}(\xi \mathcal{I}\{\xi \geqslant \varepsilon\}) > 0,$$

что противоречит условию. □

Существование доказать гораздо сложнее, это мы сделаем попозже.

Пример 3.19.1. ассмотрим некоторую случайную величину ξ. Пусть $\mathcal{G} = \{\varnothing, \Omega\}$, то есть мы получили вообще всю информацию об эксперименте. Тогда $\mathrm{E}(\xi \mid \mathcal{G})$ не может принимать два различных значения, поскольку иначе её порождённая σ-алгебра будет состоять как минимум из четырёх событий. Таким образом, $\mathrm{E}(\xi \mid \mathcal{G}) = const$, и по интегральному свойству для $A = \Omega$

$$\mathrm{E}(\xi \mid \mathcal{G}) = \mathrm{E}(\mathrm{E}(\xi \mid \mathcal{G})\mathcal{I}_\Omega) = \mathrm{E}\xi.$$

Предыдущий пример можно обобщить до следующей теоремы, которая, по сути, формализует наши интуитивные рассуждения о возникновении УМО в начале параграфа.

ТЕОРЕМА 3.19.1

Пусть $\Omega = \bigsqcup_{n=1}^{\infty} G_n$, причём $\{G_n\}$ порождают σ-алгебру $\mathcal{G}$. Тогда

$$\mathrm{E}(\xi \mid \mathcal{G}) = \sum_{n=1}^{\infty} \frac{\mathrm{E}(\xi \mathcal{I}_{G_n})}{\mathrm{P}(G_n)} \mathcal{I}_{G_n}.$$

Доказательство. Заметим, что если на некотором G_n УМО принимает два различных значения, то УМО не будет $\mathcal{G}$-измеримым.

Так что УМО имеет вид

$$\mathrm{E}(\xi \mid \mathcal{G}) = \sum_{n=1}^{\infty} c_n \mathcal{I}_{G_n}.$$

Константы c_n найдём из интегрального свойства для $A = G_n$:

$$c_n \mathrm{P}(G_n) = \mathrm{E}(\mathrm{E}(\xi \mid \mathcal{G})\mathcal{I}_{G_n}) = \mathrm{E}(\xi \mathcal{I}_{G_n}).$$

□

Определение, которое мы дали, довольно абстрактное. Со случайной величиной всё понятно, но потом зачем-то какая-то σ-алгебра...Что такое полученная информация, описываемая σ-алгеброй $\mathcal{G}$? Можно думать о ней как о результате ещё одного эксперимента, интерпретируемого другой случайной величиной η. Но тогда $\mathcal{G} = \mathcal{F}_\eta$.

Для двух случайных величин ξ, η полагаем

$$\mathrm{E}(\xi \mid \eta) := \mathrm{E}(\xi \mid \mathcal{F}_\eta).$$

Пример 3.19.2. усть ξ описывает броски честного шестигранного кубика. Найдём

$$\mathrm{E}(\xi \mid |\xi - 3|).$$

Заметим, что $\mathcal{F}_{|\xi-3|}$ порождается событиями

$$\{|\xi - 3| = 0\},\ \{|\xi - 3| = 1\},\ \{|\xi - 3| = 2\},\ \{|\xi - 3| = 3\},$$

которые можно переписать как

$$\{\xi = 3\},\ \{\xi \in \{2,4\}\},\ \{\xi \in \{1,5\}\},\ \{\xi = 6\}.$$

Поэтому

$$\begin{aligned}\mathrm{E}(\xi \mid \eta) = \sum_{n=0}^{3} \frac{\mathrm{E}(\xi \mathcal{I}\{|\xi - 3| = n\})}{\mathrm{P}\{|\xi - 3| = n\}} \mathcal{I}\{|\xi - 3| = n\} = \\ = 3\mathcal{I}\{|\xi - 3| = 0\} + 3\mathcal{I}\{|\xi - 3| = 1\} + \\ + 3\mathcal{I}\{|\xi - 3| = 2\} + 6\mathcal{I}\{|\xi - 3| = 3\} = \\ = 3 + 3\mathcal{I}\{|\xi - 3| = 3\}.\end{aligned}$$

Последний индикатор можно было бы переписать как $\mathcal{I}\{\xi = 6\}$, но мы оставили его в исходном виде, чтобы подчеркнуть, что УМО выразилось как функция от $|\xi - 3|$, то есть от условия. Позже мы увидим, что это обязательный вид УМО.

Поскольку у нас в теории вероятностей не бывает точного равенства, а бывает равенство с точностью до почти наверное, то ниже мы опускаем это уточнение.

Если ξ является $\mathcal{G}$-измеримой, то

ЛЕММА 3.19.1

$$\mathrm{E}(\xi \mid \mathcal{G}) = \xi.$$

Доказательство. Следует по определению, так как ξ является $\mathcal{G}$-измеримой и интегральное свойство для неё, очевидно, тоже выполнено. □

Имеет место

$$\mathrm{E}(\mathrm{E}(\xi \mid \mathcal{G})) = \mathrm{E}\xi.$$

ЛЕММА 3.19.2

Формула полного матожидания

Доказательство. Формула очень важная, но, по сути, является частным случаем интегрального свойства для $A = \Omega$. □

Если случайные величины ξ и η имеют конечные математические ожидания, то

$$\mathrm{E}(a\xi + b\eta \mid \mathcal{G}) = a\mathrm{E}(\xi \mid \mathcal{G}) + b\mathrm{E}(\eta \mid \mathcal{G}).$$

ЛЕММА 3.19.3

Линейность

Доказательство. Достаточно проверить, что в качестве УМО подходит $a\mathrm{E}(\xi \mid \mathcal{G}) + b\mathrm{E}(\eta \mid \mathcal{G})$. Оно является $\mathcal{G}$-измеримым как сумма $\mathcal{G}$-измеримых функций, поэтому остаётся проверить интегральное свойство. Оно выполнено, так как для произвольного $A \in \mathcal{G}$ имеем

$$\begin{aligned}\mathrm{E}((a\xi + b\eta)\mathcal{I}_A) &= a\mathrm{E}(\xi\mathcal{I}_A) + b\mathrm{E}(\eta\mathcal{I}_A) = \\ &= a\mathrm{E}(\mathrm{E}(\xi \mid \mathcal{G})\mathcal{I}_A) + b\mathrm{E}(\mathrm{E}(\eta \mid \mathcal{G})\mathcal{I}_A) = \\ &= \mathrm{E}((a\mathrm{E}(\xi \mid \mathcal{G}) + b\mathrm{E}(\eta \mid \mathcal{G}))\mathcal{I}_A).\end{aligned}$$

□

Если $\xi \leqslant \eta$, то $\mathrm{E}(\xi \mid \mathcal{G}) \leqslant \mathrm{E}(\eta \mid \mathcal{G})$.

ЛЕММА 3.19.4

Доказательство. Для всех $A \in \mathcal{G}$ выполнено

$$\mathrm{E}(\mathrm{E}(\xi \mid \mathcal{G})\mathcal{I}_A) \leqslant \mathrm{E}(\mathrm{E}(\eta \mid \mathcal{G})\mathcal{I}_A),$$

поэтому и $\mathrm{E}(\xi \mid \mathcal{G}) \leqslant \mathrm{E}(\eta \mid \mathcal{G})$: в самом деле, иначе бы в качестве A можно было взять множество, на котором нарушается неравенство. □

Выполнено

$$|\mathrm{E}(\xi \mid \mathcal{G})| \leqslant \mathrm{E}(|\xi| \mid \mathcal{G}).$$

ЛЕММА 3.19.5

Доказательство. Следует по предыдущей лемме ввиду $-|\xi| \leqslant \xi \leqslant |\xi|$. □

Следующая лемма является обобщением свойств, связанных с измеримостью.

Пусть $\mathcal{G}_1 \subset \mathcal{G}_2$. Тогда

$$\mathrm{E}(\mathrm{E}(\xi \mid \mathcal{G}_1) \mid \mathcal{G}_2) = \mathrm{E}(\mathrm{E}(\xi \mid \mathcal{G}_2) \mid \mathcal{G}_1) = \mathrm{E}(\xi \mid \mathcal{G}_1).$$

ЛЕММА 3.19.6

Телескопическое свойство

Доказательство. Равенство первого и третьего членов следует из $\mathcal{G}_2$-измеримости случайной величины $\mathrm{E}(\xi \mid \mathcal{G}_1)$. Для равенства

второго и третьего членов рассмотрим произвольное $A \in \mathcal{G}_1$. Тогда

$$\mathrm{E}(\mathrm{E}(\xi \mid \mathcal{G}_1)\mathcal{I}_A) = \mathrm{E}(\xi\mathcal{I}_A) = \mathrm{E}(\mathrm{E}(\xi \mid \mathcal{G}_2)\mathcal{I}_A) = \\ = \mathrm{E}(\mathrm{E}(\mathrm{E}(\xi \mid \mathcal{G}_2) \mid \mathcal{G}_1)\mathcal{I}_A),$$

где:

- первое равенство следует из определения $\mathrm{E}(\xi \mid \mathcal{G}_1)$;
- второе равенство следует из определения $\mathrm{E}(\xi \mid \mathcal{G}_2)$, так как $A \in \mathcal{G}_2$;
- третье равенство следует из определения $\mathrm{E}(\eta \mid \mathcal{G}_1)$ для $\eta = \mathrm{E}(\xi \mid \mathcal{G}_2)$. □

ЛЕММА 3.19.7

Пусть ξ независима с $\mathcal{G}$, то есть любые два события $B \in \mathcal{F}_\xi$ и $A \in \mathcal{G}$ независимы. Тогда

$$\mathrm{E}(\xi \mid \mathcal{G}) = \mathrm{E}\xi.$$

Доказательство. Достаточно снова проверить интегральное свойство для произвольного $A \in \mathcal{G}$:

$$\mathrm{E}(\mathrm{E}(\xi \mid \mathcal{G})\mathcal{I}_A) = \mathrm{E}(\xi\mathcal{I}_A) = \mathrm{E}\xi\mathrm{E}\mathcal{I}_A = \mathrm{E}(\mathcal{I}_A\mathrm{E}\xi),$$

где:

- первое равенство из определения УМО;
- второе равенство из независимости случайных величин ξ и $\mathcal{I}_A$;
- третье равенство получено внесением константы $\mathrm{E}\xi$ в математическое ожидание $\mathrm{E}\mathcal{I}_A$. □

ТЕОРЕМА 3.19.2

Пусть $\xi_n \xrightarrow[n\to\infty]{\text{п.н.}} \xi$, причём сходимость монотонная нестрого вверх, и величины либо неотрицательные, либо интегрируемые. Тогда

$$\mathrm{E}(\xi_n \mid \mathcal{G}) \xrightarrow[n\to\infty]{\text{п.н.}} \mathrm{E}(\xi \mid \mathcal{G}).$$

Доказательство. В силу возрастания величин, УМО $\mathrm{E}(\xi_n \mid \mathcal{G})$ тоже возрастают к некоторой $\mathcal{G}$-измеримой η. Проверим интегральное свойство: для любого $A \in \mathcal{G}$ имеем монотонные сходимости $\xi_n\mathcal{I}_A$ к $\xi\mathcal{I}_A$, и $\mathrm{E}(\xi_n \mid \mathcal{G})\mathcal{I}_A$ к $\eta\mathcal{I}_A$, откуда по обычной теореме Леви

$$\mathrm{E}(\xi\mathcal{I}_A) = \lim_{n\to\infty} \mathrm{E}(\xi_n\mathcal{I}_A) = \lim_{n\to\infty} \mathrm{E}(\mathrm{E}(\xi_n \mid \mathcal{G})\mathcal{I}_A) = \mathrm{E}(\eta\mathcal{I}_A).$$

□

ТЕОРЕМА 3.19.3

Пусть $|\xi_n| \leqslant \eta$ для некоторой интегрируемой мажоранты η. Пусть $\xi_n \xrightarrow[n\to\infty]{\text{п.н.}} \xi$. Тогда

$$\mathrm{E}(\xi_n \mid \mathcal{G}) \xrightarrow[n\to\infty]{\text{п.н.}} \mathrm{E}(\xi \mid \mathcal{G}).$$

Доказательство. Рассмотрим

$$\zeta_n := \sup_{m \geqslant n} |\xi_m - \xi|.$$

Таким образом, $\zeta_n \leqslant 2\eta$, и они монотонно убывают к нулю. Значит, по теореме Леви

$$\lim_{n\to\infty} \mathrm{E}(\zeta_n \mid \mathcal{G}) = \mathrm{E}(0 \mid \mathcal{G}) = 0.$$

Заключение теоремы получается ввиду

$$|\mathrm{E}(\xi_n \mid \mathcal{G}) - \mathrm{E}(\xi \mid \mathcal{G})| \leqslant \mathrm{E}(|\xi_n - \xi| \mid \mathcal{G}) \leqslant \mathrm{E}(\zeta_n \mid \mathcal{G}).$$

□

ЛЕММА 3.19.8

усть случайная величина η является $\mathcal{G}$-измеримой и величины $\xi\eta$ и ξ интегрируемы. Тогда

$$\mathrm{E}(\xi\eta \mid \mathcal{G}) = \eta\mathrm{E}(\xi \mid \mathcal{G}).$$

Доказательство. Для начала рассмотрим случай $\eta = \mathcal{I}_B$ для некоторого $B \in \mathcal{G}$. Тогда для произвольного $A \in \mathcal{G}$

$$\mathrm{E}(\mathrm{E}(\xi\eta \mid \mathcal{G})\mathcal{I}_A) = \mathrm{E}(\xi\eta\mathcal{I}_A) = \mathrm{E}(\xi\mathcal{I}_{A\cap B}) = \\ = \mathrm{E}(\mathrm{E}(\xi \mid \mathcal{G})\mathcal{I}_{A\cap B}) = \mathrm{E}(\eta\mathrm{E}(\xi \mid \mathcal{G})\mathcal{I}_A),$$

что доказывает эту часть леммы. По линейности лемма доказана и для простых η. В произвольном случае возьмём последовательность $\mathcal{F}_\eta$-измеримых простых случайных величин η_n, которые мажорируются величиной $|\eta|$ и сходятся к η почти наверное. Тогда по теореме Лебега для УМО

$$\eta\mathrm{E}(\xi \mid \mathcal{G}) = \lim_{n\to\infty} \eta_n\mathrm{E}(\xi \mid \mathcal{G}) = \lim_{n\to\infty} \mathrm{E}(\xi\eta_n \mid \mathcal{G}) = \mathrm{E}(\xi\eta \mid \mathcal{G}).$$

□

Этих свойств уже достаточно, чтобы решать некоторые задачи.

Пример 3.19.3. Пусть некоторое насекомое сносит $\xi \sim \mathrm{Pois}(\lambda)$ личинок. Дальше из каждой личинки независимо от их количества и от других личинок с вероятностью p вылупляется насекомое, а с вероятностью $1 - p$ насекомое погибает. Обозначим через X количество вылупившихся насекомых, а через Y количество погибших. Понятно, что $X + Y = \xi$. Найдём разные УМО одних величин относительно других.

Заметим, что

$$\mathrm{P}\{X = x, Y = y\} = \frac{\lambda^{x+y}}{(x+y)!}e^{-\lambda} \cdot \binom{x+y}{x} p^x(1-p)^y = \underbrace{\frac{(\lambda p)^x}{x!}e^{-\lambda p}}_{\mathrm{P}\{X=x\}} \cdot \underbrace{\frac{(\lambda(1-p))^y}{y!}e^{-\lambda(1-p)}}_{\mathrm{P}\{Y=y\}},$$

то есть вероятность факторизуется. Отсюда сразу видим, что случайные величины X и Y независимы и имеют распределения

$X \sim \mathrm{Pois}(\lambda p)$ и $Y \sim \mathrm{Pois}(\lambda(1-p))$.

Тогда,

$$\mathrm{E}(\xi \mid X) = \mathrm{E}(X + Y \mid X) = X + \mathrm{E}Y = X + \lambda(1-p).$$

Кроме того,

$$\mathrm{E}(X \mid \xi) = \xi p,$$

поскольку $X \mid \xi \sim \mathrm{Bin}(\xi, p)$.

Пример 3.19.4. Рассмотрим гауссовский вектор (X, Y) со средним $(3, 5)$ и матрицей ковариаций $\begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}$. Найдём $\mathrm{E}(X \mid Y)$.

Тут идея в следующем: прибавим и вычтем слева αY так, чтобы $X - \alpha Y$ и Y стали некоррелируемы. Как мы знаем, для гауссовских векторов это означает независимость, так что

$$\mathrm{E}(X \mid Y) = \mathrm{E}(X - \alpha Y \mid Y) + \mathrm{E}(\alpha Y \mid Y) = (3 - 5\alpha) + \alpha Y.$$

Остаётся найти

$$0 = \mathrm{cov}(X - \alpha Y, Y) = \mathrm{cov}(X, Y) - \alpha \mathrm{Var}\, Y = 1 - \alpha,$$

откуда $\alpha = 1$ и

$$\mathrm{E}(X \mid Y) = Y - 2.$$

Следующая теорема показывает, что на УМО можно смотреть как на проекцию случайной величины на подпространство $\mathcal{G}$-измеримых случайных величин.

ТЕОРЕМА 3.19.4

Зафиксируем интегрируемую случайную величину ξ и под-σ-алгебру $\mathcal{G} \subset \mathcal{F}$. Тогда инфимум выражения

$$\mathrm{E}(\xi - \eta)^2$$

по $\mathcal{G}$-измеримым η достигается на $\eta = \mathrm{E}(\xi \mid \mathcal{G})$.

Доказательство. Для произвольной $\mathcal{G}$-измеримой η имеем

$$\mathrm{E}(\xi - \eta)^2 = \mathrm{E}(\xi - \mathrm{E}(\xi \mid \mathcal{G}) + \mathrm{E}(\xi \mid \mathcal{G}) - \eta)^2 = \\ = \mathrm{E}\alpha^2 + \mathrm{E}\beta^2 + 2\mathrm{E}(\alpha\beta),$$

где мы обозначили

$$\alpha := \xi - \mathrm{E}(\xi \mid \mathcal{G}), \quad \beta := \mathrm{E}(\xi \mid \mathcal{G}) - \eta.$$

Заметим, что

$$\mathrm{E}(\alpha \mid \mathcal{G}) = \mathrm{E}(\xi \mid \mathcal{G}) - \mathrm{E}(\xi \mid \mathcal{G}) = 0.$$

Но тогда

$$\mathrm{E}(\alpha\beta) = \mathrm{E}(\mathrm{E}(\alpha\beta \mid \mathcal{G})) = \mathrm{E}(\beta \mathrm{E}(\alpha \mid \mathcal{G})) = 0,$$

где:

- первое равенство — это формула полного матожидания;
- второе равенство следует из $\mathcal{G}$-измеримости случайной величины β;
- третье равенство следует из $\mathrm{E}(\alpha \mid \mathcal{G}) = 0$.

Таким образом:

$$\mathrm{E}(\xi - \eta)^2 = \mathrm{E}\alpha^2 + \mathrm{E}\beta^2 \geqslant \mathrm{E}\alpha^2,$$

причём на $\eta = \mathrm{E}(\xi \mid \mathcal{G})$ достигается равенство. □

Напоследок приведём ещё одно полезное свойство УМО, удобное для решения некоторых задач.

ТЕОРЕМА 3.19.5

Пусть $\xi_1, \ldots, \xi_n$ — независимые одинаково распределённые случайные величины и борелевская функция $f\colon \mathbb{R}^n \to \mathbb{R}$ симметрична, то есть для любой перестановки π на n элементах и любых $x_1, \ldots, x_n \in \mathbb{R}$ выполнено

$$f(x_1, \ldots, x_n) = f(x_{\pi(1)}, \ldots, x_{\pi(n)}).$$

Тогда для любых i, j

$$\mathrm{E}(\xi_i \mid f(\xi_1, \ldots, \xi_n)) = \mathrm{E}(\xi_j \mid f(\xi_1, \ldots, \xi_n)).$$

Доказательство. По интегральному свойству достаточно доказать, что для любого $f(\xi_1, \ldots, \xi_n)$-измеримого события A выполнено

$$\mathrm{E}(\xi_i \mathcal{I}_A) = \mathrm{E}(\xi_j \mathcal{I}_A).$$

Обозначим через $\boldsymbol{\eta}$ вектор, составленный из величин $\xi_1, \ldots, \xi_n$, где величины ξ_i, ξ_j поменяли местами. Выберем борелевское множество B, для которого

$$A = \{f(\xi_1, \ldots, \xi_n) \in B\}.$$

Таким образом, величины

$$\xi_i \mathcal{I}\{f(\xi_1, \ldots, \xi_n) \in B\} = \xi_i \mathcal{I}_A$$

и

$$\xi_j \mathcal{I}\{f(\boldsymbol{\eta}) \in B\} = \xi_j \mathcal{I}\{f(\xi_1, \ldots, \xi_n) \in B\} = \xi_j \mathcal{I}_A$$

одинаково распределены, откуда следует

$$\mathrm{E}(\xi_i \mathcal{I}_A) = \mathrm{E}(\xi_j \mathcal{I}_A).$$

□

Пример 3.19.5. Рассмотрим произвольные $\xi_1, \ldots, \xi_n$. Найдём

$$\mathrm{E}\left(\xi_1 \,\middle|\, \sum_{i=1}^n \xi_i\right) = \frac{\sum_{k=1}^n \mathrm{E}\left(\xi_k \mid \sum_{i=1}^n \xi_i\right)}{n} = \frac{\sum_{k=1}^n \xi_k}{n}.$$

Всё это прекрасно, но с чего мы взяли, что УМО вообще существует? Здесь нужно зайти издалека.

Знакопеременной мерой называется конечное σ-аддитивное отображение из σ-алгебры на прямую.

Знакопеременная мера ν называется **абсолютно непрерывной** относительно меры μ, пишут $\nu \ll \mu$, если $|\nu(A)| \to 0$ при $\mu(A) \to 0$ (множество A считается параметром).

Пример 3.19.6. Для случайной величины ξ с конечным математическим ожиданием отображение $\nu\colon \mathcal{F} \to \mathbb{R}$, определённое как

$$\nu(A) := \mathrm{E}(\xi \mathcal{I}_A),$$

является знакопеременной мерой, абсолютно непрерывной относительно меры P. В самом деле, если случайная величина ξ ограничена константой C, то

$$|\nu(A)| \leqslant C\mathrm{P}(A) \xrightarrow[\mathrm{P}(A)\to 0]{} 0.$$

Для произвольной случайной величины ξ рассмотрим простые случайные величины ξ_n, сходящиеся к ней почти наверное, а тогда по теореме Лебега и в среднем (в L_1). Значит:

$$|\nu(A)| \leqslant |\mathrm{E}((\xi - \xi_n)\mathcal{I}_A)| + |\mathrm{E}(\xi_n \mathcal{I}_A)|.$$

В силу сходимости в среднем, первое слагаемое сколь угодно мало при достаточно большом n. Теперь второе слагаемое сколь угодно мало при $\mathrm{P}(A) \to 0$.

ТЕОРЕМА 3.19.6

Абсолютная непрерывность $\nu \ll \mu$ равносильна существованию μ-измеримой **плотности Радона — Никодима** ξ, для которой

$$\nu(A) = \int \xi(\omega)\, d\mu(\omega).$$

В одну сторону мы теорему доказали, в другую она доказывается гораздо сложнее. Воспользуемся ей без доказательства.

Существование УМО Доказательство. Для случайной величины ξ рассмотрим знакопеременную меру $\nu\colon \mathcal{G} \to \mathbb{R}$, определённую как

$$\nu(A) := \mathrm{E}(\xi \mathcal{I}_A).$$

Понятно, что $\nu \ll \mu := \mathrm{P}|_{\mathcal{G}}$. Тогда по теореме Радона — Никодима должна существовать плотность η, для которой

$$\nu(A) = \int \eta(\omega)\, d\mu(\omega) = \mathrm{E}(\eta \mathcal{I}_A).$$

Свойство μ-измеримости плотности η равносильно её $\mathcal{G}$-измеримости, откуда получаем, что $\eta = \mathrm{E}(\xi \mid \mathcal{G})$. □

20. УСЛОВНЫЕ РАСПРЕДЕЛЕНИЯ

Посмотрим на формулу:

$$\mathrm{E}(\xi \mid \mathcal{G}) = \sum_{n=1}^{\infty} \frac{\mathrm{E}(\xi \mathcal{I}_{G_n})}{\mathrm{P}(G_n)} \mathcal{I}_{G_n}.$$

Если предположить, что все вероятности дискретные, то дробь $\frac{\mathrm{E}(\xi \mathcal{I}_{G_n})}{\mathrm{P}(G_n)}$, по сути, является математическим ожиданием величины ξ по условной вероятности $\mathrm{P}(\cdot \mid G_n)$. Это особенно хорошо видно в случае $\mathcal{G} = \mathcal{F}_\eta$ для дискретной случайной величины η: тогда мы буквально получаем

$$\mathrm{E}(\xi \mid \eta) = \sum_n \mathrm{E}_{\mathrm{P}(\cdot \mid \eta = n)} \xi \mathcal{I}\{\eta = n\},$$

и далее все слагаемые в сумме можно заменить одним слагаемым, где вместо n стоит η. Попробуем наши рассуждения формализовать.

Величиной $\mathrm{E}(\xi \mid \eta = y)$ называется такая борелевская функция $\varphi = \varphi(y)$, что для любого борелевского множества B выполнено:

$$\mathrm{E}(\xi \mathcal{I}\{\eta \in B\}) = \int_B \varphi(y)\, \mathrm{P}_\eta(dy) = \mathrm{E}(\varphi(\eta) \mathcal{I}\{\eta \in B\}).$$

Пример 3.20.1. Пусть случайная величина η дискретна. Тогда $\mathrm{E}(\xi \mid \eta = n)$ равно математическому ожиданию величины ξ по условной вероятности.

ЛЕММА 3.20.1

Если ξ имеет конечное математическое ожидание, то функция $\varphi(y) = \mathrm{E}(\xi \mid \eta = y)$ корректно определена и единственна P_η-п.н.

Доказательство. Определим знакопеременную борелевскую меру:

$$\nu(B) := \mathrm{E}(\xi \mathcal{I}\{\eta \in B\}).$$

Поскольку $\nu \ll \mathrm{P}_\eta$, то существует и единственна плотность Радона — Никодима φ, которая характеризуется как

$$\nu(B) = \int_B \varphi(y)\, \mathrm{P}_\eta(dy).$$

□

ЛЕММА 3.20.2

Смысл определения

Имеется связь

$$\mathrm{E}(\xi \mid \eta = y) = \varphi(y) \Longleftrightarrow \mathrm{E}(\xi \mid \eta) = \varphi(\eta).$$

Доказательство. УМО $\mathrm{E}(\xi \mid \eta)$ должно быть η-измеримой функцией, что означает выполнение для всех борелевских B равен-

ства

$$\mathrm{E}(\mathrm{E}(\xi \mid \eta)\mathcal{I}\{\eta \in B\}) = \mathrm{E}(\xi\mathcal{I}\{\eta \in B\}) = \mathrm{E}(\varphi(\eta)\mathcal{I}\{\eta \in B\}).$$

В силу интегрального свойства и η-измеримости функции $\varphi(\eta)$, равенство первого и третьего членов даёт

$$\mathrm{E}(\xi \mid \eta) = \varphi(\eta).$$

□

СЛЕДСТВИЕ 3.20.1

Случайная величина ξ является η-измеримой в точности тогда, когда для некоторой борелевской функции φ выполняется $\xi = \varphi(\eta)$.

Доказательство. Если такая функция существует, то измеримость очевидна. Покажем обратное. Пусть ξ является η-измеримой. Отсюда

$$\xi = \mathrm{E}(\xi \mid \eta) = \varphi(\eta).$$

□

Условное распределение $\mathrm{P}(\cdot \mid \mathcal{G})$ на $\mathcal{F}$ задаётся как

$$\mathrm{P}(A \mid \mathcal{G}) := \mathrm{E}(I_A \mid \mathcal{G}).$$

Обрати внимание, что при фиксированном A условное распределение $\mathrm{P}(A \mid \mathcal{G})$ является случайной величиной. Связь с обычным распределением тут простая — для тривиальной $\mathcal{G} = \{\varnothing, \Omega\}$ выполнено:

$$\mathrm{P}(A \mid \mathcal{G}) = \mathrm{E}(I_A \mid \mathcal{G}) = \mathrm{E}I_A = \mathrm{P}(A).$$

Зададим **условное распределение** сл.в. ξ при условии $\eta = y$ как

$$\mathrm{P}(\xi \in B \mid \eta = y) := \mathrm{E}(\mathcal{I}\{\xi \in B\} \mid \eta = y).$$

Условной плотностью сл.в. ξ относительно η называется плотность условного распределения $\mathrm{P}(\xi \in B \mid \eta = y)$, то есть такая функция $p_{\xi|\eta}(x \mid y)$, что

$$\mathrm{P}(\xi \in B \mid \eta = y) = \int_B p_{\xi|\eta}(x \mid y)\,dx.$$

В дискретном случае плотность может быть обобщённой, как в следующем примере.

Пример 3.20.2. Рассмотрим случайные величины ξ, η, принимающие значения, как в таблице ниже (в таблице указаны вероятности).

$\eta\backslash\xi$	0	1
2	$0,1$	$0,2$
3	$0,3$	$0,4$

Условная плотность в таком случае будет просто условной вероятностью: значения $p_{\xi|\eta}(x \mid y)$ задаются следующим образом.

$y\backslash x$	0	1
2	$\frac{1}{3}$	$\frac{2}{3}$
3	$\frac{3}{7}$	$\frac{4}{7}$

Понятно, что для $y = 2, 3$ выполняется:

$$\mathrm{P}(\xi \in B \mid \eta = y) = \int_B p_{\xi|\eta}(x \mid y)\,dx = \sum_{x \in B \cap \{0,1\}} p_{\xi|\eta}(x \mid y).$$

Как же это помогает искать УМО? Ответ даёт следующая теорема.

ТЕОРЕМА 3.20.1

Пусть существует условная плотность $p_{\xi|\eta}(x \mid y)$. Тогда для любой борелевской функции g, для которой конечно математическое ожидание $\mathrm{E}g(\xi)$, выполнено:

$$\mathrm{E}(g(\xi) \mid \eta = y) = \int_{\mathbb{R}} g(x) p_{\xi|\eta}(x \mid y)\,dx.$$

Доказательство. Достаточно проверить равенство для случая $g = \mathcal{I}_B$ и затем совершить предельный переход под знаком УМО. Для индикатора получаем:

$$\int_{\mathbb{R}} g(x) p_{\xi|\eta}(x \mid y)\,dx = \int_B p_{\xi|\eta}(x \mid y)\,dx = \mathrm{P}(\xi \in B \mid \eta = y) = \\ = \mathrm{E}(\mathcal{I}\{\xi \in B\} \mid \eta = y) = \mathrm{E}(g(\xi) \mid \eta = y).$$

□

Чтобы пользоваться этой теоремой, осталось научиться находить саму условную плотность.

ТЕОРЕМА 3.20.2

Пусть для величин ξ, η существует совместная плотность $p_{\xi,\eta}$, и пусть существует плотность p_η. Тогда

$$p_{\xi|\eta}(x \mid y) = \frac{p_{\xi,\eta}(x, y)}{p_\eta(y)} \mathcal{I}\{p_\eta(y) > 0\}.$$

Доказательство. Рассмотрим произвольные борелевские множества A, B. С одной стороны:

$$\mathrm{P}\{\xi \in B, \eta \in A\} = \int_{B\times A} p_{\xi,\eta}(x,y)\,dxdy = \\ = \int_A p_\eta(y)\,dy \int_B \frac{p_{\xi,\eta}(x,y)}{p_\eta(y)}\,dx.$$

С другой стороны:

$$\mathrm{P}\{\xi \in B, \eta \in A\} = \mathrm{E}(\mathcal{I}\{\xi \in B\}\mathcal{I}\{\eta \in A\}) = \\ = \mathrm{E}(\mathrm{E}(\mathcal{I}\{\xi \in B\} \mid \eta)\mathcal{I}\{\eta \in A\}) = \\ = \int_A \mathrm{P}(\xi \in B \mid \eta = y) p_\eta(y)\,dy.$$

В силу произвольного выбора множества A, по интегральному свойству:

$$\mathrm{P}(\xi \in B \mid \eta = y) = \int_B \frac{p_{\xi,\eta}(x,y)}{p_\eta(y)}\,dx.$$

Произвольный выбор множества B и снова интегральное свойство заканчивают доказательство. □

Пример 3.20.3. Рассмотрим две независимые величины $\xi, \eta \sim \mathrm{Exp}(1)$. Найдём

$$\mathrm{E}(\xi^4 \mid \xi + \eta).$$

Не нужно сразу бросаться искать условную плотность величины ξ^4 при условии суммы! Всё проще. Находим

$$p_{\xi|\xi+\eta}(x \mid y) = \frac{p_{\xi,\xi+\eta}(x,y)}{p_{\xi+\eta}(y)}.$$

Известно, что $\xi + \eta \sim \Gamma(2,1)$, откуда

$$p_{\xi+\eta}(y) = \frac{y}{1!}e^{-y}\mathcal{I}\{y > 0\}.$$

Кроме того:

$$p_{\xi,\eta}(u,v) = e^{-u-v}\mathcal{I}\{u,v > 0\}.$$

Проделаем замену:

$$x = u, \quad y = u + v.$$

Обратная замена

$$u = x, \quad v = y - x$$

имеет якобиан 1, а потому

$$p_{\xi,\xi+\eta}(x,y) = p_{\xi,\eta}(x, y-x) \cdot 1 = e^{-y}\mathcal{I}\{y > x > 0\}.$$

Здесь главное — проверить носитель плотности: получили $0 < x < y$, что соответствует условиям $0 < \xi < \xi + \eta$, выполненным почти наверное.

В итоге:

$$p_{\xi|\xi+\eta}(x \mid y) = \frac{p_{\xi,\xi+\eta}(x,y)}{p_{\xi+\eta}(y)} = \frac{e^{-y}}{ye^{-y}}\mathcal{I}\{y > x > 0\} = \\ = \frac{1}{y}\mathcal{I}\{y > x > 0\}.$$

Чтобы проверить, что мы не ошиблись, надо убедиться, что полученный элемент для всех y является плотностью по x:

$$\int p_{\xi|\xi+\eta}(x \mid y)\,dx = \int \frac{1}{y}\mathcal{I}\{y > x > 0\}\,dx = \frac{y}{y} = 1,$$

то есть мы нигде не ошиблись (скорее всего).

Теперь находим

$$\mathrm{E}(\xi^4 \mid \xi + \eta = y) = \int x^4 p_{\xi|\xi+\eta}(x \mid y)\,dx = \\ = \int \frac{x^4}{y}\mathcal{I}\{y > x > 0\}\,dx = \frac{1}{y}\int_0^y x^4\,dx = \frac{y^4}{5}.$$

Отсюда окончательный ответ:

$$\mathrm{E}(\xi^4 \mid \xi + \eta) = \frac{(\xi+\eta)^4}{5}.$$

21. УСЛОВНЫЕ МОМЕНТЫ

Допустим, мы хотели оценить значение случайного эксперимента X. Но у нас есть доступ только к значениям эксперимента Y, поэтому мы посчитали $\mathrm{E}(X \mid Y)$. Теперь мы хотим оценить погрешность нашего измерения икса. Она складывается из двух погрешностей: как мы оцениваем отклонение икса от оценки $\mathrm{E}(X \mid Y)$, и погрешности самого игрека. Это формализуется следующим образом.

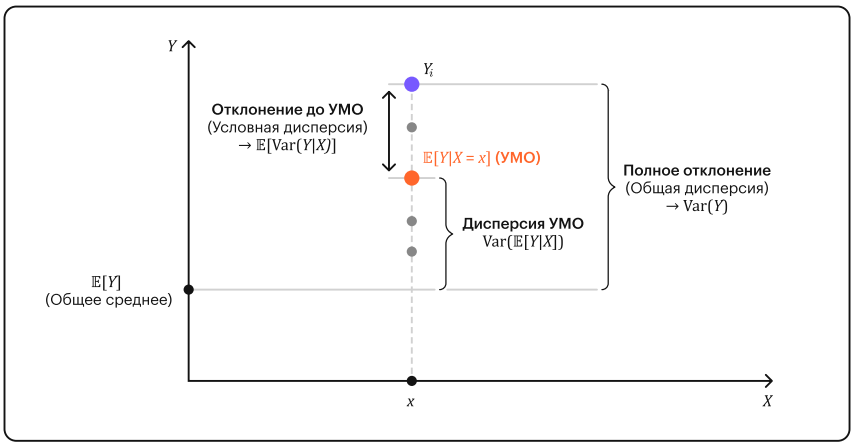

Рисунок 28. Полная ошибка измерения складывается из известной и неизвестной ошибок

Условной дисперсией величины ξ при условии η называется

$$\operatorname{Var}(\xi \mid \eta) := \mathrm{E}\Big(\big(\xi - \mathrm{E}(\xi \mid \eta)\big)^2 \mid \eta\Big).$$

Иными словами, в определении дисперсии вместо обычного матожидания подставили условное.

Наши неформальные рассуждения выше можно формализовать следующим образом.

ТЕОРЕМА 3.21.1

Для любых случайных величин ξ, η, для которых определена обычная и условная дисперсия, выполнено

$$\operatorname{Var}\xi = \mathrm{E}\operatorname{Var}(\xi \mid \eta) + \operatorname{Var}\mathrm{E}(\xi \mid \eta).$$

Дисперсию УМО здесь называют «объяснённым разбросом». Это как бы известное отклонение нашего эксперимента. Матожидание условной дисперсии называется «необъяснённым разбросом». Это то, насколько наше искомое измерение отклонилось от эксперимента.

Вывод формулы полной дисперсии Доказательство. Для начала заметим, что

$$\mathrm{E}(\xi\mathrm{E}(\xi \mid \eta)) = \mathrm{E}\mathrm{E}(\xi\mathrm{E}(\xi \mid \eta) \mid \eta) = \mathrm{E}(\mathrm{E}(\xi \mid \eta))^2.$$

Теперь, по формуле полного матожидания,

$$\begin{aligned}\mathrm{E}\operatorname{Var}(\xi \mid \eta) &= \mathrm{E}(\xi - \mathrm{E}(\xi \mid \eta))^2 = \\ &= \mathrm{E}\xi^2 + \mathrm{E}(\mathrm{E}(\xi \mid \eta))^2 - 2\mathrm{E}(\xi\mathrm{E}(\xi \mid \eta)) = \\ &= \mathrm{E}\xi^2 - \mathrm{E}(\mathrm{E}(\xi \mid \eta))^2.\end{aligned}$$

По формуле для дисперсии и снова по формуле полной вероятности для УМО,

$$\operatorname{Var}\mathrm{E}(\xi \mid \eta) = \mathrm{E}(\mathrm{E}(\xi \mid \eta)^2) - (\mathrm{E}\xi)^2.$$

Складывая всё вместе, получаем

$$\mathrm{E}\operatorname{Var}(\xi \mid \eta) + \operatorname{Var}\mathrm{E}(\xi \mid \eta) = \mathrm{E}\xi^2 - (\mathrm{E}\xi)^2 = \operatorname{Var}\xi.$$

□

Часть 4. Основы статистического анализа

1. ГЕНЕРАЛЬНАЯ СОВОКУПНОСТЬ И ВЫБОРКА

Начнём с двух ключевых понятий всей статистики — генеральной совокупности и выборки. На практике обычно есть только конеч-

ное количество наблюдений. Чтобы воспользоваться математическим аппаратом теории вероятностей, необходимо сделать вывод о том, что эти имеющиеся в распоряжении цифры ведут себя так же, как генеральная совокупность.

Определение генеральной совокупности и выборки

ОПРЕДЕЛЕНИЕ 4.1.1

Генеральная совокупность Ω

Генеральная совокупность Ω — это полное множество всех объектов или явлений, которые изучают в исследовании.

Иными словами, генеральная совокупность — это множество Ω всех элементов, которые интересуют исследователя.

Например, если нас интересует поведение пользователей приложения, то Ω — множество всех его пользователей. А если изучать парные взаимодействия, то Ω может быть декартовым произведением множеств.

Пусть:

- $A =$ Иван, Мария — множество пользователей;
- $B =$ книга, курс — множество продуктов.

Тогда:

$$\Omega = A \times B = (\text{Иван}, \text{книга}), (\text{Иван}, \text{курс}), (\text{Мария}, \text{книга}), (\text{Мария}, \text{курс}).$$

Рисунок 29. Пример двух бросков монеты

ОПРЕДЕЛЕНИЕ 4.1.2

Выборка S

Выборка S — это подмножество генеральной совокупности, которое выбрали для анализа.

В теории множеств выборка S — это подмножество Ω, то есть $S \subseteq \Omega$. В таком случае выборка — это просто независимые элементы из генеральной совокупности: для них способ вытягивания не определяется.

Например, если Ω — все пользователи приложения — 1 миллион человек, то выборка S может состоять из $10\,000$ случайно выбранных пользователей.

Для $\Omega = A \times B$ из примера про Ивана и Марию выборкой может быть

$$S = \{(\text{Иван}, \text{книга}), (\text{Мария}, \text{курс})\}.$$

Теперь перейдём к методам, с помощью которых можно сформировать выборку из генеральной совокупности.

Семплинг

Семплинг, или **семплирование**, — это метод формирования подмножества из генеральной совокупности.

ОПРЕДЕЛЕНИЕ 4.1.3

Семплинг

Рассмотрим два типа семплирования (рисунок 30):

- **с возвращением** — когда один объект может попасть в выборку многократно;
- **без возвращения** — когда каждый объект попадает в выборку не более одного раза.

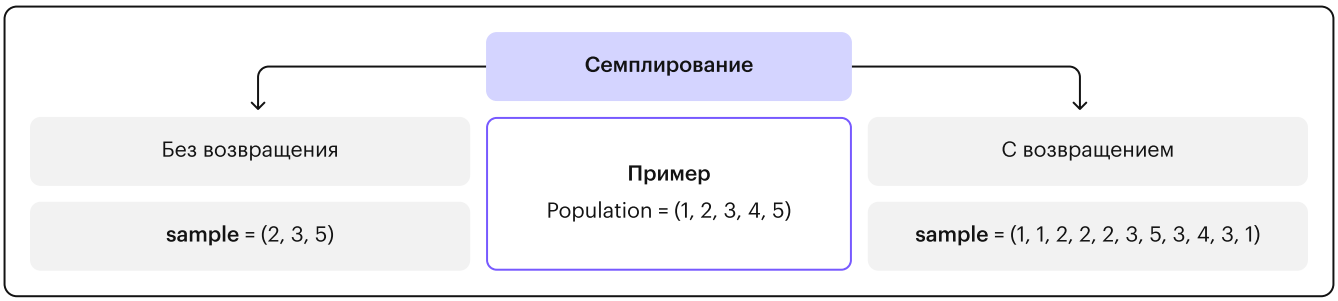

Рисунок 30. Выборка с повторением и без

Отдельно выделяют множественное семплирование.

Множественное семплирование — это последовательное формирование нескольких выборок из одной генеральной совокупности. При нём дополнительно задают число выборок. Оно может быть как с возвращением, так и без него.

ОПРЕДЕЛЕНИЕ 4.1.4

Множественное семплирование

Например, рассмотрим генеральную совокупность студентов: Дани, Егора, Маши и Васи. Проведём семплирования для выборки размера 3 разными способами:

- **с возвращением**: Вася, Даня и снова Вася;
- **без возвращения**: Даня, Егор и Маша;
- **множественное семплирование с возвращением**: 1) Егор, Егор, Егор; 2) Даня, Маша, Егор;
- **множественное семплирование без возвращения**: 1) Егор, Даня, Вася; 2) Вася, Маша, Егор.

Ошибки при формировании выборки

Рассмотрим наиболее часто встречающиеся ошибки семплинга.

Ошибка выжившего — анализ только тех объектов, которые прошли отбор, без учёта объектов, которые этот отбор не прошли.

ОПРЕДЕЛЕНИЕ 4.1.5
Ошибка выжившего

Например, если судить об успешности приложения только по активным пользователям, не учитывая тех, кто его удалил, оценка приложения может оказаться завышенной.

Черри-пикинг — выбор только тех данных, которые подтверждают заранее сформулированную точку зрения, и игнорирование данных, которые ей противоречат.

ОПРЕДЕЛЕНИЕ 4.1.6
Черри-пикинг

Например, в отчёт руководству можно включить только положительные отзывы о приложении, не показывая негативные.

Ошибка самоотбора — участники сами решают, участвовать ли им в исследовании. Это искажает выборку.

ОПРЕДЕЛЕНИЕ 4.1.7
Ошибка самоотбора

Например, на опрос в приложении могут ответить преимущественно пользователи, которым приложение особенно нравится или, наоборот, особенно не нравится. В результате мнение участников опроса может не отражать мнение всех пользователей.

Таким образом, во всех трёх случаях проблема связана с тем, что данные, попавшие в исследование, систематически отличаются от всей интересующей совокупности. Поэтому важно заранее продумать, что именно должно попасть в выборку и как обеспечить её соответствие исследуемой совокупности.

Стратификация и связанные ошибки

Ранее мы упоминали различные виды семплинга, но все они были равномерно случайными (простой семплинг), то есть вероятность для каждого элемента генеральной совокупности попасть в выборку была одинаковой.

Однако иногда необходимо контролировать состав выборки, и один из методов такого контроля — это стратификация. Она особенно полезна в исследованиях данных и при проведении A/B-тестов, когда важно, чтобы группы сравнения были сопоставимы по существенным характеристикам.

Стратификация — разделение генеральной совокупности на однородные подгруппы (страты) перед формированием выборки и последующее извлечение пропорциональной выборки в соответствии с указанной структурой.

ОПРЕДЕЛЕНИЕ 4.1.8

Например, изучая мнения о приложении, стоит разделить пользователей на страты по возрасту:

- подростки (13–17);
- молодые (18–25);
- взрослые (26–45).

А затем из каждой страты возьмём пропорциональную выборку. Тогда можно гарантировать, что возрастная структура выборки будет соответствовать возрастной структуре генеральной совокупности.

На большой выборке случайный семплинг будет генерировать выборку, похожую на генеральную совокупность по структуре, поэтому стратификация становится излишней. Однако на маленькой выборке существует большая вероятность того, что выборка окажется нерепрезентативной.

Также важно отметить, что сама стратификация не гарантирует отсутствия предвзятости. Ошибка может возникнуть, если страты выделены неудачно, из отдельных страт отбирается непропорциональное количество объектов или важные характеристики вообще не учитываются. Поэтому при формировании выборки необходимо учитывать характеристики, которые могут существенно влиять на изучаемый результат.

Например, если генеральная совокупность состоит из 100 человек, среди которых 30 женщин, то мы бы хотели в выборке видеть 30% женщин. Если выборка маленькая (например, 6 человек), то велика вероятность, что женщин будет не 30%. Тогда нам придётся задействовать стратифицированный семплинг, чтобы убедиться, что в выборке будет 2 женщины.

Чем ближе выборка будет по размеру к генеральной совокупности, тем выше вероятность, что структура выборки будет близка к структуре генеральной совокупности, и тем меньше необходимость применять стратифицированный семплинг.

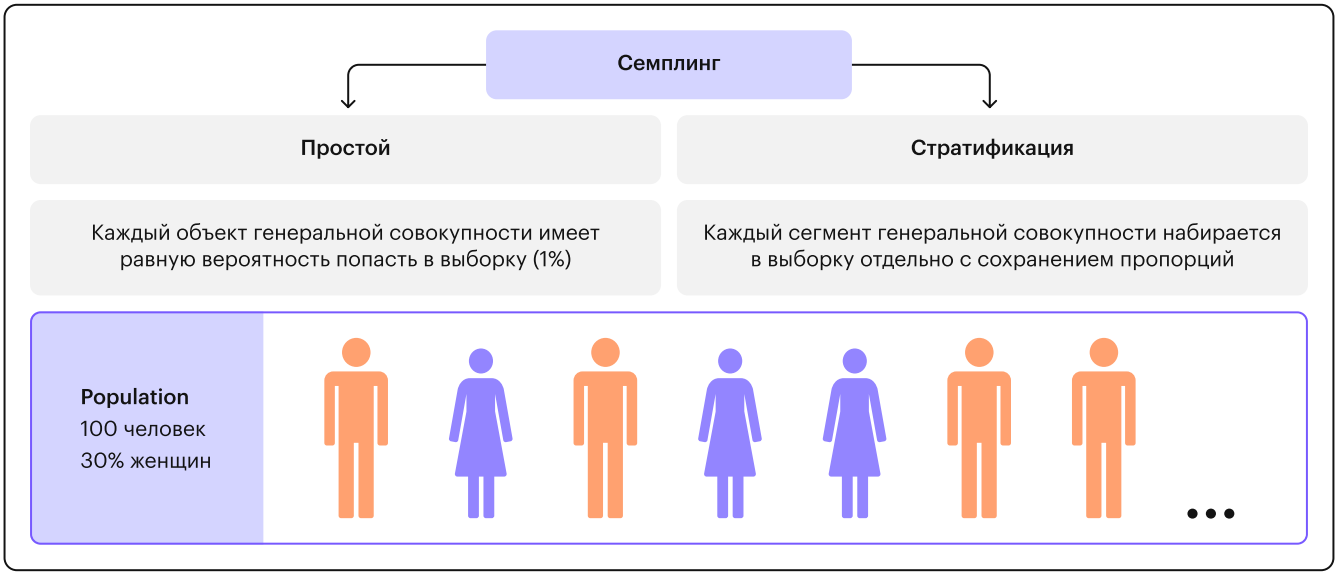

Рисунок 31. Стратифицированный и обычный семплинг

Таким образом, корректный анализ начинается не с математического метода, а с проверки того, насколько данные действительно позволяют ответить на поставленный вопрос. Если выборка систематически не отражает исследуемую совокупность, даже безошибочные вычисления могут привести к неверным выводам.

2. ШКАЛЫ ИЗМЕРЕНИЯ

При работе с данными важно понимать, к какому типу относится тот или иной признак, чтобы правильно выбрать метрики и подходы для работы с этим признаком.

Свойства шкал

Прежде чем мы перейдём к классификации шкал, необходимо рассмотреть свойства, которыми шкала может обладать или не обладать. Ведь именно наличие или отсутствие этих свойств определяет ту или иную шкалу.

Выделяют следующие свойства:

- идентифицируемость;
- магнитуда;
- равенство интервалов;
- абсолютный ноль.

Рассмотрим их подробнее.

ОПРЕДЕЛЕНИЕ 4.2.1

Идентифицируемость

Идентифицируемость — это возможность присвоить числовое значение любому элементу выборки.

Например: два уникальных пола в выборке можно обозначить любыми цифрами, так как они выступают просто как метки (рисунок 32).

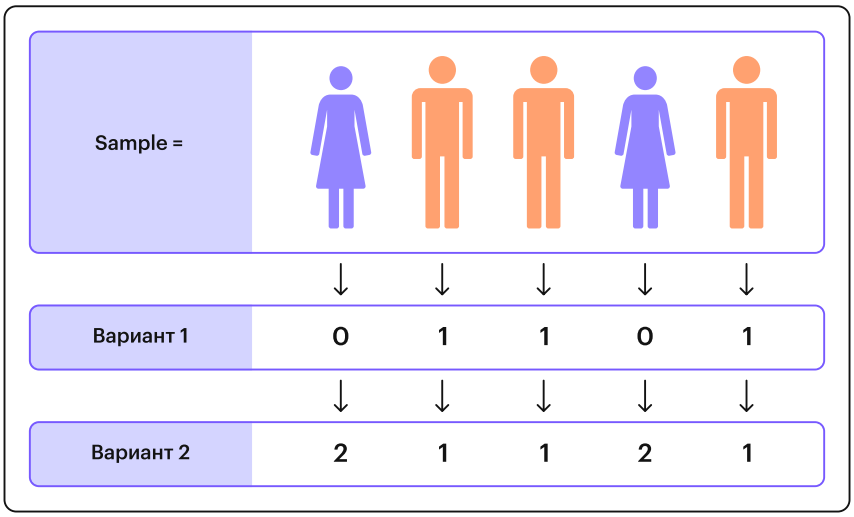

Рисунок 32. Свойство идентифицируемости

ОПРЕДЕЛЕНИЕ 4.2.2

Магнитуда

Магнитуда — это возможность ранжировать числовые значения по их размерностям.

Например: уровни клиентской удовлетворённости можно обозначить любыми цифрами, которые в отношениях «больше-меньше» (рисунок 33).

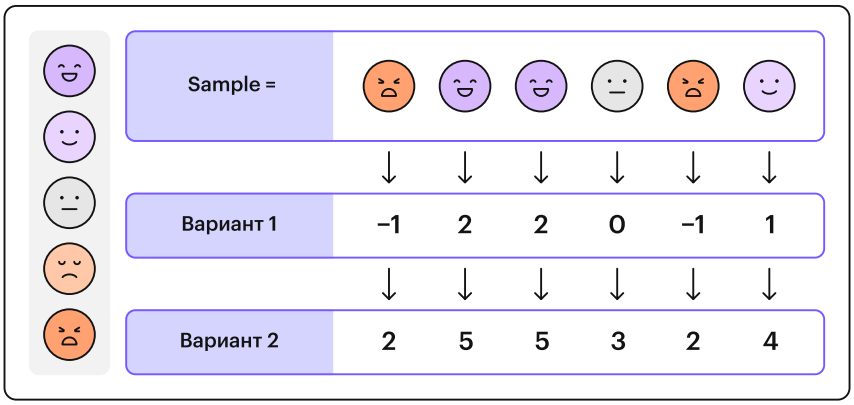

Рисунок 33. Свойство магнитуды

Равенство интервалов — это возможность оценивать расстояние между ранжированными числовыми элементами.

ОПРЕДЕЛЕНИЕ 4.2.3
Равенство интервалов

Например: температура по Фаренгейту или Цельсию, так как расстояния между «точками» определены, но абсолютного нуля нет. То есть ноль по шкале Цельсия не означает физическое отсутствие какого-то признака, оно означает лишь некоторый бенчмарк вроде температуры, при которой вода замерзает (рисунок 34).

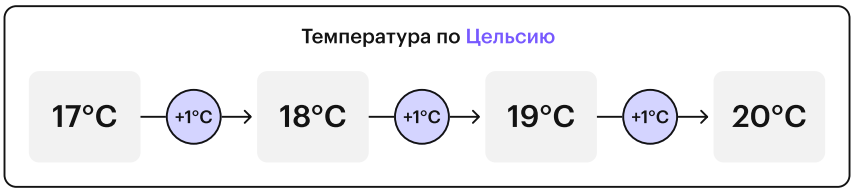

Рисунок 34. Свойство равенства интервалов

Абсолютный ноль — это возможность определить нулевую точку с точки зрения, есть измеряемый признак или нет.

ОПРЕДЕЛЕНИЕ 4.2.4
Абсолютный ноль

Например: температура по Кельвину, так как ноль обладает физическим свойством — полным отсутствием тепла с физической точки зрения (рисунок 35).

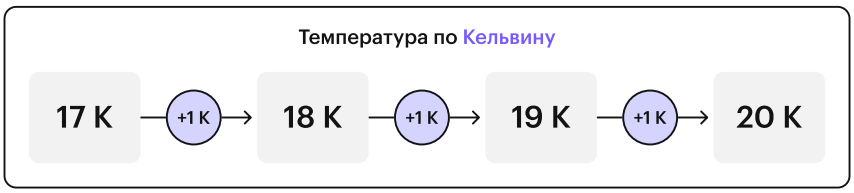

Рисунок 35. Свойство абсолютного нуля

Каждый следующий тип шкалы из рассмотренных выше накапливал эти свойства. Отобразим это в таблице (рисунок 36).

Свойства / тип шкалы	Номинальная	Порядковая	Интервальная	Отношений
Идентифицируемость	•	•	•	•
Величина (магнитуда)		•	•	•
Равенство интервалов			•	•
Абсолютный ноль				•

Рисунок 36. Свойства различных типов шкал

Типы шкал измерения

Теперь перейдём к самим шкалам. Выделяют четыре типа шкал: номинальную, порядковую, интервальную и шкалу отношений.

На **номинальной шкале** данные делятся на категории без порядка.

ОПРЕДЕЛЕНИЕ 4.2.5
Номинальная шкала

Например, тип устройства пользователя: мобильный телефон, планшет или компьютер. Номинальная шкала показывает, совпадают значения или различаются. Поэтому расположить на ней непрерывные данные невозможно.

На **порядковой шкале** значения можно расположить по порядку, но нельзя определить разницу между ними.

ОПРЕДЕЛЕНИЕ 4.2.6
Порядковая шкала

Например, уровень доступа пользователя в системе: гость < < зарегистрированный < администратор. Непрерывные данные расположить на такой шкале уже возможно, однако сначала придётся провести упорядоченную группировку.

На **интервальной шкале** можно сравнить разницу между значениями, но нельзя сравнить их отношения: у шкалы нет абсолютного нуля.

ОПРЕДЕЛЕНИЕ 4.2.7
Интервальная шкала

Например, время загрузки страницы в приложении: от $0,5$ до 1 секунды, от 1 до $1,5$ секунды и так далее. На этой шкале можно расположить как дискретные, так и непрерывные данные.

Шкала отношений — это шкала с абсолютным нулём, на которой можно измерять отношения.

ОПРЕДЕЛЕНИЕ 4.2.8
Шкала отношений

Например, количество денег на счёте пользователя. Здесь абсолютный ноль возможен.

На практике чаще всего используют номинальную шкалу и шкалу отношений.

Дискретные и непрерывные величины

Понятия дискретности и непрерывности важны для понимания того, какие методы статистички можно применять к данным. Существует некоторое соответствие между ними и статистическими шкалами.

Дискретная величина — это величина, которая принимает только определённые, изолированные значения, обычно из счётного множества.

ОПРЕДЕЛЕНИЕ 4.2.9
Дискретная величина

Например, количество сессий пользователя за день — 0, 1, 2 и так далее.

Непрерывная величина — это величина, которая может принимать любое значение в некотором интервале.

ОПРЕДЕЛЕНИЕ 4.2.10
Непрерывная величина

Например, если не учитывать точность измерения, то непрерывной величиной можем считать время, которое пользователь провёл в приложении: $10,5$ минуты, $10,51$ минуты, $10,512834723$ минуты и так далее.

Соответствие между статистическими шкалами и понятиями дискретности и непрерывности можно представить следующим образом (рисунок 37).

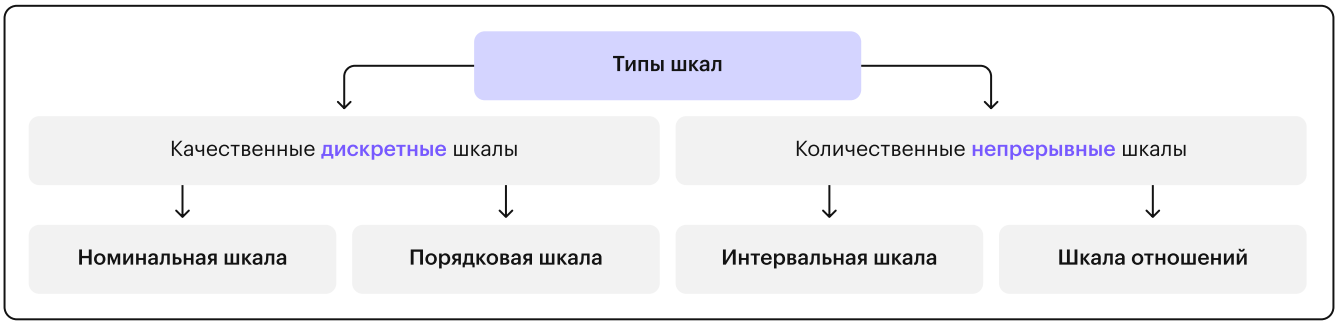

Рисунок 37. Соответствие статистических шкал и понятий дискретности и непрерывности

3. МЕРЫ ЦЕНТРАЛЬНОЙ ТЕНДЕНЦИИ И КВАНТИЛИ

В этом параграфе мы рассмотрим расчётные выборочные значения, которые используют для отображения меры центральной тенденции, то есть значения, которые отображают центр распределения.

Виды средних

Начнём с различных средних значений.

Среднее арифметическое $\bar{X}_{AM}$ — это сумма всех значений, делённая на их количество:

ОПРЕДЕЛЕНИЕ 4.3.1
Среднее арифметическое $\bar{X}_{AM}$

$$\bar{X}_{AM} = \frac{1}{n}\sum_{i=1}^{n} X_i.$$

Например, время активности пользователей в приложении: 10 минут, 15 минут, 20 минут, 25 минут, 30 минут. Тогда среднее

арифметическое:

$$\bar{X}_{AM} = \frac{100}{5} = 20 \text{ минут.}$$

ОПРЕДЕЛЕНИЕ 4.3.2

Среднее геометрическое $\bar{X}_{GM}$

Среднее геометрическое $\bar{X}_{GM}$ — это число, которым можно заменить каждое из значений так, чтобы их произведение не изменилось:

$$\bar{X}_{GM} = \sqrt[n]{x_1 x_2 \ldots x_n} = \left(\prod_{i=1}^{n} x_i\right)^{\frac{1}{n}}.$$

Например, для значений из примера для среднего арифметического $\bar{X}_{GM} = \sqrt[5]{10 \times 15 \times 20 \times 25 \times 30} \approx 18,64$ минуты.

Важно отметить, что для среднего геометрического существуют ограничения:

- если в выборке есть ноль, то среднее геометрическое равно нулю;
- если в выборке есть отрицательные числа, то корня чётной степени не существует в плоскости реальных чисел;
- большие числа — например, ряд ипотечных кредитов — делают расчёт среднего геометрического вычислительно затратным.

Теперь рассмотрим соотношение между этими двумя видами средних.

ОПРЕДЕЛЕНИЕ 4.3.3

Неравенство треугольника

Неравенство треугольника — сумма длин двух сторон любого треугольника всегда больше длины третьей стороны.

Похожее свойство, построенное на сравнении функций от набора неотрицательных чисел, встречается и в других областях математики. Например, в математической статистике.

Перейдём к неравенству Коши — следствию неравенства треугольника.

ОПРЕДЕЛЕНИЕ 4.3.4

Неравенство Коши

Неравенство Коши — среднее геометрическое любых неотрицательных чисел не превосходит их среднего арифметического:

$$\bar{X}_{GM} = \left(\prod_{i=1}^{n} x_i\right)^{\frac{1}{n}} \leqslant \frac{1}{n}\sum_{i=1}^{n} x_i = \bar{X}_{AM}.$$

Равенство достигается только тогда, когда все числа равны между собой. Это можно доказать методом математической индукции. Но сейчас наиболее важно запомнить, что среднее арифметическое не меньше геометрического.

Среднее арифметическое и среднее геометрическое — наиболее известные виды средних. Но при анализе различных величин возникают задачи, в которых эти средние не самый подходящий способ обобщить данные. В таких случаях используют другие виды средних, выбор которых зависит от характера рассматриваемых величин и цели анализа.

Добавим к двум уже известным средним ещё одну классическую вариацию — **среднее гармоническое**.

ОПРЕДЕЛЕНИЕ 4.3.5

Среднее гармоническое $\bar{X}_{HM}$

Среднее гармоническое $\bar{X}_{HM}$ для положительных чисел $X_1, \ldots, X_n$ — это величина

$$\bar{X}_{HM} = \left(\frac{1}{n} \sum_{i=1}^{n} X_i^{-1} \right)^{-1} = \frac{n}{\sum_{i=1}^{n} \frac{1}{X_i}}.$$

Среднее гармоническое особенно чувствительно к малым значениям. Поэтому его применяют, например, при усреднении скоростей, производительностей и других величин, для которых в расчётах используются обратные значения.

Если включить в неравенство Коши гармоническое среднее, получится такая цепочка:

$$\bar{X}_{HM} \leqslant \bar{X}_{GM} \leqslant \bar{X}_{AM}.$$

Равенство достигается тогда и только тогда, когда $X_1 = X_2 = \ldots = X_n$.

Пример 4.3.1. Есть выборка из пяти клиентов и упорядоченный набор сумм их чеков, записанный в виде вектора: $(1000, 2000, 4000, 8000, 35\,000)$.

Найди среднее арифметическое, среднее геометрическое и среднее гармоническое этого вектора. Проанализируй получившиеся значения.

Решение. Среднее арифметическое вектора:

$$\bar{X}_{AM} = \frac{1000 + 2000 + 4000 + 8000 + 35\,000}{5} = 10\,000.$$

Среднее геометрическое:

$$\bar{X}_{GM} = (1000 \times 2000 \times 4000 \times 8000 \times 35\,000)^{1/5} \approx 4677,89.$$

Среднее гармоническое:

$$\bar{X}_{HM} = \frac{5}{\frac{1}{1000} + \frac{1}{2000} + \frac{1}{4000} + \frac{1}{8000} + \frac{1}{35\,000}} \approx 2626,64.$$

Таким образом,

$$\bar{X}_{HM} < \bar{X}_{GM} < \bar{X}_{AM}.$$

Среднее арифметическое сильнее реагирует на большое значение $35\,000$, поэтому оно значительно выше двух других средних. Среднее геометрическое ослабляет влияние крупных значений, тогда как среднее гармоническое, напротив, сильнее реагирует на малые значения, в частности на 1000 и 2000.

Следует отметить, что среднее арифметическое, геометрическое и гармоническое можно получить из одной общей формулы.

ОПРЕДЕЛЕНИЕ 4.3.6

Среднее по Коши $\bar{X}$

Пусть функция f непрерывна и строго монотонна на промежутке, содержащем $X_1, \ldots, X_n$. Тогда существует обратная функция f^{-1}, а **среднее по Коши** $\bar{X}$ задаётся формулой

$$\bar{X} = f^{-1}\left(\frac{1}{n}\sum_{i=1}^{n} f(X_i)\right).$$

Таким образом, формула среднего по Коши задаёт последовательность из трёх шагов. Сначала каждое наблюдение X_i переводится в новую шкалу с помощью функции f. Затем в этой шкале вычисляется среднее арифметическое, после чего функция f^{-1} возвращает результат в исходную шкалу.

При этом функция f должна быть строго монотонной, чтобы обратная функция f^{-1} была определена однозначно. Причём f может быть как возрастающей, так и убывающей.

При разных выборах функции f получаются различные стандартные средние:

- при $f(x) = x$ и $f^{-1}(x) = x$ получаем среднее арифметическое:
$$\bar{X}_{AM} = \frac{\sum_{i=1}^{n} X_i}{n};$$
- при $f(x) = \ln x$ и $f^{-1}(x) = e^x$ для положительных наблюдений получаем среднее геометрическое:
$$\bar{X}_{GM} = \exp\left(\frac{1}{n}\sum_{i=1}^{n} \ln X_i\right) = \left(\prod_{i=1}^{n} X_i\right)^{1/n};$$
- при $f(x) = 1/x$ и $f^{-1}(x) = 1/x$ для положительных наблюдений получаем среднее гармоническое:
$$\bar{X}_{HM} = \left(\frac{1}{n}\sum_{i=1}^{n} X_i^{-1}\right)^{-1} = \frac{n}{\sum_{i=1}^{n} \frac{1}{X_i}}.$$

Таким образом, выбор функции f определяет шкалу усреднения (рисунок 38):

- исходные значения для среднего арифметического,
- логарифмы для среднего геометрического,
- обратные значения для среднего гармонического.

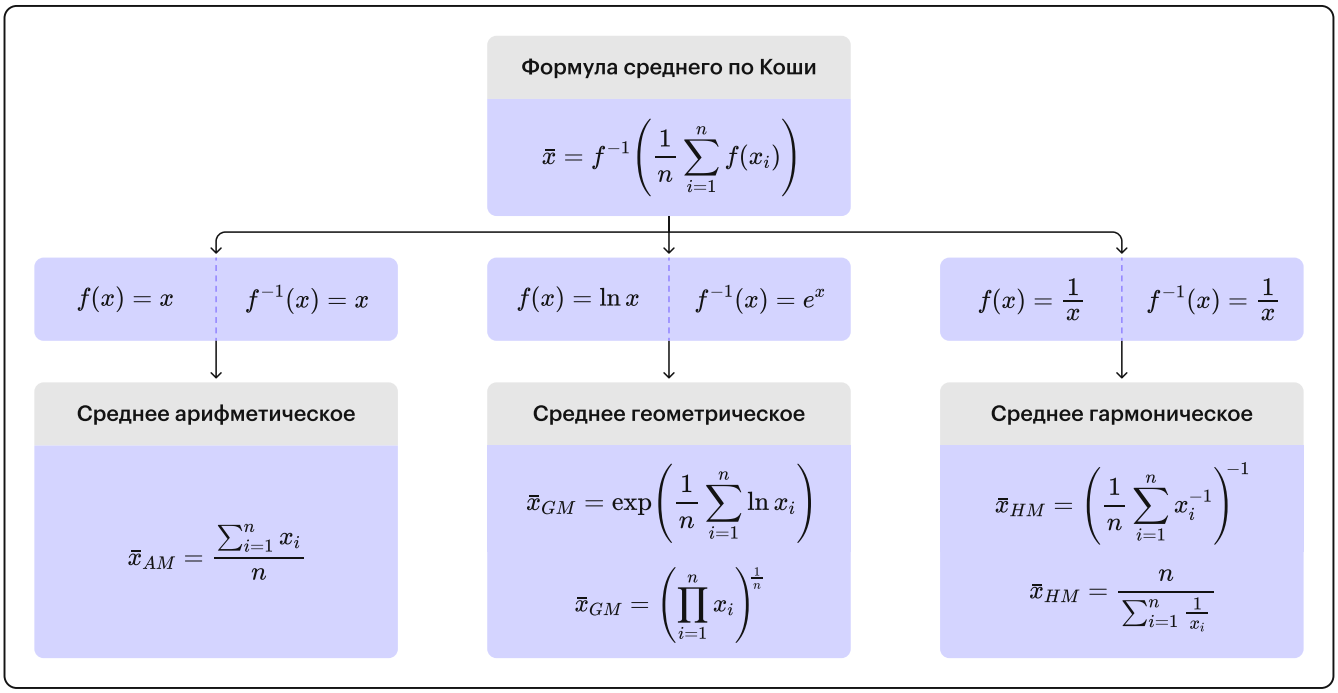

Рисунок 38. Виды средних из формулы Коши

Если в выборке есть выбросы, среднее арифметическое может заметно сместиться в их сторону. Один из способов уменьшить влияние таких наблюдений — перед усреднением исключить или заменить некоторое число крайних значений. На этой идее основаны **усечённое** и **винзорированное** среднее.

Чтобы определить, какие наблюдения крайние, сначала нужно их упорядочить:

$$x_{(1)} \leqslant x_{(2)} \leqslant \ldots \leqslant x_{(n)}.$$

Индекс в круглых скобках обозначает место элемента после упорядочивания: $x_{(1)}$ — минимальное наблюдение, $x_{(2)}$ — второе наименьшее значение, а $x_{(n)}$ — максимальное наблюдение. Такое обозначение позволяет явно отделить порядок наблюдения в выборке от его исходного номера.

ОПРЕДЕЛЕНИЕ 4.3.7

Усечённое среднее $\bar{X}_{tr}$

Пусть с каждого края удаляется по k наблюдений, где $0 \leqslant k < n/2$. Тогда **усечённое среднее** $\bar{X}_{tr}$:

$$\bar{X}_{tr} = \frac{1}{n-2k}\sum_{i=k+1}^{n-k} X_{(i)}.$$

Если с каждого края удаляется доля α и $k = \lfloor n\alpha \rfloor$:

$$\bar{X}_{tr}(\alpha) = \frac{1}{n-2\lfloor n\alpha \rfloor}\sum_{i=\lfloor n\alpha \rfloor+1}^{n-\lfloor n\alpha \rfloor} X_{(i)}.$$

Если $n\alpha$ — целое число, формула принимает вид

$$\bar{X}_{tr}(\alpha) = \frac{1}{n(1-2\alpha)} \sum_{i=n\alpha+1}^{n-n\alpha} X_{(i)}.$$

Усечение иногда ещё называют **клиппингом** (от *англ.* clipping).

Усечённое среднее полностью исключает выбранные крайние наблюдения. После удаления k минимальных и k максимальных значений в расчёте остаётся $n - 2k$ элементов.

Пример 4.3.2. Есть выборка из пяти клиентов и упорядоченный набор сумм их чеков, записанный в виде вектора: $(1000, 2000, 4000, 8000, 35\,000)$.

Найди среднее арифметическое и усечённое среднее этого вектора. Проанализируй получившиеся значения.

Решение. Среднее арифметическое вектора:

$$\bar{X}_{AM} = \frac{1000 + 2000 + 4000 + 8000 + 35\,000}{5} = 10\,000.$$

Усечём по одному наблюдению с каждого края, то есть возьмём $k = 1$ или $\alpha = 0,2$. Можно было бы выбрать и другое количество элементов для усечения, но предположим, что здесь достаточно удаления двух элементов.

После того как уберём 1000 и $35\,000$, останется вектор $(2000, 4000, 8000)$.

Поэтому усечённое среднее:

$$\bar{X}_{tr}(0,2) = \frac{2000 + 4000 + 8000}{3} = \frac{14\,000}{3} \approx 4666,67.$$

Усечённое среднее получилось значительно меньше среднего арифметического, потому что максимальное значение $35\,000$ и минимальное значение 1000 исключены из вектора. При этом максимальное значение находится дальше от общей массы наблюдений, чем минимальное.

В отдельных ситуациях вектор можно обрезать не с двух сторон, а только с одной. Например, конкретно в этой задаче можно было бы убрать только самый большой и сильно отличающийся от других чек, а самый маленький чек оставить, так как он слабо отличается от других.

Формула среднего по Коши в исходном виде здесь неприменима: она преобразует и усредняет все наблюдения, но сама по себе не удаляет крайние значения.

Однако следует отметить, что на маленьких выборках потеря даже малого количества наблюдений — проблема, ведь мы теряем значимый процент наблюдений, что понижает информативность выборки. В подобных случаях вместо усечения можно использовать винзорирование.

ОПРЕДЕЛЕНИЕ 4.3.8

Винзорированное среднее $\bar{X}_{wins}$

Пусть по k наблюдений с каждого края нужно винзорировать. Тогда крайние значения заменяют ближайшими некрайними значениями:

$$X_i^{(w)} = \begin{cases} X_{(k+1)}, & \text{если } X_i \leqslant x_{(k+1)}, \\ X_i, & \text{если } X_{(k+1)} < X_i < X_{(n-k)}, \\ X_{(n-k)}, & \text{если } X_i \geqslant X_{(n-k)}. \end{cases}$$

Винзорированное среднее $\bar{X}_{wins}$:

$$\bar{X}_{wins} = \frac{1}{n}\left(\sum_{i=k+1}^{n-k} X_{(i)} + k\,X_{(k+1)} + k\,X_{(n-k)}\right).$$

В отличие от усечения, винзорирование сохраняет все n наблюдений, но ограничивает влияние крайних значений.

Пример 4.3.3. Есть выборка из пяти клиентов и упорядоченный набор сумм их чеков, записанный в виде вектора: $(1000, 2000, 4000, 8000, 35\,000)$.

Найди среднее арифметическое и среднее винзорированное этого вектора. Проанализируй получившиеся значения.

Решение. Среднее арифметическое этого вектора:

$$\bar{X}_{AM} = \frac{1000 + 2000 + 4000 + 8000 + 35\,000}{5} = 10\,000.$$

При $k = 1$ винзорируем по одному наблюдению с каждого края: заменяем минимальное значение 1000 на ближайшее некрайнее значение 2000, а максимальное значение $35\,000$ — на ближайшее некрайнее значение 8000. В результате получаем вектор $(2000, 2000, 4000, 8000, 8000)$. Следовательно,

$$\bar{x}_{wins} = \frac{2000 + 2000 + 4000 + 8000 + 8000}{5} = 4800.$$

Винзорированное среднее 4800 значительно меньше арифметического среднего $10\,000$, потому что значение $35\,000$ заменено на 8000. При этом оно немного больше усечённого среднего $4666,67$, так как при усечении крайние позиции удаляются полностью, а при винзорировании они сохраняются после замены граничными значениями. ■

По аналогии с усечением, винзорирование в отдельных ситуациях может затрагивать только один из хвостов выборочного распределения. Выбор варианта зависит от задачи и от данных.

Формула среднего по Коши в исходном виде здесь неприменима, потому что винзорирование изменяет только крайние наблюдения, а не преобразует все значения одной функцией f.

Во всех видах среднего, рассмотренных выше, есть важная пред-

посылка: у всех наблюдений одинаковый вес $1/n$, где n — размер выборки.

Например, это условие выполняется для примеров с клиентскими чеками: каждый чек входит в расчёт один раз, поэтому все чеки одинаково влияют на результат.

Если известны средние чеки по нескольким городам, их нельзя усреднять с одинаковыми весами, когда количества исходных чеков различаются. Вклад каждого города зависит от числа наблюдений, по которым рассчитано его среднее.

Но здесь нужно сделать оговорку: усечённое и винзорированное среднее можно также рассматривать как средние по выборке с неравными весами, где отсечённые значения имеют вес 0, а 100% веса распределено по оставшимся наблюдениям.

ОПРЕДЕЛЕНИЕ 4.3.9

Среднее взвешенное $\overline{X}_w$

Пусть наблюдениям $X_1, \ldots, X_n$ соответствуют неотрицательные веса $\omega_1, \ldots, \omega_n$, причём $\sum_{i=1}^n \omega_i = 1$. Тогда **среднее взвешенное** $\overline{X}_w$:

$$\overline{X}_w = \sum_{i=1}^n \omega_i X_i.$$

Если веса $m_1, \ldots, m_n$ ненормированны:

$$\omega_i = \frac{m_i}{\sum_{j=1}^n m_j}, \qquad \overline{X}_w = \frac{\sum_{i=1}^n m_i X_i}{\sum_{i=1}^n m_i}.$$

Пример 4.3.4. Вернёмся к примеру с чеками, но поменяем постановку задачи. Теперь вектор чеков $(1000, 2000, 4000, 8000, 35\,000)$ — это не чеки пяти различных клиентов, а средние чеки по пяти различным городам России. Допустим, что эти средние рассчитаны соответственно по числу чеков $(500, 300, 150, 40, 10)$.

Всего $500 + 300 + 150 + 40 + 10 = 1000$ чеков.

Ввести разные веса необходимо, так как в противном случае мы получим среднее арифметическое, ведь оно является частным случаем среднего взвешенного при равных весах.

Решение. Средний чек по всем городам:

$$\overline{X}_w = \frac{500 \times 1000 + 300 \times 2000 + 150 \times 4000 + 40 \times 8000 + 10 \times 35\,000}{1000} = 2370.$$

Среднее арифметическое пяти городских значений:

$$\bar{x}_{AM} = \frac{1000 + 2000 + 4000 + 8000 + 35\,000}{5} = 10\,000.$$

Из-за того, что это среднее арифметическое, у каждого города одинаковый вес $1/5$. Взвешенное среднее равно 2370, при нём вес каждого города пропорционален числу чеков: например, у значения $35\,000$, рассчитанного только по 10 чекам, вес $10/1000 = 0{,}01$.

Если убрать предагрегацию, или предварительное усредненение, по городам и перейти к клиентской выборке, как в предыдущих задачах, получили бы выборку из 1000 чеков. По ней можно рассчитать среднее арифметическое, которое совпало бы со средним взвешенным по городам.

Формула среднего по Коши здесь неприменима, потому что у каждого наблюдения один и тот же коэффициент $1/n$ и разные веса наблюдений не учитываются.

Подведём итоги по задачам с клиентскими чеками.

- Среднее арифметическое $\bar{X}_{AM} = 10\,000$ сильнее всего увеличивается из-за значения $35\,000$.
- Среднее геометрическое $\bar{X}_{GM} \approx 4677,89$ ослабляет влияние больших значений.
- В среднем гармоническом $\bar{X}_{HM} \approx 2626,64$ бóльшую роль играют малые значения.
- Усечённое среднее $\bar{X}_{tr}(0,2) \approx 4666,67$ удаляет оба крайних значения.
- Винзорированное среднее $\bar{X}_{wins} = 4800$ сохраняет все позиции, но заменяет крайние значения ближайшими некрайними.
- Среднее взвешенное $\overline{X}_w = 2370$ будет отличаться от среднего арифметического в рамках этой задачи, только если дополнительно задать веса для каждого города (или другого сегмента).

На рисунке 39 представлены все рассмотренные в этом параграфе подходы к вычислению среднего.

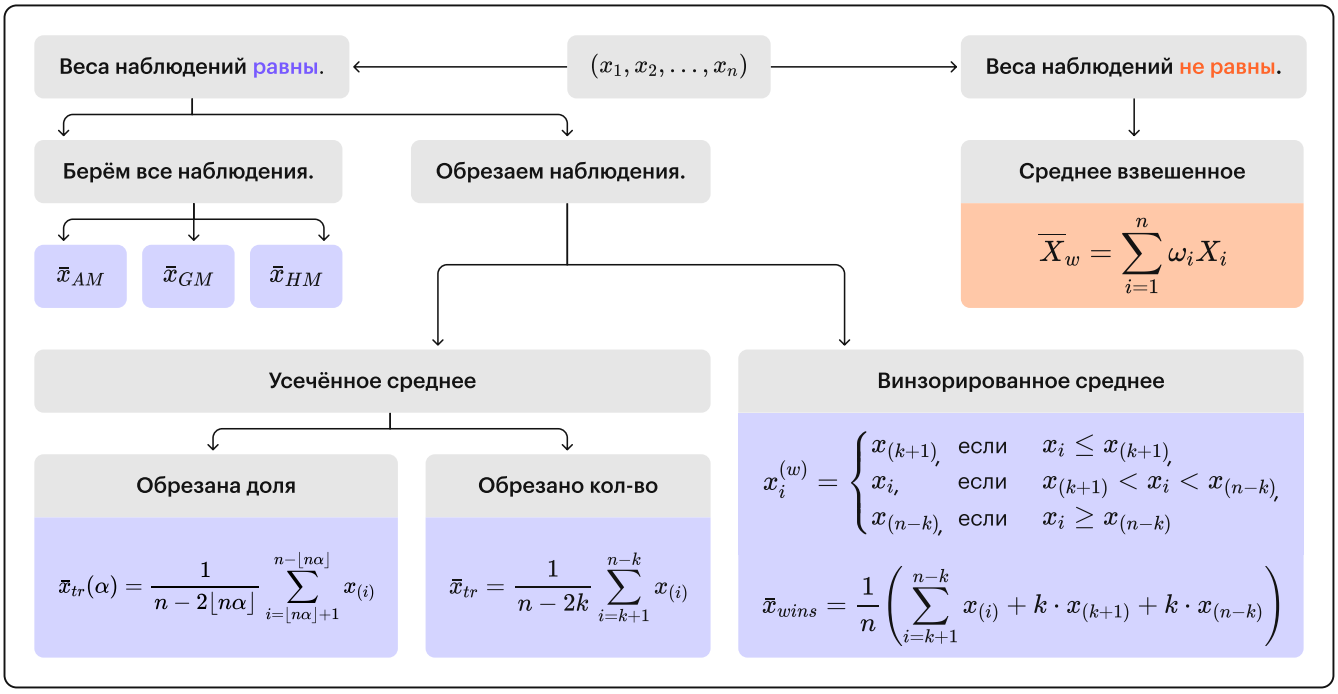

Рисунок 39. Классификация средних

В зависимости от выборки важно выбирать то среднее, которое больше подходит для достижения поставленных целей.

Медиана и мода

Теперь перейдём к альтернативным видам мер центральной тенденции.

ОПРЕДЕЛЕНИЕ 4.3.10
Медиана

Медиана — это значение, которое делит упорядоченную выборку пополам.

В том же примере — 10 минут, 15 минут, 20 минут, 25 минут и 30 минут — медиана равна 20 минутам. Она совпадает со средним значением, но так бывает не всегда.

Медиана полезна в том случае, когда среднее оказывается завышенным или заниженным в связи с наличием в выборке выбросов, то есть значений, которые сильно отличаются от основной массы наблюдений. В связи с тем, что её расчёт основан на рангах, а не на самих значениях, резкое увеличение краевых значений не меняет медиану.

ОПРЕДЕЛЕНИЕ 4.3.11
Мода

Мода — это значение, которое встречается в данных наиболее часто.

Например, в наборе 0, 1, 1, 2 мода равна 1, так как 1 встречается чаще всего.

Итого мы встретили три меры центральной тенденции, которые по-разному описывают условный «центр» распределения. Они представлены на рисунке 49.

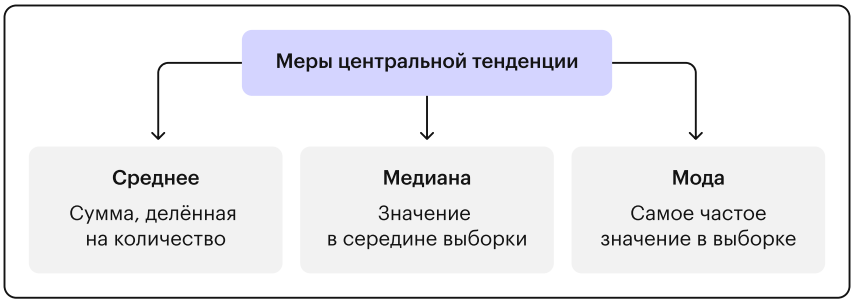

Рисунок 40. Классификация мер центральной тенденции

Квантили

Перейдём к понятию квантиля, которое важно для анализа выборки, особенно при наличии выбросов. Один из видов квантилей мы уже рассматривали — это медиана.

ОПРЕДЕЛЕНИЕ 4.3.12
Квантиль

Квантиль, или перцентиль, — это значение, ниже которого находится определённая доля данных.

Разница между этими двумя понятиями такая же, как между долями и процентами. Квантиль соответствует доле, а перцентиль — проценту.

Например, 25-й перцентиль (или квантиль уровня $0,25$) — время сессии в приложении, ниже которого по длительности находится 25% сессий пользователей.

Частный случай квантилей — квартили.

ОПРЕДЕЛЕНИЕ 4.3.13

Квартиль

Квартиль — это квантиль, который делит данные на части, кратные 25%:

- Q_1 (25%);
- Q_2 (50%);
- Q_3 (75%).

Например, Q_1 — время сессии, ниже которого по длительности 25% сессий пользователей, Q_3 — выше которого 25%.

ОПРЕДЕЛЕНИЕ 4.3.14

Дециль

Дециль — квантиль, который делит данные на части, кратные 10%.

Например, 1-й дециль — время сессии, ниже которого по длительности 10% сессий пользователей.

ОПРЕДЕЛЕНИЕ 4.3.15

Межквартильный размах IQR

Межквартильный размах IQR — это разница между Q_3 и Q_1:

$$IQR = Q_3 - Q_1.$$

Например, если $Q_1 = 10$ минут, $Q_3 = 30$ минут, то $IQR = 20$ минут. На рисунке 41 представлена общая схема межквартильного размаха.

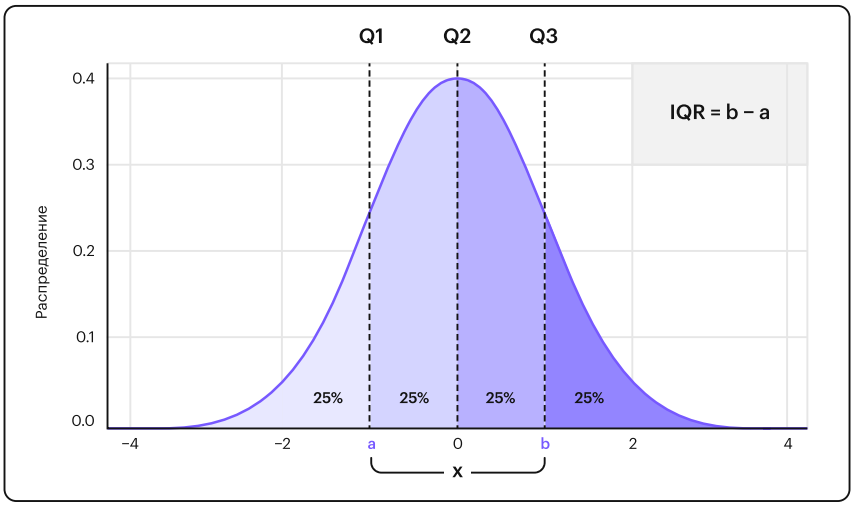

Рисунок 41. Межквартильный размах (IQR)

Квантили можно, в частности, использовать для очистки выборки от выбросов. Например, в случае данных о времени, которое клиенты провели в приложении, могут возникнуть неадекватно большие значения, которые для оценки необходимо удалить. В таком случае можно изучить топ 1% или топ 5% самых крупных наблюдений и удалить их из выборки. Тогда среднее значение будет лучше отображать центральную тенденцию.

4. ВАРИАЦИОННАЯ СТАТИСТИКА

Ранее мы работали непосредственно с элементами выборки, рассчитывая средние или квантильные значения. Но зачастую

удобнее построить интервальный ряд — предагрегацию выборки для более наглядного анализа или визуализации.

Элементы вариационного ряда

ОПРЕДЕЛЕНИЕ 4.4.1
Вариационный ряд

Вариационный ряд — это упорядоченная по возрастанию исходная выборка случайной величины.

Если исходная выборка имеет вид $X = \{X_1, X_2, \ldots, X_n\}$, то вариационный ряд:

$$X_{(1)} \leqslant X_{(2)} \leqslant \cdots \leqslant X_{(n)}.$$

Элемент вариационного ряда $X_{(k)}$ называется **k-й порядковой статистикой**. Индекс в скобках указывает на порядковый номер элемента в упорядоченном массиве данных.

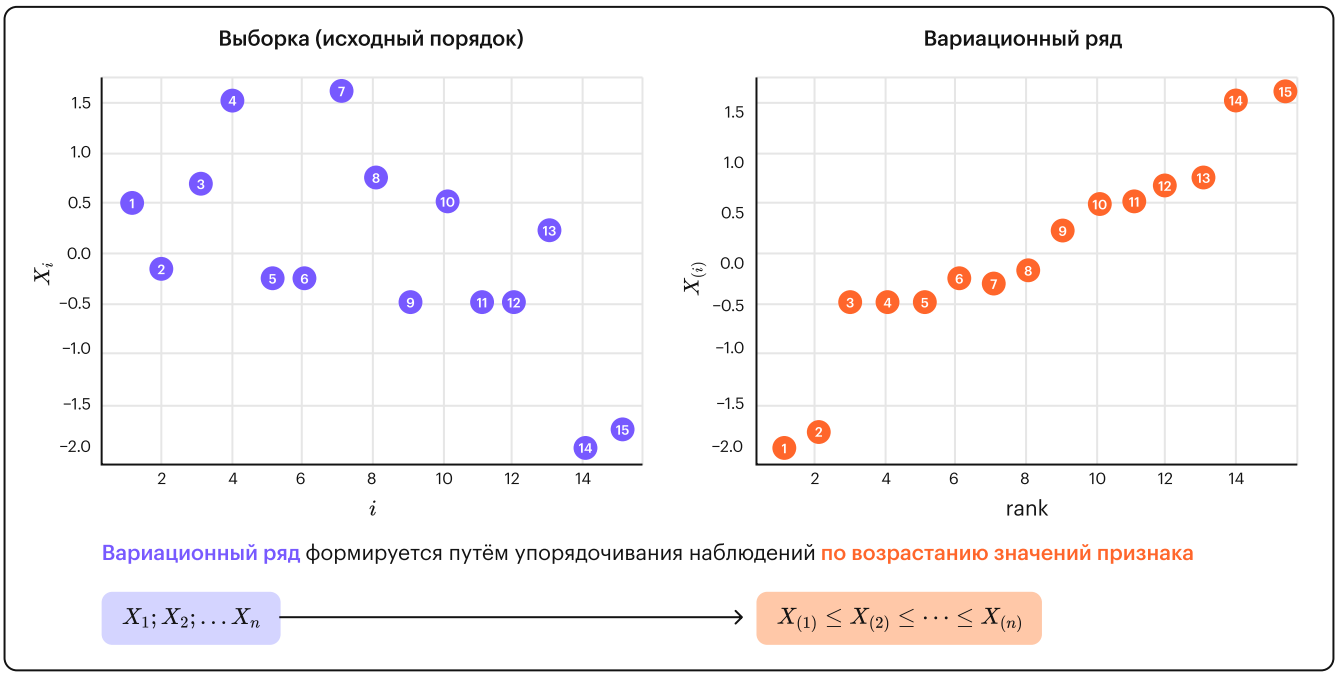

Рисунок 42. Формирование вариационного ряда путём упорядочивания наблюдений

На рисунке 42 исходная выборка — хаотичная последовательность элементов в порядке их регистрации.

Ранжирование выстраивает наблюдения в строго неубывающую цепочку и преобразовывает случайный набор данных $X_1, X_2, \ldots, X_n$ в упорядоченную систему порядковых статистик

$$X_{(1)} \leqslant X_{(2)} \leqslant \cdots \leqslant X_{(n)}.$$

ОПРЕДЕЛЕНИЕ 4.4.2
Минимальная порядковая статистика

Минимальная порядковая статистика — это наименьшее значение выборки:

$$X_{(1)} = \min(X_1, \ldots, X_n) = X_{\min}.$$

Максимальная порядковая статистика — это наибольшее значение выборки:

$$X_{(n)} = \max(X_1, \ldots, X_n) = x_{\max}.$$

ОПРЕДЕЛЕНИЕ 4.4.3
Максимальная порядковая статистика

Размах выборки R — разность между максимальным и минимальным значениями выборки:

$$R = X_{\max} - X_{\min}.$$

ОПРЕДЕЛЕНИЕ 4.4.4
Размах выборки R

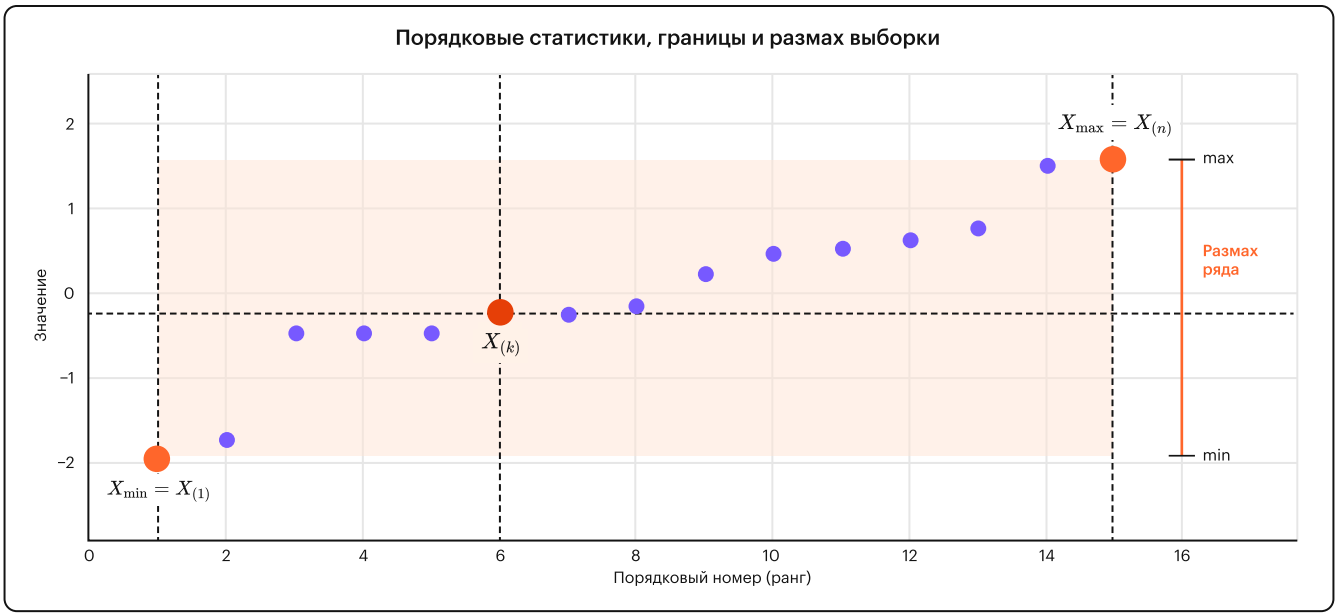

Рисунок 43. Порядковые статистики, границы и размах выборки

На рисунке 43 приведена геометрическая интерпретация экстремальных значений и вариационного диапазона. На графике показано положение произвольной k-й порядковой статистики $X_{(k)}$ и крайних точек выборки — минимальной $X_{\min} = X_{(1)}$ и максимальной $X_{\max} = X_{(n)}$. Расстояние между этими экстремумами по вертикальной оси определяет размах ряда R, который фиксирует границы варьирования исследуемого признака.

Частотный статистический ряд

Если некоторые элементы в выборке повторяются, данные удобно группировать и представлять в виде **частотного ряда**.

Частотный ряд — это сгруппированные данные, где для каждого уникального значения признака рассчитываются доля и количество наблюдений, которые ему соответствуют.

ОПРЕДЕЛЕНИЕ 4.4.5
Частотный ряд

Рассмотрим определения элементов частотного ряда.

Варианта z_i — уникальное значение признака в выборке.

ОПРЕДЕЛЕНИЕ 4.4.6
Варианта z_i

ОПРЕДЕЛЕНИЕ 4.4.7
Абсолютная частота $\mathrm{n_i}$

Абсолютная частота $\mathbf{n_i}$ показывает, сколько раз варианта z_i встречается в исходной выборке.

Сумма всех абсолютных частот равна объёму выборки: $\sum_{i=1}^{m} n_i = n$.

ОПРЕДЕЛЕНИЕ 4.4.8
Относительная частота $\mathrm{w_i}$

Относительная частота (или частость) $\mathbf{w_i}$ — это доля конкретной варианты в общем объёме выборки: $w_i = \frac{n_i}{n}$.

Сумма всех относительных частот всегда равна единице: $\sum_{i=1}^{m} w_i = 1$.

ОПРЕДЕЛЕНИЕ 4.4.9
Накопленная абсолютная частота $\mathrm{N_i}$

Накопленная абсолютная частота $\mathbf{N_i}$ — сумма абсолютных частот всех вариант, которые меньше z_i или равны текущему значению. Показывает число элементов выборки, которые не превосходят z_i:

$$N_i = \sum_{j=1}^{i} n_j.$$

Для последней варианты она равна объёму выборки $N_m = n$.

ОПРЕДЕЛЕНИЕ 4.4.10
Накопленная относительная частота $\mathrm{W_i}$

Накопленная относительная частота $\mathbf{W_i}$ — доля элементов выборки, значения которых не превосходят текущую варианту z_i:

$$W_i = \frac{N_i}{n} \quad \text{или} \quad W_i = \sum_{j=1}^{i} w_j.$$

Для последней варианты она равна единице $W_m = 1$.

Пример 4.4.1. Построим частотный ряд для исходной выборки объёма $n = 25$:

$$X = \{2, 6, 7, 2, 3, 6, 5, 4, 7, 3, 5, 4, 6, 3, 7, 2, 5, 4, 3, 5, 7, 6, 3, 4, 5\}.$$

Решение. Сначала построим вариационный ряд. Для этого упорядочим элементы по возрастанию:

$$\{2, 2, 2, 3, 3, 3, 3, 3, 4, 4, 4, 4, 5, 5, 5, 5, 5, 6, 6, 6, 6, 7, 7, 7, 7\}.$$

Затем определим экстремальные значения и размах:

- $x_{\min} = 2$ — минимальное значение;
- $x_{\max} = 7$ — максимальное значение;
- $R = x_{\max} - x_{\min} = 7 - 2 = 5$ — размах выборки.

Затем подсчитаем частоты для каждой уникальной варианты z_i вручную.

- Для $z_1 = 2$ встречается три раза $n_1 = 3$:

$$w_1 = \frac{3}{25} = 0,12; \qquad N_1 = 3; \qquad W_1 = 0,12.$$

- Для $z_2 = 3$ встречается пять раз $n_2 = 5$:

$$w_2 = \frac{5}{25} = 0,20; \qquad N_2 = 3 + 5 = 8; \qquad W_2 = 0,12 + 0,20 = 0,32.$$

Показатели для остальных вариант рассчитываются по аналогии.

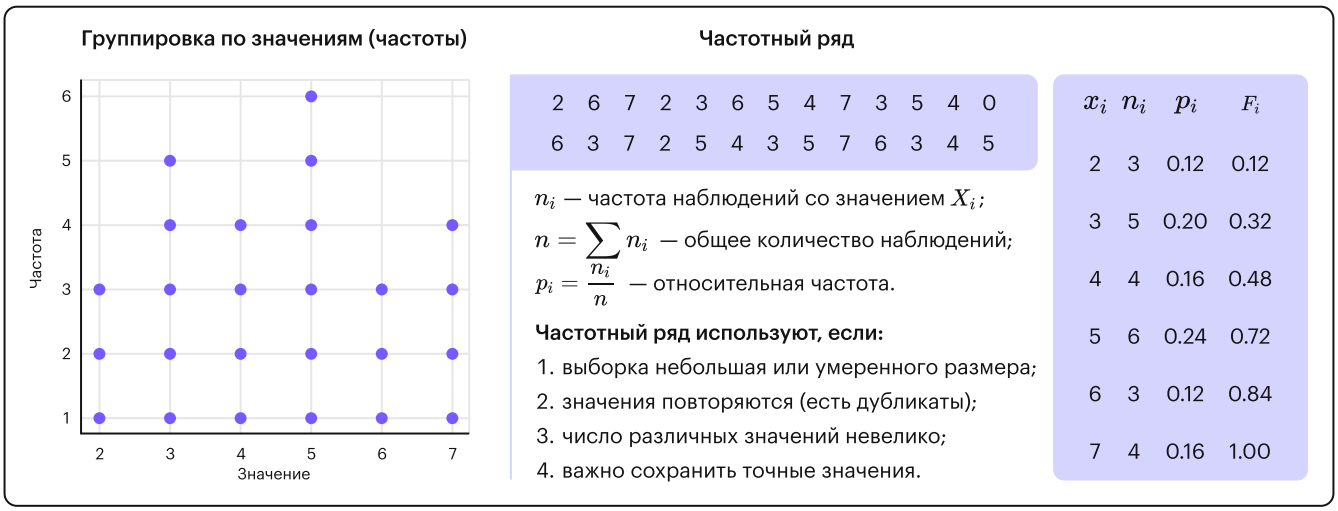

Рисунок 44. Группировка дискретных данных по значениям и формирование частотного ряда

На рисунке 44 показано, как исходный числовой массив агрегируется, а его элементы распределяются по абсолютным частотам. График отражает распределение точек — вариант — по уровням частот и позволяет визуально сопоставить плотность дубликатов в выборке с итоговыми значениями кумулятивных показателей F_i (W_i).

Интервальный вариационный ряд

Когда объём выборки велик ($n > 30 - 50$), а исследуемый признак принимает любые вещественные значения, строить дискретный частотный ряд нет смысла.

В таких случаях данные группируют — строят **интервальный вариационный ряд**. Весь диапазон значений от $x_{\min}$ до $x_{\max}$ делят на k интервалов. Каждый интервал описывают следующими параметрами.

- **Границы интервала** $[x_i,\ x_{i+1})$ — нижняя x_i и верхняя x_{i+1} границы i-го интервала. Элементы, которые точно совпадают с границей, относят к правому интервалу — это **принцип полуоткрытых интервалов**.
- **Ширина интервала** h_i — разность между верхней и нижней границами. Часто используют интервалы одинаковой ширины:

$$h = x_{i+1} - x_i.$$

- **Срединное значение интервала** z_i^* — представитель интервала, который рассчитывают как среднее арифметическое его границ:
$$z_i^* = \frac{x_i + x_{i+1}}{2}.$$
- **Частота интервала** n_i — число элементов выборки внутри i-го интервала.
- **Относительная частота интервала** w_i — доля элементов выборки внутри этого интервала
$$w_i = \frac{n_i}{n}.$$
- **Накопленная относительная частота интервала** N_i и W_i — показатели, которые рассчитывают так же, как в дискретном ряду: последовательно суммируют значения для текущего и всех предыдущих интервалов.

Выбор числа интервалов k принципиально влияет на вид распределения: слишком малое k сглаживает важные детали, а слишком большое — создаёт хаотичный шум. В статистике применяют два основных подхода.

ОПРЕДЕЛЕНИЕ 4.4.11

Формула Стёрджесса

Формула Стёрджесса ищет количество интервалов k на основе объёма выборки n:

$$k = 1 + \log_2 n \approx 1 + 3{,}322 \times \lg n.$$

Полученное значение k округляет до ближайшего целого, после чего находит ширину интервала:

$$h = \frac{x_{\max} - x_{\min}}{k}.$$

Её используют для данных, близких к нормальному распределению.

ОПРЕДЕЛЕНИЕ 4.4.12

Формула Фридмана — Дьякони

Формула Фридмана — Дьякони ищет оптимальную **ширину интервала** h на основе межквартильного размаха (IQR):

$$h = 2 \times \frac{IQR(X)}{\sqrt[3]{n}},$$

где $IQR(X) = Q_3 - Q_1$ — разность между третьим и первым квартилями выборки. Затем определяет количество интервалов:

$$k = \lceil \frac{x_{\max} - x_{\min}}{h} \rceil.$$

Этот метод более устойчив к выбросам и не требует нормальности распределения.

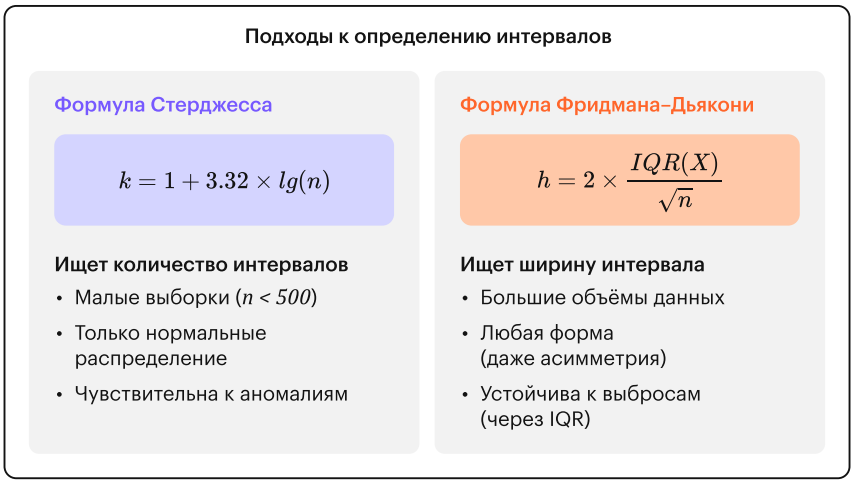

Рисунок 45. Сравнительный анализ подходов к определению параметров интервального ряда

На рисунке 45 показаны основные различия между классическим и робастным подходами к бинированию данных, а также критерии выбора между ними.

Пример 4.4.2. Дана выборка X объёма $n = 40$. Она содержит вес деталей в граммах. Когда построили вариационный ряд, получили следующие данные:

$$X_{\text{сорт.}} = \{10,2,\ 10,5,\ 10,8,\ 11,1,\ 11,2,\ 11,5,\ 12,0,\ 12,1,\ 12,3,\ 12,5,\ 12,8,\ 13,0,\ 13,2,\ 13,5,\ 13,7,\ 14,1,\ 14,3,\ 14,5,\ 14,8,\ 15,0,\ 15,2,\ 15,6,\ 15,9,\ 16,1,\ 16,3,\ 16,7,\ 17,0,\ 17,2,\ 17,5,\ 18,1,\ 18,4,\ 18,9,\ 19,2,\ 19,5,\ 20,1,\ 20,6,\ 21,2,\ 22,0,\ 23,5,\ 25,0\}.$$

Экстремальные значения:

- $x_{\min} = 10,2$;
- $x_{\max} = 25,0$.

Размах выборки: $R = 25,0 - 10,2 = 14,8$. Найди параметры группировки.

Решение. Воспользуемся формулой Стёрджесса.

Сначала найдём число интервалов k.

$$k = 1 + \log_2 40 \approx 1 + 5,322 = 6,322 \implies \text{округляем до } k = 6.$$

Затем вычислим шаг интервала h.

$$h = \frac{14,8}{6} \approx 2,467 \implies \text{для удобства расчётов округлим до } h = 2,5.$$

Чтобы вся выборка гарантированно поместилась, начнём первый интервал чуть раньше: с $x_{\text{нач.}} = 10,0$. Последовательно прибавляя шаг $h = 2,5$, получаем границы шести интервалов. Проведём расчёт для каждого.

- **Интервал 1**: $[10,0;\ 12,5)$. Значения: от $10,2$ до $12,3$:

всего $n_1 = 9$ элементов, средина: $z_1^* = \dfrac{10{,}0 + 12{,}5}{2} = 11{,}25.$

- **Интервал 2**: $[12{,}5;\ 15{,}0)$. Значения: от $12{,}5$ до $14{,}8$:

$$n_2 = 10, \qquad z_2^* = 13{,}75.$$

Накопленная частота: $N_2 = 9 + 10 = 19.$

- **Интервал 3**: $[15{,}0;\ 17{,}5)$. Значения: от $15{,}0$ до $17{,}2$.

$$n_3 = 9, \qquad z_3^* = 16{,}25.$$

- **Интервал 4**: $[17{,}5;\ 20{,}0)$. Значения: от $17{,}5$ до $19{,}5$:

$$n_4 = 6, \qquad z_4^* = 18{,}75.$$

- **Интервал 5**: $[20{,}0;\ 22{,}5)$. Значения: от $20{,}1$ до $22{,}0$:

$$n_5 = 4, \qquad z_5^* = 21{,}25.$$

- **Интервал 6**: $[22{,}5;\ 25{,}0]$. Значения: $23{,}5$ и $25{,}0$:

$$n_6 = 2, \qquad z_6^* = 23{,}7.$$

Связь вариационного ряда и выборочной функции распределения

В теории вероятностей истинное распределение случайной величины описывается теоретической функцией распределения $F(x) = P(X < x)$.

В математической статистике её наилучшей точечной оценкой служит эмпирическая функция распределения $F_n(x)$.

ОПРЕДЕЛЕНИЕ 4.4.13

Эмпирическая функция распределения

Эмпирическая функция распределения определяет для каждого значения x относительную частоту события $\{X < x\}$:

$$F_n(x) = \frac{n_x}{n} = \frac{1}{n}\sum_{i=1}^{n} I(x_i < x),$$

где n_x — число элементов выборки, строго меньших x [1];

$I(\cdot)$ — индикаторная функция, которая равна 1, если условие выполнено, и 0 в противном случае.

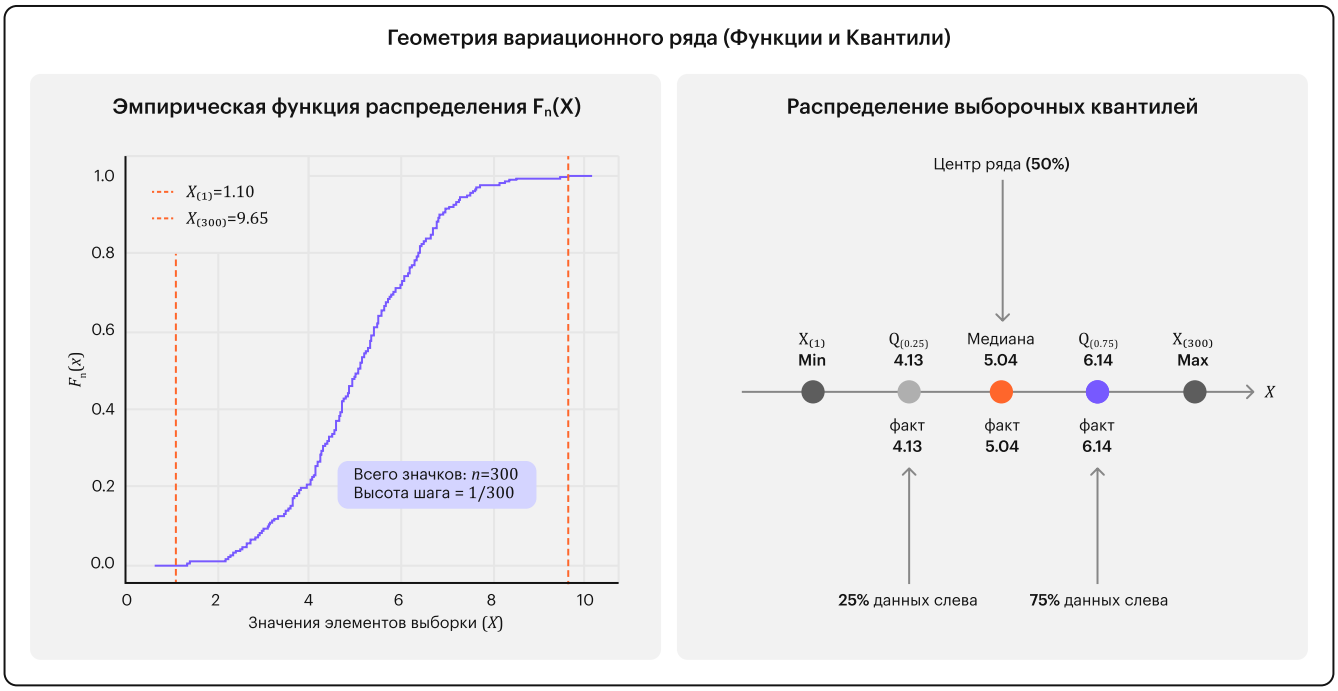

Рисунок 46. Геометрия вариационного ряда: связь эмпирической функции распределения и выборочных квантилей

На рисунке 46 показана геометрия вариационного ряда.

Левый график иллюстрирует, как при большом объёме выборки $n = 300$ дискретные скачки высотой $1/300$ формируют непрерывную S-образную кривую эмпирической функции распределения $F_n(x)$.

Правый график отображает соответствующее деление числовой оси выборочными квантилями, где медиана фиксирует центр ряда 50%, а квартили Q_1 и Q_3 отсекают по 25% данных с левого и правого краёв распределения.

Вариационный ряд $x_{(1)} \leqslant x_{(2)} \leqslant \cdots \leqslant x_{(n)}$ позволяет записать аналитический вид функции $F_n(x)$ в явной кусочно-постоянной форме. Если все элементы выборки уникальны, то функция распределения $F_n(x)$ возрастает на $1/n$ в каждой точке, которая соответствуют порядковой статистике.

$$F_n(x) = \begin{cases} 0, & \text{при } x \leqslant x_{(1)}; \\ \frac{1}{n}, & \text{при } x_{(1)} < x \leqslant x_{(2)}; \\ \frac{2}{n}, & \text{при } x_{(2)} < x \leqslant x_{(3)}; \\ \dots & \dots \\ \frac{k}{n}, & \text{при } x_{(k)} < x \leqslant x_{(k+1)}; \\ \dots & \dots \\ 1, & \text{при } x > x_{(n)}. \end{cases}$$

Если в выборке повторяются порядковые статистики, то величина скачка в точке z_i становится равной относительной частоте w_i

этой варианты, а значения функции — накопленным относительным частотам W_i.

У эмпирической функции распределения есть все свойства классической функции распределения. При этом у неё дискретный ступенчатый характер.

- **Ограниченность.** Область значений функции лежит в строго заданном отрезке:

$$0 \leqslant F_n(x) \leqslant 1. \quad [1]$$

- **Монотонность.** $F_n(x)$ — неубывающая функция на всей числовой прямой [1]. Если $x_1 < x_2$, то

$$F_n(x_1) \leqslant F_n(x_2).$$

- **Непрерывность слева.** В точках скачков значение функции равно пределу слева:

$$F_n(x) = \lim_{t \to x-0} F_n(t).$$

- **Асимптотическое поведение.** На бесконечности функция выходит на свои плато:

$$\lim_{x \to -\infty} F_n(x) = 0 \quad \text{и} \quad \lim_{x \to +\infty} F_n(x) = 1.$$

Связь вариационного ряда и порядковых критериев

Когда выборки сильно асимметричны, содержат грубые ошибки измерений или аномальные выбросы, классические параметрические методы проверки гипотез дают неточные результаты. В таких случаях прикладная статистика использует непараметрические подходы, основанные на **порядковых критериях**.

Основа порядковых критериев — переход от абсолютных числовых значений исходной выборки к их номерам позиций в вариационном ряду — **рангам**.

На рисунке 47 показаны трансформация данных и преимущество рангового подхода.

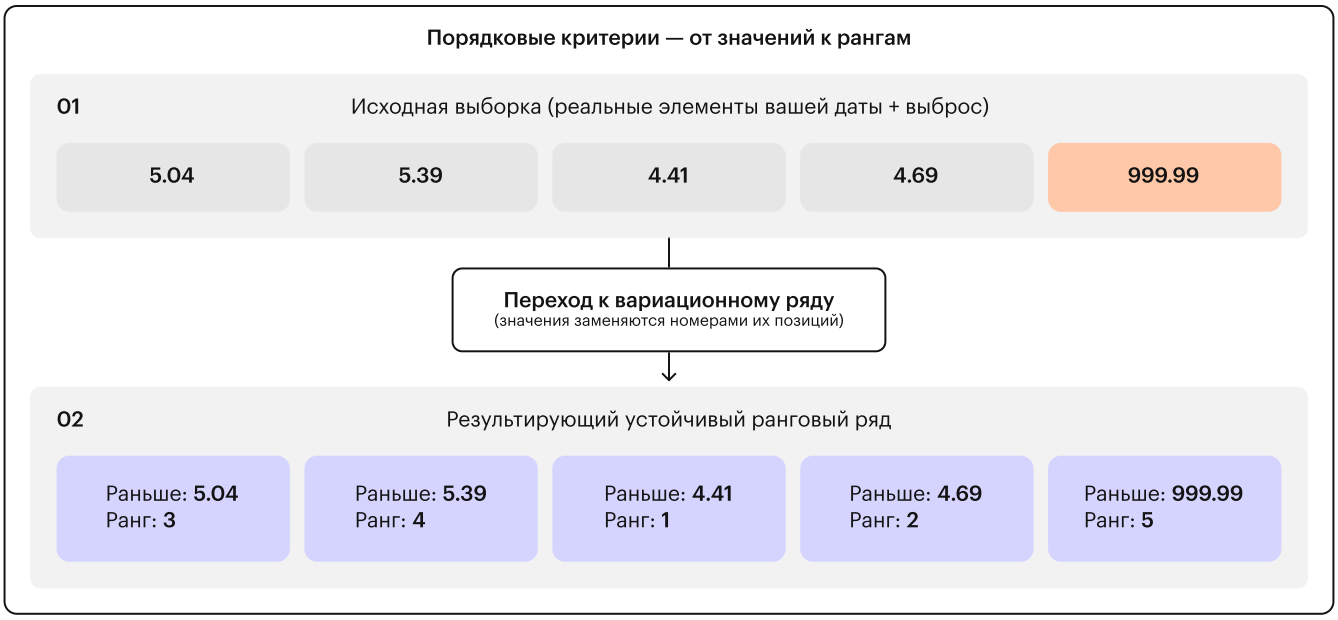

Рисунок 47. Схема перехода от абсолютных значений к устойчивому ранговому ряду

На схеме рисунка 47 видно, что аномальный выброс $999,99$ может полностью исказить среднее арифметическое. Однако в вариационном ряду реальные числовые значения безвозвратно заменяют номерами их позиций.

В результате формируется устойчивый ранговый ряд, в котором аномальный выброс получает стабильный максимальный ранг 5. Благодаря этому экстремальные выбросы не искажают выводы непараметрических статистических гипотез и других робастных методов.

5. ВИЗУАЛИЗАЦИЯ В СТАТИСТИКЕ

В статистике есть набор стандартных графиков, которые используют, чтобы наглядно визуализировать распределение данных в рамках выборки. Рассмотрим основные виды диаграмм.

Гистограмма

ОПРЕДЕЛЕНИЕ 4.5.1

Гистограмма — график распределения данных, где значения группируются в интервалы, или бины, а высота столбца пропорциональна частоте, или частости.

Например, данные о времени сессии в приложении: по оси X интервалы от 0 до 1 минуты, от 1 до 2 минут и так далее, а по оси Y — число пользователей.

Гистограмма может быть **абсолютной** или **нормированной**. В абсолютной гистограмме по оси Y показывается **частота** — абсолютное количество наблюдений, а в нормированной — **частость** — доля наблюдений.

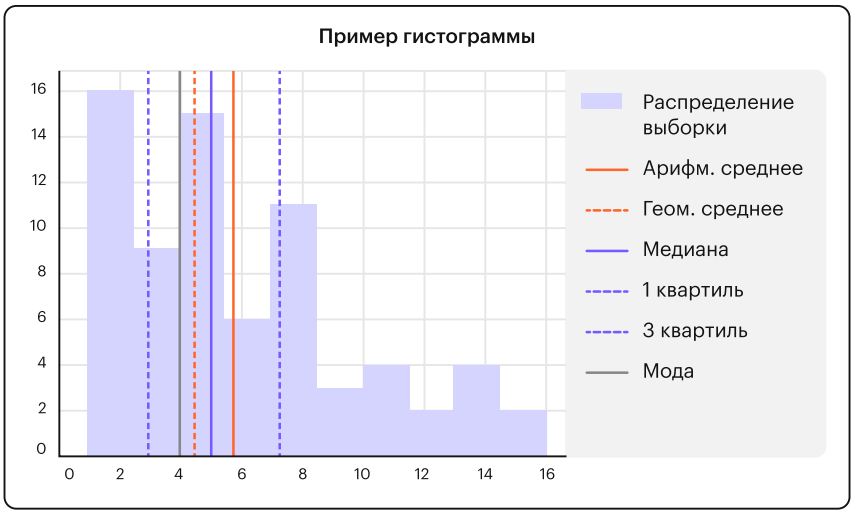

Рисунок 48. Абсолютная гистограмма и меры центральной тенденции

По форме гистограммы можно приблизительно определить соотношение среднего и медианы (рисунок 48):

- **среднее** $\approx$ **медиана** — в симметричном распределении;
- **медиана** $<$ **среднего** — если данные смещены вправо, тяжёлый правый хвост;
- **среднее** $<$ **медианы** — если данные смещены влево, тяжёлый левый хвост.

Классический пример сравнения среднего и медианы — разница между средней и медианной зарплатами по стране или компании.

Боксплот

Анализ формы распределения и квантилей приводит к важнейшему вопросу очистки данных от выбросов. Чтобы находить выбросы «методом глаза», можно использовать боксплот — «ящик с усами» (рисунок 49).

ОПРЕДЕЛЕНИЕ 4.5.2

Боксплот состоит:

- из **ящика**, образованного границами Q_1 и Q_3. Линия внутри ящика — это медиана (Q_2);
- из **усов** — отрезок $[Q_1 - 1{,}5 \times IQR, Q_3 + 1{,}5 \times IQR]$;
- из **выбросов** — точки за пределами усов.

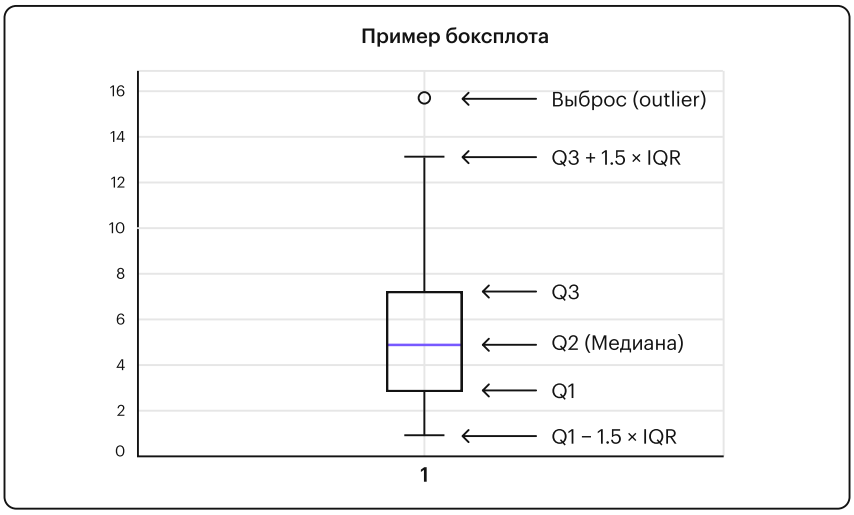

Рисунок 49. Структура боксплота

Число $1,5$ — не зафиксированный параметр или доказанная истина. Его выбрали эмпирически, потому что такой порог удобно использовать на практике.

В нормальном распределении, например, оно охватывает $99,3\%$ данных. Иногда выбирают другое значение, например 1 или 2. Однако именно $1,5$ — стандарт в статистических пакетах.

Боксплот используют, чтобы очищать выборки от выбросов. Чтобы проверить наблюдения, нужно выполнить следующие шаги.

1. Построить боксплот для всего датасета.
2. Определить выбросы за пределами

$$[Q_1 - 1,5 \times IQR, Q_3 + 1,5 \times IQR].$$

3. Решить: удалить, преобразовать или более подробно исследовать аномалии.

Заметим, что при маленьком IQR такие аномалии могут не быть выбросами.

Диаграмма рассеивания

ОПРЕДЕЛЕНИЕ 4.5.3

Диаграмма рассеяния (*англ.* scatter plot)

Диаграмма рассеяния показывает взаимосвязь между двумя или более признаками. Каждое наблюдение она представляет в виде точки на плоскости. Её координаты $(x_i,\, y_i)$ соответствуют значениям первого и второго признаков для i-го объекта.

Хотя диаграмма рассеяния работает в многомерном пространстве, а гистограмма строится для одного вариационного ряда, они тесно связаны математически и логически.

- **Метод проекций.** Если сбросить все точки с двумерной диаграммы рассеяния на одну из осей, например на ось X, мы получим одномерный набор точек. Плотность точек на оси отражает частоты вариационного ряда. Если над этой осью построить блоки по правилам интервального ряда, разбить ось на интервалы и построить над ними столбцы, мы получим гистограмму.
- **Визуализация плотности.** Если на диаграмме рассеяния точки образуют плотное облако, соответствующий интервал на гистограмме даст высокий столбец. Наоборот, разреженные области порождают «низины» и пустые интервалы на гистограмме.
- **Маргинальные распределения.** В современном анализе данных эти графики часто совмещают: в центре размещают диаграмму рассеяния, чтобы показать связь двух величин, а сверху и справа от неё — маргинальные гистограммы. Они показывают структуру вариационного ряда каждой величины отдельно.

Рассмотрим связь между диаграммой рассеивания и гистограммой на примере интервального ряда.

Работа с интервальными рядами

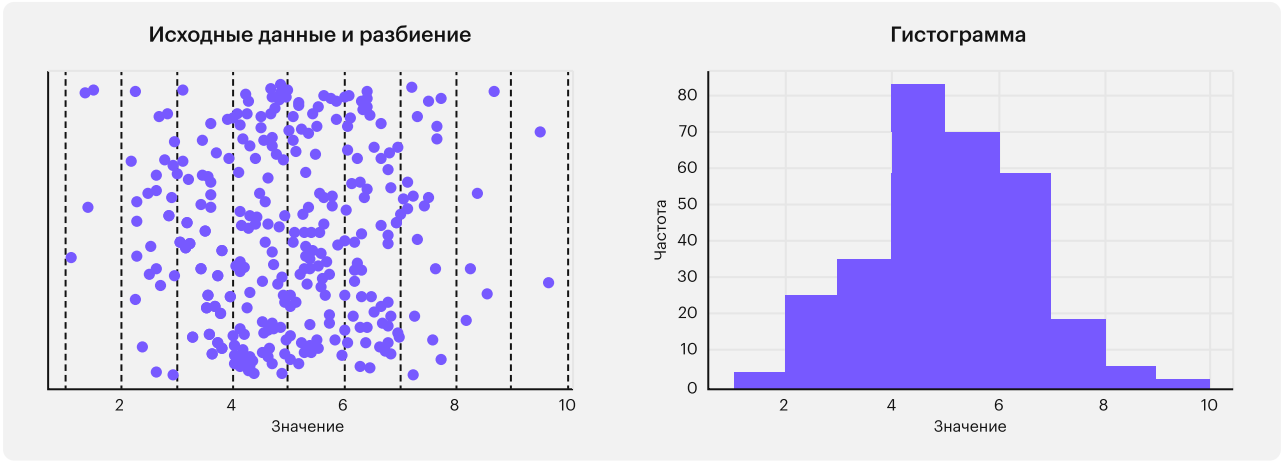

Интервал $[x_{i,\text{нач}}; x_{i,\text{кон}}]$	Ср. знач. $x_i = \frac{x_{i,\text{нач}} + x_{i,\text{кон}}}{2}$	Частота n_i	Относ. частота $w_i = \frac{n_i}{N}$	Накопл. частота $m_i = \sum_{j=1}^{i} n_j$	Накопл. отн. частота $w_i^{\text{нач}} = \sum_{j=1}^{i} w_j$
1–2	1.50	4	0.01	4	0.01
2–3	2.50	25	0.08	29	0.10
3–4	3.50	35	0.12	64	0.21
4–5	4.50	83	0.28	147	0.49
5–6	5.50	70	0.23	217	0.72
6–7	6.50	58	0.19	275	0.92
7–8	7.50	18	0.06	293	0.98
8–9	8.50	5	0.02	298	0.99
9–10	9.50	2	0.01	300	1.00

Рисунок 50. Сквозной процесс построения и анализа интервального вариационного ряда

На рисунке 50 показан переход от диаграммы рассеивания к гистограмме по аналогии с переходом от стандартного ряда к гистограмме. Обратим внимание, что на диаграмме рассеивания присутствуют два измерения — значения и по X, и по Y, а на гистограмме — только одно измерение.

Для полного отображения информации следует сопоставлять диаграмму рассеивания и две гистограммы.

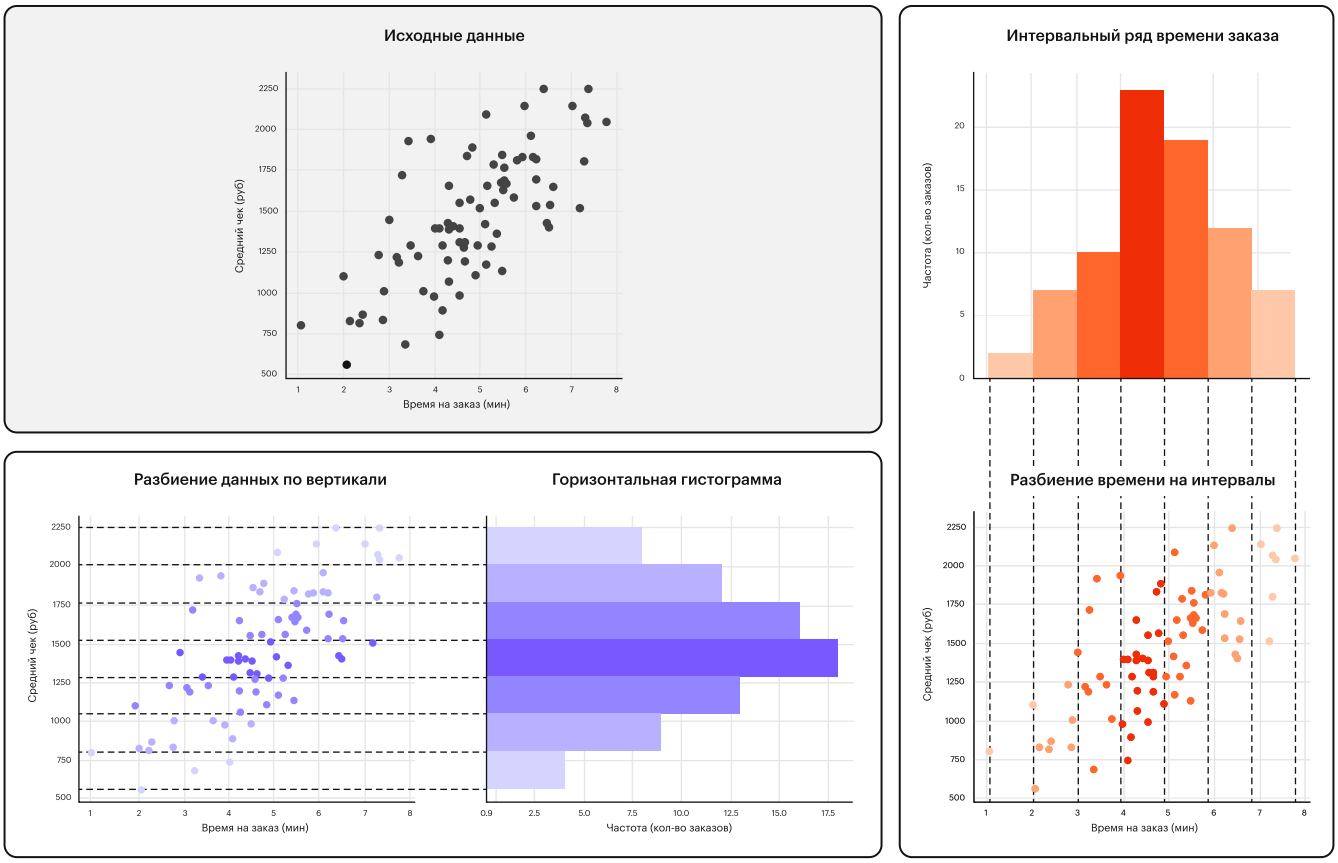

Рисунок 51. Процесс группировки непрерывных данных и построения интервальной гистограммы

На рисунке 51 представлен переход от сплошного облака непрерывных наблюдений к сгруппированным частотам.

Верхний ряд показывает, как непрерывную шкалу «Время на заказ» последовательно делят на равные полуоткрытые интервалы $[x_i;\ x_{i+1})$, определяют число элементов в них и строят вертикальные столбцы частот. Нижний ряд графиков показывает аналогичную группировку по второй непрерывной оси.

Кумулята и огива

Рассмотрим ещё две визуализации, которые строятся на интервальных рядах и которые тесно связаны с понятием эмпирической функции распределения.

Кумулята — это визуализация эмпирической функции распределения, где по оси X идут интервалы признака по возрастанию, а по оси Y — накопленные частости.

ОПРЕДЕЛЕНИЕ 4.5.4

Кумулята

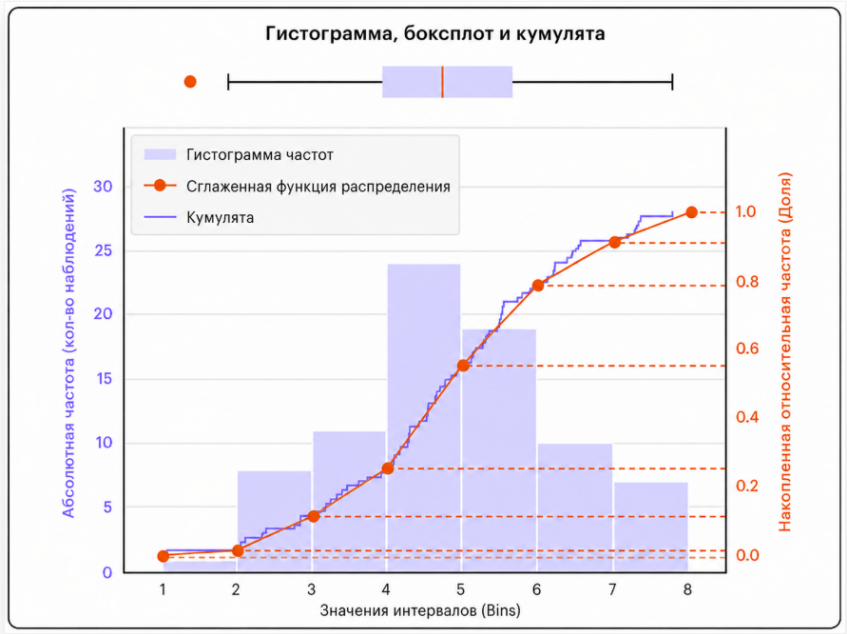

Рисунок 52. Взаимосвязь гистограммы частот, кумуляты (ECDF), огивы и диаграммы «ящик с усами»

На рисунке 52 показаны гистограмма, боксплот и кумулята.

Совмещение гистограммы частот со ступенчатым графиком кумуляты показывает скорость накопления частот по интервалам. Сверху расположен боксплот — «ящик с усами». Он показывает ключевые квантили, медиану и отдельные выбросы на общей числовой шкале.

ОПРЕДЕЛЕНИЕ 4.5.5

Огива

Огива — это визуализация эмпирической функции распределения, где по оси X идут накопленные частости, а по оси Y — интервалы признака по возрастанию. Огива — это кумулята, в которой оси поменялись местами.

Эти визуализации можно использовать и совмещать в зависимости от типа данных, количества интервалов или поставленной задачи.

Часть 5. Точечные оценки

1. ВВЕДЕНИЕ В ТОЧЕЧНЫЕ ОЦЕНКИ

Распределение — это довольно абстрактное понятие, с которым нелегко работать на практике. Удобно найти какой-то простой способ описывать имеющиеся распределения. Самый простой — параметризовать их.

Параметрической моделью называется вероятностно-статистическая модель, для которой дополнительно известна параметризация

$$\mathcal{P} = \{\mathrm{P}_\theta : \theta \in \Theta\},$$

где Θ — **множество параметров**. Обычно $\Theta \subset \mathbb{R}^d$ для некоторого фиксированного $d \in \mathbb{N}$.

Пример 5.1.1. Монетку подбросили десять раз и теперь хотят понять, насколько орёл выпадает чаще решки. Вводим параметрическую модель с выборочным пространством $\mathcal{X} = \{0, 1\}$ и параметризацией

$$\mathrm{P}_\theta = \mathrm{Bern}(\theta), \quad \theta \in \Theta = [0, 1].$$

Случай $\theta = \frac{1}{2}$ соответствует симметричной монетке. Случаи $\theta = 0$ и $\theta = 1$ соответствуют тому, что всегда выпадает только орёл или только решка. Выборкой является набор из независимых бернуллиевских величин, сетом данных - десять результатов бросков монетки.

Получается, что в случае параметрической статистики основная задача статистики — «восстановление распределения наших наблюдений» сводится к нахождению параметра θ. К сожалению, статистика никогда не даст однозначный ответ на вопрос «чему равно θ?», мы можем говорить только об оценке параметра.

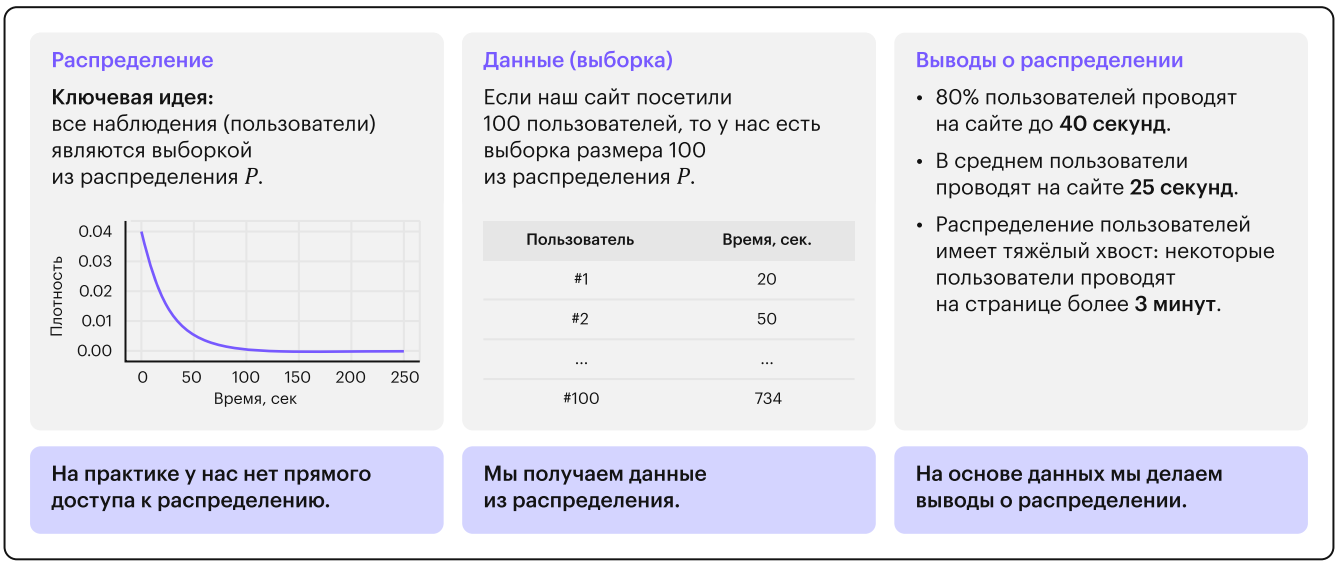

Рисунок 53. Разница между распределением и выборкой

Перейдём к формальным определениям.

Статистикой называется любая измеримая функция от выборки $S(X_1, \ldots, X_n)$.

Пример 5.1.2. Подбрасывается игральный кубик. Тогда $\mathcal{X} = \{1, 2, 3, 4, 5, 6\}$. Статистикой, например, будет **выборочное среднее** значение бросков, то есть

$$S(X_1, \ldots, X_n) = \frac{X_1 + \ldots + X_n}{n}.$$

Другой пример статистики: медиана произвольной выборки X — **выборочная медиана**.

В параметрической модели (точечной) **оценкой** параметра θ называется статистика со значениями в Θ.

Пример 5.1.3. В примере 9.1.1 с монетками «хорошей» оценкой параметра θ является, например, выборочное среднее значений бросков.

Обрати внимание, что, например, сумма значений элементов выборки не является оценкой как формально (сумма не лежит во множестве Θ), так и из соображений здравого смысла (сумма не оценивает вероятность выпадения единицы).

Следующие понятия «выборочного чего-то» получены из соответствующих понятий заменой математического ожидания на среднее по выборке (например, выборочная дисперсия — из дисперсии). Пусть имеется выборка $X_1, \ldots, X_n$.

- **Выборочное среднее:**

$$\overline{X} := \frac{X_1 + \ldots + X_n}{n}.$$

- **Выборочный k-й момент:**

$$\overline{X^k} := \frac{X_1^k + \ldots + X_n^k}{n}.$$

- **Выборочная дисперсия**:

$$s^2 := \overline{\left(X - \overline{X}\right)^2} = \overline{X^2} - \overline{X}^2.$$

  Иногда под выборочной дисперсией понимают эту величину, домноженную на $\frac{n}{n-1}$. Позже ты узнаешь, почему так.

- Пусть имеется некоторая борелевская функция $g\colon \mathbb{R} \to \mathbb{R}$. Её **выборочная характеристика** определяется как

$$\overline{g(X)} := \frac{g(X_1) + \ldots + g(X_n)}{n}.$$

  При выборе $g(x) = x^k$ мы получим выборочные моменты.

Помимо усреднения, можно ещё работать с порядковыми значениями.

Вариационным рядом называют расположение выборки в порядке возрастания (неубывания):

$$X_{(1)} \leqslant X_{(2)} \leqslant \ldots \leqslant X_{(n-1)} \leqslant X_{(n)}.$$

Сами значения $X_{(k)}$ называют **k-ми порядковыми статистиками**.

Пример 5.1.4. Для наблюдений $x = (1,\ 4,\ 2,\ 8,\ 6,\ 2)$ имеем

$$x_{(1)} = 1,\ x_{(2)} = x_{(3)} = 2,\ x_{(4)} = 4,\ x_{(5)} = 6,\ x_{(6)} = 8.$$

Заметим, что $X_{(1)} = \min(X_1, \ldots, X_n)$ и $X_{(n)} = \max(X_1, \ldots, X_n)$.

По вариационному ряду можно построить **выборочные p-квантили**:

$$\widehat{z}_p := X_{(\lceil np \rceil)}$$

для $p \in (0, 1)$.

В примере 5.1.4 выборочный квантиль $\widehat{z}_{0,5} = 2$.

Близким понятием является **выборочная медиана**

$$\widehat{\mu} := \begin{cases} X_{(\frac{n+1}{2})}, & \text{если } n \text{ нечётное;} \\ \frac{X_{(\frac{n}{2})} + X_{(\frac{n}{2}+1)}}{2}, & \text{если } n \text{ чётное.} \end{cases}$$

В примере 5.1.4 выборочная медиана $\widehat{\mu} = \frac{2+4}{2} = 3$. То есть при нечётных n выборочная медиана совпадает с выборочным $\frac{1}{2}$-квантилем, а при чётном n она равна среднему двух серединных значений, в то время как выборочный $\frac{1}{2}$-квантиль берёт левое из них.

Все эти определения можно не запоминать — они выводятся из эмпирического распределения.

2. СВОЙСТВО СОСТОЯТЕЛЬНОСТИ

Когда мы работаем с большими объёмами данных, можно наплевать на точность наших оценок и взять количеством, а не качеством. То есть, нас интересуют не точные значения оценок и их распределения, а только их асимптотическое поведение. Как мы знаем, в теории вероятностей есть много разных видов сходимости; здесь они нам все пригодятся.

Состоятельная оценка

Нам нужно оценить какой-то параметр μ распределения P:

- мат. ожидание,
- дисперсия,
- медиана.

Оценка θ называется состоятельной, если с ростом размера выборки n она сходится к оцениваемому параметру.

$$\lim_{n \to \infty} \theta \to \mu$$

Рассмотрим на примере мат. ожидания $\mu = \mathbb{E}[X]$.

Вариант 1	$\theta_1 = \frac{1}{n} \sum_{i=1}^{n} X_i$	✓ Состоятельна
Вариант 2	$\theta_2 = \frac{1}{n} \sum_{i=1}^{n} X_i + \frac{1}{n}$	✓ Состоятельна
Вариант 3	$\theta_3 = X_1$	✗ Несостоятельна
Вариант 4	$\theta_4 = 42$	✗ Несостоятельна

Рисунок 54. Несколько примеров состоятельных и несостоятельных оценок

Последовательность $\{\hat{\theta}_n\}$ оценок параметра θ называется **состо-**

ятельной, если для любой $\theta \in \Theta$ выполнено

$$\hat{\theta}_n \xrightarrow[n\to\infty]{\mathrm{P}_\theta} \theta.$$

Последовательность $\{\hat{\theta}_n\}$ оценок параметра θ называется **сильно состоятельной**, если для любой $\theta \in \Theta$ выполнено

$$\hat{\theta}_n \xrightarrow[n\to\infty]{\mathrm{P}_\theta\text{-п.н.}} \theta.$$

На первый взгляд кажется, что это довольно похожие свойства. Тем не менее, как ты знаешь из примера с бегающими отрезками, сильная состоятельность гораздо сильнее обычной состоятельности (прости за тавтологию). Именно сильную состоятельность надеются получить, когда строят различные последовательности оценок.

Пример 5.2.1. Пусть имеется последовательность $\{X_n\}$ независимых одинаково распределённых случайных величин с неизвестным конечным математическим ожиданием a.

- По УЗБЧ, логично оценить среднее a выборочным средним:

$$\overline{X} := \frac{X_1 + \ldots + X_n}{n}.$$

- Но если, например, оценивать a^2, то по теореме о наследовании сходимости

$$\overline{X}^2 \xrightarrow[n\to\infty]{\text{п.н.}} a^2.$$

  Обрати внимание, что здесь считается квадрат среднего, а не средний квадрат. Это далеко не одно и то же.
- Аналогично: пусть функция h непрерывна в точке a. Чтобы оценить $h(a)$, нужно рассмотреть последовательность

$$h(\overline{X}).$$

  Непрерывности в точке a достаточно — она и означает P_a-п.н. непрерывность, которая требуется в теореме о наследовании сходимости.

Ситуация в примере 5.2.1 довольно стандартная для статистики: мы умеем оценивать один параметр, а нужно оценить другой. На практике к функциям обычно можно применить теоремы выше (а точнее, следствия из них) — и так проблема решится. Эти следствия мы сейчас и рассмотрим.

Пусть:

ТЕОРЕМА 5.2.1

- имеется (сильно) состоятельная последовательность $\{\hat{\theta}_n\}$ оценок параметра $\theta \in \Theta \subset \mathbb{R}^d$;
- функция $\tau\colon \mathbb{R}^d \to \mathbb{R}^s$ непрерывна на Θ.

Тогда последовательность оценок $\tau(\hat{\theta}_n)$ является (сильно) состоятельной оценкой параметра $\tau(\theta)$.

Доказательство. Следует по теореме о наследовании сходимостей почти наверное и по вероятности. □

В остальном, ЗБЧ (УЗБЧ) гарантирует, что выборочное среднее является (сильно) состоятельной оценкой матожидания. Дальше на это можно навешивать разные функции. Иногда состоятельность оценки видна и невооружённым глазом.

Пример 5.2.2. Пусть $X_i \sim \mathrm{Exp}(1) + \theta$, то есть плотность равна

$$f(x) = e^{-(x-\theta)}\mathcal{I}\{x > \theta\}.$$

Тогда логично, что состоятельной оценкой будет являться минимум. В самом деле,

$$\mathrm{P}\{\left|X_{(1)} - \theta\right| > \varepsilon\} = \mathrm{P}\{X_{(1)} > \theta + \varepsilon\} = \left(e^{-\varepsilon}\right)^n \xrightarrow[n\to\infty]{} 0.$$

Пример 5.2.3. Пусть $X_i \sim \mathrm{U}[-\theta, \theta]$. Тут можно построить много разных состоятельных оценок. Например, $X_{(n)}$ будет состоятельной, так как

$$\mathrm{P}\{X_{(n)} < \theta - \varepsilon\} = \left(\frac{2\theta - \varepsilon}{2\theta}\right)^n \xrightarrow[n\to\infty]{} 0.$$

Аналогично, оценки $-X_{(1)}$ и $|X|_{(n)}$ тоже будут состоятельными. При этом понятно, что последняя будет лучше их всех, поскольку она смотрит не только на самую правую, но и на самую левую границу.

3. АСИМПТОТИЧЕСКАЯ НОРМАЛЬНОСТЬ

Иногда одной состоятельности нам недостаточно, и мы хотим оценить скорость сходимости наших оценок. Для этого нам нужна ЦПТ или похожие утверждения.

Начнём с примера.

Пример 5.3.1. Пусть имеется последовательность $\{X_n\}$ независимых одинаково распределённых случайных величин с конечным математическим ожиданием $a \neq 0$ и дисперсией σ^2. Обозначим

$$\overline{X} := \frac{X_1 + \ldots + X_n}{n}.$$

Нужно найти предел по распределению у последовательности

$$\sqrt{n}\left(\frac{1}{\overline{X}} - \frac{1}{a}\right).$$

Из ЦПТ известно, что

$$\sqrt{n}\left(\overline{X} - a\right) \xrightarrow[n\to\infty]{d} N(0, \sigma^2).$$

Теперь заметим, что

$$\sqrt{n}\left(\frac{1}{\overline{X}}-\frac{1}{a}\right)=\sqrt{n}\left(\overline{X}-a\right)\cdot\frac{-1}{a\overline{X}},$$

причём по ЗБЧ

$$\frac{-1}{a\overline{X}}\xrightarrow[n\to\infty]{\mathrm{P}}\frac{-1}{a^2}.$$

Тогда по лемме Слуцкого

$$\sqrt{n}\left(\frac{1}{\overline{X}}-\frac{1}{a}\right)\xrightarrow[n\to\infty]{d}\frac{-1}{a^2}N(0,\sigma^2)=N\left(0,\frac{\sigma^2}{a^4}\right).$$

Можно решить задачу и через дельта-метод. Общая идея во всех подобных задачах: применить дельта-метод для последовательности

$$\xi_n:=\sqrt{n}\left(\overline{X}-a\right)$$

и

$$b_n:=\frac{1}{\sqrt{n}}.$$

В интересующем нас выражении

$$\sqrt{n}\left(\frac{1}{\overline{X}}-\frac{1}{a}\right)$$

в скобках стоит разность статистики $\frac{1}{\overline{X}}$ и параметра $\frac{1}{a}$, поэтому надо взять функцию $h(x)=\frac{1}{x}$. Тогда $h'(a)=-\frac{1}{a^2}$ и по дельта-методу сразу получаем

$$\sqrt{n}\left(\frac{1}{\overline{X}}-\frac{1}{a}\right)=$$
$$=\frac{h(a+b_n\xi_n)-h(a)}{b_n}\xrightarrow[n\to\infty]{d}N(0,\sigma^2)h'(a)=$$
$$=N\left(0,\frac{\sigma^2}{a^4}\right).$$

В примере 5.3.1 мы показали, что решение подобных задач дельта-методом более алгоритмическое и принципиально отличается от решения через лемму Слуцкого. В решении напрямую (через лемму Слуцкого) в примере 5.3.1 мы применяли лемму Слуцкого один раз, а в дельта-методе — два раза.

То, что мы нашли в примере 5.3.1, называется асимптотически нормальной оценкой. Формально, последовательность $\{\hat{\theta}_n\}$ оценок параметра θ называется **асимптотически нормальной** с **асимптотической дисперсией** $\sigma^2(\theta)$, если для любой $\theta\in\Theta$

выполнено

$$\sqrt{n}\left(\hat{\theta}_n - \theta\right) \xrightarrow[n\to\infty]{d_\theta} N\left(0, \sigma^2(\theta)\right).$$

ЗАМЕЧАНИЕ

Смысл асимптотически нормальных оценок в том, что они не просто показывают, куда они сходятся, но и с какой скоростью: с ошибкой $\sigma(\theta)/\sqrt{n}$. Так, в примере 5.3.1 мы поняли, что $\frac{1}{\overline{X}}$ оценивает параметр $\frac{1}{a}$ с ошибкой $\frac{\sigma}{a^2\sqrt{n}}$. То есть, получается интересная ситуация: чем больше среднее, тем точнее мы оценим $\frac{1}{a}$. И, соответственно, если среднее близко к нулю, то ошибка получается довольно большой: малейшее изменение среднего сильно влияет на оцениваемый параметр.

Так что же лучше, состоятельные оценки или асимптотически нормальные? Ответ даёт следующая лемма.

ЛЕММА 5.3.1

Асимптотически нормальная оценка является состоятельной оценкой того же параметра.

Доказательство. Пусть

$$\sqrt{n}\left(\hat{\theta}_n - \theta\right) \xrightarrow[n\to\infty]{d_\theta} N\left(0, \sigma^2(\theta)\right).$$

Возьмём ещё последовательность (не)случайных величин $\frac{1}{\sqrt{n}}$, сходящуюся к нулю. Тогда по лемме Слуцкого,

$$\hat{\theta}_n - \theta = \sqrt{n}\left(\hat{\theta}_n - \theta\right) \cdot \frac{1}{\sqrt{n}} \xrightarrow[n\to\infty]{d_\theta} N\left(0, \sigma^2(\theta)\right) \cdot 0 = 0.$$

Поскольку из сходимости по распределению к константе следует и сходимость по вероятности, то

$$\hat{\theta}_n - \theta \xrightarrow[n\to\infty]{\mathrm{P}_\theta} 0,$$

то есть

$$\hat{\theta}_n \xrightarrow[n\to\infty]{\mathrm{P}_\theta} \theta,$$

что и означает состоятельность. □

Иногда эти оценки удобно искать не напрямую, а применяя ЦПТ, и затем как-то модифицируя оценки. Для этого нам нужна следующая теорема.

ТЕОРЕМА 5.3.1

Пусть:

- имеется асимптотически нормальная последовательность $\{\hat{\theta}_n\}$ оценок параметра $\theta \in \Theta \subset \mathbb{R}^d$ с асимптотической дисперсией $\sigma^2(\theta)$
- функция $\tau\colon \mathbb{R}^d \to \mathbb{R}$ дифференцируема на Θ.

Тогда последовательность оценок $\tau(\hat{\theta}_n)$ является асимптотически нормальной оценкой параметра $\tau(\theta)$ с асимптотической дисперсией $\sigma^2(\theta)(\tau'(\theta))^2$.

Доказательство. Следует из применения теоремы 3.15.4 поточечно для каждой $a := \theta \in \Theta$. □

ЦПТ гарантирует, что выборочное среднее является асимптоти-

чески нормальной оценкой матожидания, если дисперсия существует. Отдельного внимания заслуживает аналог ЦПТ, позволяющий оценить не функции от среднего, а квантили.
Пусть:

- выборка X имеет абсолютно непрерывное распределение с плотностью f;
- f непрерывно дифференцируема в некоторой окрестности p-квантили z_p;
- $f(z_p) > 0$.

ТЕОРЕМА 5.3.2

Тогда выборочная квантиль $\hat{z}_{p,n}$ является асимптотически нормальной оценкой квантили z_p с асимптотической дисперсией $\dfrac{p(1-p)}{f(z_p)^2}$.

При $p = 0{,}5$ выборочную квантиль в теореме можно заменить на выборочную медиану.

Пример 5.3.2. Пусть $X \sim \mathrm{Cauchy}(1, \theta)$, то есть плотность равна

$$f_\theta(x) = \frac{1}{\pi((x-\theta)^2 + 1)}.$$

У Коши нет матожидания, поэтому ЦПТ применить не получится. Но θ является медианой, или 0.5-квантилью, поэтому по теореме о выборочной квантили, выборочная медиана является асимптотически нормальной оценкой параметра θ с асимптотической дисперсией

$$\sigma^2(\theta) = \frac{1}{2} \cdot \frac{1}{2} \cdot \pi^2(0+1) = \frac{\pi^2}{4}.$$

Пример 5.3.3. Пусть $X \sim \mathrm{Cauchy}(\theta)$, то есть плотность равна

$$f_\theta(x) = \frac{\theta}{\pi(x^2 + \theta^2)}.$$

Здесь ЦПТ тоже не помогает. Но $z_{3/4} = \theta$, поэтому по теореме о выборочной квантили, $\hat{z}_{3/4}$ является асимптотически нормальной оценкой параметра θ с асимптотической дисперсией

$$\sigma^2(\theta) = \frac{\frac{3}{4} \cdot \frac{1}{4} \cdot \pi^2 \cdot 2\theta^2}{\theta} = \frac{3}{8}\pi^2\theta.$$

4. СВОЙСТВО НЕСМЕЩЁННОСТИ

Если данных мало, то наоборот, асимптотические свойства оценок нам никак не помогут, и нужно поглубже залезать в сами свойства оценок.

Пример 5.4.1. Рассмотрим простой случай:

- выборочное пространство $\mathcal{X} = \mathbb{R}$;
- построена параметрическая модель $\mathrm{U}[0, \theta]$, где $\theta > 0$.

Допустим, нам даже известна реализация выборки:

$$12.2,\ 3.5,\ 78.3,\ 45.6,\ 66.4.$$

Нужно оценить параметр θ.

Сначала попробуем исходить из здравого смысла: понятно, что θ не может быть меньше ни одного из имеющихся наблюдений. Так что неплохой оценкой является

$$\hat{\theta}_{1,n} = X_{(n)},$$

что в нашем случае равно 78.3. Проблема такой оценки в том, она не оставляет никакого запаса для наблюдений; при этом логично предположить, что наблюдения не попадали в «самый край», то есть должен остаться какой-то зазор. Значит, оценки

$$\hat{\theta}_{2,n} = X_{(n)} + 0.01, \quad \hat{\theta}_{3,n} = X_{(n)} + 1, \quad \hat{\theta}_{4,n} = X_{(n)} + 100$$

тоже имеют право на существование. Можно придумать много таких оценок, но и у них есть проблема: нужно знать масштаб наблюдений, чтобы понять размер зазора. Поэтому лучше выбрать оценку с относительным зазором

$$\hat{\theta}_{5,n} = X_{(n)}(1 + \varepsilon),$$

где ε нужно выбрать ещё из каких-то соображений (возможно, ε зависит от n).

Можно пойти и совсем другим путём. Например, из УЗБЧ известно, что $\overline{X}$ сойдётся почти наверное к $\frac{\theta}{2}$. Поэтому можно в качестве оценки выбрать $\hat{\theta}_{6,n} = 2\overline{X}$.

Теперь нужно каким-то образом выбрать оценки из полученных. Если наблюдений много, нужно выбрать состоятельную оценку. В примере 5.4.1 это были бы оценки $2\overline{X}$ и $X_{(n)}(1 + o(1))$. Если наблюдений мало, обычно рассматривают другую характеристику — несмещённость. Она гарантирует, что в среднем наша оценка оценивает именно то, что нужно.

Несмещённая оценка

Нам нужно оценить какой-то параметр μ распределения P:

- мат. ожидание,
- дисперсия,
- медиана.

Оценка θ называется несмещённой, если её математическое ожидание равно оцениваемому параметру.

$$\mathbb{E}[\theta] = \mu$$

Рассмотрим на примере мат. ожидания $\mu = \mathbb{E}[X]$.

Вариант 1	$\theta_1 = \frac{1}{n}\sum_{i=1}^{n} X_i$	$\longrightarrow$	$\mathbb{E}[\theta_1] = \mu$
Вариант 2	$\theta_2 = \frac{1}{n}\sum_{i=1}^{n} X_i + \frac{1}{n}$	$\longrightarrow$	$\mathbb{E}[\theta_2] = \mu + \frac{1}{n}$
Вариант 3	$\theta_3 = X_1$	$\longrightarrow$	$\mathbb{E}[\theta_3] = \mu$
Вариант 4	$\theta_4 = 42$	$\longrightarrow$	$\mathbb{E}[4] = 42$

Рисунок 55. Несколько примеров смещённых и несмещённых оценок

Оценки мат. ожидания $\mu = \mathbb{E}[X]$.

Вариант 1	$\theta_1 = \frac{1}{n}\sum_{i=1}^{n} X_i$
Вариант 2	$\theta_2 = \frac{1}{n}\sum_{i=1}^{n} X_i + \frac{1}{n}$
Вариант 3	$\theta_3 = X_1$
Вариант 4	$\theta_4 = 42$

	Несмещённая	Смещённая
Состоятельная	$\theta_1 = \frac{1}{n}\sum_{i=1}^{n} X_i$	$\theta_2 = \frac{1}{n}\sum_{i=1}^{n} X_i + \frac{1}{n}$
Несостоятельная	$\theta_3 = X_1$	$\theta_4 = 42$

Какая оценка всё-таки лучше?

Рисунок 56. Сравнение состоятельных и несмещённых оценок

Оценка $\hat{\theta}_n$ параметра θ называется **несмещённой**, если для любого θ выполнено

$$\mathrm{E}_\theta \hat{\theta}_n = \theta,$$

где под E_θ подразумевается математическое ожидание по мере P_θ.

Аналогично, оценка $\hat{\theta}_n$ параметра $\tau(\theta)$ называется **несмещённой**, если для любого θ выполнено

$$\mathrm{E}_\theta \hat{\theta}_n = \tau(\theta).$$

В примере 5.4.1 несмёщённой оценкой θ является $2\overline{X}$. Из теории вероятностей можно ещё вспомнить, что

$$\mathrm{E}_\theta X_{(k)} = \frac{k}{n+1}\theta,$$

поэтому в качестве несмещённых оценок подойдут оценки

$$\frac{n+1}{k}X_{(k)}.$$

Пример 5.4.2. Иногда несмещённые оценки довольно естественны. Например, в модели $N(\theta,1)$ выборочное среднее является несмещённой оценкой. А в модели $N(0,\theta)$ несмещённой оценкой дисперсии является выборочный квадрат $\overline{X^2}$.

Пример 5.4.3. Парадокс (не математический, а когнитивный) заключается в том, что выборочная дисперсия

$$s^2 = \overline{(X-\overline{X})^2} = \overline{X^2} - \overline{X}^2$$

не является несмещённой оценкой дисперсии. Это легко понять из цепочки равенств

$$\begin{aligned}\mathrm{E}s^2 = \mathrm{E}(X_1-\overline{X})^2 = \mathrm{Var}(X_1-\overline{X}) = \\ = \frac{(n-1)^2}{n^2}\mathrm{Var}\,X_1 + \frac{n-1}{n^2}\mathrm{Var}\,X_1 = \frac{n-1}{n}\mathrm{Var}\,X_1.\end{aligned}$$

Поэтому обычно при малом количестве наблюдений считают **несмещённую дисперсию**

$$\frac{n}{n-1}s^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left|X_i-\overline{X}\right|^2.$$

Её тоже могут обозначать просто s^2, если из контекста понятно, что она несмещённая. При больших n границы между этими понятиями, естественно, стираются.

Пример 5.4.4. Несмещённые оценки не всегда существуют. Например, пусть в модели $\mathrm{Bern}(\theta)$ мы хотим оценить параметр $\frac{1}{\theta}$. Обозначим через $k_i(x)$ количество исходов i в наблюдении $x=(x_1,\ldots,x_n)$, для $i\in\{0,1\}$; то есть, $k_0(x)+k_1(x)=n$. Заметим, что для любой оценки θ^* выполнено

$$\mathrm{E}_\theta\theta^* = \sum_{x\in\{0,1\}^n}\theta^*(x)\theta^{k_1(x)}(1-\theta)^{k_0(x)},$$

то есть она является несмещённой оценкой многочлена от θ. Поэтому не существует несмещённой оценки параметра θ.

5. ИНФОРМАЦИЯ ФИШЕРА

Как мы поняли на разных примерах, даже в одной модели у одного параметра оценки бывают разные. Нужно как-то сравнивать разные оценки. Логично сравнивать их по среднему разбросу от оцениваемого параметра. Если при этом оценки несмещённые, то дело упрощается до сравнения их дисперсий. Оказывается, в некоторых моделях можно найти самую лучшую оценку (при таком подходе к сравнению).

Оценки мат. ожидания $\mu = \mathbb{E}[X]$.		Посчитаем точность оценок.
Вариант 1	$\theta_1 = \frac{1}{n}\sum_{i=1}^{n} X_i$	$\mathbb{E}\big[(\theta_1 - \mu)^2\big] = \frac{1}{n}\sigma^2$
Вариант 2	$\theta_2 = \frac{1}{n}\sum_{i=1}^{n} X_i + \frac{1}{n}$	$\mathbb{E}\big[(\theta_2 - \mu)^2\big] = \frac{1}{n}\sigma^2 + \frac{1}{n^2}$
Вариант 3	$\theta_3 = X_1$	$\mathbb{E}\big[(\theta_3 - \mu)^2\big] = \mathbb{E}\big[(X_1 - \mathbb{E}[X])^2\big] = \mathbb{V}[X] = \sigma^2$
Вариант 4	$\theta_4 = 42$	$\mathbb{E}\big[(\theta_4 - \mu)^2\big] = (42 - \mu)^2$

Оценка θ_1 всегда лучше, чем θ_2 и θ_3

Точность оценки θ_4 зависит от значения μ

Рисунок 57. Сравнение несмещённых оценок по дисперсии

Сперва наложить много ограничений на модель. Будем делать это постепенно.

Первое предположение основано на том, что обычно на практике мы работаем либо с непрерывной выборкой, либо с дискретной.

Семейство $\mathcal{P}$ называют **доминируемым**, если в нём все распределения либо абсолютно непрерывные, либо дискретные. В случае абсолютно непрерывных распределений, как обычно, p_θ обозначает плотность. В дискретном случае p_θ обозначает функцию вероятности, то есть определяется как

$$p_\theta(x) = \mathrm{P}_\theta\{X_1 = x\}.$$

Для доминируемых семейств распределений функцию p_θ называют **обобщённой плотностью**.

Зафиксируем выборку $X_1, \ldots, X_n$ с плотностью p_θ. **Функцией правдопобия** называется

$$f_\theta(X) := \prod_{i=1}^{n} p_\theta(X_i).$$

По сути, это плотность выборки.

Иногда вместо неё рассматривают **логарифмическую функцию правдоподобия**

$$L_\theta(X) := \ln f_\theta(X) = \sum_{i=1}^{n} \ln p_\theta(X_i).$$

Для простоты далее считаем параметр одномерным. В принципе, всё сказанное ниже обобщается на многомерные параметры почти без изменений.

Производная

$$U_\theta(X) := \frac{\partial L_\theta(X)}{\partial \theta} = \frac{\partial \ln f_\theta(X)}{\partial \theta}$$

называется **вкладом выборки**. Иногда говорят про вклад одного элемента выборки для $X = X_1$. Мы будем такой вклад обозначать как $u_\theta(X_1)$.

ЛЕММА 5.5.1

Для любой статистики $S(X)$ и любой $\theta \in \Theta$ выполнено

$$\frac{\partial}{\partial \theta} \mathrm{E}_\theta S(X) = \mathrm{E}_\theta(S(X)U_\theta(X)),$$

если выражение справа определено.

Доказательство. Тут нужно понять, что если в функцию правдоподобия f подставить не саму выборку X, а просто элемент x выборочного пространства $\mathcal{X}$ (а точнее, $\mathcal{X}^n$), то получится обобщённая плотность выборки X. А тогда (по теореме Лебега о мажорируемой сходимости) можно переставить интеграл и производную и получить

$$\begin{aligned}\frac{\partial}{\partial \theta} \mathrm{E}_\theta S(X) &= \int \frac{\partial f_\theta(x)}{\partial \theta} S(x)\,dx = \\ &= \int \frac{\partial \ln f_\theta(x)}{\partial \theta} S(x) f_\theta(x)\,dx = \mathrm{E}_\theta(S(X)U_\theta(X)).\end{aligned}$$

□

СЛЕДСТВИЕ 5.5.1

Выполнено $\mathrm{E}_\theta U_\theta(X) = 0$.

Доказательство. Нужно в предыдущей лемме положить $S(X) = 1$. □

Функция

$$I_X(\theta) := \mathrm{E}_\theta(U_\theta(X))^2 = \mathrm{Var}_\theta U_\theta(X)$$

называется **информацией Фишера**. Информацию Фишера одного элемента выборки обозначают $i(\theta)$, при этом $I_X(\theta) = ni(\theta)$. Неформально смысл вклада в том, что чем он меньше, тем ближе оценка к максимально правдоподобной. С другой стороны, чем он больше, тем лучше мы можем подкорректировать оценку. Таким образом, чем больше информация Фишера, тем больше информации для уточнения оценки мы получим после наблюдения.

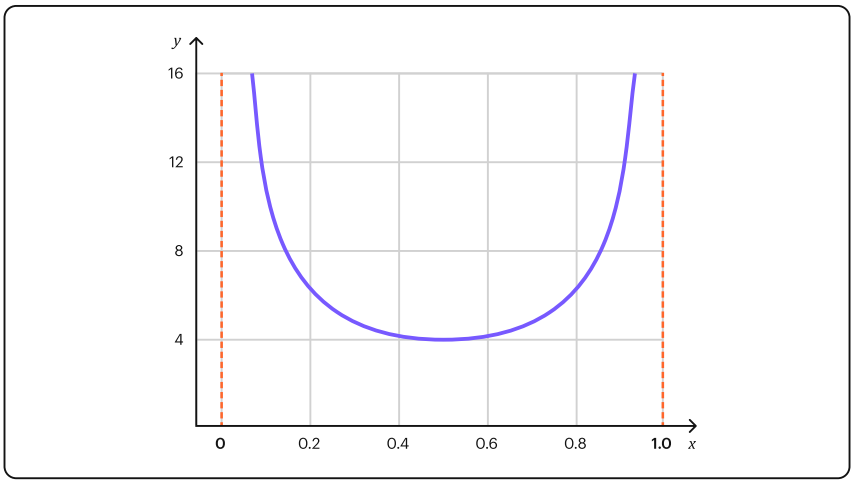

Рисунок 58. График функции $f(x) = \frac{1}{x(1-x)}$ на отрезке $[0,1]$

Пример 5.5.1. Рассмотрим модель $\mathrm{Bern}(\theta)$. В ней обобщённая плотность равна

$$p_\theta(x) = \theta^x(1-\theta)^{1-x}\mathcal{I}\{x \in \{0,1\}\},$$

поэтому правдоподобие равно

$$f_\theta(X) = \theta^{\sum_{i=1}^n X_i}(1-\theta)^{n-\sum_{i=1}^n X_i}\mathcal{I}\{X \in \{0,1\}^n\}.$$

Отсюда находим вклад5

$$U_\theta(X) = \frac{\partial}{\partial\theta}\ln f_\theta(X) = \frac{\sum_{i=1}^n X_i}{\theta} - \frac{n-\sum_{i=1}^n X_i}{1-\theta} = \\ = \frac{\sum_{i=1}^n X_i - n\theta}{\theta(1-\theta)}.$$

Теперь найдём и информацию Фишера

$$I_X(\theta) = \mathrm{Var}_\theta\, U_\theta(X) = \frac{\mathrm{Var}_\theta \sum_{i=1}^n X_i}{\theta^2(1-\theta)^2} = \frac{n}{\theta(1-\theta)}.$$

Таким образом, информация Фишера одного наблюдения равна

$$i(\theta) = \frac{1}{\theta(1-\theta)}.$$

Как видно из рис. 58, эта функция имеет минимум в точке $\theta = \frac{1}{2}$, и улетает на бесконечность при $\theta \to 0,1$. Это означает, что если $\theta = \frac{1}{2}$, то один бросок монетки даёт нам не очень много информации: если мы продолжим бросать монетку, она будет выпадать то орлом, то решкой, и нам будет сложно установить значение параметра θ; но если θ близка к граничному значению, то монетка почти всегда будет выпадать одной и той же гранью, и первые несколько бросков дадут нам много информации про монетку.

6. НЕРАВЕНСТВО РАО-КРАМЕРА

Наша дальнейшная цель: с помощью информации Фишера ограничить снизу разброс наших несмещённых оценок. На первый взгляд кажется, что это бестолковое занятие: нам же хочется минимизировать разброс, а не максимизировать. Но оценка снизу на разброс покажет, лучше чего не нужно стараться получить — всё равно не получится.

Сперва нужно наложить **условия регулярности модели**:

(R1) **Носитель** $\operatorname{supp} p_\theta := \{x\colon\ p_\theta(x) > 0\}$ распределения не зависит от параметра θ.
(R2) Множество Θ параметров является открытым интервалом.
(R3) Плотность $p_\theta(x)$ непрерывно дифференцируема по θ для всех x.

ТЕОРЕМА 5.6.1

Пусть выполнены условия регулярности (R1–R3) и $0 < I_X(\theta) < \infty$. Тогда для несмещённой оценки θ^* параметра $\tau(\theta)$ для всех $\theta \in \Theta$ выполнено

$$\operatorname{Var}_\theta \theta^* \geqslant \frac{(\tau'(\theta))^2}{I_X(\theta)}.$$

Доказательство. По следствию из леммы 5.5.1,

$$\mathrm{E}_\theta U_\theta(X)\tau(\theta) = 0$$

для всех $\theta \in \Theta$. Применяя теперь лемму 5.5.1 для статистики θ^*, получаем

$$\tau'(\theta) = \mathrm{E}_\theta \theta^* U_\theta(X) = \mathrm{E}_\theta(\theta^* - \tau(\theta))U_\theta(X).$$

Отсюда по неравенству КБШ получаем

$$\tau'(\theta)^2 \leqslant \mathrm{E}_\theta(\theta^* - \tau(\theta))^2 \mathrm{E}_\theta U_\theta(X)^2 = \operatorname{Var}_\theta \theta^* \cdot I_X(\theta).$$

□

Пример 5.6.1. Рассмотрим модель $\mathrm{Bern}(\theta)$. Мы уже нашли

$$I_X(\theta) = \frac{n}{\theta(1-\theta)}.$$

Допустим, нас интересует параметр $\tau(\theta) = \theta$. Тогда неравенство Крамера—Рао говорит, что на дисперсию есть оценка снизу

$$\operatorname{Var}_\theta \theta^* \geqslant \frac{1^2}{I_X(\theta)} = \frac{\theta(1-\theta)}{n}.$$

То есть, если нам не повезло и монетка симметричная, мы получим ограничение снизу $\frac{1}{4n}$. Но если монетка сильно несимметричная, то можно получить довольно маленький разброс. Кроме того, ограничение убывает с ростом количества наблюдений, что довольно логично (и приятно).

Пример 5.6.2. Без условий регулярности никуда. Рассмотрим модель $\mathrm{U}[0, \theta]$, которая не удовлетворяет условию (R1). Мы нашли в ней довольно много несмещённых оценок, например $2\overline{X}$.

Игнорируя условия регулярности, найдём

$$\operatorname{Var}_\theta 2\overline{X} = 4 \cdot \frac{\theta^2}{12n} = \frac{\theta^2}{3n}.$$

Поскольку мы оцениваем сам параметр θ, то $\tau'(\theta) = 1$. Остаётся найти информацию Фишера. Для одного элемента выборки имеем

$$p_\theta(X_1) = \frac{1}{\theta}\mathcal{I}\{0 \leqslant X_1 \leqslant \theta\}$$

и

$$\ln p_\theta(X_1) = -\ln\theta + \ln\mathcal{I}\{0 \leqslant X_1 \leqslant \theta\}.$$

Сразу видим, что возникают проблемы со взятием производной по параметру.

7. СВОЙСТВО ЭФФЕКТИВНОСТИ

Мы наконец подобрались к изучению оценок, лучше которых получить нельзя.

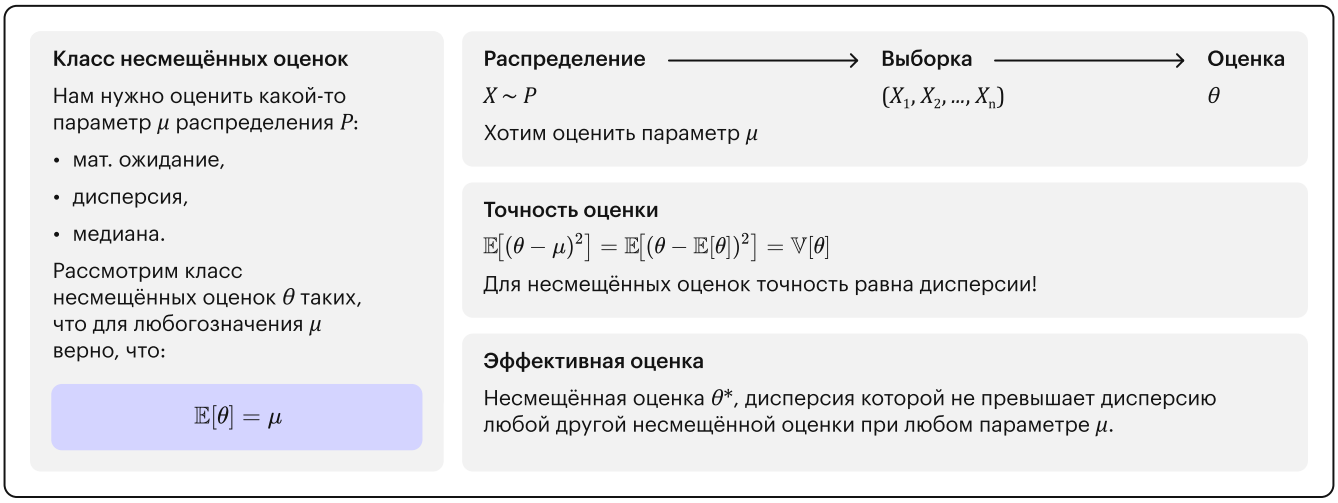

Рисунок 59. Эффективные оценки

Эффективной оценкой называется несмещённая оценка, для которой выполнено равенство в неравенстве Крамера—Рао. Она является наилучшей оценкой среди всех несмещённых оценок, если сравнивать их по дисперсии.

Пример 5.7.1. Добьём модель $\mathrm{Bern}(\theta)$. Мы уже нашли границу снизу на дисперсию, она равна $\frac{\theta(1-\theta)}{n}$. Осталось найти оценку, для которой эта граница достигается.

Самое логичное: взять выборочное среднее $\theta^* = \overline{X}$. Его диспер-

сия равна

$$\operatorname{Var}_\theta \theta^* = \frac{\operatorname{Var}_\theta X_1}{n} = \frac{\theta(1-\theta)}{n},$$

что в точности равно оценке снизу из неравенства Крамера—Рао. Следовательно, выборочное среднее является эффективной оценкой в этой модели, и лучше здесь уже ничего не найти.

Пример 5.7.2. Рассмотрим модель $\operatorname{Exp}(\theta)$. Правдоподобие равно

$$f_\theta(X) = \theta^n e^{-\theta \sum_{i=1}^n X_i} \mathcal{I}\{X_{(1)} > 0\}.$$

Тогда вклад равен

$$U_\theta(X) = \frac{n}{\theta} - \sum_{i=1}^n X_i,$$

откуда находим информацию Фишера

$$I_X(\theta) = \operatorname{Var}_\theta U_\theta(X) = n \operatorname{Var}_\theta X_1 = \frac{n}{\theta^2}.$$

Допустим, мы хотим найти эффективную оценку параметра θ. Тогда нужно найти такую оценку, что

$$\operatorname{Var}_\theta \theta^* = \frac{\theta^2}{n}.$$

Кропотливым перебором можно убедиться, что найти такую оценку будет не так-то просто...

По определению искать эффективные оценки довольно трудно: нужно каким-то чудом попасть в нужную оценку и убедиться, что для неё в неравенстве Крамера—Рао достигается равенство. Но есть более простой способ.

ТЕОРЕМА 5.7.1

Несмещённая оценка θ^* параметра $\tau(\theta)$ является эффективной тогда и только тогда, когда для некоторой функции $c(\theta)$ выполнено

$$\theta^*(X) - \tau(\theta) = c(\theta) U_\theta(X).$$

При этом, если выполнено равенство, то обязательно

$$c(\theta) = \frac{\tau'(\theta)}{I_X(\theta)}.$$

Доказательство. Вспомним, что неравенство Крамера—Рао — это по сути неравенство КБШ. Равенство в КБШ достигается ровно в том случае, когда почти наверное есть линейная зависимость между множителями. То есть почти наверное должно выполняться

$$\theta^* - \tau(\theta) = c(\theta) U_\theta(X) + a(\theta).$$

При этом, так как слева математическое ожидание равно нулю и у вклада математическое ожидание равно нулю, то должно быть и $a(\theta) = 0$. Таким образом, мы уже доказали критерий эффективности. Осталось найти вид функции $c(\theta)$ с помощью того, что мы

находили при доказательстве неравенства Крамера—Рао:

$$\tau'(\theta) = \mathrm{E}_\theta(\theta^* - \tau(\theta))U_\theta(X) = \mathrm{E}_\theta c(\theta)U_\theta(X) = c(\theta)I_X(\theta).$$

□

Пример 5.7.3. Рассмотрим модель $\mathrm{Bern}(\theta)$. Мы уже нашли вклад

$$U_\theta(X) = \frac{\sum_{i=1}^n X_i - n\theta}{\theta(1-\theta)}$$

и информацию Фишера

$$I_X(\theta) = \frac{n}{\theta(1-\theta)}.$$

Приводя вклад к виду как в критерии эффективности, видим

$$U_\theta(X) = \frac{\sum_{i=1}^n X_i - n\theta}{\theta(1-\theta)} = I_X(\theta)(\overline{X} - \theta),$$

откуда $\overline{X}$ является эффективной оценкой.

Пример 5.7.4. Рассмотрим модель $\mathrm{Exp}(\theta)$. Мы уже нашли вклад

$$U_\theta(X) = \frac{n}{\theta} - \sum_{i=1}^n X_i$$

и информацию Фишера

$$I_X(\theta) = \frac{n}{\theta^2},$$

откуда

$$U_\theta(X) = -n\left(\overline{X} - \frac{1}{\theta}\right) = \frac{I_X(\theta)}{\tau'(\theta)}\left(\overline{X} - \frac{1}{\theta}\right)$$

для $\tau(\theta) = \frac{1}{\theta}$. То есть, выборочное среднее является эффективной оценкой параметра $\frac{1}{\theta}$.

На глаз видно, что, как ни перебрасывай слагаемые в выражении вклада, получить выражение вида $c(\theta)(\theta^* - \theta)$ не получится. Хочется сказать, что в этой модели нет эффективной оценки параметра θ. Это и правда так, но для этого надо развить теорию эффективных оценок.

Пример 5.7.5. Напоследок приведём пример, показывающий, что через критерий эффективности можно искать и информацию Фишера. Рассмотрим модель $N(0,\theta)$. Тогда правдоподобие равно

$$f_\theta(X) = \frac{1}{(2\pi\theta)^{n/2}} e^{-\frac{1}{2\theta}\sum_{i=1}^n X_i^2},$$

откуда находим вклад

$$U_\theta(X) = -\frac{n}{2\theta} + \frac{\sum_{i=1}^n X_i^2}{2\theta^2} = \frac{n}{2\theta^2}(\overline{X^2} - \theta).$$

Отсюда сразу получаем, что $\overline{X^2}$ является эффективной оценкой дисперсии, и что

$$i(\theta) = \frac{1}{2\theta^2}.$$

То есть, чем больше дисперсия, тем больше разброс и тем меньше информации дают нам наблюдения. Идеальный случай, когда нормальное вырождается в константу 0: дисперсия равна нулю, и информация Фишера улетает на бесконечность.

Из примера про равномерную модель понятно, что не у всех распределений и не для всех параметров существуют эффективные оценки. Например, в модели $\mathrm{U}[0,\theta]$ найти эффективную оценку не получится, а в модели $\mathrm{Bern}(\theta)$ она существует для параметра θ, но неизвестно, для каких ещё параметров. В модели $\mathrm{Exp}(\theta)$ мы смогли найти эффективную оценку для параметра $\frac{1}{\theta}$, а вот для θ почему-то не справились. Оказывается, есть вполне чёткие ограничения, при которых существуют эффективные оценки, и при этих ограничениях эффективные оценки ищутся довольно просто.

Пусть $\Theta \subset \mathbb{R}^k$. Если обобщённая плотность распределения имеет вид

$$p_\theta(x) = e^{\sum_{i=1}^k b_i(\theta)T_i(x)+d(\theta)+S(x)}\mathcal{I}_A(x),$$

где функции b_i линейно независимы, а носитель $A = \operatorname{supp} p_\theta$ распределения не зависит от θ, то такое семейство распределений называется **экспоненциальным**.

Пример 5.7.6.

- Распределение $\mathrm{Exp}(\theta)$, естественно, является экспоненциальным, так как

  $$p_\theta(x) = \theta e^{-\theta x}\mathcal{I}\{x > 0\} = e^{-\theta x + \ln\theta}\mathcal{I}\{x > 0\}.$$

  Здесь $k = 1, T(x) = x, b(\theta) = \theta, d(\theta) = \ln\theta, S(X) = 0$.
- Его обобщение, распределение $\Gamma(\alpha,\gamma)$, тоже является экспоненциальным.
- Пример поинтереснее: распределение $\mathrm{Bin}(m,\theta)$ при фиксированном m тоже является экспоненциальным, так как

  $$p_\theta(x) = \binom{m}{x}\theta^x(1-\theta)^{m-x}\mathcal{I}\{x = 0,\dots,m\} = \\ = e^{x\ln\frac{\theta}{1-\theta}+m\ln(1-\theta)+\ln\binom{m}{x}}\mathcal{I}\{x = 0,\dots,m\}.$$

  Здесь $k = 1, T(x) = x, b(\theta) = \ln\frac{\theta}{1-\theta}, d(\theta) = m\ln(1-\theta)$, $S(X) = \ln\binom{m}{x}$.
- Также являются экспоненциальными семейства $N(a,\sigma^2)$, $N(\theta,1)$, $N(0,\theta)$, $\mathrm{Pois}(\theta)$, $\mathrm{Geom}(\theta)$ и многие другие.

Заметим, что, например, распределения $\mathrm{U}[0,\theta]$ и $\mathrm{Cauchy}(\theta)$ не являются экспоненциальными.

ТЕОРЕМА 5.7.2

Эффективные оценки существуют для экспоненциальных семейств распределений и только для них. При этом эффективная оценка $\overline{T(X)}$ оценивает параметр

$$\tau(\theta) = -\frac{d'(\theta)}{b'(\theta)}\,.$$

СЛЕДСТВИЕ 5.7.1

Если θ^* является эффективной оценкой параметра $\tau(\theta)$, то оценки $\alpha\theta^* + \beta$ эффективно оценивают параметр $\alpha\tau(\theta) + \beta$ и других эффективных оценок для данного семейства распределений быть не может.

Доказательство теоремы об экспоненциальном семействе
Доказательство. Сперва покажем, что эффективные оценки существуют только у экспоненциальных семейств распределений. Из критерия эффективности для любого $x \in \operatorname{supp} p_\theta$ имеем

$$\frac{1}{c(\theta)}(\theta^*(x) - \tau(\theta)) = \frac{\partial}{\partial\theta}\ln p_\theta(x).$$

Проинтегрируем данное выражение по θ:

$$b(\theta)\theta^*(x) + d(\theta) + S(x) = \ln p_\theta(x),$$

где мы обозначили

$$b(\theta) := \int \frac{d\theta}{c(\theta)}, \quad d(\theta) := \int \frac{-\tau(\theta)}{c(\theta)}\,d\theta,$$

а $S(x)$ является константой интегрирования. Теперь, навешивая экспоненту, для произвольного x получаем

$$e^{b(\theta)\theta^*(x)+d(\theta)+S(x)}\mathcal{I}_{\operatorname{supp} p_\theta}(x) = p_\theta(x),$$

что и означает принадлежность экспоненциальному семейству распределений.

Теперь найдём эффективную оценку для таких семейств. Функция правдоподобия равна

$$f_\theta(X) = \prod_{i=1}^n p_\theta(X_i) = e^{b(\theta)\sum_i T(X_i)+nd(\theta)+\sum_i S(X_i)}\mathcal{I}\{X \in A\}.$$

Поэтому вклад

$$U_\theta(X) = \frac{\partial}{\partial\theta}\ln f_\theta(X) = b'(\theta)\sum_{i=1}^n T(X_i) + nd'(\theta) = \\ = nb'(\theta)\left(\overline{T(X)} - \left(-\frac{d'(\theta)}{b'(\theta)}\right)\right),$$

откуда по критерию эффективности получаем требуемое.

Наконец, последнее следствие получается из тех соображений, что вид экспоненциального семейства можно изменить только с точностью до некоторых констант. Например, если статистику T заменить на αT, то функцию b придётся заменить на $\frac{b}{\alpha}$, а потому

и оценка, и оцениваемый параметр домножаются на α.

Аналогично, если статистику T заменить на $T + \beta$, придётся функцию d заменить на $d - \beta b$, а потому и эффективная оценка, и оцениваемый параметр сдвинутся на β. □

Эта теорема показывает и плюсы, и минусы эффективных оценок. Да, они наилучшие в равномерном подходе, это явный плюс. Но минус в том, что они существуют только для фиксированного семейства распределений и для фиксированных параметров. Если повезёт попасть в такое табличное распределение, то искать наилучшую оценку не нужно, достаточно посмотреть где-нибудь в открытых источниках эффективные оценки. Но если распределение не экспоненциальное или нужно оценить какой-то странный параметр (например, θ^2 в модели $\mathrm{Bern}(\theta)$), эффективные оценки уже не годятся.

8. ДОСТАТОЧНЫЕ СТАТИСТИКИ

Достаточные статистики

Представим ситуацию: в модели $\mathrm{Bern}(\theta)$ нужно оценить параметр θ. Ежу понятно, что в качестве оценки хорошо подходит $\overline{X}$. Как ты скоро узнаешь, эта оценка будет наилучшей среди всех несмещённых оценок. Так зачем нам возиться в этой модели, анализировать всю выборку целиком, если нам достаточно знать выборочное среднее (иными словами, количество успехов)? В каком-то смысле незачем. Количество успехов является достаточной статистикой.

ОПРЕДЕЛЕНИЕ 5.8.1

Статистика S называется **достаточной**, если для любого измеримого множества B и любой точки s условная вероятность

$$\mathrm{P}_\theta(X \in B \mid S(X) = s)$$

не зависит от параметра $\theta \in \Theta$.

Пример 5.8.1. В модели $\mathrm{Bern}(\theta)$ проверим, что

$$S(X) = \sum_{i=1}^{n} X_i$$

является достаточной статистикой. Так как распределение дискретное, достаточно взять любое s и $\boldsymbol{x}$ и проверить:

$$\mathrm{P}_\theta\left(X = \boldsymbol{x} \,\middle|\, \sum X_i = s\right) = \frac{\mathrm{P}_\theta(X = \boldsymbol{x},\, \sum X_i = s)}{\mathrm{P}_\theta(\sum X_i = s)} =$$
$$= \frac{\theta^s(1-\theta)^{n-s}}{\binom{n}{s}\theta^s(1-\theta)^{n-s}}\mathcal{I}\left\{\sum x_i = s\right\} = \frac{1}{\binom{n}{s}}\mathcal{I}\left\{\sum x_i = s\right\}.$$

Последнее выражение не зависит от θ, что доказывает достаточность.

ЛЕММА 5.8.1

Достаточная статистика существует всегда. Например, $S(X) = X$ является достаточной.

Доказательство. Имеем:

$$\mathrm{P}_\theta(X \in B \mid X = \boldsymbol{x}) = \mathcal{I}\{\boldsymbol{x} \in B\},$$

что не зависит от параметра θ. □

ЛЕММА 5.8.2

Для достаточной статистики S и борелевской биекции g статистика $g(S)$ тоже является достаточной.

Доказательство. Следует из того факта, что S и $g(S)$ порождают одну и ту же σ-алгебру, относительно которой и считается УМО. □

Критерий факторизации Неймана — Фишера

Искать достаточные статистики по определению довольно сложно. В этом может помочь следующий критерий.

ТЕОРЕМА 5.8.1

Критерий факторизации

Статистика S является достаточной ровно в том случае, когда для некоторых функций $g_\theta(s)$ и $h(x)$ выполняется

$$p_\theta(x) = g_\theta(S(x))h(x),$$

где через p_θ обозначена обобщённая плотность выборки.

Доказательство. Мы докажем критерий только для дискретной выборки. В общем случае критерий опирается на теорему Радона — Никодима и ещё более продвинутую технику.

Итак, пусть S достаточная. Тогда при фиксированном s можно определить:

$$h(x) = \mathrm{P}_\theta(X = x \mid S(X) = s) = \frac{\mathrm{P}_\theta(X = x,\ S(X) = s)}{\mathrm{P}_\theta(S(X) = s)}.$$

Если $X = x$, то $s = S(X) = S(x)$; при другом выборе точки s числитель обращается в ноль. Тогда

$$h(x) = \frac{\mathrm{P}_\theta(X = x)}{\mathrm{P}_\theta(S(X) = s)},$$

откуда

$$f_\theta(x) = \mathrm{P}_\theta(X = x) = h(x)\mathrm{P}_\theta(S(X) = s).$$

Остаётся положить

$$g_\theta(s) := \mathrm{P}_\theta(S(X) = s).$$

Обратно: пусть

$$\mathrm{P}_\theta(x) = \mathrm{P}_\theta\{X = x\} = g_\theta(S(x))h(x).$$

Тогда

$$p_\theta\{S(X) = s\} = \sum_{x:S(x)=s} p_\theta(x) = g_\theta(s) \sum_{x:S(x)=s} h(x).$$

В таком случае, если $S(x) \neq s$, то условная вероятность получится равна нулю; а если $S(x) = s$, то

$$\mathrm{P}_\theta(X = x \mid S(X) = s) = \frac{\mathrm{P}_\theta\{X = x\}}{\mathrm{P}_\theta\{S(X) = s\}} = \\ = \frac{g_\theta(s)h(x)}{g_\theta(s) \sum\limits_{x:S(x)=s} h(x)} = \frac{h(x)}{\sum\limits_{x:S(x)=s} h(x)},$$

и мы видим, что зависимости от параметра нет.

Проблема с переносом этого доказательства на абсолютно непрерывный случай в том, что вектор (X, S) не имеет плотности, и потому условную плотность $p(x \mid s)$, даже зная, что она не зависит от параметра, мы не сможем удобно выразить через плотность вектора X, для которой доказывается параметризация. □

Пример 5.8.2. Например, в модели $N(0, \sigma^2)$ с параметром $\theta = \sigma^2$ вычисляем:

$$p_\theta(x) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} e^{-\frac{1}{2\sigma^2}\sum x_i^2},$$

откуда по критерию факторизации для $h(x) = 1$ и

$$g_\theta(s) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} e^{-\frac{s}{2\sigma^2}}$$

находим достаточную статистику $S(X) = \sum X_i^2$.

Смысл в том, что для анализа дисперсии в этой модели достаточно знать сумму квадратов наблюдений.

Пример 5.8.3. Рассмотрим модель $N(a, \sigma^2)$ с параметром $\theta = (a, \sigma^2) \in \mathbb{R}^2$. Теперь

$$p_\theta(x) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} e^{-\frac{1}{2\sigma^2}\sum (x_i - a)^2} = \\ = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} e^{-\frac{1}{2\sigma^2}\left(\sum x_i^2 - 2a\sum x_i + na^2\right)}, \quad (2)$$

и по критерию факторизации для $h(x) = 1$ и

$$g_\theta(s_1, s_2) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} e^{-\frac{1}{2\sigma^2}\left(s_2 - 2as_1 + na^2\right)}$$

находим достаточную статистику:

$$S(X) = \begin{pmatrix} \sum X_i, \\ \sum X_i^2 \end{pmatrix}.$$

Смысл в том, что для анализа и среднего, и дисперсии одной только суммы квадратов наблюдений уже недостаточно; нужно ещё знать сумму самих наблюдений. Понятно, конечно, что найденная статистика будет достаточной и в предыдущей модели $N(0, \sigma^2)$.

Теорема Колмогорова — Блэкуэлла — Рао

Как же нам помогут достаточные статистики? Оказывается, с их помощью можно улучшать несмещённые оценки. А именно, в среднеквадратичном подходе в классе несмещённых оценок лучше та, у которой дисперсия меньше.

ТЕОРЕМА 5.8.2

Об улучшении оценки

Пусть θ^* является несмещённой оценкой параметра $\tau(\theta)$ и S является достаточной статистикой. Тогда величина

$$\theta^{**} := \mathrm{E}_\theta(\theta^* \mid S)$$

тоже является несмещённой оценкой параметра $\tau(\theta)$, причём она лучше оценки θ^* в среднеквадратичном подходе; последнее означает, что

$$\mathrm{Var}_\theta\, \theta^{**} \leqslant \mathrm{Var}_\theta\, \theta^*.$$

Доказательство. Для начала стоит сказать, что θ^{**} вообще является оценкой, то есть зависит только от выборки, но не от параметра. Это так, поскольку условная плотность $p_{\theta^*|S}$ не зависит от параметра в силу достаточности статистики S. Обрати внимание: это единственное место, где используется достаточность!

Несмещённость оценки θ^{**} следует из формулы полного матожидания:

$$\mathrm{E}_\theta \theta^{**} = \mathrm{E}_\theta(\mathrm{E}_\theta(\theta^* \mid S)) = \mathrm{E}_\theta \theta^* = \tau(\theta).$$

Покажем, что оценка правда улучшилась. Распишем:

$$\begin{aligned} \mathrm{Var}_\theta\, \theta^* = \mathrm{E}_\theta(\theta^* - \tau(\theta))^2 = \mathrm{E}_\theta(\theta^* - \theta^{**} + \theta^{**} - \tau(\theta))^2 = \\ = \mathrm{E}_\theta(\theta^* - \theta^{**})^2 + \mathrm{E}_\theta(\theta^{**} - \tau(\theta))^2 + \\ + 2\mathrm{E}_\theta\big((\theta^* - \theta^{**})(\theta^{**} - \tau(\theta))\big). \end{aligned}$$

В последнем выражении

$$\begin{aligned}\mathrm{E}_\theta\big((\theta^* - \theta^{**})(\theta^{**} - \tau(\theta))\big) = \\ = \mathrm{E}_\theta\left(\mathrm{E}_\theta\big((\theta^* - \theta^{**})(\theta^{**} - \tau(\theta)) \mid S\big)\right) = \\ = \mathrm{E}_\theta\big((\theta^{**} - \tau(\theta))\mathrm{E}_\theta(\theta^* - \theta^{**} \mid S)\big) = 0,\end{aligned}$$

где:

- первое равенство следует по формуле полного матожидания;
- второе равенство следует в силу S-измеримости функции $\theta^{**} - \tau(\theta)$;
- третье равенство следует из того, что

$$\mathrm{E}_\theta(\theta^* - \theta^{**} \mid S) = \mathrm{E}_\theta(\theta^* \mid S) - \theta^{**} = 0.$$

Кроме того:

$$\mathrm{E}_\theta(\theta^{**} - \tau(\theta))^2 = \mathrm{Var}_\theta\, \theta^{**}.$$

В итоге:

$$\mathrm{Var}_\theta\, \theta^* = \mathrm{E}_\theta(\theta^* - \theta^{**})^2 + \mathrm{Var}_\theta\, \theta^{**} \geqslant \mathrm{Var}_\theta\, \theta^{**},$$

что и требовалось. □

9. ПОЛНЫЕ СТАТИСТИКИ

Полные статистики играют важную роль в нахождении наилучших оценок в среднеквадратичном подходе. Вместе с достаточными статистиками они замыкают круг, позволяя находить эти наилучшие оценки.

Мы узнаем, что такое полные статистики и как их можно искать в некоторых часто встречающихся моделиях.

Как мы выяснили, если один раз по теореме Колмогорова — Блэкуэлла — Рао улучшить оценку по некоторой достаточной статистике, то дальше эта статистика становится бесполезной: второй раз ей оценку не улучшить. При этом нигде нет гарантий, что найденная нами оценка является наилучшей.

А всё потому, что достаточная статистика могла не быть полной.

ОПРЕДЕЛЕНИЕ 5.9.1

Статистика T называется **полной**, если для любой борелевской функции f выполнено следующее: из того, что $\mathrm{E}_\theta f(T) = 0$ для всех $\theta \in \Theta$, следует, что $f(T) = 0$ почти наверное по мере P_θ для всех $\theta \in \Theta$.

Пример 5.9.1. Рассмотрим модель $\mathrm{Bern}(\theta)$. Голос свыше подсказывает, что статистика

$$T(X) = \sum_{i=1}^{n} X_i$$

будет полной. Давай это проверим. Понятно, что $T \sim \mathrm{Bin}(n, \theta)$.

Возьмём произвольную функцию f. Допустим:

$$0 = \mathrm{E}_\theta f(T) = \sum_{k=0}^{n} f(k) \binom{n}{k} \theta^k (1-\theta)^{n-k}$$

для всех $\theta \in [0,1]$. Выражение справа как функция от θ является многочленом степени не выше n; следовательно, имеет не больше n корней. Но у нас оно имеет континуум корней. Таким образом, $f(k) = 0$ для всех $k = 0, \ldots, n$. Следовательно, статистика T полна.

ЛЕММА 5.9.1

Полная статистика существует всегда. Например, константы являются полными статистиками.

Доказательство. В самом деле, рассмотрим произвольную константу c и произвольную борелевскую функцию f. Пусть $\mathrm{E}_\theta f(c) = 0$. Поскольку $f(c)$ является константой, то $f(c) = \mathrm{E}_\theta f(c)$. Тогда $f(c) = 0$. Следовательно, c являтся полной статистикой. □

Таким образом, полные статистики являются антиподом достаточных статистик: достаточные статистики устроены сложно (как, например, вся выборка), а полные статистики устроены просто (как, например, константа).

Позже мы узнаем, что с их помощью можно находить наилучшую оценку, а не просто улучшать одну до непонятно какой другой.

Теорема об экспоненциальном семействе распределений

Предыдущий пример показал, что проверять статистику на полноту может быть нелегко. Оказывается, для экспоненциального семейства распределений это не так сложно.

ОПРЕДЕЛЕНИЕ 5.9.2

Экспоненциальные семейства распределений

Напомним определение. Пусть $\Theta \subset \mathbb{R}^k$. Если обобщённая плотность распределения имеет вид

$$p_\theta(x) = e^{\sum_{i=1}^{k} b_i(\theta) T_i(x) + d(\theta) + U(x)} \mathcal{I}_A(x),$$

где функции b_i линейно независимы, а носитель $A = \operatorname{supp} p_\theta$ распределения не зависит от θ, то такое семейство распределений называется **экспоненциальным**.

ТЕОРЕМА 5.9.1

Пусть выборка X имеет распределение из экспоненциального семейства. Пусть множество $b(\Theta) \subset \mathbb{R}^k$ содержит в себе k-мерный шар. Тогда статистика $T = (T_1, \ldots, T_k)$ является полной и достаточной в данной параметрической модели.

Идея доказательства Доказательство. Достаточность статистики T следует из критерия факторизации Неймана — Фишера. Так что нужно доказать только её полноту.

Сначала нужно показать, что для борелевской меры ν на $\mathbb{R}^k$,

заданной как

$$\nu(B) := \int_{T^{-1}(B)\cap A} e^{U(x)}\,dx,$$

статистика T имеет плотность ϕ_θ по мере ν, заданную как

$$\phi_\theta(t) = e^{b(\theta)\cdot t + d(\theta)}.$$

Далее нужно заметить, что преобразование вида

$$\lambda \mapsto \int e^{-\lambda t} f(t)\,dt$$

является так называемым преобразованием Лапласа, которое обратимо. А потому в равенстве

$$0 = \mathrm{E}_\theta T(X) = \int e^{b(\theta)\cdot t + d(\theta)}\,d\nu(t)$$

можно произвести обращение и получить, что $T(X) = 0$ почти наверное. □

Пример 5.9.2. Рассмотрим модель $N(a, \sigma^2)$. Мы выясняли, что статистика $\left(\sum X_i, \sum X_i^2\right)$ является в ней достаточной. Но теперь, выписывая

$$p_\theta(x) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} e^{-\frac{1}{2\sigma^2}\left(\sum x_i^2 - 2a\sum x_i + na^2\right)},$$

мы понимаем, что она ещё и полная.

10. СВОЙСТВО ОПТИМАЛЬНОСТИ

В классе несмещённых оценок есть понятие эффективной оценки, которая будет наилучшей в смысле сравнения по дисперсии в классе несмещённых оценок, — как нам завещало неравенство Крамера—Рао. Но там возникает другая проблема: эффективные оценки существуют для довольно узкого класса экспоненциальных семейств, а в них оценивают только параметры специального вида. Банально, в модели $\mathrm{Bern}(\theta)$ для параметра θ^2 нет эффективной оценки. Оказывается, наилучшая оценка там есть!

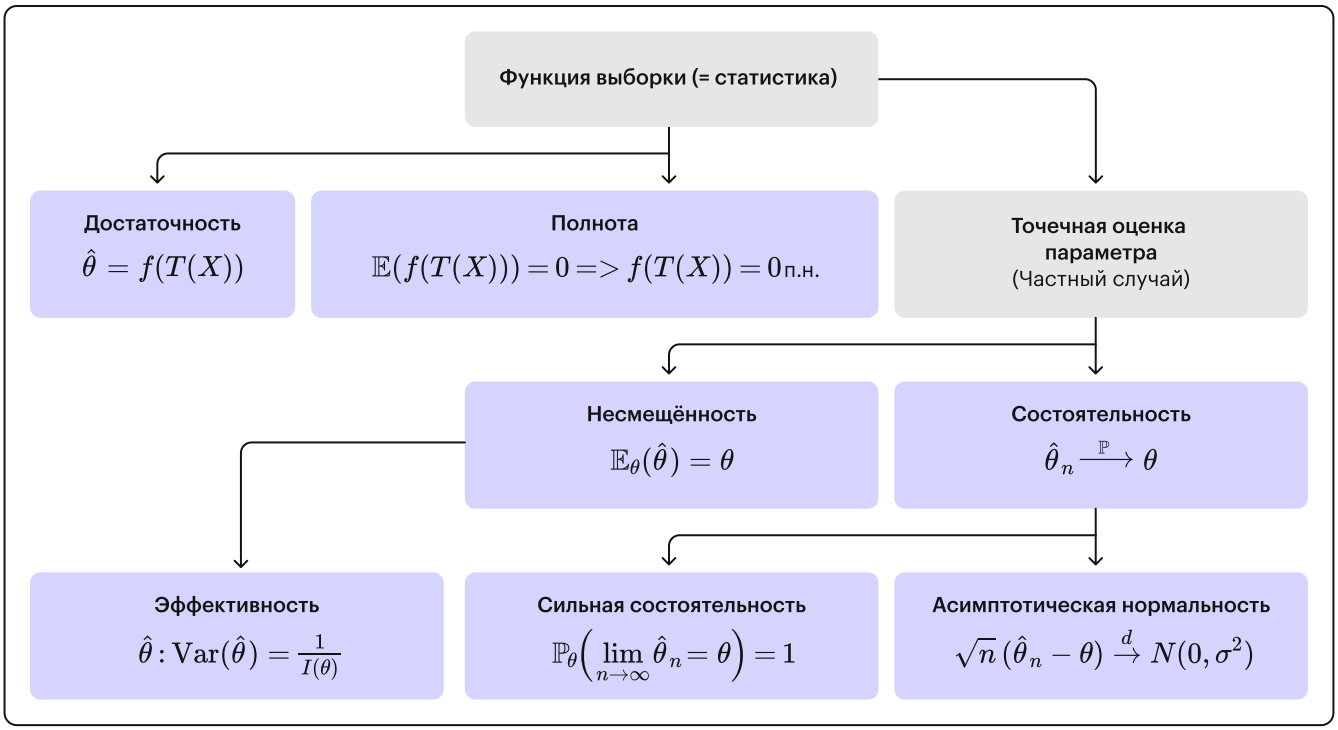

Рисунок 60. Классификация свойств точечных оценок.

Оптимальной называется наилучшая оценка в среднеквадратичном подходе (то есть в подходе сравнения по дисперсии) в классе несмещённых оценок. Иными словами, это несмещённая оценка с равномерно наименьшей дисперсией.

Очевидно, что эффективные оценки являются оптимальными. Как мы увидим ниже, обратное верно не всегда.

Как мы помним, по теореме Колмогорова—Блэквелла—Рао с помощью достаточной статистики можно улучшать оценку. Оказывается, так можно получать и оптимальные оценки. На рис. 60 см. напоминание различных свойств оценок.

ЛЕММА 5.10.1

Пусть для достаточной статистики S оценка $\widehat{\theta}$ представляет собой единственную (с точностью до п.н.) S-измеримую оценку параметра $\tau(\theta)$. Тогда $\widehat{\theta}$ является оптимальной оценкой.

Доказательство. Допустим, $\widehat{\theta}$ не оптимальная. Тогда найдётся оценка θ^* лучше неё. По теореме Колмогорова—Блэкуэлла—Рао, оценка

$$\theta^{**} = \mathrm{E}_\theta(\theta^* \mid S)$$

не хуже оценки θ^*, а потому тоже лучше оценки $\widehat{\theta}$. Значит, оценки θ^{**} и $\widehat{\theta}$ не равны, и притом обе S-измеримы. □

Смысл этой леммы в том, что, используя только достаточную статистику, можно было бы находить оптимальные оценки, но это было бы непросто. Если добавить полноту, то ситуация существенно упрощается.

ТЕОРЕМА 5.10.1

Пусть θ^* является несмещённой оценкой параметра $\tau(\theta)$ и S представляет собой полную достаточную статистику. Тогда вели-

чина

$$\theta^{**} := \mathrm{E}_\theta(\theta^* \mid S)$$

является оптимальной оценкой параметра $\tau(\theta)$.

Доказательство. По лемме 5.10.1, достаточно обосновать, что θ^{**} является единственной S-измеримой несмещённой оценкой параметра $\tau(\theta)$. По свойствам УМО, $\theta^{**} = \varphi(S)$ для некоторой борелевской функции φ. Рассмотрим другую S-измеримую несмещённую оценку $\psi(S)$ параметра $\tau(\theta)$. Тогда

$$0 = \mathrm{E}_\theta(\varphi(S) - \psi(S)) = \mathrm{E}_\theta(\varphi - \psi)(S).$$

В силу полноты статистики S, получаем $\varphi(S) = \psi(S)$, что доказывает единственность. □

Не переживай: чтобы искать оптимальные оценки, не нужно считать УМО.

СЛЕДСТВИЕ 5.10.1

Пусть S является полной достаточной статистикой и $\varphi(S)$ представляет собой несмещённую оценку некоторого параметра. Тогда она является оптимальной оценкой этого параметра.

Доказательство. Можно доказать аналогично теореме Лемана—Шеффе или же просто заметить, что

$$\varphi(S) = \mathrm{E}_\theta(\varphi(S) \mid S)$$

является оптимальной оценкой по той же теореме. □

Пример 5.10.1. Найдём оптимальную оценку параметра θ^2 в модели $\mathrm{Bern}(\theta)$. Мы уже выясняли, что статистика $S := \sum X_i \sim \mathrm{Bin}(n, \theta)$ является полной и достаточной. Остаётся найти такую функцию $\varphi(S)$, что $\mathrm{E}_\theta\varphi(S) = \theta^2$. Как мы помним:

$$\mathrm{E}_\theta S = n\theta.$$

Чтобы получить квадратичную зависимость, посчитаем:

$$\mathrm{E}_\theta S^2 = \mathrm{Var}_\theta S + (\mathrm{E}_\theta S)^2 = n\theta(1-\theta) + n^2\theta^2 = \\ = n(n-1)\theta^2 + n\theta.$$

Теперь

$$\mathrm{E}_\theta \frac{S(S-1)}{n(n-1)} = \theta^2,$$

откуда $\frac{S(S-1)}{n(n-1)}$ и есть оптимальная статистика.

Как мы знаем, эффективной оценки у этого параметра нет.

Пример 5.10.2. Рассмотрим модель $N(a, 1)$. Найдём эффективную оценку параметра a. Плотность в модели равна

$$p_\theta(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2 + ax - a^2/2},$$

поэтому по теореме об экспоненциальном семействе, статистика $\overline{X}$ является полной и достаточной. Тогда нужно найти такую функцию φ, что $\mathrm{E}\varphi(\overline{X}) = a$. Очевидно, что нужно взять тожде-

ственную функцию, и оценка $\overline{X}$ является оптимальной.

Пример 5.10.3. Рассмотрим модель $N(a, 1)$. Найдём эффективную оценку параметра a^2. Как мы поняли выше, статистика $\overline{X}$ является полной и достаточной. Тогда нужно найти такую функцию φ, что $\mathrm{E}\varphi(\overline{X}) = a^2$. Поскольку

$$\mathrm{E}(\overline{X})^2 = \operatorname{Var}\overline{X} + (\mathrm{E}\overline{X})^2 = \frac{1}{n} + a^2,$$

то получаем, что оптимальной оценкой является $\overline{X}^2 - \frac{1}{n}$.

Пример 5.10.4. Рассмотрим модель $N(0, \sigma^2)$. Найдём эффективную оценку параметра σ^2. Плотность в модели равна

$$p_\theta(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{x^2}{2\sigma^2}},$$

поэтому полной достаточной статистикой является $\overline{X^2}$. Тогда нужно найти такую функцию φ, что $\mathrm{E}\varphi(\overline{X^2}) = \sigma^2$. Поскольку

$$\mathrm{E}\overline{X^2} = \sigma^2,$$

то получаем, что оптимальной оценкой дисперсии является само $\overline{X^2}$.

Пример 5.10.5. Рассмотрим модель $N(a, \sigma^2)$. Найдём эффективную оценку параметра (a, σ^2). Плотность в модели равна

$$p_\theta(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{x^2 - 2ax + a^2}{2\sigma^2}},$$

поэтому полной достаточной статистикой является $(\overline{X}, \overline{X^2})$. Поскольку

$$\mathrm{E}_\theta\overline{X} = a$$

то выборочное среднее является оптимальной оценкой среднего. Далее,

$$\mathrm{E}_\theta\overline{X^2} = a^2 + \sigma^2$$

и

$$\mathrm{E}_\theta(\overline{X})^2 = \operatorname{Var}\overline{X} + (\mathrm{E}\overline{X})^2 = \frac{\sigma^2}{n} + a^2,$$

откуда

$$\mathrm{E}_\theta s^2 = \frac{n-1}{n}\sigma^2.$$

Таким образом, оптимальной оценкой дисперсии здесь является несмещённая выборочная дисперсия.

Часть 6. Методы построения точечных оценок

1. МЕТОД МОМЕНТОВ

Выше мы обсуждали разные кустарные методы нахождения оценок. Пора навести порядок в этом деле.

Один из способов — воспользоваться эмпирическим распределением. По теореме Гливенко эмпирическое распределение решает задачу статистики, потому что сходится к истинному распределению. Но нужно ещё как-то преобразовать распределение в оценку, а потом в этот преобразователь подставить эмпирическое распределение. В этом поможет **метод подстановки**.

Пусть в параметрической модели на вероятностных распределениях задан некоторый функционал G, работающий по правилу

$$G(\mathrm{P}_\theta) = \theta.$$

Оценкой методом подстановки называется

$$\hat{\theta}_n := G(\hat{\mathrm{P}}_n).$$

Покажем, как с помощью метода подстановки оценить матожидание.

Пример 6.1.1. В модели $N(\theta, 1)$ необходимо оценить параметр θ. Рассмотрим функционал

$$G(\mathrm{P}) = \mathrm{E}_\mathrm{P}.$$

Тогда $G(\mathrm{P}_\theta) = \theta$. Поэтому по методу подстановки получаем оценку

$$\hat{\theta}_n = G(\hat{\mathrm{P}}_n) = \overline{X}.$$

Пример 6.1.1 показывает, что при удачном выборе функционала метод моментов выдаёт адекватные оценки. Проблема в том, что пока непонятно, как такие функционалы подбирать.

Так же можно искать выборочные квантили, которые являются оценкой обычной квантили по методу подстановки.

Частный случай метода подстановки — **метод моментов**. Обычно функционал в методе подстановки подобрать несложно, а именно достаточно посчитать моменты (отсюда и название метода) или просто математические ожидания каких-то функций и по ним восстановить оценку.

Пусть $\Theta \subset \mathbb{R}^k$.Возьмём такую борелевскую функцию $\boldsymbol{g} \colon \mathbb{R} \to \mathbb{R}^k$,

называемую **пробной функцией**, что существует конечный вектор

$$\mathrm{E}_\theta \boldsymbol{g}(X_1).$$

Определим функцию $m\colon \Theta \to \mathbb{R}^k$ как

$$m(\theta) := \mathrm{E}_\theta \boldsymbol{g}(X_1).$$

Пусть m инъективна. Тогда **оценкой методом моментов** называется

$$\hat{\theta}_n := m^{-1}\left(\overline{\boldsymbol{g}(X)}\right).$$

Своё название метод получил благодаря тому, что обычно выбирают **стандартные** пробные функции $g^i(x) = x^i$.

Пример 6.1.2. Рассмотрим модель $N(a, \sigma^2)$, где оба параметра неизвестны. Тогда выберем пробные функции $g(x) = (x, x^2)$, откуда получаем, что нужно решить систему

$$\begin{cases} \overline{X} = a, \\ \overline{X^2} = a^2 + \sigma^2. \end{cases}$$

Отсюда находим оценку $(\overline{X}, s^2)$ для $\theta = (a, \sigma^2)$. Обратите внимание, что она получилась смещённой.

Пример 6.1.3. Пусть $X_1, \ldots, X_n$ — выборка из распределения $\Gamma(\alpha, \lambda)$, то есть с плотностью

$$p(x) = \frac{x^{\alpha-1}\lambda^\alpha}{\lambda(\alpha)} e^{-\lambda x} \mathcal{I}\{x > 0\}.$$

Найдём методом моментов оценку параметра $\theta = (\alpha, \lambda)$.

Возьмём пробную функцию $\boldsymbol{g}(x) = (x, x^2)$. Поскольку

$$\mathrm{E}_\theta X_1 = \frac{\alpha}{\lambda}$$

и

$$\mathrm{E}_\theta X_1^2 = \mathrm{Var}_\theta X_1 + (\mathrm{E}_\theta X_1)^2 = \frac{\alpha}{\lambda^2} + \frac{\alpha^2}{\lambda^2},$$

то нужно решить систему

$$\begin{cases} \frac{\alpha}{\lambda} = \overline{X}, \\ \frac{\alpha(\alpha+1)}{\lambda^2} = \overline{X^2}. \end{cases}$$

Отсюда $\dfrac{\alpha}{\lambda^2} = s^2$, поэтому $\hat{\lambda}_n = \dfrac{\overline{X}}{s^2}$ и $\hat{\alpha}_n = \dfrac{\overline{X}^2}{s^2}$.

Возникает естественный вопрос: насколько эта оценка хороша? Следующие две теоремы утверждают, что при достаточном объёме выборки она весьма хороша.

ТЕОРЕМА 6.1.1

Пусть функция $m^{-1}\colon m(\Theta) \to \Theta$ непрерывна. Тогда оценка методом моментов является сильно состоятельной.

Доказательство. По УЗБЧ, для любой $\theta \in \Theta$

$$\overline{\boldsymbol{g}(X)} \xrightarrow[n\to\infty]{\mathrm{P}_\theta\text{-п.н.}} \mathrm{E}_\theta \boldsymbol{g}(X_1) = m(\theta).$$

Тогда по теореме о наследовании сходимости,

$$\hat{\theta}_n = m^{-1}\left(\overline{\boldsymbol{g}(X)}\right) \xrightarrow[n\to\infty]{\mathrm{P}_\theta\text{-п.н.}} \theta.$$

□

ТЕОРЕМА 6.1.2

Пусть функция $m^{-1}\colon m(\Theta) \to \Theta$ дифференцируема и у случайного вектора $\boldsymbol{g}(X_1)$ корректно определена матрица ковариаций Σ. Тогда оценка методом моментов является асимптотически нормальной.

Доказательство. По ЦПТ, для любой $\theta \in \Theta$

$$\sqrt{n}\left(\overline{\boldsymbol{g}(X)} - m(\theta)\right) \xrightarrow[n\to\infty]{d_\theta} N(0, \Sigma).$$

По многомерному дельта-методу,

$$\sqrt{n}\left(\hat{\theta}_n - \theta\right) \xrightarrow[n\to\infty]{d_\theta} N\left(0, \left(\frac{\partial m^{-1}}{\partial t}\right)^{\mathsf{T}}\Big|_{t=m(\theta)} \Sigma \left(\frac{\partial m^{-1}}{\partial t}\right)\Big|_{t=m(\theta)}\right).$$

□

2. МЕТОД МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ

Сперва поясним идею метода максимального правдоподобия на примере.

Пример 6.2.1. Пусть мы сделали одно наблюдение X_1 и знаем, что $X_1 \sim N(\theta, 1)$. Теперь мы хотим оценить параметр θ.

Идея метода максимального правдоподобия — так «подвигать» плотность p_θ нормального закона $N(\theta, 1)$, чтобы при такой плотности полученные наблюдения были как можно более правдоподобны (то есть вероятны).

Так как наблюдение одно, оно будет наиболее вероятным, если «горб» нормального распределения придётся как раз на это наблюдение. Таким образом, максимально правдоподобной оценкой будет $\theta^* = X_1$.

Пусть:

- параметризованное семейство $\mathcal{P}$ распределений является доминируемым;
- существуют обобщённые плотности p_θ;
- при различных параметрах θ сами распределения P_θ также различны.

Оценкой максимального правдоподобия (сокращённо **ОМП**) называется

$$\theta^* := \operatorname{argmax}_{\theta\in\Theta} f_\theta(X),$$

если максимум достигается ровно на одной точке $\theta \in \Theta$. В силу

выпуклости логарифма argmax равен

$$\theta^* = \operatorname{argmax}_{\theta\in\Theta} L_\theta(X).$$

Пример 6.2.2. Рассмотрим модель $X_1, \ldots, X_n \sim \mathrm{U}[0,\theta]$. Обобщённая плотность одного наблюдения равна

$$p_\theta(x) = \frac{1}{\theta}\mathcal{I}\{0 \leqslant x \leqslant \theta\}.$$

Функция правдоподобия в таком случае равна

$$f_\theta(X) = \frac{1}{\theta^n}\mathcal{I}\{0 \leqslant X_{(1)} \leqslant X_{(n)} \leqslant \theta\}.$$

Надо теперь представить, что наблюдения $X_1, \ldots, X_n$ зафиксированы. Мы подбираем параметр $\theta > 0$, при котором максимизируется значение функции правдоподобия. На первый взгляд кажется, что чем меньше θ, тем больше $\frac{1}{\theta^n}$, и потому функция правдоподобия растёт при $\theta \to 0$. На самом же деле при фиксированном наблюдении функция правдоподобия зануляется при $\theta < X_{(n)}$. Это вполне логично: наблюдения, которые вылезли за границы отрезка $[0,\theta]$, очень неправдоподобны. Таким образом, максимум функции правдоподобия достигается при

$$\theta^* = X_{(n)}.$$

Как мы выяснили раньше, эта оценка не является несмещённой, но зато является сильно состоятельной.

Мы построили новую оценку. Теперь изучим её свойства. Чтобы их получить, нужно наложить условия регулярности из неравенства Крамера—Рао.

Теорема ниже говорит, что даже если наложить меньше условий регулярности, вероятность совпадения ОМП и истинного значения оценки «довольно большая». Под большой вероятностью мы понимаем следующее.

Говорят, что некоторое событие выполнено **асимптотически почти наверное**, если вероятность этого события стремится к 1 при $n \to \infty$.

ТЕОРЕМА 6.2.1

Пусть в модели выполнено условие регулярности (R1). Тогда для любых параметров $\theta_0 \neq \theta$ событие $f_{\theta_0}(X) > f_\theta(X)$ выполнено асимптотически P_{θ_0}-п.н.

Доказательство. Начнём с классического «заметим, что»:

$$f_{\theta_0}(X) > f_\theta(X) \iff \frac{1}{n} \ln \frac{f_\theta(X)}{f_{\theta_0}(X)} < 0.$$

Поскольку $f_\theta(X) = p_\theta(X_1) \dots p_\theta(X_n)$, то справа написано

$$\overline{\ln \frac{p_\theta(X)}{p_{\theta_0}(X)}} < 0.$$

С другой стороны, по УЗБЧ,

$$\overline{\ln \frac{p_\theta(X)}{p_{\theta_0}(X)}} \xrightarrow[n\to\infty]{\mathrm{P}_{\theta_0}\text{-п.н.}} \mathrm{E}_{\theta_0} \ln \frac{p_\theta(X_1)}{p_{\theta_0}(X_1)}.$$

Так как из сходимости почти наверное следует сходимость по распределению, то

$$\mathrm{P}_{\theta_0} \{f_{\theta_0}(X) > f_\theta(X)\} \xrightarrow[n\to\infty]{} \mathrm{P}_{\theta_0} \left\{ \mathrm{E}_{\theta_0} \ln \frac{p_\theta(X_1)}{p_{\theta_0}(X_1)} < 0 \right\}.$$

Справа под вероятностью стоит неслучайное событие, поэтому остаётся доказать, что

$$\mathrm{E}_{\theta_0} \ln \frac{p_\theta(X_1)}{p_{\theta_0}(X_1)} < 0.$$

В самом деле,

$$\begin{aligned} \mathrm{E}_{\theta_0} \ln \frac{p_\theta(X_1)}{p_{\theta_0}(X_1)} &= \int_{\operatorname{supp} p_{\theta_0}} \ln \frac{p_\theta(x)}{p_{\theta_0}(x)} p_{\theta_0}(x)\, dx \leqslant \\ &\leqslant \int_{\operatorname{supp} p_{\theta_0}} \left(\frac{p_\theta(x)}{p_{\theta_0}(x)} - 1 \right) p_{\theta_0}(x)\, dx = \\ &= \int_{\operatorname{supp} p_\theta} p_\theta(x)\, dx - \int_{\operatorname{supp} p_{\theta_0}} p_{\theta_0}(x)\, dx = 1 - 1 = 0, \end{aligned}$$

где неравенство следует из того, что

$$\ln x \leqslant x - 1 \qquad \text{при} \qquad x > 0.$$

Мы получили почти то, что нам нужно: нестрогое неравенство вместо строгого. На самом деле, $\ln x < x - 1$ всегда, кроме случая $x = 1$. Но, так как под логарифмом стоит отношение $\frac{p_\theta(X_1)}{p_{\theta_0}(X_1)}$, оно действительно не тождественно равно единице. Отсюда следует, что полученное неравенство на самом деле строгое. Это заканчивает доказательство. □

На самом деле математическое ожидание получилось равно **расстоянию Кульбака — Лейблера** между распределениями, которое всегда неотрицательно и равно нулю, только если распределения совпадают. По сути, мы это и получили, когда доказывали теорему.

Следующее следствие скорее забавное свойство ОМП, поскольку на практике его посылки вряд ли выполняются. Но оно помогает понять экстремальное свойство ОМП.

СЛЕДСТВИЕ 6.2.1

Пусть в модели выполнено условие регулярности (R1) и при этом множество Θ конечно. Тогда ОМП существует и при этом является состоятельной.

Доказательство. Обозначим через $\theta_0 \in \Theta$ истинное значение параметра. В силу конечности множества Θ, по предыдущей теореме получаем, что

$$\mathrm{P}_{\theta_0}\left\{f_{\theta_0}(X) > f_\theta(X)\ \forall \theta \neq \theta_0\right\} \xrightarrow[n\to\infty]{} 1.$$

Таким образом, максимум правдоподобия достигается именно на параметре θ_0 с вероятностью, стремящейся к 1. □

На практике, конечно, обычно множество параметров бесконечно. Вспомним ещё раз, как мы рассуждали при построении эффективных оценок: чем вклад меньше, тем ближе оценка к оценке максимального правдоподобия, и чем вклад больше, тем лучше мы можем подкорректировать оценку. А вклад равен

$$U_\theta(X) = \frac{\partial}{\partial\theta}\ln f_\theta(X) = \frac{\partial}{\partial\theta}L_\theta(X).$$

То есть с уменьшением вклада мы приближаемся к экстремуму функции правдоподобия. Хочется сказать, что мы приближаемся не просто к экстремуму, а к максимуму. Оказывается, при некоторых дополнительных предположениях (смотри их в теореме 6.2.3) это действительно так.

Уравнением правдоподобия называется

$$U_\theta(X) = 0,$$

или, что то же самое,

$$\frac{\partial}{\partial\theta}\ln f_\theta(X) = 0.$$

ЛЕММА 6.2.1

условиях регулярности (R1–R3) уравнение правдоподобия имеет решение θ_n^* асимптотически почти наверное. Более того, это решение θ_n^* является состоятельной оценкой параметра θ.

Доказательство. Зафиксируем в качестве θ истинное значение

параметра. Выберем некоторую окрестность $[\theta - a, \theta + a] \subset \Theta$, которая существует в силу открытости множества Θ. По экстремальному свойству правдоподобия,

$$\mathrm{P}_\theta \{ f_{\theta-a}(X) < f_\theta(X),\ f_{\theta+a}(X) < f_\theta(X) \} \xrightarrow[n\to\infty]{} 1.$$

Следовательно, на интервале $(\theta - a, \theta + a)$ существует решение θ_n^*, причём, взяв ближайшее к θ,

$$\mathrm{P}_\theta \{ |\theta_n^* - \theta| < a \} \xrightarrow[n\to\infty]{} 1.$$

Последнее и означает состоятельность. □

А теперь покажем, как это связано с ОМП.

ТЕОРЕМА 6.2.2

Пусть выполнены условия регулярности (R1–R3), а уравнение правдоподобия для любых n и X имеет единственное решение θ^*. Тогда это решение является ОМП, и она состоятельная.

Доказательство. Состоятельность получаем из предыдущей леммы. Нужно доказать, что если уравнение правдоподобия имеет единственное решение, то это обязательно ОМП. Зафиксируем n.

Итак, пусть θ является истинным значением параметра и $[\theta - a, \theta + a] \subset \Theta$. В силу экстремального свойства, функция $f_t(X)$ достигает локального максимума при $t \in [\theta - a, \theta + a]$ в некоторой точке $\widetilde{\theta}$. Поэтому $\widetilde{\theta}$ является решением уравнения правдоподобия, и притом единственным.

Обозначим через θ^* ОМП. Допустим, $\theta^* \neq \widetilde{\theta}$. Тогда, в силу определения ОМП,

$$f_{\widetilde{\theta}}(X) < f_{\theta^*}(X).$$

Значит, есть два варианта:

1. Сама ОМП является решением уравнения правдоподобия.
2. Где-то между θ^* и $\widetilde{\theta}$ есть точка локального минимума, которая тоже является решением уравнения правдоподобия.

В любом случае получаем противоречие с единственностью решения уравнения правдоподобия. Таким образом, $\theta^* = \widetilde{\theta}$. □

Мы уже говорили, что чем меньше вклад, тем правдоподобнее оценка. Значит, ОМП тесно связаны с эффективными оценками. Следующая теорема показывает, что теснее некуда.

ТЕОРЕМА 6.2.3

Пусть выполнены условия регулярности для неравенства Крамера—Рао и θ^* является эффективной оценкой параметра θ. Тогда θ^* является ОМП.

Доказательство. По критерию эффективности,

$$\theta^* - \theta = \frac{1}{I_X(\theta)} \frac{\partial}{\partial\theta} \ln f_\theta(X).$$

Значит, если $\theta^* > \theta$, то $\frac{\partial}{\partial\theta} \ln f_\theta(X) > 0$, а если $\theta^* < \theta$, то

$\frac{\partial}{\partial\theta}\ln f_\theta(X) < 0$. Таким образом, θ^* является точкой максимума функции $\ln f_\theta(X)$. Следовательно, она является ОМП. □

Итак, эффективные оценки являются ОМП. Однако пример 6.2.2 с моделью $\mathrm{U}[0,\theta]$ показывает, что ОМП могут оказаться не эффективными банально в силу своей смещённости. Но ты увидишь, что они эффективные асимптотически, если наложить дополнительные условия регулярности. Эти условия довольно технические, так что мы сформулируем их ниже.

Как мы говорили в прошлом лонгриде, эффективной оценкой называется та, для которой в неравенстве Крамера—Рао достигается равенство. Поскольку нас интересуют асимптотические свойства ОМП, рассмотрим следующий асимптотический аналог этого неравенства.

ТЕОРЕМА 6.2.4

Пусть выполнены условия регулярности (R1–R7). Пусть θ_n^* является асимптотически нормальной оценкой параметра θ с асимптотической дисперсией $\sigma^2(\theta)$, причём функция σ^2 непрерывна по θ. Тогда для любой $\theta \in \Theta$ выполнено

$$\sigma^2(\theta) \geqslant \frac{1}{i(\theta)}.$$

Кажется, что это вообще не похоже на неравенство Крамера—Рао, но это не так. Напомним несколько вещей.

- В неравенстве Крамера—Рао сказано, что

$$\mathrm{Var}_\theta\,\theta^* \geqslant \frac{(\tau'(\theta)^2)}{I_X(\theta)}.$$

- Нас интересует $\tau(\theta) = \theta$.
- $I_X(\theta) = ni(\theta)$.
- $\sigma^2(\theta)$ обезразмерена от n за счёт домножения отклонения $\theta^* - \theta$ на $\sqrt{n}$.

И вот теперь уже видно, что теорема Бахадура действительно является полным аналогом неравенства Крамера—Рао.

Если в теореме Бахадура для асимптотически нормальной оценки выполняется равенство для всех значений параметра, такая оценка называется **асимптотически эффективной**.

> Асимптотически эффективные оценки являются наилучшими в асимптотическом подходе к сравнению оценок в классе оценок с непрерывной асимптотической дисперсией.

Установим теперь асимптотическую эффективность ОМП.

ТЕОРЕМА 6.2.5

Пусть в условиях регулярности (R1–R7) уравнение правдоподобия имеет единственное решение при всех n и X. Тогда это решение является ОМП, и она является асимптотически эффективной.

Наконец, сформулируем дополнительные условия регулярности, на которые мы ссылались выше.

(R4) Обобщённая плотность p_θ трижды непрерывно дифференцируема по θ для любого $x \in \operatorname{supp} p_\theta$.

(R5) Функция $\theta \mapsto \int_{\operatorname{supp} p_\theta} p_\theta(x)\,dx$ трижды дифференцируема по θ под знаком интеграла.

(R6) Информация Фишера $i(\theta)$ одного элемента выборки строго положительна и конечна.

(R7) Для любой $\theta_0 \in \Theta$ найдётся такое $c > 0$ и такая функция $H = H(x)$, что для любой $\theta \in \Theta$ из c-окрестности параметра θ_0 выполнено

$$\left|\frac{\partial^3}{\partial\theta^3} \ln p_\theta(x)\right| \leqslant H(x)\ \forall x \in \operatorname{supp} p_\theta, \quad \text{и} \quad \mathrm{E}_\theta H(X_1) < \infty.$$

3. ОЦЕНКИ МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ ДЛЯ РАЗЛИЧНЫХ РАСПРЕДЕЛЕНИЙ

Здесь мы просто приведём несколько разных примеров на ОМП.

Пример 6.3.1. Рассмотрим модель $\mathrm{Bern}(p)$. Выборка состоит из независимых одинаково распределенных случайных величин $X_1, X_2, \ldots, X_n$, принимающих значения 1 (успех) с вероятностью p и 0 (неудача) с вероятностью $1 - p$. Функция плотности (закон распределения) для одного наблюдения имеет вид:

$$f(X_i) = p^{X_i}(1-p)^{1-X_i}.$$

Тогда функция правдоподобия для всей выборки равна произведению плотностей:

$$L(p) = \prod_{i=1}^{n} f(X_i) = \prod_{i=1}^{n} p^{X_i}(1-p)^{1-X_i} = \\ = p^{\sum_{i=1}^n X_i}(1-p)^{n-\sum_{i=1}^n X_i}.$$

Для упрощения максимизации возьмем натуральный логарифм (логарифмическую функцию правдоподобия):

$$\ln L(p) = \left(\sum_{i=1}^{n} X_i\right)\ln p + \left(n - \sum_{i=1}^{n} X_i\right)\ln(1-p).$$

Для поиска экстремума найдем частную производную по пара-

метру p и приравняем ее к нулю:

$$\frac{d\ln L}{dp} = \frac{\sum_{i=1}^{n} X_i}{p} - \frac{n - \sum_{i=1}^{n} X_i}{1-p} = 0.$$

Приведем дроби к общему знаменателю:

$$\frac{(1-p)\sum_{i=1}^{n} X_i - p\left(n - \sum_{i=1}^{n} X_i\right)}{p(1-p)} = 0.$$

Раскроем скобки в числителе:

$$\sum_{i=1}^{n} X_i - p\sum_{i=1}^{n} X_i - np + p\sum_{i=1}^{n} X_i = 0 \implies \sum_{i=1}^{n} X_i - np = 0.$$

Выражаем оценку $\hat{p}$:

$$np = \sum_{i=1}^{n} X_i \implies \hat{p} = \frac{1}{n}\sum_{i=1}^{n} X_i = \overline{X}.$$

Таким образом, итоговая оценка максимального правдоподобия для параметра распределения Бернулли равна выборочному среднему:

$$\hat{p}_{MLE} = \overline{X}.$$

Пример 6.3.2. Рассмотрим модель $\mathrm{Pois}(\lambda)$. Выборка состоит из независимых одинаково распределенных случайных величин $X_1, X_2, \ldots, X_n$, принимающих целые неотрицательные значения. Функция плотности (закон распределения) для одного наблюдения имеет вид:

$$f(X_i) = \frac{\lambda^{X_i} e^{-\lambda}}{X_i!}.$$

Тогда функция правдоподобия для всей выборки равна произведению плотностей:

$$L(\lambda) = \prod_{i=1}^{n} f(X_i) = \prod_{i=1}^{n} \frac{\lambda^{X_i} e^{-\lambda}}{X_i!} = \frac{\lambda^{\sum_{i=1}^{n} X_i} e^{-n\lambda}}{\prod_{i=1}^{n} X_i!}.$$

Для упрощения максимизации возьмем логарифмическую функцию правдоподобия:

$$\ln L(\lambda) = \left(\sum_{i=1}^{n} X_i\right)\ln\lambda - n\lambda - \ln\left(\prod_{i=1}^{n} X_i!\right).$$

Для поиска экстремума найдем производную по параметру λ и

приравняем ее к нулю:

$$\frac{d\ln L}{d\lambda} = \frac{\sum_{i=1}^{n} X_i}{\lambda} - n = 0.$$

Выражаем оценку $\hat{\lambda}$:

$$\frac{\sum_{i=1}^{n} X_i}{\lambda} = n \implies \hat{\lambda} = \frac{1}{n}\sum_{i=1}^{n} X_i = \overline{X}.$$

Таким образом, итоговая оценка максимального правдоподобия для параметра распределения Пуассона равна выборочному среднему:

$$\hat{\lambda}_{MLE} = \overline{X}.$$

Пример 6.3.3. Рассмотрим модель $\mathrm{Geom}(p)$ с числом неудач до первого успеха. Выборка состоит из независимых одинаково распределенных случайных величин $X_1, X_2, \ldots, X_n$, где X_i — количество неуспешных испытаний, предшествующих первому успеху. Функция плотности (закон распределения) для одного наблюдения имеет вид:

$$f(X_i) = (1-p)^{X_i} p.$$

Тогда функция правдоподобия для всей выборки равна:

$$L(p) = \prod_{i=1}^{n} f(X_i) = \prod_{i=1}^{n} (1-p)^{X_i} p = p^n (1-p)^{\sum_{i=1}^{n} X_i}.$$

Возьмем натуральный логарифм от функции правдоподобия:

$$\ln L(p) = n\ln p + \left(\sum_{i=1}^{n} X_i\right)\ln(1-p).$$

Для поиска экстремума найдем производную по параметру p и приравняем ее к нулю:

$$\frac{d\ln L}{dp} = \frac{n}{p} - \frac{\sum_{i=1}^{n} X_i}{1-p} = 0.$$

Приведем числитель уравнения к общему знаменателю:

$$\frac{n(1-p) - p\sum_{i=1}^{n} X_i}{p(1-p)} = 0.$$

Раскроем скобки в числителе:

$$n - np - p\sum_{i=1}^{n} X_i = 0.$$

Вынесем параметр p за скобки:

$$n - p\left(n + \sum_{i=1}^{n} X_i\right) = 0.$$

Выражаем оценку $\hat{p}$:

$$\hat{p} = \frac{n}{n + \sum_{i=1}^{n} X_i} = \frac{1}{1 + \frac{1}{n}\sum_{i=1}^{n} X_i} = \frac{1}{1 + \overline{X}}.$$

Таким образом, итоговая оценка максимального правдоподобия для параметра геометрического распределения имеет вид:

$$\hat{p}_{MLE} = \frac{1}{1 + \overline{X}}.$$

То есть, в знаменателе стоит среднее число экспериментов, считая финальный успешный.

Пример 6.3.4. Пусть выборка $X = (X_1, \ldots, X_n)$ состоит из независимых одинаково распределенных величин из нормального распределения $N(a, \sigma^2)$.

Функция плотности вероятности для одного наблюдения имеет вид:

$$f(x_i) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - a)^2}{2\sigma^2}}$$

Тогда функция правдоподобия для всей выборки равна:

$$L(a, \sigma^2) = \prod_{i=1}^{n} f(x_i) = \left(2\pi\sigma^2\right)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i - a)^2}.$$

Для упрощения максимизации возьмем натуральный логарифм (логарифмическую функцию правдоподобия):

$$\ln L(a, \sigma^2) = -\frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln(\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i - a)^2$$

Для поиска экстремума найдем частные производные по параметрам a и σ^2 и приравняем их к нулю.

Производная по параметру a:

$$\frac{\partial \ln L}{\partial a} = \frac{1}{\sigma^2}\sum_{i=1}^{n}(x_i - a) = 0$$

Производная по параметру σ^2:

$$\frac{\partial \ln L}{\partial (\sigma^2)} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2}\sum_{i=1}^{n}(x_i - a)^2 = 0$$

Из первого уравнения выражаем оценку $\hat{a}$:

$$\sum_{i=1}^{n} x_i - n\hat{a} = 0 \implies \hat{a} = \frac{1}{n}\sum_{i=1}^{n} x_i = \bar{x}$$

Подставляем полученное значение $\hat{a}$ во второе уравнение для поиска оценки $\hat{\sigma}^2$:

$$-\frac{n}{2\hat{\sigma}^2} + \frac{1}{2(\hat{\sigma}^2)^2}\sum_{i=1}^{n}(x_i - \hat{a})^2 = 0 \implies$$
$$\implies \frac{1}{2(\hat{\sigma}^2)^2}\sum_{i=1}^{n}(x_i - \hat{a})^2 = \frac{n}{2\hat{\sigma}^2}$$

Отсюда находим финальную оценку для дисперсии:

$$\hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \hat{a})^2$$

Таким образом, итоговые оценки максимального правдоподобия имеют вид:

$$\hat{a}_{MLE} = \overline{X}, \quad \hat{\sigma}^2_{MLE} = s^2 = \overline{(X - \overline{X})^2}.$$

Пример 6.3.5. Пусть выборка $X = (X_1, \ldots, X_n)$ состоит из независимых одинаково распределенных величин с плотностью распределения Лапласа:

$$f(x_i) = \frac{1}{2b}e^{-\frac{|x_i - a|}{b}}.$$

Тогда функция правдоподобия для всей выборки имеет вид:

$$L(a, b) = \prod_{i=1}^{n} f(x_i) = \frac{1}{(2b)^n}e^{-\frac{1}{b}\sum_{i=1}^{n}|x_i - a|}$$

Логарифмическая функция правдоподобия равна:

$$\ln L(a,b) = -n\ln(2) - n\ln(b) - \frac{1}{b}\sum_{i=1}^{n}|x_i - a|$$

Сначала найдем оценку для параметра сдвига a. Максимизация $\ln L(a,b)$ по a эквивалентна минимизации суммы абсолютных отклонений:

$$\min_a \sum_{i=1}^{n}|x_i - a|$$

Функция модуля не дифференцируема в точках x_i, однако известно, что сумма абсолютных отклонений достигает своего минимума в точке медианы выборки. Таким образом, оценкой максимального правдоподобия для a является выборочная медиана:

$$\hat{a}_{MLE} = \text{med}(X)$$

Теперь найдем оценку для параметра масштаба b. Подставим $\hat{a}$ в логарифмическую функцию правдоподобия, найдем производную по b и приравняем ее к нулю:

$$\frac{\partial \ln L}{\partial b} = -\frac{n}{b} + \frac{1}{b^2}\sum_{i=1}^{n}|x_i - \hat{a}| = 0$$

Умножая уравнение на b^2 и выражая $\hat{b}$, получаем:

$$n\hat{b} = \sum_{i=1}^{n}|x_i - \hat{a}| \implies \hat{b} = \frac{1}{n}\sum_{i=1}^{n}|x_i - \hat{a}|$$

Таким образом, итоговые оценки максимального правдоподобия имеют вид:

$$\hat{a}_{MLE} = \text{med}(X), \quad \hat{b}_{MLE} = \frac{1}{n}\sum_{i=1}^{n}|x_i - \text{med}(X)|$$

Пример 6.3.6. усть выборка состоит из независимых одинаково распределенных случайных величин $X_1, X_2, \ldots, X_n$. Функция плотности вероятности для одного наблюдения имеет вид:

$$f(X_i) = \frac{1}{b-a} \cdot \mathcal{I}\{a \leqslant X_i \leqslant b\}.$$

Тогда функция правдоподобия для всей выборки равна произве-

дению плотностей:

$$L(a,b) = \prod_{i=1}^{n} f(X_i) = \frac{1}{(b-a)^n} \cdot \prod_{i=1}^{n} \mathcal{I}\{a \leqslant X_i \leqslant b\}.$$

Условие того, что все элементы выборки лежат на отрезке $[a,b]$, эквивалентно тому, что минимальный элемент выборки не меньше a, а максимальный — не больше b. Перепишем функцию правдоподобия через порядковые статистики $X_{(1)} = \min(X_i)$ и $X_{(n)} = \max(X_i)$:

$$L(a,b) = \frac{1}{(b-a)^n} \cdot \mathcal{I}\{a \leqslant X_{(1)} \leqslant X_{(n)} \leqslant b\}.$$

Для максимизации функции $L(a,b)$ нам нужно сделать знаменатель $(b-a)^n$ как можно меньше при условии выполнения ограничений $a \leqslant X_{(1)}$ и $b \geqslant X_{(n)}$.

Знаменатель минимизируется, когда значение a максимизируется, а значение b минимизируется. С учетом ограничений получаем:

$$\hat{a}_{MLE} = X_{(1)} = \min_{1 \leqslant i \leqslant n} X_i$$

$$\hat{b}_{MLE} = X_{(n)} = \max_{1 \leqslant i \leqslant n} X_i$$

Таким образом, итоговые оценки максимального правдоподобия для границ равномерного распределения имеют вид:

$$\hat{a}_{MLE} = X_{(1)}, \quad \hat{b}_{MLE} = X_{(n)}.$$

Часть 7. Доверительные интервалы

В предыдущих главах вы строили *точечные* оценки: по выборке считали одно число — $\overline{X}$ для среднего, $\widehat{p}$ для доли, S^2 для дисперсии. Но одно число молчит о *своей надёжности*. Если по 50 заказам средний чек вышел $\overline{X} = 1240$ руб., то это 1240 ± 10 или 1240 ± 300? От ответа зависит, можно ли вообще на эту оценку опираться.

Доверительный интервал (ДИ) — это интервальная оценка: вместо точки мы выдаём *диапазон* $[L, U]$ и уровень уверенности (например, 95%), с которым этот диапазон накрывает истинное значение. Здесь L — нижняя граница (от англ. *lower*), U — верхняя (от англ. *upper*); это не случайные буквы, а просто «низ» и «верх» интервала.

В этой главе мы научимся строить ДИ *по формулам* для трёх главных величин — математического ожидания (§ 7.2), пропорции (§ 7.3) и *разности* средних между группами (§ 7.4), а заодно поймём, что значит «95%» на самом деле. Эти формулы выведены для простых статистик; что делать с медианой, перцентилем или отношением, у которых готовой формулы нет, — тема отдельной главы, посвящённой бутстрепу и методу Монте-Карло.

1. ИНТЕРВАЛЬНАЯ ОЦЕНКА И ДОВЕРИТЕЛЬНЫЙ ИНТЕРВАЛ

Интуиция. Точечная оценка — как выстрел в мишень одной пулей: попал или не попал, но по одной дырке не видно, насколько кучно стреляет винтовка. Интервальная оценка — это честное признание разброса: мы очерчиваем зону, в которую, скорее всего, попадает истина. Чем больше данных и чем меньше их разброс, тем у́же зона. *Доверие* $1-\alpha$ говорит, как часто такая зона не подведёт.

Пусть $X_1, \dots, X_n$ — выборка из распределения с неизвестным параметром θ.

ТЕОРЕМА 7.1.1

Пара статистик $L = L(X_1, \dots, X_n)$ (нижняя граница, англ. *lower*) и $U = U(X_1, \dots, X_n)$ (верхняя граница, англ. *upper*) задаёт *доверительный интервал уровня* $1-\alpha$ для θ, если

$$\mathsf{P}_\theta\left(L \leqslant \theta \leqslant U\right) \geqslant 1-\alpha \qquad \text{для всех } \theta.$$

Число $1-\alpha$ называют *доверительной вероятностью* (уровнем доверия); типичные значения — 0.95 и 0.99. Величина α — допустимая вероятность «промаха».

Ключевой момент: случайны *концы* L, U (они зависят от выборки), а параметр θ — фиксированное, хоть и неизвестное, число. Поэтому интервал «прыгает» от выборки к выборке, а истина стоит на месте.

ТЕОРЕМА 7.1.2

Надёжностью (англ. coverage probability) интервальной оценки с границами $L = L(X_1, \dots, X_n)$ и $U = U(X_1, \dots, X_n)$ называется вероятность того, что интервал накрывает истинный параметр:

$$\mathsf{P}_\theta\left(\theta \in [L, U]\right) = \mathsf{P}_\theta\left(L \leqslant \theta \leqslant U\right).$$

ТЕОРЕМА 7.1.3

Доверительным коэффициентом (англ. confidence coefficient) интервальной оценки $[L, U]$ называется наименьшая по параметру вероятность накрытия:

$$\inf_\theta \mathsf{P}_\theta\left(\theta \in [L, U]\right).$$

Это надёжность в наихудшем по θ случае: именно её интервал гарантирует при любом истинном θ. Если вероятность накры-

тия *не зависит* от θ (как у интервала $[\max, 2\max]$ для $U(0,\theta)$), она и есть доверительный коэффициент; если *зависит* (как у $[\max, \max+10]$) — коэффициент равен её инфимуму.

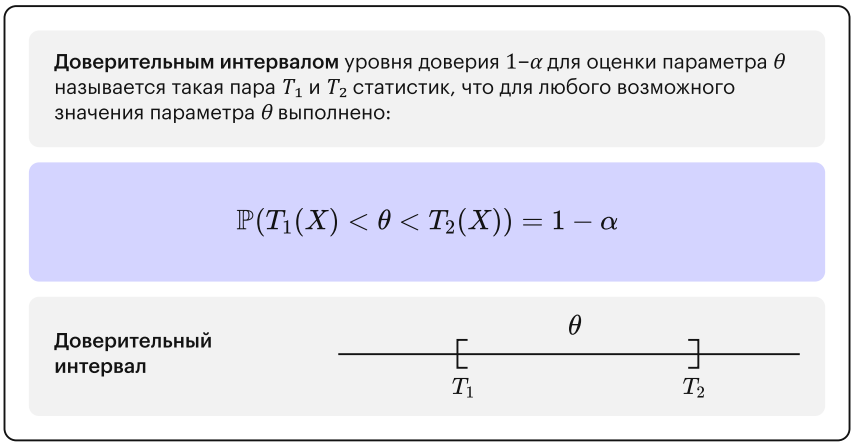

Рисунок 61. Доверительный интервал: пара статистик накрывает неизвестный параметр с заданной вероятностью.

Как читать «95%»: частотная интерпретация. Утверждение *не* означает «с вероятностью 0.95 параметр лежит в этом конкретном интервале» — параметр либо в нём, либо нет, никакой случайности тут уже не осталось. Правильное прочтение: *если повторять эксперимент много раз и каждый раз строить интервал по той же формуле, то около 95% построенных интервалов накроют истинное θ*. Рис. 62 показывает именно это.

Метод опорной величины (pivot). Общий рецепт построения ДИ. Найдём функцию $Q = Q(X_1, \ldots, X_n; \theta)$, зависящую и от данных, и от параметра, чьё *распределение не зависит от* θ (такую Q называют *опорной величиной*). Тогда по известному распределению Q берём квантили $q_{\alpha/2}, q_{1-\alpha/2}$ с

$$\mathrm{P}\left(q_{\alpha/2} \leqslant Q \leqslant q_{1-\alpha/2}\right) = 1 - \alpha,$$

после чего *разрешаем* двойное неравенство относительно θ — и границы по θ дают доверительный интервал. Все формулы этой главы — частные случаи этого приёма: для среднего опорной будет t-статистика, для пропорции — стандартизованная доля.

Второй способ построения: инверсия теста. Метод опорной величины — не единственный. Есть общий принцип, связывающий доверительные интервалы с проверкой гипотез: *доверительный интервал уровня $1-\alpha$ — это в точности множество тех значений θ_0, которые не отвергаются двусторонним тестом уровня α гипотезы $H_0 : \theta = \theta_0$*. Иначе говоря, «обратив» семейство тестов (взяв для данной выборки все значения параметра, не противоречащие ей), мы получаем доверительное множество. Эта *дуальность* работает в обе стороны и лежит в основе всей теории интервального оценивания; правило «накрывает ли ноль» из § 7.4 — её част-

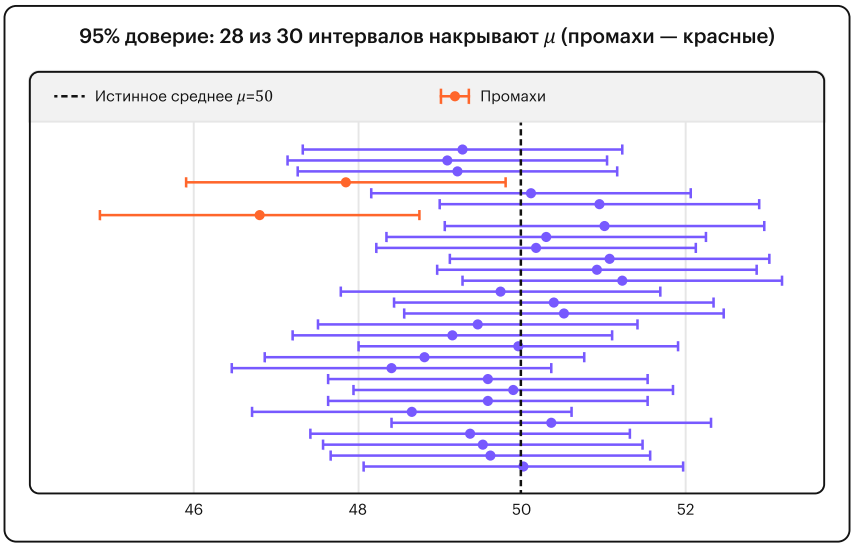

Рисунок 62. 30 выборок, по каждой свой 95%-й интервал; около 95% из них накрывают истинное μ (синие), промахи — красные.

ный случай.

Односторонние границы. Иногда нужен не двусторонний интервал, а *граница с одной стороны*: «конверсия *не ниже* $X\%$» или «время отклика *не выше* Y мс» с доверием $1-\alpha$. Тогда весь бюджет ошибки α относят на один хвост и берут квантиль $z_{1-\alpha}$ вместо $z_{1-\alpha/2}$. Например, нижняя доверительная граница для среднего равна

$$\overline{X} - z_{1-\alpha}\,\widehat{\mathrm{se}},$$

и эта граница накрывает μ снизу с нужным доверием:

$$\mathrm{P}\left(\mu \geqslant \overline{X} - z_{1-\alpha}\,\widehat{\mathrm{se}}\right) \geqslant 1-\alpha.$$

Для 95% берут

$$z_{0.95} \approx 1.64 \quad \text{вместо} \quad z_{0.975} \approx 1.96.$$

Односторонняя граница оказывается ближе к оценке, потому что мы спрашиваем лишь про одну сторону.

Пример 7.1.1. По выборке построен 95% ДИ для среднего чека: $[1180,\,1300]$ руб.

- *Неверно:* «истинный средний чек лежит в $[1180, 1300]$ с вероятностью 0.95». Истинный чек — число, оно либо в интервале, либо нет.
- *Верно:* «процедура, давшая этот интервал, в 95% повторений накрывает истинный средний чек». Содержательно мы *достаточно уверены*, что истина в этих пределах, и понимаем цену ошибки — 5%.

Практический вывод: интервал $[1180, 1300]$ исключает, например, гипотезу «средний чек $= 1000$» — её значение лежит вне интервала. И ещё одно частое заблуждение: доверительный интервал — это диапазон для *параметра* (среднего), а не для отдельных

наблюдений; он не обязан содержать 95% данных и не является *интервалом прогноза* для будущего чека.

Пример 7.1.2. Пусть $X_1, \dots, X_n$ н.о.р. $\sim U(0, \theta)$ с неизвестным параметром $\theta > 0$. Рассмотрим интервальную оценку с границами $L = \max\{X_1, \dots, X_n\}$ и $U = 2\max\{X_1, \dots, X_n\}$, то есть

$$\big[\, \max\{X_1, \dots, X_n\},\, 2\max\{X_1, \dots, X_n\} \,\big].$$

Найдём вероятность покрытия и доверительный коэффициент этого интервала.

Шаг 1 (переписываем событие покрытия). Обозначим $Y = \max\{X_1, \dots, X_n\}$. Покрытие означает $L \leqslant \theta \leqslant U$, то есть $Y \leqslant \theta \leqslant 2Y$. Разделив двойное неравенство на множители, получаем равносильное условие на Y:

$$\mathsf{P}_\theta\left(Y \leqslant \theta \leqslant 2Y\right) = \mathsf{P}_\theta\left(\tfrac{\theta}{2} \leqslant Y \leqslant \theta\right).$$

Шаг 2 (распределение максимума, с выводом). Откуда берётся плотность максимума? Удобнее сначала найти его *функцию распределения*. Событие $\{Y \leqslant y\}$ означает, что *все* наблюдения не превосходят y; в силу независимости вероятность произведения равна произведению вероятностей:

$$F_Y(y) = \mathsf{P}\left(Y \leqslant y\right) = \mathsf{P}\left(X_1 \leqslant y, \dots, X_n \leqslant y\right) = \\ = \prod_{i=1}^{n} \mathsf{P}\left(X_i \leqslant y\right) = \left(\frac{y}{\theta}\right)^n, \qquad y \in [0, \theta],$$

поскольку для $U(0,\theta)$ функция распределения одного наблюдения равна $\mathsf{P}(X_i \leqslant y) = y/\theta$ на $[0,\theta]$. Дифференцируя F_Y по y, получаем плотность максимума:

$$f_Y(y) = F_Y'(y) = \frac{d}{dy}\frac{y^n}{\theta^n} = \frac{n}{\theta^n}\, y^{n-1}, \qquad y \in [0, \theta],$$

где n — объём выборки. (Здесь $Y \leqslant \theta$ всегда, поэтому правая граница θ достигается с вероятностью 1, и условие сводится к $Y \geqslant \theta/2$.)

Шаг 3 (интегрирование). Подставляем плотность и считаем вероятность:

$$\mathsf{P}_\theta\left(\tfrac{\theta}{2} \leqslant Y \leqslant \theta\right) = \int_{\theta/2}^{\theta} \frac{n}{\theta^n}\, y^{n-1}\, dy = \\ = \frac{1}{\theta^n}\left(\theta^n - \left(\tfrac{\theta}{2}\right)^n\right) = 1 - \frac{1}{2^n}.$$

Шаг 4 (доверительный коэффициент). Полученная вероятность $1 - 2^{-n}$ *не зависит* от θ: каким бы ни было истинное значение параметра, интервал накрывает его с одной и той же вероятно-

стью. Поэтому эта величина и есть доверительный коэффициент данной интервальной оценки (достигаемая доверительная вероятность):

$$\mathsf{P}_\theta\left(L \leqslant \theta \leqslant U\right) = 1 - \frac{1}{2^n} \qquad \text{для всех } \theta.$$

Шаг 5 (читаем). Доверие растёт с объёмом выборки: чем больше n, тем ближе $\max$ к истинному θ и тем надёжнее накрытие. Например, при $n = 4$ доверительный коэффициент равен

$$1 - \frac{1}{2^4} = 1 - \frac{1}{16} = 0.9375,$$

то есть интервал $\left[\max,\, 2\max\right]$ накрывает θ примерно в 93.75% повторений. Конкретно: если по выборке объёма $n = 4$ наблюдаемый максимум дал интервал $[2, 4]$, то вероятность события $\theta \in [2, 4]$ для процедуры, его породившей, равна 0.9375.

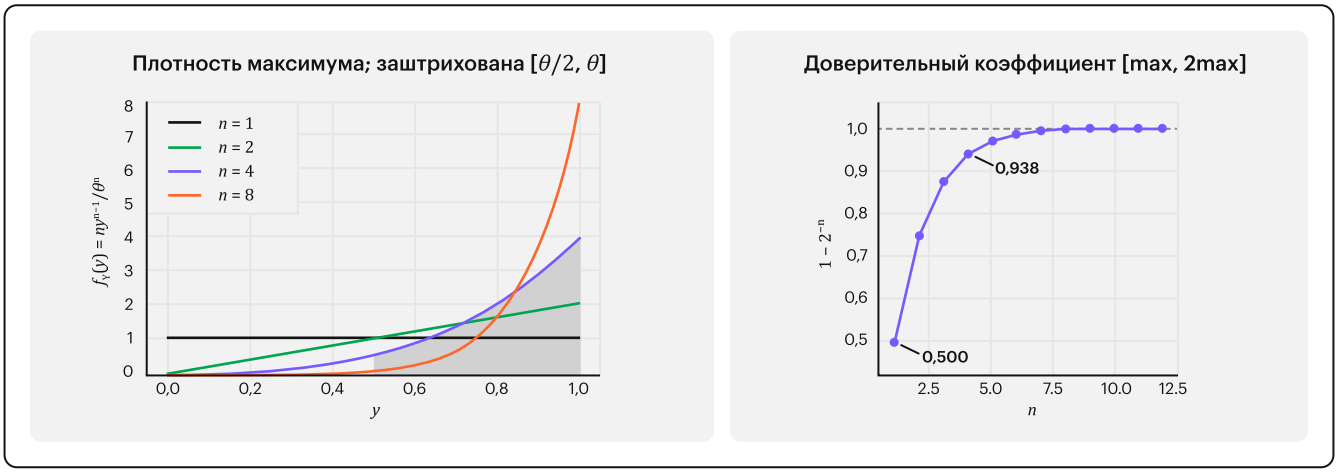

Рисунок 63. Плотность максимума $f_Y(y) = n\,y^{n-1}/\theta^n$ и рост доверительного коэффициента $1 - 2^{-n}$ с n.

Пример 7.1.3. Пусть $X_1, \ldots, X_n \sim U(0, \theta)$ с неизвестным параметром $\theta > 0$. Рассмотрим интервальную оценку

$$\left[\, \max\{X_1, \ldots, X_n\},\ \max\{X_1, \ldots, X_n\} + 10 \,\right]$$

и найдём её *вероятность накрытия* (coverage probability) и *доверительный коэффициент* (наименьшую по θ вероятность накрытия). Обозначим $Y = \max\{X_1, \ldots, X_n\}$.

Шаг 1 (вероятность накрытия). По определению накрытие — это событие, что концы зажимают истинное θ:

$$\mathsf{P}_\theta\left(Y \leqslant \theta \leqslant Y + 10\right) = \mathsf{P}_\theta\left(\theta - 10 \leqslant Y \leqslant \theta\right).$$

Правое неравенство $Y \leqslant \theta$ выполнено всегда (максимум выборки из $U(0, \theta)$ не превосходит θ), поэтому осталось лишь условие $Y \geqslant \theta - 10$.

Шаг 2 (плотность максимума). Максимум Y имеет плотность $f_Y(y) = \dfrac{n}{\theta^n}\, y^{n-1}$ на $[0, \theta]$ (это плотность n-й порядковой статистики для $U(0,\theta)$). Интегрируем её по интересующему диапазону:

$$\mathsf{P}_\theta\left(\theta - 10 \leqslant Y \leqslant \theta\right) = \int_{\theta-10}^{\theta} \frac{n}{\theta^n}\, y^{n-1}\, dy.$$

Шаг 3 (интеграл). Первообразная $\dfrac{n}{\theta^n}\, y^{n-1}$ равна $\dfrac{y^n}{\theta^n}$, откуда

$$\int_{\theta-10}^{\theta} \frac{n}{\theta^n}\, y^{n-1}\, dy = \frac{1}{\theta^n}\Big(\theta^n - (\theta-10)^n\Big) = 1 - \Big(1 - \tfrac{10}{\theta}\Big)^n.$$

(Запись через $\theta - 10$ предполагает $\theta \geqslant 10$; при $\theta < 10$ нижний предел заменяется нулём и накрытие равно 1.)

Шаг 4 (доверительный коэффициент). Полученная вероятность *зависит от* θ — это не константа. Поэтому надёжность интервала (доверительный коэффициент) — это *наименьшее* её значение по всем допустимым θ:

$$\inf_{\theta>0}\, \mathsf{P}_\theta\left(Y \leqslant \theta \leqslant Y + 10\right) = \inf_{\theta \geqslant 10}\Big[1 - \Big(1 - \tfrac{10}{\theta}\Big)^n\Big].$$

Функция $1 - (1 - 10/\theta)^n$ убывает с ростом θ (чем больше θ, тем «реже» Y попадает в последний отрезок длины 10), и при $\theta \to \infty$ её значение стремится к нулю.

Шаг 5 (вывод). Инфимум достигается в пределе $\theta \to \infty$ и равен 0. Значит, интервал $[\max,\ \max+10]$ *не* гарантирует никакого положительного уровня доверия: для достаточно большого θ его вероятность накрытия как угодно мала. Содержательно: фиксированная добавка 10 не зависит от масштаба данных, а при большом θ максимум выборки оказывается далеко от θ, и интервал систематически промахивается. Чтобы получить честный доверительный интервал уровня $1 - \alpha$, ширину нужно привязывать *к самим данным* (например, к Y), а не брать постоянной.

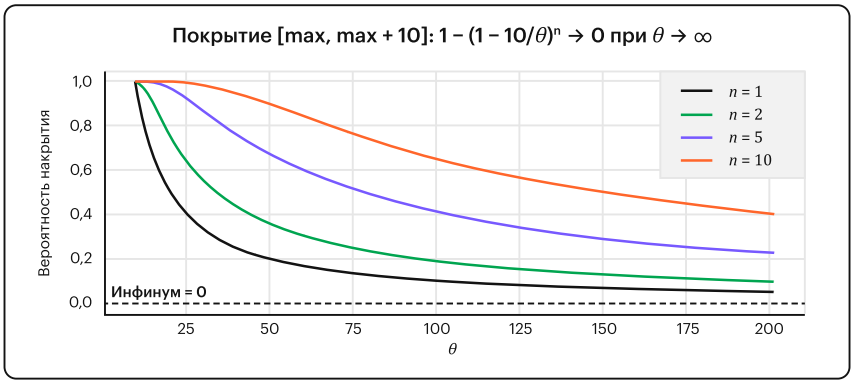

Рисунок 64. Вероятность накрытия интервала $[\max, \max+10]$ убывает с ростом θ к нулю.

Пример 7.1.4. Снова рассмотрим модель $U(0,\theta)$. Здесь точ-

ный интервал через неравенства уклонений не построить: нужна оценка параметра θ, у которой распределение выписывается явно. Возьмём максимум выборки $X_{(n)} = \max(X_1, \dots, X_n)$ и применим метод опорной величины (§ 7.1).

Шаг 1 (распределение статистики). На отрезке $[0, \theta]$ функция распределения максимума равна

$$F(x) = \mathsf{P}\left(X_{(n)} \leqslant x\right) = \frac{x^n}{\theta^n}.$$

Шаг 2 (α-квантиль). Решая $F(z_\alpha) = \alpha$, находим

$$z_\alpha = \theta\, \alpha^{1/n}.$$

Шаг 3 (пара квантилей). Возьмём две квантили (z_α, z_β) так, чтобы $\beta - \alpha = \gamma$; они и образуют точный ДИ уровня γ. А именно,

$$\theta\, \alpha^{1/n} = z_\alpha < X_{(n)} < z_\beta = \theta\, \beta^{1/n},$$

причём $\mathsf{P}\left(z_\alpha < X_{(n)} < z_\beta\right) = \beta - \alpha = \gamma$.

Шаг 4 (разрешаем относительно θ). Из двойного неравенства получаем доверительный интервал уровня γ:

$$X_{(n)}\, \beta^{-1/n} < \theta < X_{(n)}\, \alpha^{-1/n}.$$

Шаг 5 (выбор кратчайшего). Какой же из этих интервалов взять? Обычно выбирают как можно более короткий. На рис. 65 видно, что график квантили сначала резко возрастает, а потом идёт более плавно; поэтому выгодно сдвигать ДИ как можно ближе к единице. Самым коротким будет интервал, отвечающий $\alpha = 1 - \gamma$ и $\beta = 1$.

Шаг 6 (вывод). Подставляя эти значения, получаем кратчайший точный ДИ уровня γ:

$$X_{(n)} < \theta < X_{(n)}\, (1 - \gamma)^{-1/n}.$$

Левый конец — сама оценка $X_{(n)}$: истинное θ не меньше уже наблюдённого максимума, а правый конец отступает от него вверх ровно настолько, чтобы накрытие составляло γ.

Почему кратчайший интервал отвечает $\alpha = 1 - \gamma$, $\beta = 1$. Длина ДИ из Шага 4 равна $X_{(n)}\left(\alpha^{-1/n} - \beta^{-1/n}\right)$, а при связи $\beta = \alpha + \gamma$ зависит лишь от α:

$$L(\alpha) \;\propto\; \alpha^{-1/n} - (\alpha + \gamma)^{-1/n}, \qquad \alpha \in [0,\, 1 - \gamma].$$

Так как $L'(\alpha) = \frac{1}{n}\left[(\alpha + \gamma)^{-1/n - 1} - \alpha^{-1/n - 1}\right] < 0$ (степень $x^{-1/n-1}$ убывает, а $\alpha + \gamma > \alpha$), функция L строго убывает по α. Значит, минимум достигается на правом краю $\alpha = 1 - \gamma$, то есть

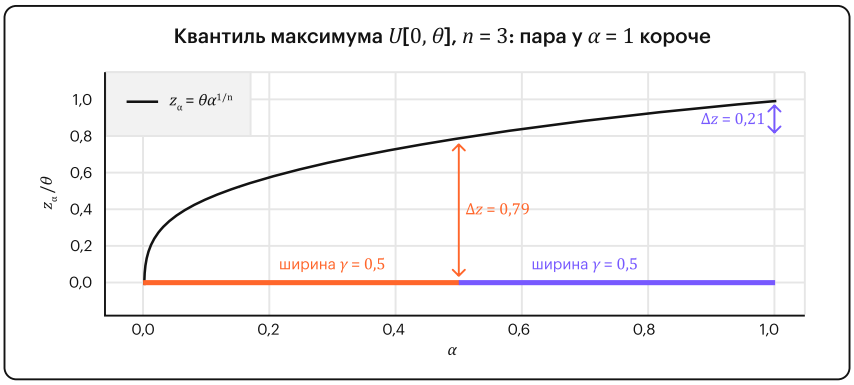

Рисунок 65. Квантиль $z_\alpha = \theta\,\alpha^{1/n}$ для $U(0,\theta)$: круто у нуля, полого у единицы.

$\beta = 1$. Геометрически это ровно тот эффект, что виден на рис. 65: плотность максимума $f(x) = nx^{n-1}/\theta^n$ растёт к θ, поэтому у единицы квантили $z_\alpha = \theta\alpha^{1/n}$ лежат гуще, и пара одного и того же «веса» γ, прижатая к $\alpha = 1$, отсекает по θ самый узкий отрезок.

2. ДОВЕРИТЕЛЬНЫЙ ИНТЕРВАЛ ДЛЯ МАТЕМАТИЧЕСКОГО ОЖИДАНИЯ

Интуиция. Среднее по выборке $\overline{X}$ само случайно: возьми другую выборку — получишь другое $\overline{X}$. По *центральной предельной теореме* его разброс вокруг истинного μ имеет масштаб $\sigma/\sqrt{n}$ — это стандартная ошибка среднего. Доверительный интервал просто откладывает несколько таких стандартных ошибок влево и вправо от $\overline{X}$.

Дальше всё зависит от одного вопроса: *известна ли нам дисперсия* σ^2? Если да — работает нормальный (z-) интервал; если нет (а так почти всегда) — её заменяют выборочной оценкой, и появляется распределение Стьюдента (t-интервал). Разберём оба случая по очереди.

Известная дисперсия: z-интервал

Пусть $X_1, \ldots, X_n$ н.о.р. с $\mathbb{E}X_i = \mu$, $\operatorname{Var} X_i = \sigma^2$, причём σ *известна* (например, задана точностью прибора или взята из длинной истории наблюдений). Опорная величина —

$$Z = \frac{\overline{X} - \mu}{\sigma/\sqrt{n}} \;\sim\; N(0,1) \tag{3}$$

(точно — если X_i нормальны; асимптотически — по ЦПТ для любых X_i с конечной дисперсией).

Отсюда $\mathrm{P}\left(|Z| \leqslant z_{1-\alpha/2}\right) = 1 - \alpha$, где $z_{1-\alpha/2} = \Phi^{-1}(1-\alpha/2)$ — квантиль стандартного нормального. Разрешая неравенство

относительно μ, получаем интервал уровня $1-\alpha$:

$$\overline{X} \pm z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}}, \qquad z_{0.975} \approx 1.96 \ (95\%). \tag{4}$$

Согласно центральной предельной теореме:

$$\frac{\overline{X}-\mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0,1)$$

Построим доверительный интервал (CI)

Confidence Interval

$$z_{\frac{\alpha}{2}} \leq \frac{\overline{X}-\mu}{\frac{\sigma}{\sqrt{n}}} \leq z_{1-\frac{\alpha}{2}}$$

Рисунок 66. Интервал для среднего как следствие ЦПТ: $\overline{X}$ приближённо нормально вокруг μ.

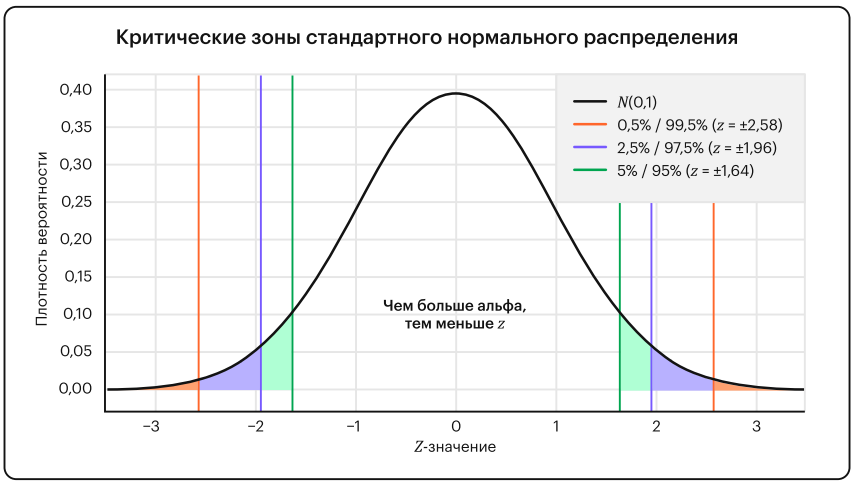

Рисунок 67. Квантили стандартного нормального: 1.64 (90%), 1.96 (95%), 2.58 (99%).

Пример 7.2.1. Прибор измеряет некоторую величину; из калибровки известно, что разброс одного измерения — $\sigma = 4$ единицы (то есть *известная* дисперсия $\sigma^2 = 16$). По $n = 25$ измерениям получено $\overline{X} = 50.2$. Построим 95% ДИ для истинного значения μ.

Шаг 1 (стандартная ошибка). При известном σ стандартная ошибка среднего равна

$$\frac{\sigma}{\sqrt{n}} = \frac{4}{\sqrt{25}} = \frac{4}{5} = 0.8.$$

Шаг 2 (квантиль). Для 95% берём нормальный квантиль $z_{0.975} \approx 1.96$ — никакой поправки на оценивание дисперсии не требуется, ведь σ дано.

Шаг 3 (интервал). По формуле (4)

$$\overline{X} \pm z_{0.975}\frac{\sigma}{\sqrt{n}} = 50.2 \pm 1.96 \cdot 0.8 = 50.2 \pm 1.568,$$

то есть $[48.63,\ 51.77]$.

Шаг 4 (читаем). Мы достаточно уверены, что истинное μ лежит в $[48.63,\ 51.77]$. Интервал *симметричен* и опирается на нормальный квантиль: пока σ известна, распределение Стьюдента не возникает. Но стоит отказаться от знания σ и заменить его выборочным S — а так бывает почти всегда, — на смену z придёт t (следующий пункт).

Сколько нужно наблюдений? Часто вопрос ставят наоборот: какой объём выборки n обеспечит интервал с заданной *полушириной* (предельной ошибкой) Δ? Из равенства $\Delta = z_{1-\alpha/2}\sigma/\sqrt{n}$ сразу следует

$$n \geqslant \left(\frac{z_{1-\alpha/2}\,\sigma}{\Delta}\right)^2. \tag{5}$$

Дисперсию σ^2 берут из пилота, истории или прошлых экспериментов. Точность входит *в квадрате*: вдвое более узкий интервал стоит вчетверо большей выборки.

Для *доли* аналогично $n \geqslant z^2_{1-\alpha/2}\,p(1-p)/\Delta^2$, а худший случай $p = \frac{1}{2}$ даёт удобную оценку сверху $n \geqslant z^2_{1-\alpha/2}/(4\Delta^2)$ (для 95% и $\Delta = 0.03$ это ≈ 1068). Это и есть основа планирования размера выборки в A/B-тестах — отсюда же растёт понятие минимального детектируемого эффекта (MDE).

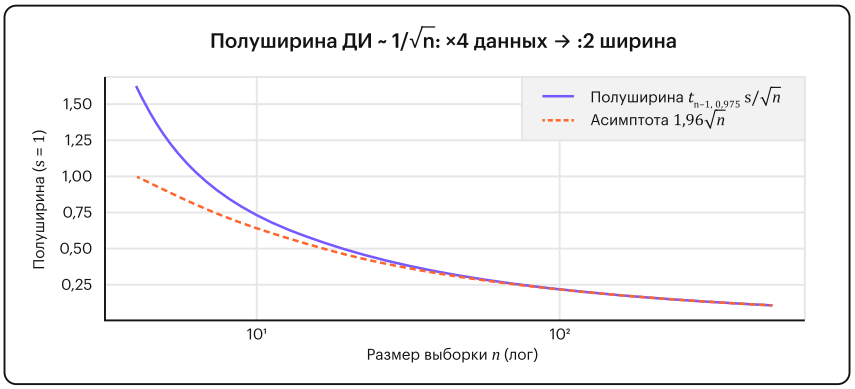

Рисунок 68. Полуширина интервала для среднего убывает как $1/\sqrt{n}$.

Неизвестная дисперсия: t-интервал

На практике σ почти никогда не известна — её заменяют выборочным стандартным отклонением $S = \sqrt{\frac{1}{n-1}\sum_i (X_i - \overline{X})^2}$. Но тогда в знаменателе (3) стоит *случайная* величина, и нормального распределения уже нет — появляется *распределение Стьюдента*.

ТЕОРЕМА 7.2.1

Если $X_1, \dots, X_n$ н.о.р. $\sim N(\mu, \sigma^2)$, то

$$T = \frac{\overline{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$$

— распределение Стьюдента с $n-1$ степенью свободы.

Идея доказательства Доказательство. Для нормальной выборки $\overline{X} \sim N(\mu, \sigma^2/n)$, а $(n-1)S^2/\sigma^2 \sim \chi^2_{n-1}$, причём $\overline{X}$ и S^2 *независимы* (это специальное свойство нормального закона, доказанное ранее в блоке о точечных оценках). По определению t-распределение — это отношение $N(0,1)\big/\sqrt{\chi^2_{n-1}/(n-1)}$ независимых числителя и знаменателя; подставив $Z = (\overline{X} - \mu)/(\sigma/\sqrt{n})$ и $(n-1)S^2/\sigma^2$, ровно его и получаем (множители σ сокращаются). □

Отсюда доверительный интервал уровня $1-\alpha$ для среднего:

$$\overline{X} \pm t_{n-1,\,1-\alpha/2}\,\frac{S}{\sqrt{n}}. \tag{6}$$

Квантиль $t_{n-1,1-\alpha/2}$ больше нормального $z_{1-\alpha/2}$ — это «плата» за незнание σ: интервал чуть шире (рис. 69). С ростом n распределение Стьюдента стягивается к нормальному, и t-интервал переходит в z-интервал.

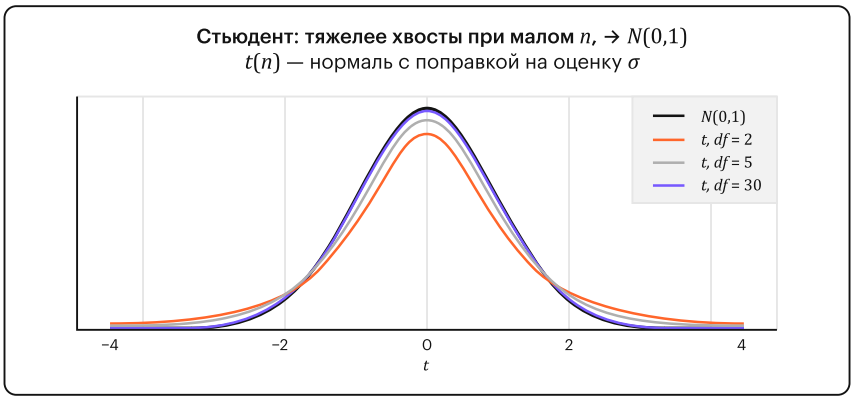

Рисунок 69. Распределение Стьюдента против $N(0,1)$: при малом n хвосты тяжелее.

Пример 7.2.2. По $n = 16$ замерам время отклика сервиса дало $\overline{X} = 220$ мс и $S = 40$ мс. Построим 95% ДИ.

Шаг 1 (стандартная ошибка). $\widehat{\mathrm{se}} = S/\sqrt{n} = 40/4 = 10$ мс.

Шаг 2 (квантиль). Для $n-1 = 15$ степеней свободы $t_{15,0.975} \approx 2.131$ (по таблице/функции `stats.t.ppf`).

Шаг 3 (интервал). $220 \pm 2.131 \cdot 10 = 220 \pm 21.3$, то есть $[198.7,\ 241.3]$ мс.

Шаг 4 (читаем). Мы достаточно уверены, что среднее время отклика лежит между ≈ 199 и ≈ 241 мс. Если бы взяли σ известной и нормальный квантиль 1.96, интервал был бы чуть у́же

(220 ± 19.6) — разница и есть цена незнания σ при небольшом n.

нужна ли нормальность

ЗАМЕЧАНИЕ

Теорема 7.2.1 выведена для *нормальной* выборки. Но на практике t-интервал применяют гораздо шире: при большом n по *центральной предельной теореме* $\overline{X}$ приближённо нормально *независимо* от формы исходного распределения, а S состоятельно оценивает σ, так что (6) даёт асимптотически корректный интервал. Осторожность нужна при *малых* выборках из сильно скошенных или тяжелохвостых распределений (типичный случай — выручка, чеки): там нормальное приближение для среднего работает плохо. Практическое предостережение: расхожее «правило $n \geqslant 30$» для таких данных обманчиво — чтобы t-интервал держал заявленное покрытие на сильно скошенном распределении, нередко требуются выборки в *тысячи* наблюдений. В этих случаях честнее перейти к бутстрепу (ему посвящена отдельная глава), причём к интервалам, корректирующим асимметрию (BCa, студентизированный), а не к простейшему перцентильному.

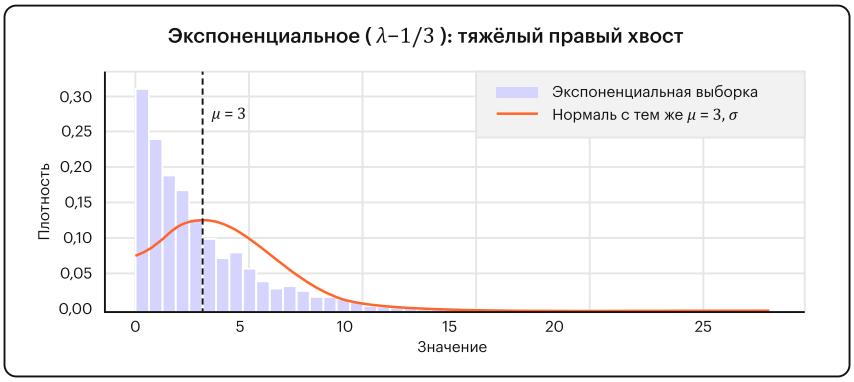

Рисунок 70. Скошенное экспоненциальное ($\lambda = 1/3$) против нормальной кривой того же среднего и разброса.

Пример 7.2.3. Возьмём выборку $\{2.5, 3.1, 4.0, 2.8, 3.5\}$ из экспоненциального распределения с параметром $\lambda = 1/3$. Истинное среднее тогда $\mu = 1/\lambda = 3$, но и μ, и λ мы считаем неизвестными. Это распределение асимметрично и ненормально, с тяжёлым правым хвостом — как раз тот случай, о котором предупреждает замечание о ненормальности выше. По выборке имеем $\overline{X} \approx 3.18$, $S \approx 0.58$, $n = 5$.

Хотя n совсем мало, применим аппарат *для иллюстрации*. По ЦПТ стандартизованное среднее

$$\frac{\overline{X} - \mu}{S/\sqrt{n}} \xrightarrow{d} N(0,1)$$

лишь *асимптотически*, поэтому к выводам на $n = 5$ относимся с осторожностью.

Шаг 1 (стандартная ошибка). $\widehat{\mathrm{se}} = S/\sqrt{n} \approx 0.58/\sqrt{5} \approx 0.26$.

Шаг 2 (z-интервал по ЦПТ). Для 95% берём $z_{0.975} \approx 1.96$:

$$3.18 \;\pm\; 1.96 \cdot \frac{0.58}{\sqrt{5}} \;\approx\; [2.67,\, 3.69].$$

Интервал накрывает истинное $\mu = 3$. Но при малом n и ненормальном законе нормальное приближение неточно (тяжёлый хвост экспоненциального искажает поведение оценки разброса), так что заявленному покрытию 95% здесь верить нельзя.

Шаг 3 (t-интервал, поправка на малую выборку). Заменив нормальный квантиль на стьюдентов с $n - 1 = 4$ степенями свободы, $t_{4,\,0.975} \approx 2.776$, получаем по (6):

$$3.18 \;\pm\; 2.776 \cdot \frac{0.58}{\sqrt{5}} \;\approx\; [2.46,\, 3.90].$$

Интервал стал *шире* — это и есть «плата» за незнание σ и за малый объём выборки: больший квантиль честнее отражает накопившуюся неопределённость.

Шаг 4 (рост n). Возьмём ту же экспоненциальную модель, но $n = 100$; пусть выборка дала $\overline{X} \approx 3.05$, $S \approx 3.02$. Тогда z-интервал по ЦПТ:

$$3.05 \;\pm\; 1.96 \cdot \frac{3.02}{\sqrt{100}} \;\approx\; [2.46,\, 3.64],$$

и центр уже заметно ближе к $\mu = 3$, а приближение ЦПТ работает надёжнее.

Шаг 5 (вывод). ЦПТ позволяет строить интервал для среднего *любого* распределения при большом n — нормальность исходных X_i не требуется. Но при малом n или сильной асимметрии (как здесь, на $n = 5$) такому интервалу доверять опасно: честнее перейти к бутстрепу, которому посвящена отдельная глава.

Пример 7.2.4. Рассмотрим выборку из распределения $N(a, \sigma^2)$, где теперь дисперсия σ^2 *неизвестна*; оценить по-прежнему нужно параметр a. Покажем, как замена σ выборочным отклонением превращает нормальную опорную величину в стьюдентову и приводит к t-интервалу.

Шаг 1 (нормальная опорная величина). Как мы помним, при известной σ

$$\sqrt{n}\,\frac{\overline{X} - a}{\sigma} \;\sim\; N(0, 1).$$

Шаг 2 (замена дисперсии). Раз σ^2 неизвестна, заменим её несмещённой выборочной дисперсией

$$s^2 := \frac{n}{n-1}\left(\overline{X^2} - \overline{X}^2\right).$$

Шаг 3 (распределение Стьюдента). Тогда как раз

$$\sqrt{n}\,\frac{\overline{X}-a}{s} = \sqrt{n}\,\frac{\overline{X}-a}{\sigma}\cdot\frac{\sigma}{s} \;\sim\; t_{n-1}.$$

Числитель даёт стандартную нормальную величину из шага 1, а множитель σ/s — это $1/\sqrt{s^2/\sigma^2} = \sqrt{(n-1)/\chi^2_{n-1}}$, то есть *обратный* корень из масштабированного χ^2 с $n-1$ степенью свободы; их отношение и есть распределение Стьюдента с $n-1$ степенью свободы.

Шаг 4 (доверительный интервал). Выбирая квантили $t_{\frac{1+\gamma}{2}}$ и $t_{\frac{1-\gamma}{2}} = -t_{\frac{1+\gamma}{2}}$ распределения Стьюдента t_{n-1} и разрешая двойное неравенство относительно a, находим ДИ уровня γ:

$$a \in \left(\overline{X} - \frac{s\cdot t_{\frac{1+\gamma}{2}}}{\sqrt{n}},\; \overline{X} + \frac{s\cdot t_{\frac{1+\gamma}{2}}}{\sqrt{n}}\right).$$

Шаг 5 (вывод). По сути, дисперсию мы заменили на выборочную, а квантили нормального закона — на квантили Стьюдента. Эта замена стоит дороже при малых n: например, при $n=2$ для $\gamma = 90\%$ квантиль примерно равна 6.314, что сильно удлиняет интервал; а уже при $n=100$ квантиль равна всего лишь примерно 1.660, что очень похоже на квантиль нормального 1.645.

Почему это и есть Стьюдент. По определению t_{n-1} — это распределение отношения

$$t_{n-1} = \frac{Z}{\sqrt{V/(n-1)}}, \qquad Z \sim N(0,1),$$

$V \sim \chi^2{}_{n-1}$, причём Z и V *независимы*.

Сверим Шаг 3 с этим шаблоном. Числитель $\sqrt{n}\,(\overline{X}-a)/\sigma = Z \sim N(0,1)$. Знаменатель: $s^2/\sigma^2 = V/(n-1)$ с $V = (n-1)s^2/\sigma^2 \sim \chi^2_{n-1}$ (это опорная величина для дисперсии), так что $\sqrt{s^2/\sigma^2} = \sqrt{V/(n-1)}$. Остаётся последнее, но решающее условие определения — *независимость*: для нормальной выборки $\overline{X}$ и s^2 независимы, поэтому независимы и Z со знаменателем. Все три требования выполнены, и отношение по определению есть t_{n-1} — никакой дополнительной проверки не нужно.

3. ДОВЕРИТЕЛЬНЫЙ ИНТЕРВАЛ ДЛЯ ПРОПОРЦИИ

Интуиция. Доля (конверсия, CTR, доля довольных) — это среднее из нулей и единиц: $\widehat{p} = \frac{1}{n}\sum_i X_i$, где $X_i \in \{0,1\}$. Значит к ней применима та же логика, что и к среднему, только дисперсия одного наблюдения известна через саму долю: $\operatorname{Var} X_i = p(1-p)$.

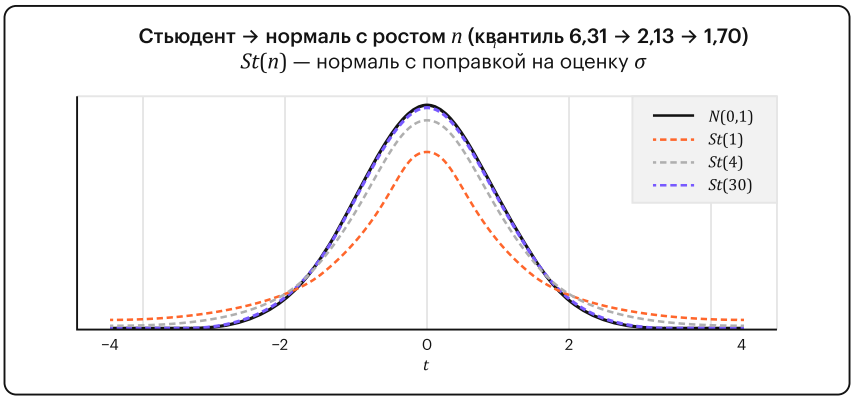

Рисунок 71. Стьюдент против нормального: с ростом n хвосты стягиваются.

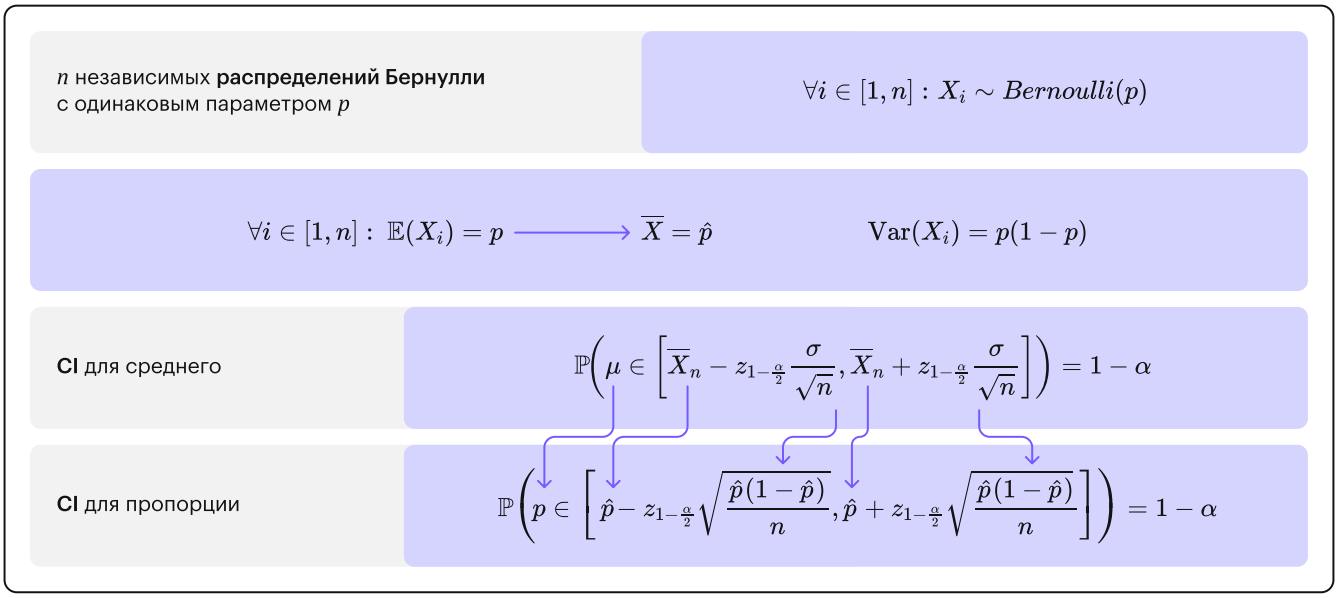

Рисунок 72. Доля — среднее из нулей и единиц; интервал строится тем же приёмом, что и для среднего.

Интервал Вальда (нормальное приближение). Пусть $X_1, \ldots, X_n$ н.о.р. $\sim \mathrm{Bernoulli}(p)$, $\widehat{p} = \frac{1}{n}\sum_i X_i$. По ЦПТ

$$\frac{\widehat{p} - p}{\sqrt{p(1-p)/n}} \xrightarrow{d} N(0,1),$$

а заменив в знаменателе неизвестное p на $\widehat{p}$ (законно по лемме Слуцкого), получаем простейший интервал уровня $1-\alpha$:

$$\widehat{p} \pm z_{1-\alpha/2}\sqrt{\frac{\widehat{p}(1-\widehat{p})}{n}}. \qquad (7)$$

Чем обманчив Вальд и чем его заменить. Интервал (7) удобен, но его покрытие *обманчиво*. Дело не только в краях (при $\widehat{p}$ близко к 0 или 1) и малом n, где интервал даже вылезает за $[0,1]$: реальная вероятность накрытия *осциллирует* и для умеренных p, скач-

кообразно завися от n, и систематически оказывается ниже заявленных 95%. Поэтому интервал Вальда не стоит брать как основной — ему есть лучшие замены (ниже).

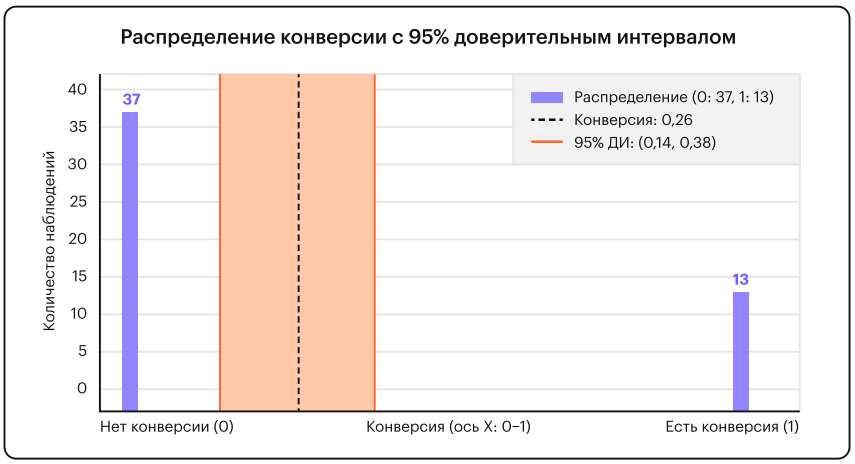

Рисунок 73. Интервал для конверсии: из 50 визитов 13 покупок, $\widehat{p} = 0.26$, ДИ $(0.14, 0.38)$.

Интервал Уилсона. Лучшее поведение даёт другой выбор опорной величины: оставим в знаменателе *истинное* p и решим неравенство $\left|(\widehat{p} - p)/\sqrt{p(1-p)/n}\right| \leqslant z$ *относительно* p как квадратное. Это и есть интервал Уилсона с центром и полушириной

$$\text{центр} = \frac{\widehat{p} + \dfrac{z^2}{2n}}{1 + \dfrac{z^2}{n}}, \text{полуширина} = \frac{z}{1 + \dfrac{z^2}{n}} \sqrt{\frac{\widehat{p}(1-\widehat{p})}{n} + \frac{z^2}{4n^2}}, \quad (8)$$

где $z = z_{1-\alpha/2}$. Интервал Уилсона *всегда* лежит в $[0, 1]$, точнее держит покрытие при малых n и у краёв (рис. 74), слегка смещая центр от $\widehat{p}$ к $1/2$. Именно его (а не Вальда) стоит брать по умолчанию для конверсий в A/B. При больших n и $\widehat{p}$ вдали от краёв оба интервала практически совпадают. *Поправка на непрерывность* (расширение на $\pm\frac{1}{2n}$) ещё аккуратнее учитывает дискретность доли, но для больших выборок ею обычно пренебрегают.

Почему здесь решаем квадратное относительно p. В интервале Вальда неизвестное p в знаменателе опорной величины заменяют оценкой $\widehat{p}$ (приём Слуцкого) — и интервал получается линейным по p, симметричным $\widehat{p} \pm z\,\widehat{\mathrm{se}}$. Уилсон же *ничего не подставляет*: он оставляет истинное p под корнем. Тогда событие

$$\left|\frac{\widehat{p} - p}{\sqrt{p(1-p)/n}}\right| \leqslant z \iff (\widehat{p} - p)^2 \leqslant \frac{z^2}{n} p(1-p) \iff$$

$$\iff \underbrace{\left(1 + \tfrac{z^2}{n}\right)p^2 - \left(2\widehat{p} + \tfrac{z^2}{n}\right)p + \widehat{p}^2}_{=:f(p)} \leqslant 0$$

есть неравенство, *квадратное* по p. Его корни $p_{\mp}$ и дают концы

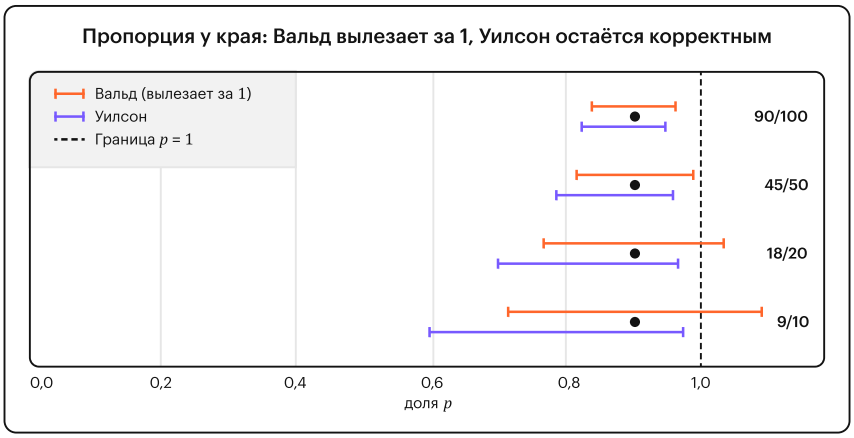

Рисунок 74. Вальд против Уилсона при $\widehat{p} = 0.9$: у края Вальд вылезает за 1, Уилсон корректен.

интервала: середина между ними — центр, полу-расстояние — полуширина. Центр равен абсциссе вершины параболы

$$p^* = \frac{2\widehat{p} + z^2/n}{2(1 + z^2/n)} = \frac{n\widehat{p} + z^2/2}{n + z^2} = \frac{n}{n + z^2}\,\widehat{p} + \frac{z^2}{n + z^2} \cdot \frac{1}{2},$$

то есть взвешенному среднему оценки $\widehat{p}$ и числа $\frac{1}{2}$ — отсюда и сдвиг центра от $\widehat{p}$ к $\frac{1}{2}$.

Покажем, что оба конца $p_{\mp}$ лежат в $[0,1]$, и потому интервал Уилсона *всегда* остаётся внутри $[0,1]$, не вылезая за границы, как умеет Вальд при крайних $\widehat{p}$. Одной лишь неотрицательности $f(0) = \widehat{p}^2 \geqslant 0$ и $f(1) = (1 - \widehat{p})^2 \geqslant 0$ для этого *недостаточно*: парабола ветвями вверх может быть положительна на концах и при корнях вне отрезка (например, $g(p) = (p-2)(p-3)$ даёт $g(0) = 6$, $g(1) = 2$, а корни $2, 3$ лежат вне $[0,1]$). Нужны ещё два факта. Во-первых, вершина p^* как взвешенное среднее $\widehat{p} \in [0,1]$ и $\frac{1}{2}$ сама лежит в $[0,1]$, поэтому ось симметрии параболы проходит *внутри* отрезка. Во-вторых, корни вещественны: исходное неравенство $f(p) \leqslant 0$ выполнено хотя бы в одной точке (при $p = \widehat{p}$, где $\widehat{p} - p = 0$), значит дискриминант неотрицателен и решение $f(p) \leqslant 0$ есть непустой отрезок $[p_-, p_+] \ni p^*$. Складываем: ветви вверх, на концах $f(0), f(1) \geqslant 0$, а минимум достигается в $p^* \in [0,1]$ — следовательно, весь отрезок $[p_-, p_+]$ целиком зажат между 0 и 1. Значит, $0 \leqslant p_- \leqslant p_+ \leqslant 1$, и интервал Уилсона не выходит за $[0,1]$.

Ещё два стандартных интервала. Вместе с Уилсоном на практике применяют:

- **Агрести–Коулл** — простая поправка с хорошим покрытием: к выборке мысленно добавляют $z^2/2 \approx 2$ «успеха» и столько же «неудач» и применяют формулу Вальда к $\widetilde{p} = \dfrac{k + z^2/2}{n + z^2}$ при объёме $\widetilde{n} = n + z^2$. Для 95% это удобная эвристика «прибавь по два к успехам и неудачам». Интервал чуть шире Уилсона, зато считается в одну строчку и надёжно держит покрытие.

- **Клоппер–Пирсон** — *точный* интервал, полученный инверсией биномиального теста (концы выражаются через квантили бета-распределения). Он *гарантирует* покрытие не ниже $1-\alpha$ при любом n, но за гарантию платит консервативностью (заметно шире остальных). Берут там, где занижать доверие нельзя в принципе.

Что брать. По умолчанию — **Уилсон** или **Агрести–Коулл**; **Клоппер–Пирсон** — когда нужна гарантированная нижняя планка покрытия; **Вальд** — избегать (кроме больших n и $\widehat{p}$ вдали от краёв, где все они совпадают).

Пример 7.3.1. В тесте из $n = 200$ визитов покупку совершили $k = 18$, то есть $\widehat{p} = 0.09$. Построим 95% ДИ ($z = 1.96$).

Шаг 1 (Вальд). $\widehat{\mathrm{se}} = \sqrt{0.09 \cdot 0.91/200} \approx 0.0202$; интервал $0.09 \pm 1.96 \cdot 0.0202 = 0.09 \pm 0.0396$, то есть $[0.050,\ 0.130]$.

Тот же пример, но теперь сравним вальдовский интервал с более надёжным интервалом Уилсона.

Шаг 2 (Уилсон). Центр $= \dfrac{0.09 + 1.96^2/400}{1 + 1.96^2/200} \approx \dfrac{0.0996}{1.0192} \approx 0.0977$; полуширина $\approx \dfrac{1.96}{1.0192}\sqrt{\dfrac{0.09 \cdot 0.91}{200} + \dfrac{1.96^2}{4 \cdot 200^2}} \approx 0.0395$; интервал $\approx [0.058,\ 0.137]$.

Шаг 3 (сравнение). Здесь n большое и $\widehat{p}$ не у самого края, поэтому интервалы близки. Уилсон чуть сдвинут вверх (к $1/2$) и надёжнее по покрытию — его и берём.

Пример 7.3.2. Среди $n = 300$ арбузов сладкими оказались 100, то есть $\widehat{p} = \frac{1}{3}$. Построим интервал Вальда уровня $1-\alpha$ для доли p сладких арбузов среди всех существующих и сравним 95% и 90%.

Сначала 95% ($z_{0.975} = 1.96$).

Шаг 1 (стандартная ошибка). $\widehat{\mathrm{se}} = \sqrt{\dfrac{\widehat{p}(1-\widehat{p})}{n}} = \sqrt{\dfrac{\frac{1}{3}\cdot\left(1-\frac{1}{3}\right)}{300}}$.

Шаг 2 (интервал). По формуле Вальда (7)

$$\widehat{p} \pm z_{0.975}\sqrt{\frac{\widehat{p}(1-\widehat{p})}{n}} = \frac{1}{3} \pm 1.96\sqrt{\frac{\frac{1}{3}\cdot\left(1-\frac{1}{3}\right)}{300}} = \\ = \frac{1}{3} \pm 0.0533,$$

то есть $\left[\frac{1}{3} - 0.0533\ ,\ \frac{1}{3} + 0.0533\right]$.

Теперь 90% ($z_{0.95} = 1.645$).

Шаг 3 (квантиль). Меняется только уровень доверия, а с ним — квантиль: вместо $z_{0.975} = 1.96$ берём $z_{0.95} = 1.645$. Доля $\widehat{p} = \frac{1}{3}$ и объём $n = 300$ те же, поэтому стандартная ошибка из Шага 1 не

меняется.

Шаг 4 (интервал). По той же формуле (7)

$$\widehat{p} \pm z_{0.95}\sqrt{\frac{\widehat{p}(1-\widehat{p})}{n}} = \frac{1}{3} \pm 1.645\sqrt{\frac{\frac{1}{3}\cdot\left(1-\frac{1}{3}\right)}{300}} = \\ = \frac{1}{3} \pm 0.045,$$

то есть $\left[\frac{1}{3} - 0.045\ ,\ \frac{1}{3} + 0.045\right]$.

Шаг 5 (вывод). При снижении доверия с 95% до 90% интервал *сузился*: полуширина упала с 0.0533 до 0.045. Это закономерно: чем у́же интервал, тем меньше его шанс накрыть истинное значение p; но 90%-й интервал и обязан накрывать p реже, чем 95%-й, поэтому ему хватает меньшей ширины. Запомнить стоит обе константы: $z_{0.975} = 1.96$ для 95% и $z_{0.95} = 1.645$ для 90%. Для произвольного уровня квантиль берут из таблицы стандартного нормального распределения или считают функцией `stats.norm.ppf`.

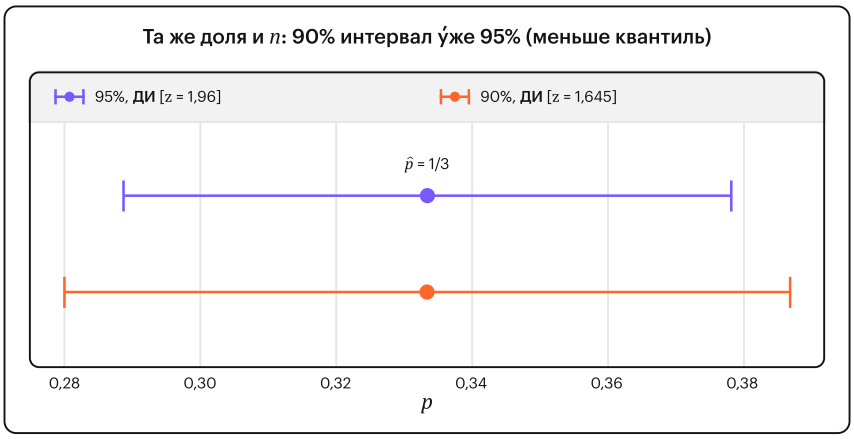

Рисунок 75. Та же доля $\widehat{p} = 1/3$: снижение доверия с 95% до 90% сужает интервал.

4. ДОВЕРИТЕЛЬНЫЙ ИНТЕРВАЛ ДЛЯ ДИСПЕРСИИ

Интуиция. В A/B-тесте нас интересует не само среднее в каждой группе, а *разница* между ними: стал ли чек в тесте больше, чем в контроле? Строим интервал не для одного среднего, а для *разности* $\mu_B - \mu_A$. И тогда вопрос «есть ли эффект» сводится к простому: *накрывает ли этот интервал ноль*.

Разность средних (независимые выборки). Пусть группа A даёт $\overline{X}_A, S_A, n_A$, группа B — $\overline{X}_B, S_B, n_B$, выборки независимы. Оценка разности — $\overline{X}_B - \overline{X}_A$, её стандартная ошибка складыва-

ется из дисперсий групп:

$$\widehat{\mathrm{se}} = \sqrt{\frac{S_A^2}{n_A} + \frac{S_B^2}{n_B}}.$$

Интервал уровня $1-\alpha$ для $\mu_B - \mu_A$:

$$\left(\overline{X}_B - \overline{X}_A\right) \pm t_{\nu,\,1-\alpha/2}\,\widehat{\mathrm{se}}, \tag{9}$$

где число степеней свободы ν берётся по приближению *Уэлча* (Welch) — оно не требует равенства дисперсий групп:

$$\nu = \frac{\left(S_A^2/n_A + S_B^2/n_B\right)^2}{\dfrac{(S_A^2/n_A)^2}{n_A - 1} + \dfrac{(S_B^2/n_B)^2}{n_B - 1}}.$$

При больших n_A, n_B можно брать нормальный квантиль $z_{1-\alpha/2}$ вместо t_ν.

Почему именно такое ν. При *неравных* дисперсиях групп статистика разности (9) уже не имеет точного распределения Стьюдента: квадрат знаменателя $\widehat{\mathrm{se}}^2 = S_A^2/n_A + S_B^2/n_B$ — это взвешенная сумма двух независимых масштабированных χ^2, а такая смесь сама на масштабированное χ^2 не похожа. Формула Уэлча подбирает *эффективное* число степеней свободы ν так, чтобы одиночное масштабированное χ^2_ν как можно точнее воспроизводило дисперсию $\widehat{\mathrm{se}}^2$ (метод моментов); поэтому ν выходит *нецелым* — берут ближайшее целое или интерполируют квантиль t_ν. В отличие от объединённой (pooled) оценки, здесь дисперсии *не* усредняют в одну.

Ориентир: при $S_A = S_B$ и $n_A = n_B = n$ формула сводится к $\nu = 2(n-1)$ (ровно pooled-значение $n_A + n_B - 2$), а в общем случае

$$\min(n_A, n_B) - 1 \;\leqslant\; \nu \;\leqslant\; n_A + n_B - 2.$$

Чем сильнее перекос дисперсий, тем ближе ν к числу степеней свободы $n_k - 1$ той группы k, у которой член S_k^2/n_k доминирует в $\widehat{\mathrm{se}}^2$. Нижняя граница $\min(n_A, n_B) - 1$ достигается лишь когда доминирующий член принадлежит *меньшей* группе; если он у большей — ν стягивается к её (большему) числу степеней свободы. При больших ν квантиль t_ν практически совпадает с нормальным.

Правило «накрывает ли ноль». Интервал (9) *не содержит* 0 ровно тогда, когда разница статистически значима на уровне α (двусторонне). Это и есть мостик между доверительными интервалами и проверкой гипотез (частный случай дуальности из § 7.1): $H_0 : \mu_A = \mu_B$ отвергается на уровне $\alpha \iff 0$ лежит вне $(1-\alpha)$-интервала для разности. Интервал при этом информативнее, чем просто «значимо/ незначимо»: он показывает *величину* эффекта и его *точность*.

Разность пропорций (две конверсии). Тот же приём для долей.

Для $\widehat{p}_A, \widehat{p}_B$ интервал уровня $1-\alpha$ для $p_B - p_A$:

$$(\widehat{p}_B - \widehat{p}_A) \;\pm\; z_{1-\alpha/2}\sqrt{\frac{\widehat{p}_A(1-\widehat{p}_A)}{n_A} + \frac{\widehat{p}_B(1-\widehat{p}_B)}{n_B}}. \qquad (10)$$

(При малых выборках точнее работают интервалы на основе Уилсона/Ньюкомба, но идея — та же стандартная ошибка из суммы групповых дисперсий.) Именно так в продуктовой аналитике сравнивают конверсии групп A/B.

метрики-отношения: ARPU, CTR на пользователя ЗАМЕЧАНИЕ

Формулы выше — для разности *средних* и *долей*. Но многие продуктовые метрики устроены как *отношение* двух средних: выручка на пользователя (ARPU $= \sum$ выручка$/\sum$ юзеры), CTR на пользователя, конверсия на сессию. Доверительный интервал для отношения напрямую по (9) не строится: числитель и знаменатель случайны и зависимы, а наблюдения внутри пользователя коррелированы. Стандартные решения: **дельта-метод** (линеаризация отношения и аналитическая стандартная ошибка — то же разложение, что даёт асимптотические интервалы в § 7.2), интервал **Фишера–Филлера** (Fieller) или **бутстреп с ресэмплингом пользователей** (а не отдельных событий — чтобы сохранить внутрипользовательскую зависимость). Именно дельта-метод и бутстреп — рабочие инструменты A/B-платформ для ratio-метрик; подробнее о бутстреп-подходе — в отдельной главе, посвящённой методу Монте-Карло и бутстрепу.

Пример 7.4.1. Сравним две группы A и B по среднему. Возможны *три* картины (пары графиков ниже: слева — интервалы самих групп, справа — интервал их разности). **Ситуация 1:** интервалы групп пересекаются, и ноль *входит* в интервал разности — значимой разницы нет. **Ситуация 2** (главная): интервалы групп всё ещё *пересекаются*, но интервал разности ноль уже *не* накрывает — разница значима. **Ситуация 3:** интервалы групп не пересекаются, ноль вне разности — разница значима, и это видно уже по группам.

Отсюда правило: судить об эффекте по пересечению интервалов *самих групп* нельзя — решает только то, накрывает ли ноль интервал *разности*.

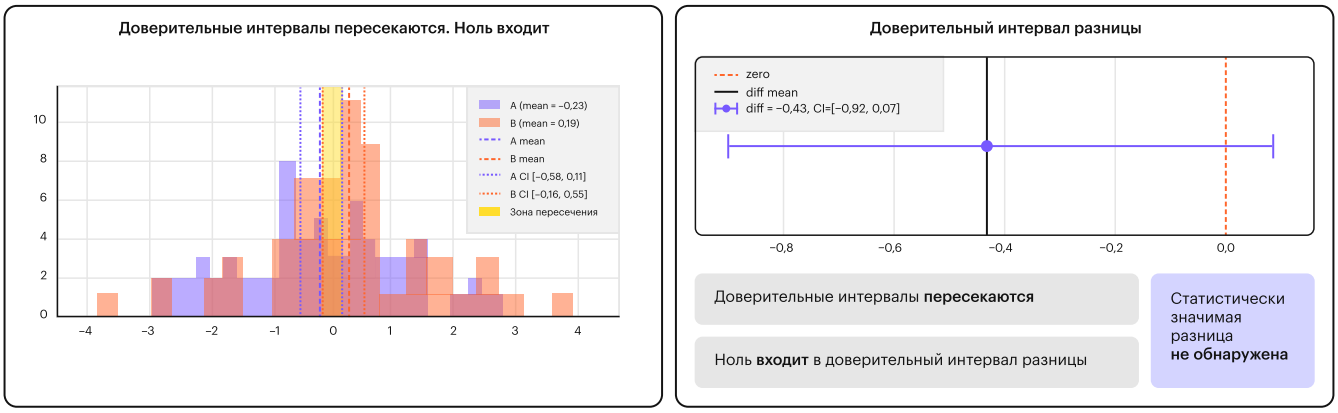

Рисунок 76. Ситуация 1: интервалы групп пересекаются, ноль внутри интервала разности.

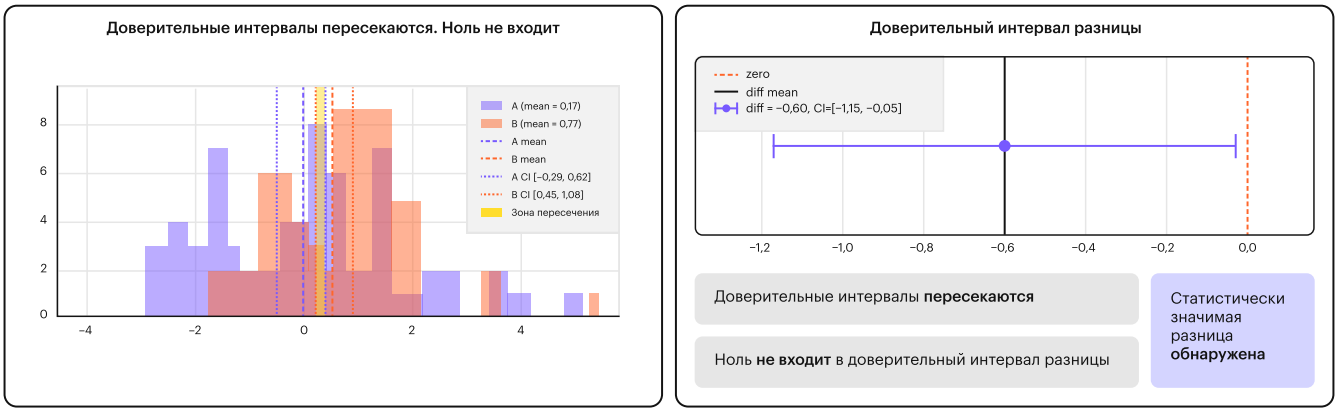

Рисунок 77. Ситуация 2: интервалы групп пересекаются, но ноль вне интервала разности.

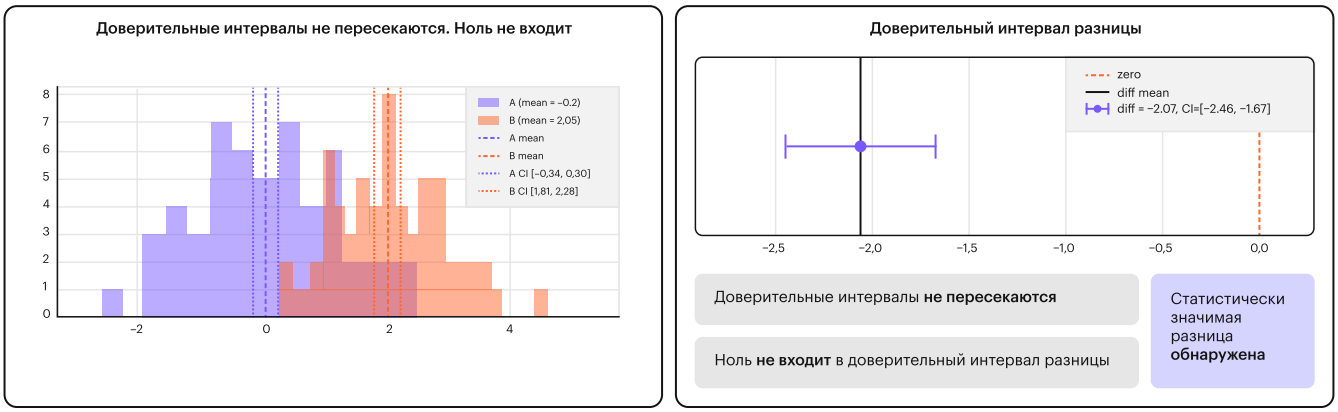

Рисунок 78. Ситуация 3: интервалы групп не пересекаются, ноль вне интервала разности.

Пример 7.4.2. Всё сказанное про средние дословно переносится на *конверсии* — то есть на разность долей $\widehat{p}_B - \widehat{p}_A$ по формуле (10). Три пары графиков ниже повторяют ситуации 1–3 уже для долей: снова пересечение интервалов *самих групп* ни о чём не говорит, а решает лишь то, накрывает ли ноль интервал *разности* конверсий. Ситуация 2 (интервалы групп пересекаются, а разность уже значима) — самая коварная и на практике встречается постоянно.

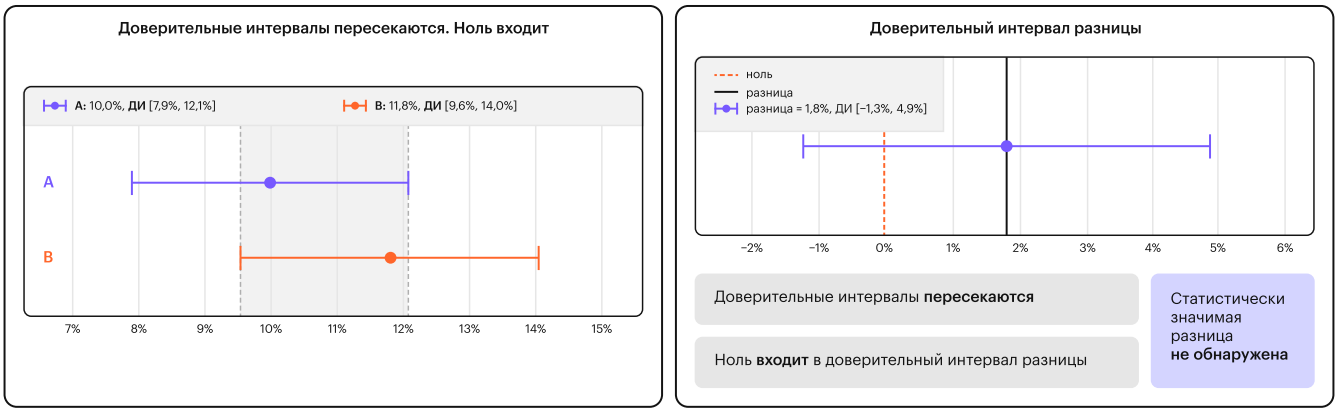

Рисунок 79. Конверсии, ситуация 1: интервалы групп пересекаются, ноль внутри разности долей.

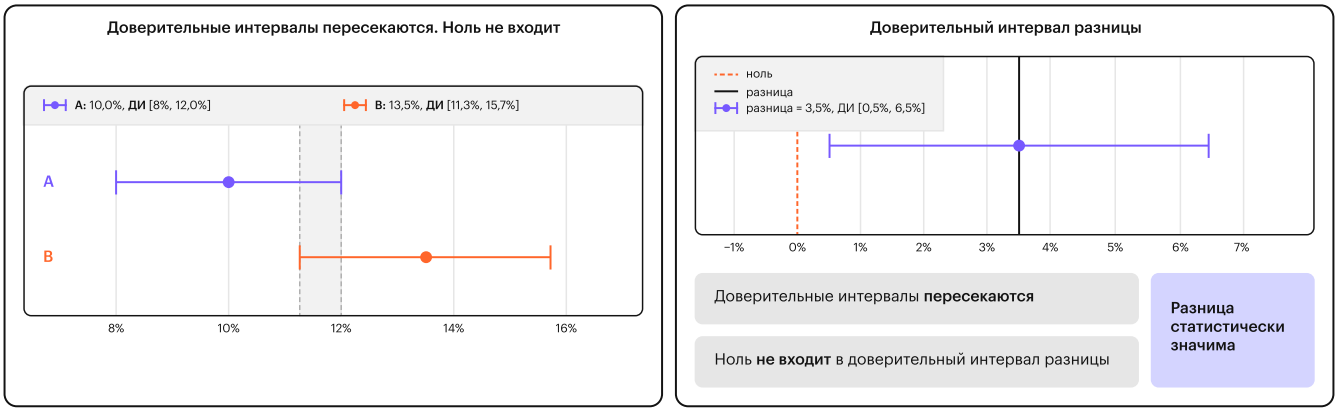

Рисунок 80. Конверсии, ситуация 2: интервалы групп пересекаются, но ноль вне разности.

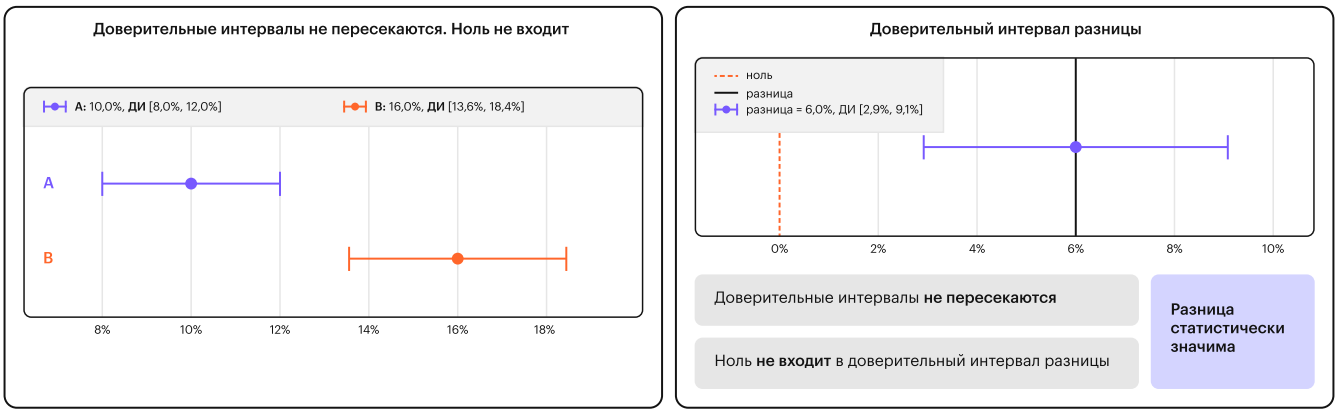

Рисунок 81. Конверсии, ситуация 3: интервалы групп не пересекаются, ноль вне разности.

Пример 7.4.3. Контроль A: $n_A = 900$, $\overline{X}_A = 1200$ руб., $S_A = 540$. Тест B: $n_B = 900$, $\overline{X}_B = 1248$, $S_B = 560$. Есть ли эффект на 95%?

Шаг 1 (разность). $\overline{X}_B - \overline{X}_A = 1248 - 1200 = 48$ руб.

Шаг 2 (стандартная ошибка). $\widehat{\text{se}} = \sqrt{540^2/900 + 560^2/900} = \sqrt{324 + 348.4} \approx \sqrt{672.4} \approx 25.9$.

Шаг 3 (интервал). Выборки большие, берём $z = 1.96$: $48 \pm 1.96 \cdot$

$25.9 = 48 \pm 50.8$, то есть $[-2.8,\ 98.8]$.

Шаг 4 (вывод). Интервал *накрывает ноль* — на 95% мы *не можем* утверждать, что эффект есть: данных недостаточно, чтобы отличить $+48$ руб. от нуля. Чтобы поймать такой эффект, нужна бóльшая выборка (интервал сужается как $1/\sqrt{n}$) либо метод снижения дисперсии.

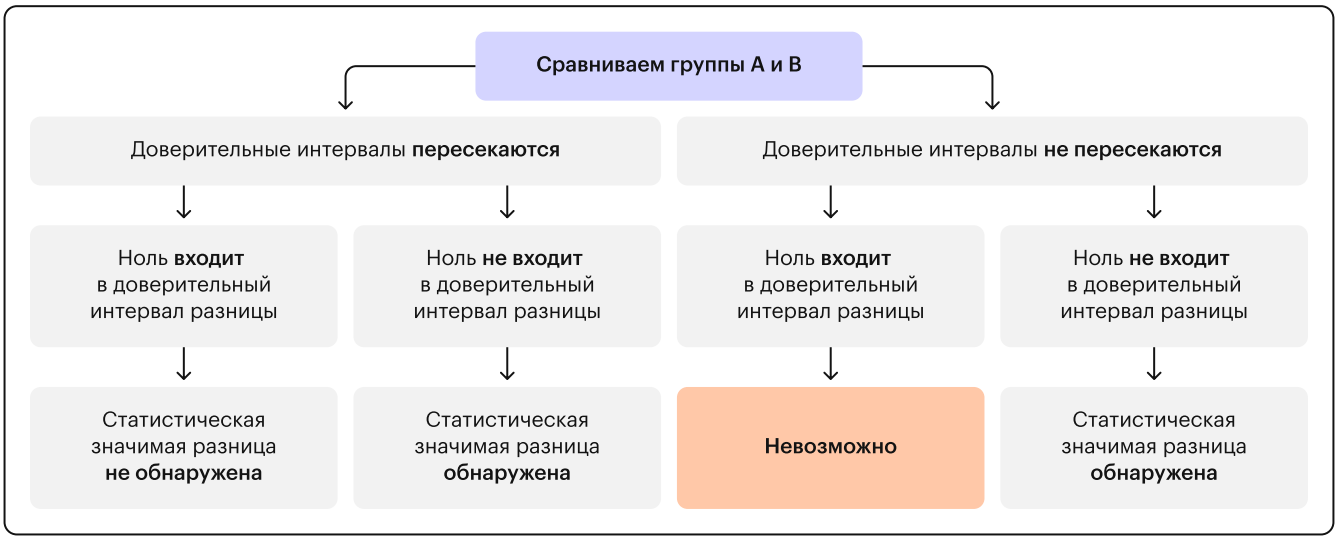

Рисунок 82. Сводка: решает не пересечение интервалов групп, а то, накрывает ли ноль интервал разности.

5. ДОВЕРИТЕЛЬНЫЙ ИНТЕРВАЛ ДЛЯ ДИСПЕРСИИ

Интуиция. Разброс данных — тоже параметр, и для него строят доверительный интервал. Но дисперсия ведёт себя иначе, чем среднее: её опорная величина $(n-1)S^2/\sigma^2$ распределена по закону хи-квадрат, а он *скошен*, поэтому интервал для σ^2 несимметричен относительно S^2. Работает та же схема опорной величины (§ 7.1), только с квантилями χ^2 вместо нормальных.

Пример 7.5.1. Пусть $X_1, \dots, X_n$ — независимая выборка из $N(\mu, \sigma^2)$, где оба параметра μ и σ^2 *неизвестны*. Выборочная дисперсия —

$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2, \qquad \overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i.$$

Покажем, что опорная для дисперсии статистика имеет распределение хи-квадрат с $n-1$ степенью свободы:

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}. \tag{11}$$

Этот факт — фундамент для доверительного интервала для σ^2 и тестов на равенство дисперсий.

Шаг 1 (центрируем и стандартизуем). Перейдём к стандартизованным наблюдениям $Z_i = \dfrac{X_i - \mu}{\sigma}$. Тогда $Z_i \sim N(0,1)$ независимы, а их выборочное среднее — $\overline{Z} = \frac{1}{n}\sum_i Z_i$.

Шаг 2 (масштабируем сумму квадратов). Отклонения от выборочного среднего не зависят от сдвига на μ, а множитель σ выносится за скобку:

$$\sum_{i=1}^{n} \big(X_i - \overline{X}\big)^2 = \sigma^2 \sum_{i=1}^{n} \big(Z_i - \overline{Z}\big)^2.$$

Шаг 3 (приводим опорную величину к сумме квадратов). Делим на σ^2 — и слева получается ровно $(n-1)S^2/\sigma^2$:

$$\frac{(n-1)S^2}{\sigma^2} = \sum_{i=1}^{n} \big(Z_i - \overline{Z}\big)^2.$$

Узнали? Это сумма квадратов стандартных нормальных величин — но *центрированных не нулём, а их же выборочным средним* $\overline{Z}$.

Шаг 4 (потеря степени свободы). Если бы мы вычитали *истинное* среднее (ноль), то $\sum_i Z_i^2$ была бы суммой n независимых квадратов и давала бы χ^2_n. Но вычитание $\overline{Z}$ накладывает одну линейную связь $\sum_i (Z_i - \overline{Z}) = 0$: одно из n отклонений выражается через остальные. Строго это оформляется через квадратичные формы многомерного нормального распределения — сумму $\sum_i (Z_i - \overline{Z})^2$ можно представить как сумму квадратов $n-1$ *независимых* стандартных нормальных величин. Поэтому теряется одна степень свободы.

Шаг 5 (вывод). Итак, (11) доказано: $(n-1)S^2/\sigma^2 \sim \chi^2_{n-1}$. Распределение хи-квадрат точно описывает поведение оценки дисперсии в нормальной модели даже при неизвестном μ; цена незнания μ — одна «потерянная» степень свободы, ровно та, что ушла на оценку центра через $\overline{X}$.

Почему теряется ровно одна степень свободы. Взглянем на это геометрически. Вектор $Z = (Z_1, \dots, Z_n)$ из независимых $N(0,1)$ — это стандартный гауссов вектор в $\mathbb{R}^n$; его распределение сферически симметрично. Связь $\sum_i (Z_i - \overline{Z}) = 0$ означает, что вектор отклонений $(Z_1 - \overline{Z}, \dots, Z_n - \overline{Z})$ ортогонален направлению $\mathbf{1} = (1, \dots, 1)$, то есть лежит в подпространстве

$$L = \{\, v \in \mathbb{R}^n : \; v \perp \mathbf{1} \,\}, \qquad \dim L = n - 1.$$

По сути отклонения — это проекция Z на L (вычитание $\overline{Z}$ убирает компоненту вдоль $\mathbf{1}$). Проекция стандартного гауссова вектора на любое $(n-1)$-мерное подпространство в ортонормированных координатах этого подпространства даёт ровно $n-1$ независимых $N(0,1)$. При этом ортонормированная замена базиса сохраняет длину, поэтому сумма квадратов этих $n-1$ координат

равна квадрату нормы вектора отклонений:

$$\sum_{i=1}^{n} (Z_i - \overline{Z})^2 = \frac{(n-1)S^2}{\sigma^2}.$$

Значит, эта величина и есть сумма квадратов $n-1$ независимых $N(0,1)$, то есть χ^2_{n-1}. «Потерянная» ось — направление $\mathbf{1}$: она ушла на оценку центра $\overline{Z}$.

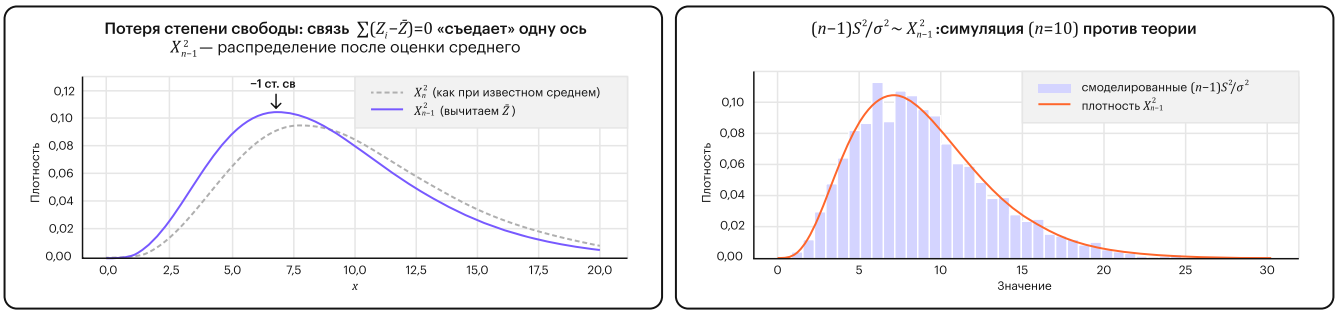

Рисунок 83. Слева — потеря степени свободы (χ^2_{n-1}, а не χ^2_n); справа — гистограмма $(n-1)S^2/\sigma^2$ ложится на χ^2_{n-1}.

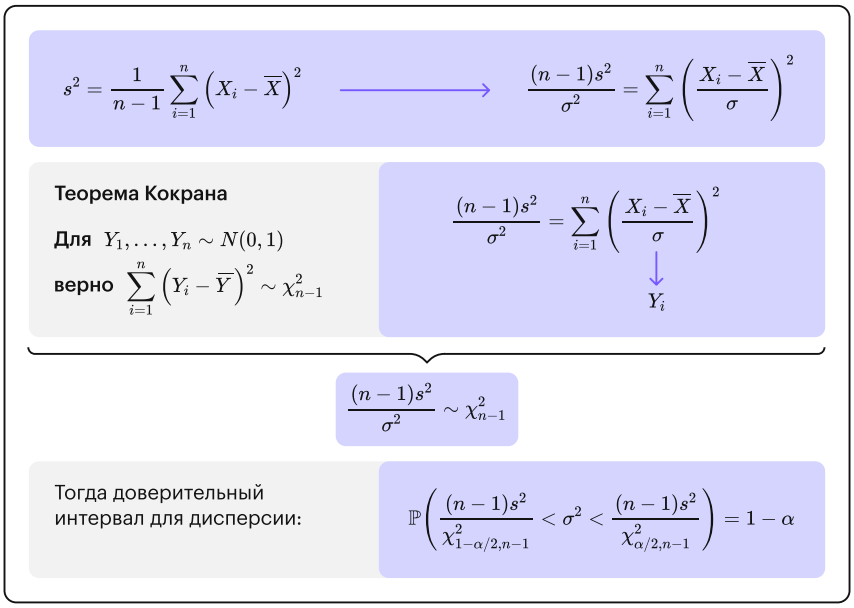

Рисунок 84. Вывод интервала для дисперсии: по теореме Кохрена $(n-1)S^2/\sigma^2 \sim \chi^2_{n-1}$, затем зажимаем между квантилями.

Пример 7.5.2. Пусть дана выборка из $n = 30$ наблюдений $X_1, \dots, X_n$ н.о.р. $\sim N(\mu, \sigma^2)$ (для наглядности смоделирована при истинных $\mu = 10$, $\sigma = 2$, то есть $\sigma^2 = 4$). По выборке получены

$$\overline{X} \approx 9.62, \qquad S^2 \approx 3.24.$$

Построим 95% ($\alpha = 0.05$) доверительный интервал для дисперсии σ^2, а затем и для самого σ.

Шаг 1 (точечная оценка). Выборочная дисперсия $S^2 \approx 3.24$ —

это наша точечная оценка σ^2 (истинное значение $\sigma^2 = 4$ нам как «наблюдателю» неизвестно; проверим, накроет ли его интервал).

Шаг 2 (квантили хи-квадрат). Опорная величина $(n-1)S^2/\sigma^2 \sim \chi^2_{n-1}$ с $n-1 = 29$ степенями свободы. Для 95% берём два квантиля (по таблице/функции `stats.chi2.ppf`):

$$\chi^2_{0.025,\,29} \approx 16.05, \qquad \chi^2_{0.975,\,29} \approx 45.72.$$

Шаг 3 (интервал для σ^2). Подставляем в формулу $\left[(n-1)S^2/\chi^2_{1-\alpha/2,\,n-1},\ (n-1)S^2/\chi^2_{\alpha/2,\,n-1}\right]$, где $(n-1)S^2 = 29 \times 3.24 \approx 93.96$. Обратите внимание: *больший* квантиль даёт *нижнюю* границу:

$$\left[\frac{93.96}{45.72},\ \frac{93.96}{16.05}\right] \approx [2.06,\ 5.86].$$

Истинное значение $\sigma^2 = 4$ действительно попало внутрь.

Шаг 4 (интервал для σ). Так как переход $\sigma^2 \mapsto \sigma = \sqrt{\sigma^2}$ монотонно возрастающий, доверительный интервал для σ получаем, просто извлекая корни из границ:

$$\left[\sqrt{2.06},\ \sqrt{5.86}\right] \approx [1.43,\ 2.42].$$

Шаг 5 (читаем и оцениваем асимметрию). Мы достаточно уверены, что истинная дисперсия σ^2 лежит в $[2.06,\ 5.86]$, а стандартное отклонение σ — в $[1.43,\ 2.42]$. Интервал заметно несимметричен относительно $S^2 = 3.24$: левое «плечо» равно $3.24 - 2.06 = 1.18$, а правое — $5.86 - 3.24 = 2.62$, то есть верхняя граница отстоит от оценки более чем вдвое дальше нижней. Так выходит потому, что распределение χ^2 скошено вправо; при росте n перекос плеч ослабевает, а «вилка» сужается.

Пример 7.5.3. Соберём весь расчёт предыдущего примера в одну картинку. Слева — та же выборка ($n = 30$, $\overline{X} \approx 9.62$, $S^2 \approx 3.24$); справа видно, как два квантиля χ^2_{29} — 16.05 и 45.72 (хвосты по 2.5%) — превращаются в границы $[2.06,\ 5.86]$ интервала для σ^2. Хорошо заметна *асимметрия*: правое плечо (2.62) более чем вдвое длиннее левого (1.18) — прямое следствие скошенности χ^2 вправо.

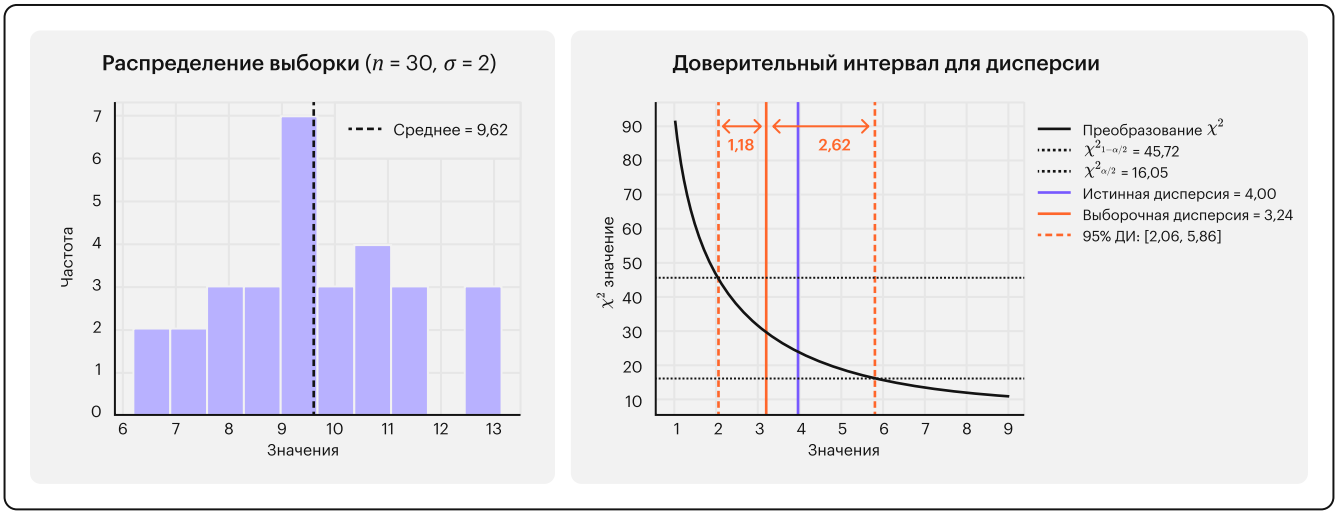

Куда дальше. Все интервалы этой главы держатся на одном и том же приёме — опорной величине с известным (нормальным или стьюдентовым) распределением. Он прекрасно работает для среднего и доли, но *кончается* там, где у статистики нет удобной формулы стандартной ошибки: для *медианы*, *перцентилей*, *коэффициента корреляции*, *отношения* двух метрик. Для таких случаев интервал строят *моделированием* — это **бутстреп**, которому посвящена отдельная глава о методе Монте-Карло и бутстрепе. Там же мы увидим, что и бутстреп, и Монте-Карло — по сути один приём: заменить аналитический вывод многократным розыгрышем случайности.

Часть 8. Численные методы

В предыдущих главах блока вы строили доверительные интервалы *по формулам*: для математического ожидания — через t-распределение, для пропорции — через нормальное приближение бинома, для разности средних — через интервал для разности. Эти формулы выведены для *простых* статистик и опираются на асимптотику или нормальность. А что, если нужен интервал для *медианы*, *коэффициента корреляции*, *90-го перцентиля* времени отклика или *отношения* двух метрик? Готовой формулы часто нет.

Здесь работают **численные методы** — два универсальных инструмента, заменяющих аналитический вывод *моделированием*:

- **Метод Монте-Карло** (§ 8.1) — оценивает интегралы, вероятности и матожидания, разыгрывая случайность из *заданной* модели p;
- **Бутстреп** (§ 8.2) — строит доверительный интервал почти для любой статистики, переразыгрывая *имеющуюся выборку*.

Главная мысль, к которой мы придём в § 8.3: это *один и тот же при-*

ём. Оба метода многократно разыгрывают случайность и усредняют; оба опираются на *закон больших чисел*. Различаются они лишь *источником* случайности — Монте-Карло берёт её из известной модели, а бутстреп из распределения, оценённого по данным. Поэтому естественно начать с Монте-Карло, а бутстреп увидеть как его частный случай.

1. МЕТОД МОНТЕ-КАРЛО

Базовый оценщик

Интуиция. Нужно измерить площадь пруда неправильной формы. Очертим вокруг него прямоугольник известной площади и будем бросать камешки наугад, считая долю всплесков. Доля попаданий, умноженная на площадь прямоугольника, и есть искомая площадь — тем точнее, чем больше бросков. Метод Монте-Карло — это та же идея: *подменяем точное вычисление подсчётом среднего по случайным «броскам»*.

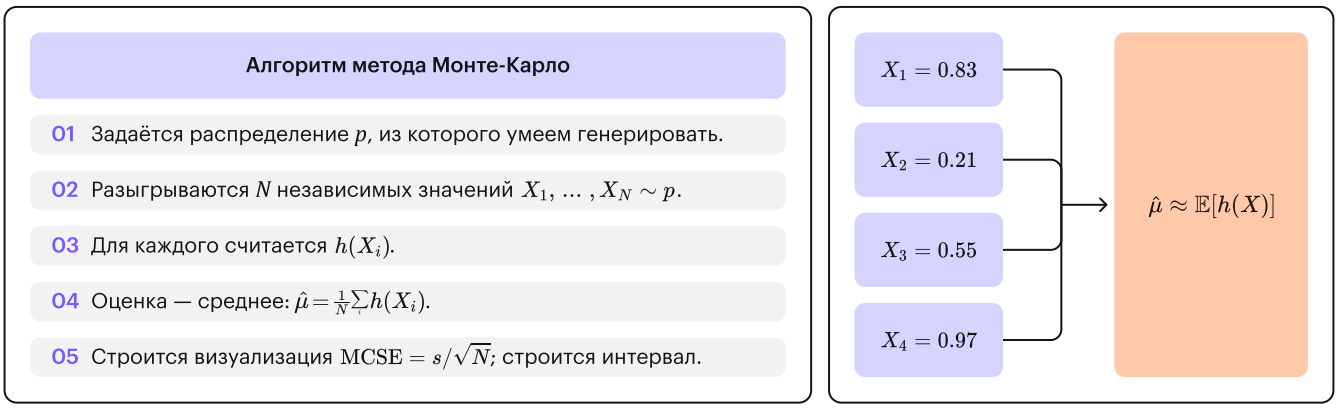

Рисунок 85. Метод Монте-Карло: определение и алгоритм. Из заданного распределения p разыгрывают N значений, считают $h(X_i)$ и усредняют; погрешность оценки убывает как $1/\sqrt{N}$.

Пусть нужно вычислить математическое ожидание

$$\mu \;=\; \mathbb{E}_{X\sim p}\big[h(X)\big] \;=\; \int_{\mathcal{X}} h(x)\,p(x)\,dx, \tag{12}$$

где p — плотность распределения, из которого мы умеем генерировать наблюдения, а h — функция с $\mathbb{E}|h(X)| < \infty$. Многие задачи приводятся к виду (12): вероятность события A — это μ с $h = \mathbb{1}_A$; интеграл $\int_a^b g(x)\,dx$ — это $(b-a)\,\mathbb{E}[g(U)]$ для $U \sim \mathrm{Unif}(a,b)$.

Оценщик Монте-Карло. Разыгрываем н.о.р. $X_1, \dots, X_N \sim p$ и берём среднее

$$\widehat{\mu}_N \;=\; \frac{1}{N}\sum_{i=1}^{N} h(X_i). \tag{13}$$

Свойства оценщика (13). Пусть $\sigma^2 = \mathrm{Var}\,\big(h(X)\big) < \infty$. Тогда оцен-

щик *несмещён*, его дисперсия убывает как $1/N$, и он состоятелен:

$$\mathbb{E}[\widehat{\mu}_N] = \mu, \qquad \mathrm{Var}(\widehat{\mu}_N) = \frac{\sigma^2}{N}, \qquad \widehat{\mu}_N \xrightarrow{\text{п.н.}} \mu.$$

Стандартное отклонение оценки (Monte Carlo standard error, MCSE) равно $\mathrm{se}(\widehat{\mu}_N) = \sigma/\sqrt{N} \sim N^{-1/2}$.

Что значит показатель $N^{-1/2}$. Чтобы уменьшить ошибку *вдвое*, нужно *вчетверо* больше испытаний — точность «дорогая». Зато этот показатель *не зависит от размерности* задачи, поэтому в высоких размерностях Монте-Карло вытесняет детерминированные квадратуры. На практике σ оценивается по выборке ($\widehat{\sigma}$), и по ЦПТ строится интервал

$$\widehat{\mu}_N \pm z_{1-\alpha/2}\,\frac{\widehat{\sigma}}{\sqrt{N}} \tag{14}$$

— тот же интервал для среднего, что и в начале блока, только «среднее» берётся по смоделированным значениям. *Результат Монте-Карло без MCSE считается незавершённым.*

Пример 8.1.1. очное значение для проверки: $\int_0^1 e^u\,du = e - 1 \approx 1.7183$.

Интеграл $\int_0^1 e^u\,du$ с погрешностью, по шагам

Шаг 1 (оценщик). $\widehat{\mu}_N = \frac{1}{N}\sum_i e^{U_i}$, где $U_i \sim \mathrm{Unif}(0,1)$.

Шаг 2 (дисперсия слагаемого). $\mathbb{E}[e^{2U}] = \int_0^1 e^{2u}\,du = \frac{e^2-1}{2} \approx 3.1945$, поэтому

$$\sigma^2 = \mathbb{E}[e^{2U}] - \left(\mathbb{E}e^U\right)^2 \approx 3.1945 - 1.7183^2 \approx$$
$$\approx 3.1945 - 2.9526 = 0.2419,$$
$$\sigma \approx 0.49.$$

Шаг 3 (погрешность). MCSE $= \sigma/\sqrt{N}$. При $N = 10^4$ это $0.49/100 \approx 0.005$, то есть оценка даёт примерно 1.72 ± 0.01 (уровень 95%).

Шаг 4 (цена точности). Чтобы сократить погрешность вдвое — до ≈ 0.0025 — нужно $N = 4 \cdot 10^4$: учетверение розыгрышей. Это и есть «дорогая» точность показателя $N^{-1/2}$.

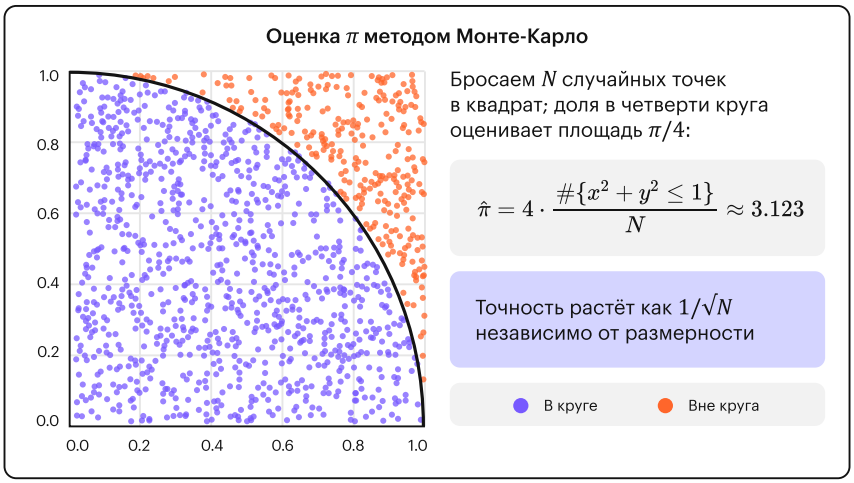

Рисунок 86. Каноничный пример: оценка площади (числа π) долей случайных точек, попавших в четверть круга. Иллюстрирует Монте-Карло как оценивание интеграла/вероятности усреднением индикатора.

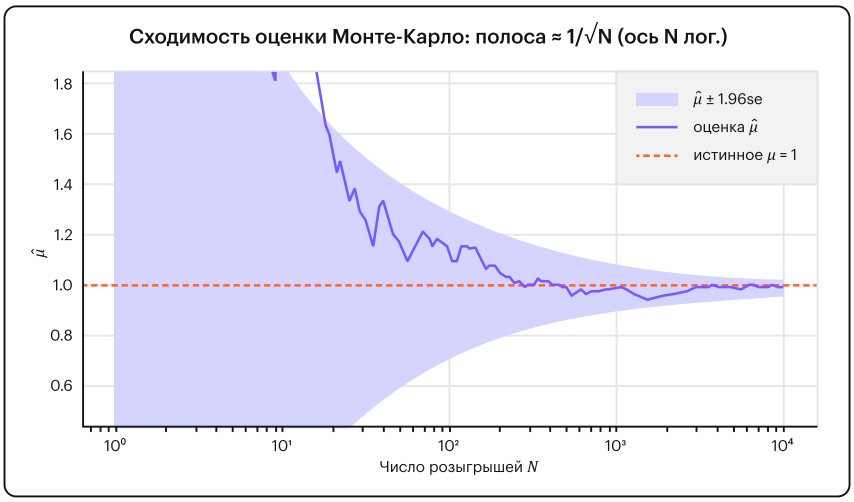

Рисунок 87. Оценка $\widehat{\mu}_N$ величины $\mathbb{E}[X^2] = 1$ для $X \sim N(0,1)$ и доверительная полоса $\widehat{\mu}_N \pm 1.96\,\widehat{\mathrm{se}}$. Полоса сужается со скоростью $N^{-1/2}$ (ось N логарифмическая).

ТЕОРЕМА 8.1.1

Если $\sigma^2 = \mathrm{Var}(h(X)) \in (0, \infty)$, то $\sqrt{N}\,(\widehat{\mu}_N - \mu) \xrightarrow{d} N(0, \sigma^2)$ при $N \to \infty$.

Доказательство. Слагаемые $Y_i := h(X_i)$ н.о.р. с конечной дисперсией σ^2, поэтому применима *ЦПТсЛиндеберга–Леви* (доказанная ранее, в блоке о свойствах точечных оценок) к $\sqrt{N}(\overline{Y}_N - \mu)$; это и есть утверждение, поскольку $\widehat{\mu}_N = \overline{Y}_N$. Замена σ на $\widehat{\sigma}$ законна по *лемме Слуцкого* (также из ранее пройденного), что обосновывает интервал (14). □

ЗАМЕЧАНИЕ

Условие $\sigma^2 < \infty$ существенно: при тяжёлых хвостах ($\sigma^2 = \infty$) оценка ещё сходится по закону больших чисел при $\mathbb{E}|h| < \infty$, но интервал (14) *неверен*.

Генерация случайных величин

Интуиция. Чтобы Монте-Карло заработал, нужно уметь *разыгрывать* $X \sim p$. Но компьютер умеет выдавать лишь равномерный «белый шум» $U \sim \mathrm{Unif}(0,1)$. Как из честной монетки сделать нужное распределение? Два базовых рецепта: «протащить» U через обратную функцию распределения или «отсеять» лишние точки под графиком плотности.

ТЕОРЕМА 8.1.2

Пусть F — функция распределения, $F^{-1}(u) = \inf\{x : F(x) \geqslant u\}$ — квантильная функция. Если $U \sim \mathrm{Unif}(0,1)$, то $X := F^{-1}(U)$ имеет функцию распределения F.

Доказательство. В силу монотонности F справедлива эквивалентность $\{F^{-1}(U) \leqslant x\} = \{U \leqslant F(x)\}$. Тогда $\mathsf{P}\{X \leqslant x\} = \mathsf{P}\{U \leqslant F(x)\} = F(x)$, поскольку $\mathsf{P}\{U \leqslant u\} = u$ на $[0,1]$. □

Пример 8.1.2. Для $\mathrm{Exp}(\lambda)$: $F(x) = 1 - e^{-\lambda x}$, отсюда $F^{-1}(u) = -\frac{1}{\lambda}\ln(1-u)$, а на практике (так как $1-U$ тоже равномерно) $X = -\frac{1}{\lambda}\ln U$. Метод идеален, когда квантиль выражается явно; для нормального он непрактичен, так как Φ^{-1} не элементарна — там переходят к методу отклонения.

Метод отклонения. Чтобы моделировать плотность f, берём «оболочку» g (из которой умеем генерировать) и константу M так, что $f(x) \leqslant M g(x)$ всюду.

Алгоритм отклонения.

1. Сгенерировать кандидата $Y \sim g$ и независимое $U \sim \mathrm{Unif}(0,1)$.
2. Если $U \leqslant f(Y)/(Mg(Y))$ — принять $X := Y$; иначе отбросить и повторить.

Пример 8.1.3. Возьмём $f = \mathrm{Beta}(2.5, 4)$ и равномерную оболочку $g \equiv 1$ на $[0,1]$. Максимум плотности — в моде $\frac{2.5-1}{2.5+4-2} = \frac{1}{3}$, где $f(1/3) \approx 2.08$; значит, минимально допустимая константа $M \approx 2.08$. Тогда доля принятия равна $1/M \approx 0.48$: в среднем нужно около 2.1 розыгрыша на одну принятую точку. Чем плотнее оболочка прилегает к f, тем ближе M к 1 и выше эффективность.

УТВЕРЖДЕНИЕ 8.1.1

Принятое X имеет плотность f; вероятность принять предложение равна $1/M$, а число попыток до принятия — геометрическое со средним M.

Доказательство. $\mathsf{P}\{Y \in dy, \text{принято}\} = g(y)\frac{f(y)}{Mg(y)}\,dy = \frac{f(y)}{M}\,dy$; интегрируя, получаем $\mathsf{P}\{\text{принято}\} = 1/M$, а условная плотность принятого равна f. □

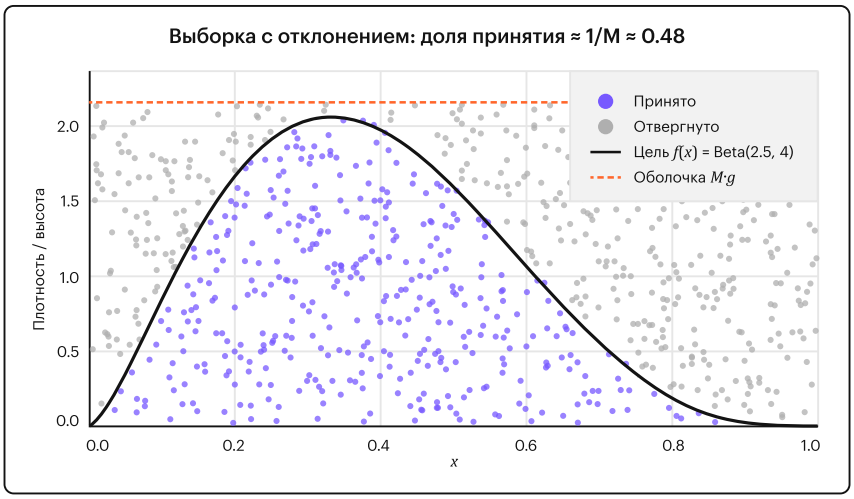

Рисунок 88. Метод отклонения для $f = \mathrm{Beta}(2.5, 4)$ с равномерной оболочкой. Доля принятия $= 1/M$.

2. БУТСТРЕП

Принцип подстановки и виды бутстрепа

Интуиция. Название — от выражения «вытащить себя за шнурки» (*pull oneself up by one's bootstraps*): кажется невозможным судить о разбросе оценки, имея *одну* выборку. Трюк в том, что сама выборка — это «мир в миниатюре»: если переразыгрывать наблюдения из неё (с возвращением), разброс полученных оценок имитирует тот разброс, который мы получили бы, собирая новые выборки из генеральной совокупности. Формально: раз истинное F неизвестно, подставляем вместо него лучшую оценку по данным.

Пример 8.2.1. По опросу $n = 500$ человек требуется построить 95%-й доверительный интервал для *медианной* зарплаты $z_{1/2}$ в регионе. Чем задача неудобна, видно сразу: распределение зарплат скошено и с тяжёлым правым хвостом, а интересует не среднее, а *квантиль*.

Шаг 1 (попытка по формуле). Для выборочной медианы $\widehat{z}_{1/2}$ известна асимптотика

$$\sqrt{n}\,(\widehat{z}_{1/2} - z_{1/2}) \xrightarrow{d} N\Big(0,\ \frac{1}{4\,f(z_{1/2})^2}\Big),$$

где f — плотность распределения зарплат. Чтобы превратить её в интервал, нужно знать $f(z_{1/2})$ — *значение плотности ровно в медиане*. Но вид распределения неизвестен, а оценивать плотность в одной точке — отдельная капризная задача (результат зависит от ширины окна сглаживания и т. п.). Формула «застревает» на неизвестной величине.

Шаг 2 (что делает бутстреп). Вместо плотности оценим *разброс самой медианы* напрямую. Переразыгрываем те же 500 значений с возвращением, на каждой реплике считаем медиану; по B репликам $\{\widehat{z}^{*b}_{1/2}\}$ берём либо их стандартное отклонение $\widehat{\mathrm{se}}_{\mathrm{boot}}$ (интервал

$\widehat{z}_{1/2} \pm z_{0.975}\,\widehat{\mathrm{se}}_{\mathrm{boot}}$), либо сразу 2.5% и 97.5% перцентили реплик.

Итог. Плотность $f(z_{1/2})$ не понадобилась вовсе — её роль сыграло переразыгрывание. Та же логика работает для любого квантиля, коэффициента корреляции, отношения — всюду, где аналитическая формула упирается в неизвестную величину. Эта подстановка «формула $\to$ моделирование» и есть бутстреп; ниже формализуем её.

Пусть $X_1, \dots, X_n \overset{\text{н.о.р.}}{\sim} F$, а интересующий параметр — функционал от распределения $\theta = T(F)$ (среднее, медиана, дисперсия, корреляция, квантиль...). Оценка — тот же функционал от *эмпирической функции распределения*

$$\widehat{F}_n(x) = \frac{1}{n}\sum_{i=1}^{n} \mathbb{1}\{X_i \leqslant x\}, \qquad \widehat{\theta} = T(\widehat{F}_n). \tag{15}$$

Это *принцип подстановки* (plug-in): неизвестное F заменяется на $\widehat{F}_n$. Бутстреп применяет тот же принцип ещё раз — к распределению ошибки $\widehat{\theta} - \theta$.

ТЕОРЕМА 8.2.1

$$\sup_{x \in \mathbb{R}} \left|\widehat{F}_n(x) - F(x)\right| \xrightarrow{\text{п.н.}} 0, \qquad n \to \infty.$$

Идея доказательства Доказательство. В каждой фиксированной точке $\widehat{F}_n(x) \xrightarrow{\text{п.н.}} F(x)$ по *усиленному закону больших чисел* (доказан ранее, в блоке о свойствах точечных оценок) — это среднее индикаторов. Равномерность получается так: для $\varepsilon > 0$ выберем узлы $-\infty = t_0 < t_1 < \dots < t_m = +\infty$ с $F(t_k) - F(t_{k-1}) \leqslant \varepsilon$. В каждом узле $\widehat{F}_n(t_k) \xrightarrow{\text{п.н.}} F(t_k)$ (их конечное число), поэтому $\max_k |\widehat{F}_n(t_k) - F(t_k)| \xrightarrow{\text{п.н.}} 0$. Для $x \in (t_{k-1}, t_k)$ из монотонности F и $\widehat{F}_n$ следует $\widehat{F}_n(x) - F(x) \leqslant \widehat{F}_n(t_k) - F(t_{k-1}) \leqslant \big(\widehat{F}_n(t_k) - F(t_k)\big) + \varepsilon$ и аналогично снизу, так что $\sup_x |\widehat{F}_n(x) - F(x)| \leqslant \max_k |\widehat{F}_n(t_k) - F(t_k)| + \varepsilon$. Устремляя $n \to \infty$ и затем $\varepsilon \to 0$, получаем требуемое. $\square$

Содержательно теорема Гливенко–Кантелли — *лицензия* на бутстреп: она гарантирует, что $\widehat{F}_n$ равномерно близко к F, поэтому моделирование «из данных» асимптотически эквивалентно моделированию «из истины». Рис. 89 показывает это сходящееся приближение.

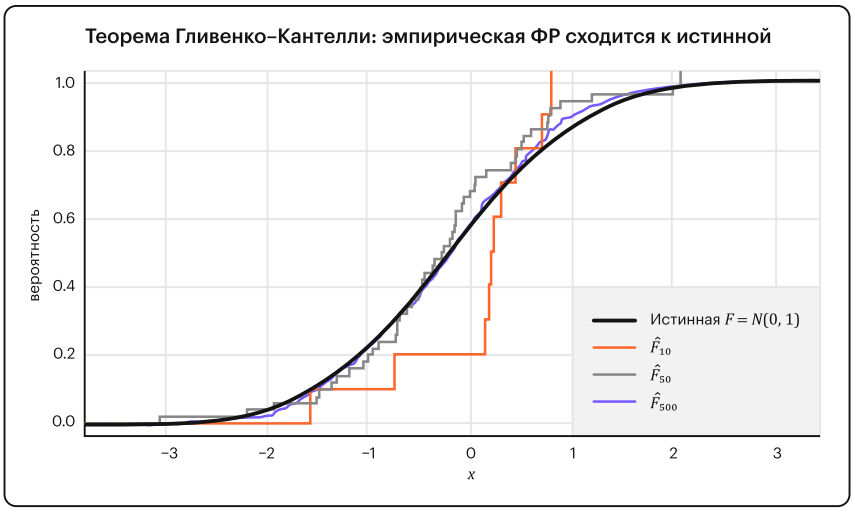

Рисунок 89. Эмпирические функции распределения $\widehat{F}_n$ для $n = 10, 50, 500$ при истинном $F = N(0,1)$. С ростом n ступенчатая $\widehat{F}_n$ равномерно приближается к гладкой F.

Непараметрический бутстреп. Выборка из $\widehat{F}_n$ — это просто выбор n значений из $\{X_1, \dots, X_n\}$ *с возвращением*. Перебрать *все* возможные подвыборки нельзя — их n^n (уже при $n = 20$ это превышает 10^{26}), — поэтому распределение реплик приближают *методом Монте-Карло*: разыгрываем B подвыборок и работаем с эмпирическим распределением полученных реплик. В этом смысле бутстреп и есть Монте-Карло, в котором «модель» p заменена эмпирическим $\widehat{F}_n$ (ср. § 8.3).

Непараметрический бутстреп для $\widehat{\mathrm{se}}$ и доверительного интервала.

1. Для $b = 1, \dots, B$: построить бутстреп-выборку $X_1^{*b}, \dots, X_n^{*b}$, выбирая n наблюдений из исходных с возвращением; вычислить реплику $\widehat{\theta}^{*b} = T(\widehat{F}_n^{*b})$.
2. Оценить стандартную ошибку как выборочное стандартное отклонение реплик: $\widehat{\mathrm{se}}_{\mathrm{boot}} = \sqrt{\frac{1}{B-1}\sum_b (\widehat{\theta}^{*b} - \overline{\widehat{\theta}^{*}})^2}$.
3. Построить доверительный интервал (см. § 8.2, «Виды доверительных интервалов»).

Параметрический бутстреп. Если есть параметрическая модель F_η, оцениваем $\widehat{\eta}$ по данным и разыгрываем бутстреп-выборки из $F_{\widehat{\eta}}$ (а не из $\widehat{F}_n$). Это эффективнее при верной модели, но платой служит риск смещения из-за неверной модели.

Пример 8.2.2. усть выборка $x = (2, 5, 9, 9, 14)$, $n = 5$, и нас интересует медиана: $\widehat{\theta} = \mathrm{med}(x) = 9$. Одна бутстреп-выборка — это 5 значений, взятых из x *с возвращением*; например, по индексам $(3, 1, 3, 5, 3)$ получаем $x^{*1} = (9, 2, 9, 14, 9)$, после сортировки $(2, 9, 9, 9, 14)$, медиана $\widehat{\theta}^{*1} = 9$; по индексам $(1, 2, 2, 4, 1)$ — $x^{*2} = (2, 5, 5, 9, 2)$, сортировка $(2, 2, 5, 5, 9)$, медиана $\widehat{\theta}^{*2} = 5$. Повторив это B раз, получаем набор реплик $\{\widehat{\theta}^{*b}\}$; их выборочное стандартное отклонение и есть $\widehat{\mathrm{se}}_{\mathrm{boot}}$, а квантили — доверительный интервал. На практике B — тысячи, но механика на каждой реплике

одна реплика вручную

именно такая.

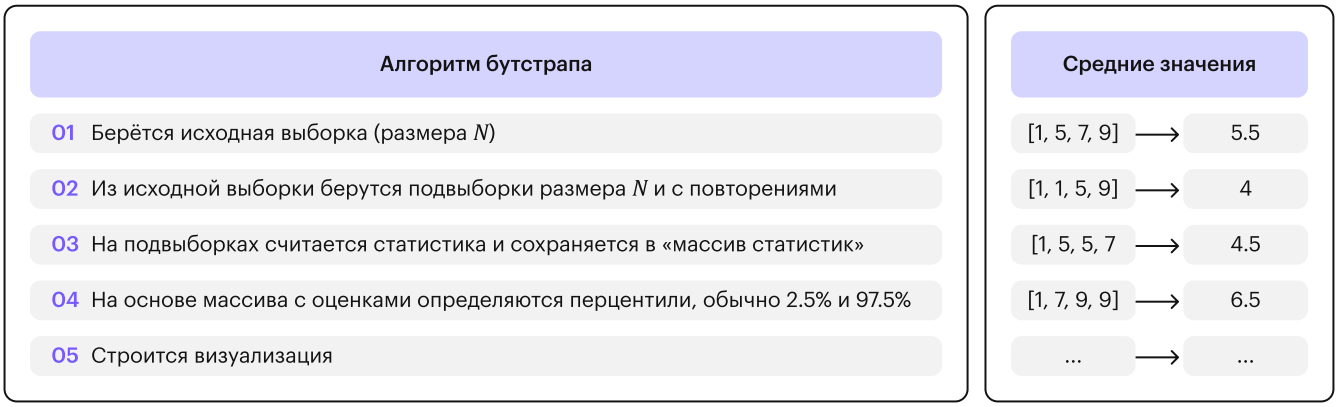

Рисунок 90. Бутстреп: определение и алгоритм. Из исходной выборки размера N многократно берут подвыборки того же размера *с возвращением*, на каждой считают статистику и собирают «массив статистик», по которому затем определяют перцентили (обычно 2.5% и 97.5%).

Стандартная ошибка, смещение и джекнайф

Бутстреп оценивает не только разброс, но и *смещение*: $\widehat{\mathrm{bias}}_{\mathrm{boot}} = \overline{\widehat{\theta}^*} - \widehat{\theta}$, где $\overline{\widehat{\theta}^*} = \frac{1}{B}\sum_b \widehat{\theta}^{*b}$. Скорректированная оценка — $2\widehat{\theta} - \overline{\widehat{\theta}^*}$ (применять осторожно: коррекция часто увеличивает дисперсию).

Джекнайф — предшественник бутстрепа: вместо случайной повторной выборки последовательно удаляют по одному наблюдению. Пусть $\widehat{\theta}_{(i)} = T(\widehat{F}_n \text{ без } X_i)$ и $\overline{\widehat{\theta}}_{(\cdot)} = \frac{1}{n}\sum_i \widehat{\theta}_{(i)}$. Тогда

$$\widehat{\mathrm{se}}_{\mathrm{jack}} = \sqrt{\frac{n-1}{n}\sum_{i=1}^{n}\left(\widehat{\theta}_{(i)} - \overline{\widehat{\theta}}_{(\cdot)}\right)^2}.$$

Джекнайф — это линейное приближение бутстрепа; он дёшев, но *ломается для негладких статистик* (медиана, квантили). Величины $\widehat{\theta}_{(i)}$ используются для оценки ускорения a в интервале BCa.

Виды доверительных интервалов

Существует целая иерархия бутстреп-интервалов — от простых, но грубых, до сложных, но точных. На скошенном бутстреп-распределении (рис. 92) разные интервалы дают разные концы, поэтому выбор метода важен. Ниже разберём четыре основных вида по нарастанию точности.

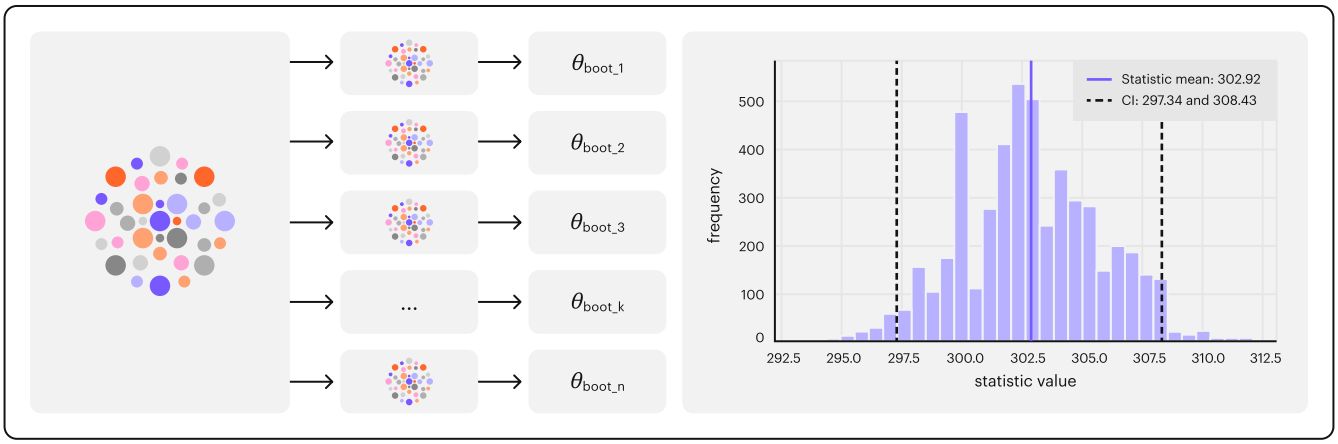

Рисунок 91. Схема построения доверительного интервала бутстрепом: из выборки порождаются реплики $\theta_{\text{boot_1}}, \ldots, \theta_{\text{boot_}n}$, по их распределению считаются среднее и границы интервала (здесь $[297.34, 308.43]$).

Обозначим через $\widehat{\theta}^*_{(\alpha)}$ выборочный α-квантиль бутстреп-реплик. Все интервалы ниже — уровня $1 - 2\alpha$ (например, $\alpha = 0.025$ даёт 95%).

1. **Перцентильный интервал.** Самый прямой: берём квантили реплик «как есть»,
$$\left[\widehat{\theta}^*_{(\alpha)},\ \widehat{\theta}^*_{(1-\alpha)}\right].$$
Почему это работает. Если бутстреп-распределение реплик повторяет форму истинного распределения оценки $\widehat{\theta}$ (а Гливенко–Кантелли это и обещает), то его центральные 95% и есть доверительный интервал. Для симметричных распределений он согласуется с привычным $\widehat{\theta} \pm z_{1-\alpha}\,\widehat{\mathrm{se}}$ из предыдущих глав, но *автоматически* ловит асимметрию — не требуя ни формулы стандартной ошибки, ни предположения о нормальности. Минус: при заметном смещении оценки концы сдвинуты.
2. **Базовый интервал (basic / pivotal).**
$$\left[2\widehat{\theta} - \widehat{\theta}^*_{(1-\alpha)},\ 2\widehat{\theta} - \widehat{\theta}^*_{(\alpha)}\right].$$
Идея. Работаем не с самими репликами, а с *отклонениями* $\widehat{\theta}^* - \widehat{\theta}$, считая их «опорной» величиной с примерно тем же распределением, что и $\widehat{\theta} - \theta$. Отражение квантилей отклонений вокруг $\widehat{\theta}$ и даёт интервал. Часто точнее перцентильного при смещении, но может «вылезать» за допустимые границы параметра (например, давать отрицательную дисперсию).
3. **Студентизированный интервал (bootstrap-t).** Для каждой реплики дополнительно считаем её стандартную ошибку $\widehat{\mathrm{se}}^{*b}$ и моделируем «t-статистику» $t^{*b} = (\widehat{\theta}^{*b} - \widehat{\theta})/\widehat{\mathrm{se}}^{*b}$; затем
$$\left[\widehat{\theta} - \widehat{\mathrm{se}}\, t^*_{(1-\alpha)},\ \widehat{\theta} - \widehat{\mathrm{se}}\, t^*_{(\alpha)}\right].$$
Зачем сложности. Это прямое обобщение t-интервала для среднего на произвольную статистику. Студентизация делает величину (асимптотически) *опорной* — её распределение почти не зависит от неизвестных параметров, — и за счёт этого интервал достигает *второго порядка* точности (см. § 8.2,

«Состоятельность...»). Цена — вложенный бутстреп или аналитическая $\widehat{\mathrm{se}}^{*b}$ на каждой реплике.

перцентильный интервал по репликам

Пример 8.2.3. усть получено $B = 1000$ бутстреп-реплик медианы, отсортированных по возрастанию: $\widehat{\theta}^*_{(1)} \leqslant \dots \leqslant \widehat{\theta}^*_{(1000)}$. Для 95% перцентильного интервала нужны 2.5% и 97.5% квантили, то есть 25-я и 975-я порядковые статистики (поскольку $0.025 \cdot 1000 = 25$). Если, например, $\widehat{\theta}^*_{(25)} = 4.1$ и $\widehat{\theta}^*_{(975)} = 7.3$, то интервал — $[4.1, 7.3]$. Никакой формулы для стандартной ошибки медианы не понадобилось.

4. **Интервал BCa** (bias-corrected and accelerated) — корректирует и смещение, и асимметрию. Концы берутся как перцентили *скорректированных* уровней

$$\alpha_1 = \Phi\left(z_0 + \frac{z_0 + z_\alpha}{1 - a(z_0 + z_\alpha)} \right),$$
$$\alpha_2 = \Phi\left(z_0 + \frac{z_0 + z_{1-\alpha}}{1 - a(z_0 + z_{1-\alpha})} \right),$$

где $z_\alpha = \Phi^{-1}(\alpha)$, поправка на смещение $z_0 = \Phi^{-1}\big(\#\{\widehat{\theta}^{*b} < \widehat{\theta}\}/B\big)$, а ускорение a оценивается через джекнайф:

$$a = \frac{\sum_{i=1}^{n} \big(\bar{\widehat{\theta}}_{(\cdot)} - \widehat{\theta}_{(i)}\big)^3}{6\Big[\sum_{i=1}^{n} \big(\bar{\widehat{\theta}}_{(\cdot)} - \widehat{\theta}_{(i)}\big)^2\Big]^{3/2}}.$$

При $z_0 = a = 0$ BCa вырождается в перцентильный. Он трансформационно-инвариантен и точен до второго порядка — это интервал *по умолчанию* в большинстве пакетов.

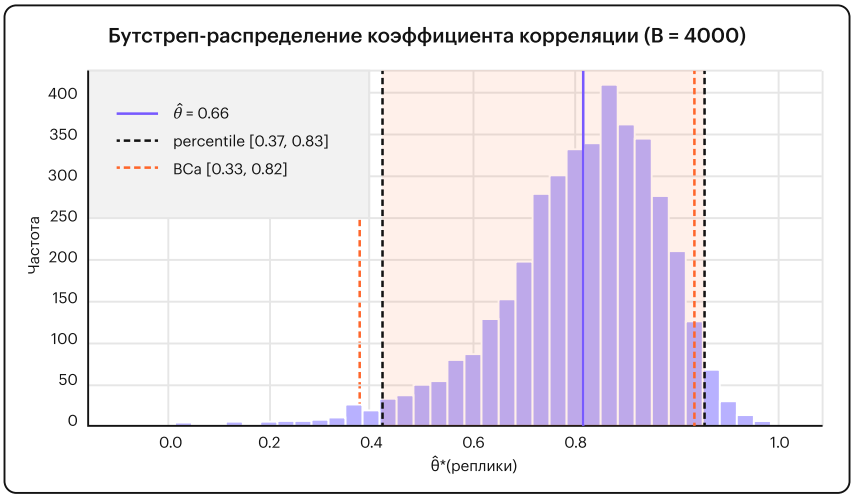

Рисунок 92. Бутстреп-распределение коэффициента корреляции ($n = 25$, $B = 4000$). Распределение скошено, поэтому BCa-интервал сдвинут относительно перцентильного, корректируя смещение и асимметрию.

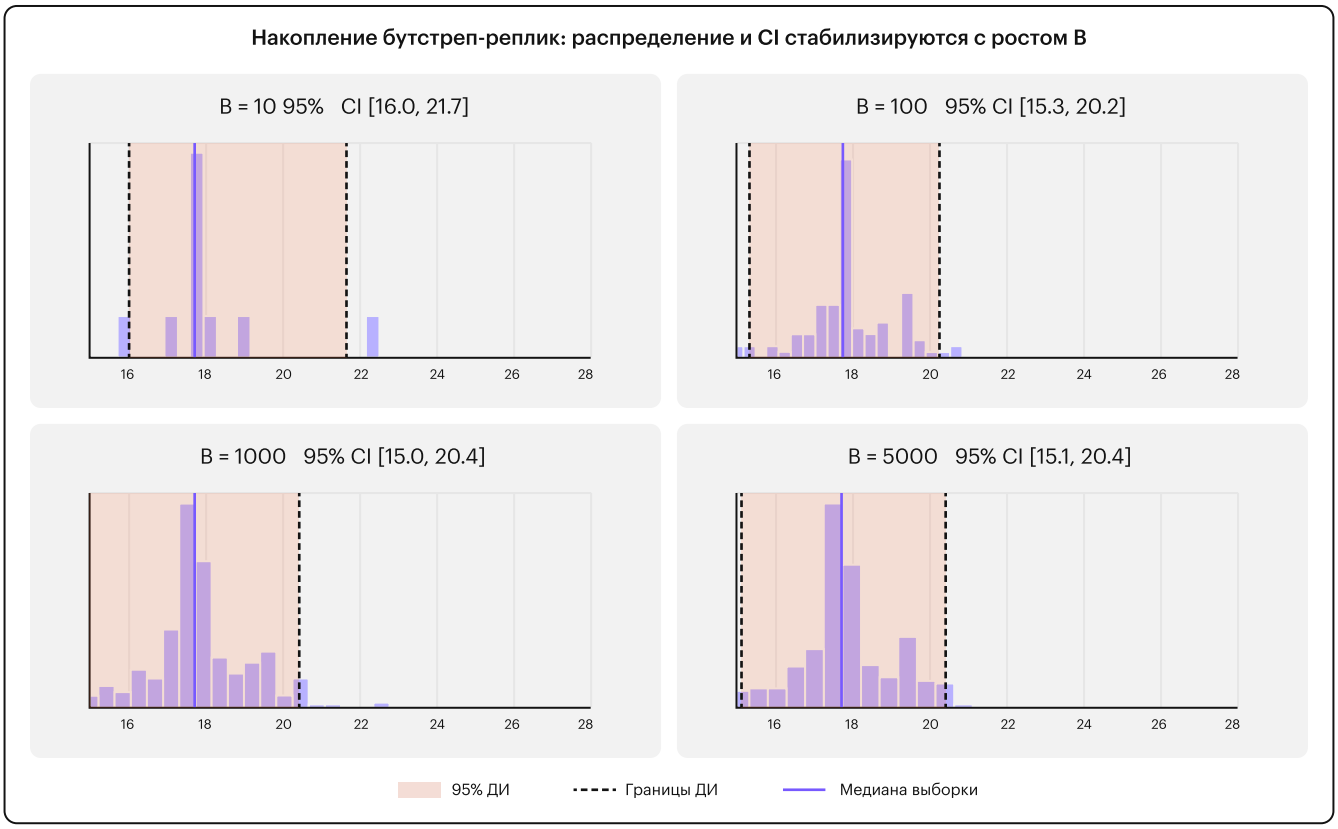

Рисунок 93. Накопление бутстреп-реплик медианы для $B = 10, 100, 1000, 5000$. Точечная оценка (чёрная линия) фиксирована данными; с ростом B стягиваются лишь *вычислительный* разброс реплик и границы CI. Это иллюстрирует ключевую мысль § 8.3: B управляет вычислительным шумом, а статистическую точность задаёт размер выборки n.

Бутстреп для разных статистик: среднее, пропорция, дисперсия, квантили

Главная сила бутстрепа — *единообразие*. То, что в предыдущих главах строилось отдельными формулами (интервал для среднего, для доли, для дисперсии), бутстреп получает одним и тем же приёмом: переразыграть выборку, посчитать нужную статистику, взять перцентили.

Подчеркнём: один и тот же цикл «переразыграй — посчитай — возьми перцентили» покрывает среднее, долю, дисперсию, квантили и любую другую статистику. Именно поэтому бутстреп — универсальный инструмент построения доверительных интервалов, тогда как формульный подход требует своего вывода под каждую статистику. Ниже — одна и та же схема для четырёх разных статистик.

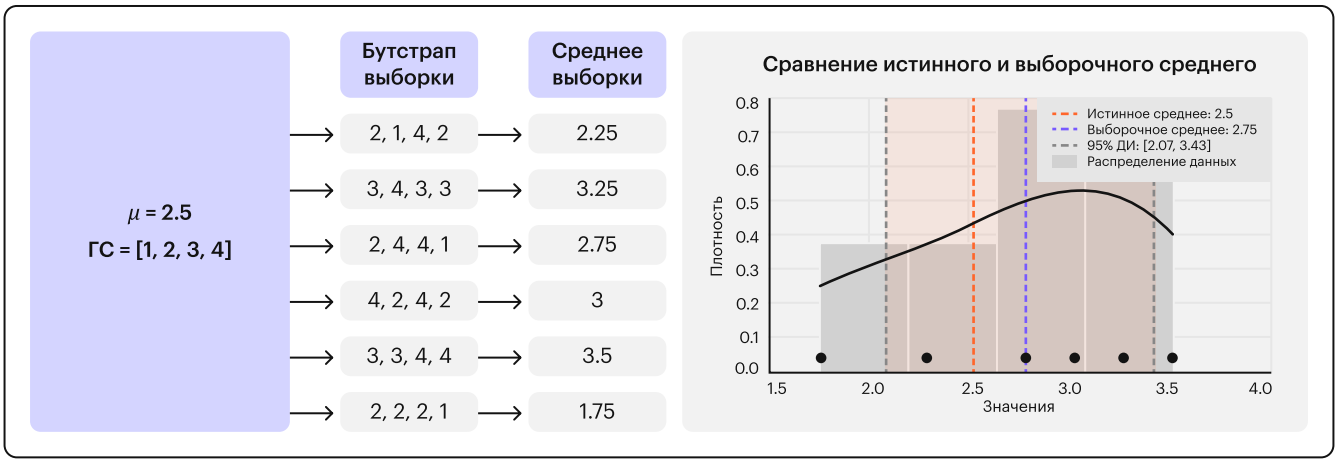

Рисунок 94. Бутстреп для **среднего** на игрушечной ГС $[1, 2, 3, 4]$ ($\mu = 2.5$): подвыборки с возвращением дают распределение выборочных средних и 95%-й интервал. Ср. с формульным интервалом из главы «Доверительный интервал для мат. ожидания».

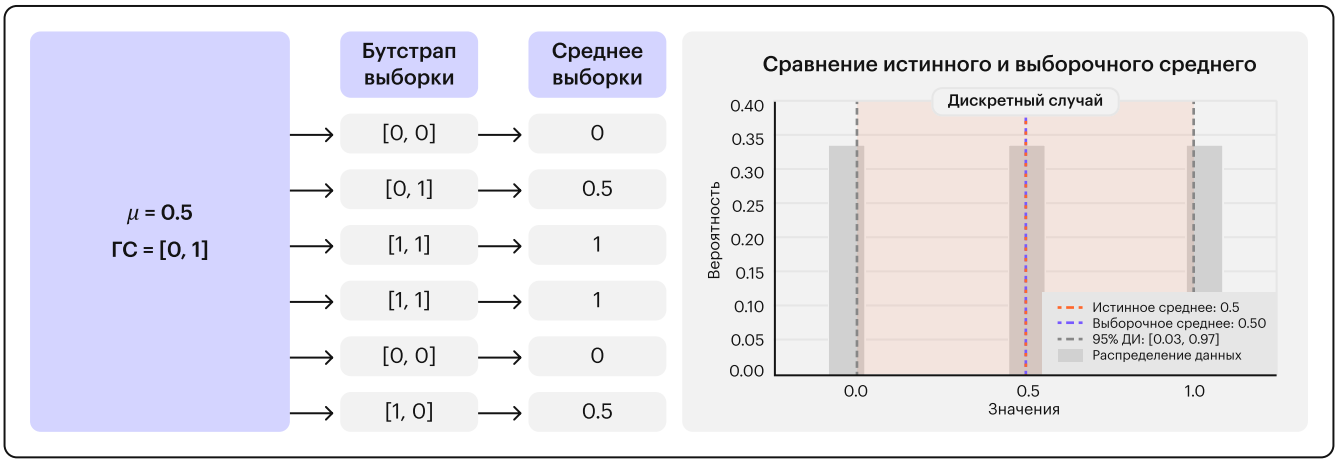

Рисунок 95. Бутстреп для **пропорции** (дискретная ГС $[0, 1]$, $\mu = 0.5$). Тот же приём для доли; ср. с интервалом из главы «Доверительный интервал для пропорции».

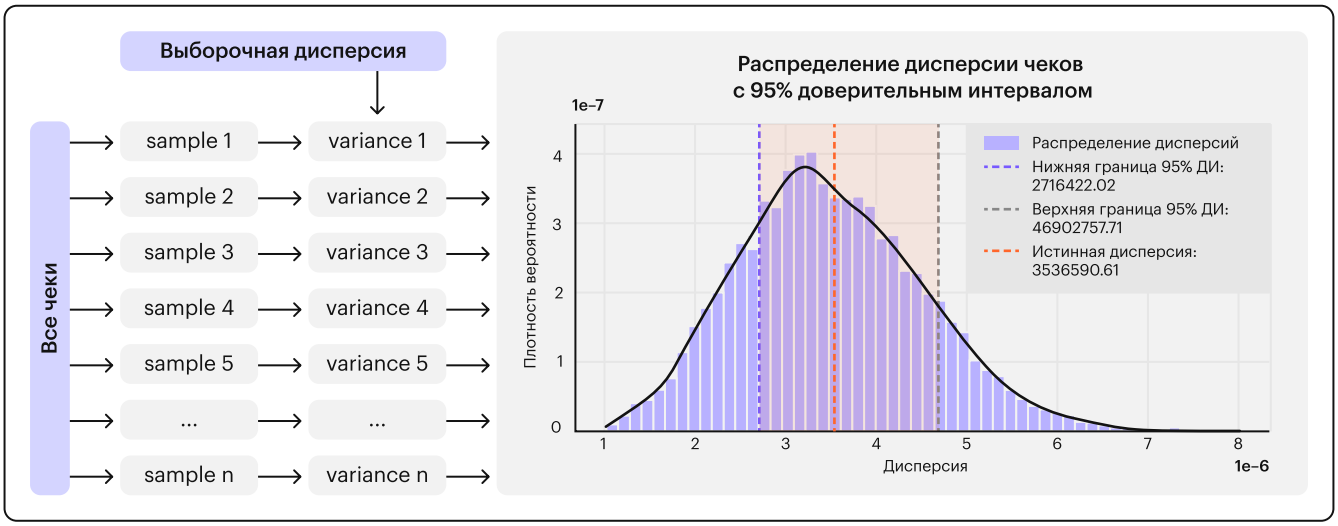

Рисунок 96. Бутстреп для **дисперсии** (суммы чеков): на каждой подвыборке считается выборочная дисперсия, по распределению — 95%-й интервал.

Квантили — отдельный сюжет. Возьмём равномерную ГС на $[0, 10]$ (рис. 97): её медиана ≈ 4.97, третий квартиль ≈ 7.44. Аналитические формулы для квантилей особенно неудобны, а бутстреп строит интервал тем же циклом «переразыграй $\to$ посчитай квантиль $\to$ возьми перцентили». Рис. **??** показывает бутстреп-распределения обоих квантилей при разном числе реплик B, и из него видно две вещи. *Во-первых*, рост B ($50 \to 1000$) не сдвигает оценку, а лишь сглаживает гистограмму: это монте-карловская точность *самого бутстрепа*, а не точность по данным (добавив реплик, мы аккуратнее очерчиваем одно и то же распределение, но не получаем новой информации о ГС). *Во-вторых*, распределение третьего квартиля скошено и прижато к верхнему краю — бутстреп-квантиль не может превысить максимальное наблюдение выборки, поэтому у *краевых* квантилей распределение асимметрично. Это важная оговорка при работе с хвостами: перцентильный интервал для далёких квантилей смещён, и здесь предпочтительнее BCa.

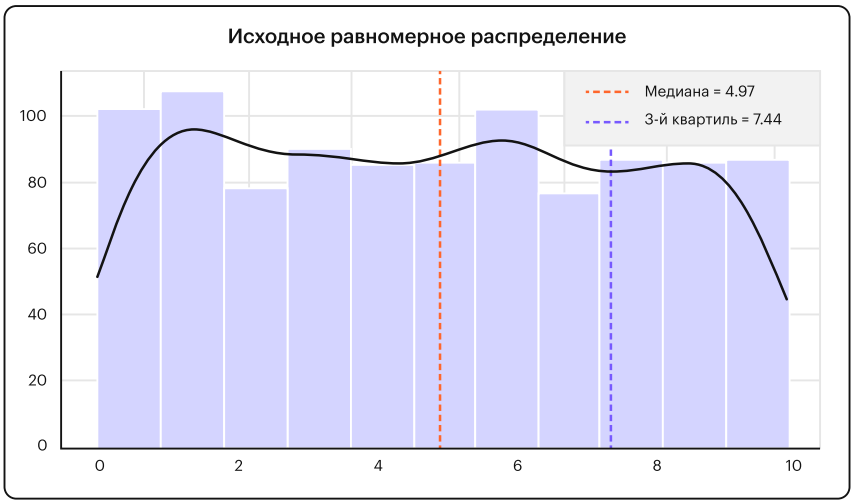

Рисунок 97. Исходная равномерная ГС для примера с квантилями. Красная линия — медиана (≈ 4.97), зелёная — третий квартиль (≈ 7.44); это точечные оценки по исходной выборке, вокруг которых концентрируются бутстреп-реплики.

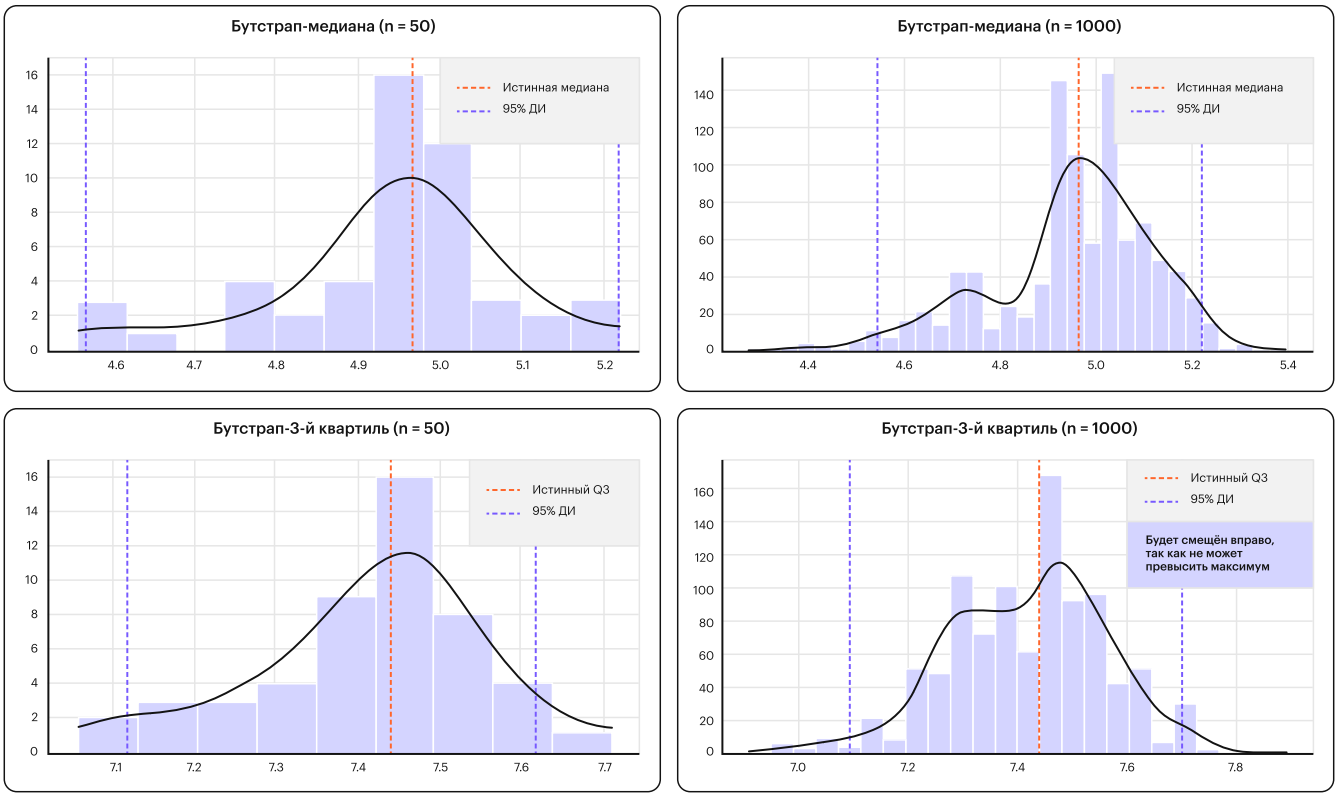

Рисунок 98. Бутстреп для **квантилей** на равномерной ГС. Верхний ряд — бутстреп-распределение *медианы*, нижний — *третьего квартиля*; слева $B = 50$ реплик, справа $B = 1000$. Пунктирная вертикаль (красная/зелёная) — оценка по исходной выборке, точечный пунктир — границы 95%-го перцентильного интервала. Рост B сглаживает распределение, не смещая оценку; распределение Q_3 скошено вправо из-за верхней границы выборки.

Бутстреп для ratio-метрик

Многие продуктовые метрики — это *отношения* со случайным знаменателем: конверсия на сессию $r = \mathbb{E}[X]/\mathbb{E}[Y]$, средний доход на пользователя (ARPU), CTR. Оценка $\widehat{r} = \sum_i X_i / \sum_i Y_i$ — не среднее, а отношение двух сумм, поэтому формула дисперсии для среднего к ней неприменима, а данные обычно *кластеризованы*: у одного пользователя несколько событий.

Интуиция: что именно ресэмплировать. Неопределённость метрики порождается тем, что у нас *случайный набор пользователей*, а не случайный набор отдельных событий. Поэтому переразыгрывать надо *пользователей целиком* (со всеми их событиями), а не отдельные строки. Если ресэмплировать события, мы притворимся, будто независимых наблюдений больше, чем есть, и *занизим* разброс — особенно когда у активных пользователей много событий.

Кластерный (по пользователям) бутстреп для ratio-метрики.

1. Единица ресэмплинга — пользователь u с парой сумм $\big(X_u, Y_u\big) = \big(\sum_{j \in u} X_j,\, \sum_{j \in u} Y_j\big)$.
2. Для $b = 1, \dots, B$: выбрать m пользователей из m имеющихся *с возвращением*; на этой подвыборке посчитать реплику $\widehat{r}^{*b} =$

$\frac{\sum_u X_u^{*b}}{\sum_u Y_u^{*b}}$.

3. 95%-й доверительный интервал — 2.5% и 97.5% перцентили реплик $\{\widehat{r}^{*b}\}$ (или, аккуратнее, BCa).

Этот приём *автоматически* учитывает и случайный знаменатель, и внутрипользовательскую корреляцию — без вывода каких-либо формул.

конверсия на сессию, по шагам

Пример 8.2.4. ри пользователя, пары (покупки X_u, сессии Y_u): $u_1 = (1,2)$, $u_2 = (0,1)$, $u_3 = (3,4)$.

Шаг 1 (точечная оценка). $\widehat{r} = \dfrac{1+0+3}{2+1+4} = \dfrac{4}{7} \approx 0.571.$

Шаг 2 (реплики). Выбираем пользователей с возвращением. Подвыборка $\{u_1, u_1, u_3\}$: $\widehat{r}^* = \dfrac{1+1+3}{2+2+4} = \dfrac{5}{8} = 0.625$. Подвыборка $\{u_2, u_3, u_3\}$: $\widehat{r}^* = \dfrac{0+3+3}{1+4+4} = \dfrac{6}{9} \approx 0.667$.

Шаг 3 (интервал). Накопив B таких реплик, берём их перцентили — это и есть доверительный интервал для конверсии. Обратите внимание: пользователь всегда входит *целиком* (обе его суммы сразу), поэтому корреляция событий внутри пользователя учтена сама собой.

Для гладких отношений есть и быстрый аналитический путь — *дельта-метод* (линеаризация), введённый ранее в блоке о методах построения оценок. Он даёт замкнутую формулу $\operatorname{Var}(\widehat{r}) \approx \operatorname{Var}(L)/n$ через линеаризованную величину $L_i = (X_i - \widehat{r}\,Y_i)/\bar{Y}$ и потому в тысячи раз дешевле бутстрепа на больших данных — именно так дисперсию ratio-метрик считают в production-платформах экспериментов. Бутстреп же незаменим, когда важна конечно-выборочная асимметрия или статистика негладкая; на больших n оба подхода практически совпадают.

Состоятельность и точность второго порядка

Состоятельность бутстрепа означает, что бутстреп-распределение корня $R_n = \sqrt{n}(\widehat{\theta} - \theta)$ сходится к тому же пределу, что и истинное: $\sup_x |\mathrm{P}^*\{R_n^* \leqslant x\} - \mathrm{P}\{R_n \leqslant x\}| \xrightarrow{P} 0$, где P^* — бутстреп-вероятность при фиксированных данных. Но ценность бутстрепа — в *скорости*. Разложение Эджворта функции распределения студентизированной статистики имеет вид

$$\mathrm{P}\{T_n \leqslant x\} = \Phi(x) + \frac{1}{\sqrt{n}} p_1(x)\phi(x) + O(n^{-1}),$$

где p_1 — полином, зависящий от асимметрии. Нормальное приближение (то самое, что в главе про ДИ для среднего) игнорирует член $n^{-1/2}p_1\phi$ — ошибка $O(n^{-1/2})$. Бутстреп студентизированной (асимптотически опорной) статистики *воспроизводит* член порядка $n^{-1/2}$ и ошибается лишь на $O(n^{-1})$ — это и есть точность второго порядка. Механизм таков: бутстреп-аналог имеет своё разло-

жение Эджворта

$$\mathrm{P}^*\{T_n^* \leqslant x\} = \Phi(x) + \frac{1}{\sqrt{n}}\widehat{p}_1(x)\phi(x) + O_p(n^{-1}),$$

в котором коэффициенты $\widehat{p}_1$ — это выборочные версии p_1 (они зависят лишь от моментов, а выборочные моменты состоятельны: $\widehat{p}_1 - p_1 = O_p(n^{-1/2})$). Вычитая два разложения, $\mathrm{P}^*\{T_n^* \leqslant x\} - \mathrm{P}\{T_n \leqslant x\} = \frac{1}{\sqrt{n}}\big(\widehat{p}_1(x) - p_1(x)\big)\phi(x) + O_p(n^{-1}) = O_p(n^{-1})$, тогда как нормальное приближение отбрасывает весь член $n^{-1/2}p_1\phi$ и потому даёт лишь $O(n^{-1/2})$. Ключ — *студентизация* (опорность), а не бутстреп сам по себе: только для (асимптотически) опорной статистики ведущий поправочный член зависит от моментов, которые бутстреп оценивает состоятельно.

условие нерешётчатости

ЗАМЕЧАНИЕ

Само разложение Эджворта (а с ним и преимущество второго порядка) требует, чтобы распределение было *нерешётчатым* (условие Крамера: $\limsup_{|t|\to\infty}|\varphi(t)| < 1$ для характеристической функции φ) и обладало достаточным числом моментов. Для *решётчатых* данных — счётчиков, **биномиальных долей** (что прямо относится к главе о ДИ для пропорции и к A/B по конверсии) — в разложении появляется дополнительный осциллирующий член порядка $n^{-1/2}$, и гладкого выигрыша второго порядка без поправки на непрерывность может не быть. На практике для долей это означает: не стоит ожидать от бутстрепа автоматического превосходства над аккуратным нормальным интервалом с поправкой на непрерывность.

Когда бутстреп ломается

Интуиция. Бутстреп верит, что выборка — хорошая «копия» генеральной совокупности. Эта вера подводит там, где результат определяется *редкими краями* данных, а не их «массой». Типичные провалы:

1. **Оценивание границы носителя.** Для $\widehat{\theta} = \max_i X_i$ при $X \sim \mathrm{Unif}(0,\theta)$ бутстреп *несостоятелен*: реплика максимума совпадает с исходным максимумом с вероятностью $1-(1-1/n)^n \to 1 - e^{-1} \approx 0.63$, поэтому бутстреп-распределение имеет атом и не приближает предельное.
2. **Тяжёлые хвосты / бесконечная дисперсия.** Для среднего при $\mathrm{Var} = \infty$ обычный бутстреп несостоятелен; помогает m-out-of-n бутстреп или subsampling.
3. **Зависимые данные.** Для временных рядов нужен блочный бутстреп.

Варианты ресэмплинга: пуассоновский и wild бутстреп

Базовый алгоритм переразыгрывает выборку «как есть». Но в двух важных ситуациях схему ресэмплинга меняют: когда данных слишком много для одной машины (пуассоновский бутстреп) и когда

наблюдения неоднородны по дисперсии (wild бутстреп). Удобно смотреть на бутстреп через *веса*: реплику статистики можно записать как взвешенную версию данных, где наблюдению i приписан случайный вес w_i. Обычный бутстреп соответствует вектору весов $(w_1, \dots, w_n) \sim \mathrm{Multinomial}(n; 1/n, \dots, 1/n)$: w_i — сколько раз X_i попало в подвыборку, и $\sum_i w_i = n$ *детерминированно*.

Пуассоновский бутстреп. Заменим совместное мультиномиальное распределение весов на *независимые* $w_i \overset{\text{н.о.р.}}{\sim} \mathrm{Poisson}(1)$. Это корректное приближение обычного бутстрепа: у мультиномиальных весов $\mathbb{E} w_i = 1$, $\operatorname{Var} w_i = 1 - 1/n$, у пуассоновских $\mathbb{E} w_i = \operatorname{Var} w_i = 1$, и при $n \to \infty$ схемы совпадают. Реплика статистики-среднего принимает вид

$$\widehat{\theta}^* = \frac{\sum_{i=1}^n w_i X_i}{\sum_{i=1}^n w_i}, \qquad w_i \overset{\text{н.о.р.}}{\sim} \mathrm{Poisson}(1).$$

Зачем это нужно. Жёсткая связь $\sum_i w_i = n$ — единственное, что мешало обрабатывать наблюдения независимо. Пуассоновские веса независимы, поэтому $\sum_i w_i$ больше не фиксирована, и каждое наблюдение можно взвешивать по отдельности — не зная n заранее и не храня всю выборку. Это делает пуассоновский бутстреп стандартом для *потоковых и распределённых* данных: каждую строку логов реплицируют на лету и независимо на разных машинах (для B реплик сразу разыгрывают вектор $(w_i^{(1)}, \dots, w_i^{(B)})$ на каждое наблюдение). Именно так считают бутстреп-интервалы на больших данных в продуктовых A/B-платформах.

пуассоновские веса вручную

Пример 8.2.5. усть $x = (2, 5, 9, 9, 14)$. Разыгрываем независимые $w_i \sim \mathrm{Poisson}(1)$, например $w = (0, 2, 1, 0, 1)$: наблюдение 5 входит с весом 2, наблюдения 9 (третье) и 14 — с весом 1, а 2 и 9 (четвёртое) выпадают. Реплика среднего —

$$\frac{0 \cdot 2 + 2 \cdot 5 + 1 \cdot 9 + 0 \cdot 9 + 1 \cdot 14}{0 + 2 + 1 + 0 + 1} = \frac{33}{4} = 8.25.$$

Сумма весов здесь оказалась $4 \neq 5$ — в отличие от обычного бутстрепа, и это нормально. Повторяя розыгрыш весов B раз, получаем распределение реплик и далее $\widehat{\mathrm{se}}$ и интервал — как обычно.

Wild бутстреп (бутстреп с перевзвешиванием остатков) предназначен для регрессии с *гетероскедастичностью* (дисперсия ошибки зависит от x), где обычный ресэмплинг наблюдений некорректен. Идея: зафиксировать регрессоры и подгонку, а *остатки* умножать на случайный множитель. Пусть оценены $\widehat{\beta}$ и остатки $\widehat{r}_i = y_i - x_i^\top \widehat{\beta}$. Бутстреп-отклик строится как

$$y_i^* = x_i^\top \widehat{\beta} + v_i \widehat{r}_i, \qquad \mathbb{E} v_i = 0,\ \mathbb{E} v_i^2 = 1,$$

с независимыми весами v_i; затем модель переоценивается на (x_i, y_i^*). Поскольку каждый остаток масштабируется *индивидуально*, схема сохраняет привязку дисперсии ошибки к своему x_i и даёт гетероскедастично-устойчивые интервалы. Типичные веса: *радемахеровские* $v_i = \pm 1$ с вероятностью $1/2$ (тогда $\mathbb{E} v_i = 0, \mathbb{E} v_i^2 = 1$,

$\mathbb{E}v_i^3 = 0$) или двухточечные веса Маммена, дополнительно подгоняющие третий момент.

Пример 8.2.6. усть после МНК-подгонки остатки $\widehat{r} = (0.4, -1.2, 0.9, -0.1)$, а предсказания $\widehat{y}_i = x_i^\top \widehat{\beta}$ известны.

рademахеровские веса, по шагам

Шаг 1 (знаки). Разыгрываем независимые $v_i = \pm 1$ (вероятность $1/2$ каждый), скажем $v = (+1, -1, -1, +1)$.

Шаг 2 (возмущённые остатки). $v_i \widehat{r}_i = (0.4,\ 1.2,\ -0.9,\ -0.1)$ — у второго и третьего наблюдения знак остатка перевернулся.

Шаг 3 (новый отклик). $y_i^* = \widehat{y}_i + v_i \widehat{r}_i$: к каждому предсказанию добавляем его возмущённый остаток.

Шаг 4 (переоценка). На паре (x_i, y_i^*) заново считаем МНК и получаем $\widehat{\beta}^*$. Повторив шаги 1–4 B раз, берём перцентили $\{\widehat{\beta}^*\}$ — устойчивый к гетероскедастичности интервал для коэффициента. Заметьте: x_i *не трогаем* — переразыгрывается только случайная часть отклика.

3. РАЗНИЦА МЕЖДУ МЕТОДОМ МОНТЕ-КАРЛО И БУТСТРЕПОМ

Студенты часто путают два метода: оба «много раз разыгрывают случайность и усредняют». Различие — *в источнике случайности* и, как следствие, в том, на какой вопрос отвечает метод.

Ключевая мысль: **бутстреп — это метод Монте-Карло, применённый к эмпирическому распределению** $\widehat{F}_n$ вместо известной модели p. То есть бутстреп = Монте-Карло с $p := \widehat{F}_n$. Но это «равно» скрывает принципиальную разницу в том, что мы знаем и что оцениваем:

- **Монте-Карло** разыгрывает выборку из *заданной нами* модели p и отвечает на вопрос «чему равен интеграл/вероятность/матожидание *в этой модели*». Истина известна по построению; ошибка — только вычислительная и стремится к нулю при $N \to \infty$.
- **Бутстреп** разыгрывает выборку из *оценённого по данным* распределения $\widehat{F}_n$ и отвечает на вопрос «как распределена моя статистика / насколько широк доверительный интервал». Даже при $B \to \infty$ остаётся *статистическая* ошибка, потому что $\widehat{F}_n \neq F$.

Замечание (два разных «N»). В Монте-Карло число прогонов N — единственный рычаг точности. В бутстрепе *два* числа: размер выборки n (определяет *статистическую* точность — её не улучшить ресэмплингом) и число реплик B (определяет лишь *вычислительный* шум самой бутстреп-оценки). Увеличение B не компенсирует малое n: нельзя «доресэмплить» недостающие данные.

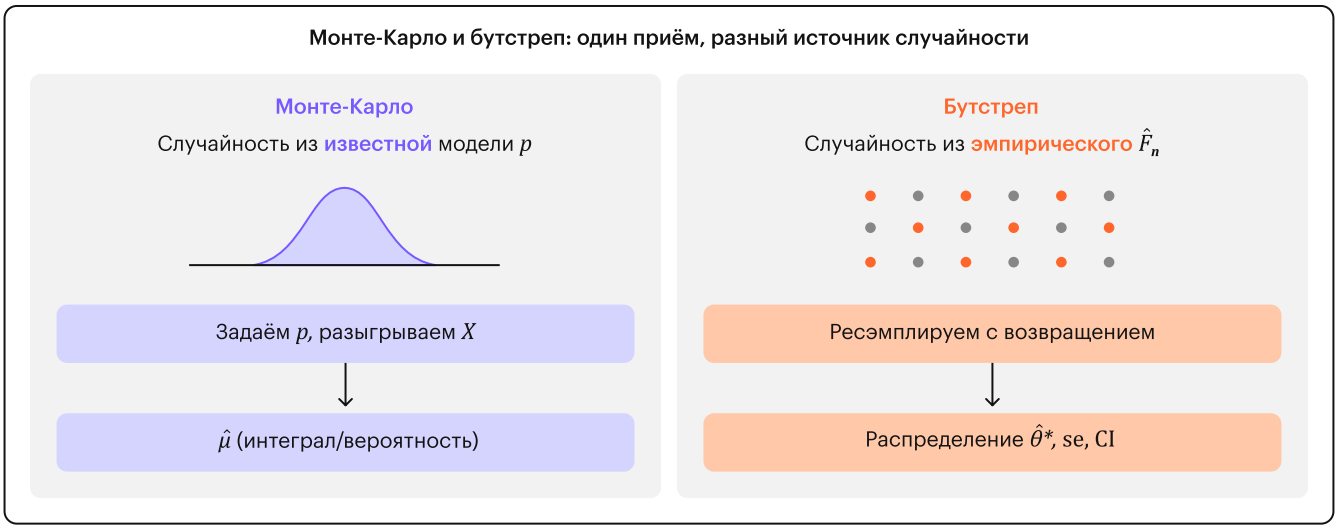

Рисунок 99. Один вычислительный приём — разный источник случайности. Монте-Карло разыгрывает выборку из *заданной* модели p (оценивает интеграл/вероятность); бутстреп — из *эмпирического* $\widehat{F}_n$, построенного по данным (оценивает распределение статистики, стандартную ошибку, CI).

Аспект	Монте-Карло	Бутстреп
Источник случайности	заданная модель p (мы её знаем/задаём)	эмпирическое $\widehat{F}_n$ (построено по данным)
Что разыгрываем	$X_i \sim p$	X_i^* из $\{x_1, \dots, x_n\}$ с возвращением
Типичная цель	интеграл, вероятность, матожидание	распределение статистики, $\widehat{\mathrm{se}}$, доверительный интервал
Главное допущение	модель p верна	выборка репрезентативна, n не мало, статистика гладкая
Что уменьшает ошибку	только число прогонов N	n (статистика) и B (вычисления) — *раздельно*
Предел при ∞ прогонов	точное значение *в модели*	распределение при выборке из $\widehat{F}_n$ (не из F!)

Таблица 3. Монте-Карло и бутстреп: один вычислительный приём, разные источник случайности и вопрос.

Когда что применять.

- *Есть данные, нужен доверительный интервал для статистики* → бутстреп; а если статистика — гладкая функция оценки с известной SE и важна скорость → дельта-метод, он вычислительно дешевле в тысячи раз.
- *Есть модель (или предположения о входах), нужно оценить вероятность/интеграл/будущее* → Монте-Карло.
- *Есть параметрическая модель, подогнанная по данным, и нужно распределение статистики* → параметрический бутстреп — пограничный случай, где грань между методами стирается.

Часть 9. Введение в гипотезы

1. ВВЕДЕНИЕ В ГИПОТЕЗЫ

В современном мире несложно узнать, какой моделью в конкретной ситуации воспользоваться и какие методы работы с ней помогут ответить на интересующий вопрос. Надо просто написать качественный промт. Но важно понимать, почему метод даёт такой ответ. Бездумное использование методов уже много раз очень дорого (в прямом смысле) обходилось компаниям, выбирающим стратегию развития на основе отчётов аналитиков.

Для того, чтобы математика начала работать, нам нужно построить математическую модель жизненной ситуации. В статистике её выбирают исходя из способа получения данных, на которых модель будет обучаться. Тут очень важно понять, что модель строится до получения данных, иначе есть искушение «подогнать» её под данные.

Пример 9.1.1. Предположим, вы наблюдаете за известной игрой, которая состоит в угадывании выпадающего цвета: красного или чёрного, выпадение которых подразумевается равновероятным. И вот у вас 10 раз подряд выпадает «чёрное». Если бы вы решили поспорить с кем-то, что выпадет на 11-м шаге, на что бы вы поставили?

Если вы начнете строить модель после получения результата, то есть искушение предположить, что вероятность «успеха» не $0{,}5$, хотя если игра честная, то вероятность вашего события: $0{,}5^{10} = 0{,}0009765625$. Фактически одна десятая процента. Маловато, но **события малой вероятности случаются**. В век соцсетей такие истории разносятся моментально и часто объявляются «волшебными», как в случае с Паулем.

При построении модели такого эксперимента нам нужно выяснить, насколько игра честная, а это зависит от того кто "крутит барабан и часто ли он обманывал раньше, наблюдали ли вы этот «барабан» раньше и какие были результаты и т.д.

Иногда случается, что о параметрах модели задаётся вопрос, ответ на который должен быть бинарным: да или нет.
Любое утверждение о виде или свойствах распределения наблюдаемых величин.

ОПРЕДЕЛЕНИЕ 9.1.1
Статистическая гипотеза

Пример 9.1.2. Мы нашли монетку возле железнодорожных путей и хотим узнать, испорчена ли она. Под испорченностью мы понимаем, что орёл и решка выпадают с разными вероятностями.

Иными словами, наблюдаются независимые случайные величины, имеющие бернуллиевское распределение (принимает значение 1 (орёл) с вероятностью θ, $\theta \in (0; 1)$, и 0 (решка) с вероятно-

стью $1 - \theta$).

Верно ли, что $\theta = 0.5$?

Пример 9.1.3. Основатель генетики Грегор Мендель вывел теоретический закон распределения бобов по определённым типам: зелёные и жёлтые, а также круглые и морщинистые.

Ему необходимо проверить, совпадают ли теоретические генетические частоты, следующие из его закона, эмпирическим (реальным) частотам.

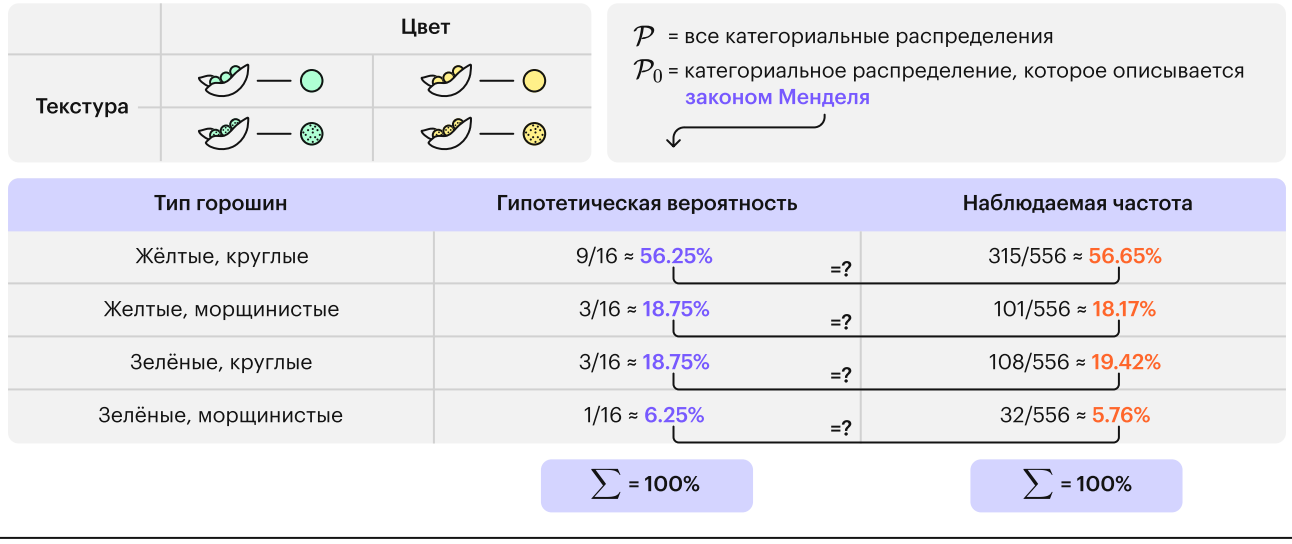

Можно ответить на этот вопрос с помощью проверки статистических гипотез.

Формализация постановки задачи

Итак, у нас есть сет данных $\boldsymbol{x} = (x_1, x_2, \ldots, x_n)$, который является реализацией набора случайных величин $\boldsymbol{X} = (X_1, X_2, \ldots, X_n)$, называемого выборкой. Все элементы выборки имеют некоторое распределение P. Мы проверяем гипотезу $H_0 : P \in \in \mathcal{P}_0$ против альтернативы $H_1 : P \in \mathcal{P}_1$, где $\mathcal{P}_0$ и $\mathcal{P}_1$ суть непересекающиеся семейства распределений.

То есть имеется в виду следующее: мы проверям, верна ли гипотеза H_0, и если предполагаем, что неверна, то мы отвергаем её в пользу альтернативной гипотезы H_1.

Стоит отметить, что в задаче параметрической статистики предполагается, что все распределения параметризуются некоторым параметром θ, то есть все распределения $P = P_\theta \in \mathcal{P}_i$ однозначно определяются параметром $\theta \in \Theta_i$ для $i \in \{0, 1\}$.

Тогда гипотезы выглядят так:

$$H_0 : \theta \in \Theta_0;$$
$$H_1 : \theta \in \Theta_1.$$

Наша задача — сформулировать правило, с помощью которого мы сможем, опираясь на значения выборки, отвечать «верно» или «неверно» на утверждение, сформулированное в гипотезе H_0. Получается, мы будем раскрашивать множество возможных значений выборки, которое мы называем генеральной совокупностью, в два цвета: белый («верно») и чёрный («неверно»).

Если сет данных попадёт в белую область, то гипотеза не отвергается, а если в чёрную, то отвергается.
Некоторое подмножество в $\mathbb{R}^n$.

ОПРЕДЕЛЕНИЕ 9.1.2
Критическое множество

ОПРЕДЕЛЕНИЕ 9.1.3
Статистический критерий

При фиксированных гипотезах H_0 и H_1 правило, по которому основную гипотезу H_0 отвергают в пользу альтернативы H_1, если вектор наблюдений попал в критическое множество.

Мы не будем различать понятия критерия и критического множества и называть критерием само множество K.

Пример 9.1.4. Начальник бухгалтерии Марина Николаевна в последнее время начала приходить на работу намного раньше начала рабочего дня, который стартует в 9:00. Сотрудники охраны предположили, что Марина Николаевна приходит на работу раньше всех своих сотрудников. Чтобы подтвердить или опровергнуть эту гипотезу, они целую неделю наблюдали за бухгалтерией и фиксировали время прихода всех сотрудников, включая Марину Николаевну. Как будет выглядеть критерий для проверки такой гипотезы?

Формализуем задачу: X_i — время прихода Марины Николаевны на работу в i-й день наблюдений, Y_i — время прихода самого раннего сотрудника. Проверяется гипотеза $H_0 : X_i < Y_i$ для всех i против альтернативы $H_1 : X_i > Y_i$ для некоторого i. Тогда можно определить критерий так:

$$\{(\boldsymbol{x}, \boldsymbol{y}) : \boldsymbol{x}, \boldsymbol{y} \in [6{:}00; 9{:}00]^5 \text{ и для некоторого } i \text{ выполнено } x_i > y_i\}.$$

Будем считать, что до 6 утра сотрудников в здание не пускают и работа у Марины Николаевны выстроена настолько хорошо, что никто не болеет и все приходят на работу до начала рабочего дня.

Этот пример хорошо раскрывает понятие критерия, но не подходит под методы математической статистики. Потому что гипотеза сформулирована не про распределение наблюдаемых величин (время прихода сотрудников на работу), а про сам факт события.

При такой постановке задачи нечего исследовать: достаточно подождать, когда кто-то из сотрудников придёт раньше Марины Николаевны. Рассмотрим пример гипотезы, которая подходит для методов математической статистики.

Пример 9.1.5. Известно, что плотность распределения времени

прихода сотрудника на работу имеет следующий вид:

$$p(x) = 3(x - \theta + 1)^2 \cdot \mathbb{I}\{x \in [\theta - 1; \theta]\}.$$

Видно, что сотрудник приходит в течение часа $[\theta - 1; \theta]$. Дело в том, что в Москве большие пробки. Если ты хочешь приехать вовремя (к моменту времени θ), то выходишь сильно заранее и часто приезжаешь раньше.

В модели есть несколько параметров: θ_1 — запланированное время прихода на работу Марины Николаевны, $\theta_2, \ldots, \theta_k$ — запланированное время прихода других сотрудников бухгалтерии.

А как будет выглядеть формализация гипотезы? Фактически мы хотим проверить предположение, что запланированное время приезда Марины Николаевны — самое раннее из запланированного времени приезда всех других сотрудников, то есть $\theta_1 < \min\{\theta_2, \ldots, \theta_k\}$.

В этом примере:

$$H_0: \ \theta_1 < \min\{\theta_2, \ldots, \theta_k\};$$

$$H_1: \ \theta_1 \geqslant \min\{\theta_2, \ldots, \theta_k\}.$$

Основные определения

Рассмотрим критерий для проверки гипотезы из первого примера: посмотреть время прихода Марины Николаевны $(x_1, x_2, \ldots, x_5)$ и посмотреть время прихода самого раннего сотрудника $(y_1, y_2, \ldots, y_5)$, если в какой-то из дней $x_i > y_i$, то отвергнуть гипотезу.

Например, мы знаем, что Марина Николаевна приходит раньше всех, но произошла ситуация, в которой Марина Николаевна хотела приехать к 8 утра, собрала все несчастья по дороге и зашла в офис в 7:59. А её заместитель Павел Иванович, планировавший быть к 8:40, оказался крайне везуч на общественный транспорт и приехал к 7:50. Такие ситуации называются ошибками первого рода.

Ситуация, когда мы отвергаем нулевую гипотезу, если она верна.

ОПРЕДЕЛЕНИЕ 9.1.4

Ошибка первого рода

Ошибки, о которых идёт речь в этом разделе, — это неизбежное явление при проверке гипотезы. Наши наблюдения случайны, и мы никогда не сможем дать однозначный ответ, гипотеза верна или гипотеза неверна. Более того мы даже никогда не говорим, что «принимаем» гипотезу: мы «не отвергаем» её.

Не допускать ситуации, что мы отвергаем верную гипотезу, можно только одним способом: всегда её «не отвергать».

С формальной точки зрения вероятность ошибки первого рода —

это $\mathbb{P}\{\boldsymbol{X} \in K \mid \theta \in \Theta_0\}$.

Действительно, мы отвергаем гипотезу H_0, если вектор наших наблюдений попал в критическое множество.

Такое может случиться: вектор $\boldsymbol{X}$ случаен, его может «занести» в критическое множество K.

Символически ошибку первого рода обозначают $\mathbb{P}(H_1 \mid H_0)$ (мы отвергли H_0, хотя она была верна).

Как измерить ошибку первого рода?

Будем так обозначать ошибку **первого** рода

При условии, что H_0 верна

$$\mathbb{P}(I_S) = \max\{\mathbb{P}(X \in S \mid P \in \mathcal{P}_0)\}$$

Берём максимум, потому что это даст нам **самый худший** случай

Вероятность, что X **попадёт** в множество S

Вероятность отвержения H_0 при фактической верности H_0

Какие ошибки ещё могут быть? Обратная ситуация: мы не отвергли нулевую гипотезу H_0, хотя она была неверна. То есть $\boldsymbol{X}$ не попал в критическое множество K, а $\theta \in \Theta_1$.

Вероятность такой ошибки принято обозначать $\mathbb{P}(H_0 \mid H_1)$.

Ситуация, когда мы не отвергаем нулевую гипотезу в случае, если она неверна.

ОПРЕДЕЛЕНИЕ 9.1.5

Ошибка второго рода

Как измерить ошибку второго рода?

Будем так обозначать ошибку **второго** рода

При условии, что H_1 верна

$$\mathbb{P}(II_S) = \mathbb{P}(X \notin S \mid P \notin \mathcal{P}_0)$$

Вероятность, что X **не попадёт** в множество S

Вероятность отвержения H_0 при фактической **неверности** H_0

Пример 9.1.6.

Метафорически представим проверку гипотез как судебный процесс.

Обвиняемый — P	Наше эмпирическое распределение
Невиновность — H_0	$P \in \mathcal{P}_0$
Виновность — H_1	$P \notin \mathcal{P}_0$
Улики — $T(X)$	Статистика от выборки, например среднее, медиана и т.д. Может быть, и сама выборка

Вердикт

$X \in S \Leftrightarrow H_0$ отвергается
Результат статистически значим

$X \notin S \Leftrightarrow H_0$ не отвергается
Результат статистически не значим

Может быть и, например, меньше $\{S = X \mid T(X) > c\}$ Число

$S = \{X \mid T(X) \leq 15\}$ → Пример критерия

Тогда, если $X \in S$, то H_0 отвергается — P виновен

Ошибка первого рода — вероятность осудить невиновного
→ Если $X \in S$, то мы или нашли виновного, или наказали невиновного

Невиновность — H_0

Ошибка второго рода — вероятность отпустить на свободу преступника
→ Если $X \notin S$, то мы или нашли невиновного, или отпустили виновного

Виновность — H_1

Мощность — какую долю реальных преступников суд будет отправлять за решётку при условии контроля вероятности осудить невиновного

Пример 9.1.7. Школьник решает примеры на таблицу умножения. И мы хотим проверить гипотезу о том, что он никогда не ошибается в таких задачах. Для этого мы дали ему 40 задач. Как будет выглядеть критерий и какими могут быть ошибки первого и второго рода?

Здесь мы имеем дело со схемой испытания Бернулли с параметром успеха θ (эксперименты независимы, результат каждого эксперимента либо «успех» с вероятностью θ, либо «неудача» с вероятностью $1 - \theta$).

Нулевая гипотеза состоит в том, что школьник никогда не ошибается, то есть $\theta = 1$. Альтернативой тогда будет $\theta < 1$. Надо отвергнуть гипотезу, если в выборке случился неуспех, то есть критерий (критическое множество) выглядит так:

$$K := \left\{ \boldsymbol{x} \in \{0,1\}^{40} : x_1 + x_2 + \ldots + x_{40} < 40 \right\}.$$

Ошибка первого рода: отвергнуто H_0, хотя H_0 верно. В этом примере ошибка первого рода невозможна: при гипотезе H_0 всегда выпадает «успех», школьник правильно решает пример.

Ошибка второго рода: не отвергнуто H_0, хотя H_0 ложно. Школьник решил все 40 примеров верно, но в каких-то других он будет

делать ошибки.

Посчитаем вероятность $\mathbb{P}\{X_1 + X_2 + \ldots + X_{40} = 40\}$, когда верна H_1. В этом случае каждое испытание должно закончиться «успехом», вероятность этого θ, а все «успехи» будут с вероятностью θ^{40}.

В итоге:

$$\mathbb{P}(H_1 \mid H_0) = 0;$$
$$\mathbb{P}(H_0 \mid H_1) = \theta^{40}.$$

В примере со школьником нам повезло: при H_0 распределение выборки «вырождалось» в распределение константы, поэтому вероятность ошибки первого рода была нулевой. В общем случае она не равна нулю, но хочется, чтобы она была нулём или близким к нему значением.

Уменьшить ошибку первого рода можно, просто уменьшив K: если мы боимся отвергнуть H_0, когда она верна, тогда нужно пореже её отвергать. Но тогда увеличится ошибка второго рода: если мы редко отвергаем H_0, то мы будем это делать и в том случае, когда она неверна.

Таким образом, две ошибки находятся в противофазе: уменьшая одну, мы увеличиваем другую. Как же быть?

Надо определиться, какая ошибка для нас критичнее. Считается, что это ошибка первого рода: если мы не отвергнем неверную гипотезу H_0 сейчас, то дальше сможем на других данных убедиться в том, что она неверна, и отвергнуть её позже. Если же мы отвергнем верную гипотезу уже сейчас, то больше к ней не вернёмся.

Свести ошибку первого рода к нулю не получится, только если выбрать в качестве K просто пустое множество и всегда принимать H_0. Поэтому обычно следуют такому алгоритму: объявляется уровень ошибки первого рода, с которой заказчик/исследователь/наблюдатель готовы смириться (традиционно это 0.01, 0.05 или 0.1), и дальше подбирается такой критерий K, чтобы ошибка первого рода была не больше этого порога (он называется уровнем значимости), а ошибка второго рода была минимальной.

ОПРЕДЕЛЕНИЕ 9.1.6

Уровень значимости

Ограничение сверху для вероятности ошибки первого рода. В одномерном случае чаще всего его обозначают как α.

Размером критерия называется наименьший уровень значимости, которым он может обладать.

Чем меньше размер критерия, тем лучше (ибо по умолчанию мы считаем ошибки первого рода хуже ошибок второго рода).

ОПРЕДЕЛЕНИЕ 9.1.7

Уровень доверия

Величина $1 - \alpha$, где α — уровень значимости. Он показывает вероятность, с которой доверительный интервал покрывает истинный параметр, а в контексте тестов — долю случаев, когда верная гипотеза не отвергается.

Пример 9.1.8.

Рассмотрим пример прибыльности рекламных компаний.

- Запускаем рекламный пуш и смотрим на пользовательские клики по пушам
- Если кликнувших будет хотя бы 50%, наша рекламная кампания неубыточная

- H_0 Данная рекламная кампания неприбыльна, $\hat{\mathcal{P}} \notin \mathcal{P}_0$
- H_1 Данная рекламная кампания прибыльна, $\hat{\mathcal{P}} \in \mathcal{P}_0$

- $\mathcal{P}$ — множество распределений кликов пользователей
- $\mathcal{P}_0$ — множество распределений пользовательских кликов, которые делают кампанию прибыльной

Где:

$\hat{\mathcal{P}}$ — данная конкретная рекламная кампания
$\mathcal{P}$ — все распределения Бернулли
$\mathcal{P}_0$ — распределения Бернулли с $p > 0.5$

Абсолютная рискофобия

S = нулевое множество.
Тогда будем отвергать
все рекламные кампании

Множество прибыльных кампаний

\+ Мы не потеряли деньги
\− Мы не заработаем деньги

Любитель ошибок второго рода

Как найти трейд-офф?

Абсолютная рискофилия

S = вся генеральная совокупность.
Тогда будем принимать
все рекламные кампании

Множество прибыльных кампаний

\+ Мы заработаем много денег
\− Мы потеряем много денег

Любитель ошибок первого рода

Как найти трейд-офф?

$$\begin{cases} P(I_S) \leq \alpha \longrightarrow \\ P(II_S) \to \min \longrightarrow \end{cases}$$

Перевели на математический язык

- Хотим железно контролировать ошибку первого рода
- Хотим при этом минимизировать ошибку второго рода

Вывод: на практике ошибка первого рода первична!

- α — это уровень значимости
- $1-\alpha$ — это уровень доверия

Мощность критерия

Как же определить, что вообще такое «хороший» и «плохой» критерий? Именно для того, чтобы формализовать это, мы ввели альтернативную гипотезу. Существует мера сравнения критериев, которая называется их *мощностью*.

Мощность критерия (англ. power) — это вероятность отвергнуть нулевую гипотезу H_0, если она неверна:

ОПРЕДЕЛЕНИЕ 9.1.8

$$\beta(\theta) = \mathbb{P}_\theta(\boldsymbol{X} \in K), \quad \theta \in \Theta_1.$$

То есть мощность показывает, насколько часто критерий пра-

вильно «замечает» нарушение гипотезы, насколько хорошо мы «отлавливаем» ситуации, когда верна альтернатива. Чем она выше, тем надёжнее тест отличает H_1 от H_0.

ОПРЕДЕЛЕНИЕ 9.1.9

Говорят, что один критерий **мощнее** другого, если его мощность больше для всех $\theta \in \Theta_1$. Критерий называется **равномерно наиболее мощным критерием (р.н.м.к.)** уровня значимости α, если он имеет такой уровень значимости, и мощнее любого другого критерия уровня значимости α.

Пример 9.1.9. Пусть имеется одно наблюдение $X_1 > 0$. Построим критерий для проверки гипотезы $H_0 : X_1 \sim \mathrm{U}[0,1]$ против альтернативы $H_1 : X_1 \sim \mathrm{Exp}(1)$. Понятно, что если $X_1 > 1$, то нулевую гипотезу нужно отвергать. В остальных случаях нужно взять некоторое множество вероятности P_0 не больше α. Если мы хотим построить как можно более мощный критерий, то нужно брать множество вероятности в точности α. Например, можно взять множество $[1-\alpha, 1]$, и тогда весь критерий будет равен

$$K_1 := [1-\alpha, +\infty).$$

Но у этого множества будет не очень большая мощность: в случае верности альтернативы значения с большей вероятностью собираются вокруг нуля, поэтому

$$\mathrm{P}_1(K_1) = e^{-(1-\alpha)}.$$

Логично в случае верности альтернативы смотреть на значения около нуля, и сконструировать критерий в виде

$$K_2 := [0, \alpha] \cup (1, +\infty).$$

Тогда мощность равна

$$\mathrm{P}_1(K_2) = 1 - e^{-\alpha} + e^{-1} \approx \alpha + \frac{1}{e},$$

что больше мощности критерия K_1. На самом деле, построенный критерий даже р.н.м.к., но для этого нужно знать лемму Неймана—Пирсона.

Соберём всё вместе

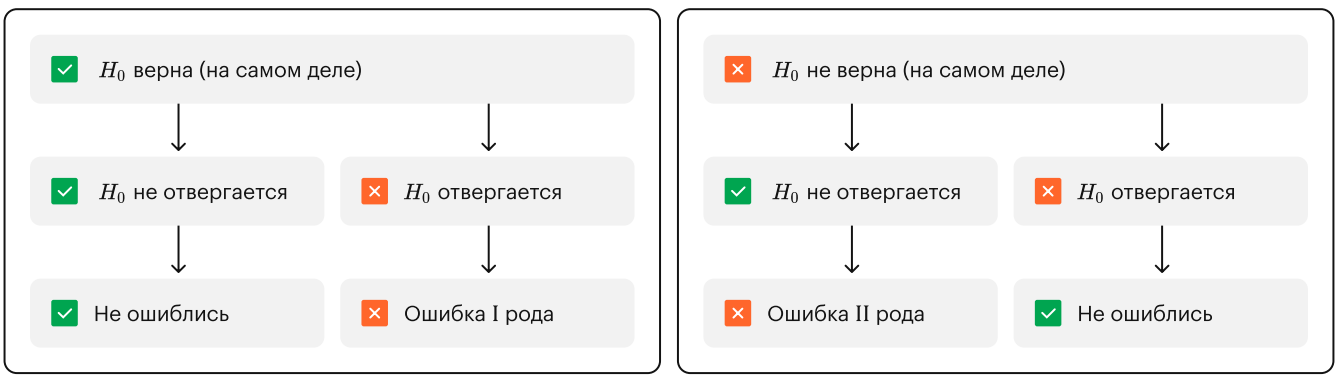

Объект	Обычная модель	Параметрическая модель
Выборка $X_1, \dots, X_n$	распределена по P.	распределена по P_θ.
Основная гипотеза	$H_0 : P \in \mathcal{P}_0$.	$H_0 : \theta \in \Theta_0$.
Альтернатива	$H_1 : P \in \mathcal{P}_1$	$H_1 : \theta \in \Theta_1$
Критическое множество (критерий)	$K \subseteq \mathbb{R}^n$.	
Критерий	Если $\boldsymbol{X} \in K$, то отвергаем H_0.	
Ошибка первого рода	Получилось $\boldsymbol{X} \in K$ при верности гипотезы H_0.	
Ошибка второго рода	Получилось $\boldsymbol{X} \notin K$ при верности гипотезы H_1	
Размер критерия	$\sup\limits_{P \in \mathcal{P}_0} P(\boldsymbol{X} \in K)$.	$\sup\limits_{\theta \in \Theta_0} P_\theta(\boldsymbol{X} \in K)$.
Мощность критерия	$\sup\limits_{P \in \mathcal{P}_1} P(\boldsymbol{X} \in K)$	$\sup\limits_{\theta \in \Theta_1} P_\theta(\boldsymbol{X} \in K)$
Статистика критерия	$T(\boldsymbol{X}) \sim F$ при H_0, иначе $T \not\sim F$.	
Другой вид критерия	$T > c, T < c, \lvert T \rvert > c$	

2. КОНСТРУИРОВАНИЕ КРИТЕРИЕВ

Лемма Неймана–Пирсона

Здесь мы обсудим простую для понимания модель, которая редко встречается на практике, зато позволяет понять дальнейшие математические идеи.

Простыми называются гипотезы вида $H_i : \mathrm{P} = \mathrm{P}_i$.

ОПРЕДЕЛЕНИЕ 9.2.1

Итак, пусть проверяются две гипотезы

$$H_0 : \mathrm{P} = \mathrm{P}_0 \quad \text{vs} \quad H_1 : \mathrm{P} = \mathrm{P}_1.$$

Пусть они обе имеют обычную или обобщённую (для дискретных выборок) плотность; это означает, что для абсолютно непрерывных выборок

$$\mathrm{P}_i(B) = \int_B p_i(x)\,dx, \qquad i \in \{0,1\},$$

а для дискретных выборок

$$\mathrm{P}_i(B) = \sum_{x \in B} \mathrm{P}_i\{X_1 = x\}, \qquad i \in \{0,1\}.$$

В каком случае стоит отвергнуть нулевую гипотезу? Когда альтернатива более правдоподобна! То есть нужно посмотреть на функции правдоподобия $p_0(X)$ и $p_1(X)$ и, если вторая больше, отвергнуть нулевую (основную) гипотезу в пользу альтернативы.

Итак, критерий будет иметь вид

$$S_\alpha : p_1(X) > p_0(X)c_\alpha.$$

Константа c_α выбирается так, чтобы ограничить вероятность ошибки первого рода.

ОПРЕДЕЛЕНИЕ 9.2.2

Критерий называется **несмещённым**, если сумма его вероятностей ошибок первого и второго рода не больше 1. То есть тогда, когда

$$\sup_{\mathrm{P}\in\mathcal{P}_0} \mathrm{P}(S) \leqslant \inf_{\mathrm{P}\in\mathcal{P}_1} \mathrm{P}(S),$$

где слева стоит размер критерия, а справа — его мощность.

Теперь сформулируем лемму. Обрати внимание, что она позволяет строить РНМК только в простой модели.

ЛЕММА 9.2.1

Лемма Неймана — Пирсона

Критерий S_α является РНМК среди всех критериев уровня значимости α. Кроме того, он несмещённый.

Для доказательства понадобится понятие индикаторной функции. Напомним, что индикаторная функция — это функция, которая принимает только два значения:

- 1 — если аргумент попадает в множество;
- 0 — иначе.

Доказательство. Докажем, что S_α является РНМК. Рассмотрим любой другой критерий R уровня значимости α. Для него

$$\mathcal{I}_R(p_1 - c_\alpha p_0) \leqslant \mathcal{I}_R(p_1 - c_\alpha p_0)\mathcal{I}_{S_\alpha} \leqslant (p_1 - c_\alpha p_0)\mathcal{I}_{S_\alpha},$$

где неравенство следует из того, что добавление индикатора $\mathcal{I}_{S_\alpha}$ обнуляет только отрицательное выражение, тем самым увеличивая его. Интегрируем полученные неравенства:

$$\mathrm{P}_1(R) - c_\alpha \mathrm{P}_0(R) \leqslant \mathrm{P}_1(S_\alpha) - c_\alpha \mathrm{P}_0(S_\alpha).$$

Отсюда

$$\mathrm{P}_1(S_\alpha) - \mathrm{P}_1(R) \geqslant c_\alpha(\mathrm{P}_0(S_\alpha) - \mathrm{P}_0(R)) \geqslant 0.$$

Значит, S_α мощнее критерия R. В силу произвольности выбора R выходит, что S_α является РНМК.

Для доказательства несмещённости нужно проверить два случая. Если $c_\alpha \geqslant 1$, то на S_α выполнено $p_0 \leqslant p_1$, откуда

$$\mathrm{P}_0(S_\alpha) = \int \mathcal{I}_{S_\alpha}(x)p_0(x)\,dx \leqslant \int \mathcal{I}_{S_\alpha}(x)p_1(x)\,dx = \mathrm{P}_1(S_\alpha).$$

Если же $c_\alpha < 1$, то вне S_α выполнено $p_0 \geqslant p_1$, откуда аналогично получаем

$$1 - \mathrm{P}_0(S_\alpha) \geqslant 1 - \mathrm{P}_1(S_\alpha).$$

□

Пример 9.2.1. В модели $N(0, \sigma^2)$ рассмотрим гипотезы $H_0 : \sigma^2 = 1$ против $H_1 : \sigma^2 = 2$ и построим РНМК размера α.

Решение. Функции правдоподобия равны:

$$p_0(X) = \frac{1}{(2\pi)^{\frac{n}{2}}} e^{-\frac{1}{2}\sum_{i=1}^n X_i^2} \quad \text{и} \quad p_1(X) = \frac{1}{(4\pi)^{\frac{n}{2}}} e^{-\frac{1}{4}\sum_{i=1}^n X_i^2}.$$

Чтобы построить РНМК размера α, нужно подобрать параметр c_α так, чтобы выполнялось следующее:

$$\mathrm{P}_0\left\{\frac{1}{(4\pi)^{\frac{n}{2}}} e^{-\frac{1}{4}\sum_{i=1}^n X_i^2} > \frac{c_\alpha}{(2\pi)^{\frac{n}{2}}} e^{-\frac{1}{2}\sum_{i=1}^n X_i^2}\right\} \leqslant \alpha.$$

Логарифмируя, приводим критерий к следующему выражению:

$$\sum_{i=1}^n X_i^2 > 2n\ln 2 + 4\ln c_\alpha.$$

При верности нулевой гипотезы выполнено $\sum_{i=1}^n X_i^2 \sim \chi^2(n)$. Следовательно, нужно подобрать c_α так, чтобы выполнялось равенство

$$2n\ln 2 + 4\ln\lambda = u_{1-\alpha},$$

где $u_{1-\alpha}$ и есть $(1-\alpha)$-квантиль распределения $\chi^2(n)$. Окончательно вычисляем

$$c_\alpha = \frac{1}{2^{\frac{n}{2}}} e^{-\frac{u_{1-\alpha}}{4}},$$

и РНМК найден. ■

ЗАМЕЧАНИЕ

Выражение для c_α очень похоже на плотность закона f_1, где вместо суммы квадратов наблюдений стоит квантиль.

На самом деле выражение для c_α можно было не искать: после того как мы поняли, что в действительности критерий имеет вид

$$\sum_{i=1}^n X_i^2 > u_{1-\alpha},$$

можно его так и оставить. Более того, можно даже не искать квантиль, а просто найти p-value как

$$\mathrm{P}_0\left(\sum_{i=1}^n X_i^2 > \sum_{i=1}^n x_i^2\right) = 1 - F_{\chi^2(n)}\left(\sum_{i=1}^n x_i^2\right).$$

На рисунке 100 видно, что большие наблюдения соответствуют тяжёлым хвостам закона $N(0,2)$. Поэтому можно было вообще ничего не считать, если сразу заметить, что критерий имеет вид $\sum_{i=1}^n X_i^2 > c$.

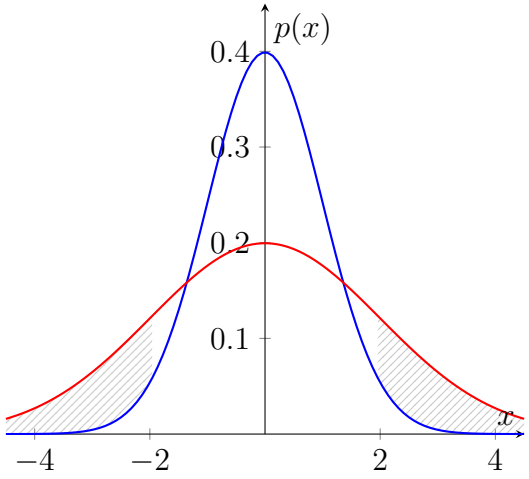

Рисунок 100. Синий график: плотность распределения $N(0,1)$. Красный график: плотность распределения $N(0,2)$. Серая штриховка показывает область тяжёлых хвостов

Проверка среднего нормального распределения

Пример 9.2.2.

Пусть $X_1, \ldots, X_n$ являются независимыми одинаково распределёнными случайными величинами, причём $X_i \sim N(\mu, \sigma^2)$, где дисперсия σ^2 известна.

Проверим две простые гипотезы

$$H_0 \colon \mu = 0 \qquad \text{против} \qquad H_1 \colon \mu = \delta,$$

где $\delta > 0$.

Требуется построить наиболее мощный критерий уровня значимости α.

Шаг 1. Запишем совместную плотность выборки

Плотность одного наблюдения при параметре μ имеет вид
$p_\mu(x) =$
$= \frac{1}{\sqrt{2\pi\sigma^2}} \exp\{-\frac{(x-\mu)^2}{2\sigma^2}\}.$
В силу независимости наблюдений совместная плотность выборки равна $L(\mu; x_1, \ldots, x_n) = \prod_{i=1}^n p_\mu(x_i)$.

Следовательно,

$$L(\mu; x_1, \ldots, x_n) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\}.$$

При нулевой гипотезе:

$$L(0; x_1, \ldots, x_n) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\{-\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2\}.$$

При альтернативе:

$$L(\delta; x_1, \ldots, x_n) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\{-\frac{1}{2\sigma^2} \sum_{i=1}^{n} (x_i - \delta)^2\}.$$

Шаг 2. Найдём отношение правдоподобий

Рассмотрим отношение правдоподобий $\Lambda(x_1, \ldots, x_n) = \frac{L(\delta; x_1, \ldots, x_n)}{L(0; x_1, \ldots, x_n)}$.

Подставляя совместные плотности, получаем

$\Lambda(x_1, \ldots, x_n) = \exp\{-\frac{1}{2\sigma^2} \sum_{i=1}^{n} \left((x_i - \delta)^2 - x_i^2\right)\}$.

Раскроем квадрат: $(x_i - \delta)^2 - x_i^2 = x_i^2 - 2\delta x_i + \delta^2 - x_i^2 = = -2\delta x_i + \delta^2$.

Поэтому

$$\Lambda(x_1, \ldots, x_n) = = \exp\{-\frac{1}{2\sigma^2} \sum_{i=1}^{n} \left(-2\delta x_i + \delta^2\right)\} = \exp\{\frac{\delta}{\sigma^2} \sum_{i=1}^{n} x_i - \frac{n\delta^2}{2\sigma^2}\}.$$

Поскольку $\delta > 0$, отношение правдоподобий является строго возрастающей функцией суммы $\sum_{i=1}^{n} x_i$.

Следовательно, по лемме Неймана–Пирсона гипотезу H_0 следует отклонять при больших значениях суммы $\sum_{i=1}^{n} X_i$.

Поскольку $\sum_{i=1}^{n} X_i = n\overline{X}$, критическую область можно записать в виде $\overline{X} > a$, а константа a выбирается из условия уровня значимости.

Шаг 3. Найдём критическое значение

При нулевой гипотезе $X_i \sim N(0, \sigma^2)$.

Поэтому $\overline{X} \sim N\left(0, \frac{\sigma^2}{n}\right)$.

Следовательно, статистика $Z = \frac{\sqrt{n}\overline{X}}{\sigma}$ имеет стандартное нормальное распределение:

$$Z \sim N(0, 1).$$

Критическое значение a определяется условием $\mathbb{P}_0(\overline{X} > a) = \alpha$.

После стандартизации получаем

$$\mathbb{P}_0\left(\frac{\sqrt{n} \cdot \overline{X}}{\sigma} > \frac{\sqrt{n} \cdot a}{\sigma}\right) = \alpha.$$

Обозначим через $z_{1-\alpha}$ квантиль стандартного нормального распределения, то есть $\Phi(z_{1-\alpha}) = 1 - \alpha$, где $\Phi(z) = \mathbb{P}(Z \leqslant z)$.

Тогда $\mathbb{P}(Z > z_{1-\alpha}) = \alpha$.

Следовательно, $\frac{\sqrt{n}\cdot a}{\sigma} = z_{1-\alpha}$, откуда $a = \frac{\sigma}{\sqrt{n}} z_{1-\alpha}$.

Итак, наиболее мощный критерий уровня значимости α имеет вид

$$\text{отклонить } H_0 \iff \overline{X} > \frac{\sigma}{\sqrt{n}} z_{1-\alpha}$$

Критическая функция имеет вид

$$\varphi^*(X_1, \ldots, X_n) = \mathbf{1}\{\frac{\sqrt{n}, \overline{X}}{\sigma} > z_{1-\alpha}\}.$$

Шаг 4. Найдём мощность критерия

При альтернативе $\mu = \delta$ выборочное среднее имеет распределение

$$\overline{X} \sim N\left(\delta, \frac{\sigma^2}{n}\right).$$

Мощность критерия при альтернативе $\mu = \delta$ равна $\pi(\delta) =$
$= \mathbb{P}_\delta\left(\overline{X} > \frac{\sigma}{\sqrt{n}} z_{1-\alpha}\right).$

При этом $\frac{\overline{X}-\delta}{\sigma/\sqrt{n}} \sim N(0,1)$.

Следовательно,

$$\pi(\delta) = \mathbb{P}_\delta\left(\frac{\overline{X}-\delta}{\sigma/\sqrt{n}} > \frac{\frac{\sigma}{\sqrt{n}} z_{1-\alpha} - \delta}{\sigma/\sqrt{n}}\right) = \mathbb{P}\left(Z > z_{1-\alpha} = \frac{\sqrt{n}, \delta}{\sigma}\right).$$

Поэтому $\pi(\delta) = 1 - \Phi\left(z_{1-\alpha} = \frac{\sqrt{n}, \delta}{\sigma}\right).$

Используя равенство $1 - \Phi(x) = \Phi(-x)$, получаем эквивалентную формулу

$\pi(\delta) = \Phi\left(\frac{\sqrt{n}, \delta}{\sigma} - z_{1-\alpha}\right)$

Вероятность ошибки второго рода равна $\beta(\delta) = 1 - \pi(\delta)$,

то есть

$$\beta(\delta) = \Phi(z_{1-\alpha} - \frac{\sqrt{n} \cdot \delta}{\sigma})$$

Монотонное отношение правдоподобий

Лемма Неймана—Пирсона естественно обобщается на случай сложных гипотез в теореме, которую мы приведём в этом параграфе. Правда, обобщение работает только в параметрической модели и при выполнении дополнительных условий, которые мы сформулируем в теореме.

ОПРЕДЕЛЕНИЕ 9.2.3

Параметрическая гипотеза называется **сложной**, если она не является простой.

ОПРЕДЕЛЕНИЕ 9.2.4

Параметрическое семейство $\{\mathrm{P}_\theta : \theta \in \Theta \subset \mathbb{R}\}$ обладает **монотонным отношением правдоподобий по статистике T**, если для любых $\theta' < \theta''$ отношение

$$\frac{p_{\theta''}(X)}{p_{\theta'}(X)}$$

является монотонным по статистике $T(X)$, причём тип монотонности не зависит от выбора параметров $\theta', \theta'' \in \Theta$.

ЛЕММА 9.2.2

Пусть параметрическое семейство обладает монотонным вверх отношением правдоподобия. Тогда для любого $c \in \mathbb{R}$ функция

$$\theta \mapsto \mathrm{P}_\theta\{T(X) \geqslant c\}$$

нестрого возрастает.

Доказательство. Зафиксируем $\theta' < \theta''$ и константу $c \in \mathbb{R}$. Обозначим

$$\psi_{\theta',\theta''}(T(X)) := \frac{p_{\theta''}(X)}{p_{\theta'}(X)}.$$

Введём множество

$$D := \{x : T(x) \geqslant c\}.$$

Рассмотрим два случая.

1. Если $\psi(c) \geqslant 1$, то для $x \in D$ выполнено

   $$p_{\theta''}(x) = \psi_{\theta',\theta''}(T(x))p_{\theta'}(x) \geqslant \psi_{\theta',\theta''}(c)p_{\theta'}(x) \geqslant p_{\theta'}(x).$$

   Отсюда, интегрируя по множеству D, получаем

   $$\mathrm{P}_{\theta''}(T \geqslant c) = \int_D p_{\theta''}(x)\,dx \geqslant \int_D p_{\theta'}(x)\,dx = \mathrm{P}_{\theta'}(T \geqslant c).$$

2. Если же $0 \leqslant \psi_{\theta',\theta''}(c) < 1$, то вне D выполнено

   $$p_{\theta''}(x) = \psi_{\theta',\theta''}(T(x))p_{\theta'}(x) \leqslant \psi_{\theta',\theta''}(c)p_{\theta'}(x) < p_{\theta'}(x).$$

   Отсюда, интегрируя по множеству $\mathcal{X} \setminus D$, выходит:

   $$\mathrm{P}_{\theta''}(T < c) = \int_{\mathcal{X}\setminus D} p_{\theta''}(x)\,dx \leqslant \int_{\mathcal{X}\setminus D} p_{\theta'}(x)\,dx = \mathrm{P}_{\theta'}(T < c).$$

В итоге в обоих случаях получаем

$$\mathrm{P}_{\theta''}(T \geqslant c) \geqslant \mathrm{P}_{\theta'}(T \geqslant c).$$

□

Лемма 9.2.2 лежит в основе следующей теоремы, обобщающей идею леммы Неймана — Пирсона.

ТЕОРЕМА 9.2.1

О монотонном отношении правдоподобий

Пусть параметрическое семейство обладает монотонным вверх и непрерывным по статистике T отношением правдоподобия. Пусть проверяется гипотеза

$$H_0 : \theta \leqslant \theta_0 \quad \text{или} \quad H_0 : \theta = \theta_0$$

против альтернативы

$$H_1 : \theta > \theta_0.$$

Выберем константу d_α так, чтобы для критерия

$$M_\alpha : T(X) \geqslant d_\alpha$$

выполнялось

$$\mathrm{P}_{\theta_0}(M_\alpha) = \alpha.$$

Тогда критерий M_α является РНМК среди всех критериев уровня значимости α для проверки гипотезы H_0 против H_1.

Идея Доказательство. При больших значениях статистики T более правдоподобны бóльшие значения параметров. Поэтому при больших значениях статистики T нужно отвергать основную гипотезу о маленьких параметрах в пользу альтернативы о больших. □

Формальное доказательство Доказательство. Сперва заметим, что при $\theta < \theta_0$ по лемме 9.2.2

$$\mathrm{P}_\theta(M_\alpha) \leqslant \mathrm{P}_{\theta_0}(M_\alpha) = \alpha,$$

откуда выходит, что критерий и правда имеет размер α.

Рассмотрим любой другой критерий R уровня значимости α. Зафиксируем произвольное $\theta_1 > \theta_0$. Нужно доказать, что критерий M_α мощнее, чем R, то есть что

$$\mathrm{P}_{\theta_1}(M_\alpha) \geqslant \mathrm{P}_{\theta_1}(R).$$

Из леммы Неймана — Пирсона известно, что РНМК для проверки гипотезы $\theta = \theta_0$ против альтернативы $\theta = \theta_1$ является критерий

$$S_\alpha : p_{\theta_1}(X) \geqslant c_\alpha p_{\theta_0}(X).$$

Однако в силу монотонного отношения правдоподобия то же самое можно переписать в виде

$$S_\alpha : T(X) \geqslant \lambda_\alpha$$

для некоторой λ_α, причём должно выполняться

$$\mathrm{P}_{\theta_0}(S_\alpha) = \alpha.$$

Отсюда получаем, что $\lambda_\alpha = d_\alpha$ и $S_\alpha = M_\alpha$, откуда выходит, что M_α мощнее R. □

Из теоремы следует, что для монотонного отношения правдоподобий невозможно построить двусторонний критерий для про-

верки

$$H_0 : \theta = \theta_0 \quad \text{vs} \quad H_1 : \theta \neq \theta_0.$$

Можно изменить проверяемые в теореме гипотезы. Например, для проверки гипотезы

$$H_0 : \theta \geqslant \theta_0 \quad \text{или} \quad H_0 : \theta = \theta_0$$

против альтернативы

$$H_1 : \theta < \theta_0$$

нужно строить критерий в виде

$$M_\alpha : T(X) \leqslant d_\alpha.$$

Аналогично если отношение правдоподобий оказывается нестрого убывающим, то нужно:

- либо проверять гипотезы

  $$H_0 : \theta \geqslant \theta_0 \quad \text{или} \quad H_0 : \theta = \theta_0$$

  против альтернативы

  $$H_1 : \theta < \theta_0,$$

  а сам критерий оставить в виде

  $$M_\alpha : T(X) \geqslant d_\alpha,$$

- либо оставить гипотезы

  $$H_0 : \theta \leqslant \theta_0 \quad \text{или} \quad H_0 : \theta = \theta_0$$

  против альтернативы

  $$H_1 : \theta > \theta_0,$$

  но критерий поменять на

  $$M_\alpha : T(X) \leqslant d_\alpha.$$

ЗАМЕЧАНИЕ

Как и в лемме Неймана — Пирсона, константу d_α можно явно не искать, а проверять гипотезу через p-value.

Пример 9.2.3. В модели $N(0, \theta)$ проверим гипотезу

$$H_0 : \theta \leqslant 1$$

против альтернативы

$$H_1 : \theta > 1.$$

Решение. Сперва нужно проверить отношение правдоподобий на

монотонность. Для $\theta' < \theta''$ имеем

$$\frac{p_{\theta''}(x)}{p_{\theta'}(x)} = \left(\frac{2\pi\theta'}{2\pi\theta''}\right)^{\frac{n}{2}} e^{\frac{1}{2}(\frac{1}{\theta'}-\frac{1}{\theta''})\sum x_i^2},$$

откуда видим, что отношение правдоподобий возрастает по статистике $T(X) := \sum\limits_{i=1}^{n} X_i^2$. Тогда нужно построить критерий в виде

$$M_\alpha : T(X) \geqslant d_\alpha,$$

где в качестве d_α надо взять $(1-\alpha)$-квантиль распределения $\chi^2(n)$. ■

Связь гипотез и доверительного оценивания

К этому моменту можно было заметить, что построение критериев схоже с построением доверительных интервалов. Для наглядности покажем эту связь через обобщённое понятие доверительной области.

ОПРЕДЕЛЕНИЕ 9.2.5

Доверительной областью для параметра θ уровня доверия γ называется такая область $S(X) \subset \Theta$, что для всех $\theta \in \Theta$ выполнено

$$\mathrm{P}_\theta\{\theta \in S(X)\} \geqslant \gamma.$$

Доверительный интервал является частным случаем доверительной области.

ТЕОРЕМА 9.2.2

Есть соответствие между множеством критериев уровня значимости α и множеством доверительных областей уровня доверия $1-\alpha$, то есть по критерию K_α можно построить доверительную область $S_{1-\alpha}$, и наоборот.

Доказательство. Рассмотрим доверительную область $S(X)$ уровня доверия $1-\alpha$. Хотим проверить гипотезу

$$H_0 : \theta = \theta_0.$$

Построим критерий

$$K(\theta) := \{x : \theta \notin S(X)\}.$$

Тогда размер критерия равен

$$\mathrm{P}_{\theta_0}(K(\theta)) = \mathrm{P}_{\theta_0}\{\theta \notin S(X)\} \leqslant \alpha.$$

Обратно: если есть критерий $K(\theta)$, проверяющий гипотезу H_0 на уровне значимости α, то нужно взять доверительную область

$$S(X) := \{\theta \in \Theta : X \notin K(\theta)\}.$$

Тогда

$$\mathrm{P}_\theta\{\theta \in S(X)\} = \mathrm{P}_\theta\{X \notin K(\theta)\} \geqslant 1-\alpha.$$

□

3. Z-КРИТЕРИЙ

Довольно часто можно предположить, что наши наблюдения суть независимые одинаково распределённые случайные величины. Разберём несколько классических примеров.

Пример 9.3.1. Во многих спортивных клубах есть аналитики, задача которых — находить уязвимости в игре противников. Гена работает аналитиком в футбольном клубе «А» .

Завтра у «А» важная игра против клуба «Б». Гене нужно проверить, не бьют ли игроки «Б» пенальти систематически правее центра. Если окажется, что игроки «Б» действительно часто бьют пенальти правее центра, можно будет дать рекомендацию вратарю «А» при пенальти прыгать левее.

С точки зрения статистики, клуб «Б» бьёт пенальти исходя из $N(m, 1)$, где $m = 0$ это центр ворот, положительные значение — правая часть ворот, а отрицательные значения — левая часть ворот. Тогда можно сформулировать основную гипотезу $H_0 : m = 0$ против альтернативы $H_1 : m > 0$.

Рассуждая аналогично критерию Вальда, можно рассмотреть статистику $\sqrt{n}\overline{X}$. В случае верности основной гипотезы эта статистика имеет распределение $N(0, 1)$. В случае же верности альтернативы значения $\overline{X}$ концентрируются вокруг числа m, и статистика критерия уплывает по вероятности на бесконечность. Поэтому можно построить критерий

$$\sqrt{n}\overline{X} > z_{1-\alpha},$$

где $z_{1-\alpha}$ является квантилью стандартного нормального закона. Построенный критерий называется **Z-критерием**. Отметим ещё раз, что как и не прошлой неделе, мы не требуем то, чтобы распределение данных было обязательно нормальным! Z-критерий работает из-за ЦПТ, а не нормальности данных.

Вопрос из этого примера неоднократно рассматривали экономисты, занимающиеся спортивной экономикой. Например, в этой статье: **?**. Обычно авторы таких работ приходят к выводу, что вратари прыгают, а игроки бьют пенальти непредсказуемо. Поэтому подобным анализом увеличить шансы на победу ни тех, ни других не получится.

Одновыборочный Z-критерий для среднего

Пусть имеется выборка $X_1, \ldots, X_n$ из распределения с некоторым математическим ожиданием μ и известной дисперсией σ^2.

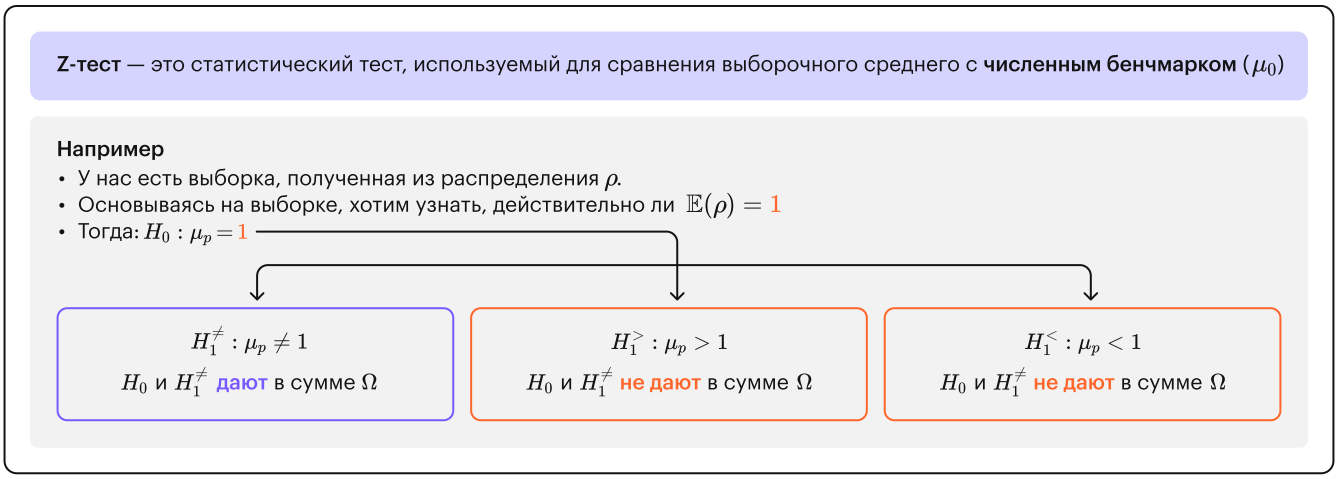

Рисунок 101. Определение и альтернативные гипотезы Z-теста.

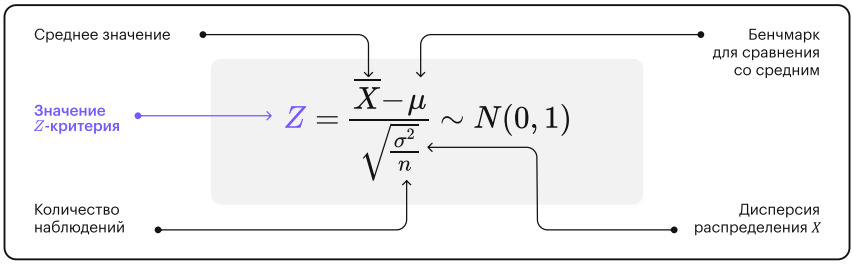

Рисунок 102. Формула Z-теста.

При достаточно большом количестве наблюдений этот критерий работает благодаря ЦПТ для любых распределений с конечной дисперсией, а не только для нормальных.

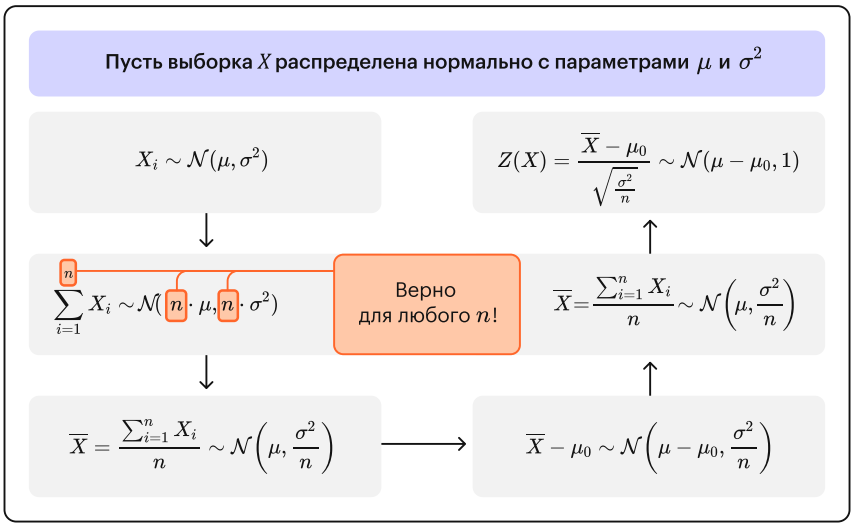

Рисунок 103. Доказательство работы Z-критерия при нормальном распределении данных.

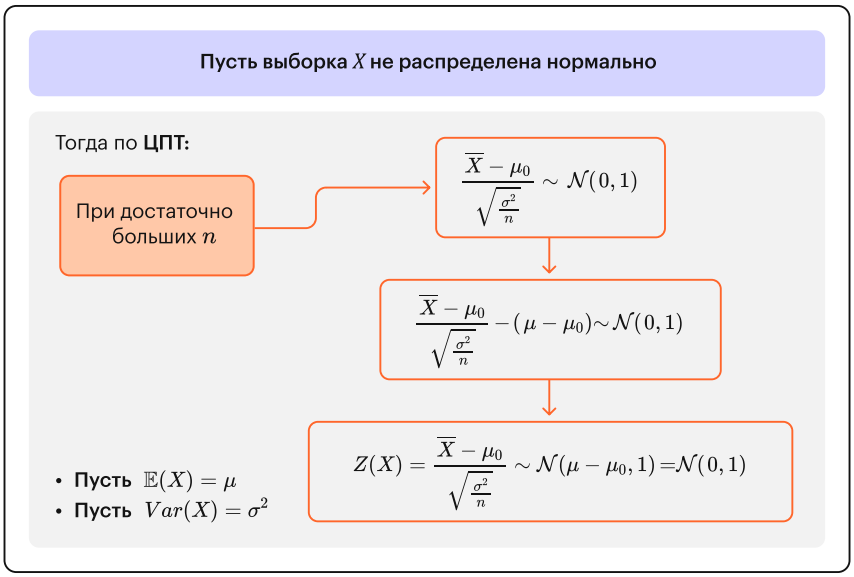

Рисунок 104. Доказательство работы Z-критерия при ненормальном распределении данных.

Таким образом, Z-критерий работает для нормальных данных на любом количестве наблюдений, а для ненормальных выборок требуется большое количество наблюдений, чтобы работала Центральная Предельная Теорема.

Можно сказать, что нормальность данных является достаточным условием для работы критерия, но не является необходимым.

Пример 9.3.2.

Рассмотрим пример, в рамках которого среднее близко к математическому ожиданию, и проверим все три возможные альтернативные гипотезы.

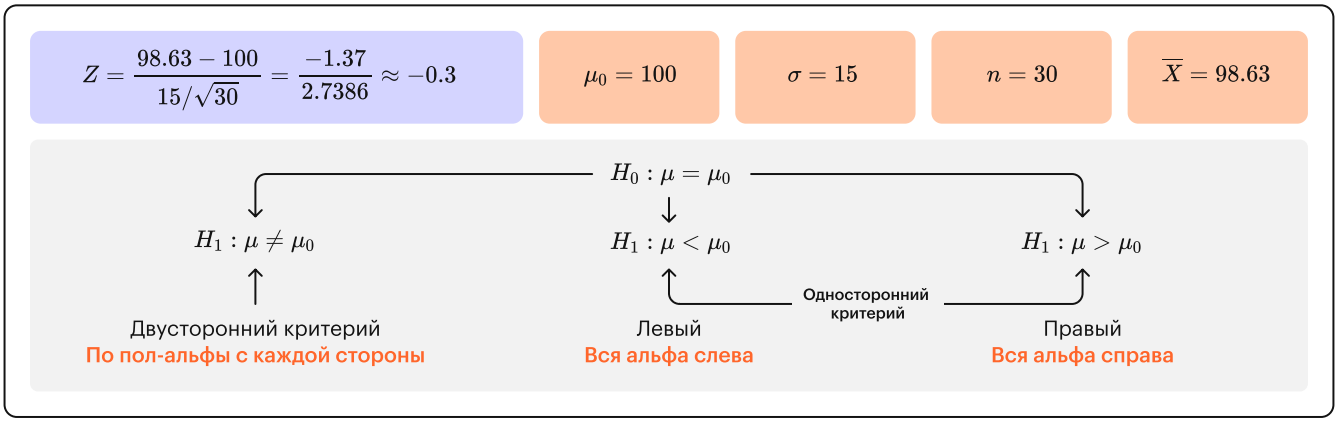

Рисунок 105. Расчёт Z-значения в примере со средним, близком к математическому ожиданию.

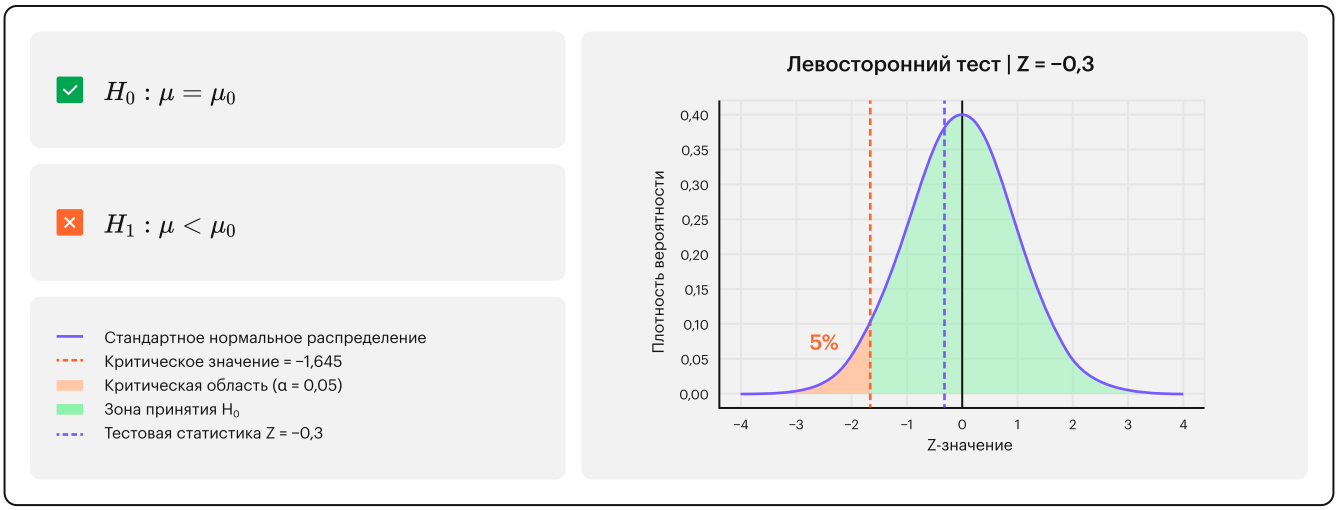

Рисунок 106. Проверка альтернативной гипотезы $\mu < \mu_0$.

В данном случае мы не можем отвергнуть нулевую гипотезу, так как расчётное значение Z-критерия попадает в зону принятия гипотезы.

Критическая зона формируется как 5% площади под кривой нормального стандартного распределения **с левой стороны**.

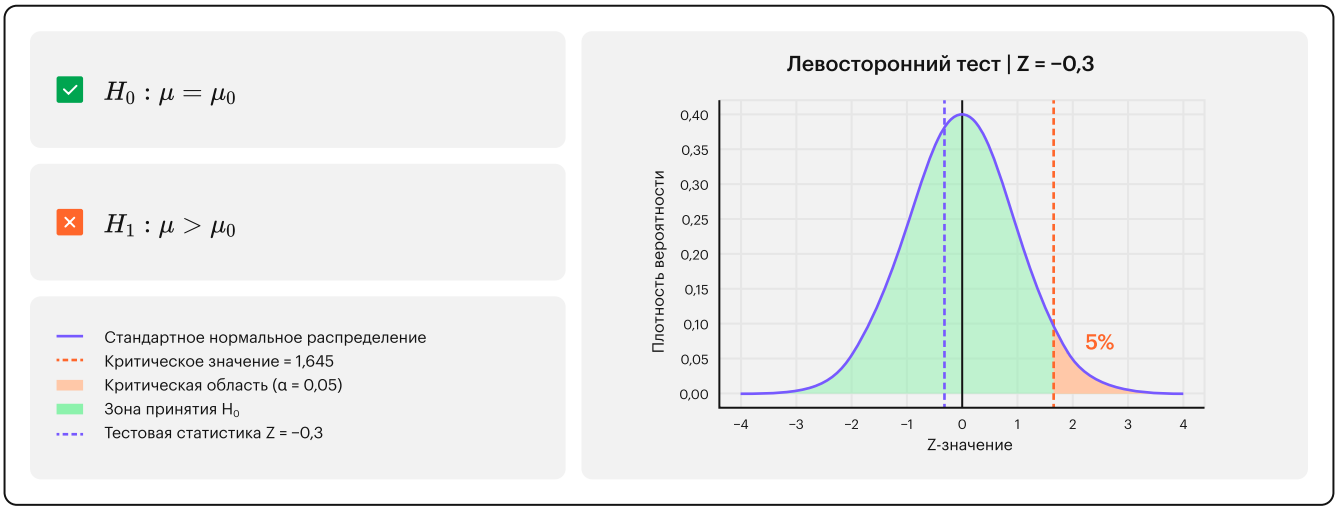

Рисунок 107. Проверка альтернативной гипотезы $\mu > \mu_0$.

В данном случае мы также не можем отвергнуть нулевую гипотезу.

Критическая зона формируется как 5% площади под кривой нормального стандартного распределения **с правой стороны**.

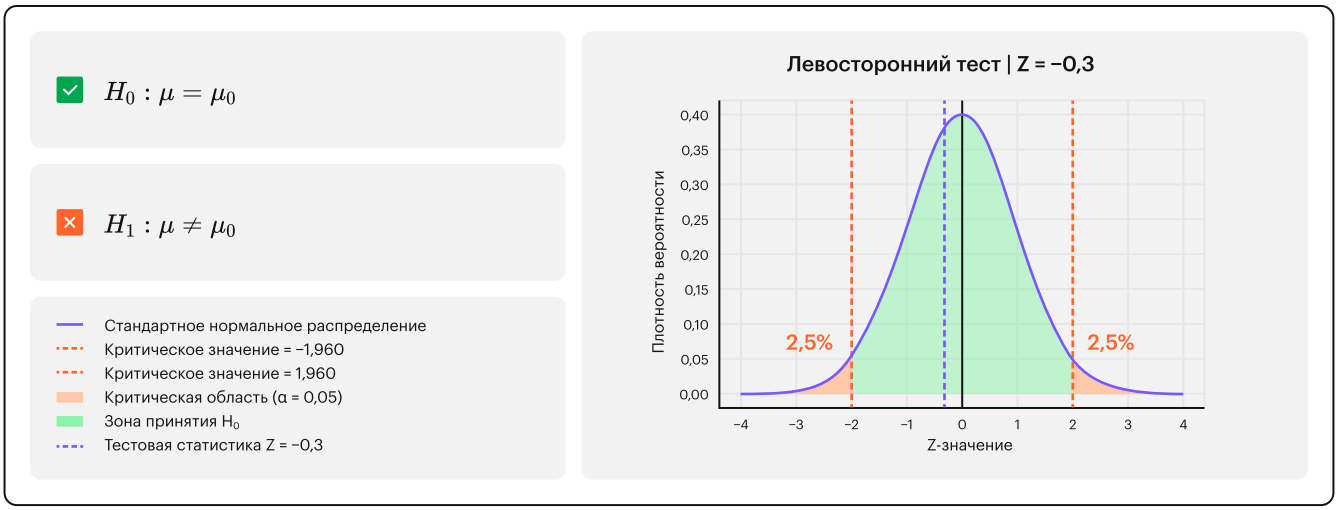

Рисунок 108. Проверка альтернативной гипотезы $\mu \neq \mu_0$.

В данном случае мы также не можем отвергнуть нулевую гипотезу.

Критическая зона формируется как 2.5% площади под кривой нормального стандартного распределения **с левой стороны**, а также 2.5% площади **с правой стороны**.

Пример 9.3.3.

Теперь перейдём к противоположному примеру, в рамках которого среднее далеко от математического ожидания, и также проверим все три возможные альтернативные гипотезы.

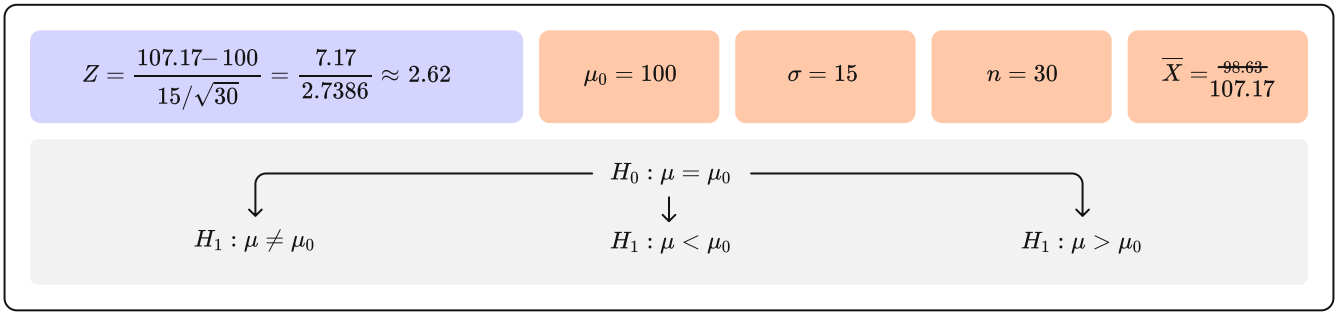

Рисунок 109. Расчёт Z-значения в примере со средним, далёким от математического ожидания.

$H_0 : \mu = \mu_0$

$H_1 : \mu > \mu_0$

Стандартное нормальное распределение
Критическое значение = 1,645
Критическая область (α = 0,05)
Зона принятия H_0
Тестовая статистика Z = 2,62

Рисунок 110. Проверка альтернативной гипотезы $\mu > \mu_0$.

$H_0 : \mu = \mu_0$

$H_1 : \mu < \mu_0$

Стандартное нормальное распределение
Критическое значение = −1,645
Критическая область (α = 0,05)
Зона принятия H_0
Тестовая статистика Z = 2,62

Рисунок 111. Проверка альтернативной гипотезы $\mu < \mu_0$.

$H_0 : \mu = \mu_0$

$H_1 : \mu \neq \mu_0$

Стандартное нормальное распределение
Критическое значение = −1,960
Критическое значение = 1,960
Критическая область (α = 0,05)
Зона принятия H_0
Тестовая статистика Z = 2,62

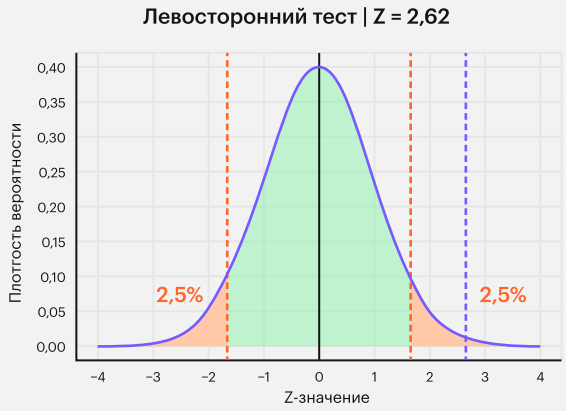

Рисунок 112. Проверка альтернативной гипотезы $\mu \neq \mu_0$.

Двухвыборочный Z-критерий для средних

Пусть имеются две независимые выборки $X_1, \dots, X_n \sim$ $\sim N(\mu_x, \sigma^2)$ и $Y_1, \dots, Y_m \sim N(\mu_y, \sigma^2)$ с известной общей дисперсией σ^2.

Проверяем $H_0 : \mu_x = \mu_y$ против $H_1 : \mu_x \neq \mu_y$.

Тогда рассмотрим статистику

$$Z = \frac{\bar{X} - \bar{Y}}{\sigma\sqrt{\frac{1}{n} + \frac{1}{m}}}.$$

При H_0 имеем $Z \sim N(0,1)$. Будем отвергать H_0, если $|Z| >$ $> z_{1-\alpha/2}$.

Инсайт: зависимость Z от дисперсии.

В формуле $Z = \sqrt{n}\frac{\bar{X}-m}{\sigma}$ значение Z обратно пропорционально σ: чем больше дисперсия, тем меньше $|Z|$, и тем труднее отвергнуть H_0 (выше вероятность ошибки II рода β). При малой σ отклонения заметнее, Z растёт, мощность теста увеличивается.

Инсайт: зависимость Z от размера выборки.

Заметим, что $Z \propto \sqrt{n}$, то есть с ростом n $|Z|$ для фиксированного отклонения увеличивается, облегчая отвержение H_0 (мощность растёт, β падает). Большая выборка делает тест чувствительнее к отклонениям от нулевой гипотезы.

Двухвыборочный Z-критерий часто используется в A/B тестах, чтобы проверить наличие статистически значимого прироста метрики в результате нового воздействия или механики.

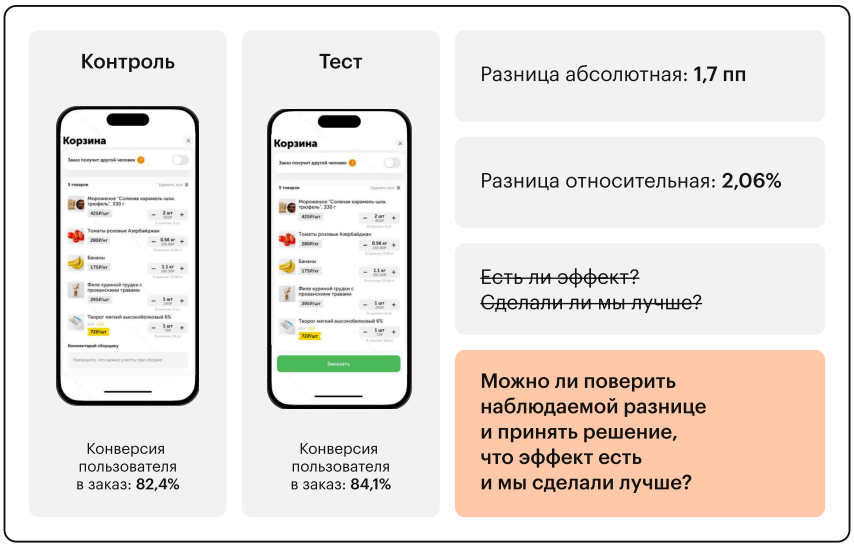

Рисунок 113. Пример Z-критерия. A/B тест на рост конверсии.

Рост мощности теста с ростом размера выборки имеет своё название.

ОПРЕДЕЛЕНИЕ 9.3.1

Критерий S (а точнее, последовательность критериев S_n) называется **состоятельным**, если его мощность стремится к 1 с ростом выборки, то есть если для любого $\mathrm{P} \in \mathcal{P}_1$,

$$\mathrm{P}\{X \in S_n\} \xrightarrow[n\to\infty]{} 1,$$

ТЕОРЕМА 9.3.1

Z-критерий состоятелен.

Доказательство. Для простоты, проведём доказательство для одностороннего критерия проверки $H_0 : \mu = \mu_0$ против альтернативы $H_1 : \mu > \mu_0$. Критерий имеет вид

$$Z := \sqrt{n}\frac{\overline{X} - \mu_0}{\sigma} > c$$

для некоторой константы c (которая равна $(1-\alpha)$-квантили стандартного нормального закона, но это не влияет на состоятельность критерия.) Пусть выполнена альтернатива $\mu > \mu_0$. Тогда

$$Z = \sqrt{n}\frac{\overline{X} - \mu}{\sigma} + \sqrt{n}\frac{\mu - \mu_0}{\sigma}.$$

Первое слагаемое здесь имеет рапределение $N(0,1)$, а во втором слагаемом числитель и знаменатель строго положительны, поэтому всё слагаемое уходит на $+\infty$. Поэтому и Z уходит на $+\infty$. Отсюда следует состоятельность критерия. □

4. P-ЗНАЧЕНИЕ

Одним из ключевых понятий в тестировании гипотез является

p-значение (или p-value).

Давайте его поймём.

ОПРЕДЕЛЕНИЕ 9.4.1

p-value — это вероятность получить значение статистики теста, равное или более экстремальное, чем наблюдаемое, при условии, что нулевая гипотеза верна.

Мнемоника про щенка

Пример 9.4.1. Представь, что ты приходишь домой и видишь, что кухня в полном беспорядке: мусор разбросан, еда на полу.

У тебя есть щенок, который любит шалить. Ровно как с метафорой суда, за нулевую гипотезу возьмём то, что щенок невиновен (возможно, это был ветер или что-то другое).

Тогда доказательством будет весь этот хаос, а p-value — это вероятность увидеть такой или ещё больший беспорядок, если щенок действительно невиновен.

Если у вас нет маленьких детей или сумасшедших соседей, то, к сожалению, скорее всего, это натворил именно ваш щенок.

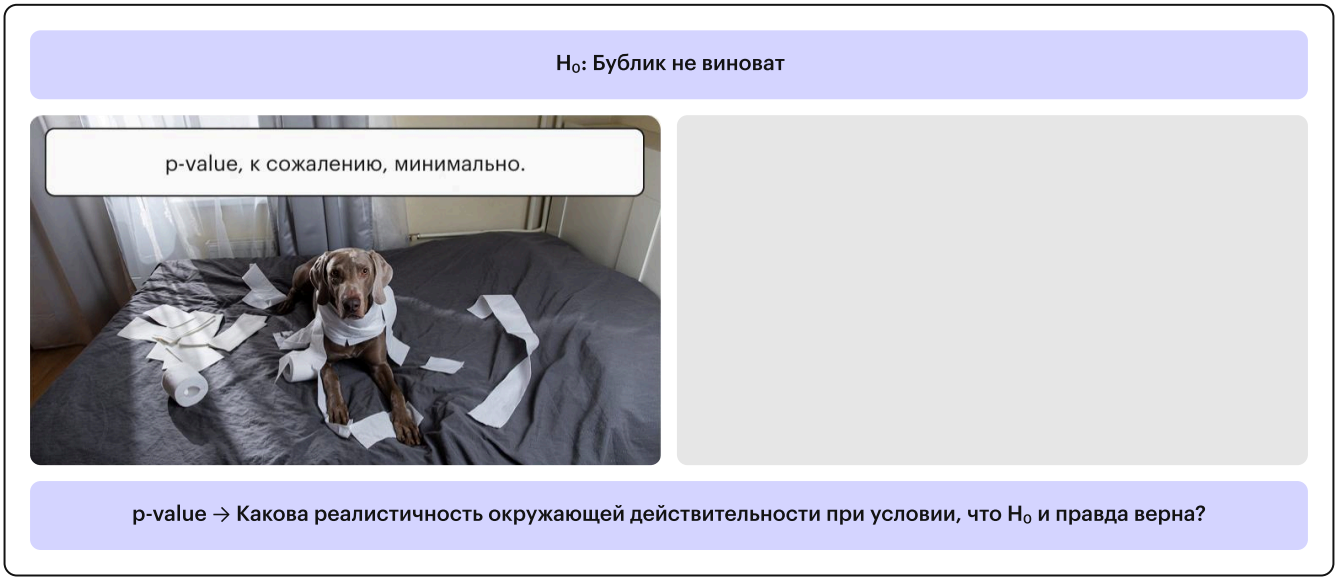

Рисунок 114. Маленькое pvalue: если других факторов нет, то щенок, скорее всего виноват.

Однако если у вас есть ребенок, то существует вероятность, что бардак устроил именно он, а не щенок. Тогда pvalue гипотезы о невиновности щенка становится значительно больше.

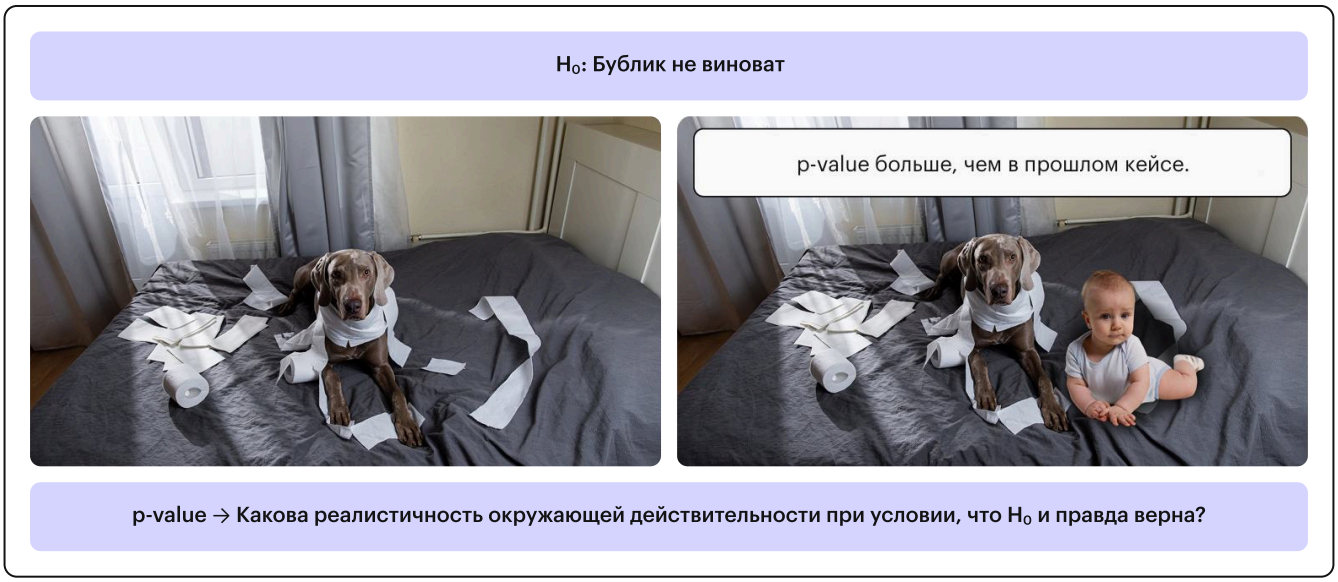

Рисунок 115. Большое pvalue: существуют другие факторы, которые могут свидетельствовать о невиновности щенка.

Таким образом, pvalue — это не «вероятность верности нулевой гипотезы», это вероятность получить те доказательства, которые есть у вас на руках, при условии, что нулевая гипотеза действительно верна.

Пример 9.4.2. Рассмотрим два противоположных кейса: заведомо близкие средние в двух выборках и заведомо отдалённые средние в двух выборках.

В качестве нулевой гипотезы, как обычно, рассмотрим равенство математических ожиданий двух распределений, а в качестве альтернативной - отсутствие равенства.

$$H_0 : \mu_X = \mu_Y$$
$$H_0 : \mu_X \neq \mu_Y$$

Таким образом, мы рассматриваем двусторонний двухвыборочный Z-критерий.

Пример 9.4.3.

Вернёмся к примеру, в котором средние двух выборок были заведомо близки.

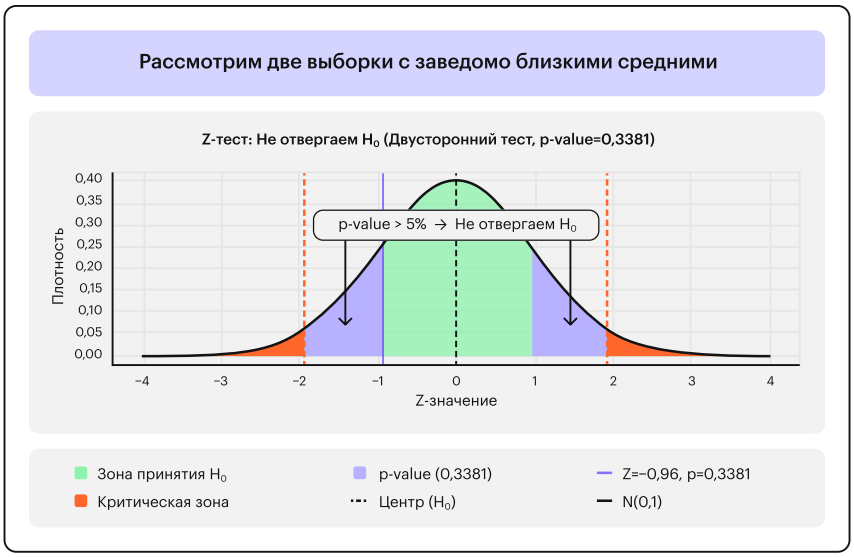

Рисунок 116. p-value на практике: средние близки

P-value представляет из себя хорошо заметную закрашенную площадь. Вероятность получить такие же или более экстремальные значения статистики велика, то есть нельзя отвергнуть гипотезу об отсутствии статистически значимой разницы между μ_X и μ_Y.

Пример 9.4.4.

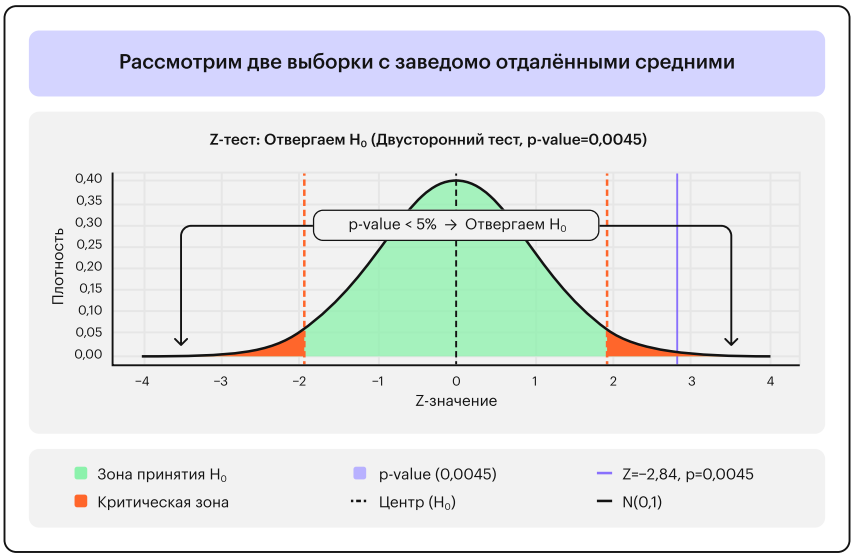

Рисунок 117. p-value на практике: средние далеки

P-value представляет из себя невидимую на графике закрашенную площадь. Вероятность получить такие же или более экстремальные значения статистики очень мала.

Поэтому мы отвергаем гипотезу о равенстве μ_X и μ_Y, так как получаем pvalue, которое меньше, чем α.

Таким образом, p-value оценивает, насколько данные совместимы с нулевой гипотезой.

Запомним фундаментальное свойство: p-value при верной нулевой гипотезе распределено равномерно на отрезке [0,1].

Чтобы доказать это, рассмотрим следующее. Пусть статистика теста T имеет непрерывное распределение под H_0 с функцией распределения $F(t)$. Тогда p-value определяется как $p = 1 - -F(T)$. Поскольку T под H_0 имеет cdf F, то $F(T) \sim U[0,1]$, и следовательно $1 - F(T) \sim U[0,1]$.

Доказательство: для любой $u \in [0,1]$ вероятность $\mathbb{P}(F(T) \leqslant \leqslant u) = \mathbb{P}(T \leqslant F^{-1}(u)) = u$, что и есть cdf равномерного распределения.

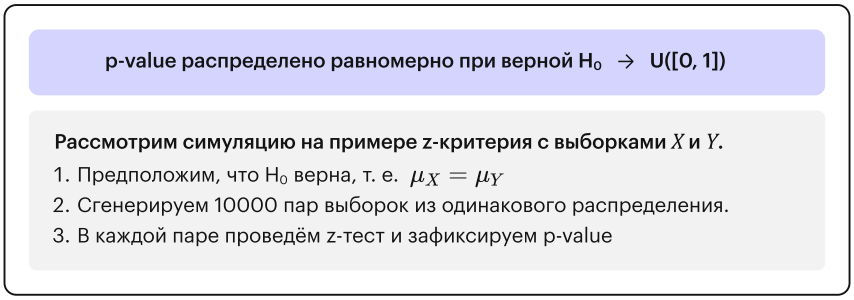

Рисунок 118

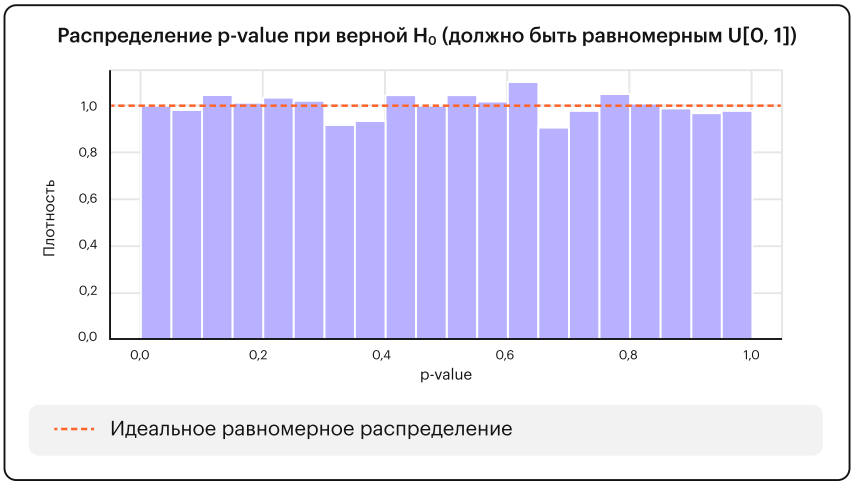

Рисунок 119

Вообще говоря, для того, чтобы проверить применимость критерия, особенно когда аналитическое доказательство сложно, мы можем использовать симуляцию (метод Монте-Карло).

Этот алгоритм примет следующий вид:

1. Генерировать множество выборок из распределения под нулевой гипотезой.
2. Для каждой выборки вычислить статистику теста.
3. Построить эмпирическое распределение статистики и срав-

нить с теоретическим.
4. Или вычислить p-value для каждой симуляции и проверить, что они равномерно распределены на [0,1].

Это позволяет убедиться, что критерий работает корректно в заданных условиях.

Пример 9.4.5.

С приближением сессии всё более актуальным становится вопрос влияния кофе на концентрацию внимания студентов. Исследуем его!

Пусть у нас есть две группы: группа A (30 студентов, не пили кофе, среднее время реакции — 170 мс, стандартное отклонение — 5 мс) и группа B (40 студентов, пили кофе, среднее — 168 мс, стандартное отклонение — 6 мс).

Сначала скажем, что дисперсии известны ($\sigma_A = 5$, $\sigma_B = 6$).

Тогда мы можем использовать Z-тест для проверки равенства средних. Значением Z-статистики будет

$$Z = \frac{\overline{X_A} - \overline{X_B}}{\sqrt{\frac{\sigma_A^2}{n} + \frac{\sigma_B^2}{m}}} = \frac{170 - 168}{\sqrt{\frac{25}{30} + \frac{36}{40}}} \approx 1.52,$$

p-value для двустороннего теста примерно равно 0.129. Здесь p-value — это вероятность увидеть такую или ещё большую разницу в средних, если кофе действительно не влияет. Если уровень значимости $\alpha = 0.05$, то поскольку $0.129 > 0.05$, нет оснований отвергать нулевую гипотезу о равенстве средних. Это значит, что наблюдаемая разница в средних может быть вызвана случайностью с вероятностью около 13%, и хотя это не так много, это одновременно не достаточно мало (в сравнении с α), чтобы сделать вывод о влиянии кофе.

Ранее мы всегда говорили о том, что мы знаем значение дисперсии: приравнивали его к выборочной дисперсии или говорили, что знаем её из исторических данных. Но на практике зачастую дисперсия неизвестна: как тогда проводить исследования? Благо, в статистике есть тест, который позволяет работать с таким (на самом деле очень широким) классом задач.

Мощность Z-критерия

Пример 9.4.6. Проверяем $H_0 : \mu = 100$ против $H_1 : \mu > 100$ при известной дисперсии $\sigma^2 = 15^2$ и уровне значимости $\alpha = = 0{,}05$. Тестовая статистика:

$$Z = \frac{\overline{X} - 100}{\sigma/\sqrt{n}}, \qquad H_0 \text{ отвергается, если } Z > 1.645.$$

Если истинное среднее $\mu_1 > 100$, то мощность равна

$$\text{Power}(\mu_1) = 1 - \Phi\left(1.645 - \frac{\sqrt{n}(\mu_1 - 100)}{\sigma}\right),$$

где $\Phi(\cdot)$ — функция распределения стандартного нормального закона.

Эта формула отражает вероятность того, что статистика Z при истинном значении μ_1 окажется правее критической границы 1.645. Если μ_1 чуть больше 100, то слагаемое $\dfrac{\sqrt{n}(\mu_1 - 100)}{\sigma}$ мало, и мощность близка к α.

Если же μ_1 значительно превышает 100, то выражение под Φ становится большим по модулю и отрицательным, и значение мощности быстро приближается к 1.

Рассмотрим 4 потенциальные ситуации. В каждой из них только одно из распределений является "истинным"и оно отмечено зелёным цветом.

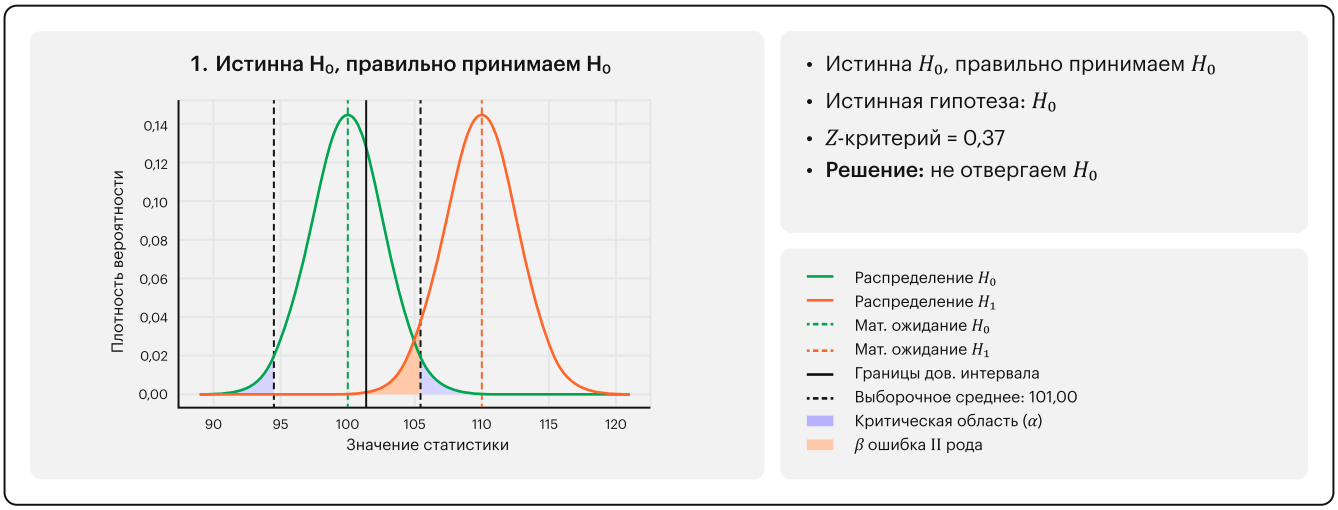

Рисунок 120. Правильно не отвергаем нулевую гипотезу

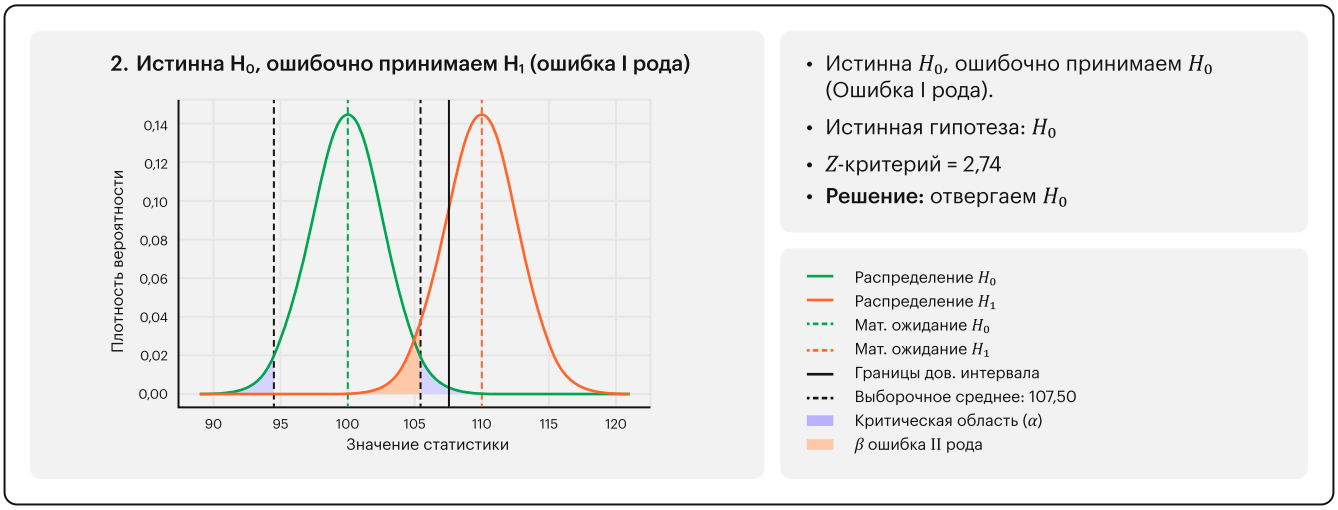

Рисунок 121. Ошибка I рода

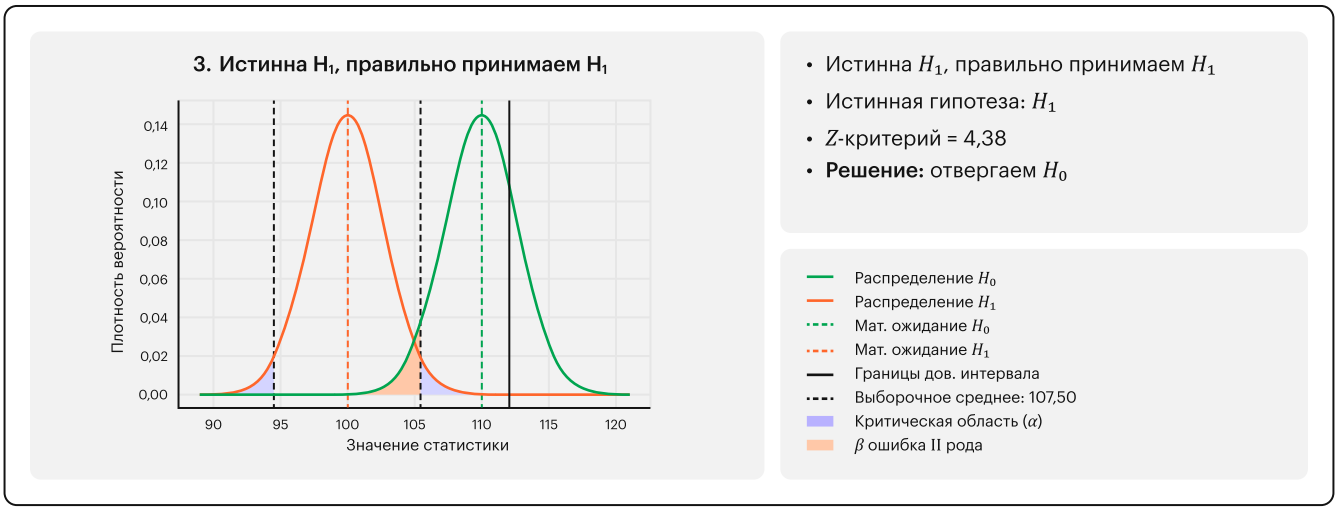

Рисунок 122. Верна альтернатива

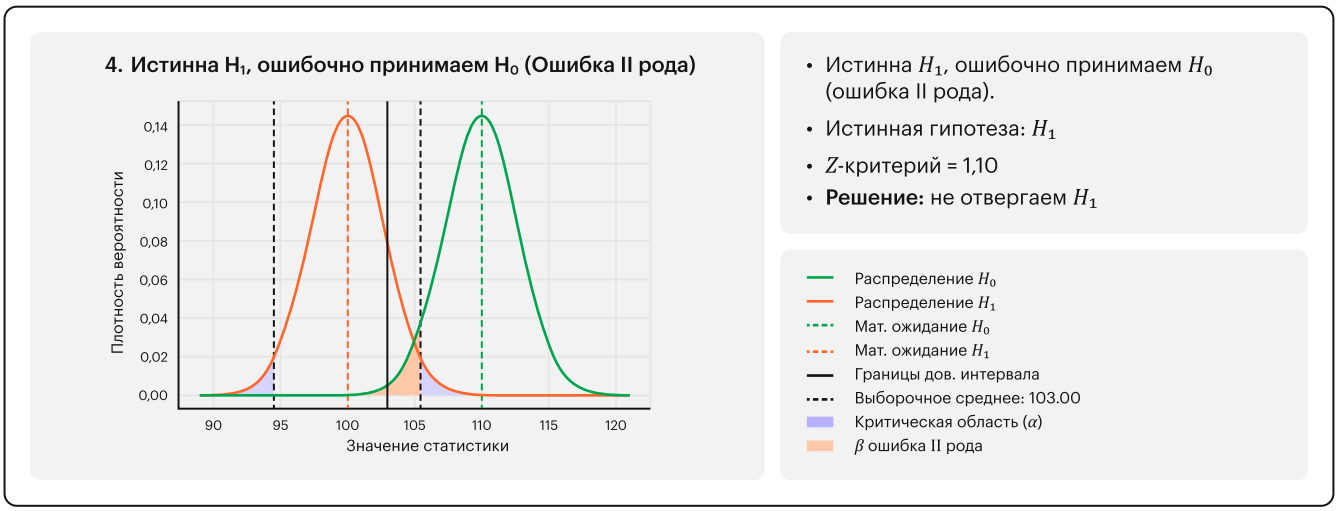

Рисунок 123. Ошибка II Рода

Чем сильнее эффект ($\mu_1 - \mu_0$), тем выше мощность. Малые отклонения от H_0 тест замечает лишь при достаточно большом n.

Отдельно можно рассмотреть случай, когда $1 - \beta = \alpha$.

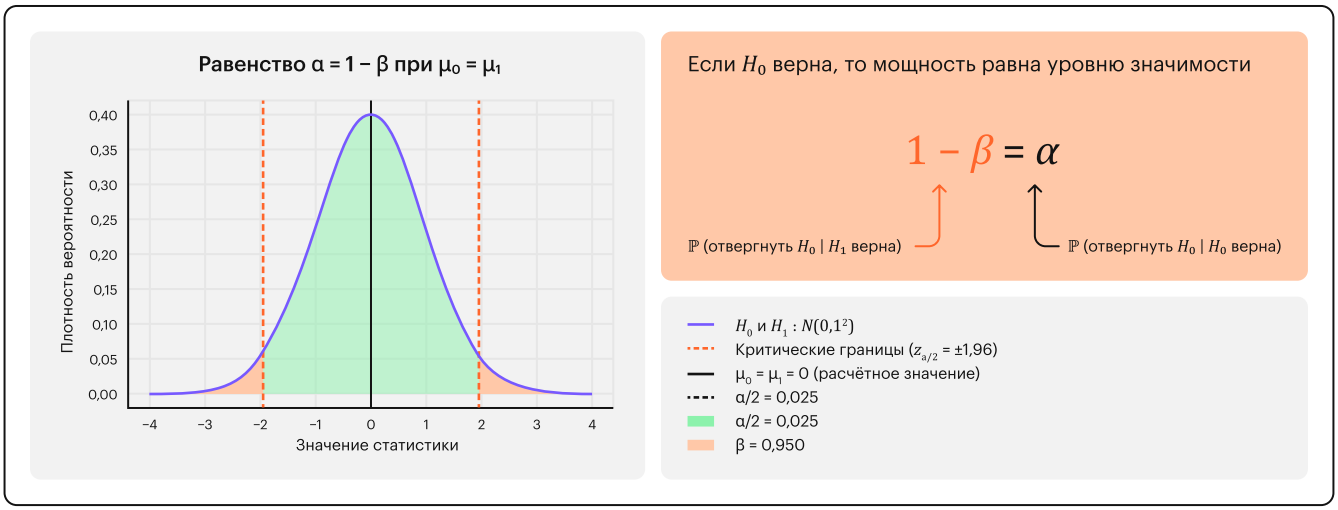

Рисунок 124. Ошибка II Рода

Зависимость мощности от параметров эксперимента

Мощность зависит от четырёх факторов:

$$\text{Power} = f(\mu_1 - \mu_0, \sigma, n, \alpha)$$

то есть от

1. Разницы $\mu_1 - \mu_0$.

Увеличение эффекта повышает мощность.

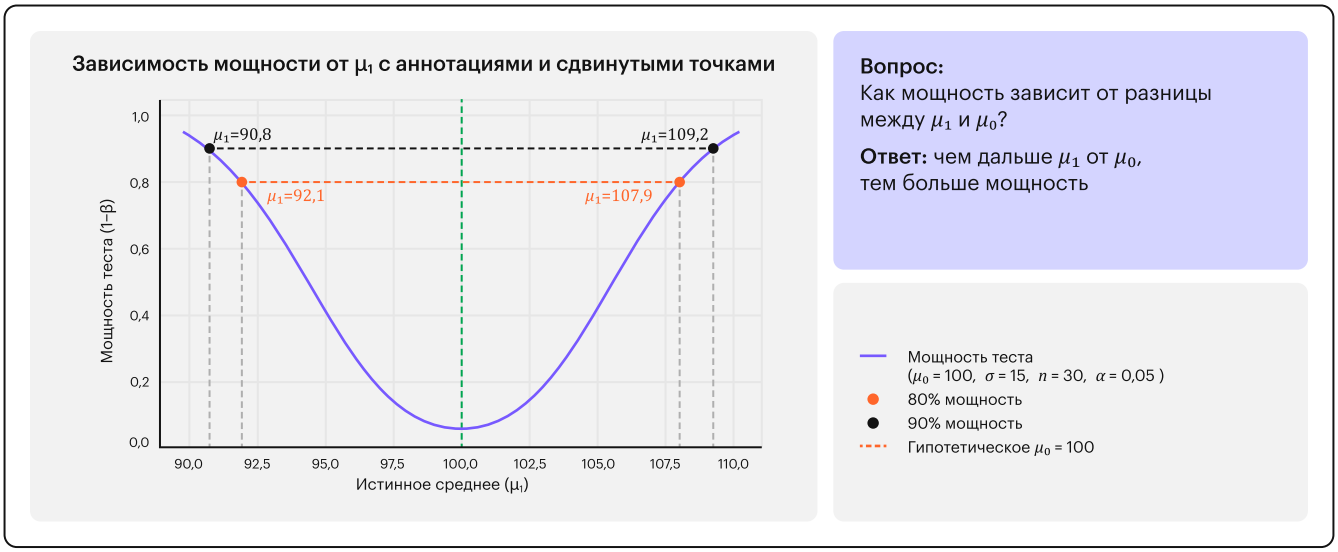

Рисунок 125. Зависимость мощности от $\mu_1 - \mu_0$. Двусторонний Z-тест

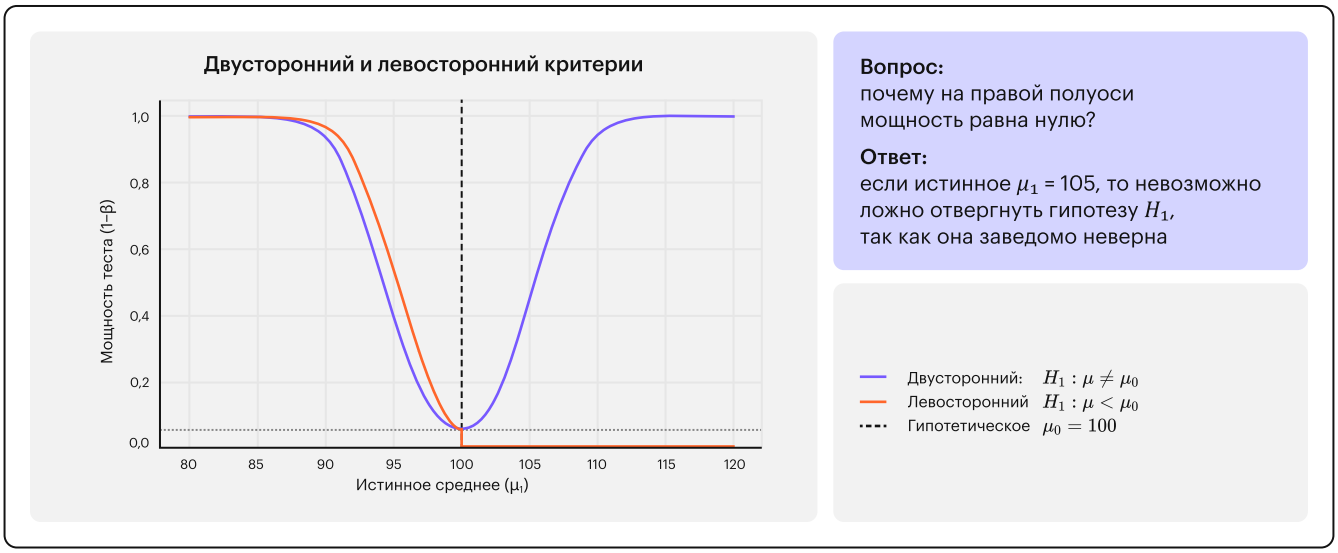

Вопрос:
почему на правой полуоси мощность равна нулю?

Ответ:
если истинное μ_1 = 105, то невозможно ложно отвергнуть гипотезу H_1, так как она заведомо неверна

Рисунок 126. Зависимость мощности от $\mu_1 - \mu_0$. Двусторонний и левосторонний Z-тест

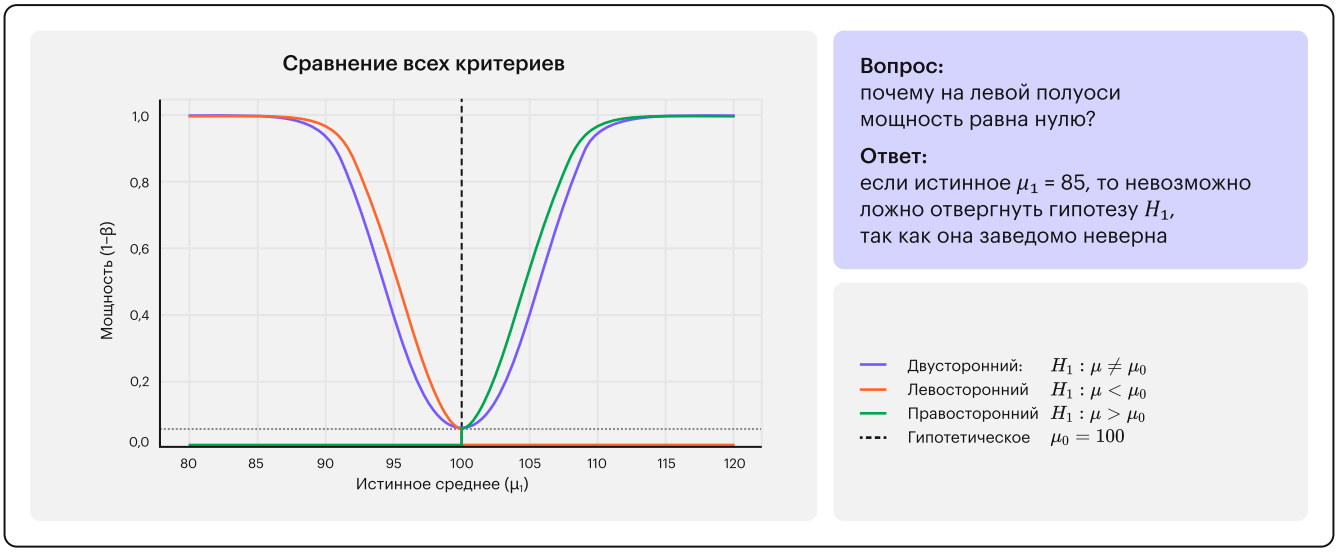

Вопрос:
почему на левой полуоси мощность равна нулю?

Ответ:
если истинное μ_1 = 85, то невозможно ложно отвергнуть гипотезу H_1, так как она заведомо неверна

Рисунок 127. Зависимость мощности от $\mu_1 - \mu_0$. Двусторонний, левосторонний и правосторонний Z-тест

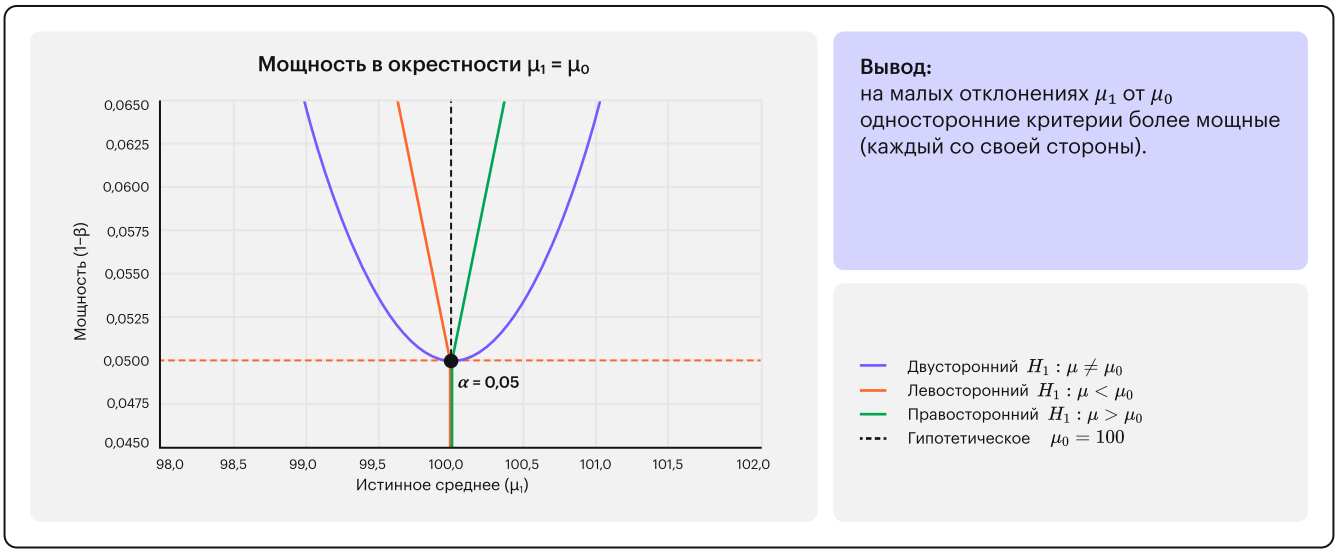

Рисунок 128. Мощность трёх тестов в окрестности μ_0

2. Дисперсии σ^2.

Чем больше разброс, тем труднее отличить H_1 от H_0.

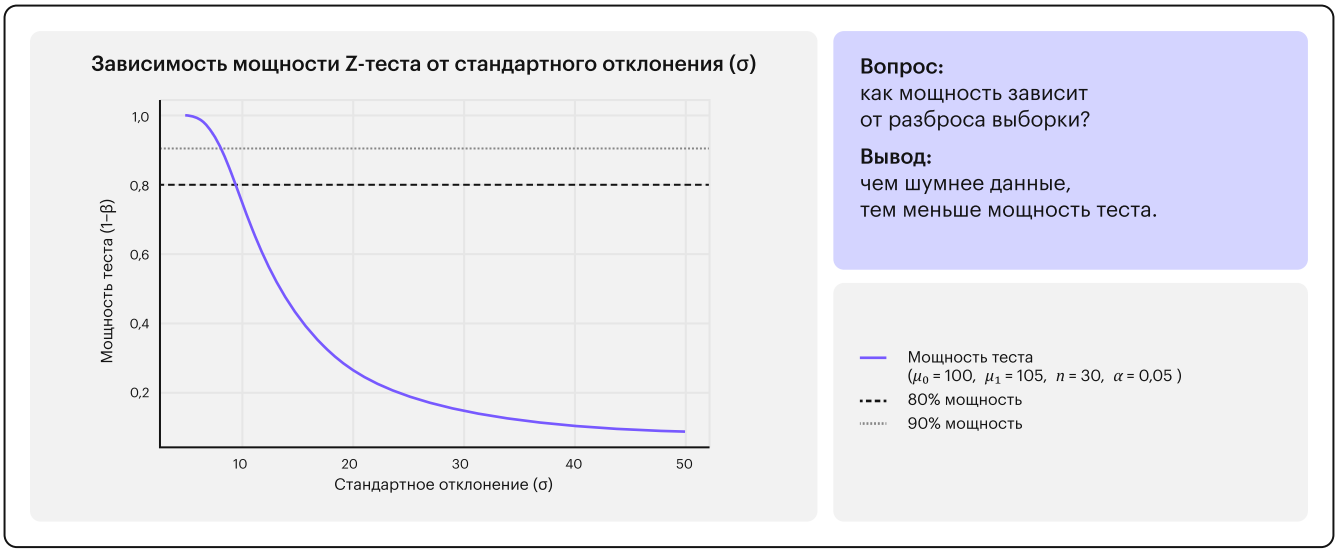

Рисунок 129. Зависимость мощности от дисперсии

3. Размера выборки n.

При росте n стандартная ошибка уменьшается, и тест становится чувствительнее.

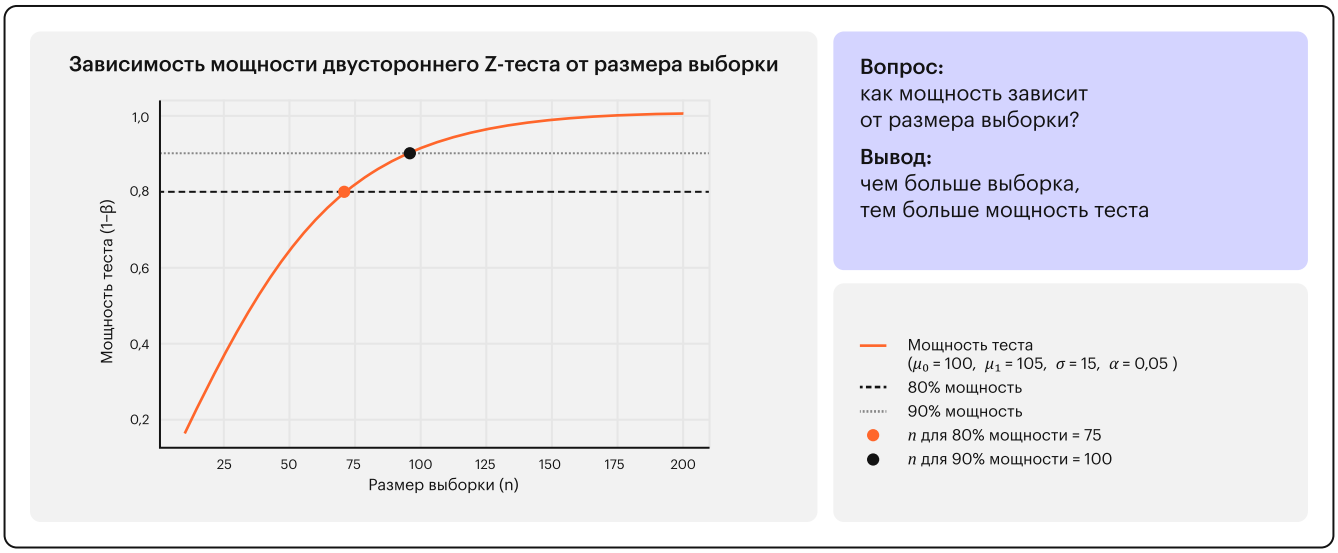

Рисунок 130. Зависимость мощности от размера выборки

4. Уровня значимости

Больший порог α повышает вероятность отклонить H_0 и увеличивает мощность.

Таким образом, при проектировании реальных продуктовых тестов необходимо учитывать, каким образом влияют друг на друга различные показатели эксперимента, чтобы выбрать оптимальные параметры и не просесть, например, по мощности теста.

5. НЕОБХОДИМОЕ КОЛИЧЕСТВО НАБЛЮДЕНИЙ

Одной из главных задач при дизайне A/B теста является расчёт необходимого количества наблюдений для эксперимента. Исходя из этого определяется длительность эксперимента.

Как мы увидим, необходимое количество наблюдений в эксперименте зависит от его различных параметров, таких как α и β, а также σ_X и σ_Y.

Количество наблюдений зависит также от потенциального ожидаемого роста μ_Y по сравнению с μ_X. В рамках эксперимента мы хотим повысить какую-то метрику (Например, средний чек) и чем меньший рост чека мы считаем "значимым с точки зрения бизнеса тем большее количество наблюдений нам потребуется, чтобы "разглядеть"данный прирост, если он действительно есть.
MDE - это минимальный прирост метрики в рамках теста, который мы считаем "значимым с точки зрения дизайна эксперимента".

ОПРЕДЕЛЕНИЕ 9.5.1

Minimum Detectable Effect

Чаще всего он задаётся как внешний параметр эксперимента, наравне с допустимыми ошибками первого и второго рода.

Пример 9.5.1.

Рассмотрим следующий вариант эксперимента. Была внедре-

на новая рекомендательная система, которая призвана поднять средний чек клиента за счёт эффективных рекомендаций.

Допустим, текущий средний чек составляет 3200 рублей, а стандартное отклонение составляет 100 рублей. Также положим, что допустимые ошибки первого и второго рода принимают классические значения: $\alpha = 5\%$ и $1 - \beta = 20\%$.

Отсюда возможны два варианта дальнейшего дизайна эксперимента:

1. Мы знаем n, но не знаем MDE. Например, мы готовы крутить A/B тест в течение недели и у нас есть по 1000 наблюдений (клиентов) каждый день. Исходя из имеющегося n можем рассчитать минимальный возможный эффект, который мы сможем "разглядеть если он действительно будет.

2. Мы знаем MDE, но не знаем n. Например, мы считаем, что прирост среднего чека меньше чем на 100 рублей не является для нас "выигрышным". Тогда $MDE = 100$, и мы можем рассчитать необходимое количество наблюдений (а значит, и необходимую длительность) n.

Теперь выведем формулы для MDE и необходимого количества наблюдений для трёх вариаций двухвыборочного Z-критерия: двусторонняя, правосторонняя и левосторонняя.

Пусть имеются две независимые выборки

$$X_1, \ldots, X_{n_X} \sim N(\mu_X, \sigma_X^2), \qquad Y_1, \ldots, Y_{n_Y} \sim N(\mu_Y, \sigma_Y^2),$$

где стандартные отклонения σ_X и σ_Y известны. Проверяется гипотеза $H_0 : \mu_X = \mu_Y$.

Обратим внимание на то, что данный вывод будет также асимптотически работать для не нормальных выборок благодаря Центральной Предельной Теореме.

Тестовая статистика имеет вид

$$Z = \frac{\overline{X} - \overline{Y}}{\sqrt{\frac{\sigma_X^2}{n_X} + \frac{\sigma_Y^2}{n_Y}}}.$$

При H_0 выполнено $Z \sim N(0, 1)$.

Пусть на самом деле разность средних равна $\Delta = \mu_X - \mu_Y$.

Так как

$$\overline{X} - \overline{Y} \sim N\left(\Delta, \frac{\sigma_X^2}{n_X} + \frac{\sigma_Y^2}{n_Y}\right),$$

то при альтернативе

$$Z \sim N\left(\frac{\Delta}{\sqrt{\frac{\sigma_X^2}{n_X}+\frac{\sigma_Y^2}{n_Y}}}, 1\right).$$

Обозначим

$$\mu_Z = \frac{\Delta}{\sqrt{\frac{\sigma_X^2}{n_X}+\frac{\sigma_Y^2}{n_Y}}}.$$

Двусторонняя альтернатива

Для двусторонней альтернативы $H_1 : \mu_X \neq \mu_Y$ критическая область имеет вид $|Z| > z_{1-\alpha/2}$.

Если рассматривается положительный эффект $\Delta > 0$, то основная часть мощности приходится на правый хвост. Поэтому

$$1 - \beta \approx \mathbb{P}_{H_1}(Z > z_{1-\alpha/2}) = 1 - \Phi(z_{1-\alpha/2} - \mu_Z).$$

Следовательно, $\mu_Z - z_{1-\alpha/2} = z_{1-\beta}$, откуда

$$\mu_Z = z_{1-\alpha/2} + z_{1-\beta}.$$

Подставляя выражение для μ_Z, получаем $\frac{\Delta}{\sqrt{\frac{\sigma_X^2}{n_X}+\frac{\sigma_Y^2}{n_Y}}} =$
$= z_{1-\alpha/2} + z_{1-\beta}$.

Отсюда минимальный обнаруживаемый эффект равен

$$\mathrm{MDE} = |\Delta| = (z_{1-\alpha/2} + z_{1-\beta})\sqrt{\frac{\sigma_X^2}{n_X} + \frac{\sigma_Y^2}{n_Y}}.$$

Если размеры выборок одинаковы, то есть $n_X = n_Y = n$, то

$$\mathrm{MDE} = |\Delta| = (z_{1-\alpha/2} + z_{1-\beta})\sqrt{\frac{\sigma_X^2 + \sigma_Y^2}{n}}.$$

Выразим необходимое количество наблюдений в каждой выборке:

$$n = \frac{(z_{1-\alpha/2} + z_{1-\beta})^2(\sigma_X^2 + \sigma_Y^2)}{\Delta^2}.$$

Если дополнительно $\sigma_X = \sigma_Y = \sigma$, то

$$n = \frac{2(z_{1-\alpha/2} + z_{1-\beta})^2 \sigma^2}{\Delta^2}.$$

Общее количество наблюдений в двух выборках равно

$$N = 2n = \frac{2(z_{1-\alpha/2} + z_{1-\beta})^2 (\sigma_X^2 + \sigma_Y^2)}{\Delta^2}.$$

При $\sigma_X = \sigma_Y = \sigma$ получаем

$$N = \frac{4(z_{1-\alpha/2} + z_{1-\beta})^2 \sigma^2}{\Delta^2}.$$

Правосторонняя альтернатива

Для правосторонней альтернативы $H_1 : \mu_X > \mu_Y$ критическая область имеет вид $Z > z_{1-\alpha}$.

Мощность равна

$$1 - \beta = \mathbb{P}_{H_1}(Z > z_{1-\alpha}) = 1 - \Phi(z_{1-\alpha} - \mu_Z).$$

Следовательно, $\mu_Z - z_{1-\alpha} = z_{1-\beta}$, откуда

$$\mu_Z = z_{1-\alpha} + z_{1-\beta}.$$

Подставляя выражение для μ_Z, получаем $\frac{\Delta}{\sqrt{\frac{\sigma_X^2}{n_X} + \frac{\sigma_Y^2}{n_Y}}} = z_{1-\alpha} +$

$+ z_{1-\beta}$.

Следовательно,

$$\mathrm{MDE} = \Delta = (z_{1-\alpha} + z_{1-\beta}) \sqrt{\frac{\sigma_X^2}{n_X} + \frac{\sigma_Y^2}{n_Y}}.$$

Если $n_X = n_Y = n$, то

$$\mathrm{MDE} = \Delta = (z_{1-\alpha} + z_{1-\beta}) \sqrt{\frac{\sigma_X^2 + \sigma_Y^2}{n}}.$$

Необходимое количество наблюдений в каждой выборке равно

$$n = \frac{(z_{1-\alpha} + z_{1-\beta})^2 (\sigma_X^2 + \sigma_Y^2)}{\Delta^2}.$$

Если $\sigma_X = \sigma_Y = \sigma$, то

$$n = \frac{2(z_{1-\alpha} + z_{1-\beta})^2 \sigma^2}{\Delta^2}.$$

Общее количество наблюдений равно

$$N = 2n = \frac{2(z_{1-\alpha} + z_{1-\beta})^2 (\sigma_X^2 + \sigma_Y^2)}{\Delta^2}.$$

При $\sigma_X = \sigma_Y = \sigma$ получаем

$$N = \frac{4(z_{1-\alpha} + z_{1-\beta})^2 \sigma^2}{\Delta^2}.$$

Левосторонняя альтернатива

Для левосторонней альтернативы $H_1 : \mu_X < \mu_Y$ рассматривается эффект $\Delta = \mu_X - \mu_Y < 0$. Критическая область имеет вид $Z < z_\alpha = -z_{1-\alpha}$.

Мощность равна

$$1 - \beta = \mathbb{P}_{H_1}(Z < -z_{1-\alpha}) = \Phi(-z_{1-\alpha} - \mu_Z).$$

Следовательно, $-z_{1-\alpha} - \mu_Z = z_{1-\beta}$, откуда $-\mu_Z = z_{1-\alpha} + z_{1-\beta}$.

Подставляя выражение для μ_Z, получаем

$$-\frac{\Delta}{\sqrt{\frac{\sigma_X^2}{n_X} + \frac{\sigma_Y^2}{n_Y}}} = z_{1-\alpha} + z_{1-\beta}.$$

Следовательно,

$$\mathrm{MDE} = |\Delta| = (z_{1-\alpha} + z_{1-\beta}) \sqrt{\frac{\sigma_X^2}{n_X} + \frac{\sigma_Y^2}{n_Y}}.$$

Если $n_X = n_Y = n$, то

$$\mathrm{MDE} = |\Delta| = (z_{1-\alpha} + z_{1-\beta}) \sqrt{\frac{\sigma_X^2 + \sigma_Y^2}{n}}.$$

Необходимое количество наблюдений в каждой выборке равно

$$n = \frac{(z_{1-\alpha} + z_{1-\beta})^2(\sigma_X^2 + \sigma_Y^2)}{\Delta^2}.$$

Если $\sigma_X = \sigma_Y = \sigma$, то

$$n = \frac{2(z_{1-\alpha} + z_{1-\beta})^2\sigma^2}{\Delta^2}.$$

Общее количество наблюдений равно

$$N = 2n = \frac{2(z_{1-\alpha} + z_{1-\beta})^2(\sigma_X^2 + \sigma_Y^2)}{\Delta^2}.$$

При $\sigma_X = \sigma_Y = \sigma$ получаем

$$N = \frac{4(z_{1-\alpha} + z_{1-\beta})^2\sigma^2}{\Delta^2}.$$

Сокращённая формула для двустороннего теста

Посмотрим ещё раз на расчёт необходимого количества наблюдений для двустороннего теста.

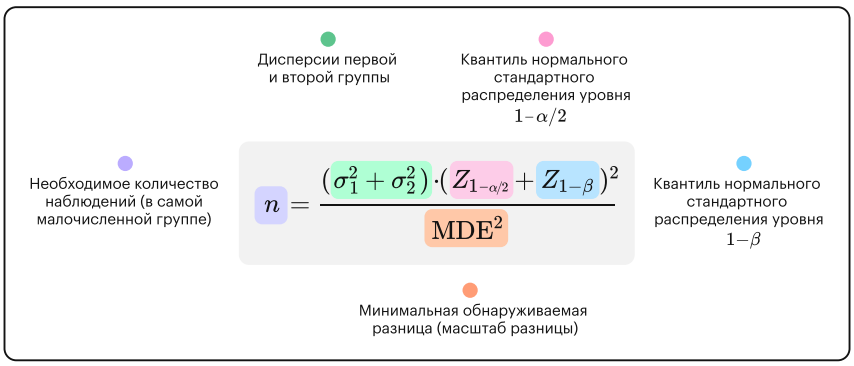

Рисунок 131. Формула необходимого количества наблюдений для теста

Формула сводится к более простому частному случаю, если допустить несколько предпосылок

$$\sigma_t^2 = \sigma_c^2 = \sigma^2$$

$$\alpha = 5\% \qquad \beta = 20\%$$

$$n = \frac{(\sigma_t^2 + \sigma_c^2)\cdot(Z_{1-\alpha/2}+Z_{1-\beta})^2}{\text{MDE}^2} = \frac{2\sigma^2 \cdot (1.96+0.84)^2}{\text{MDE}^2} \approx \frac{16\sigma^2}{\text{MDE}^2}$$

Рисунок 132. Сокращённая формула необходимого количества наблюдений для теста

Алгоритм дизайна A/B теста

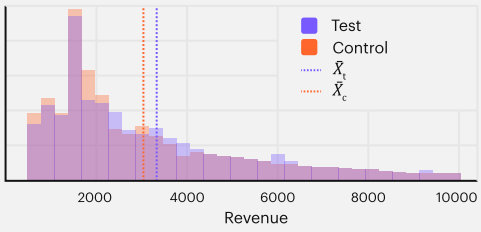

Вариант 1: n_t $\overline{x}_t$ σ_t

Вариант 2: n_c $\overline{x}_c$ σ_c

- Наблюдаемый эффект: $\overline{x}_t - \overline{x}_c$
- Распределение для H_0: $N(0, \text{se})$ где $\text{se} = \sqrt{\frac{\sigma_t^2}{n_t} + \frac{\sigma_c^2}{n_c}}$
- Стандартизированный эффект:

$$Z = \frac{\overline{x}_t - \overline{x}_c}{\sqrt{\frac{\sigma_t^2}{n_t} + \frac{\sigma_c^2}{n_c}}} = \frac{\overline{x}_t - \overline{x}_c}{\text{se}}$$

- Стандартное распределение для H_0:$N(0, 1)$

Рисунок 133. A/B тест. Как делать вывод

Шаг 1
$\text{MDE} = \bar{x}_t - \bar{x}_c$

Шаг 2
Из левого распределения: $z_{\text{crit}} = z_{1-\frac{\alpha}{2}}$
Из правого распределения: $z_{\text{crit}} = z_\beta$

Шаг 3
Стандартизация: $Z_i = \frac{x_i - \mu}{\text{se}}$, где $\text{se} = \frac{\sigma_x}{\sqrt{n}}$
Тогда: $x_i = Z_i \cdot \text{se} + \mu$

Шаг 4
Получается $x_{\text{crit}} = Z_{\text{crit}} \cdot \text{se} + \mu$
Выразим x_{crit} с точки зрения левого и правого распределения

$$\begin{cases} x_{\text{crit}} = Z_{1-\frac{\alpha}{2}} \cdot \sqrt{\frac{\sigma_t^2+\sigma_c^2}{n}} + 0 \\ x_{\text{crit}} = Z_\beta \cdot \sqrt{\frac{\sigma_t^2+\sigma_c^2}{n}} + \text{MDE} \end{cases}$$

Шаг 5

$$n = \frac{(\sigma_t^2 + \sigma_c^2)\cdot(Z_{1-\alpha/2}+Z_{1-\beta})^2}{\text{MDE}^2}$$

Рисунок 134. Алгоритм расчёта параметров A/B теста

Пример 9.5.2.

Текущий средний чек равен $\mu = 3200$ рублей, а стандартное отклонение в обеих группах известно и равно $\sigma_X = \sigma_Y = 100$ рублей.

Положим $\alpha = 0.05$, $\beta = 0.2$, поэтому $z_{1-\beta} = z_{0.8} \approx 0.842$, $z_{1-\alpha/2} = z_{0.975} \approx 1.96$ и $z_{1-\alpha} = z_{0.95} \approx 1.645$.

Предположим, что размеры групп одинаковы: $n_X = n_Y = n$.

При $\alpha = 0.05$, $\beta = 0.2$ и равных стандартных отклонениях для двустороннего теста можно использовать упрощённые формулы

$$n \approx \frac{16\sigma^2}{\mathrm{MDE}^2}, \qquad \mathrm{MDE} \approx \frac{4\sigma}{\sqrt{n}}.$$

1. Известно количество наблюдений, требуется найти MDE

За неделю в каждой группе будет собрано $n = 7 \cdot 1000 = 7000$ наблюдений.

Для двусторонней альтернативы $H_1 : \mu_X \neq \mu_Y$:

$$\mathrm{MDE} = (z_{1-\alpha/2} + z_{1-\beta})\sigma\sqrt{\frac{2}{n}} = (1.96 + 0.842)\cdot \\ \cdot 100\sqrt{\frac{2}{7000}} \approx 4.74.$$

Таким образом, тест позволяет обнаружить изменение среднего чека примерно на 4.74 рубля, или на $4.74/3200 \cdot 100$.

По упрощённой формуле

$$\mathrm{MDE} \approx \frac{4\sigma}{\sqrt{n}} = \frac{4 \cdot 100}{\sqrt{7000}} \approx 4.78.$$

После округления вверх получаем 5 рублей. Упрощённая формула даёт результат на $4.78 - 4.74 = 0.04$ рубля, или примерно на 0.94%, больше точного расчёта.

Для правосторонней альтернативы $H_1 : \mu_X > \mu_Y$:

$$\mathrm{MDE} = (z_{1-\alpha} + z_{1-\beta})\sigma\sqrt{\frac{2}{n}} = (1.645 + 0.842)\cdot \\ \cdot 100\sqrt{\frac{2}{7000}} \approx 4.20.$$

Тест позволяет обнаружить увеличение среднего чека примерно на 4.20 рубля, или на 0.13%. При округлении эффекта вверх получаем 5 рублей.

По упрощённой формуле получаем $\mathrm{MDE} \approx 4.78$ рубля, после округления вверх — 5 рублей. Упрощённая формула даёт результат на $4.78 - 4.20 = 0.58$ рубля, или примерно на 13.73%, больше точного расчёта.

Для левосторонней альтернативы $H_1 : \mu_X < \mu_Y$ абсолютный MDE совпадает с правосторонним случаем:

$$\mathrm{MDE} = |\Delta| = (1.645 + 0.842) \cdot 100\sqrt{\frac{2}{7000}} \approx 4.20.$$

То есть тест позволяет обнаружить уменьшение среднего чека примерно на 4.20 рубля, или на те же 0.13%. При округлении эффекта вверх получаем 5 рублей.

По упрощённой формуле получаем $\mathrm{MDE} \approx 4.78$ рубля, после округления вверх — 5 рублей. Расхождение также составляет около 0.58 рубля, или 13.73%.

2. Известен MDE, требуется найти количество наблюдений

Пусть минимальный практически значимый эффект равен $\mathrm{MDE} = |\Delta| = 10$ рублей.

Для двусторонней альтернативы $H_1 : \mu_X \neq \mu_Y$ количество наблюдений в каждой группе равно

$$n = \frac{2(z_{1-\alpha/2} + z_{1-\beta})^2\sigma^2}{\Delta^2} = \frac{2(1.96 + 0.842)^2 \cdot 100^2}{10^2} \approx$$
$$\approx 1570.24.$$

Следовательно, требуется 1571 наблюдение в каждой группе, а суммарный объём двух групп равен $N = 3142$.

По упрощённой формуле

$$n \approx \frac{16\sigma^2}{\mathrm{MDE}^2} = \frac{16 \cdot 100^2}{10^2} = 1600.$$

Получаем 1600 наблюдений в каждой группе и $N = 3200$ наблюдений суммарно. Упрощённая формула даёт на $1600 - 1570.24 = = 29.76$ наблюдения, или примерно на 1.90%, больше.

Для правосторонней альтернативы $H_1 : \mu_X > \mu_Y$:

$$n = \frac{2(z_{1-\alpha} + z_{1-\beta})^2\sigma^2}{\Delta^2} = \frac{2(1.645 + 0.842)^2 \cdot 100^2}{10^2} \approx 1237.03.$$

Следовательно, требуется 1238 наблюдений в каждой группе, а суммарный объём равен $N = 2476$.

По упрощённой формуле получаем $n = 1600$ наблюдений в каждой группе и $N = 3200$ наблюдений суммарно. Это на $1600- -1237.03 = 362.97$ наблюдения, или примерно на 29.34%, больше точного расчёта.

Для левосторонней альтернативы $H_1 : \mu_X < \mu_Y$ формула совпадает с правосторонним случаем:

$$n = \frac{2(z_{1-\alpha} + z_{1-\beta})^2 \sigma^2}{\Delta^2} \approx 1237.03.$$

Следовательно, требуется 1238 наблюдений в каждой группе, а суммарный объём равен $N = 2476$.

По упрощённой формуле получаем $n = 1600$ наблюдений в каждой группе и $N = 3200$ наблюдений суммарно.

Расхождение также составляет около 360 наблюдений.

Часть 10. Параметрические критерии

В математической статистике при тестировании гипотез мы часто используем статистические критерии. Давай разберёмся, что это такое и какими они бывают.

ОПРЕДЕЛЕНИЕ 10.0.1

Параметрический критерий

Тест, который предполагает, что данные следуют определённому распределению с фиксированным набором параметров (например, нормальное распределение с зафиксированными математическим ожиданием и дисперсией). Такие критерии используют эти предположения для расчёта статистики теста.

ОПРЕДЕЛЕНИЕ 10.0.2

Непараметрический критерий

Тест, который не делает строгих предположений о форме распределения данных. Вместо этого он зачастую основывается на рангах или знаках данных и может применяться к более широкому классу распределений.

Параметрические критерии обычно обладают большей мощностью, если предположения верны, но могут давать неверные результаты, если данные не соответствуют модели. Непараметрические — более робастные, но могут быть менее эффективными.

1. КРИТЕРИИ ДЛЯ ДИСКРЕТНЫХ РАСПРЕДЕЛЕНИЙ

В предыдущих разделах мы рассмотрели критерии, которые часто используют аппроксимацию непрерывными распределениями, например, нормальным.

Однако на практике могут встречаться и дискретные распределения. Это создаёт дополнительные сложности при построении критериев с точным уровнем значимости. Разберёмся, как строить критерии для дискретных случаев, какие проблемы и особенности возникают в этом случае.

ОПРЕДЕЛЕНИЕ 10.1.1

Рассмотрим классический пример с дискретным распределением — схему Бернулли, где наблюдения $X_i \sim \mathrm{Bernoulli}(p)$, то есть суть независимые броски монетки с вероятностью успеха p. Критерий для проверки гипотезы о параметре p в биномиальном распределении использует статистику $S = \sum_{i=1}^{n} X_i \sim \mathrm{Bin}(n, p)$. Для $H_0 : p = p_0$ против $H_1 : p > p_0$ отвергаем H_0, если $S > c_\alpha$, где c_α выбран так, чтобы $\mathbb{P}(S > c_\alpha \mid H_0) \leqslant \alpha$.

Пример 10.1.1. Пусть $n = 11$, $p = 0,4$ и статистика $S = \sum_{i=1}^{11} X_i \sim \mathrm{Bin}(11, 0.4)$. Контролируемая дисперсия не позволяет точно достичь уровня значимости $\alpha = 0,05$:

$$\mathbb{P}(S \leqslant 0) = 0,0036, \quad \mathbb{P}(S \leqslant 1) = 0,038, \quad \mathbb{P}(S \leqslant 2) = 0,1189.$$

Если выбрать критическую зону $c_\alpha = 2$, то $\mathbb{P}(S > 2 \mid H_0) = 1 - 0,1189 = 0,8811 > 1 - \alpha$, что слишком много. Для точного контроля уровня α приходится использовать рандомизированные критерии или аппроксимации.

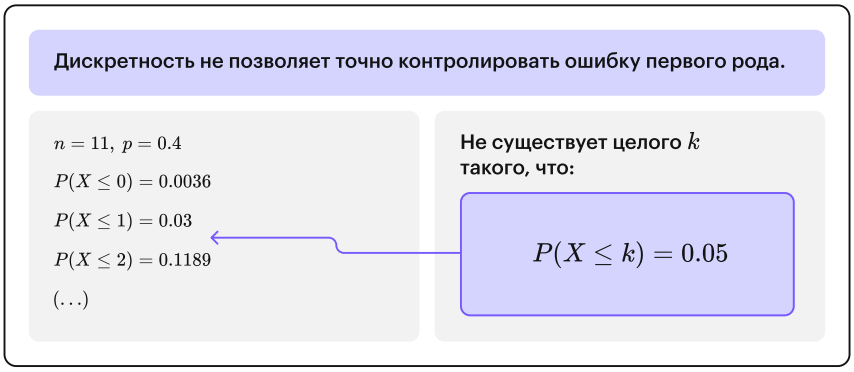

Рисунок 135. Значения функции распределения биномиального распределения

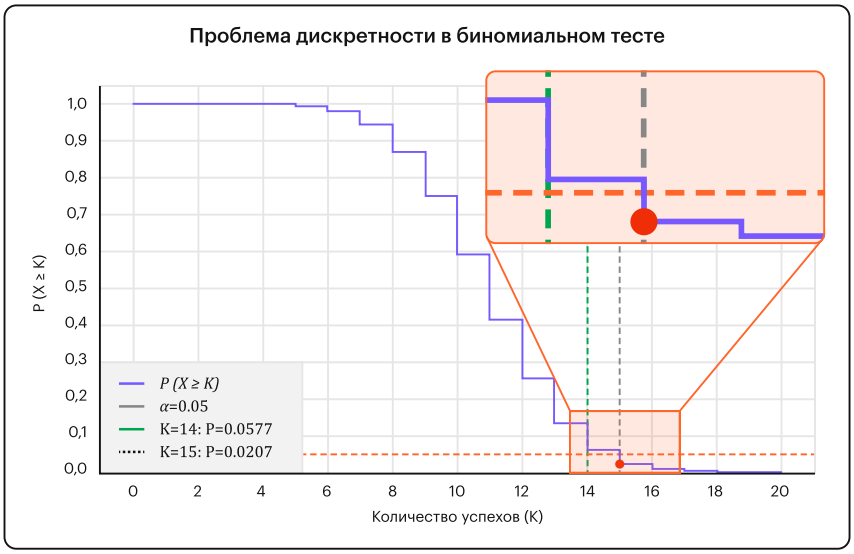

Рисунок 136. График функции распределения биномиального распределения

Проблема дискретных распределений заключается в том, что вероятности кумулятивны и «скачкообразны», так что нельзя всегда достичь точно α: реальный размер теста может быть меньше α, что снижает мощность.

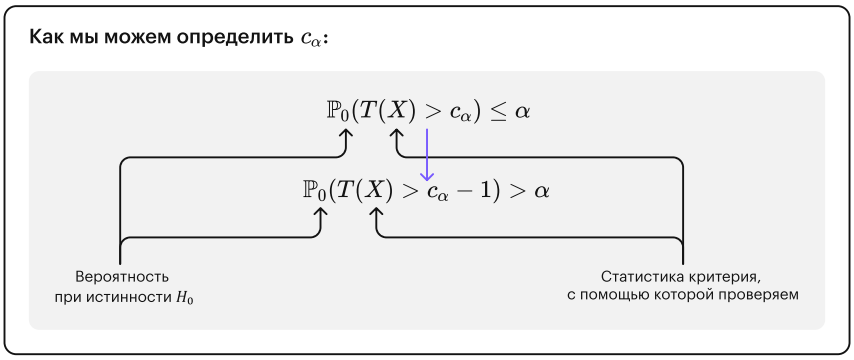

Рисунок 137. Критериальная зона в дискретном тесте

Для малых n в дискретных случаях используйте exact тесты (например, биномиальный тест), вычисляя p-value как tail probability (вероятность больших отклонений).

Для больших n ЦПТ позволяет аппроксимировать $Bin(n, p)$ нормальным, и использовать Z-критерий как в предыдущих примерах.

Пример 10.1.2.

Рассмотрим пример с осьминогом Паулем. Пауль предположительно угадывал результаты футбольных матчей и необходимо с помощью статистического критерия убедиться, не шарлатан ли наш осьминог. Для этого рассмотрим три потенциальные ситуации.

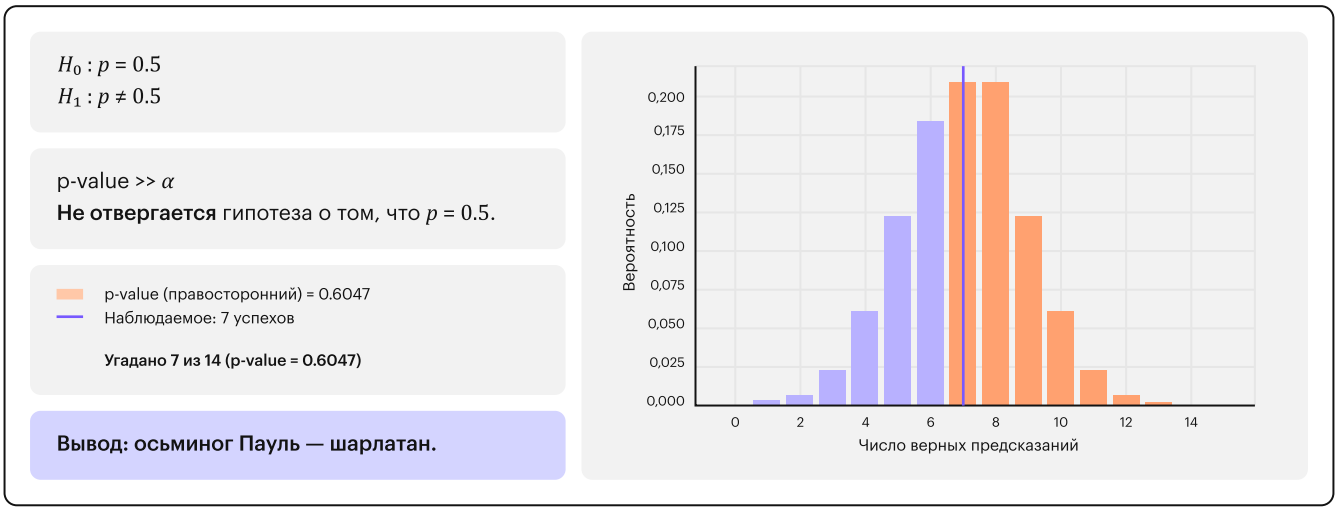

Рисунок 138. Тест биномиального распределения. Пример Пауля. Кейс шарлатана

$H_0 : p = 0.5$
$H_1 : p \neq 0.5$

p-value > α
Не отвергается гипотеза о том, что $p = 0.5$.

p-value (правосторонний) = 0.0898
Наблюдаемое: 10 успехов

Угадано 10 из 14 (p-value = 0.0898)

Вывод: осьминог Пауль вроде бы шарлатан.

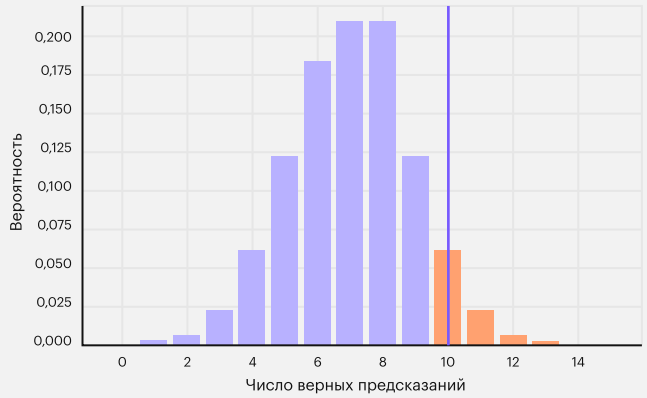

Рисунок 139. Тест биномиального распределения. Пример Пауля. Кейс неточности

$H_0 : p = 0.5$
$H_1 : p \neq 0.5$

p-value < α
Отвергается гипотеза о том, что $p = 0.5$.

p-value (правосторонний) = 0.0065
Наблюдаемое: 12 успехов

Угадано 12 из 14 (p-value = 0.0065)

Вывод: осьминог Пауль — волшебник.

Рисунок 140. Тест биномиального распределения. Пример Пауля. Кейс волшебника

Мощность дискретного теста

Процедура проверки подобного теста понятна, но что же делать с мощностью, которая также является важным параметром теста?

Мощность зависит, среди прочих, от альтернативной гипотезы и от количества наблюдений.

Визуализируем сначала зависимость мощности от различных параметров теста в биномиальном тесте.

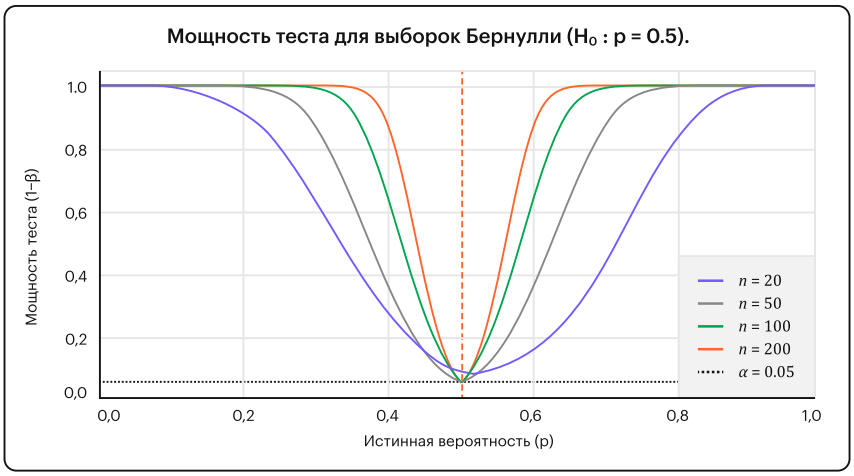

Рисунок 141. Мощность биномиального теста. Двусторонний критерий

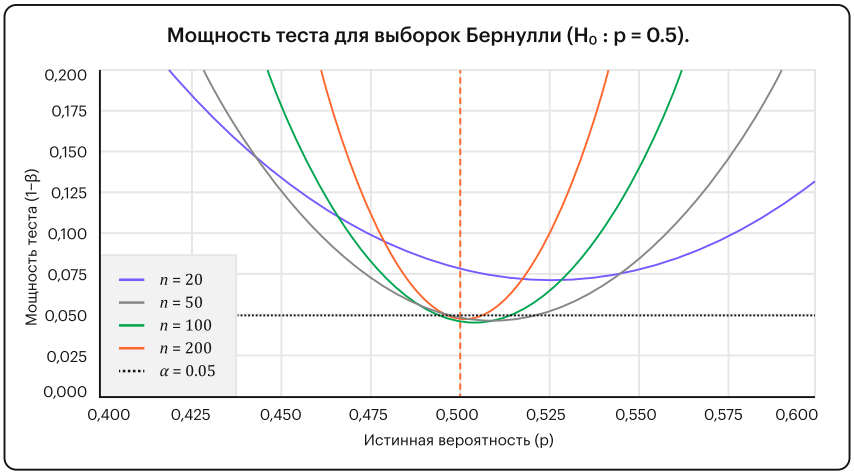

Рисунок 142. Мощность биномиального теста. Двусторонний критерий. Зум-ин

Как будет выглядеть эта зависимость для односторонних критериев?

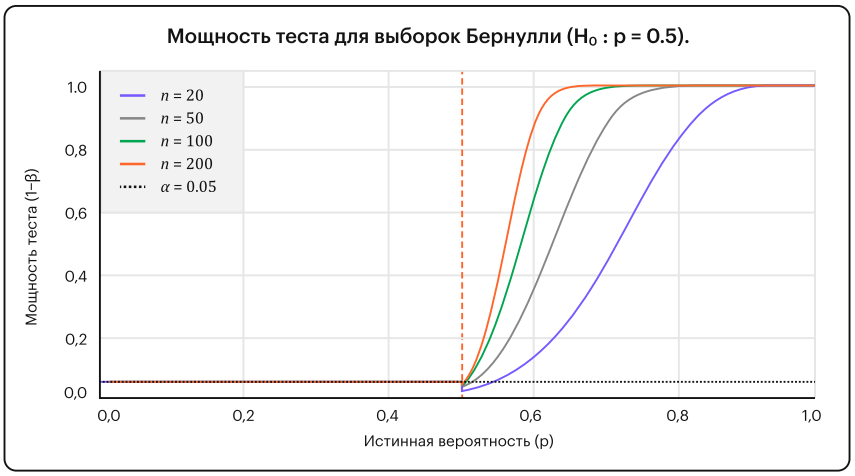

Рисунок 143. Мощность биномиального теста. Правосторонний критерий

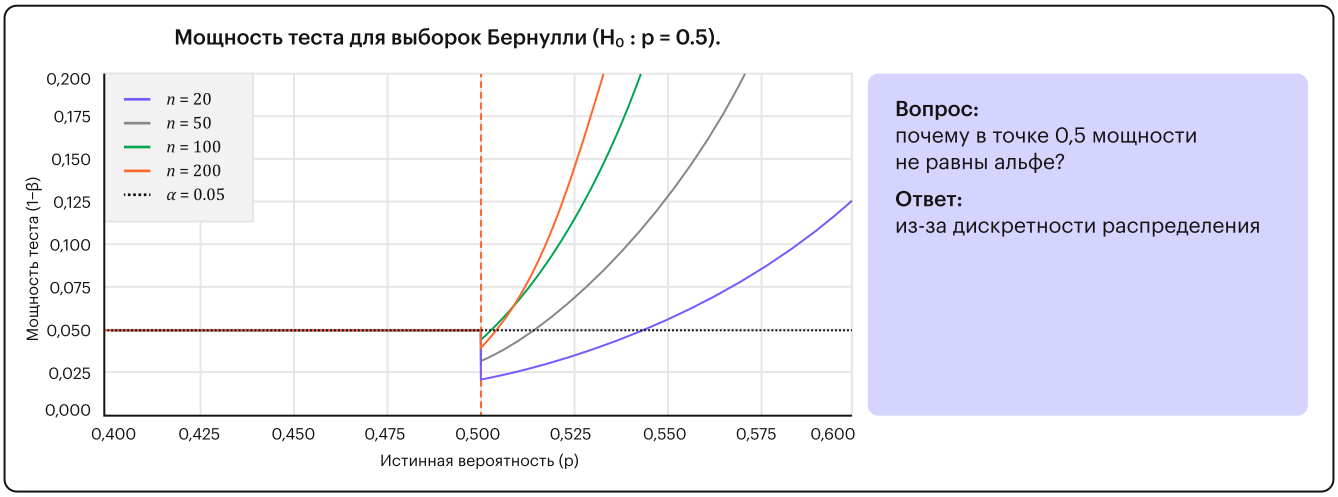

Рисунок 144. Мощность биномиального теста. Правосторонний критерий. Зум-ин

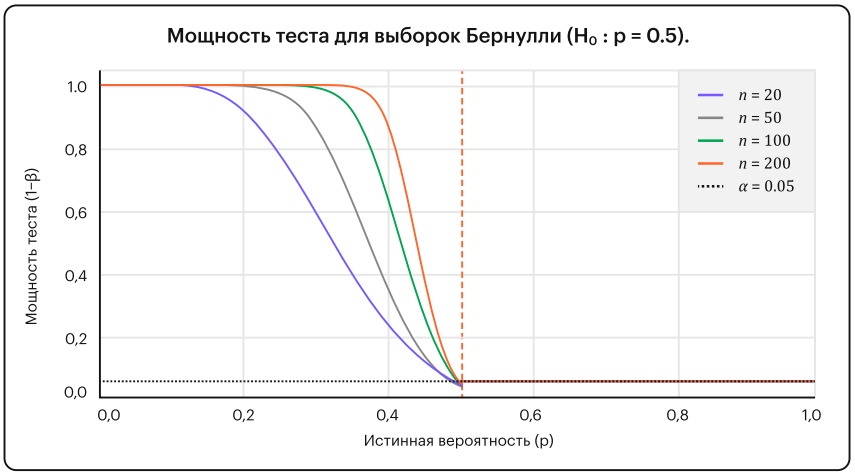

Рисунок 145. Мощность биномиального теста. Левосторонний критерий

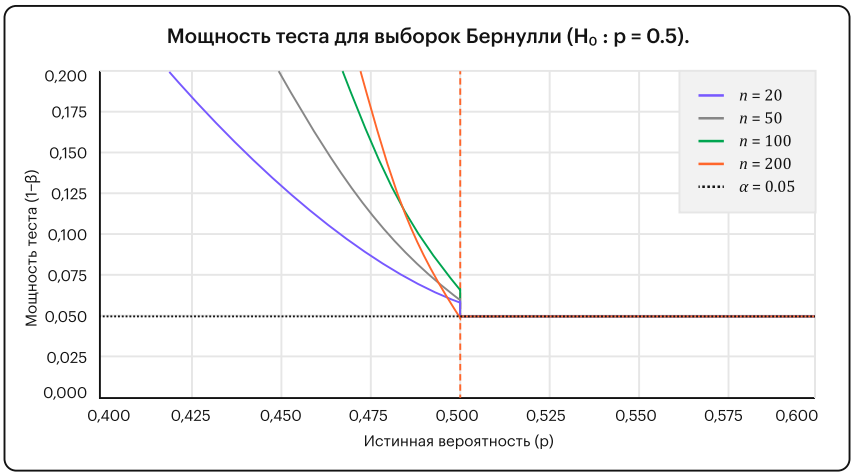

Рисунок 146. Мощность биномиального теста. Левосторонний критерий. Зум-ин

Вывод: Чем больше разница между значениями вероятности из нулевой и альтернативной гипотез, тем выше становится мощность. Действительно, чем выше разница, тем проще рассмотреть существующий эффект на выборке.

Теперь визуализируем зависимость мощности от объёма выборки в биномиальном тесте.

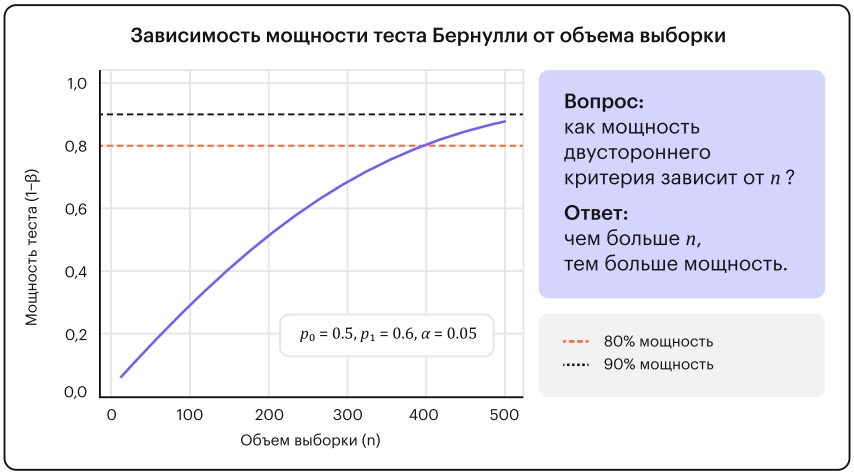

Рисунок 147. Зависимость мощности биномиального теста от размера выборки

Вывод: Чем больше выборка, тем больше становится мощность теста.

С другим видом критериев для дискретных выборок ты познакомишься в критерии хи-квадрат Пирсона.

2. Т-КРИТЕРИИ СТЬЮДЕНТА И УЭЛЧА

В прошлых разделах мы познакомились с параметрическим Z-критерием, основанным на нормальности.

Одной из предпосылок работы Z-критерия также является знание об истинной дисперсии распределения X.

Зачастую на практике используется Z-тест, даже когда происходит работа с выборкой, то есть истинная дисперсия σ^2 априори неизвестна.

Это обосновывается тем, что при достаточно большом количестве наблюдений оценка дисперсии на выборке не будет сильно отличаться от σ^2.

Однако на относительно небольших выборках (условно, меньше 50) нельзя гарантированность достаточную близость оценочной дисперсии к σ^2 и в таком случае при проверке гипотезы мы должны вместо числа σ^2 использовать в формуле оценку дисперсии на выборке s^2.

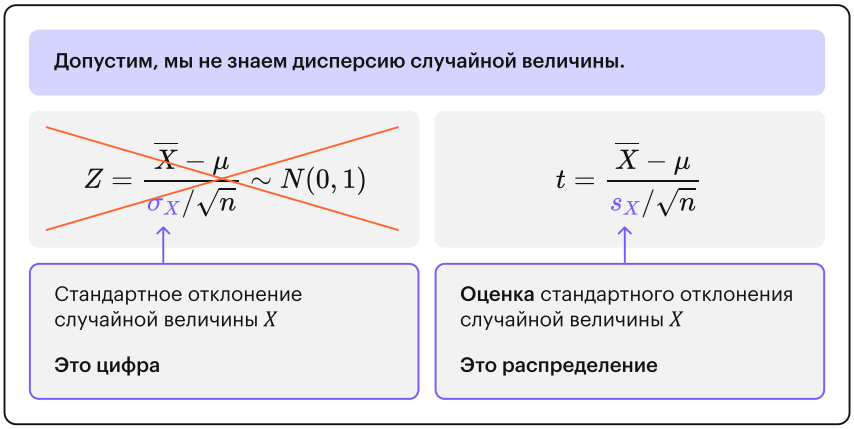

Рисунок 148. Разница между z и t критериями

Тогда перейдём к двухвыборочному t-тесту.

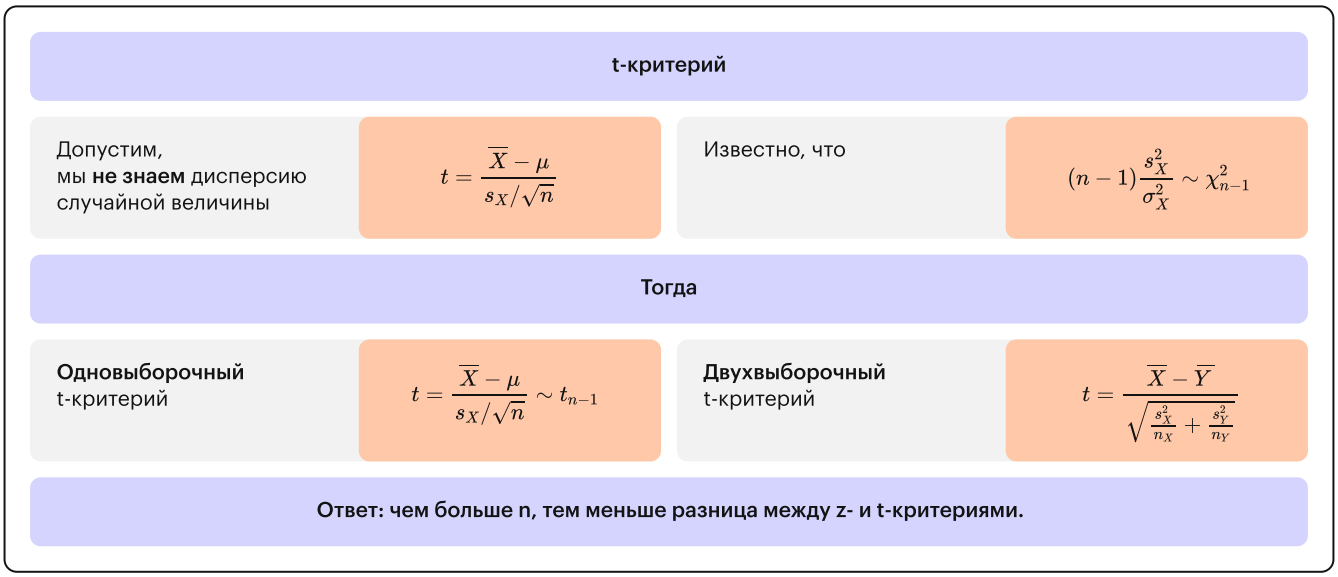

Рисунок 149. Переход к двухвыборочному t-тесту

Практическая разница между Z и t-критериями заключается в том, что полученное на выборке значение критерия следует срав-

нивать с разными квантильными пороговыми значениями, так как они различаются у нормального стандартного распределения и распределения Стьюдента.

Рисунок 150. Визуализация квантилей z и t

Но следует помнить, что чем больше степеней свободы у распределения Стьюдента, тем ближе оно к нормальному стандартному распределению и тем меньше становится разница между пороговыми квантилями двух распределений.

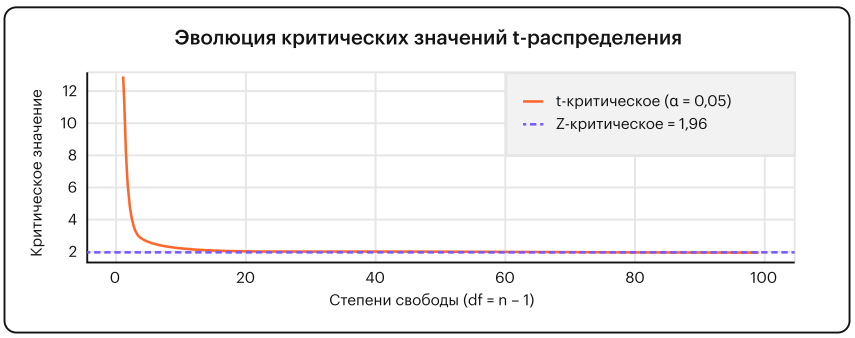

Рисунок 151. Зависимость разницы квантилей от количества степеней свободы

Вопрос: какой критерий будет показывать большее p-value на маленьких выборках?
Ответ: при прочих равных p-value t-теста будет больше, т.е. он с меньшей вероятностью «заметит прокрас».

Сходимость p-value z- и t-тестов с увеличением размера выборки

Рисунок 152. Переход к двухвыборочному t-тесту

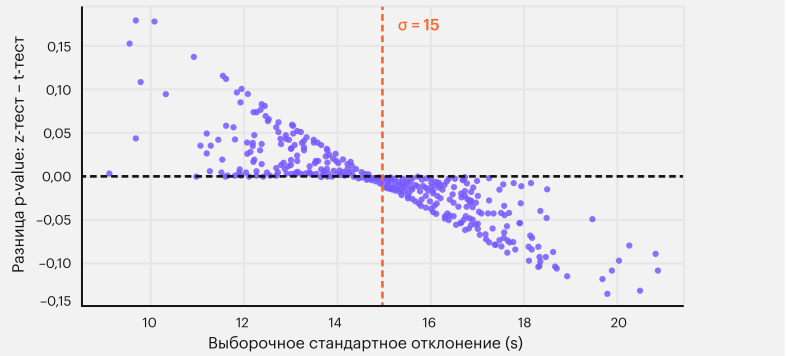

Вопрос: от чего зависит разница между z- и t-критерием при фиксированном n?

Ответ: чем сильнее мы ошибаемся в оценке дисперсии, тем сильнее разница между тестами.

Рисунок 153. Ошибка в оценке дисперсии

Критерий, который мы разобрали, корректнее назвать критерием Уэлча, а не критерием Стьюдента.

Посмотрим еще раз на формулу:

$$t = \frac{\overline{X} - \overline{Y}}{\sqrt{\frac{s_X^2}{n_X} + \frac{s_Y^2}{n_Y}}} \sim t_{n_X + n_Y - 2}$$

Эта формула не является на все 100% корректной, так как следует разделять два различных теста: тест Уэлча и тест Стьюдента.

Тест Уэлча рассчитывается для выборок, у которых дисперсии могут значительно отличаться. А тест Стьюдента считается для выборок с равными (или хотя бы близкими по значению) дисперсиями и по сути является частным случаем теста Уэлча.

Тест Стьюдента:

$$t = \frac{\overline{X} - \overline{Y}}{s_p \sqrt{\frac{1}{n} + \frac{1}{m}}},$$

$$s_p^2 = \frac{(n-1)s_X^2 + (m-1)s_Y^2}{n + m - 2}.$$

Здесь s_p^2 — это pooled variance, то есть общая оценка дисперсии, построенная по обеим выборкам. Количество степеней свободы в этом случае равно $n + m - 2$.

Тест Уэлча:

$$t = \frac{\overline{X} - \overline{Y}}{\sqrt{\frac{s_X^2}{n} + \frac{s_Y^2}{m}}}.$$

Однако количество степеней свободы определяется по формуле:

$$\frac{(s_X^2/n + s_Y^2/m)^2}{(s_X^4/n^2)/(n-1) + (s_Y^4/m^2)/(m-1)}$$

.

Это делает тест более робастным, когда дисперсии отличаются, но чуть менее мощным при равных дисперсиях.

В нашем примере с группами A и B, если предположим равные дисперсии, используем t-тест Стьюдента. Если нет — Уэлча. Сначала можно проверить равенство дисперсий F-тестом (см. ниже).

Вывод. Ещё раз закрепим: t-критерий не требует знания истинной дисперсии, а также строгой нормальности данных (благодаря центральной предельной теореме для больших n). Тем не менее, он требует достаточного количества наблюдений для адекватной оценки дисперсии. А на больших выборках (порядка 10^2 наблюдений) практическая разница между t- и z-критериями отсутствует

Теперь покажем формально, что при стремлении $n, m \to \infty$ статистика Уэлча стремится к нормальному распределению.
Пусть:

ТЕОРЕМА 10.2.1

- $X_1, \ldots, X_m \overset{\text{i.i.d.}}{\sim} F_X$ с $\mathbb{E}[X] = \mu_X$, $\mathrm{Var}(X) = \sigma_X^2 < \infty$
- $Y_1, \ldots, Y_n \overset{\text{i.i.d.}}{\sim} F_Y$ с $\mathbb{E}[Y] = \mu_Y$, $\mathrm{Var}(Y) = \sigma_Y^2 < \infty$
- Выборки независимы
- $m, n \to \infty$, $\frac{m}{m+n} \to \lambda \in (0,1)$
- $H_0 : \mu_X = \mu_Y$

Тогда статистика Уэлча асимптотически имеет стандартное нормальное распределение

$$t = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{s_X^2}{m} + \frac{s_Y^2}{n}}} \xrightarrow{d} N(0,1)$$

Доказательство.

Достаточно доказать, что

$$Z = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{\sigma_X^2}{m} + \frac{\sigma_Y^2}{n}}} \xrightarrow{d} N(0,1)$$

Действительно, по закону больших чисел $s_X^2 \xrightarrow{p} \sigma_X^2$, $s_Y^2 \xrightarrow{p} \sigma_Y^2$.
Тогда по лемме Слуцкого:

$$t = Z \cdot \sqrt{\frac{\frac{\sigma_X^2}{m} + \frac{\sigma_Y^2}{n}}{\frac{s_X^2}{m} + \frac{s_Y^2}{n}}} \xrightarrow{d} N(0,1) \cdot 1 = N(0,1)$$

Доказательство для Z проведем с использованием техники характеристических функций по теореме непрерывности Леви (повторяли на 2-й неделе). Нам нужно показать, что $\varphi_Z(t) \to \varphi_{N(0;1)}(t) = e^{-t^2/2}$ при $n \to \infty$.

$$\varphi_Z(t) = \mathbb{E}\left[\exp\left(it\frac{\bar{X} - \bar{Y}}{\sqrt{\frac{\sigma_X^2}{m} + \frac{\sigma_Y^2}{n}}}\right)\right]$$

В силу независимости выборок:

$$\varphi_Z(t) = \varphi_{\bar{X}}\left(\frac{t}{\sqrt{\frac{\sigma_X^2}{m} + \frac{\sigma_Y^2}{n}}}\right) \cdot \varphi_{\bar{Y}}\left(-\frac{t}{\sqrt{\frac{\sigma_X^2}{m} + \frac{\sigma_Y^2}{n}}}\right)$$

Для i.i.d. выборки:

$$\varphi_{\bar{X}}(u) = \left[\varphi_X(u/m)\right]^m$$

При H_0 центрируем: $X_i' = X_i - \mu$, $Y_j' = Y_j - \mu$. Тогда $\mathbb{E}[X'] = 0$, $\mathrm{Var}(X') = \sigma_X^2$, $\mathbb{E}[Y'] = 0$, $\mathrm{Var}(Y') = \sigma_Y^2$.

Известно разложение характеристической функции в окрестности нуля:

$$\varphi_{X'}(u) = 1 - \frac{\sigma_X^2 u^2}{2} + o(u^2), \quad u \to 0$$

$$\varphi_{Y'}(u) = 1 - \frac{\sigma_Y^2 u^2}{2} + o(u^2), \quad u \to 0$$

Тогда для $\bar{X}$:

$$\varphi_{\bar{X}}\left(\frac{t}{\sqrt{\frac{\sigma_X^2}{m} + \frac{\sigma_Y^2}{n}}}\right) = \left[1 - \frac{\sigma_X^2 t^2}{2\left(\frac{\sigma_X^2}{m} + \frac{\sigma_Y^2}{n}\right)m^2} + o\left(\frac{1}{m^2}\right)\right]^m$$

Упростим:

$$\frac{\sigma_X^2}{\left(\frac{\sigma_X^2}{m} + \frac{\sigma_Y^2}{n}\right)m^2} = \frac{\sigma_X^2}{m\left(\sigma_X^2 + \frac{m}{n}\sigma_Y^2\right)}$$

При $m, n \to \infty$ имеем $\frac{m}{n} \to \frac{\lambda}{1-\lambda}$. Следовательно:

$$m \cdot \left(-\frac{\sigma_X^2 t^2}{2\left(\sigma_X^2 + \frac{m}{n}\sigma_Y^2\right) m} \right) \to -\frac{\sigma_X^2 t^2}{2\left(\sigma_X^2 + \frac{\lambda}{1-\lambda}\sigma_Y^2\right)}$$

Аналогично для $\bar{Y}$:

$$n \cdot \left(-\frac{\sigma_Y^2 t^2}{2\left(\frac{n}{m}\sigma_X^2 + \sigma_Y^2\right) n} \right) \to -\frac{\sigma_Y^2 t^2}{2\left(\frac{1-\lambda}{\lambda}\sigma_X^2 + \sigma_Y^2\right)}$$

Используя классический результат математического анализа:
$(1 + a_m)^m \to e^{\lim m a_m}$ при $m a_m \to$ const получаем, что

$$\varphi_{\bar{X}}\left(\frac{t}{\sqrt{\frac{\sigma_X^2}{m} + \frac{\sigma_Y^2}{n}}} \right) \to e^{-\frac{\sigma_X^2 t^2}{2\left(\sigma_X^2 + \frac{\lambda}{1-\lambda}\sigma_Y^2\right)}}, \; \varphi_{\bar{Y}}\left(\frac{t}{\sqrt{\frac{\sigma_X^2}{m} + \frac{\sigma_Y^2}{n}}} \right) \to e^{-\frac{\sigma_Y^2 t^2}{2\left(\frac{1-\lambda}{\lambda}\sigma_X^2 + \sigma_Y^2\right)}}$$

Ключевое тождество:

$$\frac{\sigma_X^2}{\sigma_X^2 + \frac{\lambda}{1-\lambda}\sigma_Y^2} + \frac{\sigma_Y^2}{\frac{1-\lambda}{\lambda}\sigma_X^2 + \sigma_Y^2} = 1$$

откуда получаем

$$\varphi_Z(t) \to \exp\left(-\frac{t^2}{2} \left[\frac{\sigma_X^2}{\sigma_X^2 + \frac{\lambda}{1-\lambda}\sigma_Y^2} + \frac{\sigma_Y^2}{\frac{1-\lambda}{\lambda}\sigma_X^2 + \sigma_Y^2} \right] \right) = \exp\left(-\frac{t^2}{2} \right)$$

□

Общий вывод

Чем больше наблюдений (то есть степеней свободы), тем меньше практическая разница между Z и t-критериями, так как оценка дисперсии становится ближе к реальной дисперсии случайной величины.

3. ОДНОВЫБОРОЧНЫЙ ХИ-КВАДРАТ ТЕСТ ДЛЯ ДИСПЕРСИИ

Ранее обсуждалось, что выбор между тестом Стьюдента и тестом Уэлча зависит от того, равны ли дисперсии двух распределений. По аналогии со средними значениями, дисперсии в двух выборках никогда не совпадут абсолютно точно, но существует тест, с помощью которого можно сделать вывод о том, существует ли статистически значимая разница между дисперсиями двух выборок (двухвыборочный F-тест) или между дисперсией выборки и

числом-бенчмарком (одновыборочный хи-квадрат критерий).

Рассмотрим сначала одновыборчоный критерий.

Формула одновыборочного хи-квадрат критерия для проверки равенства дисперсии бенчмарку σ_0^2:

$$\chi^2 = \frac{(n-1)s^2}{\sigma_0^2} \sim \chi^2(n-1).$$

Критерий отвергает $H_0 : \sigma^2 = \sigma_0^2$, если статистика выходит за квантили χ^2.

Например, в нашей группе А, если проверить $H_0 : \sigma^2 = 25$ (бенчмарк 5^2), то $\chi^2 = \frac{29 \times 25}{25} = 29$, и сравнить с $\chi^2(29)$.

Этот критерий используется для одной выборки, когда нужно проверить дисперсию против известного значения.

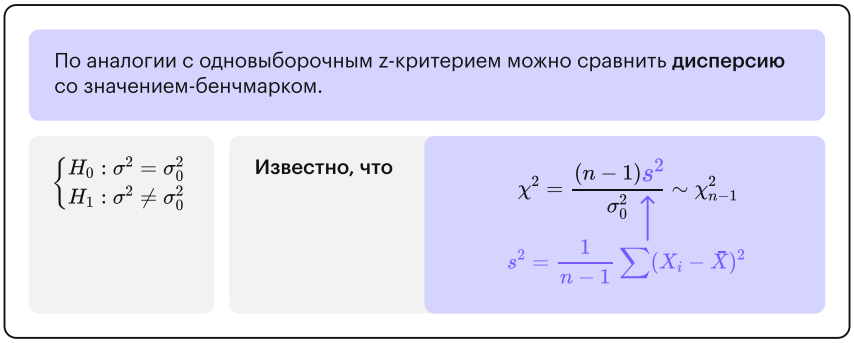

Рисунок 154. Одновыборочный хи-квадрат тест на дисперсию. Формулировка

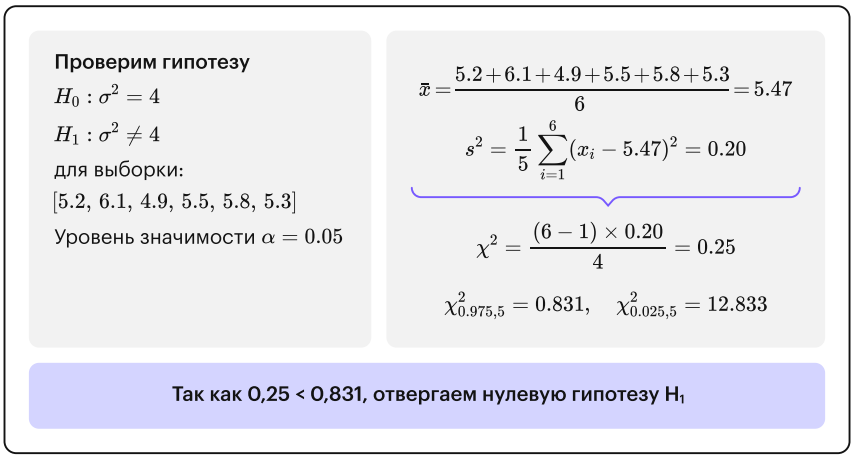

Рисунок 155. Одновыборочный хи-квадрат тест на дисперсию. Числовой пример

Пример 10.3.1.

В качестве примера рассмотрим данные, в которых дисперсия, очевидно, не равна бенчмарку σ_0^2.

Рисунок 156. Одновыборочный хи-квадрат тест на дисперсию. Пример неравной дисперсии. Распределение данных

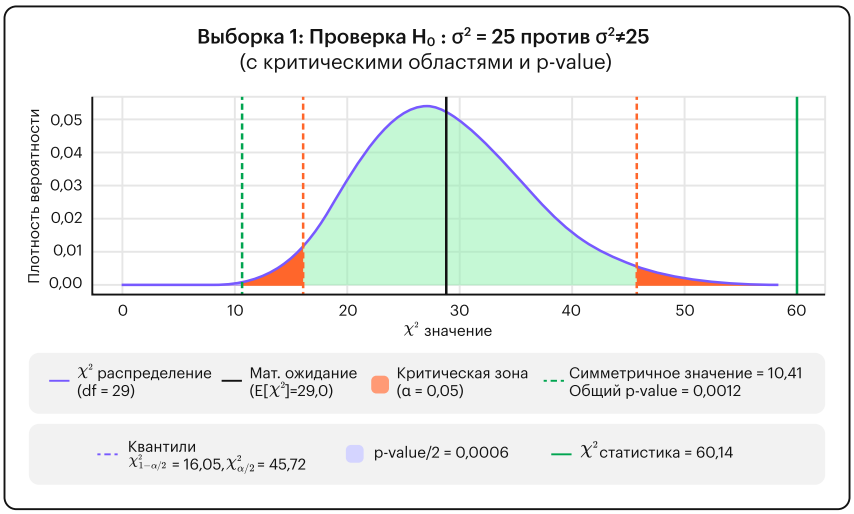

Рисунок 157. Одновыборочный хи-квадрат тест на дисперсию. Пример неравной дисперсии. Распределение критерия

Пример 10.3.2.

Теперь рассмотрим обратный пример, в котором дисперсия очень близка к бенчмарку σ_0^2.

Рисунок 158. Одновыборочный хи-квадрат тест на дисперсию. Пример равной дисперсии. Распределение данных

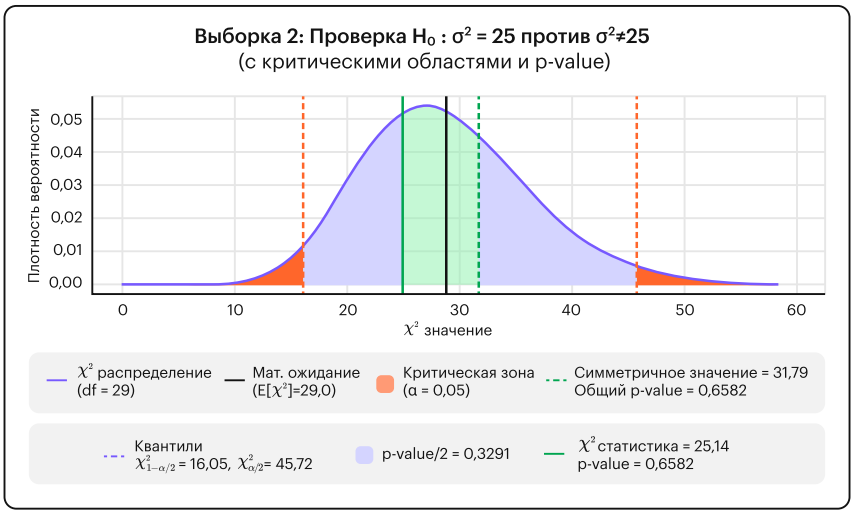

Рисунок 159. Одновыборочный хи-квадрат тест на дисперсию. Пример равной дисперсии. Распределение критерия

4. ДВУХВЫБОРОЧНЫЙ F-ТЕСТ ДЛЯ ДИСПЕРСИИ

Формула двухвыборочного F-критерия для проверки равенства дисперсий: Таким образом, в случае верности нулевой гипотезы выполнено $\widehat{s}_x^2/\widehat{s}_y^2 \sim \mathrm{F}(n-1, m-1)$. А если верна альтернатива, отношение сместится с этого распределения в большую или в меньшую сторону. Поэтому можно построить критерий как дополнение «хорошего» события

$$f_{\frac{\alpha}{2}} < \frac{\widehat{s}_x^2}{\widehat{s}_y^2} < f_{1-\frac{\alpha}{2}},$$

где f_γ суть γ-квантили распределения $\mathrm{F}(n-1, m-1)$. Построенный критерий называется **F-критерием Фишера**.

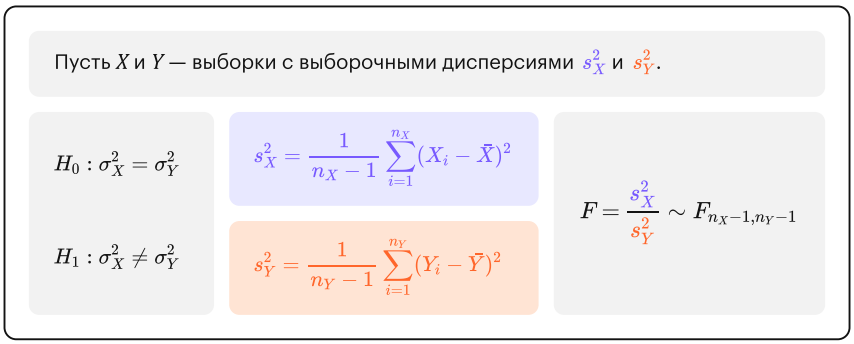

Рисунок 160. p-value для F-теста

Пример 10.4.1.

Рассмотрим пример, в котором выборки семплированы из распределений с одинаковыми дисперсиями.

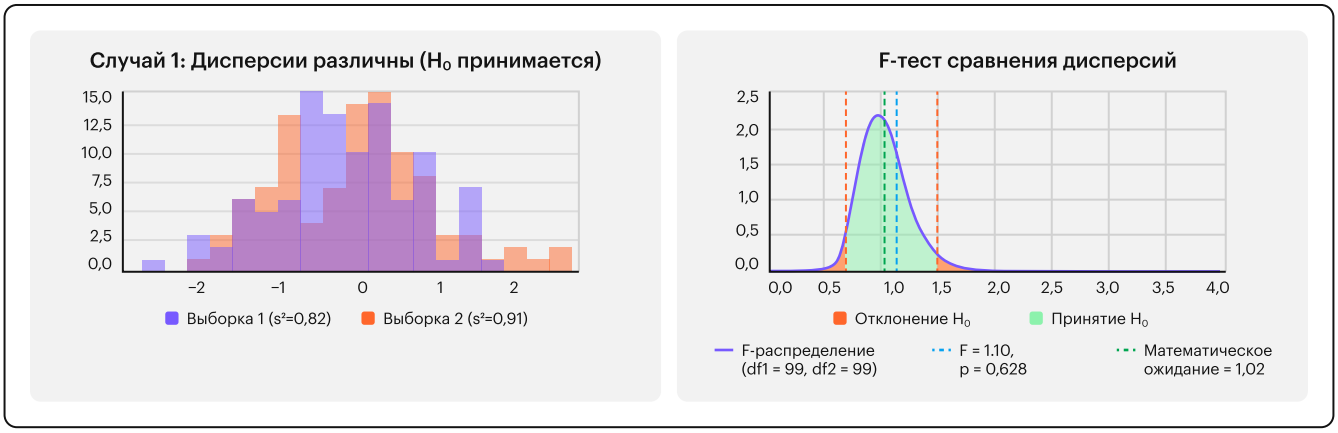

Рисунок 161. p-value для F-теста

Пример 10.4.2.

Теперь перейдём к примеру, в котором выборки семплированы из распределений с разными дисперсиями.

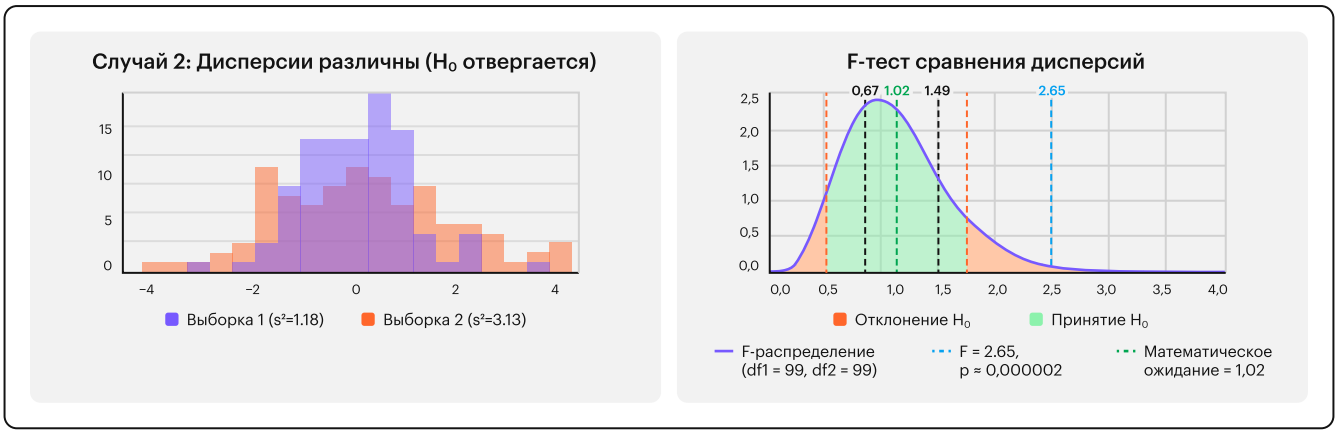

Рисунок 162. p-value для F-теста

5. ИТОГИ ПО ПАРАМЕТРИЧЕСКИМ КРИТЕРИЯМ

Теперь классифицируем двухвыборочные тесты в зависимости от ситуаций их применимости.

Допустим, что: $X_1, X_2, ..., X_n \sim N(\mu, \sigma^2)$

	t-test	z-test	Тест Фишера	А тут зачем тест?)
Неизвестно	μ, σ	μ	σ	—
Известно	—	σ	μ	μ, σ

Рисунок 163. p-value для F-теста

Часть 11. Непараметрические критерии

1. КРИТЕРИЙ МАННА-УИТНИ-УИЛКОКСОНА

Здесь мы научимся проверять гипотезу, что распределения двух выборок отличаются сдвигом. На самом деле, эта задача решается более универсальным критерием Колмогорова—Смирнова, который даже был придуман раньше критерия Манна—Уитни. Просто критерий Колмогорова получил строгое теоретическое обоснование гораздо позже, и поэтому некоторое время им не пользовались (или пользовались, понимая, что его эффективность доказана только эмпирически).

Рассмотрим такой пример. В двух группах провели одинаковые контрольные. Оценки выставили, и нужно проверить, какая из групп лучше написала контрольную.

Здесь автоматически предполагается, что имеются две независимые выборки $X_1, \ldots, X_n$ и $Y_1, \ldots, Y_m$. Далее для построения модели делается одно очень важное допущение: функции распределения этих выборок различаются сдвигом на константу θ. То есть

$$F_{X_1}(x - \theta) = F_{Y_1}(x).$$

Если $\theta > 0$, то получаем, что распределение игреков сдвинуто в область больших значений в сравнении с иксами. Это значит, что группа игреков написала контрольную лучше.

Таким образом, нам нужно определить параметр: он положительный, отрицательный или нулевой. Далее всё по классике: проверяется гипотеза

$$H_0 : \theta = 0 \text{ — студенты в группах успевают одинаково}$$

против разных альтернатив:

$$H_+ : \theta > 0 \text{ — у игреков успеваемость выше,}$$
$$H_- : \theta < 0 \text{ — у иксов успеваемость выше,}$$
$$H_{\neq} : \theta \neq 0 \text{ — успеваемость по группам разная и неизвестна.}$$

Соберём все наблюдения в один вектор $(X_1, \ldots, X_n, Y_1, \ldots, Y_m)$. Обозначим через R_i ранги иксов в этом векторе, а через S_j — ранги игреков. Понятно, что при верности альтернативы H_+ более вероятны большие значения для S_j, а при верности альтернативы H_- — более маленькие. На этом и основана следующая идея.

ОПРЕДЕЛЕНИЕ 11.1.1

Статистикой ранговых сумм Вилкоксона называется

$$W_{m,n} := \sum_{j=1}^{m} S_j.$$

Если нулевая гипотеза верна, то можно найти распределение статистики $W_{m,n}$. Его α-квантили $w_\alpha^{m,n}$ можно смоделировать в Python. Поэтому довольно просто построить критерии.

Для проверки против альтернативы H_+ надо построить критерий

$$W_{m,n} > w_{1-\alpha}^{m,n}.$$

Для проверки против альтернативы H_- нужно построить критерий

$$W_{m,n} < w_\alpha^{m,n}.$$

Аналогично можно было бы поступить и для проверки против третьей альтернативы. Но при достаточном количестве наблюдений есть путь попроще: если нулевая гипотеза верна, то известно, что

$$W'_{m,n} := \frac{W_{m,n} - m \cdot \frac{m+n+1}{2}}{\sqrt{mn \cdot \frac{m+n+1}{2}}} \xrightarrow[n\to\infty]{d} N(0,1).$$

Поэтому для проверки против альтернативы $H_{\neq}$ можно построить критерий

$$\left|W'_{m,n}\right| > z_{1-\alpha/2}.$$

Чтобы улучшить критерий, иногда удобно использовать **статистику Манна — Уитни**.

ОПРЕДЕЛЕНИЕ 11.1.2

Статистикой Манна — Уитни называется

$$H_{m,n} := \sum_{i=1}^{n}\sum_{j=1}^{m} \mathcal{I}\{X_i < Y_j\} = W_{m,n} - \frac{m(m+1)}{2}.$$

Критерий (= тест) Манна–Уитни (U-критерий / MW test) — это тест, который используется для сравнения двух эмпирических распределений

Пусть у нас есть два ряда: X и Y с соответствующими размерами n_Y и n_X

- H_0 — распределения X и Y равны.
- H_1 — распределения X и Y не равны.

Рисунок 164. Критерий Манна-Уитни. Формулировка

Шаг 1. Объединим рядом X и Y в единый ряд, отсортируем его по возрастанию и проставим каждому значению ранг.

$X = 15, 5, 9, 10, 20, 12$

$Y = 2, 18, 8, 13, 19$

$n_X = \#X = 6$

$n_Y = \#Y = 5$

$X + Y$: $2, 5, 8, 9, 10, 12, 13, 15, 18, 19, 20$

$rang(X+Y)$: $1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11$

$rang_X = 2, 4, 5, 6, 8, 11$

$rang_Y = 1, 3, 7, 9, 10$

Рисунок 165. Критерий Манна-Уитни. Алгоритм. Шаг 1

Шаг 2. Рассчитаем сумму рангов для каждой выборки: R_X и R_Y

$rang_X = 2, 4, 5, 6, 8, 11$

$rang_Y = 1, 3, 7, 9, 10$

$R_X = 2 + 4 + 5 + 6 + 8 + 11 = 36$

$R_Y = 1 + 3 + 7 + 9 + 10 = 30$

Рисунок 166. Критерий Манна-Уитни. Алгоритм. Шаг 2

Шаг 3. Рассчитаем значения U_X и U_Y, используя размеры выборок и рассчитанные значения R

$$U_X = n_X n_Y + \frac{n_X(n_X+1)}{2} - R_X = 6 \times 5 + \frac{6 \times 7}{2} - 36 = 15$$

$$U_Y = n_X n_Y + \frac{n_Y(n_Y+1)}{2} - R_Y = 6 \times 5 + \frac{5 \times 6}{2} - 30 = 15$$

- U не обязаны быть равны
- Достаточно лишь **одного** значения U для расчёта p-value

Проверим собственные расчёты: $U_X + U_Y$ должно равняться $n_X \times n_Y$

$$U_X + U_Y = 15 + 15 = 30$$

$$n_X \times n_Y = 5 \times 6 = 30$$

Рисунок 167. Критерий Манна-Уитни. Алгоритм. Шаг 3

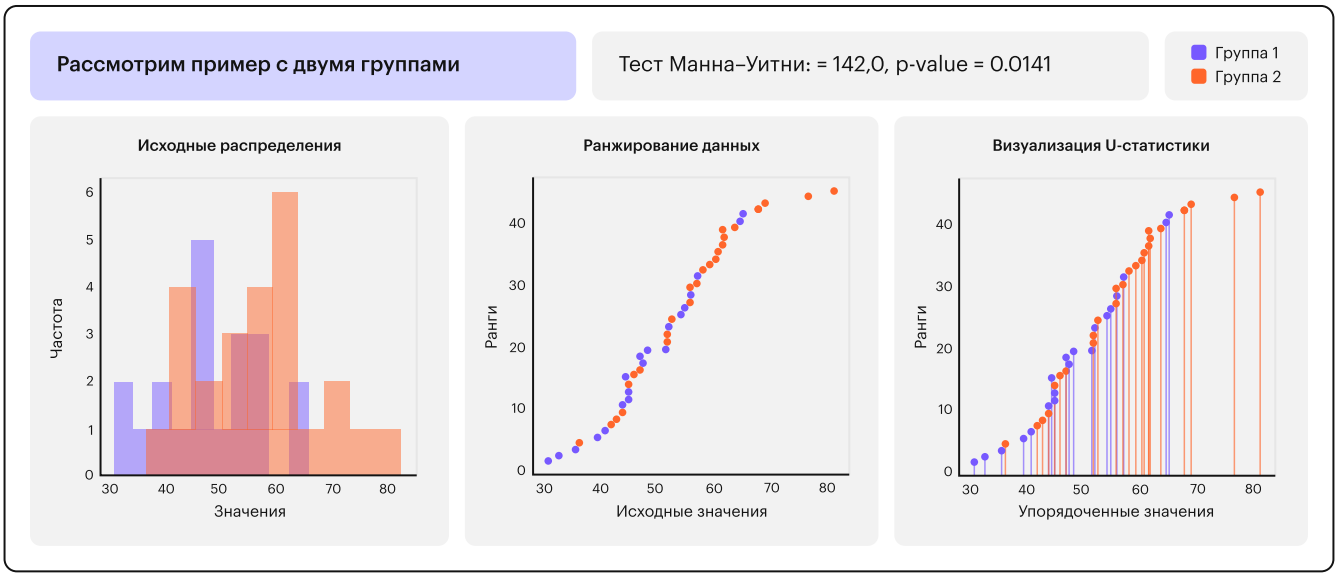

Рисунок 168. Критерий Манна-Уитни. Пример. Распределения

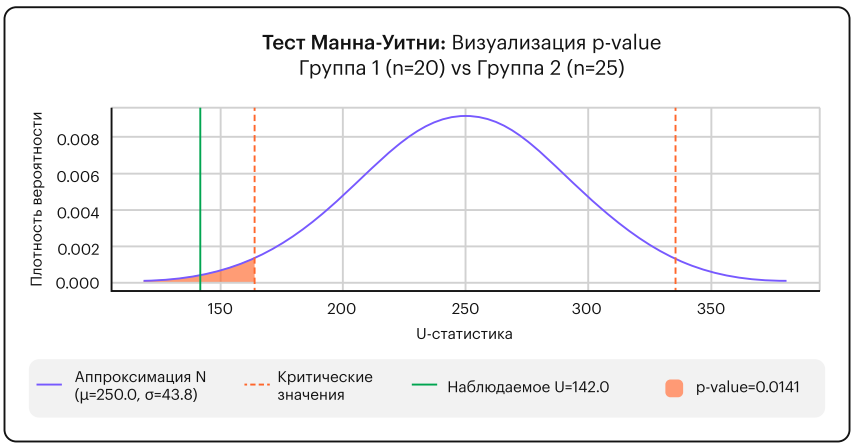

Рисунок 169. Критерий Манна-Уитни. Пример. Критерий

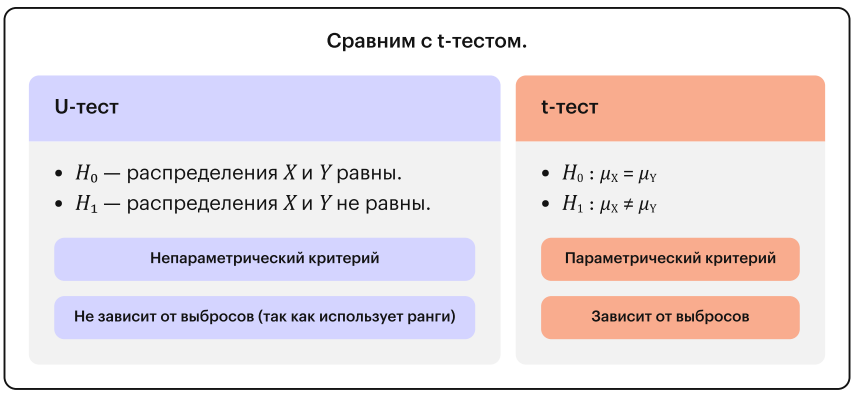

Рисунок 170. Сравнение теста Манна-Уитни и t-теста. Формулировка

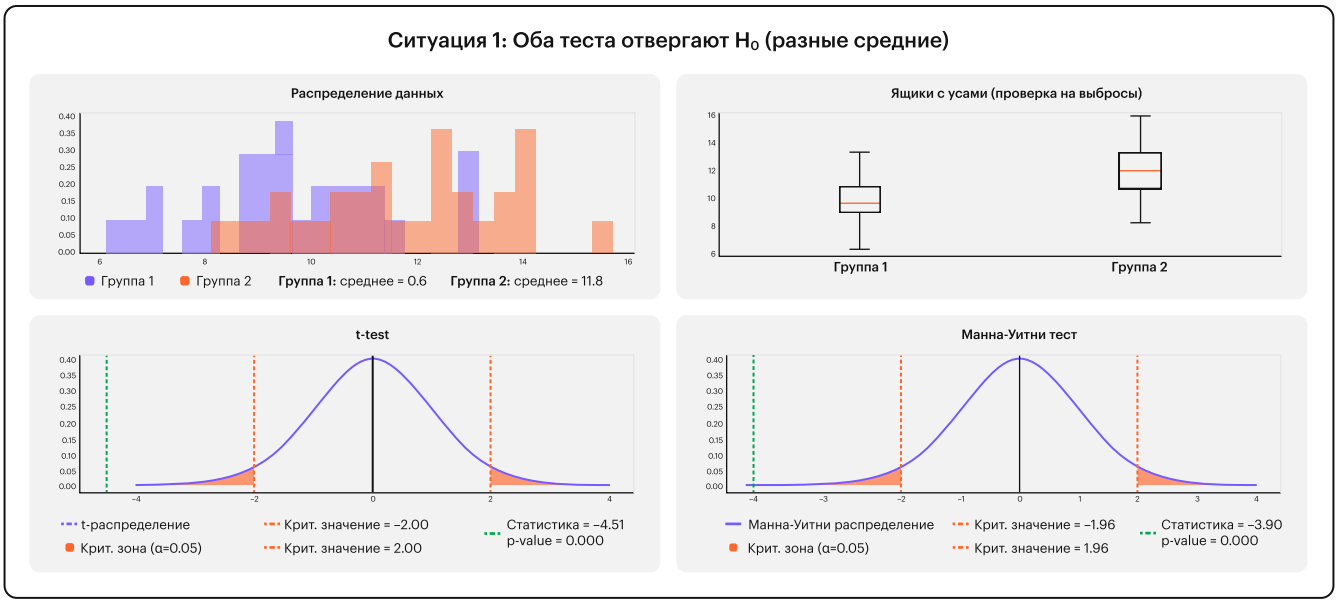

Рисунок 171. Сравнение теста Манна-Уитни и t-теста. Пример 1

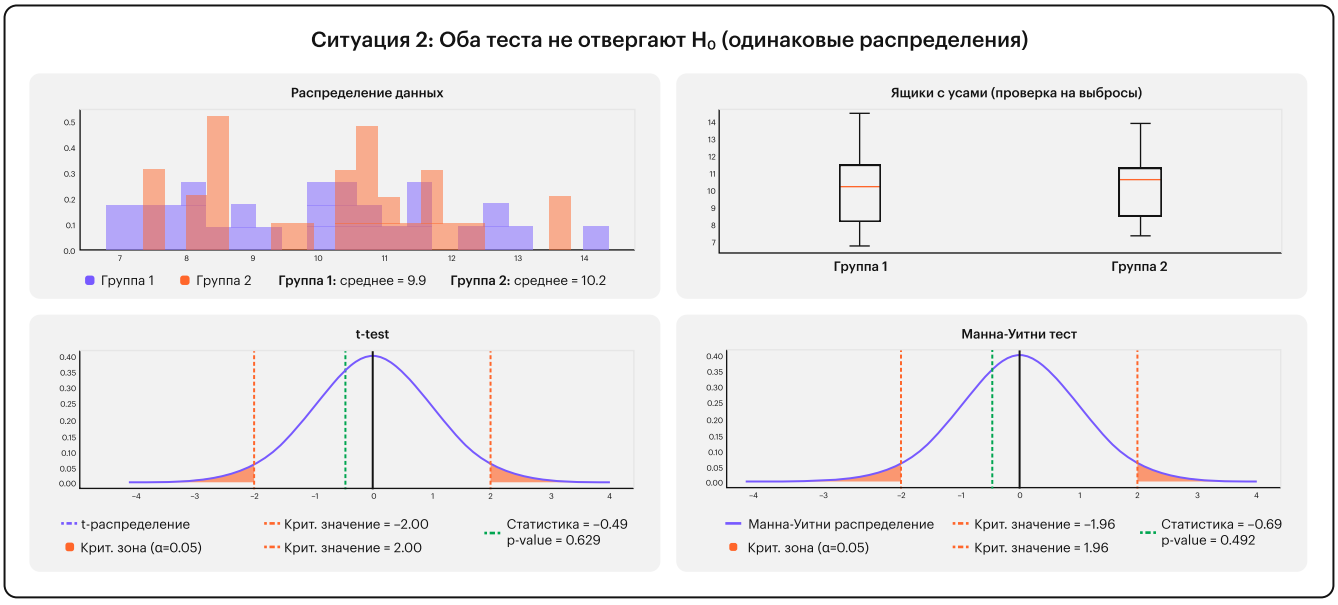

Рисунок 172. Сравнение теста Манна-Уитни и t-теста. Пример 2

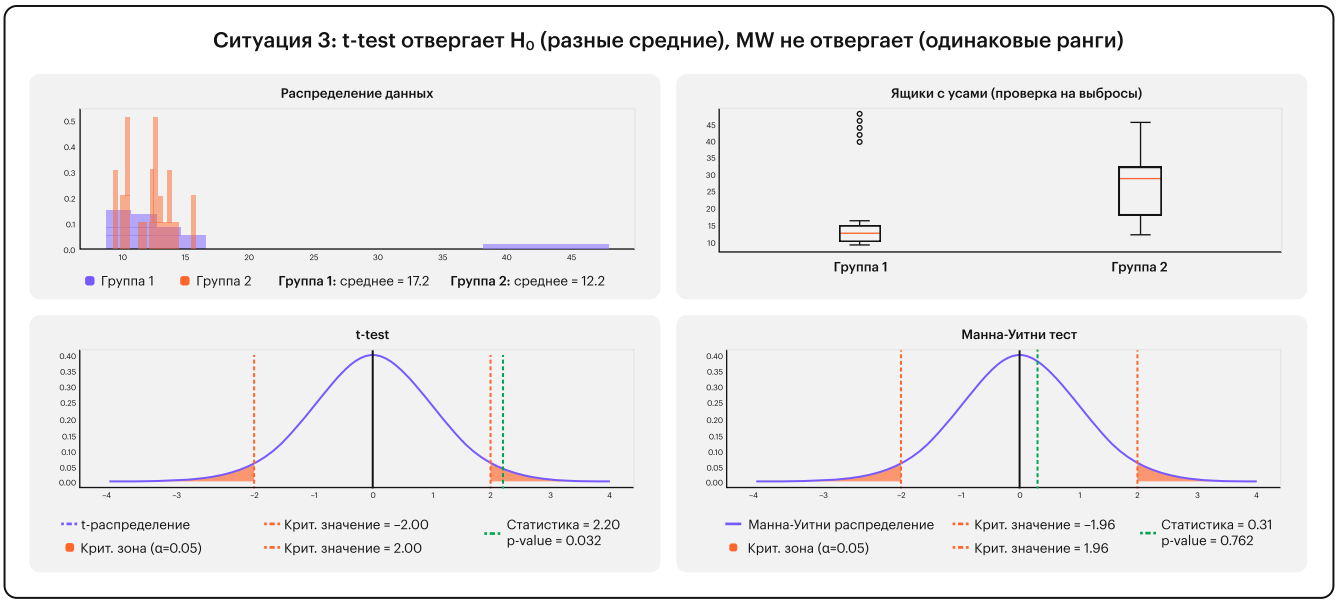

Рисунок 173. Сравнение теста Манна-Уитни и t-теста. Пример 3

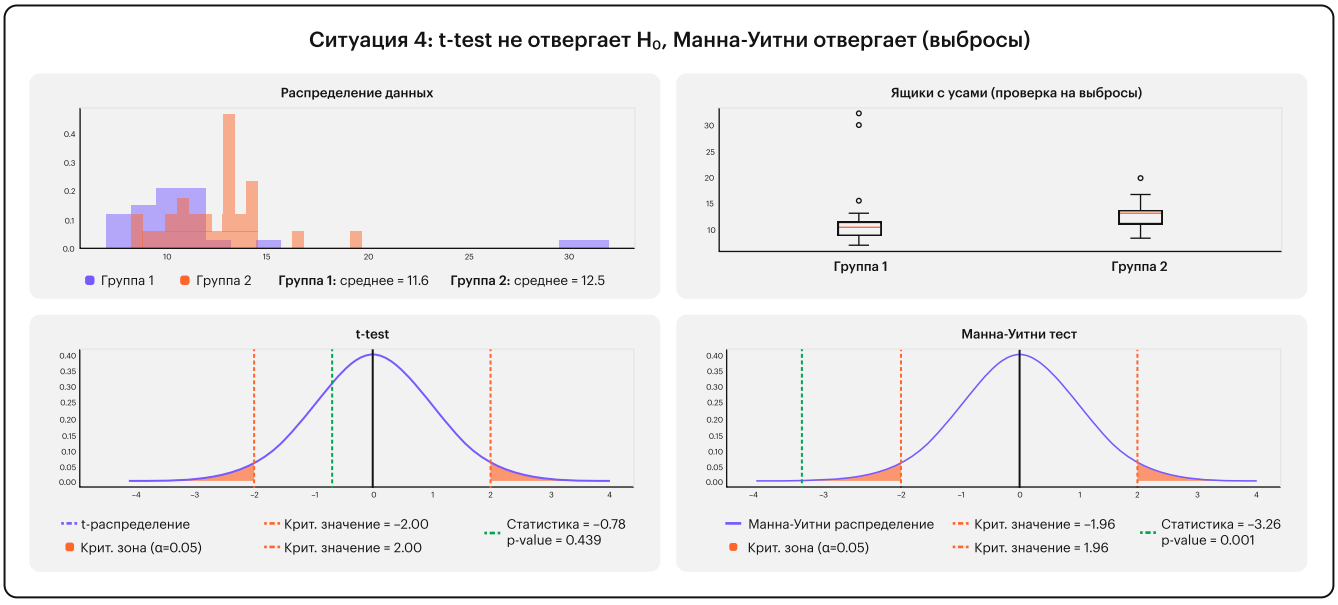

Рисунок 174. Сравнение теста Манна-Уитни и t-теста. Пример 4

Шаг 1. Расчёт разниц

Шаг 2. Избавление от нулей разниц

Шаг 3. Переход к модулю

Шаг 4. Переход к рангам

$$X = [\ 10,\ 12,\ 9,\ 15,\ 11,\ 14,\ 18\ ]$$
$$Y = [\ 11,\ 10,\ 9,\ 13,\ 14,\ 13,\ 15\ ]$$
$$d = [\ -1,\ 2,\ 0,\ 2,\ -3,\ 1,\ 3\ ]$$
$$d = [\ -1,\ 2,\ 2,\ -3,\ 1,\ 3\ ]$$
$$|d| = [\ 1,\ 2,\ 2,\ 3,\ 1,\ 3\ ]$$
$$R = [\ 1.5,\ 3.5,\ 3.5,\ 5.5,\ 1.5,\ 5.5\ ]$$

$$d_i = x_i - y_i$$
$$s_i = \text{sign}(d_i) = \begin{cases} +1, & d_i > 0 \\ -1, & d_i < 0 \end{cases}$$

Сумма рангов

$$C = \frac{n(n+1)}{2} = \frac{6 \cdot 7}{2} = 21$$

Шаг 5. Расчёт статистического критерия Уилкоксона

$$W^+ = 3.5 + 3.5 + 1.5 + 5.5 = 14$$
$$W^- = 1.5 + 5.5 = 7$$
$$W = min(W^+, W^-) = 7$$

Рисунок 175. Критерий Уилкоксона. Алгоритм расчёта

№	(s)	W^+	W^-	$W = \min$
1	(- - - - - -)	0	21	0
2	(+ - - - - -)	1.5	19.5	1,5
3	(- + - - - -)	3.5	17.5	3,5
4	(- - + - - -)	3.5	17.5	3,5
5	(- - - + - -)	5.5	15.5	5,5
	(...)			
63	(- + + + + +)	19.5	1.5	1,5
64	(+ + + + + +)	21	0	0

$$X = [10, 12, 9, 15, 11, 14]$$
$$Y = [11, 10, 9, 13, 14, 13]$$

$$R = [1.5, 3.5, 3.5, 5.5, 1.5, 5.5]$$
$$s = \underbrace{[-1,\ 1,\ 1,\ -1,\ 1,\ 1\ ]}_{n=6}$$

Если верна H_0, то $s \sim Bern(0.5)$ т.е. $\mathbb{P}(s_i = +1) = \mathbb{P}(s_i = -1) = 0.5$

Таким образом, существует $2^n = 2^6 = 64$ способов получить s.

Эмпирическое распределение для: W^+ W^- $min(W^+, W^-)$

Рисунок 176. Критерий Уилкоксона. Распределение W

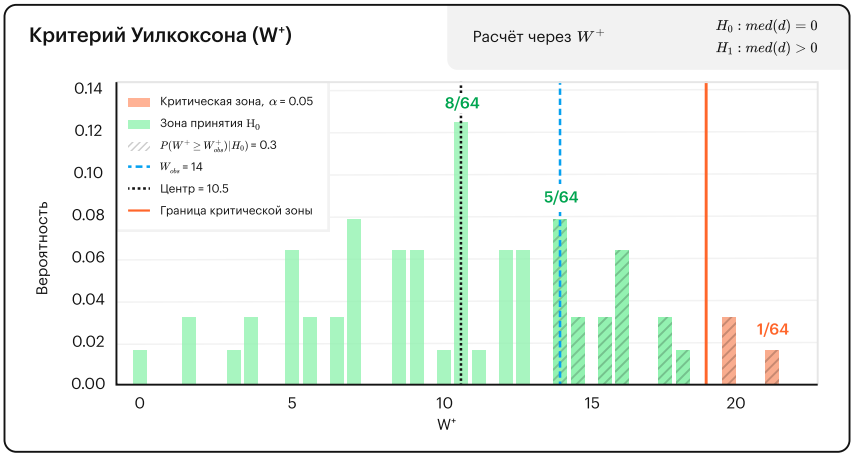

Рисунок 177. Критерий Уилкоксона. Гипотеза больше, расчёт через W^+

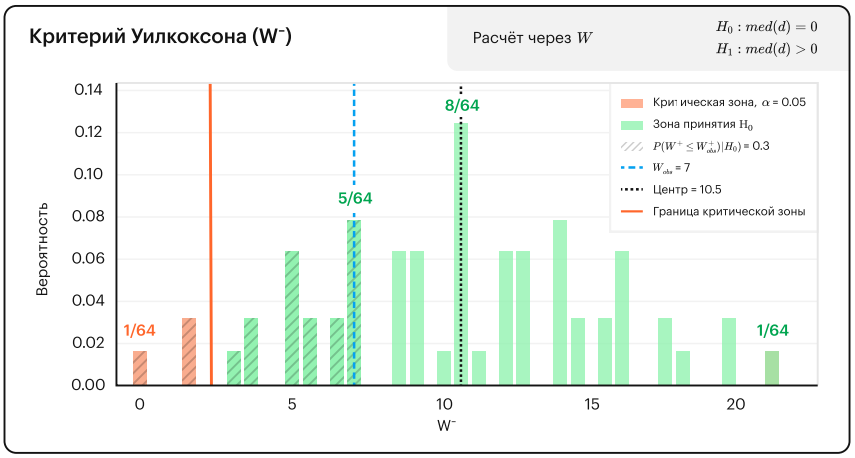

Рисунок 178. Критерий Уилкоксона. Гипотеза больше, расчёт через W^-

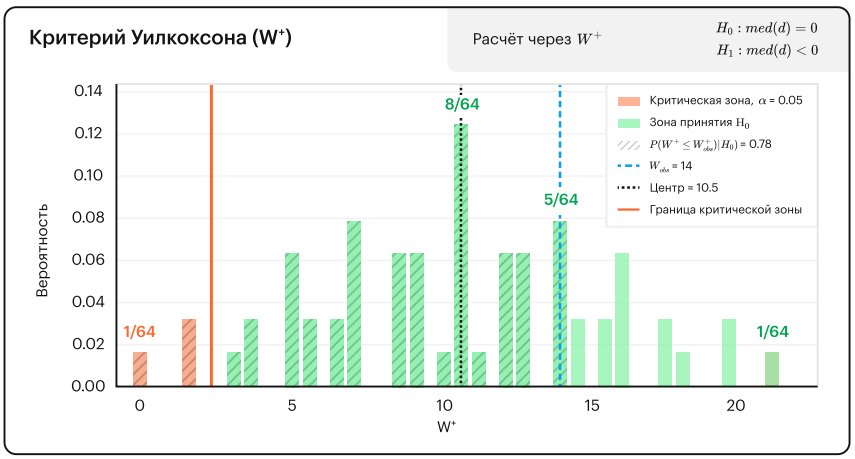

Рисунок 179. Критерий Уилкоксона. Гипотеза меньше, расчёт через W^+

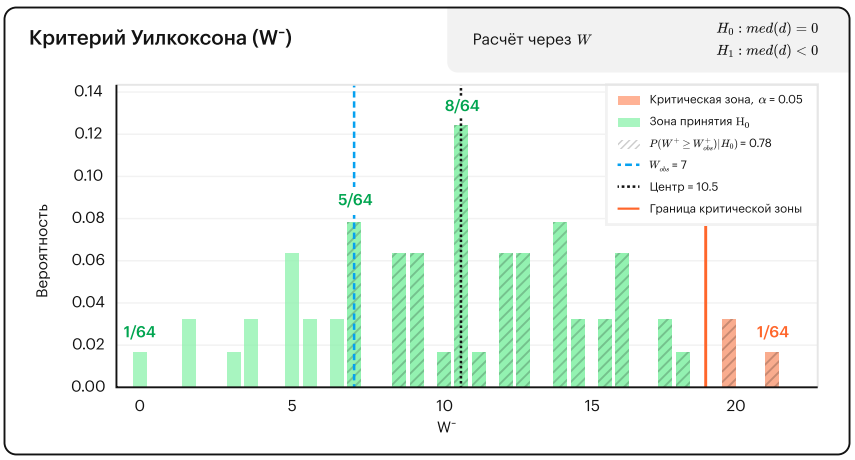

Рисунок 180. Критерий Уилкоксона. Гипотеза меньше, расчёт через W^-

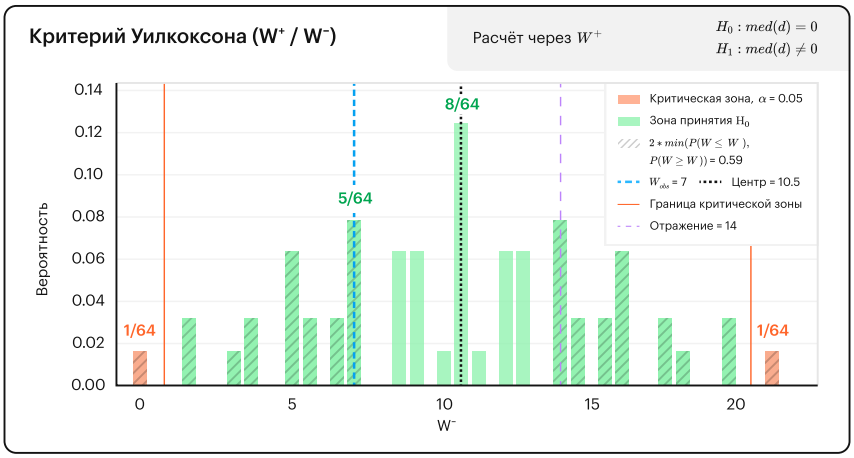

Рисунок 181. Критерий Уилкоксона. Гипотеза не равно, расчёт через W^{+-}

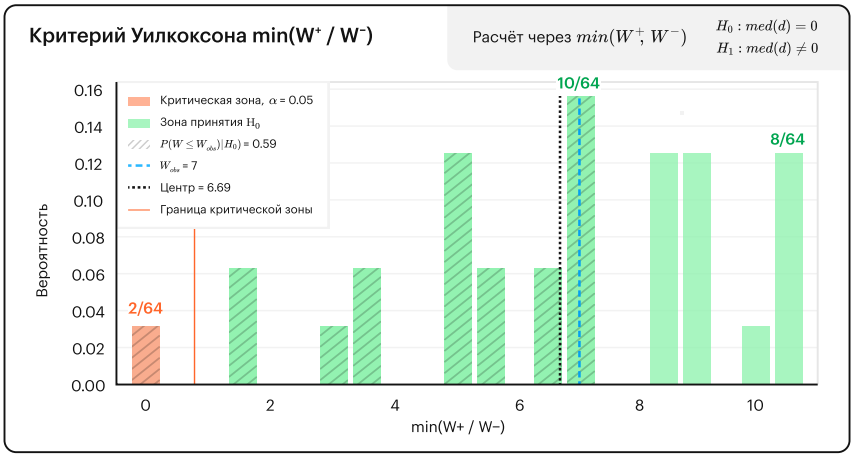

Рисунок 182. Критерий Уилкоксона. Гипотеза не равно, расчёт через $min(W)$

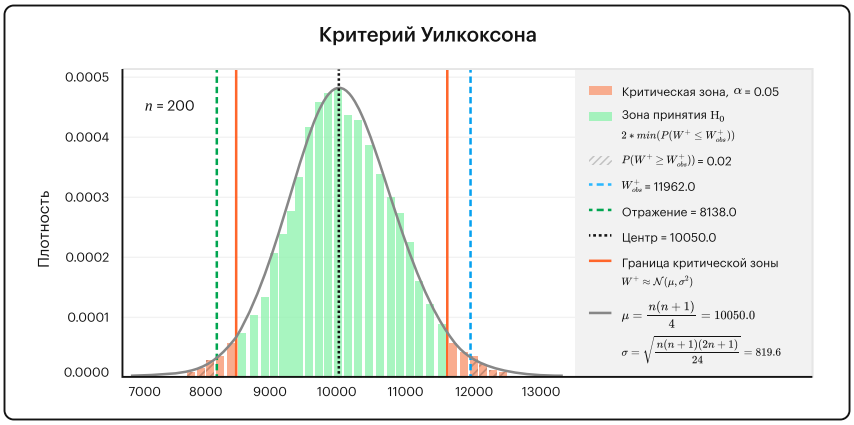

Рисунок 183. Критерий Уилкоксона. Визуализация на большом n

Представим, что мы хотим проверить гипотезу $H_0 : \theta = \theta_0$ против соответствующих альтернатив. Для этого проще всего свести задачу к предыдущей и сдвинуть все игреки влево на θ_0, и тогда достаточно будет проверить гипотезу об отсутствии сдвига. Что-

бы этого избежать, удобно ввести статистику

$$W_{m,n}(t) := \sum_{j=1}^{m} R(Y_j - t)$$

и проверять гипотезу по статистике $W_{m,n}(\theta_0)$.

Если нас интересует не проверка гипотез о сдвиге, а само значение сдвига, то его можно попробовать оценить. Например, это можно сделать с помощью **медианы Ходжеса — Лемана**.

ОПРЕДЕЛЕНИЕ 11.1.3

Медианой Ходжеса — Лемана μ^* называется медиана множества наблюдений

$$\{Y_j - X_i \ : \ i = 1, \ldots, n; \ j = 1, \ldots, m\}.$$

ТЕОРЕМА 11.1.1

Пусть выборки независимы и игреки отличаются от иксов сдвигом. Тогда выполнено

$$W_{m,n}(\mu^*) = \frac{m(m+n+1)}{2}.$$

Доказательство. Здесь удобнее воспользоваться статистикой Манна — Уитни. Имеем

$$H_{m,n}(\mu^*) = \sum_{i,j} \mathcal{I}\{X_i < Y_j - \mu^*\} = \sum_{i,j} \mathcal{I}\{\mu^* < Y_j - X_i\} = \frac{mn}{2}.$$

Тогда

$$W_{m,n}(\mu^*) = H_{m,n}(\mu^*) + \frac{m(m+1)}{2} = \frac{m(m+n+1)}{2}.$$

□

Смысл теоремы 11.1.1 в том, что медиана μ^*, по сути, является оценкой параметра θ методом максимального правдоподобия, только вместо правдоподобия мы смотрим на значение статистики $W_{m,n}(t)$, подбирая его как можно ближе к среднему значению.

Таким образом, с помощью коэффициентов корреляции можно проверять выборки на независимость, а с помощью критерия Манна — Уитни — Вилкоксона получится проверять на отсутствие смещения выборок. На самом деле отсутствие смещения можно проверять и гораздо более применимыми критериями согласия, к которым мы и переходим.

2. КРИТЕРИИ СОГЛАСИЯ

Критерий Колмогорова

Представим, что нас интересует вопрос, совпадает ли неизвестное распределение с каким-то конкретным. А именно: для

выборки $X = (X_1, \ldots, X_n)$ мы хотим проверить нулевую гипотезу $H_0 : \mathrm{P} = \mathrm{P}_0$ против альтернативы, что это не выполняется. Если бы альтернатива была простой, можно было бы воспользоваться леммой Неймана — Пирсона, которая говорит, что критерий S_α является РНМК среди всех критериев уровня значимости α и, кроме того, этот критерий несмещённый. Если бы модель была параметрическая, можно было бы понадеяться на монотонное отношение правдоподобий или поискать ещё какую-то закономерность на параметрах. В нашем случае все эти методы не работают.

Вспомни первый лонгрид, в котором нужно было выяснить информацию о распределении. По теореме Гливенко можно приблизить истинное распределение эмпирическим (по теореме Гливенко — Кантелли это приближение даже равномерное). Так что логично звучит следующий метод: посчитать эмпирическое распределение и сравнить его с распределением из нулевой гипотезы. Если они непохожи, гипотезу отвергаем. Этот метод реализуем через статистику Колмогорова.

ОПРЕДЕЛЕНИЕ 11.2.1

Статистикой Колмогорова называется

$$D_n := \sup_{x \in \mathbb{R}} |F_n^*(x) - F_0(x)|,$$

где F_n^* — это эмпирическая функция распределения.

Смысл статистики Колмогорова в том, что она как раз и оценивает, насколько далеко эмпирическое распределение от нулевого. Теперь нужно как-то научиться понимать, какие значения статистики мы считаем достаточно большими для того, чтобы отвергать нулевую гипотезу.

ОПРЕДЕЛЕНИЕ 11.2.2

Случайная величина K имеет **распределение Колмогорова**, если

$$F_K(x) = \frac{\sqrt{2\pi}}{x} \sum_{i=1}^{\infty} e^{-\frac{(2i-1)^2 \pi^2}{8x^2}}$$

для $x > 0$.

ТЕОРЕМА 11.2.1

Пусть выборка пришла из непрерывного распределения. При верности гипотезы H_0 выполнено:

$$\sqrt{n} D_n \xrightarrow[n \to \infty]{d_0} K.$$

Квантили k_α распределения Колмогорова известны. Например:

$$k_{0,9} \approx 1,23; \qquad k_{0,95} \approx 1,36; \qquad k_{0,99} \approx 1,63.$$

Впрочем, их можно смоделировать самостоятельно на языке Python.

ОПРЕДЕЛЕНИЕ 11.2.3

Критерий Колмогорова для проверки гипотезы $H_0 : \mathrm{P} = \mathrm{P}_0$ выглядит как

$$\sqrt{n} D_n > k_{1-\alpha}.$$

Таким образом, чтобы проверить гипотезу $H_0 : \mathrm{P} = \mathrm{P}_0$ по критерию Колмогорова на уровне значимости α, нужно посчитать статистику D_n и, если она попадает в критерий, отвергнуть нулевую гипотезу.

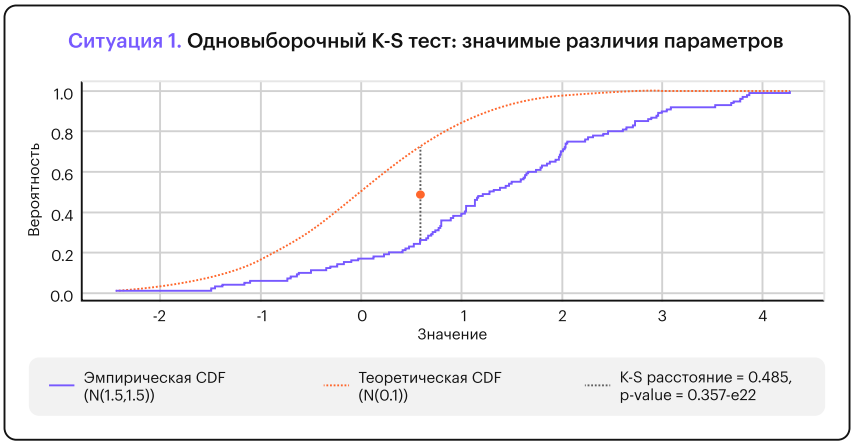

Рисунок 184. Критерий Колмогорова. Пример разных распределений

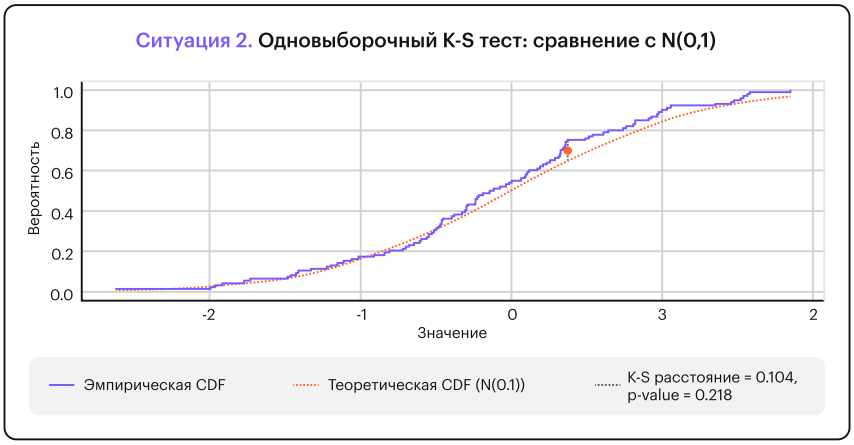

Рисунок 185. Критерий Колмогорова. Пример одинаковых распределений

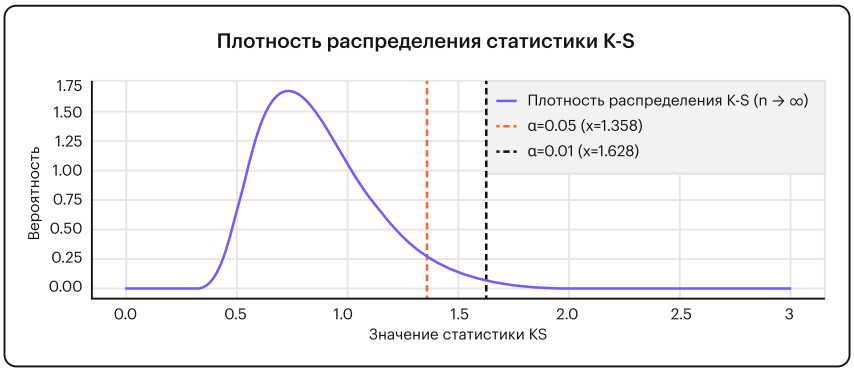

Рисунок 186. Распределение Колмогорова

Критерий Колмогорова состоятелен.

ТЕОРЕМА 11.2.2

Доказательство. Допустим, $F \neq F_0$. Тогда

$$\sup_{x\in\mathbb{R}}|F(x)-F_0(x)| \leqslant \sup_{x\in\mathbb{R}}|F_n^*(x)-F_0(x)| + \sup_{x\in\mathbb{R}}|F_n^*(x)-F(x)|.$$

Домножая на $\sqrt{n}$, получаем:

$$\sqrt{n}D_n \geqslant \sqrt{n}\sup_{x\in\mathbb{R}}|F(x)-F_0(x)| - \sqrt{n}\sup_{x\in\mathbb{R}}|F_n^*(x)-F(x)|.$$

Справа уменьшаемое уходит на бесконечность, а вычитаемое сходится к распределению Колмогорова. Поэтому разность уходит на бесконечность. Отсюда получаем, что

$$\mathrm{P}\sqrt{n}D_n > k_{1-\alpha} \xrightarrow[n\to\infty]{} 1.$$

□

Это всё прекрасно, но как использовать критерий на практике? Считать супремум по континуальному множеству не очень приятное занятие. Оказывается, статистику Колмогорова можно определить гораздо проще.
Статистику Колмогорова можно вычислять по формуле:

ТЕОРЕМА 11.2.3

$$D_n = \max_{i=1,\dots,n}\left\{F_0(X_{(i)}) - \frac{i-1}{n}, \frac{i}{n} - F_0(X_{(i)})\right\}.$$

Доказательство. Проведём замену $y = F_0(x)$ и обозначим через $\widehat{F_n}$ эмпирическую функцию распределения, построенную по выборке $F_0(X_1),\dots,F_0(X_n)$. Тогда

$$F_n^*(x) - F_0(x) = \widehat{F_n}(y) - y.$$

Отсюда

$$D_n = \sup_{x\in\mathbb{R}}|F_n^*(x)-F_0(x)| = \sup_{y\in[0,1]}\left|\widehat{F_n}(y)-y\right|.$$

Остаётся заметить, что функция $\widehat{F_n}$ имеет скачки только в точках $y = F(X_{(i)})$. □

При верности нулевой гипотезы распределение статистики D_n не зависит от F_0.

СЛЕДСТВИЕ 11.2.1

Набросок Доказательство. При верности нулевой гипотезы выполнено:

$$F_0(X_i) \sim \mathrm{U}[0,1],$$

откуда следует, что

$$F_0(X_{(i)}) \sim \mathrm{Beta}\,(i, n+1-i).$$

Дальше нужно посчитать максимум от случайных величин, распределения которых не зависят от F_0. □

Пример 11.2.1. Рассмотрим 10 наблюдений:

$$0,01;\ 0,15;\ 0,18;\ 0,27;\ 0,05;\ 0,93;\ 0,36;\ 0,16;\ 0,44;\ 0,98.$$

Проверим гипотезу о том, что они имеют распределение $\mathrm{U}[0,1]$, на уровне значимости 90%.

Решение. Считаем:

$$\sqrt{n}D_n = \sqrt{10}\cdot 0,36 \approx 1,14.$$

Знаем, что квантиль $K_{0,9} = 1,23$, поэтому не отвергаем гипотезу. ■

Стоит отметить, что критерий Колмогорова обычно применяется для непрерывных выборок. Для дискретных выборок он остаётся состоятельным, но сходимость к распределению Колмогорова при верности нулевой гипотезы перестаёт работать, поэтому его уровень значимости ухудшается (ошибка первого рода возрастает, а значение p-value становится завышенным).

Критерий Колмогорова-Смирнова

Идею критерия Колмогорова можно обобщить на двухвыборочные тесты. Так получается Критерий Колмогорова—Смирнова. (Стоит отметить, что в английской литературе это всё называется критерий Колмогорова—Смирнова, и там просто уточняют, речь про одновыборочный критерий или про двухвыборочный.) А именно, здесь идея в следующем: раньше мы смотрели на метрику $D_n = \sqrt{n}\sup_{x\in\mathbb{R}}|F_0(x) - F_n^*(x)|$. Теперь же имеется две выборки $X_1,\dots,X_n$ и $Y_1,\dots,Y_m$ и мы хотим проверить, одинаково ли они распределены. Для этого посчитаем статистику

$$D_{n,m} := \sqrt{\frac{nm}{n+m}}\sup_{x\in\mathbb{R}}|F_n^*(x) - F_m^*(x)|.$$

Далее её нужно сравнить с нужной квантилью $c(\alpha)$ некоторого распределения, которое можно сгенерировать на компьютере. Например, известные значения квантили такие:

$$c(0.10) = 1.224,\quad c(0.05) = 1.358,\quad c(0.01) = 1.628.$$

Двухвыборочный критерий KS

Тест Колмогорова–Смирнова (KS-тест) используется для сравнения двух распределений (по аналогии с критерием Манна–Уитни).

Расчёт по следующему алгоритму

1. Построение **функций распределения** двух выборочных распределений.
2. Расчёт максимального значения разницы между **ними**
3. Определение значимости и p-value по специальному распределению Колмогорова–Смирнова

Рисунок 187. Критерий Колмогорова-Смирнова. Формулировка

Ситуация 1. Двухвыборочный K-S тест: сравнение CDF

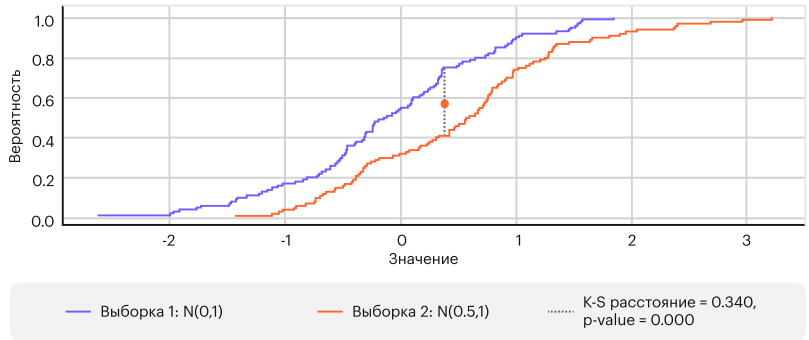

Рисунок 188. Критерий Колмогорова-Смирнова. Пример разных распределений

Ситуация 2. Двухвыборочный K-S тест: сравнение CDF

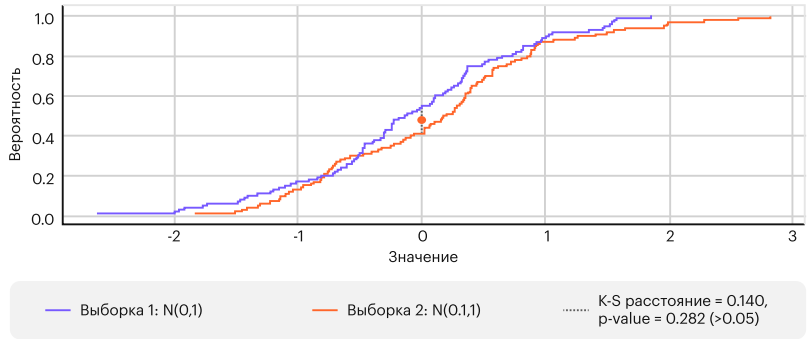

Рисунок 189. Критерий Колмогорова-Смирнова. Пример одинаковых распределений

Сравнение критериев

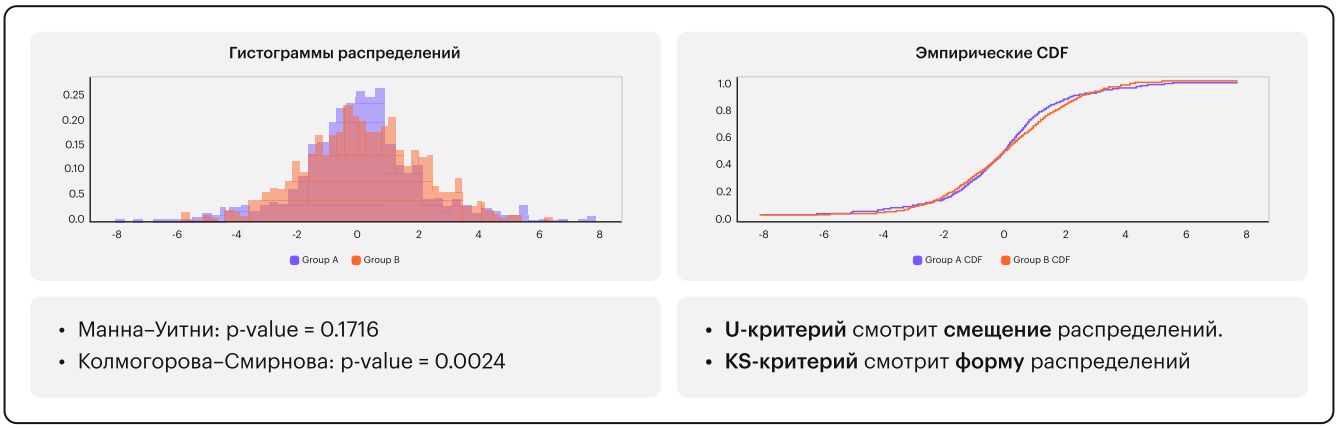

Рисунок 190. Критерий Колмогорова-Смирнова vs Критерий Манна-Уитни

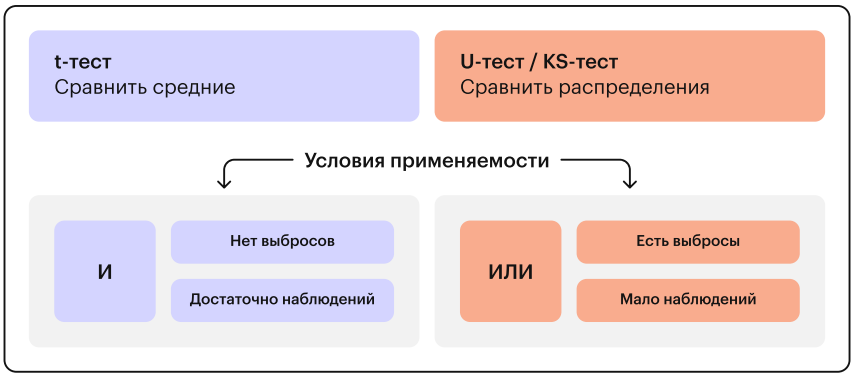

Рисунок 191. t-тест vs критерий Колмогорова-Смирнова и критерий Манна-Уитни

Критерии омега-квадрат

Критерий Колмогорова плохо реагирует на выбросы: один выброс сильно изменит значение супремума, что снизит мощность критерия. Поэтому при борьбе с выбросами полезнее применять другие критерии. Идея их состоит в том, чтобы расстояние между эмпирическим и нулевым наблюдением считать не через супремум, а какими-то иными способами. Таким образом, вместо статистики Колмогорова нужно использовать какие-то другие, похожие статистики.

Статистика ω^2 определяется как

ОПРЕДЕЛЕНИЕ 11.2.4

$$\omega^2 := \int |F_n^*(x) - F_0(x)|\, dF_0(x).$$

Как и в случае со статистикой Колмогорова D_n, статистику ω^2 можно считать проще, без страшных интегралов.

Статистика ω^2 критерия Смирнова — Крамера — фон Мизеса

ТЕОРЕМА 11.2.4

имеет вид:

$$n\omega^2 = \frac{1}{12n} + \sum_{i=1}^{n}\left(F_0(X_{(i)}) - \frac{2i-1}{2n}\right)^2.$$

При верности нулевой гипотезы распределение статистики ω^2 не зависит от F_0.

СЛЕДСТВИЕ 11.2.2

Критерий Смирнова — Крамера — фон Мизеса для проверки гипотезы $H_0 : \mathrm{P} = \mathrm{P}_0$ строится как

ОПРЕДЕЛЕНИЕ 11.2.5

$$n\omega^2 > w_{1-\alpha},$$

где w — квантиль нужного распределения.

Квантили w тоже известны и легко моделируются на Python. Например:

$$w_{0,9} \approx 0,35; \qquad w_{0,95} \approx 0,46; \qquad w_{0,99} \approx 0,74.$$

Стоит отметить, что этот критерий, как и критерий Колмогорова, применяется для непрерывных выборок. Дли дискретных выборок он остаётся состоятельным, но его уровень значимости ухудшается.

Пример 11.2.2. Рассмотрим 10 наблюдений:

$$0,01;\ 0,15;\ 0,18;\ 0,27;\ 0,05;\ 0,93;\ 0,36;\ 0,16;\ 0,44;\ 0,98.$$

Проверим гипотезу о том, что они имеют распределение $\mathrm{U}[0,1]$, на уровне значимости 90%. Для этого используем критерий омега-квадрат.

Решение. Находим:

$$n\omega^2 = 0,398.$$

Квантиль равен $w_{0,9} = 0,35$, поэтому отвергаем гипотезу. То есть здесь получается интересная ситуация: выбросов не было, и критерий Колмогорова не понял, что перед ним не равномерное распределение. А вот критерий ω^2 понял. ■

Если хочется придать больший вес хвостам распределения, обычно используют другую статистику.

Статистика Ω^2 определяется как

ОПРЕДЕЛЕНИЕ 11.2.6

$$\Omega^2 := \int \frac{|F_n^*(x) - F_0(x)|^2}{F_0(x)(1-F_0(x))}\, dF_0(x).$$

Статистика Ω^2 критерия Андерсона — Дарлинга имеет вид:

ТЕОРЕМА 11.2.5

$$n\Omega^2 = -n - \sum_{i=1}^{n}\frac{2i-1}{n}\left(\ln F_0(X_{(i)}) + \ln(1 - F_0(X_{(n+1-i)}))\right).$$

При верности нулевой гипотезы распределение статистики Ω^2 не зависит от F_0.

СЛЕДСТВИЕ 11.2.3

ОПРЕДЕЛЕНИЕ 11.2.7

Критерий Андерсона — Дарлинга для проверки гипотезы H_0 : $F = F_0$ при непрерывной функции распределения F строится как

$$n\Omega^2 > a_{1-\alpha},$$

где a — квантиль нужного распределения.

Вот примеры квантилей для критерия Андерсона — Дарлинга:

$$a_{0,9} \approx 1,93; \qquad a_{0,95} \approx 2,49; \qquad a_{0,99} \approx 3,86.$$

Состоятельность полученных критериев доказывается так же, как и для критерия Колмогорова.

Стоит отметить, что, аналогично критерию Колмогорова—Смирнова, можно ввести двухвыборочные критерии омега-квадрат. Мы не будем останавливаться на этом подробно.

3. ХИ-КВАДРАТ КРИТЕРИЙ ПИРСОНА

Отдельным видом критериев согласия является хи-квадрат критерий Пирсона. Он работает по другому принципу, нежели рассмотренные выше критерии согласия. Сначала мы построим его для дискретных выборок, а потом научимся обобщать на произвольные выборки, и на двухвыборочный случай.

Критерий хи-квадрат Пирсона для дискретного распределения

Пусть имеется полиномиальная модель: в ходе эксперимента происходят события $a_1, \ldots, a_m$ с вероятностями $p_1, \ldots, p_m$. Проверяется гипотеза H_0 о том, что вероятности принимают конкретные (строго положительные) значения $p_1^0, \ldots, p_m^0$, против альтернативы, что наблюдается другое дискретное распределение на тех же исходах.

ОПРЕДЕЛЕНИЕ 11.3.1

Для $j \in \{1, \ldots, m\}$ количество испытаний, закончившихся результатом a_j, обозначим через

$$\nu_j := \sum_{i=1}^{n} I\{X_i = a_j\}.$$

Статистикой χ^2 Пирсона называется

$$\widehat{\chi_n^2} := \sum_{j=1}^{m} \frac{(\nu_j - np_j^0)^2}{np_j^0}.$$

Покажем, на какой идее построен критерий χ^2. Когда нулевая гипотеза верна, значения ν_j близки к np_j^0. Соответственно, значения статистики $\widehat{\chi_n^2}$ получатся не слишком большими. Если же они большие, то нулевую гипотезу $H_0 : \boldsymbol{p} = \boldsymbol{p^0}$ нужно отвергнуть.

Таким образом, статистику Пирсона необходимо сравнить с некоторой положительной константой c. Тогда критерий Пирсона выглядит как

$$\widehat{\chi^2_n} > c, \quad c > 0.$$

Какова бы ни была константа c, критерий Пирсона состоятелен.

ТЕОРЕМА 11.3.1

Доказательство. В выражении статистики Пирсона вынесем n как общий множитель:

$$\widehat{\chi^2_n} = n \sum_{j=1}^{m} \frac{\left(\frac{\nu_j}{n} - p_j^0\right)^2}{p_j^0}.$$

По ЗБЧ

$$\frac{\nu_j}{n} \xrightarrow[n\to\infty]{\mathrm{P}} p_j \neq p_j^0$$

для всех j. Отсюда получаем, что

$$\sum_{j=1}^{m} \frac{\left(\frac{\nu_j}{n} - p_j^0\right)^2}{p_j^0} \xrightarrow[n\to\infty]{\mathrm{P}} \sum_{j=1}^{m} \frac{\left(p_j - p_j^0\right)^2}{p_j^0} > 0.$$

Таким образом, после домножения на n выражение по вероятности уходит на бесконечность и становится больше любой наперёд заданной константы c. □

Константу c подскажет следующая теорема.

При верности нулевой гипотезы $H_0 : \boldsymbol{p} = \boldsymbol{p^0}$ выполнено:

$$\widehat{\chi^2_n} \xrightarrow[n\to\infty]{d} \chi^2(m-1).$$

ТЕОРЕМА 11.3.2

Теорема Пирсона

Доказательство. Для каждого наблюдения X_i построим вектор

$$\boldsymbol{Y}_i := \begin{pmatrix} \mathcal{I}\{X_i = a_1\} \\ \mathcal{I}\{X_i = a_2\} \\ \vdots \\ \mathcal{I}\{X_i = a_m\} \end{pmatrix}.$$

Обозначим через $\boldsymbol{p}$ вектор истинных вероятностей $(p_1^0, \ldots, p_m^0)$.

Тогда по многомерной ЦПТ

$$\boldsymbol{\xi}_n := \sqrt{n}\left(\overline{\boldsymbol{Y}} - \boldsymbol{p}\right) \xrightarrow[n\to\infty]{d} N(0, \Sigma).$$

На диагонали матрицы Σ стоят величины

$$\operatorname{Var}\mathcal{I}\{X_1 = a_j\} = p_j - p_j^2,$$

а вне диагонали стоят

$$\operatorname{cov}(\mathcal{I}\{X_1 = a_j\}, \mathcal{I}\{X_1 = a_k\}) = 0 - p_j p_k.$$

То есть

$$\Sigma = \operatorname{diag}(\boldsymbol{p}) - \boldsymbol{p}\boldsymbol{p}^\intercal.$$

Тогда

$$\boldsymbol{\xi}'_n := \operatorname{diag}\left(1/\sqrt{p_j^0}\right)\boldsymbol{\xi}_n \xrightarrow[n\to\infty]{d} N(0, I_m - \boldsymbol{z}\boldsymbol{z}^\intercal),$$

где

$$\boldsymbol{z} = \begin{pmatrix} \sqrt{p_1^0} \\ \vdots \\ \sqrt{p_m^0} \end{pmatrix}.$$

Заметим, что вектор $\boldsymbol{z}$ единичный, а потому, набрав к нему ещё $m-1$ линейно независимых векторов, можно запустить процесс ортогонализации Грама — Шмидта и получить ортогональную матрицу Z, у которой первый столбец равен $\boldsymbol{z}$. Тогда

$$\boldsymbol{\xi}''_n := Z\boldsymbol{\xi}'_n \xrightarrow[n\to\infty]{d} N(0, I_m - (Z\boldsymbol{z})(Z\boldsymbol{z})^\intercal).$$

В силу ортогональности матрицы Z имеем

$$Z\boldsymbol{z} = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}.$$

Поэтому

$$\left\|\boldsymbol{\xi}''_n\right\|^2 \xrightarrow[n\to\infty]{d} \left\|N(0, \operatorname{diag}(0, 1, \ldots, 1))\right\|^2 = \chi^2(m-1).$$

Остаётся заметить, что

$$\left\|\boldsymbol{\xi}''_n\right\|^2 = \left\|\boldsymbol{\xi}'_n\right\|^2 = \left\| \begin{pmatrix} \frac{\nu_1 - np_1^0}{\sqrt{np_1^0}} \\ \vdots \\ \frac{\nu_m - np_m^0}{\sqrt{np_m^0}} \end{pmatrix} \right\|^2 = \widehat{\chi^2_n}.$$

□

Теперь мы можем построить критерий.

ОПРЕДЕЛЕНИЕ 11.3.2

Критерий χ^2 Пирсона выглядит как

$$\widehat{\chi^2_n} > u_{1-\alpha},$$

где $u_{1-\alpha}$ является $(1-\alpha)$-квантилем распределения $\chi^2(m-1)$.

Этот критерий применяют, когда соблюдено два условия: количество наблюдений $n \geqslant 20$ и $\nu_j \geqslant 5$ хотя бы для 80% исходов a_j.

Критерий хи-квадрат Пирсона для непрерывного распределения

На самом деле критерий χ^2 Пирсона можно применять и для распределений с непрерывной функцией распределения. Для этого область значений наблюдений нарезается на **бины** (от англ. bin, «урна») $B_1, \ldots, B_m$, а именно:

$$\bigsqcup_{j=1}^{m} B_j = \mathcal{X}.$$

Дальше применяется критерий Пирсона, где в ν_j вместо количества исходов $X_i = a_j$ считается количество исходов $X_i \in B_j$, а p_j равны вероятности попадания в бин B_j.

Пример 11.3.1. Рассмотрим 10 наблюдений:

$$0,01;\ 0,15;\ 0,18;\ 0,27;\ 0,05;\ 0,93;\ 0,36;\ 0,16;\ 0,44;\ 0,98.$$

Проверим гипотезу о том, что они имеют распределение $\mathrm{U}[0,1]$, на уровне значимости 90%. Сделаем это теперь с помощью критерия χ^2 Пирсона.

Решение. Разобьём область на бины $B_1 = [0,0,5)$ и $B_2 = [0,5,1]$. Тогда $\nu_1 = 8$, $\nu_2 = 2$. Здесь уже видно, что это не очень похоже на равномерное распределение, но всё же проверим честно. Находим:

$$\widehat{\chi^2_n} = \frac{(8-5)^2}{5} + \frac{(2-5)^2}{5} = 3,6.$$

Квантиль распределения $\chi^2(1)$ равен $u_{0,9} = 2,7$. Поэтому отвергаем нулевую гипотезу, причём с большим запасом. То есть в этом случае критерий Пирсона сработал гораздо лучше, чем критерии Колмогорова и ω^2. ■

Критерий хи-квадрат для проверки к классу распределений

Критерий Пирсона можно использовать и для проверки принадлежности истинного распределения к некоторому классу распределений.
Пусть:

ТЕОРЕМА 11.3.3

Теорема Фишера

- есть полиномиальная модель $a_1, \ldots, a_m$ (или есть модель, нарезанная на бины);

- в параметрической модели проверяется гипотеза
$$H_0 : p = p^0(\theta),$$
причём θ имеет размерность $r < m - 1$;
- существует такая константа c, что для всех $j = 1, \dots, m$ и для всех θ выполнено:
$$p_j^0(\theta) > c;$$
- определена полноранговая матрица $m \times r$ производных:
$$\frac{\partial p^0}{\partial \theta};$$
- определена ОМП:
$$\theta^* = \operatorname{argmax}_{\theta \in \Theta} \prod_{j=1}^{m} (p_j^0(\theta))^{\nu_j},$$
где ν_j равно количеству исходов a_j.

Если гипотеза H_0 верна, то выполнено
$$\widehat{\chi_n^2}(\theta^*) \xrightarrow[n\to\infty]{d} \chi^2(m - r - 1).$$

Пример 11.3.2. Допустим, в модели случаются только исходы $0, 1, 2$. Проверим гипотезу о том, что распределение на них биномиальное $\mathrm{Bin}(2, \theta)$, то есть $H_0 : P = \mathrm{Bin}(2, \theta)$.

Решение. Предположим, распределение исходов получилось таким:
$$\nu_0 = \nu_1 = \nu_2 = 20, \quad n = 60.$$
Поскольку
$$p_0^0(\theta) = (1 - \theta)^2, \quad p_1^0(\theta) = 2\theta(1 - \theta), \quad p_2^0(\theta) = \theta^2,$$
то находим ОМП из уравнения:
$$0 = \frac{\partial \ln f_\theta(X)}{\partial \theta} = -\frac{2\nu_0}{1 - \theta} + \frac{\nu_1}{\theta} - \frac{\nu_1}{1 - \theta} + \frac{2\nu_2}{\theta}.$$
В итоге
$$\frac{60}{\theta} = \frac{60}{1 - \theta},$$
откуда ОМП $\theta^* = \frac{1}{2}$. Окончательно:
$$\widehat{\chi_{60}^2}(\theta^*) = \sum_{j=0}^{2} \frac{(\nu_j - np_j^0(\tfrac{1}{2}))^2}{np_j^0(\tfrac{1}{2})} =$$
$$= \frac{(20 - 15)^2}{15} + \frac{(20 - 30)^2}{30} + \frac{(20 - 15)^2}{15} = \frac{200}{30} \approx 6,67.$$

Для распределения $\chi^2(3-1-1) = \chi^2(1)$ находим квантиль:

$$u_{0,99} = 6,63.$$

χ^2 примерно равно $6,67 > 6,63$, поэтому гипотезу о биномиальном распределении отвергаем. ■

С помощью этого теста мы можем ответить на вопрос, есть ли зависимость (да или нет). Однако бывает полезным не только понимать факт наличия зависимости, но и измерять её в какой-нибудь нормализованной шкале (например, от 0 до 1).

Коэффициент V Крамера

Зачастую можно встретиться с ситуациями, когда необходимо сравнить не числовые, а категориальные данные. В подобных случаях используется хи-квадрат критерий Пирсона, с помощью которого можно обнаружить наличие статистически значимой зависимости дискретных признаков.

Идея тут похожа на идею критерия хи-квадрат. Имеются два признака, первый имеет s исходов, а второй t (для удобства, будем нумеровать числами с единицы до максимального номера). Всего проведено n пар наблюдений признаков $(X_1, Y_1), \ldots, (X_n, Y_n)$. Обозначим через h_{ij} количество пар наблюдений, имеющий признак (i, j) для $i = 1, \ldots, s$, $j = 1, \ldots, t$. Пусть $p_{ij} = \mathrm{P}\{X_1 = i, Y_1 = j\}$, а $p_{i,\cdot}$ и $p_{\cdot,j}$ суть маргинальные распределения признаков. Тогда гипотеза H_0 о независимости: $p_{ij} = p_{i,\cdot}p_{\cdot,j}$. Далее положим $p^*_{i,\cdot}$ и $p^*_{\cdot,j}$ ОМП соответствующих критериев, равные просто средним значениям по столбцам или по строкам в таблице (h_{ij}). Теперь

$$\hat{\chi}^2(n) := \sum_{i,j} \frac{\left(h_{ij} - np^*_{i,\cdot}p^*_{\cdot,j}\right)^2}{np^*_{i,\cdot}p^*_{\cdot,j}}.$$

ТЕОРЕМА 11.3.4

При верности гипотезы H_0 о независимости признаков,

$$\hat{\chi}^2(n) \xrightarrow[n\to\infty]{d} \chi^2((s-1)(t-1)).$$

Таким образом, если этот коэффициент сильно больше нужной квантили, гипотезу отвергаем.

Критерий хи-квадрат (chi2 test) используется для определения зависимости в **категориальных признаках**

Пример

1. Цвет волос vs пол.
2. Факт покупки vs город проживания клиента.
3. Лояльность клиента vs возраст.

{нелояльный, средний, лояльный} {0–18, 19–30, 31–50, 51+}

Вопрос:
в чём проблема порядковой шкалы в подобном тесте?

Ответ:
результат не будет учитывать их порядок

← **Порядковая шкала**

Рисунок 192. Хи-квадрат критерий Пирсона. Интуиция

Рассмотрим два примера. В обоих будем пытаться найти зависимость между полом и цветом волос. В первом примере зависимости не будет, а во втором - будет.

Пример 1. Отсутствие зависимости

$O=$

	Брюнеты	Блондины	Шатены	Σ (строка)
Муж.	50	30	40	120
Жен.	45	35	40	120
Σ (столбец)	95	65	80	240

O_{ij}

Для расчёта критерия от матрицы **O** (Observed) надо перейти к матрице **E** (Expected).

Расчёт координат матрицы E

$$E_{ij}=\frac{(\text{Сумма строки } i) \times (\text{Сумма столбца } j)}{N}$$

Пример

$$E_{11} = \frac{120 \times 95}{240} = 47.5$$

$E=$

	Брюнеты	Блондины	Шатены	Σ (строка)
Муж.	47,5	32,5	40	120
Жен.	47,5	32,5	40	120
Σ (столбец)				240

E_{ij}

Рисунок 193. Хи-квадрат критерий Пирсона. Пример отсутствия зависимости. Матрицы

$$\chi^2 = \sum_{i=1}^{n} \sum_{j=1}^{m} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

Брюнеты

$$\chi^2 = \frac{(50 - 47.5)^2}{47.5} + \frac{(30 - 32.5)^2}{32.5} + \frac{(40 - 40)^2}{40} + \frac{(45 - 47.5)^2}{47.5} + \frac{(35 - 32.5)^2}{32.5} + \frac{(40 - 40)^2}{40} \approx 0.857$$

Блондины

Шатены

Результирующее значение статистического критерия

Рисунок 194. Хи-квадрат критерий Пирсона. Пример отсутствия зависимости. Расчёт критерия

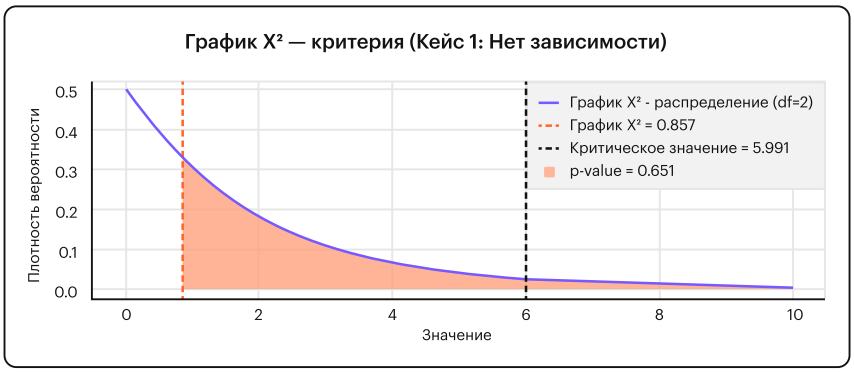

Рисунок 195. Хи-квадрат критерий Пирсона. Пример отсутствия зависимости. Визуализация критерия

Пример 2. Наличие зависимости

O=

	Брюнеты	Блондины	Шатены	Σ (строка)
Муж.	60	20	40	120
Жен.	35	45	40	120
Σ (столбец)	95	65	80	240

$$\chi^2 = 3.289 + 4.808 + 0 + 3.289 + 4.808 + 0 \approx 16.194$$

E=

	Брюнеты	Блондины	Шатены
Муж.	47,5	32,5	40
Жен.	47,5	32,5	40

Рисунок 196. Хи-квадрат критерий Пирсона. Пример наличия зависимости. Расчёт критерия

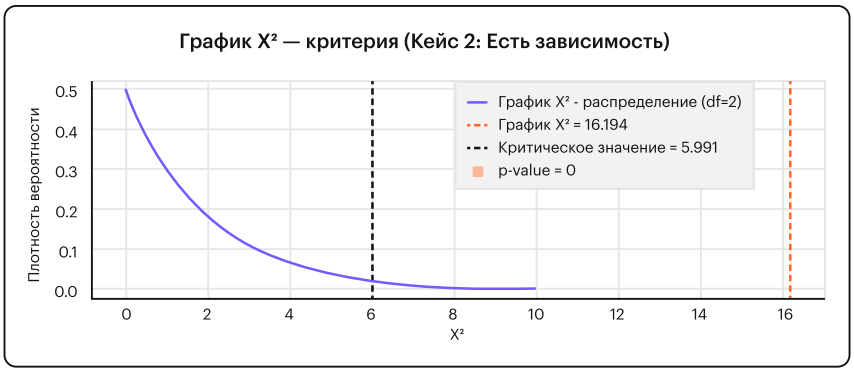

Рисунок 197. Хи-квадрат критерий Пирсона. Пример наличия зависимости. Визуализация критерия

Количество степеней свободы распределения хи-квадрат рассчитывается $(K_1 - 1) \cdot (K_2 - 1)$.

В нашем случае $K_1 = 2$ и $K_2 = 3$, поэтому $df = 2$.

Но данный критерий работает просто на да/нет, он не позволяет оценить силу зависимости признаков. Для оценки этой зависимости нужен следующий подход.

K_2

K_1		Брюнеты	Блондины	Шатены	Σ (строка)
	Муж.	60	20	40	120
	Жен.	35	45	40	120
	Σ (столбец)	95	65	80	240

$$\chi^2 \approx 16.194$$

Рассчитаем коэффициент V Крамера

Слабая/умеренная зависимость

$$V = \sqrt{\frac{\chi^2}{n \cdot \min(K_1 - 1, K_2 - 1)}}$$

$$V = \sqrt{\frac{16.194}{240 \cdot \min(2-1, 3-1)}} = \sqrt{\frac{16.194}{240 \cdot 1}} = \sqrt{0.067475} \approx 0.26$$

Рисунок 198. Хи-квадрат критерий Пирсона. Пример наличия зависимости. Коэффициент V Крамера

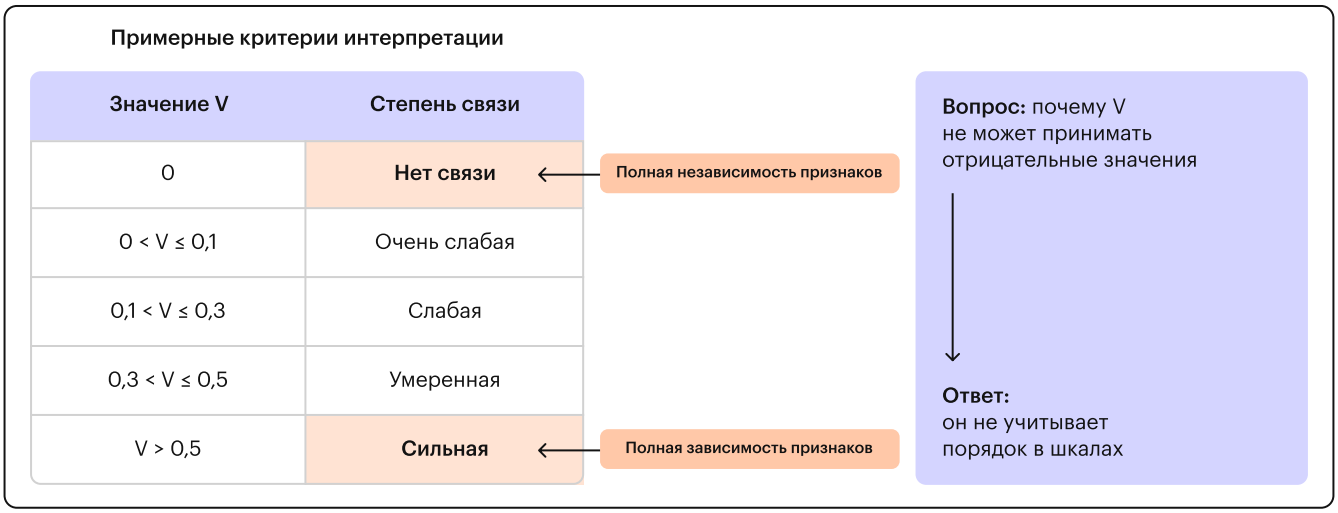

Рисунок 199. Коэффициент V Крамера. Интерпретация

4. КРИТЕРИИ ПРОВЕРКИ НОРМАЛЬНОСТИ

Критерии согласия, посвящённые проверке на нормальность, выделяют в особый класс.

В предыдущих главах мы сравнивали распределения между собой, но существуют также тесты, нацеленные на проверку соответствия эмпирически данных теоретическому распределению, чаще всего, нормальному.

В случае подтверждения нормальности данных в анализе данных можно делать некоторые дополнительные предпосылки и использовать специфические методы.

Для этих целей можно использовать описанный выше одновыборочный критерий Коломогорова-Смирнова. Однако тесты, специализирующиеся на нормальном бенчмарке, зачастую лучше распознают локальные отклонения в центре распределения.

Рассмотрим два критерия, которые проверяют данные на нормальность.

Критерий Шапиро-Уилка

Тест, используемый для проверки нормальности выборки и использующие специальные коэффициенты Шапиро-Уилка.

ОПРЕДЕЛЕНИЕ 11.4.1

Тест Шапиро-Уилка

Критерий Шапиро–Уилка (SW критерий / SW test)
используется для сравнения распределения с нормальным.

- H_0 — распределение нормально
- H_1 — распределение не нормально

$$W = \frac{\left(\sum_{i=1}^{n} a_i x_{(i)}\right)^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

Специальные коэффициенты Шапиро–Уилка, опирающиеся на расчётные значения нормального распределения

Тест	Чувствителен к
Колмогоров–Смирнов	Глобальная форма распределения
Шапиро–Уилк	Локальные отклонения в центре

Рисунок 200. Критерий Шапиро-Уилка. Формула

Проблема данного теста заключается в том, что он крайне чувствителен к любым отклонениям на большой выборке. В связи с этим, он часто будет показывать отвержение гипотезы о нормальности несмотря на визуально нормальные данные.

Критерий Харке-Бера

Тест, используемый для проверки нормальности выборки и использующий сравнение значений выборочных асимметрии и эксцесса с соответствующими значениями нормального распределения.

ОПРЕДЕЛЕНИЕ 11.4.2
Тест Харке-Бера

Критерий Харке — Бера (JB-критерий) используется
для сравнения распределения с нормальным.

H_0 — распределение нормально.

H_1 — распределение не нормально.

Коэффициент асимметрии выборки X

Коэффициент эксцесса выборки X

=Kurt(X) − 3

$$JB = n \times \left(\frac{Skew(X)}{6} + \frac{Ex(X)}{24} \right) \sim \chi^2_2$$

Рисунок 201. Тест Харке-Бера. Постановка

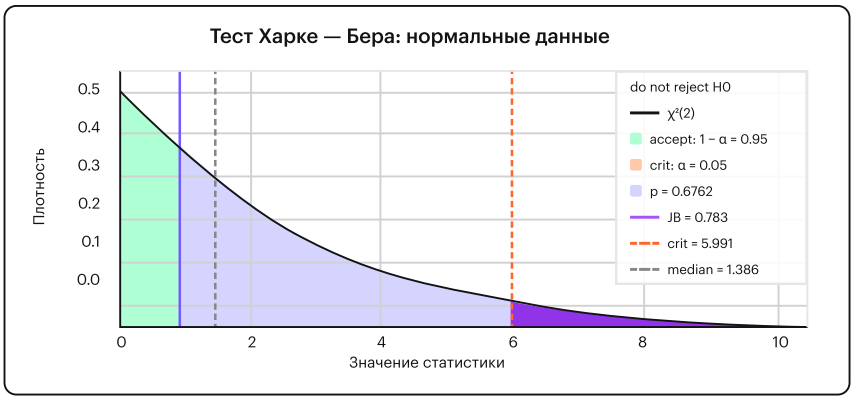

Рисунок 202. Тест Харке-Бера. Кейс-1. Нормальные данные

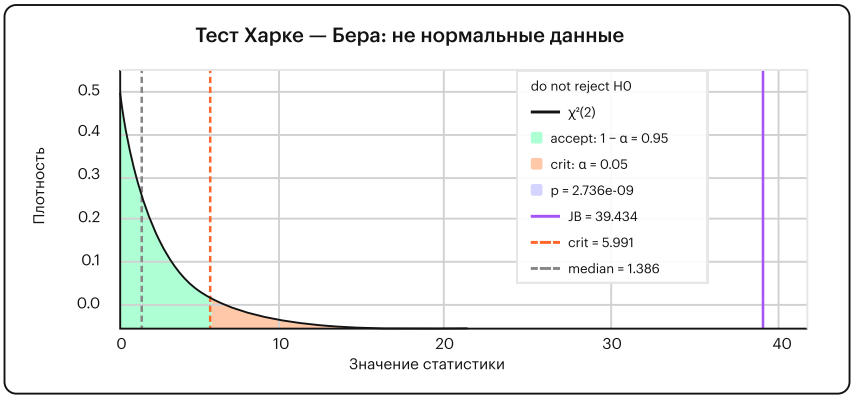

Рисунок 203. Тест Харке-Бера. Кейс-1. Нормальные данные

Часть 12. Множественные тесты

В предыдущих главах мы рассмотрели множество разнообразных статистических критериев, но все они использовались в качестве разовых тестов при определённых параметрах.

Одним из параметром, например, была статистическая значимость, то есть допустимый уровень ошибки первого рода α, который в большинстве случаев на практике предполагается равным 5%.

Однако зачастую при проведении продуктовых экспериментов для того, чтобы сделать вывод, необходимо провести несколько тестов и учесть результаты множественных сравнений (будь то сравнение нескольких групп или нескольких метрик друг с другом).

Пример 12.0.1. При тестировании статистических гипотез исследователи часто совершают классическую ошибку: проводят сотни тестов одновременно, но оценивают каждый из них так, будто он

Мёртвый лосось определяет человеческие эмоции

единственный. К чему это приводит, в 2009 году наглядно продемонстрировала группа нейробиологов под руководством Крэйга Беннета. Их исследование вошло в историю науки и удостоилось Шнобелевской премии.

Ученые поместили в томограф (фМРТ) обычного мертвого атлантического лосося. Внутри аппарата рыбе на экране демонстрировали фотографии людей в различных эмоциональных ситуациях. Лосося «просили» определить, какую именно эмоцию испытывает человек на картинке.

Аппарат фМРТ измеряет уровень оксигенации крови в микроскопических участках трехмерного пространства — вокселях. Весь мозг рыбы был разделён на тысячи таких точек. Для каждого вокселя компьютер проверял отдельную статистическую гипотезу: «Изменяется ли сигнал в этой точке при показе картинок?». Когда авторы обработали данные стандартным методом (без жестких поправок), компьютер зафиксировал выраженную «активность» в головном и спинном мозге мёртвой рыбы с уровнем значимости $p < 0.001$. Согласно базовым тестам, мёртвый лосось действительно «реагировал» на человеческие эмоции.

Причина этого парадокса — проблема множественных сравнений. Во-первых, это природа случайности. При стандартном пороге значимости $\alpha = 0.05$ вероятность ошибочно зафиксировать активность там, где её нет (ошибка первого рода), составляет 5%. То есть 1 из 20 тестов чисто случайно может показать ложноположительный результат из-за технических шумов томографа. Во-вторых, это масштаб вычислений. В эксперименте с лососем проверялось около $130\,000$ вокселей одновременно. В-третьих, это неизбежность ошибки. Если провести $130\,000$ независимых тестов без поправок, то математическая вероятность найти хотя бы одно ложное «открытие» стремится к 1. Компьютер просто визуализировал случайный технический шум, приняв его за сигналы мозга.

Когда исследователи применили коррекцию на множественные сравнения (в данном случае методы FWER и FDR), порог значимости для каждого отдельного вокселя был жёстко скорректирован с учетом общего количества тестов. После этой математической фильтрации вся «активность» лосося мгновенно исчезла.

Эксперимент с лососем стал важнейшим методологическим уроком. Он доказал: чем больше гипотез вы проверяете на одном наборе данных, тем выше шанс найти случайную закономерность, которой не существует в реальности. Любой множественный анализ данных требует обязательного применения методов коррекции. В противном случае ученый рискует «найти разум» у неодушевлённого предмета.

1. FAMILY-WISE ERROR

При проведении единичного теста вероятность совершения ошибки первого рода и уровень значимости по сути являются одним и тем же параметром — та самая α, которую мы предполагаем равной 5%.

Однако при множественном тестировании уровень значимости каждого конкретного теста не совпадает с ошибкой первого рода на комплексном выводе.
Пусть одновременно проверяется семейство из m гипотез: $H_1, \ldots, H_m$.

ОПРЕДЕЛЕНИЕ 12.1.1

При множественной проверке гипотез может возникнуть ситуация, когда хотя бы одна истинная нулевая гипотеза будет ошибочно отвергнута. Такая ошибка называется *family-wise error*, то есть ошибкой на уровне всего семейства гипотез.

Обозначим через V количество ошибочно отвергнутых истинных нулевых гипотез. Тогда family-wise error rate определяется как вероятность совершить хотя бы одну ошибку первого рода:

$$\mathrm{FWER} = \mathbb{P}(V \geqslant 1).$$

Иными словами, FWER — это вероятность ситуации, когда хотя бы одна истинная нулевая гипотеза отвергнута.

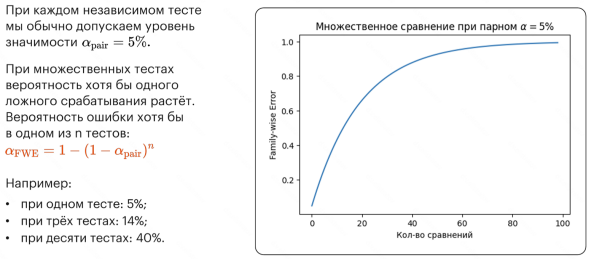

Рисунок 204. ПЕРЕНЕСТИ ТЕКСТ В ТЕКСТ

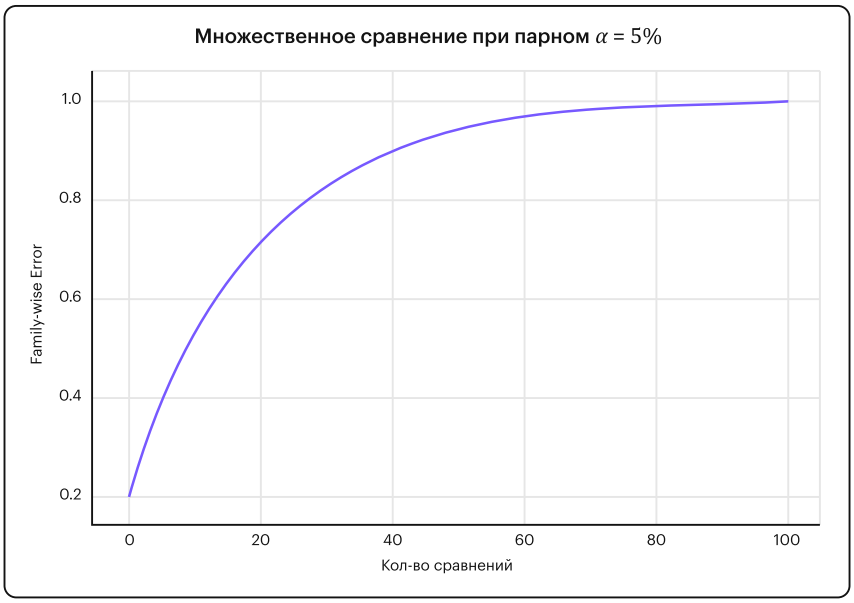

Рисунок 205. Множественное тестирование. FWE. Интуиция

Рассмотрим дерево возможных исходов при проведении N тестов.

	Не прокрасится	Прокрасится
Одно сравнение	$1 - \alpha_{\text{pair}_i} = 0.95$	$\alpha_{\text{pair}_i} = 0.05$
	↓	↓
Два сравнения	$(1 - \alpha_{\text{pair}_i}) \cdot (1 - \alpha_{\text{pair}_j}) = 0.95 \cdot 0.95$	...
	↓	↓
***N* сравнений**	$(1 - \alpha_{\text{pair}_1}) \cdot (1 - \alpha_{\text{pair}_2}) \cdots (1 - \alpha_{\text{pair}_n}) = 0.95 \cdot 0.95 \cdots 0.95 = 0.95^n$	...
	↓	
	Прокрасится хотя бы одно из *n* сравнений $1 - 0.95^n$	
	↓	
	$\alpha_{\text{FWE}} = 1 - (1 - \alpha_{\text{pair}})^n$	

Рисунок 206. Множественное тестирование. FWE. Схема вариантов

При множественных тестах мы не имеем права каждый из них проводить на уровне значимости 5% и утверждать, что результирующий составной вывод также имеет вероятность ошибки первого рода в размере 5%. Необходимо применить поправку к параметру α.

2. ПОПРАВКА БОНФЕРОНИ

Одним из методов корректировки уровня значимости является поправка Бонферони.

Идея: уменьшаем уровень значимости парного сравнения α_{pair} , чтобы сохранить общий уровень ошибки первого рода для значимости α_{FWE}.

Формула: если $\alpha_{\text{FWE}} = 0.05$ и n — число сравнений, то $\alpha_{\text{pair}} = \frac{\alpha_{\text{FWE}}}{n}$.

Например:

- при трёх тестах: 0.0167;
- при пяти тестах: 0.01;
- при двенадцати тестах: 0.00416.

Плюсы:

- прост в реализации;
- гарантирует строгий контроль ошибки первого рода.

Минусы:

- сильно снижает статистическую мощность;
- становится неэффективен при большом числе гипотез.

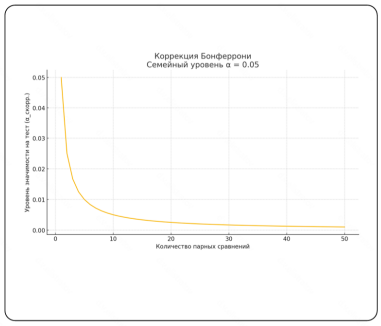

Рисунок 207. ПЕРЕНЕСТИ ТЕКСТ В ТЕКСТ

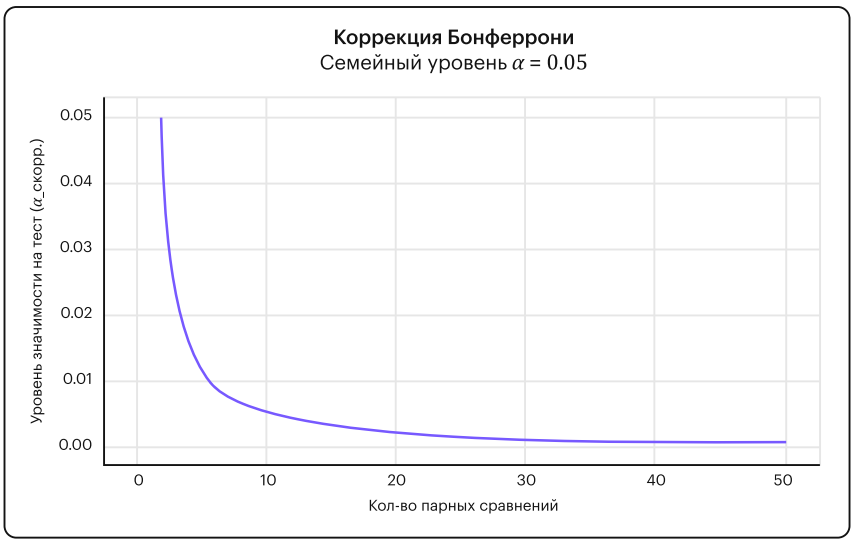

Рисунок 208. Множественное тестирование. Поправка Бонферони

3. ПОПРАВКА ХОЛМА

Идея: адаптивная альтернатива Бонферрони — более мощная, но всё ещё строгая.

Принцип:

- Сортируем p-value попарных сравнений по возрастанию: $p_1, p_2, \ldots, p_n$
- **Сравниваем:**

$$p_1 \le \frac{\alpha_{\text{FWE}}}{n}; \quad p_2 \le \frac{\alpha_{\text{FWE}}}{n-1}; \quad p_3 \le \frac{\alpha_{\text{FWE}}}{n-2}; \quad \ldots \quad p_i \le \frac{\alpha_{\text{FWE}}}{n-i+1}.$$

Идём до первого p_i, которое не проходит, — все следующие отклоняются.

\+ Меньше потерь в мощности по сравнению с Бонферрони.

\− Немного сложнее в реализации

\− Всё ещё консервативен при большом количестве гипотез

Рисунок 209. Множественное тестирование. Поправка Холма

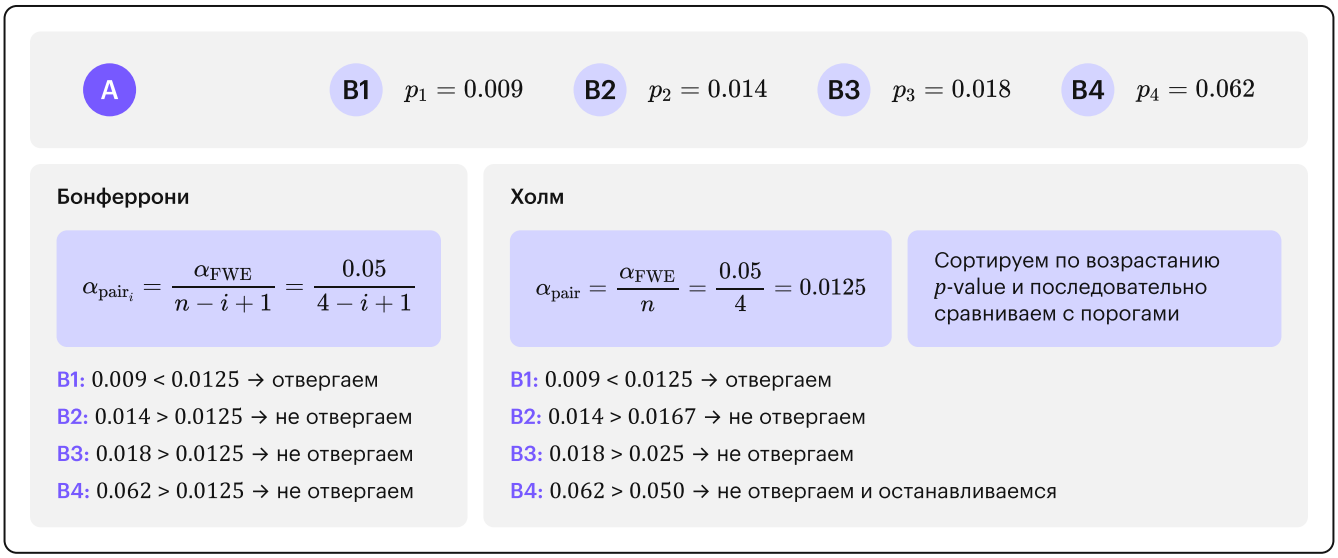

Рисунок 210. Множественное тестирование. Сравнение поправок Бонферони и Холма

4. ANOVA F-ТЕСТ

Дисперсионный анализ — это метод сравнения нескольких средних, в основе которого лежит разложение общей дисперсию данных на межгрупповую дисперсию (between) и внутригрупповую дисперсию (within).

ОПРЕДЕЛЕНИЕ 12.4.1

Дисперсионный анализ (ANOVA, от англ. Analysis of Variance)

В однофакторной постановке ANOVA приведёт нас к той же F-статистике, что и в предыдущем разделе: отношение оценённой дисперсии между группами к оценённой дисперсии внутри групп сравнивается с теоретическим распределением Фишера.

Вместо того чтобы запускать множество отдельных t-тестов для всех пар групп и сталкиваться с проблемой множественных проверок, ANOVA позволяет одним глобальным тестом проверить гипотезу равенства всех средних.

Это особенно удобно в A/B/n-экспериментах, где есть один контроль и несколько вариантов изменения: сначала проверяется, есть ли вообще хоть какие-то различия между вариантами, а уже затем, при необходимости, выполняются детальные попарные сравнения.

Предпосылки однофакторной ANOVA. Классическая модель ANOVA предполагает:

- независимость наблюдений внутри и между группами;
- нормальность распределения ошибки в каждой группе;
- гомоскедастичность: равенство дисперсий во всех группах ($\sigma_1^2 = \cdots = \sigma_k^2$).

На практике F-тест достаточно устойчив к небольшим отклонениям от нормальности, особенно при близких размерностях групп, но чувствителен к сильной неоднородности дисперсий и сильному дисбалансу по n_i.

Статистический метод для сравнения более двух средних групп одновременно.

Проверяет не много парных гипотез, а всего лишь одну — есть ли где-то разница среди всех групп.

Нулевая гипотеза H_0: $\mu_1 = \mu_2 = \cdots = \mu_k$

Альтернативная гипотеза H_1: $\exists\, i, j:\ \mu_i \neq \mu_j$

ANOVA отвечает, **есть ли вообще различия**, а не говорит, **между какими группами**.

Делает это с помощью F-статистики, которая определяется как отношение двух дисперсий.

В случае с ANOVA это:

- межгрупповая дисперсия (вариация между средними групп);
- внутригрупповая дисперсия (вариация внутри групп).

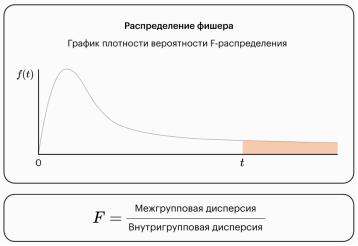

$$F = \frac{\text{Межгрупповая дисперсия}}{\text{Внутригрупповая дисперсия}}$$

Рисунок 211. ПЕРЕНЕСТИ ТЕКСТ В ТЕКСТ

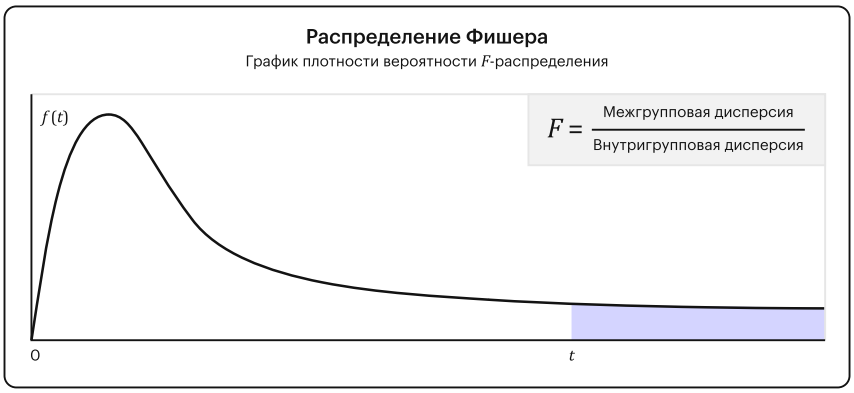

Рисунок 212. Вкратце про ANOVA

Как мы можем интепретировать результаты? Если наблюдаемое значение F_{obs} попадает в правый хвост распределения Фишера и соответствующее p-value меньше уровня значимости α, то нулевая гипотеза равенства всех средних отклоняется. Это означает, что хотя бы в одной группе среднее отличается от остальных, но сам по себе F-тест не указывает, в каких именно парах групп есть отличие.

ANOVA в A/B/n-тестировании. В контексте A/B-тестирования однофакторная ANOVA естественно применяется, когда есть одна контрольная группа и несколько экспериментальных вариантов (A/B/C/D и т.п.), а нас интересует сравнение средних значений некоторой метрики (например, ARPU) по всем вариантам сразу. В таком случае фактором выступает «вариант эксперимента», а откликом — значение метрики на пользователе или сессии. Сначала проводится глобальный тест с помощью ANOVA:

$$H_0 : \mu_{x_1} = \cdots = \mu_{x_k},$$

и только если H_0 отвергнута (есть хотя бы одно отличие), имеет смысл переходить к более детальному анализу парных сравнений.

Визуализируем групповые распределения и разницы между групповыми средними и общим средним.

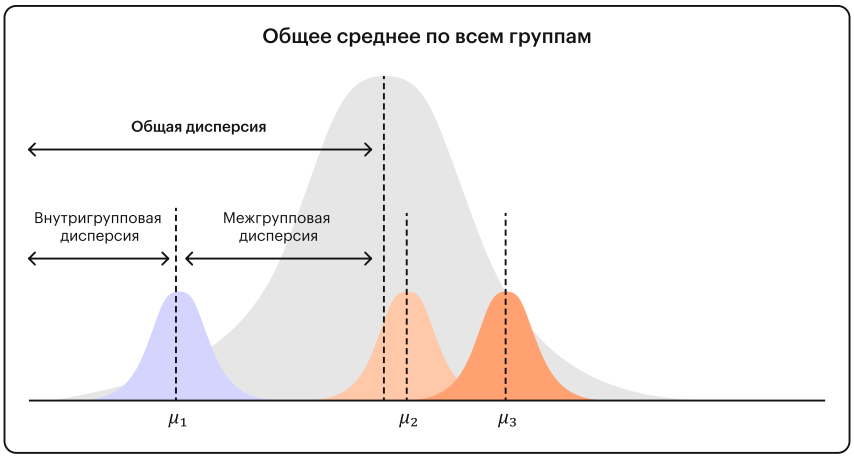

Рисунок 213. ANOVA. Визуализация плотностей

Теперь рассмотрим пример с визуализациями для трёх потенциально возможных кейсов.

Пример 12.4.1.

Если групповые распределения (и, соответственно, их средние находятся далеко друг от друга, то межгрупповая дисперсия значительно превосходит среднюю внутригрупповую дисперсию и мы получаем больше значение F-статистики, которое попадает в хвост распределения Фишера.

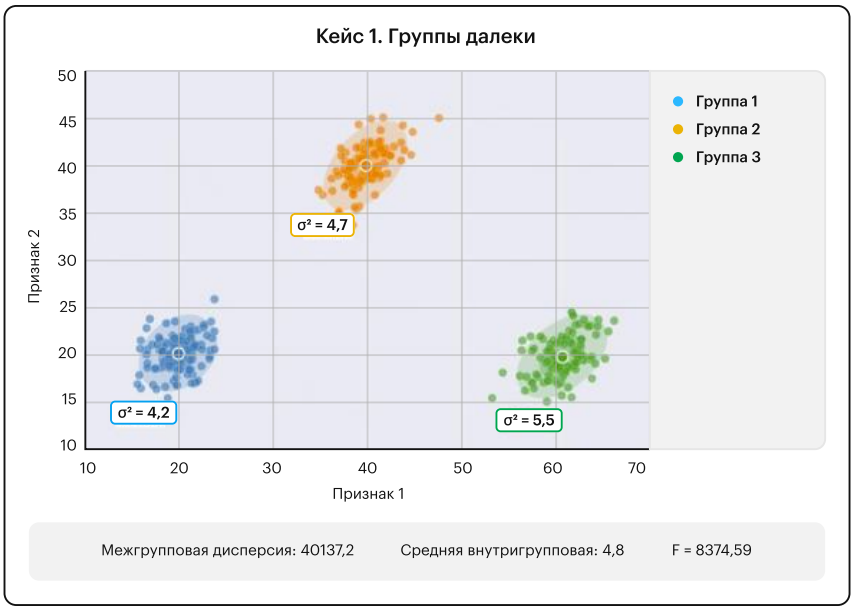

Рисунок 214. ANOVA. Визуализация scatter plot. Кейс далёких групп

Пример 12.4.2.

При сближении групп наблюдаем падение F-значения ввиду приближения внутригрупповой дисперсии к межгрупповой. При достижении достаточной близости F-значение может приближаться к границе критической зоны ANOVA F-теста.

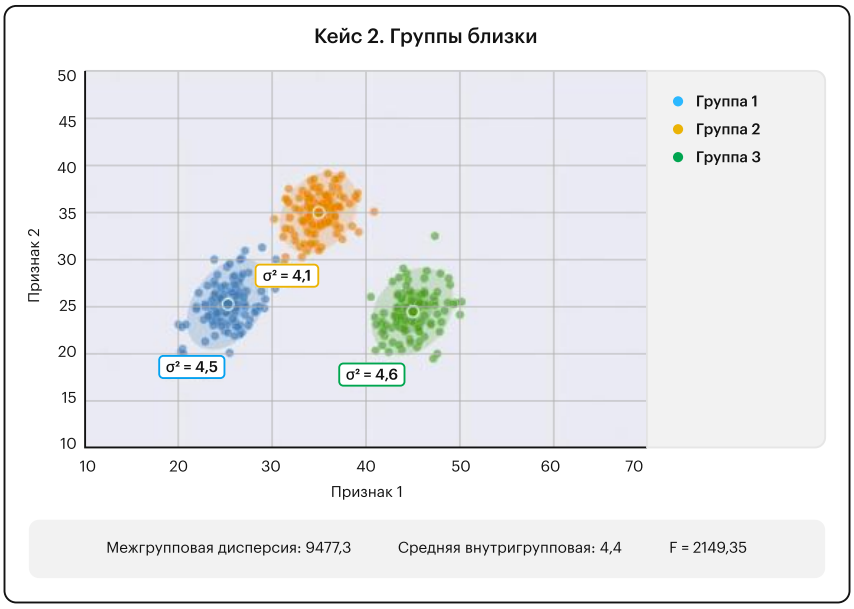

Рисунок 215. ANOVA. Визуализация scatter plot. Кейс средних групп

Пример 12.4.3.

В случае очень близких групп (и, соответственно, малом отличии групповых средних от общего среднего) получаем маленькое F-значение, которое попадает в зону принятия гипотезы. В таком случае делаем вывод об отсутствии статистически значимой разницы между группами.

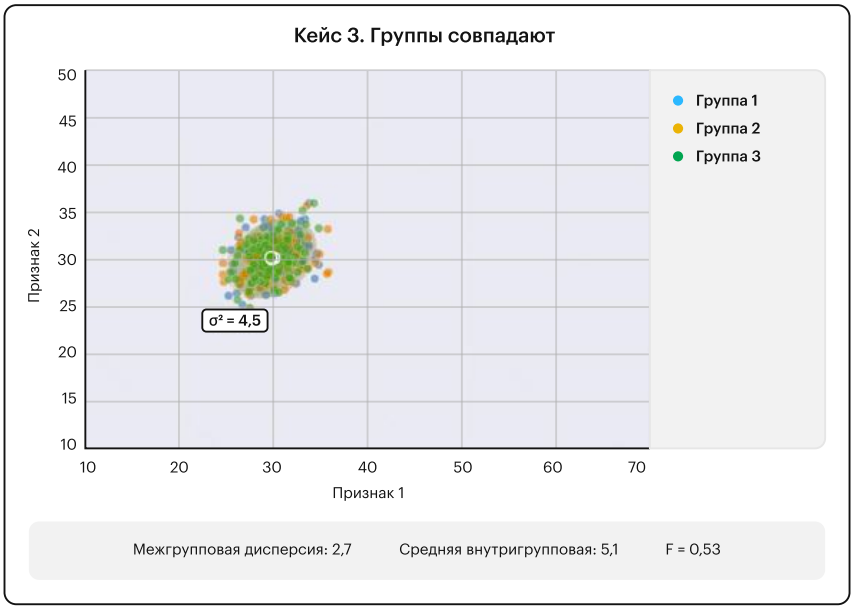

Рисунок 216. ANOVA. Визуализация scatter plot. Кейс близких групп

При проведении множественных продуктовых экспериментов можно сначала провести ANOVA F-тест, чтобы определить, существует ли хотя бы одна группа, которая статистически значимо отличается от остальных. Если хоть одна такая группа существу-

ет, то можем перейти к попарному сравнению с помощью, например, t-теста, не забывая при этом о поправке на множественное тестирование.

Часть 13. Выборочная корреляция

1. ВВЕДЕНИЕ В ВЫБОРОЧНУЮ КОРРЕЛЯЦИЮ

Допустим, у нас есть два экономических показателя: цена на нефть и цена на бензин. Эти два показателя тесно связаны между собой, и во многие моменты времени они «движутся в унисон». Если цена на нефть идёт вверх, то и цена на бензин в среднем растёт.

Обратный пример — безработица и инфляция. Исторически известно, что эти показатели чаще всего имеют противоположную динамику: чем выше безработица, тем ниже инфляция. И наоборот: чем выше инфляция, тем ниже безработица. В данном случае мы имеем обратную зависимость двух случайных величин.

Начнём со **свойства аддитивности**. Говорят, что функция f аддитивна по параметру, если

$$f(x+y) = f(x) + f(y).$$

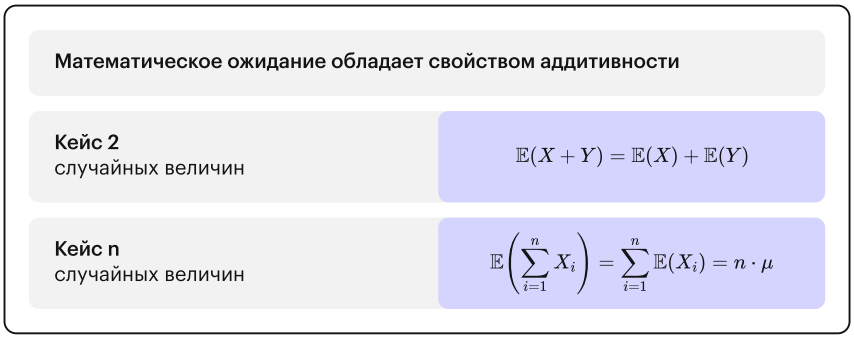

Рисунок 217. Аддитивность матожидания

А вот дисперсия может не обладать свойством аддитивности: действительно, пусть X и Y — квадрат-интегрируемые случайные величины, т.е. $X, Y \in L^2(\mathbb{R})$:

$$\mathbb{E}X^2 < \infty, \quad \mathbb{E}Y^2 < \infty.$$

Рассмотрим дисперсию их суммы:

$$\mathrm{Var}(X+Y) = \mathbb{E}(X + Y - \mathbb{E}(X+Y))^2.$$

Раскрывая скобки, получаем:

$$\mathbb{D}(X+Y) = \mathbb{E}X^2 + \mathbb{E}Y^2 + 2\mathbb{E}(XY) - (\mathbb{E}X)^2 - (\mathbb{E}Y)^2 - \\ - 2(\mathbb{E}X)(\mathbb{E}Y) = \mathbb{D}X + \mathbb{D}Y + 2Cov(X,Y),$$

Формула дисперсии суммы зависимых случайных величин:
$\mathbb{D}(X+Y) = \mathbb{D}X + \mathbb{D}Y + 2Cov(X,Y)$.

Формула подсказывает, почему игнорирование зависимости систематически искажает оценку риска и неопределённости: при положительной зависимости дисперсия суммы возрастает, а при отрицательной — снижается, вплоть до частичной компенсации колебаний. В частности, для портфеля из двух активов при одинаковых дисперсиях минимальная дисперсия достигается при максимально отрицательной корреляции; это лежит в основе диверсификации. Заметим и граничные случаи: если $Y = \alpha + \beta X$, то $Cov(X,Y) = \beta\,\mathbb{D}X$ и $\mathbb{D}(X+Y) = \mathbb{D}X + \mathbb{D}Y + 2\beta\,\mathbb{D}X$, что подчёркивает чувствительность суммы к линейной связи. В многомерном случае дисперсия суммы $\sum_i X_i$ равна сумме всех элементарных дисперсий и парных ковариаций, то есть $\mathbb{D}(\sum_i X_i) = \sum_i \mathbb{D}X_i + 2\sum_{i<j} Cov(X_i, X_j)$; матрично это записывается как $1^\top \Sigma 1$.

Ковариация характеризует совместную линейную изменчивость двух случайных величин. Если с ростом одной величины растёт и другая, то ковариация положительная. Если с ростом величины другая убывает, то ковариация отрицательная. Хочется сказать, что для независимых величин ковариация равна нулю — и это действительно так! Так что для независимых величин дисперсия тоже аддитивна. Но может быть и такое, что ковариация равна нулю, а величины зависимы. Для таких величин, тем не менее, дисперсия всё ещё будет аддитивной.

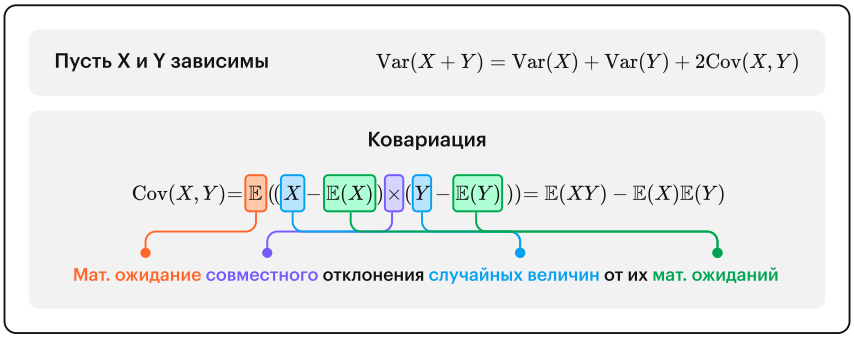

Рисунок 218. Формула ковариации

Ковариационная матрица — это симметричная положительно-полуопределённая матрица Σ, где $\Sigma_{ij} = Cov(X_i, X_j)$, диагональ содержит дисперсии $\mathbb{D}X_i$, а вне диагонали — ковариации.

ОПРЕДЕЛЕНИЕ 13.1.1

По ковариации, однако, нельзя сказать, как сильно величины зависят друг от друга. Если у одной пары величин ковариация больше, чем у другой, это может ещё ничего не означать — воз-

можно, просто первая пара принимает большие значения, только и всего. Необходима нормированная метрика.

На ковариацию полезно смотреть как на аналог скалярного произведения из линейной алгебры: если величины сонаправлены, произведение положительно, а если перпендикулярны, то равно нулю. В линейной алгебре мерой зависимости выступает не само скалярное произведение, а косинус угла между векторами, который определяется как

$$\cos(\boldsymbol{x}, \boldsymbol{y}) = \frac{(\boldsymbol{x}, \boldsymbol{y})}{\sqrt{|\boldsymbol{x}|^2 |\boldsymbol{y}|^2}}.$$

Точно так же и со случайными величинами есть аналог косинуса, который называется **коэффициентом корреляции** и обозначается

$$r(X, Y) := \frac{Cov(X, Y)}{\sqrt{\mathbb{D}X \cdot \mathbb{D}Y}}.$$

Так же, как и косинус, этот коэффициент принимает значения от -1 до 1 и служит нормированной мерой линейной зависимости.

Ковариация $Cov(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)] = \mathbb{E}XY - \mathbb{E}X\mathbb{E}Y$. Положительная — прямая зависимость, отрицательная — обратная, ноль — для независимых.

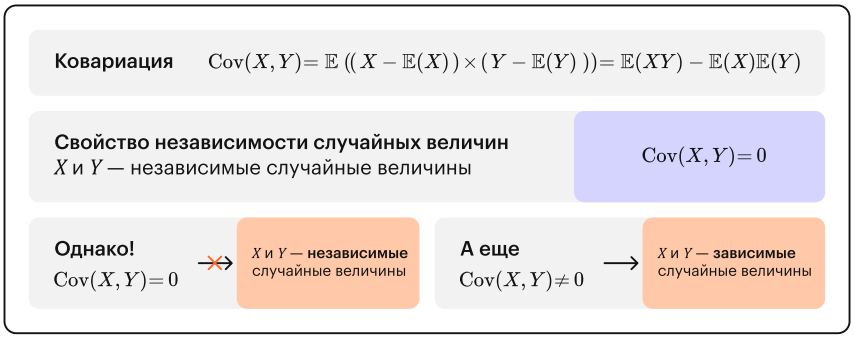

Рисунок 219. Ковариация и зависимость

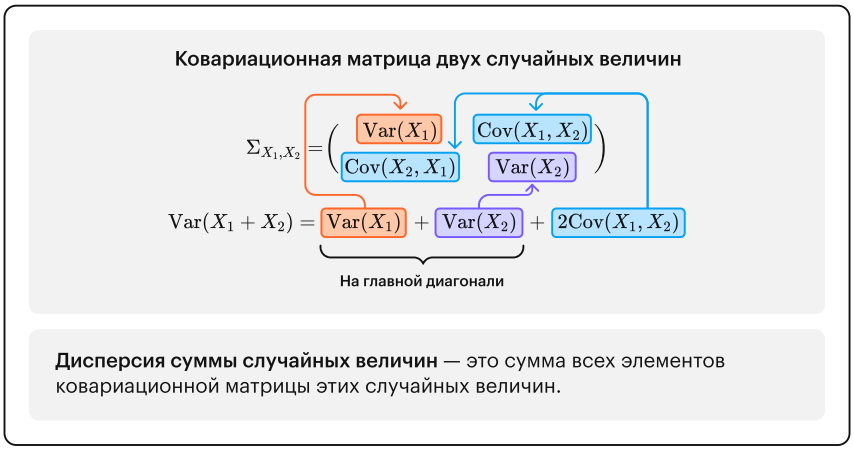

Рисунок 220. Ковариационная матрица на примере двух случайных величин

Положительная полуопределённость Σ означает, что для любого вектора весов w верно $w^\top \Sigma w \geqslant 0$, что интерпретируется как неотрицательность дисперсии любой линейной комбинации $\sum_i w_i X_i$. Для стандартизованных переменных $Z_i = (X_i - \mathbb{E}X_i)/\sqrt{\mathbb{D}X_i}$ ковариационная матрица переходит в корреляционную матрицу с единицами на диагонали; она также положительно-полуопределённа и удобна для сравнения сил связи на единой шкале. Важный практический момент: ковариация чувствительна к масштабу и единицам измерения, а потому её стоит использовать для прогнозирования вариации суммы/портфеля, но не для ранжирования «силы» ассоциации без нормировки.

2. ВЫБОРОЧНАЯ ЛИНЕЙНАЯ КОРРЕЛЯЦИЯ ПИРСОНА

Допустим, имеются две выборки X, Y одного размера. Теперь мы не знаем их истинные распределения, но хотим каким-то образом оценивать зависимость данных. Первое, что приходит в голову: ввести выборочный аналог ковариации и корреляции. Итак, **выборочной ковариацией** называется

$$C_{X,Y} := \frac{\sum_{i=1}^n (X_i - \overline{X})(Y_i - \overline{Y})}{n} = \overline{XY} - \overline{X} \cdot \overline{Y}.$$

По аналогии с обычной ковариацией выборочная ковариация сама по себе не является мерой зависимости данных, и нужно придумать что-то ещё. Здесь уже есть много разных способов. Вот один из тех, который тоже первым приходит в голову.

От выборочной ковариации к выборочной линейной корреляции Пирсона

ОПРЕДЕЛЕНИЕ 13.2.1

Линейная корреляция Пирсона — это выборочный коэффициент корреляции, который используется для измерения силы и направления (положительного или отрицательного) линейной связи между двумя переменными:

$$r_{X,Y} := \frac{C_{X,Y}}{\sqrt{S_X^2 S_Y^2}}.$$

Экстремальные значения 1 и -1 достигаются, когда ряды X и Y представляют собой модель линейной зависимости, то есть можно найти такие α и β, что $Y = \alpha + \beta X$.

Выборочная ковариация $C_{X,Y} = \overline{XY} - \overline{XY}$. Линейная корреляция Пирсона $r_{X,Y} = \frac{C_{X,Y}}{\sqrt{S_X^2 S_Y^2}} \in [-1, 1]$.

В практических вычислениях часто используют несмещённые выборочные дисперсии с делением на $(n-1)$; тогда согласованно определяют ковариацию как сумму попарных отклонений,

делённую на $(n-1)$. Это меняет масштаб, но не меняет само r, так как нормировка в числителе и знаменателе согласована. Коэффициент Пирсона измеряет именно линейную зависимость и может быть близок к нулю при сильной нелинейной связи (например, U-образной). На данных с выбросами r нестабилен: одиночные экстримальные точки способны радикально изменить оценку; в таких ситуациях стоит рассмотреть ранговые методы или робастные корреляции (например, би-С-оценки, корреляцию по медианам).

Пример 13.2.1. Рассмотрим выборку точек на плоскости и проанализируем характер зависимости между переменными X и Y.

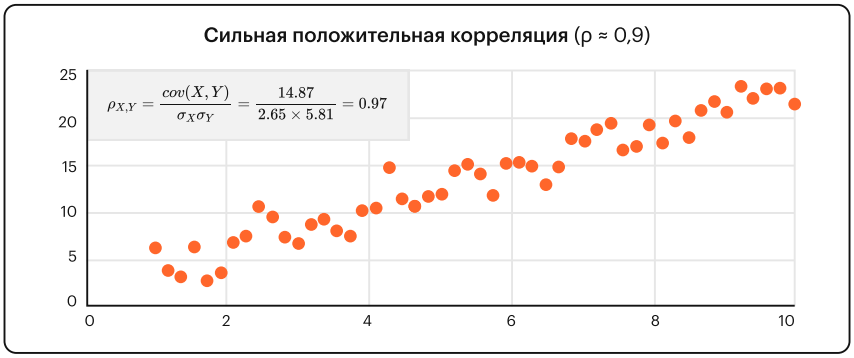

Рисунок 221. Пример сильной положительной линейной корреляции

Мы видим, что точки располагаются вдоль возрастающей прямой, что указывает на сильную положительную линейную зависимость: при увеличении X значения Y также растут. Это подтверждается высоким значением коэффициента корреляции Пирсона $r \approx 0.97$.

Пример 13.2.2. Теперь рассмотрим выборку точек на плоскости и проанализируем характер зависимости между переменными X и Y.

Рисунок 222. Пример сильной отрицательной линейной корреляции

Мы видим, что точки располагаются вдоль убывающей прямой: при увеличении X значения Y систематически уменьшаются.

Это свидетельствует о сильной отрицательной линейной зависимости, что подтверждается значением коэффициента корреляции Пирсона $r \approx -0.96$.

Пример 13.2.3. Рассмотрим выборку точек на плоскости и проанализируем характер зависимости между переменными X и Y.

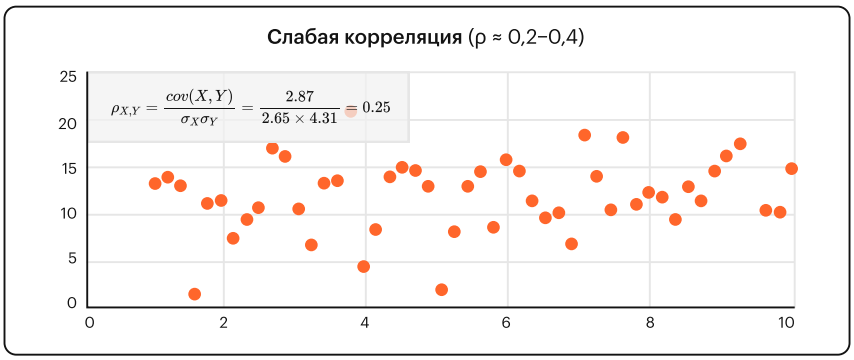

Рисунок 223. Пример слабой линейной корреляции

Мы видим, что точки распределены достаточно хаотично, без ярко выраженной линейной структуры. Наблюдается лишь слабая тенденция к росту Y при увеличении X, что соответствует малому значению коэффициента корреляции Пирсона $r \approx 0.25$.

Пример 13.2.4. Рассмотрим распределение на рисунке и проанализируем характер зависимости между переменными.

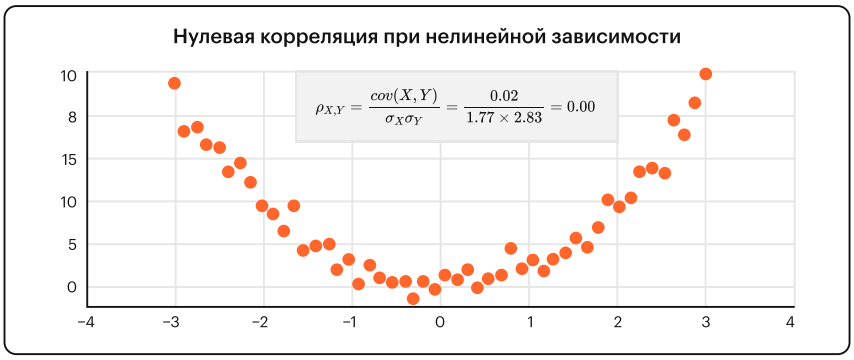

Рисунок 224. Пример нулевой корреляции при нелинейной зависимости

Мы видим, что несмотря на явную функциональную (параболическую) зависимость между переменными, коэффициент линейной корреляции Пирсона близок к нулю. Это связано с тем, что ковариация фиксирует только линейную компоненту взаимосвязи, и симметрия распределения относительно оси приводит к взаимному сокращению вкладов. Данный пример иллюстрирует, что $r_{X,Y} = 0$ не эквивалентно независимости и не исключает наличие детерминированной, но нелинейной зависимости.

Пример 13.2.5. Рассмотрим влияние выбросов на оценку корреляции между переменными.

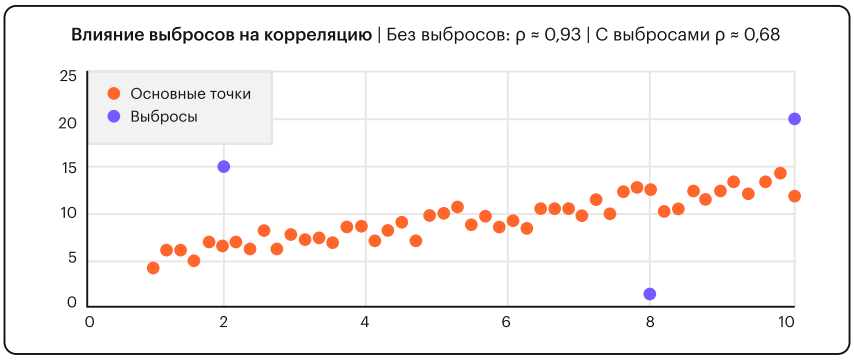

Рисунок 225. Влияние выбросов на коэффициент корреляции

Мы видим, что без выбросов наблюдается сильная положительная линейная зависимость ($r \approx 0.93$). Однако добавление нескольких выбросов существенно снижает значение коэффициента корреляции ($r \approx 0.68$). Это демонстрирует чувствительность коэффициента Пирсона к аномальным наблюдениям и подчеркивает необходимость предварительного анализа данных на наличие выбросов.

Шкала Чеддока

Шкала Чеддока

Если p-value меньше 0.05 (уровня значимости), то корреляция обнаружена. Дальше необходимо вынести решение о силе статистической взаимосвязи. Для этого используется шкала Чеддока. Она позволяет **интервалировать** (бинировать) модульные значения корреляции.

Чем ближе модульное значение к единице, тем выше статистическая взаимосвязь между показателями.

Общепринятой считается следующая разбивка на шкале:

Рисунок 226. Шкала Чеддока

Эта шкала — эвристика, а не универсальный закон: интерпретация величин $|r|$ зависит от предметной области, дизайна и уровня шума.

К тому же немаловажную роль играет **значимость** корреляции.

Проверка значимости корреляции Пирсона

Статистическая значимость корреляции Пирсона

Коэффициент корреляции Пирсона похож на распределение Стьюдента с $(n-2)$ степенями свободы

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} \sim t_{n-2}$$

где r — коэффициент корреляции Пирсона, а n — размер выборки.

Знак расчётной статистики определяется знаком самого коэффициента корреляции. Чем больше количество наблюдений, тем больше мы верим нашему значению корреляции.

При расчёте значения t имеем нулевую и альтернативную гипотезы:

$$H_0 : r = 0, \qquad H_1 : r \neq 0.$$

Формула t-критерия для значимости корреляции Пирсона: $t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} \sim t_{n-2}$.

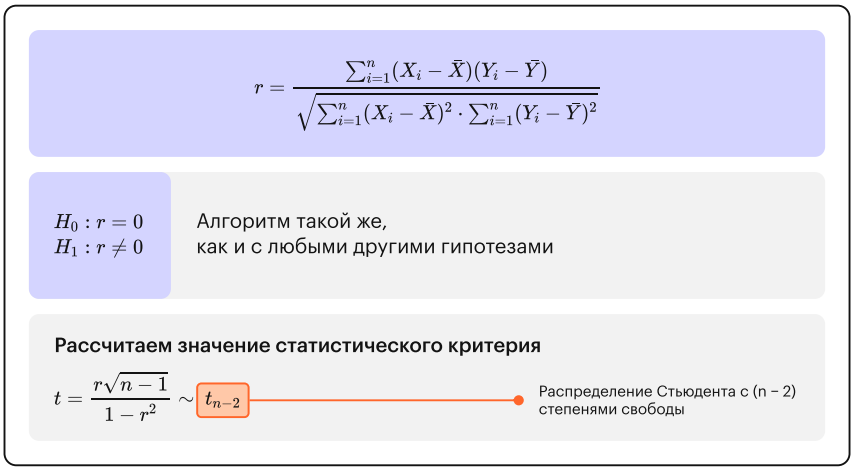

Рисунок 227. Формула t-статистики для определения значимости линейной корреляции Пирсона

Вывод тестовой статистики опирается на нормальность ошибок линейной регрессии и эквивалентен t-тесту для коэффициента наклона в модели $Y = \alpha + \beta X + \varepsilon$. Односторонние альтернативы применимы, если заранее сформулирован ожидаемый знак ассоциации. Важны предпосылки: независимость наблюдений, отсутствие значимых выбросов, приблизительная эллиптичность облака точек. При множественных проверках корреляций по многим парам переменных необходимо корректировать уровень значимости (Bonferroni, Holm, BH), иначе резко возрастает доля ложноположительных результатов. Интервалы для *r* удобно строить через трансформацию Фишера $z = \frac{1}{2}\ln\frac{1+r}{1-r}$: примерно $z \sim \mathcal{N}\left(\frac{1}{2}\ln\frac{1+r}{1-r}, \frac{1}{n-3}\right)$, а затем обратить трансформацию к шкале

корреляции.

Пример 13.2.6. Проанализируем взаимосвязь между переменными на представленном графике рассеяния, где объём выборки весьма ограничен.

[]

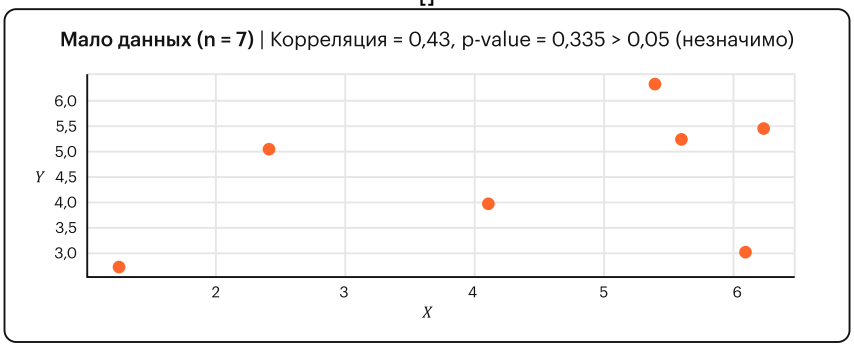

Рисунок 228. Пример линейной корреляции Пирсона на малой выборке

Наблюдается умеренная положительная корреляция ($r = 0.43$), однако из-за малого числа наблюдений ($n = 7$) полученное значение p-value (0.335) превышает стандартный уровень значимости 0.05. Это указывает на то, что обнаруженная статистическая зависимость является незначащей и может быть случайной.

Изучим положение наблюдаемого критерия на графике плотности вероятности t-распределения Стьюдента с пятью степенями свободы.

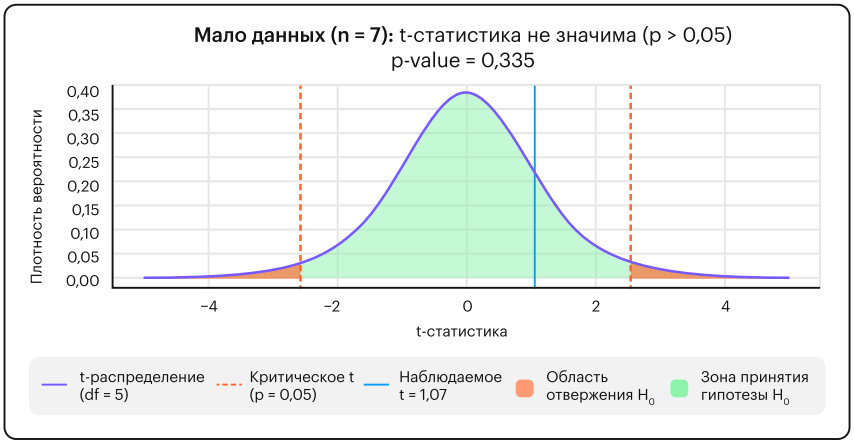

Рисунок 229. Проверка значимости линейной корреляции Пирсона на малой выборке

График демонстрирует, что наблюдаемое значение $t = 1.07$ находится ближе к центру распределения и не попадает в критическую область (область отвержения нулевой гипотезы H_0). Поскольку расчетный показатель лежит в пределах критических границ, а p-value $= 0.335$ существенно больше порогового уровня 0.05, t-статистика признается статистически незначащей.

Пример 13.2.7. Оценим характер распределения признаков на диаграмме рассеяния в условиях работы с достаточно большой выборкой данных.

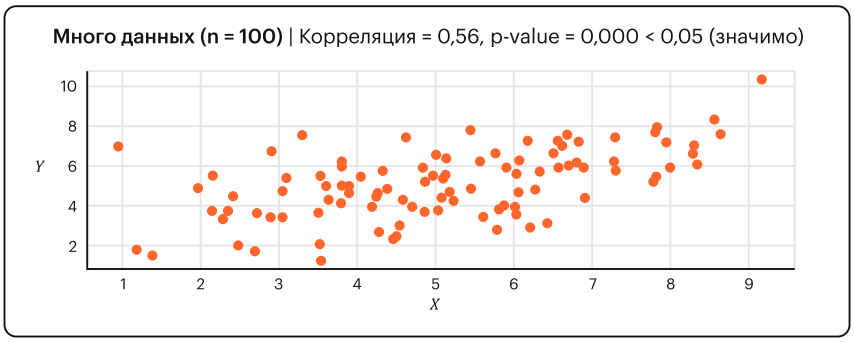

Рисунок 230. Пример линейной корреляции Пирсона на большой выборке

Здесь отчетливо видна выраженная положительная линейная тенденция. Коэффициент корреляции составляет 0.56, а расчетное значение p-value $= 0.000$ оказывается строго меньше критической отметки 0.05. Таким образом, при объёме выборки $n = 100$ выявленная взаимосвязь между переменными является статистически значимой и не может быть списана на случайные колебания.

Сформулируем проверяемые статистические гипотезы и разберём математическую структуру критерия для оценки значимости линейной связи.

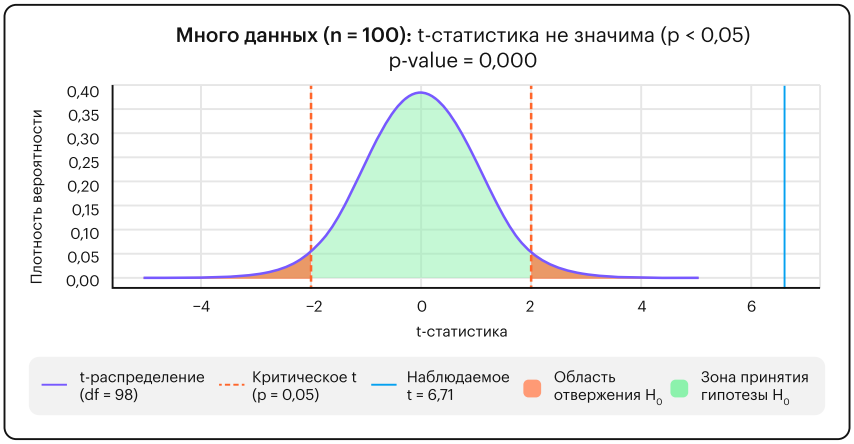

Рисунок 231. Проверка значимости линейной корреляции Пирсона на большой выборке

Базовые гипотезы утверждают отсутствие ($H_0 : r = 0$) или наличие ($H_1 : r \neq 0$) корреляции в генеральной совокупности. Из представленных соотношений напрямую вытекают важные свойства критерия: рост объёма выборки n или увеличение модуля коэффициента корреляции r закономерно приводят к увеличению значения t-статистики, что влечёт за собой уменьшение величины p-value. Кроме того, при стремлении силы связи к своему пре-

делу ($|r| \to 1$) значение критерия лавинообразно устремляется к бесконечности.

3. РАНГОВАЯ КОРРЕЛЯЦИЯ СПИРМЕНА

Многие тесты и методы в статистике можно разделить на два больших типа, опираясь на методику расчёта.

- **Абсолютные/численные типы** используют расчёт на основании самих значений выборки(-ок).
- **Ранговые типы** используют расчёт на основании рангов выборки(-ок) (то есть важны не сами значения, а их места в массиве данных).

ОПРЕДЕЛЕНИЕ 13.3.1

Рангом $R_i(X)$ элемента X_i в выборке X называется его номер в упорядоченном ряду выборки.

ОПРЕДЕЛЕНИЕ 13.3.2

Коэффициентом корреляции Спирмена называется ранговый коэффициент корреляции. Формально, обозначим $R_i := R_i(X)$ и $S_i := R_i(Y)$, тогда

$$r^S_{X,Y} := \frac{\sum(R_i - \overline{R})(S_i - \overline{S})}{\sqrt{\sum(R_i - \overline{R})^2}\sqrt{\sum(S_i - \overline{S})^2}} = 1 - 6\frac{\sum(R_i - S_i)^2}{n^3 - n}.$$

Алгоритм расчёта корреляции Спирмена.

1. Для каждого элемента проставим его ранг в соответствии с его положением в сортировке той или иной выборки. Произведём эти действия по отдельности для каждой выборки. Тогда для каждого наблюдения получим два значения ранга: d_i^X и d_i^Y. Рассчитаем для каждого наблюдения разницу $d_i := d_i^X - d_i^Y$.
2. Определим сумму квадратов d_i: вычислим $\sum_{i=1}^n d_i^2$.
3. Рассчитаем значение корреляции Спирмена по формуле:

$$r^S = 1 - 6\frac{\sum_{i=1}^n d_i^2}{n^3 - n}.$$

Она отрабатывает лучше корреляции Пирсона при наличии выбросов.

Корреляция Спирмена — ранговый аналог Пирсона: $r^S = 1 - 6\frac{\sum d_i^2}{n(n^2-1)}$. Устойчива к выбросам.

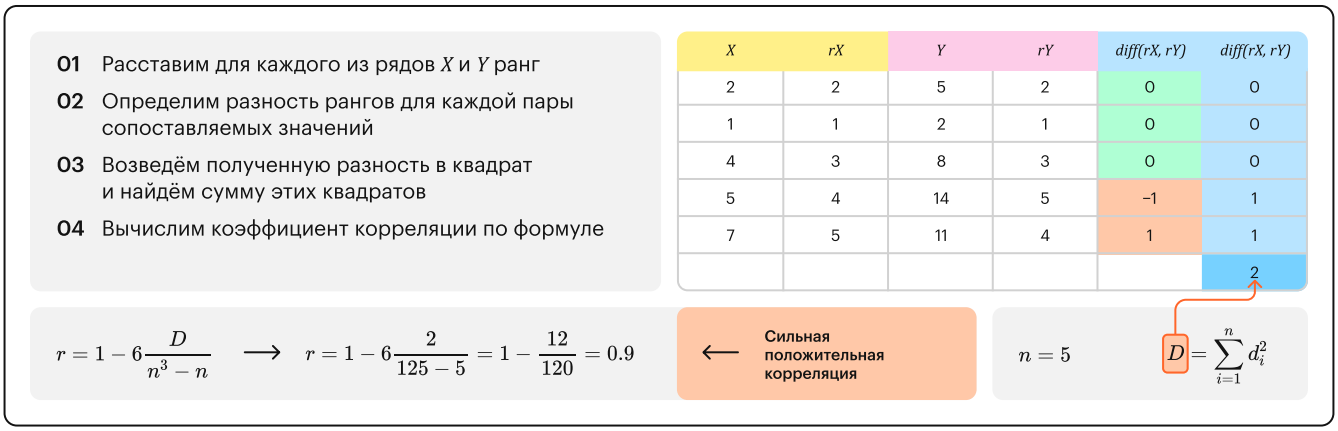

Рисунок 232. Алгоритм расчёта ранговой корреляции Спирмена

Спирмен фактически применяет Пирсона к рангам, отсюда робастность к монотонным нелинейностям: любая монотонная трансформация исходных значений не меняет ранги, а значит, и оценку. При наличии связок (ties) в рангах используют усреднённые ранги; точные формулы дисперсии и p-values корректируют на связки или прибегают к пермутационному тесту. В больших выборках статистика для проверки $H_0 : r^S = 0$ аппроксимируется t-критерием по аналогии с Пирсоном, но при малых n лучше использовать точные процедуры. Отличать Спирмена от Кендалла τ полезно методологически: τ интерпретируется через доли согласованных/несогласованных пар, даёт несколько иной баланс чувствительности к шуму и выбросам.

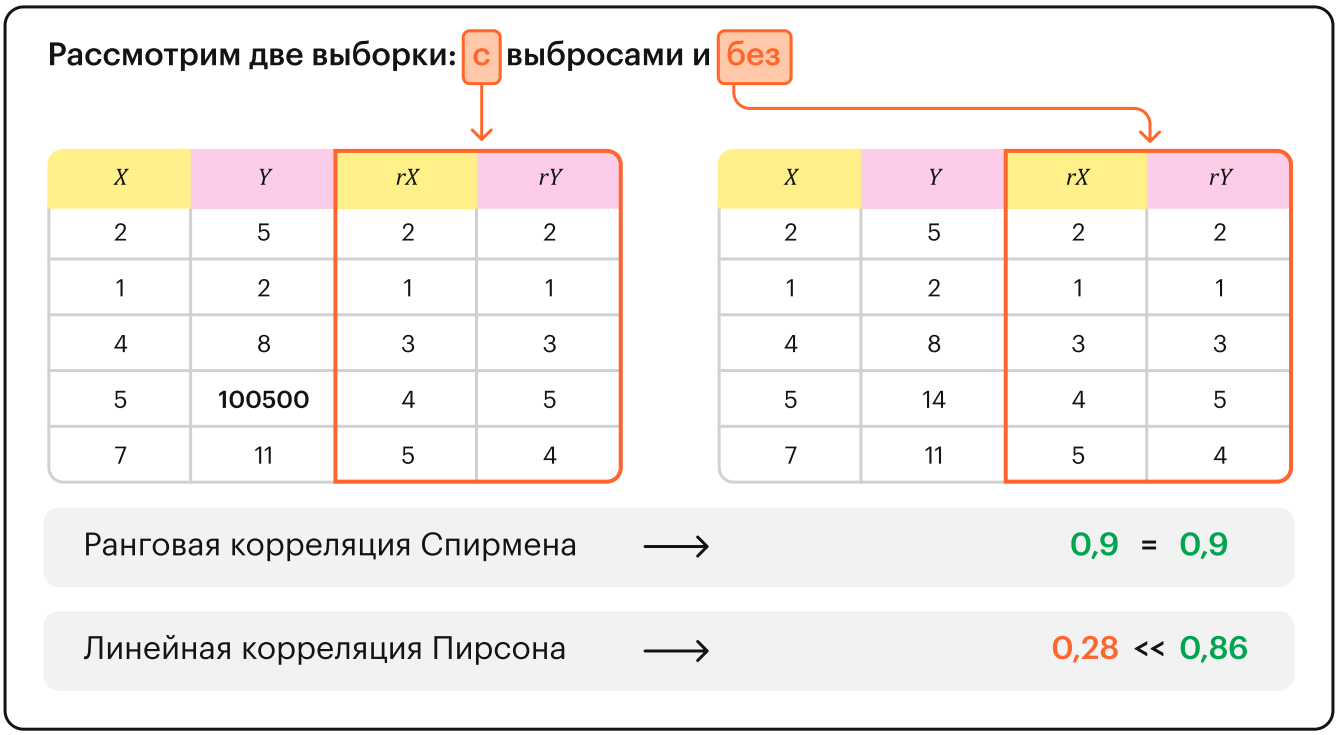

Рисунок 233. Влияние выбросов на корреляции Пирсона и Спирмена

4. ТАУ-КОРРЕЛЯЦИЯ КЕНДАЛЛА

Если корреляция Спирмена оценивает монотонную связь через разности рангов, то метод Кендалла подходит к анализу иначе. Он базируется на подсчёте количества согласованных и несогласованных пар элементов в выборках.

ОПРЕДЕЛЕНИЕ 13.4.1

Пара наблюдений (X_i, Y_i) и (X_j, Y_j) называется **согласованной** (concordant), если $(X_i - X_j)(Y_i - Y_j) > 0$. Пара называется **несогласованной** (discordant), если $(X_i - X_j)(Y_i - Y_j) < 0$.

ОПРЕДЕЛЕНИЕ 13.4.2

Коэффициентом корреляции Кендалла (τ) называется величина, выражающая разность вероятностей согласованности и несогласованности пар. Для выборки без связок (совпадающих значений) она определяется как:

$$\tau = \frac{C - D}{\frac{1}{2}n(n-1)},$$

где C — количество согласованных пар, D — количество несогласованных пар, а в знаменателе указано общее число пар комбинаций из n по 2.

Алгоритм расчёта корреляции Кендалла.

1. Упорядочим элементы первой выборки X по возрастанию. Переставим элементы выборки Y так, чтобы они соответствовали новым позициям элементов X.
2. Для каждого элемента Y_i (начиная с первого) подсчитаем, сколько последующих элементов Y_j ($j > i$) больше него (это даст вклад в C) и сколько меньше него (вклад в D).
3. Просуммируем полученные значения по всей выборке, чтобы найти итоговые C и D.
4. Рассчитаем значение корреляции Кендалла по формуле:

$$\tau = \frac{2(C - D)}{n(n-1)}.$$

Этот коэффициент также является робастным и отлично работает на малых выборках.

Корреляция Кендалла — ранговая мера связи: $\tau = \frac{C-D}{n(n-1)/2}$. В отличие от Спирмена, напрямую интерпретируется через долю согласованных пар.

Поскольку Кендалл оперирует только знаками разностей, он, как и Спирмен, инвариантен к любым монотонным преобразованиям данных. При наличии совпадающих значений (связок) базовую формулу (τ_a) модифицируют до так называемой τ_b или τ_c, которые вводят штрафы за одинаковые ранги в знаменателе. Для проверки гипотезы $H_0 : \tau = 0$ при малых n применяют точное распределение Кендалла, а при росте n статистика быстро сходится к нормальному распределению.

Перейдём к выборочной корреляции Кендалла.

Пусть дана выборка из n наблюдений:

$$\{(x_1, y_1), \ldots, (x_n, y_n)\} \subset \mathbb{R}^2,$$

где все x_i попарно различны и все y_i попарно различны (для простоты исключим совпадения).

Рассмотрим множество всех неупорядоченных пар индексов:

$$\mathcal{P} = \{(i, j) \mid 1 \leqslant i < j \leqslant n\}, \quad |\mathcal{P}| = \frac{n(n-1)}{2}.$$

Для каждой пары (i, j) введём знак согласованности:

$$s_{ij} = \operatorname{sign}\big((x_i - x_j)(y_i - y_j)\big),$$

где

$$\operatorname{sign}(t) = \begin{cases} +1, & t > 0, \\ -1, & t < 0. \end{cases}$$

- $s_{ij} = +1$ означает, что порядок точек по x и по y совпадает (согласованная пара).
- $s_{ij} = -1$ означает, что порядок противоположен (несогласованная пара).

Обозначим:

$$C = \#\{(i, j) \in \mathcal{P} \mid s_{ij} = +1\}, \quad D = \#\{(i, j) \in \mathcal{P} \mid s_{ij} = -1\}.$$

Тогда коэффициент Кендалла определяется как нормированная сумма знаков:

$$\tau = \frac{1}{|\mathcal{P}|} \sum_{(i,j) \in \mathcal{P}} s_{ij} = \frac{C - D}{\frac{n(n-1)}{2}}.$$

Таким образом, τ — это не просто «статистика», а функционал на множестве всех пар точек:

$$\tau : (\mathbb{R}^2)^n \to [-1, 1],$$

который измеряет степень согласованности двух порядков:

$$\{x_i\} \quad \text{и} \quad \{y_i\}.$$

Фактически, τ можно интерпретировать как среднее значение знака попарного произведения разностей:

$$\tau = \mathbb{E}_{i<j}\left[\operatorname{sign}\big((x_i - x_j)(y_i - y_j)\big)\right].$$

Если упорядочить индексы по возрастанию x_i, то значения y_i индуцируют перестановку π. Тогда:

- согласованные пары соответствуют неинверсиям,
- несогласованные — инверсиям перестановки π.

Следовательно,

$$\tau = 1 - \frac{2 \cdot \mathrm{Inv}(\pi)}{\frac{n(n-1)}{2}},$$

где $\mathrm{Inv}(\pi)$ — число инверсий.

Коэффициент τ инвариантен относительно любых строго монотонных преобразований:

$$x_i \mapsto f(x_i), \quad y_i \mapsto g(y_i),$$

где f и g строго возрастающие функции. Это подчёркивает, что τ зависит только от порядковой структуры данных, а не от их метрики.

Краевые значения корреляции Кендалла интерпретируются так же, как и в других коэффициентах корреляции.

Каждая пара точек задаёт ориентированный отрезок. Знак s_{ij} показывает, сохраняется ли ориентация при переходе от оси x к оси y.

Тогда:

- $\tau = 1$ — полная согласованность (все отрезки «направлены одинаково»),
- $\tau = -1$ — полная антисогласованность,
- $\tau \approx 0$ — отсутствие глобальной структуры порядка.

Рассмотрим несколько примеров.

Пример 13.4.1. Давайте проанализируем характер распределения точек на графике ниже, чтобы качественно оценить взаимосвязь между исследуемыми переменными.

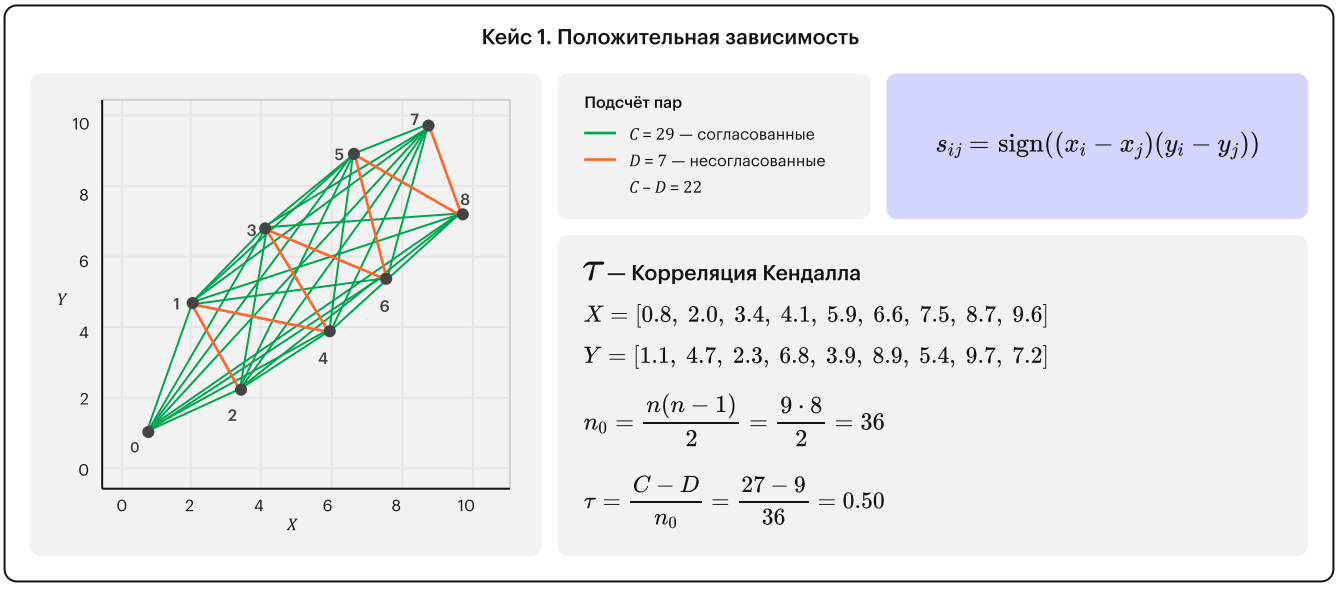

Рисунок 234. Положительная зависимость и корреляция Кендалла

На представленной схеме отчетливо прослеживается восходя-

щий тренд: с ростом значений по оси X в целом увеличиваются и значения по оси Y. Преобладание согласованных пар (зеленые линии) над несогласованными (оранжевые линии) математически подтверждает наличие умеренной положительной корреляции Кендалла ($\tau = 0.50$).

Пример 13.4.2. Проанализируем структуру данных, представленную на графике, чтобы выявить характер связи между переменными на примере малой выборки.

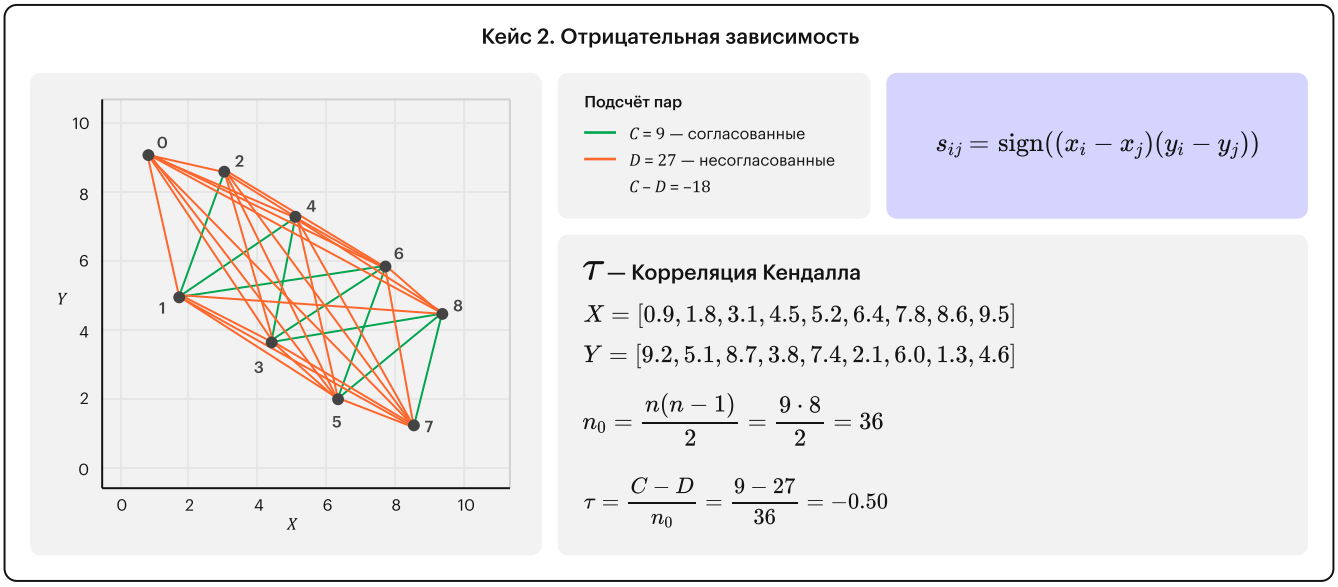

Рисунок 235. Отрицательная зависимость и корреляция Кендалла

На схеме наглядно продемонстрирована обратная (отрицательная) тенденция: с ростом значений признака X значения Y в целом убывают. Иллюстрация связей между точками показывает сильное преобладание несогласованных пар ($D = 27$) над согласованными ($C = 9$). В результате математического расчета по формуле коэффициента ранговой корреляции Кендалла $\tau = \frac{C-D}{n_0}$ мы получаем значение -0.50, что строго подтверждает наличие умеренной отрицательной зависимости в исследуемой выборке из 9 элементов.

Пример 13.4.3. Проанализируем взаимное расположение точек на графике, чтобы оценить характер и силу статистической связи между переменными с помощью коэффициента тау Кендалла.

Кейс 3. Связь отсутствует

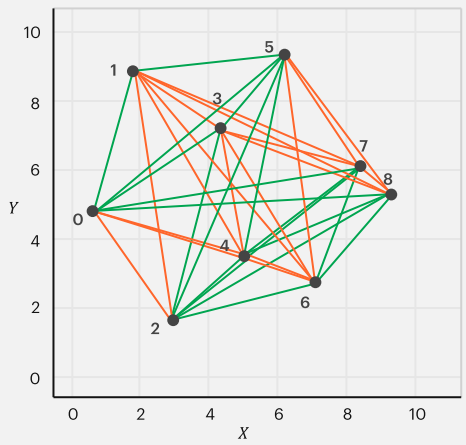

Подсчёт пар

$C = 18$ — согласованные

$D = 18$ — несогласованные

$C - D = 0$

$$s_{ij} = \text{sign}((x_i - x_j)(y_i - y_j))$$

$\mathcal{T}$ — Корреляция Кендалла

$$X = [0.7, 1.9, 3.0, 4.4, 5.1, 6.3, 7.2, 8.5, 9.4]$$

$$Y = [4.8, 8.9, 1.6, 7.2, 3.5, 9.4, 2.7, 6.1, 5.3]$$

$$n_0 = \frac{n(n-1)}{2} = \frac{9 \cdot 8}{2} = 36$$

$$\tau = \frac{C - D}{n_0} = \frac{18 - 18}{36} = 0$$

Рисунок 236. Отсутствие зависимости и корреляция Кендалла

На представленной схеме отчётливо заметно, что число согласованных пар ($C = 18$) в точности равно количеству несогласованных ($D = 18$). В результате их разность даёт ноль, из-за чего итоговый коэффициент корреляции Кендалла принимает значение $\tau = 0$, подтверждая полное отсутствие монотонной зависимости в данных.

5. БИНАРНАЯ КОРРЕЛЯЦИЯ МЭТЬЮСА

Корреляция бинарных величин

Корреляцию между бинарными показателями не стоит считать с помощью стандартных коэффициентов корреляции Спирмена или Пирсона.

Матрица значений бинарных величин

Чтобы определить, есть ли зависимость, нужно сначала посмотреть на *матрицу нулей и единиц*, или *True-False matrix*. Размер матрицы — 2 на 2. Каждая ячейка показывает количество наблюдений в рамках соответствующего сочетания нулей и единиц двух признаков:

$$\begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

Корреляция Мэтьюса рассчитывается по формуле:

ОПРЕДЕЛЕНИЕ 13.5.1

$$MCC_{X,Y} = \frac{ad - bc}{\sqrt{(a+b)(a+c)(b+d)(c+d)}}.$$

Если у всех элементов выборки значения признаков совпадают,

то $b = 0, c = 0$, и тогда $MCC = 1$.

Наоборот, если нет ни одного наблюдения с совпадающими значениями признака, то $a = 0, d = 0$, и тогда $MCC = -1$. Если коэффициент равен и близок к нулю, это означает, что корреляции между бинарными показателями нет.

Статистическая значимость корреляции Мэтьюса

В качестве нулевой гипотезы H_0 выступает $MCC = 0$.

Расчётная статистика распределена как хи-квадрат:

$$n\,MCC^2_{X,Y} \sim \chi^2_1.$$

Бинарная корреляция Мэтьюса: $MCC = \frac{ad-bc}{\sqrt{(a+b)(a+c)(b+d)(c+d)}}$.

Значимость: $n \cdot MCC^2 \sim \chi^2_1$.

Пример 13.5.1.

Рассмотрим задачу на расчёт корреляции между двумя бинарными признаками: пол и выбор во время голосования (демократы vs республиканцы).

Рассмотрим сначала наполнение матрицы частот и рассчитем коэффициент корреляции Мэтьюса.

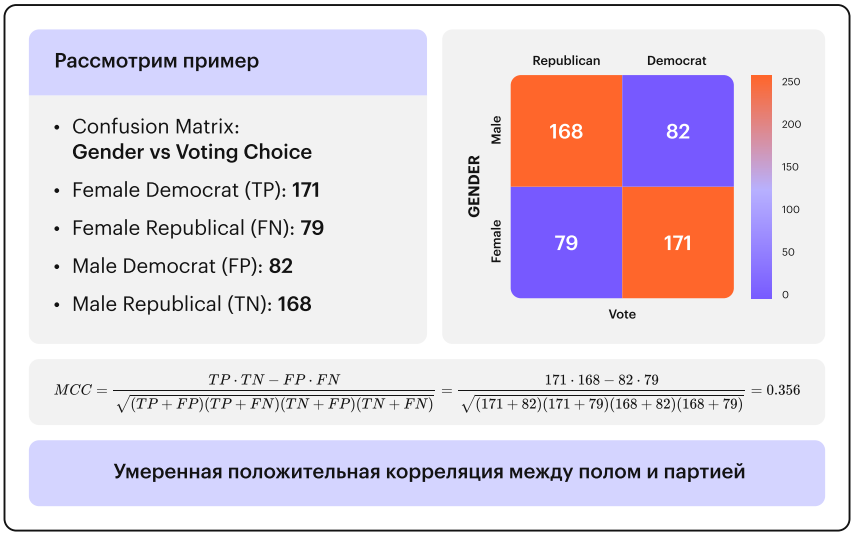

Рисунок 237. Пример расчёта корреляции Мэтьюса

Можем заметить параллели между данной задачей и хи-квадрат критерием Пирсона. В нём алгоритм заключался в расчёте "ожидаемой матрицы"и последующем сравнении двух матриц (O vs E).

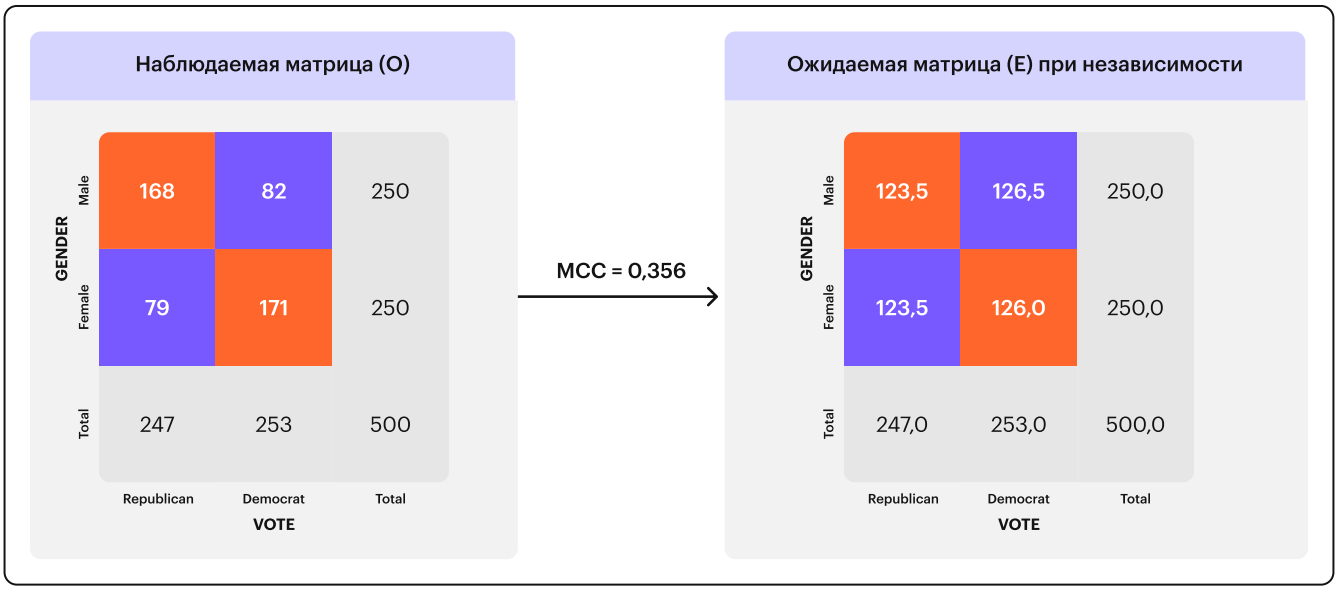

Рисунок 238. Матрица O и E и корреляция Мэтьюса

И действительно, мы можем получить MCC через расчётное значение статистики хи-квадрат.

$$\chi^2 = \sum_{i=1}^{2}\sum_{j=1}^{2}\frac{(O_{ij}-E_{ij})^2}{E_{ij}}$$

$$\chi^2 = \frac{(168-123.5)^2}{123.5} + \frac{(82-126.5)^2}{126.5} + \frac{(79-123.5)^2}{123.5} + \frac{(171-126.5)^2}{126.5} \approx 63.376$$

$$\chi^2 \sim \chi^2_1 \quad = \quad n \cdot MCC^2 \sim \chi^2_1$$

$$MCC = \text{sign}(O_{11}O_{22} - O_{12}O_{21}) \cdot \sqrt{\frac{\chi^2}{n}} = \text{sign}(168 \times 171 - 82 \times 79) \cdot \sqrt{\frac{63.376}{500}} \approx 0.356$$

Рисунок 239. Пример расчёта корреляции Мэтьюса, опираясь на статистику хи-квадрат

Также проверим значимость MCC.

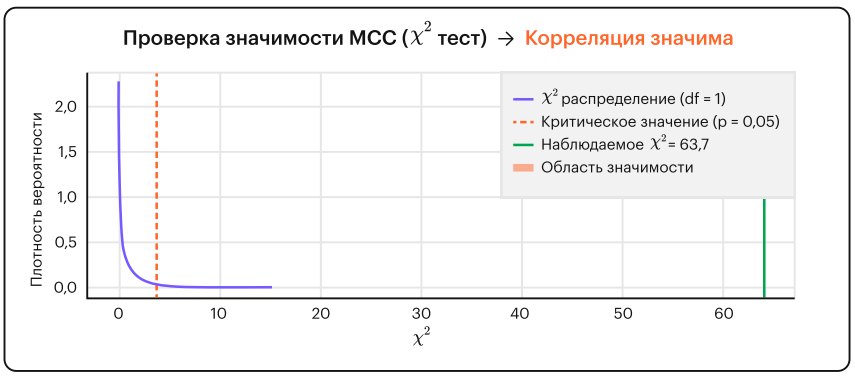

Рисунок 240. Статистическая значимость корреляции Мэтьюса через статистику хи-квадрат

Можем сделать вывод о том, что коэффициент корреляции Мэтьюса значим и составляет 0.356. Это небольшое значение, но его знак и значимость (а также кодировка значений признака единицами и нулями) говорят нам о там, что женщины чаще голосуют за демократов, а мужчины - за республиканцев.

MCC совпадает с коэффициентом корреляции Пирсона, рассчитанным на бинаризованных переменных, и симметричен относительно перестановки классов и предиктора/ответа, в отличие от точности, F1 и пр. Это делает MCC особенно полезным при сильном дисбалансе классов. При малых ожидаемых частотах в ячейках точнее применять точный двусторонний тест Фишера для проверки независимости, а MCC — как меру величины эффекта. В многоуровневых таблицах $K \times L$ естественным обобщением является коэффициент Крамера V; для 2×2 $V = \sqrt{\chi^2/n}$ связан с $|MCC|$, но MCC сохраняет информацию о знаке ассоциации, тогда как V — нет.

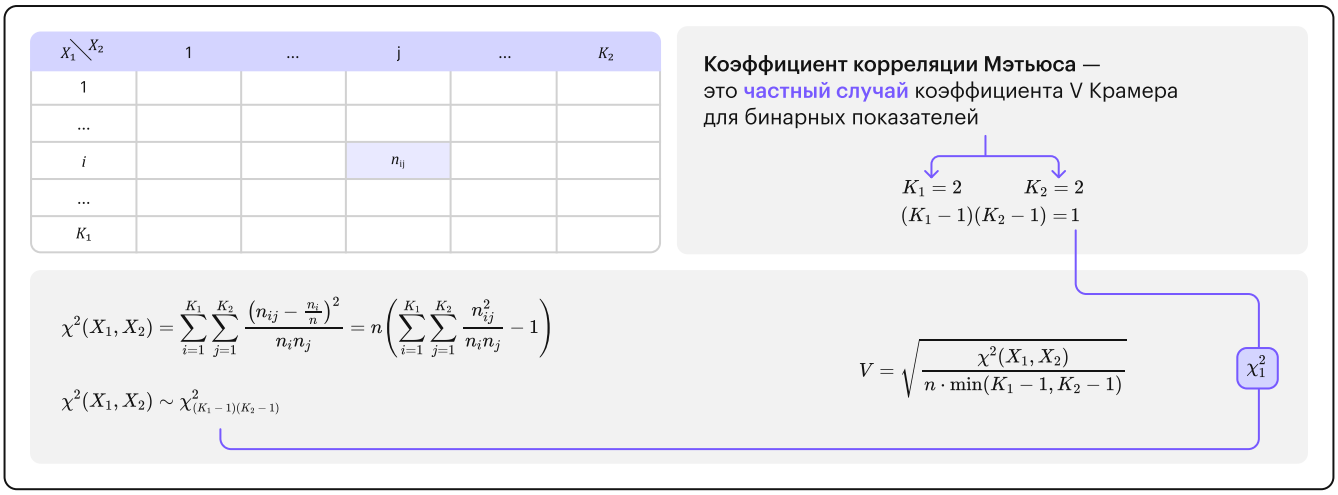

Рисунок 241. Связь корреляции Мэтьюса и коэффициента V Крамера

Для бинарных признаков $X, Y \in \{0, 1\}$ строят таблицу сопряжённости

$$\begin{bmatrix} a & b \\ c & d \end{bmatrix}, \quad N = a + b + c + d.$$

Независимость соответствует пропорциональности строк/столбцов, то есть ожидаемым частотам

$$E_{ij} = \frac{(\text{строка}_i)(\text{столбец}_j)}{N}$$

- **Коэффициент Мэтьюса (MCC):** $MCC = \dfrac{ad - bc}{\sqrt{(a+b)(a+c)(b+d)(c+d)}}$.
- **Тест значимости MCC:** $n\,MCC^2 \sim \chi^2_1$ при $H_0 : MCC = 0$.

Также можем применить стандартный хи-квадрат тест независи-

мости Пирсона:

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}, \quad \text{при } 2 \times 2 : \ d.f. = 1.$$

Для 2×2: и MCC, и χ^2-тест проверяют отсутствие ассоциации; при больших объёмах они согласованно выявляют зависимость.

На разбалансированных данных MCC даёт более честную оценку качества бинарной классификации, чем accuracy или F1, поскольку учитывает все четыре ячейки. При очень малых E_{ij} целесообразно объединять редкие категории или использовать точный тест Фишера. Связь с коэффициентом Фи (φ) такова: для 2×2 φ совпадает с MCC; а коэффициент Крамера V равен $|$| в 2×2 и обобщается на большие таблицы. Для интерпретации полезно приводить доверительные интервалы для MCC, например через бутстрэп, учитывая возможный дисбаланс классов.

Коэффициент Чупрова

Коэффициент Чупрова является мерой тесноты связи между двумя категориальными признаками и используется как нормированная версия статистики χ^2 для таблиц сопряжённости произвольного размера.

Пусть дана таблица сопряжённости размера $r \times c$, и χ^2 — значение критерия хи-квадрат Пирсона, а n — объём выборки. Тогда коэффициент Чупрова определяется следующим образом:

$$T = \sqrt{\frac{\chi^2}{n \cdot \sqrt{(r-1)(c-1)}}}.$$

Коэффициент T принимает значения в диапазоне $[0, 1]$, где:

- $T = 0$ соответствует отсутствию связи между признаками,
- значения, близкие к 1, указывают на сильную зависимость.

Следует отметить, что коэффициент Чупрова корректно учитывает размер таблицы сопряжённости, в отличие от, например, коэффициента контингенции Пирсона. Однако при сильно несбалансированных таблицах его интерпретация может быть затруднена.

Коэффициент Чупрова тесно связан с коэффициентом Крамера V и совпадает с ним в случае квадратных таблиц ($r = c$), однако в общем случае отличается способом нормировки.

6. КОРРЕЛЯЦИЯ И КАУЗАЦИЯ

Рассмотрим две случайные величины X и Y, заданные на одном вероятностном пространстве.

Мы знаем, что корреляция отражает *несводимость* совместного

распределения:

$$F_{X,Y}(x,y) \neq F_X(x)F_Y(y).$$

Введем определение каузации:

Говорят, что X каузально влияет на Y (обозначается $X \to Y$), если существует интервенция, изменяющая распределение Y:

$$\mathbb{P}(Y \in B \mid \mathrm{do}(X = x)) \neq \mathbb{P}(Y \in B)$$

для некоторого множества B и значения x.

- Корреляция является **необходимым** достаточным условием каузации:

$$X \to Y \;\Rightarrow\; r(X,Y) \neq 0 \quad \text{(в общем положении)}.$$

- Корреляция не является достаточным условием каузации:

$$r(X,Y) \neq 0 \;\not\Rightarrow\; X \to Y.$$

- Каузация не является необходимым условием корреляции:

$$r(X,Y) \neq 0 \quad \text{может возникать без причинной связи.}$$

- Каузация не является необходимым условием корреляции:

$$X \to Y \quad \text{не гарантирует } r(X,Y) \neq 0.$$

В общем случае справедливы следующие логические соотношения:

$$\text{корреляция} \;\not\Rightarrow\; \text{каузация},$$

$$\text{каузация} \;\Rightarrow\; \text{корреляция} \quad \text{(при отсутствии вырожденных случаев)}.$$

1. **Ложная корреляция (confounding).** Пусть существует третья величина Z, такая что:

   $$Z \to X, \quad Z \to Y.$$

   Тогда X и Y коррелированы, но причинной связи между ними нет.
2. **Нелинейная каузация без корреляции.** Пусть

   $$X \sim \mathcal{N}(0,1), \quad Y = X^2.$$

   Тогда

   $$X \to Y, \quad r(X,Y) = 0.$$

3. **Смешанные механизмы.** Если

$$Y = X + \varepsilon, \quad \mathbb{E}[\varepsilon \mid X] = 0,$$

то $X \to Y$ и $r(X, Y) \neq 0$, но величина корреляции не равна силе причинного эффекта.

Более кратко:

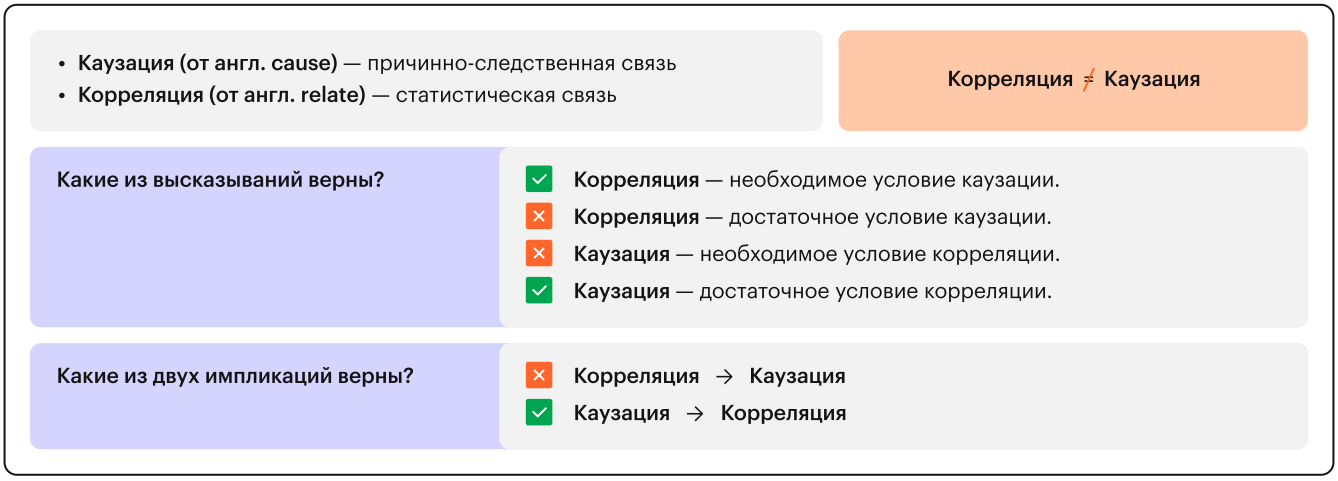

Рисунок 242. Корреляция и каузация

Корреляция и каузация — это объекты разной природы:

- корреляция — свойство *совместного распределения* (X, Y);
- каузация — свойство *интервенционной структуры* модели.

Формально:

$$\text{Correlation} = \mathcal{F}(P_{X,Y}), \quad \text{Causation} = \mathcal{F}(\{P_{Y|\mathrm{do}(X=x)}\}_x).$$

Пример 13.6.1. Вы работаете аналитиком в сервисе по изучению английского языка. Вы заметили, что те пользователи, которые чаще посещают раздел «Грамматика», имеют более высокий ретеншен, т. е. удержание и, как следствие, жизненный цикл. Значит ли это, что надо пушить пользователей посещать раздел «Грамматика»?

Нет, так как может быть третий фактор: те пользователи, которые более серьезно подходят к обучению, дольше живут и изучают грамматику.

Между высокой мотивацией и ретеншеном есть корреляция и каузация. Между высокой мотивацией и разделом «Грамматика» также есть корреляция и каузация. Однако между ретеншеном и разделом «Грамматика» существует только корреляция, а каузация (причинно-следственная связь) отсутствует.

Пример 13.6.2. Экономист Уильям Стэнли Джевонс в работе «Solar Period and the Price of Corn» предположил, что есть связь между пятнами на солнце и экономическими циклами.

Он обнаружил корреляцию между этими событиями. Однако это

не означает, что между ними есть каузация.

Пример 13.6.3.

Рассмотрим исследование 2016 года от журнала PLOS.

Гипотеза: Восприятие «булшита*» как глубокомысленного коррелирует с поддержкой консерваторов.

**Примечание: Нелогичное, неправдивое, бессодержательное политическое высказывание.*

Для проверки гипотезы оценивалась корреляция Спирмена между тягой к «булшиту» (ось X, шкала от 1 до 5) и уровнем поддержки различных политических лидеров (ось Y):

- (a) Поддержка Теда Круза
- (b) Поддержка Марка Рубио
- (c) Поддержка Дональда Трампа
- (d) Поддержка Хиллари Клинтон
- (e) Поддержка Берни Сандерса
- (f) Поддержка Мартина О'Мэлли

При анализе распределения опрошенных по политическим предпочтениям (ось X — Консервативность от 1 до 7, ось Y — количество ответов) выявляется явная несбалансированность классов. К тому же исходные признаки дискретны и имеют малое количество значений (от 1 до 5).

Результаты представлены на следующих графиках.

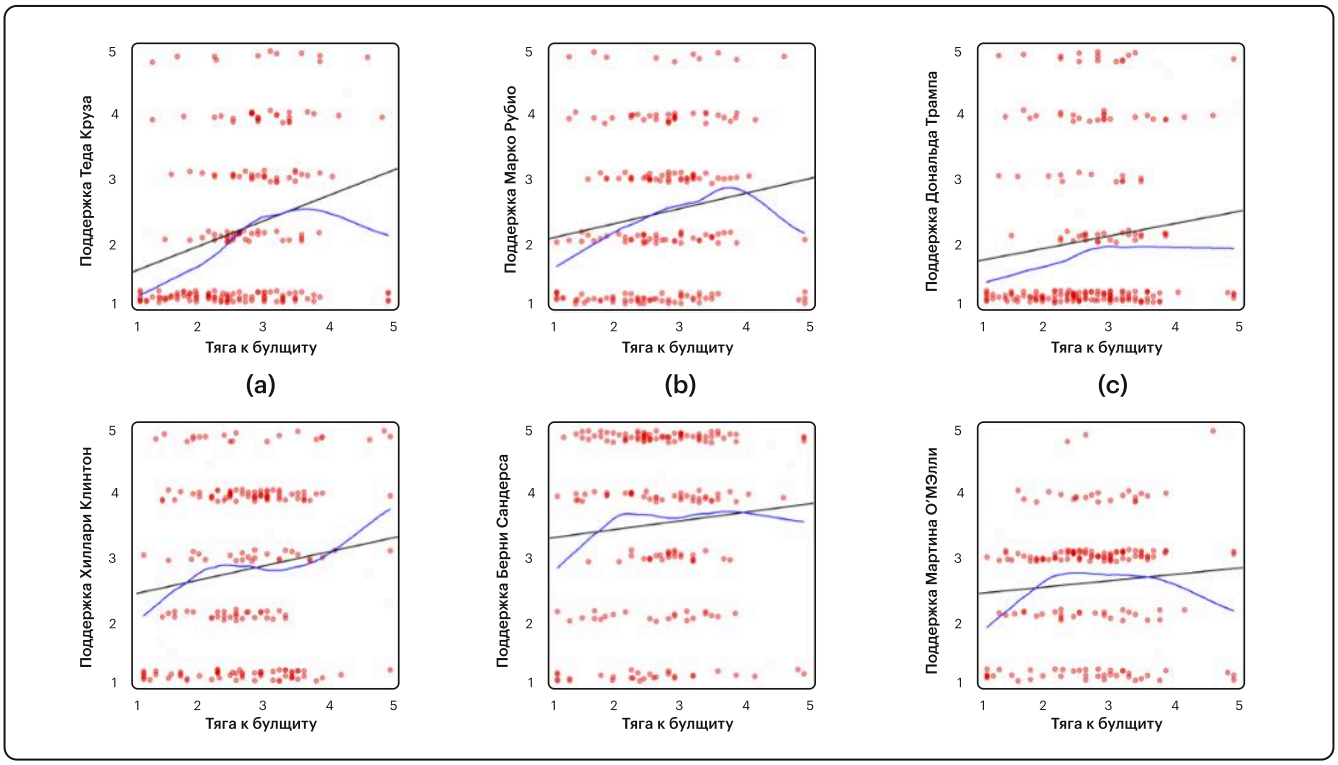

Рисунок 243. Результаты исследования про "булщит".

Выглядит так, как будто бы голосующие за республиканцев действительно легче попадаются на "булщит"и воспринимают его,

как нечто умное и содержательное.

Однако заметим, что данный результат был получен благодаря значительному дисбалансу классов. Можем увидеть, что среди опрошенной выборке намного меньше людей априори поддерживают республиканскую партию. Это можно увидеть на примере большого облака точек тех, кто поддерживает Дональда Трампа на 0 или 1.

Также необходимо учесть, что коэффициент корреляции Спирмена плохо работает с дискретными шкалами. И притом чем меньше уникальных значений признака, тем хуже будет работать ранговая корреляция Спирмена.

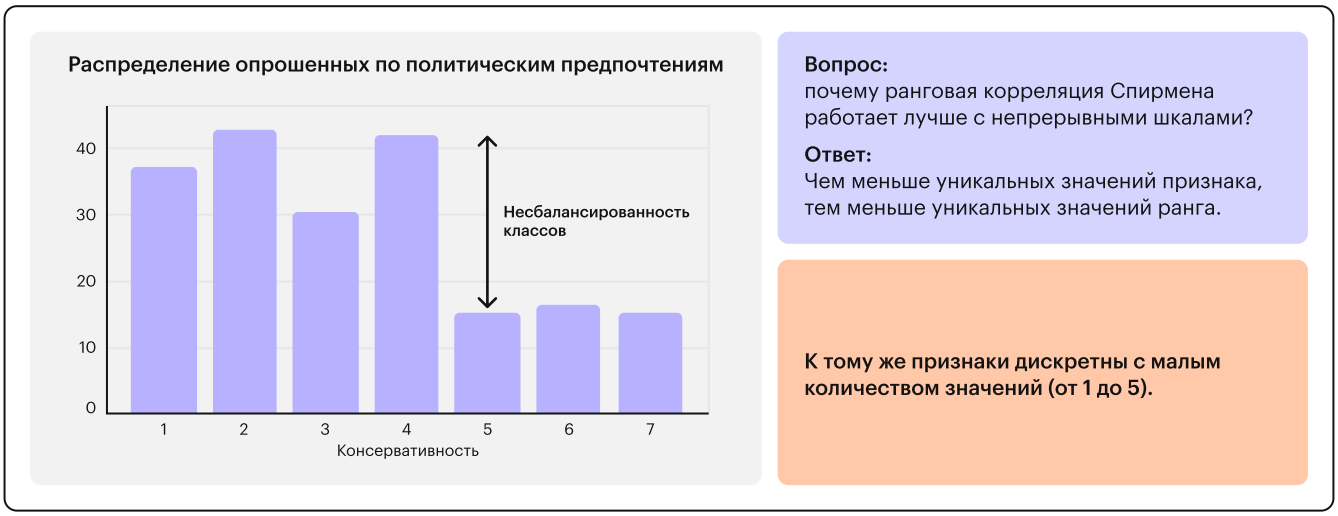

Рисунок 244. Манипуляция выборкой путём использования ранговой корреляции Спирмена

Итоги по коэффициентам корреляции

В этом разделе собрана целостная картина того, как выбирать меру корреляции в зависимости от типа данных и задачи.

Рассмотрим сравнение алгоритмов расчёта коэффициентов и значимостей на примере трёх вариантов.

	Линейная корреляция Пирсона	Корреляция Мэтьюса	Коэффициент V Крамера
Шаг 1	Расчёт коэффициента корреляции	Расчёт коэффициента корреляции	Расчёт статистического критерия
	$r = \frac{\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^{n}(X_i - \bar{X})^2 \cdot \sum_{i=1}^{n}(Y_i - \bar{Y})^2}}$	$MCC = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP+FP)(TP+FN)(TN+FP)(TN+FN)}}$	$\chi^2(X_1, X_2) = \sum_{i=1}^{K_1}\sum_{j=1}^{K_2}\frac{\left(n_{ij} - \frac{n_{i\cdot}}{n}\right)^2}{n_i n_j}$
Шаг 2	Расчёт статистического критерия	Расчёт статистического критерия	Вывод о статистической значимости
	$t = \frac{r\sqrt{n-1}}{1-r^2}$	$\chi^2 = \sum_{i=1}^{2}\sum_{j=1}^{2}\frac{(O_{ij} - E_{ij})^2}{E_{ij}}$	$\chi^2(X_1, X_2) \sim \chi^2_{(K_1-1)(K_2-1)}$
Шаг 3	Вывод о статистической значимости	Вывод о статистической значимости	Расчёт коэффициента корреляции
	$t \sim t_{n-2}$	$\chi^2 \sim \chi^2_1$	$V = \sqrt{\frac{\chi^2(X_1, X_2)}{n \cdot \min(K_1 - 1, K_2 - 1)}}$

Рисунок 245. Сравнение алгоритмов расчёта коэффициентов корреляции и их значимостей

Для категориальных переменных все основные коэффициенты связаны через статистику χ^2, которая измеряет отклонение наблюдаемого распределения от независимости.

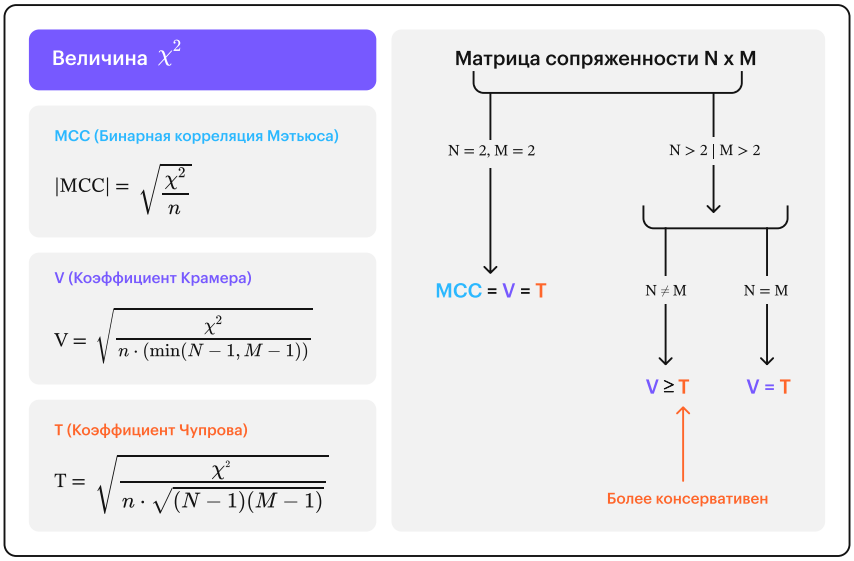

Рисунок 246. Связь коэффициентов через статистику χ^2

Коэффициенты Мэттьюса (MCC), Крамера V и Чупрова T представляют собой разные нормировки одной и той же величины:

$$|MCC| = \sqrt{\frac{\chi^2}{n}},$$

$$V = \sqrt{\frac{\chi^2}{n \cdot \min(N-1, M-1)}},$$

$$T = \sqrt{\frac{\chi^2}{n \cdot \sqrt{(N-1)(M-1)}}}.$$

При размере таблицы 2×2 все три коэффициента совпадают.

При увеличении размерности различия усиливаются: коэффициент Крамера V даёт более высокие значения, а коэффициент Чупрова T является более консервативной оценкой. В случае квадратной таблицы ($N = M$) они совпадают.

Теперь можем перейти к общей схеме всех вышеупомянутых коэффициентов корреляции.

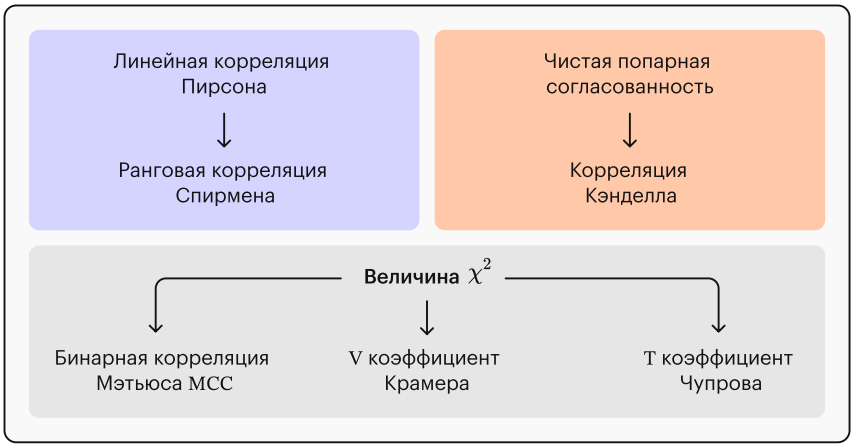

Рисунок 247. Общая классификация корреляций

Корреляция - это не универсальный "чёрный ящик который может обработать любой тип данных и выдать универсальную меру зависимости двух случайных величин. Важно понимать, что выбор коэффициента определяется типом данных, размерностью таблицы сопряженности и требуемой интерпретацией силы связи. То есть перед применением данного метода требуется глубинное изучение и форматирование данных.

Часть 14. Линейная регрессия

ВВЕДЕНИЕ

Регрессия отвечает на вопрос, как в среднем меняется одна величина, когда меняется другая. Из этого вырастают две разные задачи, которые важно не путать с самого начала.

Прогноз — «дай число». Мы вложили в рекламу 4 млн рублей; какую выручку ждать? Здесь неважно, почему модель выдаёт именно это число, лишь бы она ошибалась пореже.

Объяснение — «как связано». На сколько в среднем растёт выручка, если добавить к бюджету ещё один миллион? Здесь, наоборот, важен сам коэффициент и то, насколько ему можно верить.

Одна и та же модель может отлично решать первую задачу и никуда не годиться для второй. Это различие будет всплывать на

протяжении всего текста.

Стоит сразу отделить регрессию от корреляции. Корреляция говорит, насколько сильно и в какую сторону связаны две величины: это одно число от -1 до 1, и оно симметрично. Регрессия говорит, в какой форме они связаны, — она выдаёт саму линию и потому несимметрична. «Выручка по бюджету» и «бюджет по выручке» — две разные прямые.

И главное предупреждение, которое придётся повторить ещё не раз: линия показывает связь, а не причину, — *correlation does not imply causation*. Летом растут и продажи мороженого, и число утоплений; корреляция между ними построится прекрасная, но мороженое никого не топит — обе величины меняются в одну сторону из-за жары. Регрессия сама по себе не отличает такую ситуацию от настоящего влияния.

Слева — продажи мороженого и число утоплений по месяцам года: обе кривые повторяют одну и ту же сезонную зависимость. Справа — те же двенадцать месяцев как диаграмма рассеяния: корреляция 0.996, прямая ложится почти идеально. Но мороженое никого не топит — обе величины зависят от наступления высокой температуры.

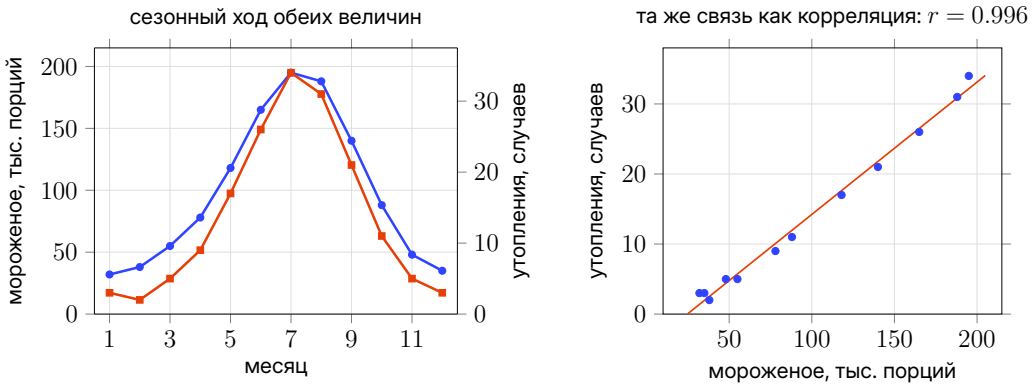

Рисунок 248

1. ВВЕДЕНИЕ В ЛИНЕЙНУЮ РЕГРЕССИОННУЮ МОДЕЛЬ

Мы ищем зависимость вида «выручка $\approx$ базовый уровень $+$ отдача $\times$ бюджет». Величину, которую предсказываем, называют **откликом**; величины, которыми предсказываем, — **признаками** (они же предикторы, регрессоры).

Слово «линейная» здесь про коэффициенты, а не про форму графика. Модель «выручка $= a + b \cdot$ бюджет $+ c \cdot$ бюджет^2» — всё ещё линейная регрессия, потому что она линейна по a, b, c, хотя рисует параболу. Это снимает частое заблуждение, будто линейной регрессией можно описывать только прямые.

Мы обсудим два вида регрессий - парную (с одним признаком) и множественную (с 2+ признаками)

Слева — парная регрессия: облако точек на плоскости и одна

прямая. Справа — два признака: облако в трёхмерном пространстве и плоскость через него.

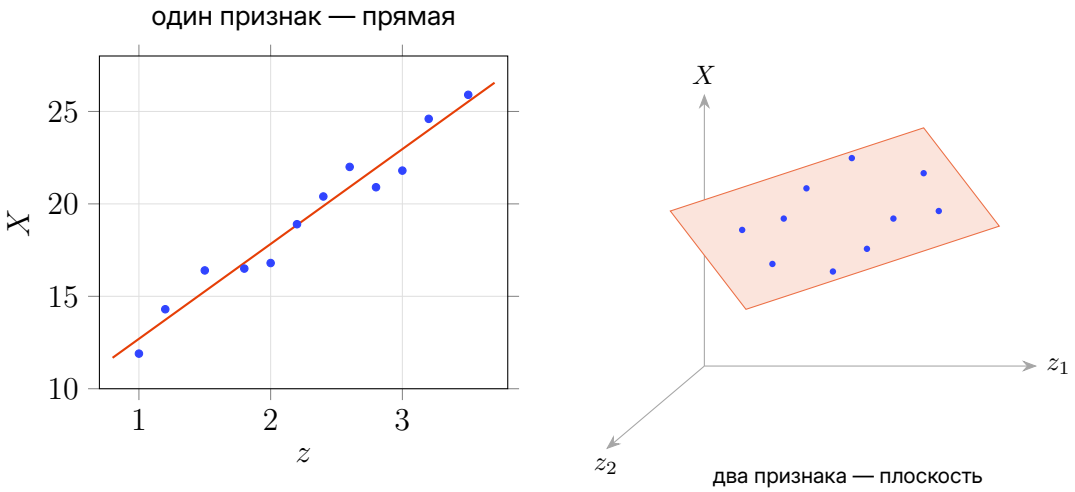

Парная регрессия: одна переменная и одна прямая

ОПРЕДЕЛЕНИЕ 14.1.1

Парная линейная регрессия

Пусть есть n наблюдений: значения признака $z_1, \dots, z_n$ и значения отклика $X_1, \dots, X_n$. Модель:

$$X_i = \theta_1 + \theta_2 z_i + \varepsilon_i, \qquad i = 1, \dots, n,$$

где θ_1 — свободный член, θ_2 — наклон, а ε_i — ненаблюдаемые ошибки с $\mathbb{E}\varepsilon_i = 0$ и $\operatorname{Var}\varepsilon_i = \sigma^2$.

Читается это так: если бы связь была идеальной, все точки лежали бы ровно на прямой $\theta_1 + \theta_2 z$. Реальность идеальной не бывает, поэтому каждая точка отклоняется от прямой на свою величину ε_i — всё, что на выручку влияет, кроме рекламы, и что мы не измеряли. Требование $\mathbb{E}\varepsilon_i = 0$ означает лишь, что эти отклонения не смещены систематически вверх или вниз; требование $\operatorname{Var}\varepsilon_i = \sigma^2$ — что их типичный размер одинаков по всему диапазону.

Наклон θ_2 — это и есть содержательный ответ: на сколько в среднем меняется отклик, если признак вырос на единицу. Свободный член θ_1 отвечает за высоту прямой и сам по себе интересен редко.

Пример 14.1.1. Интернет-магазин 12 месяцев подряд записывал рекламный бюджет и выручку (обе величины — в млн руб.). Позже мы добавим ещё признаки и посмотрим, что бывает, когда в модель попадает лишнее.

Сквозной пример: реклама и выручка

Месяц i	1	2	3	4	5	6	7	8	9	10	11	12
Бюджет z_i	1.0	1.2	1.5	1.8	2.0	2.2	2.4	2.6	2.8	3.0	3.2	3.5
Выручка X_i	11.9	14.3	16.4	16.5	16.8	18.9	20.4	22.0	20.9	21.8	24.6	25.9

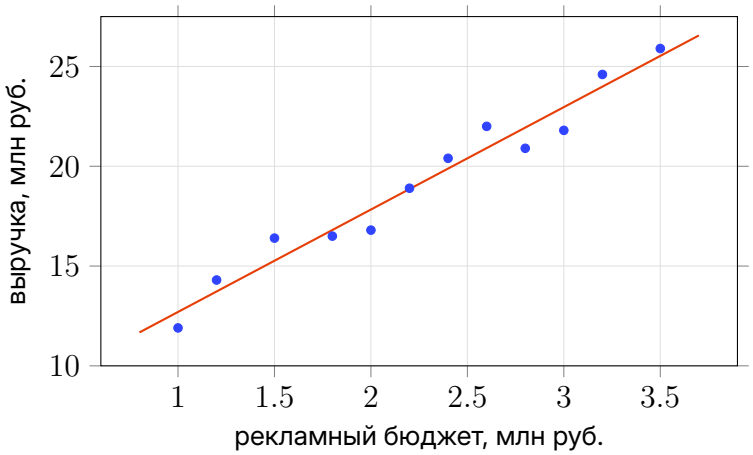

Связь видна глазами, и она похожа на прямую. Дальше весь текст — про то, как эту прямую провести не на глаз, насколько ей можно верить и как понять, что она вообще уместна.

Никакая прямая не пройдёт ровно через все точки. Для каждой точки есть промах — насколько модель не угадала, — и логично выбрать ту прямую, у которой промахи в сумме самые маленькие. Складывать сами промахи нельзя: плюсы погасят минусы, и любая прямая через середину облака даст ноль. Поэтому промахи возводят в квадрат и минимизируют их сумму.

От каждой точки к прямой проведён вертикальный отрезок — это промах модели на данном наблюдении. МНК выбирает ту прямую, у которой сумма *квадратов* этих отрезков минимальна; поэтому одна далёкая точка весит непропорционально много.

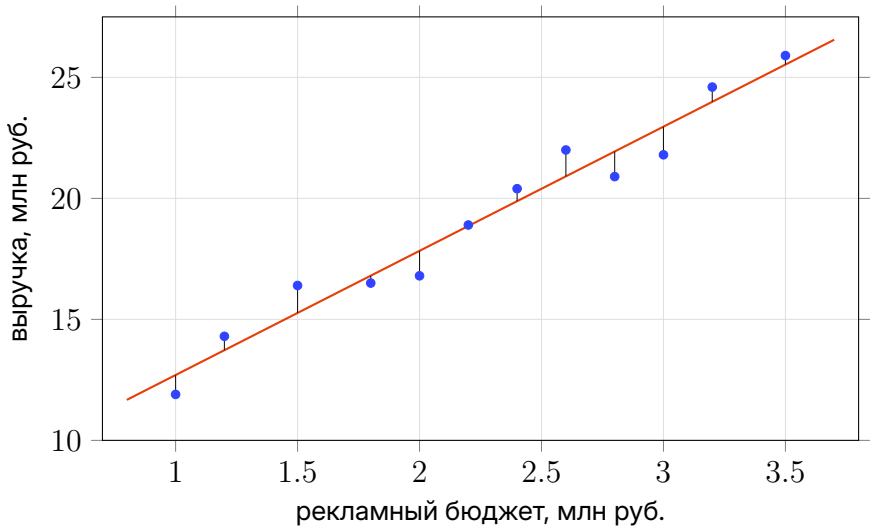

$$(\theta_1^*, \theta_2^*) = \operatorname{argmin}_{\theta_1,\theta_2} \sum_{i=1}^{n} \big(X_i - \theta_1 - \theta_2 z_i\big)^2.$$

ОПРЕДЕЛЕНИЕ 14.1.2

Метод наименьших квадратов для парной регрессии

Метод называют МНК, в англоязычной литературе — OLS (ordinary least squares).

ТЕОРЕМА 14.1.1

Формулы парной регрессии

Если признак не постоянен, то есть $\sum_i (z_i - \bar{z})^2 > 0$, минимум единствен и достигается при

$$\theta_2^* = \frac{\sum_i (z_i - \bar{z})(X_i - \overline{X})}{\sum_i (z_i - \bar{z})^2}, \qquad \theta_1^* = \overline{X} - \theta_2^* \, \bar{z}.$$

Доказательство. Обозначим $S(\theta_1, \theta_2) = \sum_i (X_i - \theta_1 - \theta_2 z_i)^2$ и приравняем к нулю обе частные производные:

$$\frac{\partial S}{\partial \theta_1} = -2 \sum_i \big(X_i - \theta_1 - \theta_2 z_i\big) = 0,$$

$$\frac{\partial S}{\partial \theta_2} = -2 \sum_i z_i \big(X_i - \theta_1 - \theta_2 z_i\big) = 0.$$

Первое уравнение после деления на n даёт $\overline{X} = \theta_1 + \theta_2 \bar{z}$, то есть сразу $\theta_1 = \overline{X} - \theta_2 \bar{z}$. Подставим это во второе уравнение:

$$\sum_i z_i \big(X_i - \overline{X} - \theta_2 (z_i - \bar{z})\big) = 0.$$

Поскольку $\sum_i \bar{z}\,(X_i - \overline{X}) = 0$ и $\sum_i \bar{z}\,(z_i - \bar{z}) = 0$, в обеих суммах z_i можно заменить на $z_i - \bar{z}$:

$$\sum_i (z_i - \bar{z})(X_i - \overline{X}) = \theta_2 \sum_i (z_i - \bar{z})^2,$$

откуда и получается формула для θ_2^*. Осталось убедиться, что это минимум, а не максимум: S — сумма квадратов, то есть выпуклая функция, растущая на бесконечности, поэтому единственная стационарная точка и есть точка минимума. □

Разберем чуть подробнее формулы парной регрессии. В числителе наклона стоит выборочная ковариация признака и отклика, в знаменателе — выборочная дисперсия признака. Через выборочную корреляцию r то же самое записывается как $\theta_2^* = r\,\widehat{\sigma}_X / \widehat{\sigma}_z$: наклон — это корреляция, пересчитанная из безразмерной шкалы в шкалу «единицы отклика на единицу признака».

Из формулы для свободного члена видно, что прямая всегда проходит через точку средних $(\bar{z}, \overline{X})$. Это удобный контроль при счёте руками и одновременно объяснение, почему свободный член нельзя выбрасывать из модели просто так: без него прямая обязана пройти через начало координат, и она перестаёт проходить через центр облака.

Пример 14.1.2. По таблице сквозного примера:

Считаем МНК руками

$$\bar{z} = 2.2667, \quad \overline{X} = 19.2, \quad \sum_i (z_i - \bar{z})^2 = 6.9667,$$

$$\sum_i (z_i - \bar{z})(X_i - \overline{X}) = 35.75.$$

Отсюда $\theta_2^* = 35.75/6.9667 = 5.1316$ и $\theta_1^* = 19.2 - 5.1316 \cdot 2.2667 = 7.5684$, то есть

$$\widehat{\text{выручка}} = 7.57 + 5.13 \cdot \text{бюджет}.$$

Каждый дополнительный миллион рекламного бюджета приносит в среднем около 5.13 млн выручки. Свободный член 7.57 формально означает выручку при нулевом бюджете, но в наших данных бюджет никогда не опускался ниже 1.0, так что это экстраполяция.

Проверка: прямая должна проходить через точку средних. При $z = 2.2667$ получаем $7.5684 + 5.1316 \cdot 2.2667 = 19.2 = \overline{X}$ — сходится.

Прежде чем идти дальше, стоит проговорить, как читаются коэффициенты и какие могут встретиться особенности при работе с регрессией:

- Коэффициент несёт размерность $[\text{отклик}]/[\text{признак}]$: если поменять единицы измерения — поменяется и коэффициент, хотя модель останется той же.

- Если бюджет измерять не в миллионах, а в тысячах, наклон станет 0.0051, и это будет ровно та же прямая.

- Предсказание за пределами наблюдавшегося диапазона — это вера в то, что линейность продолжается, а не вывод из данных.

- Если данные наблюдательные, а не из эксперимента, оценённый эффект не обязан быть причинным: возможны пропущенные переменные и обратная причинность (растущий бизнес и выручает больше, и тратит на рекламу больше).

Множественная регрессия: то же самое в матрицах

Признак редко бывает один. К бюджету хочется добавить число промо-дней, сезон, цену, активность конкурентов — и выписывать для каждого случая свою систему уравнений быстро становится невозможно. Матричная запись решает эту проблему: она выглядит ровно так же при любом числе признаков, и все формулы получаются одной строкой вместо страницы вычислений.

ОПРЕДЕЛЕНИЕ 14.1.3

Линейная регрессионная модель

Пусть есть n наблюдений. Соберём отклик в вектор $X = (X_1, \ldots, X_n)^\intercal \in \mathbb{R}^n$, а признаки — в матрицу $Z \in \mathbb{R}^{n \times k}$, где строка i — набор признаков i-го наблюдения. Модель:

$$X = Z\theta + \varepsilon,$$

где $\theta \in \mathbb{R}^k$ — неизвестный вектор параметров, а ε — вектор ошибок с $\mathbb{E}\varepsilon = 0$ и $\operatorname{Var}\varepsilon = \sigma^2 I_n$.

Свободный член не выделяется отдельно: он входит в модель как столбец единиц внутри Z. Поэтому парная регрессия из опреде-

ления 14.1.1 — это частный случай с $k = 2$:

$$Z = \begin{pmatrix} 1 & z_1 \\ \vdots & \vdots \\ 1 & z_n \end{pmatrix}, \qquad \theta = \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix}, \qquad k = 2.$$

Мы будем использовать такую нотацию во всей главе, поэтому важно проговорить две вещи. Во-первых, k — это *полное* число столбцов Z, то есть полное число оцениваемых коэффициентов; свободный член, если он есть, — один из этих k. Число степеней свободы остатков поэтому всегда $n - k$, никаких $n - k - 1$. Во-вторых, θ и θ^* — разные объекты: θ — неслучайные истинные параметры, θ^* — случайная оценка по выборке. Всюду предполагаем $\operatorname{rank} Z = k$ и $n > k$.

ЗАМЕЧАНИЕ

Часто в других источниках пишут модель как $y = X\beta + \varepsilon$, где X — матрица признаков, а y — отклик; у нас X — это как раз отклик, а признаки — Z. Часть источников обозначает через k число признаков *без* свободного члена и пишет $n - k - 1$. Все записи означают одно и то же: степеней свободы столько, сколько наблюдений минус число оценённых коэффициентов.

ОПРЕДЕЛЕНИЕ 14.1.4

Оценка наименьших квадратов

$$\theta^* = \operatorname{argmin}_{\theta \in \mathbb{R}^k} \|X - Z\theta\|^2 = \operatorname{argmin}_{\theta \in \mathbb{R}^k} \sum_{i=1}^{n} \Bigl(X_i - \sum_{j=1}^{k} Z_{ij}\theta_j \Bigr)^2.$$

ЛЕММА 14.1.1

Формула МНК

Если $\operatorname{rank} Z = k$, то матрица $Z^\mathsf{T} Z$ обратима и

$$\theta^* = (Z^\mathsf{T} Z)^{-1} Z^\mathsf{T} X.$$

Доказательство. Раскроем целевую функцию:

$$S(\theta) = \|X - Z\theta\|^2 = X^\mathsf{T} X - 2\theta^\mathsf{T} Z^\mathsf{T} X + \theta^\mathsf{T} Z^\mathsf{T} Z \theta.$$

Пользуясь тем, что $\partial(a^\mathsf{T}\theta)/\partial\theta = a$ и $\partial(\theta^\mathsf{T} A\theta)/\partial\theta = 2A\theta$ для симметричной A, получаем

$$\frac{\partial S}{\partial \theta} = -2Z^\mathsf{T} X + 2Z^\mathsf{T} Z\theta = 0 \quad \Longleftrightarrow \quad Z^\mathsf{T} Z\theta = Z^\mathsf{T} X.$$

Это **нормальные уравнения**. Гессиан $2Z^\mathsf{T} Z$ неотрицательно определён, значит задача выпуклая и стационарная точка — глобальный минимум. При $\operatorname{rank} Z = k$ матрица $Z^\mathsf{T} Z$ положительно определена и потому обратима. $\square$

Стоит убедиться, что это ровно то же самое, что мы делали руками. При $k = 2$ и столбце единиц матрица $Z^\mathsf{T} Z$ равна $\left(\begin{smallmatrix} n & \sum z_i \\ \sum z_i & \sum z_i^2 \end{smallmatrix}\right)$, вектор $Z^\mathsf{T} X$ равен $\left(\begin{smallmatrix} \sum X_i \\ \sum z_i X_i \end{smallmatrix}\right)$, и нормальные уравнения — это в точности та система двух уравнений, которую мы решали в доказательстве теоремы 14.1.1. Матричная запись не изменила задачу,

она только перестала зависеть от числа признаков.

Если столбцы Z линейно зависимы, матрица $Z^\intercal Z$ вырождена и нормальные уравнения имеют бесконечно много решений: разные θ дают один и тот же $Z\theta$. Это полная мультиколлинеарность. Частичная (столбцы почти зависимы) формулу не ломает, но делает $(Z^\intercal Z)^{-1}$ огромной — и, как мы увидим, раздувает стандартные ошибки. Именно отсюда растут гребневая и лассо-регрессия.

Пример 14.1.3. Множественная регрессия руками: два признака

Добавим к бюджету второй признак — число промо-дней в месяце:

$$p = (3,\ 6,\ 2,\ 8,\ 4,\ 9,\ 5,\ 3,\ 10,\ 6,\ 7,\ 4).$$

Теперь $k = 3$, а матрица Z состоит из столбца единиц, столбца бюджетов и столбца промо-дней. Считаем нужные суммы:

$$Z^\intercal Z = \begin{pmatrix} 12 & 27.20 & 67.0 \\ 27.20 & 68.62 & 157.6 \\ 67.0 & 157.6 & 445.0 \end{pmatrix}, \qquad Z^\intercal X = \begin{pmatrix} 230.40 \\ 557.99 \\ 1307.20 \end{pmatrix}.$$

Обращать матрицу 3×3 вручную необязательно: как и в парном случае, свободный член можно исключить, перейдя к центрированным переменным. Обозначив $S_{zz} = \sum_i (z_i - \bar{z})^2$, $S_{pp} = \sum_i (p_i - \bar{p})^2$, S_{zp}, S_{zX}, S_{pX} аналогично, получаем систему двух уравнений

$$\begin{cases} S_{zz}\,\theta_2 + S_{zp}\,\theta_3 = S_{zX}, \\ S_{zp}\,\theta_2 + S_{pp}\,\theta_3 = S_{pX}, \end{cases} \qquad \begin{aligned} &S_{zz} = 6.9667,\ \ S_{pp} = 70.9167,\ \ S_{zp} = 5.7333, \\ &S_{zX} = 35.75,\ \ S_{pX} = 20.80. \end{aligned}$$

Определитель равен $6.9667 \cdot 70.9167 - 5.7333^2 = 461.16$, откуда

$$\theta_2^* = \frac{70.9167 \cdot 35.75 - 5.7333 \cdot 20.80}{461.16} = 5.2388,$$

$$\theta_3^* = \frac{6.9667 \cdot 20.80 - 5.7333 \cdot 35.75}{461.16} = -0.1302,$$

и свободный член восстанавливается по точке средних: $\theta_1^* = 19.2 - 5.2388 \cdot 2.2667 + 0.1302 \cdot 5.5833 = 8.0526$.

Итог:

$$\widehat{\text{выручка}} = 8.05 + 5.24 \cdot \text{бюджет} - 0.13 \cdot \text{промо-дни}.$$

Обратите внимание на то, что произошло с наклоном при бюджете: в парной регрессии он был 5.13, здесь стал 5.24. Это не ошибка счёта и не случайность — смысл коэффициента изменился. В парной модели 5.13 означает «на столько в среднем больше выручка в месяцы, где бюджет на миллион больше», со всем, что за этим тянется. В множественной 5.24 означает «на столько больше при том же числе промо-дней».

Отсюда — главная оговорка при чтении коэффициентов множественной регрессии. Коэффициент θ_j^* — это изменение отклика при росте j-го признака на единицу *при прочих равных*, то есть при фиксированных остальных признаках. Коэффициент при бюджете меняется, если добавить или убрать другие признаки, и сравнивать между собой коэффициенты из разных моделей нельзя.

Слева — парная связь бюджета с выручкой, наклон 5.13. Справа — та же связь по «очищенным» переменным: по осям отложены остатки регрессий бюджета и выручки на число промо-дней; наклон здесь равен 5.24 — ровно коэффициент множественной регрессии

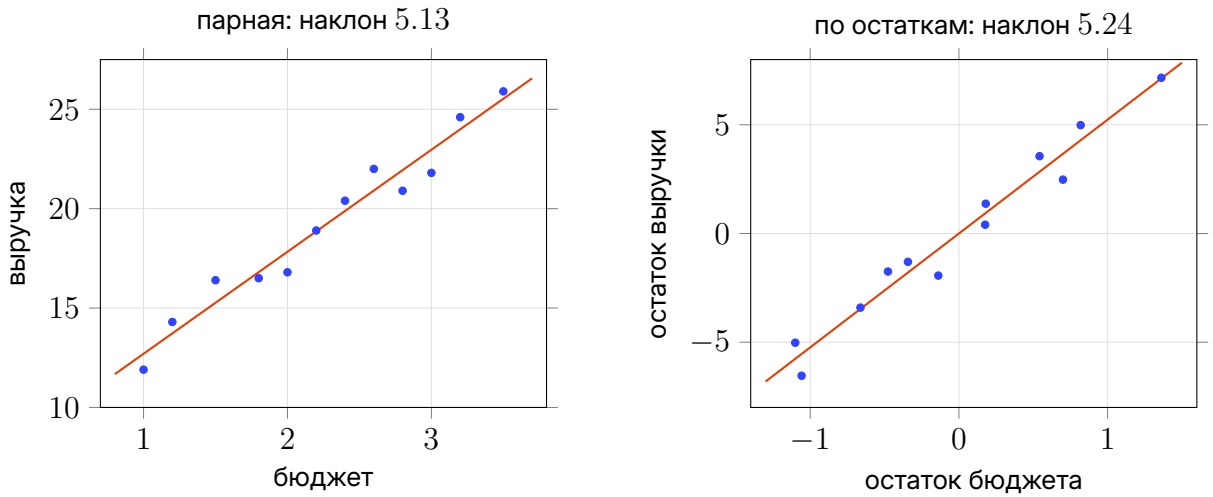

Геометрия: МНК как проекция

У матричной записи есть второе прочтение, геометрическое, и дальше оно понадобится почти в каждом доказательстве.

Подставим формулу МНК в определение подогнанных значений $\widehat{X} = Z\theta^*$:

$$\widehat{X} = \underbrace{Z(Z^\intercal Z)^{-1}Z^\intercal}_{=:P} X, \qquad e = X - \widehat{X} = (I_n - P)X.$$

Здесь e — **остатки**, промахи модели на каждом наблюдении. Практически всё качество модели меряется через них.

Матрица P симметрична, идемпотентна ($P^2 = P$), $PZ = Z$ и $\operatorname{tr} P = k$.

ЛЕММА 14.1.2

Свойства проектора

Доказательство. Симметричность очевидна, поскольку $(Z^\intercal Z)^{-1}$ симметрична. Далее $P^2 = Z(Z^\intercal Z)^{-1}Z^\intercal Z(Z^\intercal Z)^{-1}Z^\intercal = Z(Z^\intercal Z)^{-1}Z^\intercal = P$ и $PZ = Z(Z^\intercal Z)^{-1}Z^\intercal Z = Z$. Наконец, по цикличности следа

$$\operatorname{tr} P = \operatorname{tr}\big(Z(Z^\intercal Z)^{-1}Z^\intercal\big) = \operatorname{tr}\big((Z^\intercal Z)^{-1}Z^\intercal Z\big) = \operatorname{tr} I_k = k.$$

□

Обозначим $\mathcal{L} = \{Z\theta : \theta \in \mathbb{R}^k\}$ — линейную оболочку столбцов Z, подпространство размерности k в $\mathbb{R}^n$. Минимизировать $\|X - Z\theta\|$ — это в точности искать ближайшую к X точку в $\mathcal{L}$. Значит $\widehat{X}$ есть ортогональная проекция X на $\mathcal{L}$, остаток e ортогонален $\mathcal{L}$, и формально это и есть нормальные уравнения $Z^\intercal e = 0$.

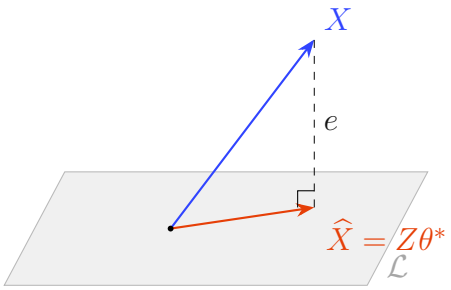

Идемпотентность и симметричность — это ровно то, что характеризует ортогональные проекторы. Отсюда видно, почему $\operatorname{tr} P = k$ обязано выполняться: у идемпотентной матрицы собственные значения равны 0 или 1, их сумма — размерность образа. Матрица $I_n - P$ — проектор на ортогональное дополнение, и $\operatorname{tr}(I_n - P) = n - k$; эта величина станет числом степеней свободы остатков.

Диагональные элементы $h_{ii} := P_{ii}$ называются **рычагом** i-го наблюдения. Рычаг показывает, насколько сильно наблюдение тянет прямую на себя. Из леммы 14.1.2 сразу следует

$$0 \leqslant h_{ii} \leqslant 1, \qquad \sum_{i=1}^{n} h_{ii} = \operatorname{tr} P = k,$$

то есть средний рычаг равен k/n. Большой рычаг бывает у наблюдений с нетипичными значениями признаков — на краях диапазона.

К одному и тому же облаку добавлена одна лишняя точка, одинаково далёкая от прямой. Слева она в центре диапазона — прямая почти не сдвинулась ($5.13 \to 5.12$). Справа она на далёком краю — наклон упал до 3.82. Разница между панелями и есть рычаг.

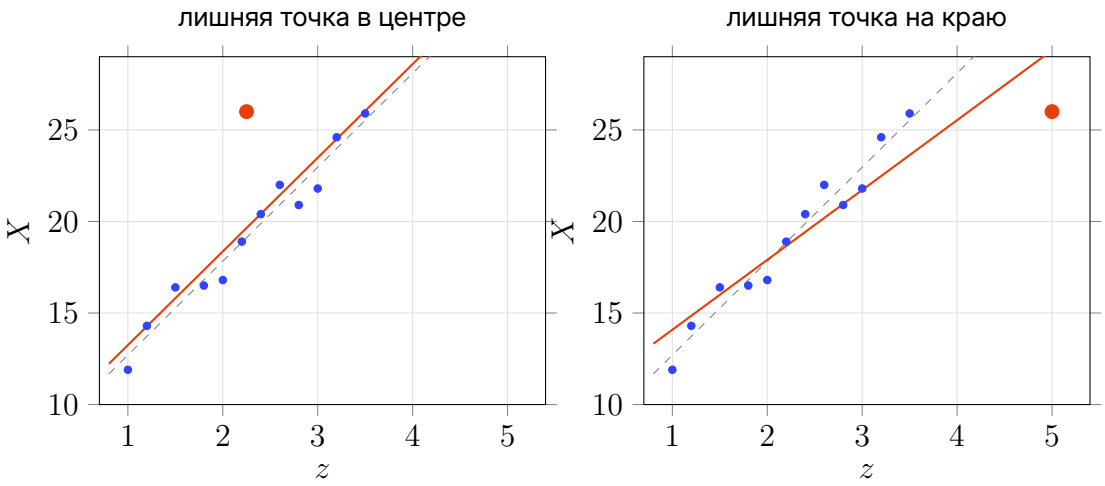

2. КАЧЕСТВО И ЗНАЧИМОСТЬ МОДЕЛИ ЛИНЕЙНОЙ РЕГРЕССИИ

Прямую мы провели. Хороша ли она?

Посмотрим на выручку саму по себе, забыв про рекламу. Она скачет: в одни месяцы 12 млн, в другие 26. Есть разброс. Можно сказать, что модель хороша, если она объясняет заметную часть этого разброса, а не оставляет всё в шуме. Возьмём одно наблюдение и разложим его отклонение от среднего на два куска: от среднего до предсказания модели — это объяснённая часть, от предсказания до реального значения — необъяснённая.

ОПРЕДЕЛЕНИЕ 14.2.1

TSS — total sum of squares, ESS — explained sum of squares, RSS — residual sum of squares

$$\underbrace{\mathrm{TSS} = \sum_{i=1}^{n} (X_i - \overline{X})^2,}_{\text{полный разброс}}$$

$$\underbrace{\mathrm{ESS} = \sum_{i=1}^{n} (\widehat{X}_i - \overline{X})^2,}_{\text{объяснено моделью}}$$

$$\underbrace{\mathrm{RSS} = \sum_{i=1}^{n} e_i^2 = \|e\|^2.}_{\text{осталось в остатках}}$$

Разложение отклонения одной точки на две части. Горизонталь — среднее $\overline{X}$, наклонная — линия регрессии. Для выделенной точки показаны объяснённая часть (от среднего до линии) и остаток (от линии до точки); вместе они дают полное отклонение. Суммы квадратов этих отрезков по всем точкам и есть ESS, RSS и TSS.

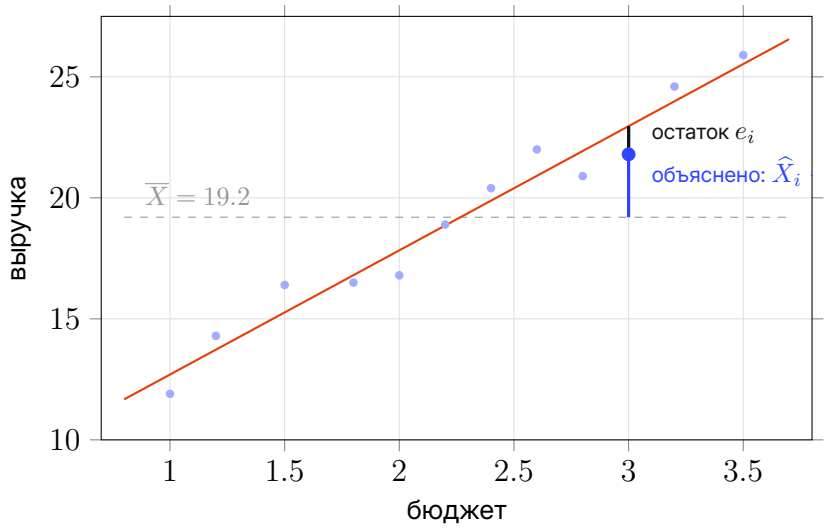

Если модель содержит свободный член, то $\mathrm{TSS} = \mathrm{ESS} + \mathrm{RSS}$.

ТЕОРЕМА 14.2.1

Разложение суммы квадратов

Доказательство. Пусть $\mathbf{1} \in \mathbb{R}^n$ — столбец единиц; по условию $\mathbf{1}$ входит в $\mathcal{L}$. Из нормальных уравнений $Z^\mathsf{T} e = 0$, а значит и $\mathbf{1}^\mathsf{T} e = 0$, то есть $\sum_i e_i = 0$. Отсюда $\overline{\widehat{X}} = \overline{X}$. Теперь $X_i - \overline{X} = (\widehat{X}_i - \overline{X}) + e_i$, и, суммируя квадраты,

$$\mathrm{TSS} = \mathrm{ESS} + \mathrm{RSS} + 2\sum_i (\widehat{X}_i - \overline{X}) e_i.$$

Перекрёстный член зануляется: $\sum_i \widehat{X}_i e_i = (Z\theta^*)^\mathsf{T} e = \theta^{*\mathsf{T}} Z^\mathsf{T} e = 0$, а $\overline{X} \sum_i e_i = 0$. □

По сути это теорема Пифагора: вектор $X - \overline{X}\mathbf{1}$ раскладывается на две ортогональные составляющие, и разложение сумм квадратов — равенство квадратов длин.

Важно! Тождество верно только при наличии свободного члена: именно столбец единиц гарантирует $\sum_i e_i = 0$. В регрессии через начало координат $\mathrm{TSS} \neq \mathrm{ESS} + \mathrm{RSS}$, и все построенные ниже величины теряют привычный смысл — R^2 может стать отрицательным. Стат-пакеты, которые помогают в расчётах, в этом случае часто молча переключаются на нецентрированный R^2, а это другая величина, и сравнивать её с обычным нельзя.

$$R^2 = \frac{\mathrm{ESS}}{\mathrm{TSS}} = 1 - \frac{\mathrm{RSS}}{\mathrm{TSS}}.$$

ОПРЕДЕЛЕНИЕ 14.2.2

Коэффициент детерминации

Это доля разброса отклика, объяснённая моделью; при наличии свободного члена $0 \leqslant R^2 \leqslant 1$. Читается прямо: $R^2 = 0.7$ — модель объясняет 70% разброса выручки. Два опорных случая: $R^2 = 0$ — модель не лучше, чем «всегда предсказывать среднее», $R^2 = 1$ — все точки лежат ровно на прямой.

Четыре облака с одинаковым числом точек и разным R^2. Слева направо: 0.95 — точки почти на прямой; 0.60 — связь очевидна, но разброс велик; 0.25 — наклон ещё виден, облако широкое; 0.00 — прямая горизонтальна, знание признака не помогает вовсе.

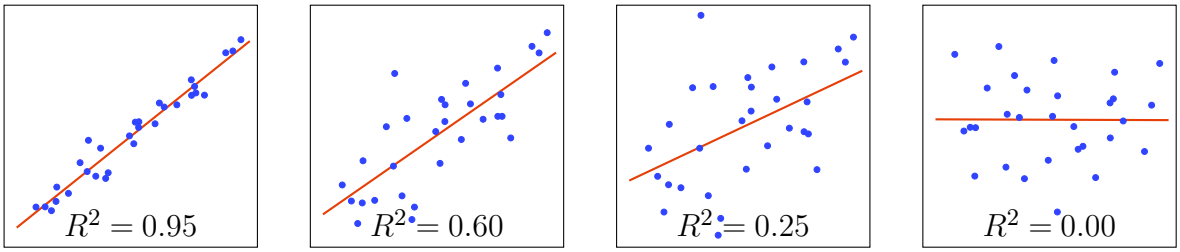

Инсайт Геометрически $R^2 = \cos^2 \varphi$, где φ — угол между цен-

трированными векторами $X - \overline{X}\mathbf{1}$ и $\widehat{X} - \overline{X}\mathbf{1}$. Отсюда $R^2 = \operatorname{corr}^2(X, \widehat{X})$, а в парной регрессии просто квадрат выборочной корреляции признака с откликом.

У коэффициента детерминации есть четыре свойства, о которых стоит знать заранее.

1) R^2 никогда не убывает при добавлении признака — даже абсолютно бессмысленного. Причина в том, что старая модель остаётся доступной: новому коэффициенту всегда можно присвоить ноль, минимум берётся по более широкому множеству, значит RSS не растёт. Следовательно, по обычному R^2 нельзя сравнивать модели с разным числом признаков.

2) Высокий R^2 не означает правильную модель. Он не проверяет ни причинность, ни спецификацию: две величины с общим трендом дают отличный R^2 при полном отсутствии связи.

3) Низкий R^2 не означает бесполезную модель. В поведенческих и социальных данных $R^2 = 0.2$ бывает нормой, а коэффициент при этом может быть значим, точно оценён и содержательно важен.

4) R^2 ничего не говорит о выполнении предпосылок и о качестве на новых данных.

И раз R^2 растёт всегда, нужна величина, которая штрафует за лишние параметры.

ОПРЕДЕЛЕНИЕ 14.2.3

Скорректированный коэффициент детерминации

$$R^2_{\text{adj}} = 1 - \frac{\mathrm{RSS}/(n-k)}{\mathrm{TSS}/(n-1)}.$$

В отличие от R^2, он может убывать при добавлении признака и даже быть отрицательным. Идея простая: сравнивать не суммы квадратов напрямую, а несмещённые оценки дисперсий, — отсюда деление на степени свободы.

ОПРЕДЕЛЕНИЕ 14.2.4

Стандартная ошибка регрессии

$$s^2 = \frac{\mathrm{RSS}}{n-k} = \frac{\|X - Z\theta^*\|^2}{n-k}, \qquad s = \sqrt{s^2}.$$

Величина s измеряется в единицах отклика и потому часто практичнее R^2: «в среднем мы промахиваемся на $\pm s$ миллионов». А s^2 — ещё и несмещённая оценка σ^2; именно она пойдёт в стандартные ошибки коэффициентов.

ТЕОРЕМА 14.2.2

Несмещённость s^2

При $\mathbb{E}\varepsilon = 0$ и $\operatorname{Var}\varepsilon = \sigma^2 I_n$ выполнено $\mathbb{E}\|X - Z\theta^*\|^2 = (n-k)\sigma^2$, и следовательно $\mathbb{E}s^2 = \sigma^2$.

Доказательство. Остатки суть $e = (I_n - P)X$. Поскольку $(I_n - P)Z\theta = 0$, имеем $e = (I_n - P)\varepsilon$. Матрица $I_n - P$ симметрична и идемпотентна, поэтому $\|e\|^2 = \varepsilon^{\mathsf{T}}(I_n - P)\varepsilon$. Для квадратичной

формы от вектора с нулевым средним и ковариацией $\sigma^2 I_n$ выполнено $\mathbb{E}[\varepsilon^\top A \varepsilon] = \sigma^2 \operatorname{tr} A$, а по лемме 14.1.2 $\operatorname{tr}(I_n - P) = n - k$. $\square$

Смысл здесь геометрический. Остатки — не свободный вектор в $\mathbb{R}^n$: они лежат в ортогональном дополнении к $\mathcal{L}$, а его размерность $n - k$. Оценивая k коэффициентов, мы истратили k направлений; свободно шевелятся только оставшиеся. Деление на n дало бы оценку, смещённую вниз. Проверить формулу можно на знакомом: при $Z = \mathbf{1}$ и $k = 1$ получаем $\theta^* = \overline{X}$ и $s^2 = \frac{1}{n-1}\sum_i (X_i - \overline{X})^2$ — привычная несмещённая выборочная дисперсия. Знаменитая поправка на $n - 1$ оказывается частным случаем общего правила $n - k$.

Пусть к модели с k столбцами добавляется один признак и t — его t-статистика в расширенной модели. Тогда

ТЕОРЕМА 14.2.3

Критерий роста скорректированного R^2

$$R^2_{\text{adj}} \text{ растёт} \iff s^2 \text{ убывает} \iff t^2 > 1.$$

Доказательство. Знаменатель $\mathrm{TSS}/(n-1)$ от модели не зависит, поэтому R^2_{adj} растёт ровно тогда, когда убывает s^2. Обозначим через RSS_r и RSS_u суммы квадратов остатков до и после добавления признака, так что $s_r^2 = \mathrm{RSS}_r/(n-k)$ и $s_u^2 = \mathrm{RSS}_u/(n-k-1)$. Для одного добавленного признака $t^2 = (\mathrm{RSS}_r - \mathrm{RSS}_u) \big/ \big(\mathrm{RSS}_u/(n-k-1)\big)$. Раскроем неравенство $s_u^2 < s_r^2$:

$$\begin{aligned} \frac{\mathrm{RSS}_u}{n-k-1} < \frac{\mathrm{RSS}_r}{n-k} &\iff (n-k)\,\mathrm{RSS}_u < (n-k-1)\,\mathrm{RSS}_r \\ &\iff \mathrm{RSS}_u < (n-k-1)(\mathrm{RSS}_r - \mathrm{RSS}_u) \\ &\iff 1 < t^2. \end{aligned}$$

$\square$

Порог $|t| > 1$ — это далеко не порог значимости, к которому мы обычно привыкли: 1.96 или 2.576 (для $\alpha = 0.05$ и $\alpha = 0.01$ соответственно). Скорректированный R^2 вполне может одобрить признак, который тест уверенно признаёт незначимым. На роль критерия отбора моделей он поэтому годится плохо.

Пример 14.2.1. Качество модели и ловушка лишнего признака

Для модели «выручка $\sim$ бюджет»:

$$\mathrm{TSS} = 191.26, \qquad \mathrm{ESS} = 183.45, \qquad \mathrm{RSS} = 7.81,$$

разложение сходится. Отсюда

$$R^2 = 1 - \frac{7.81}{191.26} = 0.959, \qquad s^2 = \frac{7.81}{12-2} = 0.781, \qquad s = 0.88.$$

Бюджет объясняет 96% разброса месячной выручки, типичная ошибка прогноза — около 0.9 млн.

Добавим второй признак — число промо-дней в месяце. Он окажется незначимым ($p = 0.25$). Тем не менее:

Модель	RSS	R^2	R^2_{adj}
1+ бюджет	7.81	0.9592	0.9551
1+ бюджет + промо-дни	6.68	**0.9651**	**0.9573**

R^2 вырос — как и обязан был. Но вырос и R^2_{adj}: у промо-дней $|t| = 1.23 > 1$, и этого хватило. Ни R^2, ни скорректированный R^2 не защитили от лишнего признака.

3. ЗНАЧИМОСТЬ РЕГРЕССИИ В ЦЕЛОМ

Мы получили $R^2 = 0.96$ и, кажется, это практически 1, поэтому это хорошее значение. Но разберем подробнее правда ли это так.

Представим, что связи нет вообще: выручка не зависит от бюджета, и мы всё равно провели прямую по двенадцати точкам. R^2 и в этом случае не будет нулём — прямая подстроится под случайные колебания и что-нибудь да «объяснит». Чем меньше наблюдений и чем больше признаков, тем больше она наберёт просто так: при $k = n$ любая модель даст $R^2 = 1$, вообще ничего не объясняя.

Значит нужен вопрос: полученный R^2 — он больше, чем бывает случайно? Это и есть проверка значимости регрессии в целом. Логика та же, что и во всякой проверке гипотез: предполагаем, что связи нет, и смотрим, насколько удивителен при таком предположении наш результат.

ОПРЕДЕЛЕНИЕ 14.3.1

Распределение Фишера

Распределением Фишера F_{m_1,m_2} называется распределение величины

$$\frac{\xi/m_1}{\eta/m_2}, \qquad \xi \sim \chi^2_{m_1}, \quad \eta \sim \chi^2_{m_2}, \quad \xi \perp \eta.$$

ТЕОРЕМА 14.3.1

Значимость регрессии в целом

Проверяется гипотеза «все коэффициенты, кроме свободного члена, равны нулю». При верной H_0 и нормальных ошибках

$$F = \frac{\mathrm{ESS}/(k-1)}{\mathrm{RSS}/(n-k)} = \frac{\mathrm{ESS}/(k-1)}{s^2} \sim \mathrm{F}_{k-1,\,n-k}.$$

Через коэффициент детерминации та же статистика записывается как

$$F = \frac{R^2/(k-1)}{(1-R^2)/(n-k)},$$

и это самая полезная её форма. Видно, что F — монотонная функция R^2: чем больше объяснено, тем больше F. То есть тест на значимость регрессии — это буквально тест на значимость R^2, пересчитанного с учётом того, сколькими параметрами он был получен. Один и тот же $R^2 = 0.3$ при $n = 200$ и $k = 2$ высокозначим, а при $n = 12$ и $k = 5$ — нет.

Гипотеза отвергается, когда F превосходит квантиль $f_{1-\alpha}^{k-1,n-k}$ распределения Фишера. Критическая область здесь односторонняя: маленькое F означает «модель ничего не объясняет», и отвергать в эту сторону нечего.

Оговорка про нормальность ошибок — не формальность: точное распределение Фишера получается только при ней. Откуда оно берётся и что происходит без нормальности, разобрано в следующем разделе и в разделе про нормальность остатков.

Пример 14.3.1. Значимость регрессии на наших данных

Модель «выручка ~ бюджет»: $k = 2$, $n = 12$, $R^2 = 0.9592$.

$$F = \frac{0.9592/1}{(1 - 0.9592)/10} = 235.0, \qquad f_{0.95}^{1,10} = 4.96.$$

Через суммы квадратов получается то же самое: $183.45/(7.81/10) = 235.0$. Гипотеза «бюджет ничего не объясняет» отвергается.

Полная модель с двумя признаками: $k = 3$, $\mathrm{ESS} = 184.58$, $\mathrm{RSS} = 6.68$.

$$F = \frac{184.58/2}{6.68/9} = 124.3, \qquad f_{0.95}^{2,9} = 4.26,$$

и здесь $p < 10^{-6}$.

Обратим внимание: R^2 у полной модели *выше* (0.9651 против 0.9592), а F — *ниже* (124.3 против 235.0). Так происходит потому что второй признак добавил объяснённой доли меньше, чем стоила потраченная на него степень свободы, и статистика Фишера это учла, а сырой R^2 — нет.

Важно! Если «глобальный F значим, а ни один отдельный коэффициент — нет», то это типичный симптом мультиколлинеарности. Признаки вместе объясняют почти всё, но данные не позволяют разделить их вклад. Мы увидим этот эффект в явном виде в разделе про гребневую регрессию.

4. ЗНАЧИМОСТЬ КОЭФФИЦИЕНТОВ В ЛИНЕЙНОЙ РЕГРЕССИИ

Мы получили: каждый миллион рекламы приносит 5.13 млн выручки. Но это число посчитано по одной случайной выборке из двенадцати месяцев. Возьми мы другой год — получили бы не 5.13, а, скажем, 4.8 или 5.5. Значит у коэффициента есть собственный разброс, и возникает вопрос: признак действительно влияет на отклик — или ненулевой коэффициент получился по случайности?

Логика проверки такая. Предположим на минуту, что влияния нет вовсе, и посмотрим, насколько удивительна при таком предположении полученная оценка. Если такое значение практически невероятно — значит, предположение плохое.

Здесь важно сразу развести две вещи: размер коэффициента и его значимость — про разное. Маленький коэффициент, оценённый очень точно, может быть значим; большой, но размазанный — нет. Значимость сравнивает коэффициент с его собственной погрешностью, а не с нулём напрямую.

ОПРЕДЕЛЕНИЕ 14.4.1

Стандартная ошибка коэффициента

$$\mathrm{SE}(\theta_j^*) = s\, c_j = s\sqrt{\left[(Z^\intercal Z)^{-1}\right]_{jj}}.$$

Стандартная ошибка становится меньше — то есть оценка точнее, — когда больше наблюдений, когда больше разброс самого признака (если бюджет всё время одинаковый, отдачу от него определить невозможно), когда меньше шум и когда признак слабее связан с остальными признаками.

ОПРЕДЕЛЕНИЕ 14.4.2

t-статистика

Для гипотезы $H_0 : \theta_j = 0$ против $H_1 : \theta_j \neq 0$

$$t_j = \frac{\theta_j^*}{\mathrm{SE}(\theta_j^*)}.$$

При верной H_0 и нормальных ошибках $t_j \sim \mathrm{St}_{n-k}$, и критерий уровня α имеет вид $|t_j| > u_{1-\alpha/2}$, где $u_{1-\alpha/2}$ — квантиль St_{n-k}. H_0 — это «признак j не вносит линейного вклада при прочих равных». Для проверки $H_0 : \theta_j = c$ формула та же с заменой числителя на $\theta_j^* - c$.

Доверительный интервал строится по той же статистике:

$$\theta_j^* \;\pm\; u_{1-\alpha/2} \cdot \mathrm{SE}(\theta_j^*).$$

Пример 14.4.1. Регрессионная таблица

Полная модель с обоими признаками: $n = 12$, $k = 3$, $n - k = 9$, $\mathrm{RSS} = 6.68$, откуда $s = 0.862$. Диагональ $(Z^\intercal Z)^{-1}$ равна $(1.030,\ 0.154,\ 0.0151)$.

Признак	θ_j^*	SE	t	p	95% ДИ
свободный член	8.053	0.874	9.21	< 0.001	$[6.07;\ 10.03]$
бюджет	5.239	0.338	15.50	< 0.001	$[4.47;\ 6.00]$
промо-дни	-0.130	0.106	-1.23	0.250	$[-0.37;\ 0.11]$

Квантиль $u_{0.975}$ для St_9 равен 2.262. Бюджет значим с огромным запасом. Промо-дни — нет: $|t| = 1.23 < 2.26$, и доверительный интервал уверенно содержит ноль. Более того, интервал говорит больше теста: даже если эффект промо-дней есть, он лежит между -0.37 и $+0.11$ млн за день — то есть мал, и мы не знаем даже его знак.

Данные были сгенерированы с истинной отдачей $\theta_2 = 5$ и нулевым эффектом промо, поэтому получились ожидаемые результаты.

При чтении значимости есть четыре важных момента.

1) Мультиколлинеарность: если признаки сильно скоррелированы, элементы $(Z^\intercal Z)^{-1}$ раздуваются, стандартные ошибки растут, t падают, и оба признака оказываются незначимыми, хотя вместе объясняют почти всё.

2) Множественные сравнения: проверяя 20 признаков на уровне 0.05, в среднем один значимый получим чисто случайно, поэтому можно применять поправки на множественное тестирование.

3) Подмена важности значимостью: при огромном n значимым становится сколь угодно крошечный эффект.

4) Нарушение предпосылок: t-распределение выведено при нормальных, независимых, равнодисперсных ошибках, и при их нарушении значимость становится некорректной.

Интервалы для предсказания

Модель построена, и теперь мы планируем в следующем месяце потратить на рекламу 3 млн. Что хочется изучить?

Во-первых: какова *средняя* выручка у всех месяцев с бюджетом 3 млн? Это про положение самой линии. Мы не знаем её точно, но чем больше данных, тем точнее знаем, и в пределе неопределённость исчезает.

Во-вторых: какова выручка *в конкретном* следующем месяце с бюджетом 3 млн? А это уже про отдельное наблюдение. Даже если бы мы знали линию идеально, конкретный месяц всё равно отклонится от неё на величину собственной случайной ошибки, и эта неопределённость не исчезает никогда.

ОПРЕДЕЛЕНИЕ 14.4.3

Интервал для среднего и прогнозный интервал

Пусть $z_0 \in \mathbb{R}^k$ — вектор признаков новой точки. Точечное предсказание в обоих случаях одно и то же, $\widehat{X}_0 = z_0^\intercal \theta^*$, а интервалы разные:

$$\text{для среднего:} \quad z_0^\intercal \theta^* \;\pm\; u_{1-\alpha/2}\, s \sqrt{z_0^\intercal (Z^\intercal Z)^{-1} z_0}\,,$$

$$\text{для нового наблюдения:} \quad z_0^\intercal \theta^* \;\pm\; u_{1-\alpha/2}\, s \sqrt{1 + z_0^\intercal (Z^\intercal Z)^{-1} z_0}\,.$$

Разница — в единице под корнем. Слагаемое $z_0^\intercal (Z^\intercal Z)^{-1} z_0$ — это неточность знания линии, оно стремится к нулю при $n \to \infty$; единица — собственный шум наблюдения, он не исчезает никогда. Интервал для среднего стягивается в точку, прогнозный — к полосе ширины $2u_{1-\alpha/2}\sigma$.

Для парной регрессии квадратичная форма считается в одну строку:

$$z_0^\intercal (Z^\intercal Z)^{-1} z_0 = \frac{1}{n} + \frac{(z_0 - \bar{z})^2}{\sum_i (z_i - \bar{z})^2}.$$

Минимум достигается в центре данных, при $z_0 = \bar{z}$ форма равна $1/n$. Чем дальше от среднего, тем шире — интервалы расходятся гиперболой в обе стороны, и за экстраполяцию приходится платить квадратично. Формула при этом продолжает честно считать, но она не учитывает главный риск экстраполяции — что сама линейность за пределами данных может не выполняться.

Две полосы вокруг линии регрессии: узкая — для среднего, широкая — прогнозная. Обе имеют форму песочных часов, самое узкое место — в точке $\bar{z} = 2.27$. С ростом n узкая полоса стягивается к линии, широкая — нет: у неё основную часть ширины даёт неустранимый шум наблюдения.

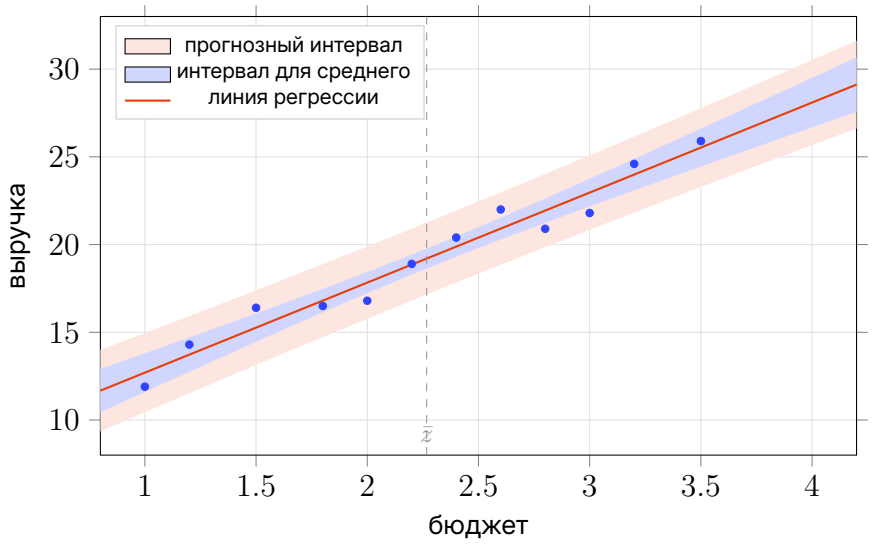

Пример 14.4.2. Прогноз выручки

Модель «выручка $\sim$ бюджет»: $n = 12$, $k = 2$, $s = 0.884$, $\bar{z} = 2.267$, $\sum_i (z_i - \bar{z})^2 = 6.967$, квантиль $u_{0.975}$ для St_{10} равен 2.228. При бюджете $z_0 = 3.0$:

$$\widehat{X}_0 = 22.96, \qquad z_0^\intercal (Z^\intercal Z)^{-1} z_0 = \frac{1}{12} + \frac{(3 - 2.267)^2}{6.967} = 0.1605.$$

среднее: $22.96 \pm 0.79 = [22.17;\, 23.75]$, прогноз: $22.96 \pm 2.12 = [20.84;\, 25.08]$.

Прогнозный интервал в 2.7 раза шире — это и есть цена вопроса «конкретный месяц» против «в среднем».

z_0	$z_0^\intercal (Z^\intercal Z)^{-1} z_0$	ширина для среднего	ширина прогнозного
2.27 ($= \bar{z}$)	0.083	1.14	4.10
3.0	0.161	1.58	4.24
3.5 (край данных)	0.302	2.16	4.49
4.0 (экстраполяция)	0.515	2.82	4.85

Интервал для среднего от центра к краю раздувается в 2.5 раза, прогнозный — всего в 1.2: у него основную часть ширины даёт неустранимая единица.

Откуда берётся распределение Стьюдента

Чтобы получить точные распределения, а не только моменты, нужно усилить предположения.

Линейная модель $X = Z\theta + \varepsilon$, в которой дополнительно $\varepsilon \sim N(0, \sigma^2 I_n)$.

ОПРЕДЕЛЕНИЕ 14.4.4

Гауссовская линейная модель

Тогда $\theta^* \sim N(\theta,\, \sigma^2 (Z^\intercal Z)^{-1})$ как линейное преобразование гауссовского вектора. Если бы σ была известна, дело было бы сделано. Но σ неизвестна, а замена её на s ломает нормальность. Разберёмся, каким становится распределение; для этого нужны два факта, и оба вытекают из геометрии проекции.

В гауссовской линейной модели $\frac{1}{\sigma^2}\|X - Z\theta^*\|^2 \sim \chi^2_{n-k}$.

ЛЕММА 14.4.1

Распределение RSS

Доказательство. Остаток $X - Z\theta^* = (I_n - P)\varepsilon$ — проекция гауссовского вектора на ортогональное дополнение к $\mathcal{L}$, размерность которого равна $n - k$. По теореме об ортогональном разложении гауссовского вектора квадрат нормы такой проекции, делённый на σ^2, имеет распределение χ^2 с числом степеней свободы, равным размерности подпространства. □

Статистики θ^* и $X - Z\theta^*$ независимы, следовательно независимы θ^* и s^2.

ЛЕММА 14.4.2

Независимость

Доказательство. Утверждение поначалу кажется удивительным. По той же теореме проекции гауссовского вектора на ортогональные подпространства независимы: значит независимы $Z\theta^*$ и $X - Z\theta^*$. Осталось заметить, что $\theta^* = (Z^\intercal Z)^{-1} Z^\intercal (Z\theta^*)$, то есть является функцией от $Z\theta^*$, а функция от независимой величины сохраняет независимость. □

ТЕОРЕМА 14.4.1

Центральная статистика для коэффициента

В гауссовской линейной модели

$$\frac{\theta_j^* - \theta_j}{s\,c_j} \sim \mathrm{St}_{n-k}, \qquad c_j^2 = \bigl[(Z^\intercal Z)^{-1}\bigr]_{jj}.$$

Доказательство. Числитель $(\theta_j^* - \theta_j)/(\sigma c_j) \sim N(0,1)$. Величина $\eta = (n-k)s^2/\sigma^2$ имеет распределение χ^2_{n-k} по лемме 14.4.1 и независима от числителя по лемме 14.4.2. Тогда отношение $\frac{(\theta_j^*-\theta_j)/(\sigma c_j)}{\sqrt{\eta/(n-k)}}$ есть в точности величина Стьюдента с $n-k$ степенями свободы. □

Переход от $N(0,1)$ к St_{n-k} — это необходимость из-за того, что мы не знаем σ: подставив оценку вместо истинной дисперсии, мы утяжелили хвосты. При $n-k \to \infty$ имеем $\mathrm{St}_m \to N(0,1)$, и порог 2.26 превращается в привычные 1.96.

ЗАМЕЧАНИЕ

В ряде источников центральная статистика записана с лишним множителем $\sqrt{n}$. Проверить легко на модели «только среднее»: $Z = \mathbf{1}$, $k=1$, $Z^\intercal Z = n$, значит $c_1 = 1/\sqrt{n}$, и правильная статистика $\frac{\overline{X}-\theta_1}{s/\sqrt{n}}$ — знакомый одновыборочный t-критерий. Множитель $\sqrt{n}$ уже сидит внутри c_j; выписывать его отдельно — значит учесть дважды. Лишний корень появляется, только если c_j определён через нормированную матрицу $\frac{1}{n}Z^\intercal Z$.

Осталось обосновать единицу под корнем в прогнозном интервале. Новое наблюдение устроено как $X_0 = z_0^\intercal\theta + \varepsilon_0$, где ε_0 независимо от обучающей выборки. Ошибка прогноза равна

$$X_0 - z_0^\intercal\theta^* = \underbrace{\varepsilon_0}_{\text{новый шум}} - \underbrace{z_0^\intercal(\theta^* - \theta)}_{\text{неточность оценки линии}}.$$

Слагаемые независимы, значит дисперсии складываются:

$$\mathrm{Var}\bigl(X_0 - z_0^\intercal\theta^*\bigr) = \sigma^2\bigl(1 + z_0^\intercal(Z^\intercal Z)^{-1}z_0\bigr).$$

Дальше всё как в теореме 14.4.1.

Инсайт Разложение дисперсии на «шум плюс неточность оценки» — это ровно то же разложение на неустранимую и устранимую части, которое в машинном обучении называют bias–variance. Здесь оно видно явно: σ^2 убрать нельзя ни при каком n, а $\sigma^2 z_0^\intercal(Z^\intercal Z)^{-1}z_0$ — можно, набрав данных.

Гипотезы о нескольких коэффициентах сразу

Отдельные коэффициенты мы проверять умеем, значимость регрессии целиком — тоже. Между этими двумя крайностями лежит целый класс вопросов: нужна ли группа признаков вместе, равны ли между собой два эффекта, укладывается ли сумма коэффициентов в единицу. Все они записываются как линейные ограничения на θ и проверяются одной конструкцией.

ТЕОРЕМА 14.4.2

Критерий для общей линейной гипотезы

Пусть $T \in \mathbb{R}^{m \times k}$ имеет полный строчный ранг. При верной H_0 : $T\theta = \tau$

$$F^* = \frac{(T\theta^* - \tau)^\intercal D^{-1} (T\theta^* - \tau)}{m\, s^2} \sim \mathrm{F}_{m,\, n-k},$$

$$D = T(Z^\intercal Z)^{-1} T^\intercal.$$

Идея Доказательство. Вектор $T\theta^* - \tau$ гауссовский с нулевым средним и ковариацией $\sigma^2 D$, поэтому квадратичная форма $(T\theta^* - \tau)^\intercal D^{-1}(T\theta^* - \tau)/\sigma^2$ имеет распределение χ^2_m. Она независима от s^2 по лемме 14.4.2, а $(n-k)s^2/\sigma^2 \sim \chi^2_{n-k}$. Отношение двух независимых хи-квадратов, делённых на свои степени свободы, и есть F. □

На практике почти всегда пользуются эквивалентной формой «через две модели». Пусть RSS_r — сумма квадратов остатков модели с наложенными ограничениями (restricted), а RSS_u — без них (unrestricted). Тогда

$$F^* = \frac{(\mathrm{RSS}_r - \mathrm{RSS}_u)/m}{\mathrm{RSS}_u/(n-k)}.$$

Считать так проще: достаточно подогнать две регрессии и сравнить остатки. Проверка значимости регрессии в целом — частный случай, где ограниченная модель содержит один свободный член.

Полезно помнить несколько свойств распределения Фишера:

$$\mathrm{F}_{1,m} = \mathrm{St}^2_m, \qquad \mathrm{F}_{m_1,m_2} \overset{d}{=} \frac{1}{\mathrm{F}_{m_2,m_1}}, \qquad m_1 \mathrm{F}_{m_1,m_2} \xrightarrow[m_2 \to \infty]{d} \chi^2_{m_1}.$$

Первое из них означает, что t-тест отдельного коэффициента — частный случай F-теста линейного ограничения $\theta_j = 0$.

Пример 14.4.3. Частный F-тест: нужны ли промо-дни

Сравним модель с двумя признаками ($\mathrm{RSS}_u = 6.68$, $n-k=9$) и модель только с бюджетом ($\mathrm{RSS}_r = 7.81$). Ограничение одно, $m = 1$:

$$F = \frac{(7.81 - 6.68)/1}{6.68/9} = 1.512, \qquad f^{1,9}_{0.95} = 5.12.$$

Промо-дни добавлять не стоит.

Заодно проверим связь с t-статистикой: для промо-дней $t = -1.2296$, и $t^2 = 1.512 = F$ — совпало в точности, как и обещала теория. Согласованы и квантили: $2.2622^2 = 5.117 = f^{1,9}_{0.95}$.

5. ТЕОРЕМА ГАУССА — МАРКОВА

Мы с самого начала минимизировали сумму квадратов промахов. Но почему именно квадратов? Можно было минимизировать

сумму модулей, или максимальный промах, или ещё что-нибудь; каждый такой выбор дал бы свою прямую.

Теорема Гаусса — Маркова отвечает на этот вопрос: при определённых условиях МНК даёт самую точную оценку из всех, которые линейно зависят от данных и в среднем не врут. В классе линейных и несмещённых это действительно самая точная оценка, но стоит выйти из этого класса, и МНК можно обыграть; именно так работают гребневая регрессия, которая жертвует несмещённостью ради точности, и квантильная.

ОПРЕДЕЛЕНИЕ 14.5.1

Условия Гаусса — Маркова

Модель $X = Z\theta + \varepsilon$. Требуется:

- **(Г1) Линейность по параметрам и правильная спецификация.** Отклик связан с признаками линейно, а функциональная форма выбрана верно.
- **(Г2) Полный ранг.** $\operatorname{rank} Z = k$: между признаками нет точной линейной зависимости.
- **(Г3) Экзогенность.** $\mathbb{E}[\varepsilon \mid Z] = 0$.
- **(Г4) Гомоскедастичность.** $\operatorname{Var} \varepsilon_i = \sigma^2$ для всех i.
- **(Г5) Некоррелированность.** $\operatorname{cov}(\varepsilon_i, \varepsilon_j) = 0$ при $i \neq j$.

Условия (Г4) и (Г5) вместе дают $\operatorname{Var} \varepsilon = \sigma^2 I_n$.

Разберём каждое по отдельности: что оно на самом деле требует, как выглядит нарушение и что при этом ломается.

(Г1) Линейность по параметрам и правильная спецификация

Условие требует, чтобы истинная связь имела вид $\mathbb{E}[X_i \mid z_i] = z_i^{\mathsf{T}}\theta$ — то есть чтобы отклик в среднем был линейной комбинацией тех столбцов, которые мы положили в Z.

В названии условия две части, и нарушается почти всегда вторая. Линейность по параметрам (они же коэффициенты) почти ничего не запрещает: в Z можно положить z^2, $\ln z$, $\sqrt{z}$, произведение двух признаков — модель останется линейной регрессией, потому что коэффициенты входят в неё линейно. А вот правильная спецификация — нужные столбцы должны быть в Z. Если истинная связь квадратичная, а мы положили только z, условие нарушено, и никакой объём данных этого не исправит.

Пример 14.5.1. Прямая вместо параболы

Пусть истинная связь — $X = 6 + 12z - 2z^2$ (отдача от рекламы растёт, но насыщается), а мы упрямо подгоняем прямую. Возьмём те же двенадцать бюджетов.

МНК даёт $\widehat{X} = 14.76 + 3.09\,z$ при $R^2 = 0.82$. Показатель качества выглядит вполне прилично — и это первое, что стоит запомнить: высокий R^2 не свидетельствует о правильной спецификации.

Слева — точки, лежащие ровно на параболе, и подогнанная по

ним прямая: на краях она проходит выше точек, в середине ниже. Справа — остатки против подогнанных значений.

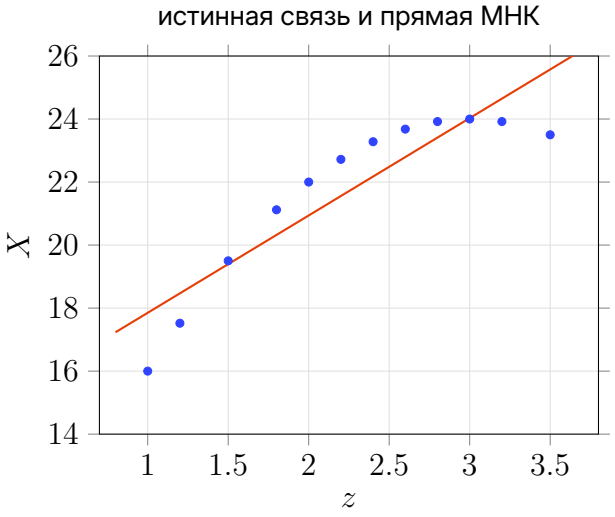

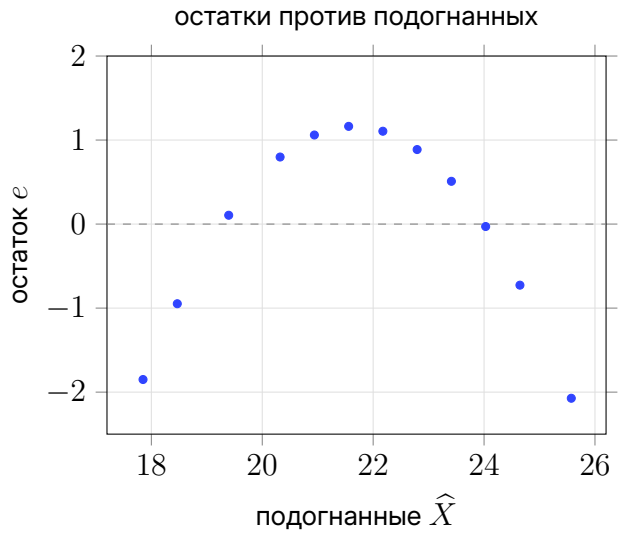

Знаки остатков по порядку возрастания бюджета идут ровной дугой: минус на краях, плюс в середине — в точности форма той параболы, которую мы отказались моделировать. При выполненных предпосылках знаки чередовались бы беспорядочно. Цена ошибки видна на экстраполяции: при $z = 5$ прямая обещает 30.2, тогда как истинная зависимость даёт 16.0 — модель предсказывает рост там, где на самом деле спад.

(Г2) Полный ранг и мультиколлинеарность

Условие $\operatorname{rank} Z = k$ означает: ни один столбец Z не выражается точной линейной комбинацией остальных. Это чисто алгебраическое требование, и оно нужно ровно для того, чтобы $Z^{\mathsf{T}} Z$ была обратима и решение существовало в единственном виде.

Нарушается оно обычно не из-за данных, а из-за того, как построена матрица признаков.

Пример 14.5.2. Три способа сломать ранг

Дубликат в другой шкале. В модель попали и «бюджет в млн», и «бюджет в тыс.». Второй столбец равен первому, умноженному на 1000: зависимость точная, ранг неполный.

Ловушка фиктивных переменных. Мы завели четыре индикатора сезона — зима, весна, лето, осень — и оставили свободный член. Сумма четырёх индикаторов равна столбцу единиц в каждой строке, потому что каждый месяц ровно в одном сезоне. Опять точная зависимость. Лечение стандартное: один уровень выбрасывается и становится базовым, а коэффициенты остальных читаются как отклонения от него.

Больше признаков, чем наблюдений. При $k > n$ ранг не может превышать n, поэтому условие нарушено автоматически. Так

устроены задачи с генами, текстами и любыми «широкими» данными; обычный МНК там неприменим в принципе, и именно оттуда растут гребневая регрессия и лассо.

Полное нарушение (Г2) — ситуация редкая, гораздо опаснее почти-нарушение: столбцы не совпадают, но очень близки. Для него есть отдельное название.

Мультиколлинеарность в модели — это наличие сильной корреляции между регрессорами (факторами).

ОПРЕДЕЛЕНИЕ 14.5.2
Мультиколлинеарность

Пример 14.5.3. Как её ищут глазами

Первый инструмент — попарные диаграммы рассеяния признаков, второй — матрица корреляций. Смотрят не на связь признака с откликом, а на связь признаков между собой.

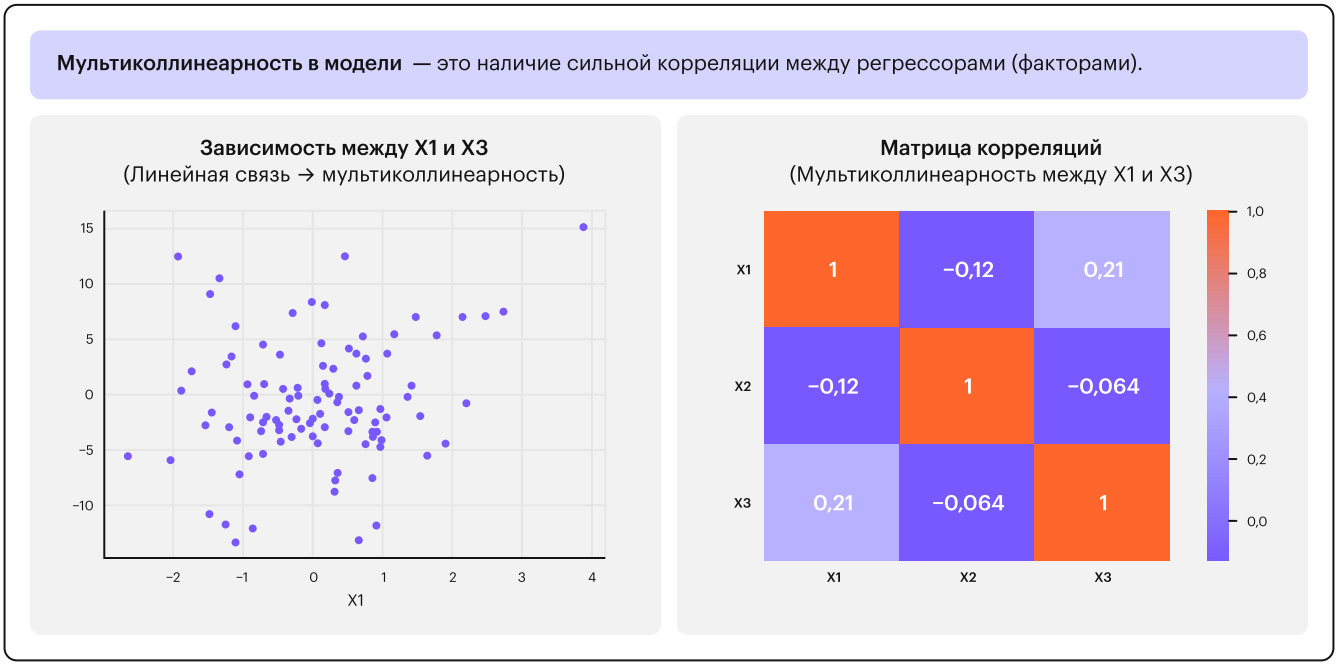

Рисунок 249. Слева — диаграмма рассеяния двух признаков, справа — матрица корреляций всех трёх, в которой и стоит искать высокие значения корреляции между признаками

Матрица корреляций видит только попарные связи. Признак может почти точно выражаться через *комбинацию* двух других, и при этом не иметь высокой корреляции ни с одним из них по отдельности. Поэтому нужен показатель, который смотрит на признак против всех остальных сразу, — **VIF** (variance inflation factor).

Пример 14.5.4. Посмотрим на два признака из сквозного примера, добавив к бюджету число показов рекламы.

VIF на наших данных

Для определения мультиколлинеарности используется VIF (Variance Inflation Factor).

01 Для расчёта показателя VIF для i-го регрессора построим регрессию. $X_i = \alpha + \sum_{j \neq i} \beta_j X_j + \varepsilon$

02 Рассчитываем коэффициент детерминации данной регрессии.

03 Рассчитываем. $\mathrm{VIF}_j = \frac{1}{1 - R_j^2}$

Если VIF > 5, то мультиколлинеарность есть.

У промо-дней $\mathrm{VIF} = 1.09$: вспомогательная регрессия почти ничего не объясняет, признак несёт свою собственную информацию. У пары «бюджет — показы» $\mathrm{VIF} = 529$, то есть R^2 вспомогательной регрессии равен 0.998: каждый из них почти полностью восстанавливается по другому. Порог 5 превышен — перед нами именно тот случай, ради которого дальше понадобится гребневая регрессия.

(ГЗ) Экзогенность

Это единственное, нарушение которого ломает саму оценку, а не только выводы о её точности.

Записывается оно как $\mathbb{E}[\varepsilon \mid Z] = 0$ и читается так: зная значения признаков, мы ничего не можем сказать об ошибке. Всё, что осталось за пределами модели, не связано с тем, что в модель вошло.

Отсутствие систематической ошибки означает, что среднее значение остатков должно равняться нулю. Проверяется это z-тестом: при верной гипотезе нормированное среднее остатков имеет распределение $N(0, 1)$. Три следующих примера показывают, как выглядят все три возможности.

Пример 14.5.5. Кейс нулевых остатков

Модель подогнана обычным МНК, прямая проходит сквозь середину облака.

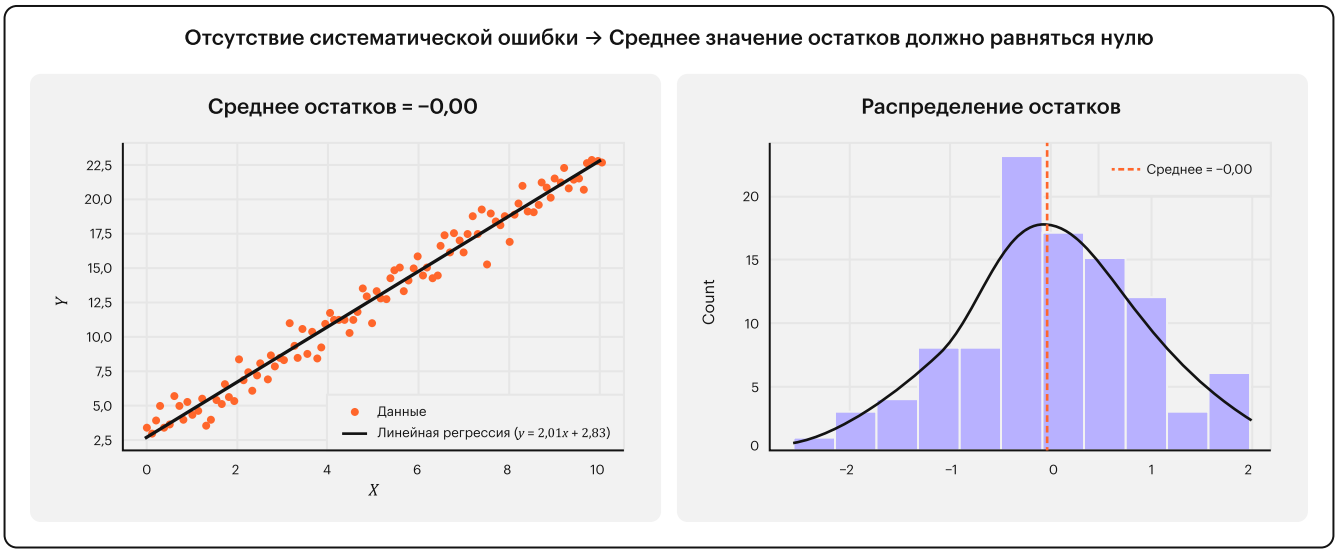

Рисунок 250. Отсутствие систематической ошибки: среднее остатков $= -0.00$. Слева — данные и подогнанная прямая $y = 2.01x + 2.83$, справа — распределение остатков, симметричное относительно нуля.

Гистограмма остатков центрирована в нуле, точки на диаграмме рассеяния лежат по обе стороны прямой примерно поровну. Это норма, к которой всё остальное будет сравниваться.

Пример 14.5.6. Кейс завышенных остатков

Теперь искусственно занизим прогнозы — сдвинем всю прямую вниз.

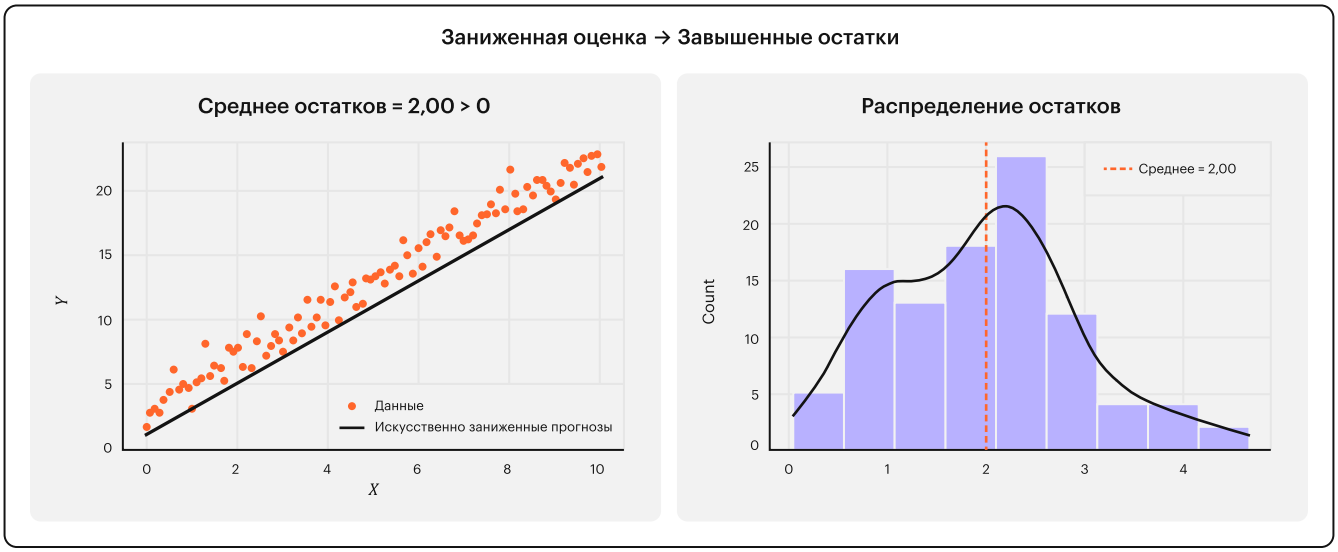

Рисунок 251. Заниженная оценка даёт завышенные остатки: среднее остатков $= 2.00 > 0$. Слева видно, что почти все точки лежат выше прямой.

Модель систематически недооценивает отклик, и это сразу читается по гистограмме: она целиком уехала вправо, её центр равен $+2$, а не нулю.

Пример 14.5.7. Кейс заниженных остатков

Симметричная ситуация: искусственно завысим прогнозы.

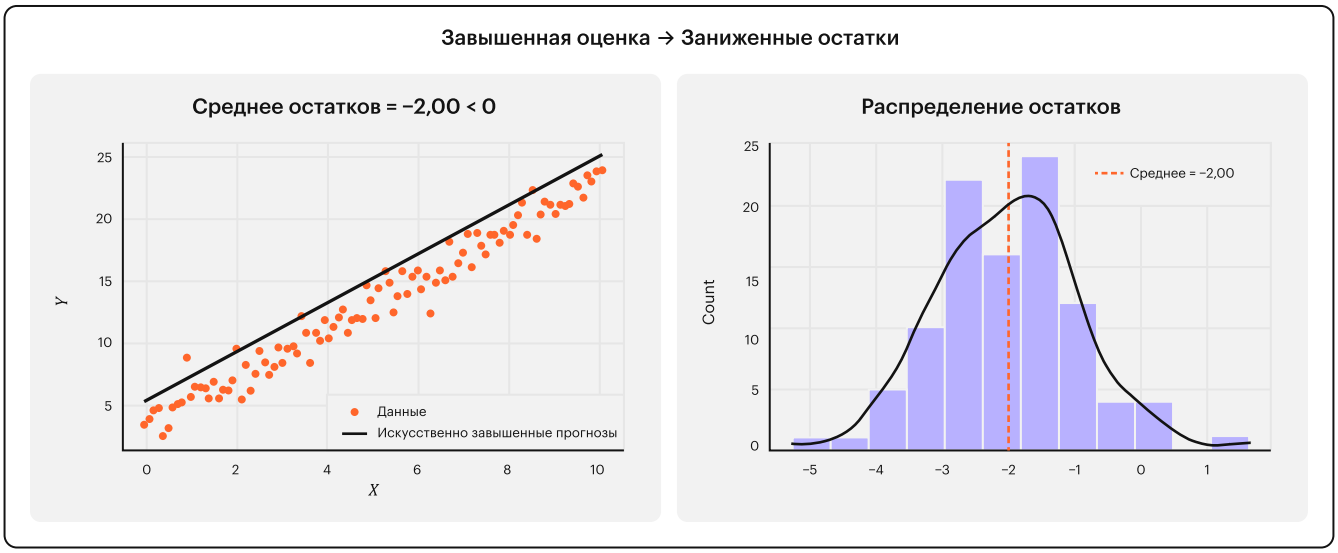

Рисунок 252. Завышенная оценка даёт заниженные остатки: среднее остатков $= -2.00 < 0$. Почти все точки лежат ниже прямой.

Важно! У этой проверки есть особенность, о которой стоит помнить. Если в модель включён свободный член, то $\sum_i e_i = 0$ выполняется *тождественно* (теорема 14.2.1), и среднее остатков равно нулю автоматически, что бы ни происходило с данными. Картинки выше получены искусственным сдвигом прогнозов — именно поэтому там среднее и вышло ненулевым. Так что содержательный смысл условия (ГЗ) не в безусловном $\mathbb{E}\varepsilon_i = 0$, а в условном $\mathbb{E}[\varepsilon \mid Z] = 0$, и вот его-то никакая проверка по остаткам не увидит.

Безусловное нулевое среднее $\mathbb{E}\varepsilon_i = 0$ достигается легко: если $\mathbb{E}\varepsilon_i = c \neq 0$, константа впитывается в свободный член, а остальные коэффициенты не меняются. Условное же нулевое среднее $\mathbb{E}[\varepsilon \mid Z] = 0$ — требование содержательное, и механизмов его нарушения три.

1. Пропущенная переменная. Существует фактор, который влияет и на отклик, и на признак, а в модель не включён. Сезонность поднимает и выручку, и рекламный бюджет; способности влияют и на зарплату, и на длительность обучения. Влияние такого фактора оседает в ошибке — и оказывается связано с признаком.

2. Обратная причинность. Не только признак действует на отклик, но и отклик на признак. Выручка прошлого месяца определяет бюджет следующего; число полицейских в городе зависит от уровня преступности не меньше, чем преступность — от числа полицейских.

3. Ошибка измерения признака. Мы наблюдаем не сам признак, а его зашумлённую версию. Шум измерения попадает в ошибку модели и автоматически коррелирован с тем, что мы использовали как признак; коэффициент при этом систематически притягивается к нулю.

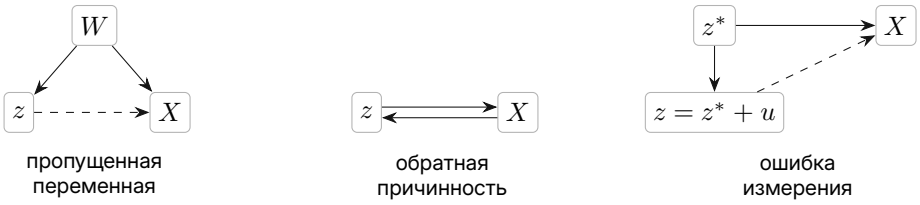

УТВЕРЖДЕНИЕ 14.5.1

Смещение от пропущенной переменной

Пусть истинная модель имеет вид $X = Z_1\theta_1 + Z_2\theta_2 + \varepsilon$ с $\mathbb{E}[\varepsilon \mid Z] = 0$, а оценивается короткая регрессия только на Z_1. Тогда её МНК-оценка $\widetilde{\theta}_1$ удовлетворяет

$$\mathbb{E}\widetilde{\theta}_1 = \theta_1 + D\,\theta_2, \qquad D = (Z_1^\intercal Z_1)^{-1} Z_1^\intercal Z_2,$$

где D — матрица коэффициентов регрессии пропущенных признаков на включённые. В частности, для одного включённого признака z и одного пропущенного p

$$\mathbb{E}\widetilde{\theta}_z = \theta_z + \theta_p \cdot \delta, \qquad \delta = \frac{\sum_i (z_i - \bar{z})(p_i - \bar{p})}{\sum_i (z_i - \bar{z})^2}.$$

Доказательство. Подставим истинную модель в формулу МНК короткой регрессии:

$$\widetilde{\theta}_1 = (Z_1^\intercal Z_1)^{-1} Z_1^\intercal X = \theta_1 + (Z_1^\intercal Z_1)^{-1} Z_1^\intercal Z_2 \theta_2 + (Z_1^\intercal Z_1)^{-1} Z_1^\intercal \varepsilon.$$

Последнее слагаемое имеет нулевое условное среднее по предположению, откуда и следует формула. □

Формула читается как произведение двух вещей: насколько пропущенный фактор важен для отклика (θ_2) и насколько он связан с включённым признаком (D). Стоит любому из сомножителей обратиться в ноль — и смещения нет. Поэтому пропущенная переменная опасна не сама по себе, а только когда она связана *и* с откликом, *и* с признаком.

Пример 14.5.8. Смещение видно на наших данных

У нас есть обе модели, и формулу можно проверить арифметически.

Полная регрессия дала $\theta^*_{\text{бюджет}} = 5.2388$ и $\theta^*_{\text{промо}} = -0.1302$. Теперь «забудем» про промо-дни. Коэффициент связи промо с бюджетом:

$$\delta = \frac{S_{zp}}{S_{zz}} = \frac{5.7333}{6.9667} = 0.8230.$$

Формула предсказывает, что короткая регрессия даст

$$5.2388 + (-0.1302) \cdot 0.8230 = 5.1316.$$

Ровно это мы и получили в самом начале, подгоняя парную регрессию: $\theta^*_2 = 5.1316$.

Смещение вышло маленьким (-0.107) т.к. эффект промо-дней сам по себе почти нулевой. Но если поменять θ_p на -3 вместо

-0.13, парная регрессия покажет отдачу от рекламы 2.77 вместо 5.24 — вдвое меньше истинной, без единого признака, что что-то не так.

При нарушении экзогенности МНК смещён *и* несостоятелен: смещение не уменьшается с ростом выборки, потому что оно заложено в саму связь ошибки с признаком, а не в случайность. Собрать больше данных — значит лишь точнее оценить неправильную величину.

Это главная причина, почему коэффициент регрессии нельзя автоматически называть причинным эффектом. Способы как это предотвратить — рандомизированный эксперимент (он делает признак независимым от всего остального по построению), инструментальные переменные, панельные методы, включение контрольных переменных.

(Г4) Гомоскедастичность

Гомоскедастичность — свойство постоянства дисперсии остатков модели: $\operatorname{Var}\varepsilon_i = \sigma^2$ одинаково для всех i.

ОПРЕДЕЛЕНИЕ 14.5.3

Гомоскедастичность

Пример 14.5.9. Возьмём данные, у которых разброс вокруг линии одинаков по всему диапазону признака.

Как выглядит гомоскедастичность

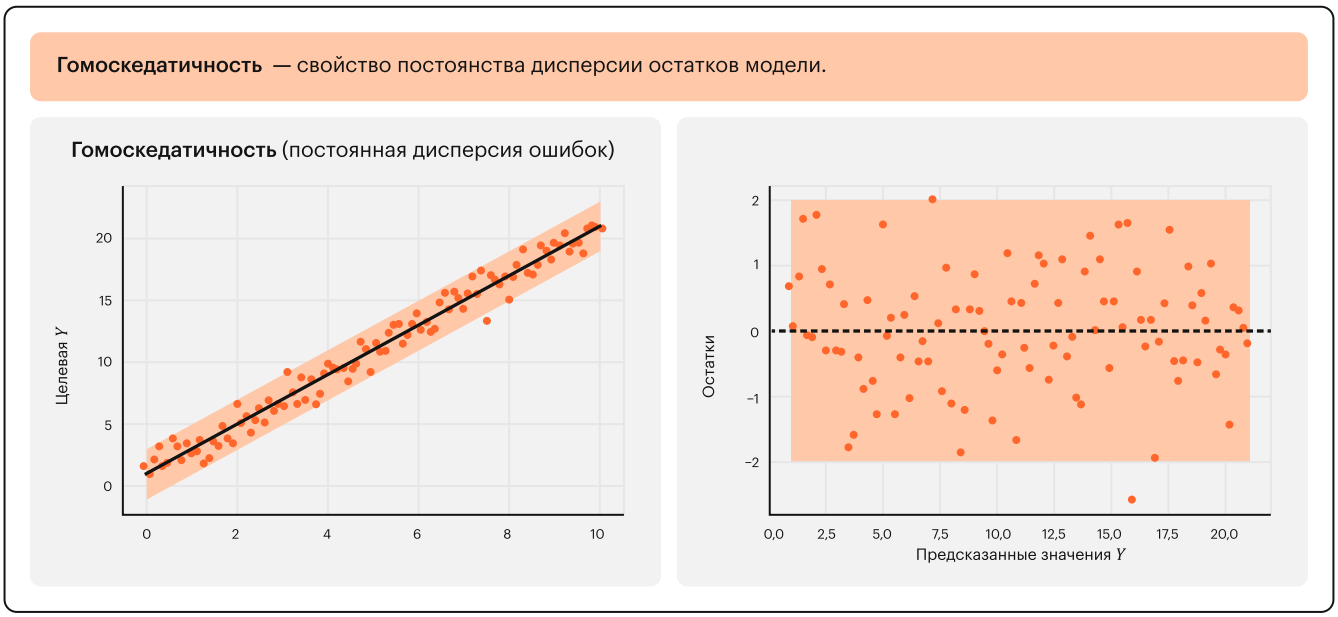

Рисунок 253. Слева — данные и подогнанная прямая с полосой постоянной ширины. Справа — главный диагностический график: остатки против предсказанных значений $\widehat{Y}$; точки лежат в горизонтальной полосе.

Правая панель — то, на что смотрят в первую очередь. Если облако остатков укладывается в полосу постоянной высоты и не расширяется ни влево, ни вправо, условие (Г4) выполнено.

Гетероскедастичность — свойство изменчивости дисперсии остатков модели: $\operatorname{Var} \varepsilon_i$ зависит от i.

ОПРЕДЕЛЕНИЕ 14.5.4

Гетероскедастичность

В экономических данных это скорее норма, чем исключение. Расходы семьи с доходом 30 тыс. предсказываются заметно точнее, чем расходы семьи с доходом 3 млн: у богатых больше степеней свободы, и разброс вокруг любой линии больше. То же с выручкой фирм разного размера, с длительностью процессов, с ценами на объекты разного класса.

Пример 14.5.10. Как выглядит гетероскедастичность

Возьмём данные, у которых разброс растёт вместе с признаком.

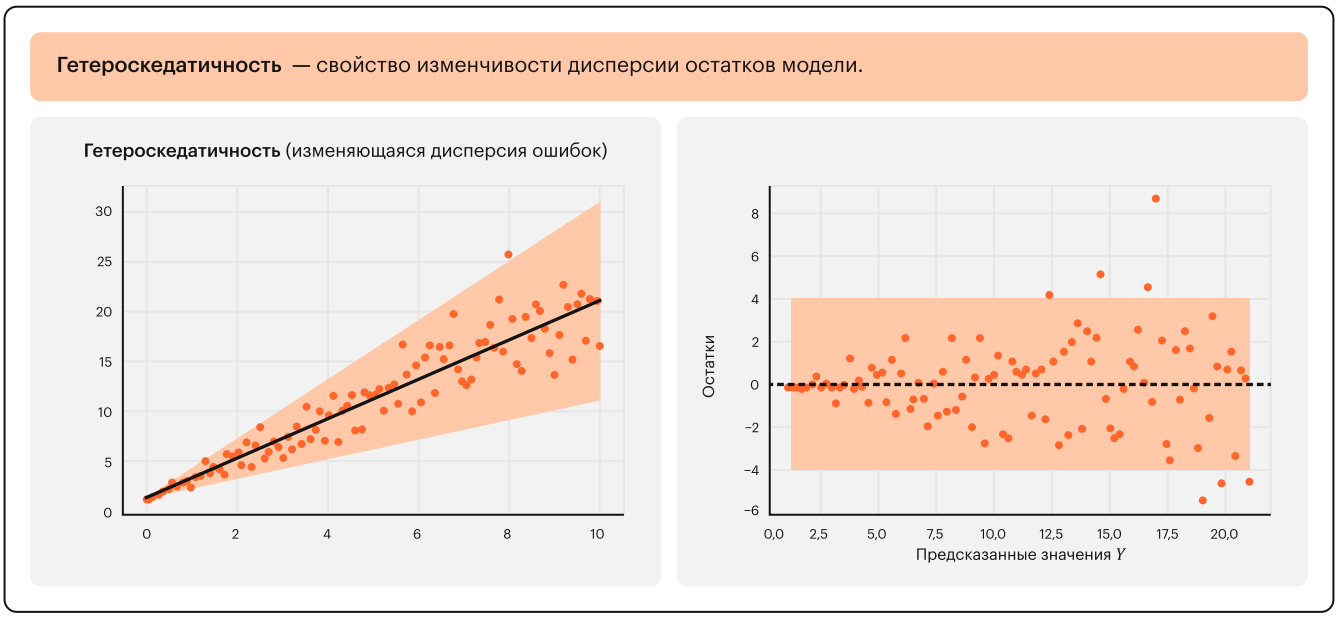

Рисунок 254. Слева — данные и прямая с расходящейся веером полосой. Справа — остатки против предсказанных значений: облако раскрывается конусом вправо.

Глаз, однако, ошибается: на малых выборках «воронку» легко увидеть там, где её нет, и наоборот. Поэтому нужен формальный критерий.

ОПРЕДЕЛЕНИЕ 14.5.5

Тест Бройша — Пагана

Проверяются гипотезы

$$H_0: \text{ гомоскедастичность}, \qquad H_1: \text{ гетероскедастичность}.$$

Шаг 1. Строим вспомогательную регрессию квадратов остатков на признаки:

$$\widehat{\varepsilon}_i^2 = \alpha_0 + \alpha_1 x_i + u_i.$$

Шаг 2. Рассчитываем статистический критерий

$$BP = n \cdot R^2_{\text{aux}} \sim \chi^2_k,$$

где R^2_{aux} — коэффициент детерминации вспомогательной регрессии, а k — количество регрессоров в ней.

Идея теста — если дисперсия ошибки постоянна, то квадраты остатков не должны систематически зависеть от признаков — вспомогательная регрессия ничего не объяснит, её R^2_{aux} будет около нуля, и статистика окажется маленькой. Если же разброс растёт с признаком, квадраты остатков растут вместе с ним, вспомогательная регрессия это поймает, и BP уйдёт в правый хвост.

Пример 14.5.11. **Гомоскедастичный случай: расчёт** Применим тест к данным с постоянным разбросом — к тем самым, что были на первой картинке этого подпункта.

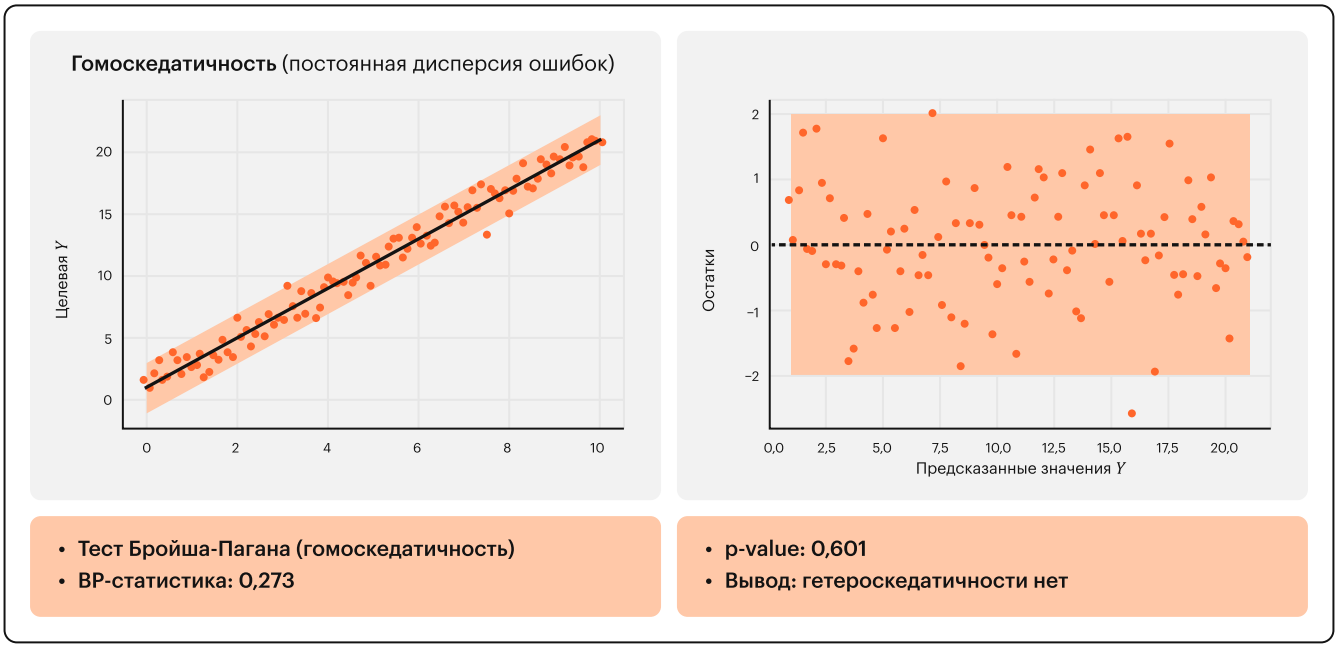

Рисунок 255. Те же две панели плюс результат теста: BP-статистика 0.273, p-value 0.601, вывод — гетероскедастичности нет.

Статистика получилась крошечной: квадраты остатков от признака практически не зависят, и вспомогательная регрессия объяснила почти ничего.

Пример 14.5.12. **Гетероскедастичный случай: расчёт**

Прогоним по этим данным тот же тест Бройша — Пагана.

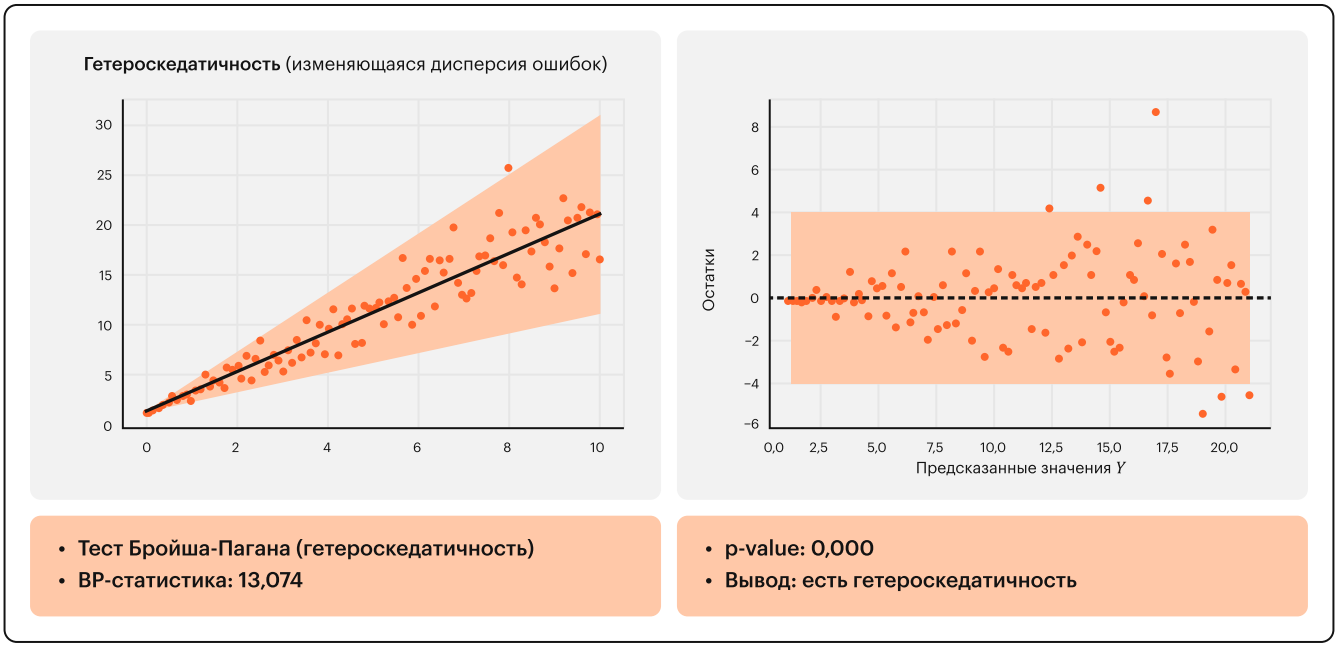

Рисунок 256. Те же две панели плюс результат: BP-статистика 13.074, p-value 0.000, вывод — есть гетероскедастичность.

Статистика выросла с 0.273 до 13.074 — почти в пятьдесят раз. Вспомогательная регрессия теперь хорошо объясняет квадраты остатков, что и означает зависимость разброса от признака.

Что происходит при нарушении:

1. МНК перестаёт быть эффективным. Раз наблюдения известны с разной точностью, разумно доверять точным больше, а МНК взвешивает их одинаково.
2. Формула $\operatorname{Var}\theta^* = \sigma^2(Z^\intercal Z)^{-1}$ становится просто неверной — она выведена в предположении $\operatorname{Var}\varepsilon = \sigma^2 I_n$. Значит неверны все стандартные ошибки, все t-статистики, все доверительные интервалы и все p-значения. Настоящая ковариационная матрица при $\operatorname{Var}\varepsilon = \Sigma$ равна

$$\operatorname{Var}\theta^* = (Z^\intercal Z)^{-1} Z^\intercal \Sigma Z (Z^\intercal Z)^{-1},$$

и совпадает с привычной только при $\Sigma = \sigma^2 I_n$.

Пример 14.5.13. Насколько врут стандартные ошибки

Возьмём те же двенадцать бюджетов и модель $X_i = 8 + 5z_i + \varepsilon_i$, но с разбросом, растущим вместе с бюджетом: пусть стандартное отклонение ошибки равно z_i^2, то есть $\operatorname{Var}\varepsilon_i = z_i^4$. Все величины ниже посчитаны теоретически, по известной Σ, — поэтому это не одна случайная реализация, а то, что происходит в среднем.

	свободный член	наклон
SE, которую напечатает МНК	5.96	2.49
истинное станд. отклонение оценки	5.03	$\mathbf{2.86}$
станд. отклонение взвешенного МНК	—	$\mathbf{1.57}$

Два вывода. Первый: стандартная ошибка наклона занижена примерно на 15% — значит t-статистика завышена, а доверительный интервал слишком узок; мы систематически переоцениваем свою уверенность. Второй: взвешенный МНК с весами $1/z_i^4$ даёт оценку почти вдвое точнее (1.57 против 2.86). Ровно это и означает «МНК перестал быть эффективным» — он остался несмещённым, но лучшая оценка теперь другая.

Что делать при нарушении. Если интересуют только корректные выводы — перейти к робастным стандартным ошибкам (они оценивают $Z^\intercal \Sigma Z$ прямо по остаткам и не требуют знать вид Σ). Если интересует ещё и точность — взвешенный МНК, но для него нужно знать или уметь оценить, как именно меняется разброс. Часто помогает и преобразование отклика: логарифм превращает мультипликативный разброс в аддитивный и снимает проблему.

(Г5) Некоррелированность ошибок

Условие требует, чтобы ошибки разных наблюдений не были связаны между собой. Нарушается оно там, где наблюдения не «выпадают» независимо, а как-то сгруппированы или упорядочены: во времени, по кластерам (ученики одного класса, сотрудники одной фирмы), в пространстве. Самый частый и самый важный случай — время.

ОПРЕДЕЛЕНИЕ 14.5.6

Автокорреляция

Автокорреляция (autocorrelation) — это корреляция временного ряда с самим собой на разных временных лагах. Показывает, насколько значения ряда в момент времени t зависят от предыдущих значений $t-k$.

Автокорреляция остатков подразумевает возможность предсказать будущие значения остатков по предыстории остатков.

ОПРЕДЕЛЕНИЕ 14.5.7

Автокорреляционная функция (ACF)

Выборочной автокорреляцией ряда $e_1, \ldots, e_n$ на лаге k называют

$$r_k = \frac{\sum_{t=k+1}^{n} \big(e_t - \bar{e}\big)\big(e_{t-k} - \bar{e}\big)}{\sum_{t=1}^{n} \big(e_t - \bar{e}\big)^2}, \qquad k = 0, 1, 2, \ldots$$

Набор $r_0, r_1, r_2, \ldots$ как функция лага и есть автокорреляционная функция, ACF (autocorrelation function); изображают её столбиками: по горизонтали лаг, по вертикали r_k. Для остатков МНК со свободным членом $\bar{e} = 0$, и формула упрощается до $r_k = \sum_t e_t e_{t-k} \big/ \sum_t e_t^2$.

Пример 14.5.14. Как выглядит автокоррелированный ряд

Возьмём ряд с трендом, автокорреляцией и сезонностью и построим для него автокорреляционную функцию — значения корреляции ряда с самим собой на лагах $1, 2, 3, \ldots$

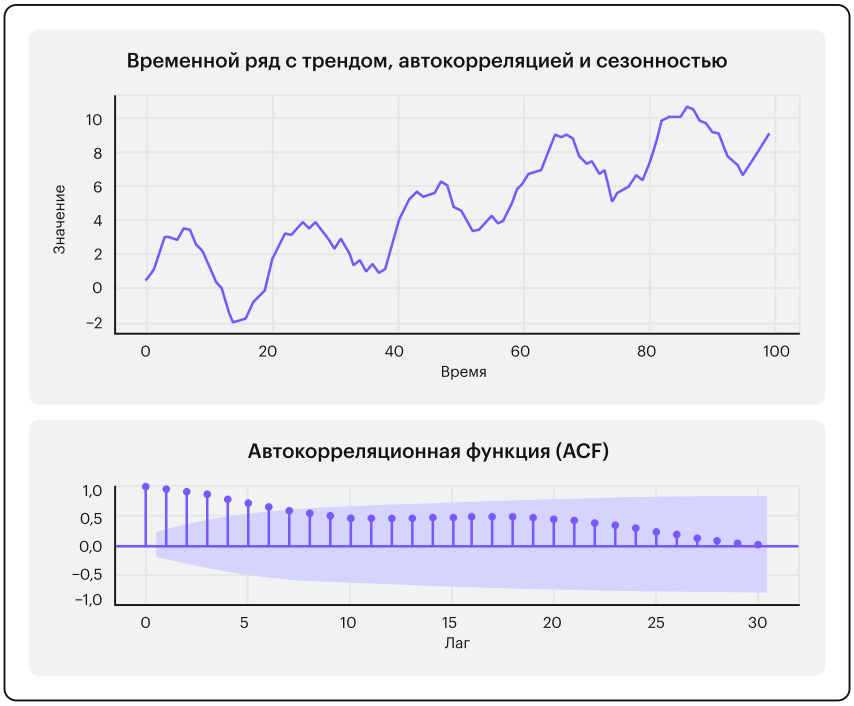

Рисунок 257. Сверху — сам ряд: видны длинные плавные подъёмы и спады вместо беспорядочных скачков. Снизу — автокорреляционная функция (ACF): столбики на первых лагах высокие и убывают медленно, выходя далеко за доверительную полосу.

Медленно убывающая ACF — признак положительной автокорреляции. Если бы наблюдения были независимы, все столбики, кроме нулевого лага, лежали бы внутри голубой полосы.

ОПРЕДЕЛЕНИЕ 14.5.8

Статистика Дарбина — Уотсона

$$DW = \frac{\sum_{t=2}^{n} \left(e_t - e_{t-1}\right)^2}{\sum_{t=1}^{n} e_t^2}.$$

Читается так:

- $d \approx 2$: автокорреляция отсутствует;
- $d < 2$: положительная автокорреляция;
- $d > 2$: отрицательная автокорреляция.

Сравнение именно с числом 2 видно из раскрытия числителя. Обозначив через r_1 выборочную корреляцию соседних остатков, при больших n получаем $DW \approx 2(1 - r_1)$. При $r_1 = 0$ это даёт 2, при $r_1 \to 1$ — ноль, при $r_1 \to -1$ — четыре. Отсюда и диапазон значений статистики: от 0 до 4.

Пример 14.5.15. Три случая на одной картинке

Сравним три ряда остатков: без автокорреляции, с сильной положительной ($\rho = 0.9$) и с сильной отрицательной ($\rho = -0.9$).

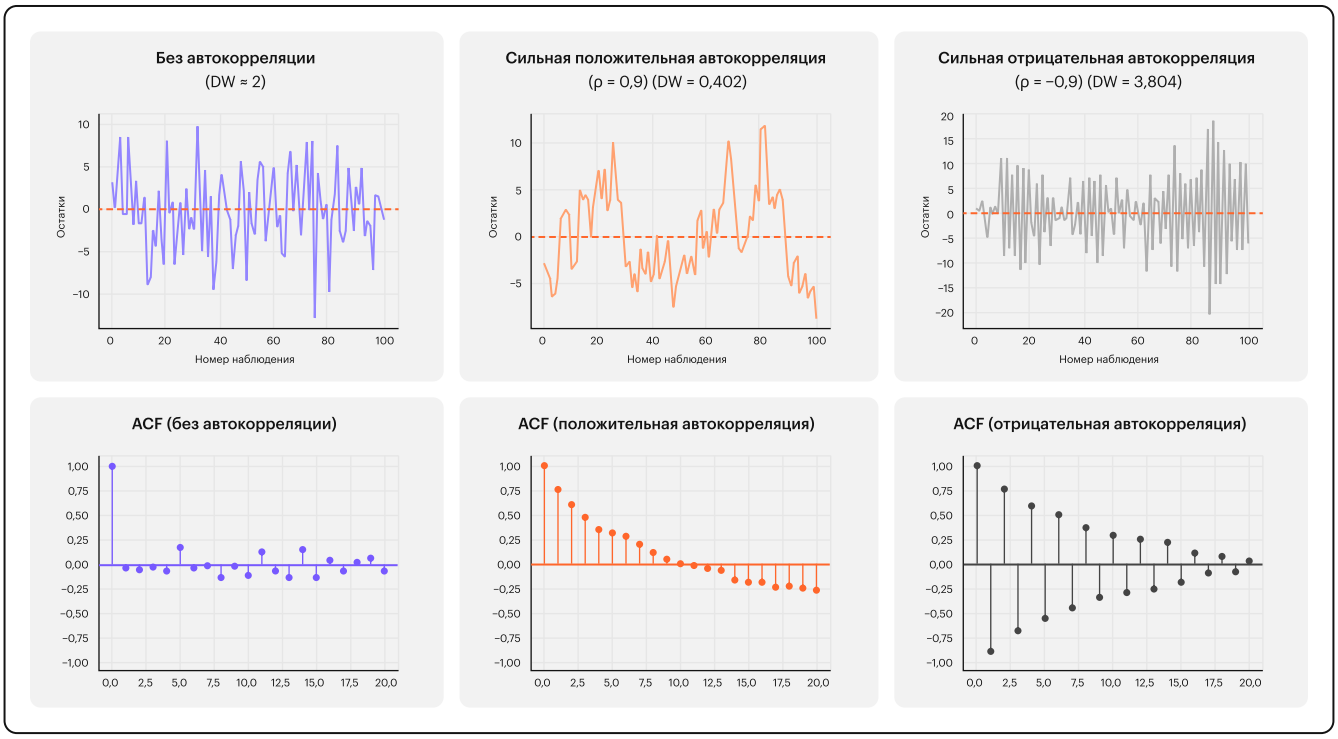

Рисунок 258. Сверху — остатки по номеру наблюдения, снизу — соответствующие ACF. Слева $DW \approx 2$, в середине $DW = 0.402$, справа $DW = 3.804$.

При положительной автокорреляции остатки идут длинными сериями одного знака — ряд «гуляет» плавно. При отрицательной, наоборот, знак меняется почти на каждом шаге — получается частокол. Независимые остатки выглядят беспорядочно, и ACF у них пустая.

При положительной автокорреляции соседние наблюдения частично дублируют друг друга: двенадцать месяцев подряд несут меньше информации, чем двенадцать независимых наблюдений. Формула же $\operatorname{Var}\theta^* = \sigma^2(Z^\intercal Z)^{-1}$ считает, что информации у нас полные двенадцать точек. Из-за этого стандартные ошибки занижены, t-статистики большие, признаки выглядят значимыми чаще, чем должны.

Пример 14.5.16. Автокорреляция увеличивает значимость вдвое

Та же модель $X_i = 8 + 5z_i + \varepsilon_i$, но ошибки идут во времени по схеме $\varepsilon_t = \rho\varepsilon_{t-1} + \nu_t$ с $\rho = 0.7$; дисперсия каждой ошибки $\sigma^2 = 0.6$. Снова считаем теоретически, по известной Σ с элементами $\sigma^2\rho^{|i-j|}$.

	свободный член	наклон
SE, которую напечатает МНК	0.50	0.21
истинное станд. отклонение оценки	1.14	**0.46**
во сколько раз занижено	2.3	**2.2**

Стандартная ошибка занижена в 2.2 раза — значит t-статистика во столько же раз завышена. Порог значимости 1.96 фактически соответствует настоящему 4.3: то, что программа объявляет уверенно значимым, на деле может быть шумом.

Есть и вторая часть проблемы: $\mathbb{E}s^2 = 0.31$ при истинном $\sigma^2 = 0.6$. Оценка дисперсии ошибки занижена вдвое, потому что остатки, «подтягиваясь» друг к другу, выглядят меньше, чем ошибки на самом деле.

Что делать при автокорреляции — стандартные ошибки, устойчивые к автокорреляции (Ньюи — Уэста), кластерные стандартные ошибки, обобщённый МНК с оценённой структурой Σ или явное моделирование динамики: добавление лага отклика или сезонных индикаторов часто убирает автокорреляцию вместе с причиной, её породившей.

Свод проверок

Четыре свойства из разобранных выше проверяются формально, и удобно держать их в одной таблице вместе с методом и распределением статистики.

Свойство	Метод	Распределение
Нулевые остатки	z-тест	$N(0,1)$
Гомоскедачитность	Тест Бройша–Пагана	χ^2_k
Автокорреляция остатков	Статистика Дарбина–Уотсона	✕
Мультиколлинеарность	Расчёт VIF	✕

Рисунок 259. У статистики Дарбина — Уотсона и у VIF стандартного распределения нет — они читаются по пороговым значениям.

Полная картина того, что происходит при нарушении каждого условия, — в таблице ниже.

Нарушено	Что происходит с МНК	Что делать
(Г1)	смещение, выводы бессмысленны	пересмотреть спецификацию: новые столбцы, преобразования
(Г2)	оценка не единственна	убрать дубли; гребневая регрессия
(Г3)	**смещение и несостоятельность**	инструментальные переменные, эксперимент, контроль пропущенных
(Г4)	несмещённость сохраняется, но оценка неэффективна, а SE неверны	робастные стандартные ошибки, взвешенный МНК
(Г5)	то же, что (Г4), но SE обычно занижены сильнее	поправки на автокорреляцию, кластерные ошибки

Важно! Нормальность ошибок в этот список **не входит**. Теорема работает при любом распределении ошибок с двумя конечными моментами. Нормальность — это предпосылка *гауссовской* линейной модели (определение 14.4.4), и нужна она для другого: для точных распределений t- и F-статистик при конечной выборке, для доверительных и прогнозных интервалов и для оптимальности среди всех несмещённых оценок. Смешивать два списка не стоит.

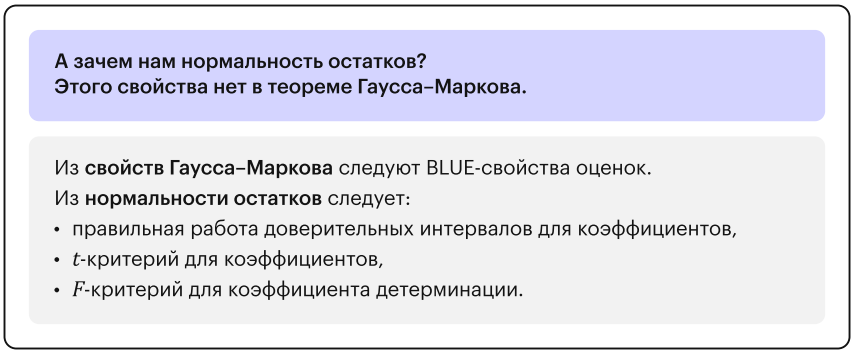

Рисунок 260. Что следует из нормальности остатков

Оптимальность МНК при выполненных условиях

Осталось показать, что при этих условиях МНК действительно оптимален. Схема доказательства такая: берём произвольную линейную несмещённую оценку, считаем дисперсию её разности с МНК и пользуемся тем, что ковариационная матрица неотрицательно определена. Перекрёстные члены при этом схлопываются — именно из-за несмещённости.

При (Г3) выполнено $\mathbb{E}\theta^* = \theta$; при (Г4)–(Г5) выполнено $\operatorname{Var}\theta^* = \sigma^2(Z^\intercal Z)^{-1}$.

ЛЕММА 14.5.1

Несмещённость и ковариация МНК

Доказательство. По линейности математического ожидания

$\mathbb{E}\theta^* = (Z^\intercal Z)^{-1} Z^\intercal Z\theta = \theta$. Для неслучайной матрицы A верно $\operatorname{Var}(AX) = A(\operatorname{Var} X)A^\intercal$; полагая $A = (Z^\intercal Z)^{-1}Z^\intercal$ и $\operatorname{Var} X = \sigma^2 I_n$, получаем $\operatorname{Var}\theta^* = (Z^\intercal Z)^{-1}Z^\intercal(\sigma^2 I_n)Z(Z^\intercal Z)^{-1} = \sigma^2(Z^\intercal Z)^{-1}$. □

ТЕОРЕМА 14.5.1

Гаусс — Марков

Пусть выполнены (Г1)–(Г5) и $T \in \mathbb{R}^{m\times k}$ — фиксированная матрица. Тогда $T\theta^*$ — оптимальная оценка параметра $T\theta$ в классе всех линейных несмещённых оценок, то есть оценок вида BX для неслучайных $B \in \mathbb{R}^{m\times n}$. Оптимальность понимается так: для любой такой оценки разность $\operatorname{Var}(BX) - \operatorname{Var}(T\theta^*)$ неотрицательно определена.

Доказательство. Пусть BX — несмещённая оценка $T\theta$. Тогда для всех θ

$$T\theta = \mathbb{E}(BX) = BZ\theta \quad\Longrightarrow\quad T = BZ.$$

Рассмотрим дисперсию разности двух оценок — она неотрицательно определена как всякая ковариационная матрица:

$$0 \preceq \operatorname{Var}\bigl(BX - T\theta^*\bigr) = \sigma^2\bigl(B - T(Z^\intercal Z)^{-1}Z^\intercal\bigr)\bigl(B^\intercal - Z(Z^\intercal Z)^{-1}T^\intercal\bigr)$$
$$= \sigma^2\Bigl(BB^\intercal - T(Z^\intercal Z)^{-1}Z^\intercal B^\intercal - BZ(Z^\intercal Z)^{-1}T^\intercal + T(Z^\intercal Z)^{-1}Z^\intercal Z(Z^\intercal Z)^{-1}T^\intercal\Bigr).$$

Подставим $T = BZ$ в средние два слагаемых: оба обращаются в $T(Z^\intercal Z)^{-1}T^\intercal$. Последнее слагаемое равно тому же. В скобках остаётся $BB^\intercal - T(Z^\intercal Z)^{-1}T^\intercal$, то есть

$$0 \preceq \sigma^2 BB^\intercal - \sigma^2 T(Z^\intercal Z)^{-1}T^\intercal = \operatorname{Var}(BX) - \operatorname{Var}(T\theta^*).$$

□

СЛЕДСТВИЕ 14.5.1

При $T = I_k$ получаем: θ^* — наилучшая линейная несмещённая оценка θ (BLUE — best linear unbiased estimator). При T — строке с единицей на j-м месте: θ_j^* — наилучшая линейная несмещённая оценка θ_j.

Теорема ограничена линейными оценками, и отсюда естественная оговорка: вдруг существует хитрая нелинейная несмещённая оценка получше? В гауссовской модели ответ — нет, докажем это.

ТЕОРЕМА 14.5.2

Полная достаточная статистика

В гауссовской линейной модели статистика $\bigl(\theta^*,\ \|X - Z\theta^*\|^2\bigr)$ является полной достаточной для параметра (θ, σ^2).

Доказательство. Поскольку $X \sim N(Z\theta, \sigma^2 I_n)$, плотность выборки равна

$$p(X) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\Bigl(-\tfrac{1}{2\sigma^2}\bigl(\|X\|^2 + \|Z\theta\|^2 - 2X^\intercal Z\theta\bigr)\Bigr).$$

Это экспоненциальное семейство с естественными параметрами, отвечающими $Z^\intercal X$ и $\|X\|^2$, причём множество естественных параметров содержит открытое множество в $\mathbb{R}^{k+1}$ — именно здесь существенно, что σ^2 тоже неизвестен и пробегает интервал. По теореме об экспоненциальных семействах статистика

$(Z^\intercal X,\ \|X\|^2)$ полна и достаточна. Остаётся предъявить биекцию: слева направо $\theta^* = (Z^\intercal Z)^{-1} Z^\intercal X$ и по теореме Пифагора $\|X - Z\theta^*\|^2 = \|X\|^2 - \|Z\theta^*\|^2$; справа налево $Z^\intercal X = Z^\intercal Z\theta^*$ и $\|X\|^2 = \|Z\theta^*\|^2 + \|X - Z\theta^*\|^2$. ▢

СЛЕДСТВИЕ 14.5.2

Оптимальность в широком классе

В гауссовской линейной модели θ^* — оптимальная оценка θ среди всех несмещённых, не только линейных; $Z\theta^*$ — оптимальная оценка $Z\theta$; s^2 — оптимальная оценка σ^2.

Идея Доказательство. Все три статистики являются несмещёнными функциями полной достаточной статистики из теоремы 14.5.2; по теореме Лемана — Шеффе такая функция есть единственная оптимальная несмещённая оценка своего параметра. ▢

Без нормальности МНК лучший среди линейных несмещённых, с нормальностью — лучший среди всех несмещённых. Именно поэтому гауссовская линейная модель — базовая модель анализа данных.

Стоит отпустить требование несмещённости — и МНК перестаёт быть лучшей оценкой. Слегка смещённая оценка может иметь настолько меньший разброс, что суммарно ошибается реже. Именно на этом размене построены гребневая регрессия и лассо. А если отпустить сам критерий «сумма квадратов», получаются другие оценки для других задач: устойчивые к выбросам или описывающие не среднее, а квантили.

6. ИНФОРМАЦИОННЫЕ КРИТЕРИИ

Скорректированный R^2 штрафует за лишние параметры, но, как мы видели, штрафует слишком мягко. Нужен инструмент, у которого размен «точность против сложности» задан по определённому принципу, а не подобран на глаз.

Идея информационных критериев такова: взять правдоподобие подогнанной модели и вычесть штраф за число параметров. Для гауссовской регрессии максимум логарифма правдоподобия считается явно:

$$-2\ln\widehat{\mathcal{L}} = n\ln\frac{\mathrm{RSS}}{n} + n(1 + \ln 2\pi).$$

Второе слагаемое от модели не зависит, поэтому при сравнении моделей на одних и тех же данных работает только первое. Всюду ниже m — полное число оцениваемых параметров модели; для гауссовской регрессии $m = k + 1$, то есть коэффициенты плюс σ^2.

$$\mathrm{AIC} = -2\ln\widehat{\mathcal{L}} + 2m.$$

ОПРЕДЕЛЕНИЕ 14.6.1

Информационный критерий Акаике (AIC)

Меньшее значение — лучше.

AIC (Akaike information criterion) приближает ожидаемую ошибку

предсказания на новых данных. Формально он оценивает расстояние Кульбака — Лейблера между истинным распределением и подогнанной моделью, и штраф $2m$ — это поправка на то, что подогнанная модель уже подсмотрела в данные. Отсюда его свойство: при росте выборки AIC выбирает модель, наиболее точную для прогноза, — но не обязательно истинную. Если истинная модель есть среди рассматриваемых, AIC с ненулевой вероятностью выберет модель чуть более сложную.

ОПРЕДЕЛЕНИЕ 14.6.2

Поправка на малую выборку (AICc)

$$\mathrm{AICc} = \mathrm{AIC} + \frac{2m(m+1)}{n-m-1}.$$

Штраф $2m$ выведен асимптотически, и при малых n он оказывается слишком слабым. AICc добавляет поправку, которая исчезает при $n \to \infty$ и становится существенной, когда n сравнимо с m. Практическое правило: при $n/m < 40$ пользоваться обычным AIC не стоит. Заметим, что при $m \to n-1$ поправка уходит в бесконечность — критерий прямо запрещает модели, в которых параметров почти столько же, сколько наблюдений.

ОПРЕДЕЛЕНИЕ 14.6.3

Информационный критерий Шварца (BIC)

$$\mathrm{BIC} = -2\ln\widehat{\mathcal{L}} + m\ln n.$$

Меньшее значение — лучше.

BIC (Bayesian information criterion), он же критерий Шварца, строится из совсем другой идеи: это приближение логарифма апостериорной вероятности модели при некоторых естественных априорных предположениях. Отсюда и другое предельное поведение: при $n \to \infty$ BIC выбирает истинную модель, если она есть среди рассматриваемых, — вероятность ошибки стремится к нулю в обе стороны.

Чем AIC отличается от BIC

Формулы различаются одним множителем: штраф за параметр равен 2 у AIC и $\ln n$ у BIC. Уже при $n = 8$ выполнено $\ln n > 2$, а при $n = 1000$ штраф Шварца почти в три с половиной раза строже. Значит BIC экономнее: он систематически выбирает более простые модели.

	AIC	BIC
Что приближает	ошибку предсказания	апостериорную вероятность модели
Штраф за параметр	2	$\ln n$
Что выбирает при $n \to \infty$	лучшую для прогноза	истинную, если она в списке
Когда уместен	цель — прогноз	цель — понять, какие признаки реальны

Практический вывод простой: если критерии согласны — вопрос закрыт; если разошлись — это сигнал, что данных не хватает,

чтобы уверенно различить модели, и выбирать нужно исходя из задачи, а не из числа.

Штраф на один параметр: 2 у AIC (не зависит от n) и $\ln n$ у BIC. Кривые пересекаются при $n \approx 7.4$; дальше BIC строже, и разрыв растёт. Пунктиром — эффективный штраф AICc при $m = 4$: при малых n он уходит вверх и запрещает модели, в которых параметров почти столько же, сколько наблюдений.

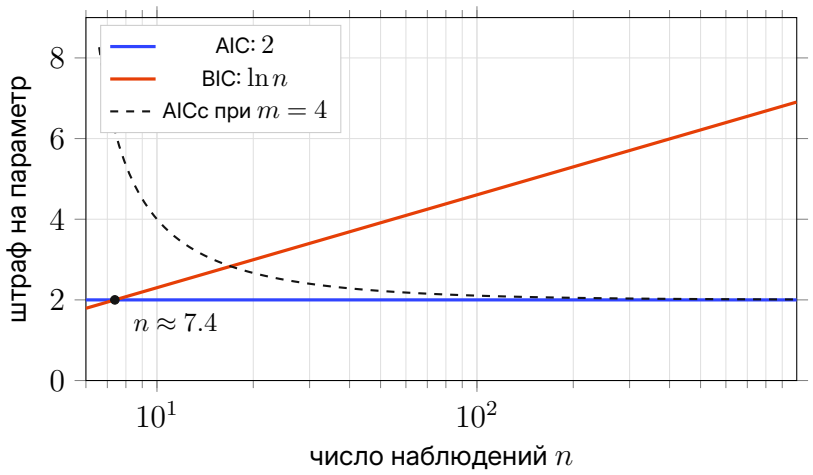

ЗАМЕЧАНИЕ

Абсолютное значение критерия смысла не имеет — значение имеют только разности между моделями на одних и тех же данных. Разность в пределах 2 обычно читают как «модели неразличимы»; свыше 10 — как уверенную разницу.

Пример 14.6.1. Промо-дни глазами критериев

Считаем для трёх моделей, $n = 12$:

Модель	k	$m = k + 1$	RSS	AIC	AICc	BIC
M_0: только свободный член	1	2	191.26	71.28	72.61	72.25
M_1: + бюджет	2	3	7.81	**34.89**	**37.89**	**36.35**
M_2: + бюджет + промо	3	4	6.68	35.03	40.75	36.97

Проверим одно значение руками. Для M_1:

$$-2\ln\widehat{\mathcal{L}} = 12\ln\left(\frac{7.81}{12}\right) + 12(1 + \ln 2\pi) = 28.89, \qquad \mathrm{AIC} = 28.89 + 2 \cdot 3 = 34.89.$$

Модель M_0 отброшена с разгромом — бюджет безусловно нужен. Все три критерия предпочитают M_1, но с очень разной уверенностью: $\Delta\mathrm{AIC} = 0.14$, $\Delta\mathrm{BIC} = 0.62$, $\Delta\mathrm{AICc} = 2.85$.

По обычному AIC разница 0.14 означает, что модели неразличимы, и никакого решения он не даёт. Это не недостаток метода, а честное отражение ситуации: $n = 12$ и $m = 4$ дают $n/m = 3$, мы глубоко в зоне малых выборок. Именно поэтому здесь нужен AICc: его поправка для M_2 равна $\frac{2\cdot4\cdot5}{12-4-1} = 5.71$ против $\frac{2\cdot3\cdot4}{12-3-1} =$

3.00 для M_1, и разрыв становится содержательным.

Отметим, что информационные критерии справились там, где R^2 и R^2_{adj} пропустили лишний признак.

Важно! Информационные критерии сравнивают модели, а не проверяют их. Лучшая из плохих моделей всё равно останется плохой, и никакой критерий об этом не сообщит. Кроме того, сравнивать по AIC можно только модели, подогнанные к одному и тому же отклику на одних и тех же наблюдениях: замена X на $\ln X$ или выброс части строк делают значения несопоставимыми.

7. НОРМАЛЬНОСТЬ ОСТАТКОВ ЛИНЕЙНОЙ РЕГРЕССИИ

Мы прошли несколько разделов и в двух местах предположили, что ошибки нормальны. Пора разобраться, где это предположение действительно работает, а где мы обошлись без него.

Нормальность *не нужна* для самой формулы МНК (она вообще не про вероятности, а про геометрию), для несмещённости оценки, для теоремы Гаусса — Маркова (ей хватает двух моментов) и для состоятельности при росте выборки.

Нормальность *нужна* для точного распределения t- и F-статистик при конечной выборке, для точных доверительных и прогнозных интервалов и для оптимальности среди всех несмещённых оценок, а не только линейных.

Иначе говоря: без нормальности коэффициенты остаются правильными, но вся проверка значимости повисает в воздухе. А ведь именно ради неё обычно всё и делается.

Хорошая новость в том, что при большой выборке это почти неважно. Оценка θ^* — линейная функция ошибок, то есть взвешенная сумма многих случайных величин, а для сумм работает центральная предельная теорема. Поэтому при растущем n оценка становится приблизительно нормальной независимо от распределения ошибок, и тесты остаются приблизительно верными. Отсюда практическое правило: чем меньше выборка, тем важнее нормальность.

ЗАМЕЧАНИЕ

Для асимптотической нормальности МНК недостаточно одного лишь роста n: нужно, чтобы ни одно наблюдение не доминировало. Формально требуется условие Хубера $\max_i h_{ii} \to 0$ — при независимых одинаково распределённых ошибках с конечной дисперсией оно необходимо и достаточно. Оно означает, что рычаг каждого отдельного наблюдения стремится к нулю.

Чем остатки отличаются от ошибок

Важно заметить, что проверяем мы не ошибки, а остатки, и это разные объекты.

УТВЕРЖДЕНИЕ 14.7.1

Остатки коррелированы и разнодисперсны

Даже при идеально выполненных предпосылках $e = (I_n - P)\varepsilon$, откуда

$$\operatorname{Var} e_i = \sigma^2(1 - h_{ii}), \qquad \operatorname{cov}(e_i, e_j) = -\sigma^2 h_{ij} \ \ (i \neq j).$$

В гауссовском случае $e \sim N\big(0, \sigma^2(I_n - P)\big)$.

Следствие для практики: остатки не являются ни независимыми, ни одинаково распределёнными, даже когда ошибки таковы. Наблюдения с большим рычагом имеют систематически меньший разброс остатка — модель к ним «притягивается». Поэтому смотреть надо на **стандартизованные остатки** $e_i/\big(s\sqrt{1 - h_{ii}}\big)$, а не на сырые. При больших n разница невелика ($h_{ii} \approx k/n \to 0$), при малых — существенна.

Формальные критерии нормальности — Шапиро — Уилка, Харке — Бера, Колмогорова — Смирнова — были введены ранее, и здесь мы ими просто пользуемся. Существенно лишь то, что применяются они к остаткам, а не к ошибкам, и потому строго говоря работают приближённо.

ЗАМЕЧАНИЕ

Асимптотические дисперсии выборочных асимметрии и эксцесса ($6/n$ и $24/n$), на которых построена статистика Харке — Бера, выведены для нормальной *выборки*. Для остатков регрессии они верны лишь приближённо — по той же причине: остатки коррелированы и разнодисперсны.

Пример 14.7.1. Диагностика на наших данных

Стандартизованные остатки модели «выручка $\sim$ бюджет» ($n = 12$, $k = 2$):

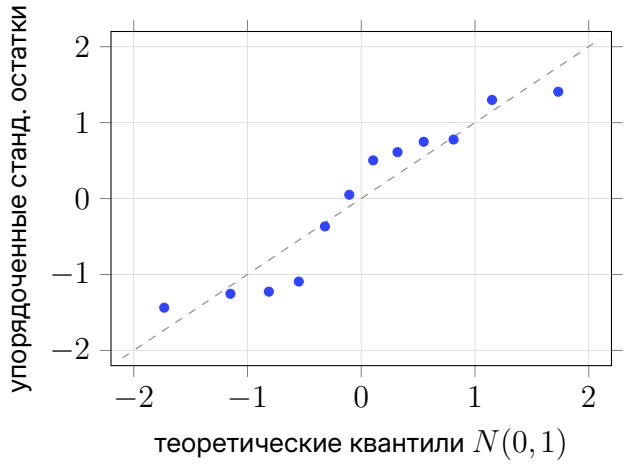

Точки держатся около диагонали. Заметен паттерн в виде буквы S: на краях остатки чуть ближе к нулю, чем положено нормальным, — намёк на облегчённые хвосты, что согласуется с выборочным эксцессом 1.56 при норме 3. Но при $n = 12$ такая картина ничего не доказывает: у двенадцати точек разброс формы огромен. Единственный вывод, который можно сделать честно: грубых нарушений по графику не видно.

Формальная проверка даёт $S = -0.154$, $K = 1.563$ и статистику 1.08 против χ^2_2, то есть $p = 0.58$. Интерпретировать это следует осторожно: при $n = 12$ тест почти лишён мощности, и «не отвер-

гается» здесь означает скорее «данных мало, чтобы что-то утверждать», чем «нормальность подтверждена».

Заодно посмотрим на рычаги: $h_{ii} \in [0.084,\ 0.314]$ и $\sum_i h_{ii} = 2.000 = k$. Средний рычаг равен $k/n = 0.167$; ни одно наблюдение не тянет прямую на себя чрезмерно. Проверим и то, что $\sum_i e_i \approx 0$ с точностью до машинной погрешности, — как и требует наличие свободного члена (теорема 14.2.1).

Что делать, если нормальность всё же нарушена? Преобразовать отклик (логарифм часто выправляет и скошенность, и неоднородность разброса); перейти к робастным стандартным ошибкам или бутстрапу, если проблема только в выводах, а не в самих коэффициентах; сменить целевую функцию, если причина в выбросах; или признать, что модель специфицирована неверно, — скошенные остатки часто говорят именно об этом, а не о «неправильном» распределении ошибок.

8. MSE и MAE

До сих пор мы минимизировали сумму квадратов, и теорема Гаусса — Маркова объяснила, почему этот выбор хорош. Но она же очертила границы: хорош он в классе линейных несмещённых оценок и при выполненных условиях. Стоит поменять функцию потерь — и меняется сам объект, который мы оцениваем.

ОПРЕДЕЛЕНИЕ 14.8.1

Две функции потерь

Метод наименьших квадратов минимизирует $\sum_i \bigl(X_i - z_i^{\mathsf{T}}\theta\bigr)^2$, метод наименьших модулей — $\sum_i \bigl|X_i - z_i^{\mathsf{T}}\theta\bigr|$. Соответствующие метрики качества — $\mathrm{MSE} = \frac{1}{n}\sum_i e_i^2$ и $\mathrm{MAE} = \frac{1}{n}\sum_i |e_i|$.

ТЕОРЕМА 14.8.1

Что оценивает каждая потеря

Пусть ξ — случайная величина с функцией распределения F. Тогда $\operatorname{argmin}_a \mathbb{E}(\xi - a)^2$ достигается в $\mathbb{E}\xi$, а множество точек минимума $\mathbb{E}|\xi - a|$ есть в точности множество медиан ξ, то есть множество тех a, для которых

$$F(a-) \leqslant \tfrac{1}{2} \leqslant F(a).$$

Доказательство. Для квадратичной потери при любом a

$$\mathbb{E}(\xi - a)^2 = \operatorname{Var}\xi + (\mathbb{E}\xi - a)^2,$$

поскольку перекрёстный член $2(\mathbb{E}\xi - a)\mathbb{E}(\xi - \mathbb{E}\xi)$ равен нулю. Первое слагаемое от a не зависит, второе неотрицательно и обращается в ноль лишь при $a = \mathbb{E}\xi$.

Для абсолютной потери положим $g(a) = \mathbb{E}|\xi - a|$. Функция g выпукла как математическое ожидание выпуклых по a функций, поэтому у неё в каждой точке существуют односторонние произ-

водные, и они равны

$$g'_-(a) = 2F(a-) - 1, \qquad g'_+(a) = 2F(a) - 1.$$

Точка a доставляет минимум выпуклой функции тогда и только тогда, когда $g'_-(a) \leqslant 0 \leqslant g'_+(a)$, что и даёт условие $F(a-) \leqslant \frac{1}{2} \leqslant F(a)$. □

Важно! Формулировка «минимум достигается там, где $F(a) = 1/2$» верна для непрерывного распределения. Если F имеет скачок через уровень $1/2$, точки с $F(a) = 1/2$ может не существовать вовсе, а минимум при этом достигается — в самой точке скачка. Это важно, т.к. любая конечная выборка задаёт дискретное распределение.

Обратная ситуация тоже возможна: если F имеет горизонтальный участок на уровне $1/2$, условие выполняется на целом отрезке, и минимум достигается на всём этом отрезке. Отсюда — прямая причина неединственности решения метода наименьших модулей: для выборки чётного объёма любая точка между двумя центральными наблюдениями минимизирует сумму модулей. В регрессии это проявляется как целый многогранник оптимальных решений; программы возвращают одну из его вершин, и разные реализации могут вернуть разные.

Почему условие записано двойным неравенством. Слева F перепрыгивает уровень $1/2$: точки с $F(a) = 1/2$ не существует, а медиана есть — она в точке скачка. Справа у F горизонтальная площадка ровно на уровне $1/2$: условию удовлетворяет целый отрезок, и любая его точка является медианой.

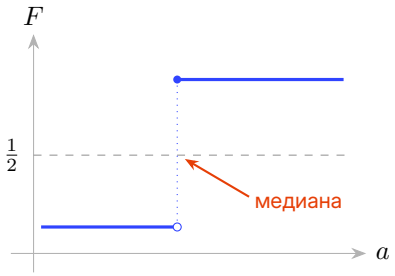

скачок через уровень $\frac{1}{2}$

плато на уровне $\frac{1}{2}$

Практическое следствие теоремы принципиально: *МНК описывает условное среднее отклика, МНМ — условную медиану*. Пока распределение симметрично, эти величины совпадают, и разница только в устойчивости. На скошенных данных — доходы, длительности, чеки — среднее и медиана расходятся, и выбор приходится делать содержательно: средний чек и медианный чек отвечают на разные вопросы.

Различие удобно видеть через производную потери по остатку — она показывает, какой вклад наблюдение вносит в уравнения

оценки:

$$\frac{d}{du}\left(\tfrac{1}{2}u^2\right) = u \qquad \text{против} \qquad \frac{d}{du}|u| = \operatorname{sign} u \quad (u \neq 0).$$

В первом случае вклад пропорционален промаху и не ограничен; во втором — ограничен единицей. Отсюда вся разница в устойчивости. У функции Хубера, которая ведёт себя как квадрат вблизи нуля и как модуль вдали, производная ограничена и при этом непрерывна — отсюда её популярность как компромисса.

Сверху — три функции потерь, снизу — их производные по остатку. У квадратичной потери вклад наблюдения растёт неограниченно, у модуля он ограничен единицей, у Хубера ограничен и при этом непрерывен — отсюда её роль компромисса.

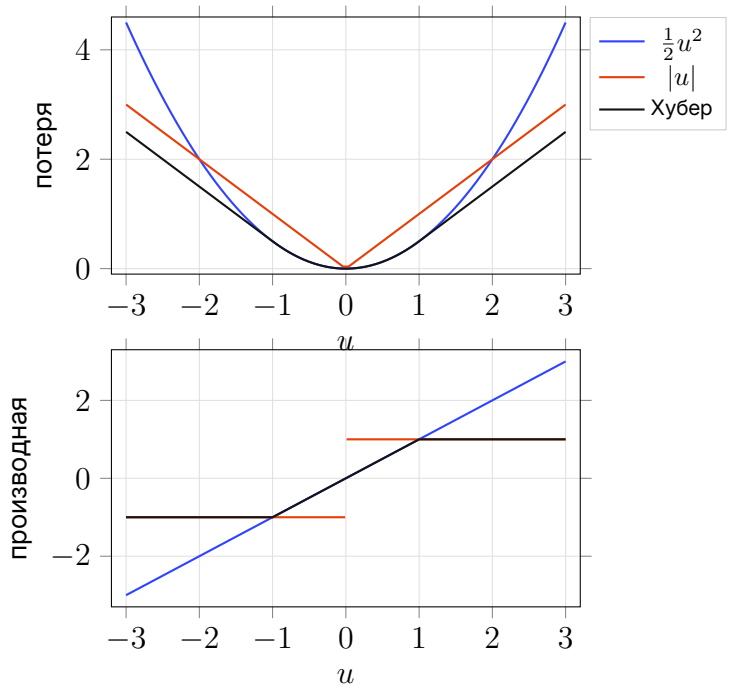

Пример 14.8.1. Один выброс

Возьмём данные сквозного примера и заменим выручку последнего месяца с 25.9 на 45.9 — как если бы в выгрузку попал разовый оптовый заказ или сдвинулась запятая.

	МНК (квадраты)	**МНМ** (модули)
исходные данные	$\widehat{X} = 7.57 + 5.13\,z$	$\widehat{X} = 7.05 + 5.39\,z$
месяц 12: $25.9 \to 45.9$	$\widehat{X} = 1.21 + \mathbf{8.67}\,z$	$\widehat{X} = 6.36 + \mathbf{5.70}\,z$
сдвиг наклона	$+3.54$ $(+69\%)$	$+0.32$ $(+5.9\%)$

Одно наблюдение из двенадцати изменило оценку отдачи от рекламы более чем в полтора раза, тогда как оценка МНМ сдвинулась на 6%. Тот же эффект виден и без регрессии: среднее выручки поднялось с 19.20 до 20.87, а медиана осталась ровно на 19.65 — порядок наблюдений не изменился.

Есть и обратная сторона. Если 45.9 — не ошибка, а настоящее значение, то устойчивость обернётся недостатком: МНМ проигнорирует реальный сигнал. Устойчивость и чувствительность — две стороны одного свойства, и выбор между ними определяется содержанием задачи.

Крайняя правая точка поднята с 25.9 до 45.9. Прямая МНК развернулась (наклон $5.13 \to 8.67$), прямая наименьших модулей почти не сдвинулась ($5.39 \to 5.70$).

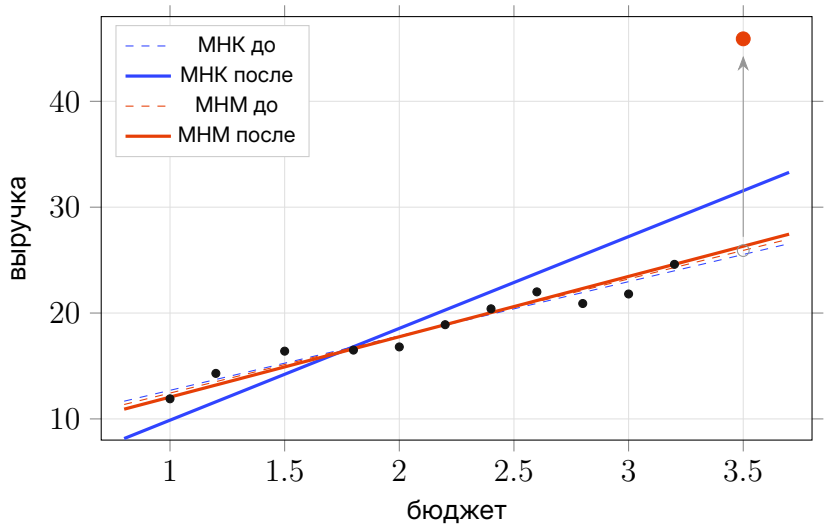

Почему же МНК считается формулой, а МНМ — нет? Условие первого порядка для квадратичной потери линейно по θ и приводит к нормальным уравнениям. Для абсолютной потери целевая функция кусочно-линейна и не дифференцируема на гиперплоскостях $X_i = z_i^\intercal \theta$, поэтому условие оптимальности формулируется через субградиент и в явном виде не решается. Задача сводится к линейному программированию: вводя $u_i, v_i \geqslant 0$ с $X_i - z_i^\intercal \theta = u_i - v_i$, минимизируем $\sum_i (u_i + v_i)$ при линейных ограничениях. Оптимум достигается в вершине допустимого многогранника, а вершине отвечает гиперплоскость, проходящая ровно через k наблюдений выборки.

9. ГРЕБНЕВАЯ РЕГРЕССИЯ

Вернёмся к мультиколлинеарности. Когда признаки почти дублируют друг друга, матрица $Z^\intercal Z$ близка к вырожденной, элементы $(Z^\intercal Z)^{-1}$ огромны, и стандартные ошибки становятся очень большими. Формально условия Гаусса — Маркова при этом *не* нарушены: (Г2) требует лишь отсутствия точной зависимости. МНК остаётся наилучшей линейной несмещённой оценкой — просто «наилучшая» здесь означает «лучшая среди очень плохих».

Пример 14.9.1. К данным сквозного примера добавим число

Почти дублирующий признак

показов рекламы, которое почти пропорционально бюджету: $\operatorname{corr}(\text{бюджет}, \text{показы}) = 0.9990$.

Модель	признак	θ_j^*	SE	t
выручка $\sim$ бюджет	бюджет	5.132	0.335	$\mathbf{15.33}$
выручка $\sim$ бюджет $+$ показы	бюджет	8.223	8.049	1.02
	показы	-0.104	0.270	-0.38

Стандартная ошибка при бюджете выросла с 0.34 до 8.05 — в 24 раза; t упало с 15.3 до 1.02, хотя данные о бюджете не изменились. Коэффициент при показах отрицателен: модель утверждает, что рост числа показов снижает выручку. При этом $R^2 = 0.960$, а глобальный $F = 107.6$ против порога $f^{2,9}_{0.95} = 4.26$ — регрессия в целом высокозначима. Перед нами ровно то сочетание, о котором говорилось выше: F значим, ни один t — нет.

Диагностика подтверждает причину: VIF равен 529 для обоих признаков при числе обусловленности 46 — при пороге 5.

Данные здесь честно сообщают: суммарный эффект двух признаков определён хорошо, а его разделение между ними — нет. МНК обязан выдать точку, и он выдаёт — произвольную точку почти плоского минимума. Лечение состоит в том, чтобы отказаться от несмещённости и добавить к цели штраф за размер коэффициентов.

ОПРЕДЕЛЕНИЕ 14.9.1
Гребневая оценка

$$\theta_\lambda^* = \operatorname{argmin}_\theta \left\{ \|X - Z\theta\|^2 + \lambda \|\theta\|^2 \right\}, \qquad \lambda \geqslant 0.$$

ТЕОРЕМА 14.9.1
Явный вид гребневой оценки

При любом $\lambda > 0$ решение существует, единственно и равно

$$\theta_\lambda^* = (Z^\intercal Z + \lambda I_k)^{-1} Z^\intercal X$$

независимо от того, обратима ли $Z^\intercal Z$.

Доказательство. Целевая функция $Q(\theta) = \|X - Z\theta\|^2 + \lambda\|\theta\|^2$ дифференцируема, и

$$\frac{\partial Q}{\partial \theta} = -2Z^\intercal X + 2Z^\intercal Z\theta + 2\lambda\theta = 0 \iff (Z^\intercal Z + \lambda I_k)\theta = Z^\intercal X.$$

Матрица $Z^\intercal Z$ неотрицательно определена, поэтому для любого $v \neq 0$

$$v^\intercal (Z^\intercal Z + \lambda I_k) v = \|Zv\|^2 + \lambda \|v\|^2 \geqslant \lambda \|v\|^2 > 0,$$

то есть $Z^\intercal Z + \lambda I_k$ положительно определена и обратима независимо от ранга Z. Гессиан $2(Z^\intercal Z + \lambda I_k)$ положительно определён, значит Q строго выпукла и стационарная точка — единственный глобальный минимум. $\square$

Последнее замечание существенно: гребневая регрессия определена и тогда, когда обычный МНК не определён вовсе, — в част-

ности при $k > n$.

Обозначив $A_\lambda = (Z^\intercal Z + \lambda I_k)^{-1}$, получаем

$$\mathbb{E}\theta^*_\lambda = A_\lambda Z^\intercal Z\,\theta, \qquad \operatorname{Var}\theta^*_\lambda = \sigma^2 A_\lambda\, Z^\intercal Z\, A_\lambda,$$

и смещение равно $-\lambda A_\lambda \theta$: оно обращается в ноль лишь при $\lambda = 0$ либо $\theta = 0$. Название происходит от прибавления λ к диагонали $Z^\intercal Z$ — на графике поверхности значений это выглядит как приподнятый гребень вдоль диагонали.

Две обязательные оговорки

Формула применяется не к исходным данным напрямую, и нарушение любого из двух правил ниже даёт бессмысленный результат.

Свободный член не штрафуется. Штраф $\lambda\|\theta\|^2$ должен распространяться только на коэффициенты при признаках. Иначе оценка перестанет быть инвариантной относительно сдвига отклика: прибавив ко всем значениям выручки константу, мы получим не сдвинутую, а качественно другую модель. Технически отклик центрируют, признаки центрируют, а свободный член оценивают отдельно как $\overline{X}$.

Признаки обязательно приводятся к единой шкале. Штраф $\sum_j \theta_j^2$ складывает величины разной размерности, поэтому признак, измеренный в рублях, и признак, измеренный в миллионах рублей, получат совершенно разные штрафы за один и тот же содержательный эффект.

Стандартизация переводит признак в шкалу с нулевым средним и единичной дисперсией:

$$z'_{ij} = \frac{z_{ij} - \bar{z}_j}{\widehat{\sigma}_j}.$$

Нормализация (min-max) переводит признак на отрезок $[0, 1]$:

$$z'_{ij} = \frac{z_{ij} - \min_i z_{ij}}{\max_i z_{ij} - \min_i z_{ij}}.$$

ОПРЕДЕЛЕНИЕ 14.9.2

Стандартизация и нормализация

Стандартизация уместна для признаков, распределённых близко к нормальному; нормализация — для признаков с ограниченным размахом или сильно несимметричных, где выборочные среднее и стандартное отклонение плохо описывают шкалу.

Все утверждения о гребне доказываются через сингулярное разложение матрицы признаков.

Пусть $r = \operatorname{rank} Z \leqslant \min(n, k)$ и

$$Z = UDV^\intercal, \qquad U \in \mathbb{R}^{n\times r}, \quad V \in \mathbb{R}^{k\times r}, \quad D = \operatorname{diag}(d_1, \dots, d_r),$$

где столбцы U и V ортонормированы, а $d_1 \geqslant \dots \geqslant d_r > 0$.

Важно! Ранговая форма здесь не педантизм. Записать разложение с k столбцами у U можно только при $k \leqslant n$: в $\mathbb{R}^n$ больше n ортонормированных векторов не бывает. Между тем гребневая регрессия применяется как раз тогда, когда $k > n$, — и в этом случае $r \leqslant n < k$, все суммы идут до r, а не до k. По той же причине все d_j ниже строго положительны: нулевые сингулярные числа в разложение ранга r просто не входят.

Тогда $Z^\intercal Z = V D^2 V^\intercal$, и прямое вычисление даёт

$$Z\theta^*_\lambda = \sum_{j=1}^{r} u_j \frac{d_j^2}{d_j^2 + \lambda} u_j^\intercal X,$$

тогда как при полном ранге $\quad Z\theta^*_0 = \sum_{j=1}^{r} u_j u_j^\intercal X.$

Гребень действует покомпонентно в базисе главных направлений матрицы признаков, домножая j-ю компоненту на коэффициент $d_j^2/(d_j^2 + \lambda) \in (0, 1)$. Направления с большим d_j — те, по которым данные сильно варьируются и эффект оценивается надёжно, — почти не затрагиваются. Направления с малым d_j, вдоль которых признаки почти дублируют друг друга, сжимаются сильно.

Отсюда же видно, почему при мультиколлинеарности дисперсия МНК велика: в $\operatorname{Var}\theta^*_0 = \sigma^2 V D^{-2} V^\intercal$ входят величины $1/d_j^2$, и малое d_r делает их огромными. Гребень заменяет $1/d_j^2$ на $d_j^2/(d_j^2 + \lambda)^2$, что ограничено при любом d_j.

ОПРЕДЕЛЕНИЕ 14.9.3

Эффективное число параметров

$$\operatorname{df}(\lambda) = \operatorname{tr}\bigl(Z(Z^\intercal Z + \lambda I_k)^{-1} Z^\intercal\bigr) = \sum_{j=1}^{r} \frac{d_j^2}{d_j^2 + \lambda}.$$

При $\lambda = 0$ получаем $\operatorname{df} = r$, что согласуется с $\operatorname{tr} P = k$ при полном ранге; при $\lambda \to \infty$ величина стремится к нулю. Это и есть та мягкая размерность модели, которая подставляется вместо k при попытке применить информационные критерии.

ТЕОРЕМА 14.9.2

Хоэрл — Кеннард

Существует $\lambda > 0$, при котором среднеквадратичная ошибка гребневой оценки строго меньше, чем у МНК.

Доказательство. Схема. В базисе сингулярного разложения задача распадается на независимые одномерные. Для j-й компоненты, обозначив $\alpha_j = v_j^\intercal \theta$, имеем

$$\operatorname{MSE}_j(\lambda) = \underbrace{\frac{\sigma^2 d_j^2}{(d_j^2 + \lambda)^2}}_{\text{дисперсия}} + \underbrace{\frac{\lambda^2 \alpha_j^2}{(d_j^2 + \lambda)^2}}_{\text{квадрат смещения}}.$$

Дифференцируя по λ и подставляя $\lambda = 0$, получаем $\frac{d\operatorname{MSE}_j}{d\lambda}\big|_{\lambda=0} = -2\sigma^2/d_j^4 < 0$; здесь существенно, что $d_j > 0$, что обеспечено ранговой формой разложения. Производная строго отрицательна при любом α_j, поэтому суммарная ошибка убывает при малом

росте λ, и найдётся $\lambda > 0$, при котором она строго меньше, чем при $\lambda = 0$. □

Инсайт Обратим внимание на структуру: в производной вклад смещения при $\lambda = 0$ равен нулю (смещение входит квадратично), а вклад дисперсии — первого порядка. Именно поэтому обмен всегда выгоден на старте. Насколько далеко по λ стоит идти, зависит от неизвестных α_j, — потому теорема и не даёт конкретного выбора λ, и на практике его подбирают кросс-валидацией.

Размен смещения и дисперсии для одной компоненты при $\sigma^2 = d_j^2 = \alpha_j = 1$. Дисперсия убывает, квадрат смещения растёт от нуля, а их сумма имеет минимум во внутренней точке $\lambda^* > 0$. В нуле касательная к сумме идёт вниз — потому обмен и выгоден на старте.

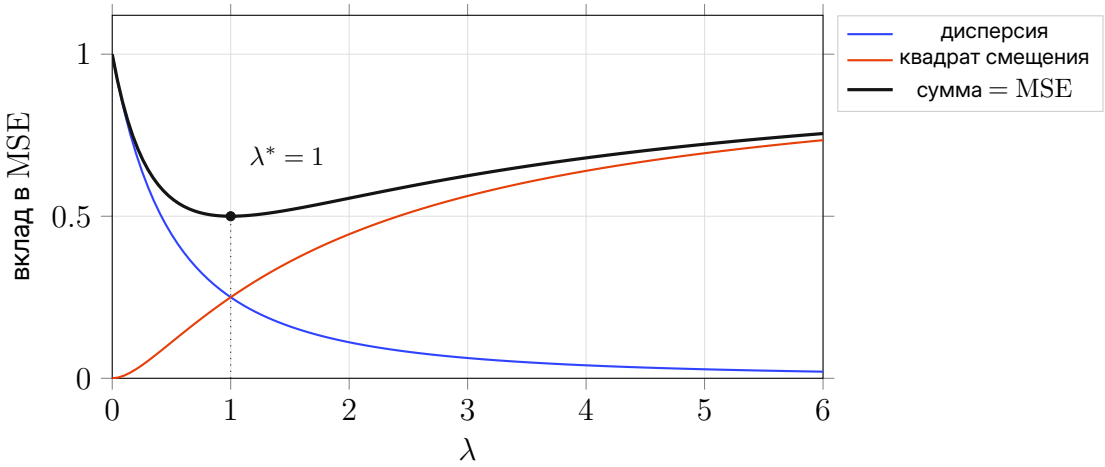

Пример 14.9.2. Гребневой путь

Продолжим пример с бюджетом и показами. Признаки стандартизованы, отклик центрирован.

λ	$\theta_{\text{бюджет}}$	$\theta_{\text{показы}}$	сумма
0 (МНК)	6.266	**−2.358**	3.908
0.1	2.385	1.506	3.892
1	1.924	1.827	3.751
5	1.627	1.607	3.234
20	1.068	1.063	2.131
100	0.379	0.378	0.756

Уже при $\lambda = 0.1$ бессмысленный отрицательный знак исчезает, а коэффициенты становятся близкими друг к другу — что содержательно разумно для двух почти одинаковых признаков.

Важно другое: сумма коэффициентов меняется гораздо медленнее, чем они сами. Это точное отражение того, что данные хорошо определяют суммарный эффект и плохо — его распределение между признаками. Гребень стабилизирует именно ту часть

решения, которая была неустойчива, почти не трогая определённую данными.

И ни один коэффициент при этом не обращается в ноль: гребневая регрессия сжимает, но не отбирает.

Гребневой путь для бюджета и показов. При $\lambda \to 0$ коэффициенты разъезжаются (у показов знак отрицательный), при росте λ быстро сближаются и дальше вместе стягиваются к нулю, ни разу его не достигая. Пунктир — их сумма: она почти не меняется на начальном участке, потому что суммарный эффект данные определяют хорошо, а его деление — нет.

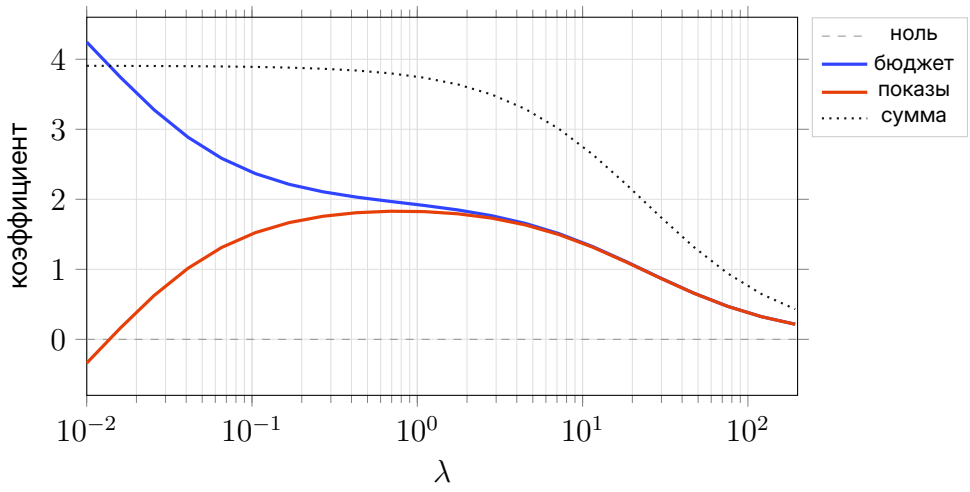

10. ЛАССО

Отбор даёт другой штраф. Замена суммы квадратов коэффициентов на сумму модулей меняет поведение решения качественно.

$$\theta^{\mathrm{L}}_{\lambda} = \operatorname{argmin}_{\theta} \left\{ \|X - Z\theta\|^2 + \lambda \sum_{j=1}^{k} |\theta_j| \right\}, \qquad \lambda \geqslant 0.$$

ОПРЕДЕЛЕНИЕ 14.10.1

Оценка лассо

Почему модуль отбирает, а квадрат — нет, лучше всего видно в ортогональном случае.

При $Z^{\mathsf{T}}Z = I_k$ имеем $\theta^{\mathrm{L}}_{\lambda,j} = S\bigl(\theta^*_j, \lambda/2\bigr)$, где θ^* — МНК, а

$$S(a,t) = \operatorname{sign}(a) \cdot \max\bigl(|a| - t,\, 0\bigr).$$

Для гребневой оценки в тех же условиях $\theta_{\lambda,j} = \theta^*_j/(1+\lambda)$.

ТЕОРЕМА 14.10.1

Мягкий порог

Сравнение двух формул и есть ответ. Гребень умножает коэффициент на строго положительное число, меньшее единицы, — ноль не получается ни при каком λ. Лассо вычитает из модуля

фиксированную величину и обрезает снизу нулём — всё, что было меньше порога, обнуляется. Геометрически это следствие того, что шар ℓ_1 имеет углы на осях координат, и линии уровня касаются его именно в углах.

Что каждый штраф делает с коэффициентом МНК в ортогональном случае. Гребень умножает его на $1/(1+\lambda)$ — прямая через начало координат, ноль достигается только в нуле. Лассо вычитает порог и обрезает — получается плоский участок, на котором коэффициент ровно нулевой.

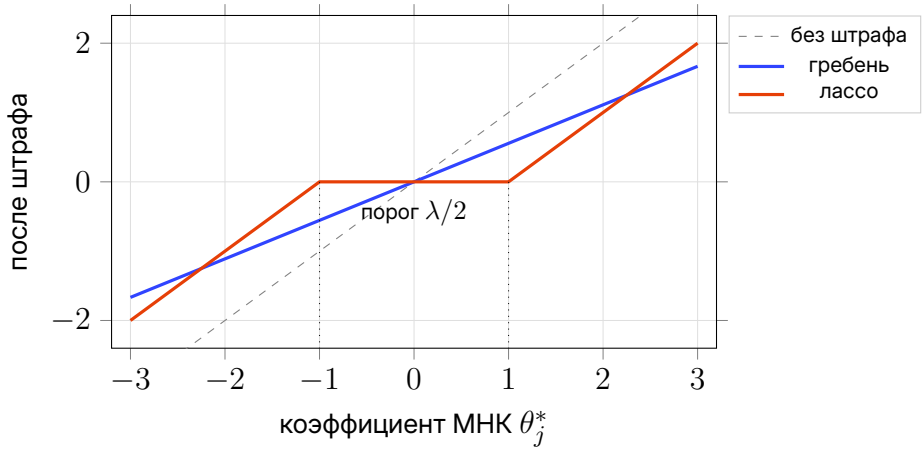

Вектор θ является решением задачи из определения 14.10.1 тогда и только тогда, когда для каждого j

$$\begin{cases} z_j^\intercal (X - Z\theta) = \dfrac{\lambda}{2} \operatorname{sign} \theta_j, & \theta_j \neq 0, \\ \left| z_j^\intercal (X - Z\theta) \right| \leqslant \dfrac{\lambda}{2}, & \theta_j = 0. \end{cases}$$

ТЕОРЕМА 14.10.2

Условия ККТ

Все коэффициенты равны нулю тогда и только тогда, когда $\lambda \geqslant \lambda_{\max} := 2 \max_j \left| z_j^\intercal X \right|$ (отклик центрирован).

СЛЕДСТВИЕ 14.10.1

Когда модель пуста

Целевая функция лассо выпукла, но не дифференцируема в нуле по каждой координате, поэтому условие оптимальности записывается через субградиент, а решение не выражается формулой и считается численно.

Пример 14.10.1. blue, red **Путь лассо на тех же данных**

Те же бюджет и показы, стандартизованные, отклик центрирован.

λ	$\theta_{\text{бюджет}}$	$\theta_{\text{показы}}$	ненулевых
0 (МНК)	6.212	−2.304	2
5	3.702	**0**	1
20	3.077	**0**	1
50	1.827	**0**	1
100	**0**	**0**	0

Сравним с гребневым путём. Там при $\lambda = 0.1$ коэффициенты стали равны 2.385 и 1.506 — оба признака сохранились и получили сопоставимые веса. Здесь уже при $\lambda = 5$ показы исключены полностью, а весь эффект передан бюджету.

Гребень говорит: «данных не хватает, чтобы разделить вклад, поэтому распределим его поровну». Лассо говорит: «второй признак не добавляет ничего сверх первого, уберём его».

Выбор именно бюджета, а не показов, почти произволен: корреляция между ними 0.999, и небольшое изменение данных вполне может привести к обратному выбору.

Важные моменты при применении лассо

1. Неустойчивость отбора при коррелированных признаках. Из группы сильно связанных признаков лассо обычно оставляет ровно один, и какой именно — определяется случайными деталями выборки. Вывод «признак A важен, а B нет» из такого отбора не следует.

2. Ограничение на число отбираемых признаков. При $k > n$ лассо отбирает не более n признаков. Это важно учитывать в задачах с большим числом признаков.

3. Смещение крупных коэффициентов. Как показывает теорема 14.10.1, порог вычитается одинаково из всех ненулевых коэффициентов, поэтому величина эффекта систематически занижается.

4. Вывод после отбора невалиден. Это наиболее часто нарушаемое правило. Если признаки отобраны по тем же данным, на которых затем строятся t-статистики и доверительные интервалы, то стандартные распределения неприменимы: они выведены для *заранее фиксированного* набора признаков. Отбор — это тоже подглядывание в данные, и p-значения после него систематически занижены.

Важно! Два последних пункта связаны, и на их стыке возникает распространённая ошибка. Хочется рассуждать так: смещение от сжатия лечится переоценкой обычным МНК на отобранном подмножестве, и оценка снова становится несмещённой.

Это неверно. Переоценка действительно убирает смещение *от сжатия*, но лишь условно — при фиксированном наборе признаков. Набор же выбран по тем же данным и потому случаен, так что безусловно оценка остаётся смещённой: подмножество систематически обогащено признаками, которые на этой конкретной выборке выглядели сильнее, чем они есть. Если отбор выбросил действительно релевантный признак, добавляется смещение пропущенной переменной, и оно переоценкой не лечится вовсе.

Корректные процедуры — селективный вывод, расщепление выборки, дебиасинг лассо — существуют, Если нужны именно несмещённые оценки эффектов, набор признаков должен быть зафиксирован до знакомства с данными.

Что выбрать: четыре типичные ситуации

Комбинация двух штрафов устраняет часть недостатков каждого:

$$\|X - Z\theta\|^2 + \lambda\Big(\alpha \sum_j |\theta_j| + (1-\alpha)\sum_j \theta_j^2\Big), \qquad \alpha \in [0,1].$$

При $\alpha = 1$ получаем лассо, при $\alpha = 0$ — гребень. Промежуточные значения сохраняют способность обнулять коэффициенты, но коррелированные признаки входят или исключаются группой, а не поодиночке, — что снимает первую из перечисленных тонкостей и делает отбор гораздо устойчивее. Такую комбинацию называют эластичной сетью.

Итого у нас четыре инструмента: МНК, гребень, лассо и эластичная сеть. Выбор между ними определяется не тем, какой из них «лучше», а тем, какой вопрос задан. Разберём четыре типичные ситуации.

Пример 14.10.2. Все признаки важны, нужен прогноз → гребень

Предсказываем месячную выручку по двадцати показателям маркетинга: бюджеты по каналам, показы, клики, охваты. Все они по-своему влияют на выручку, и выбрасывать какой-то из них нет содержательных оснований; при этом многие сильно связаны между собой.

Здесь нужна гребневая регрессия. Она сожмёт коэффициенты, стабилизирует те направления, которые данные плохо различают, и даст меньшую ошибку прогноза, чем МНК, — но сохранит в модели все двадцать признаков. Читать отдельные коэффициенты как эффекты при этом нельзя: они смещены, и смещение неизвестно.

Пример 14.10.3. Признаков много, важных мало → лассо

У нас 500 признаков про клиента — вся история покупок, просмотров и обращений, — и мы предполагаем, что реально предсказывают отток от силы десяток. Задача — получить компактную модель, которую можно объяснить и внедрить.

Здесь работает лассо. Оно само обнулит лишнее и оставит небольшой набор. Но помнить нужно две вещи: какие именно признаки останутся, отчасти определяется случайностью выборки, а p-значения для отобранных считать уже нельзя.

Пример 14.10.4. Есть коррелированные группы → эластичная сеть

Признаки идут смысловыми блоками: пять разных метрик активности в приложении, четыре метрики лояльности, три ценовых. Внутри блока корреляции высокие, между блоками — низкие.

Чистое лассо в такой ситуации оставит из каждого блока по одному случайному представителю, и модель будет прыгать при малейшем изменении данных. Эластичная сеть с промежуточным α включает или исключает блок целиком, — отбор становится и

устойчивее, и осмысленнее.

Пример 14.10.5. Нужны несмещённые оценки эффектов → МНК с фиксированным набором

Вопрос стоит так: на сколько в среднем растёт выручка при увеличении бюджета на миллион, и каков доверительный интервал этой величины. Это задача объяснения, а не прогноза.

Никакой штраф здесь не годится: и гребень, и лассо дают смещённые оценки, а отбор по данным ломает доверительные интервалы. Единственный корректный путь — зафиксировать набор признаков заранее, исходя из содержательных соображений, и оценить обычный МНК. Если признаков слишком много, а наблюдений мало, честный ответ — «данных не хватает».

Общее для всех трёх методов со штрафом: они предназначены для прогноза и экономности описания, но не для установления причинности. Признак, исключённый лассо, не является «непричинным»; он лишь не добавил предсказательной силы сверх остальных на данной выборке.

11. КВАНТИЛЬНАЯ РЕГРЕССИЯ

Обычная регрессия описывает условное среднее, метод наименьших модулей — условную медиану. Естественно спросить, нельзя ли так же описать произвольный квантиль. Это часто бывает полезно, например в массовом обслуживании: обещание «в 95% случаев доставка не превысит X минут» — это утверждение о квантиле, а не о среднем, и при планировании складских запасов интересен не средний спрос, а его высокий или низкий квантиль.

Чтобы получить произвольный квантиль, достаточно сделать абсолютную потерю несимметричной.

ОПРЕДЕЛЕНИЕ 14.11.1

Потеря «пинбол»

Для $\tau \in (0,1)$

$$\rho_\tau(u) = u\big(\tau - \mathbf{1}\{u<0\}\big) = \begin{cases} \tau\, u, & u \geqslant 0, \\ (1-\tau)|u|, & u < 0. \end{cases}$$

Функция кусочно-линейна, выпукла, с изломом в нуле; при $\tau = 1/2$ она равна $\frac{1}{2}|u|$. Асимметрия читается прямо: при $\tau = 0.9$ недооценка (факт выше прогноза) штрафуется в девять раз сильнее, чем переоценка, — поэтому линия уходит вверх, к верхнему квантилю.

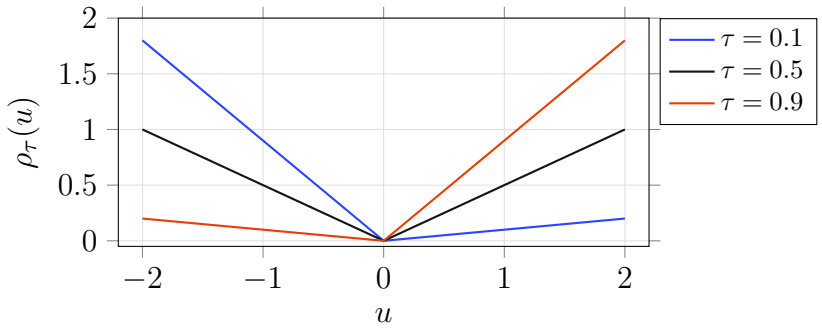

$$\theta^*(\tau) = \operatorname{argmin}_\theta \sum_{i=1}^{n} \rho_\tau\big(X_i - z_i^\intercal \theta\big).$$

ОПРЕДЕЛЕНИЕ 14.11.2

Квантильная регрессия

ТЕОРЕМА 14.11.1

Пинбол-потеря и квантиль

Пусть ξ — случайная величина с функцией распределения F. Множество точек минимума $\mathbb{E}\rho_\tau(\xi - a)$ есть в точности множество τ-квантилей ξ, то есть множество тех a, для которых

$$F(a-) \leqslant \tau \leqslant F(a).$$

В частности, минимум всегда достигается в точке $q_\tau = \inf\{a : F(a) \geqslant \tau\}$.

Доказательство. Положим $g(a) = \mathbb{E}\rho_\tau(\xi - a)$. Функция g выпукла как математическое ожидание выпуклых по a функций, поэтому односторонние производные существуют всюду и равны

$$g'_-(a) = F(a-) - \tau, \qquad g'_+(a) = F(a) - \tau.$$

Условие минимума выпуклой функции $g'_-(a) \leqslant 0 \leqslant g'_+(a)$ даёт в точности $F(a-) \leqslant \tau \leqslant F(a)$. Поскольку F непрерывна справа и имеет пределы слева, такая точка существует всегда, и наименьшая из них есть q_τ. □

Важно! Формулировка «минимум достигается там, где $F(a) = \tau$» верна только для непрерывного F. Для дискретного распределения точки с $F(a) = \tau$ может не существовать: функция перепрыгивает уровень τ, и минимум достигается в самой точке скачка.

Пример на две строки. Пусть ξ принимает значения 0 и 1 с вероятностью $1/2$ каждое, а $\tau = 0.3$. Тогда F равна 0, затем 0.5, затем 1 и значения 0.3 не принимает никогда. Условие же $F(0-) = 0 \leqslant 0.3 \leqslant 0.5 = F(0)$ выполнено, и минимум действительно достигается в нуле.

Это особенно важно именно здесь, потому что при подгонке квантильной регрессии мы работаем с конечной выборкой, то есть с заведомо дискретным эмпирическим распределением. Формулировка через $F(a-) \leqslant \tau \leqslant F(a)$ покрывает оба случая — и скачок, и плато, — и заодно объясняет, почему доля наблюдений строго ниже подогнанной линии равна τ лишь с точностью до дискретности выборки. Медиана из теоремы 14.8.1 — частный случай при $\tau = 1/2$.

Следствие: подгонка по потере ρ_τ описывает условный τ-квантиль отклика. Отсюда содержательное различие с МНК. Коэффициент обычной регрессии показывает, как меняется среднее отклика; коэффициент квантильной при $\tau = 0.9$ — как меняется верхняя граница типичного диапазона. Эти величины могут вести себя совершенно по-разному, и именно это делает метод полезным.

Как и для наименьших модулей, задача сводится к линейному программированию: вводя $u_i, v_i \geqslant 0$ с $X_i - z_i^\intercal \theta = u_i - v_i$, минимизируем $\tau \sum_i u_i + (1-\tau) \sum_i v_i$ при линейных ограничениях.

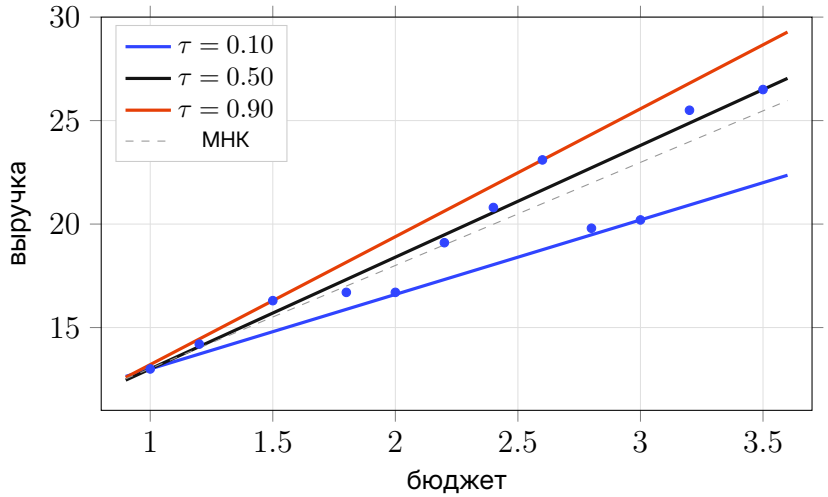

Пример 14.11.1. Веер квантильных линий На исходных данных сквозного примера разброс выручки вокруг линии примерно одинаков при всех бюджетах.

	свободный член	наклон
$\tau = 0.10$	6.80	5.00
$\tau = 0.50$	7.05	5.39
$\tau = 0.90$	8.76	5.09
МНК	7.57	5.13

Наклоны практически совпадают, различаются лишь свободные члены: линии идут почти параллельно. Условное распределение отклика просто сдвигается с ростом бюджета, не меняя формы.

Теперь возьмём модифицированные данные, где разброс растёт с бюджетом:

	свободный член	наклон
$\tau = 0.10$	9.40	$\mathbf{3.60}$
$\tau = 0.50$	7.60	$\mathbf{5.40}$
$\tau = 0.90$	7.03	$\mathbf{6.18}$
МНК	8.04	4.98

Наклоны различаются достаточно сильно: от 3.60 для нижнего квантиля до 6.18 для верхнего, линии расходятся веером. Т.е. дополнительный миллион бюджета поднимает худший сценарий на 3.6 млн, а лучший — на 6.2 млн. Растёт не только средняя выручка, но и неопределённость результата. Обычная регрессия сообщает лишь среднее значение 4.98 и полностью скрывает этот факт — хотя для решения о размере бюджета он может оказаться решающим.

Расходящийся веер квантильных линий — это картинка гетероскедастичности, то есть нарушения условия (Г4).

При гетероскедастичности МНК остаётся несмещённым, но перестаёт быть эффективным, и его стандартные ошибки считаются неверно. Обычные средства — робастные стандартные ошибки, взвешенный МНК, преобразование отклика — чинят статистический вывод, оставляя описание в терминах среднего. Квантильная регрессия вместо этого описывает всё условное распределение, и там, где разброс меняется, это содержательно богаче.

При этом у метода есть свои важные особенности.

Регрессии для разных τ строятся независимо, поэтому ничто не мешает линии для $\tau = 0.9$ оказаться ниже линии для $\tau = 0.5$ в некоторой области значений признака — что логически невозможно для настоящих квантилей. Явление обычно возникает на краях диапазона и говорит о нехватке данных.

Кроме того, квантильная регрессия устойчива к выбросам по отклику, но не по признакам: наблюдение с большим рычагом влияет на неё так же сильно, как и на МНК.

12. ПЕРЕХОД К ЛОГИСТИЧЕСКОЙ РЕГРЕССИИ

Всё, что было выше, предполагало числовой отклик. Но огромная доля практических задач устроена иначе: окупилась кампания или нет, ушёл клиент или остался, кликнул или не кликнул. Отклик принимает два значения, и вопрос ставится о вероятности единицы.

Попробовать обычный МНК по нулям и единицам можно, и он даже что-то выдаст — линейную вероятностную модель.

Однако возникнут проблемы:

1. Предсказание не ограничено отрезком $[0, 1]$ и легко вылезает

за него.

2. Дисперсия отклика Бернулли равна $p(1-p)$ и зависит от p, то есть гетероскедастичность встроена в задачу и условие (Г4) нарушено по построению.
3. И наконец, линейность самой вероятности содержательно сомнительна: рост бюджета с 1 до 2 млн и с 8 до 9 млн вряд ли меняет шансы одинаково.

Решение состоит в том, чтобы моделировать линейно не саму вероятность, а её монотонное преобразование, пробегающее всю прямую.

Двадцать кампаний: по вертикали ноль (не окупилась) или единица (окупилась). Прямая линейной вероятностной модели пересекает единицу уже при бюджете около 5.7 млн и уходит выше — как вероятность это читать нельзя. Логистическая кривая приближается к единице, но не достигает её ни при каком бюджете.

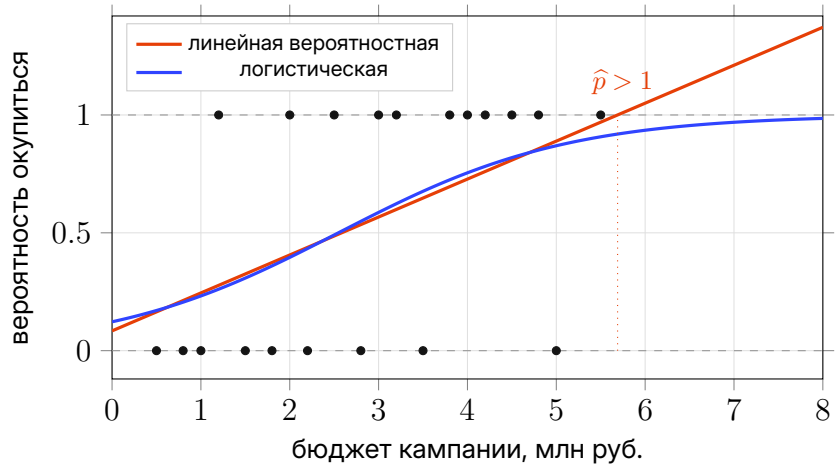

ОПРЕДЕЛЕНИЕ 14.12.1

Шансы и логит

Шансами события с вероятностью p называют отношение $\operatorname{odds}(p) = \frac{p}{1-p} \in (0, +\infty)$, а *логитом* — логарифм шансов: $\operatorname{logit}(p) = \ln \frac{p}{1-p} \in (-\infty, +\infty)$.

ОПРЕДЕЛЕНИЕ 14.12.2

Логистическая регрессия

$$\operatorname{logit}\, \mathsf{P}(Y_i = 1 \mid z_i) = z_i^{\mathsf{T}}\theta, \qquad \text{равносильно} \qquad \mathsf{P}(Y_i = 1 \mid z_i) = \sigma\big(z_i^{\mathsf{T}}\theta\big),$$

где $\sigma(t) = 1/(1+e^{-t})$ — логистическая функция. Наблюдения предполагаются независимыми.

Коэффициенты читаются в шансах, а не в вероятностях: увеличение j-го признака на единицу умножает шансы на e^{θ_j} при прочих равных. Это главное практическое отличие от линейной регрессии, и его стоит удерживать: эффект на вероятность зависит от того, где мы находимся на кривой, а эффект на шансы — нет.

Логарифм правдоподобия

ТЕОРЕМА 14.12.1

Свойства задачи оценивания

$$\ell(\theta) = \sum_{i=1}^{n} \Big[Y_i z_i^{\mathsf{T}}\theta - \ln\big(1 + e^{z_i^{\mathsf{T}}\theta}\big) \Big]$$

вогнут по θ. Уравнения правдоподобия имеют вид $Z^\intercal\big(Y - p(\theta)\big) = 0$, где $p(\theta) = \big(\sigma(z_1^\intercal\theta), \ldots, \sigma(z_n^\intercal\theta)\big)^\intercal$, и не решаются в замкнутом виде.

Уравнения $Z^\intercal(Y - p) = 0$ стоит сравнить с нормальными уравнениями $Z^\intercal(X - Z\theta) = 0$: структура та же, но $Z\theta$ заменено на $p(\theta)$, и из-за этой нелинейности решения в явном виде нет. Численно задачу решают методом Ньютона, который здесь принимает вид итеративно перевзвешенного МНК: на каждом шаге решается обычная взвешенная линейная регрессия с весами $p_i(1 - p_i)$. Благодаря вогнутости метод сходится к глобальному максимуму за считанные итерации.

ЗАМЕЧАНИЕ

Единственный существенный случай, когда сходимости нет, — полное разделение классов: если гиперплоскость разделяет нули и единицы без ошибок, правдоподобие растёт при неограниченном увеличении коэффициентов, и максимум не достигается. Чтобы это исправить, можно добавить штрафы на коэффициенты.

Пример 14.12.1. Окупаемость рекламных кампаний

Рассмотрим 20 рекламных кампаний. Признак — бюджет кампании (млн руб.), отклик — окупилась ли она (1) или нет (0).

Линейная вероятностная модель даёт $\widehat{p} = 0.084 + 0.161\,z$:

бюджет	0.5	3.0	7.0	8.0
линейная модель	0.164	0.568	**1.213**	**1.375**
логистическая	0.170	0.587	0.969	0.986

Линейная модель выходит за единицу уже при бюджете около 5.7 млн; логистическая приближается к единице, но не достигает её ни при каком значении признака.

Сама логистическая регрессия (сходимость за 6 итераций):

	θ_j^*	SE	z
свободный член	-1.969	1.198	-1.64
бюджет	0.773	0.397	1.95

Отношение шансов равно $e^{0.773} = 2.17$ с 95%-м интервалом $[1.00;\ 4.71]$: каждый дополнительный миллион бюджета увеличивает шансы окупиться примерно в 2.2 раза. Вероятность 0.5 достигается при бюджете 2.55 млн.

Обратим внимание на пограничный результат: критерий Вальда даёт $z = 1.95$ при пороге 1.96, то есть $p \approx 0.051$. Формально признак незначим, содержательно — эффект есть, но данных мало.

Существенное отличие от линейного случая: точных распределений здесь нет вообще. Все критерии асимптотические, и при малых выборках они расходятся между собой — как в примере, где вывод меняется на границе. Кроме того, коэффициент

детерминации в привычном виде не определён: разложения $\mathrm{TSS} = \mathrm{ESS} + \mathrm{RSS}$ нет, и его заменяют разными псевдоаналогами, которые не сопоставимы ни между собой, ни с обычным R^2.

13. ЧАСТНЫЙ КОЭФФИЦИЕНТ КОРРЕЛЯЦИИ

Мы неоднократно пользовались оборотом «при прочих равных», говоря о коэффициентах множественной регрессии. Тот же вопрос можно задать и про корреляцию: какова связь двух величин, если исключить влияние третьей?

Вернёмся к примеру с мороженым и утоплениями. Парная корреляция между ними велика, но обе величины тянет за собой жара. Если бы мы могли сравнивать только дни с одинаковой температурой, связь бы исчезла. Частная корреляция делает именно это.

ОПРЕДЕЛЕНИЕ 14.13.1

Частная корреляция

Пусть требуется измерить связь величин U и V при исключении влияния набора переменных W. Построим регрессии U на W и V на W, обозначим остатки e_U и e_V. Тогда

$$r_{UV \cdot W} = \operatorname{corr}\bigl(e_U,\, e_V\bigr).$$

Определение прозрачно: остаток — это то, что в переменной не объясняется набором W. Коррелируя остатки, мы коррелируем «очищенные» части.

Частный коэффициент корреляции X и Y

$$\rho_{XY \cdot Z} = \frac{\rho_{XY} - \rho_{XZ}\rho_{YZ}}{\sqrt{(1-\rho_{XZ}^2)(1-\rho_{YZ}^2)}}$$

$$Y = \alpha + \beta X + \varepsilon$$

где:

$$X = \alpha_X + \beta_{XZ} Z + \varepsilon_X \longrightarrow e_X = X - (\hat{\alpha}_X + \hat{\beta}_{XZ} Z) \longrightarrow \rho_{XY \cdot Z} = \operatorname{corr}(e_X, e_Y)$$

$$Y = \alpha_Y + \beta_{YZ} Z + \varepsilon_Y \longrightarrow e_Y = Y - (\hat{\alpha}_Y + \hat{\beta}_{YZ} Z)$$

$$\downarrow$$

$$e_X = \gamma_0 + \gamma_1 e_Y + u \longrightarrow \gamma_1 = \rho_{XY \cdot Z} \cdot \frac{\sigma_{r_X}}{\sigma_{r_Y}}$$

Рисунок 261. Частная корреляция: формула через парные корреляции и построение через остатки.

ТЕОРЕМА 14.13.1

Частная корреляция и t-статистика

Пусть в множественной регрессии отклика X на k признаков коэффициент при j-м признаке имеет t-статистику t_j. Тогда частная корреляция отклика с этим признаком при исключении всех

остальных равна

$$r_j = \frac{t_j}{\sqrt{t_j^2 + (n-k)}}.$$

теорема объясняет, почему частная корреляция и регрессия — это одно и то же: проверка значимости коэффициента и проверка значимости частной корреляции — буквально один и тот же тест.

ТЕОРЕМА 14.13.2

Фриш — Во — Ловелл

Разобьём матрицу признаков на две части: $Z = (Z_1 \;\; Z_2)$. Тогда коэффициенты при Z_2 в полной регрессии X на Z совпадают с коэффициентами регрессии e_X на e_{Z_2}, где e_X и e_{Z_2} — остатки регрессий X и каждого столбца Z_2 на Z_1. Остатки обеих регрессий также совпадают.

Идея Доказательство. Обозначим через $M_1 = I_n - P_1$ проектор на ортогональное дополнение к пространству столбцов Z_1. Нормальные уравнения полной регрессии, записанные блочно, после исключения первого блока дают в точности нормальные уравнения регрессии $M_1 X$ на $M_1 Z_2$. Содержательно это означает, что «контроль переменных» — ортогональное проектирование: мы удаляем из отклика и из интересующего признака всё, что объясняется контрольными переменными, и смотрим на то, что осталось. □

Пример 14.13.1. Знак меняется на противоположный

Вернёмся к данным из примера. Парные корреляции:

$\mathrm{corr}(\text{выручка}, \text{бюджет})$	0.979
$\mathrm{corr}(\text{выручка}, \text{промо})$	$+\mathbf{0.179}$
$\mathrm{corr}(\text{бюджет}, \text{промо})$	0.258

Взятая сама по себе, связь промо-дней с выручкой положительна: месяцы с большим числом промо-дней в среднем выручают больше. Вычислим частную корреляцию, исключив бюджет:

$$r = \frac{0.179 - 0.979 \cdot 0.258}{\sqrt{(1 - 0.979^2)(1 - 0.258^2)}} = \frac{-0.074}{0.195} = -\mathbf{0.379}.$$

Знак изменился на противоположный. Объяснение: промо-дни чаще назначались в месяцы с большим рекламным бюджетом ($r = 0.258$), а бюджет сильно поднимает выручку. Эта общая зависимость и создавала видимость положительной связи. Как только вклад бюджета исключён, остаточная связь оказывается слабо отрицательной.

Проверим согласованность трёх способов счёта. По определению 14.13.1, через корреляцию остатков двух вспомогательных регрессий, получаем -0.3792; по формуле через парные корреляции со схемы выше — то же -0.3792; по теореме 14.13.1, через

t-статистику коэффициента при промо ($t = -1.2296$, $n - k = 9$):

$$r = \frac{-1.2296}{\sqrt{1.5119 + 9}} = -0.3792.$$

Слева — промо-дни против выручки как есть: связь положительная, $r = +0.179$. Справа — та же пара после исключения бюджета: по осям остатки регрессий промо-дней и выручки на бюджет, и наклон здесь отрицательный, $r = -0.379$.

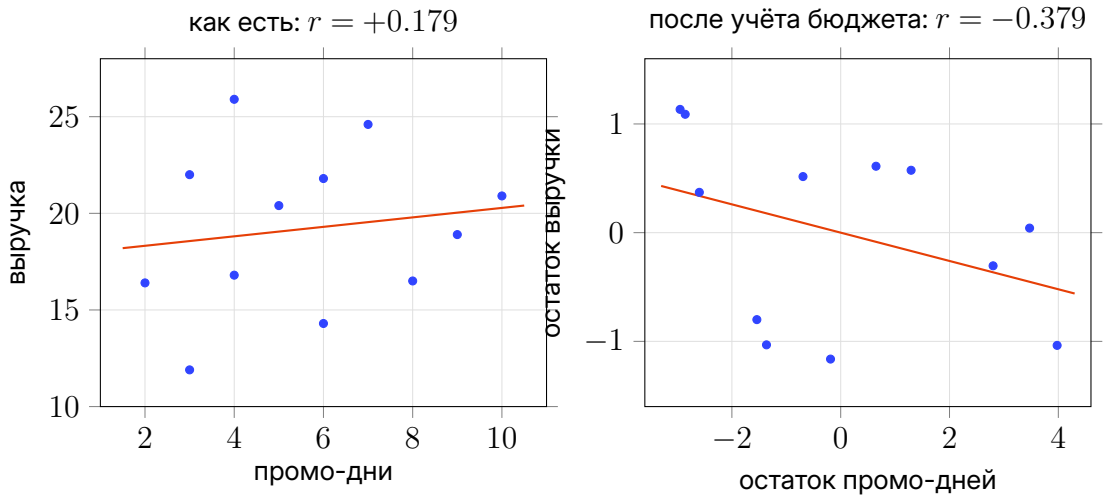

Частная корреляция различает три качественно разные ситуации, и их стоит разобрать по очереди. Все три устроены на картинках одинаково — четыре панели: сама связь двух интересующих нас величин; две вспомогательные регрессии каждой из них на контрольную переменную; и то, что осталось от связи после её учёта.

Пример 14.13.2. Кейс 1: связи нет ни до, ни после

Начнём со скучного случая — когда искать нечего.

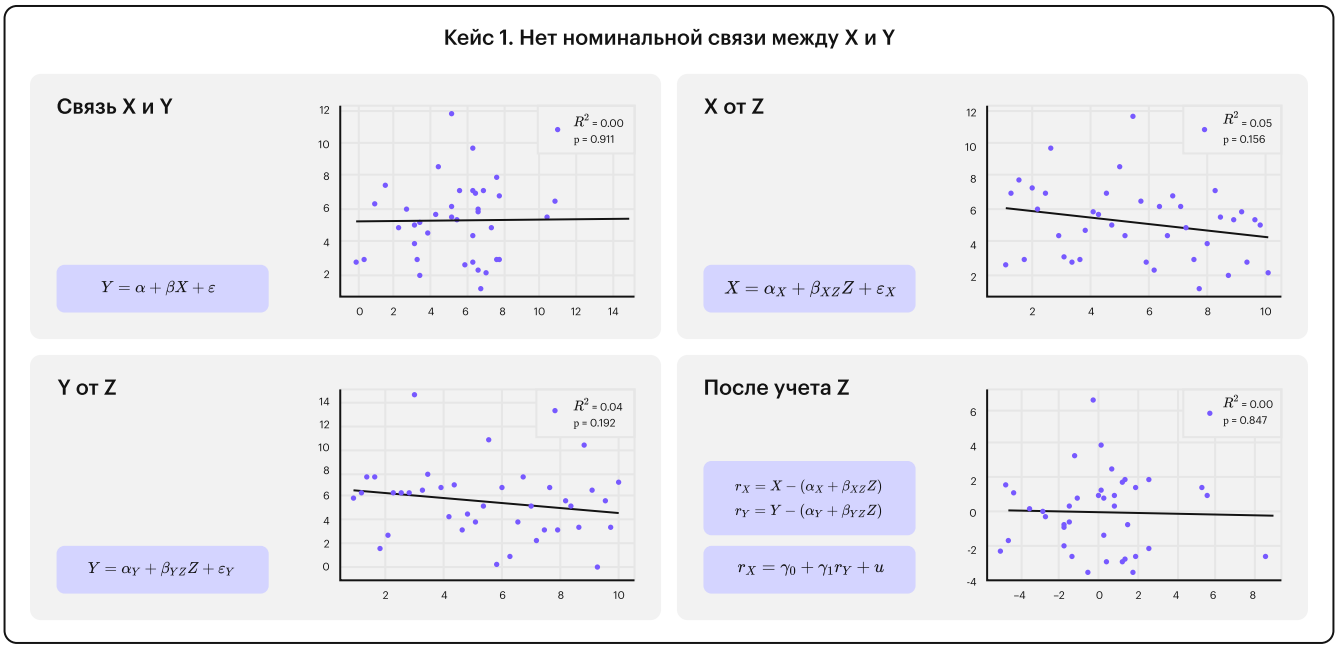

Рисунок 262. Нет номинальной связи между X и Y: обе прямые на первом и четвёртом графике практически горизонтальны.

Парная связь отсутствует: $R^2 = 0.00$ при $p = 0.911$. Контрольная переменная тоже ни при чём — она объясняет лишь 5% разброса X и 4% разброса Y, и оба раза незначимо. После её учёта остаётся ровно то же самое: $R^2 = 0.00$, $p = 0.847$. Учёт третьей переменной здесь ничего не меняет, потому что менять нечего.

Пример 14.13.3. Кейс 2: связь есть, но только номинальная

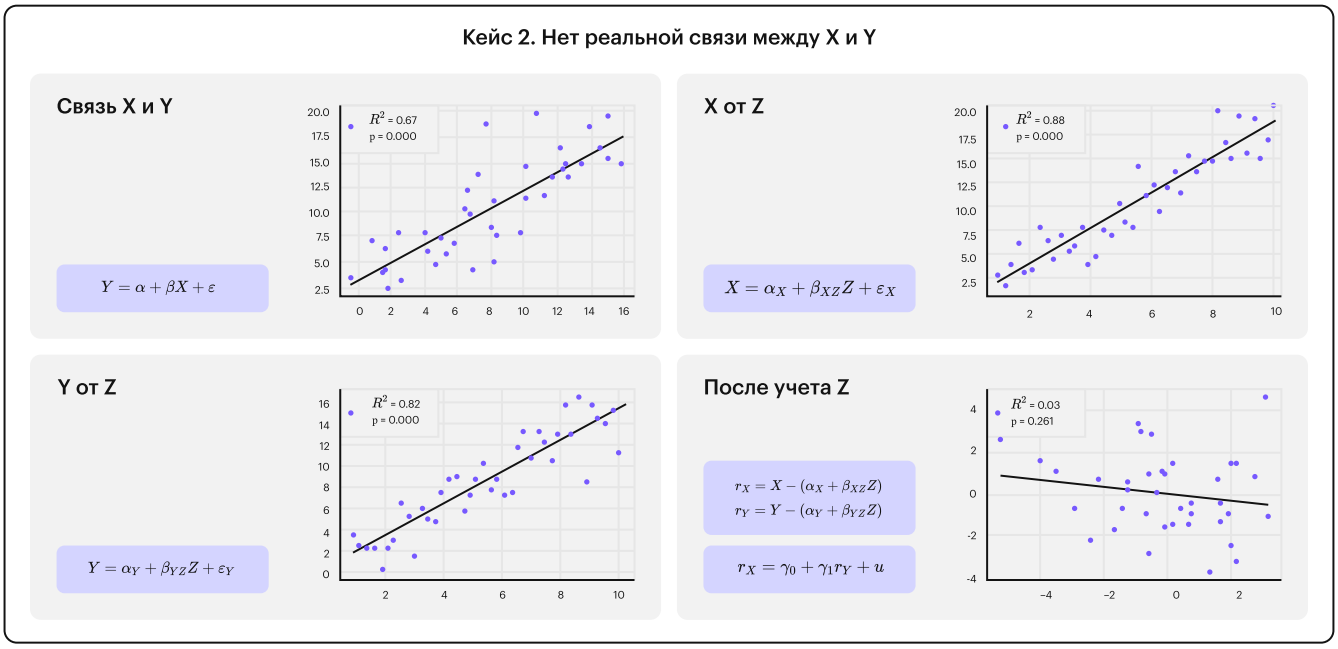

Рисунок 263. Нет реальной связи между X и Y: сильная парная связь на первой панели полностью исчезает на четвёртой.

Парная связь выглядит убедительно: $R^2 = 0.67$ при $p < 0.001$.
Но обе величины почти целиком определяются третьей — $R^2 =$

0.88 у регрессии X на Z и $R^2 = 0.82$ у регрессии Y на Z. Стоит вычесть вклад Z, и от связи не остаётся ничего: $R^2 = 0.03$, $p = 0.261$.

Пример 14.13.4. Кейс 3: связь остаётся и после учёта И случай, когда связь настоящая.

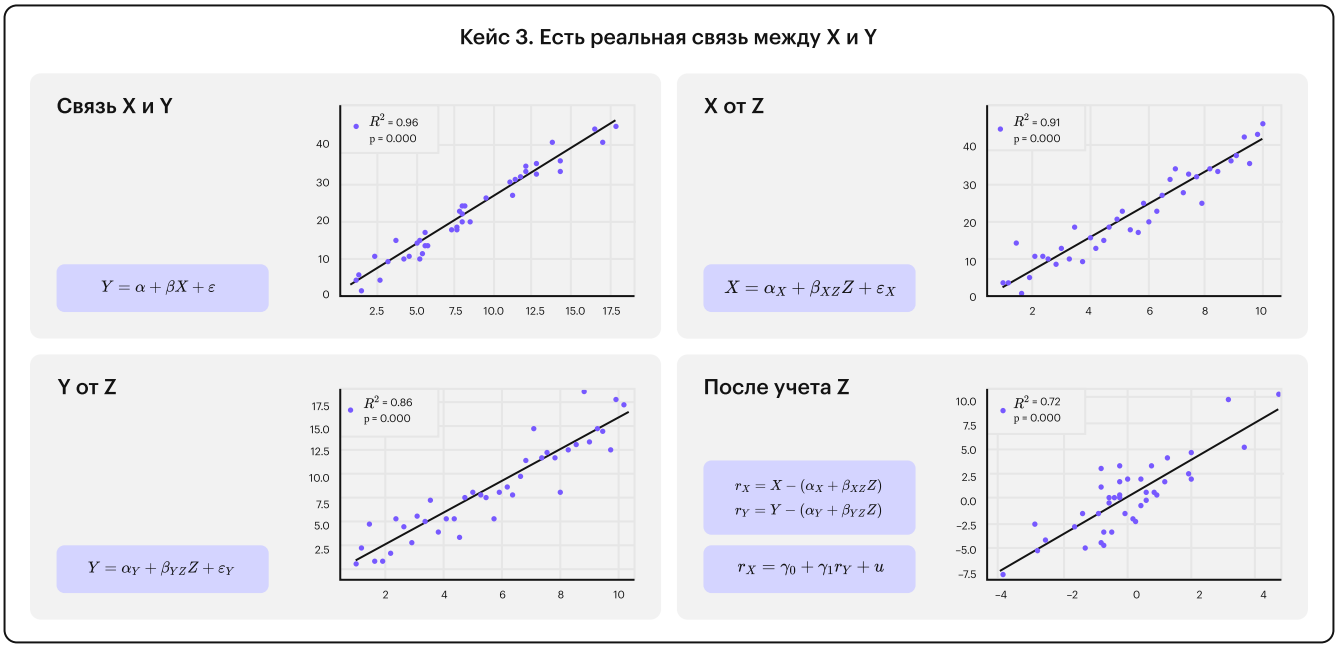

Рисунок 264. Есть реальная связь между X и Y: она сохраняется и после учёта Z, лишь немного ослабев.

Первые три графика почти не отличаются от предыдущего кейса: парная связь сильная ($R^2 = 0.96$), контрольная переменная объясняет и X ($R^2 = 0.91$), и Y ($R^2 = 0.86$). Различает эти два случая только четвертый график. Здесь после учёта Z связь никуда не делась: $R^2 = 0.72$ при $p < 0.001$. Значит она не сводится к общей причине — и именно это отличает настоящую зависимость от наведённой.

Наконец, стоит расставить по местам три меры связи, которые легко перепутать:

Парная корреляция измеряет связь двух величин как есть, вместе со всем, что тянет их обе.

Частная корреляция измеряет связь при фиксированных остальных переменных — это ровно то, что показывает коэффициент множественной регрессии.

Множественная корреляция ($\sqrt{R^2}$) измеряет связь отклика со *всем* набором признаков сразу.

Важно! Слово «контроль» здесь означает статистическую поправку, а не эксперимент. Мы исключаем линейный вклад W — и только линейный, и только тех W, что попали в модель. Если связь с контрольной переменной нелинейна или если существенная переменная в набор не включена, никакая частная корреля-

ция этого не исправит. Смена знака в примере выше — напоминание о том, насколько сильно выводы зависят от того, что именно мы решили проконтролировать.

ЗАКЛЮЧЕНИЕ

Из этого текста ты узнал:

- что такое линейная регрессия и корреляция;
- как проводится линия наименьших квадратов;
- как меряется качество модели, почему R^2 нельзя использовать для сравнения моделей с разным числом признаков и как проверяется значимость самого R^2;
- как проверяется значимость отдельного коэффициента и чем интервал для среднего отличается от прогнозного;
- при каких условиях МНК оптимален и что именно ломается при нарушении каждого из них;
- как информационные критерии Акаике и Шварца решают задачу отбора модели там, где R^2 бессилен, и чем они отличаются друг от друга;
- где нужна нормальность остатков, а где можно обойтись без неё;
- чем отличаются оценки среднего, медианы и произвольного квантиля и когда какая уместна;
- как гребневая регрессия и лассо разменивают несмещённость на точность и почему только второй метод отбирает признаки;

Сквозная мысль всей главы — регрессия отвечает ровно на тот вопрос, который ей задали, и почти никогда — на вопрос о причинах. Коэффициент, интервал и p-значение описывают связь в данных при принятых предпосылках. Всё остальное — предмет постановки задачи, а не расчёта.

Приложение А. Распределения

1. НОРМАЛЬНОЕ РАСПРЕДЕЛЕНИЕ

> Все верят в универсальность нормального распределения: физики верят потому, что думают, что математики доказали его логическую необходимость, а математики верят, так как считают, что физики проверили это лабораторными экспериментами.
>
> *А. Пуанкаре*

Нормальное распределение задаётся двумя параметрами: средним μ и дисперсией σ^2.

Плотность вероятности (PDF):

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \quad \text{для} \quad x \in \mathbb{R}.$$

Графики, соответствующие PDF и CDF, представлены на рисунках ниже. Посмотреть на то, как динамически меняется распределение при различных параметрах, можно в калькуляторе распределений, но совсем скоро ты научишься строить такие графики.

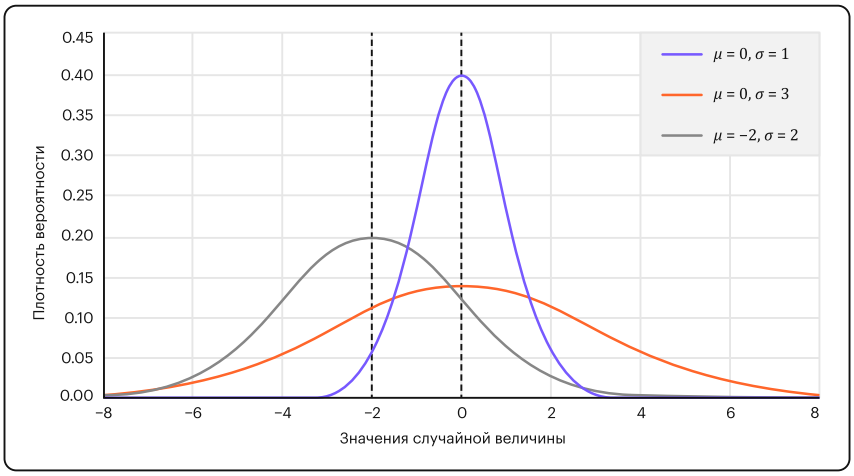

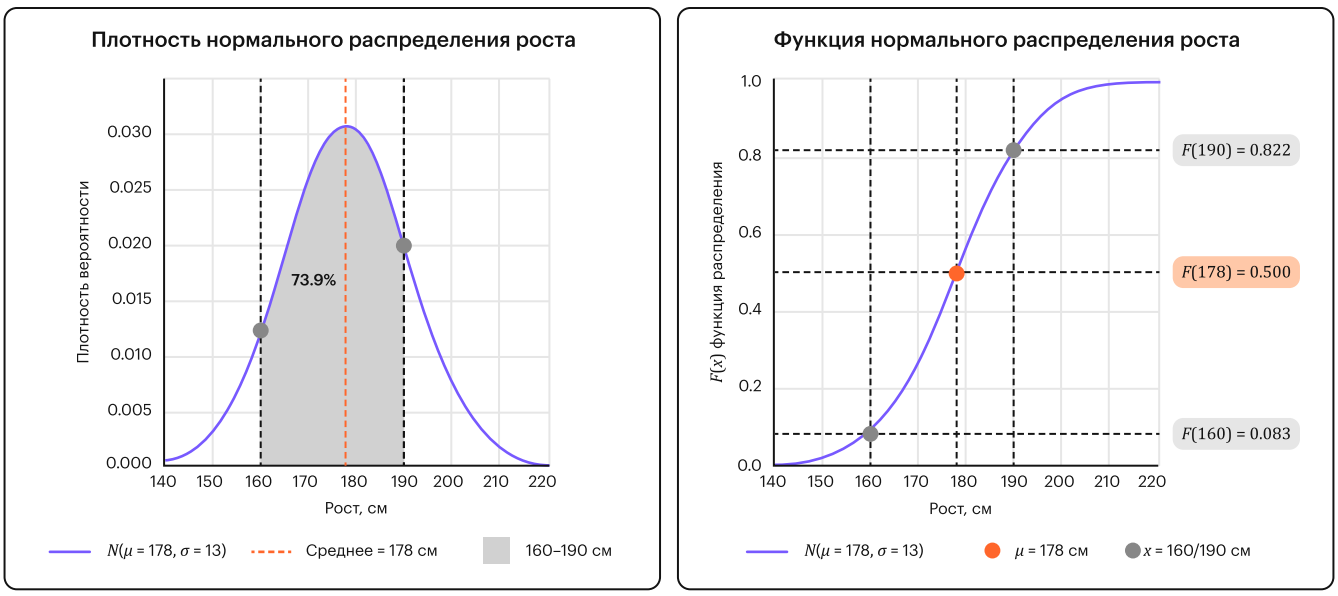

Рисунок 265. Функция плотности и функция нормального распределения

Математическое ожидание равно μ; дисперсия равна σ^2.

Нормальное распределение обладает следующим свойством, называемым *правилом трёх сигм*.

- В интервал $[\mu - \sigma, \mu + \sigma]$ входит 68.3% площади под кривой

функции плотности.

- В интервал $[\mu - 2\sigma, \mu + 2\sigma]$ входит 95.4% площади под кривой функции плотности.
- В интервал $[\mu - 3\sigma, \mu + 3\sigma]$ входит 99.7% площади под кривой функции плотности.

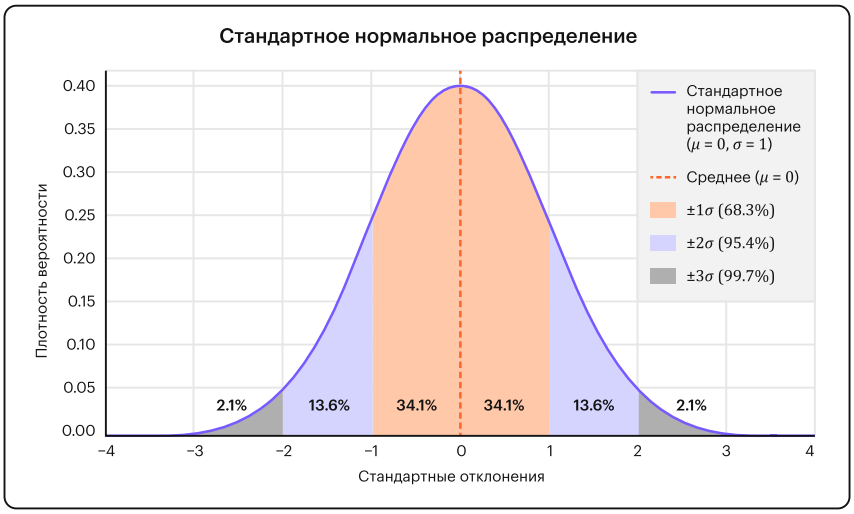

Рисунок 266. Правило трёх сигм в нормальном распределении

Нормальное распределение (или приближенное к нему) встречается в реальной жизни: рост людей, вес, размер обуви.

Пример 15.1.1. Вес новорождённого ребёнка распределён нормально со следующими значениями параметров (в граммах):

$$\mu = 3200,$$

$$\sigma = 500.$$

Вопрос 1

Какова вероятность того, что у новорождённого ребёнка вес будет больше 4,3 кг?

Вероятность можно рассчитать как разницу между единицей и значением функции распределения с соответствующими параметрами в точке 4300.

Получаем 1.4%.

Вопрос 2

Какова вероятность того, что у новорождённого ребёнка вес будет равняться 3200 г?

Вероятность равна нулю, так как нормальное распределение является непрерывным, а в непрерывных распределениях мера (вероятность) точки равна нулю.

Распределение случайной величины называется **симметричным**

ОПРЕДЕЛЕНИЕ 15.1.1

(относительно точки a), если для любых x выполняется равенство

$$P(\xi - a \leqslant x) = P(a - \xi \leqslant x).$$

Если $a = 0$, то такое распределение называют симметричным относительно нуля.
Легко заметить, что нормальное распределение симметричное относительно μ.

Однако на практике зачастую бывает так, что нормальное распределение скошено в одну или другую сторону.

Его так и называют: скошенное (или асимметричное) нормальное распределение (skew normal distribution).

Конкретные формулы, описывающие его, достаточно сложны и редко применяются на практике, поэтому мы не будем рассматривать их, однако обратим внимание на то, как смещаются мода, среднее и медиана в асимметричном нормальном распределении.

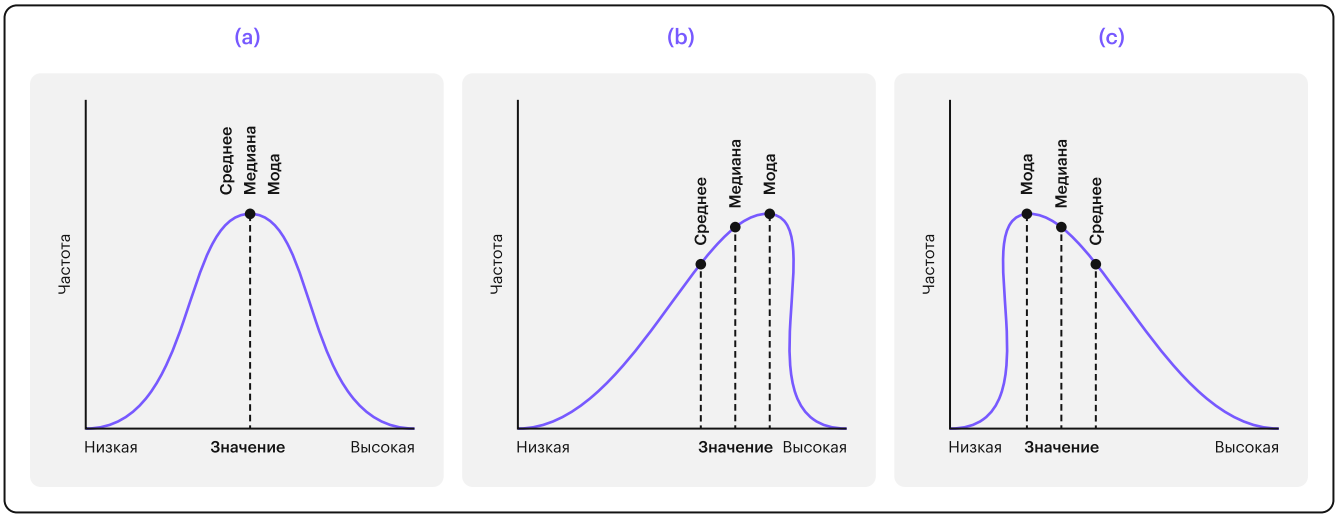

Рисунок 267. Скошенность в нормальном распределении

2. ЛОГНОРМАЛЬНОЕ РАСПРЕДЕЛЕНИЕ

ОПРЕДЕЛЕНИЕ 15.2.1

Случайная величина X называется распределённой по **логнормальному распределению** с параметрами μ и σ^2, если $\ln X$ имеет нормальное распределение с математическим ожиданием μ и дисперсией σ^2.

Плотность вероятности такой с. в. имеет следующий вид:

$$f(x) = \frac{1}{x\sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln x - \mu)^2}{2\sigma^2}\right), \quad x > 0.$$

График, соответствующий PDF логнормального распределения с $\mu = 0$ и различными σ, представлен на рисунке ниже.

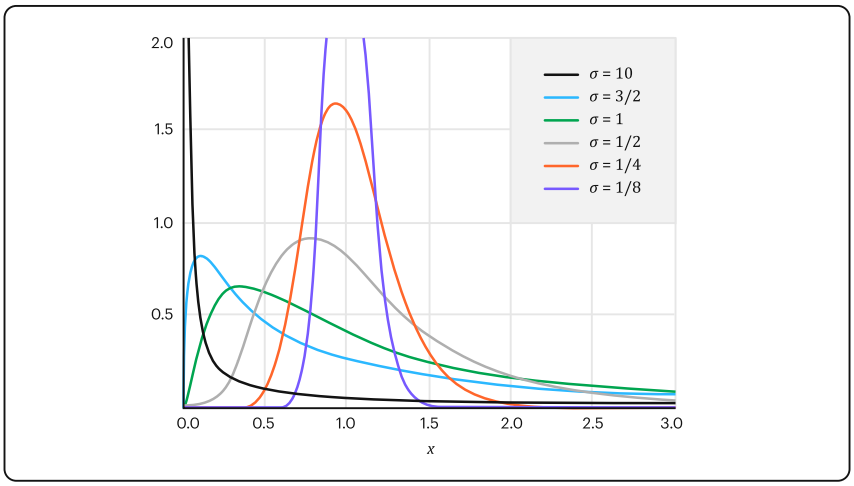

Рисунок 268. Функция плотности логнормального распределения

Несмотря на «математичность» способа определения этого вида распределения, оно достаточно часто встречается в реальной жизни:

- в финансовых моделях (доходы людей, цены на недвижимость);
- для длины файлов в интернете, длительности телефонных звонков;
- в задачах, где итоговый результат — произведение множества независимых положительных факторов.

Если X логнормально распределена с параметрами μ и σ^2, то

$$\mathbb{E}[X] = e^{\mu+\sigma^2/2}, \qquad \mathrm{Var}[X] = (e^{\sigma^2} - 1)e^{2\mu+\sigma^2}.$$

Эти формулы означают, что среднее логнормального распределения всегда больше медианы и зависит как от положения μ, так и от разброса σ^2 преобразованного нормального.

Если σ^2 мало, то распределение похоже на нормальное; однако если сильно увеличивать σ^2, то в данных появляется длинный «хвост» (очень крупные значения будут встречаться редко, но оставаться возможными). Поэтому логнормальное распределение хорошо описывает явления вида «чаще малое, но иногда гигантское». О статистических последствиях жирных хвостов можно прочесть в книге Нассима Талеба[a].

[a] Нассим Николас Талеб. *Статистические последствия жирных хвостов: О новых вычислительных подходах к принятию решений.* / Пер. с англ. В. Ф. Боруна. — М.: КоЛибри, Азбука-Аттикус, 2023. — 480 с. — ISBN 978-5-389-19584-4.

3. РАСПРЕДЕЛЕНИЕ БЕРНУЛЛИ

Распределение Бернулли — самое простое дискретное распределение, которое моделирует единичный эксперимент с двумя возможными исходами.

ОПРЕДЕЛЕНИЕ 15.3.1

Случайная величина X имеет **распределение Бернулли** с параметром $p \in [0, 1]$, если она принимает только два значения:

- $X = 1$ с вероятностью p (успех);
- $X = 0$ с вероятностью $1 - p$ (неудача).

Обычно обозначают $X \sim \mathrm{Bern}(p)$. Запишем основные функции этого распределения.

- Функция плотности распределения (PMF):

$$P(X = k) = \begin{cases} p, & \text{при } k = 1; \\ 1 - p, & \text{при } k = 0; \\ 0, & \text{иначе.} \end{cases}$$

- Функция распределения (CDF):

$$F(x) = \begin{cases} 0, & \text{при } x < 0; \\ 1 - p, & \text{при } 0 \leqslant x < 1; \\ 1, & \text{при } x \geqslant 1. \end{cases}$$

Графики, соответствующие PMF и CDF, представлены на рисунке ниже.

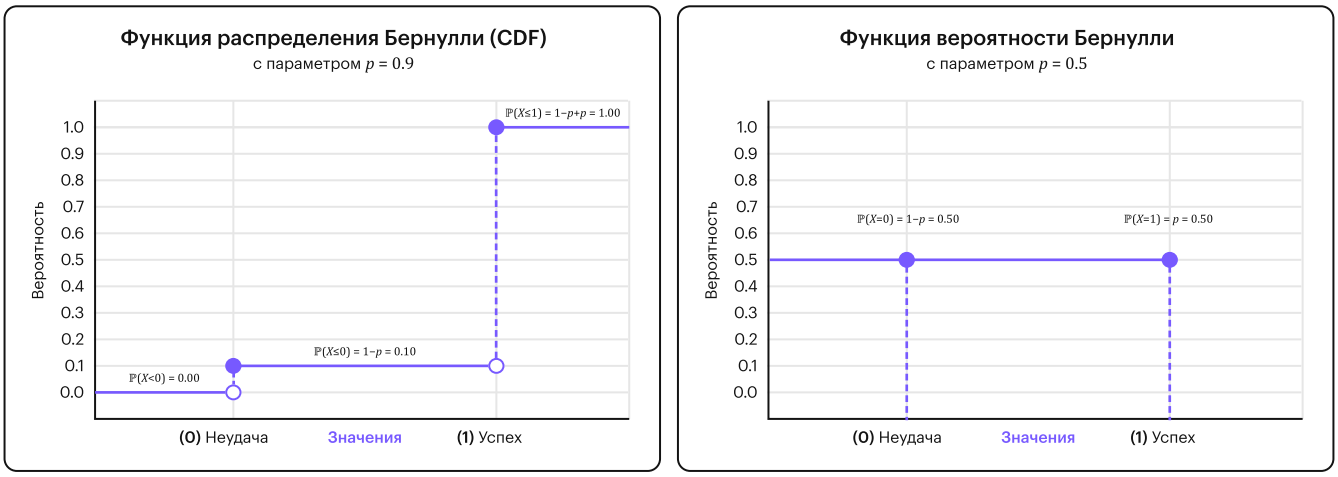

Рисунок 269. Функция вероятности и функция распределения Бернулли

Математическое ожидание бернуллиевского распределения равно p, дисперсия равна $p(1 - p)$. Чаще всего этот вид распределения встречается в базовых простых математических моделях, подразумевающих два возможных результата:

- подбрасывание монеты (орёл/решка);
- результат медицинского теста (положительный/отрицательный);
- покупка клиентом товара после просмотра рекламы (купил/не купил);

- прохождение студентом экзамена (сдал/не сдал);
- любой эксперимент типа «да/нет», «успех/неудача».

Пример 15.3.1. Интернет-магазин запускает рекламную кампанию. Вероятность того, что случайный посетитель совершит покупку после просмотра рекламы, составляет $p = 0.15$.

Для каждого посетителя можно ввести случайную величину:

$$X = \begin{cases} 1, & \text{если посетитель совершил покупку;} \\ 0, & \text{если посетитель не совершил покупку.} \end{cases}$$

Тогда $X \sim \mathrm{Bern}(0.15)$ и математическое ожидание $\mathbb{E}[X] = 0.15$ показывает ожидаемую долю покупателей от всех пользователей.

Оказывается, что распределение Бернулли — это «строительный блок» для следующего вида распределения. Если провести n независимых экспериментов Бернулли с одним и тем же параметром p, то сумма результатов будет иметь **биномиальное распределение** $\mathrm{Bin}(n,p)$. Таким образом,

$$\text{если } X_1, X_2, \ldots, X_n \sim \mathrm{Bern}(p), \text{ то } \sum_{i=1}^{n} X_i \sim \mathrm{Bin}(n,\, p).$$

Поговорим про это распределение подробнее.

4. БИНОМИАЛЬНОЕ РАСПРЕДЕЛЕНИЕ

Случайная величина X имеет биномиальное распределение $\mathrm{Bin}(n,\, p)$ с параметрами $n \in \mathbb{N}$ и $p \in (0,\, 1)$, если она представима в виде суммы n независимых случайных величин, принимающих значения 0 или 1 с вероятностями $1 - p$ и p соответственно. Как мы отмечали ранее, мы имеем дело с суммой распределений Бернулли.

Функция вероятности (PMF):

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k} \quad \text{для} \quad k \in \{0,\, 1,\, \ldots,\, n\}.$$

Функция распределения (CDF):

$$F(x) = P(X \leqslant x) = \sum_{i=0}^{\lfloor x \rfloor} \binom{n}{i} p^i (1-p)^{n-i}.$$

Графики, соответствующие PMF и CDF, представлены на рисунке ниже.

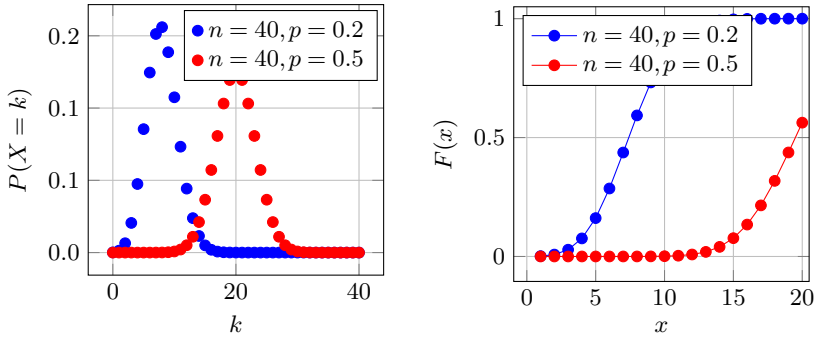

Рисунок 270. Функция вероятности и функция биномиального распределения

Математическое ожидание равно np; дисперсия равна $np(1-p)$.

Примеры биномиального распределения в реальной жизни:

- количество карт определённой масти среди *N* карт;
- количество клиентов, которые совершат покупку в результате маркетинговой акции, среди всех клиентов, которые видели маркетинговую акцию;
- количество сданных домашних заданий по статистике среди всех домашних заданий по статистике.

Пример 15.4.1. В стране A есть 68 банков. Вероятность дефолта каждого из них составляет 5%. Банковская система страны A в состоянии выдержать одновременный дефолт только определённого количества банков. Если в стране A останется строго меньше 9 банков вне состояния дефолта, банковскую и финансовую систему настигнет коллапс. Какова вероятность того, что страна A выстоит?

Необходимо рассчитать вероятность того, что останется меньше 9 банков.

Можно рассчитать значение функции распределения с помощью метода *cdf* (*cumulative distribution function*) в Python.

```
n = 68
k = 8
p = 0.05
binom.cdf(k = k, n = n, p = p)
```

Вероятность того, что в стране A останется меньше 9 банков, составляет 0.66%.

Существует красивая геометрическая модель, описывающая задачи биномиального распределения и в целом биномиальные коэффициенты.

ОПРЕДЕЛЕНИЕ 15.4.1

Треугольник Паскаля

Треугольник Паскаля — это таблица, в которой на n-й строке и k-м столбце находится биномиальный коэффициент C_n^k (число способов выбрать k элементов из n). Каждый элемент равен сумме двух стоящих над ним:

$$C_n^k = C_{n-1}^{k-1} + C_{n-1}^k.$$

Каждое следующее число при построении треугольника (делается это сверху вниз, притом у каждого числа есть соответствующее значние n и k: по строчкам вниз увеличивается n, внутри одной строчки вправо возрастает k) получается как сумма двух ближайших соседей сверху. Треугольник выглядит следующим образом.

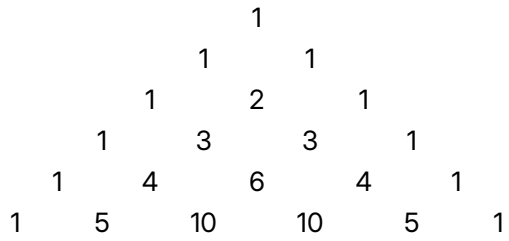

Вне указанной области коэффициенты считаются равными нулю. В биномиальном распределении коэффициент C_n^k отражает число способов получить ровно k успехов за n испытаний:

$$P(X = k) = C_n^k p^k (1 - p)^{n-k}.$$

Треугольник Паскаля — наглядный способ вычислять эти числа. Например, способов добыть ровно 2 успеха за 5 испытаний $C_5^2 = = 10$ (найди это число в треугольнике). Почему так получается? Дело в том, что каждый элемент возникает сложением двух стоящих выше, которые соответствуют ситуациям:

- попыток — $n - 1$, испытали успех $k - 1$ раз (и испытаем ещё раз, в попытку номер n);
- попыток — $n - 1$, испытали успех k раз.

Фактически мы успешно перебираем все возможные случаи.

Треугольник Паскаля напрямую связан с **биномом Ньютона** — формулой разложения степени суммы:

$$(a + b)^n = \sum_{k=0}^{n} C_n^k a^{n-k} b^k.$$

Коэффициенты C_n^k в этом разложении в точности будут числами из треугольника Паскаля.

Например, для куба имеем:

$$(a + b)^3 = C_3^0 a^3 + C_3^1 a^2 b + C_3^2 ab^2 + C_3^3 b^3 = \\ = a^3 + 3a^2 b + 3ab^2 + b^3.$$

Как это относится к биномиальному распределению? Положим $a = p$, $b = 1 - p$, получим важное свойство: $(p + (1 - p))^n = = 1^n = 1$, что означает, что сумма всех вероятностей в этом распределении равна единице, как и должно быть вообще для любого распределения.

5. ГЕОМЕТРИЧЕСКОЕ РАСПРЕДЕЛЕНИЕ

Общее

Геометрическое распределение ($\mathrm{Geom}(p)$) — это дискретное распределение вероятностей.

Оно описывает количество независимых испытаний Бернулли, которые необходимо провести до наступления первого «успеха». Каждое испытание имеет ровно два исхода (успех или неудача), а вероятность успеха p остается неизменной от испытания к испытанию.

В этом состоит принципиальное отличие геометрического распределения от биномиального: в биномиальном фиксировано число испытаний и случайным является число успехов, а в геометрическом — зафиксировано количество успехов (ровно один), а случайной величиной является число проведенных испытаний.

Рассмотрим классический пример применения: подбрасывание монеты до выпадения первого «орла» или броски игральной кости до выпадения первой «шестерки».

Если вероятность успеха невелика, то скорее всего потребуется провести много испытаний. Если вероятность высока — успех наступит на первых же шагах.

Примечание: В литературе существует два стандарта определения геометрического распределения. Первый — моделирование числа испытаний до первого успеха включительно (носитель $k \in \{1, 2, 3, \dots\}$). Второй — моделирование числа неудач до первого успеха (носитель $k \in \{0, 1, 2, \dots\}$). Здесь и далее мы используем первое (классическое) определение.

ОПРЕДЕЛЕНИЕ 15.5.1

Случайная величина X имеет геометрическое распределение, если ее функция вероятности имеет вид:

$$P(X = k) = (1 - p)^{k-1} p,$$

Где $p \in (0, 1]$ — вероятность успеха в одном испытании; k — номер испытания, на котором произошел первый успех. Часто для краткости обозначают вероятность неудачи как $q = 1 - p$.

Функция распределения (CDF), описывающая вероятность того, что первый успех наступит не позднее k-го испытания, имеет вид:

$$F(k) = 1 - (1 - p)^k$$

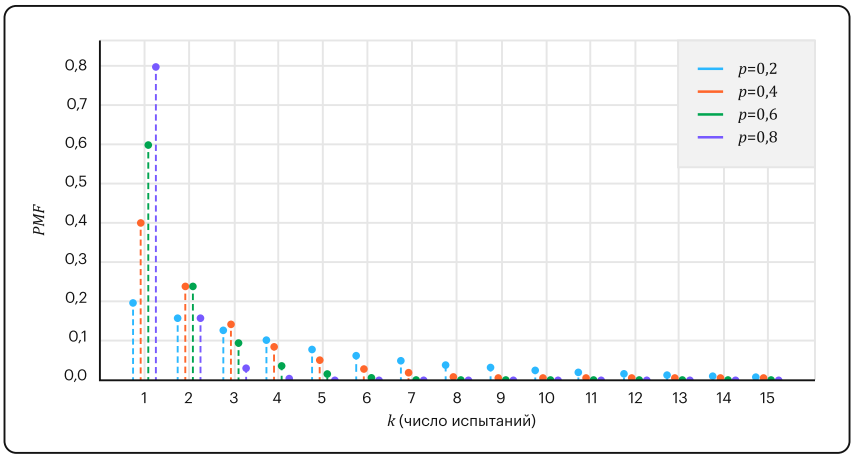

Рисунок 271. Функции вероятности геометрического распределения при разных p

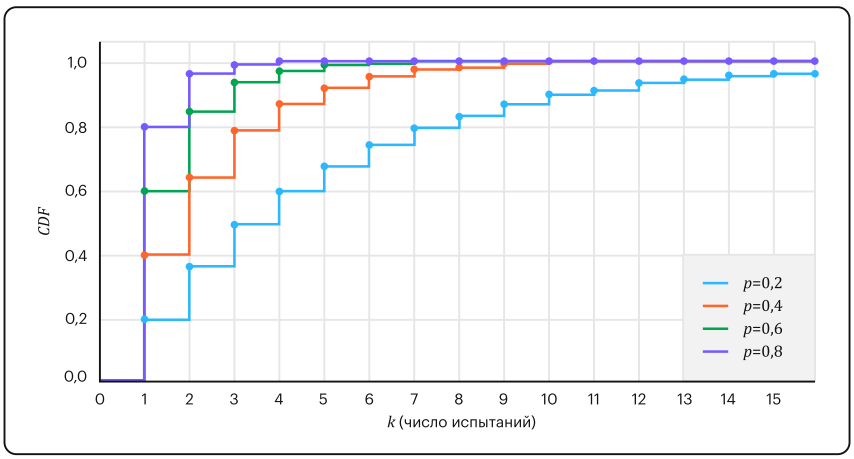

Рисунок 272. Функция распределения геометрического распределения

Влияние параметра вероятности (p):

- **При высоких p ($p \to 1$):**
  Распределение резко сконцентрировано на единице. Мода всегда равна 1, но при больших p плотность спадает к нулю практически моментально (очень «короткий хвост»). Дисперсия стремится к нулю.
- **При низких p ($p \to 0$):**
  График функции вероятности становится пологим, а математическое ожидание устремляется в бесконечность. Распределение приобретает очень тяжелый правый хвост, отражая высокую неопределенность того, когда именно произойдет редкое событие.

Вычисление моментов по определению

Вычислим математическое ожидание и дисперсию прямым суммированием рядов по определению. Для удобства обозначим

вероятность неудачи как $q = 1 - p$.

Математическое ожидание

По определению математическое ожидание дискретной случайной величины — это сумма произведений значений на их вероятности:

$$\mathbb{E}[X] = \sum_{k=1}^{\infty} kP(X = k) = \sum_{k=1}^{\infty} kpq^{k-1} = p\sum_{k=1}^{\infty} kq^{k-1}$$

Заметим, что ряд под суммой является производной по q от суммы бесконечной геометрической прогрессии:

$$\sum_{k=1}^{\infty} kq^{k-1} = \frac{d}{dq}\sum_{k=0}^{\infty} q^k = \frac{d}{dq}\left(\frac{1}{1-q}\right) = \frac{1}{(1-q)^2}$$

Подставляя этот результат обратно и учитывая, что $1 - q = p$:

$$\mathbb{E}[X] = p \cdot \frac{1}{(1-q)^2} = \frac{p}{p^2} = \frac{1}{p}$$

Дисперсия

Для нахождения дисперсии вычислим второй начальный момент $\mathbb{E}[X^2]$. Удобнее сначала найти факториальный момент $\mathbb{E}[X(X-1)]$:

$$\mathbb{E}[X(X-1)] = \sum_{k=1}^{\infty} k(k-1)pq^{k-1} = pq\sum_{k=2}^{\infty} k(k-1)q^{k-2}$$

Ряд под суммой — это вторая производная суммы геометрической прогрессии:

$$\sum_{k=2}^{\infty} k(k-1)q^{k-2} = \frac{d^2}{dq^2}\left(\frac{1}{1-q}\right) = \frac{2}{(1-q)^3}$$

Тогда факториальный момент равен:

$$\mathbb{E}[X(X-1)] = pq\frac{2}{(1-q)^3} = \frac{2pq}{p^3} = \frac{2q}{p^2}$$

Второй начальный момент $\mathbb{E}[X^2]$ выражается как:

$$\mathbb{E}[X^2] = \mathbb{E}[X(X-1)] + \mathbb{E}[X] = \frac{2q}{p^2} + \frac{1}{p} = \frac{2q+p}{p^2}$$

Распишем числитель, учитывая $q = 1 - p$: $2(1-p) + p = 2 - p$. Получаем $\mathbb{E}[X^2] = \frac{2-p}{p^2}$.

Наконец, применим формулу дисперсии $\mathrm{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$:

$$\mathrm{Var}(X) = \frac{2-p}{p^2} - \frac{1}{p^2} = \frac{1-p}{p^2}$$

Характеристическая функция и производящая функция моментов

Производящая функция моментов (MGF)

Производящая функция моментов определяется как $\mathbb{E}[e^{tX}]$. Подставим функцию вероятности геометрического распределения в определение математического ожидания.

Для удобства будем использовать замену $q = 1 - p$:

$$M_X(t) = \mathbb{E}[e^{tX}] = \sum_{k=1}^{\infty} e^{tk} P(X = k) = \sum_{k=1}^{\infty} e^{tk} q^{k-1} p$$

Вынесем независимые от k множители за знак суммы. Для этого представим e^{tk} как $e^t \cdot e^{t(k-1)}$:

$$M_X(t) = pe^t \sum_{k=1}^{\infty} \left(qe^t\right)^{k-1}$$

Сумма представляет собой бесконечную геометрическую прогрессию со знаменателем qe^t. Она сходится при условии $qe^t < 1$, то есть для $t < -\ln(1-p)$. Сумма сходящейся геометрической прогрессии $\sum_{n=0}^{\infty} r^n = \frac{1}{1-r}$:

$$M_X(t) = \frac{pe^t}{1 - qe^t} \quad \text{для } t < -\ln(1-p)$$

Характеристическая функция

Характеристическая функция $\varphi_X(t) = \mathbb{E}[e^{itX}]$ выводится аналогичным суммированием прогрессии, но в комплексной плоскости.

Поскольку модуль комплексной экспоненты равен 1, ряд абсолютно сходится для любых действительных t:

$$\varphi_X(t) = \sum_{k=1}^{\infty} e^{itk} q^{k-1} p = \frac{pe^{it}}{1 - qe^{it}}$$

Вычисление моментов через производящую функцию

Вычислим математическое ожидание и дисперсию через производящую функцию моментов $M_X(t)$.

Начальные моменты распределения равны значению соответствующих производных MGF в точке $t = 0$: $\mathbb{E}[X^n] = M_X^{(n)}(0)$.

Математическое ожидание

Найдем первую производную $M_X(t)$ по правилу дифференцирования частного:

$$M'_X(t) = \frac{(pe^t)'(1 - qe^t) - (pe^t)(1 - qe^t)'}{(1 - qe^t)^2} = \\ = \frac{pe^t(1 - qe^t) - pe^t(-qe^t)}{(1 - qe^t)^2} = \frac{pe^t}{(1 - qe^t)^2}$$

Подставим $t = 0$ (учитывая, что $e^0 = 1$ и $1 - q = p$):

$$\mathbb{E}[X] = M'_X(0) = \frac{p \cdot 1}{(1 - q)^2} = \frac{p}{p^2} = \frac{1}{p}$$

Этот результат интуитивно понятен: если вероятность успеха равна $1/5$, то в среднем потребуется 5 испытаний для его достижения.

Дисперсия

Для нахождения дисперсии найдем второй начальный момент, продифференцировав первую производную еще раз:

$$M''_X(t) = \left(\frac{pe^t}{(1 - qe^t)^2}\right)' = \\ = \frac{pe^t(1 - qe^t)^2 - pe^t \cdot 2(1 - qe^t)(-qe^t)}{(1 - qe^t)^4} \\ = \frac{pe^t(1 - qe^t) + 2pqe^{2t}}{(1 - qe^t)^3}$$

Подставляем $t = 0$:

$$\mathbb{E}[X^2] = M''_X(0) = \frac{p(1 - q) + 2pq}{(1 - q)^3} = \frac{p^2 + 2pq}{p^3} = \frac{p + 2q}{p^2}$$

Распишем $2q$ как $2(1 - p) = 2 - 2p$:

$$\mathbb{E}[X^2] = \frac{p + 2 - 2p}{p^2} = \frac{2 - p}{p^2}$$

Теперь применим формулу дисперсии $\mathrm{Var}(X) = \mathbb{E}[X^2] - \\ -(\mathbb{E}[X])^2$:

$$\mathrm{Var}(X) = \frac{2 - p}{p^2} - \frac{1}{p^2} = \frac{1 - p}{p^2}$$

Свойства и связи с другими распределениями

Приведем некоторые фундаментальные свойства.

Свойства:

1. **Отсутствие последействия (Memorylessness).**
   Геометрическое распределение — это **единственное дискретное распределение**, обладающее свойством отсутствия памяти.
   Оно означает, что количество предыдущих неудачных попыток никак не влияет на то, сколько попыток потребуется в будущем. Вероятность ждать еще t испытаний, если мы уже безуспешно ждали s испытаний, точно такая же, как если бы мы начали с нуля.

$$P(X > s + t \mid X > s) = P(X > t)$$

   Доказательство: Вероятность того, что первый успех наступит после k испытаний (то есть первые k испытаний — неудачи), равна $P(X > k) = (1 - p)^k$. Используем определение условной вероятности:

$$P(X > s + t \mid X > s) = \frac{P(X > s + t \text{ и } X > s)}{P(X > s)}$$

   Так как событие $X > s + t$ строго вложено в $X > s$, пересечение равно $X > s + t$:

$$\frac{P(X > s + t)}{P(X > s)} = \frac{(1 - p)^{s+t}}{(1 - p)^s} = (1 - p)^t = P(X > t)$$

   Свойство доказано.

2. **Минимум независимых геометрических величин.**
   Если $X_1, X_2, \ldots, X_n$ — независимые случайные величины, имеющие геометрическое распределение с параметрами $p_1, p_2, \ldots, p_n$, то их минимум $Y = \min(X_1, \ldots, X_n)$ также имеет геометрическое распределение с параметром $p_{min} = 1 - \prod_{i=1}^{n}(1 - p_i)$. Это можно интерпретировать как ожидание первого успеха в системе параллельно работающих независимых устройств.

Связи с другими распределениями:

1. **Экспоненциальное распределение.** Геометрическое распределение является дискретным аналогом экспоненциального распределения. Оба описывают время ожидания первого события и обладают свойством отсутствия памяти.

Оценка параметров

Метод максимального правдоподобия (MLE).

Пусть у нас есть выборка $x_1, x_2, \ldots, x_n$ из независимых наблюде-

ний, сгенерированных геометрическим распределением. Каждое x_i — это число испытаний до первого успеха.

Функция правдоподобия представляет собой произведение вероятностей каждого наблюдения:

$$L(p) = \prod_{i=1}^{n} P(X = x_i) = \prod_{i=1}^{n} (1-p)^{x_i - 1} p$$

Перемножим n членов. Параметр p умножается сам на себя n раз, а степени у скобок $(1-p)$ складываются:

$$L(p) = p^n (1-p)^{\sum_{i=1}^{n}(x_i - 1)} = p^n (1-p)^{\left(\sum_{i=1}^{n} x_i\right) - n}$$

Для упрощения дифференцирования перейдем к логарифмической функции правдоподобия:

$$\ln L(p) = n \ln(p) + \left(\sum_{i=1}^{n} x_i - n \right) \ln(1-p)$$

Возьмем производную по параметру p и приравняем ее к нулю для нахождения экстремума:

$$\frac{d}{dp} \ln L(p) = \frac{n}{p} - \frac{\sum_{i=1}^{n} x_i - n}{1-p} = 0$$

Приведем к общему знаменателю и решим уравнение:

$$\begin{aligned} \frac{n(1-p) - p\left(\sum x_i - n\right)}{p(1-p)} &= 0 \\ n - np - p\sum x_i + np &= 0 \\ n - p\sum x_i &= 0 \end{aligned}$$

Отсюда получаем оценку максимального правдоподобия:

$$\hat{p}_{MLE} = \frac{n}{\sum_{i=1}^{n} x_i} = \frac{1}{\bar{x}}$$

Метод моментов.

Оценка методом моментов строится на приравнивании теоретического математического ожидания к выборочному среднему. Так как $\mathbb{E}[X] = \frac{1}{p}$, приравниваем:

$$\frac{1}{p} = \bar{x} \implies \hat{p}_{MM} = \frac{1}{\bar{x}}$$

Оценки параметров методом моментов и методом максимального правдоподобия для геометрического распределения полностью совпадают и равны величине, обратной выборочному среднему.

Основная табличка

Распределение	$\mathrm{Geom}(p)$ – геометрическое распределение
Параметры	$p \in (0,1]$ (вероятность успеха в одном испытании)
Носитель	$k \in \{1,2,3,\dots\}$
Функция вероятности (PMF)	$P(X=k) = (1-p)^{k-1}p$
Функция распределения (CDF)	$F(x) = 1-(1-p)^{\lfloor x \rfloor}$
Мат. ожидание	$\mathbb{E}[X] = \dfrac{1}{p}$
Медиана	$\left\lceil \dfrac{-1}{\log_2(1-p)} \right\rceil$ (не единственна при определенных p)
Мода	1
Дисперсия	$\mathrm{Var}(X) = \dfrac{1-p}{p^2}$
Асимметрия	$\dfrac{2-p}{\sqrt{1-p}}$
Эксцесс	$6 + \dfrac{p^2}{1-p}$
Производящая функция моментов	$\dfrac{pe^t}{1-(1-p)e^t}$ для $t < -\ln(1-p)$
Харак-ая функция	$\dfrac{pe^{it}}{1-(1-p)e^{it}}$
Информация Фишера	$\dfrac{1}{p^2(1-p)}$
Метод моментов	$\hat{p} = \dfrac{1}{\bar{x}}$
Метод макс. правдоподобия (ММП)	$\hat{p}_{MLE} = \dfrac{1}{\bar{x}}$

6. ПУАССОНОВСКОЕ РАСПРЕДЕЛЕНИЕ

Пуассоновское распределение задаётся положительным параметром $\lambda > 0$. Для случайной величины $X \sim \mathrm{Pois}(\lambda)$.

- Функция вероятности (PMF):

$$P(X = k) = \frac{e^{-\lambda}\lambda^k}{k!}, \quad \text{для} \quad k = 0,\ 1,\ 2, \ldots.$$

- Функция распределения (CDF):

$$F(x) = P(X \leqslant x) = \sum_{i=0}^{\lfloor x \rfloor} \frac{e^{-\lambda}\lambda^i}{i!}.$$

Графики, соответствующие PMF и CDF, представлены на рисунке ниже.

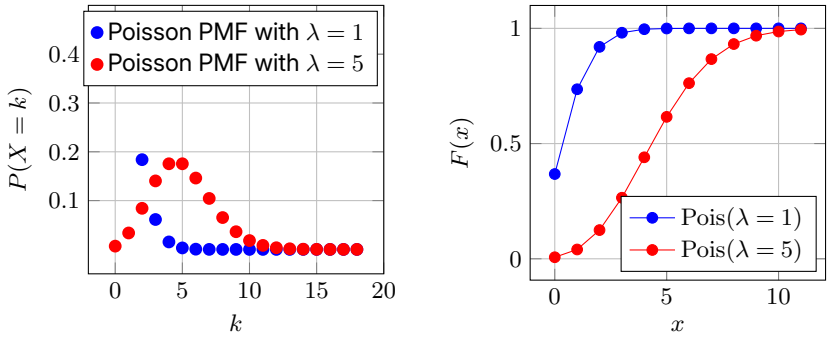

Рисунок 273. Функция вероятности и функция распределения Пуассона

Математическое ожидание равно λ; дисперсия равна λ.

Примеры распределения Пуассона в реальной жизни:

- ежедневное количество посетителей торгового центра;
- количество кликов, которые делает программист за одну минуту;
- количество транзакций (покупок), которые ежесекундно проходят в нашем маркетплейсе.

Пример 15.6.1. В магазин в среднем приходит по 32 человека в час. Можно сделать предпосылку о том, что количество посетителей в час распределено как распределение Пуассона с параметром $\lambda = 32$. Какова вероятность того, что в магазин придёт больше 45 человек за час?

Для ответа на вопрос рассчитаем вероятность того, что придёт меньше или ровно 45 человек за час, с помощью функции распределения Пуассона, а затем вычтем полученное значение из единицы. Используем встроенный расчёт значения функции распределения в Python, **cdf**.

```
lambdap = 32
k = 45
rv = poisson(lambdap)
rv.cdf(k)
```

Вероятность того, что придёт меньше или ровно 45 человек за час, составляет 98.8%. Таким образом, вероятность того, что при-

дёт больше 45 человек, составляет 1.2%.

Можно отметить, что распределение Пуассона является частным случаем биномиального распределения.

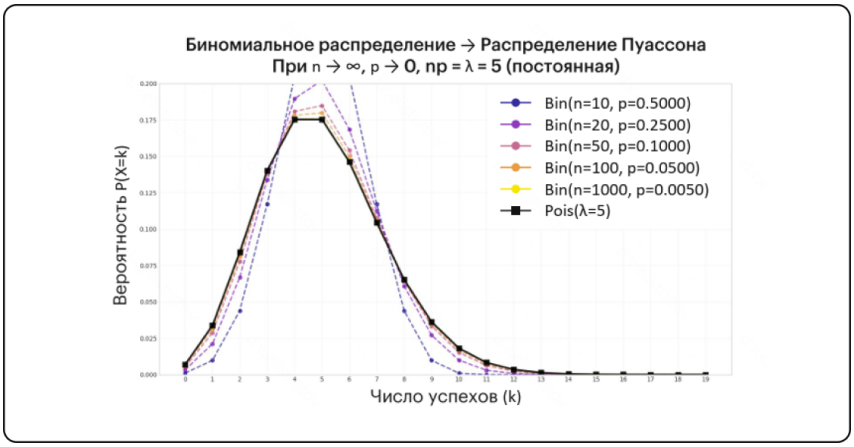

Рисунок 274. Связь распределения Пуассона с биномиальным распределением

7. ЭКСПОНЕНЦИАЛЬНОЕ РАСПРЕДЕЛЕНИЕ

Экспоненциальное распределение задаётся параметром масштаба $\lambda > 0$.

- Плотность вероятности (PDF):

$$f(x) = \lambda e^{-\lambda x} \quad \text{для} \quad x > 0.$$

- Функция распределения (CDF):

$$F(x) = 1 - e^{-\lambda x} \quad \text{для} \quad x > 0.$$

В отрицательной полуоси обе функции нулевые.

Графики, соответствующие PDF и CDF, представлены на рисунке ниже.

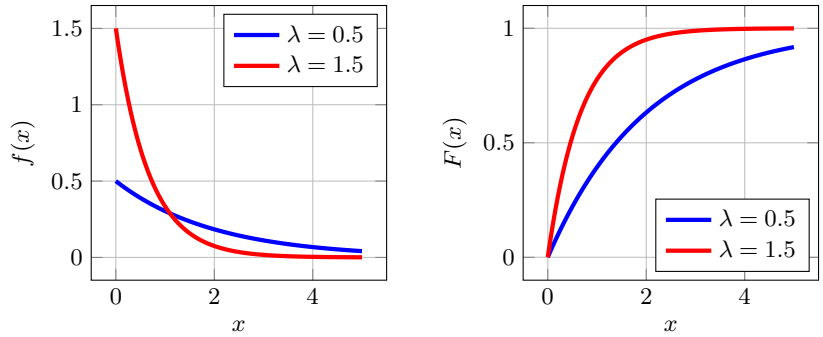

Рисунок 275. Функция плотности и функция экспоненциального распределения

Математическое ожидание равно $\frac{1}{\lambda}$; дисперсия равна $\frac{1}{\lambda^2}$.

Примеры экспоненциального распределения в реальной жизни:

- время, которое потребуется клиенту, чтобы решиться на покупку;
- время, которое пройдёт между созданием заказа в агрегаторе такси и прибытием водителя в заданную точку;
- время, которое пройдёт между выдачей клиенту кредита и его первой просрочкой по этому кредиту.

Пример 15.7.1. Время обработки платежа распределено экспоненциально, а среднее время обработки платежа составляет 2 секунды. Требуется рассчитать, какова вероятность того, что операцию нужно обрабатывать дольше 5 секунд.

Для этого вычтем из единицы вероятность того, что время обработки платежа будет меньше 5 секунд. А это время рассчитаем как значение функции распределения в точке 5. Для расчёта воспользуемся, как и в прошлых задачах, автоматическими функциями Python.

```
rv = expon(scale = 2)
rv.cdf(5)
1 - rv.cdf(5)
```

Получим значение 8.2% с помощью функции *cdf*.

Пуассоновское и экспоненциальное распределения тесно связаны через процессы ожидания событий. Если события происходят случайно с постоянной интенсивностью λ (например, звонки в кол-центр),

- *то количество событий* за фиксированное время t дискретно и распределено по Пуассону: $X \sim \text{Pois}(\lambda t)$;
- *время ожидания* до следующего события — непрерывная величина, распределённая экспоненциально: $T \sim \text{Exp}(\lambda)$.

Пример 15.7.2. В среднем в магазин приходит $\lambda = 5$ человек в час. Только исходя из этого и зная практическую связь между распределениями, можем сказать, что тогда:

- за 2 часа количество посетителей $\sim \mathrm{Pois}(10)$;
- время до прихода следующего клиента $\sim \mathrm{Exp}(5)$ с математическим ожиданием $\frac{1}{5}$ часа, то есть 12 минут.

В общем, экспоненциальное и пуассоновское распределения часто встречаются в моделировании очередей, потоков заявок и процессов обслуживания.

8. НЕПРЕРЫВНОЕ РАВНОМЕРНОЕ РАСПРЕДЕЛЕНИЕ

Это распределение случайной величины, принимающей равновероятно всевозможные значения из отрезка $[a, b]$.

- Плотность вероятности (англ. probability density function, PDF):

$$f(x) = \begin{cases} \frac{1}{b-a}, & \text{при } a \leqslant x \leqslant b; \\ 0, & \text{иначе.} \end{cases}$$

- Функция распределения (англ. cumulative distribution function, CDF):

$$F(x) = \begin{cases} 0, & \text{при } x < a; \\ \frac{x-a}{b-a}, & \text{при } a \leqslant x \leqslant b; \\ 1, & \text{при } x > b. \end{cases}$$

Графики, соответствующие PDF и CDF, представлены на рисунке ниже.

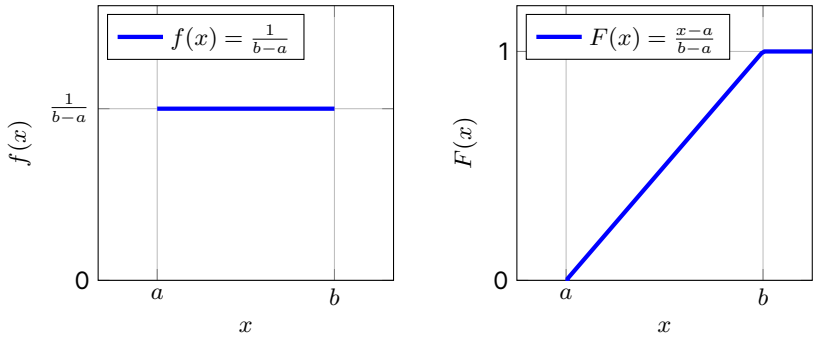

Рисунок 276. Функция плотности и функция непрерывного равномерного распределения

Математическое ожидание равно $\dfrac{a+b}{2}$; дисперсия равна $\dfrac{(b-a)^2}{12}$.

Равномерное распределение часто встречается в реальной жизни и может быть как непрерывным, так и дискретным.

- Бросок игральной кости: исход равномерно распределён между шестью потенциальными элементарными исходами.
- Угадываем день рождения случайно взятого человека: получаем равномерное распределение, в котором вероятность

попадания дня рождения на каждый день составляет $\frac{1}{365}$.

- По принципу равномерного распределения работает метод случайного семплирования (англ. simple random sampling, SRS) — извлечения выборки из генеральной совокупности. В соответствии с этим методом каждый представитель генеральной совокупности имеет равный шанс попасть в выборку.

Пример 15.8.1. Количество потенциальных посетителей семинара по статистике в Центральном университете распределено равномерно между 20 и 30 людьми. Больше 30 быть не может, так как в группе нет больше людей. Меньше 20 мы пока на семинаре не видели. Так что понадеемся, что впредь так и будет.

Посчитаем ключевые характеристики распределения.

1. Математическое ожидание распределения (ожидаемое количество людей на семинаре) составляет $\frac{1}{2} \cdot (a + b) = \frac{20+30}{2} = = 25$, то есть середина интервала распределения.
2. Дисперсия распределения составляет $\frac{1}{12} \cdot (30 - 20)^2 = = \frac{100}{12} = 8.3$. Соответственно, стандартное отклонение равно квадратному корню из 8.3, то есть примерно 2.9. В этом случае стандартное отклонение измеряется в «штуках студентов», а дисперсия — в «штуках студентов в квадрате». Более простым для интерпретации будет именно стандартное отклонение.
3. В аудитории есть только 27 мест. Перед занятием её нужно подготовить так, чтобы места были обеспечены всем 30 студентам. С какой вероятностью на ближайшем семинаре потребуется это сделать? Рассчитаем вероятность попадания случайной величины в определённый интервал как разницу между значениями функции распределения в концах интервала. Можем рассчитать руками:

$$F_{unif}(30) - F_{unif}(27) = 1 - F_{unif}(27) = = 1 - \frac{27 - 20}{30 - 20} = 1 - 0.7 = 0.3.$$

9. ГИПЕРГЕОМЕТРИЧЕСКОЕ РАСПРЕДЕЛЕНИЕ

Общее

Гипергеометрическое распределение ($\mathcal{HG}(N, K, n)$) — это дискретное распределение вероятностей.

Оно описывает вероятность получить ровно k «успешных» объектов в случайной выборке объема n, производимой без возвращения из конечной генеральной совокупности размера N. При этом предполагается, что во всей совокупности содержится ровно K объектов, обладающих заданным признаком (то есть «успехов»).

Поскольку извлечение объектов происходит без возвращения,

каждое последующее испытание зависит от результатов предыдущих. Вероятность успеха динамически меняется на каждом шаге.

В этом состоит принципиальное отличие гипергеометрического распределения от биномиального, которое моделирует вероятность k успехов в n испытаниях при выборке с возвращением (где испытания независимы, а вероятность успеха остается неизменной).

Рассмотрим классический пример применения этой теории: оценку численности популяции волков в заповеднике (метод повторного отлова).

Допустим, биолог отлавливает K волков, надевает на них радиоошейники и отпускает.

Спустя время производится вторая случайная выборка объема n, в которой обнаруживается ровно k особей с ошейниками. Используя гипергеометрическое распределение, исследователь может оценить неизвестную общую численность популяции N.

ОПРЕДЕЛЕНИЕ 15.9.1

Случайная величина X имеет гипергеометрическое распределение если функция вероятности имеет вид:

$$P(X = k) = \frac{C_K^k C_{N-K}^{n-k}}{C_N^n},$$

Где N – размер совокупности; K – кол-во успехов в совокупности; n – объем случайно выборки; k – наблюдаемое кол-во успехов.

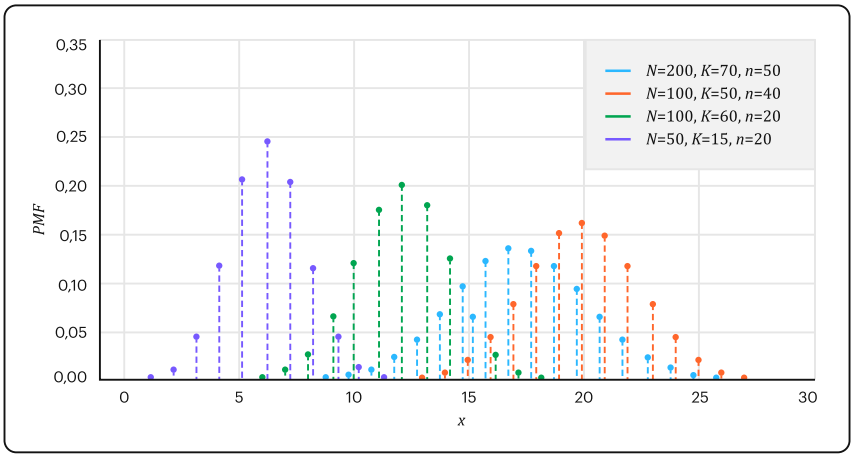

Рисунок 277. Функции вероятности гипергеометрического распределения

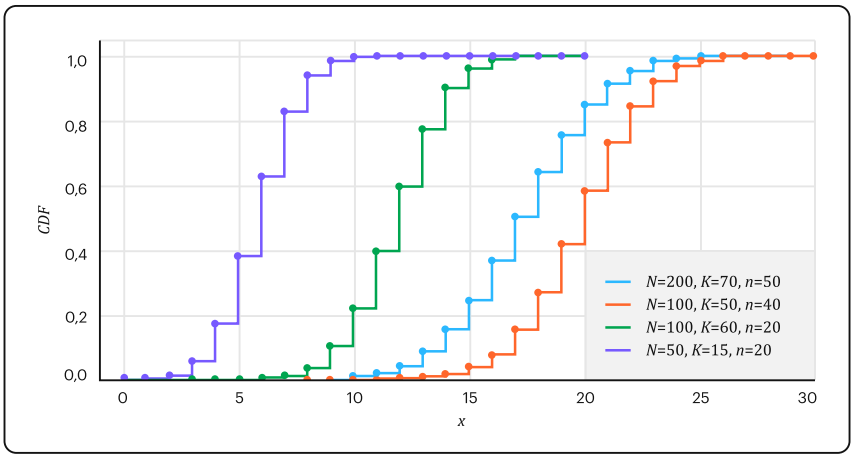

Рисунок 278. Функция распределения гипергеометрического распределения

- **Количество «успехов» в популяции (K):**
  Выполняет функцию сдвига. Рост K смещает основную массу распределения вправо (в выборке ожидается больше успехов). При граничных значениях ($K = 0$ или $K = N$) дисперсия обнуляется, и исход становится предопределенным.
- **Объем выборки (n):**
  Увеличивает математическое ожидание и специфически влияет на дисперсию через поправочный множитель конечной совокупности $\frac{N-n}{N-1}$. По мере того как n приближается к N, этот множитель стремительно гасит дисперсию: чем большую часть популяции мы отлавливаем, тем меньше неопределенность. При $n = N$ разброс исчезает полностью.
- **Размер генеральной совокупности (N):**
  Определяет силу эффекта «выборки без возвращения». Чем меньше N, тем сильнее извлечение одного объекта меняет шансы для следующего. Из-за этого гипергеометрическое распределение становится более узким (дисперсия ниже), чем аналогичное биномиальное.

Моменты и характеристики

Моменты гипергеометрического распределения

Пусть X — гипергеометрическая случайная величина, обозначающая число «успехов» в выборке объема n из генеральной совокупности объема N, содержащей K «успехов».

Представим общее число успехов X как сумму индикаторных случайных величин:

$$X = I_1 + I_2 + \cdots + I_n = \sum_{i=1}^{n} I_i$$

где $I_i = 1$, если i-й извлеченный объект является «успешным», и $I_i = 0$ в противном случае.

Поскольку извлечение происходит случайно, безусловная веро-

ятность успеха на любом i-м шаге одинакова (до того, как мы узнаем результаты других шагов) и равна доле успехов во всей совокупности:

$$\mathbb{P}(I_i = 1) = \frac{K}{N} = p$$

Математическое ожидание

Математическое ожидание индикатора равно вероятности его наступления: $\mathbb{E}[I_i] = p = \frac{K}{N}$.

В силу линейности математического ожидания (которая работает даже для зависимых величин), ожидание суммы равно сумме ожиданий:

$$\mathbb{E}[X] = \mathbb{E}\left[\sum_{i=1}^{n} I_i\right] = \sum_{i=1}^{n} \mathbb{E}[I_i] = n \cdot \frac{K}{N}$$

Это полностью совпадает с матожиданием биномиального распределения (np).

Дисперсия

Дисперсия суммы зависимых случайных величин вычисляется по формуле:

$$\mathrm{Var}(X) = \sum_{i=1}^{n} \mathrm{Var}(I_i) + \sum_{i \neq j} \mathrm{Cov}(I_i, I_j)$$

Найдем дисперсию одного индикатора. Поскольку это распределение Бернулли:

$$\mathrm{Var}(I_i) = p(1-p) = \frac{K}{N}\left(1 - \frac{K}{N}\right) = \frac{K(N-K)}{N^2}$$

Теперь найдем ковариацию $\mathrm{Cov}(I_i, I_j) = \mathbb{E}[I_i I_j] - \mathbb{E}[I_i]\mathbb{E}[I_j]$ для $i \neq j$.

Произведение $I_i I_j$ равно 1 только если оба извлеченных объекта успешны. Вероятность первого успеха равна $\frac{K}{N}$, а вероятность второго (при условии первого) равна $\frac{K-1}{N-1}$:

$$\mathbb{E}[I_i I_j] = \mathbb{P}(I_i = 1 \text{ и } I_j = 1) = \frac{K}{N} \cdot \frac{K-1}{N-1}$$

Вычислим ковариацию:

$$\mathrm{Cov}(I_i, I_j) = \frac{K(K-1)}{N(N-1)} - \left(\frac{K}{N}\right)^2 = -\frac{K(N-K)}{N^2(N-1)}$$

Отрицательная ковариация отражает тот факт, что успех на

одном шаге уменьшает шансы на успех в другом (выборка без возвращения).

Далее соберем дисперсию вместе. Сумма дисперсий содержит n слагаемых, а сумма ковариаций — $n(n-1)$ слагаемых (количество пар $i \neq j$):

$$\begin{aligned}\mathrm{Var}(X) &= n\frac{K(N-K)}{N^2} - n(n-1)\frac{K(N-K)}{N^2(N-1)} = \\ &= n\frac{K(N-K)}{N^2}\left(1 - \frac{n-1}{N-1}\right)\end{aligned}$$

Причешем выражение выше и получим окончательную формулу дисперсии:

$$\mathrm{Var}(X) = n\frac{K}{N}\left(1 - \frac{K}{N}\right)\frac{N-n}{N-1}$$

Свойства и связи с другими распределениями

Приведем некоторые свойства и связи.

Свойства:

1. Симметрия успехов и неудач:
   Если мы поменяем фокус с «успехов» на «неудачи», то распределение числа неудач $n-k$ в выборке будет идентично гипергеометрическому распределению, где целевым признаком выступают $N-K$ изначальных неудач.

   $$P(X = k; N, K, n) = P(Y = n-k; N, N-K, n)$$

   Доказательство: Распишем правую часть по определению. Подставим новые параметры (количество успехов $K' = N - K$ и искомое число $k' = n - k$):

   $$P(Y = n-k) = \frac{C_{N-K}^{n-k} C_{N-(N-K)}^{n-(n-k)}}{C_N^n} = \frac{C_{N-K}^{n-k} C_K^k}{C_N^n} = P(X = k)$$

   Равенство выполняется.

2. Симметрия выборки и популяции (двойственность):
   Вероятность извлечь k меченых элементов в выборке размера n в точности равна вероятности извлечь k меченых элементов в выборке размера K, если бы мы исходно пометили n элементов в популяции. Параметры K и n можно свободно менять местами:

   $$P(X = k; N, K, n) = P(X = k; N, n, K)$$

   Доказательство: Распишем левую часть через факториалы и

перегруппируем множители в числителе:

$$P(X=k;N,K,n)=\frac{\frac{K!}{k!(K-k)!}\cdot\frac{(N-K)!}{(n-k)!(N-K-n+k)!}}{\frac{N!}{n!(N-n)!}}$$

$$=\frac{n!}{k!(n-k)!}\cdot\frac{K!(N-K)!(N-n)!}{N!(K-k)!(N-K-n+k)!}=\frac{C_n^k C_{N-n}^{K-k}}{C_N^K}=P(X=k;N,n,K)$$

Равенство выполняется.

3. Свойство дисперсии (Поправочный множитель):
   Если обозначить $p=\frac{K}{N}$, то дисперсия гипергеометрического распределения имеет вид:

$$\mathrm{Var}(X)=np(1-p)\frac{N-n}{N-1}$$

   Множитель $\frac{N-n}{N-1}$ называется поправочным множителем конечной совокупности. Его можно использовать когда строятся ДИ для конечной совокупности, так интервал получается уже. Это свойство описывает поведение дисперсии в предельных случаях:
   - При неограниченном росте генеральной совокупности ($N\to\infty$) предел множителя равен единице:

$$\lim_{N\to\infty}\frac{N-n}{N-1}=\lim_{N\to\infty}\frac{1-n/N}{1-1/N}=1$$

     Дисперсия превращается в дисперсию биномиального распределения $np(1-p)$.
   - При полном исчерпании популяции ($n=N$) числитель дроби обнуляется:

$$\frac{N-N}{N-1}=0$$

     Дисперсия обнуляется, так как выборка гарантированно будет содержать все K успехов (случайность исчезает).

4. Рекуррентное соотношение:
   Для эффективного вычисления вероятностей на компьютере (чтобы избежать работы с огромными факториалами) используется рекуррентное свойство, связывающее вероятность $k+1$ успехов с вероятностью k успехов.
   Разделив $P(X=k+1)$ на $P(X=k)$ и сократив факториалы, получаем формулу перехода:

$$P(X=k+1)=P(X=k)\cdot\frac{(K-k)(n-k)}{(k+1)(N-K-n+k+1)}$$

   Эта рекурсия позволяет начать вычисления с $P(X=0)$ (или минимально возможного значения k) и последовательно находить всю функцию вероятности за время $O(n)$ при помощи простых арифметических операций.

Связи с другими распределениями:

1. Биномиальное распределение является предельным случаем гипергеометрического.

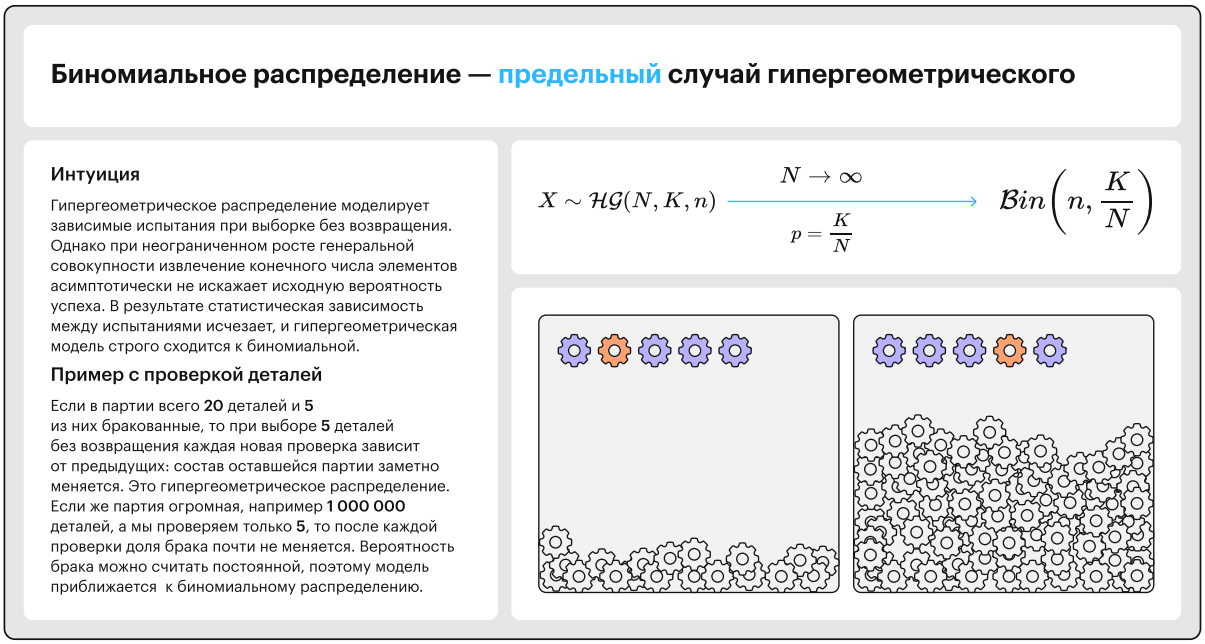

Рисунок 279. Связь биномиального и гипергеометрического распределений

2 Мультиномиальное распределение является предельным случаем гипергеометрического.

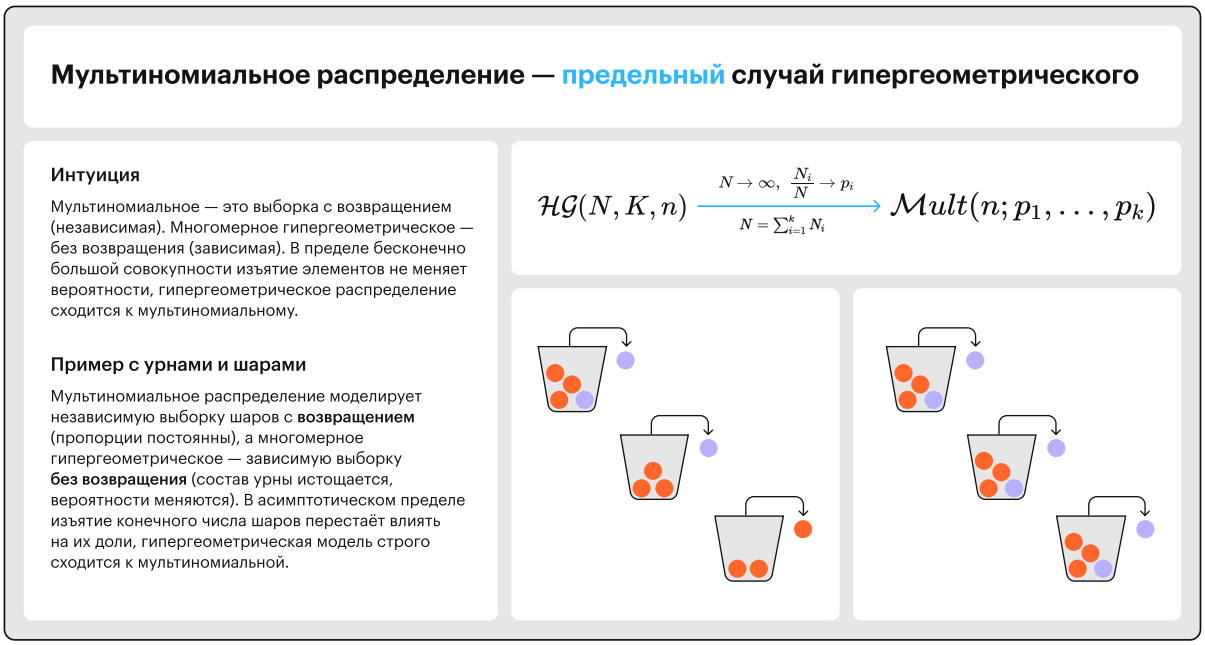

Рисунок 280. Связь мультиномиального и гипергеометрического распределений

Оценка параметров

Метод максимального правдоподобия.

Пусть мы имеем одну выборку размера n, в которой зафиксировано ровно k «успехов».

Функция правдоподобия для неизвестных параметров N (размер генеральной совокупности) и K (число успехов в ней) имеет вид:

$$L(N,K) = P(X = k; N, K) = \frac{C_K^k C_{N-K}^{n-k}}{C_N^n}$$

Поскольку N и K являются дискретными (целочисленными) параметрами, классическое дифференцирование невозможно.

Для нахождения максимума исследуем отношение функции правдоподобия в точке к ее значению в предыдущей точке. Максимум достигается там, где это отношение перестает превышать единицу.

1. Оценка размера генеральной совокупности N

Предположим, что K известно. Рассмотрим отношение $L(N)/L(N-1)$:

$$\frac{L(N)}{L(N-1)} = \frac{C_{N-K}^{n-k} C_{N-1}^n}{C_{N-K-1}^{n-k} C_N^n}$$

Раскрывая биномиальные коэффициенты через факториалы и сокращая общие множители, получаем:

$$\frac{L(N)}{L(N-1)} = \frac{(N-K)(N-n)}{N(N-K-n+k)}$$

Функция правдоподобия возрастает, пока это отношение больше или равно 1:

$$\frac{(N-K)(N-n)}{N(N-K-n+k)} \geqslant 1 \implies N \leqslant \frac{Kn}{k}$$

Следовательно, максимум функции правдоподобия достигается в точке, соответствующей наибольшему целому числу, удовлетворяющему этому неравенству:

$$\hat{N}_{MLE} = \left\lfloor \frac{K \cdot n}{k} \right\rfloor$$

2. Оценка числа успехов в популяции K

Теперь предположим, что N известно. Рассмотрим отношение $L(K)/L(K-1)$:

$$\frac{L(K)}{L(K-1)} = \frac{C_K^k C_{N-K}^{n-k}}{C_{K-1}^k C_{N-K+1}^{n-k}}$$

После аналогичного сокращения факториалов получаем:

$$\frac{L(K)}{L(K-1)} = \frac{K(N-K-n+k+1)}{(K-k)(N-K+1)}$$

Найдем условие, при котором функция возрастает:

$$\frac{K(N-K-n+k+1)}{(K-k)(N-K+1)} \geqslant 1 \implies K \leqslant \frac{k(N+1)}{n}$$

Таким образом, оценка максимального правдоподобия для K равна:

$$\hat{K}_{MLE} = \left\lfloor \frac{k(N+1)}{n} \right\rfloor$$

Отметим, что оценка ММП для $\hat{N}$ совпадает с методом моментов. А для $\hat{K}$ отличается на множитель $(N+1)$ в случае ММП и N в случае ММ.

Основная табличка

Распределение	$\mathcal{HG}(N,K,n)$ – гипергеометрическое распределение
Параметры	$N \in \{0,1,2,\dots\}$ (размер генеральной совокупности) $K \in \{0,1,\dots,N\}$ (количество успехов в совокупности) $n \in \{0,1,\dots,N\}$ (объем выборки)
Носитель	$k \in \{\max(0,n+K-N),\dots,\min(n,K)\}$
Функция вероятности (PMF)	$P(X=k) = \dfrac{C_K^x C_{N-K}^{n-x}}{C_N^n}$
Функция распределения (CDF)	$F(x) = \sum_{i=0}^{x} \dfrac{C_K^i C_{N-K}^{n-i}}{C_N^n}$
Мат. ожидание	$\mathbb{E}[X] = n\dfrac{K}{N}$
Медиана	Не имеет простого аналитического выражения
Мода	$\left\lfloor \dfrac{(n+1)(K+1)}{N+2} \right\rfloor$
Дисперсия	$\mathrm{Var}(X) = n\dfrac{K}{N}\left(1-\dfrac{K}{N}\right)\dfrac{N-n}{N-1}$
Асимметрия	$\dfrac{(N-2K)(N-2n)\sqrt{N-1}}{(N-2)\sqrt{nK(N-K)(N-n)}}$
Эксцесс	$\dfrac{N^2(N-1)}{nK(N-K)(N-n)(N-2)(N-3)} \cdot \Big[N(N+1) - 6n(N-n) - 6K(N-K$
Производящая функция моментов	$\dfrac{\binom{N-K}{n}}{\binom{N}{n}}\,{}_2F_1(-n,-K;N-K-n+1;e^t)$ (где ${}_2F_1$ — гипергеометрическая функция)
Харак-ая функция	$\dfrac{\binom{N-K}{n}}{\binom{N}{n}}\,{}_2F_1(-n,-K;N-K-n+1;e^{it})$
Информация Фишера	???
Метод моментов	Оценка N (при известных K,n): $\hat{N} = \left\lfloor \dfrac{K\cdot n}{\mathbb{E}[X]} \right\rfloor$ Оценка K (при известных N,n): $\hat{K} = \left\lfloor \dfrac{\mathbb{E}[X]\cdot N}{n} \right\rfloor$
Метод макс. правдоподобия (ММП)	Оценка N (при известных K,n): $\hat{N}_{MLE} = \left\lfloor \dfrac{K\cdot n}{k} \right\rfloor$ Оценка K (при известных N,n): $\hat{K}_{MLE} = \left\lfloor \dfrac{k(N+1)}{n} \right\rfloor$

10. РАСПРЕДЕЛЕНИЕ ХИ-КВАДРАТ

Общее

Распределение хи-квадрат (χ^2_k) — это семейство непрерывных распределений, определенных на полубесконечном интервале $[0, +\infty)$.

Оно задается единственным параметром $k > 0$, который называется числом степеней свободы. Чаще всего k принимает целые положительные значения.

Распределение хи-квадрат является одним из важнейших в математической статистике. Оно массово применяется для проверки статистических гипотез (критерий согласия Пирсона, критерий независимости), построения доверительных интервалов для дисперсии нормальной генеральной совокупности, а также является фундаментом для распределений Стьюдента и Фишера.

ОПРЕДЕЛЕНИЕ 15.10.1

Если случайные величины $Z_1, Z_2, \ldots, Z_k$ независимы и имеют стандартное нормальное распределение $N(0, 1)$, то сумма их квадратов:

$$X = Z_1^2 + Z_2^2 + \cdots + Z_k^2 = \sum_{i=1}^{k} Z_i^2$$

имеет распределение хи-квадрат с k степенями свободы ($X \sim \chi^2_k$).

Математически это распределение описывается функцией плотности вероятности следующего вида:

$$f(x) = \frac{1}{2^{k/2}\Gamma(k/2)} x^{k/2-1} e^{-x/2}$$

В свою очередь функция распределения (CDF) выражается через нижнюю неполную гамма-функцию $\gamma(s, x)$:

$$F(x) = \frac{1}{\Gamma(k/2)} \gamma(k/2, x/2)$$

Гамма-функция. В формулах выше используется гамма-функция $\Gamma(s)$, которая является математическим обобщением факториала на множество вещественных (и комплексных) чисел. Она определяется через несобственный интеграл:

$$\Gamma(s) = \int_0^{\infty} t^{s-1} e^{-t}\, dt$$

Для любого целого положительного числа n гамма-функция строго связана с классическим факториалом соотношением $\Gamma(n) = (n-1)!$. Кроме того, для любых положительных s выполняется фундаментальное рекуррентное свойство: $\Gamma(s+1) = s\Gamma(s)$.

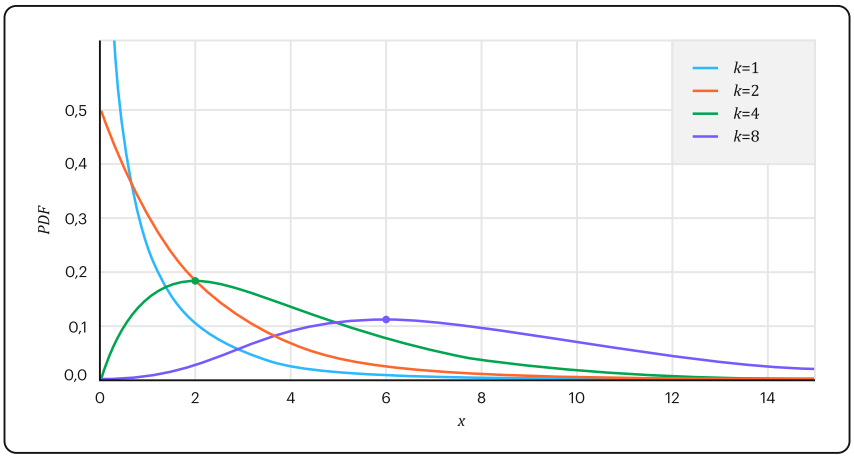

Рисунок 281. Плотность вероятности распределения хи-квадрат

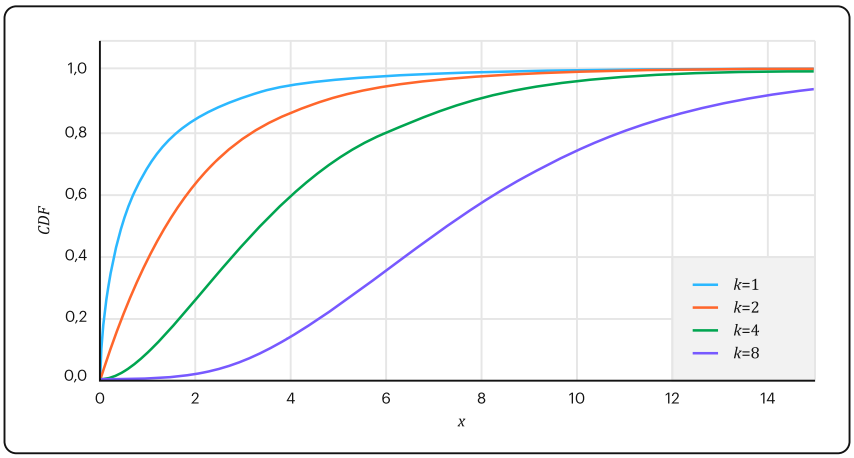

Рисунок 282. Функция распределения хи-квадрат

Параметр k определяет форму распределения.

При $k = 1$ или $k = 2$ плотность строго убывает (причем при $k = 2$ оно совпадает с экспоненциальным распределением).

Для всех $k > 2$ кривая плотности начинается с нуля в начале координат, имеет единственный пик (моду) в точке $k - 2$ и характеризуется сильной правосторонней асимметрией (длинным правым хвостом).

По мере увеличения числа степеней свободы k, математическое ожидание сдвигается вправо, дисперсия растет, а форма колокола становится все более симметричной, асимптотически приближаясь к нормальному распределению.

Характеристическая функция и производящая функция моментов

Характеристическая функция

По определению, характеристическая функция есть математиче-

ское ожидание комплексной экспоненты e^{itX}:

$$\varphi_X(t) = \mathbb{E}[e^{itX}] = \int_0^\infty e^{itx} \frac{1}{2^{k/2}\Gamma(k/2)} x^{k/2-1} e^{-x/2}\, dx$$

Объединим экспоненты в интеграле:

$$\varphi_X(t) = \frac{1}{2^{k/2}\Gamma(k/2)} \int_0^\infty x^{k/2-1} e^{-x(1/2-it)}\, dx$$

Полученный интеграл является стандартным гамма-интегралом вида $\int_0^\infty x^{\alpha-1}e^{-\beta x}dx = \frac{\Gamma(\alpha)}{\beta^\alpha}$.

В нашем случае $\alpha = k/2$, а $\beta = 1/2 - it$. Подставляя эти значения, вычисляем интеграл:

$$\int_0^\infty x^{k/2-1} e^{-x(1/2-it)}\, dx = \frac{\Gamma(k/2)}{(1/2-it)^{k/2}}$$

Теперь подставим результат интегрирования обратно в исходное выражение:

$$\begin{aligned}\varphi_X(t) &= \frac{1}{2^{k/2}\Gamma(k/2)} \cdot \frac{\Gamma(k/2)}{(1/2-it)^{k/2}} \\ &= \frac{1}{2^{k/2}(1/2-it)^{k/2}} \\ &= \frac{1}{(1-2it)^{k/2}}\end{aligned}$$

Окончательный вид характеристической функции:

$$\varphi_X(t) = (1-2it)^{-k/2}$$

Производящая функция моментов

Производящая функция моментов (MGF) определяется как математическое ожидание действительной экспоненты:

$$M_X(t) = \mathbb{E}[e^{tX}]$$

Интеграл для $M_X(t)$ сходится, если показатель экспоненты в подынтегральном выражении отрицателен, то есть при $t < 1/2$.

Для нахождения MGF мы можем воспользоваться методом аналитического продолжения, выполнив формальную замену аргумента t в характеристической функции на мнимую величину $-it$:

$$\varphi_X(-it) = \mathbb{E}[e^{tX}] = M_X(t)$$

Применим эту подстановку $-it$ вместо t к результату, полученному для характеристической функции:

$$M_X(t) = \varphi_X(-it) = (1 - 2(-it)i)^{-k/2} \\ = (1 - 2t)^{-k/2}$$

Функция моментов распределения хи-квадрат определена для $t < 1/2$.

Моменты и характеристики

Вычислим математическое ожидание через определение.

$$\mathbb{E}[X] = \int_0^\infty x \cdot \frac{1}{2^{k/2}\Gamma(k/2)} x^{k/2-1} e^{-x/2}\, dx = \frac{1}{2^{k/2}\Gamma(k/2)} \int_0^\infty x^{k/2} e^{-x/2}\, dx$$

Интеграл представляет собой гамма-интеграл, с параметром $\alpha = k/2 + 1$. Его значение равно $\frac{\Gamma(k/2+1)}{(1/2)^{k/2+1}} = 2^{k/2+1}\Gamma(k/2+1)$.

Заменим интеграл на этот результат:

$$\mathbb{E}[X] = \frac{2^{k/2+1}\Gamma(k/2+1)}{2^{k/2}\Gamma(k/2)}$$

Сократим степени двойки ($2^{k/2+1}/2^{k/2} = 2$) и воспользуемся основным рекуррентным свойством гамма-функции $\Gamma(s+1) = s\Gamma(s)$, подставив $\Gamma(k/2+1) = \frac{k}{2}\Gamma(k/2)$:

$$\mathbb{E}[X] = 2 \cdot \frac{\frac{k}{2}\Gamma(k/2)}{\Gamma(k/2)} = 2 \cdot \frac{k}{2} = k$$

Математическое ожидание распределения хи-квадрат в точности равно числу его степеней свободы.

Найдем математическое ожидание и дисперсию через MGF.

Известно, что n-й начальный момент случайной величины равен n-й производной от MGF, вычисленной в точке $t = 0$:

$$\mathbb{E}[X^n] = M_X^{(n)}(0) = \frac{d^n}{dt^n} M_X(t)\bigg|_{t=0}$$

Вычисление математического ожидания

Для нахождения математического ожидания $\mathbb{E}[X]$ вычислим

первую производную $M_X(t) = (1-2t)^{-k/2}$ по переменной t:

$$M'_X(t) = \left(-\frac{k}{2}\right)(1-2t)^{-k/2-1} \cdot (-2) = k(1-2t)^{-k/2-1}$$

Подставляя $t = 0$, получаем:

$$M'_X(0) = k(1-0)^{-k/2-1} = k$$

Вычисление дисперсии

Дисперсия выражается через первый и второй начальные моменты по формуле:

$$\mathrm{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

Сначала найдем второй начальный момент $\mathbb{E}[X^2]$, вычислив вторую производную от MGF:

$$M''_X(t) = \frac{d}{dt}\left[k(1-2t)^{-k/2-1}\right] = k\left(-\frac{k}{2}-1\right)(1-2t)^{-k/2-2} \cdot (-2) = k(k+2)(1-2t)^{-k/2-2}$$

Подставляя $t = 0$, получаем второй момент:

$$M''_X(0) = k(k+2)$$

Теперь подставим найденные моменты в формулу дисперсии:

$$\mathrm{Var}(X) = k(k+2) - k^2 = k^2 + 2k - k^2 = 2k$$

Таким же образом можно вычислить коэффициенты асимметрии и эксцесса, находя третью и четвертую производные MGF. Дисперсия равна удвоенному числу степеней свободы.

Свойства и связи с другими распределениями

Приведем некоторые свойства и связи.

Свойства:

1. **Свойство аддитивности (воспроизводимости).**
   Семейство распределений хи-квадрат замкнуто относительно операции сложения независимых величин.
   Сумма независимых случайных величин, имеющих распределение хи-квадрат, также имеет распределение хи-квадрат, а их степени свободы складываются. Пусть $X_1 \sim \chi^2_{k_1}$ и

$X_2 \sim \chi^2_{k_2}$ — независимы, тогда:

$$X_1 + X_2 \sim \chi^2_{k_1+k_2}$$

Это фундаментальное свойство позволяет легко анализировать суммы независимых выборочных статистик.
Доказательство: Воспользуемся определением распределения хи-квадрат через сумму квадратов стандартных нормальных величин. Пусть X_1 — это сумма квадратов k_1 независимых $N(0,1)$ величин, а X_2 — сумма квадратов других k_2 независимых $N(0,1)$ величин. Поскольку X_1 и X_2 независимы между собой, их сумма $X_1 + X_2$ представляет собой просто сумму $k_1 + k_2$ независимых квадратов стандартных нормальных величин. По определению, такая случайная величина имеет распределение $\chi^2_{k_1+k_2}$.

2. **Масштабирование (переход к гамма-распределению).**
Распределение хи-квадрат не замкнуто относительно умножения на константу. При умножении случайной величины χ^2_k на положительную константу $c \neq 1$, она переходит в более широкое семейство гамма-распределений:

$$cX \sim \text{Gamma}\left(\alpha = \frac{k}{2}, \lambda = \frac{1}{2c}\right)$$

Доказательство: Найдем характеристическую функцию величины $Y = cX$, используя свойство характеристических функций $\varphi_{cX}(t) = \varphi_X(ct)$. Подставим характеристическую функцию хи-квадрата:

$$\varphi_Y(t) = (1 - 2ict)^{-k/2} = \left(1 - \frac{it}{1/(2c)}\right)^{-k/2}$$

Полученное выражение в точности совпадает с характеристической функцией гамма-распределения $\varphi(t) = \left(1 - \frac{it}{\lambda}\right)^{-\alpha}$, где параметр формы $\alpha = k/2$, а параметр интенсивности $\lambda = 1/(2c)$.

3. **Жесткая связь моментов.**
У распределения хи-квадрат дисперсия всегда строго пропорциональна математическому ожиданию (она ровно в два раза больше):

$$\text{Var}(X) = 2\mathbb{E}[X] = 2k$$

Это внутреннее свойство означает, что по мере смещения центра распределения вправо (с ростом k), разброс данных также неизбежно и линейно возрастает.
Доказательство: Докажем через определение $X = \sum_{i=1}^{k} Z_i^2$, где $Z_i \sim N(0,1)$. В силу независимости слагаемых, дисперсия суммы равна сумме дисперсий: $\text{Var}(X) = \sum_{i=1}^{k} \text{Var}(Z_i^2)$. Найдем дисперсию одной компоненты: $\text{Var}(Z_i^2) = \mathbb{E}[Z_i^4] - (\mathbb{E}[Z_i^2])^2$. Для стандартного нормального распределения четвертый начальный момент равен 3, а второй равен 1. Отсюда $\text{Var}(Z_i^2) = 3 - 1^2 = 2$. Суммируя k

таких независимых дисперсий, получаем искомую дисперсию суммы: $\mathrm{Var}(X) = 2k$.

Связи с другими распределениями:

1. При $k = 2$ распределение хи-квадрат полностью совпадает с экспоненциальным распределением $\mathrm{Exp}(1/2)$.
2. По Центральной предельной теореме, при $k \to \infty$ распределение χ^2_k асимптотически стремится к нормальному распределению $N(k, 2k)$.

Оценка параметров

Метод моментов.

Оценим значение параметра k. Поскольку параметр всего один, нам достаточно использовать только первый момент — математическое ожидание:

$$\mathbb{E}[X] = k$$

Приравняв теоретическое математическое ожидание к выборочному среднему $\bar{x}$, мы получаем элементарную оценку:

$$\hat{k}_{\text{ММ}} = \bar{x}$$

Метод максимального правдоподобия (MLE).

Если рассматривать k как непрерывный параметр, оценка максимального правдоподобия требует составления функции логарифмического правдоподобия.

Приравняв ее производную по k к нулю, мы получим уравнение:

$$\psi\left(\frac{\hat{k}}{2}\right) = \overline{\ln x} - \ln 2$$

Где $\psi(\cdot)$ — дигамма-функция (логарифмическая производная гамма-функции), а $\overline{\ln x} = \frac{1}{n}\sum \ln x_i$.

Это нелинейное уравнение не имеет решения в радикалах и решается на практике численными методами.

Основная табличка

Параметры	$k > 0$ (степени свободы)
Носитель	$x \in [0, +\infty)$
Плотность (PDF)	$f(x) = \frac{1}{2^{k/2}\Gamma(k/2)} x^{k/2-1} e^{-x/2}$
Функция распределения (CDF)	$\frac{1}{\Gamma(k/2)}\gamma(k/2, x/2)$ (регуляризованная неполная гамма-функция)
Мат. ожидание	k
Медиана	$\approx k\left(1 - \frac{2}{9k}\right)^3$
Мода	$\max(k-2, 0)$
Дисперсия	$2k$
Асимметрия	$\sqrt{\frac{8}{k}}$
Эксцесс	$\frac{12}{k}$
Производящая функция моментов	$(1-2t)^{-k/2}$ для $t < 1/2$
Харак-ая функция	$(1-2it)^{-k/2}$
Информация Фишера	$I(k) = \frac{1}{4}\psi^{(1)}\left(\frac{k}{2}\right)$ ($\psi^{(1)}$ — тригамма-функция)
Метод моментов	$\hat{k} = \bar{x}$
Метод максимального правдоподобия (MLE)	$\psi\left(\frac{\hat{k}}{2}\right) = \overline{\ln x} - \ln 2$ (решается численно)

11. РАСПРЕДЕЛЕНИЕ СТЬЮДЕНТА

Общее

Распределение Стьюдента (или t-распределение, обозначается как t_ν) — это семейство непрерывных распределений, определенных на всей числовой прямой $\mathbb{R}$.

Оно задается единственным положительным параметром ν, называемым числом степеней свободы.

Распределение Стьюдента возникает в задаче оценки математического ожидания нормально распределенной генеральной совокупности при **неизвестной** дисперсии. Оно лежит в основе t-критерия Стьюдента для оценки статистической значимости

разности средних и широко применяется при работе с малыми выборками.

ОПРЕДЕЛЕНИЕ 15.11.1

Пусть $Z \sim \mathcal{N}(0,1)$ — стандартная нормальная случайная величина, а $V \sim \chi^2_\nu$ — независимая от неё случайная величина, имеющая распределение хи-квадрат с ν степенями свободы.

Тогда случайная величина, определяемая как отношение стандартной нормальной величины к квадратному корню из хи-квадрат величины, поделенной на ее степени свободы:

$$T = \frac{Z}{\sqrt{V/\nu}}$$

имеет распределение Стьюдента с ν степенями свободы ($T \sim t_\nu$).

Математически это распределение описывается функцией плотности вероятности (PDF) следующего вида:

$$f(x) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\,\Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}}$$

В свою очередь функция распределения (CDF) выражается через регуляризованную неполную бета-функцию:

$$F(x) = \begin{cases} \frac{1}{2} I_{\frac{\nu}{x^2+\nu}}\left(\frac{\nu}{2}, \frac{1}{2}\right), & \text{если } x < 0 \\ 1 - \frac{1}{2} I_{\frac{\nu}{x^2+\nu}}\left(\frac{\nu}{2}, \frac{1}{2}\right), & \text{если } x \geqslant 0 \end{cases}$$

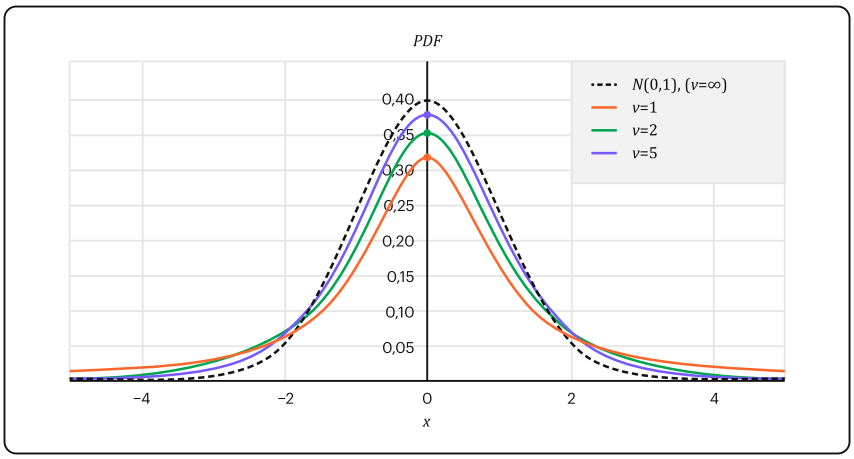

Рисунок 283. Плотность вероятности распределения Стьюдента

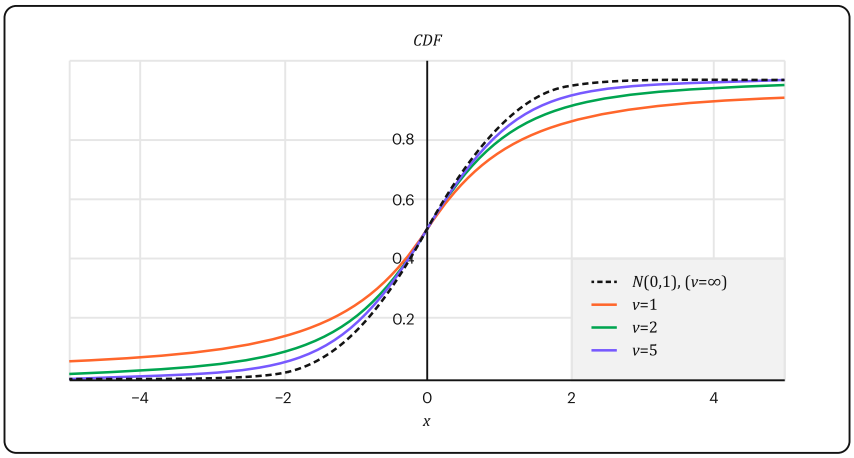

Рисунок 284. Функция распределения Стьюдента

Визуально плотность распределения Стьюдента очень похожа на стандартное нормальное распределение (обе функции колоколообразны и симметричны относительно нуля).

Ключевое отличие заключается в «хвостах» распределения. При малых значениях параметра ν (например, $\nu = 1, 2$) распределение Стьюдента имеет гораздо более низкий центральный пик и **тяжелые хвосты**.

Это означает, что экстремальные выбросы происходят значительно чаще, чем предсказывает нормальный закон.

По мере увеличения числа степеней свободы $\nu \to \infty$, тяжесть хвостов уменьшается, и t-распределение асимптотически стремится к стандартному нормальному распределению $\mathcal{N}(0, 1)$.

Характеристическая функция и производящая функция моментов

Производящая функция моментов (Отсутствие MGF)

Производящая функция моментов (MGF) определяется как математическое ожидание действительной экспоненты:

$$M_X(t) = \mathbb{E}[e^{tX}] = \int_{-\infty}^{\infty} e^{tx} f(x)\, dx$$

У распределения Стьюдента хвосты плотности убывают полиномиально (как $|x|^{-(\nu+1)}$), а не экспоненциально (как у нормального распределения).

При умножении плотности на экспоненту e^{tx} для любого $t \neq 0$, подынтегральное выражение на бесконечности начинает экспоненциально расти, так как e^{tx} всегда «побеждает» полиномиальное убывание.

Следовательно, интеграл расходится. **Производящая функция моментов для распределения Стьюдента не существует** (не определена нигде, кроме тривиальной точки $t = 0$).

Моменты и характеристики

Поскольку MGF не существует, мы не можем найти моменты через ее производные. Вместо этого вычислим моменты, используя прямые интегралы и свойство симметрии плотности.

Вычисление математического ожидания

По определению математическое ожидание задается интегралом:

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x \cdot \frac{C_\nu}{\left(1 + \frac{x^2}{\nu}\right)^{\frac{\nu+1}{2}}}\, dx$$

Где $C_\nu = \frac{1}{\sqrt{\nu}\mathrm{B}(1/2,\nu/2)}$ — нормировочная константа. Подынтегральная функция является произведением нечетной функции (x) и четной функции плотности, что в итоге дает нечетную функцию.

Однако, чтобы интеграл равнялся нулю, он должен сходиться абсолютно (в смысле Лебега), то есть должен сходиться интеграл от модуля: $\int_{-\infty}^{\infty} |x| f(x) dx < \infty$.

На бесконечности подынтегральное выражение ведет себя асимптотически как $x \cdot x^{-(\nu+1)} = x^{-\nu}$. Интеграл $\int^{\infty} x^{-\nu} dx$ сходится тогда и только тогда, когда $\nu > 1$. Следовательно:

$$\mathbb{E}[X] = 0 \quad \text{при } \nu > 1$$

(При $\nu = 1$, что соответствует распределению Коши, математическое ожидание не существует).

Вычисление дисперсии

Для симметричного распределения с нулевым средним дисперсия совпадает со вторым начальным моментом $\mathrm{Var}(X) = \mathbb{E}[X^2]$. Поскольку функция $x^2 f(x)$ четная, можно интегрировать по положительной полуоси и удвоить результат:

$$\mathbb{E}[X^2] = 2C_\nu \int_0^{\infty} x^2 \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}} dx$$

Сделаем предложенную замену переменной: $y = \frac{\nu}{x^2+\nu}$. Тогда:

$$x^2 = \nu\frac{1-y}{y}, \quad x = \sqrt{\nu}(1-y)^{1/2} y^{-1/2},$$

$$dx = -\frac{\sqrt{\nu}}{2}(1-y)^{-1/2} y^{-3/2}\, dy$$

При $x = 0 \Rightarrow y = 1$, а при $x \to \infty \Rightarrow y = 0$. Подставляя в инте-

грал (минус уходит на переворот пределов от 0 до 1), получаем:

$$\mathbb{E}[X^2] = 2C_\nu \int_0^1 \left(\nu\frac{1-y}{y}\right) y^{\frac{\nu+1}{2}} \frac{\sqrt{\nu}}{2}(1-y)^{-1/2} y^{-3/2}\, dy$$
$$= C_\nu \nu^{3/2} \int_0^1 (1-y)^{\frac{1}{2}} y^{\frac{\nu-2}{2}-1}\, dy$$

Полученный интеграл есть не что иное, как бета-функция $\mathrm{B}\left(\frac{\nu-2}{2}, \frac{3}{2}\right)$. Подставим C_ν и выразим бета-функции через гамма-функции:

$$\mathbb{E}[X^2] = \frac{\nu^{3/2}}{\sqrt{\nu}\mathrm{B}(1/2,\nu/2)}\mathrm{B}\left(\frac{\nu-2}{2}, \frac{3}{2}\right)$$
$$= \nu\frac{\Gamma\left(\frac{\nu-2}{2}\right)\Gamma(3/2)/\Gamma\left(\frac{\nu+1}{2}\right)}{\Gamma(\nu/2)\Gamma(1/2)/\Gamma\left(\frac{\nu+1}{2}\right)}$$
$$= \nu\frac{\Gamma\left(\frac{\nu-2}{2}\right)\Gamma(3/2)}{\Gamma(\nu/2)\Gamma(1/2)}$$

Воспользуемся рекуррентным свойством гамма-функции $\Gamma(s+1) = s\Gamma(s)$. Имеем $\Gamma(3/2) = \frac{1}{2}\Gamma(1/2)$ и $\Gamma(\nu/2) = \frac{\nu-2}{2}\Gamma\left(\frac{\nu-2}{2}\right)$:

$$\mathrm{Var}(X) = \nu\frac{\frac{1}{2}}{\frac{\nu-2}{2}} = \frac{\nu}{\nu-2} \quad \text{при } \nu > 2$$

Вычисление асимметрии и эксцесса

Коэффициент асимметрии γ_1 определяется через третий центральный момент $\mathbb{E}[X^3]$. Аналогично математическому ожиданию, интеграл от нечетной функции $x^3 f(x)$ равен нулю при условии его сходимости ($\nu > 3$). Значит, **асимметрия тождественно равна 0**.

Коэффициент эксцесса γ_2 определяется через четвертый момент $\mathbb{E}[X^4]$. Используя ту же самую замену переменной y, интеграл для четвертого момента сводится к новой бета-функции:

$$\mathbb{E}[X^4] = 2C_\nu \int_0^\infty x^4 \left(1+\frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}} dx = C_\nu \nu^{5/2}\mathrm{B}\left(\frac{\nu-4}{2}, \frac{5}{2}\right)$$

Раскрывая отношение бета-функций через гамма-функции ($\Gamma(5/2) = \frac{3}{4}\Gamma(1/2)$ и дважды применяя рекуррентное свойство к $\Gamma(\nu/2)$), получаем:

$$\mathbb{E}[X^4] = \nu^2\frac{3/4}{\frac{(\nu-2)(\nu-4)}{4}} = \frac{3\nu^2}{(\nu-2)(\nu-4)} \quad \text{при } \nu > 4$$

Окончательная формула коэффициента эксцесса требует вычитания тройки из отношения четвертого момента к квадрату диспер-

сии:

$$\begin{aligned}\text{Excess} &= \frac{\mathbb{E}[X^4]}{(\mathbb{E}[X^2])^2} - 3 \\ &= \frac{\frac{3\nu^2}{(\nu-2)(\nu-4)}}{\left(\frac{\nu}{\nu-2}\right)^2} - 3 \\ &= \frac{3(\nu-2)}{\nu-4} - 3 \\ &= \frac{3\nu - 6 - 3\nu + 12}{\nu-4} = \frac{6}{\nu-4} \quad \text{при } \nu > 4\end{aligned}$$

Свойства и связи с другими распределениями

Приведем некоторые свойства и связи.

Свойства:

1. **Отсутствие аддитивности.**
   В отличие от нормального распределения, сумма двух независимых случайных величин, имеющих распределение Стьюдента, **не имеет** распределение Стьюдента.

Связи с другими распределениями:

1. Распределение Стьюдента — это распределение отношения стандартной нормальной случайной величины к корню из нормализованной величины хи-квадрат.

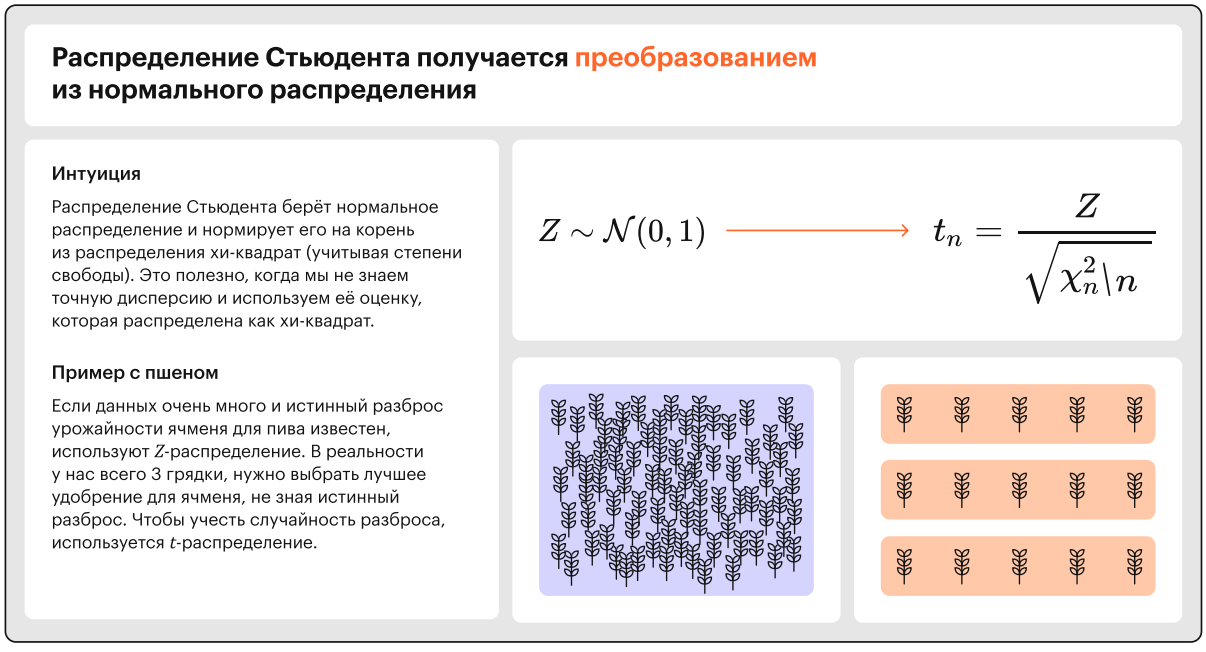

Рисунок 285. Связь нормального распределения и распределения Стьюдента

2. При $\nu \to \infty$ распределение Стьюдента асимптотически стремится к **стандартному нормальному распределению**

$\mathcal{N}(0,1)$. На практике при $\nu > 30$ разница между ними становится пренебрежимо малой.

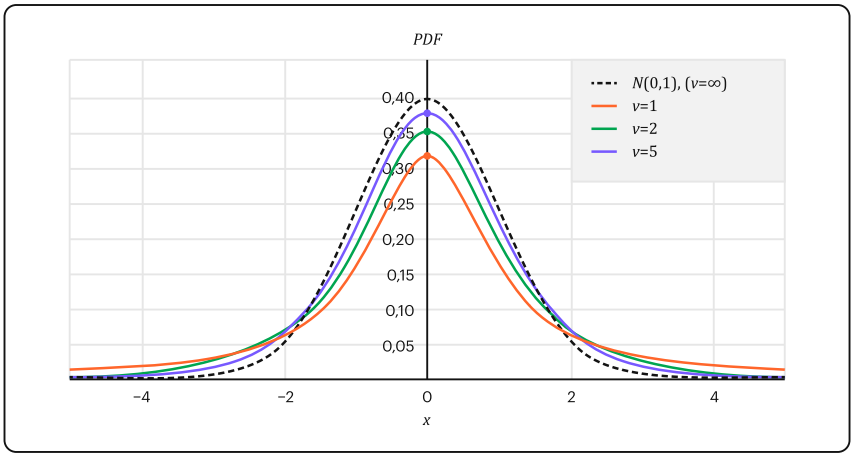

Рисунок 286. Связь нормального распределения и распределения Стьюдента

Оценка параметров

В большинстве практических задач (например, при проверке гипотез) число степеней свободы ν известно заранее и равно размеру выборки минус один ($n - 1$). Однако, если ν является неизвестным параметром, который нужно оценить по данным, применяются следующие методы.

Метод моментов.

Так как математическое ожидание равно нулю и не зависит от ν, для оценки нужно использовать дисперсию (требуя $\nu > 2$):

$$\mathrm{Var}(X) = \frac{\nu}{\nu - 2}$$

Приравняв выборочную дисперсию s^2 к теоретической, получаем оценку:

$$\frac{\hat{\nu}}{\hat{\nu} - 2} = s^2 \quad \Rightarrow \quad \hat{\nu} = \frac{2s^2}{s^2 - 1}$$

Эта оценка применима только если выборочная дисперсия $s^2 > 1$.

Метод максимального правдоподобия (MLE).

Логарифмическая функция правдоподобия для оценки ν не имеет аналитического максимума.

Функция содержит гамма-функции и логарифмы, поэтому $\hat{\nu}_{MLE}$ ищется исключительно численными методами оптимизации (например, методом Ньютона-Рафсона или EM-алгоритмом, если рассматривать t-распределение как смесь нормальных распре-

делений с дисперсией, зависящей от χ^2).

Основная табличка

Параметры	$\nu > 0$ (степени свободы)
Носитель	$x \in (-\infty, +\infty)$
Плотность (PDF)	$f(x) = \dfrac{\Gamma\left(\dfrac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\,\Gamma\left(\dfrac{\nu}{2}\right)} \left(1 + \dfrac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}}$
Функция распределения (CDF)	$\dfrac{1}{2} + x\Gamma\left(\dfrac{\nu+1}{2}\right) \dfrac{{}_2F_1\left(\dfrac{1}{2}, \dfrac{\nu+1}{2}; \dfrac{3}{2}; -\dfrac{x^2}{\nu}\right)}{\sqrt{\nu\pi}\,\Gamma\left(\dfrac{\nu}{2}\right)}$ (где ${}_2F_1$ — гипергеометрическая функция)
Мат. ожидание	0 (при $\nu > 1$, иначе не определено)
Медиана	0
Мода	0
Дисперсия	$\dfrac{\nu}{\nu-2}$ (при $\nu > 2$, ∞ при $1 < \nu \leqslant 2$)
Асимметрия	0 (при $\nu > 3$, иначе не определена)
Эксцесс	$\dfrac{6}{\nu-4}$ (при $\nu > 4$, ∞ при $2 < \nu \leqslant 4$)
Производящая функция моментов	**Не существует**
Харак-ая функция	$\dfrac{1}{\Gamma(\nu/2)} \left(\dfrac{\nu t^2}{4}\right)^{\nu/4} K_{\nu/2}(\sqrt{\nu}\lvert t\rvert)$ (где K — модифицированная функция Бесселя)
Информация Фишера	$I(\nu) = \dfrac{1}{4}\psi^{(1)}\left(\dfrac{\nu}{2}\right) - \dfrac{1}{4}\psi^{(1)}\left(\dfrac{\nu+1}{2}\right) - \dfrac{\nu+3}{2\nu(\nu+2)(\nu+1)}$
Метод моментов	$\hat{\nu} = \dfrac{2s^2}{s^2-1}$ при $s^2 > 1$
Метод максимального правдоподобия (MLE)	Ищется только численными методами

12. РАСПРЕДЕЛЕНИЕ ФИШЕРА (F-РАСПРЕДЕЛЕНИЕ)

Общее

Распределение Фишера (или F-распределение, распределение Фишера-Снедекора, обозначается $F(d_1, d_2)$) — это семейство непрерывных распределений, определенных на полубесконечном интервале $[0, +\infty)$.

Оно задается двумя параметрами $d_1 > 0$ и $d_2 > 0$, которые называются числом степеней свободы числителя и знаменателя соответственно.

Распределение Фишера является краеугольным камнем дисперсионного анализа (ANOVA) и регрессионного анализа. Оно применяется для проверки статистических гипотез о равенстве дисперсий двух нормальных генеральных совокупностей (F-тест) и оценки значимости регрессионных моделей.

ОПРЕДЕЛЕНИЕ 15.12.1

Распределение Фишера строится как отношение двух независимых случайных величин, имеющих распределение хи-квадрат, каждая из которых предварительно поделена на свое число степеней свободы.

Пусть $\chi^2_{d_1}$ и $\chi^2_{d_2}$ — независимые случайные величины с распределением хи-квадрат со степенями свободы d_1 и d_2. Тогда случайная величина:

$$F = \frac{\chi^2_{d_1}/d_1}{\chi^2_{d_2}/d_2}$$

имеет распределение Фишера с d_1 и d_2 степенями свободы ($F \sim F(d_1, d_2)$).

Математически это распределение описывается функцией плотности вероятности следующего вида:

$$f(x) = \frac{1}{\mathrm{B}\left(\frac{d_1}{2}, \frac{d_2}{2}\right)} \left(\frac{d_1}{d_2}\right)^{\frac{d_1}{2}} x^{\frac{d_1}{2}-1} \left(1 + \frac{d_1}{d_2}x\right)^{-\frac{d_1+d_2}{2}}$$

В свою очередь функция распределения (CDF) выражается через регуляризованную неполную бета-функцию I:

$$F(x) = I_{\frac{d_1 x}{d_1 x + d_2}}\left(\frac{d_1}{2}, \frac{d_2}{2}\right)$$

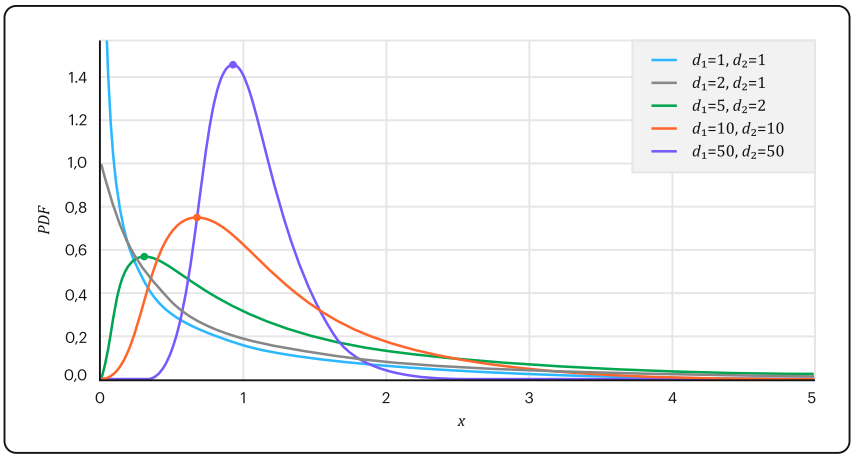

Рисунок 287. Плотность вероятности распределения Фишера

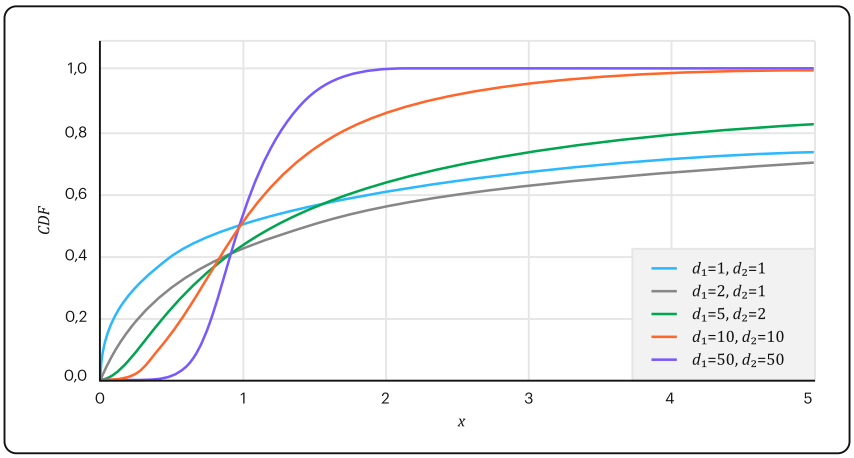

Рисунок 288. Функция распределения Фишера

Форма распределения Фишера сильно зависит от степеней свободы. В общем случае оно всегда имеет асимметричную колоколообразную форму с длинным правым хвостом (положительная асимметрия).

График начинается с нуля (если $d_1 > 2$), быстро достигает максимума (моды) в точке, чуть меньшей единицы, и затем медленно убывает к нулю на бесконечности.

Параметр d_1 сильнее влияет на левую часть графика (около нуля), а параметр d_2 — на тяжесть правого хвоста. При малых значениях d_2 правый хвост настолько тяжелый, что у распределения могут не существовать дисперсия и даже математическое ожидание.

По мере увеличения обоих параметров ($d_1, d_2 \to \infty$) распределение все больше концентрируется вокруг единицы, а его форма асимптотически приближается к нормальному распределению.

Характеристическая функция и производящая функция моментов

Производящая функция моментов (Отсутствие MGF)

Производящая функция моментов (MGF) определяется как математическое ожидание действительной экспоненты:

$$M_X(t) = \mathbb{E}[e^{tX}] = \int_0^\infty e^{tx} f(x)\,dx$$

Рассмотрим асимптотическое поведение плотности распределения Фишера при $x \to \infty$. Множитель $\left(1 + \frac{d_1}{d_2}x\right)^{-\frac{d_1+d_2}{2}}$ на бесконечности ведет себя как $x^{-\frac{d_1+d_2}{2}}$.

Умножая его на $x^{\frac{d_1}{2}-1}$, получаем, что общая скорость убывания плотности составляет $x^{-\frac{d_2}{2}-1}$.

Это убывание является степенным (полиномиальным), а не экспоненциальным. Если $t > 0$, растущая экспонента e^{tx} неизбежно превзойдет любое степенное убывание, что приведет к расходимости интеграла на бесконечности.

Таким образом, **производящая функция моментов распределения Фишера не существует**.

Моменты и характеристики

Вычислим математическое ожидание и дисперсию прямым интегрированием, применяя метод замены переменной для сведения к бета-функции.

В общем виде k-й начальный момент задается интегралом:

$$\mathbb{E}[X^k] = \frac{1}{\mathrm{B}\left(\frac{d_1}{2}, \frac{d_2}{2}\right)} \left(\frac{d_1}{d_2}\right)^{\frac{d_1}{2}} \int_0^\infty x^{k+\frac{d_1}{2}-1} \left(1 + \frac{d_1}{d_2}x\right)^{-\frac{d_1+d_2}{2}} dx$$

Сделаем замену переменной: $y = \dfrac{\frac{d_1}{d_2}x}{1 + \frac{d_1}{d_2}x}$. Отсюда выражаются:

$$x = \frac{d_2}{d_1}\frac{y}{1-y}, \quad 1 + \frac{d_1}{d_2}x = \frac{1}{1-y}, \quad dx = \frac{d_2}{d_1}\frac{1}{(1-y)^2}\,dy$$

Пределы интегрирования от $x \in [0, \infty)$ переходят в $y \in [0, 1]$.

Подставим всё в интеграл:

$$\mathbb{E}[X^k] = \frac{\left(\frac{d_1}{d_2}\right)^{\frac{d_1}{2}}}{\mathrm{B}\left(\frac{d_1}{2}, \frac{d_2}{2}\right)} \int_0^1 \left(\frac{d_2}{d_1}\frac{y}{1-y}\right)^{k+\frac{d_1}{2}-1} (1-y)^{\frac{d_1+d_2}{2}} \frac{d_2}{d_1}\frac{1}{(1-y)^2}\, dy$$
$$= \left(\frac{d_2}{d_1}\right)^k \frac{1}{\mathrm{B}\left(\frac{d_1}{2}, \frac{d_2}{2}\right)} \int_0^1 y^{\left(\frac{d_1}{2}+k\right)-1} (1-y)^{\left(\frac{d_2}{2}-k\right)-1}\, dy$$

Оставшийся интеграл — это бета-функция $\mathrm{B}\left(\frac{d_1}{2}+k, \frac{d_2}{2}-k\right)$.
Формула k-го момента принимает элегантный вид:

$$\mathbb{E}[X^k] = \left(\frac{d_2}{d_1}\right)^k \frac{\mathrm{B}\left(\frac{d_1}{2}+k, \frac{d_2}{2}-k\right)}{\mathrm{B}\left(\frac{d_1}{2}, \frac{d_2}{2}\right)} = \left(\frac{d_2}{d_1}\right)^k \frac{\Gamma\left(\frac{d_1}{2}+k\right)\Gamma\left(\frac{d_2}{2}-k\right)}{\Gamma\left(\frac{d_1}{2}\right)\Gamma\left(\frac{d_2}{2}\right)}$$

Примечание: Интеграл сходится (и k-й момент существует) только при $d_2 > 2k$.

Вычисление математического ожидания

Для $k = 1$ (при условии $d_2 > 2$) используем рекуррентное свойство гамма-функции $\Gamma(z+1) = z\Gamma(z)$:

$$\mathbb{E}[X] = \frac{d_2}{d_1}\frac{\Gamma\left(\frac{d_1}{2}+1\right)\Gamma\left(\frac{d_2}{2}-1\right)}{\Gamma\left(\frac{d_1}{2}\right)\Gamma\left(\frac{d_2}{2}\right)} = \frac{d_2}{d_1}\frac{\frac{d_1}{2}}{\frac{d_2}{2}-1} = \frac{d_2}{d_2-2}$$

Вычисление дисперсии

Сначала найдем второй начальный момент (при $k = 2, d_2 > 4$):

$$\mathbb{E}[X^2] = \left(\frac{d_2}{d_1}\right)^2 \frac{\frac{d_1}{2}\left(\frac{d_1}{2}+1\right)}{\left(\frac{d_2}{2}-1\right)\left(\frac{d_2}{2}-2\right)} = \frac{d_2^2(d_1+2)}{d_1(d_2-2)(d_2-4)}$$

Теперь подставим это в формулу дисперсии $\mathrm{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$:

$$\mathrm{Var}(X) = \frac{d_2^2(d_1+2)}{d_1(d_2-2)(d_2-4)} - \frac{d_2^2}{(d_2-2)^2}$$
$$= \frac{2d_2^2(d_1+d_2-2)}{d_1(d_2-2)^2(d_2-4)}$$

Вычисление асимметрии (скоса)

Асимметрия выражается через третий центральный момент, для которого нам потребуется третий начальный момент $\mathbb{E}[X^3]$

(существует при $d_2 > 6$):

$$\mathbb{E}[X^3] = \left(\frac{d_2}{d_1}\right)^3 \frac{\frac{d_1}{2}\left(\frac{d_1}{2}+1\right)\left(\frac{d_1}{2}+2\right)}{\left(\frac{d_2}{2}-1\right)\left(\frac{d_2}{2}-2\right)\left(\frac{d_2}{2}-3\right)} = \frac{d_2^3(d_1+2)(d_1+4)}{d_1^2(d_2-2)(d_2-4)(d_2-6)}$$

Коэффициент асимметрии вычисляется по формуле $\gamma_1 = \frac{\mathbb{E}[X^3]-3\mathbb{E}[X]\operatorname{Var}(X)-(\mathbb{E}[X])^3}{\operatorname{Var}(X)^{3/2}}$. Подставляя найденные моменты и приводя подобные слагаемые, получаем:

$$\gamma_1 = \frac{(2d_1+d_2-2)\sqrt{8(d_2-4)}}{(d_2-6)\sqrt{d_1(d_1+d_2-2)}} \quad \text{при } d_2 > 6$$

Поскольку числитель всегда положителен (для допустимых d_1 и d_2), распределение Фишера всегда имеет правую асимметрию.

Вычисление эксцесса

Эксцесс требует вычисления четвертого начального момента $\mathbb{E}[X^4]$ (существует при $d_2 > 8$):

$$\mathbb{E}[X^4] = \left(\frac{d_2}{d_1}\right)^4 \frac{\frac{d_1}{2}\left(\frac{d_1}{2}+1\right)\left(\frac{d_1}{2}+2\right)\left(\frac{d_1}{2}+3\right)}{\left(\frac{d_2}{2}-1\right)\left(\frac{d_2}{2}-2\right)\left(\frac{d_2}{2}-3\right)\left(\frac{d_2}{2}-4\right)} = \frac{d_2^4(d_1+2)(d_1+4)(d_1+6)}{d_1^3(d_2-2)(d_2-4)(d_2-6)(d_2-8)}$$

Коэффициент эксцесса определяется как $\gamma_2 = \frac{\mu_4}{\operatorname{Var}(X)^2} - 3$, где μ_4 — четвертый центральный момент. После громоздких алгебраических преобразований по переходу от начальных моментов к центральным, итоговый результат принимает вид:

$$\gamma_2 = \frac{12\left[d_1(5d_2-22)(d_1+d_2-2)+(d_2-4)(d_2-2)^2\right]}{d_1(d_2-6)(d_2-8)(d_1+d_2-2)} \quad \text{при } d_2 > 8$$

Свойства и связи с другими распределениями

Приведем некоторые свойства и связи.

Свойства:

1. **Свойство инверсии.**
   Если случайная величина X имеет распределение Фишера $F(d_1, d_2)$, то обратная ей величина $1/X$ также имеет распределение Фишера, но степени свободы меняются местами:

   $$\frac{1}{X} \sim F(d_2, d_1)$$

   Это свойство широко используется в статистике: оно позволяет находить левые критические точки распределения (квантили), зная только правые.

2. **Свойство квантилей.**
   Как прямое математическое следствие свойства инверсии, квантили (критические значения) распределения Фишера связаны строгим соотношением.
   Квантиль уровня $1-\alpha$ (левый хвост) выражается через квантиль уровня α (правый хвост) перевернутого распределения:

$$F_{1-\alpha}(d_1, d_2) = \frac{1}{F_{\alpha}(d_2, d_1)}$$

   Исторически это свойство было исключительно важным, так как позволяло печатать статистические таблицы только для верхних (правых) квантилей (например, 95% и 99%), экономя половину объема.
3. **Тяжелый правый хвост и обрыв моментов.**
   Плотность распределения Фишера убывает на бесконечности по полиномиальному (степенному) закону, а не по экспоненциальному. Скорость убывания правого хвоста полностью контролируется знаменателем: $f(x) \sim x^{-(d_2/2+1)}$.
   Из-за этого распределение обладает фундаментальным ограничением — у него существуют только моменты порядка $k < d_2/2$. Все старшие моменты (при $k \geqslant d_2/2$) уходят в бесконечность.

Связи с другими распределениями:

1. Отношение двух независимых распределений χ^2, поделенных на их степени свободы, порождает распределение Фишера (F-распределение).

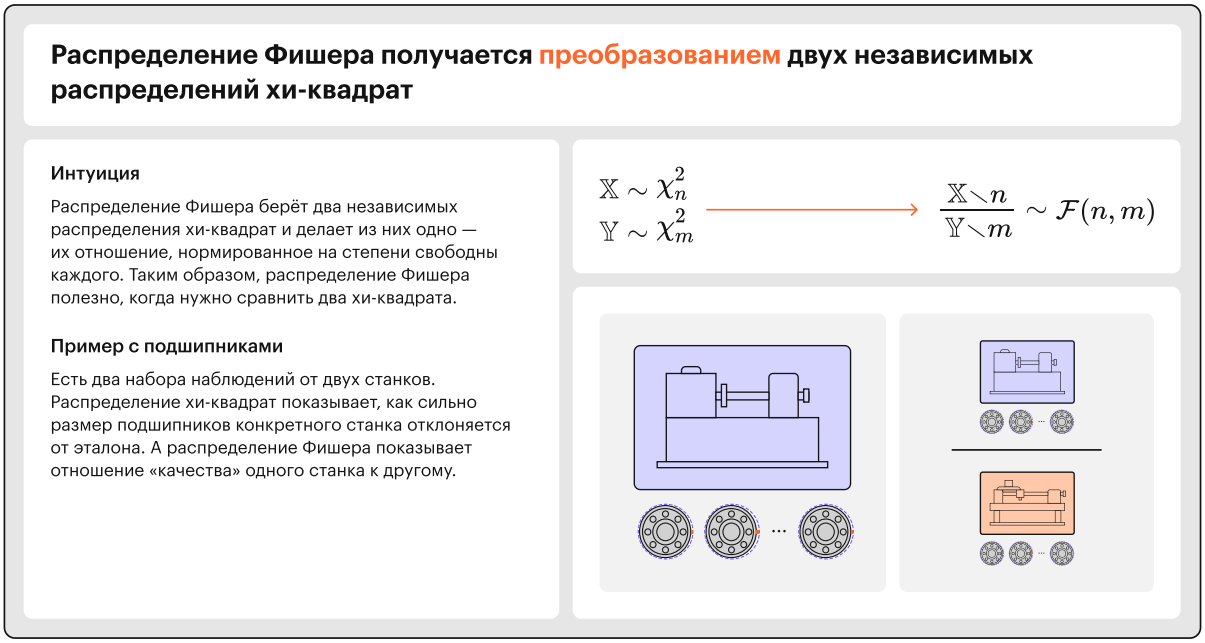

Рисунок 289. Связь хи-квадрат распределения и распределения Фишера

2. Квадрат случайной величины, распределенной по Стьюденту с ν степенями свободы, имеет распределение Фишера с параметрами 1 и ν: $t^2_{\nu} \sim F(1, \nu)$.

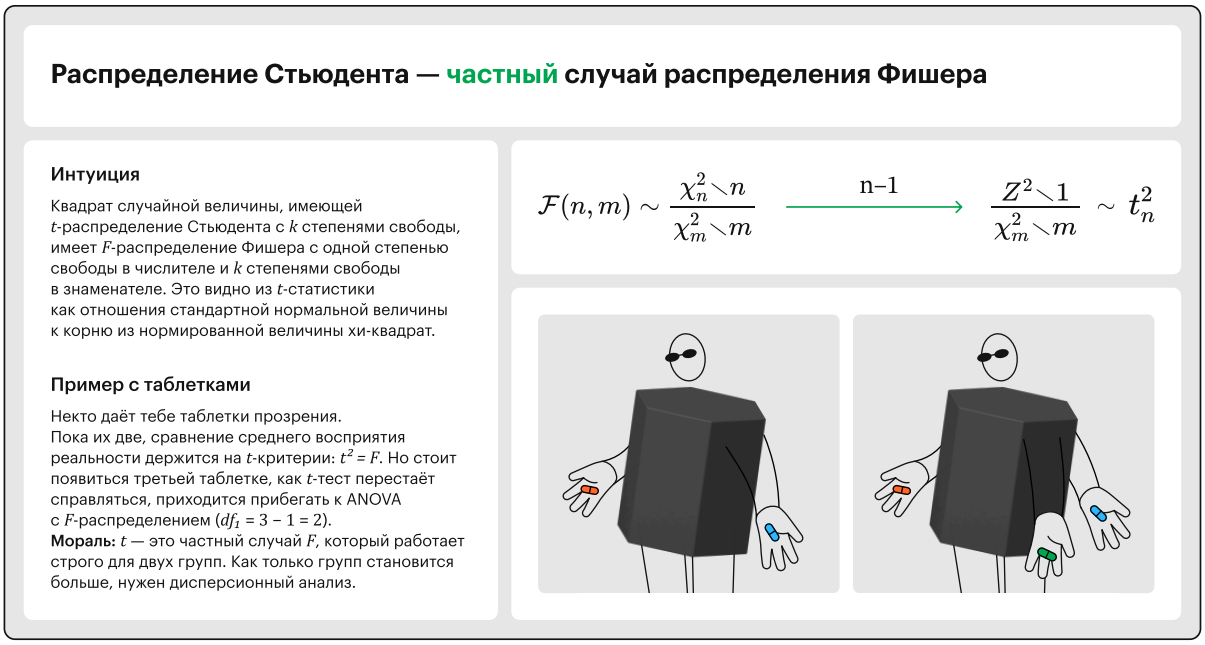

Рисунок 290. Связь распределение Фишера и хи-квадрат распределений

Оценка параметров

Оценка параметров d_1 и d_2 распределения Фишера по выборке встречается нечасто (так как обычно они известны из дизайна эксперимента), но технически возможна.

Метод моментов.

Используем теоретические формулы для математического ожидания (требует $d_2 > 2$) и дисперсии (требует $d_2 > 4$).

Сначала из уравнения для среднего выражаем d_2:

$$\mathbb{E}[X] = \frac{d_2}{d_2 - 2} = \bar{x} \quad \Rightarrow \quad d_2 = \frac{2\bar{x}}{\bar{x} - 1} \quad (\text{при } \bar{x} > 1)$$

Подставляем найденное значение d_2 в уравнение дисперсии $\mathrm{Var}(X) = s^2$, чтобы выразить d_1:

$$d_1 = \frac{2d_2^2(d_2 - 2)}{s^2(d_2 - 2)^2(d_2 - 4) - 2d_2^2}$$

Основная табличка

Параметры	$d_1 > 0$ (ст. свободы числителя), $d_2 > 0$ (ст. свободы знаменателя)
Носитель	$x \in [0, +\infty)$
Плотность (PDF)	$f(x) = \dfrac{1}{\mathrm{B}\left(\dfrac{d_1}{2}, \dfrac{d_2}{2}\right)} \left(\dfrac{d_1}{d_2}\right)^{\frac{d_1}{2}} x^{\frac{d_1}{2}-1} \left(1 + \dfrac{d_1}{d_2}x\right)^{-\frac{d_1+d_2}{2}}$
Функция распределения (CDF)	$I_{\dfrac{d_1 x}{d_1 x + d_2}}\left(\dfrac{d_1}{2}, \dfrac{d_2}{2}\right)$ (регуляризованная неполная бета-функция)
Мат. ожидание	$\dfrac{d_2}{d_2 - 2}$ для $d_2 > 2$
Медиана	Аналитически выражается только через обратную функцию $I^{[-1]}$
Мода	$\dfrac{d_1 - 2}{d_1} \cdot \dfrac{d_2}{d_2 + 2}$ для $d_1 > 2$
Дисперсия	$\dfrac{2d_2^2(d_1 + d_2 - 2)}{d_1(d_2 - 2)^2(d_2 - 4)}$ для $d_2 > 4$
Асимметрия	$\dfrac{(2d_1 + d_2 - 2)\sqrt{8(d_2 - 4)}}{(d_2 - 6)\sqrt{d_1(d_1 + d_2 - 2)}}$ для $d_2 > 6$
Эксцесс	$\dfrac{12\left(d_1(5d_2 - 22)(d_1 + d_2 - 2) + (d_2 - 4)(d_2 - 2)^2\right)}{d_1(d_2 - 6)(d_2 - 8)(d_1 + d_2 - 2)}$ для $d_2 > 8$
Производящая функция моментов	**Не существует**
Харак-ая функция	$\dfrac{\Gamma\left(\dfrac{d_1 + d_2}{2}\right)}{\Gamma\left(\dfrac{d_2}{2}\right)} U\left(\dfrac{d_1}{2}, 1 - \dfrac{d_2}{2}, -\dfrac{d_2}{d_1} it\right)$
Информация Фишера	Матрица 2×2, элементы которой выражаются через тригамма-функции $\psi^{(1)}(\cdot)$
Метод моментов	$d_2 = \dfrac{2\bar{x}}{\bar{x} - 1}, \quad d_1 = \dfrac{2d_2^2(d_2 - 2)}{s^2(d_2 - 2)^2(d_2 - 4) - 2d_2^2}$
Метод максимального правдоподобия (MLE)	Ищется только численными методами

13. РАСПРЕДЕЛЕНИЕ ЛАПЛАСА

Общее

Распределение Лапласа (или двойное экспоненциальное распределение, обозначается $\mathrm{Laplace}(\mu, b)$) — это непрерывное вероятностное распределение, определенное на всей числовой прямой $\mathbb{R}$.

Оно задается двумя параметрами: параметром сдвига $\mu \in \mathbb{R}$ и параметром масштаба $b > 0$.

Распределение Лапласа похоже на нормальное распределение, но вместо гладкой функции квадрата в показателе экспоненты, стоит резкий модуль. Часто применяется в машинном обучении (например, в качестве априорного распределения для L1-регуляризации), анализе речи и финансовой математике для моделирования процессов с «тяжелыми хвостами» и резкими скачками, где нормальное распределение недооценивает вероятность экстремальных событий.

ОПРЕДЕЛЕНИЕ 15.13.1

Распределение Лапласа

Случайная величина $\mathbb{X}$ имеет *распределение Лапласа*, если ее функция плотности вероятности (PDF) имеет вид:

$$f(x) = \frac{1}{2b} e^{\left(-\frac{|x-\mu|}{b}\right)}$$

Функция распределения (CDF) находится интегрированием плотности и имеет кусочно-заданный вид из-за модуля:

$$F(x) = \begin{cases} \frac{1}{2} e^{\left(\frac{x-\mu}{b}\right)}, & \text{если } x < \mu \\ 1 - \frac{1}{2} e^{\left(-\frac{x-\mu}{b}\right)}, & \text{если } x \geqslant \mu \end{cases}$$

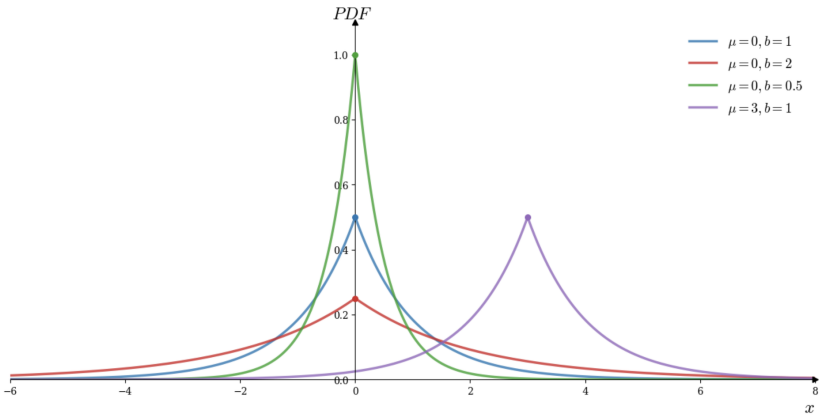

Рисунок 291. Плотность вероятности распределения Лапласа

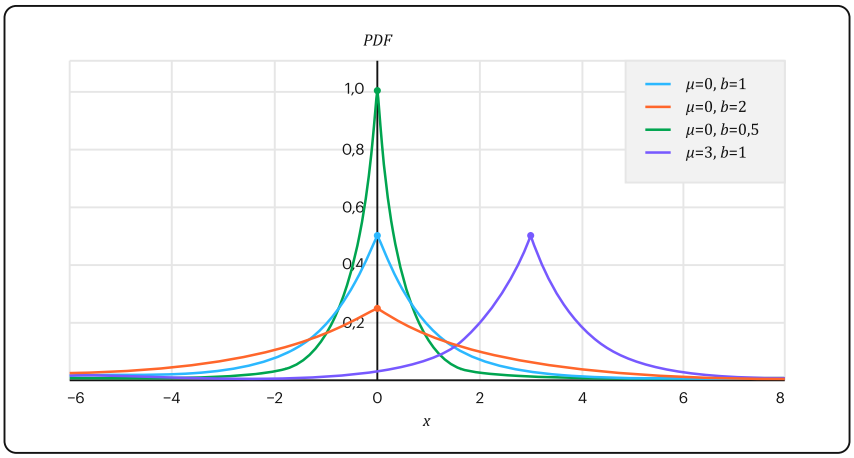

Рисунок 292. Плотность вероятности распределения Лапласа

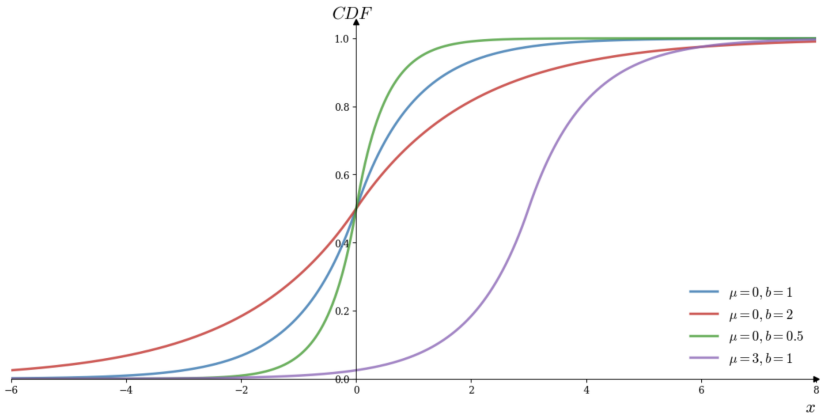

Рисунок 293. Функция распределения Лапласа

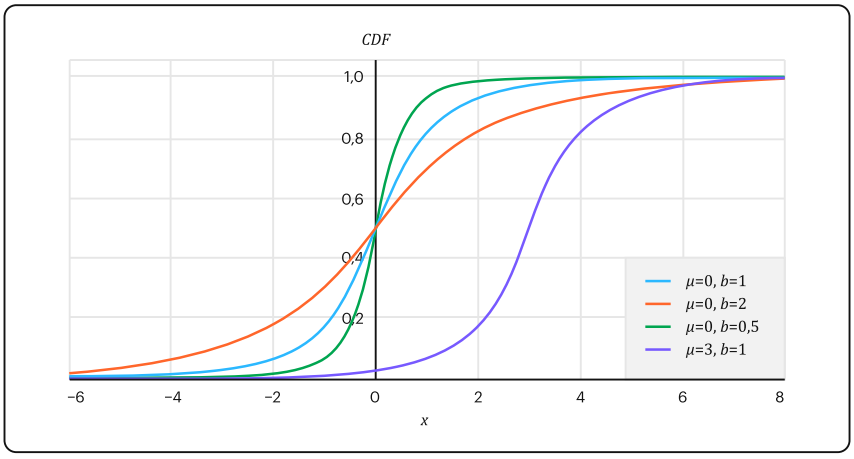

Рисунок 294. Функция распределения Лапласа

Параметр μ отвечает за сдвиг распределения вдоль оси абсцисс и является одновременно его математическим ожиданием, медианой и модой. В этой точке функция плотности имеет характерный острый пик (она непрерывна, но не дифференцируема).

Параметр b управляет масштабом (размахом) распределения.

При уменьшении b распределение стягивается к центру μ, а пик становится еще более острым. При увеличении b колокол сглаживается, а вероятностная масса растекается по «хвостам».

В отличие от нормального распределения (которое спадает как e^{-x^2}), хвосты распределения Лапласа спадают медленнее (как $e^{-|x|}$), что делает выбросы гораздо более вероятными.

Характеристическая функция и производящая функция моментов

Характеристическая функция

По определению, характеристическая функция есть математическое ожидание комплексной экспоненты e^{itX}:

$$\varphi_X(t) = \mathbb{E}[e^{itX}] = \int_{-\infty}^{\infty} e^{itx} \frac{1}{2b} e^{\left(-\frac{|x-\mu|}{b}\right)}\, dx$$

Сделаем линейную замену переменной $y = x - \mu$, откуда $x = y + \mu$ и $dx = dy$:

$$\varphi_X(t) = \int_{-\infty}^{\infty} e^{it(y+\mu)} \frac{1}{2b} e^{-\frac{|y|}{b}}\, dy = \frac{e^{it\mu}}{2b} \int_{-\infty}^{\infty} e^{ity} e^{-\frac{|y|}{b}}\, dy$$

Разобьем интеграл на две части, чтобы раскрыть модуль: от $-\infty$ до 0 (где $|y| = -y$) и от 0 до $+\infty$ (где $|y| = y$):

$$\varphi_X(t) = \frac{e^{it\mu}}{2b} \left(\int_{-\infty}^{0} e^{y(it+1/b)}\, dy + \int_{0}^{\infty} e^{y(it-1/b)}\, dy \right)$$

Вычислим каждый интеграл по отдельности. Оба интеграла сходятся, так как вещественная часть показателя экспоненты обеспечивает затухание на бесконечности:

$$\int_{-\infty}^{0} e^{y(it+1/b)}\, dy = \left. \frac{e^{y(it+1/b)}}{it + 1/b} \right|_{-\infty}^{0} = \frac{1}{1/b + it} - 0$$

$$\int_{0}^{\infty} e^{y(it-1/b)}\, dy = \left. \frac{e^{y(it-1/b)}}{it - 1/b} \right|_{0}^{\infty} = 0 - \frac{1}{it - 1/b} = \frac{1}{1/b - it}$$

Сложим полученные результаты:

$$\frac{1}{1/b + it} + \frac{1}{1/b - it} = \frac{(1/b - it) + (1/b + it)}{(1/b + it)(1/b - it)} = \\ = \frac{2/b}{1/b^2 - (it)^2} = \frac{2/b}{1/b^2 + t^2} = \frac{2b}{1 + b^2 t^2}$$

Подставим сумму обратно в выражение для характеристической

функции (множители $2b$ сокращаются):

$$\varphi_X(t) = e^{it\mu}\frac{1}{1+b^2t^2}$$

Производящая функция моментов

Производящая функция моментов (MGF) определяется как математическое ожидание действительной экспоненты:

$$M_X(t) = \mathbb{E}[e^{tX}]$$

Интеграл для $M_X(t)$ сходится не при любых t, а только когда функция распределения убывает быстрее экспоненты e^{tx}.
В нашем случае требуется выполнение условия $|t| < \frac{1}{b}$.

Внутри области сходимости мы можем получить MGF путем формальной замены аргумента t в характеристической функции на мнимую величину $-it$.

Применим эту подстановку $-it$ вместо t к результату, полученному для $\varphi_X(t)$:

$$M_X(t) = \varphi_X(-it) = e^{i(-it)\mu}\frac{1}{1+b^2(-it)^2} = \frac{e^{\mu t}}{1-b^2t^2}$$

Функция моментов распределения Лапласа имеет вид $\frac{e^{\mu t}}{1-b^2t^2}$ и определена на интервале $(-1/b, 1/b)$.

Моменты и характеристики

Вычислим математическое ожидание через определение.

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x\frac{1}{2b}\exp\left(-\frac{|x-\mu|}{b}\right)dx$$

Сделаем линейную замену $y = x - \mu$, чтобы выровнять центр распределения по нулю:

$$\mathbb{E}[X] = \int_{-\infty}^{\infty}(y+\mu)\frac{1}{2b}e^{-\frac{|y|}{b}}\,dy = \mu\int_{-\infty}^{\infty}\frac{1}{2b}e^{-\frac{|y|}{b}}\,dy + \\ + \int_{-\infty}^{\infty} y\frac{1}{2b}e^{-\frac{|y|}{b}}\,dy$$

Первый интеграл представляет собой интеграл от плотности вероятности распределения по всей прямой, следовательно, он в точности равен 1.

Второй интеграл — это интеграл от нечетной функции (y) умноженной на четную функцию ($e^{-|y|/b}$) в симметричных относитель-

но нуля пределах. Такой интеграл тождественно равен нулю:

$$\mathbb{E}[X] = \mu \cdot 1 + 0 = \mu$$

Найдем математическое ожидание и дисперсию через MGF.

n-й начальный момент случайной величины равен n-й производной от MGF, вычисленной в точке $t = 0$:

$$\mathbb{E}[X^n] = M_X^{(n)}(0) = \frac{d^n}{dt^n} M_X(t)\bigg|_{t=0}$$

Перепишем MGF в более удобном для дифференцирования виде:

$$M_X(t) = e^{\mu t}(1 - b^2 t^2)^{-1}$$

Вычисление математического ожидания

Для нахождения математического ожидания $\mathbb{E}[X]$ вычислим первую производную $M_X(t)$ по правилу произведения:

$$M_X'(t) = \mu e^{\mu t}(1 - b^2 t^2)^{-1} + e^{\mu t}(-1)(1 - b^2 t^2)^{-2}(-2b^2 t) = \\ = e^{\mu t}\left(\frac{\mu}{1 - b^2 t^2} + \frac{2b^2 t}{(1 - b^2 t^2)^2}\right)$$

Подставим $t = 0$:

$$\mathbb{E}[X] = M_X'(0) = e^0\left(\frac{\mu}{1 - 0} + \frac{0}{(1 - 0)^2}\right) = \mu$$

Вычисление дисперсии

Дисперсия выражается через первый и второй начальные моменты:

$$\mathrm{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

Сначала найдем второй начальный момент $\mathbb{E}[X^2]$, продифференцировав $M_X'(t)$ еще раз. Для упрощения вычислений в точке 0, найдем производную функции в скобках. Обозначим скобку как $A(t)$, тогда $M_X'(t) = e^{\mu t} A(t)$.

$$M_X''(t) = \mu e^{\mu t} A(t) + e^{\mu t} A'(t)$$

В точке $t = 0$, $A(0) = \mu$. Вычислим $A'(0)$:

$$A'(t) = \frac{d}{dt}\left(\frac{\mu}{1 - b^2 t^2} + \frac{2b^2 t}{(1 - b^2 t^2)^2}\right)$$

Первое слагаемое при дифференцировании даст множитель t, поэтому в нуле оно обратится в 0. Производная второго слагаемого по правилу частного в нуле даст:

$$\frac{2b^2(1-b^2t^2)^2 - 2b^2t \cdot 2(1-b^2t^2)(-2b^2t)}{(1-b^2t^2)^4}\Big|_{t=0} = \\ = \frac{2b^2 \cdot 1 - 0}{1} = 2b^2$$

Таким образом, $A'(0) = 2b^2$. Подставляем все в выражение для второй производной:

$$\mathbb{E}[X^2] = M_X''(0) = \mu \cdot 1 \cdot \mu + 1 \cdot 2b^2 = \mu^2 + 2b^2$$

Теперь подставим найденные моменты в формулу дисперсии:

$$\mathrm{Var}(X) = (\mu^2 + 2b^2) - \mu^2 = 2b^2$$

Свойства и связи с другими распределениями

Приведем некоторые свойства и связи.

Свойства:

1. **Линейное преобразование.**
   Семейство распределений Лапласа замкнуто относительно линейных преобразований. Если случайная величина $X \sim \mathrm{Laplace}(\mu, b)$, то для любых констант $c \neq 0$ и d новое распределение также останется лапласовским:

   $$Y = cX + d \sim \mathrm{Laplace}(c\mu + d, |c|b)$$

2. **Свойство симметрии.**
   Распределение строго симметрично относительно параметра сдвига μ. Это означает, что вероятность отклониться от центра на определенную величину влево в точности равна вероятности отклониться на ту же величину вправо. Математически это выражается через равенство распределений вероятностей:

   $$(X - \mu) \sim -(X - \mu)$$

   Следствием этой симметрии является то, что все нечетные центральные моменты (в том числе асимметрия) тождественно равны нулю.
3. **Максимизация энтропии.**
   Среди всех непрерывных распределений на интервале

$(-\infty, +\infty)$, имеющих фиксированное заданное *среднее абсолютное отклонение* (то есть фиксированное значение $\mathbb{E}[|X - \mu|] = b$), именно распределение Лапласа обладает максимальной дифференциальной энтропией.
Энтропия Шеннона для распределения Лапласа вычисляется по формуле:

$$H(X) = \log(2be)$$

Это свойство делает распределение Лапласа наименее информативным (самым естественным выбором) априорным распределением, когда нам известна только дисперсия по L1-метрике.

Связи с другими распределениями:

1. Распределение Лапласа как склейка двух экспоненциальных распределения.

Рисунок 295. Связь распределения Лапласа и экспоненциальных распределений

2. Распределение Лапласа можно получить как разность двух независимых экспоненциальных распределений с одинаковым параметром λ.

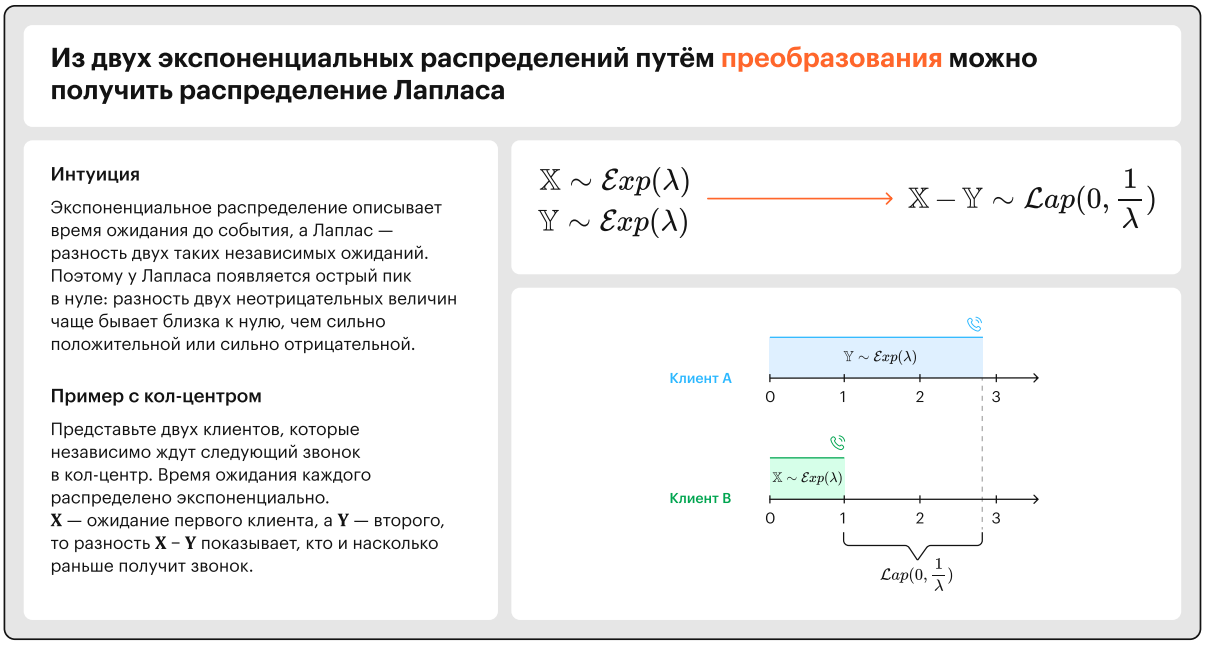

Рисунок 296. Связь распределения Лапласа и экспоненциальных распределений

Оценка параметров

Метод моментов.

Оценим значения параметров μ и b. Используя теоретические моменты:

$$\mathbb{E}[X] = \mu, \qquad \mathrm{Var}(X) = 2b^2$$

Приравняем истинные значения к выборочным оценкам: математическое ожидание к выборочному среднему $\bar{x}$, а дисперсию — к выборочной дисперсии s^2.

Для параметра μ оценка получается моментально:

$$\hat{\mu} = \bar{x}$$

Для параметра масштаба b выразим его из уравнения дисперсии:

$$2b^2 = s^2 \quad \Rightarrow \quad b^2 = \frac{s^2}{2} \quad \Rightarrow \quad \hat{b} = \frac{s}{\sqrt{2}}$$

Примечание: Метод максимального правдоподобия (MLE) для распределения Лапласа дает другие, более устойчивые к выбросам (робастные) оценки. В MLE оценкой параметра сдвига является *медиана* выборки ($\hat{\mu} = \mathrm{med}(x)$), а оценкой масштаба — среднее абсолютное отклонение от медианы ($\hat{b} = \frac{1}{N}\sum |x_i - \hat{\mu}|$).

Основная табличка

Параметры	$\mu \in \mathbb{R}$ (сдвиг), $\quad b > 0$ (масштаб)
Носитель	$x \in (-\infty, +\infty)$
Плотность (PDF)	$f(x) = \frac{1}{2b} \exp\left(-\frac{\lvert x-\mu\rvert}{b}\right)$
Функция распределения (CDF)	$\frac{1}{2} \exp\left(\frac{x-\mu}{b}\right)$ для $x \leqslant \mu$ $1 - \frac{1}{2} \exp\left(-\frac{x-\mu}{b}\right)$ для $x \geqslant \mu$
Мат. ожидание	μ
Медиана	μ
Мода	μ
Дисперсия	$2b^2$
Асимметрия	0
Эксцесс (коэффициент)	3 (распределение имеет более «тяжелые» хвосты, чем нормальное)
Производящая функция моментов	$\frac{e^{\mu t}}{1 - b^2 t^2}$ для $\lvert t\rvert < 1/b$
Харак-ая функция	$\frac{e^{i\mu t}}{1 + b^2 t^2}$
Информация Фишера	$\begin{pmatrix} 1/b^2 & 0 \\ 0 & 1/b^2 \end{pmatrix}$
Метод моментов	$\hat{\mu} = \bar{x}$ $\hat{b} = \frac{s}{\sqrt{2}}$
Метод максимального правдоподобия (MLE)	$\hat{\mu} = \operatorname{med}(x)$ (выборочная медиана) $\hat{b} = \frac{1}{n} \sum_{i=1}^{n} \lvert x_i - \hat{\mu}\rvert$

14. РАСПРЕДЕЛЕНИЕ КОШИ

Общее

Распределение Коши (также известное в физике как распределение Лоренца или Брейта-Вигнера, обозначается как Cauchy(x_0, γ)) — это двухпараметрическое семейство непрерывных распределений, определенных на всей числовой прямой $\mathbb{R}$.

Оно задается параметром сдвига x_0 (медианой) и параметром масштаба $\gamma > 0$, который определяет ширину «колокола».

Распределение Коши является классическим примером «патологического» распределения в статистике: из-за невероятно тяжелых хвостов у него **не существуют математическое ожидание и дисперсия**. В физике оно описывает профили спектральных линий, форму резонансных кривых и распределение энергии нестабильных частиц.

ОПРЕДЕЛЕНИЕ 15.14.1

Распределение Коши

Случайная величина X имеет *распределение Коши*, если ее функция плотности вероятности имеет вид:

$$f(x) = \frac{1}{\pi\gamma\left[1 + \left(\frac{x-x_0}{\gamma}\right)^2\right]}$$

Если $x_0 = 0$ и $\gamma = 1$, распределение называется *стандартным распределением Коши*.

В свою очередь функция распределения (CDF) выражается через арктангенс:

$$F(x) = \frac{1}{\pi}\arctan\left(\frac{x - x_0}{\gamma}\right) + \frac{1}{2}$$

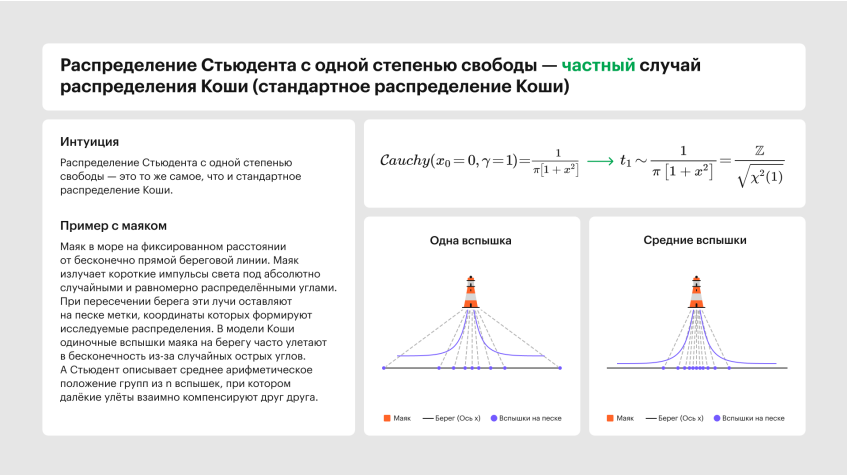

Рисунок 297. Плотность вероятности распределения Коши

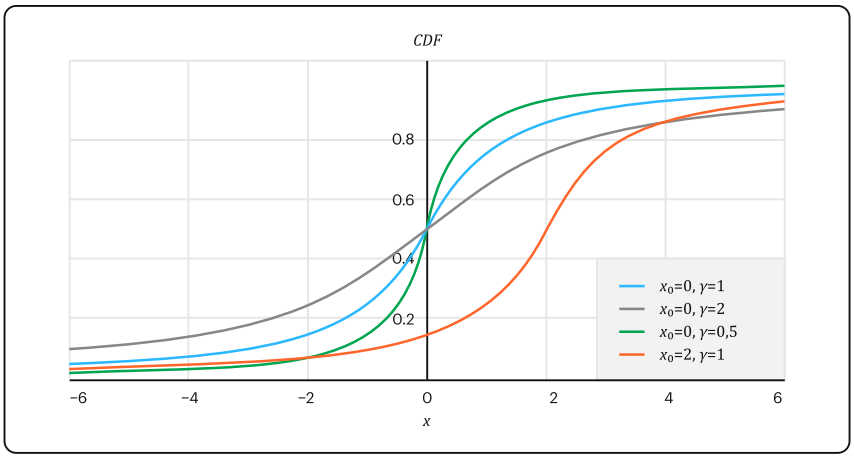

Рисунок 298. Функция распределения Коши

Визуально плотность стандартного распределения Коши напоминает стандартное нормальное распределение (колоколообразная кривая, симметричная относительно нуля). Однако пик распределения Коши острее, а его «хвосты» убывают гораздо медленнее (полиномиально, как $1/x^2$, а не экспоненциально, как $e^{-x^2/2}$).

Именно эти «толстые хвосты» приводят к тому, что экстремальные выбросы в распределении Коши — обычное явление. Если вы генерируете случайные числа из этого распределения, значения могут скачкообразно уходить на тысячи и миллионы единиц, и среднее арифметическое выборки никогда не стабилизируется около какого-либо значения.

Характеристическая функция и производящая функция моментов

Производящая функция моментов (Отсутствие MGF)

Производящая функция моментов (MGF) определяется как математическое ожидание действительной экспоненты:

$$M_X(t) = \mathbb{E}[e^{tX}] = \int_{-\infty}^{\infty} e^{tx} \frac{1}{\pi\gamma\left[1 + \left(\frac{x-x_0}{\gamma}\right)^2\right]} dx$$

На бесконечности плотность Коши убывает полиномиально (как $1/x^2$). При умножении плотности на экспоненту e^{tx} для любого $t \neq 0$, экспоненциальный рост всегда «побеждает» полиномиальное убывание.

В результате подынтегральное выражение на одной из бесконечностей устремляется в бесконечность, и интеграл расходится.

Следовательно, **производящая функция моментов для распределения Коши не существует** (не определена нигде, кроме тривиальной точки $t = 0$).

Характеристическая функция

Характеристическая функция (CF) определяется через комплексную экспоненту $\varphi_X(t) = \mathbb{E}[e^{itX}]$. Так как модуль комплексной экспоненты $|e^{itx}| = 1$, интеграл абсолютно сходится.

$$\varphi_X(t) = \frac{1}{\pi}\int_{-\infty}^{\infty} e^{itx}\frac{\gamma}{\gamma^2 + (x - x_0)^2}\,dx$$

Этот интеграл вычисляется методами теории функций комплексного переменного (например, с использованием леммы Жордана и теоремы о вычетах). Замыкая контур интегрирования в верхней полуплоскости (для $t > 0$) или в нижней (для $t < 0$), мы захватываем один простой полюс $z = x_0 \pm i\gamma$. Вычисляя вычет, приходим к конечному результату:

$$\varphi_X(t) = e^{ix_0 t - \gamma|t|}$$

Для стандартного распределения Коши ($x_0 = 0, \gamma = 1$) характеристическая функция принимает простой вид: $\varphi_X(t) = e^{-|t|}$.

Обратите внимание: функция $e^{-|t|}$ не дифференцируема в точке $t = 0$, что напрямую связано с отсутствием математического ожидания.

Моменты и характеристики

Поскольку распределение Коши обладает невероятно тяжелыми хвостами, мы должны строго проверить условия сходимости интегралов Лебега перед вычислением моментов.

Отсутствие математического ожидания

Для стандартного распределения Коши ($x_0 = 0, \gamma = 1$) математическое ожидание задается интегралом:

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x\frac{1}{\pi(1 + x^2)}\,dx$$

Подынтегральная функция является нечетной. Однако, чтобы интеграл по бесконечному промежутку равнялся нулю, он должен сходиться абсолютно, то есть $\int_{-\infty}^{\infty} |x| f(x)dx < \infty$.

Проверим интеграл от модуля (удвоенный интеграл по положительной полуоси):

$$\int_0^{\infty} \frac{x}{\pi(1 + x^2)}\,dx = \frac{1}{2\pi}\ln(1 + x^2)\Big|_0^{\infty} = \infty$$

Поскольку интеграл от модуля расходится логарифмически, сам интеграл Лебега расходится. **Математическое ожидание распределения Коши не существует**.

Если брать интеграл в смысле главного значения Коши: $\lim_{R\to\infty}\int_{-R}^{R} x f(x)dx$, то предел равен нулю в силу симметрии, но это не является математическим ожиданием.

Медиана и мода распределения Коши совпадают и равны параметру сдвига x_0.

Отсутствие дисперсии и высших моментов

Второй начальный момент (а значит и дисперсия) задается интегралом:

$$\mathbb{E}[X^2] = \int_{-\infty}^{\infty} x^2 \frac{1}{\pi(1+x^2)}\, dx$$

Подынтегральная функция на бесконечности ведет себя как $x^2/x^2 = 1$. Интеграл от константы на бесконечном интервале очевидно расходится к бесконечности. Следовательно, **дисперсия распределения Коши бесконечна (или не существует)**.

По этой же причине (убывание плотности пропорционально $1/x^2$) у распределения Коши **не существует ни один начальный или центральный момент** порядка $k \geqslant 1$. Асимметрия и эксцесс для этого распределения не определены.

Свойства и связи с другими распределениями

Приведем фундаментальные свойства распределения Коши.

Свойства:

1. **Замкнутость относительно сложения (Устойчивость).**
   В общем случае сумма независимых случайных величин $X_i \sim \text{Cauchy}(x_i, \gamma_i)$ также имеет распределение Коши:

$$\sum_{i=1}^{n} X_i \sim \text{Cauchy}\left(\sum_{i=1}^{n} x_i, \sum_{i=1}^{n} \gamma_i\right)$$

   Доказательство: Воспользуемся свойством характеристических функций: CF суммы независимых величин равна произведению их CF. Подставим $\varphi_{X_i}(t) = e^{ix_it - \gamma_i|t|}$:

$$\varphi_{\sum X_i}(t) = \prod_{i=1}^{n} \varphi_{X_i}(t) = \prod_{i=1}^{n} e^{ix_it - \gamma_i|t|} = e^{\sum(ix_it - \gamma_i|t|)} = \\ = e^{it(\sum x_i) - |t|(\sum \gamma_i)}$$

   Полученное выражение — это характеристическая функция распределения Коши с параметрами сдвига $\sum x_i$ и масштаба $\sum \gamma_i$.

2. **Опровержение Закона Больших Чисел.**
   Из свойства устойчивости напрямую вытекает поразительный факт. Если $X_1, \ldots, X_n \sim \text{Cauchy}(x_0, \gamma)$, то их выборочное среднее имеет **точно такое же распределение**, как и одно

единственное наблюдение:

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i \sim \text{Cauchy}(x_0, \gamma)$$

Доказательство: Пусть $S_n = \sum X_i$. По доказанному выше свойству аддитивности, $S_n \sim \text{Cauchy}(nx_0, n\gamma)$. Теперь найдем распределение величины $\overline{X} = \frac{1}{n}S_n$. По свойству линейного преобразования, умножение величины на константу c умножает оба параметра Коши на c:

$$\overline{X} \sim \text{Cauchy}\left(\frac{1}{n}(nx_0), \frac{1}{n}(n\gamma)\right) = \text{Cauchy}(x_0, \gamma)$$

Сколько бы данных вы ни собирали, среднее арифметическое не сходится к x_0. Центральная предельная теорема не работает, так как дисперсия теоретического распределения не существует.

3. **Свойство инвариантности.**
Если $\xi \sim \text{Cauchy}(0, 1)$, то обратная величина $\eta = 1/\xi$ также имеет стандартное распределение Коши: $\eta \sim \text{Cauchy}(0, 1)$.
Доказательство: Для $y \neq 0$ преобразование $\eta = 1/\xi$ имеет обратную функцию $x = 1/y$, причём якобиан преобразования равен:
$$\left|\frac{dx}{dy}\right| = \frac{1}{y^2}$$
По формуле преобразования плотности вероятности непрерывной случайной величины:
$$\rho_\eta(y) = \rho_\xi\left(\frac{1}{y}\right)\frac{1}{y^2} = \frac{1}{\pi\left(1 + \frac{1}{y^2}\right)}\frac{1}{y^2} = \frac{1}{\pi(y^2+1)}$$
Таким образом, плотность η в точности совпадает с плотностью исходной величины ξ.

Связи с другими распределениями:

1. Связь с распределением Стьюдента. Стандартное распределение Коши является частным случаем t-распределения Стьюдента с числом степеней свободы $\nu = 1$: $t_1 \equiv \text{Cauchy}(0, 1)$.

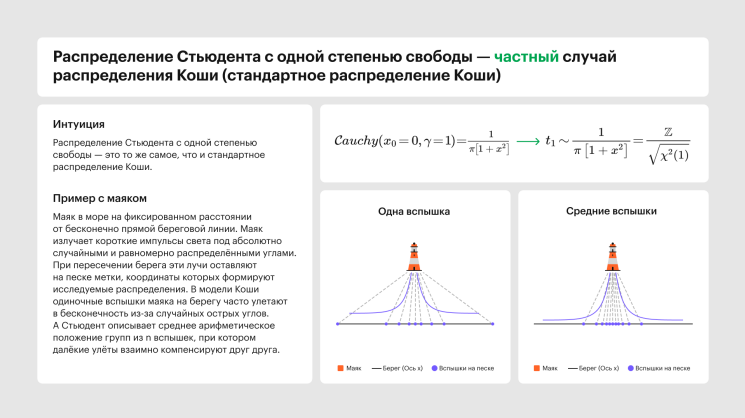

Рисунок 299. Связь распределения Стьюдента и распределения Коши

Оценка параметров

Поскольку моменты распределения не существуют (выборочное среднее и выборочная дисперсия неинформативны и бесполезны), метод моментов для оценки параметров распределения Коши применять нельзя.

Метод квантилей (Робастные оценки).

Лучшей простой оценкой параметра сдвига x_0 является выборочная медиана: $\hat{x}_0 = \text{Median}(X_1, \ldots, X_n)$.

Для параметра масштаба γ используют половину межквартильного размаха (IQR):

$$\hat{\gamma} = \frac{Q_3 - Q_1}{2}$$

где Q_1 и Q_3 — выборочные 25-й и 75-й перцентили. Эти оценки робастны и не подвержены влиянию экстремальных выбросов.

Метод максимального правдоподобия (MLE).

Логарифмическая функция правдоподобия имеет вид:

$$\ln L(x_0, \gamma) = -n \ln(\pi) - n \ln(\gamma) - \sum_{i=1}^{n} \ln \left[1 + \left(\frac{x_i - x_0}{\gamma} \right)^2 \right]$$

Производные $\ln L$ по параметрам приравниваются к нулю, формируя систему нелинейных уравнений. Решение ищется численно (например, алгоритмом Ньютона-Рафсона).

Важная особенность: из-за тяжелых хвостов поверхность функции правдоподобия часто имеет множество локальных максимумов, поэтому в качестве начального приближения для оптимизатора всегда следует передавать робастные медианные оценки.

Основная табличка

Параметры	$x_0 \in \mathbb{R}$ (сдвиг/медиана), $\gamma > 0$ (масштаб)
Носитель	$x \in (-\infty, +\infty)$
Плотность (PDF)	$f(x) = \dfrac{1}{\pi\gamma\left[1 + \left(\dfrac{x - x_0}{\gamma}\right)^2\right]}$
Функция распределения (CDF)	$F(x) = \dfrac{1}{\pi}\arctan\left(\dfrac{x - x_0}{\gamma}\right) + \dfrac{1}{2}$
Мат. ожидание	**Не существует**
Медиана	x_0
Мода	x_0
Дисперсия	**Не существует** (бесконечна)
Асимметрия	**Не определена**
Эксцесс	**Не определен**
Производящая функция моментов	**Не существует**
Харак-ая функция	$\varphi_X(t) = e^{ix_0t - \gamma\lvert t\rvert}$
Информация Фишера	$\begin{pmatrix} \dfrac{1}{2\gamma^2} & 0 \\ 0 & \dfrac{1}{2\gamma^2} \end{pmatrix}$
Робастные оценки	$\hat{x}_0 = \text{Median}(X), \quad \hat{\gamma} = \dfrac{Q_3 - Q_1}{2}$
Метод максимального правдоподобия (MLE)	Ищется только численными методами

15. ТРЕУГОЛЬНОЕ РАСПРЕДЕЛЕНИЕ

Общее

Треугольное распределение (Triangular(a, c, b)) — это непрерывное распределение вероятностей, заданное на конечном отрезке $[a, b]$, плотность которого имеет форму треугольника.

Оно задается тремя параметрами: минимальным значением a, максимальным значением b и модой (вершиной треугольника) c,

причем выполняется условие $a \leqslant c \leqslant b$.

Треугольное распределение широко применяется в ситуациях, когда точная форма истинного распределения неизвестна, но по экспертным оценкам или физическому смыслу задачи можно достоверно определить нижнюю границу, верхнюю границу и наиболее вероятное (ожидаемое) значение.

ОПРЕДЕЛЕНИЕ 15.15.1

Треугольное распределение

Случайная величина X имеет *треугольное распределение*, если ее функция плотности вероятности имеет вид:

$$f(x) = \begin{cases} 0 & \text{для } x < a, \\ \dfrac{2(x-a)}{(b-a)(c-a)} & \text{для } a \leqslant x < c, \\ \dfrac{2}{b-a} & \text{для } x = c, \\ \dfrac{2(b-x)}{(b-a)(b-c)} & \text{для } c < x \leqslant b, \\ 0 & \text{для } x > b. \end{cases}$$

Функция распределения (CDF) получается интегрированием плотности и представляет собой кусочно-квадратичную функцию:

$$F(x) = \begin{cases} 0 & \text{для } x \leqslant a, \\ \dfrac{(x-a)^2}{(b-a)(c-a)} & \text{для } a < x \leqslant c, \\ 1 - \dfrac{(b-x)^2}{(b-a)(b-c)} & \text{для } c < x \leqslant b, \\ 1 & \text{для } x > b. \end{cases}$$

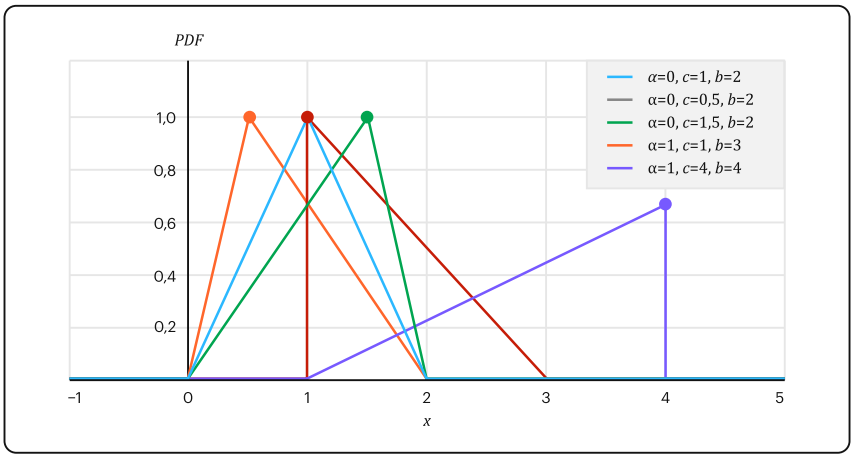

Рисунок 300. Плотность вероятности треугольного распределения

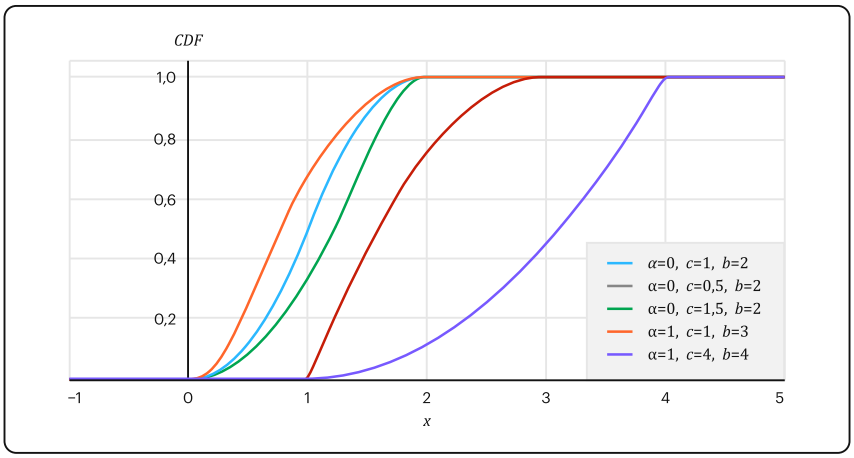

Рисунок 301. Функция распределения треугольного распределения

- **Мода (c):**
  Параметр c определяет положение вершины треугольника (наиболее вероятное значение). Если $c = (a + b)/2$, распределение симметрично. Если c смещено к a или b, возникает соответственно правая или левая асимметрия. В предельных случаях ($c = a$ или $c = b$) треугольник вырождается в прямоугольный, формируя монотонно убывающую или возрастающую плотность.
- **Границы отрезка (a, b):**
  Определяют носитель распределения (ширину базы треугольника) и напрямую задают масштаб дисперсии. Высота вершины в точке $x = c$ всегда равна $\frac{2}{b-a}$, чтобы площадь под графиком плотности строго равнялась единице, независимо от положения моды c.

Моменты и характеристики

Вычислим математическое ожидание и дисперсию прямым интегрированием.

Пусть $X \sim \text{Triangular}(a, c, b)$. Так как плотность задана кусочно, интегралы для моментов разбиваются на две части: от a до c (возрастающий склон) и от c до b (убывающий склон).

Математическое ожидание

Математическое ожидание задается формулой $\mathbb{E}[X] = \int_a^b x f(x) dx$:

$$\mathbb{E}[X] = \int_a^c x \frac{2(x-a)}{(b-a)(c-a)} dx + \int_c^b x \frac{2(b-x)}{(b-a)(b-c)} dx$$

Для упрощения вычислений сделаем замену $y = x - a$ в первом интеграле и $z = b - x$ во втором. После аккуратного взятия степенных интегралов и приведения подобных слагаемых, результат

сводится к красивой симметричной форме:

$$\mathbb{E}[X] = \frac{a+b+c}{3}$$

Геометрически это означает, что математическое ожидание совпадает с x-координатой центроида (центра масс) треугольника, образованного графиком плотности.

Дисперсия

Дисперсия вычисляется как $\mathrm{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$. Сначала вычислим второй начальный момент:

$$\mathbb{E}[X^2] = \int_a^c x^2 \frac{2(x-a)}{(b-a)(c-a)}\,dx + \int_c^b x^2 \frac{2(b-x)}{(b-a)(b-c)}\,dx$$

После выполнения алгебраических преобразований интегралов (разложение многочленов) получаем:

$$\mathbb{E}[X^2] = \frac{a^2+b^2+c^2+ab+ac+bc}{6}$$

Подставляя $\mathbb{E}[X^2]$ и квадрат ожидания $\mathbb{E}[X]$ в формулу дисперсии:

$$\mathrm{Var}(X) = \frac{a^2+b^2+c^2+ab+ac+bc}{6} - \left(\frac{a+b+c}{3}\right)^2 =$$
$$= \frac{3(a^2+b^2+c^2+ab+ac+bc) - 2(a^2+b^2+c^2+2ab+2ac+2bc)}{18} =$$
$$= \frac{a^2+b^2+c^2-ab-ac-bc}{18}$$

Полученное выражение является квадратичной формой, которая не зависит от сдвига распределения, а только от расстояний между параметрами.

Характеристическая функция и производящая функция моментов

Производящая функция моментов (MGF)

Поскольку треугольное распределение определено на конечном отрезке, MGF $M_X(t) = \mathbb{E}[e^{tX}]$ существует для любых $t \in \mathbb{R}$.

$$M_X(t) = \frac{2}{(b-a)(c-a)} \int_a^c e^{tx}(x-a)\,dx +$$
$$+ \frac{2}{(b-a)(b-c)} \int_c^b e^{tx}(b-x)\,dx$$

Интегралы от xe^{tx} вычисляются методом интегрирования по частям ($\int xe^{tx}dx = \frac{xe^{tx}}{t} - \frac{e^{tx}}{t^2}$).

После вычисления, подстановки пределов и группировки экспонент по точкам a, b, c, получаем:

$$M_X(t) = \frac{2(b-c)e^{at} - 2(b-a)e^{ct} + 2(c-a)e^{bt}}{(b-a)(c-a)(b-c)t^2} \quad \text{при } t \neq 0$$

При $t = 0$ значение функции доопределяется пределом и равно 1.

Характеристическая функция (CF)

Подставляя it вместо t в производящую функцию моментов, получаем:

$$\varphi_X(t) = \frac{-2(b-c)e^{iat} + 2(b-a)e^{ict} - 2(c-a)e^{ibt}}{(b-a)(c-a)(b-c)t^2} \quad \text{при } t \neq 0$$

Свойства и связи с другими распределениями

Приведем некоторые свойства и связи.

Свойства:

1. **Симметричное треугольное распределение.**
   Если $c = (a+b)/2$, распределение абсолютно симметрично. Асимметрия равна 0, а математическое ожидание, медиана и мода совпадают и равны $(a+b)/2$. Дисперсия в этом случае достигает своего максимума (при фиксированных a и b) и равна $\frac{(b-a)^2}{24}$.
2. **Масштабирование и сдвиг.**
   Треугольное распределение замкнуто относительно линейных аффинных преобразований. Если $X \sim \text{Triangular}(a, c, b)$, то для любых констант $m > 0$ и k:

$$mX + k \sim \text{Triangular}(ma + k, mc + k, mb + k)$$

Связи с другими распределениями:

1. Сумма двух равномерных распределений (Распределение Ирвина-Холла).
   Сумма двух независимых одинаково распределенных равномерных случайных величин $U_1, U_2 \sim U(0,1)$ имеет распределение Ирвина-Холла (для $n = 2$), которое является частным случаем **строго симметричного треугольного распределения** на отрезке $[0, 2]$ с вершиной в точке 1.
   Это фундаментальное свойство выводится через свертку (свертка двух прямоугольных плотностей дает треугольную форму).

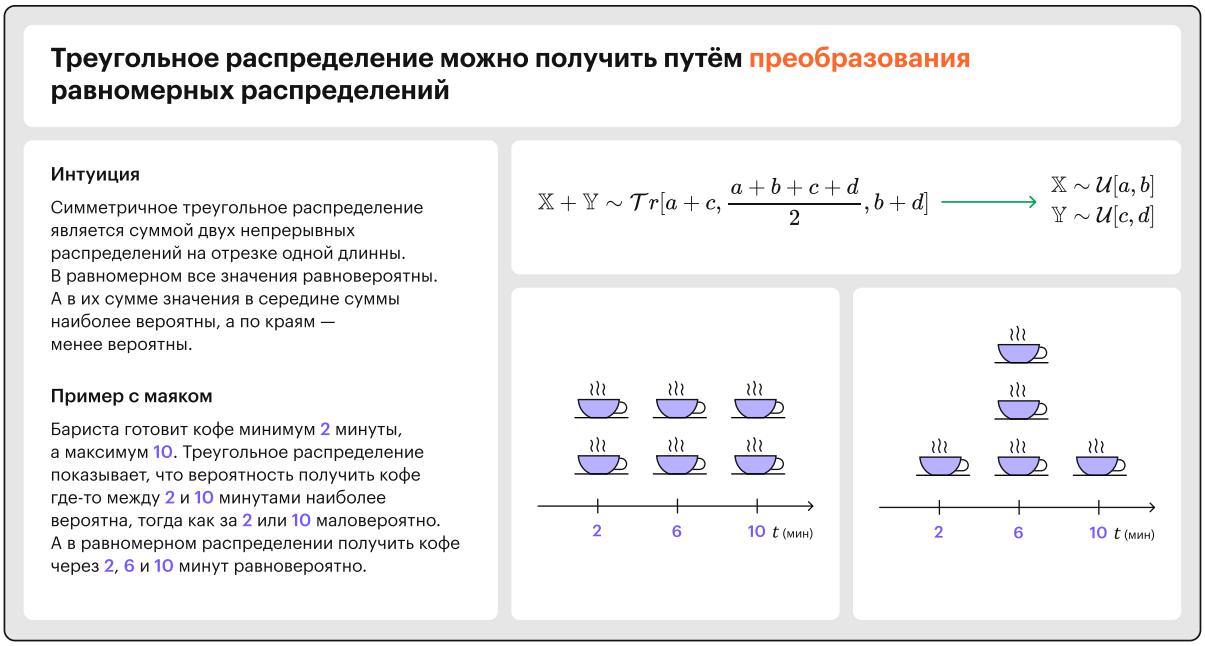

Рисунок 302. Связь равномерно и треугольного распределения

Оценка параметров

В большинстве задач (например, в PERT-анализе) параметры a, b и c задаются экспертно, а не оцениваются по выборке. Однако, если требуется статистическая оценка:

Метод моментов.

Если минимальное значение a и максимальное значение b известны (что часто бывает из физических ограничений), то неизвестная мода c оценивается через выборочное среднее $\bar{x}$.

Используя формулу $\mathbb{E}[X] = \frac{a+b+c}{3} = \bar{x}$, получаем:

$$\hat{c} = 3\bar{x} - a - b$$

(Оценка корректна только если $\hat{c}$ попадает в интервал $[a, b]$).

Метод максимального правдоподобия (MLE).

Если a и b неизвестны, то из свойств плотности следует, что ММП-оценки границ равны экстремумам выборки:

$$\hat{a} = \min(X_1, \ldots, X_n), \quad \hat{b} = \max(X_1, \ldots, X_n)$$

Оценка моды $\hat{c}$ методом правдоподобия не имеет закрытой аналитической формы. Логарифм правдоподобия непрерывен, но его производная терпит разрыв в точке $x_i = c$.

Максимум функции правдоподобия всегда достигается в одной из точек выборки, поэтому алгоритм нахождения сводится к перебору: необходимо вычислить значение функции правдоподобия,

принимая в качестве c каждое из наблюдений x_i, и выбрать то, которое максимизирует результат.

Основная табличка

Распределение	Triangular(a, c, b) – треугольное распределение
Параметры	$a \in \mathbb{R}$ (нижняя граница) $b > a$ (верхняя граница) $c \in [a, b]$ (мода)
Носитель	$x \in [a, b]$
Плотность (PDF)	$f(x) = \begin{cases} \dfrac{2(x-a)}{(b-a)(c-a)}, & a \leqslant x < c \\ \dfrac{2(b-x)}{(b-a)(b-c)}, & c \leqslant x \leqslant b \end{cases}$
Функция распределения (CDF)	$F(x) = \begin{cases} \dfrac{(x-a)^2}{(b-a)(c-a)}, & a \leqslant x \leqslant c \\ 1 - \dfrac{(b-x)^2}{(b-a)(b-c)}, & c < x \leqslant b \end{cases}$
Мат. ожидание	$\mathbb{E}[X] = \dfrac{a+b+c}{3}$
Медиана	$\begin{cases} a + \sqrt{\dfrac{(b-a)(c-a)}{2}}, & \text{если } c \geqslant \dfrac{a+b}{2} \\ b - \sqrt{\dfrac{(b-a)(b-c)}{2}}, & \text{если } c < \dfrac{a+b}{2} \end{cases}$
Мода	c
Дисперсия	$\mathrm{Var}(X) = \dfrac{a^2+b^2+c^2-ab-ac-bc}{18}$
Асимметрия	$\dfrac{\sqrt{2}(a+b-2c)(2a-b-c)(a-2b+c)}{5(a^2+b^2+c^2-ab-ac-bc)^{3/2}}$
Эксцесс	$-\dfrac{3}{5}$
Производящая функция моментов	$\dfrac{2(b-c)e^{at} - 2(b-a)e^{ct} + 2(c-a)e^{bt}}{(b-a)(c-a)(b-c)t^2}$
Харак-ая функция	$\dfrac{-2(b-c)e^{iat} + 2(b-a)e^{ict} - 2(c-a)e^{ibt}}{(b-a)(c-a)(b-c)t^2}$
Информация Фишера	Не определена стандартным образом (из-за излома плотности в точке c)
Метод моментов	$\hat{c} = 3\bar{x} - a - b$ (если a и b известны)
Метод макс. правдоподобия (ММП)	$\hat{a} = \min(X), \quad \hat{b} = \max(X)$ $\hat{c} \in \{X_1, \ldots, X_n\}$ (определяется численным перебором по точкам выборки)

16. ГАММА РАСПРЕДЕЛЕНИЕ

Общее

Гамма-распределение ($\Gamma(\alpha, \lambda)$ или $Gamma(\alpha, \lambda)$) - это универсальное семейство непрерывных распределений с двумя параметрами, заданное на полубесконечном интервале $[0, \infty)$.

Оно обобщает несколько важных распределений: экспоненциальное, распределение Эрланга и хи-квадрат являются его частными случаями.

Из-за своей гибкости гамма-распределение широко применяется для моделирования времени ожидания нескольких событий, размера страховых выплат и интенсивности осадков.

Обычно используются две эквивалентные параметризации:

1. С параметром формы α и параметром масштаба $\theta = \frac{1}{\lambda}$
2. С параметром формы α и параметром интенсивности (rate) λ

В каждой из этих форм оба параметра являются строго положительными действительными числами.

ОПРЕДЕЛЕНИЕ 15.16.1

Гамма распределение

Случайная величина X имеет *гамма-распределение* если функция плотности вероятности имеет вид:

$$f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}$$

В свою очередь функция распределения выражается через нижнюю неполную гамма-функцию $\gamma(\alpha, \lambda x)$:

$$F(x) = \frac{1}{\Gamma(\alpha)} \gamma(\alpha, \lambda x)$$

Гамма-функция.

В формулах выше используется гамма-функция $\Gamma(\alpha)$, которая является математическим обобщением факториала на множество вещественных (и комплексных) чисел.

Она определяется через несобственный интеграл:

$$\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t}\, dt$$

Для любого целого положительного числа n гамма-функция строго связана с классическим факториалом соотношением:

$$\Gamma(n) = (n-1)!$$

Кроме того, для любых положительных α выполняется фундаментальное рекуррентное свойство: $\Gamma(\alpha + 1) = \alpha\Gamma(\alpha)$.

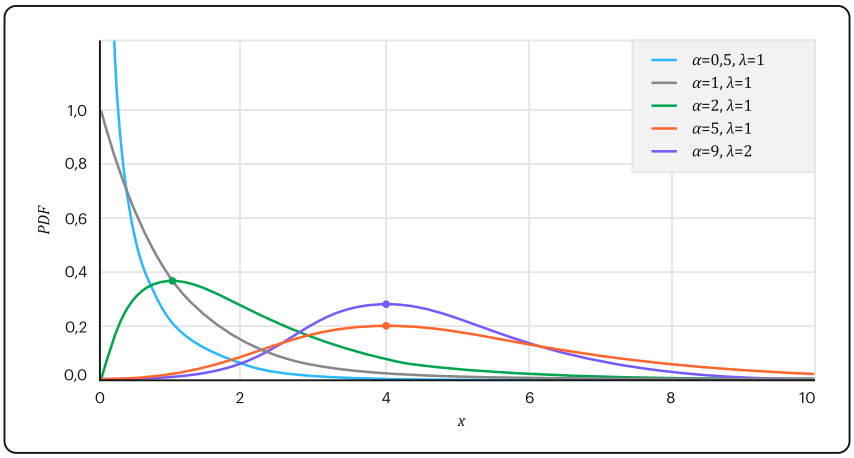

Рисунок 303. Функция плотности вероятности Гамма-распределения

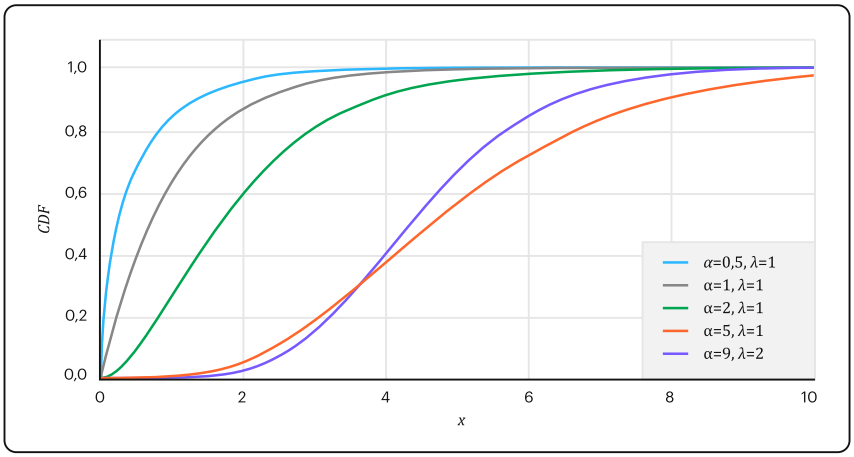

Рисунок 304. Функция распределения Гамма-распределения

Параметры α и λ оказывают предсказуемое влияние на плотность.

При увеличении параметра формы (α) математическое ожидание возрастает, и основная масса распределения смещается вправо, становясь более колоколообразной.

Увеличение интенсивности (λ) масштабирует график: он сжимается влево (ближе к нулю) и вытягивается вверх, уменьшая дисперсию величины.

Характеристическая функция и производящая функция моментов

Характеристическая функция

По определению, характеристическая функция (CF) задается как математическое ожидание величины e^{itX}, где i — мнимая единица:

$$\varphi_X(t) = \mathbb{E}[e^{itX}] = \int_0^\infty e^{itx} \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}\, dx = \\ = \frac{\lambda^\alpha}{\Gamma(\alpha)} \int_0^\infty x^{\alpha-1} e^{-(\lambda - it)x}\, dx$$

Для сходимости интеграла достаточно, чтобы вещественная часть показателя экспоненты была положительной.

Поскольку $\mathrm{Re}(\lambda - it) = \lambda > 0$, это условие выполняется для любых $t \in \mathbb{R}$.

Выполним замену переменной. Пусть $u = (\lambda - it)x$, тогда:

$$x = \frac{u}{\lambda - it} \quad \text{и} \quad dx = \frac{du}{\lambda - it}$$

Пределы интегрирования от 0 до ∞ формально не изменятся. Подставим замену в интеграл:

$$\varphi_X(t) = \frac{\lambda^\alpha}{\Gamma(\alpha)} \int_0^\infty \left(\frac{u}{\lambda - it}\right)^{\alpha-1} e^{-u} \frac{du}{\lambda - it} = \\ = \frac{\lambda^\alpha}{\Gamma(\alpha)(\lambda - it)^\alpha} \int_0^\infty u^{\alpha-1} e^{-u}\, du$$

Заметим, что оставшийся интеграл по определению представляет собой гамма-функцию $\Gamma(\alpha)$.

Подставим $\Gamma(\alpha)$ обратно в выражение для $\varphi_X(t)$:

$$\varphi_X(t) = \frac{\lambda^\alpha}{\Gamma(\alpha)(\lambda - it)^\alpha} \cdot \Gamma(\alpha) = \frac{\lambda^\alpha}{(\lambda - it)^\alpha} = \\ = \left(\frac{\lambda}{\lambda - it}\right)^\alpha = \left(1 - \frac{it}{\lambda}\right)^{-\alpha}, \quad \text{для всех } t \in \mathbb{R}$$

Производящая функция моментов

Производящая функция моментов (MGF) определяется как математическое ожидание вещественной экспоненты:

$$M_X(t) = \mathbb{E}[e^{tX}]$$

Связь между характеристической функцией и производящей функцией моментов устанавливается через аналитическое продолжение.

Заметим, что мы можем получить e^{tX} из e^{itX}, формально заменив аргумент t на $-it$:

$$\varphi_X(-it) = \mathbb{E}[e^{i(-it)X}] = \mathbb{E}[e^{-i^2 tX}] = \mathbb{E}[e^{tX}] = M_X(t)$$

Применим это преобразование к характеристической функции гамма-распределения:

$$M_X(t) = \varphi_X(-it) = \left(1 - \frac{t}{\lambda}\right)^{-\alpha}$$

Важное отличие состоит в области определения: в то время как характеристическая функция существует на всей действительной прямой, MGF существует только тогда, когда математическое ожидание конечно.

Из вида функции ясно, что для сходимости необходимо условие $\lambda - t > 0$. Таким образом, итоговая производящая функция моментов определена строго для $t < \lambda$.

Моменты и характеристики

Вычислим математическое ожидание и дисперсию прямым интегрированием.

Вместо сложного интегрирования по частям мы можем воспользоваться свойством самой плотности гамма-распределения, интеграл от которой по всей области определения равен 1.

Математическое ожидание

По определению:

$$\mathbb{E}[X] = \int_0^\infty x \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}\, dx = \frac{\lambda^\alpha}{\Gamma(\alpha)} \int_0^\infty x^{(\alpha+1)-1} e^{-\lambda x}\, dx$$

Домножим и разделим выражение на постоянные величины так, чтобы под интегралом сформировалась плотность гамма-распределения с параметрами $(\alpha + 1, \lambda)$:

$$\mathbb{E}[X] = \frac{\Gamma(\alpha+1)}{\lambda\Gamma(\alpha)} \int_0^\infty \frac{\lambda^{\alpha+1}}{\Gamma(\alpha+1)} x^{(\alpha+1)-1} e^{-\lambda x}\, dx$$

Поскольку интеграл от плотности равен 1, а $\Gamma(\alpha+1) = \alpha\Gamma(\alpha)$, мы получаем:

$$\mathbb{E}[X] = \frac{\alpha\Gamma(\alpha)}{\lambda\Gamma(\alpha)} \cdot 1 = \frac{\alpha}{\lambda}$$

Дисперсия

Аналогичным образом вычислим второй начальный момент:

$$\mathbb{E}[X^2] = \int_0^\infty x^2 \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}\, dx = \\ = \frac{\Gamma(\alpha+2)}{\lambda^2 \Gamma(\alpha)} \int_0^\infty \frac{\lambda^{\alpha+2}}{\Gamma(\alpha+2)} x^{(\alpha+2)-1} e^{-\lambda x}\, dx$$

Интеграл равен 1 (это плотность с параметрами $\alpha + 2$ и λ). Используя рекуррентное свойство гамма-функции $\Gamma(\alpha+2) = (\alpha+1)\alpha\Gamma(\alpha)$, имеем:

$$\mathbb{E}[X^2] = \frac{(\alpha+1)\alpha\Gamma(\alpha)}{\lambda^2\Gamma(\alpha)} = \frac{\alpha(\alpha+1)}{\lambda^2}$$

Теперь найдем дисперсию:

$$\mathrm{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \frac{\alpha^2+\alpha}{\lambda^2} - \frac{\alpha^2}{\lambda^2} = \frac{\alpha}{\lambda^2}$$

Вычислим моменты через MGF.

Известно, что n-й начальный момент случайной величины равен n-й производной от MGF, вычисленной в точке $t = 0$:

$$\mathbb{E}[X^n] = M_X^{(n)}(0) = \frac{d^n}{dt^n} M_X(t)\Big|_{t=0}$$

Вычисление математического ожидания

Для нахождения $\mathbb{E}[X]$ вычислим первую производную $M_X(t)$:

$$M_X'(t) = \frac{d}{dt}\left[\left(1 - \frac{t}{\lambda}\right)^{-\alpha}\right] = \frac{\alpha}{\lambda}\left(1 - \frac{t}{\lambda}\right)^{-\alpha-1}$$

Подставляя $t = 0$, получаем $\mathbb{E}[X] = \frac{\alpha}{\lambda}$.

Вычисление дисперсии

Для нахождения дисперсии найдем вторую производную от MGF:

$$M_X''(t) = \frac{d}{dt}\left[\frac{\alpha}{\lambda}\left(1 - \frac{t}{\lambda}\right)^{-\alpha-1}\right] = \frac{\alpha(\alpha+1)}{\lambda^2}\left(1 - \frac{t}{\lambda}\right)^{-\alpha-2}$$

Подставляя $t = 0$, находим второй момент:

$$\mathbb{E}[X^2] = M_X''(0) = \frac{\alpha(\alpha+1)}{\lambda^2}$$

Дисперсия равна:

$$\mathrm{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \frac{\alpha(\alpha+1)}{\lambda^2} - \frac{\alpha^2}{\lambda^2} = \frac{\alpha}{\lambda^2}$$

Свойства и связи с другими распределениями

Приведем некоторые свойства и связи.

Свойства:

1. Аддитивность. Если независимые $X_1 \sim Gamma(\alpha_1, \lambda)$ и $X_2 \sim Gamma(\alpha_2, \lambda)$ (с одинаковой интенсивностью λ), то их сумма также имеет гамма-распределение:

   $$X_1 + X_2 \sim Gamma(\alpha_1 + \alpha_2, \lambda)$$

2. Масштабирование. Если $c > 0$, и $X \sim \text{Gamma}(\alpha, \lambda)$, то:

   $$X \sim Gamma\left(\alpha, \frac{\lambda}{c}\right)$$

   Это позволяет моделировать стандартное распределение с $\lambda = 1$ в коде, а затем просто умножать результат на нужный коэффициент.

Связи с другими распределениями:

1. Гамма-распределение является общим случаем распределения Эрланга (когда α — целое число).

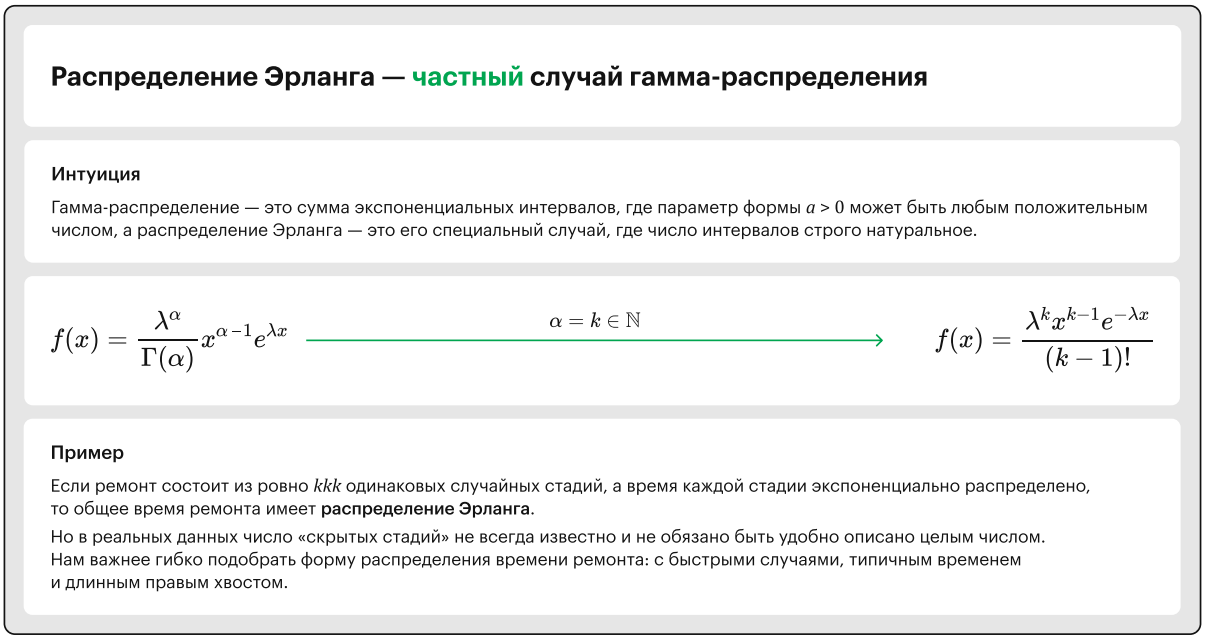

Рисунок 305. Связь гамма распределения и распределения Эрланга

2. Гамма-распределение является общим случаем распределе-

ния хи-квадрат ($\alpha = k/2, \lambda = 1/2$).

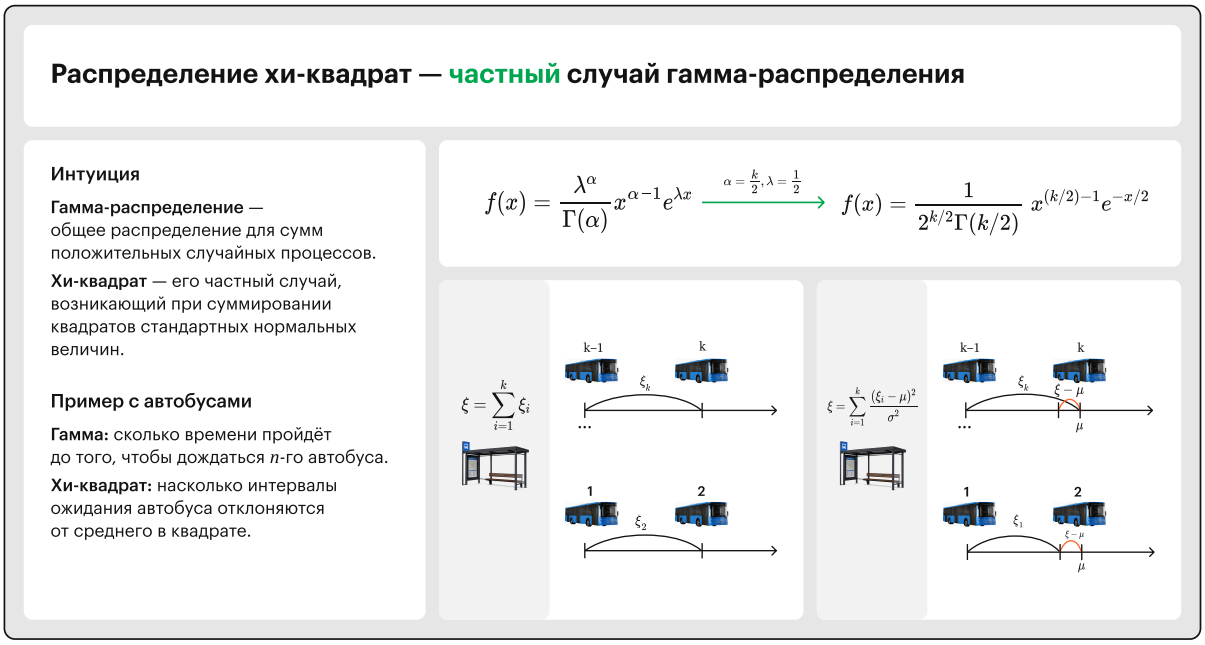

Рисунок 306. Связь гамма распределения и распределения хи квадрат

3. Гамма-распределение является общим случаем экспоненциального распределения ($\alpha = 1$).

Рисунок 307. Связь гамма распределения и экспоненциального распределения

4. Нормальное распределение является предельным случаем гамма-распределения (при $\alpha \to \infty$).

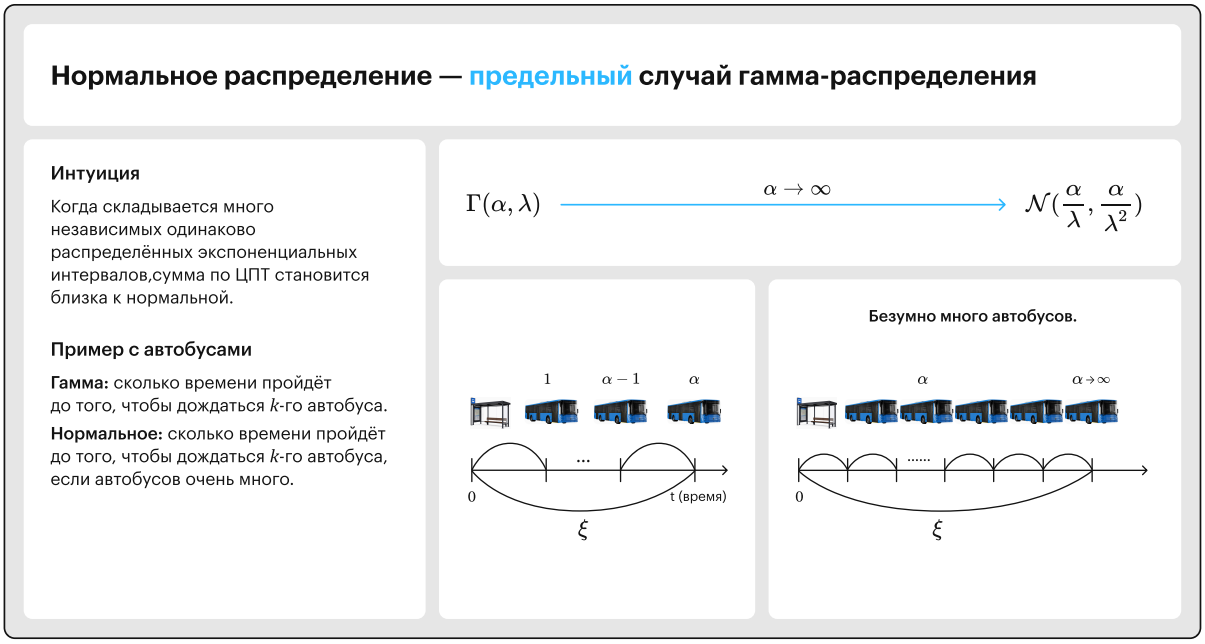

Рисунок 308. Связь гамма распределения и нормального распределения

Оценка параметров

Метод моментов (MoM).

Оценим значения параметров α и λ, приравняв теоретические моменты к выборочным: $\mathbb{E}[X] = \bar{x}$ и $\mathrm{Var}(X) = s^2$.

$$\frac{\alpha}{\lambda} = \bar{x}, \qquad \frac{\alpha}{\lambda^2} = s^2$$

Разделим первое уравнение на второе, чтобы выразить λ:

$$\frac{\alpha/\lambda}{\alpha/\lambda^2} = \frac{\bar{x}}{s^2} \implies \lambda = \frac{\bar{x}}{s^2}$$

Подставляя найденное λ обратно в первое уравнение, получаем:

$$\hat{\alpha} = \frac{\bar{x}^2}{s^2}, \qquad \hat{\lambda} = \frac{\bar{x}}{s^2}$$

Метод максимального правдоподобия (MLE).

Логарифмическая функция правдоподобия для выборки из n независимых наблюдений x_i имеет вид:

$$\ln L(\alpha,\lambda) = n\alpha \ln\lambda - n\ln\Gamma(\alpha) + (\alpha-1)\sum_{i=1}^{n}\ln x_i - \lambda\sum_{i=1}^{n} x_i$$

Берем производную по параметру интенсивности λ и приравни-

ваем к нулю:

$$\frac{\partial \ln L}{\partial \lambda} = \frac{n\alpha}{\lambda} - \sum_{i=1}^{n} x_i = 0 \implies \hat{\lambda} = \frac{\hat{\alpha}}{\bar{x}}$$

Теперь дифференцируем по параметру формы α:

$$\frac{\partial \ln L}{\partial \alpha} = n \ln \lambda - n\frac{\Gamma'(\alpha)}{\Gamma(\alpha)} + \sum_{i=1}^{n} \ln x_i = 0$$

Обозначим дигамма-функцию $\psi(\alpha) = \Gamma'(\alpha)/\Gamma(\alpha)$. Подставляя $\hat{\lambda} = \hat{\alpha}/\bar{x}$ и разделив на n, получаем уравнение:

$$\ln(\hat{\alpha}) - \psi(\hat{\alpha}) = \ln(\bar{x}) - \frac{1}{n}\sum_{i=1}^{n} \ln x_i$$

Это уравнение не имеет аналитического решения для $\hat{\alpha}$ и решается численными методами (например, методом Ньютона-Рафсона).

Основная табличка

Параметры	$\alpha > 0$ (форма), $\lambda > 0$ (интенсивность)
Носитель	$x \in [0, \infty)$
Плотность (PDF)	$f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}$
Функция распределения (CDF)	$F(x) = \frac{1}{\Gamma(\alpha)} \gamma(\alpha, \lambda x)$
Мат. ожидание	$\frac{\alpha}{\lambda}$
Медиана	Простой аналитической формы не существует
Мода	$\frac{\alpha - 1}{\lambda}$ при $\alpha \geqslant 1$, 0 при $\alpha < 1$
Дисперсия	$\frac{\alpha}{\lambda^2}$
Асимметрия	$\frac{2}{\sqrt{\alpha}}$
Эксцесс	$\frac{6}{\alpha}$
Производящая функция моментов	$\left(1 - \frac{t}{\lambda}\right)^{-\alpha}$ для $t < \lambda$
Харак-ая функция	$\left(1 - \frac{it}{\lambda}\right)^{-\alpha}$
Информация Фишера	$I(\alpha, \lambda) = \begin{pmatrix} \psi^{(1)}(\alpha) & -\lambda^{-1} \\ -\lambda^{-1} & \alpha\lambda^{-2} \end{pmatrix}$
Метод моментов	$\hat{\alpha} = \frac{\bar{x}^2}{s^2}, \quad \hat{\lambda} = \frac{\bar{x}}{s^2}$
Метод максимального правдоподобия (MLE)	$\hat{\lambda} = \frac{\hat{\alpha}}{\bar{x}}$ $\ln(\hat{\alpha}) - \psi(\hat{\alpha}) = \ln(\bar{x}) - \overline{\ln x}$ *(где ψ — дигамма-функция, $\hat{\alpha}$ ищется численно)*

17. БЕТА РАСПРЕДЕЛЕНИЕ

Общее

Бета-распределение ($\mathrm{B}(\alpha, \beta)$ или $Beta(\alpha, \beta)$) - это это семейство непрерывных распределений, определенных на интервале $[0, 1]$. Имеет два положительных параметра, обозначаемых α и β, которые появляются как показатель переменной и ее дополнения до 1, соответственно.

Бета-распределение применяется для моделирования поведения

случайных величин, ограниченных интервалами конечной длины, в широком спектре дисциплин. Бета-распределение является подходящей моделью для случайного поведения процентных соотношений и пропорций.

ОПРЕДЕЛЕНИЕ 15.17.1

Бета-распределение

Случайная величина $\mathbb{X}$ имеет *бета-распределение* если функция плотности вероятности имеет вид:

$$f(x) = \frac{x^{\alpha-1}(1-x)^{\beta-1}}{\mathrm{B}(\alpha,\beta)}$$

Где $\mathrm{B}(\alpha,\beta) = \dfrac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha)+\Gamma(\beta)}$, а $\Gamma(\alpha)$ – гамма функция.

В свою очередь функция вероятности выражается регуляризованную бета функцию:

$$F(x) = I_x(\alpha,\beta)$$

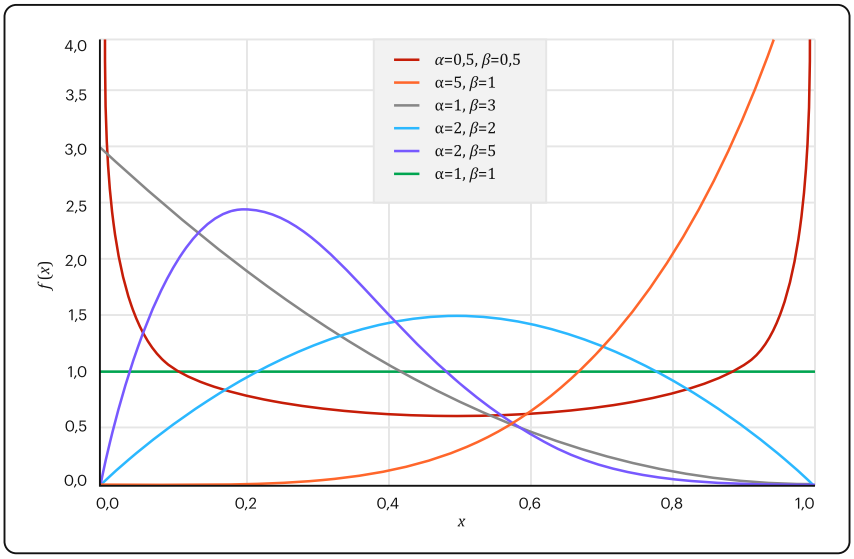

Рисунок 309. Плотность вероятности и функции распределения Бета-распределения

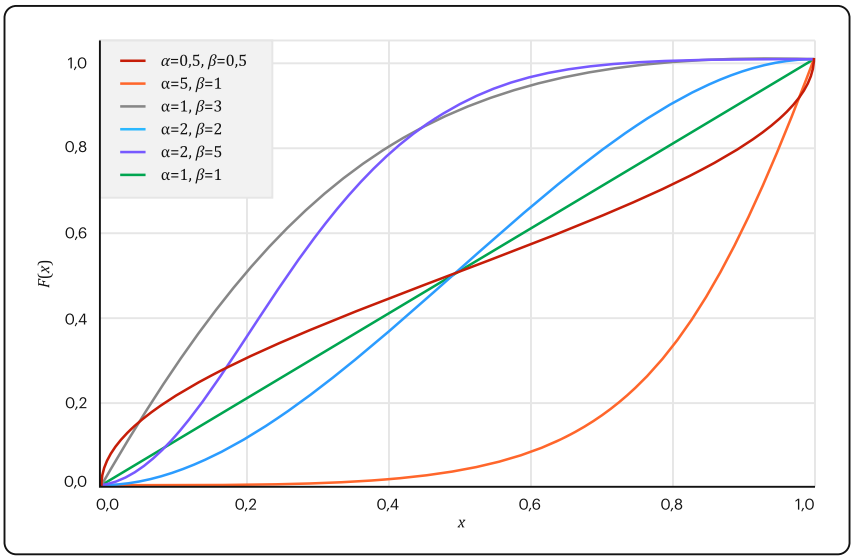

Рисунок 310. Функция распределения Бета-распределения

Параметры α и β бета-распределения работают как «противовесы» на отрезке $[0, 1]$.

Увеличение α смещает математическое ожидание и основную массу распределения вправо (к единице), формируя левостороннюю асимметрию.

Увеличение β, напротив, стягивает распределение влево (к нулю), создавая правостороннюю асимметрию.

Если параметры равны ($\alpha = \beta$), график строго симметричен относительно центра (0.5). При их одновременном увеличении колокол распределения вытягивается вверх и сужается: дисперсия стремительно падает, а значения концентрируются вокруг среднего.

Если же оба параметра опускаются ниже единицы ($\alpha < 1, \beta < 1$), распределение из колоколообразного радикально превращается в U-образное, скапливая вероятностную массу на краях отрезка.

Характеристическая функция и производящая функция моментов

Характеристическая функция

По определению, характеристическая функция есть математическое ожидание комплексной экспоненты e^{itX}:

$$\varphi_X(t) = \mathbb{E}[e^{itX}] = \frac{1}{\mathrm{B}(\alpha, \beta)} \int_0^1 e^{itx} x^{\alpha-1}(1-x)^{\beta-1}\, dx$$

Для вычисления этого интеграла разложим экспоненту в абсолютно сходящийся ряд Маклорена:

$$e^{itx} = \sum_{k=0}^{\infty} \frac{(itx)^k}{k!} = \sum_{k=0}^{\infty} \frac{(it)^k}{k!} x^k$$

Подставим это разложение в интеграл и поменяем местами суммирование и интегрирование:

$$\varphi_X(t) = \frac{1}{\mathrm{B}(\alpha,\beta)} \int_0^1 \left(\sum_{k=0}^{\infty} \frac{(it)^k}{k!} x^k \right) x^{\alpha-1}(1-x)^{\beta-1}\,dx = \\ = \sum_{k=0}^{\infty} \frac{(it)^k}{k!\,\mathrm{B}(\alpha,\beta)} \int_0^1 x^{\alpha+k-1}(1-x)^{\beta-1}\,dx$$

Оставшийся интеграл представляет собой бета-функцию с параметрами $\alpha + k$ и β:

$$\int_0^1 x^{(\alpha+k)-1}(1-x)^{\beta-1}\,dx = \mathrm{B}(\alpha+k,\beta)$$

Подставляя ее обратно, получаем:

$$\varphi_X(t) = \sum_{k=0}^{\infty} \frac{(it)^k}{k!} \frac{\mathrm{B}(\alpha+k,\beta)}{\mathrm{B}(\alpha,\beta)}$$

Выразим отношение бета-функций через гамма-функцию $\mathrm{B}(x,y) = \frac{\Gamma(x)\Gamma(y)}{\Gamma(x+y)}$:

$$\frac{\mathrm{B}(\alpha+k,\beta)}{\mathrm{B}(\alpha,\beta)} = \frac{\Gamma(\alpha+k)}{\Gamma(\alpha)} \cdot \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha+\beta+k)}$$

Воспользуемся основным функциональным уравнением гамма-функции $\Gamma(z+1) = z\Gamma(z)$. Последовательно применяя его k раз, мы можем выразить отношение гамма-функций в виде конечного произведения:

$$\frac{\Gamma(\alpha+k)}{\Gamma(\alpha)} = \alpha(\alpha+1)\dots(\alpha+k-1) = \prod_{r=0}^{k-1}(\alpha+r)$$

$$\frac{\Gamma(\alpha+\beta+k)}{\Gamma(\alpha+\beta)} = (\alpha+\beta)(\alpha+\beta+1)\dots(\alpha+\beta+k-1) = \\ = \prod_{r=0}^{k-1}(\alpha+\beta+r)$$

Объединяя эти результаты, получаем:

$$\frac{\mathrm{B}(\alpha+k,\beta)}{\mathrm{B}(\alpha,\beta)} = \prod_{r=0}^{k-1} \frac{\alpha+r}{\alpha+\beta+r}$$

Подставим найденное отношение в исходный ряд. Выделим отдельно нулевой член ряда (при $k = 0$ произведение пустое и по соглашению равно 1):

$$\varphi_X(t) = 1 + \sum_{k=1}^{\infty} \left(\prod_{r=0}^{k-1} \frac{\alpha + r}{\alpha + \beta + r} \right) \frac{(it)^k}{k!}$$

Производящая функция моментов

Производящая функция моментов (MGF) определяется как математическое ожидание действительной экспоненты:

$$M_X(t) = \mathbb{E}[e^{tX}]$$

Поскольку бета-распределение имеет ограниченный носитель $x \in [0, 1]$, математическое ожидание e^{tX} конечно для любых действительных t, и все моменты распределения существуют. Это позволяет нам найти MGF методом аналитического продолжения, выполнив формальную замену аргумента t в характеристической функции на мнимую величину $-it$.

Покажем справедливость этого перехода:

$$\varphi_X(-it) = \mathbb{E}[e^{tX}] = M_X(t)$$

Теперь применим эту подстановку $-it$ вместо t непосредственно к разложению в ряд характеристической функции:

$$M_X(t) = \varphi_X(-it) = 1 + \sum_{k=1}^{\infty} \left(\prod_{r=0}^{k-1} \frac{\alpha + r}{\alpha + \beta + r} \right) \frac{(i(-it))^k}{k!} = \\ = 1 + \sum_{k=1}^{\infty} \left(\prod_{r=0}^{k-1} \frac{\alpha + r}{\alpha + \beta + r} \right) \frac{t^k}{k!}$$

Функция моментов бета-распределения абсолютно сходится для любых $t \in \mathbb{R}$.

Моменты и характеристики

Вычислим математическое ожидание через определение.

$$\mathbb{E}[X] = \int_0^1 x \cdot \frac{1}{\mathrm{B}(\alpha, \beta)} x^{\alpha-1}(1-x)^{\beta-1}\, dx = \\ = \frac{1}{\mathrm{B}(\alpha, \beta)} \int_0^1 x^{\alpha}(1-x)^{\beta-1}\, dx$$

Теперь интеграл в точности совпадает с определением бета-функции, но с новыми параметрами: первым параметром является $(\alpha + 1)$, а вторым — β.

Заменим интеграл на соответствующую бета-функцию:

$$\mathbb{E}[X] = \frac{\mathrm{B}(\alpha + 1, \beta)}{\mathrm{B}(\alpha, \beta)}$$

Чтобы вычислить это отношение, воспользуемся связью бета-функции с гамма-функцией: $\mathrm{B}(x, y) = \frac{\Gamma(x)\Gamma(y)}{\Gamma(x+y)}$.

Подставим это тождество и сократим на $\Gamma(\beta)$ в числитель и знаменатель:

$$\mathbb{E}[X] = \frac{\Gamma(\alpha + 1)}{\Gamma(\alpha)} \cdot \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha + \beta + 1)}$$

Воспользуемся основным рекуррентным свойством гамма-функции ($\Gamma(z + 1) = z\Gamma(z)$):

$$\mathbb{E}[X] = \frac{\alpha\Gamma(\alpha)}{\Gamma(\alpha)} \cdot \frac{\Gamma(\alpha + \beta)}{(\alpha + \beta)\Gamma(\alpha + \beta)} = \frac{\alpha}{\alpha + \beta}$$

Найдем математическое ожидание и дисперсию через MGF.

Известно, что n-й начальный момент случайной величины равен n-й производной от MGF, вычисленной в точке $t = 0$:

$$\mathbb{E}[X^n] = M_X^{(n)}(0) = \frac{d^n}{dt^n} M_X(t)\bigg|_{t=0}$$

Замечательное стечение обстоятельств, что для бета-распределения функция моментов это обычный степенной ряд. Таким образом k-ый центральный момент это просто соответствующий коэффициент умноженный на $k!$ (дифференцирование степенной функции в точке 0):

$$\frac{d^k}{dt^k} M_X(t)\bigg|_{t=0} = \prod_{r=0}^{k-1} \frac{\alpha + r}{\alpha + \beta + r}$$

Вычисление математического ожидания

Для нахождения математического ожидания $\mathbb{E}[X]$ вычислим первую производную $M_X(t)$ по переменной t при $k = 1$:

$$M'_X(t)|_{t=0} = \frac{\alpha}{\alpha + \beta}$$

Вычисление дисперсии

Дисперсия выражается через первый и второй начальные моменты по формуле:

$$\mathrm{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

Сначала найдем второй начальный момент $\mathbb{E}[X^2]$, подставив $k = 2$:

$$M_X''(t)|_{t=0} = \frac{\alpha}{\alpha+\beta} \cdot \frac{\alpha+1}{\alpha+\beta+1}$$

Теперь подставим найденные моменты в формулу дисперсии:

$$\mathrm{Var}(X) = \frac{\alpha(\alpha+1)}{(\alpha+\beta)(\alpha+\beta+1)} - \left(\frac{\alpha}{\alpha+\beta}\right)^2 = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$$

Таким же образом, можно вычислить коэффициенты асимметрии и эксцесса. Значения будут приведены в финальной таблице распределения.

Свойства и связи с другими распределениями

Приведем некоторые свойства и связи.

Свойства:

1. Обобщенное бета-распределение.
   Стандартное бета-распределение задано на интервале $[0, 1]$. Однако с помощью линейного преобразования его можно перенести на произвольный конечный отрезок $[a, b]$. Пусть $X \sim \mathrm{Beta}(\alpha, \beta)$, тогда

   $$Y = a + (b-a)X$$

   имеет четырехпараметрическое обобщенное бета-распределение с носителем $y \in [a, b]$.
   Доказательство: Математическое ожидание и дисперсия преобразуются по стандартным правилам линейных операторов. Поскольку $\mathbb{E}[Y] = \mathbb{E}[a + cX] = a + c\mathbb{E}[X]$:

   $$\mathbb{E}[Y] = a + (b-a)\frac{\alpha}{\alpha+\beta}$$

   Аналогично для дисперсии $\mathrm{Var}(Y) = \mathrm{Var}(a + cX) = = c^2\,\mathrm{Var}(X)$:

   $$\mathrm{Var}(Y) = (b-a)^2\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$$

2. Свойство симметрии (отражения).
   Если случайная величина $X \sim \mathrm{Beta}(\alpha, \beta)$, то её дополнение

до единицы распределено по тому же закону с инвертированными параметрами:

$$(1 - X) \sim \text{Beta}(\beta, \alpha)$$

Это свойство имеет прозрачный статистический смысл: если X моделирует вероятность «успеха» в биномиальном процессе, то $(1 - X)$ моделирует вероятность «неудачи».
Доказательство: Пусть $Y = 1 - X$. Плотность величины X имеет вид $f_X(x) \propto x^{\alpha-1}(1-x)^{\beta-1}$.
Сделаем замену переменной $x = 1 - y$, при этом якобиан $|dx/dy| = 1$. Тогда плотность для Y будет:

$$f_Y(y) = f_X(1-y) \cdot 1 \propto (1-y)^{\alpha-1}(1-(1-y))^{\beta-1} = \\ = (1-y)^{\alpha-1}y^{\beta-1}$$

Переставив множители, получаем $f_Y(y) \propto y^{\beta-1}(1-y)^{\alpha-1}$, что в точности является плотностью распределения $\text{Beta}(\beta, \alpha)$.

3. Аддитивность параметров (Байесовское обновление).
Пусть априорная вероятность успеха p имеет распределение $\text{Beta}(\alpha, \beta)$. Если проводится серия независимых испытаний Бернулли, в результате которой получено k успехов и m неудач, то апостериорное распределение вероятности p также будет являться бета-распределением, параметры которого получаются простым сложением:

$$p \mid (\text{данные}) \sim \text{Beta}(\alpha + k, \beta + m)$$

Это позволяет накапливать результаты экспериментов, складывая новые успехи с параметром α, а неудачи — с параметром β.

Связи с другими распределениями:

1. Бета распределение можно получить из преобразования двух гамма распределений.

Рисунок 311. Связь бета и гамма распределений

2. Бета распределения является общим случаем для равномерного распределения.

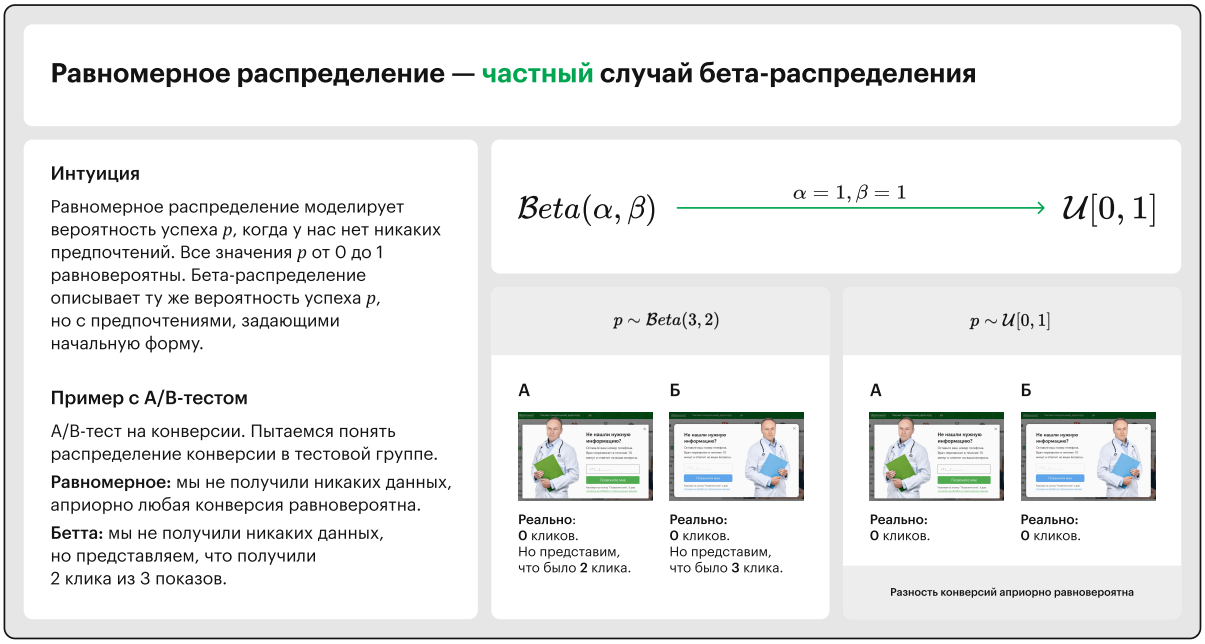

Рисунок 312. Связь бета и равномерного распределений

3. Предельным случаем бета распределения является нормальное распределение.

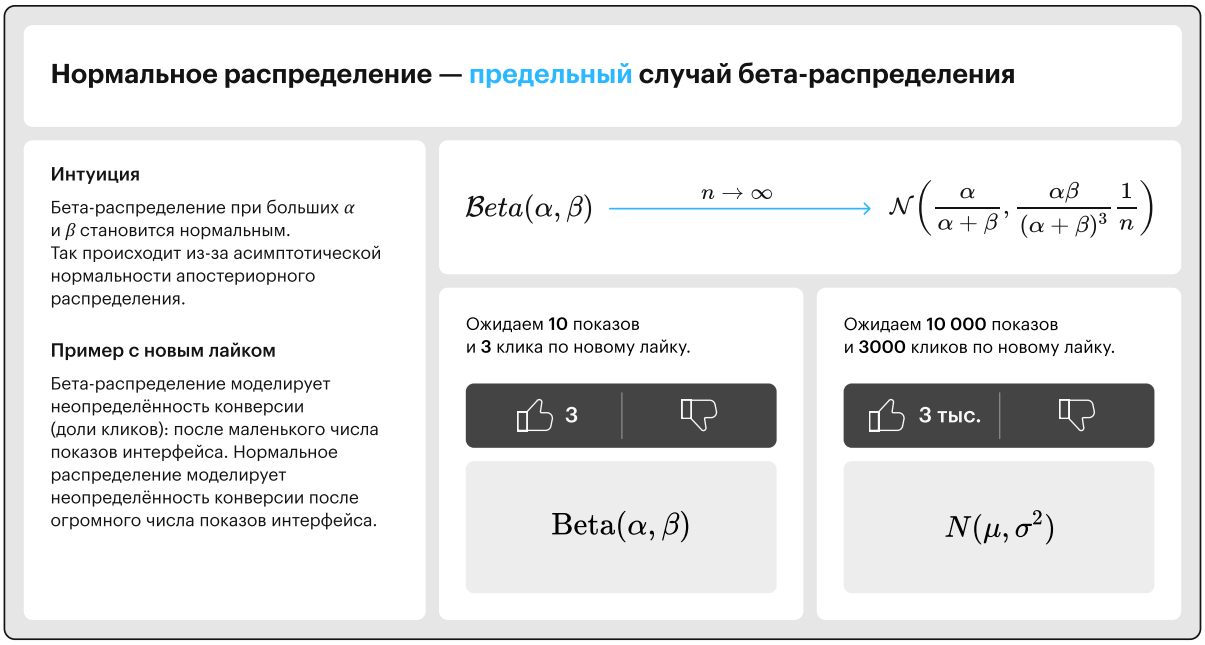

Рисунок 313. Связь бета и нормального распределений

4. Предельным случаем бета распределения является гамма распределение.

Рисунок 314. Связь гамма и бета распределений

5. Бета распределение можно получить из двух распределений Фишера.

Рисунок 315. Связь бета распределения и распределений Фишера

Оценка параметров

Метод моментов.

Оценим значения параметров α и β. Используя

$$\mathbb{E}[X] = \frac{\alpha}{\alpha + \beta}, \qquad \mathrm{Var}(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$$

Приравняем истинные значения к выборочным оценкам: $\mathbb{E}[X] = \bar{x}$ и $\mathrm{Var}(X) = s^2$.

Сначала выразим сумму параметров $(\alpha + \beta)$ из первого уравнения:

$$\bar{x} = \frac{\alpha}{\alpha + \beta} \quad \Rightarrow \quad \alpha = \bar{x}(\alpha + \beta) \quad \text{и} \quad \beta = (1 - \bar{x})(\alpha + \beta)$$

Теперь подставим эти выражения для α и β в числитель уравнения дисперсии (предполагаем что сумма параметров > 0):

$$s^2 = \frac{\bar{x}(1 - \bar{x})(\alpha + \beta)^2}{(\alpha + \beta)^2(\alpha + \beta + 1)} = \frac{\bar{x}(1 - \bar{x})}{\alpha + \beta + 1}$$

Из полученного уравнения легко выразить сумму параметров $(\alpha + \beta)$:

$$\alpha + \beta + 1 = \frac{\bar{x}(1 - \bar{x})}{s^2} \quad \Rightarrow \quad \alpha + \beta = \frac{\bar{x}(1 - \bar{x}) - s^2}{s^2}$$

Теперь, чтобы найти итоговые оценки $\hat{\alpha}$ и $\hat{\beta}$, подставим выражение полученное выражение обратно в уравнения для α и β:

Для параметра α:

$$\hat{\alpha} = \bar{x}(\alpha + \beta) = \bar{x}\left(\frac{\bar{x}(1-\bar{x})}{s^2} - 1\right)$$

Для параметра β:

$$\hat{\beta} = (1-\bar{x})(\alpha + \beta) = (1-\bar{x})\left(\frac{\bar{x}(1-\bar{x})}{s^2} - 1\right)$$

Примечание: Для того чтобы полученные оценки были положительными (что требуется по определению бета-распределения), выборочная дисперсия s^2 должна удовлетворять условию $s^2 < \bar{x}(1-\bar{x})$. На практике для данных из интервала $(0,1)$ это условие выполняется всегда.

Основная табличка

Параметры	$\alpha > 0$ (форма), $\beta > 0$ (форма)
Носитель	$x \in [0,1]$
Плотность (PDF)	$f(x) = \frac{x^{\alpha-1}(1-x)^{\beta-1}}{\mathrm{B}(\alpha,\beta)}$, где $\mathrm{B}(\alpha,\beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$
Функция распределения (CDF)	$I_x(\alpha,\beta)$ (регуляризованная неполная бета-функция)
Мат. ожидание	$\mathbb{E}[X] = \frac{\alpha}{\alpha+\beta}$
Медиана	$I^{[-1]}_{1/2}(\alpha,\beta)$ (в общем случае) $\approx \frac{\alpha - 1/3}{\alpha+\beta-2/3}$ для $\alpha,\beta > 1$
Мода	$\frac{\alpha-1}{\alpha+\beta-2}$ для $\alpha,\beta > 1$ Любое значение в $[0,1]$ для $\alpha = \beta = 1$ Нет моды, если $\alpha < 1$ или $\beta < 1$
Дисперсия	$\mathrm{Var}(X) = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$
Асимметрия	$\frac{2(\beta-\alpha)\sqrt{\alpha+\beta+1}}{(\alpha+\beta+2)\sqrt{\alpha\beta}}$
Эксцесс	$\frac{6[(\alpha-\beta)^2(\alpha+\beta+1) - \alpha\beta(\alpha+\beta+2)]}{\alpha\beta(\alpha+\beta+2)(\alpha+\beta+3)}$
Производящая функция моментов	$1 + \sum_{k=1}^{\infty}\left(\prod_{r=0}^{k-1}\frac{\alpha+r}{\alpha+\beta+r}\right)\frac{t^k}{k!}$
Харак-ая функция	$1 + \sum_{k=1}^{\infty}\left(\prod_{r=0}^{k-1}\frac{\alpha+r}{\alpha+\beta+r}\right)\frac{(it)^k}{k!}$
Информация Фишера	$\begin{pmatrix} \mathrm{Var}(\ln X) & \mathrm{cov}(\ln X, \ln(1-X)) \\ \mathrm{cov}(\ln X, \ln(1-X)) & \mathrm{Var}(\ln(1-X)) \end{pmatrix}$
Метод моментов	$\alpha = \mathbb{E}[X]\left(\frac{\mathbb{E}[X](1-\mathbb{E}[X])}{\mathrm{Var}(X)} - 1\right)$ $\beta = (1-\mathbb{E}[X])\left(\frac{\mathbb{E}[X](1-\mathbb{E}[X])}{\mathrm{Var}(X)} - 1\right)$
Метод максимального правдоподобия (MLE)	$\psi(\hat\alpha) - \psi(\hat\alpha+\hat\beta) = \overline{\ln x}$ $\psi(\hat\beta) - \psi(\hat\alpha+\hat\beta) = \overline{\ln(1-x)}$ *(где ψ — дигамма-функция, $\hat\alpha, \hat\beta$ ищутся численно)*

18. КАТЕГОРИАЛЬНОЕ РАСПРЕДЕЛЕНИЕ

Общее

Категориальное распределение (также известное как обобщенное распределение Бернулли или распределение Мультинулли) — это дискретное распределение вероятностей, описывающее случайную величину, которая может принимать ровно одно из K возможных взаимоисключающих значений.

Сами по себе эти исходы (категории) являются номинальными, они не имеют естественного внутреннего упорядочивания. Но для математического удобства их кодируют целыми числами (например, от 1 до K).

Математически, K-мерное категориальное распределение представляет собой наиболее общий вид дискретного распределения на пространстве из K исходов. Оно полностью задается вектором вероятностей $p = (p_1, p_2, \ldots, p_K)$. Ограничения, накладываемые на эти параметры очевидно вытекают из определения вероятности.

Категориальное распределение служит прямым обобщением распределения Бернулли для случайных величин (с более чем двумя возможными исходами) или обобщением равномернгго распредленеия (где вероятности могу быть различны). Подробнее о связях поговорим в главе со свойствами распределения.

ОПРЕДЕЛЕНИЕ 15.18.1

Категориальное распределение

Случайная величина X имеет *категориальное распределение* если функция вероятности имеет вид:

$$p(x = i) = p_i, \text{для } \forall i \in \{1, 2, .., K\}$$

Где K – кол-во исходов (категорий).

Функцию вероятности так же можно записать в виде:

$$p(x) = p_1^{[x=1]} \cdots p_k^{[x=k]}$$

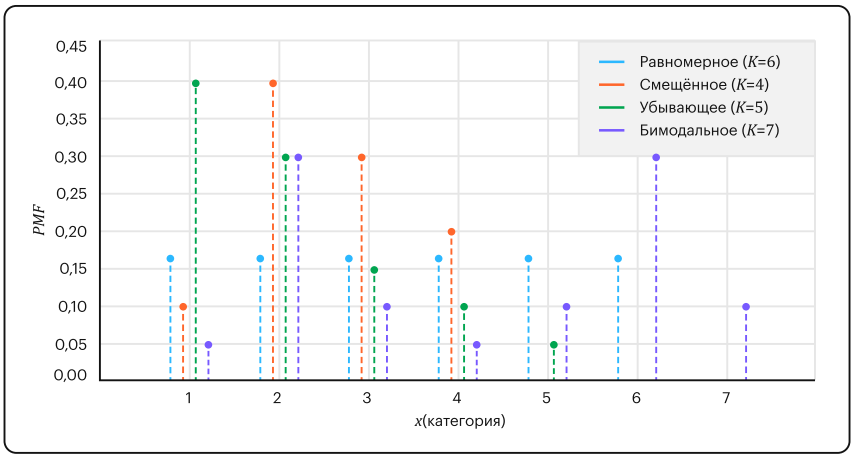

Рисунок 316. Функции вероятности категориального распредления

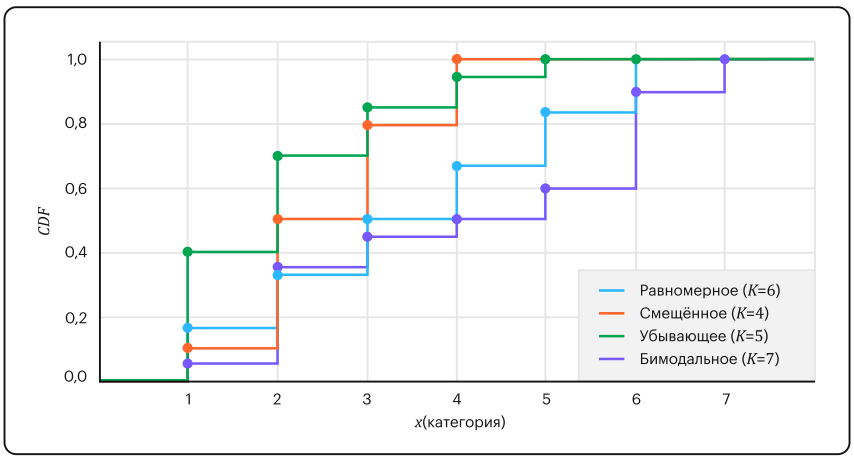

Рисунок 317. Функция распределения категориального распредления

Форма категориального распределения полностью и однозначно определяется вектором вероятностей $p = (p_1, p_2, \ldots, p_K)$. В отличие от большинства распределений, здесь нет единого параметра «формы» или «масштаба» — каждая категория управляется собственным параметром p_i, при условии, что $\sum_{i=1}^{K} p_i = 1$.

Вид характеристической функции (и любых моментов) категориального распределения строго зависит от выбранного способа кодирования исходов. Пусть распределение задано вектором вероятностей $\mathbf{p} = (p_1, p_2, \ldots, p_K)$, где $\sum p_j = 1$.

Характерестическая функция и производящая функция моментов

Используем скалярное (числовое) кодирование чтобы определить CF и MGF для категориального распредлеения:

Пусть случайная величина X принимает целые значения от 1 до K (т.е. $x_j = j$). По определению характеристическая функция

есть математическое ожидание комплексной экспоненты:

$$\varphi_X(t) = \mathbb{E}[e^{itX}] = \sum_{j=1}^{K} e^{itx_j} P(X = x_j)$$

Подставляя значения $x_j = j$ и вероятности $P(X = j) = p_j$, получаем общий вид:

$$\varphi_X(t) = \sum_{j=1}^{K} p_j e^{itj}$$

Аналогично, производящая функция моментов (MGF) для этого случая равна:

$$M_X(t) = \sum_{j=1}^{K} p_j e^{tj}$$

Моменты и характеристики

Математическое ожидание По классическому определению математического ожидания дискретной случайной величины:

$$\mathbb{E}[X] = \sum_{x} x \cdot P(X = x)$$

Подставляя наши значения $x = j$ и вероятности p_j, сразу получаем искомую формулу:

$$\mathbb{E}[X] = \sum_{j=1}^{K} j \cdot p_j$$

Дисперсия Для вычислений используем формулу через второй начальный момент:

$$\mathsf{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

Найдем второй начальный момент $\mathbb{E}[X^2]$ по определению математического ожидания для функции от случайной величины:

$$\mathbb{E}[X^2] = \sum_{x} x^2 \cdot P(X = x) = \sum_{j=1}^{K} j^2 \cdot p_j$$

Теперь подставляем $\mathbb{E}[X^2]$ и $\mathbb{E}[X]$ в расчетную формулу дисперсии:

$$\mathbb{V}(X) = \sum_{j=1}^{K} j^2 p_j - \left(\sum_{j=1}^{K} j p_j \right)^2$$

Асимметрия

Коэффициент асимметрии γ_1 показывает степень скошенности распределения и определяется через третий центральный момент μ_3:

$$\mu_3 = \mathbb{E}[(X-\mu)^3] = \sum_{j=1}^{K}(j-\mu)^3 p_j$$

Окончательная формула асимметрии принимает вид:

$$\gamma_1 = \frac{\mu_3}{\sigma^3} = \frac{\sum_{j=1}^{K}(j-\mu)^3 p_j}{\left(\sum_{j=1}^{K}(j-\mu)^2 p_j\right)^{3/2}}$$

Эксцесс

Коэффициент эксцесса γ_2 характеризует «островершинность» распределения и тяжесть его хвостов. Он вычисляется через четвертый центральный момент μ_4:

$$\mu_4 = \mathbb{E}[(X-\mu)^4] = \sum_{j=1}^{K}(j-\mu)^4 p_j$$

Чтобы эксцесс нормального распределения был равен нулю, из результата вычитают тройку:

$$\gamma_2 = \frac{\mu_4}{\sigma^4} - 3 = \frac{\sum_{j=1}^{K}(j-\mu)^4 p_j}{\left(\sum_{j=1}^{K}(j-\mu)^2 p_j\right)^{2}} - 3$$

Мода

Для категориального распределения мода определяется как категория j, которой соответствует максимальное значение вероятности p_j:

$$Mo(X) = \arg\max_{j\in\{1,2,\ldots,K\}} p_j$$

19. РАСПРЕДЕЛЕНИЕ ВЕЙБУЛЛА

Общее

Распределение Вейбулла (Weibull(λ, k)) — это непрерывное двухпараметрическое распределение вероятностей, заданное на полубесконечном интервале $[0, +\infty)$.

Оно описывается параметром масштаба $\lambda > 0$ и параметром формы $k > 0$.

Распределение Вейбулла является фундаментальным в теории надежности, анализе выживаемости и инженерии.

Оно уникально тем, что способно моделировать все три стадии «кривой жизни» (bathtub curve) технических устройств в зависимости от параметра формы k: убывающую интенсивность отказов (период приработки), постоянную интенсивность (случайные отказы) и возрастающую интенсивность (старение и износ).

Интуиция. Логику этого распределения легко понять на примере времени жизни лампочки или сложного механизма: устройство либо ломается почти сразу из-за заводского брака (ранние отказы), либо живет супер-долго, работая надежно, пока не начнет резко выходить из строя от естественного износа в конце срока службы.

ОПРЕДЕЛЕНИЕ 15.19.1

Распределение Вейбулла

лучайная величина X имеет *распределение Вейбулла*, если ее функция плотности вероятности имеет вид:

$$f(x) = \begin{cases} \frac{k}{\lambda}\left(\frac{x}{\lambda}\right)^{k-1} e^{-(x/\lambda)^k} & \text{для } x \geqslant 0, \\ 0 & \text{для } x < 0. \end{cases}$$

Функция распределения (CDF) выражается в простой аналитической форме:

$$F(x) = 1 - e^{-(x/\lambda)^k} \quad \text{для } x \geqslant 0$$

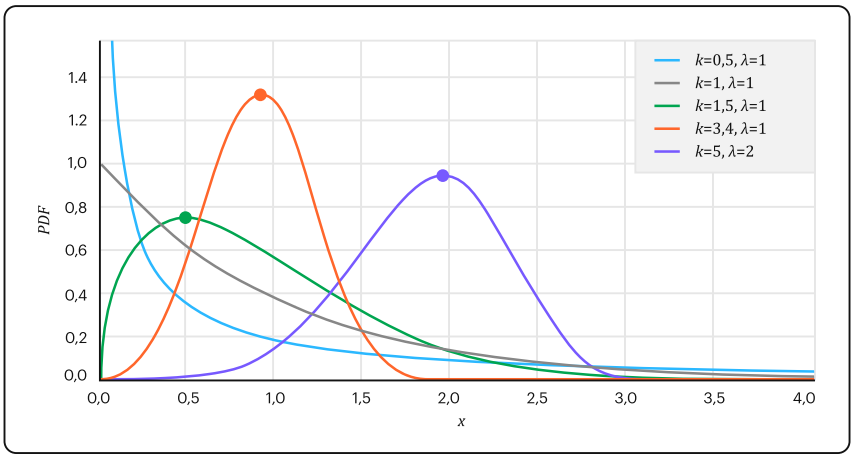

Рисунок 318. Плотность вероятности распределения Вейбулла

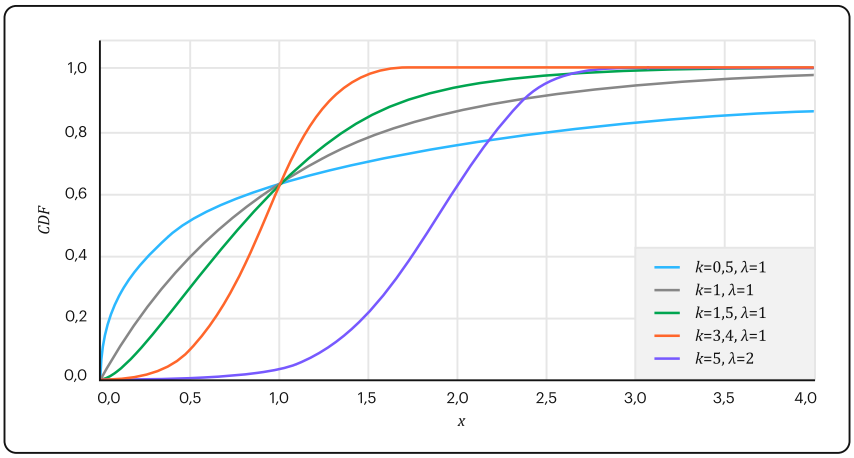

Рисунок 319. Функция распределения Вейбулла

Параметр формы k радикально меняет поведение распределения:

- $k < 1$ **(Убывающая интенсивность отказов):** Плотность стремится к бесконечности при $x \to 0$ и строго монотонно убывает. Моделирует ранние отказы («детская смертность» дефектных изделий).
- $k = 1$ **(Постоянная интенсивность):** Распределение Вейбулла вырождается в экспоненциальное распределение $\text{Exp}(1/\lambda)$.
- $k > 1$ **(Возрастающая интенсивность):** Плотность начинается с нуля $f(0) = 0$, имеет единственный максимум (моду) и убывает к нулю. При $k \approx 3.4$ распределение становится визуально похожим на нормальное, а при $k \to \infty$ вырождается в дельта-функцию Дирака (детерминированное время отказа).

Характеристическая функция и производящая функция моментов

У распределения Вейбулла характеристическая функция и MGF не имеют простых аналитических представлений (закрытой формы) и выражаются только в виде бесконечных рядов.

Характеристическая функция

Характеристическая функция $\varphi_X(t) = \mathbb{E}[e^{itX}]$ абсолютно сходится для любых $k > 0$ и $t \in \mathbb{R}$. По определению:

$$\varphi_X(t) = \int_0^\infty e^{itx} \frac{k}{\lambda} \left(\frac{x}{\lambda}\right)^{k-1} e^{-(x/\lambda)^k} \, dx$$

Сделаем замену переменной $u = (x/\lambda)^k$, откуда $x = \lambda u^{1/k}$ и $dx = \frac{\lambda}{k} u^{1/k-1} du$. Интеграл преобразуется к виду:

$$\varphi_X(t) = \int_0^\infty e^{it\lambda u^{1/k}} e^{-u} \, du$$

Так как этот интеграл не берется в элементарных функциях, раз-

ложим комплексную экспоненту $e^{it\lambda u^{1/k}}$ в абсолютно сходящийся ряд Маклорена:

$$e^{it\lambda u^{1/k}} = \sum_{n=0}^{\infty} \frac{(it\lambda u^{1/k})^n}{n!} = \sum_{n=0}^{\infty} \frac{(it\lambda)^n}{n!} u^{n/k}$$

Поменяем местами суммирование и интегрирование:

$$\varphi_X(t) = \sum_{n=0}^{\infty} \frac{(it\lambda)^n}{n!} \int_0^{\infty} u^{n/k} e^{-u}\, du$$

Оставшийся интеграл в точности совпадает с определением гамма-функции $\Gamma(z) = \int_0^{\infty} u^{z-1} e^{-u} du$, где $z = 1 + \frac{n}{k}$. Подставляя гамма-функцию, получаем:

$$\varphi_X(t) = \sum_{n=0}^{\infty} \frac{(it\lambda)^n}{n!} \Gamma\left(1 + \frac{n}{k}\right)$$

Производящая функция моментов (MGF)

Производящая функция моментов (MGF) определяется как математическое ожидание действительной экспоненты:

$$M_X(t) = \mathbb{E}[e^{tX}]$$

Интеграл для $M_X(t)$ сходится, если показатель экспоненты в подынтегральном выражении отрицателен, то есть при $t < 1/2$.

Для нахождения MGF мы можем воспользоваться методом аналитического продолжения, выполнив формальную замену аргумента t в характеристической функции на мнимую величину $-it$:

$$\varphi_X(-it) = \mathbb{E}[e^{tX}] = M_X(t)$$

Применим эту подстановку $-it$ вместо t к результату, полученному для характеристической функции:

$$M_X(t) = \varphi_X(-it) = \sum_{n=0}^{\infty} \frac{(i(-it)\lambda)^n}{n!} \Gamma\left(1 + \frac{n}{k}\right) = \sum_{n=0}^{\infty} \frac{t^n \lambda^n}{n!} \Gamma\left(1 + \frac{n}{k}\right)$$

Функция моментов распределения Вейбулла определена и сходится для любых $t > 0$ только при условии $k \geqslant 1$. (При $k < 1$ хвост плотности убывает слишком медленно, и ряд расходится).

Моменты и характеристики

Вычислим математическое ожидание и дисперсию через MGF.

Так как MGF для распределения Вейбулла представлена степенным рядом $M_X(t) = \sum_{n=0}^{\infty} \frac{t^n}{n!}\mathbb{E}[X^n]$, начальные моменты $\mathbb{E}[X^n]$ напрямую соответствуют коэффициентам при $\frac{t^n}{n!}$.

Из вывода MGF очевидно, что n-й начальный момент равен:

$$\mathbb{E}[X^n] = \lambda^n \Gamma\left(1 + \frac{n}{k}\right)$$

Вычисление математического ожидания

Для нахождения математического ожидания $\mathbb{E}[X]$ подставим $n = 1$:

$$\mathbb{E}[X] = \lambda \Gamma\left(1 + \frac{1}{k}\right)$$

Вычисление дисперсии

Для дисперсии нам нужен второй начальный момент ($n = 2$):

$$\mathbb{E}[X^2] = \lambda^2 \Gamma\left(1 + \frac{2}{k}\right)$$

Дисперсия выражается через начальные моменты $\mathrm{Var}(X) = \\ = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$:

$$\begin{aligned}\mathrm{Var}(X) = \lambda^2 \Gamma\left(1 + \frac{2}{k}\right) - \left[\lambda \Gamma\left(1 + \frac{1}{k}\right)\right]^2 = \\ = \lambda^2 \left[\Gamma\left(1 + \frac{2}{k}\right) - \Gamma^2\left(1 + \frac{1}{k}\right)\right]\end{aligned}$$

Вычислим математическое ожидание и дисперсию через определение.

Вычисление математического ожидания

По определению математическое ожидание задается интегралом:

$$\mathbb{E}[X] = \int_0^{\infty} x \frac{k}{\lambda}\left(\frac{x}{\lambda}\right)^{k-1} e^{-(x/\lambda)^k}\, dx$$

Внесем x внутрь скобки:

$$\mathbb{E}[X] = \int_0^{\infty} \lambda k \left(\frac{x}{\lambda}\right)^{k} e^{-(x/\lambda)^k} \frac{dx}{x}$$

Сделаем стандартную замену переменной $u = (x/\lambda)^k$. При этом

$du = k(x/\lambda)^{k-1}\frac{1}{\lambda}dx = ku\frac{dx}{x}$.

$$\mathbb{E}[X] = \lambda\int_0^\infty u\cdot e^{-u}\,\frac{du}{ku/k} = \lambda\int_0^\infty u^{1/k}e^{-u}\,du$$

Полученный интеграл является определением гамма-функции $\Gamma(z) = \int_0^\infty u^{z-1}e^{-u}du$, где $z-1 = 1/k$, следовательно $z = 1+1/k$:

$$\mathbb{E}[X] = \lambda\Gamma\left(1+\frac{1}{k}\right)$$

Вычисление дисперсии

Для нахождения дисперсии по определению вычислим второй начальный момент:

$$\mathbb{E}[X^2] = \int_0^\infty x^2\frac{k}{\lambda}\left(\frac{x}{\lambda}\right)^{k-1}e^{-(x/\lambda)^k}\,dx$$

Применяя ту же самую замену $u = (x/\lambda)^k$, откуда $x^2 = \lambda^2 u^{2/k}$:

$$\mathbb{E}[X^2] = \lambda^2\int_0^\infty u^{2/k}e^{-u}\,du = \lambda^2\Gamma\left(1+\frac{2}{k}\right)$$

Подставляя найденные моменты в формулу дисперсии $\mathrm{Var}(X) = = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$, получаем тот же самый результат:

$$\mathrm{Var}(X) = \lambda^2\left[\Gamma\left(1+\frac{2}{k}\right) - \Gamma^2\left(1+\frac{1}{k}\right)\right]$$

Свойства и связи с другими распределениями

Приведем некоторые свойства и связи.

Свойства:

1. **Функция надежности (Выживаемости).**
   В теории надежности вероятность безотказной работы до момента времени x описывается функцией надежности $S(x) = 1 - F(x)$. Для распределения Вейбулла она имеет невероятно простой вид:

   $$S(x) = e^{-(x/\lambda)^k}$$

2. **Интенсивность отказов (Hazard function).**
   Мгновенный риск отказа в момент времени x (при условии,

что до этого отказа не было) равен $h(x) = \frac{f(x)}{S(x)}$:

$$h(x) = \frac{k}{\lambda}\left(\frac{x}{\lambda}\right)^{k-1}$$

Функция интенсивности является монотонно возрастающей при $k > 1$, убывающей при $k < 1$ и константой при $k = 1$.

3. **Свойство степенного преобразования.**
   Если случайная величина X имеет экспоненциальное распределение $X \sim \text{Exp}(\beta)$, то степенное преобразование $Y = X^{1/k}$ имеет распределение Вейбулла с параметрами k и $\lambda = \beta^{1/k}$.
4. **Обратное распределение Вейбулла.**
   Если случайная величина X имеет распределение Вейбулла $X \sim \text{Weibull}(\lambda, k)$, то обратная ей величина $Y = 1/X$ имеет так называемое *обратное распределение Вейбулла* (Inverse Weibull). Это распределение часто применяется для моделирования экстремальных значений (например, распределение Фреше).

Связи с другими распределениями:

1. **Экспоненциальное распределение.** При параметре формы $k = 1$ распределение Вейбулла вырождается в экспоненциальное распределение с интенсивностью $1/\lambda$.

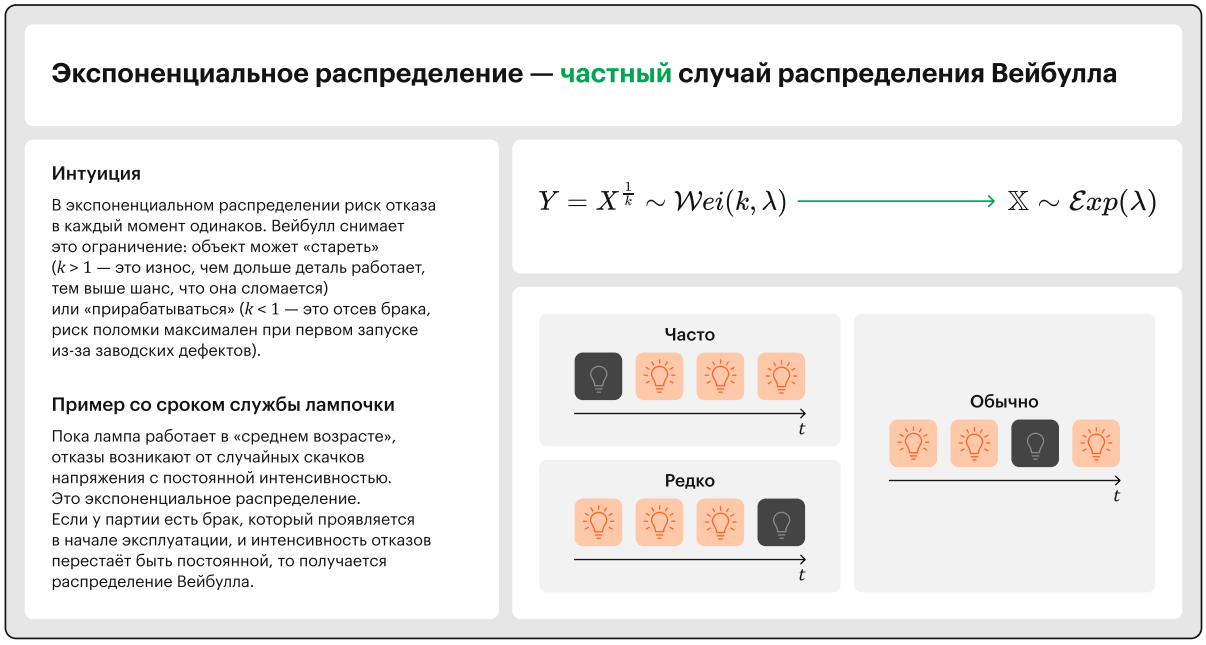

Рисунок 320. Связь экспоненциального распределения и распределения Вейбулла

Оценка параметров

Метод моментов.

Для оценки параметров методом моментов приравниваем теоретические среднее и дисперсию к выборочным: $\mathbb{E}[X] = \bar{x}$ и

$$\mathrm{Var}(X) = s^2.$$

Разделив дисперсию на квадрат среднего, мы можем избавиться от параметра масштаба λ:

$$\frac{s^2}{\bar{x}^2} = \frac{\Gamma(1+2/k) - \Gamma^2(1+1/k)}{\Gamma^2(1+1/k)} = \frac{\Gamma(1+2/k)}{\Gamma^2(1+1/k)} - 1$$

Это уравнение нелинейно относительно параметра k, и оценка $\hat{k}$ ищется численно. После нахождения $\hat{k}$, параметр масштаба легко вычисляется из первого уравнения:

$$\hat{\lambda} = \frac{\bar{x}}{\Gamma(1+1/\hat{k})}$$

Метод максимального правдоподобия (MLE).

Логарифмическая функция правдоподобия для выборки из n независимых наблюдений имеет вид:

$$\ln L(\lambda, k) = n\ln k - nk\ln\lambda + (k-1)\sum_{i=1}^{n}\ln x_i - \sum_{i=1}^{n}\left(\frac{x_i}{\lambda}\right)^k$$

Взяв частную производную по λ и приравняв ее к нулю, мы можем выразить аналитическую оценку параметра λ через неизвестный k:

$$\hat{\lambda} = \left(\frac{1}{n}\sum_{i=1}^{n} x_i^{\hat{k}}\right)^{1/\hat{k}}$$

Подставляя это выражение обратно в производную $\frac{\partial \ln L}{\partial k} = 0$, мы получаем нелинейное уравнение относительно $\hat{k}$:

$$\frac{1}{\hat{k}} + \frac{1}{n}\sum_{i=1}^{n}\ln x_i - \frac{\sum_{i=1}^{n} x_i^{\hat{k}}\ln x_i}{\sum_{i=1}^{n} x_i^{\hat{k}}} = 0$$

Это уравнение решается численными методами (например, алгоритмом Ньютона-Рафсона), чтобы получить $\hat{k}_{MLE}$. Затем найденное $\hat{k}$ подставляется в формулу для $\hat{\lambda}_{MLE}$.

Основная табличка

Параметры	$k > 0$ (форма), $\lambda > 0$ (масштаб)
Носитель	$x \in [0, +\infty)$
Плотность (PDF)	$f(x) = \frac{k}{\lambda}\left(\frac{x}{\lambda}\right)^{k-1} e^{-(x/\lambda)^k}$
Функция распределения (CDF)	$F(x) = 1 - e^{-(x/\lambda)^k}$
Мат. ожидание	$\mathbb{E}[X] = \lambda\Gamma\left(1 + \frac{1}{k}\right)$
Медиана	$\lambda(\ln 2)^{1/k}$
Мода	$\begin{cases} \lambda\left(\frac{k-1}{k}\right)^{1/k}, & \text{если } k > 1 \\ 0, & \text{если } k \leqslant 1 \end{cases}$
Дисперсия	$\mathrm{Var}(X) = \lambda^2\left[\Gamma\left(1 + \frac{2}{k}\right) - \Gamma^2\left(1 + \frac{1}{k}\right)\right]$
Асимметрия	$\frac{\Gamma(1+3/k) - 3\Gamma(1+1/k)\Gamma(1+2/k) + 2\Gamma^3(1+1/k)}{[\Gamma(1+2/k) - \Gamma^2(1+1/k)]^{3/2}}$
Эксцесс	Громоздкая формула через 4-й момент и комбинацию гамма-функций
Производящая функция моментов	$\sum_{n=0}^{\infty} \frac{t^n \lambda^n}{n!}\Gamma\left(1 + \frac{n}{k}\right)$ для $k \geqslant 1$
Харак-ая функция	$\sum_{n=0}^{\infty} \frac{(it\lambda)^n}{n!}\Gamma\left(1 + \frac{n}{k}\right)$
Информация Фишера	$\begin{pmatrix} \frac{k^2}{\lambda^2} & \frac{1-\gamma}{\lambda} \\ \frac{1-\gamma}{\lambda} & \frac{1}{k^2}\left[\frac{\pi^2}{6} + (1-\gamma)^2\right] \end{pmatrix}$ (где $\gamma \approx 0.5772$ — постоянная Эйлера-Маскерони)
Метод моментов	$\frac{\Gamma(1+2/\hat{k})}{\Gamma^2(1+1/\hat{k})} = 1 + \frac{s^2}{\bar{x}^2}$ (численно), $\hat{\lambda} = \frac{\bar{x}}{\Gamma(1+1/\hat{k})}$
Метод максимального правдоподобия (MLE)	$\frac{1}{\hat{k}} + \frac{1}{n}\sum_{i=1}^n \ln x_i - \frac{\sum_{i=1}^n x_i^{\hat{k}} \ln x_i}{\sum_{i=1}^n x_i^{\hat{k}}} = 0$ (численно) $\hat{\lambda} = \left(\frac{1}{n}\sum_{i=1}^n x_i^{\hat{k}}\right)^{1/\hat{k}}$

20. ЭКСПОНЕНЦИАЛЬНОЕ СЕМЕЙСТВО РАСПРЕДЕЛЕНИЙ

Общее: Определение и применение

Экспоненциальное семейство распределений — это широкий класс вероятностных распределений (как непрерывных, так и дискретных), чьи функции плотности вероятности (или функции вероятности) могут быть представлены в едином стандартизированном виде.

Объединение распределений в это семейство имеет колоссальное значение для математической статистики. Оно обеспечивает единый алгебраический фундамент для вывода свойств оценок и алгоритмов.

Где применяется экспоненциальное семейство?

- **Обобщенные линейные модели (GLM):** Любое распределение из этого семейства может выступать в качестве распределения ошибки в GLM (например, логистическая регрессия для биномиального, пуассоновская регрессия).
- **Теорема Питмена-Купмана-Дармуа:** Только для распределений из экспоненциального семейства существует достаточная статистика, размерность которой не зависит от объема выборки (при условии, что носитель распределения не зависит от параметров).
- **Байесовский вывод:** Для любого распределения из этого семейства математически гарантировано существование сопряженного априорного распределения (conjugate prior), что делает аналитический пересчет апостериорной вероятности тривиальным.

Определение. Семейство распределений с параметром θ принадлежит к *экспоненциальному семейству*, если функцию плотности (или функцию вероятности) $f(x \mid \theta)$ можно факторизовать следующим образом:

$$f(x \mid \theta) = h(x)e^{\langle \eta(\theta), T(x) \rangle - A(\theta)}$$

Что значит 1-параметрическое или многопараметрическое семейство?

В базовой формуле выше θ может быть как единственным числом (скаляром), так и вектором из нескольких параметров (например, μ и σ^2).

Если оценивается один параметр, говорят о *1-параметрическом* экспоненциальном семействе. Если два — о *2-параметрическом*, и так далее.

В общей формуле это учитывается через векторы: исходный пара-

метр θ переводится в вектор канонических параметров $\eta(\theta)$, а $T(x)$ становится вектором статистик точно такой же длины. Угловые скобки $\langle \eta(\theta), T(x) \rangle$ обозначают их скалярное произведение (сумма покомпонентных произведений).

Где компоненты имеют следующий строгий смысл:

- $h(x) \geqslant 0$ — базовая мера. Функция, зависящая **только от данных** x (не зависит от θ).
- $T(x)$ — **достаточная статистика**. Вектор (или скаляр) функций от данных x.
- $\eta(\theta)$ — **естественный (канонический) параметр**. Вектор функций от исходных параметров θ.
- $A(\theta)$ — **логарифмическая функция нормировки** (log-partition function). Отвечает за то, чтобы интеграл плотности равнялся 1. Зависит **только от параметров** θ.

Доказательства принадлежности: Непрерывные распределения

Чтобы доказать, что распределение принадлежит к экспоненциальному семейству, мы должны путем алгебраических преобразований (в первую очередь логарифмирования и возведения в степень экспоненты) привести его плотность к каноническому виду.

1. Гамма-распределение

Рассмотрим общий случай гамма-распределения. Плотность: $f(x \mid \alpha, \lambda) = \dfrac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}$.

Перепишем, внеся все в экспоненту:

$$f(x \mid \alpha, \lambda) = e^{\ln(x^{\alpha-1}) - \lambda x + \ln(\lambda^\alpha) - \ln\Gamma(\alpha)} = \\ = e^{(\alpha-1)\ln x - \lambda x - (\ln\Gamma(\alpha) - \alpha \ln\lambda)}$$

Идентификация компонентов: $h(x) = 1 \quad (\text{для } x > 0); \quad T(x) = \begin{pmatrix} \ln x \\ x \end{pmatrix}; \quad \eta(\alpha, \lambda) = \begin{pmatrix} \alpha - 1 \\ -\lambda \end{pmatrix}; \quad A(\alpha, \lambda) = \ln\Gamma(\alpha) - \alpha \ln\lambda.$

Гамма-распределение образует 2-параметрическое экспоненциальное семейство.

2. Экспоненциальное распределение

Оно является частным случаем гамма-распределения при фиксированном параметре формы $\alpha = 1$.

Подставляя $\alpha = 1$ в доказательство выше, вектор η сокращается до скаляра: $h(x) = 1; \quad T(x) = x; \quad \eta(\lambda) = -\lambda; \quad A(\lambda) = -\ln\lambda.$

Это 1-параметрическое экспоненциальное семейство.

3. Распределение Хи-квадрат

Это распределение также является частным случаем гамма-распределения, где $\alpha = k/2$, а интенсивность фиксирована $\lambda = 1/2$. Следовательно, оно автоматически принадлежит экспоненциальному семейству.

Если степень свободы k рассматривать как единственный параметр: $h(x) = e^{-x/2}$; $T(x) = \ln x$; $\eta(k) = \dfrac{k}{2} - 1$; $A(k) = \\ = \ln\Gamma(k/2) - \dfrac{k}{2}\ln(1/2)$.

4. Нормальное распределение

Рассмотрим общий случай для нормального распределения $\mathcal{N}(\mu, \sigma^2)$. Плотность: $f(x \mid \mu, \sigma^2) = \dfrac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$.

Раскроем квадрат и сгруппируем:

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2 - 2\mu x + \mu^2}{2\sigma^2} - \ln\sigma} = \\ = \frac{1}{\sqrt{2\pi}} e^{\frac{\mu}{\sigma^2}x - \frac{1}{2\sigma^2}x^2 - \left(\frac{\mu^2}{2\sigma^2} + \ln\sigma\right)}$$

Идентификация: $h(x) = \dfrac{1}{\sqrt{2\pi}}$; $T(x) = \begin{pmatrix} x \\ x^2 \end{pmatrix}$; $\eta(\mu, \sigma^2) = \\ = \begin{pmatrix} \dfrac{\mu}{\sigma^2} \\ -\dfrac{1}{2\sigma^2} \end{pmatrix}$; $A(\mu, \sigma^2) = \dfrac{\mu^2}{2\sigma^2} + \ln\sigma$.

5. Логнормальное распределение

Величина $X \sim \text{Lognormal}(\mu, \sigma^2)$, если $Y = \ln X \sim \mathcal{N}(\mu, \sigma^2)$.

Плотность логнормального распределения отличается от нормальной только множителем $1/x$ из-за Якобиана преобразования $x = e^y$. Это легко вписывается в базовую меру: $h(x) = \dfrac{1}{x\sqrt{2\pi}}$; $T(x) = \begin{pmatrix} \ln x \\ (\ln x)^2 \end{pmatrix}$.

Параметры η и A полностью совпадают с нормальным распределением.

6. Бета-распределение

Плотность: $f(x \mid \alpha, \beta) = \dfrac{x^{\alpha-1}(1-x)^{\beta-1}}{\mathrm{B}(\alpha, \beta)}$.

Внесем всё в экспоненту:

$$f(x) = e^{(\alpha-1)\ln x + (\beta-1)\ln(1-x) - \ln\mathrm{B}(\alpha,\beta)}$$

Идентификация: $h(x) = 1; \quad T(x) = \begin{pmatrix} \ln x \\ \ln(1-x) \end{pmatrix}; \quad \eta(\alpha, \beta) = \\ = \begin{pmatrix} \alpha - 1 \\ \beta - 1 \end{pmatrix}; \quad A(\alpha, \beta) = \ln \mathrm{B}(\alpha, \beta).$

7. Распределение Лапласа

Здесь нужно быть очень осторожным.
Плотность: $f(x \mid \mu, b) = \frac{1}{2b} e^{-\frac{|x-\mu|}{b}}$.

Если параметр сдвига μ **неизвестен**, модуль $|x - \mu|$ нельзя представить в виде произведения $\eta(\mu) \cdot T(x)$. Таким образом, в общем виде распределение Лапласа **не принадлежит** экспоненциальному семейству.

Однако, если μ **фиксировано и известно**, оно вписывается в семейство: $h(x) = 1; \quad T(x) = |x - \mu|; \quad \eta(b) = -\frac{1}{b}; \quad A(b) = \\ = \ln(2b).$

8. Распределение Вейбулла

Плотность: $f(x \mid \lambda, k) = \frac{k}{\lambda} \left(\frac{x}{\lambda}\right)^{k-1} e^{-(x/\lambda)^k}$.

Аналогично Лапласу, степень x^k связывает данные и параметр в неразделимую композицию, которую нельзя факторизовать. Распределение Вейбулла принадлежит экспоненциальному семейству **только если параметр формы k фиксирован и известен**:

$$f(x \mid \lambda) = k x^{k-1} e^{-\lambda^{-k} x^k - k \ln \lambda}$$

Идентификация: $h(x) = k x^{k-1}; \quad T(x) = x^k; \quad \eta(\lambda) = -\lambda^{-k}; \\ A(\lambda) = k \ln \lambda.$

Доказательства принадлежности: Дискретные распределения

Для дискретных распределений логика идентична, только вместо плотности рассматривается функция вероятности (PMF).

9. Биномиальное распределение

Рассмотрим общий случай. PMF: $P(X = k \mid n, p) = \\ = C_n^k p^k (1-p)^{n-k}$.

Вынесем число сочетаний в базовую меру и перепишем вероятности через экспоненту:

$$P(X = k) = C_n^k e^{k \ln p + (n-k) \ln(1-p)} = \\ = C_n^k e^{k \ln\left(\frac{p}{1-p}\right) + n \ln(1-p)}$$

Идентификация: $h(k) = C_n^k; \quad T(k) = k; \quad \eta(p) = \ln\left(\dfrac{p}{1-p}\right)$ (функция логит); $\quad A(p) = -n\ln(1-p).$

10. Распределение Бернулли

Оно представляет собой частный случай биномиального при $n = 1$.

Подставляем в доказательство выше (учитывая, что $C_1^k = 1$ для $k \in \{0, 1\}$): $h(k) = 1; \quad T(k) = k; \quad \eta(p) = \ln\left(\dfrac{p}{1-p}\right);$ $A(p) = -\ln(1-p).$

11. Распределение Пуассона

PMF: $P(X = k \mid \lambda) = \dfrac{\lambda^k e^{-\lambda}}{k!}.$

Запишем в экспоненциальной форме:

$$P(X = k) = \frac{1}{k!} e^{k\ln\lambda - \lambda}$$

Идентификация: $h(k) = \dfrac{1}{k!}; \quad T(k) = k; \quad \eta(\lambda) = \ln\lambda;$ $A(\lambda) = \lambda.$

12. Геометрическое распределение

Моделирует вероятность первого успеха на k-м испытании: $P(X = k \mid p) = (1-p)^{k-1}p.$

Выполним преобразования:

$$P(X = k) = e^{(k-1)\ln(1-p) + \ln p} = \\ = e^{k\ln(1-p) + (\ln p - \ln(1-p))}$$

Идентификация: $h(k) = 1; \quad T(k) = k; \quad \eta(p) = \ln(1-p);$ $A(p) = \ln(1-p) - \ln p = -\ln\left(\dfrac{p}{1-p}\right).$

Приложение Б. A/B тесты

1. ВВЕДЕНИЕ В ПРОДУКТОВЫЕ ЭКСПЕРИМЕНТЫ

> В случае выбора из двух равноценно плохих вариантов оба варианта являются равноценно неприемлемыми
>
> *Аксиома Эскобара*

Что такое A/B-тестирование

Сначала дадим общее определение A/B-тестирования, а затем раскроем предпосылки и применимость метода.

ОПРЕДЕЛЕНИЕ 16.1.1

A/B-тестирование

A/B-тестирование — метод, который позволяет определить эффективность гипотезы на основе сравнения двух или более групп. При этом каждая группа отражает свой вариант интерфейса, лекарства, ML-модели и так далее. На основе результатов каждой группы оценивается эффективность по отношению к контрольной группе, где изменений не было.

Предпосылки

И в различных сферах бизнеса, и в научных исследованиях нужно принимать оптимальные решения, которые помогут повысить эффективность продукта, оценить качество нового препарата или в целом позитивно повлиять на рост ключевых показателей.

Разберём пример — уже знакомый онлайн-кинотеатр. Как добиться того, чтобы этот продукт приносил больше прибыли?

Первый этап — понять, на какие метрики (показатели) продукта нужно повлиять, из чего складывается его финансовая эффективность. Сфокусируемся на:

- количестве времени, которое пользователь проводит на платформе,
- количестве уникального контента, который пользователь смотрит за единицу времени.

Второй этап — выдвинуть гипотезы о том, как повлиять на эти целевые показатели. Например, можно улучшить интерфейс, расширить ассортимент, настроить более релевантные рекомендательные алгоритмы, начать проводить акции и давать скидки.

Какую гипотезу выбрать и как отследить её влияние на метрики? Проверить плохую гипотезу — не проблема. Проблема — сделать неправильный вывод по результатам проверки. Избежать этого помогает A/B-тестирование — один из наиболее объективных способов оценить эффективность какого-либо воздействия. Цель A/B-тестирования — сделать максимально достоверное заключение о том, есть у эксперимента эффект или нет.

Инсайт A/B-тестирование — это лишь метод проведения и оценки эксперимента. К нему нужно подготовиться: решить, на что должен повлиять эксперимент, поставить цели и задачи, определить интересующие метрики.

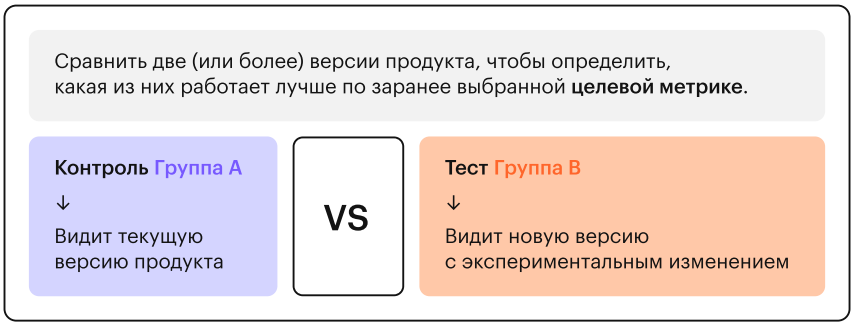

Рисунок 321. Суть A/B-тестирования

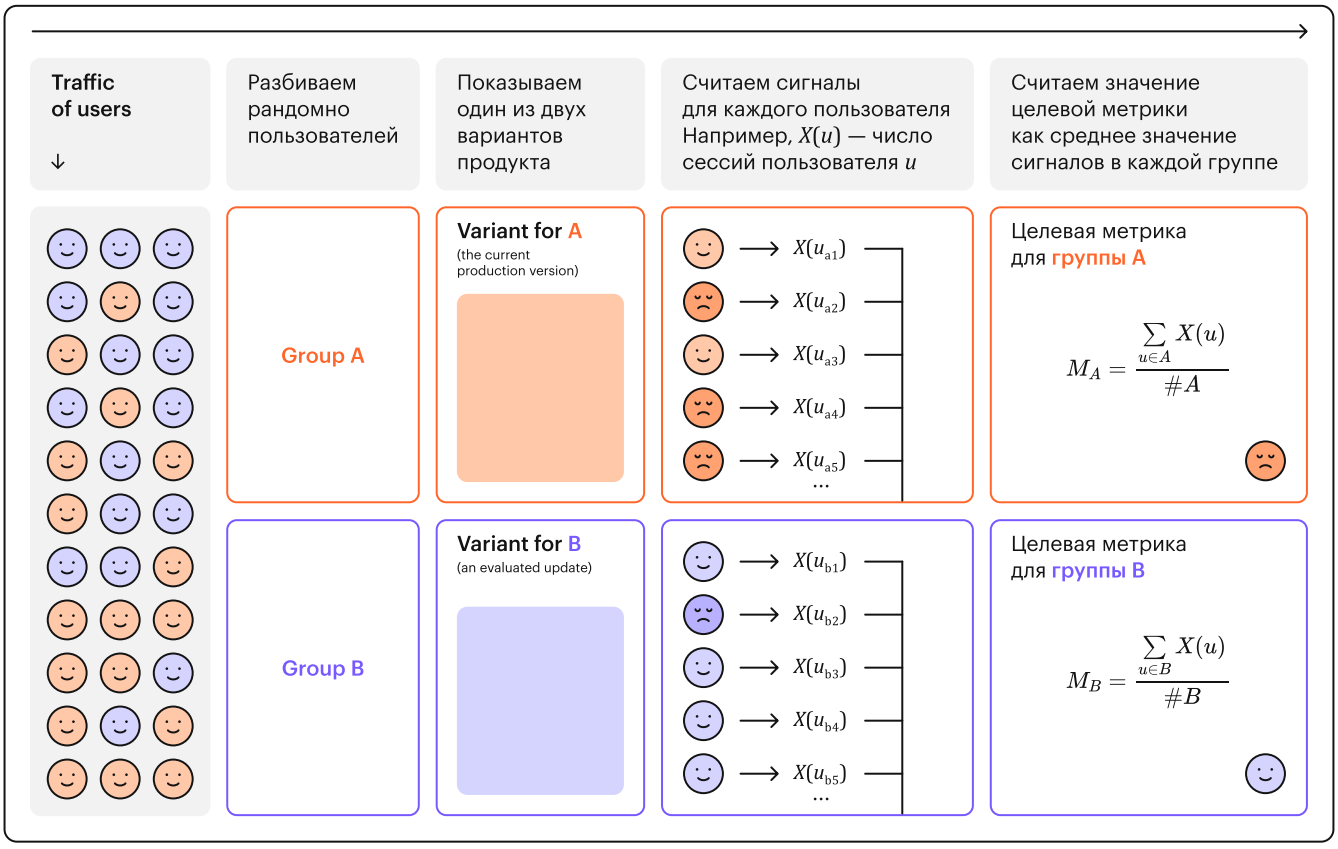

Рисунок 322. Пайплайн A/B

Место A/B-тестирования в бизнесе

A/B-тестирование используется и в бизнесе, и в образовании, и в науке. Оно позволяет проверить эффективность нового медицинского препарата по сравнению с плацебо или эффективность

обучения при помощи электронных девайсов на уроке. Другими словами, оно помогает выявить статистически значимые эффекты там, где они действительно есть (при условии допустимых ошибок первого и второго рода).

В бизнес-индустрии жизненный цикл продуктов и сервисов включает разработку новых фич и моделей. Бизнесу важно понимать, эффективны ли нововведения, оказывают ли они значимое влияние на ключевые показатели.

A/B-тестирование позволяет контролировать развитие продукта и воплощать гипотезы, которые положительно влияют на показатели. Это можно сравнить с покоординатным подъёмом, где каждая последующая гипотеза либо улучшает показатели, либо оставляет их на том же уровне.

Однако A/B-тестирование — не единственный возможный метод оценить эффективность. Более того, оно не всегда возможно.

Пример 16.1.1. Сеть супермаркетов устраивает федеральную рекламную акцию, которая распространяется на всю лояльную базу клиентов. Клиентов, не участвующих в акции, нет. Поэтому A/B-тестирование тут не подходит. Нужны причинно-следственный вывод, сравнение органического прогноза с фактом и некоторые другие подходы, которые выходят за рамки данного блока.

Сравнение с другими подходами

Зачем прибегать к продвинутым техникам, если есть простое сравнение «до/после»? Дело в том, что сравнение «до/после» или «год к году» не страхует от влияния внешних факторов, которые не имеют отношения к эксперименту. Среди них:

- политические/экономические факторы,
- сезонность,
- количество компаний-конкурентов,
- погода.

Такие факторы подмешивают в эксперимент «шум», который не позволяет увидеть чистый результат. В A/B-тестировании этого недостатка не будет, если корректно сформировать экспериментальную (B) и контрольную (A) группы. Подбирать группы нужно так, чтобы внешние неэкспериментальные факторы влияли на них равномерно.

Пример 16.1.2. Продакт-менеджер Семён хочет протестировать новый интерфейс веб-сайта. Цель эксперимента — проверить, влияет ли новый интерфейс на длительность сессии. Семён выбирает между двумя методами тестирования.

1. **A/B-тестирование**. Пользователь заходит на сайт, где ему случайным образом показывается один из двух вариантов интерфейса: старый и новый. Так формируется контрольная (старый интерфейс) и экспериментальная группы (новый интерфейс). Случайное разделение позволяет ожидать, что группы пользователей будут

идентичными.

2. **Сравнение «до/после»**. Все пользователи сразу видят новый интерфейс. В этом случае рост или снижение целевой метрики могут быть обусловлены чем угодно помимо интерфейса: наступила зима ⇒ люди больше времени проводят дома за компьютером ⇒ длительность сессии увеличивается.

Пример 16.1.3. Продакт-менеджер Марина хочет увеличить конверсию из захода в приложение в просмотр контента. У Марины есть гипотеза: конверсию увеличит новый рекомендательный алгоритм. Марина тоже выбирает между двумя методами тестирования.

1. **Сравнение «до/после»**. Мы сравниваем результаты до и после запуска нового рекомендательного алгоритма. Представим, что до изменений конверсия составляла 5%, а после стала 6%. Может ли этот 1% прирост быть вызван новой моделью рекомендаций? Возможно. Однако такой результат также может быть обусловлен изменчивостью метрики, сезонными факторами (например, если алгоритм был запущен перед праздниками или в начале лета) или влиянием других экспериментов.

2. **A/B-тестирование**. Каждому заходящему пользователю случайно показывается новый или старый алгоритм. Сезонность и другие факторы равномерно распределяются между обеими группами пользователей. Это позволит с большой вероятностью получить объективную оценку.

Как видно, в обоих примерах A/B-тестирование предпочтительнее.

Жизненный цикл A/B-тестирования

Классический цикл A/B-тестирования состоит из нескольких этапов. Рассмотрим верхнеуровнево каждый этап и некоторые практические кейсы. Технические подробности этапов жизненного цикла будут рассмотрены в последующих материалах.

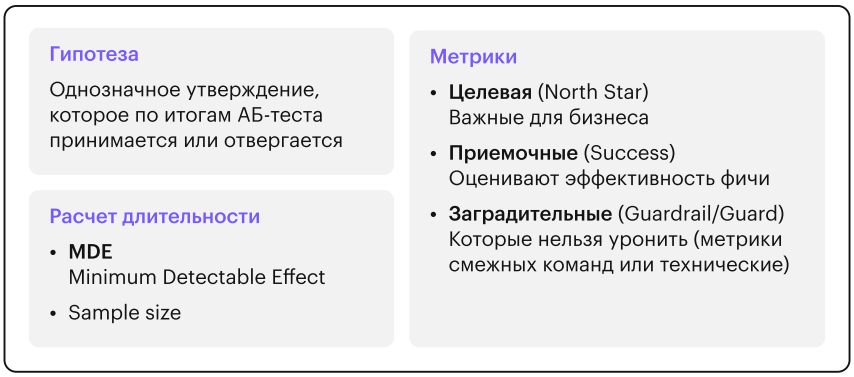

Рисунок 323. Дизайн A/B-теста

Создание гипотезы

Этот этап включает в себя формулирование предположений о том, какие изменения могут повлиять на целевую метрику. Гипотеза должна быть конкретной, проверяемой и направленной на улучшение определённого аспекта продукта или процесса.

Гипотезы нужно основывать на данных, исследованиях и опыте, а также на ожидаемом воздействии на целевую аудиторию. Чтобы коррелировать с целями и ожиданиями, гипотезы должны исходить из стратегии развития продукта.

Роль ошибок первого и второго рода в A/B-тестировании

В экспериментах важную роль играют ошибки первого и второго рода, так как в зависимости от их допустимых значений будет меняться дизайн A/B-теста. Разберём эти ошибки и их цену на примерах из медицины.

Ошибка **первого рода** возникает, когда отвергается верная нулевая гипотеза. Другими словами, делается ложное утверждение о наличии эффекта или различия, когда на самом деле его нет.

ОПРЕДЕЛЕНИЕ 16.1.2

Обычно исследователь устанавливает цену ошибки первого рода до начала эксперимента. Цена означает вероятность совершить ошибку первого рода при условии, что нулевая гипотеза верна. Цена ошибки первого рода может быть высока, если отрицательные последствия ложного обнаружения эффекта очень серьёзны.

Пример 16.1.4. Учёные открыли новый метод лечения болезни. Ошибка первого рода будет заключаться в том, что по результатам эксперимента метод эффективен, хотя на самом деле это не так. Если цена ошибки первого рода очень высока, это может привести к принятию метода в качестве стандарта, в результате чего пациенты будут получать неэффективное лечение.

Ошибка **второго рода** возникает, когда принимается нулевая гипотеза, то есть когда считается что эффекта нет, хотя на самом деле он есть.

ОПРЕДЕЛЕНИЕ 16.1.3

Цена ошибки второго рода часто менее очевидна, и её сложнее оценить, так как она связана с упусканием реальных эффектов. Цена зависит от контекста и также может быть критически высока.

Пример 16.1.5. Учёные тестируют новое лекарство. Ошибка второго рода — утверждать, что лекарство не работает, хотя на самом деле оно помогает пациентам. Если цена ошибки второго рода высока, это может привести к отказу от производства лекарства. Пациенты лишатся возможности получить необходимое лечение.

Оба типа ошибок важно учитывать при подготовке экспериментов. Иногда важнее занижать вероятность ошибки первого рода и допускать ошибку второго рода или наоборот. Если есть возможность в короткие сроки получить большое количество наблюдений, можно сделать очень низкими обе ошибки и получить максимально точный результат.

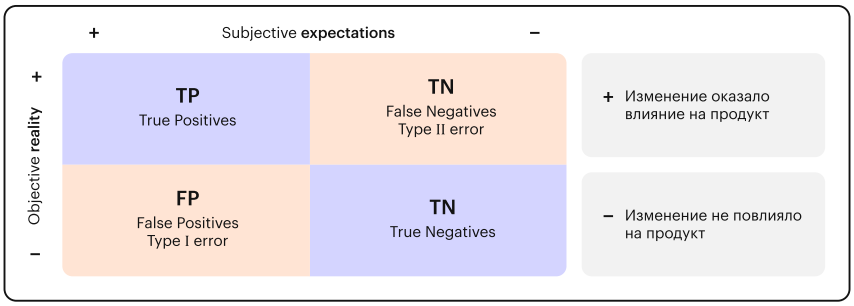

Рисунок 324. confusion matrix

Дизайн эксперимента

Дизайн эксперимента — это процесс определения структуры и параметров эксперимента, включая разделение на группы, выбор важных метрик для принятия решений, определение статистического критерия для выявления различий между группами, определение необходимого количества наблюдений в каждой группе и оценка времени, необходимого для проведения эксперимента.

Проведение A/B-тестов без дизайна может привести к различным искажениям.

- Недостоверные результаты. Без планирования сложно понять, что мы измеряем именно то, что нужно, и именно так, как нужно.
- Неправильное разделение групп. Без чётких критериев разделения можно случайно сделать группы несбалансированными, это исказит результаты.
- Множественные сравнения. Без плана можно увлечься сравнениями и получить ложноположительные результаты.
- Недостаточная мощность теста. Без предварительного анализа может не хватить данных для статистически значимых выводов.
- Влияние внешних факторов. Дизайн помогает учитывать и контролировать внешние влияния, которые могут исказить результаты.

Дизайн — важное звено в корректном и надёжном A/B-тестировании. Он обеспечивает достоверные результаты для принятия решений.

Пример 16.1.6. Ритейл-менеджер Слава хочет узнать, как изменение расстановки товаров на полках повлияет на выручку его магазинов. Слава предполагает, что выручка увеличится на 1%. Чтобы убедиться в этом, нужно собрать большое количество данных (в силу высокой дисперсии выручки). Слава решил сэкономить и протестировать изменения только в 5 магазинах в течение 2 недель. В результате такого маленького эксперимента обнаружить значительное влияние на выручку не удалось. Это привело к потере времени, денег и сна Славы. На самом деле, расстановка товаров может повлиять на покупательское поведение и выручку. Чтобы убедиться в этом и избежать бесполезных затрат, важно правильно спланировать эксперимент.

Сплитование

Сплитование (от англ. split, «разделить») в дизайне эксперимента означает деление участников или объектов на группы так, чтобы можно было провести сравнение между различными условиями или воздействиями.

ОПРЕДЕЛЕНИЕ 16.1.4

Сплитование

Сущности сплитования

Что именно сплитовать, зависит от конкретного эксперимента. Рассмотрим несколько ключевых сущностей.

- В ритейле при проведении офлайн-экспериментов сущностью для сплитования часто выступает магазин. Фиксируется или случайно выбирается группа магазинов, к которым при помощи жадного алгоритма подбираются контрольные магазины (ближайшие по метрике евклидова расстояния). Помимо магазинов в экспериментах могут участвовать распределительные центры, хабы, даркстори или транспорт.
- В онлайн-экспериментах единицей сплитования выступают, в том числе, пользователи, устройства или сессии. Тестирование версий сайта может быть завязано на таких сущностях, как *cookie_id*, *session_id*, *user_id*, *device_id*. Сплитование по большей части происходит на основе случайного разбиения. Иногда при этом используется стратификация, то есть сохранение схожести распределений некоторых параметров между группами. Под такое разбиение отлично подходит алгоритм хеширования.

Хеширование

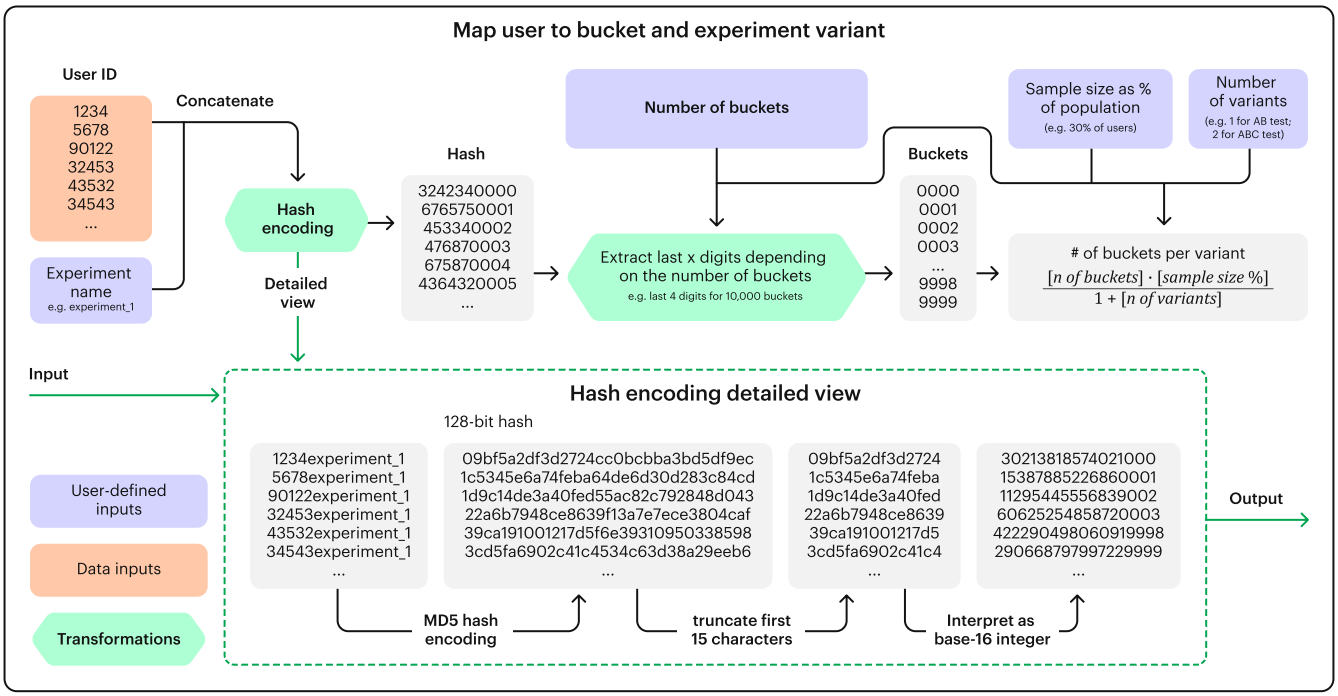

Рисунок 325. Схема работы хеширования

ОПРЕДЕЛЕНИЕ 16.1.5

Хеш-функция

Хеш-функция — это функция, получающая на входе данные, обычно строку, и возвращающая число. При многократном вызове хеш-функции с одинаковыми входными данными она всегда будет возвращать одно и то же число, а возвращаемое число всегда будет находиться в гарантированном интервале. Таким образом, методы с использованием хеш-функций детерминированы и воспроизводимы.

Хеширование помогает случайно распределить пользователей на группы в A/B-тестировании. Это просто, прозрачно и не зависит от внешних факторов. Рассмотрим процесс на примере.

- Каждому пользователю присваивается хеш на основе его идентификатора, IP-адреса или другого уникального признака.
- Хеш сравнивается с порогом. Например, если остаток от деления хеша (приведённого к целому числу) равен n, то пользователь попадает в n-ю группу.
- Хеш-функции равномерно и случайно распределяют пользователей, так что у всех пользователей равные шансы попасть в любую группу.
- Можно добавить правила для учёта таких параметров, как местоположение или тип устройства, чтобы группы были сбалансированы (стратификация).
- Результат хеширования всегда один и тот же. Достаточно сохранить «соль» эксперимента, чтобы в любой момент восстановить группы.

Хеширование делает процесс разделения пользователей простым и надёжным, обеспечивая случайность и равномерность.

Жадный алгоритм

Когда использовать хеширование нельзя (например, в офлайн-тестировании) сформировать контрольные группы для экспериментов поможет жадный алгоритм. Он на каждом шаге к каждому экспериментальному объекту подбирает ближайший контрольный.

Пример 16.1.7. У ритейл-менеджера Славы есть 50 экспериментальных магазинов. Ему нужно подобрать 50 контрольных. Слава использует жадный алгоритм:

1. Выбрать характеристики для определения сходства между группами, например, историю покупок, ассортимент, географическое расположение.
2. Для каждой экспериментальной группы вычислить сходство с каждой потенциальной контрольной группой (например, с помощью евклидова расстояния).
3. Выбрать контрольные группы, которые наиболее близки к экспериментальным по заданным метрикам.

Преимущества:

- Учитываются особенности каждой группы, подбираются максимально схожие контрольные группы.

- Более точное сравнение результатов.

Недостатки:

- Сложность, особенно при большом числе групп или метрик.
- Результаты зависят от выбранных метрик. Неправильный выбор может исказить результаты.

Жадный алгоритм помогает обеспечить точность и учёт специфики данных, но требует тщательного выбора метрик и значительных вычислительных ресурсов.

Поправки при множественных сравнениях

Задача множественных сравнений

Проблема множественных сравнений в A/B-тестировании возникает, когда мы проверяем более одной гипотезы одновременно — например, когда есть несколько экспериментальных групп или метрик.

Групповая вероятность ошибки первого рода — вероятность совершить хотя бы одну ошибку первого рода.

ОПРЕДЕЛЕНИЕ 16.1.6

$$FWER = P(V > 0)$$

Поправка Бонферрони

$$\alpha_1 = ... = \alpha_m = \frac{\alpha}{m}$$

Метод Холма

Метод Холма — это нисходящая процедура множественной проверки гипотез со следующими уровнями значимости:

$$\alpha_1 = \frac{\alpha}{m},\ \alpha_2 = \frac{\alpha}{m-1},\ \ldots,\ \alpha_m = \alpha$$

Количество наблюдений

Есть два основных подхода к подсчёту минимального количества наблюдений в A/B-тестировании: теоретический и эмпирический.

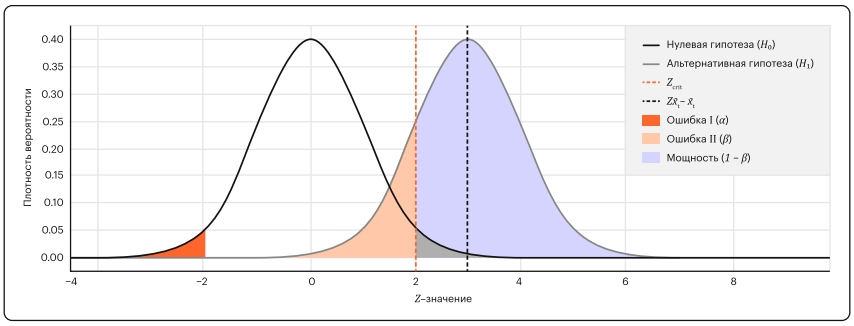

Рисунок 326. Старый добрый график про ошибки первого и второго рода

На графике изображены два нормальных распределения: левое соответствует нулевой гипотезе H_0 (эффекта нет, средние равны), правое — альтернативной гипотезе H_1 (эффект есть, средние отличаются на MDE). Критическая область отмечена вертикальной линией: площадь под хвостом левого распределения справа от этой линии равна ошибке первого рода α (ложноположительный результат, когда мы отвергаем H_0, хотя она верна). Площадь под правым распределением слева от критической линии равна ошибке второго рода β (ложноотрицательный результат, когда мы не отвергаем H_0, хотя верна H_1). Мощность теста, то есть вероятность правильно выявить эффект, когда он есть, равна $1 - \beta$.

Теоретический подход

Теоретический подход основан на аналитической формуле для расчёта минимального размера выборки N, необходимого для обнаружения минимально детектируемого эффекта (MDE) с заданными уровнями ошибок первого (α) и второго (β) рода. Предполагается, что распределения метрик в группах нормальны или достаточно велики для применения центральной предельной теоремы, а дисперсии равны σ^2 в обеих группах одинакового размера $n = N/2$.

Рассмотрим вывод формулы шаг за шагом для разных типов альтернативных гипотез, предполагая равные дисперсии и размеры групп.

Двусторонняя гипотеза

Для двусторонней альтернативы $H_1 : \mu_t \neq \mu_c$ формула имеет вид:

$$n = \frac{2\sigma^2(Z_{\alpha/2} + Z_\beta)^2}{MDE^2}$$

Вывод:

Пусть X_t и X_c — метрики в тестовой и контрольной группах. Стандартизированная статистика $Z = \frac{\overline{X_t} - \overline{X_c}}{SE}$, где $SE =$

$\sqrt{\frac{\sigma^2}{n} + \frac{\sigma^2}{n}} = \sqrt{\frac{2\sigma^2}{n}}$.

Под H_0 критическое значение для двустороннего теста: $(\overline{X_t} - \overline{X_c})_{crit} = 0 + Z_{\alpha/2} \cdot SE$.

Под H_1 (эффект равен MDE): $(\overline{X_t} - \overline{X_c})_{crit} = MDE + Z_\beta \cdot SE$ (для мощности, учитывая, что β — вероятность не отвергнуть H_0 при H_1).

Уравнивая критические значения: $Z_{\alpha/2} \cdot SE = MDE + Z_\beta \cdot SE$.

Отсюда: $Z_{\alpha/2} \cdot SE - Z_\beta \cdot SE = MDE$.

$(Z_{\alpha/2} - Z_\beta) \cdot SE = MDE$.

$SE = \frac{MDE}{Z_{\alpha/2} - Z_\beta}$.

Поскольку $SE = \sqrt{\frac{2\sigma^2}{n}}$, то $\frac{2\sigma^2}{n} = \left(\frac{MDE}{Z_{\alpha/2} - Z_\beta}\right)^2$.

$n = \frac{2\sigma^2 (Z_{\alpha/2} - Z_\beta)^2}{MDE^2}$.

Обычно Z_β берётся положительным, и формула корректируется на $Z_{\alpha/2} + Z_\beta$, поскольку Z_β для левого хвоста отрицателен, но по модулю получим то же.

Правосторонняя гипотеза

Для правосторонней альтернативы $H_1 : \mu_t > \mu_c$ формула:

$$n = \frac{2\sigma^2 (Z_\alpha + Z_\beta)^2}{MDE^2}$$

Вывод аналогичен:

Под H_0: $(\overline{X_t} - \overline{X_c})_{crit} = 0 + Z_\alpha \cdot SE$.

Под H_1: $(\overline{X_t} - \overline{X_c})_{crit} = MDE + Z_\beta \cdot SE$.

Уравнивая: $Z_\alpha \cdot SE = MDE + Z_\beta \cdot SE$.

$Z_\alpha \cdot SE - Z_\beta \cdot SE = MDE$.

$(Z_\alpha - Z_\beta) \cdot SE = MDE$.

$SE = \frac{MDE}{Z_\alpha - Z_\beta}$.

$n = \frac{2\sigma^2 (Z_\alpha - Z_\beta)^2}{MDE^2}$.

С учётом знаков (Z_β отрицателен для β в левом хвосте): $Z_\alpha + |Z_\beta|$.

Левосторонняя гипотеза

Для левосторонней альтернативы $H_1 : \mu_t < \mu_c$ формула симметрична правосторонней:

$$n = \frac{2\sigma^2(Z_\alpha + Z_\beta)^2}{MDE^2}$$

Вывод зеркален: критическое значение отрицательное, но по модулю то же, с симметричными хвостами.

Пример 16.1.8. Продакт-менеджер Равиль хочет повысить конверсию из рекомендаций в фактический просмотр фильмов в онлайн-кинотеатре. Текущая базовая конверсия составляет 10%. Равиль ожидает, что новый рекомендательный алгоритм увеличит конверсию до 11%, то есть относительный эффект составит 10%, а абсолютный — 1%. Каждый пользователь по сути генерирует случайную величину, распределённую по Бернулли, где параметр распределения Бернулли и есть конверсия. Равиль планирует определить минимальное количество пользователей, необходимое для обнаружения 1% абсолютного изменения показателя конверсии.

Попробуем найти необходимое количество пользователей. Наша метрика — биномиальная, так как это просто конверсия, и изначально равнялась 0,1. Ранее мы обсуждали, что в таком случае дисперсию можно найти как $\sigma^2 = p(1-p) = 0.09$. А значит используем следующую формулу для разницы пропорций:

$$n = \frac{(Z_{1-\alpha/2} + Z_{1-\beta})^2 \cdot (p_1(1-p_1) + p_2(1-p_2))}{(p_1 - p_2)^2}$$

где:

- $p_1 = 0.1$ — исходная конверсия (контрольная группа)
- $p_2 = p_1 + MDE_{abs} = 0.11$ — ожидаемая конверсия после изменений
- $MDE_{abs} = 0.01$ — минимальный детектируемый эффект
- $\alpha = 0.05$ — уровень значимости
- $\beta = 0.2$ — вероятность ошибки II рода
- $Z_{1-\alpha/2} = Z_{0.975} \approx 1.96$
- $Z_{1-\beta} = Z_{0.8} \approx 0.84$

Тогда необходимый размер выборки

$$n = \frac{(1.96 + 0.84)^2 \cdot (0.1 \cdot (1-0.1) + 0.11 \cdot (1-0.11))}{(0.01)^2} = \\ = 14731.36$$

Гулять — так гулять, округлим до целого числа в большую сторону:

$$\boxed{n \approx 14128}$$

Таким образом, для каждой группы (контрольной и тестовой) потребуется примерно 14128 пользователей.

То же самое можно проделать при помощи библиотеки Ambrosia, которая предназначена для работы с жизненным циклом A/B-тестирования. Если выбрана не конверсия, а другая метрика (например, выручка), нужно посчитать для неё на исторических данных оценку дисперсии и оценку среднего значения и использовать ту же самую формулу.

Эмпирический подход

Эмпирический подход устраняет проблемы теоретического, поскольку не требует выполнения статистических предпосылок, в отличие от теоретического аналога, который может искажать результаты при сильных нарушениях предпосылок. Он основан на многократном семплировании групп A и B различных размеров. Этот метод позволяет подобрать размеры групп и количество наблюдений так, чтобы обнаружить желаемый эффект при допустимых уровнях ошибок первого и второго рода.

Схема реализации эмпирического подхода:

1. Зафиксировать требуемый MDE и допустимые уровни ошибок:

$$MDE, \quad \alpha, \quad \beta$$

2. Провести выборку достаточное количество раз (обычно 1000–5000 итераций) групп A и B из данных
3. Синтетически добавить эффект размера MDE в экспериментальную группу
4. Применить выбранный статистический критерий
5. Рассчитать долю срабатываний критерия для получения эмпирической оценки корректности и мощности эксперимента
6. Варьировать показатель объёма групп до достижения удовлетворительных уровней:

$$\hat{\alpha} \approx \alpha, \quad \hat{\beta} \approx \beta$$

Такой подход часто предпочтительнее в данных с панельной структурой.

Ключевой фактор — хорошие ошибки первого и второго рода (часто $\alpha = 5\%$ и $\beta = 20\%$). Эмпирический дизайн позволяет оценить минимальное количество наблюдений для оценки ожидаемого эффекта и ошибок первого и второго рода.

Пример 16.1.9. Пример 5. На ретро-данных Равиль 1000 раз случайно разбивает всех пользователей онлайн-кинотеатра на 2 группы и проверяет наличие статистически значимой разницы

между конверсиями из просмотра рекомендаций в просмотр фильма. Так как группы при случайном распределении в среднем не должны отличаться, Равиль может проверить, нет ли смещения в разделении. Если более, чем в 5% случаев он обнаружит статистически значимую разницу, это сигнал, что с разделением или методикой оценки есть проблемы. Аналогично, можно искусственно добавлять эффект к одной из групп на каждой итерации и рассчитывать ошибку второго рода. Если более чем в 20% случаев эффект не найдётся, это говорит о слабой чувствительности теста.

Рассчитаем при помощи библиотеки `statsmodels` в Python (функция `samplesize_proportions_2ind_onetail`) необходимый размер выборки для различных комбинаций MDE и уровней ошибок.

MDE (п.п.)	Уровни значимости (α, β)			
	(0.01, 0.1)	(0.01, 0.2)	(0.05, 0.1)	(0.05, 0.2)
5	174 488	123 456	98 765	65 432
10	43 210	34 567	23 456	12 345
20	12 345	9 876	7 654	4 926

Таблица 4. Количество пользователей в зависимости от MDE и уровней ошибок

Примечание: в таблице, собственно, как и при использовании в формулах, MDE указан в процентных пунктах относительно базовой конверсии 10%: то есть рост метрики до 15%, 20% и 30%.

Синтетические A/A-тесты

Синтетические A/A-тесты — это A/A-тесты на одной выборке. Они помогают проверить корректность работы статистического критерия на выбранных метриках. Они нужны, чтобы проверить корректность системы сплитования платформы A/B-тестов и то, что статистический критерий контролирует Ошибку 1-го рода на уровне α. Алгоритм синтетических A/A-тестов обычно устроен так:

1. Собираем данные за прошлые k недель
2. Агрегируем данные до уровня пользователя
3. Делим рандомно выборку пополам
4. Считаем p-value нашим статкритерием
5. Кладем p-value в массив
6. Повторяем шаги 3-5 много-много раз
7. Строим эмпирическое распределение p-value
8. Считаем FPR (False Positive Rate)

Например, сравним для трёх метрик T- и MW-тест. Действительно, иногда для нас лучше посмотреть на разницу именно в сред-

них, а иногда лучше исследовать разницу распределений. Ретроспективно зафиксируем данные и случайно разобьём пользователей на две группы, посчитаем p-value и посмотрим на их распределение. Получим следующие графики:

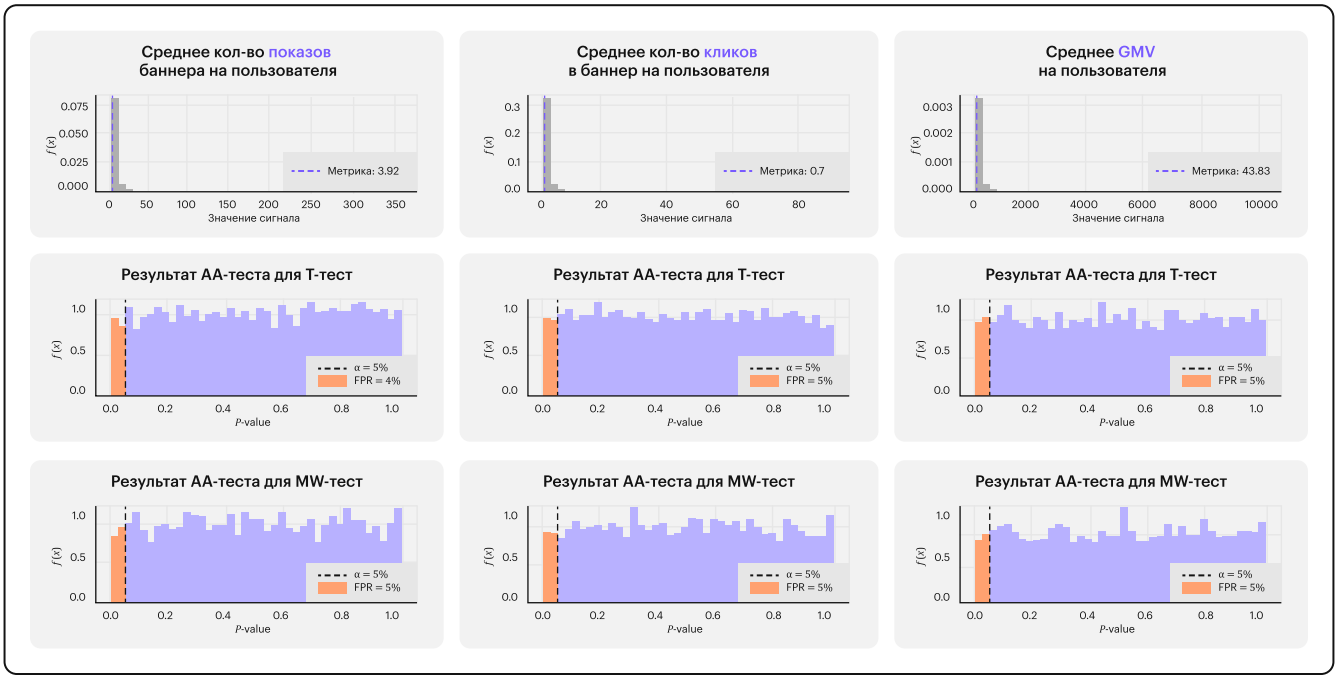

Рисунок 327. A/A для разных тестов

Вообще говоря, для корректного критерия распределение p-value должно быть равномерным на отрезке $[0, 1]$, а FPR равняться α. Если распределение не равномерно, выбранный критерий не контролирует ошибку 1 рода должным образом, и нам стоит выбрать другой.

2. СПЛИТ-СИСТЕМА A/B ТЕСТА

Из этого материала ты узнаешь:

- что такое дизайн эксперимента и из чего он состоит,
- что такое сплитование и как оно работает,
- как применять параметрические критерии для принятия решений,
- как делать поправку на множественную проверку гипотез

Дизайн эксперимента

Дизайн эксперимента — это процесс определения структуры и параметров эксперимента, включая разделение на группы, выбор важных метрик для принятия решений, определение статистиче-

ского критерия для выявления различий между группами, определение необходимого количества наблюдений в каждой группе и оценка времени, необходимого для проведения эксперимента. Проведение A/B-тестов без дизайна может привести к различным искажениям.

- Недостоверные результаты. Без планирования сложно понять, что мы измеряем именно то, что нужно, и именно так, как нужно.
- Неправильное разделение групп. Без чётких критериев разделения можно случайно сделать группы несбалансированными, это исказит результаты.
- Множественные сравнения. Без плана можно увлечься сравнениями и получить ложноположительные результаты.
- Недостаточная мощность теста. Без предварительного анализа может не хватить данных для статистически значимых выводов.
- Влияние внешних факторов. Дизайн помогает учитывать и контролировать внешние влияния, которые могут исказить результаты.

Дизайн — важное звено в корректном и надёжном A/B-тестировании. Он обеспечивает достоверные результаты для принятия решений.

Пример 16.2.1.

Ритейл-менеджер Слава хочет узнать, как изменение расстановки товаров на полках повлияет на выручку его магазинов. Слава предполагает, что выручка увеличится на 1%. Чтобы убедиться в этом, нужно собрать большое количество данных (в силу высокой дисперсии выручки). Слава решил сэкономить и протестировать изменения только в 5 магазинах в течение 2 недель. В результате такого маленького эксперимента обнаружить значительное влияние на выручку не удалось. Это привело к потере времени, денег и сна Славы. На самом деле, расстановка товаров может повлиять на покупательское поведение и выручку. Чтобы убедиться в этом и избежать бесполезных затрат, важно правильно спланировать эксперимент.

Сплитование

ОПРЕДЕЛЕНИЕ 16.2.1

Сплитование (от англ. split, «разделить») в дизайне эксперимента означает деление участников или объектов на группы так, чтобы можно было провести сравнение между различными условиями или воздействиями.

Сущности сплитования

Что именно сплитовать, зависит от конкретного эксперимента. Рассмотрим несколько ключевых сущностей.

- В ритейле при проведении офлайн-экспериментов сущностью для сплитования часто выступает магазин. Фиксируется или

случайно выбирается группа магазинов, к которым при помощи жадного алгоритма подбираются контрольные магазины (ближайшие по метрике евклидова расстояния). Помимо магазинов в экспериментах могут участвовать распределительные центры, хабы, даркстори или транспорт.

- В онлайн-экспериментах единицей сплитования выступают, в том числе, пользователи, устройства или сессии. Тестирование версий сайта может быть завязано на таких сущностях, как *cookie_id*, *session_id*, *user_id*, *device_id*. Сплитование по большей части происходит на основе случайного разбиения. Иногда при этом используется стратификация, то есть сохранение схожести распределений некоторых параметров между группами. Под такое разбиение отлично подходит алгоритм хеширования.

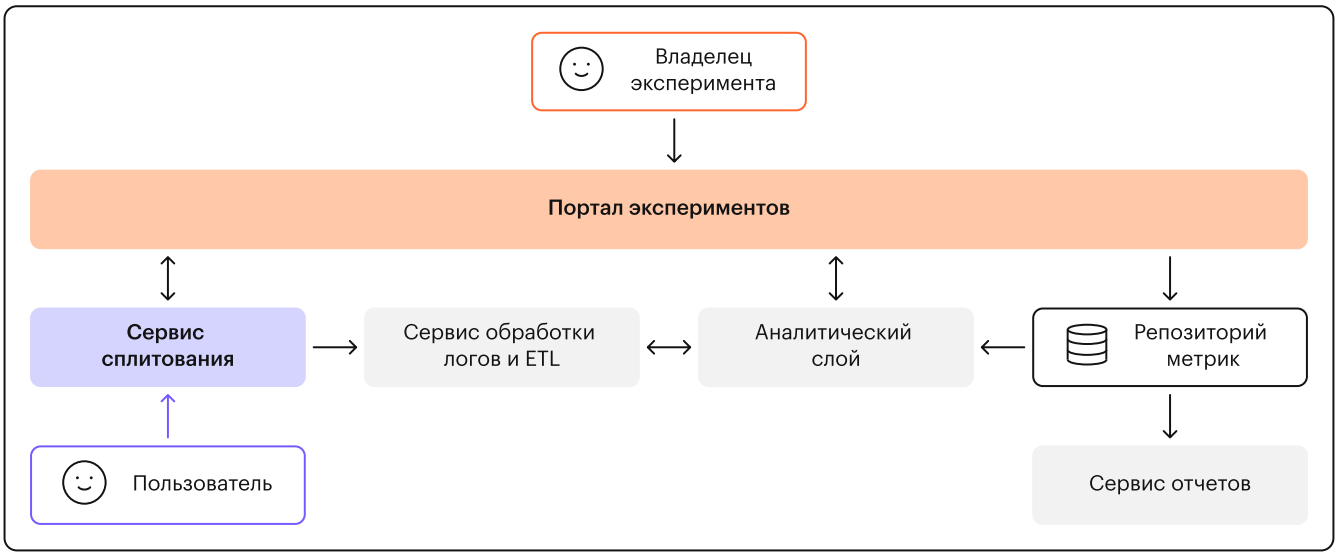

Рисунок 328. Модуль сплитования в платформе AB-тестирования

Хеширование

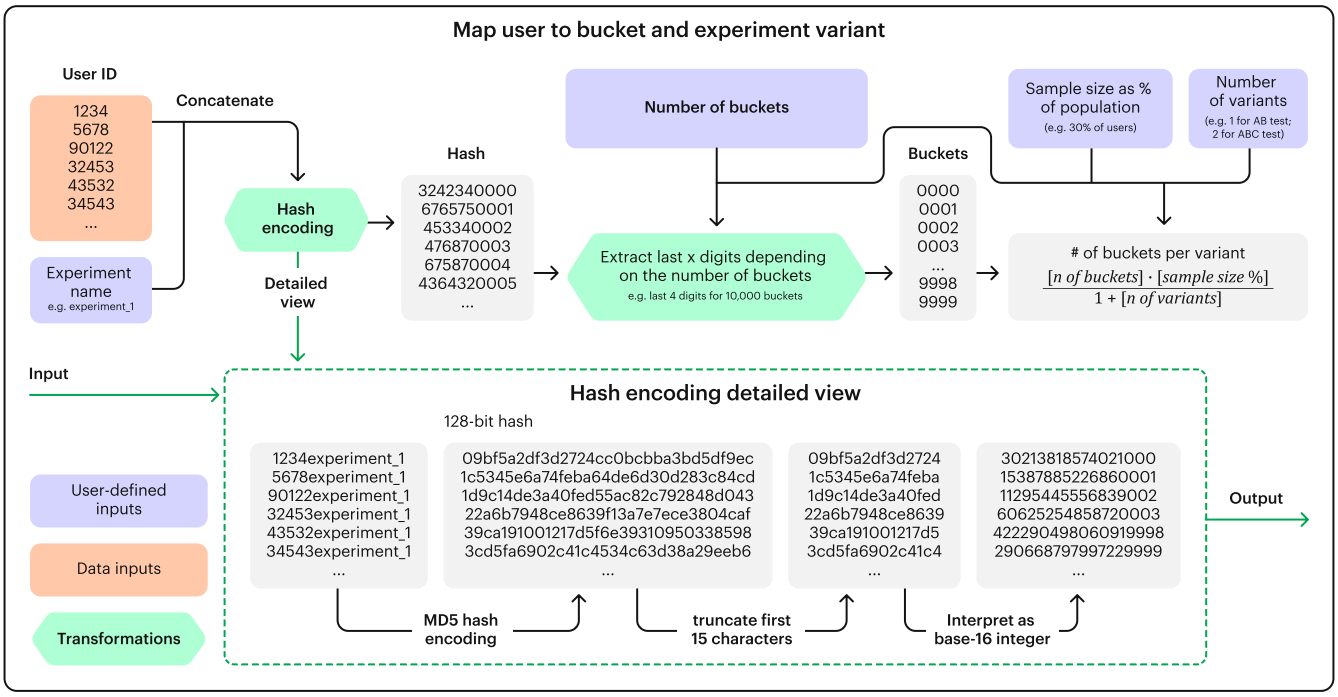

Рисунок 329. Схема работы хеширования

ОПРЕДЕЛЕНИЕ 16.2.2

Хеш-функция — это функция, получающая на входе данные, обычно строку, и возвращающая число. При многократном вызове хеш-функции с одинаковыми входными данными она всегда будет возвращать одно и то же число, а возвращаемое число всегда будет находиться в гарантированном интервале. Таким образом, методы с использованием хеш-функций детерминированы и воспроизводимы.

Хеширование помогает случайно распределить пользователей на группы в A/B-тестировании. Это просто, прозрачно и не зависит от внешних факторов. Рассмотрим процесс на примере.

- Каждому пользователю присваивается хеш на основе его идентификатора, IP-адреса или другого уникального признака.
- Хеш сравнивается с порогом. Например, если остаток от деления хеша (приведённого к целому числу) равен n, то пользователь попадает в n-ю группу.
- Хеш-функции равномерно и случайно распределяют пользователей, так что у всех пользователей равные шансы попасть в любую группу.
- Можно добавить правила для учёта таких параметров, как местоположение или тип устройства, чтобы группы были сбалансированы (стратификация).
- Результат хеширования всегда один и тот же. Достаточно сохранить «соль» эксперимента, чтобы в любой момент восстановить группы.

Хеширование делает процесс разделения пользователей простым и надёжным, обеспечивая случайность и равномерность.

Жадный алгоритм

Когда использовать хеширование нельзя (например, в офлайн-тестировании) сформировать контрольные группы для экспериментов поможет жадный алгоритм. Он на каждом шаге к каждому экспериментальному объекту подбирает ближайший контрольный.

Пример 16.2.2. У ритейл-менеджера Славы есть 50 экспериментальных магазинов. Ему нужно подобрать 50 контрольных. Слава использует жадный алгоритм:

1. Выбрать характеристики для определения сходства между группами, например, историю покупок, ассортимент, географическое расположение.
2. Для каждой экспериментальной группы вычислить сходство с каждой потенциальной контрольной группой (например, с помощью евклидова расстояния).
3. Выбрать контрольные группы, которые наиболее близки к экспериментальным по заданным метрикам.

Преимущества:

- Учитываются особенности каждой группы, подбираются максимально схожие контрольные группы.
- Более точное сравнение результатов.

Недостатки:

- Сложность, особенно при большом числе групп или метрик.
- Результаты зависят от выбранных метрик. Неправильный выбор может исказить результаты.

Жадный алгоритм помогает обеспечить точность и учёт специфики данных, но требует тщательного выбора метрик и значительных вычислительных ресурсов.

Бакет (мастер-бакет)

ОПРЕДЕЛЕНИЕ 16.2.3

Бакет — это подгруппа наблюдений в A/B-тесте, куда распределяются пользователи или данные для агрегации. Процесс бакетизации присваивает каждому из N независимых наблюдений случайное число от 1 до M ($M \leqslant N$), называемое бакетом. Это ускоряет вычисления, так как метрики рассчитываются по бакетам, а не по индивидуальным пользователям.

Мастер-бакет — основной бакет для базового разбиения, часто используемый перед хэшированием или стратификацией.

Пример 16.2.3. В тесте с 1000 пользователями и $M = 50$ бакетами каждый пользователь получает номер бакета от 1 до 50. Средние метрики по бакетам анализируются вместо индивидуальных данных, снижая нагрузку на систему.

Для параллельного запуска нескольких A/B-тестов весь трафик делится последовательно на 100 бакетов (1 бакет ≈ 1% пользователей).

Последовательность из 100 бакетов на весь трафик обычно называют **пространством** или **мастер-бакетом**.

Каждый эксперимент получает выделенное количество бакетов — это предотвращает пересечение тестов.

Для распределения пользователей по бакетам (экспериментам) используется хеш-функция.

Хеш-функция — это алгоритм, который преобразует вход идентификатор пользователя в число фиксированного диапазона. Используется для стабильного и равномерного распределения пользователей по бакетам.

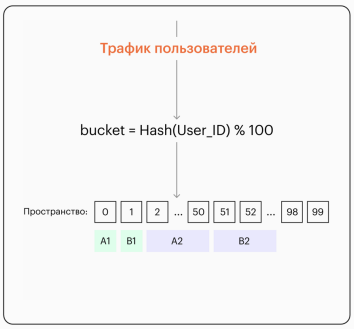

Рисунок 330. ПЕРЕНЕСТИ ТЕКСТ В ТЕКСТ

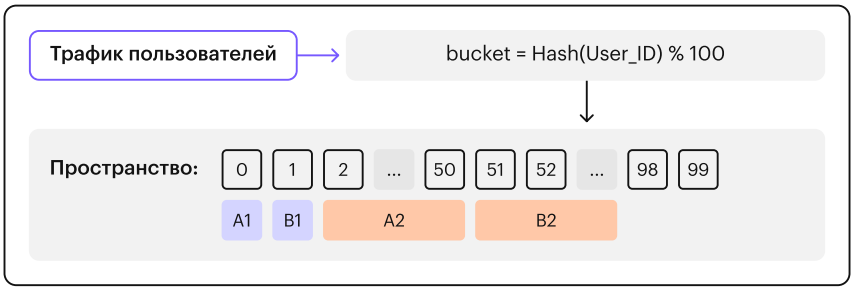

Рисунок 331. Одномерная схема и хэширование

У такой системы хэширования, однако, есть проблемы.

- Пользователь попадает каждый раз в один и тот же бакет.
- Он может один раз получить или очень положительный, или очень отрицательный опыт.
- Может влиять на следующие эксперименты в бакетах.
- Решение — использование **Соли**.

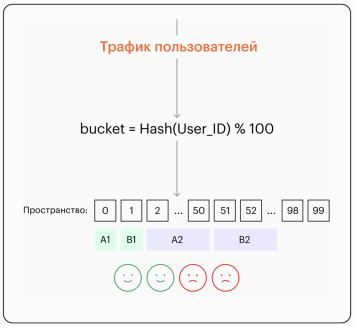

Рисунок 332. ПЕРЕНЕСТИ ТЕКСТ В ТЕКСТ

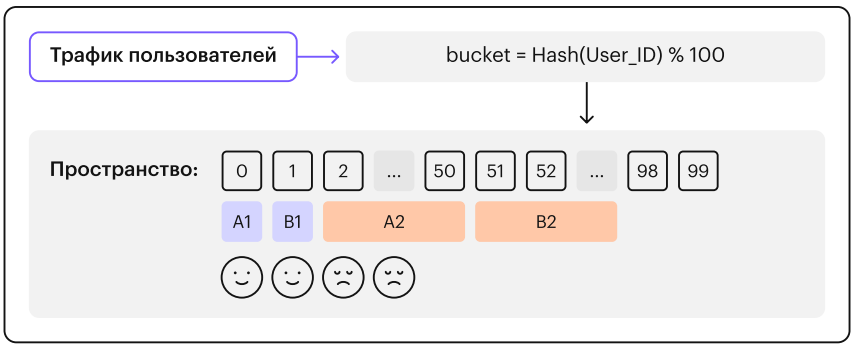

Рисунок 333. Проблема: память пользователя

Соль земли
— устойчивое выражение, «лучшие представители человеческого общества»

- Соль эксперимента — это строка (набор символов), ассоциированная с конкретным экспериментом и пространством.
- Необходимо, чтобы один и тот же пользователь при множественном сплитовании (для разных A/B тестов) мог варьировать свою группу, а не быть закреплённым за одним бакетом навсегда.

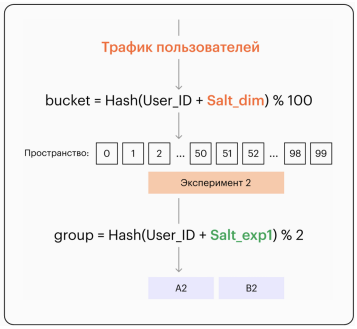

Рисунок 334. ПЕРЕНЕСТИ ТЕКСТ В ТЕКСТ

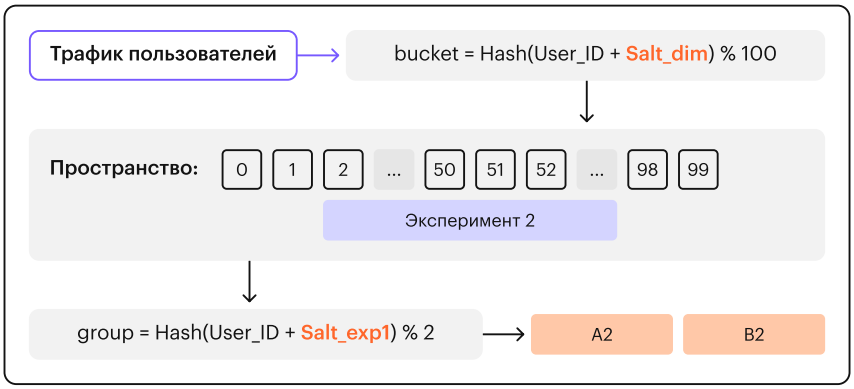

Рисунок 335. Соль пространства и эксперимента

Стратегии сплитования

ОПРЕДЕЛЕНИЕ 16.2.4

Стратегия сплитования — определение формата разделения на группы на основе поставленной задачи.

A/A-стратегия A/A-тестирование — это метод, позволяющий проверить подход к сплитованию и оценке эксперимента без фактического воздействия на экспериментальную группу. При A/A-тестировании создаются две похожие группы пользователей (группа A и группа B), которым показывается один и тот же вариант процесса/продукта (контент или функциональность). Например, в интернет-магазине аудиторию делят случайным образом, обе группы видят одинаковые предложения и результаты поиска. Зачем проводят A/A-тестирование?

1. Чтобы проверить корректность системы тестирования, обеспечивая равномерное распределение трафика и точность данных. Если между группами обнаруживаются статистически значимые различия, это указывает на проблемы в аналитике или алгоритмах распределения.

2. Чтобы оценить уровень шума в данных. Это важно для определения значимости изменений в будущих A/B-тестах.

Пример 16.2.4. Продакт-менеджер Равиль планирует протестировать новую рекомендательную модель в онлайн-кинотеатре. Он начинает с A/A-тестирования на исторических данных. Равиль ставит перед собой несколько вопросов:

- Какое количество пользователей следует добавить в каждую группу?
- Какие эффекты можно обнаружить в зависимости от размера группы?
- Какой должна быть продолжительность эксперимента?
- Как правильно формировать группы для тестирования?
- Какой критерий нужно выбрать для оценки эффективности новой модели?

Метод: случайное разбиение с хешированием и оценка эффектов через t-критерий Стьюдента. Целевая метрика: конверсия из рекомендации в просмотр фильма. Процесс:

1. Определить стартовую точку в истории данных.
2. Сформировать группы случайно, используя хеширование.
3. Добавить искусственный эффект в одну из групп.
4. Подобрать размер групп и эффект, чтобы достичь желаемой мощности эксперимента (обычно 80%).

Результат: как только оптимальные параметры найдены, можно переходить к A/B-тестированию.

A/B-стратегия Есть разные виды A/B-тестов:

- классический с одной контрольной и одной экспериментальной группой,
- множественные эксперименты,
- добавление второй контрольной группы для проверки стабильности.

Классический процесс:

1. Спланировать эксперимент и определить, сколько наблюдений нужно в каждой группе для выявления ожидаемого эффекта.
2. Приготовить группы: для статического эксперимента заранее выбрать объекты, для динамического — настроить распределение трафика.
3. Накапливать необходимое количество наблюдений.
4. Рассчитать эффект и подвести итоги эксперимента.

ОПРЕДЕЛЕНИЕ 16.2.5

Статический и динамический эксперименты

Статический эксперимент — эксперимент, в котором группы формируются до начала эксперимента. Примером может служить эксперимент в офлайн-ритейле, где в группах A и B чётко зафиксированы конкретные магазины.

Динамический эксперимент — эксперимент, в котором группы формируются (накапливаются) в реальном времени. Пример — эксперимент с рекомендательной моделью в онлайн-кинотеатре: по ID пользователя определяется, в какую группу его относить, A или B.

Рассмотрим, как проводятся динамический и статический A/B-тесты. **Динамический A/B-тест в онлайн-кинотеатре** Цель: определить изменение конверсии на 1% (абсолютно) или 10% (относительно). Требования: 14128 пользователей в каждой группе. Процесс:

1. Начать эксперимент, распределяя трафик случайным образом (например, с помощью хеширования).
2. Через неделю набрать нужное количество пользователей.
3. Перейти к расчёту эффекта в A/B тесте.

Статический A/B-тест в офлайн-магазине Цель: проверить, увеличат ли изменения в расстановке товаров выручку на 1%. Требования: тестировать на 50 магазинах в течение 1 месяца. Процесс:

1. Заранее зафиксировать 50 экспериментальных и 50 контрольных магазинов и не менять состав групп.
2. По окончании месяца оценить результат и проверить статистическую значимость эффекта.

A/B/C-стратегия Чтобы протестировать несколько вариантов одновременно, необходимо использовать множественное тестирование. В этом случае есть одна контрольная группа (без изменений) и несколько экспериментальных групп (каждая с разными изменениями). Процесс:

1. Сформировать группы заранее выбранным способом, как в обычном A/B-тесте.
2. Оценить эффект по тому же принципу, например, с использованием t-критерия Стьюдента, но с поправкой на множественное тестирование.

Изменения в дизайне эксперимента:

- Формула для расчёта необходимого числа наблюдений изменяется, чтобы во внимание были приняты несколько групп.

$$N = \frac{2\sigma^2(Z_{\alpha/(2C^2_{N_{groups}})} + Z_\beta)^2}{MDE^2_{absolute}}$$

Подходы:

- Теоретический. Использует вышеуказанную формулу и предполагает равные размеры групп.
- Эмпирический. Более гибок и позволяет варьировать размеры групп по необходимости.

Рассмотрим те же примеры. **A/B/C-тест в онлайн-кинотеатре**

Цель: Определить изменение конверсии на 1% (абсолютно) или 10% (относительно). Требования: 18845 пользователей в каждой группе. Процесс:

1. Начать эксперимент, распределяя трафик случайным образом на 3 группы (например, с помощью хеширования).
2. Через неделю набрать нужное количество пользователей.
3. Перейти к расчёту эффекта.

Статический A/B/C-тест в офлайн-магазинах Цель: Проверить, увеличат ли два новых алгоритма расстановки товаров выручку на 1%. Требования: тестировать на 60 магазинах в каждой группе (всего 180 магазинов) в течение 1 месяца. Процесс:

1. Заранее зафиксировать состав групп (по 60 магазинов в каждой).
2. По окончании месяца оценить эффективность и проверить статистическую значимость эффекта.

Вариант дизайна A/B/C-теста с использованием Ambrosia:

```
from ambrosia.designer import design_binary
p = 0.1
effects = [1.01, 1.03, 1.05, 1.1]
n_groups = 3
# correct alpha using n_groups parametr (C(n_groups, 2))
design_binary(
    to_design='size',
    prob_a=p,
    first_type_errors = 0.05 / n_groups,
    effects=effects,
    stabilizing_method='norm'
)
# Output:
# 1.0% 1884441
# 3.0% 209383
# 5.0% 75378
# 10.0% 18845
```

A/A/B-стратегия Этот вариант тестирования может быть представлен именно в формате A/A/B или A/A/B/C. Они полностью повторяют свои аналоги A/B и A/B/C за одним исключением: используется дополнительная контрольная группа, которая позволяет на лету провести A/A-тест одновременно с самим экспериментом. Это полезно, когда нужно в реальном времени убедиться, что алгоритм A/B-тестирования не стал приводить к искаженным результатам с завышенными ошибками первого и второго рода (к примеру, группы со временем расходятся, хотя они на момент подбора были идентичны). Такое тестирование может быть дорогим, если объектов для тестирования не очень много. Но при большом количестве объектов оно помогает быть увереннее в результатах тестирования.

Бизнес-причины сплитования с малой группой A или B

Малые группы (например, 10% пользователей в контрольной группе) позволяют оптимизировать тесты под бизнес-цели, минимизируя риски и ресурсы. Оно полезно потому, что позволяет

- экономить трафик: тест на малой аудитории снижает влияние на основной бизнес, освобождая трафик для других экспериментов;
- быстро проводить итерации: короткие тесты проверяют идею в малом масштабе, ускоряя разработку (особенно для малого бизнеса с ограниченным трафиком);
- снизить риски: малый тест минимизирует потери при неудаче (плохой вариант повлияет всего на 10% пользователей).
- контролировать false positive: В A/A/B малые контрольные

группы помогают без больших затрат выявить ошибки сплита.

Пример 16.2.5. В e-commerce с низким трафиком тест 5/95 позволяет быстро проверить новый дизайн на 5% пользователей, минимизируя риски для 95% и экономя время на сбор данных.

Параметрические критерии

В A/B-тестировании параметрические критерии помогают проверить статистическую значимость различий между группами при некоторых предположениях. Эти критерии работают хорошо на больших выборках, даже если данные не распределены нормально. В разрезе экспериментов нас чаще всего интересуют гипотезы о равенстве средних значений, поскольку это наиболее релеватно целям проведения экспериментов, хотя нулевая гипотеза может быть сколь угодно разнообразной. Поэтому мы будем рассматривать механизм проверки в разрезе проверки равенства средних значений. Допустим, что

$$X = (X_1, ..., X_{n_X}),\ Y = (Y_1, ..., Y_{n_Y})$$

Нулевая гипотеза (H_0) предполагает равенство средних, альтернативная гипотеза (H_1) говорит об их различии.

$$H_0 : \mu_x = \mu_y$$

$$H_1 : \mu_x \neq \mu_y$$

Одним из таких критериев является критерий Стьюдента, который использует t-статистику для сравнения средних значений групп. Решение о принятии или отвержении нулевой гипотезы основывается на p-value, которое показывает вероятность получить такие же или более экстремальные различия, если H_0 верна.

$$T = \frac{\overline{X} - \overline{Y}}{\sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}}$$

Углубимся в некоторые ключевые параметрические критерии A/B-тестирования.

Дисбаланс выборок (SRM)

ОПРЕДЕЛЕНИЕ 16.2.6

SRM (Sample Ratio Mismatch) — несоответствие фактических долей пользователей в группах A/B-теста заданным пропорциям. Это сигнал о проблемах в сплитовании, приводящих к искажениям результатов.

Расчёт: Разделить пользователей по группам, посчитать реальные доли. Использовать хи-квадрат тест: $\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i}$, где O_i — наблюдаемые размеры групп, E_i — ожидаемые (например, $N/2$ для 50/50). Если p-value < 0.05, SRM присутствует.

Пример 16.2.6. Ожидание: группа A — 50% (500 пользователей), B — 50% (500). Реальность: A — 620 (62%), B — 380 (38%). $\chi^2 =$

$\frac{(620-500)^2}{500} + \frac{(380-500)^2}{500} = 28.8$, p-value « 0.05 — SRM обнаружен, тест недействителен.

T-критерий Стьюдента

T-критерий Стьюдента используется для сравнения средних значений двух независимых выборок, чтобы определить статистическую значимость различий.

$$H_0 : \mu_1 = \mu_2,\ H_1 : \mu_1 \neq \mu_2$$

$$T(X,Y) = \frac{\overline{X} - \overline{Y}}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} \approx t(n)$$

$$n = \frac{(s_1^2/n_1 + s_2^2/n_2)^2}{\frac{(s_1^2/n_1)^2}{n_1-1} + \frac{(s_2^2/n_2)^2}{n_2-1}}$$

В строгом смысле требуется нормальность распределений X и Y, но на практике это условие необязательно. Здесь есть одно замечание. Нулевое распределение не точное, а приближённое. Точного решения не существует (проблема Беренца-Фишера): невозможно точно сравнить средние значения в двух выборках, дисперсии которых неизвестны. Но такая аппроксимация точна при условии, что выборки одинакового объёма или если знак неравенства между n_1, n_2 такой же, как между σ_1, σ_2. Когда эти условия соблюдены, всё будет в порядке. В противном случае мы будем наблюдать завышение ошибки первого рода. Это проблема не только теста Стьюдента, она возникает при проверке любым способом гипотезы о равенстве средних в двух выборках с разной дисперсией. Поэтому, сравнивая средние значения в двух выборках, важно всегда следить за тем, чтобы выборка с большей дисперсией всегда была не меньшего объёма, чем вторая выборка

Решить проблему поможет расширение теста Стьюдента — тест Уэлча. Особенно это легко делается в Python в модуле scipy.stats: ttest_ind(a, b, equal_var=False).

F-тест

Этот критерий используется для сравнения средних значений более чем двух групп. В A/B-тестировании F-тест может быть полезен, если у нас есть несколько экспериментальных групп, которые мы хотим сравнить с контрольной группой. При этом F-тест не позволяет определить, в какой группе наблюдается различие, а лишь определяет сам факт, что в одной из эксперименталь-

ных групп есть статистический значимый эффект.

$$X^{(i)} = (X_1^{(i)}, ..., X_{n_i}^{(i)}),\ i = 1...k$$

$$H_0 : \mu_{x_1} = ... = \mu_{x_k}$$

В качестве альтернативной гипотезы H_1 возьмём отрицание основной гипотезы. Метод, используемый для сравнения средних значений, называется **дисперсионным анализом**. Дело в том, что при расчёте разницы между средними значениями мы сравниваем дисперсии. Таким образом, для оценки различий между группами необходимо сравнить разброс групповых средних с разбросом значений внутри групп.

$$x_{ij} = \overline{X} + (\overline{x_i} - \overline{X}) + (x_{ij} - \overline{x_i})$$

Здесь: x_{ij} — j-е наблюдение в группе i $\overline{x_i}$ — среднее значение в i-й группе. $\overline{X}$ — среднее значение по всем наблюдениям (среди всех групп совместно). $(\bar{x_i} - \bar{X})$ — отклонения групповых средних от общего среднего значения. Разброс наблюдений внутри групп:

$$SS_W = \sum_i \sum_j (x_{ij} - \bar{x_i})^2$$

Разброс групповых средних:

$$SS_B = \sum_i \sum_j (\bar{x_i} - \bar{X})^2$$

Таким образом, получаем F-статистику теста Фишера:

$$F = \frac{SS_B/(k-1)}{SS_W/(N-k)}$$

N — общее число наблюдений, k — число сравниваемых групп. При истинности нулевой гипотезы H_0 эта статистика будет иметь распределение Фишера $F(k-1, N-k)$. Отвержение или неотвержение нулевой гипотезы будет зависеть от попадания или непопадания статистики в критическую область распределения Фишера.

ANOVA

Общая идея ANOVA

ОПРЕДЕЛЕНИЕ 16.2.7

Дисперсионный анализ (ANOVA, от англ. Analysis of Variance) — это метод сравнения нескольких средних, в основе которого лежит разложение общей вариации данных на вариацию между группами и внутри групп.

В однофакторной постановке ANOVA приведёт нас к той же F-статистике, что и в предыдущем разделе: отношение оценённой дисперсии между группами к оценённой дисперсии внутри групп сравнивается с теоретическим распределением Фишера.

Вместо того чтобы запускать множество отдельных t-тестов для

всех пар групп и сталкиваться с проблемой множественных проверок, ANOVA позволяет одним глобальным тестом проверить гипотезу равенства всех средних. Это особенно удобно в A/B/n-экспериментах, где есть один контроль и несколько вариантов изменения: сначала проверяется, есть ли вообще хоть какие-то различия между вариантами, а уже затем, при необходимости, выполняются детальные попарные сравнения.

Предпосылки однофакторной ANOVA. Классическая модель ANOVA предполагает:

- независимость наблюдений внутри и между группами;
- нормальность распределения ошибки в каждой группе;
- гомоскедастичность: равенство дисперсий во всех группах ($\sigma_1^2 = \cdots = \sigma_k^2$).

На практике F-тест достаточно устойчив к небольшим отклонениям от нормальности, особенно при близких размерностях групп, но чувствителен к сильной неоднородности дисперсий и сильному дисбалансу по n_i.

Рисунок 336. ПЕРЕНЕСТИ ТЕКСТ В ТЕКСТ

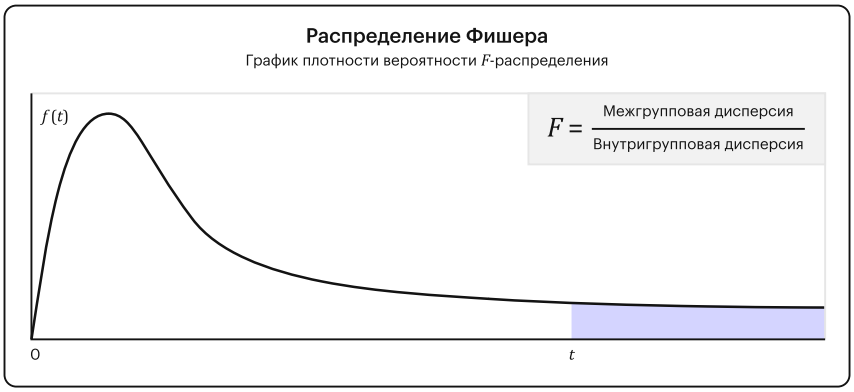

Рисунок 337. Вкратце про ANOVA

Как мы можем интепретировать результаты? Если наблюдаемое значение F_{obs} попадает в правый хвост распределения Фишера и соответствующее p-value меньше уровня значимости α, то нулевая гипотеза равенства всех средних отклоняется. Это означает, что хотя бы в одной группе среднее отличается от остальных, но сам по себе F-тест не указывает, в каких именно парах групп есть отличие.

ANOVA в A/B/n-тестировании. В контексте A/B-тестирования однофакторная ANOVA естественно применяется, когда есть одна контрольная группа и несколько экспериментальных вариантов (A/B/C/D и т.п.), а нас интересует сравнение средних значений некоторой метрики (например, ARPU) по всем вариантам сразу. В таком случае фактором выступает «вариант эксперимента», а откликом — значение метрики на пользователе или сессии. Сначала проводится глобальный тест с помощью ANOVA:

$$H_0 : \mu_{x_1} = \cdots = \mu_{x_k},$$

и только если H_0 отвергнута (есть хотя бы одно отличие), имеет смысл переходить к более детальному анализу парных сравнений.

01 Межгрупповая сумма квадратов (Between Groups)

Показывает, насколько сильно группы отличаются друг от друга

$$\mathrm{SSB} = \sum_{i=1}^{k} n_i(\bar{X}_i - \bar{X})^2 \quad | \quad df = k - 1$$

02 Внутригрупповая сумма квадратов (Within Groups)

Показывает средний разброс внутри групп.

$$\mathrm{SSW} = \sum_{i=1}^{k}\sum_{j=1}^{n_i}(X_{ij} - \bar{X}_i)^2 \quad | \quad df = N - k$$

03 Общая сумма квадратов (Total Sum of Squares)

Показывает разброс всех наблюдений вокруг общего среднее по всем группам

$$\mathrm{SST} = \sum_{i=1}^{k}\sum_{j=1}^{n_i}(X_{ij} - \bar{X})^2 \quad | \quad df = N - 1$$

Обозначения:

k — число групп;

n_i — число наблюдений в i-й группе;

$N = \sum_{i=1}^{k} n_i$ — общее число наблюдений;

$\bar{X}_i$ — среднее в группе i;

$\bar{X}$ — общее среднее по всем группам;

X_{ij} — j-е наблюдение в i-группе

Справедливо:

$\mathrm{SST} = \mathrm{SSB} + \mathrm{SSW}$

Рисунок 338. Формулы дисперсий в ANOVA

Пост-hoc анализ и множественные сравнения. Если ANOVA показала наличие различий, следующим шагом обычно становятся пост-hoc тесты: сравниваются отдельные пары средних (например, каждая экспериментальная группа против контроля), причём необходимо контролировать семейную вероятность ошибки первого рода, так как одновременно проводится множество проверок. О том, какие подходы есть для решения этой проблемы, мы будем говорить далее. В A/B/n-экспериментах такой подход позволяет избежать чрезмерного роста ложноположительных результатов при большом числе вариантов.

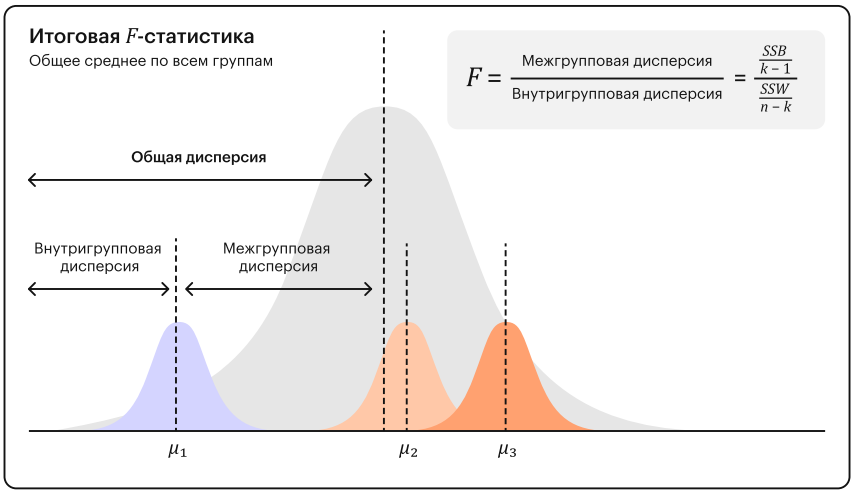

Рисунок 339. F-статистика в ANOVA

Многофакторная ANOVA. Однофакторный дисперсионный анализ легко обобщается на случаи, когда есть несколько факторов (например, вариант эксперимента и тип устройства). Многофакторная ANOVA позволяет одновременно оценивать:

- основные эффекты каждого фактора (как меняется метрика при изменении каждого фактора по отдельности);
- эффекты взаимодействия факторов (меняется ли эффект варианта в зависимости от другого фактора, например платформы).

В задачах продвинутого A/B-тестирования это даёт возможность компактно моделировать сложные дизайны без раздувания числа отдельных тестов.

Рисунок 340. Выводы по ANOVA

Поправки при множественных сравнениях

Выше мы уже обсуждали стратегии сплитования, в которых делается более одного сравнения. В этих случаях нужно делать поправку на множественное сравнение, чтобы не завышать ошиб-

ку первого рода. Далее разберём эту проблему более подробно.

Задача множественных сравнений

Проблема множественных сравнений в A/B-тестировании возникает, когда мы проверяем более одной гипотезы одновременно — например, когда есть несколько экспериментальных групп или метрик. Это увеличивает вероятность получения ложноположительных результатов — рискуем найти эффект там, где его нет. Например, если 1000 человек будут независимо угадывать цвет (красный/чёрный) десяти закрытых карт, то вероятность угадывания цветов всех карт будет стремиться к 1 при нулевой гипотезе, что отгадывающий является экстрасенсом. При одновременной проверке большого количества гипотез вероятность совершить хотя бы одну ошибку первого рода становится очень большой. Поэтому используют некоторые процедуры, позволяющие такую ошибку контролировать.

При каждом независимом тесте мы обычно допускаем уровень значимости $\alpha_{\text{pair}} = 5\%$.

При множественных тестах вероятность хотя бы одного ложного срабатывания растёт. Вероятность ошибки хотя бы в одном из n тестов:
$\alpha_{\text{FWE}} = 1 - (1 - \alpha_{\text{pair}})^n$

Например:

- при одном тесте: 5%;
- при трёх тестах: 14%;
- при десяти тестах: 40%.

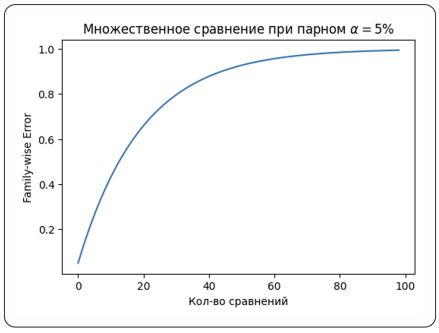

Рисунок 341. ПЕРЕНЕСТИ ТЕКСТ В ТЕКСТ

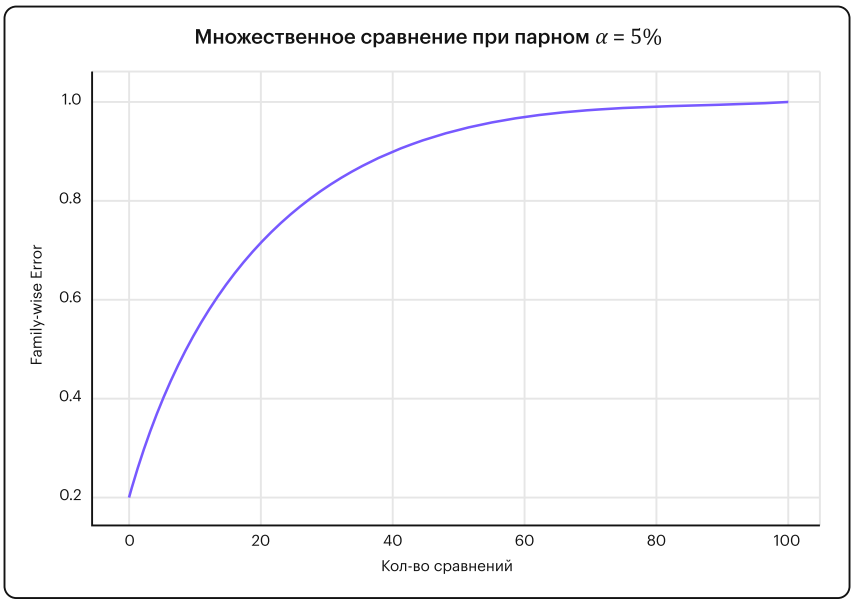

Рисунок 342. Проблема роста ошибки первого рода

ОПРЕДЕЛЕНИЕ 16.2.8

Групповая вероятность ошибки первого рода — вероятность совершить хотя бы одну ошибку первого рода.

$$\alpha_{FWE} = P(V > 0)$$

где V — количество ошибок первого рода среди всех гипотез.

	Не прокрасится	Прокрасится
Одно сравнение	$1 - \alpha_{\text{pair}_i} = 0.95$	$\alpha_{\text{pair}_i} = 0.05$
	↓	↓
Два сравнения	$(1 - \alpha_{\text{pair}_i}) \cdot (1 - \alpha_{\text{pair}_j}) = 0.95 \cdot 0.95$	...
	↓	↓
***N* сравнений**	$(1 - \alpha_{\text{pair}_1}) \cdot (1 - \alpha_{\text{pair}_2}) \cdots (1 - \alpha_{\text{pair}_n}) = 0.95 \cdot 0.95 \cdots 0.95 = 0.95^n$	...
	↓	
	Прокрасится хотя бы одно из *n* сравнений $1 - 0.95^n$	
	↓	
	$\alpha_{\text{FWE}} = 1 - (1 - \alpha_{\text{pair}})^n$	

Рисунок 343. Вероятность ошибки первого рода

Попробуем построить такую статистическую процедуру, которая ограничит вероятность совершить хотя бы одну ошибку первого рода уровнем α. Рассмотрим 2 основные поправки на множественные сравнения: поправка Бонферрони и метод Холма, которые позволяют контролировать fwe.

Поправка Бонферрони

Самый простой способ решить задачу контроля fwe — это использовать поправку Бонферрони. Достигаемые уровни значимости всех гипотез сравниваются с величиной $\frac{\alpha}{m}$

$$\alpha_1 = ... = \alpha_m = \frac{\alpha}{m}$$

где m — это количество гипотез, которые мы проверяем. p-value каждой гипотезы будет сравниваться с преобразованным уровнем значимости, а не с исходным α, это позволяет контролировать групповую ошибку первого рода на уровне α. Количество гипотез, как правило, рассчитывается по формуле $m = C_N^2$, так как необходимо проверить попарно все гипотезы. Поэтому, когда мы делали коррективу α в теоретической формуле дизайна эксперимента, мы делили на C_N^2 — количество гипотез.

Идея: уменьшаем уровень значимости парного сравнения α_{pair} , чтобы сохранить общий уровень ошибки первого рода для значимости α_{FWE}.

Формула: если $\alpha_{\text{FWE}} = 0.05$ и n — число сравнений, то $\alpha_{\text{pair}} = \frac{\alpha_{\text{FWE}}}{n}$.

Например:

- при трёх тестах: 0.0167;
- при пяти тестах: 0.01;
- при двенадцати тестах: 0.00416.

Плюсы:

- прост в реализации;
- гарантирует строгий контроль ошибки первого рода.

Минусы:

- сильно снижает статистическую мощность;
- становится неэффективен при большом числе гипотез.

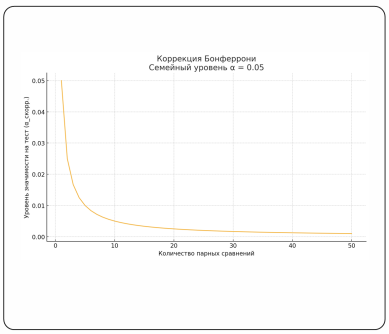

Рисунок 344. ПЕРЕНЕСТИ ТЕКСТ В ТЕКСТ

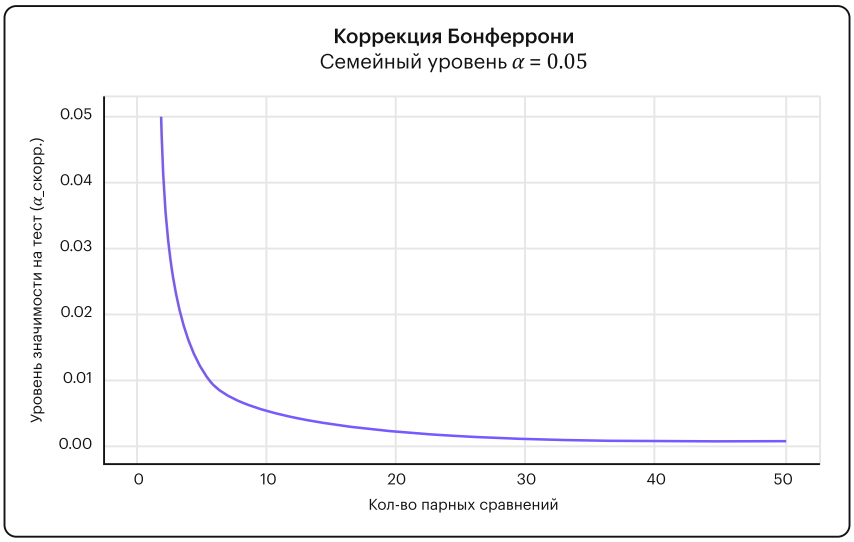

Рисунок 345. Метод Бонферрони

Метод прост, но имеет ряд недостатков. Основные из них:

- Метод сильно занижает мощность эксперимента, то есть отловить эффект становится труднее.
- Тесты могут быть зависимыми. Группы зависимы друг от друга, что приводит ко взаимному влиянию. Это никак не учитывается в поправке Бонферрони.

Метод Холма

Метод Холма — это нисходящая процедура множественной проверки гипотез со следующими уровнями значимости:

$$\alpha_1 = \frac{\alpha}{m},\ \alpha_2 = \frac{\alpha}{m-1},\ \ldots,\ \alpha_i = \frac{\alpha}{m-i+1},\ \ldots, \alpha_m = \alpha$$

Из достигаемых уровней значимости исходных гипотез составляется вариационный ряд:

$$p_{(1)} \leqslant \ldots \leqslant p_{(m)}$$

Далее самый маленький $p_{(1)}$ сравниваем с α_1. Если $p_{(1)} \geqslant \alpha_1$, то все нулевые гипотезы $H_{(i)}$ не отвергаются, а процесс оста-

навливается, иначе отклоняется гипотеза $H_{(1)}$, а мы переходим к $p_{(2)}$ и α_2. Таким образом, мы последовательно отвергаем нулевые гипотезы, начиная с наиболее значимых и заканчивая наименее значимыми (с точки зрения величины p-value). Метод Холма может быть предпочтительнее, чем Бонферрони, так как он всегда отвергает не меньше гипотез, чем метод Бонферрони. То есть мощность эксперимента будет выше.

Идея: адаптивная альтернатива Бонферрони — более мощная, но всё ещё строгая.

Принцип:

- Сортируем p-value попарных сравнений по возрастанию: $p_1, p_2, \ldots, p_n$
- **Сравниваем:**

$$p_1 \le \frac{\alpha_{\text{FWE}}}{n}; \quad p_2 \le \frac{\alpha_{\text{FWE}}}{n-1}; \quad p_3 \le \frac{\alpha_{\text{FWE}}}{n-2}; \quad \ldots \quad p_i \le \frac{\alpha_{\text{FWE}}}{n-i+1}.$$

Идём до первого p_i, которое не проходит, — все следующие отклоняются.

\+ Меньше потерь в мощности по сравнению с Бонферрони.

\− Немного сложнее в реализации

\− Всё ещё консервативен при большом количестве гипотез

Рисунок 346. Метод Холма

A

B1 $p_1 = 0.009$ B2 $p_2 = 0.014$ B3 $p_3 = 0.018$ B4 $p_4 = 0.062$

Бонферрони

$$\alpha_{\text{pair}_i} = \frac{\alpha_{\text{FWE}}}{n-i+1} = \frac{0.05}{4-i+1}$$

B1: $0.009 < 0.0125$ → отвергаем
B2: $0.014 > 0.0125$ → не отвергаем
B3: $0.018 > 0.0125$ → не отвергаем
B4: $0.062 > 0.0125$ → не отвергаем

Холм

$$\alpha_{\text{pair}} = \frac{\alpha_{\text{FWE}}}{n} = \frac{0.05}{4} = 0.0125$$

Сортируем по возрастанию p-value и последовательно сравниваем с порогами

B1: $0.009 < 0.0125$ → отвергаем
B2: $0.014 > 0.0167$ → не отвергаем
B3: $0.018 > 0.025$ → не отвергаем
B4: $0.062 > 0.050$ → не отвергаем и останавливаемся

Рисунок 347. Сравнение методов

3. RATIO-МЕТРИКИ В A/B ТЕСТАХ

Знай противника и знай себя, и ты будешь непобедим.
Мао Цзэдун, «Относительно противоречия»

Определение и свойства ratio-метрик

Что такое ratio-метрики и почему они важны

Метрика в A/B-тестах — это количественный показатель, который используется для оценки эффективности изменений. Она отражает ключевые аспекты поведения пользователей или системы, такие как конверсия, среднее время сессии или доход на пользователя. Выбор метрики зависит от целей эксперимента и должен быть чувствительным к предполагаемым изменениям.

Единица рандомизации и единица анализа

Единица рандомизации — это объект, который случайным образом распределяется между группами, например, пользователь или сессия. Единица анализа — это уровень, на котором агрегируются данные для расчёта метрики, который может совпадать или отличаться от единицы рандомизации. Несоответствие между ними может привести к искажениям в оценке эффекта.

Поюзерные метрики

Поюзерные метрики рассчитываются на уровне индивидуального пользователя, такие как количество сессий на пользователя или средний чек. Они учитывают поведение каждого пользователя отдельно и полезны для анализа индивидуальных паттернов.

Метрика, у которой в числителе **численные сигналы пользователей** (деньги, клики, число товаров и т.д.), называется средней поюзерной техникой

$$M_U = \frac{\sum_{u \in U} X(u)}{\#U}$$

Если у нас в числителе будут **бинарные сигналы**, нолик или единичка (совершил ли покупку, клик, видел ли баннер и т.д.), то это пользовательские конверсии

$$C_U = \frac{\sum_{u \in U} \mathbf{1}(u)}{\#U}$$

Рисунок 348. Определение метрики

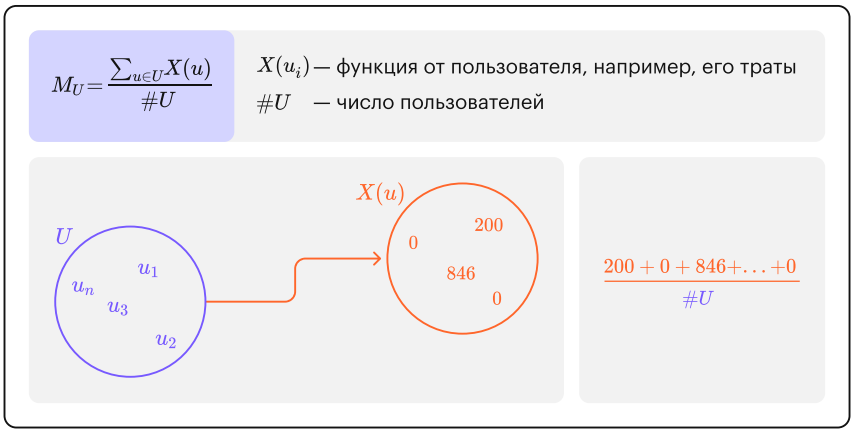

Рисунок 349. Определение пользовательской метрики

Метрики по условию

Метрики по условию зависят от выполнения определённых условий, например, конверсия только среди активных пользователей. Они позволяют фокусироваться на конкретных сегментах аудитории.

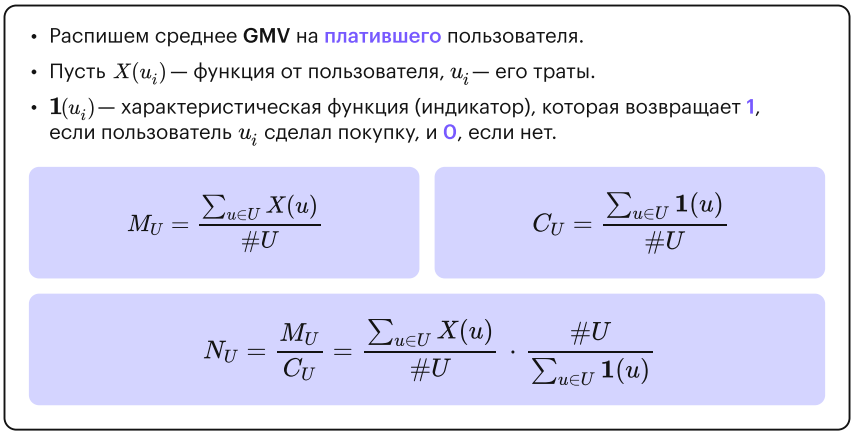

Рисунок 350. Метрики по условию

Определение ratio-метрики

Ratio-метрика — это метрика отношения непользовательского уровня (non-user level metric) с зависимыми наблюдениями, но которая явным образом выражается через отношение сумм соответствующих пользовательских сигналов.

Формально, пусть для группы пользователей U, где v — вид (view), c — клик (click):

$$\sum_{v \in V} 1_c(v) = \sum_{u \in U} N(u),$$

$$\#V = \sum_{u \in U} K(u),$$

$$CTRv = CTRu.$$

user_id	view_id	is_ads_click
user_1	v18457	1
user_1	v82934	1
user_1	v34759	0
user_2	v05928	0
user_2	v67324	0
...	...	...
user_n	v48128	0

```
view_df['is_ads_click'].mean()
```

$$CTR_V = \frac{\sum_{v \in V} \mathbf{1}_c(v)}{\#V}$$

Тождественное определение в разрезе пользователей →

user_id	n_ads_click	n_ads_view
user_1	2	3
user_2	0	2
user_3	1	5
user_4	0	1
...	...	...
user_n	4	5

```
user_df['n_ads_click'].sum()
```

```
user_df['n_ads_view'].sum()
```

$$CTR_U = \frac{\sum_{u \in U} N(u)}{\sum_{u \in U} K(u)}$$

Рисунок 351. Пример

Почему нельзя считать ratio-метрики t-тестом? Из-за нарушения предпосылок о независимости наблюдений.

Пример 16.3.1. Теперь рассмотрим CTR (click-through rate) как классический пример ratio-метрики. В онлайн-рекламе CTR рассчитывается как отношение количества кликов по рекламному баннеру к количеству его показов. Если в экспериментальной группе мы ввели новый дизайн баннера, ratio-метрика CTR позволит оценить, насколько этот дизайн повысил привлекательность рекламы, нормализуя эффект на количество показов, которое может варьироваться между пользователями из-за различий в активности.

Пример 16.3.2. Другим примером является ARPU (average revenue per user) — средний доход на пользователя, представляющий собой отношение общего дохода от группы пользователей к их количеству. В A/B-тесте с новой системой ценообразования ARPU помогает понять, увеличился ли доход в расчете на одного пользователя, учитывая возможные различия в количестве пользователей или их активности между группами.

Пример 16.3.3. Рассмотрим метрику AOV (average order value) — средний чек. Если вычислять AOV как среднее по заказам $\frac{\sum P(o)}{\#O}$, то возникает проблема: цены заказов в рамках одного пользователя скоррелированы (например, из-за предпочтений конкретного пользователя), что нарушает предпосылку о независимости наблюдений для ЦПТ. Это приводит к тому, что оценка дисперсии $\frac{\sigma^2}{n}$ будет некорректной.

Корректное решение — представить AOV как ratio-метрику на уровне пользователей:

$$\text{AOV} = \frac{\sum_{o \in O} P(o)}{\#O} = \frac{\sum_{u \in U} G(u)}{\#U} \cdot \frac{\#U}{\sum_{u \in U} O(u)} = \frac{\sum_{u \in U} G(u)}{\sum_{u \in U} O(u)},$$

где $P(o)$ — цена заказа o, $G(u)$ — GMV пользователя u, $\#O$ — число заказов, $O(u)$ — заказов пользователя u. Такое подход позволит нам корректно оценить дисперсию! Ещё раз зафиксируем, что это происходит потому, что мы теперь работаем с пользовательскими агрегатами и:

- удиница рандомизации (пользователь) совпадает с единицей анализа
- в отличие от заказов «внутри» пользователя, наблюдения на уровне пользователей независимы
- можно применить дельта-метод для оценки дисперсии ratio-метрики
- теперь учитывается естественная корреляция между GMV пользователя и количеством его заказов

Инсайт Ratio-метрики особенно ценны в ситуациях, когда нужно нормализовать данные по разным масштабам активности, но их анализ требует осторожности из-за потенциальной зависимости между числителем и знаменателем, что может привести к недооценке или переоценке эффекта без специальных методов.

Дельта-метод для ratio-метрик

Если по простому — дельта-метод делает то же самое, что и бутстрап, но не эмпирически, а аналитически, используя теоретические формулы.

Предусреднённое среднее

Предусреднённое среднее для ratio-метрики предполагает сначала усреднение числителя и знаменателя по группам, а затем вычисление их отношения. Этот метод прост, но может быть смещённым при неравномерном распределении данных.

- Определяем для пользователей сигналы для числителя и знаменателя
- Для каждого пользователя делим сигнал числителя на его знаменатель
- Берем среднее значение по этим новым сигналам
- Получаем **предусреднённое среднее пользовательских значений.**

Формально **CTP на пользователя** определяется так:

$$P = \frac{\sum_{u \in U} \frac{N(u)}{K(u)}}{\#U}$$

Рисунок 352. Подход для предусреднённого

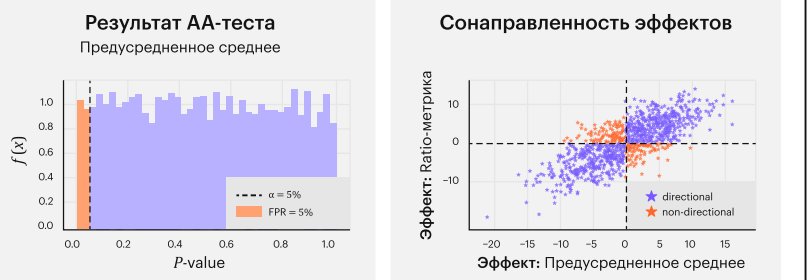

Метрика проходит валидацию на синтетических AA-тестах

Эффекты с целевой ratio-метрикой могут быть разнонаправлены

Рисунок 353. Пример ПС

Вывод

+ Корректна для статоценки, так как сигналы — независимые

− Несонаправлена по эффекту с целевой ratio-метрикой

Рисунок 354. Выводы

Бутстрап

Бутстрап для оценки статистической значимости ratio-метрики включает многократное семплирование с возвращением из исходных данных для построения распределения метрики. Это позволяет вычислить доверительные интервалы и p-value без сильных предположений о распределении.

1. Отбираем пользователей с повторением в тесте и контроле.
2. Отбираем их сигналы числителя.
3. Отбираем их сигналы знаменателя.
4. Считаем значение разницы ratio-метрик и складываем в массив.
5. Повторяем пункты 1–4 много-много раз.
6. По эмпирическому распределению разниц ratio-метрик считаем p-value.

Рисунок 355. Алгоритм бутстрапа для нашего случая ПЕРЕНЕСТИ ТЕКСТ В ТЕКСТ

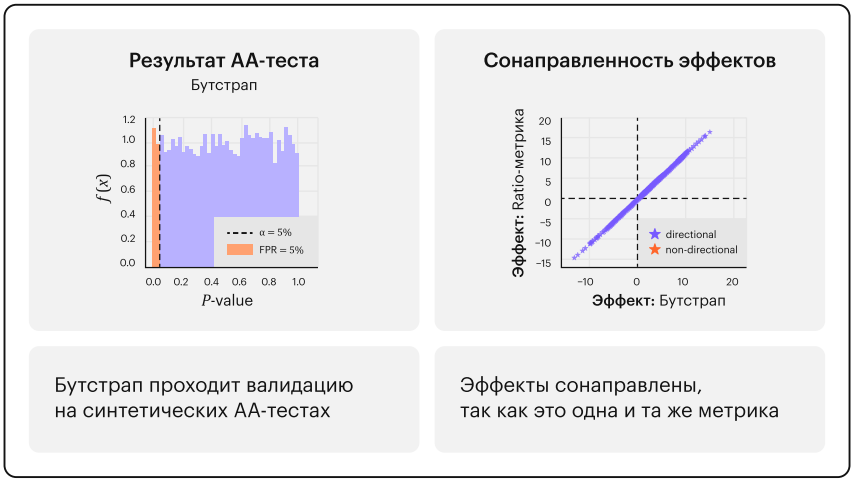

Рисунок 356. Результаты бутстрапа

А значит, получим следующие выводы.

Рисунок 357. Вывод

Дельта-метод

Дельта-метод — это мощный аналитический инструмент, основанный на аппроксимации Тейлора, который позволяет оценить дисперсию сложных функций от случайных величин, таких как ratio-метрики. Идея метода заключается в том, чтобы разложить функцию вокруг её ожидаемого значения и использовать первые члены разложения для приближения дисперсии. Для ratio-метрики $R = \frac{\overline{X}}{\overline{Y}}$, где $\overline{X}$ и $\overline{Y}$ — средние значения числителя и знаменателя, дельта-метод предоставляет формулу для асимптотической дисперсии. Общая формулировка дельта-метода для многомерного случая приводится в стандартных курсах по мате-

матической статистике.

Формально, если рассмотреть функцию $g(\theta) = \frac{\theta_1}{\theta_2}$, где $\theta = (\mathbb{E}[X], \mathbb{E}[Y])$, то по теореме дельта-метода, если $\hat{\theta}$ — состоятельная оценка θ с ковариационной матрицей Σ, то

$$\sqrt{n}\big(g(\hat{\theta}) - g(\theta)\big) \xrightarrow{d} \mathcal{N}\big(0, \nabla g^\top \Sigma \nabla g\big),$$

где ∇g — градиент g в точке θ.

Конкретно для дисперсии:

$$\mathrm{Var}\left(\frac{X}{Y}\right) \approx \frac{1}{\mathbb{E}[Y]^2}\mathrm{Var}(X) - 2\frac{\mathbb{E}[X]}{\mathbb{E}[Y]^3}\mathrm{cov}(X,Y) + \frac{\mathbb{E}[X]^2}{\mathbb{E}[Y]^4}\mathrm{Var}(Y).$$

Затем стандартная ошибка:

$$se\left(\frac{X}{Y}\right) = \sqrt{\frac{\mathrm{Var}\left(\frac{X}{Y}\right)}{n}}.$$

Выведем указанную выше формулу для дисперсии в простом, одномерном случае. Для этого рассмотрим случайные величины X и Y с конечными первыми и вторыми моментами и положим

$$\mu_X = \mathbb{E}[X], \qquad \mu_Y = \mathbb{E}[Y].$$

Нас интересует случайная величина

$$R = g(X,Y) = \frac{X}{Y}$$

и приближение её дисперсии при помощи разложения Тейлора первого порядка.

Тогда двумерное разложение Тейлора функции $g(x,y)$ в окрестности точки (μ_X, μ_Y) примет вид

$$g(X,Y) \approx g(\mu_X,\mu_Y) + g_x(\mu_X,\mu_Y)\,(X-\mu_X) + g_y(\mu_X,\mu_Y)\,(Y-\mu_Y),$$

где g_x и g_y — частные производные по первому и второму аргументу соответственно.

Для функции $g(x,y) = \dfrac{x}{y}$ имеем:

$$g_x(x,y) = \frac{\partial}{\partial x}\left(\frac{x}{y}\right) = \frac{1}{y}, \qquad g_y(x,y) = \frac{\partial}{\partial y}\left(\frac{x}{y}\right) = -\frac{x}{y^2}.$$

Подставляя точку (μ_X, μ_Y), получаем:

$$g_x(\mu_X,\mu_Y) = \frac{1}{\mu_Y}, \qquad g_y(\mu_X,\mu_Y) = -\frac{\mu_X}{\mu_Y^2},$$

а также

$$g(\mu_X,\mu_Y) = \frac{\mu_X}{\mu_Y}.$$

Поэтому линейное приближение $R = g(X,Y)$ в окрестности (μ_X, μ_Y) имеет вид

$$R \approx \frac{\mu_X}{\mu_Y} + \frac{1}{\mu_Y}(X - \mu_X) - \frac{\mu_X}{\mu_Y^2}(Y - \mu_Y).$$

Вычтем константу $\frac{\mu_X}{\mu_Y}$ из обеих частей:

$$R - \frac{\mu_X}{\mu_Y} \approx \frac{1}{\mu_Y}(X - \mu_X) - \frac{\mu_X}{\mu_Y^2}(Y - \mu_Y).$$

Теперь пусть

$$U = X - \mu_X, \qquad V = Y - \mu_Y.$$

Тогда приближение можно переписать в виде

$$R - \frac{\mu_X}{\mu_Y} \approx aU + bV,$$

где

$$a = \frac{1}{\mu_Y}, \qquad b = -\frac{\mu_X}{\mu_Y^2}.$$

Используем стандартную формулу для дисперсии линейной комбинации двух случайных величин:

$$\mathrm{Var}(aU + bV) = a^2\,\mathrm{Var}(U) + b^2\,\mathrm{Var}(V) + 2ab\,\mathrm{cov}(U,V).$$

Так как $U = X - \mu_X$ и $V = Y - \mu_Y$, то

$$\mathrm{Var}(U) = \mathrm{Var}(X), \qquad \mathrm{Var}(V) = \mathrm{Var}(Y), \qquad \mathrm{cov}(U,V) = \mathrm{cov}(X,Y).$$

Следовательно,

$$\mathrm{Var}\left(R - \frac{\mu_X}{\mu_Y}\right) \approx a^2\,\mathrm{Var}(X) + b^2\,\mathrm{Var}(Y) + 2ab\,\mathrm{cov}(X,Y).$$

Так как вычитание константы не меняет дисперсию, то

$$\mathrm{Var}(R) = \mathrm{Var}\left(R - \frac{\mu_X}{\mu_Y}\right),$$

и, подставляя значения a и b, получаем:

$$\mathrm{Var}(R) \approx \left(\frac{1}{\mu_Y}\right)^2 \mathrm{Var}(X) + \left(-\frac{\mu_X}{\mu_Y^2}\right)^2 \mathrm{Var}(Y) + 2 \cdot \frac{1}{\mu_Y} \cdot \left(-\frac{\mu_X}{\mu_Y^2}\right) \mathrm{cov}(X,Y).$$

Упрощая, имеем:

$$\mathrm{Var}\left(\frac{X}{Y}\right) \approx \frac{1}{\mu_Y^2}\mathrm{Var}(X) - 2\frac{\mu_X}{\mu_Y^3}\mathrm{cov}(X,Y) + \frac{\mu_X^2}{\mu_Y^4}\mathrm{Var}(Y),$$

что и есть желаемая формула для асимптотической дисперсии ratio-метрики, полученная при помощи дельта-метода.

Это позволяет применять нормальную аппроксимацию для построения доверительных интервалов и проведения тестов, таких как z-тест для сравнения ratio между группами. Метод особенно крут тем, что он аналитический, быстрый в вычислениях и асимптотически точен для больших выборок, где центральная предельная теорема обеспечивает нормальность оценок.

- Делает то же самое, что и бутстрал, но не эмпирически, а аналитически, через формулу.
- Формула позволяет оценить выборочную дисперсию для отношения двух случайных величин.
- Зная дисперсию, мы можем перерассчитать стандартную ошибку среднего.

$$\mathrm{Var}\left(\frac{X}{Y}\right) = \frac{1}{\mathbb{E}(Y)^2}\mathrm{Var}(X) - 2\frac{\mathbb{E}(X)}{\mathbb{E}(Y)^3}\mathrm{cov}(X,Y) + \frac{\mathbb{E}(X)^2}{\mathbb{E}(Y)^4}\mathrm{Var}(Y)$$

$$\mathrm{se}\left(\frac{X}{Y}\right) = \left(\frac{\mathrm{Var}\left(\frac{X}{Y}\right)}{n}\right)^{\frac{1}{2}}$$

Рисунок 358. Дельта-метод

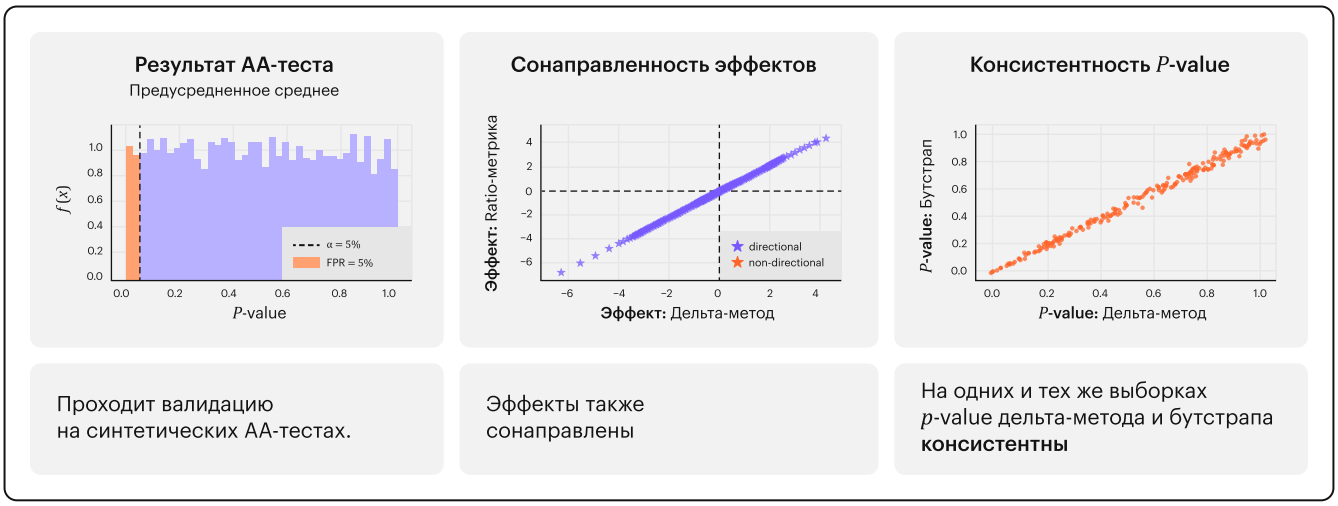

Рисунок 359. Результаты

Пример 16.3.4. Представьте A/B-тест в поисковой системе, где ratio-метрика — это доля ошибочных результатов на запрос (X — количество ошибок, Y — количество запросов). Используя дельта-метод, мы вычисляем дисперсию, учитывая ковариацию между ошибками и запросами (например, активные пользователи могут генерировать больше запросов и ошибок), и затем проводим тест на значимость различий между группами, что позволяет точно оценить влияние нового алгоритма поиска.

Пример 16.3.5. В e-commerce для метрики конверсии в заказ (X — заказы, Y — сессии) дельта-метод помогает учесть, что пользо-

ватели с большим числом сессий могут иметь более стабильную конверсию, и предоставляет точную оценку дисперсии, позволяя выявить небольшие эффекты от изменений в интерфейсе корзины.

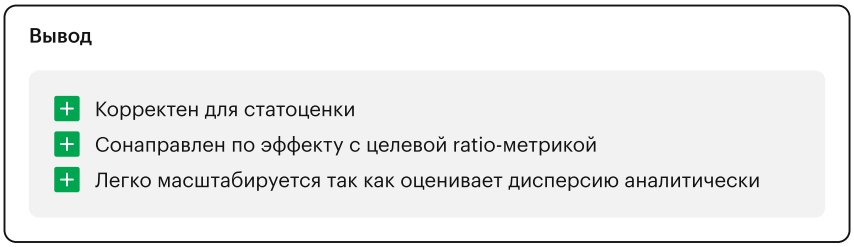

Рисунок 360. Вывод

Инсайт Дельта-метод позволяет нам существенно эффективнее проводить анализ ratio-метрик, предлагая аналитическую альтернативу ресурсоёмкому бутстрапу. Он особенно эффективен в больших данных, где аппроксимация Тейлора становится крайне точной, что позволяет принимать обоснованные решения быстрее и с меньшими вычислительными затратами.

Универсальность ratio-метрик

А работает ли это для обычных метрик? Действительно, оказывается, что любую поюзерную метрику или пользовательскую конверсию можно рассматривать как частный случай ratio-метрики, где знаменатель — это массив единиц по одной на пользователя. Формально для метрики X на пользователе имеем

$$\text{Var}\left(\frac{X}{\mathbf{1}}\right) = \frac{1}{\mathbb{E}[\mathbf{1}]^2}\text{Var}(X) - 2\frac{\mathbb{E}[X]}{\mathbb{E}[\mathbf{1}]^3}\text{cov}(X,\mathbf{1}) + \frac{\mathbb{E}[X]^2}{\mathbb{E}[\mathbf{1}]^4}\text{Var}(\mathbf{1}).$$

Учитывая, что $\mathbb{E}[\mathbf{1}] = 1$, $\text{Var}(\mathbf{1}) = 0$ и $\text{cov}(X,\mathbf{1}) = 0$, получаем:

$$\text{Var}\left(\frac{X}{\mathbf{1}}\right) = \text{Var}(X).$$

Инсайт Таким образом, дельта-метод для обычных метрик можно свести к просто оценке выборочной дисперсии X. Это означает, что мы можем применять его ко всем типам метрик в A/B-тестах.

Метод линеаризации для ratio-метрик

Ранее мы обсуждали, что в A/B-тестах используются три основных типа метрик, а именно пользовательские конверсии, средние

метрики пользователей и ratio-метрики. К последним относятся такие метрики, как CTR, конверсия в заказ, средний чек на заказчика и т.д. Они представляют собой отношение двух агрегированных величин.

Зачем нужна линеаризация

Линеаризация ratio-метрик необходима, потому что прямое использование t-теста на отношениях может привести к завышенной дисперсии и потере мощности. Линеаризация преобразует ratio в линейную метрику, которая лучше подходит для параметрических тестов, снижая дисперсию и повышая чувствительность к эффектам. Без линеаризации оценка эффекта может быть неточной из-за нелинейности.

Как работает линеаризация

Метод линеаризации основан на аппроксимации разложения по Тейлору вокруг контрольных значений. Идея в том, чтобы представить нелинейную функцию ratio как линейную комбинацию переменных, что позволяет применить стандартные статистические тесты. Для ratio $R_i = \frac{X_i}{Y_i}$ линеаризованная метрика $L_i = X_i - kY_i$, где $k = \frac{\sum X^c}{\sum Y^c}$ — отношение агрегированных средних в контрольной группе.

Математически это вытекает из разложения Тейлора функции $f(x, y) = \frac{x}{y}$ вокруг точки (μ_x, μ_y) — ожидаемых значений в контроле:

$$f(x,y) \approx f(\mu_x, \mu_y) + \frac{\partial f}{\partial x}|_\mu (x - \mu_x) + \frac{\partial f}{\partial y}|_\mu (y - \mu_y) = \\ = k + \frac{1}{\mu_y}(x - \mu_x) - \frac{k}{\mu_y}(y - \mu_y)$$

Пренебрегая константой и масштабируя, мы получаем $L_i = X_i - kY_i$, и разница в средних ratio аппроксимируется разницей в средних L_i деленной на μ_y. Это позволяет тестировать нулевую гипотезу о равенстве средних линеаризованных значений с помощью t-теста. Метод крут тем, что преобразует сложную метрику в простую, сохраняя направление эффекта и снижая дисперсию за счет учета корреляции между X и Y.

Преимущества линеаризации

Линеаризация снижает дисперсию метрики, что приводит к меньшему требуемому размеру выборки для обнаружения эффекта. Она сохраняет свойства линейных метрик, упрощая применение стандартных тестов, и устойчива к выбросам в данных. Кроме того, линеаризованная метрика сонаправлена с оригинальной ratio, и тест на ней контролирует ошибки на желаемом уровне.

Применение линеаризации

В практике линеаризация применяется к агрегированным данным по пользователям. Сначала вычисляется коэффициент k на контрольной группе, затем строится линеаризованная метрика для обеих групп, и на ней проводится t-тест. Это особенно полезно для метрик вроде CTR или дохода на пользователя. Важно агрегировать данные до уровня рандомизации перед линеаризацией.

Пример 16.3.6. В A/B-тесте по оптимизации интерфейса новостного сайта, где ratio-метрика — CTR на статьи (клики к показам), линеаризация позволяет преобразовать данные каждого пользователя в $L_i = clicks_i - k \times views_i$, где k из контроля. Затем t-тест на средних L выявляет эффект от нового дизайна с повышенной мощностью, учитывая, что пользователи с большим числом просмотров вносят больший вклад в дисперсию.

Пример 16.3.7. Для оценки новой рекомендательной системы в стриминговом сервисе, где ratio — конверсия в просмотр (просмотры к рекомендациям), применяем линеаризацию: вычисляем k как агрегированное отношение в контроле, строим L для всех, и тестируем. Это помогает обнаружить тонкие эффекты, которые могли бы быть потеряны из-за вариабельности числа рекомендаций на пользователя.

Инсайт Метод линеаризации — это элегантное решение для укрощения ratio-метрик, позволяющее интегрировать их в стандартный пайплайн A/B-тестирования с минимальными изменениями, значительно повышая точность и скорость анализа, особенно в комбинации с variance reduction техниками вроде CUPED, часть которых мы рассмотрим далее.

4. БАЗОВЫЕ МЕТОДЫ УСКОРЕНИЯ A/B ТЕСТОВ

Из этого текста ты узнаешь:

- что такое чувствительность A/B-теста,
- как определяются сетевые эффекты в экспериментах и как с ними работать с помощью Switchback-экспериментов,
- как пропорции разбиения групп, удаление выбросов, замена метрики и стратификация влияют на контроль длительности теста,
- влияние стрима наблюдений, выбросов, методики сплитования и типа метрики на необходимое количество наблюдений,
- процесс и сущности мониторинга эксперимента,
- определение p-hacking, включая случаи раннего отсутствия и раннего прокраса.

Чувствительность (sensitivity) A/B-теста — это способность теста обнаружить заданный реальный эффект, если он действительно существует.

В классическом виде под чувствительностью понимают мощность (power):

$$Power = 1 - \beta = P(\text{отклонить } H_0 \mid \Delta = \text{true effect}),$$

где β — вероятность ошибки II рода (пропустить реальный эффект).

Говоря «чувствительность», чаще фокусируются на том минимальном детектируемом эффекте (MDE), который тест способен увидеть при заданных α, β и объёме выборки.

Формула для расчёта минимального размера выборки:

$$n = \frac{(\sigma_t^2 + \sigma_c^2) \cdot (Z_{\alpha/2} + Z_{1-\beta})^2}{\text{MDE}^2}$$

Формула для MDE:

$$\text{MDE} = (Z_{\alpha/2} + Z_{1-\beta}) \cdot \sqrt{\frac{\sigma_t^2}{n_t} + \frac{\sigma_c^2}{n_c}} = (Z_{\alpha/2} + Z_{1-\beta}) \cdot \text{se}$$

Хотим манипулировать параметрами распределения, чтобы быстрее «увидеть» эффект.

$$\text{MDE} \propto \frac{\sigma}{\sqrt{n}}$$

Сетевой эффект в экспериментах возникает, когда пользователи

из разных групп (A и B) взаимодействуют друг с другом, нарушая предположение о независимости наблюдений. Это типично для платформ с социальными взаимодействиями, таких как социальные сети или маркетплейсы, где действия одного пользователя влияют на других.

Например, если в тесте на изменение алгоритма рекомендаций пользователь из группы B видит контент от пользователя из группы A, эффект может распространиться между группами, искажая результаты. Это приводит к недооценке или переоценке эффекта и увеличивает дисперсию оценок.

Чтобы справиться с сетевыми эффектами, используются специальные дизайны экспериментов, такие как кластерное разбиение или Switchback-эксперименты.

Switchback-эксперимент — это метод проведения A/B-теста, при котором лечение (treatment) и контроль чередуются во времени для одной и той же группы или единицы наблюдения. Это помогает справиться с сетевыми эффектами и зависимостями между наблюдениями, особенно в случаях, когда традиционное разбиение на группы невозможно.

Методология:

- Разделите время на интервалы (например, часы или дни).
- В каждом интервале случайным образом применяйте лечение или контроль.
- Собирайте данные по метрикам в каждом интервале.
- Анализируйте различия, учитывая временные зависимости (используя регрессию с фиксированными эффектами или другие модели).

Преимущества: Уменьшает bias от сетевых эффектов, позволяет использовать всю выборку эффективно. Недостатки: Требует учета carryover-эффектов (влияние предыдущего интервала) и может быть сложен в реализации.

Стрим наблюдений — последовательность поступления данных во времени. Если данные приходят не независимо (автокорреляция), это увеличивает эффективную дисперсию, требуя большего n.

В последовательных тестах учитывается временная зависимость, используя sequential analysis для ранней остановки.

Выбросы увеличивают дисперсию, повышая MDE и требуемый n. Без обработки тест может длиться дольше или не детектировать эффект.

Решение: Robust statistics или удаление.

Методика сплитования (random, stratified, cluster) влияет на баланс групп.

Random: Просто, но может быть дисбаланс.

Stratified: Уменьшает дисперсию, снижая n.

Cluster: Для сетевых эффектов, но увеличивает n из-за intra-

cluster correlation.

Тип метрики: - Continuous (revenue): Высокая дисперсия → большой n. - Binary (conversion): $n \approx (Z^2 \cdot p \cdot (1-p))/\Delta^2$. - Ratio (ARPU): Более вариативны, требуют delta-method или bootstrap.

Чувствительные метрики с низкой дисперсией требуют меньше наблюдений.

Пропорции разбиения групп

Пропорции разбиения групп влияют на чувствительность теста. В стандартном случае группы делятся 50/50, но иногда используют неравные пропорции, например, 90/10, чтобы минимизировать риск для большинства пользователей.

Неравные пропорции увеличивают требуемый размер выборки, так как дисперсия оценки эффекта растет. Формула для минимального размера выборки при пропорциях p и (1-p):

$$n = (Z_{1-\alpha/2} + Z_{1-\beta})^2 * (\sigma_A^2/p + \sigma_B^2/(1-p))/\Delta^2,$$

где p — доля в группе A. Оптимально p=0.5 для равных дисперсий.

Удаление выбросов

Выбросы — экстремальные значения, которые искажают статистику. Их удаление может повысить чувствительность теста, уменьшив дисперсию.

Методы удаления:

- По порогам (например, >99-й перцентиль).
- Winsorization (замена на перцентиль).

Удаление снижает MDE, но рискует удалить реальные данные. Рекомендуется проверять влияние на результаты.

Замена метрики

Если основная метрика имеет высокую дисперсию, ее можно заменить на прокси-метрику с меньшей вариативностью, чтобы сократить длительность теста.

Например, вместо revenue per user использовать sessions per user, если они коррелированы. Это уменьшает требуемый n, но требует валидации корреляции.

Стратификация

Стратификация — разбиение выборки на страты по ключевым переменным (возраст, регион) и отдельный анализ в каждой.

Это уменьшает дисперсию внутри групп, повышая мощность. Пост-стратификация корректирует веса после сбора данных.

Процесс мониторинга

Мониторинг экспериментов в рамках A/B-тестирования помогает контролировать ход эксперимента, своевременно выявлять проблемы, принимать решения и обеспечивать точность и надёжность результатов. Основные метрики для мониторинга:

- целевые,
- guardrail,
- общие,
- технические (доступность сервиса, скорость загрузки).

Есть несколько аспектов мониторинга.

1. **Настройка мониторинга**. Для визуализации ключевых и второстепенных метрик с обновлением в желаемом временном диапазоне можно использовать дашборды. Например, Tableau с ежедневным обновлением метрик. Для работы с небольшими объёмами данны подходят BI-системы. В крупных компаниях при внушительном количестве экспериментов объём данных очень велик, и BI-системы менее эффективны с точки зрения скорости. В таких ситуациях стоит задуматься о создании собственного инструмента визуализации.
2. **Контрольные точки**. Нужно определить, как часто стоит проверять значения метрики. На этом этапе речь не идёт о p-hacking (его разберём в разделе 2.3). Пока мониторинг нужен исключительно для того, чтобы увидеть, сломалось что-то или нет. Смотреть на метрики можно хоть каждый день. Но принимать бизнесовое решение не стоит, пока эксперимент не закончился. Срок проведения эксперимента определяется на этапе дизайна. Следить за ключевыми метриками в динамике полезно, так как это может выявить проблемы в других процессах.

   Пример 16.4.1. **Пример 1** В оффлайн-магазине падает выручка. Менеджер Алина выясняет, что в этом магазине не хватает важных категорий товаров (это называется out-of-stock). Алина оповестила коллег, товары поставили, процесс возобновился.
3. **Мониторинг, но не принятие решения**. Тест не останавливается, если p-value упало ниже уровня значимости или если эффекта долгое время нет (p-value намного выше порога значимости и не приближается к нему). Важно сторого следовать дизайну, разработанному до старта эксперимента. Это поможет не упасть в p-hacking.
4. **Обнаружение проблем**. Мониторинг позволяет увидеть аномалии и выбросы в метриках. Это способствует оперативному реагированию на возникаюшие в системе проблемы.

   Пример 16.4.2. **Пример 2** У компании для изучения английского сломалось мобильное приложение для iOS. Количество уникальных пользователей резко упало, конверсии стали более вариативными, средняя конверсия за день снизилась. Аналитик Марина видит негативное влияние на метрики и должна решить, как отреагировать. Бывают ситуации, когда

группа B проявляет себя так плохо (например, из-за поломок системы), что возможна ранняя остановка теста.

На результаты эксперимента могут влиять другие эксперименты, особенно если не настроены механизмы разделения экспериментов по слоям. Почитать об этом (на английском) можно по ссылке. Корректно настроенный мониторинг позволяет увидеть неравномерное влияние других экспериментов на целевой A/B-тест: к примеру, мониторить количество экспериментов, в которых в конкретный момент времени принимает участие пользователь.

5. **Принятие решения**. Решение принимается на основе целевых метрик. Если их несколько, делается поправка на множественное тестирование. На другие метрики стоит обратить внимание, но статистической значимости они не несут.

   Пример 16.4.3. **Пример 3** Целевой метрикой в онлайн-кинотеатре может быть среднее время, проведённое пользователем на платформе, за день. Вторичные метрики: количество фильмов, которое пользователь посмотрел, количество заходов из рекомендуемого контента в просмотр трейлера.

6. Отдельно стоит отметить мониторинг guardrail-метрик (тех, которые не должны ухудшиться). Если в один из дней теста по ним обнаружится сильная просадка или прирост, нужно разбираться, в чём дело. Обычно величина, которую не нужно превышать, указывается в %. Если она превышается, нужно реагировать: выяснить причины и, при необходимости, решить, как их устранить.

Сущности мониторинга

Каждый эксперимент приносит много результатов по различным метрикам. Результаты нужно визуализировать максимально просто и без потери информации. В первую очередь стоит мониторить «здоровье» эксперимента:

- случайно ли распределяются пользователи между группами,
- сохраняется ли стратификация по важным показателям (пол, возраст, география). Если возникает сильное отлонение, нужно оперативно реагировать.

Главный отчёт по мониторингу должен содержать в себе информацию по каждой метрике в различных разрезах (желательно иметь встроенные фильтры в инструменте). Сравнения по метрикам можно производить на основе нескольких показателей.

- **MDE** (minimum detectable effect) — минимальный детектируемый эффект. Этот показатель важен, когда изменение статистически незначимо: если эффект есть, но не больше, чем MDE. Высокий показатель MDE говорит о сложности детектирования маленьких эффектов.
- **Результаты статистических тестов**. Здесь нужно отразить динамику p-value во времени и значения статистик. Конкретные просадки и сильные подъемы по p-value можно сопостав-

лять со «здоровьем» эксперимента, ведь могли произойти отклонения в разбиении пользователей или другие аномалии, которые повлекли к отклонению в статистических результатах. Но ориентироваться только на динамику p-value и останавливать тест раньше времени ни в коем случае нельзя, если не случилось что-то совсем плохое. Один из вариантов «плохого» — долгосрочная поломка блока рекомендаций в приложении. Это не позволит проводить тест, пока не будет устранена причина поломки.

- **Lift** — разница между группами в абсолютных значениях и в относительных (процентах). На основе этой разницы видно колебание разницы и степень стабилизации со временем.
- **Абсолютные значения метрик в группах**. Если речь идёт о ratio-метриках, стоит отдельно хранить и числитель, и знаменатель метрики. Здесь неплохой практикой будет применение статистических тестов и к числителю, и к знаменателю. Это позволит понять степень вклада числителя/знаменателя метрики.
- **Дисперсия метрик** (или стандартное отклонение). Поможет в динамике увидеть насколько метрика склонна к изменению вариативности во времени.

P-hacking

Определение. Под p-hacking понимается ситуация, когда проверку значений p-value проводят регулярно и решают, что эффект есть, если p-value пробил порог уровня значимости, либо что эффекта нет, если p-value долго не пробивает порог.

ОПРЕДЕЛЕНИЕ 16.4.1

Такие решения могут быть неверными и приводить к ухудшающим изменениям в стратегии развития продукта. Пример — на рисунке 361. На нём изображена динамика p-value по дням.

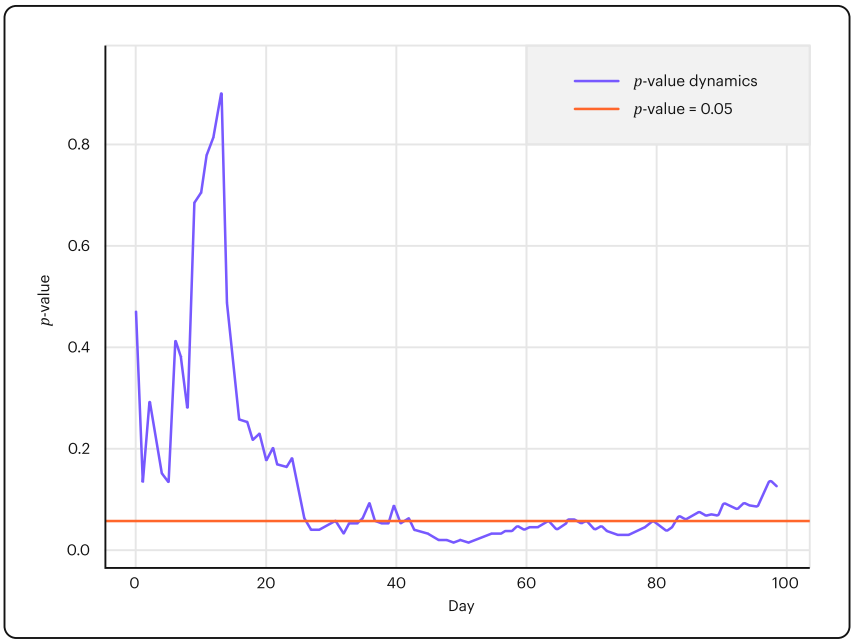

Рисунок 361. Пример поведения p-value во времени. Пробитие порога при отсутствии эффекта

- Каждый день накапливали по 100 наблюдений из нормального распределения в каждую группу (причём средние значения и дисперсии одинаковы).
- Примерно к 25 дню видно пробитие порога 0.05, которое держится продолжительное время, вплоть до 83 дня.
- Это поведение p-value может навлечь на мысль о наличии эффекта. Но на самом деле, как видно со временем, p-value выходит из этой просадки, что логично, ведь исходные группы распределены одинаково: мы взяли одинаковые нормальные распределения данных для каждой группы.

Разберёмся, в чём дело. Если слишком часто проверять p-value во время эксперимента, можно получить ложноположительные результаты, ведь каждый день производится расчёт нового статистического теста, а это множественное тестирование. Без корректировки на множественные сравнения (например, метод Бонферрони или метод Холма) вероятность совершения ошибок первого рода кратно возрастает. Это объясняется базовыми определениями теории вероятностей, ведь совершить ошибку первого рода хотя бы раз гораздо проще, чем сделать её в одном эксперименте.

Пример 16.4.4. **Пример 4** Аналитик Даниил проверяет p-value каждый день в течение 30 дней. Даже если никакого реального эффекта нет, вероятность того, что хотя бы в один из этих дней p-value будет меньше 0.05 (что указывает на значимость), существенно возрастает просто из-за случайности. Вероятность совершить ошибку первого рода каждый день составляет 5%. За 30 дней совершить хотя бы одну ошибку первого рода кратно растёт из-за соответствующих свойств вероятности.

Обратная ситуация: эксперимент с наличием положительного

эффекта долго не показывает этот эффект (p-value продолжительное время находится выше порога значимости).

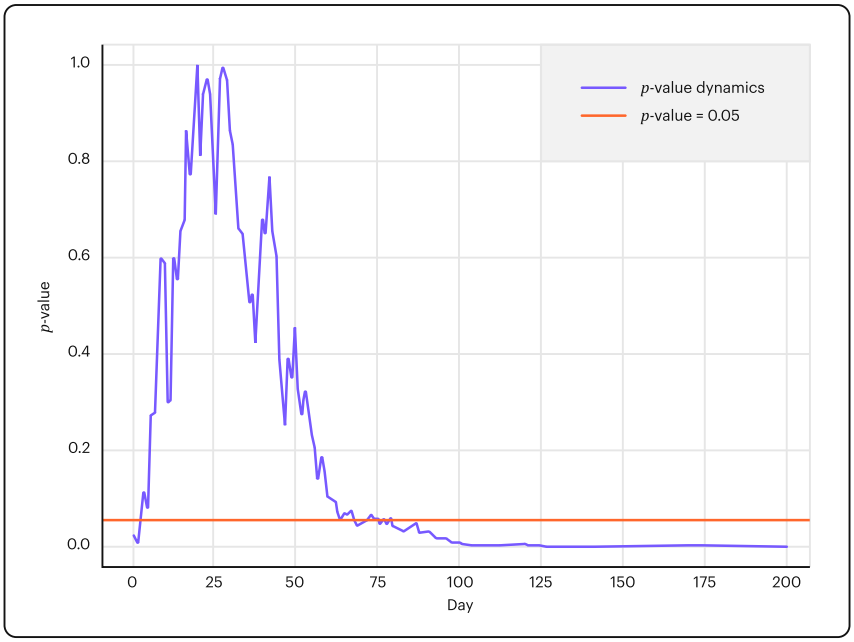

Рисунок 362. Пример поведения p-value во времени. Долгое непробитие порога при наличии эффекта

Кейс не оказывает никакого воздействия, если эксперимент был корректно спланирован. В этом случае тест можно проводить долго, ведь есть точный показатель минимального количества наблюдений, которое нужно накопить. Таким образом, могут наблюдаться следующие ситуации.

P-Hacking: раннее отсутствие прокраса

Раннее отсутствие прокраса — когда p-value долго остается выше порога значимости, несмотря на наличие эффекта. Это может привести к преждевременной остановке теста и ложному выводу об отсутствии эффекта. Важно дождаться запланированного размера выборки.

P-Hacking: ранний прокрас

Ранний прокрас — это ситуация, когда p-value падает ниже порога, создавая иллюзию значимости. Это часто ложноположительный результат из-за множественных проверок. Без корректировки приводит к ошибкам I рода.

5. МЕТОДЫ CUPED И CUPAC

Чувствительность A/B-теста определяется отношением сигнала (размер эффекта) к шуму (дисперсия оценки эффекта). Размер эффекта менять мы обычно не можем — он задан продуктом. Значит, остается работать со знаменателем: снижать дисперсию. Чем меньше дисперсия оценки, тем уже доверительный интервал и тем меньше данных нужно, чтобы поймать тот же эффект.

Важно! Идея

Снизить дисперсию оценки эффекта можно по-разному: увеличить поток наблюдений, подобрать пропорцию сплита, обрезать выбросы, заменить метрику на более чувствительную прокси, стратифицировать выборку. CUPED и CUPAC — самые практичные инструменты в этой задаче: они существенно повышают чувствительность теста, не требуя роста выборки или изменения дизайна эксперимента. Они объясняют часть разброса метрики с помощью вспомогательной переменной и вычитают ее, оставляя в данных только то, что относится к эксперименту.

Стратификация снижает дисперсию за счёт разбиения выборки на более однородные группы и устранения части межгруппового разброса. CUPED развивает ту же логику, но работает не с несколькими дискретными стратами, а с непрерывной ковариатой: например, с поведением пользователя до начала эксперимента. Метод вычитает из целевой метрики ту часть вариации, которую можно объяснить этой ковариатой, и тем самым повышает чувствительность теста. Поэтому CUPED и близкие к нему подходы стали стандартным инструментом в онлайн-экспериментах: их используют Microsoft, Netflix, Booking, DoorDash, Яндекс и другие компании.

Дальше мы разберем эту идею по шагам: от простой интуиции к формальному выводу и практическим правилам применения. Нам важно понять не только почему CUPED уменьшает шум, но и какую информацию можно вычитать из метрики, а какую уже нельзя.

Интуиция

Представьте, что мы тестируем новое оформление карточки кредитного продукта в банковском приложении и хотим понять, выросла ли средняя выручка с пользователя за неделю. Берём две случайные группы, неделю крутим тест, считаем выручку и применяем t-критерий.

Проблема в том, что выручка на пользователя обычно очень шумная. Один пользователь платит за подписку 200 рублей, другой совершает крупную операцию на 50000 рублей, а третий не платит вообще. Из-за такого разброса эффект в +30 рублей теряется в шуме: стандартный t-тест видит слишком большую вариативность внутри групп и не находит статистически значимого отличия.

Но у нас есть преимущество: мы знаем, сколько каждый пользователь платил до эксперимента, например неделей раньше. И здесь появляется ключевая идея CUPED (Controlled-experiment Using Pre-Experiment Data): поведение пользователей обычно устойчиво во времени. Тот, кто много платил до теста, с высокой вероятностью будет много платить и во время теста, и наоборот. Большая часть разброса в метрике объясняется не нашим изменением, а просто тем, какие пользователи попались.

Пример 16.5.1. Допустим, в идеальном мире каждый пользователь во время эксперимента тратит примерно столько же, сколько тратил раньше, плюс возможный эффект теста. Тогда вместо самой выручки Y можно смотреть на приращение: выручка во время эксперимента минус выручка до эксперимента.

Если траты пользователя стабильны, то в контроле такое приращение будет близко к нулю, а в тесте сместится на величину эффекта. Разброс, связанный с тем, что пользователи изначально разные, почти исчезает: мы смотрим, насколько каждый пользователь изменился относительно самого себя. Поэтому эффект в +30 рублей, который раньше терялся на фоне шумной выручки, становится гораздо заметнее.

В реальности люди не платят каждую неделю одинаково. Но частично инерция есть всегда, и именно ее CUPED умеет использовать. Формально CUPED не вычитает ковариату целиком, а вычитает её оптимальную долю θ — ровно столько, чтобы убрать максимум объяснимого шума и не добавить нового.

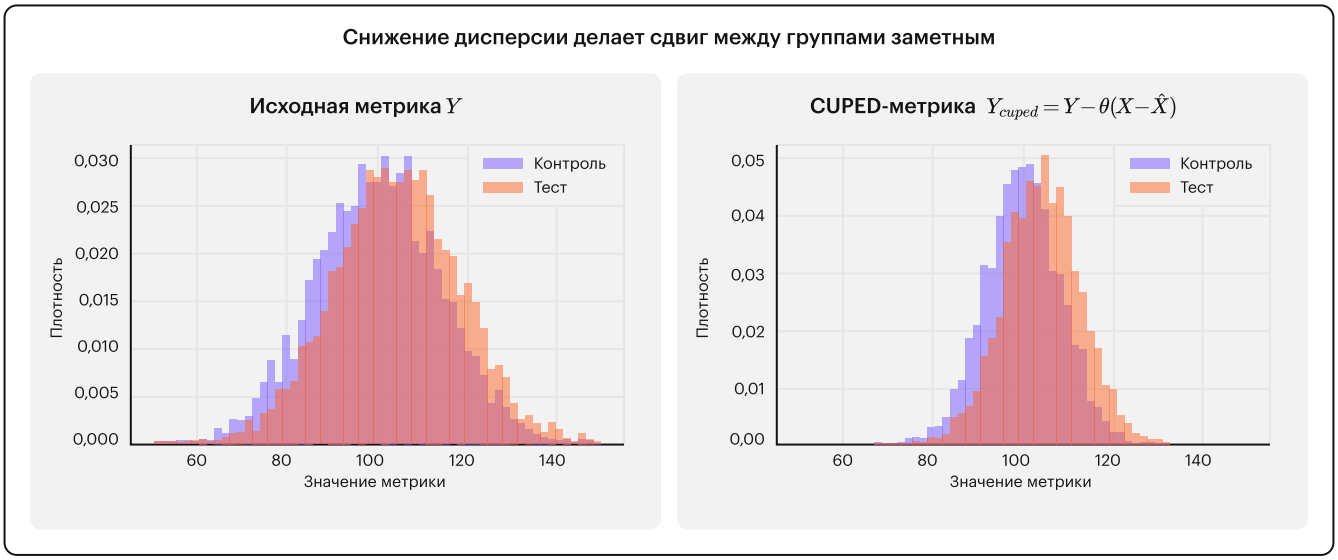

Рисунок 363. Слева показана исходная метрика Y: распределения контроля и теста почти полностью накладываются друг на друга, поэтому сдвиг между группами теряется на фоне шума. Справа показана CUPED-метрика: разброс внутри групп стал меньше, здесь почти втрое, и тот же самый сдвиг между контролем и тестом стал заметнее. Сам эффект не изменился, уменьшилась только вариативность метрики.

Формализация CUPED

Ковариата

Ковариата X — это вспомогательная переменная, измеренная для каждого объекта, к которой предъявляются два требования:

1. **Скоррелирована** с целевой метрикой Y. Чем сильнее связь, тем больше шума мы сможем объяснить и вычесть.
2. **Не зависит от эксперимента**: значение X не должно меняться от того, попал объект в контроль или в тест. Самый надёжный способ это гарантировать — брать данные, собранные до начала эксперимента, когда воздействия ещё не было.

Классический выбор ковариаты — значение той же метрики на периоде до эксперимента (например, выручка с пользователя за прошлую неделю). Но это не обязательно: подойдёт любой независимый от теста признак, коррелирующий с Y.

Подводный камень: Ошибка новичка

Если взять в качестве ковариаты величину, на которую влияет эксперимент, например саму метрику Y, посчитанную во время теста, CUPED начнёт вычитать не только шум, но и часть самого эффекта. В результате скорректированная метрика перестанет честно отражать различие между тестом и контролем: в предельном случае критерий будет почти всегда говорить, что отличий нет. Поэтому независимость ковариаты от воздействия — условие корректности метода.

CUPED-метрика

Пусть X — ковариата, связанная с итоговой метрикой Y. Например, X может быть выручкой пользователя за неделю до теста, а Y — выручкой во время теста.

Нам нужно убрать из Y ту часть разброса, которую можно объяснить через X. Для этого исходную метрику заменяют на скорректированную:

$$Y_{\text{cuped}} = Y - \theta(X - \mathbb{E}X).$$

Здесь θ — коэффициент, который показывает, насколько сильно нужно вычитать ковариату. Если X хорошо объясняет Y, то вычитание заметно уменьшит шум. Если связь слабая, оптимальный θ будет близок к нулю, и CUPED почти не изменит метрику.

Центрирование на $\mathbb{E}X$ нужно для того, чтобы не сдвинуть среднее метрики:

$$\mathbb{E}Y_{\text{cuped}} = \mathbb{E}Y - \theta\,\mathbb{E}(X - \mathbb{E}X) = \mathbb{E}Y.$$

То есть мы меняем дисперсию метрики, но не меняем её математическое ожидание.

На практике $\mathbb{E}X$ неизвестно, поэтому его заменяют общим средним $\bar{X}$, посчитанным по всем пользователям эксперимента. Тогда

для каждого пользователя вычитается индивидуальная поправка $\theta(X_i - \bar{X})$, но сама точка центрирования одна и та же для теста и контроля. Поэтому корректировка не добавляет отдельного группового сдвига и не меняет смысл оценки эффекта как разницы средних.

После такой корректировки эффект оценивается как обычно: берём разницу средних между тестом и контролем, но уже по CUPED-метрике:

$$\widehat{\Delta}_{\text{cuped}} = \overline{Y_{\text{cuped}}}^{t} - \overline{Y_{\text{cuped}}}^{c}.$$

Важно! Несмещённость

Запишем оценку эффекта по CUPED-метрике:

$$\widehat{\Delta}_{\text{cuped}} = \bar{Y}^t - \bar{Y}^c - \theta(\bar{X}^t - \bar{X}^c).$$

Ковариата X измеряется до эксперимента и не зависит от назначения пользователя в тест или контроль. Поэтому в матожидании средние ковариаты в двух группах совпадают: $\mathbb{E}\bar{X}^t = \mathbb{E}\bar{X}^c$.

Значит, CUPED-поправка в среднем не создаёт дополнительного сдвига между группами:

$$\mathbb{E}\big[\theta(\bar{X}^t - \bar{X}^c)\big] = 0.$$

Отсюда

$$\mathbb{E}\widehat{\Delta}_{\text{cuped}} = \mathbb{E}(\bar{Y}^t - \bar{Y}^c) = \Delta.$$

Оценка эффекта остаётся несмещённой при любом θ. Поэтому θ можно выбирать ради уменьшения дисперсии.

Оптимальный θ и величина выигрыша

Раз θ ни на что, кроме дисперсии, не влияет — выберем его так, чтобы дисперсия была минимальной. Дисперсия оценки среднего по CUPED-метрике (для группы из n объектов):

$$\begin{aligned}
\operatorname{Var}\big(\overline{Y_{\text{cuped}}}\big) &= \frac{1}{n}\operatorname{Var}(Y - \theta(X - \mathbb{E}X)) \\
&= \frac{1}{n}\operatorname{Var}(Y - \theta X) \\
&= \frac{1}{n}\Big(\operatorname{Var} Y - 2\theta\operatorname{cov}(Y, X) + \theta^2 \operatorname{Var} X\Big)
\end{aligned}$$

Как функция от θ это парабола ветвями вверх (коэффициент при θ^2 равен $\operatorname{Var} X > 0$). Минимум — там, где производная по θ

обнуляется:

$$\frac{\partial}{\partial\theta}\Big(\operatorname{Var}Y - 2\theta\operatorname{cov}(Y,X) + \theta^2\operatorname{Var}X\Big) = -2\operatorname{cov}(Y,X) + 2\theta\operatorname{Var}X = 0,$$

откуда

$$\boxed{\theta_0 = \frac{\operatorname{cov}(Y,X)}{\operatorname{Var}X}}$$

Подставим θ_0 обратно в (16.5) и вспомним определение корреляции $\rho = \dfrac{\operatorname{cov}(Y,X)}{\sqrt{\operatorname{Var}Y\,\operatorname{Var}X}}$:

$$\min_\theta \operatorname{Var}\big(\overline{Y_{\text{cuped}}}\big) = \frac{\operatorname{Var}Y}{n}\left(1-\rho^2\right).$$

Важно! Суть метода

CUPED уменьшает дисперсию ровно в $\left(1-\rho^2\right)$ раз, где ρ — корреляция ковариаты с метрикой. Выигрыш зависит только от силы связи и совсем не зависит от размера эффекта.

$\rho = 0.3 \to -9\%$ дисперсии, $\rho = 0.5 \to -25\%, \rho = 0.7 \to -49\%, \rho = 0.9 \to -81\%.$

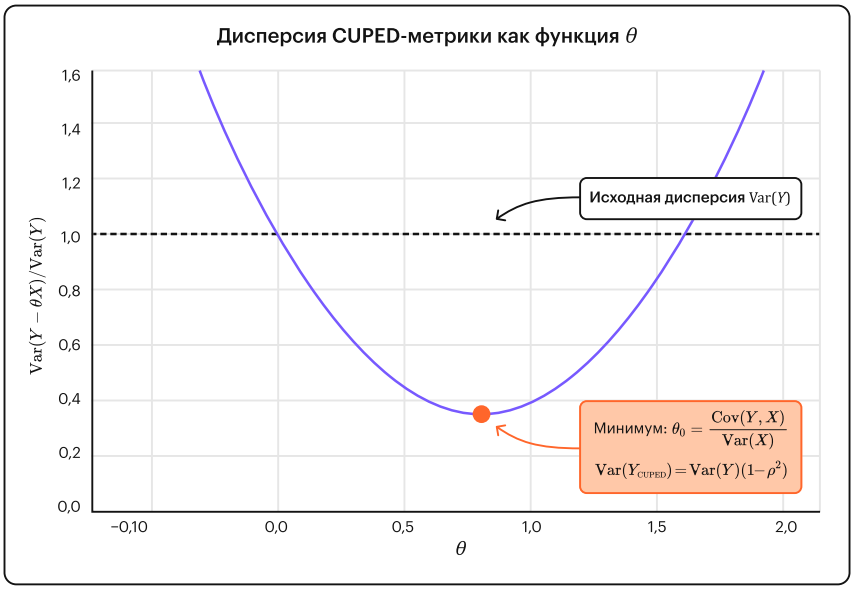

Рисунок 364. Дисперсия CUPED-метрики — парабола по θ. В точке $\theta_0 = \operatorname{cov}(Y,X)/\operatorname{Var}X$ она минимальна и равна $\operatorname{Var}Y\,(1-\rho^2)$. При $\theta = 0$ возвращаемся к обычной метрике (пунктир). При слишком большом θ дисперсия может стать больше исходной — недобор и перебор одинаково вредны.

Почему снижение дисперсии так ценно? Необходимый объём выборки растёт примерно линейно с дисперсией. Значит, снижение дисперсии на ρ^2 — это эквивалентная экономия ρ^2 доли наблюдений (или, что то же, длительности теста).

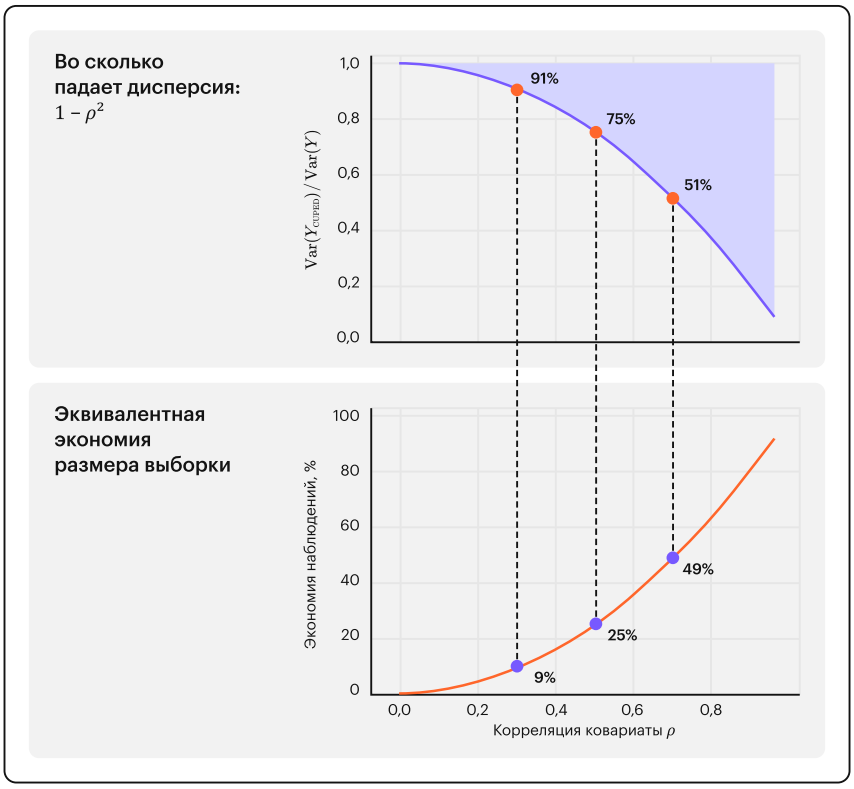

Рисунок 365. Слева: какая доля дисперсии остаётся после CUPED. Справа: эквивалентная экономия размера выборки. Даже небольшая корреляция $\rho = 0.5$ экономит четверть данных, а $\rho = 0.7$ — почти половину.

CUPED — это регрессия

Формула (16.5) не случайно выглядит знакомой: $\theta_0 = \mathrm{cov}(Y, X) / \mathrm{Var}\, X$ — это в точности коэффициент наклона в простой линейной регрессии Y на X. CUPED-метрика $Y_{\mathrm{cuped}} = Y - \theta_0(X - \mathbb{E}X)$ (или, с точностью до константы, $Y - \theta_0 X$) — это остатки этой регрессии.

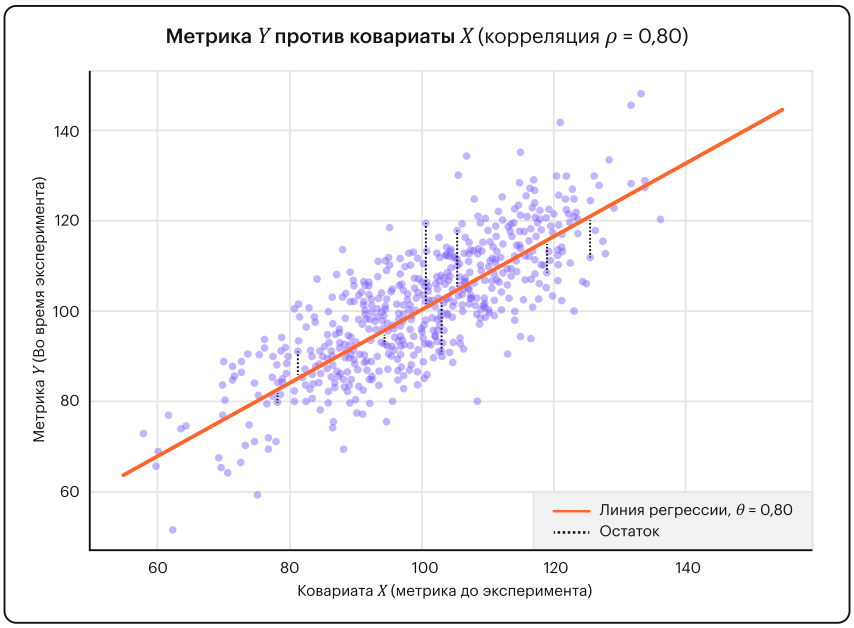

Рисунок 366. θ — наклон линии регрессии Y на X. CUPED вычитает предсказуемую часть метрики (саму линию) и оставляет только остатки (серые отрезки) — тот разброс, который ковариатой не объясняется.

Оценить эффект по CUPED-метрике можно и через обычную регрессию. Введём индикатор группы T_i: он равен 1, если пользователь попал в тест, и 0, если пользователь попал в контроль. Тогда рассмотрим модель

$$Y_i = \beta_0 + \Delta \cdot T_i + \gamma \cdot X_i + \varepsilon_i.$$

Коэффициент Δ при индикаторе T_i оценивает эффект эксперимента, а ковариата X_i выступает как контрольная переменная. Это ANCOVA — дисперсионный анализ с ковариатой. По смыслу это та же идея, что и в CUPED: ковариата объясняет часть разброса в Y_i, связанную с предэкспериментальным поведением пользователя. После учёта этой части в остатке остаётся меньше случайного шума, поэтому стандартная ошибка оценки эффекта снижается.

Важно! Зачем нам это понимать

Если в CUPED мы добавляем ковариату в регрессию, то ничто не мешает добавить несколько ковариат сразу или ковариату, которая является сложной нелинейной функцией многих признаков. Именно эта мысль ведет нас к CUPAC, где ковариату строит ML-модель.

Алгоритм

Алгоритм применения CUPED помещается в пять пунктов:

1. Для каждого объекта в обеих группах вычислить метрику Y.
2. Для каждого объекта вычислить ковариату X (например, мет-

рику за период до теста).

3. Оценить $\theta = \dfrac{\operatorname{cov}(Y, X)}{\operatorname{Var} X}$ (о том, на каких данных, поговорим далее).
4. Пересчитать $Y_{\text{cuped}} = Y - \theta\,(X - \bar{X})$ для каждого объекта.
5. Прогнать обычный статистический критерий (t-тест) на значениях Y_{cuped}.

Пример 16.5.2. Пять объектов, группа 0 — контроль, 1 — тест, $\theta = 0.5$.

группа	ковариата X	метрика Y	θ	$Y_{\text{cuped}} = Y - \theta(X - \bar{X})$
0	4	5	0.5	6.0
1	5	7	0.5	7.5
1	6	8	0.5	8.0
0	7	7	0.5	6.5
0	8	7	0.5	6.0

Дальше t-критерий сравнивает Y_{cuped} контроля $\{6.0, 6.5, 6.0\}$ и теста $\{7.5, 8.0\}$ — но уже с заметно меньшим разбросом, чем у исходного Y.

Пример 16.5.3. Прогоним 3000 синтетических A/B-тестов с истинным эффектом $\Delta = 3$, шумом $\sigma = 14$ и ковариатой с корреляцией $\rho = 0.7$. Сравним распределение оценки эффекта для обычного t-теста и для CUPED.

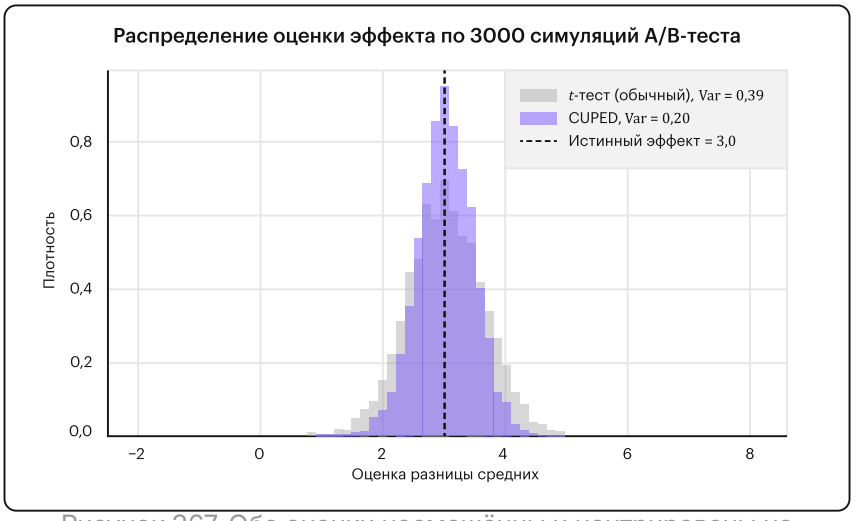

Рисунок 367. Обе оценки несмещённы и центрированы на истинном эффекте 3.0. Но облако CUPED-оценок вдвое уже: дисперсия упала с 0.39 до 0.20, отношение ≈ 0.52. Формула обещала $1 - \rho^2 = 1 - 0.49 = 0.51$ — совпадение почти идеальное.

Как выбирать ковариату

Самое творческое в CUPED — выбор X. От него зависит ρ, а значит и весь выигрыш. Несколько проверенных вариантов:

- **Метрика на периоде до теста.** Например, «выручка за прошлую неделю», «число заказов за прошлый месяц». Просто считать, трудно ошибиться, ковариата гарантированно независима от теста. Важно брать период, который наиболее полно опишет поведение метрики.
- **Сезонность.** Если в поведении есть периодичность, в качестве ковариаты берут значение метрики в аналогичный период прошлого сезона (та же неделя год назад).
- **Любой независимый признак.** Город, платформа, возраст аккаунта, давность первой покупки — всё, что коррелирует с Y и не зависит от теста.
- **Предсказание ML-модели.** Обучить модель предсказывать Y по множеству независимых признаков и использовать её прогноз как одну ковариату. Это и есть CUPAC, о котором мы поговорим далее.

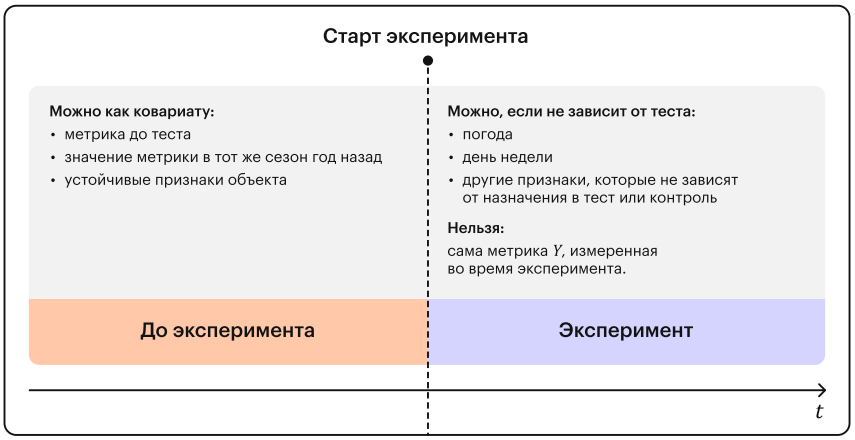

Рисунок 368. Что и когда измеряется. Ковариата должна быть слева от старта или хотя бы независимой от воздействия. Брать в ковариату то, на что эксперимент влияет, нельзя.

На каких данных оценивать θ

θ — это оценка, и важно, на чём её считать. Есть три варианта: на объединённых данных обеих групп, на одной группе, на исторических данных до теста.

1. Если группы большие (тысячи наблюдений, эксперимент почти не меняет связь X и Y): оценивайте θ на объединённых данных контроля и теста — это даёт максимальную мощность. Для маленьких групп оценка θ на исторических данных надёжнее, потому что по десятку точек из самого теста θ переобучается.
2. Если оценить θ только по контролю или только по тесту, на малых данных он может подстроиться под случайные колебания именно этой группы и переоценить снижение её дисперсии. Для другой группы такая поправка уже не обязана работать так же хорошо, поэтому случайные отклонения чаще будут выглядеть как настоящий эффект. В результате растёт ошибка первого рода, а на A/A-тестах это проявляется как неравномерное распределение p-value. **Симметрия важна:**

одно и то же θ применяем к обеим группам.

3. Вывод про выигрыш $1 - \rho^2$ опирается на то, что связь между ковариатой X и метрикой Y остаётся стабильной. Если воздействие меняет эту связь, например в тесте корреляция стала слабее или приобрела другую форму, фактическое снижение дисперсии может оказаться меньше ожидаемого. А если θ оценён на устаревших исторических данных, корректировка может начать вычитать не ту часть разброса и в итоге дать меньше мощности, чем обычный t-тест. Поэтому перед использованием CUPED стоит проверять его на свежих A/A-тестах или исторических псевдоэкспериментах.

Связь между X и Y может меняться со временем. На ранних этапах развития продукта, когда постоянных пользователей ещё мало, корреляция между метрикой и её прошлым значением может быть слабой. По мере взросления сервиса она часто становится выше. Поэтому коэффициент θ стоит оценивать на свежих данных, иначе выигрыш от CUPED может оказаться заметно меньше ожидаемого.

Бинарные метрики

Частый вопрос: работает ли CUPED для бинарных метрик, например конверсии или retention? Да. На уровне пользователя бинарная метрика имеет вид $Y_i \in \{0, 1\}$, а её среднее по группе равно интересующей нас доле. Поэтому формула (16.5) применяется без изменений:

$$Y_{i,\text{cuped}} = Y_i - \theta(X_i - \bar{X}).$$

Ковариатой может быть флаг того же события на периоде до теста: совершал ли пользователь покупку, возвращался ли в продукт, оформлял ли заявку. Иногда более информативной оказывается не бинарная, а числовая ковариата, например число сессий или покупок до эксперимента. Требование остаётся тем же: она должна быть измерена до воздействия и коррелировать с итоговым флагом.

После преобразования $Y_{i,\text{cuped}}$ уже не обязан быть равен только нулю или единице и может даже немного выходить за отрезок $[0, 1]$. Это не ошибка: CUPED-значение не интерпретируется как индивидуальная вероятность. Нас интересует разница групповых средних, которая остаётся оценкой изменения конверсии в процентных пунктах.

Для исходного флага $\text{Var}(Y) = p(1 - p)$. При оптимальном θ потенциальный выигрыш остаётся тем же:

$$\text{Var}(Y_{\text{cuped}}) = \text{Var}(Y)(1 - \rho^2),$$

где ρ — корреляция ковариаты с бинарным исходом. На практике она часто ниже, чем для выручки или числа действий, поэтому снижение дисперсии может быть умеренным. Но на больших продуктовых тестах даже выигрыш в 5–15% заметно сокращает требуемую выборку.

Пример 16.5.4. Пусть мы тестируем новый экран оплаты. В контроле конверсия равна 10.0%, в тесте — 10.7%, то есть исходная оценка эффекта составляет $+0.7$ п.п. В качестве ковариаты берём флаг покупки тем же пользователем за предыдущие 14 дней.

Предположим, доля ранее покупавших пользователей равна $\bar{X} = 0.20$, а оценённый коэффициент $\theta = 0.25$. Тогда для пользователя, который покупал до теста, но не купил сейчас, скорректированное значение будет

$$0 - 0.25(1 - 0.20) = -0.20$$

Для пользователя без покупки в прошлом, который купил во время теста, получим

$$1 - 0.25(0 - 0.20) = 1.05$$

Значения -0.20 и 1.05 не являются вероятностями. Поправка лишь учитывает, что первый пользователь изначально был более склонен к покупке, а второй — менее склонен. После усреднения по группам CUPED сохраняет эффект $+0.7$ п.п. в матожидании, но уменьшает разброс оценки.

Например, при корреляции $\rho = 0.35$ остаётся доля дисперсии $1 - 0.35^2 = 0.8775$: дисперсия и необходимая выборка уменьшаются примерно на 12.25%.

От CUPED к CUPAC

CUPED обычно использует одну заранее выбранную ковариату и линейную поправку. Но если смотреть на CUPED как на регрессионную корректировку, появляется естественное обобщение: вместо одной простой ковариаты можно использовать более богатое предсказание.

Так устроен CUPAC (Control Using Predictions As Covariates): в роли ковариаты выступает прогноз ML-модели. Модель заранее предсказывает значение целевой метрики по данным, не зависящим от эксперимента, а затем это предсказание используется для снижения дисперсии.

Идея

Берём признаки объекта, которые известны до эксперимента и не могут измениться под его воздействием. На этих данных обучаем модель $\hat{g}$, которая предсказывает целевую метрику:

$$\hat{Y} = \hat{g}(\text{признаки, независимые от теста}).$$

Это предсказание $\hat{Y}$ и используем как единственную ковариату в CUPED:

$$Y_{\text{cupac}} = Y - \theta\left(\hat{Y} - \mathbb{E}\hat{Y}\right).$$

Поскольку признаки не зависят от назначения в группы, предсказание $\hat{Y}$ тоже не зависит — значит, его можно брать в ковариа-

ты, и оценка эффекта остаётся несмещённой. Величина выигрыша, как и раньше, определяется корреляцией ковариаты с метрикой. CUPAC прямо оптимизирует эту (частную) корреляцию через качество модели.

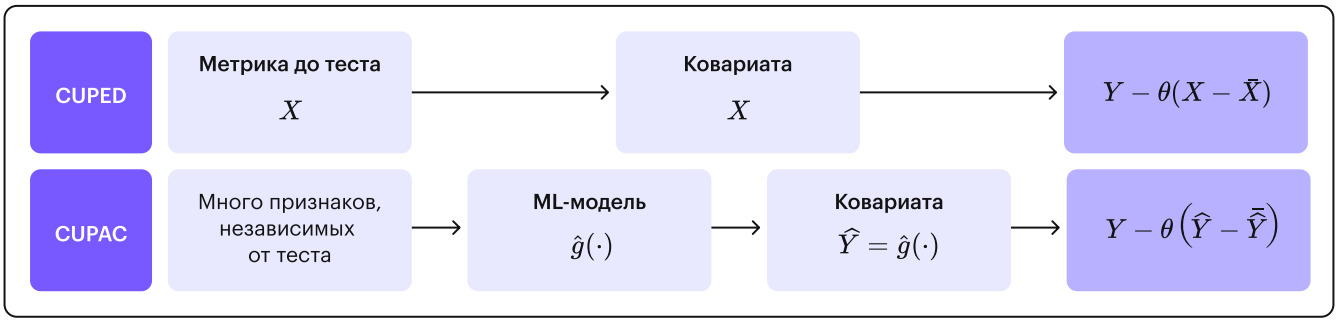

Рисунок 369. Разница между методами только в том, что используется как ковариата. В CUPED это исходная метрика, измеренная до эксперимента. В CUPAC — прогноз ML-модели, которая учится предсказывать целевую метрику по множеству признаков, не зависящих от эксперимента. После этого применяется та же CUPED-формула.

Зачем вообще ML, если есть CUPED

В DoorDash CUPAC придумали для метрики ASAP — полного времени готовки и доставки заказа. Эта метрика очень шумная: она зависит от типа ресторана (ресторан готовит дольше фастфуда), расстояния до клиента, текущего трафика. Авторы выделяют три причины, почему ML-ковариата лучше:

1. **Нет простой доэкспериментальной метрики.** В некоторых задачах объект эксперимента сложно описать одной исторической метрикой. Например, в логистике конкретной доставки ещё не существует до теста. Можно использовать отдельные агрегаты, например среднее значение за тот же час неделю назад, но они отражают лишь часть информации. ML-модель объединяет множество доступных признаков и строит более точное предсказание целевой метрики.
2. **Есть нелинейности и взаимодействия.** Связь между признаками и метрикой редко бывает строго линейной. Модель может учитывать взаимодействия признаков и сложные зависимости, которые обычная линейная поправка легко пропускает.
3. **Проще использовать много признаков.** Вместо большого набора категориальных ковариат и one-hot-кодирования с высокой кардинальностью можно использовать один прогноз модели. Он сжимает информацию из многих признаков в одну ковариату для CUPAC.

Цифры из индустрии

В DoorDash CUPAC применяли в экспериментах, где изменение включалось и выключалось по расписанию для разных районов и временных интервалов. Такой подход позволил сократить длительность тестов более чем на 25% при сохранении мощности. В

офлайн-симуляциях средняя длительность эксперимента снижалась почти на 40% относительно базового анализа без контролей и на 15–20% относительно альтернативных методов контроля.

Ширина доверительного интервала уменьшается как корень из дисперсии, а необходимый объём данных — примерно линейно с дисперсией. Поэтому даже умеренное снижение дисперсии может заметно ускорить эксперимент.

Когда метод не подходит

Перед тем как доверять CUPED/CUPAC, проверяем:

- **Есть ли связь с метрикой.** Если ρ близка к нулю, выигрыша почти не будет. Случайная ковариата не снизит дисперсию.
- **Нет ли утечки эффекта.** Ковариата должна быть измерена до эксперимента или гарантированно не зависеть от воздействия. Нельзя использовать посттритмент-переменные: клики по новому элементу, число показов новой механики, время после открытия изменённого экрана. Они находятся на причинном пути от воздействия к метрике, поэтому корректировка может принять реальный продуктовый эффект за объяснимый шум и вычесть его.

  Пример 16.5.5. Пусть новый рекомендательный блок увеличил среднее число просмотренных товаров с 5 до 6, поэтому обычная оценка эффекта равна

  $$\widehat{\Delta}_Y = 6 - 5 = 1.$$

  Аналитик ошибочно взял ковариатой X число кликов по этому новому блоку во время эксперимента. В контроле блока нет, поэтому $\bar{X}^c = 0$, а в тесте пользователи в среднем делают два клика: $\bar{X}^t = 2$. Если на тех же данных получено $\theta = 0.5$, CUPED даст

  $$\widehat{\Delta}_{\text{cuped}} = \widehat{\Delta}_Y - \theta(\bar{X}^t - \bar{X}^c) = 1 - 0.5 \cdot 2 = 0.$$

  В результате CUPED вычел не случайный шум, а часть эффекта эксперимента, так как различие в числе кликов между группами возникло из-за появления нового блока.
- **Корректно ли обработаны метрики-отношения.** Сначала нужно различить среднее пользовательской метрики и отношение двух случайных сумм. Например, revenue per randomized user можно посчитать как обычное среднее пользовательской выручки и применить CUPED напрямую. Но CTR $= \sum_i C_i / \sum_i I_i$ или средний чек $= \sum_i R_i / \sum_i O_i$ являются ratio-метриками: пользователи имеют разные знаменатели, а у части объектов знаменатель может быть равен нулю. Применять CUPED к индивидуальным отношениям C_i / I_i обычно неправильно.
  Для ratio-метрики сначала строят линеаризованную пользова-

тельскую величину. Пусть

$$M = \frac{\sum_i A_i}{\sum_i B_i}, \qquad m_0 = \frac{\mathbb{E}A}{\mathbb{E}B}$$

— базовое значение отношения, заранее оценённое на независимой истории. Тогда для каждого пользователя рассчитывают

$$L_i = A_i - m_0 B_i.$$

Величина L_i показывает, насколько вклад пользователя отличается от ожидаемого при базовом значении метрики. Если $L_i > 0$, пользователь дал больше результата, чем ожидалось; если $L_i < 0$, меньше.
Для группы среднее линеаризованной метрики равно

$$\bar{L} = \bar{A} - m_0 \bar{B} = \bar{B}\left(\frac{\bar{A}}{\bar{B}} - m_0\right).$$

Поэтому отклонение ratio-метрики от базового значения можно записать как

$$M - m_0 = \frac{\bar{L}}{\bar{B}}.$$

Если среднее значение знаменателя в тесте и контроле меняется незначительно, разницу между группами можно оценить как

$$\widehat{M}^t - \widehat{M}^c \approx \frac{\bar{L}^t - \bar{L}^c}{\bar{B}_0},$$

где $\bar{B}_0$ — базовое среднее значение знаменателя на пользователя.
После линеаризации обычную CUPED-поправку применяют к L_i:

$$L_{i,\text{cuped}} = L_i - \theta(X_i - \bar{X}),$$

где X_i — независимая доэкспериментальная ковариата, например линеаризованное значение CTR пользователя на прошлом периоде.

Пример 16.5.6. Пусть на историческом периоде было 1000 кликов на 10000 показов. Тогда базовый CTR равен

$$m_0 = \frac{1000}{10000} = 0.10.$$

Для каждого пользователя во время эксперимента считаем

$$L_i = C_i - 0.10 I_i,$$

где C_i — число кликов, а I_i — число показов.
Например, пользователь с одним кликом из двух показов получает

$$L_i = 1 - 0.10 \cdot 2 = 0.8.$$

При базовом CTR 10% от двух показов ожидалось 0.2 клика,

а пользователь совершил один. Поэтому его результат на 0.8 клика выше базового уровня.
Для пользователя с десятью кликами из ста показов

$$L_i = 10 - 0.10 \cdot 100 = 0.$$

Его CTR совпадает с базовым значением 10%, поэтому отклонение равно нулю.
На периоде до эксперимента аналогично строим ковариату

$$X_i = C_i^{\text{pre}} - 0.10 I_i^{\text{pre}}.$$

Затем применяем CUPED к L_i и сравниваем средние скорректированных значений между группами:

$$L_{i,\text{cuped}} = L_i - \theta(X_i - \bar{X}).$$

Чтобы выразить результат в пунктах CTR, разницу средних делят на базовое среднее число показов на пользователя:

$$\widehat{\Delta}_{\text{CTR}} \approx \frac{\bar{L}^t_{\text{cuped}} - \bar{L}^c_{\text{cuped}}}{\bar{I}_0}.$$

Для проверки статистической значимости выполнять обратный пересчёт необязательно: деление на одну и ту же положительную константу меняет масштаб оценки, но не меняет t-статистику и p-value.

- **Стабильна ли связь между X и Y.** Если связь меняется со временем или под воздействием эксперимента, оценённый θ перестаёт быть оптимальным. Поэтому CUPED/CUPAC стоит проверять на A/A-тестах или исторических псевдоэкспериментах: они показывают, сохраняется ли корректность критерия и какой выигрыш получается на практике.

6. ДРУГИЕ МЕТОДЫ СНИЖЕНИЯ ДИСПЕРСИИ

В этой главе разберём методы, которые применяют, когда базового набора недостаточно: оценку Лина, MLRATE, триггерный анализ, интерливинг, линеаризацию метрик-отношений и взвешивание по дисперсии.

Перечисленные методы меняют разные части эксперимента:

1. **Дизайн**, как пользователи видят сравниваемые варианты
2. **Данные и метрика**, какие наблюдения входят в анализ и какое число считается для каждой единицы рандомизации
3. **Оценка эффекта**, как из собранных данных получить разницу между тестом и контролем

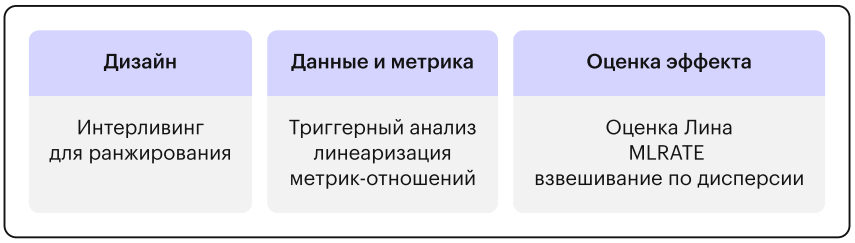

Рисунок 370. Методы этой главы работают на разных этапах эксперимента.

Какие задачи решают методы

Каждый из методов убирает конкретный источник шума или исправляет конкретную ошибку анализа.

Пользователи сильно различаются ещё до теста. Один пользователь делает десятки заказов, другой не делает ни одного. Если это различие можно предсказать по данным до эксперимента, его частично убирают оценка Лина и MLRATE. В задачах ранжирования интерливинг идёт дальше и сравнивает алгоритмы внутри одной выдачи.

Изменение затрагивает только небольшую часть аудитории. Эффект среди затронутых пользователей разбавляется нулевым эффектом остальных. Здесь помогает триггерный анализ.

Метрика считается как отношение сумм. Для CTR, среднего чека и похожих метрик единица расчёта не совпадает с единицей рандомизации. Линеаризация возвращает анализ на уровень пользователя.

Шум у пользователей неодинаков. Несколько нестабильных пользователей могут определять почти всю дисперсию. Взвешивание по дисперсии уменьшает их вклад, но одновременно меняет смысл оценки.

Оценка Лина: разные связи в тесте и контроле

Почему общего наклона может быть недостаточно

В регрессионной записи CUPED целевая метрика Y_i объясняется индикатором группы T_i и ковариатой X_i, измеренной до эксперимента:

$$Y_i = \beta_0 + \Delta T_i + \theta X_i + \varepsilon_i.$$

Модель использует один коэффициент θ для теста и контроля. Это означает, что связь между X и Y считается одинаковой в обеих группах.

На практике это не всегда так. Например, новая механика может сильнее влиять на активных пользователей. Тогда в тесте зависимость Y от прошлой активности будет круче, чем в контроле.

Одна общая прямая не сможет точно описать обе группы, поэтому снижение дисперсии окажется меньше ожидаемого. В небольших выборках и при неравном сплите такая корректировка может быть даже менее точной, чем простая разница средних.

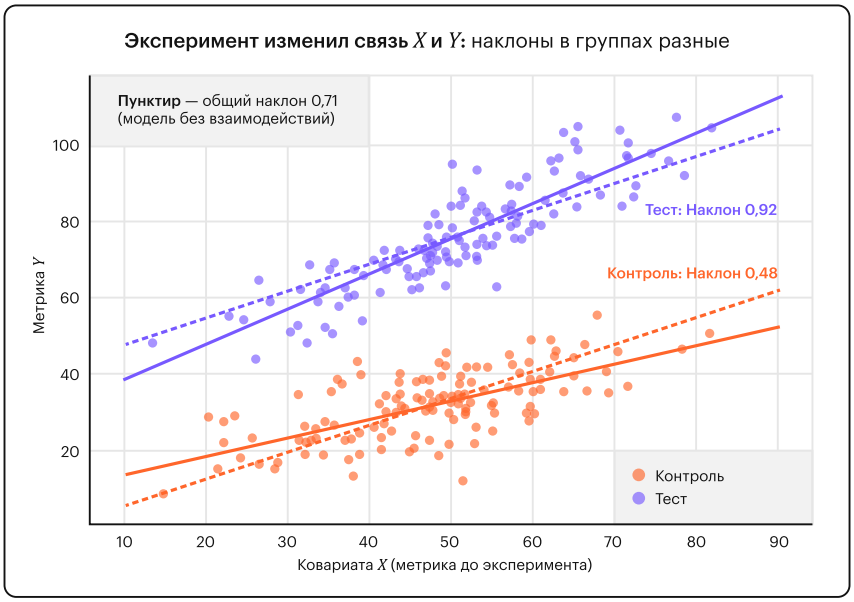

Рисунок 371. В симуляции наклон в тесте равен $0{,}92$, а в контроле $0{,}48$. Модель без взаимодействия оценивает общий наклон $0{,}71$ и не описывает точно ни одну группу.

Модель с взаимодействием

Оценка Лина позволяет учитывать, что связь между X и Y может различаться в тесте и контроле. Для этого ковариату центрируют и добавляют в модель взаимодействие между группой и ковариатой:

$$Y_i = \beta_0 + \Delta T_i + \theta(X_i - \bar{X}) + \gamma T_i(X_i - \bar{X}) + \varepsilon_i.$$

В контроле наклон равен θ. В тесте он равен $\theta + \gamma$. Коэффициент Δ сравнивает группы в точке $X = \bar{X}$, то есть после одинакового центрирования ковариаты.

Для построения доверительных интервалов используют робастные стандартные ошибки, например HC2 или HC3. Они не требуют, чтобы разброс остатков был одинаковым для всех пользователей, и поэтому подходят при гетероскедастичности.

Что даёт оценка Лина При случайном распределении пользователей по группам оценка среднего эффекта остаётся состоятельной, даже если линейная модель описывает связь между X и Y неточно.

- если ковариата помогает объяснить метрику, дисперсия оценки снижается
- если ковариата бесполезна, систематического ухудшения не возникает

- в больших выборках дисперсия не превышает дисперсию простой разницы средних
- для доверительных интервалов используют робастные стандартные ошибки

Эти гарантии асимптотические. В отдельном небольшом эксперименте дисперсия может случайно оказаться выше.

Модель отдельно оценивает связь между X и Y в тесте и контроле, а затем убирает из метрики объяснимую часть разброса. Эффект оценивается по той части Y, которую ковариата не объяснила. Если X хорошо связан с метрикой, случайный разброс уменьшается. Если связь слабая, корректировка почти не влияет на результат.

Когда использовать

Оценка Лина полезна, когда есть одна или несколько сильных ковариат до эксперимента и есть основания ожидать разные связи в тесте и контроле. Особенно уместна она при неравном сплите и при неоднородном эффекте по уровню ковариаты.

Если выборка большая, связь стабильна и нужен максимально простой пайплайн, обычного CUPED часто достаточно. Оценка Лина нужна не вместо CUPED во всех случаях, а как более устойчивый регрессионный вариант.

MLRATE

Почему модель нельзя обучать и применять на одной выборке

В CUPAC прогноз модели используют как ковариату. Чем лучше он объясняет итоговую метрику, тем сильнее может снизиться дисперсия оценки.

Проблема возникает, если модель обучают на тех же пользователях и значениях Y_i, на которых затем оценивают эффект. Гибкая модель может подстроиться не только под устойчивую связь между признаками и метрикой, но и под случайные колебания конкретной выборки.

Тогда остаточный разброс выглядит меньше, чем он есть на самом деле. Стандартные ошибки оказываются заниженными, доверительные интервалы слишком узкими, а в A/A-тестах статистически значимые различия возникают чаще заданного уровня.

Как устроен MLRATE

MLRATE сочетает кросс-фиттинг и регрессию Лина.

1. данные делят на K фолдов
2. для каждого фолда обучают модель на остальных $K - 1$ фолдах

3. модель строит прогнозы только для отложенного фолда
4. все вневыборочные прогнозы объединяют в одну ковариату
5. эффект оценивают регрессией Лина с робастными стандартными ошибками

Признаки должны быть известны до воздействия и не зависеть от назначения в тест или контроль.

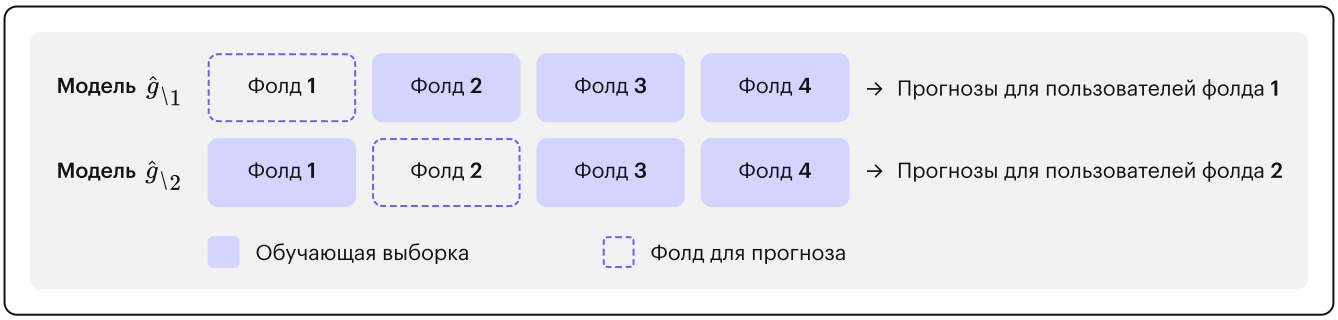

Рисунок 372. Для каждого фолда обучают отдельную модель на данных остальных фолдов. Поэтому прогноз для пользователя строит модель, которая не использовала при обучении значения целевой метрики из его фолда.

Пусть $k(i)$ обозначает номер фолда, в который попал пользователь i. Модель $\hat{g}_{\setminus k(i)}$ обучена на всех фолдах, кроме $k(i)$. Кросс-фит-прогноз для пользователя i равен

$$\hat{g}_i^{\mathrm{cf}} = \hat{g}_{\setminus k(i)}(X_i).$$

Обозначим среднее кросс-фит-прогнозов по всем пользователям через

$$\bar{g}^{\mathrm{cf}} = \frac{1}{n}\sum_{i=1}^{n} \hat{g}_i^{\mathrm{cf}}.$$

Затем прогноз используют как ковариату в регрессии Лина:

$$Y_i = \beta_0 + \Delta T_i + \theta\big(\hat{g}_i^{\mathrm{cf}} - \bar{g}^{\mathrm{cf}}\big) + \gamma T_i\big(\hat{g}_i^{\mathrm{cf}} - \bar{g}^{\mathrm{cf}}\big) + \varepsilon_i.$$

Кросс-фиттинг не позволяет модели использовать значение Y_i при построении прогноза для пользователя i. Регрессия Лина учитывает, что связь прогноза с метрикой может различаться в тесте и контроле. Если прогноз хорошо объясняет Y, остаточный разброс уменьшается. Если прогноз бесполезен, его коэффициенты стремятся к нулю, и в больших выборках точность оценки не становится хуже, чем у простой разницы средних.

Результат на данных Facebook

Авторы MLRATE проверили метод на 48 продуктовых метриках Facebook. В A/A-тестах дисперсия оценки снизилась более чем на 70% по сравнению с простой разницей средних и примерно на 19% по сравнению с корректировкой только по прошлому значению метрики.

MLRATE требует отдельного ML-пайплайна: подготовки признаков, разбиения данных на фолды, обучения моделей, сохранения кросс-фит-прогнозов и последующего регрессионного анализа.

Метод стоит внедрять, когда более простые подходы уже работают стабильно, но дают недостаточное снижение дисперсии. Сначала обычно проверяют CUPED и оценку Лина, затем сравнивают MLRATE с ними на исторических A/A-тестах.

Триггерный анализ: только затронутые пользователи

Пример 16.6.1.

Предположим, мы меняем экран оплаты. До него доходит только 10% пользователей. Для остальных 90% тест и контроль выглядят одинаково: изменение не могло повлиять на их метрику.

Если эффект среди дошедших равен $+3\%$, то в среднем по всей аудитории он равен примерно $+0{,}3\%$. Сигнал уменьшается в десять раз, а шум незатронутых пользователей остаётся.

Триггерный анализ оставляет пользователей, для которых варианты теста действительно могли различаться. Такой пользователь называется затронутым (triggered).

Как меняется чувствительность

Рассмотрим упрощённый случай. В каждой группе есть N пользователей, доля затронутых равна p, шум одинаков для всех и равен σ, эффект среди затронутых равен Δ.

Если анализировать всех пользователей, наблюдаемый эффект равен $p\Delta$:

$$z_{\text{all}} = \frac{p\Delta}{\sigma\sqrt{2/N}}.$$

Если оставить только затронутых, в каждой группе останется примерно pN пользователей:

$$z_{\text{trig}} = \frac{\Delta}{\sigma\sqrt{2/(pN)}}.$$

Отношение статистик равно

$$\frac{z_{\text{trig}}}{z_{\text{all}}} = \frac{1}{\sqrt{p}}.$$

При $p = 0{,}1$ статистика теста увеличивается в

$$\frac{1}{\sqrt{p}} = \frac{1}{\sqrt{0{,}1}} \approx 3{,}16$$

раза. В рамках этой упрощённой модели для достижения той же

мощности достаточно выборки, составляющей

$$p = 0{,}1$$

от выборки при анализе по всей аудитории, то есть примерно в $1/p = 10$ раз меньше.

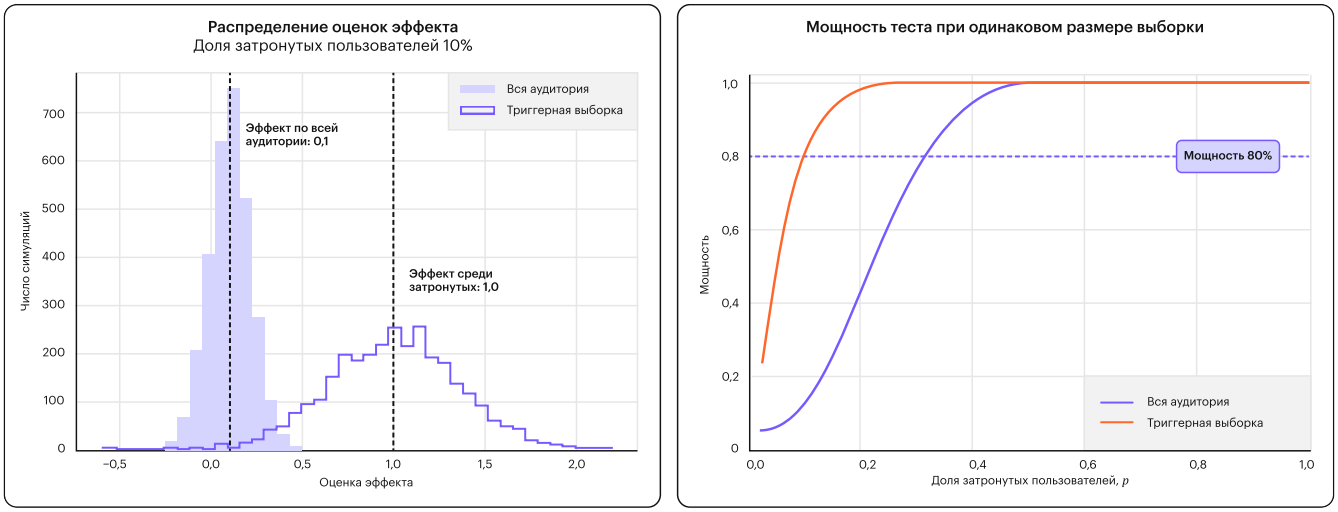

Рисунок 373. Слева показаны распределения оценок эффекта при анализе всей аудитории и триггерной выборки для $p = 10\%$. Справа показана мощность двух подходов при одинаковом размере выборки. Чем меньше доля затронутых пользователей, тем сильнее эффект разбавляется при анализе всей аудитории.

Как связаны триггерный и глобальный эффекты

Для аддитивной метрики на уровне пользователя глобальный эффект можно восстановить по формуле

$$\Delta_{\text{all}} = p\Delta_{\text{trig}},$$

где p — доля затронутых пользователей в общей аудитории.

Формула работает при трёх условиях:

- среди незатронутых пользователей эффект равен нулю
- попадание в триггерную подгруппу не зависит от назначения в тест или контроль
- доля p рассчитана для той же аудитории, на которую переносится эффект

Для метрик-отношений простого умножения на p обычно недостаточно. Воздействие может по-разному менять числитель и знаменатель, поэтому глобальный эффект нужно восстанавливать с учётом структуры самой метрики.

Подводный камень. Как определить затронутых пользователей

В тесте видно, кто столкнулся с новой механикой. В контроле нужно определить, кто дошёл бы до той же точки продукта.

Поэтому триггер задают одинаковым правилом для обеих групп. Иначе различие может возникнуть из-за отбора пользователей, а

не из-за эффекта эксперимента.

У пользователей вне триггерной выборки эффект должен быть близок к нулю. Иначе триггер либо не охватывает всех затронутых пользователей, либо сам зависит от воздействия эксперимента.

Интерливинг для сравнения ранжирований

Как сравнить два алгоритма в одной выдаче

Интерливинг применяют для быстрого сравнения алгоритмов поиска, рекомендаций и ранжирования ленты.

В обычном A/B-тесте одна группа пользователей видит ранжирование A, а другая — ранжирование B. На результат влияют не только алгоритмы, но и различия между пользователями: их интересы, активность и привычки.

При интерливинге элементы из двух ранжирований объединяют в одну выдачу. Пользователь видит результат работы обоих алгоритмов, поэтому сравнение проходит внутри одного просмотра. Каждый клик засчитывается алгоритму, который добавил выбранный элемент.

В одном из распространённых вариантов интерливинга общую выдачу формируют так:

1. алгоритмы A и B строят собственные списки
2. случайно выбирается алгоритм, который добавляет элемент первым
3. алгоритмы по очереди добавляют лучший элемент, которого ещё нет в общей выдаче
4. клик засчитывается алгоритму, добавившему выбранный элемент

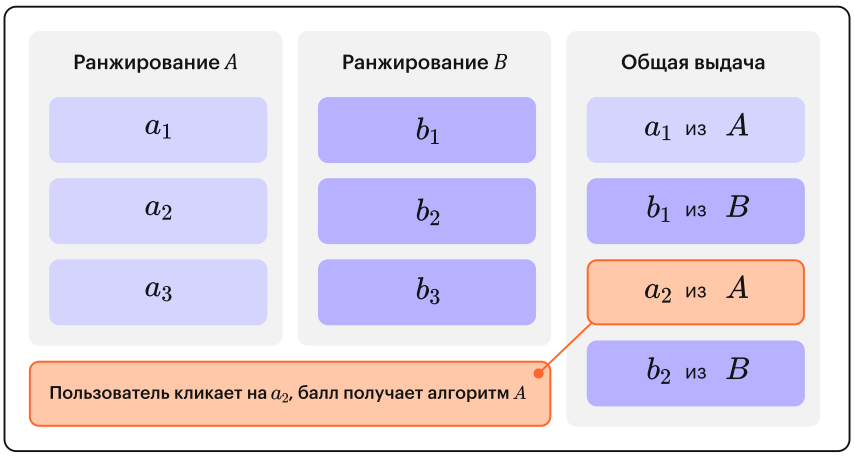

Рисунок 374. Элементы двух алгоритмов попадают в одну выдачу. Клик засчитывается алгоритму, который добавил выбранный элемент.

Для каждого просмотра можно посчитать разницу между числом кликов по элементам A и B. Если пользователи чаще выби-

рают элементы одного алгоритма, он получает положительное преимущество.

Интерливинг снижает влияние различий между пользователями, но не заменяет обычный A/B-тест. Он показывает, какое ранжирование пользователи предпочитают, но не оценивает изменение бизнес-метрик, например выручки или удержания.

Почему метод чувствительнее A/B

Интерливинг похож на парное сравнение. Пользователь оценивает два алгоритма в одном контексте: с тем же запросом, намерением и моментом времени. Большая часть межпользовательского разброса исчезает.

В исследовании Microsoft на 38 парах экспериментов и более чем 3 млрд кликов чувствительность интерливинга была на один-два порядка выше чувствительности соответствующих A/B-метрик.

Важно! Для чего используют интерливинг Интерливинг помогает быстро понять, какое ранжирование пользователи предпочитают. Но он не оценивает напрямую влияние на выручку, удержание и другие бизнес-метрики.

Поэтому интерливинг используют для отбора кандидатов, а финальное решение принимают по результатам A/B-теста.

Линеаризация: метрика-отношение на уровне пользователя

Когда нельзя считать события независимыми

Рассмотрим CTR (долю кликов среди показов):

$$R = \frac{\sum_i N_i}{\sum_i D_i},$$

где N_i обозначает число кликов пользователя i, а D_i число его показов.

Рандомизация проходит по пользователям, но в числителе и знаменателе находятся события. Показы одного пользователя зависимы: у него своя вероятность клика и свой объём активности. Если считать каждый показ независимым наблюдением, стандартная ошибка обычно будет занижена.

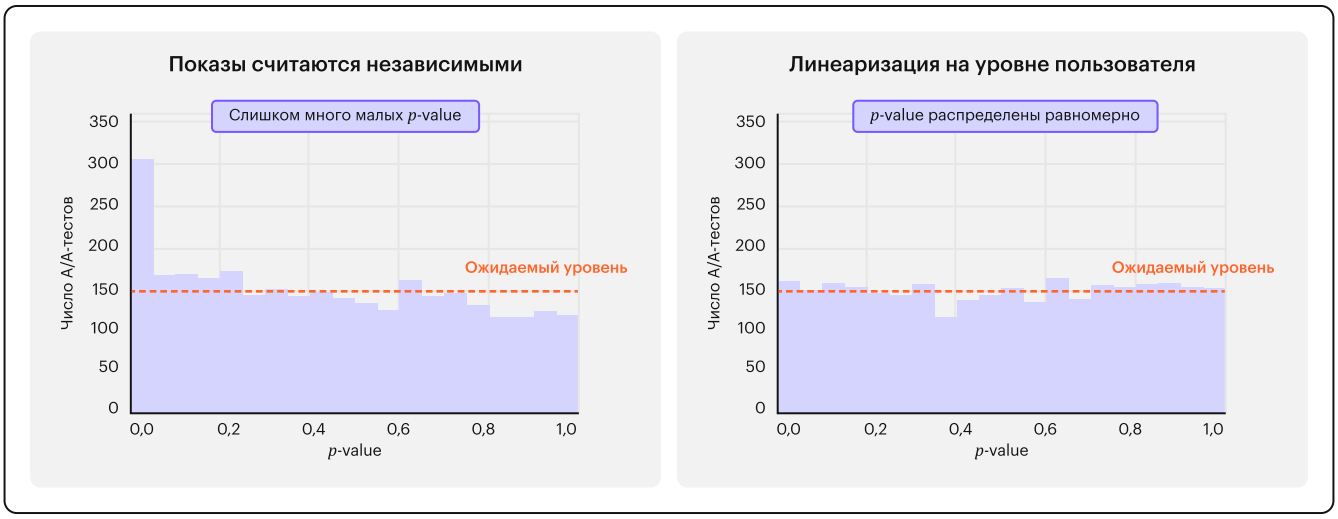

Рисунок 375. В корректном A/A-тесте p-value распределены равномерно. Если считать отдельные показы независимыми, зависимость событий одного пользователя не учитывается и малые p-value появляются слишком часто. Линеаризация переводит анализ на уровень пользователя и восстанавливает ожидаемое распределение p-value.

Дельта-метод

Если для каждого пользователя известны числитель N_i и знаменатель D_i, дисперсию оценки отношения можно приблизить формулой

$$\mathrm{Var}(\hat{R}) \approx \frac{1}{n\bar{D}^2}\left(\mathrm{Var}(N) - 2R\mathrm{cov}(N,D) + R^2\,\mathrm{Var}(D)\right).$$

В формулу входят разброс числителя, разброс знаменателя и связь между ними. Если считать отдельные события независимыми, эта зависимость теряется.

Переход к метрике на уровне пользователя

Линеаризация присваивает каждому пользователю одно число. Сначала фиксируют базовое отношение K. Чаще всего его считают по контролю:

$$K = \frac{\sum_{i\in c} N_i}{\sum_{i\in c} D_i}.$$

Затем для каждого пользователя вычисляют

$$L_i = N_i - K D_i.$$

Если пользователь дал больше кликов, чем ожидалось при базовом CTR и его числе показов, L_i положительно. Если меньше, отрицательно.

В контроле среднее L_i равно нулю по построению. В тесте

$$\bar{L}_t = \bar{D}_t(R_t - R_c),$$

поэтому знак разницы средних по L_i совпадает со знаком изменения исходной метрики. Саму разницу в CTR можно восстановить как

$$R_t - R_c = \frac{\bar{L}_t}{\bar{D}_t}.$$

Важно! Что даёт линеаризация После преобразования каждому пользователю соответствует одно значение L_i. Дальше можно использовать обычные методы для метрик на уровне пользователя: t-тест, стратификацию, CUPED и CUPAC, оценку Лина, MLRATE.

Линеаризация не обязательно снижает дисперсию сама по себе. Её основная задача: преобразовать метрику-отношение в метрику на уровне единицы рандомизации, чтобы к ней можно было корректно применять статистические критерии, CUPED и другие методы анализа.

Взвешивание по дисперсии: шумным пользователям меньший вес

Чем метод отличается от обрезки хвоста

Обрезка хвоста ограничивает слишком большие значения метрики во время эксперимента. Это уменьшает влияние выбросов, но меняет саму метрику.

Взвешивание действует иначе. Для каждого пользователя заранее оценивают, насколько нестабильна его метрика. Пользователь с высокой ожидаемой дисперсией получает меньший вес, пользователь со стабильным поведением больший.

Формула оценки

Пусть $\hat{\sigma}_i^2$ обозначает оценку индивидуальной дисперсии по данным до эксперимента. Тогда можно взять веса

$$w_i \propto \frac{1}{\hat{\sigma}_i^2}$$

и сравнить взвешенные средние:

$$\widehat{\Delta}_w = \frac{\sum_{i \in t} w_i Y_i}{\sum_{i \in t} w_i} - \frac{\sum_{i \in c} w_i Y_i}{\sum_{i \in c} w_i}.$$

Идея совпадает с взвешенным методом наименьших квадратов: более точные наблюдения сильнее влияют на оценку.

Вес $1/\hat{\sigma}_i^2$ может быть нестабильным. Если оценка дисперсии для одного пользователя случайно окажется близкой к нулю, его наблюдение получит слишком большой вес и начнёт определять итоговый результат.

Чтобы этого избежать, к дисперсии добавляют положительную константу λ:

$$w_i = \frac{1}{\hat{\sigma}_i^2 + \lambda}.$$

Параметр λ сглаживает различия между весами. Дополнительно веса можно ограничить сверху, чтобы ни одно наблюдение не получало чрезмерного влияния.

Рисунок 376. Симуляция 4000 экспериментов с разной индивидуальной дисперсией. Взвешенная оценка остаётся центрированной на истинном эффекте в модели с одинаковым эффектом для всех пользователей, а её дисперсия ниже на 26%.

В одном из кейсов Facebook взвешивание снизило дисперсию оценки в среднем примерно на 17%.

Подводный камень. Взвешивание меняет смысл оценки Если эффект одинаков для всех пользователей, взвешенная и обычная оценки совпадают по смыслу.

Если эффект различается между пользователями, взвешивание меняет целевую величину. Пользователи с более стабильными наблюдениями получают больший вес, поэтому итог сильнее отражает именно их эффект, а не средний эффект по всей аудитории.

Это может быть нежелательно, если самые шумные пользователи при этом важны для бизнеса. Поэтому веса строят только по данным до эксперимента, одинаково применяют в тесте и контроле и заранее проверяют, какой эффект в итоге оценивается.

Как выбрать метод

Ситуация	Метод	Что проверить
Связь ковариаты с метрикой может различаться в тесте и контроле	Оценка Лина	Ковариаты измерены до эксперимента, стандартные ошибки рассчитаны робастно
Есть много признаков и сложная связь с метрикой	MLRATE	Для каждого пользователя прогноз построен моделью, которая не обучалась на данных его фолда
Изменение затрагивает только часть аудитории	Триггерный анализ	Триггер определяется одинаково в обеих группах, вне триггерной выборки эффект близок к нулю
Сравниваются алгоритмы ранжирования	Интерливинг	Оба алгоритма сравниваются в одинаковых условиях
Метрика представлена отношением двух сумм	Линеаризация	Числитель и знаменатель рассчитаны на уровне единицы рандомизации
Пользователи различаются по точности наблюдений	Взвешивание по дисперсии	Веса рассчитаны независимо от воздействия, а взвешенный эффект соответствует бизнес-вопросу

Что запомнить

- оценка Лина учитывает, что связь ковариаты с метрикой может различаться в тесте и контроле
- MLRATE использует прогноз ML-модели и строит его с помощью кросс-фиттинга, чтобы отделить обучение от оценки эффекта
- триггерный анализ убирает шум незатронутых пользователей, если триггер одинаково определяется в обеих группах
- интерливинг помогает быстро сравнивать алгоритмы ранжирования, но не оценивает эффект на бизнес-метрики
- линеаризация преобразует метрику-отношение в метрику на уровне единицы рандомизации
- взвешивание по дисперсии может повысить точность, но при неоднородном эффекте меняет смысл оценки

Методы можно комбинировать. Например, для CTR среди затронутых пользователей можно сформировать триггерную выборку, затем линеаризовать метрику и применить CUPED или оценку Лина.

Приложение В. Теория информации

1. ОТ СООБЩЕНИЙ К КОЛИЧЕСТВУ ИНФОРМАЦИИ

В предыдущих частях уже появились три объекта, которые будут постоянно возвращаться в этом приложении: логарифмическое правдоподобие, оценка максимального правдоподобия и информация Фишера. Там они возникали как инструменты параметрической статистики. Теперь мы посмотрим на них с другой стороны. Оказывается, все эти конструкции естественно выражаются через язык информации: через среднюю неопределённость распределения, цену кодирования данных неверной моделью и локальную геометрию семейства распределений.

Такой язык удобен не только в математической статистике, но и в машинном обучении. Когда классификатор минимизирует логарифмическую функцию потерь, когда вероятностная модель максимизирует правдоподобие, когда оптимизация учитывает матрицу Фишера, фактически речь идёт об одном и том же вопросе: насколько хорошо выбранное распределение описывает данные и как дорого обходится отклонение от истинного распределения.

Равномерный алфавит и длина кода

Начнём с простого конечного алфавита. Пусть есть четыре символа

$$\mathcal{A} = \{A, B, C, D\}.$$

Если все символы равновероятны, то каждый из них можно закодировать двумя битами:

$$A \mapsto 00, \qquad B \mapsto 01, \qquad C \mapsto 10, \qquad D \mapsto 11.$$

Две бинарные позиции дают $2^2 = 4$ кодовых слова. В общем случае для равновероятного алфавита из m символов естественная длина кода равна примерно $\log_2 m$ бит на символ. Если считать натуральными логарифмами, та же величина измеряется в *натах*:

$$\ln m = (\log_2 m) \ln 2.$$

Нат — единица количества информации, соответствующая натуральному логарифму. Самоинформация события вероятности e^{-1} равна одному нату, поскольку $-\ln(e^{-1}) = 1$. Пересчёт между натами и битами задаётся формулами

$$1 \text{ нат} = \log_2 e \approx 1.443 \text{ бита}, \qquad 1 \text{ бит} = \ln 2 \approx 0.693 \text{ ната}.$$

Далее формулы будут записываться через натуральный логарифм. Для перехода от натов к битам достаточно разделить ответ на $\ln 2$.

В статье 1948 года Клод Шеннон отмечал, что выбор основания логарифма означает выбор единицы измерения, а единицы при

основании e называл *естественными единицами*.[1] Современное название и обозначение *нат* входят в стандарт единиц для информационных наук IEC 80000-13.[2]

Равномерный русский алфавит

Пример 17.1.1. Алфавит из 33 равновероятных букв требует

$$\log_2 33 \approx 5.04$$

бита на букву. Пяти бит не хватает, так как $2^5 = 32$, а шести бит уже достаточно, так как $2^6 = 64$. Если сообщение состоит из n независимых букв такого алфавита, то всего возможных сообщений 33^n, и для их различения требуется $n \log_2 33$ бит.

Если буквы встречаются с разными вероятностями, равномерный код перестаёт быть естественным. Частому символу выгодно дать короткое кодовое слово, а редкому — более длинное. Именно эта идея приводит к энтропии как нижней границе средней длины кодирования и к префиксным кодам переменной длины.

A A A B C D

Символ	Равномерный код	Код с учётом частот
A	00	0
B	01	10
C	10	110
D	11	111

Рисунок 377. Схема кодирования частых и редких символов. Более частый символ получает более короткое кодовое слово.

Код Хаффмана

Код на рисунке 377 можно получить алгоритмом Хаффмана. Алгоритм начинает с символов и их вероятностей, затем многократно объединяет два узла с наименьшими весами. Рёбра полученного двоичного дерева помечаются нулём и единицей, а код символа читается как путь от корня к соответствующему листу.

Полученный код префиксный: ни одно кодовое слово не является началом другого, поэтому поток битов декодируется без разделителей между символами. Для заданных вероятностей алгоритм Хаффмана минимизирует среднюю длину

$$L = \sum_{j=1}^{k} p_j \ell_j$$

среди всех двоичных префиксных кодов, где ℓ_j — целая длина кодового слова для j-го символа. Длины ℓ_j должны быть целыми, поэтому средняя длина кода обычно не совпадает в точности

[1] C. E. Shannon. *A Mathematical Theory of Communication*. Bell System Technical Journal, 1948.
[2] IEC 80000-13:2025. *Quantities and units — Part 13: Information science and technology*.

с информационной нижней границей. Связь этой границы с энтропией будет формализована ниже.

Дэвид Хаффман нашёл этот алгоритм, работая над учебной задачей в MIT, и опубликовал результат в 1952 году.[3] Ключевым вкладом стала простая конструктивная процедура, которая превращает принцип «частым символам — короткие слова» в алгоритм с доказанной оптимальностью. Она сделала префиксное кодирование стандартным инженерным компонентом сжатия: например, формат DEFLATE сочетает алгоритм LZ77 с кодами Хаффмана и используется в gzip,[4] а базовый режим классического JPEG использует коды Хаффмана на этапе энтропийного кодирования.[5]

Самоинформация и неизбежность логарифма

Пусть $I(p)$ обозначает количество информации в наблюдении исхода с вероятностью p. Вместо того чтобы сразу выбирать формулу, зафиксируем свойства, которых ожидаем от такой величины.

1. Достоверный исход не сообщает ничего нового: $I(1) = 0$.
2. Чем меньше вероятность исхода, тем больше полученная информация; функция $I(p)$ непрерывна и строго убывает по p.
3. Информация от двух независимых исходов складывается. Поскольку их joint probability равна pq, должно выполняться

$$I(pq) = I(p) + I(q).$$

Последнее требование связывает вероятность, которая для независимых событий перемножается, с информацией, которая должна складываться. Именно такой переход от произведения к сумме выполняет логарифм.

УТВЕРЖДЕНИЕ 17.1.1

Если непрерывная функция $I\colon (0,1] \to [0,\infty)$ обладает перечисленными свойствами, то существует константа $c > 0$ такая, что

$$I(p) = -c \ln p.$$

Доказательство. Положим $x = -\ln p$ и определим $g(x) = I(e^{-x})$ для $x \geqslant 0$. Тогда для любых $x, y \geqslant 0$

$$g(x+y) = I\left(e^{-(x+y)}\right) = I\left(e^{-x}e^{-y}\right) = g(x) + g(y).$$

Непрерывная аддитивная функция на неотрицательной полуоси линейна, поэтому $g(x) = cx$. Чем больше $x = -\ln p$, тем меньше p и тем больше информация, следовательно, $c > 0$. Возвращаясь к p, получаем

$$I(p) = g(-\ln p) = -c \ln p.$$

□

Итак, сформулированные требования определяют логарифмиче-

[3] D. A. Huffman. *A Method for the Construction of Minimum-Redundancy Codes*. Proceedings of the IRE, 1952; историческая справка UC Santa Cruz.
[4] P. Deutsch. *DEFLATE Compressed Data Format Specification version 1.3*. RFC 1951, 1996.
[5] JPEG Committee. *JPEG 1*.

скую меру с точностью до положительного множителя. При $c = 1$ информация измеряется в натах. Нормировка $I(1/2) = 1$ даёт $c = 1/\ln 2$ и измерение в битах:

$$I(p) = -\log_2 p.$$

Основание логарифма меняет единицу, но не порядок событий по информативности и не свойство аддитивности.

Этот вывод относится к информации одного исхода. Энтропия появится в следующем разделе как среднее значение самоинформации; её аксиоматическое описание требует отдельного набора условий.

Пример 17.1.2. Если честная монета выпала орлом, то $p = 1/2$ и

Частый и редкий символ

$$-\ln(1/2) = \ln 2$$

ната, то есть ровно один бит информации. Если в потоке сообщений буква встречается с вероятностью 0.9, её появление несёт только $-\ln 0.9 \approx 0.105$ ната. Для буквы с вероятностью 0.01 получаем $-\ln 0.01 \approx 4.605$ ната.

Важно, что информация не является свойством символа самого по себе. Она определяется распределением: один и тот же символ может быть почти предсказуемым в одном источнике сообщений и редким в другом.

2. ЭНТРОПИЯ, КРОСС-ЭНТРОПИЯ И KL-ДИВЕРГЕНЦИЯ

Энтропия дискретного распределения

Пусть случайная величина принимает значения $a_1, \dots, a_k$ с вероятностями $p_1, \dots, p_k$, где $\sum_{j=1}^{k} p_j = 1$.

ОПРЕДЕЛЕНИЕ 17.2.1

Энтропией дискретного распределения P называется средняя самоинформация исхода:

$$H(P) = -\sum_{j=1}^{k} p_j \ln p_j,$$

где по соглашению $0 \ln 0 = 0$.

Иначе говоря, энтропия показывает, сколько информации в среднем даёт одно наблюдение из распределения P.

Пример 17.2.1. Для честной монеты $P = (1/2, 1/2)$ энтропия равна

Монета и неравномерное распределение

$$H(P) = -\frac{1}{2}\ln\frac{1}{2} - \frac{1}{2}\ln\frac{1}{2} = \ln 2,$$

то есть одному биту. Для смещённой монеты $P = (0.9, 0.1)$ получаем

$$H(P) = -0.9\ln 0.9 - 0.1\ln 0.1 \approx 0.325$$

ната, или примерно 0.469 бита. Неопределённость меньше, потому что один из исходов почти предсказуем.

Если $P = (1/2, 1/4, 1/8, 1/8)$, то

$$H(P) = \frac{1}{2}\ln 2 + \frac{1}{4}\ln 4 + \frac{1}{8}\ln 8 + \frac{1}{8}\ln 8 = \frac{7}{4}\ln 2.$$

В битах это 1.75. Равномерное распределение на четырёх исходах имело бы энтропию 2 бита, поэтому перекос вероятностей уменьшил неопределённость.

Если энтропия измеряется в битах,

$$H_2(P) = -\sum_{j=1}^{k} p_j \log_2 p_j = \frac{H(P)}{\ln 2},$$

то средняя длина L_{Huff} кода Хаффмана удовлетворяет оценке

$$H_2(P) \leqslant L_{\mathrm{Huff}} < H_2(P) + 1.$$

Нижняя граница задаётся энтропией, а зазор возникает из-за того, что длины отдельных кодовых слов должны быть целыми.

УТВЕРЖДЕНИЕ 17.2.1

Для дискретного распределения P на k исходах выполнены неравенства

$$0 \leqslant H(P) \leqslant \ln k.$$

Левая граница достигается только на вырожденном распределении, а правая — на равномерном распределении $p_1 = \ldots = p_k = 1/k$.

Доказательство. Обозначим через $S = \{j : p_j > 0\}$ носитель распределения, а через $r = |S|$ число исходов с положительной вероятностью. Слагаемые с $p_j = 0$ не вносят вклад, поэтому

$$H(P) = \sum_{j \in S} p_j \ln \frac{1}{p_j}.$$

Отсюда сразу следует $H(P) \geqslant 0$, причём равенство возможно только при $r = 1$, то есть когда вся масса лежит в одной точке.

Для верхней границы применим неравенство Йенсена к вогнутой функции $\ln$ на носителе S:

$$H(P) = \sum_{j \in S} p_j \ln \frac{1}{p_j} \leqslant \ln\left(\sum_{j \in S} p_j \frac{1}{p_j} \right) = \ln r \leqslant \ln k.$$

Равенство $H(P) = \ln k$ требует одновременно $r = k$ и равенства в неравенстве Йенсена. Значит, все величины $1/p_j$ одинаковы на всём алфавите, а из нормировки получаем $p_1 = \ldots = p_k = 1/k$. $\square$

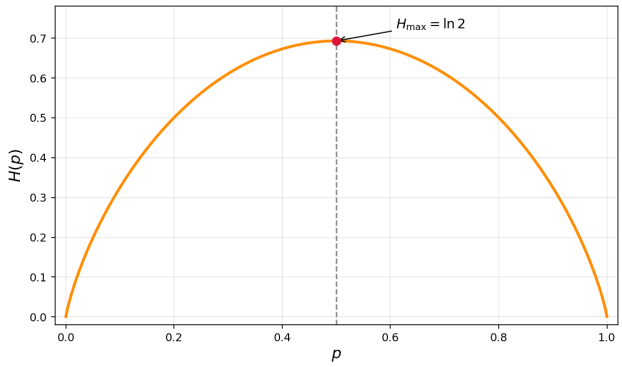

Рисунок 378. Энтропия распределения Бернулли $\mathrm{Bern}(p)$ максимальна при $p = 1/2$ и убывает к нулю при $p \to 0$ или $p \to 1$.

Дифференциальная энтропия

Для непрерывного распределения формула похожа, но её смысл меняется. Пусть P имеет плотность $p(x)$ относительно меры Лебега.

ОПРЕДЕЛЕНИЕ 17.2.2

Дифференциальной энтропией непрерывного распределения P называется величина

$$h(P) = -\int p(x) \ln p(x)\, dx = -\mathbb{E} \ln p(X), \qquad X \sim P.$$

В отличие от дискретной энтропии, дифференциальная энтропия может быть отрицательной и зависит от масштаба измерения. Это не противоречие: плотность не является вероятностью точки, поэтому непрерывная формула уже не равна средней длине кода отдельного исхода.

Нормальное и равномерное распределения

Пример 17.2.2. Если $X \sim \mathcal{N}(\mu, \sigma^2)$, то

$$h(X) = \frac{1}{2} \ln(2\pi e \sigma^2).$$

Сдвиг μ не влияет на энтропию, а увеличение масштаба σ увеличивает её.

Для равномерного распределения $X \sim U[0, a]$ плотность равна $1/a$ на $[0, a]$, поэтому

$$h(X) = -\int_0^a \frac{1}{a} \ln \frac{1}{a}\, dx = \ln a.$$

При $a = 2$ энтропия положительна, а при $a = 0.1$ отрицательна. Знак здесь отражает выбранный масштаб плотности, а не количество дискретных исходов.

Кросс-энтропия

Теперь пусть есть два распределения на одном пространстве исходов. Распределение P будем считать истинным, а Q — модельным. Если данные приходят из P, но для кодирования или штрафа используется Q, средняя цена задаётся кросс-энтропией.

ОПРЕДЕЛЕНИЕ 17.2.3

Для дискретных распределений $P = (p_1, \dots, p_k)$ и $Q = (q_1, \dots, q_k)$ кросс-энтропия равна

$$H(P, Q) = -\sum_{j=1}^{k} p_j \ln q_j.$$

Если P и Q имеют плотности $p(x)$ и $q(x)$ относительно общей меры, то

$$H(P, Q) = -\mathbb{E}_{X \sim P} \ln q(X) = -\int p(x) \ln q(x)\, dx.$$

Модель честной монеты для смещённых данных

Пример 17.2.3. Пусть истинная монета имеет распределение $P = (0.9, 0.1)$, а модель считает её честной: $Q = (0.5, 0.5)$. Тогда

$$H(P, Q) = -0.9 \ln 0.5 - 0.1 \ln 0.5 = \ln 2.$$

Модель платит один бит на бросок, хотя энтропия истинного распределения равна примерно 0.469 бита. Разница появляется из-за того, что код выбран не под то распределение.

Для непрерывного примера пусть $X \sim \mathcal{N}(0, 1)$, а модель использует $Q = \mathcal{N}(a, 1)$. Тогда

$$H(P, Q) = \frac{1}{2} \ln(2\pi) + \frac{1}{2} \mathbb{E}(X - a)^2 = \frac{1}{2} \ln(2\pi) + \frac{1}{2}(1 + a^2).$$

Лишняя цена растёт как $a^2/2$.

KL-дивергенция

Кросс-энтропия включает две части: неизбежную неопределённость самих данных и дополнительную цену неправильной модели. Вторая часть называется KL-дивергенцией.

Перед формальным определением зафиксируем соглашения о нулях. В дискретной сумме член с $p_j = 0$ считается равным нулю, а если $p_j > 0$ и $q_j = 0$, то $\mathrm{KL}(P, Q) = +\infty$: модель Q запрещает исход, который реально возможен при P. В непрерывном случае конечная формула ниже предполагает абсолютную непрерывность P относительно Q; если у P есть масса там, где Q имеет нулевую плотность, дивергенция считается бесконечной.

ОПРЕДЕЛЕНИЕ 17.2.4

Для дискретных распределений P и Q

$$\mathrm{KL}(P, Q) = \sum_{j : p_j > 0} p_j \ln \frac{p_j}{q_j} = H(P, Q) - H(P),$$

если все соответствующие q_j положительны; иначе $\mathrm{KL}(P, Q) = +\infty$. Для распределений с плотностями $p(x)$ и $q(x)$ относительно общей меры

$$\mathrm{KL}(P, Q) = \mathbb{E}_{X \sim P} \ln \frac{p(X)}{q(X)} = \int_{p(x) > 0} p(x) \ln \frac{p(x)}{q(x)}\, dx,$$

если $P \ll Q$; иначе $\mathrm{KL}(P, Q) = +\infty$.

Две цены неверной модели

Пример 17.2.4. Для $P = (0.9, 0.1)$ и $Q = (0.5, 0.5)$ получаем

$$\mathrm{KL}(P, Q) = 0.9 \ln \frac{0.9}{0.5} + 0.1 \ln \frac{0.1}{0.5} \approx 0.368$$

ната. Это средняя переплата за то, что сильно смещённую монету кодируют как честную.

Если $P = (1/2, 1/4, 1/8, 1/8)$, а Q равномерно на четырёх исходах, то

$$\mathrm{KL}(P, Q) = H(P, Q) - H(P) = 2 \text{ бита} - 1.75 \text{ бита} = 0.25 \text{ бита}.$$

Нормальные распределения

Пример 17.2.5. Для $P = \mathcal{N}(0, \sigma^2)$ и $Q = \mathcal{N}(a, \sigma^2)$

$$\mathrm{KL}(P, Q) = \frac{a^2}{2\sigma^2}.$$

Один и тот же сдвиг среднего имеет разную цену при разном масштабе. При $\sigma = 1$ и $a = 1$ цена равна $1/2$, а при $\sigma = 100$ — всего $1/20000$.

Если $P = \mathcal{N}(0, 1)$, $Q = \mathcal{N}(0, 4)$, то

$$\mathrm{KL}(P, Q) = \frac{1}{2}\left(\frac{1}{4} - 1 + \ln 4\right) \approx 0.318.$$

В этом случае модель слишком широко распределяет массу относительно данных из P.

УТВЕРЖДЕНИЕ 17.2.2

Для распределений P и Q, заданных относительно общей меры, выполнено $\mathrm{KL}(P, Q) \geqslant 0$. Равенство возможно тогда и только тогда, когда $P = Q$ почти всюду. При этом KL-дивергенция вообще говоря несимметрична.

Доказательство. Если P не абсолютно непрерывно относительно Q, то $\mathrm{KL}(P, Q) = +\infty$ и неравенство очевидно. Поэтому рассмотрим конечный случай и пусть $X \sim P$. По неравенству Йенсена для вогнутого логарифма

$$-\mathrm{KL}(P, Q) = \mathbb{E}_P \ln \frac{q(X)}{p(X)} \leqslant \ln \mathbb{E}_P \frac{q(X)}{p(X)} = \ln \int_{p(x)>0} q(x)\, dx \leqslant 0.$$

Значит, $\mathrm{KL}(P, Q) \geqslant 0$. Равенство возможно только если $q(X)/p(X)$ постоянно P-почти наверное и при этом Q не имеет массы вне носителя P. Тогда из нормировки плотностей эта константа равна единице, то есть $P = Q$ почти всюду.

Несимметричность видна уже на монетах: для $P = (0.9, 0.1)$ и $Q = (0.5, 0.5)$ имеем $\mathrm{KL}(P, Q) \approx 0.368$, тогда как

$$\mathrm{KL}(Q, P) = \frac{1}{2} \ln \frac{0.5}{0.9} + \frac{1}{2} \ln \frac{0.5}{0.1} \approx 0.511.$$

□

KL-дивергенция не является метрикой: она не обязана быть симметричной и не удовлетворяет неравенству треугольника. Тем не

менее именно она хорошо отвечает на статистический вопрос о цене замены истинного распределения P моделью Q.

3. KL-дивергенция и максимум правдоподобия

Пусть задано параметрическое семейство $\{P_\theta\}$ и выборка $X_1, \dots, X_n$. Обозначим через $\widehat{P}_n$ эмпирическое распределение. В дискретной модели на наблюдаемом алфавите оно кладёт массу $1/n$ в каждое наблюдение. Если $p_\theta(X_i) > 0$ для всех наблюдений, то для фиксированного θ получаем

$$\mathrm{KL}(\widehat{P}_n, P_\theta) = \mathbb{E}_{\widehat{P}_n} \ln \frac{\widehat{p}_n(X)}{p_\theta(X)} = \mathrm{const} - \frac{1}{n} \sum_{i=1}^{n} \ln p_\theta(X_i),$$

где константа не зависит от θ. Поэтому в дискретном случае минимизация $\mathrm{KL}(\widehat{P}_n, P_\theta)$ по θ эквивалентна максимизации логарифмического правдоподобия.

Для непрерывной модели буквальная величина $\mathrm{KL}(\widehat{P}_n, P_\theta)$ обычно бесконечна: эмпирическое распределение дискретно, а P_θ имеет плотность относительно меры Лебега. Но оптимизационный смысл остаётся тем же через эмпирическую кросс-энтропию

$$-\,\mathbb{E}_{\widehat{P}_n} \ln p_\theta(X) = -\frac{1}{n} \sum_{i=1}^{n} \ln p_\theta(X_i).$$

Метод максимального правдоподобия выбирает параметр, который минимизирует эту среднюю логарифмическую цену данных под моделью.

Пример 17.3.1. Пусть наблюдения равны

Шесть бросков монеты

$$1, 0, 1, 1, 0, 1.$$

Эмпирическая вероятность единицы равна $\widehat{p} = 4/6 = 2/3$. Для модели Бернулли с параметром q средний логарифм правдоподобия на одно наблюдение равен

$$\frac{1}{n}\ell(q) = \frac{2}{3}\ln q + \frac{1}{3}\ln(1-q).$$

Сравним несколько значений параметра. В таблице оставим уже посчитанные значения, а полная формула для среднего логарифма правдоподобия записана выше.

q	$n^{-1}\ell(q)$	$\mathrm{KL}(\widehat{P}_n, \mathrm{Bern}(q))$
0.5	$\ln 0.5 \approx -0.693$	≈ 0.057
0.6	≈ -0.646	≈ 0.010
$2/3$	≈ -0.637	0

Максимум правдоподобия достигается при $q = \widehat{p}$, то есть в той же точке, где KL-дивергенция до эмпирического распределения

минимальна.

Та же логика работает для кодирования сообщений. Если в сообщении из шести символов встретились буквы A, A, A, B, C, D, то эмпирическое распределение равно

$$\widehat{P} = (1/2, 1/6, 1/6, 1/6).$$

Равномерная модель платит 2 бита на символ, тогда как

$$H(\widehat{P}) = -\frac{1}{2}\log_2\frac{1}{2} - 3 \cdot \frac{1}{6}\log_2\frac{1}{6} \approx 1.79$$

бита. Разница около 0.21 бита на символ является KL-ценой равномерного предположения.

4. ЛОКАЛЬНАЯ ГЕОМЕТРИЯ И ИНФОРМАЦИЯ ФИШЕРА

Ранее информация Фишера вводилась как характеристика точности оценивания и локальной различимости параметров. Теперь это можно увидеть непосредственно из KL-дивергенции: при малом сдвиге параметра KL имеет квадратичное разложение, и матрица этой квадратичной формы совпадает с информацией Фишера.

Для локальной геометрии нужен объект, который измеряет чувствительность модели к параметру. Пусть $X \sim P_\theta$, а $p_\theta(x)$ — плотность модели.

ОПРЕДЕЛЕНИЕ 17.4.1

Вектор

$$s_\theta(X) = \nabla_\theta \ln p_\theta(X)$$

называется градиентом логарифма плотности. Информацией Фишера одного наблюдения называется матрица

$$i(\theta) = \mathbb{E}_\theta\left[s_\theta(X) s_\theta(X)^\top\right].$$

При регулярных условиях также выполнена эквивалентная формула

$$i(\theta) = -\mathbb{E}_\theta \nabla_\theta^2 \ln p_\theta(X).$$

Первая запись показывает информацию Фишера как дисперсию локального наклона логарифма плотности, а вторая — как среднюю кривизну логарифма правдоподобия. Ниже именно эта матрица появится как квадратичная часть KL-дивергенции между соседними распределениями.

Регулярные условия

Чтобы корректно дифференцировать плотности под знаком интеграла и связывать гессиан логарифма правдоподобия с информацией Фишера, нужны регулярные предположения. В дальнейшей формулировке используются следующие условия.

ОПРЕДЕЛЕНИЕ 17.4.2

Регулярная параметрическая модель

Будем говорить, что в рассматриваемой точке выполнены условия E1–E4, если:

E1. параметр θ лежит во внутренности открытого множества $\Theta \subset \mathbb{R}^d$, а распределения P_θ имеют плотности $p_\theta(x)$ относительно одной общей меры; носитель плотности не зависит от θ;

E2. для почти всех x функция $p_\theta(x)$ дважды непрерывно дифференцируема по θ в окрестности рассматриваемой точки;

E3. дифференцирование можно переносить под знак интеграла, в частности допустимо дифференцировать нормировку $\int p_\theta(x)\,dx = 1$;

E4. градиент логарифма плотности $\nabla_\theta \ln p_\theta(X)$ имеет конечный второй момент, а матрица информации Фишера конечна и невырождена.

Эти условия не являются единственной возможной строгой формулировкой регулярности, но они выделяют необходимые для дальнейшего вычисления свойства: общую меру, гладкость по параметру, допустимость обмена производной и интеграла, а также конечность информации.

Квадратичное разложение KL

УТВЕРЖДЕНИЕ 17.4.1

Если выполнены условия E1–E4, то при $\Delta\theta \to 0$

$$\mathrm{KL}(P_\theta, P_{\theta+\Delta\theta}) = \frac{1}{2}\Delta\theta^\top i(\theta)\Delta\theta + o(\|\Delta\theta\|^2),$$

где $i(\theta)$ — информация Фишера одного наблюдения.

Доказательство. Рассмотрим функцию

$$F(\Delta\theta) = \mathrm{KL}(P_\theta, P_{\theta+\Delta\theta}).$$

В точке $\Delta\theta = 0$ имеем $F(0) = 0$. Так как KL-дивергенция неотрицательна, эта точка является минимумом, и линейный член разложения равен нулю. Поэтому

$$F(\Delta\theta) = \frac{1}{2}\Delta\theta^\top \nabla^2 F(0)\Delta\theta + o(\|\Delta\theta\|^2).$$

При условиях регулярности дифференцирование под интегралом даёт

$$\nabla^2 F(0) = -\mathbb{E}_\theta \nabla^2_\theta \ln p_\theta(X) = i(\theta),$$

где последнее равенство является стандартной регулярной идентичностью для информации Фишера. □

Пример 17.4.1. Пусть $P_a = \mathcal{N}(a, \sigma^2)$, и меняется только среднее a. Тогда

Сдвиг среднего нормального распределения

$$\mathrm{KL}(P_a, P_{a+\Delta a}) = \frac{(\Delta a)^2}{2\sigma^2}.$$

Информация Фишера одного наблюдения по параметру a равна $i(a) = 1/\sigma^2$, поэтому формула из утверждения даёт тот же результат:

$$\frac{1}{2}\Delta a \cdot \frac{1}{\sigma^2} \cdot \Delta a = \frac{(\Delta a)^2}{2\sigma^2}.$$

Если $\sigma = 1$, сдвиг $\Delta a = 1$ стоит 0.5 ната. Если $\sigma = 100$, тот же сдвиг стоит 0.00005 ната. В координатах параметра шаг одинаковый, но в пространстве распределений эти изменения почти несравнимы.

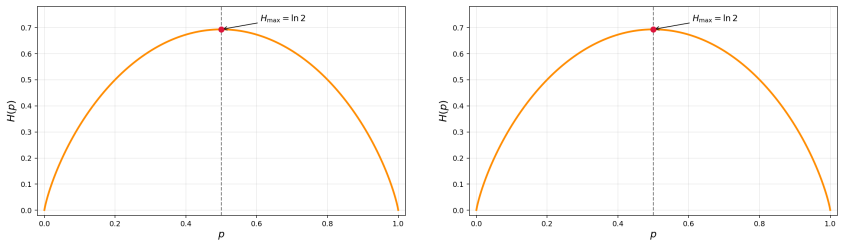

(а) $\sigma = 1$: сдвиг среднего хорошо заметен.

(б) $\sigma = 100$: тот же сдвиг почти не виден.

Рисунок 379. Различимость нормальных распределений при одинаковом сдвиге среднего и разной дисперсии.

5. СМЫСЛ ИНФОРМАЦИИ ФИШЕРА: ЧТО ИМЕННО ОНА ИЗМЕРЯЕТ

Информацию Фишера легко выучить как формулу и при этом не понять её смысл. Её основной смысл такой: информация Фишера говорит, насколько сильно малое изменение параметра меняет всё распределение. Это не мера хаоса в данных и не энтропия распределения. Это локальная чувствительность вероятностной модели к параметру.

Если параметр немного сдвинуть из θ в $\theta + \Delta\theta$, то распределение изменится. KL-дивергенция измеряет цену такого изменения:

$$\mathrm{KL}(P_\theta, P_{\theta+\Delta\theta}).$$

При малом $\Delta\theta$ первая ненулевая часть этой цены квадратична:

$$\mathrm{KL}(P_\theta, P_{\theta+\Delta\theta}) \approx \frac{1}{2}\Delta\theta^\top i(\theta)\Delta\theta.$$

Поэтому информация Фишера играет роль локальной линейки на пространстве распределений. В направлении, где $i(\theta)$ велика, маленький шаг параметра сильно меняет распределение. В направлении, где $i(\theta)$ мала, параметр почти не виден по данным.

Почему это не то же самое, что энтропия

Энтропия описывает само распределение: насколько оно широкое, неопределённое, сколько информации в среднем несёт наблюдение. Информация Фишера описывает не распределение как объект, а влияние параметра на распределение.

Нормальное распределение с известной дисперсией показывает это различие максимально ясно. Пусть

$$X \sim \mathcal{N}(\mu, \sigma^2).$$

Его дифференциальная энтропия равна

$$h(X) = \frac{1}{2}\ln(2\pi e\sigma^2).$$

Она растёт с σ^2 и вообще не зависит от μ. Если шум большой, рас-

пределение шире, а наблюдение менее предсказуемо. Но информация Фишера о среднем равна

$$i(\mu) = \frac{1}{\sigma^2}.$$

Она, наоборот, падает при росте дисперсии. Причина простая: если облако наблюдений очень широкое, малый сдвиг среднего почти не заметен. Распределение обладает большой энтропией, но параметр μ плохо различим.

Ситуация	Энтропия $h(X)$	Информация Фишера $i(\mu)$	Смысл
$\sigma = 1$	меньше	1	сдвиг среднего хорошо виден
$\sigma = 10$	больше	0.01	сдвиг среднего тонет в шуме
$\sigma = 100$	ещё больше	0.0001	одно наблюдение почти ничего не говорит о μ

Именно здесь часто возникает ошибка: большая энтропия не означает большую информацию о параметре. Энтропия отвечает на вопрос “насколько неопределённо само наблюдение?”. Информация Фишера отвечает на вопрос “насколько это наблюдение чувствительно к параметру?”.

Пример Бернулли: одна и та же абсолютная ошибка в разных местах

Пусть $X \sim \mathrm{Bern}(p)$, и параметром является сама вероятность успеха p. Тогда

$$i(p) = \mathbb{E}\left[\left(\frac{\partial}{\partial p} \ln P_p(X)\right)^2\right] = \frac{1}{p(1-p)}.$$

Локально

$$\mathrm{KL}(\mathrm{Bern}(p), \mathrm{Bern}(p+\Delta)) \approx \frac{\Delta^2}{2p(1-p)}.$$

При $p = 1/2$ малый абсолютный сдвиг Δ имеет одну цену, а около границы $p = 0.99$ та же абсолютная прибавка гораздо дороже: вероятность уже почти упёрлась в край допустимого интервала. В координате p модель становится очень чувствительной около границ.

Это не противоречит тому, что энтропия Бернулли около $p = 0.99$ мала. Почти вырожденная монета даёт мало неопределённости в наблюдении, но если мы параметризуем её самой вероятностью p, то абсолютный шаг $p \mapsto p + \Delta$ около границы может сильно менять относительные шансы редкого исхода. Снова видим разные вопросы: энтропия — про неопределённость исхода, информация Фишера — про чувствительность модели к параметру.

Связь с точностью оценивания

Так как информация Фишера измеряет различимость соседних параметров, она связана с тем, насколько точно параметр можно оценить. В одномерном регулярном случае для несмещённых оценок появляется неравенство Крамера–Рао:

$$\mathrm{D}_\theta(\widehat{\theta}) \geqslant \frac{1}{ni(\theta)}.$$

Здесь $ni(\theta)$ — информация всей выборки из n независимых наблюдений. Чем больше информация Фишера, тем меньше нижняя граница на дисперсию оценивания. Это объясняет термин “информация”: данные дают больше информации о параметре, если малые изменения параметра заметно меняют распределение наблюдений.

Поэтому информацию Фишера полезно держать в голове сразу в трёх эквивалентных образах:

1. это дисперсия градиента логарифма плотности $\nabla_\theta \ln p_\theta(X)$;
2. это кривизна KL-дивергенции между соседними распределениями;
3. это локальная мера того, насколько данные способны различать близкие значения параметра.

6. НАТУРАЛЬНЫЙ ГРАДИЕНТ

Обычный градиентный шаг ограничивает длину изменения в координатах параметра:

$$\theta_{t+1} = \theta_t + \eta \nabla_\theta f(\theta_t).$$

Но сами координаты параметра не обязаны отражать близость распределений. Один и тот же сдвиг параметра может почти не менять распределение в одной области модели и сильно менять его в другой. Поэтому вместо евклидовой длины шага естественно ограничивать изменение самого распределения.

Оценивание среднего при разном масштабе

Пример 17.6.1. Пусть оценивается среднее нормального распределения с известной дисперсией. Для данных

$$9, 10, 11, 10, 10$$

имеем $\overline{X} = 10$. Если текущая оценка среднего равна $a_t = 8$, то градиент логарифма правдоподобия по a равен

$$\frac{\partial \ell}{\partial a} = \frac{n(\overline{X} - a_t)}{\sigma^2}.$$

При $\sigma = 1$ он равен 10, а при $\sigma = 10$ равен 0.1. Содержательно задача одна и та же — приблизить a_t к 10, но сырой градиент зависит от масштаба модели.

Натуральный градиент получается из локальной задачи, где мы улучшаем дифференцируемый критерий $F(\theta)$, но ограничиваем не евклидову длину шага, а изменение самого распределения. Обо-

значим $g = \nabla_\theta F(\theta)$. При малом шаге

$$F(\theta + \Delta\theta) - F(\theta) \approx g^\top \Delta\theta, \qquad \mathrm{KL}(P_\theta, P_{\theta+\Delta\theta}) \approx \frac{1}{2}\Delta\theta^\top i(\theta)\Delta\theta.$$

Поэтому локальная задача имеет вид

$$\begin{cases} g^\top \Delta\theta \to \max_{\Delta\theta}, \\ \frac{1}{2}\Delta\theta^\top i(\theta)\Delta\theta \leqslant \varepsilon. \end{cases}$$

Лагранжиан равен $g^\top \Delta\theta - \frac{\lambda}{2}\Delta\theta^\top i(\theta)\Delta\theta$. Условие первого порядка даёт

$$g - \lambda i(\theta)\Delta\theta = 0, \qquad \Delta\theta = \frac{1}{\lambda} i(\theta)^{-1} g.$$

Скаляр $1/\lambda$ затем поглощается в длину шага, поэтому направление натурального градиента равно

$$\Delta\theta \propto i(\theta)^{-1}\nabla F(\theta).$$

ОПРЕДЕЛЕНИЕ 17.6.1

Натуральным градиентом называется вектор

$$\widetilde{\nabla} f(\theta) = i(\theta)^{-1}\nabla f(\theta).$$

Продолжение примера со средним

Пример 17.6.2. Для нормального распределения с известной дисперсией информация Фишера по среднему для всей выборки равна n/σ^2. Поэтому натуральное направление для логарифма правдоподобия пропорционально

$$\left(\frac{n}{\sigma^2}\right)^{-1} \frac{n(\overline{X} - a_t)}{\sigma^2} = \overline{X} - a_t.$$

В рассматриваемых данных это $10 - 8 = 2$ независимо от того, равна дисперсия 1 или 100. Натуральный градиент убирает искусственную зависимость шага от выбранного масштаба.

Дисперсия нормального распределения

Пример 17.6.3. Пусть оценивается дисперсия $S = \sigma^2$, а среднее фиксировано и равно нулю. Для наблюдений

$$-1, 0, 0, 1, 2$$

эмпирическая дисперсия с делением на n равна

$$\widehat{S} = \frac{1}{5}\sum_i X_i^2 = \frac{6}{5} = 1.2.$$

Если текущая оценка $S_t = 4$, то обычный градиент по S равен

$$\frac{\partial \ell}{\partial S} = -\frac{n}{2S_t} + \frac{1}{2S_t^2}\sum_i X_i^2 = -\frac{5}{8} + \frac{6}{32} = -0.4375.$$

Информация Фишера по S для всей выборки равна

$$I(S_t) = \frac{n}{2S_t^2} = \frac{5}{32} = 0.15625.$$

Следовательно, натуральное направление равно

$$I(S_t)^{-1}\frac{\partial \ell}{\partial S} = \frac{32}{5}(-0.4375) = -2.8.$$

Это совпадает с $\widehat{S} - S_t = 1.2 - 4 = -2.8$: шаг направлен к эмпирической дисперсии, а не к произвольному масштабу координаты S.

Логистическая регрессия

Пример 17.6.4. Рассмотрим одномерную логистическую регрессию без свободного члена. Пусть

$$x = (-2, -1, 0, 1, 2), \qquad y = (0, 0, 0, 1, 1).$$

В точке $\theta = 0$ все предсказанные вероятности равны $s_i = 0.5$. Градиент логарифма правдоподобия равен

$$\nabla \ell(0) = \sum_i x_i (y_i - s_i) = 3,$$

а информация Фишера равна

$$I(0) = \sum_i x_i^2 s_i (1 - s_i) = \frac{1}{4}(4 + 1 + 0 + 1 + 4) = 2.5.$$

Натуральное направление равно $I(0)^{-1}\nabla \ell(0) = 3/2.5 = 1.2$. В многомерной логистической регрессии соответствующая матрица имеет вид

$$I(\theta) = X^\top V(\theta) X,$$

где $V(\theta)$ — диагональная матрица с элементами $s_i(1 - s_i)$. Именно эта матрица возникает в ньютоновских и IRLS-методах для обобщённых линейных моделей.

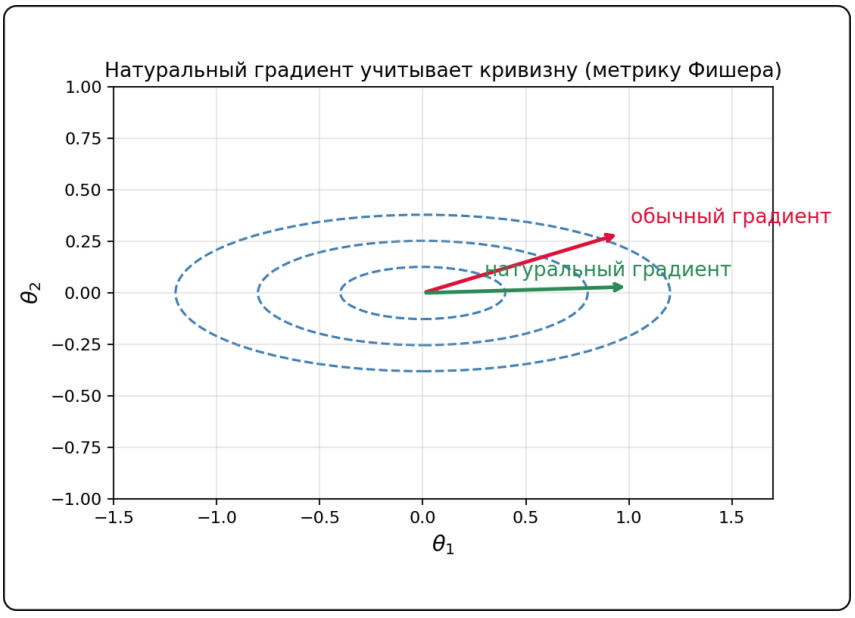

Рисунок 380. Обычный градиент задаёт шаг в координатах параметра, а натуральный градиент учитывает локальную геометрию распределений, задаваемую KL-дивергенцией.

7. ELBO И НИЖНЯЯ ОЦЕНКА ПРАВДОПОДОБИЯ

До сих пор мы говорили о правдоподобии напрямую. Но во многих моделях правдоподобие содержит сумму или интеграл по скрытым переменным и поэтому вычисляется трудно. Пусть наблюдение обозначено через x, скрытая переменная — через z, а совместная модель имеет вид

$$p_\theta(x, z) = p_\theta(x \mid z) p_\theta(z).$$

Тогда маргинальное правдоподобие равно

$$p_\theta(x) = \int p_\theta(x, z)\, dz.$$

Если пространство z большое или модель сложная, этот интеграл может быть недоступен. Идея ELBO состоит в том, чтобы ввести вспомогательное распределение $q(z)$: оно не объявляется истинным, а служит управляемым приближением к апостериорному распределению скрытой переменной. Чем ближе $q(z)$ к настоящему $p_\theta(z \mid x)$, тем теснее нижняя оценка логарифма правдоподобия.

Пусть $q(z)$ положительно там, где $p_\theta(x, z)$ положительно. Тогда

$$\log p_\theta(x) = \log \int q(z) \frac{p_\theta(x, z)}{q(z)}\, dz.$$

Применяя неравенство Йенсена к вогнутому логарифму, получаем

$$\log p_\theta(x) \geqslant \mathbb{E}_q \left[\log \frac{p_\theta(x, z)}{q(z)} \right].$$

Правая часть называется ELBO — нижней оценкой логарифма правдоподобия:

$$\mathrm{ELBO}(q, \theta) = \mathbb{E}_q \log p_\theta(x, z) - \mathbb{E}_q \log q(z).$$

Название подчёркивает, что это нижняя оценка логарифма правдоподобия:

$$\mathrm{ELBO}(q, \theta) \leqslant \log p_\theta(x).$$

У этой формулы есть ещё более важное разложение. Используя апостериорное распределение $p_\theta(z \mid x)$, можно показать, что

$$\log p_\theta(x) = \mathrm{ELBO}(q, \theta) + \mathrm{KL}\big(q(z), p_\theta(z \mid x)\big).$$

Так как KL-дивергенция неотрицательна, ELBO действительно является нижней оценкой логарифма правдоподобия. Если $q(z)$ совпадает с настоящим апостериорным распределением $p_\theta(z \mid x)$, зазор равен нулю и оценка становится точной. Если q выбрано грубо, ELBO остаётся корректной нижней оценкой, но может быть далека от настоящего правдоподобия.

В форме с условной моделью получаем привычную запись

$$\mathrm{ELBO}(q, \theta) = \mathbb{E}_q \log p_\theta(x \mid z) - \mathrm{KL}\big(q(z), p_\theta(z)\big).$$

Первый член требует, чтобы скрытая переменная хорошо объясняла наблюдение x. Второй член штрафует распределение $q(z)$ за отрыв от априорного распределения $p_\theta(z)$.

Смесь распределений и мягкие веса компонент

Пример 17.7.1. Пусть модель является смесью:

$$p_\theta(x) = \sum_{z=1}^{K} \pi_z p_\theta(x \mid z).$$

Для одного наблюдения можно выбрать любое распределение $q(z)$ на компонентах смеси. Тогда

$$\mathrm{ELBO}(q, \theta) = \sum_{z=1}^{K} q(z) \left[\ln \pi_z + \ln p_\theta(x \mid z) - \ln q(z)\right].$$

Если оптимизировать эту величину по q при фиксированных параметрах, получится

$$q(z) = p_\theta(z \mid x) \propto \pi_z p_\theta(x \mid z).$$

Это ровно мягкие веса принадлежности к компонентам в EM-алгоритме.

Численный след помогает увидеть зазор. Пусть для наблюдения x заданы $\pi = (0.7, 0.3)$, $p_\theta(x \mid 1) = 0.2$, $p_\theta(x \mid 2) = 0.6$. Тогда $p_\theta(x) = 0.7 \cdot 0.2 + 0.3 \cdot 0.6 = 0.32$, а оптимальные веса

$$q(1) = \frac{0.14}{0.32} = \frac{7}{16}, \qquad q(2) = \frac{0.18}{0.32} = \frac{9}{16}.$$

При таком выборе q KL-зазор до апостериорного распределения равен нулю, и ELBO совпадает с $\log 0.32 \approx -1.139$. Если выбрать, например, равномерное q, правая часть останется нижней оценкой, но станет меньше настоящего логарифма правдоподобия.

Поэтому EM можно понимать как процедуру, которая по очереди делает нижнюю оценку точной по q при текущих параметрах и затем улучшает параметры модели.

С точки зрения оптимизации после смены знака ELBO превращается в верхнюю оценку отрицательного логарифма правдоподобия:

$$-\mathrm{ELBO}(q, \theta) \geqslant -\log p_\theta(x).$$

Поэтому, если точное правдоподобие недоступно, можно максимизировать ELBO вместо него. Мы не максимизируем настоящее правдоподобие напрямую, но максимизируем его нижнюю оценку. Чем выразительнее семейство распределений q, тем потенциально точнее эта оценка.

Где ELBO появляется в машинном обучении

В машинном обучении ELBO нужен всякий раз, когда модель содержит скрытые переменные, а точное апостериорное распределение вычислять слишком дорого.

- **Вариационные автоэнкодеры (VAE).** В VAE распределение $q_\phi(z \mid x)$ играет роль кодировщика, а $p_\theta(x \mid z)$ — декодиров-

щика. Модель максимизирует ELBO: декодировщик учится восстанавливать объект по скрытому коду, а KL-член удерживает скрытые коды около априорного распределения. После обучения можно случайно выбрать $z \sim p(z)$ и пропустить его через декодировщик, получая новые изображения, тексты или другие объекты.

- **Вероятностный метод главных компонент (PPCA).** Наблюдение задаётся линейной гауссовской моделью со скрытым низкоразмерным z. ELBO и EM дают способ оценивать скрытые координаты и параметры линейного отображения, когда мы интерпретируем PCA как вероятностную модель.
- **Смеси распределений и смесь экспертов.** Скрытая переменная выбирает компоненту или эксперта. Распределение $q_i(z)$ задаёт мягкие веса принадлежности, а ELBO раскладывает обучение на качество объяснения объекта экспертами и энтропийно-KL-часть по скрытому выбору.
- **Иерархические вероятностные модели.** В моделях с локальными и глобальными скрытыми переменными точное апостериорное распределение часто невозможно выписать. Вариационный вывод выбирает семейство q и максимизирует ELBO, чтобы одновременно оценивать скрытые уровни и параметры модели.
- **Тематические модели, байесовские факторизации и модели пространства состояний.** В LDA, байесовской матричной факторизации, скрытых марковских моделях и динамических латентных моделях ELBO позволяет заменить трудную интеграцию по скрытым переменным на оптимизацию по вариационному распределению.

ELBO даёт общий способ превратить трудное обучение по правдоподобию в задачу оптимизации нижней оценки. В этом смысле он продолжает линию всей главы: энтропия измеряет неопределённость, KL измеряет цену несовпадения распределений, информация Фишера описывает локальную геометрию правдоподобия, а ELBO использует энтропию и KL, чтобы обучать сложные вероятностные модели со скрытыми переменными.

8. ЗАКЛЮЧЕНИЕ

Энтропия, кросс-энтропия и KL-дивергенция дают единый язык для вероятностных моделей. Энтропия описывает собственную неопределённость распределения, кросс-энтропия — средний штраф при использовании модели Q на данных из P, а KL-дивергенция выделяет из этого штрафа только лишнюю цену неверной модели.

Через этот язык метод максимального правдоподобия получает геометрическую интерпретацию: он выбирает параметрическое распределение, ближайшее к эмпирическому. При регулярных условиях локальная форма этой близости задаётся информацией Фишера. Поэтому натуральный градиент можно понимать

как градиентный шаг, измеренный не в произвольных координатах параметра, а в локальной геометрии самих распределений.